

RESEARCH ARTICLE

Open Access



SimBoost: 一种跨读方法 利用梯度提升机预测药物与靶点的 结合亲和力

Tong He^{1†}, Marten Heidemeyer^{1†}, Fuqiang Ban², Artem Cherkasov^{2‡} and Martin Ester^{1*‡}

摘要

药物与靶点相互作用的计算预测是药物发现领域的一个长期挑战。针对各种二元药物 - 靶点基准数据集, 已有不少相当准确的预测结果。然而, 二元表示相互作用数据的一个显著缺陷在于, 未相互作用的药物 - 靶点对的缺失终点与无活性情况无法区分, 而且预测的活性水平取决于预先设定的二值化阈值。在本文中, 我们提出了一种名为 *SimBoost* 的方法, 该方法可预测化合物与蛋白质结合亲和力的连续 (非二元) 值, 从而涵盖从真正阴性到真正阳性相互作用的整个相互作用谱。此外, 我们还提出了一种名为 *SimBoostQuant* 的方法版本, 该版本计算预测区间以评估预测亲和力的置信度, 从而明确界定适用性领域指标。我们在两个已建立的药物 - 靶点相互作用基准数据集和一个我们提议用作跨读应用化学信息学基准的新数据集上对 *SimBoost* 和 *SimBoostQuant* 进行了评估。我们证明了我们的方法在所研究的数据集上均优于先前报道的模型。

关键词: 跨读法、梯度提升、药物靶点相互作用、预测区间、适用域、定量构效关系

背景

在药物研发过程中, 找到一种能选择性地与特定蛋白质结合的化合物是一项极具挑战性且通常成本高昂的工作, 超过 90% 的候选化合物因交叉反应性和/或毒性问题而失败。因此, 通过计算方法了解化合物与靶蛋白的相互作用是药物研究中的一个重要课题。这类计算机模拟方法能够通过系统地优先筛选出最有效的化合物来加快实验湿实验室的工作, 并有助于预测其潜在的副作用。

近期的研究[1]表明, 基于机器学习的方法有可能通过从有限的相互作用数据中学习, 并结合化合物之间以及蛋白质之间的相似性信息, 大规模预测化合物与蛋白质之间的相互作用。将药物之间的相似性和靶点之间的相似性纳入考量, 以推断未经测试的药物 - 靶点对之间的相互作用, 这是交叉参照方法[2]的核心所在。用于此类基于机器学习的预测方法的训练和评估的常见数据集是酶、离子通道、核受体和 G 蛋白偶联受体数据集 [3]。这些数据集包含二进制标签: 若药物 - 靶点对 (d_i , t_j) 已知相互作用 (如湿实验室实验所示), 则 $Y_{(i,j)} = 1$; 若已知 (d_i , t_j) 不相互作用或药物 - 靶点对 (d_i , t_j) 的相互作用未知, 则 $Y_{(i,j)} = 0$ 。这些数据集往往倾向于包含被认为更重要或更容易研究的药物和靶点。

*Correspondence: ester@cs.sfu.ca; ester@sfu.ca

[†]Tong He and Marten Heidemeyer contributed equally to this work

[‡]Artem Cherkasov and Martin Ester labs contributed equally to the work

¹School of Computing Science, Simon Fraser University, 8888 University Drive, Burnaby, BC V5A 1S6, Canada

Full list of author information is available at the end of the article

为了进行实验测试。正如[4]中所详述的, 使用此类二元数据集存在两个主要局限性: (1) 真阴性相互作用和缺失值无法区分; (2) 给定的化合物-靶点相互作用被视为二元开/关关系, 尽管使用一个能量化化合物与靶点结合强度的连续值会更具信息量。文献[4]介绍了两个连续相互作用数据集以及连续评估指标 CI, 并提出了一种名为 *KronRLS* 的跨读方法, 用于预测连续结合亲和力。*KronRLS* 中的预测基于每个药物-靶点对的相似性得分, 其中药物-靶点对的相似性通过药物-药物相似性矩阵和靶点-靶点相似性矩阵的克罗内克积来定义。另一种此前已被证明在药物靶点相互作用预测中表现出色方法是矩阵分解 (MF) [5-7], 其最简单的形式仅从给定的结合值中学习预测药物靶点相互作用, 而不引入药物之间和靶点之间的相似性信息。

直观来看, *KronRLS* 和 MF 都存在仅能捕捉训练数据中线性依赖关系的局限性。据我们所知, 文献中尚未提出用于药物-靶点相互作用预测的非线性方法。此外, 我们认为由于训练数据集存在偏差, 有必要为预测结果分配一个置信度分数。正如 [8] 中所强调的, 解决跨读方法预测结果的不确定性问题非常重要, 但此前的方法都忽略了这一需求。

在本文中, 我们提出了一种新颖的非线性方法 *SimBoost*, 用于连续药物-靶点结合亲和力预测, 以及使用分位数回归来估计预测区间以作为置信度度量的 *SimBoostQuant* 版本。给定连续结合亲和力的训练数据集以及药物之间和靶点之间的相似性, *SimBoost* 构建药物、靶点和药物-靶点对的特征, 并使用梯度提升机来预测药物-靶点对的结合亲和力并生成预测区间。除了梯度提升之外, 另一种能够预测某些因变量的值并生成预测区间的非线性方法是随机森林 [9]。我们选择梯度提升而非随机森林有两个原因。首先, 随机森林中的所有树都可以视为同分布的。因此, 如果它们的预测存在偏差, 那么预测的平均值也会存在偏差, 这可能会导致最终结果的准确性降低。其次, 文献[9]中介绍的用于分位数回归的随机森林算法生成的树结构与常规随机森林算法相同,

只是改变了叶节点预测值的生成方式。这意味着这些树并非以适应分位数回归的方式生长。而我们提出的梯度提升方法克服了这两方面的局限性。

梯度提升机在先前的定量构效关系 (QSAR) 研究中已被采用[10, 11]。斯韦特尼克等人[11]将梯度提升机与常用的 QSAR 方法 (如用于化合物的回归和分类问题的支持向量机) 的性能进行了比较。辛格和希卡[10]利用梯度提升机来预测纳米材料的毒性效应。在这两项研究中, 梯度提升机在预测性能、速度和稳健性方面都表现出了良好的效果。与这些先前的研究相比, 我们工作的主要区别在于问题的设定: 在[10, 11]中, 是对单个实体 (纳米材料或化合物) 进行预测, 并且给出了化合物/纳米材料的描述符。而在药物-靶点的设定中, 我们则是对实体对进行预测, 即一种药物和一个靶点。因此, 我们提出了一种新的特征工程步骤, 这是我们的方法在学习和预测阶段所依赖的。

相关工作

传统的药物靶点相互作用预测方法通常专注于特定感兴趣的靶点。这些方法又可以分为基于靶点的方法[12-14]和基于配体的方法[15-18]。在基于靶点的方法中, 根据靶点 (以及化合物) 的三维结构模拟候选化合物与蛋白质靶点的分子对接。这种方法被广泛用于虚拟筛选化合物与靶蛋白的相互作用; 然而, 当靶蛋白的三维结构不可用时 (这种情况经常发生, 尤其是对于 G 蛋白偶联受体和离子通道), 这种方法就不适用了。基于配体的方法的思路是根据已知与靶点相互作用的配体 (化合物) 来建模靶点的共同特征。一个有趣的例子是研究[4], 该研究利用已知药物副作用的相似性来预测新的药物靶点相互作用。然而, 如果蛋白质靶点已知相互作用的配体数量较少, 基于配体的方法可能效果不佳。

为了能在更大范围内实现更高效的预测, 即同时对多个目标进行预测, 并克服传统方法的局限性, 基于机器学习的方法近来备受关注。在化学和生物科学领域, 基于机器学习的方法被称为 (多目标) 定量构效关系 (QSAR) 方法, 该方法将一组预测因子与活性之间的关系联系起来。

将描述药物 - 靶点对的物理化学性质的变量与代表相互作用存在与否或强度的响应变量相关联。

当前的机器学习方法可分为两类, 即基于特征的方法和基于相似性的方法。在基于特征的方法中, 已知的药物 - 靶点相互作用通过将药物的化学描述符与靶点的描述符相结合生成的特征向量来表示[19-23]。以这些特征向量作为输入, 可以使用标准的机器学习方法, 如支持向量机 (SVM)、朴素贝叶斯 (NB) 或神经网络 (NN) 来预测新药物 - 靶点对的相互作用。Vina 等人[24]提出了一种仅考虑靶点序列和药物化学连接性的方法, 但不依赖于几何优化或药物 - 药物和靶点 - 靶点相似性。Cheng 等人[25]引入了一种多靶点 QSAR 方法, 该方法整合了化学子结构和蛋白质序列描述符, 基于从 ChEMBL 数据库中提取的两个综合数据集来预测 G 蛋白偶联受体和激酶的相互作用。梅杰特等人[26]评估了不同的机器学习方法和数据平衡方案, 并报告称随机森林在活性预测方面表现最佳, 并且能够准确推断化合物的选择性。

在基于相似性的方法中[3, 27-32], 会生成药物-药物对和靶点-靶点对的相似性矩阵。可以使用不同类型的相似性度量来生成这些矩阵[33]; 通常, 使用化学结构指纹来计算药物之间的相似性, 使用蛋白质序列比对得分来计算靶点之间的相似性。使用相似性的一种最简单的方法是最近邻分类器[28], 它通过将最相似药物/靶点的相互作用特征加权 (权重由相似性决定) 求和来预测新的相互作用。[27]中提出的核方法利用药物-药物和靶点-靶点的相似性为所有药物-靶点对 (成对核) 计算相似性, 然后使用具有已知标签的药物-靶点对核来训练支持向量机分类器。[28-30]中提出的方法通过二部图来表示药物-靶点相互作用, 如果存在边则将药物-靶点对标记为 +1, 否则标记为 -1。对于每种药物和每个靶点, 分别训练一个支持向量机 (局部模型), 用于预测该药物 (靶点) 与所有靶点 (药物) 的相互作用。这些相似性矩阵被用作支持向量机 (SVM) 的核函数, 对于每一对而言, 最终的预测结果是通过分别对药物支持向量机和靶点支持向量机的得分取平均值来获得的。

上述所有基于机器学习的药物 - 靶点相互作用预测方法都将该任务表述为二分类问题, 其目标是将给定的药物 - 靶点对分类为结合或非结合。正如 [4]

中所指出的, 二分类问题表述的缺点在于无法区分真正的负相互作用和未经测试的药物 - 靶点对, 并且整个相互作用谱 (包括真阳性与真阴性相互作用) 也无法得到很好的覆盖。Pahikkala 等人 [4] 提出了 KronRLS 方法, 该方法可预测连续的药物 - 靶点结合亲和力值。据我们所知, KronRLS 是文献中唯一预测连续结合亲和力的方法, 因此我们在下面对其进行了详细介绍, 因为我们在实验中将其作为基准。此外, 我们还介绍了矩阵分解, 因为它在文献中被用于二分类药物 - 靶点相互作用预测, 并且在我们提出的方法中也起着重要作用。

KronRLS

正则化最小二乘模型 (RLS) 此前已被证明能够高精度地预测二元药物靶点相互作用[31]。在[4]中介绍的 KronRLS 可以被视为这些模型的推广, 用于预测连续结合值。给定一组药物 $\{d_i\}$ 和一组靶点 $\{t_j\}$, 训练数据由一组药物-靶点对 $X = \{x_1, \dots, x_m\}$ (X 是 $\{d_i \times t_j\}$ 的子集) 以及相关的连续结合亲和力向量 $y = y_1, \dots, y_m$ 组成。目标是学习一个预测函数 $f(x)$, 用于所有可能的药物-靶点对 $x \in \{d_i \times t_j\}$, 即一个能最小化目标函数的函数:

$$J(f) = \sum_{i=1}^m (y_i - f(x_i))^2 + \lambda \|f\|_k^2$$

在目标函数中, $\|f\|_k^2$ 表示 f 的范数, 该范数与一个核函数 k 相关联 (如下所述), 而 $\lambda > 0$ 是用户定义的正则化参数。上述目标函数的最小值可表示为

$$f(x) = \sum_{i=1}^m a_i k(x, x_i)$$

核函数 k 是 m 个药物 - 靶点对中任意两个之间的对称相似性度量, 可由 $m \times m$ 矩阵 K 表示。对于药物和靶点各自的两个单独的相似性矩阵 K_d 和 K_t , 每个药物 - 靶点对的相似性矩阵可计算为 $K_d \otimes K_t$, 其中 $\otimes$ 表示克罗内克积。如果训练集 X 包含所有可能的药物 - 靶点对, K 可计算为 $K = K_d \otimes K_t$, 参数向量 a 可通过求解以下线性方程组来学习:

$$(K + \lambda I)a = y$$

其中 I 是 $d_i \times t_j$ 单位矩阵。如果仅将 $\{d_i \times t_j\}$ 的一个子集作为训练数据给出, 向量 y 将会有缺失值。

为了求解参数 a , [4] 建议使用结合克罗内克代数优化的共轭梯度法来求解线性方程组。

矩阵分解

矩阵分解 (MF) 技术已被证明在个性化推荐任务中特别有效[34], 并且此前已被用于药物-靶点相互作用预测[5-7]。在矩阵分解中, 矩阵 $M \in \mathbb{R}^{d \times t}$

(对于药物-靶点预测任务, M 表示 d 种药物与 t 个靶点的结合亲和力矩阵) 通过两个潜在因子矩阵 $P \in \mathbb{R}^{k \times d}$ 和 $Q \in \mathbb{R}^{k \times t}$ 的乘积来近似。

通过最小化在观测到的亲和度集合 κ 上的正则化平方误差来学习因子矩阵 P 和 Q :

$$\min_{Q,P} \sum_{(d_i,t_j) \in \kappa} (m_{ij} - q_i^T p_j)^2 + \lambda(\|p\|^2 + \|q\|^2)$$

术语 $(m_{ij} - q_i^T p_j)^2$ 表示所学参数与观测到的结合亲和力的拟合程度。术语 $(\|p\|^2 + \|q\|^2)$ 对所学参数的大小进行惩罚, 以防止过拟合, 常量 λ 控制这两个项的权重。利用所学矩阵 P 和 Q , 可以计算出所有药物-靶点对的预测矩阵 M' with:

$$M' = P^T Q$$

在 *SimBoost* 中, 因子矩阵 P 和 Q 的列分别被用作药物和靶点特征向量的一部分, 因此矩阵分解被用作特征提取步骤。

方法

问题定义

我们假设输入数据格式为 (M, D, T) , 其中 M 是一个包含连续值的矩阵, 其中 M_{ij} 表示药物 i 与靶点 j 的结合亲和力。 D 是药物的相似性矩阵, T 是靶点的相似性矩阵。具体来说, 我们将 M 的第 i 行定义为 $M_{i,:}$, 将 M 的第 j 列定义为 $M_{:,j}$ 。同样地, 我们将 D 的第 i 行定义为 $D_{i,:}$, 将 T 的第 j 行定义为 $T_{:,j}$ 。 M 中只有部分元素被观测到, 我们的目标是利用给定的信息预测 M 中所有未观测到的值。


SimBoost 和 *SimBoostQuant*

我们提出的方法称为 *SimBoost*, 它为每种药物、每个靶点以及每种药物-靶点对构建特征。这些特征分别代表药物、靶点和药物-靶点对的属性。

SimBoost 为每一对药物和靶点关联一个特征向量。从具有已观测结合亲和力的配对中, 它训练一个梯度提升机模型来学习特征与结合亲和力之间的非线性关系。一旦模型训练完成, *SimBoost* 就可以根据未观测药物-靶点对的已知特征对其结合亲和力进行预测。

我们还提出了一种名为 *Sim-BoostQuant* 的 *SimBoost* 版本, 它通过使用分位数回归来学习给定药物-靶点对的预测区间, 以此作为预测置信度的度量来计算预测的置信度。

图 1 展示了 *SimBoost* 和 *Sim-BoostQuant* 的工作流程, 包括特征工程、梯度提升树和预测区间这三个步骤。下面将对这些步骤进行介绍。



特征工程

我们定义了三种类型的特征来描述药物、靶点以及药物 - 靶点对的属性。
类型 1 特征：我们为每个单独的对象（即药物或靶点）提取特征。

- · 对象在 M 中的观测值数量 (n_{obs})。
- 矩阵 M 中对应行/列的观测值数量。
- · 该对象所有相似度得分的平均值 (ave_{sim})。
- 对于药物 i ，平均值为 $D_{i\cdot}$ 。
- 对于目标 j ，平均值为 $T_{j\cdot}$ 。
- · 物体相似度值的直方图（相似度直方图）。
- 相似值频率的向量，其中分箱的数量是一个输入参数。
- · M 中该对象观测值的平均值 (ave_{val})。
- 对于药物 i ，平均值为 $M_{i\cdot}$ 。
- 对于目标 j ，平均值为 $M_{\cdot j}$ 。

类型 2 特征：我们分别从 D 和 T 中构建两个网络，一个用于药物，另一个用于靶点。节点为药物或靶点，如果两个节点之间的相似度高于用户定义的阈值，则它们之间存在一条边。我们为每个节点定义以下特征。

- · 邻居数量 (num_{nb})
- 节点的 k 个最近邻节点的相似度值 (k_{sim})。
- 节点的 k 个最近邻中类型 1 特征的平均值 ($k_{ave_{feat}}$)，即对来自不同对象的这些向量进行简单平均，从而得到一个长度相同的向量。
- 节点的 k 个最近邻中类型 1 特征的加权平均值（以相似度值为权重） ($k_{w_{ave_{feat}}}$)。
- · 节点的介数中心性、接近中心性和特征向量中心性，如文献[35]中所述 (bt 、 cl 、 ev)。
- · 如文献[36]所述的 PageRank 得分 (pr)。

类型 3 的特征：我们从 M 中构建药物与靶点的网络。节点为药物和靶点，一条边连接一个药物和一个靶点，边的权重为结合亲和力。我们为每个药物 - 靶点对定义以下特征。

- · 矩阵分解 (mf) 得到的潜在向量。

通过矩阵分解 M 获得的药物或靶点的潜在向量。

- · 药物对靶点邻近物（如有）的加权评分 ($d_{t_{ave}}$)。
- 若药物 i 与靶点 j 的邻近靶点存在观测到的亲和力，则取其平均值。
- · 目标与药物邻近物（如有）之间的加权得分平均值 ($t_{d_{ave}}$)。
- 若目标 j 与药物 i 的相邻药物有观测到的亲和力，则取这些值的平均值。
- 节点的中间中心性、接近中心性和特征向量中心性 ($d_{t_{bt}}$ 、 $d_{t_{cl}}$ 、 $d_{t_{ev}}$)。
- · 页面排名得分 ($d_{t_{pr}}$)。

对于每种药物和靶点，我们构建类型 1 和类型 2 特征向量，对于每种药物 - 靶点组合 (d_i, t_j)，我们将 d_i 和 t_j 的类型 1 和类型 2 特征向量以及 (d_i, t_j) 的类型 3 特征向量进行拼接来构建特征向量，如表 1 所示。

梯度提升回归树

为了预测药物 - 靶点对的连续结合亲和力，我们基于特征工程部分定义的特征训练了一个监督学习模型。我们选择梯度提升机作为我们的模型，该模型最初在 [37] 中被提出，原因在于其具有以下优点 [38, 39]：

- · 准确性：提升算法是一种集成模型，它训练一系列“弱学习器”，逐步实现较高的准确性。
- · 效率：训练过程可以并行化，大大缩短了训练时间。

在接下来的内容中，我们将简要介绍此模型的一个变体——梯度提升回归树，我们在方法中使用了该模型。详情请参阅[38, 39]。在常见的监督学习场景中，数据集可以表示为包含 n 个特征向量与标签的配对集合： $D = \{(x_i, y_i)\}$ ($|D| = n$)。在我们的任务背景下， $x_i \in R^d$ 是第 i 个药物-靶点对的特征向量，而 $y_i \in R$ 则是其结合亲和力。在梯度提升回归树模型中，对于输入 x_i 的预测得分 y_i 由以下函数形式给出：

表 1 d_i 、 t_j 特征向量的结构

$d_{i \text{ 第 1 类}}$	$t_{j \text{ 第 1 类}}$	$d_{i \text{ 第 2 类}}$	$t_{j \text{ 第 2 类}}$	$((d_i, t_j) \text{ 的第 3 类型})$
-----------------------	-----------------------	-----------------------	-----------------------	--------------------------------

$$\hat{y}_i = \phi(x_i) = \sum_{k=1}^K f_k(x_i), f_k \in F$$

其中 K 表示回归树的数量, F 表示所有可能的树的集合。为了学习树的集合 $\{f_k\}$, 我们定义了以下正则化目标函数:

$$L(\phi) = \sum_i l(\hat{y}_i, y_i) + \sum_k \Omega(f_k)$$

其中, l 是一个可微的损失函数, 用于评估预测值 $\hat{y}_i$ 与已知结合亲和力 y_i 之间的差异。第二项 Ω 用于衡量模型 (即树的集合) 的复杂度, 以避免过拟合。通过此目标函数, 将选择一组简单且具有预测性的提升树作为最佳模型。

由于该模型将树作为参数, 因此我们无法直接在欧几里得空间中使用传统的优化方法来求解。相反, 我们采用增量式训练模型: 在每次迭代 t 时, 搜索 F 以找到一棵新的树 f_t , 使其优化目标函数, 然后将其添加到集成模型中。形式上, 设 $y_i^{(t)}$

(t) 是

在第 t 次迭代中对第 i 对的预测, 模型找到 f_t 以优化以下目标。

$$\begin{aligned} L^{(t)} &= \sum_{i=1}^n l(y_i, \hat{y}_i^{(t)}) + \sum_{i=1}^t \Omega(f_i) \\ &= \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \sum_{i=1}^t \Omega(f_i) \end{aligned}$$

这一目标意味着模型向集合中添加最佳函数。在一般情况下, 上述目标仍然难以优化, 因此我们使用二阶泰勒展开式来近似该目标。

$$L^{(t)} \simeq \sum_{i=1}^n \left[l(y_i, \hat{y}_i^{(t-1)}) + g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right] + \sum_{i=1}^t \Omega(f_i)$$

其中 $g_i = \partial_{y_i^{(t-1)}} l(y_i, y_i^{(t-1)})$ 且 $h_i = \partial_{y_i^{(t-1)}}^2 l(y_i, y_i^{(t-1)})$ 。

我们可以通过去掉常数项, 在第 t 步得到以下近似目标: $\tilde{L}^{(t)} = \sum_{i=1}^n \left[g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right] + \Omega(f_t)$

梯度提升算法会迭代地添加树, 以针对用户指定的若干次迭代进行优化 $\tilde{L}^{(t)}$ 。通常在连续数据的监督学习任务中, 我们使用平方损失函数 $L = (y - \hat{y})^2$ 来计算误差。该损失函数的一阶和二阶梯度分别为:

$$g_i = 2(\hat{y} - y)$$

$$h_i = 2$$

我们定义 Ω 如下:

$$\Omega(f_t) = \gamma T + \frac{1}{2} \lambda \sum_j w_j^2$$

其中 T 表示树的数量, w_j^2 表示来自 f_t 的第 j 片叶子所对应数据的预测得分, 而 γ 和 λ 则是两个权重参数。

预测区间

我们通过引入分位数回归的概念来扩展梯度提升回归树, 以表征预测的置信度。假设模型能够根据分位数参数 α 预测分位数。为了获得区间, 我们需要训练模型两次, 分别计算 α quantile 分位数和 $(1 - \alpha)$ 分位数, 以得到预测区间的边界。对于结合亲和力的预测, 我们使用区间的中位数。

要进行分位数回归, 我们使用以下损失函数, 而非平方损失函数:

$$l_i = \alpha(y_i - u_i)I_{y_i > u_i} + (1 - \alpha)(y_i - u_i)I_{y_i < u_i}$$

其中, α 是分位数参数, y_i 是真实的结合亲和力, 而 u_i 是预测值。

在梯度提升树的框架内, 新的损失函数可以通过随机梯度下降法进行优化。每个数据样本的梯度为

$$g_i = \alpha I_{y_i > u_i} - (1 - \alpha) I_{y_i < u_i}$$

二阶梯度在此处不适用, 因此我们将其设为 1。

由于我们更关注具有高结合亲和力的药物-靶点对, 因此模型会更重视这些药物-靶点对。为了实现这一点, 我们根据真实亲和力对预测误差进行加权, 即真实亲和力越大, 预测误差的权重就越大。由此得到的损失函数和梯度如下:

$$l_i = y_i[\alpha(y_i - u_i)I_{y_i > u_i} + (1 - \alpha)(y_i - u_i)I_{y_i < u_i}]$$

$$g_i = y_i[\alpha I_{y_i > u_i} - (1 - \alpha) I_{y_i < u_i}]$$

实验

数据

我们对所提出的方法在三个药物-靶点结合亲和力数据集上的性能进行了评估。我们使用了来自 [40, 41] 研究的两个大规模生物化学选择性测定数据集, 这两个数据集已在原始论文 [4] 中用于评估 KronRLS 的性能。这两个数据集

将分别称为戴维斯数据集和梅茨数据集。戴维斯数据集包含了 68 种药物与 442 个靶点的所有配对的结合亲和力和观测值，通过 K_d 值（激酶解离常数）来衡量。梅茨数据集包含 1421 种药物和 156 个靶点，其中 42% 的药物 - 靶点对的结合亲和力以 pK_i 值（对数转换的激酶抑制常数）给出。戴维斯数据集中的 K_d 值被转换为对数空间（即：


$$pK_d = -\log_{10}\left(\frac{K_d}{1e9}\right)$$

戴维斯和梅茨数据集适合用于药物靶点相互作用预测模型的评估，因为数据异质性不是问题。我们可以假定每个数据集对所测药物-靶点对的实验设置相同，且结合亲和力具有可比性。当处理来自多个来源的实验结果时，数据可能会存在异质性：在一种情况下，结合亲和力可能通过 K_i 测量，在另一种情况下通过 K_d 测量，在第三种情况下通过 IC_{50} 测量。数据异质性的另一个来源是不同的实验设置。一种整合不同来源观测结果的方法，名为 *KIBA*，以及相应的数据集在 [42] 中有所介绍。在这项工作中，作者将来自多个数据库的实验结果整合到一个包含 52,498 种化合物和 467 个靶点的生物活性矩阵中，其中包括 246,088 个观测值。该矩阵中的结合亲和力以 *KIBA* 值给出。我们利用该数据集获取了第三个评估数据集，将其称为 *KIBA* 数据集，方法是从原始数据集（从 [42] 的补充材料中下载）中移除所有观测值少于 10 个的药物和靶点，最终得到一个包含 2116 种药物和 229 个靶点的数据集，其密度为 24%。

表 2 三个数据集的统计信息

数据集	药物数量	目标数量	密度 (%)
戴维斯	68	442	100
梅斯	1421	156	42.1
KIBA	2116	229	24.4

在模型评估中，我们还纳入了对药物-靶点配对进行分类的性能评估，使用了 AUC 和 AUPR 这两项指标。在这些实验中，我们使用了通过应用阈值进行二值化的数据集版本，正如 [4] 中所做。对于 *Metz* 数据集，我们采用了 [4] 中建议的阈值 $pK_i \geq 7.6$ ，将标签设为 1，即结合。对于 *Davis* 数据集，我们使用了阈值 $pK_d \geq 7.0$ ，这比 [4] 中建议的阈值稍宽松一些。在 *KIBA* 数据集中，*KIBA* 值越低，结合亲和力越高，[42] 建议使用 *KIBA* 值 ≤ 3.0 的阈值来对数据集进行二值化。在额外的预处理步骤中，我们对 *KIBA* 数据集进行了转换，即对每个值取负，并将所有值加上最小值，以获得一个阈值，使得阈值以上的所有值都被归类为结合。未转换数据集中的 *KIBA* 阈值 3.0 则变为 12.1。表 2 列出了各数据集的大小和密度，图 2 展示了这三个数据集的亲和力值分布情况。在原始的戴维斯数据集中，很大一部分值被标注为 “> 10,000 K_d ”，这意味着在湿实验室实验中未检测到结合亲和力。在预处理后的数据集中，这些值被转换为 “10,000 K_d ($5pK_d$)”，这也就解释了为何在值为 “ $5pK_d$ ” 处会出现较高的柱状图。对于 *Davis* 和 *Metz* 数据集，我们使用的药物-药物和靶点-靶点相似性矩阵是预先计算好的。



此处的药物相似性是基于化合物的二维化学结构, 利用 PubChem 的结构聚类服务器计算得出的。该工具基于结构相似性使用单连接算法对化合物进行聚类[44], 并允许下载包含每对药物相似性的相似性矩阵。靶点相似性是基于蛋白质序列, 使用归一化的 Smith-Waterman 得分计算得出的[3]。对于 KIBA 数据集, 我们通过 PubChem 的化合物聚类工具获取药物相似性矩阵, 正如[4]的作者为 Davis 和 Metz 数据集所做的那样。首先将给定的化合物 ChEMBL ID 与它们的 PubChem CID 进行匹配, 然后将这些 CID 作为输入提供给 PubChem 网页界面。该网络工具允许下载上述化合物的相似性矩阵 (与 Metz 和 David 数据集中的药物相似性计算方式类似)。对于 KIBA 数据集, 我们从 NCBI 下载了蛋白质序列, 并使用 Biostrings R 包对序列进行比对, 计算了每对序列的归一化 Smith Waterman 相似性。

结果

在我们的实验中评估的基准方法是基于连续数据训练的矩阵分解 (简称为 MF), 以及基于连续数据 (简称为连续 KronRLS) 或二值化数据 (简称为二值 KronRLS) 训练的 KronRLS 方法。对于 MF, 我们使用文献 [43] 中描述的 libmf 实现。对于 KronRLS, 我们使用文献 [4] 作者提供的原始代码。

我们还对所提出的两个模型的性能进行了比较。两者的区别在于损失函数, 第一个模型采用常见的平方损失 (SimBoost), 第二个模型采用分位数回归损失 (Sim-BoostQuant)。我们使用 xgboost 库来训练模型 [38]。

我们进行五折交叉验证。为确保每个目标值既用于训练又用于测试, 我们构建折数的方式使得每个目标值在至少两个折中都有观测值。为了测试性能分数的方差, 我们对每个数据集上的每个模型重复进行十次交叉验证, 并报告每个指标的均值和标准差。所使用的评估指标为均方根误差 (RMSE)、曲线下面积 (AUC)、精确率-召回率曲线下面积 (AUPR) 和一致性指数 (CI)。均方根误差是连续预测误差的常用度量。二元度量 AUC 和 AUPR 在药物靶点相互作用预测的相关研究中被广泛

使用, 用于衡量预测的排序误差。AUPR 在这类研究中被广泛采用, 因为它在高度不平衡的数据集中对假阳性预测的惩罚力度更大[45]。一致性指数是针对连续值的排序度量, 由[4]提出。对于一组配对数据, 一致性指数是随机抽取两个具有不同标签值的药物-靶点对, 其预测值排序正确的概率。

KronRLS 通过内部交叉验证步骤确定最优正则化参数, 并选择在期望指标上表现最佳的参数来预测测试折。因此, KronRLS 的预测可能取决于所使用的指标。具体而言, 当应用分类指标 AUC 或 AUPR 时, KronRLS 学习并预测二元标签, 这意味着在训练步骤之前, 数据集会根据截止阈值进行二值化处理。

相比之下, 我们的方法仅预测连续值, 在预测步骤之后应用二值化阈值来计算 AUC 和 AUPR 指标。我们认为, 给定两个模型 A 和 B, 其中模型 A 学习预测连续值, 而模型 B 学习预测二值, 如果模型 A 在 AUC 和 AUPR 方面的表现与模型 B 一样好, 那么模型 A 更具优势, 因为它在数据集阈值发生变化时无需重新训练。为了公平比较, 我们还列出了 KronRLS 在预测连续值并在预测步骤之后应用阈值时的 AUC 和 AUPR 表现。

讨论

关于四个性能指标的结果分别在表 3 (Davis 数据集)、表 4 (Metz 数据集) 和表 5 (KIBA 数据集) 中给出。对于每个指标, 表现最佳的方法的值均以粗体突出显示。

我们观察到, 在所有数据集上, SimBoost 在所有性能指标方面始终优于所有基线。根据 10 次重复实验所得的标准差, 这种改进是显著的 (表 4)。

特别是对于 Davis 数据集, SimBoost 将矩阵分解 (MF) 的均方根误差 (RMSE) 降低了 51%, 并将连续 KronRLS 的平均精度均值 (AUPR) 提高了 12%。对于 Metz 数据集, SimBoost 将矩阵分解 (MF) 的均方根误差 (RMSE) 降低了 45%, 将二元 KronRLS 的平均精度均值 (AUPR) 提高了 11%, 并将矩阵分解 (MF) 的覆盖率 (CI) 提高了 8%。对于 KIBA 数据集, SimBoost 将矩阵分解 (MF) 的均方根误差 (RMSE) 降低了 47%, 将二元 KronRLS 的平均精度均值 (AUPR) 提高了 2%, 并将矩阵分解 (MF) 的覆盖率 (CI) 提高了 7%。

SimBoostQuant 在均方根误差 (RMSE)、曲线下面积 (AUC) 和置信区间 (CI) 方面取得了第二好的成绩。虽然该模型在预测性能方面不如 SimBoost,

表 3 Davis 数据集的结果，为 10 次重复的平均值和标准差

	均方根误差	AUC	AUPR	CI
MF	0.509±0.010	0.876 ± 0.004	0.499±0.017	0.816 ± 0.004
连续 KronRLS	0.608 ± 0.002	0.942 ± 0.001	0.679 ± 0.003	0.860 ± 0.001
二元克朗RLS	–	0.931 ± 0.001	0.686 ± 0.006	–
SimBoost	0.247 ± 0.003	0.956 ± 0.001	0.758 ± 0.005	0.884 ± 0.001
SimBoostQuant	0.36 ± 0.001	0.942 ± 0.002	0.680 ± 0.002	0.871 ± 0.004

表 4 为在梅茨数据集上的结果，给出了 10 次重复实验的平均值和标准差

	均方根误差	AUC	AUPR	CI
MF	0.303±0.005	0.895±0.003	0.358±0.011	0.788 ± 0.001
连续 KronRLS	0.562 ± 0.001	0.943 ± 0.001	0.518 ± 0.003	0.789 ± 0.001
二元克罗内克RLS	–	0.932 ± 0.001	0.565 ± 0.004	–
SimBoost	0.166 ± 0.001	0.958 ± 0.001	0.629 ± 0.003	0.851 ± 0.001
SimBoostQuant	0.249 ± 0.002	0.942 ± 0.002	0.523 ± 0.004	0.813±0.020

表 5 KIBA 数据集的结果，包含 10 次重复实验的平均值和标准差

	均方根误差	AUC	AUPR	CI
MF	0.382 ± 0.003	0.831 ± 0.002	0.631 ± 0.004	0.792 ± 0.001
连续 KronRLS	0.620 ± 0.001	0.884 ± 0.001	0.735 ± 0.001	0.792 ± 0.001
二元克罗内克RLS	–	0.904 ± 0.001	0.7660 ± 0.001	–
SimBoost	0.204 ± 0.001	0.907 ± 0.001	0.782 ± 0.001	0.847 ± 0.001
SimBoostQuant	0.299 ± 0.001	0.875 ± 0.001	0.708 ± 0.002	0.796 ± 0.001

它具有量化预测值置信度的优势。为了更深入地了解 Sim-Boost 的性能,图 3,4 和 5 分别展示了在三个数据集上 Sim-Boost 的预测值与实际值的对比情况。图 6 展示了来自 KIBA 数据集的两个靶点的所有药物的 Sim-BoostQuant 预测区间。最上方的绿点划线对应的是上四分位数，最下方的红虚线对应的是下四分位数。中间的蓝点划线是四分位数的平均值，用作我们的预测值。实线黑线是训练数据集中的真实值。药物名称列在 x 轴上，按照预测值进行了排序。从左至右，两张图中药物的观测数量分别为 37 和 1136，平均区间宽度分别为 1.51 和 0.75。我们观察到，随着观测数量的增加，宽度减小，如图 7 所示。

这是因为通常来说，观测值越多，模型所含的信息也就越多。对于给定的目标，不同化合物的预测区间宽度差异很大，因此在预测亲和力较高的化合物中，我们选择预测区间较窄的那些。图 8 绘制了各特征的相对重要性，这些重要性由 xgboost 软件包计算得出，特征名称如“方法”部分所述。我们注意到，最重要的特征是药物与靶点的平均亲和力以及从矩阵分解中获得的潜在因子。药物/靶点的平均亲和力能够捕捉其典型的结合行为，这对于预测与特定靶点/药物的结合亲和力很有价值。虽然 SimBoost 明显优于矩阵分解，这或许是因为它能够发现非线性关系，但矩阵分解所学习到的潜在因子确实为 SimBoost 提供了重要的特征。




图 3 Davis 数据集上 SimBoost 的预测值与真实值的对比




图 4 SimBoost 预测值与梅斯实际值对比图




图 5 SimBoost 预测值与 KIBA 真实值的对比




图 6 来自 KIBA 的两个目标的预测区间




图 7 KIBA 数据集中观测值数量与预测区间平均宽度之间的关系




图 8 戴维斯的相对特征重要性

结论

现有的大多数化学信息学方法用于预测药物-靶点相互作用时，都是进行二分类，即结合与不结合。在本文中，我们提出了新颖的跨读方法 *SimBoost*，用于预测连续的（而非二元的）药物-靶点结合亲和力。如上所述，连续值能够区分真正的阴性值和缺失值，并提供更多有关蛋白质-化合物结合强度的信息。据我们所知，*SimBoost* 是首个用于连续药物-靶点相互作用预测的非线性方法，也是首个计算预测区间以衡量预测置信度的方法。

在我们的实验中，我们在 Davis, Metz 和 KIBA 数据集上将 *SimBoost* 与 KronRLS（该任务的最新方法）进行了比较。据我们所知，这是首次使用 KIBA 数据集来评估药物-靶点相互作用预测的研究，我们认为由于其异质性和均衡性，该数据集应在未来的研究中用作基准集。

总之，我们的贡献如下：

我们提出了首个用于连续药物-靶点结合亲和力预测的非线性类推方法 *SimBoost*。*SimBoost* 从药物和靶点的相似性以及矩阵分解模型中提取有用特征，并训练梯度提升树模型。

我们提出了一种名为 *SimBoost-Quant* 的 *SimBoost* 版本，该版本在使用相同特征的情况下，不仅能预测结合亲和力，还能预测置信区间作为预测置信度的衡量标准。

我们在三个数据集上进行了大量实验，评估了四项性能指标。结果表明，*SimBoost* 和 *SimBoostQuant* 始终优于最先进的方法。

应当指出的是，尽管 *SimBoost* 是一种更精确的方法，但 *SimBoostQuant* 能提供有关预测置信度的重要信息，从而明确应对适用性领域这一挑战。在我们看来，在这两种方法之间做出选择，本质上是在稍许更精确的预测与稍多一些的信息量之间进行权衡。

作者贡献

ME、AC、TH 和 MH 提出了该研究的构想。TH 和 MH 开发了预测方法。TH、MH 和 FB 准备了数据集，并设计和执行了实验。TH、MH 和 ME 撰写了手稿，AC 和 FB 进行了校对。所有作者都阅读并批准了最终的手稿。

作者详情

¹ 加拿大不列颠哥伦比亚省本拿比市大学路 8888 号西蒙弗雷泽大学计算机科学学院，邮编 V5A 1S6。² 加拿大不列颠哥伦比亚省温哥华市英属哥伦比亚大学温哥华前列腺中心医学院，邮编 V6H 3Z6。

利益冲突

作者声明他们不存在利益冲突。

数据和材料的可用性

支持本文结论的原始数据集可通过以下链接获取：http://staff.cs.utu.fi/~aatapa/data/DrugTarget/known_drug-target_interaction_affinities_pKi_Metz_et_al.2011.txt http://pubs.acs.org/doi/suppl/10.1021/ci400709dci400709d_si_002.xlsx

预处理后的数据、实验代码和详细说明可在以下链接获取：<https://zenodo.org/record/164436>。

资金

作者衷心感谢以下资助来源：加拿大自然科学与工程研究理事会（NSERC）的“Create 计划”项目“用于分析基因组多样性和动态变化的计算方法”（433905-2013），AC 感谢 NSERC 发现研究资助。

出版者按

施普林格·自然对于已发表地图中的司法管辖区主张以及机构归属不持立场。

收稿日期：2016 年 11 月 3 日 接受日期：2017 年 3 月 30 日
Published online: 18 April 2017

参考文献

- Ding H, Takigawa I, Mamitsuka H, Zhu S (2014) Similarity-based machine learning methods for predicting drug-target interactions: a brief review. *Brief Bioinform* 15(5):734–747
- Ball N, Cronin MT, Shen J, Blackburn K, Booth ED, Bouhifd M, Donley E, Egnash L, Hastings C, Juberg DR, Kleensang A (2015) Toward good read-across practice (GRAP) guidance. *Altex* 33(2):149–166
- Yamanishi Y, Araki M, Gutteridge A, Honda W, Kanehisa M (2008) Prediction of drug-target interaction networks from the integration of chemical and genomic spaces. *Bioinformatics* 24(13):232–240
- Pahikkala T, Airola A, Pietila S et al (2015) Toward more realistic drug-target interaction predictions. *Brief Bioinform* 16(2):325–337. doi:10.1093/bib/bbu010
- Liu Y, Wu M, Miao C, Zhao P, Li XL (2016) Neighborhood regularized logistic matrix factorization for drug-target interaction prediction. *PLoS Comput Biol* 12(2):e1004760
- Ezzat A, Zhao P, Wu M et al (2016) Drug-target interaction prediction with graph regularized matrix factorization. *IEEE/ACM Trans Comput Biol Bioinf*. doi:10.1109/tcbb.2016.2530062
- Gonen M, Kaski S (2014) Kernelized Bayesian Matrix Factorization. *IEEE Trans Pattern Anal Mach Intell* 36(10):2047–2060. doi:10.1109/tpami.2014.2313125
- Patlewicz G, Ball N, Becker RA, Booth ED, Cronin MT, Kroese D, Steup D, van Ravenzwaay B, Hartung T (2014) Food for thought: read-across approaches—misconceptions, promises and challenges ahead. *Altern Anim Exp: ALTEX* 31(4):387–396
- Meinshausen N (2006) Quantile regression forests. *J Mach Learn Res* 7:983–999
- Singh K, Shikha G (2014) Nano-QSAR modeling for predicting biological activity of diverse nanomaterials. *RSC Adv* 4(26):13215–13230
- Svetnik V, Wang T, Tong C, Liaw A, Sheridan R, Song Q (2015) Boosting: an ensemble learning tool for compound classification and QSAR modeling. *J Chem Inf Model* 45(3):786–799

12. Morris GM et al (2009) AutoDock4 and AutoDockTools4: automated docking with selective receptor flexibility. *J Comput Chem* 30(16):2785–2791
13. Cheng AC et al (2007) Structure-based maximal affinity model predicts small-molecule druggability. *Nat Biotechnol* 25(1):71–75
14. Rarey M et al (1996) A fast flexible docking method using an incremental construction algorithm. *J Mol Biol* 261(3):470–489
15. Campillos M et al (2008) Drug target identification using side-effect similarity. *Science* 321(5886):263–266
16. Kinnings SL et al (2009) Drug discovery using chemical systems biology: repositioning the safe medicine Comtan to treat multi-drug and extensively drug resistant tuberculosis. *PLoS Comput Biol* 5(7):e1000423
17. Li YY, An J, Jones SJM (2011) A computational approach to finding novel targets for existing drugs. *PLoS Comput Biol* 7(9):e1002139
18. Wang K et al (2013) Prediction of drug–target interactions for drug repositioning only based on genomic expression similarity. *PLoS Comput Biol* 9(11):e1003315
19. Yabuuchi H et al (2011) Analysis of multiple compound–protein interactions reveals novel bioactive molecules. *Mol Syst Biol* 7(1):472
20. Nagamine N, Sakakibara Y (2007) Statistical prediction of protein–chemical interactions based on chemical structure and mass spectrometry data. *Bioinformatics* 23(15):2004–2012
21. Nagamine N et al (2009) Integrating statistical predictions and experimental verifications for enhancing protein–chemical interaction predictions in virtual screening. *PLoS Comput Biol* 5(6):e1000397
22. Schürer SC, Muskul SM (2013) Kinome-wide activity modeling from diverse public high-quality data sets. *J Chem Inf Model* 53(1):27–38
23. Manallack DT et al (2002) Selecting screening candidates for kinase and G protein-coupled receptor targets using neural networks. *J Chem Inf Comput Sci* 42(5):1256–1262
24. Vina D et al (2009) Alignment-free prediction of a drug–target complex network based on parameters of drug connectivity and protein sequence of receptors. *Mol Pharm* 6(3):825–835
25. Cheng F et al (2012) Prediction of chemical–protein interactions: multitarget-QSAR versus computational chemogenomic methods. *Mol Biosyst* 8(9):2373–2384
26. Merget B, Turk S, Eid S et al (2017) Profiling prediction of kinase inhibitors: toward the virtual assay. *J Med Chem* 60(1):474–485. doi:10.1021/acs.jmedchem.6b01611
27. Jacob L, Vert J-P (2008) Protein–ligand interaction prediction: an improved chemogenomics approach. *Bioinformatics* 24(19):2149–2156
28. Bleakley K, Yamanishi Y (2009) Supervised prediction of drug–target interactions using bipartite local models. *Bioinformatics* 25(18):2397–2403
29. Bleakley K, Biau G, Vert J-P (2007) Supervised reconstruction of biological networks with local models. *Bioinformatics* 23(13):i57–i65
30. Mordelet F, Vert J-P (2008) SIRENE: supervised inference of regulatory networks. *Bioinformatics* 24(16):i76–i82
31. Xia Z, Wu L-Y, Zhou X, Wong ST (2010) Semi-supervised drug–protein interaction prediction from heterogeneous biological spaces. *BMC Syst Biol* 4(Suppl 2):S6. doi:10.1186/1752-0509-4-s2-s6
32. van Laarhoven T, Nabuurs SB, Marchiori E (2011) Gaussian interaction profile kernels for predicting drug–target interaction. *Bioinformatics* 27(21):3036–3043
33. Öztürk H, Ozkirimli E, Özgür A (2016) A comparative study of SMILES-based compound similarity functions for drug–target interaction prediction. *BMC Bioinformatics* 17(1):128
34. Koren Y, Bell R, Volinsky C (2009) Matrix factorization techniques for recommender systems. *Computer* 42(8):30–37
35. Newman M (2010) Networks: an introduction. Oxford University Press, Oxford
36. Page L et al (1999) The PageRank citation ranking: bringing order to the web. Stanford InfoLab, Stanford
37. Friedman JH (2001) Greedy function approximation: a gradient boosting machine. *Ann Stat* 1:1189–1232
38. Chen T, He T (2015) Higgs boson discovery with boosted trees. In: Cowan et al (eds) JMLR: workshop and conference proceedings 2015, vol 42, pp 69–80
39. Chen T, Guestrin C (2016) Xgboost: a scalable tree boosting system. arXiv preprint [arXiv:1603.02754](https://arxiv.org/abs/1603.02754)
40. Metz JT, Johnson EF, Soni NB, Merta PJ, Kifle L, Hajduk PJ (2011) Navigating the kinome. *Nat Chem Biol* 7(4):200–202
41. Davis MI, Hunt JP, Herrgard S, Ciceri P, Wodicka LM, Pallares G, Hocker M, Treiber DK, Zarrinkar PP (2011) Comprehensive analysis of kinase inhibitor selectivity. *Nat Biotechnol* 29(11):1046–1051
42. Tang J, Szwarda A, Shakyawar S, Xu T, Hintsanen P, Wennerberg K, Aitokallio T (2014) Making sense of large-scale kinase inhibitor bioactivity data sets: a comparative and integrative analysis. *J Chem Inf Model* 54(3):735–743
43. Chin WS, Yuan BW, Yang MY, Zhuang Y, Juan YC, Lin CJ (2016) LIBMF: a library for parallel matrix factorization in shared-memory systems. *J Mach Learn Res* 17(86):1–5
44. Olson CF (1995) Parallel algorithms for hierarchical clustering. *Parallel Comput* 21(8):1313–1325
45. Yang F, Xu J, Zeng J (2014) Drug–target interaction prediction by integrating chemical, genomic, functional and pharmacological data. In: Pacific symposium on biocomputing. NIH Public Access

Submit your manuscript to a SpringerOpen[®] journal and benefit from:

- Convenient online submission
- Rigorous peer review
- Immediate publication on acceptance
- Open access: articles freely available online
- High visibility within the field
- Retaining the copyright to your article

Submit your next manuscript at ► [springeropen.com](https://www.springeropen.com)