

R-DTI: 基于二阶相关性探索的药物靶点相互作用预测

杨华^{1,2,3}, 徐天阳^(1,2,3), 宋晓宁^(1,2,3*), 冯振华^(1,2,3), 王锐^(1,2,3), 张文杰^(1,2,3), 吴晓军^(1,2,3)

¹江南大学人工智能与计算机科学学院, 江苏无锡

²中国科技部中英人工智能联合实验室

³中国教育部国际人工智能联合实验室

{7211905018; wenjie.zhang}@stu.jiangnan.edu.cn; {tiyang.xu; x.song; fengzhenhua; cs wr; wu _ xiaojun}@jiangnan.edu.cn;

摘要

随着先进的多模态特征提取技术的发展, 药物靶点相互作用 (DTI) 预测的性能有了很大的提高。然而, 现有方法存在两个主要困难。首先, 目前基于蛋白质序列的特征提取器无法很好地表示复杂的蛋白质结构。其次, 蛋白质和药物特征之间的差距增加了分类器的脆弱性, 从而降低了预测的鲁棒性。为了解决这些问题, 我们提出了一种新型 R-DTI 方法, 在蛋白质结构特征提取和 DTI 预测阶段探索二阶相关性。具体来说, 我们构建了一个预先训练好的结构特征提取器, 挖掘每个氨基酸的原子相关性。然后, 对特征间结构保留的黎曼网络进行签名, 以扩展现有的蛋白质提取模式。为了提高预测的鲁棒性, 我们还开发了一种黎曼分类器, 它使用统一特征空间的二阶蛋白质-药物释放。广泛的实验结果证明了我们的 R-DTI 最新技术, 在 BindingDB 和 DrugBank 数据集上的 AUC-ROC 分别高出 1.4% 和 1.9%。

代码 - <https://github.com/JU-HuaY/R-DTI>

导言

药物靶点相互作用 (DTI) 预测对于虚拟药物筛选和加速药物发现流水线至关重要 (Cao 等人, 2012 年; Coelho、Arrais 和 Oliveira, 2016 年)。DTI 预测方法主要是针对分类 (Jacob 和 Vert, 2008 年) 和回归 (Tang 等, 2014 年) 这两个任务设计的, 其目的是定性和量化药物靶点相互作用 (DTI)。

DTI。由于这两项任务都依赖于相似的背骨, 因此基于深度学习的 DTI 预测模型 (Öztürk, Özgür, and Ozkirimli 2018; Lee, Keum, and Nam 2019) 由于其参数容量大, 在这两项任务中都很出色。在

一般来说, 它们的卓越性能取决于两个关键因素: 特征提取和预测表述。

在特征提取方面, 基于深度学习的 DTI 预测模型通常从文本和结构模式中提取蛋白质和药物特征 (Hua, 2023a、

2025)。文本特征提取技术近来发展迅速, 尤其是随着大尺度模型 (LLMs) 的出现 (Elnaggar 等人, 2021 年; Wang 等人, 2019 年), 它可以根据预先训练的模型生成关键语义特征。对于药物结构特征, 许多诱导剂 (Hua 等人, 2023a,b) 可以通过分子分析工具 Rdkit (Landrum 等, 2016 年) 直接将简化分子输入线性输入系统 (Simplified Molecular-Input Line-Entry System, SMILES) 方程转化为图结构特征。然而, 蛋白质结构的复杂性给其表示带来了挑战。如图 1 (a)所示, Lim 等人 (2019 年) 提出了一种图注意算法, 从三维蛋白质结构数据中预测 DTI。然而, 该方法只考虑了少量样本来构建蛋白质结构, 缺乏对不同蛋白质的通用性。Wu 等人 (2024 年) 提出了一种预训练编码器, 首先解决了在没有结构数据的情况下无法提取结构特征的问题。如图 1 (b)所示, 该编码器是基于包含氨基酸接触矩阵的数据集, 通过对比学习进行训练的。然而, 如果没有三维属性和相应的拓扑结构, 接触矩阵不足以代表蛋白质结构特征 (Hua 等, 2024 年)。因此, 如何提高提取的蛋白质结构特征的质量还有待探索。

在预测方面, 现有方法主要依赖于欧氏 DTI 表征分析, 包括药物-目标联合特征 (一阶相关性) 和药物-目标关系特征 (二阶相关性) 两类。这两种类型都存在典型的局限性。如图 1 所示, 一阶相关性预测方法 (Lee、Keum 和 Nam, 2019 年; Abbasi 等, 2020 年) 包含数据驱动的影响因素, 使分类器训练偏向蛋白质特征, 而抑制药物线索。虽然基于二阶相关性预测的 DTI 方法 (Chen 等人, 2020 年; Wu 等人, 2024 年) 能有效解决这一问题, 但它们仍存在两个问题。1) 相关性计算涉及矩阵乘法, 如果蛋白质和药物特征空间不, 就会融合 DTI 特征的语义信息。2) 由于信息密度过大, 二阶相关性不稳定, 对收敛状态提出了挑战。

为了解决这些问题, 我们提出了一种基于二阶相关性探索的新型 R-DTI 框架。对于

*宋晓宁为通讯作者。

版权 © 2025 年, 艺术智能促进协会 (www.aaai.org)。保留所有权利。




图 1: (a)、(b)和(c)显示了三种结构特征提取器。(d)和(e)显示了用于 DTI 预测的一阶和二阶欧氏相关性建模。(f)显示了我们提出的用于 DTI 预测的二阶黎曼相关性建模。

为了提取氨基酸的结构特征，我们根据氨基酸的结构特性和黎曼空间度量设计了一种提取器。具体来说，我们利用原子向量的协方差矩阵来强调氨基酸内部的二阶相关性。同时，为了保留蛋白质中氨基酸之间的拓扑关系，我们考虑了分布在蛋白质流形上氨基酸。在数学上，构建的协方差矩阵恰好位于相应的切线空间上，该空间描述了组成原子的二阶黎曼相关性（Arsigny 等人，2007 年），如图 1 (c)所示。考虑到这一点，我们构建了一个预先训练好的基于序列的提取器，它能从给定的蛋白质结构中学习到足够的先验结构知识。在进行预测时，为了弥补 DTI 特征的学习偏差并稳定学习阶段，我们将 DTI 特征的二阶黎曼相关性用于 DTI 预测。我们首先统一蛋白质和药物特征空间，并将蛋白质和药物特征映射到二阶黎曼 DTI 特征中。然后，我们将 DTI 特征投影到低维空间，以确保其稳定性。最后，利用稳定的 DTI 特征通过线性分类器实现最终预测。

我们在六个基准数据集上对所提出的方法进行了评估。广泛的实验结果表明，我们的 R-DTI 与最先进的方法相比性能更优。此外，我们的可视化研究还证明了利用二阶相关性矩阵来高亮生物分子焦点区域的优点。

总之，R-DTI 的主要贡献包括

- 新颖的 R-DTI 框架首次将黎曼流形引入 DTI 预测，在六个公共数据集上的表现优于一水平。
- 一种新的基于序列的蛋白质结构特征外设，包含先验原子属性和蛋白质拓扑信息。

- 黎曼分类器可补偿 DTI 特征的偏差，从而稳定性能。

相关工作

药物靶点相互作用进展

DTI 预测是一项根据蛋白质和药物的特征来判别它们之间是否存在相互作用的任务。预测算法通常包括三个过程：蛋白质特征提取、药物特征提取和相互作用预测（Hua 等，2023b）。在初级研究阶段，Yamanishi 等人（2008 年）使用手工制作的特征进行蛋白质和药物特征工程，然后使用浅层机器学习解决方案进行 DTI 预测。传统方法以严格的理论推导为基础，因此在表示和预测分析方面都具有极佳的可解释性。然而，浅层方法受限于其模型容量和硬件限制。

随着计算设备和深度学习方法的发展（Song 等人，2024 年），许多先进的 DTI 预测方法，如 DeepDTA（Öztürk, Özgür, and... Ozkirimli, 2018 年）和 HADTI（Zhao 等，2022 年）受到广泛关注。这些方法展示了在构建具有大量参数的模型时实现高精度 DTI 预测的潜力。然而，这些深度方法在特征提取和决策制定方面都处于黑箱状态。因此，由于缺乏可理解的理论依据，对其优势的解解释变得更加复杂。

黎曼网络技术

深度神经网络已在许多人工智能任务中显示出其优势（徐、朱和吴，2023 年；唐、王和胡，2023 年）。在密集欧几里得空间中分层获得的特征图是最重要的组成部分。然而，由坐标定义的实际数据特征遵循

非欧几里得几何 (Huang 和 Van Gool, 2017 年)。为了解决这些非欧几里得特征, Helgason (1965 年) 首先提出了非欧几里得域上的局部大地卷积概念, 以提取形状流形上的局部斑块。在此基础上, Huang 和 Van Gool (2017 年) 开发了对称正定 (SPD) 流形, 并提出了由 BiMap 和 ReEig 组成的 SPDNet。

这些组件分别受到欧氏线性层和 ReLU 层的启发。

鉴于其固有的低维度建模能力, 黎曼 SPD 流形已成功应用于

生物领域。为了更好地学习原蛋白的表示方法, Detlefsen、Hauberg 和 Boomsma (2022 年) 开发了一种新的原蛋白表示方法。合适的黎曼度量, 对应于沿流形整合的一热编码蛋白质之间的测地线间距。此外, Wang 等人 (2022 年) 提出了一个单值分子表征学习框架, 在二维黎曼流形上提供分子地理计量和化学特征的多分辨率表征。这些研究探讨了在黎曼流形上建立生物信息学网络模型的可行性。

拟议的 R-DTI 方法

拟议的 R-DTI 包含三个部分, 两个特征提取器, 分别对蛋白质和药物数据进行编码, 以及用于最终预测的黎曼分类器。

多模式蛋白质特征提取器

我们使用预先训练好的提取器从蛋白质序列中提取文本和结构特征, 如图 2 所示。

首先, Prot-Bert (Elnaggar et al.

模型 (LLM) 和 DenseNet (Hua 等人, 2023b) 来依次表示和提取蛋白质文本特征、

$\mathbf{F}_p^t \in \mathbb{R}^{L_p \times C_t}$, 其中 L_p 和 C_t 是序列长度, F_t 是序列长度。文本特征通道。然后, 我们预先训练

基于序列的提取器可以补充蛋白质结构信息。具体来说, 我们使用基于结构的提取器和包含蛋白质序列和经过验证的三维结构的三维 PDB 数据 (Berman 人, 2000 年) 来提取蛋白质的结构信息。

为基于序列的提取器提供动力。为了对齐三维结构

在此基础上, 我们将三维数据与序列进行重写。集, $\{(\mathbf{P}_i^a, \mathbf{c}_i^a)\}_{i=1}^K$, 到氨基酸集, $\{(\mathbf{P}_i, \mathbf{c}_i)\}_{i=1}^K$, 其中 K

$\mathbf{p}_i$ 和 $\mathbf{c}_i^a$ 是第 i 个原子的属性矢量及其共同属性矢量。

秩, $\mathbf{P}_i$ 和 $\mathbf{c}_i$ 是第 i 个氨基酸的属性矩阵及其坐标, N 和 K 分别是原子和氨基酸的编号。具体来说, $\mathbf{P}(i)$ 的协方差为

原子属性向量 $\{\mathbf{p}_i^a, \dots, \mathbf{p}_i^a\} \in \mathbb{R}_0^{C_a \times (N_i/a)}$, 用于作为氨基酸属性, $\mathbf{P}_i \in \mathbb{R}^{(C_a) \times (C_i)}$, 其中 C_i 是指

是原子属性向量的长度, N_i

第 i 个氨基酸的原子数。根据设计, 氨基酸的参数是 SPD 矩阵, 其中包含二阶 Ric-

无论输入维度的多样性如何, 所有原子的甘露相关性都是一样的。然后对这些 SPD 矩阵进行处理通过 SPDNet, 实现了黎曼维度压缩

和非线性映射。此外, 我们还将氨基酸所有原子坐标的中心点记录为其坐标、

$\mathbf{c}_i \in \mathbb{R}^3$, 并将所有氨基酸坐标与其

作为氨基酸组的特性, $\{(\mathbf{P}, \mathbf{c})\}_{i=1}^K$ 。接下来, 亲

通过基于结构的提取器, 从改写后的三维数据中提取出蛋白质结构隐藏特征。

基于结构的提取器是基于 SPD-GNN 模块构建。在 SPD-GNN 模块的 l 层, 我们根据已知的氨基酸坐标, 将蛋白质动态地构建为 K-Nearest Neighbors (KNN) 图。 $\mathbf{P}^l$ 按以下方式交替更新:

$$\mathbf{m}_{i,j} = \mathbf{W}_c \begin{pmatrix} \mathbf{P} \\ \mathbf{P}^{(l)} \mathbf{W}^{(T)} \end{pmatrix} \mathbf{e} \quad \mathbf{m}_i = \sum_{j \in N_i} \mathbf{m}_{i,j}, \quad (1)$$

$$\mathbf{P}_i^{l+1} = f^l(\mathbf{W}_r \mathbf{P}_i^l, \mathbf{P}_i^l, \mathbf{W}_p^{(T)} \mathbf{P}_i^l, \mathbf{m}_i), \quad (2)$$

其中 $\mathbf{W}_c \in \mathbb{R}^{(C_a) \times (2)(C_i)}$ 和 $\mathbf{W}_r \in \mathbb{R}^{(C_a) \times (2)(C_i)}$ 是跨形成矩阵, f^l 是 ReEig 层, 它引入了 $\mathbf{m}_{i,j}$ 是基于 KNN 生成的边缘 $e_{i,j}$ 两端氨基酸的关联信息。我们使用多重 SPD-GNN 层来获取结构隐藏特征, 并将其作为伪标签来训练基于序列的提取器。同时, 我们在基于序列的提取器中嵌入蛋白质序列, 并通过 DenseNet 提取文本特征。然后, 我们使用 SPDNet 压缩文本特征的共方差, 作为所需的隐藏特征 $\mathbf{F}_{p0}^t, \dots, \mathbf{F}_{pN}^t$ 与结构隐藏特征 $\mathbf{F}_{s0}^t, \dots, \mathbf{F}_{sN}^t$ 对齐。此外, 我们还设计了一个基于变换器的重构器, 根据隐藏特征预测每个氨基酸的坐标, 进一步增强其结构信息。然后将提取的结构隐藏特征映射到欧几里得空间, 并将其

$$\mathbf{F} = \left\{ \begin{matrix} \mathbf{F}_p \\ \mathbf{F}_s \end{matrix} \right\}$$

维数简化为矢量形式, 即 $\mathbf{F}^s$

$$\in \mathbb{R}^{L_p \times C_s}$$

最后, 我们将它们与文本特征 $\mathbf{F}^t$ 合并, 得到最终的多模式蛋白质特征 $\mathbf{F}_p \in \mathbb{R}^{(L_p) \times (C_t + (C_i)0)}$ 。

多模式药物特征提取器

与蛋白质类似, 我们用两种方式表示药物, 即文本特征和结构特征。在文本特征提取方面, 我们使用基于 LLM 的 Smiles-Bert (Wang 等人, 2019 年) 来表示药物 SMILES。然后, 药物文本特征、

$\mathbf{F}_d^t \in \mathbb{R}^{(L_d) \times (C_d)}$, 可由 DenseNet (Hua 等, 2023b) 从这些表征中提取。对于结构特征的提取我们用分子图来表示 SMILES、

包含原子矢量 $\mathbf{F}_d \in \mathbb{R}^{N \times C_a}$ 和

ency 矩阵, $\mathbf{A} \in \mathbb{R}^{(N) \times (N)}$, 使用 Rdkit 工具 (Landrum 人, 2016 年)。然后, 从以下数据中提取结构特征我们提出的分子图 At-

M-GAT 模块的表述如下

$$\mathbf{W}_a = \sigma(\psi(\mathbf{F}_{(d)}) \psi(\mathbf{F}_d)) \quad (3)$$

$$\mathbf{F}_d^{s,l+1} = (\mathbf{A} * \mathbf{W}_a) \psi(\mathbf{F}_d^{s,l}) + \mathbf{F}_d^{s,l} \quad (4)$$

其中 $\mathbf{W}_a \in \mathbb{R}^{(N) \times (N)}$ 是原子相关性矩阵, $\sigma()$

和 $\psi()$ 分别为 sigmoid 层和线性层。然后, 我们将

结构特征, $\mathbf{F}^s \in \mathbb{R}^{L_d \times C_s}$, 以及文本、

并通过交叉注意区块在它们之间建立联系, 交叉注意区块的表述如下

$$\mathbf{F}_d^s = \text{softmax} \left(\frac{\psi(\mathbf{F}_d^t) \psi(\mathbf{F}_d^s)^T}{d \sqrt{C_s}} \right) \psi(\mathbf{F}_d^s) + \mathbf{F}_d^s \quad (5)$$




图 2: R-DTI 概述: (a) 基于序列的结构特征提取器的预训练过程; (b) 药物-靶标相互作用预测流水线。

最后，我们将更新后的结构特征与文字特征相结合，作为最终的药物特征，即 $\mathbf{F}_d \in \mathbb{R}^{(L_d) \times (C_d + C_s)}$ 。

黎曼分类器

在结合蛋白质和药物特征之前，我们提出了一种新方法统一它们的特征空间。如图 1 (f) 所示，我们将蛋白质和药物特征嵌入一个新的特征空间 V 中，它们遵循严格的正交性。然后，我们将蛋白质和药物特征串联起来，映射到一个统一的空间中，这个过程可以是

可表述如下

$$\mathbf{F}_{joint} = \psi \left(\begin{bmatrix} \mathbf{F}_p \\ \mathbf{0} \\ \mathbf{F}_d \end{bmatrix} \right), \quad (6)$$

其中， $\mathbf{F}_{joint} \in \mathbb{R}^{L_j \times C_j}$ 是联合特征， L_j 和 C_j 是联合特征。分别是其长度和通道。 $\psi()$ 是

通过线性层和 GELU 层进行处理。然后，我们计算联合特征在其两个维度上的协方差矩阵，作为其黎曼特征、基于通道的

$\mathbf{F}_{r,c} \in \mathbb{R}^{C_j \times C_j}$ 和基于长度的 $\mathbf{F}_{p,l} \in \mathbb{R}^{L_j \times L_j}$ 。

为了将这些黎曼特征压缩成一个稳定的结构，我们需要我们使用由 BiMap、ReEig 和 LogEig 层组成的 SPDNet 来增强与 DTI 预测最相关的内形成。附录 A 介绍了 SPDNet 的三个层。压缩特征上三角的元素被转换成向量，作为蛋白质-药物配对的交互特征。最后，我们通过多层感知器 (MLP) 层根据这些交互特征预测 DTI。需要注意的是，虽然黎曼特征包含样本对的二阶相关性，有利于 DTI 预测，但相关性计算会使梯度计算复杂化，妨碍特征提取器的训练。因此，我们提出了一种由 1D 对话层和 MLP 层组成的辅助分类器，直接将语义信息反馈给上述两种多模式特征提取器，如图 2 所示。通过设计，提取的特征是

这进一步提高了 R-DTI 的性能。我们的损失函数、超参数设置和测量指标见附录 B。

评估

评估数据集

我们在六个数据集上对所提出的方法进行了评估，其中包括四个经典的 DTI 基准数据集：Human、C.elegans (Tsubaki、Tomii 和 Sese, 2019 年)、BindingDB (Chen, 2020 年)、Drug-Bank (Zhao 等, 2022 年)，以及两个 DTA 数据集：Davi 和 KIBA (Davis 等, 2011 年)。附录 C 列出了这六个数据集的统计数据，其基本信息如下如图 3 所示。具体来说，图 3 (a) 显示了一个常见的问题，即蛋白质的长度远长于图 3 (b)。

而不是药物分子。图 3 (b) 显示了六个数据集的阳性和阴性样本数量。图 3 (c) 显示了两个 DTI 数据集的亲和力标签分布。为了评估 DTI 预判定模型在标签不平衡时的准确性，我们将两个 DTA 数据集重建为二元分类数据集。与 (Zhao 等, 2022 年) 一致，我们将阈值设为 5.0 和 5.0。

戴维斯数据集和 KIBA 数据集分别为 12.1。此外，为了评估 DTI 模型的泛化能力，我们将 BindingDB (Chen 等, 2020 年) 的测试数据分成三个子集，即未见药物、未见目标和未见配对。正负样本的数量如图 3 (d) 所示。

与最新技术的比较

我们将所提出的 R-DTI 方法与最先进的 DTI 预测模型进行了比较，包括 TransformerCPI (陈等人, 2020 年)、HADTI (赵人, 2022 年)、CPInformer (华等, 2023 年 b)、TriMulDTI (德汉等人, 2023 年)、MFR-DTA (华等人, 2023 年 a) 和 PSC-CPI (吴等, 2024 年)。我们在表 1 中报告了四个经典 DTI 基准的实验结果 (以 AUC-ROC 和 AUC-PR 度量)。所提出的 R-DTI 方法在大多数指标上都优于所有其他方法，特别是在 BindingDB 和 Drug-




图 3：数据集信息：（a）原蛋白和药物的平均长度；（b）阳性和阴性样本的数量；（c）Davis 和 KIBA 中亲和力得分的分布；（d）BindingDB 中三个子集的阳性和阴性样本的数量。

库数据集。从图 3 (b)可以看出，BindingDB 和 DrugBank 数据集的质量更高，数据量更大，标签更均衡，更适合评估 DTI 模型的整体性能。具体来说，在 BindingDB 中，与排名第二的 PSC-CPI 相比，所提出的 R-DTI 方法在 AUC-ROC 和 AUC-PR 方面的性能分别提高了 1.4% 和 1.0%。同时，在 DrugBank 中，我们方法的 AUC-ROC 和 AUC-PR 分别比 PSC-CPI 高出 1.9% 和 1.5%，证明了 R-DTI 的优越性。在小样本数据集（人类和优雅小鼠）中，R-DTI 模型的优越性能保持稳定。

为了评估泛化效果，我们在图 4 中展示了最先进方法在 BindingDB 三个测试子集中的表现，包括未见药物、未见焦油和未见配对。我们发现，大多数方法在“未见目标”子集中的表现都比在“未见药物”子集中的表现差，这表明它们学习到的参数在一定程度上偏向于蛋白质。然而，使用黎曼 SPD 特征（即蛋白质和药物联合特征的协方差矩阵）的 R-DTI 可以有效提高其在未见目标子集中的泛化能力。此外，Unseen 配对子集是最困难的子集，但 R-DTI 模型在 AUC-ROC 和 AUC-PR 方面都有不俗表现，与排名第二的 PSC-CPI 相比，性能提高了 1.2%。对于戴维斯和 KIBA 这两个 DTA 数据集，我们通过交互作用（以 AUC-ROC 和 AUC-PR 衡量）和亲和力预测（以 CI 和 MSE 衡量）这两个任务来评估前两种方法，并在表 2 中报告了结果。这两个数据集的标签分布都是不平衡的，因此可以有效地用于评估模型在两个任务中的鲁棒性。




图 4：与 BindingDB 中未见药物、目标和配对设置的最先进方法比较。

在处理标签不平衡分类和长尾回归任务时，所有方法的 AUC-PR 都不尽如人意。表 2 显示，这两个数据集上，所有方法的 AUC-PR 都无法达到令人满意的性能，这也证实了上述观点。不过，R-DTI 模型在这些指标上的表现相对稳健，进一步证明了它的。此外，我们提出的方法在亲和预测任务中也表现出色，它在两个 DTA 数据集上的 CI 和 MSE 都达到了最佳结果，验证了它在长尾回归任务中的鲁棒性。

消融研究与讨论

成分分析 R-DTI 模型是我们新开发的框架，不依赖任何现有的基线方法。因此，我们构建了一个基本的 DTI 预测架构作为基线（模型-1），以评估在两个经典 DTI 基准（BindingDB 和 DrugBank）上的创新。具体来说，基线由蛋白质纹理特征提取器和完整的多模式药物特征提取器组成，并对蛋白质和药物特征进行联合提取。在此基础上，辅助分类器用于预测 DTI。我们在第 3 章中报告了采用不同配置的新型组件的模型结果。很明显，添加了蛋白质结构特征的模型-2 在两个数据集上的表现都优于模型-1，这说明了所提出的提取器的有效性。模型 3 和模型-4 分别显示了仅使用特征联合块或基于模型-2 的黎曼分类器的结果，两者都显示了一定的性能改进，体现了两个组件的优势。不过，我们注意到，两个组件的组合，即模型-5，在两个数据集上的准确率都有很大提高。这一改进在很大程度上证实了当蛋白质和药物的特征空间不一致时，黎曼分类器的性能是有限的，分类器的卓越能力取决于特征联合块。我们还测试了仅使用一般药物和蛋白质特征作为模型-6 的黎曼分类器，结果表明

方法	绑定数据库		药物库		人类		C.elegans	
	AUC-ROC↑	AUC-PR↑	AUC-ROC↑	AUC-PR↑	AUC-ROC↑	AUC-PR↑	AUC-ROC↑	AUC-PR↑
TransformerCPI	0.951±0.003	0.949±0.004	0.837±0.003	0.836±0.002	0.973±0.002	0.979±0.002	0.988±0.002	0.987±0.001
哈迪	0.956±0.003	0.951±0.004	0.889±0.001	0.897±0.001	0.978±0.002	0.980±0.003	0.985±0.003	0.987±0.003
CPIInformer	0.965±0.002	0.966±0.003	0.887±0.002	0.891±0.002	0.985±0.003	0.989±0.002	0.991±0.002	0.992±0.001
TriMulDTI	0.963±0.003	0.967±0.002	0.895±0.002	0.897±0.003	0.985±0.003	0.986±0.002	0.986±0.003	0.988±0.002
MFR-DTA	0.962±0.002	0.959±0.003	0.893±0.002	0.891±0.002	0.986±0.003	0.983±0.002	0.988±0.002	0.985±0.001
PSC-CPI	0.969±0.001	0.972±0.002	0.895±0.001	0.897±0.001	0.988±0.002	0.993±0.002	0.993±0.001	0.992±0.001
R-DTI	0.983±0.001	0.982±0.002	0.914±0.001	0.912±0.001	0.991±0.001	0.992±0.003	0.996±0.001	0.996±0.001

表 1：在四个经典 DTI 基准上与 SOTA 方法在 AUC-ROC 和 AUC-PR 方面的比较。

方法	戴维斯 (互动)		戴维斯 (亲和力)		KIBA (互动)		KIBA (亲和力)	
	AUC-ROC↑	AUC-PR↑	CI↑	MSE↓	AUC-ROC↑	AUC-PR↑	CI↑	MSE↓
TransformerCPI	0.878±0.001	0.767±0.002	0.859±0.003	0.286±0.002	0.900±0.001	0.785±0.002	0.859±0.002	0.203±0.002
哈迪	0.920±0.002	0.838±0.002	0.876±0.001	0.279±0.001	0.916±0.001	0.799±0.002	0.871±0.003	0.191±0.003
CPIInformer	0.921±0.001	0.833±0.003	0.874±0.002	0.277±0.002	0.923±0.002	0.814±0.001	0.867±0.003	0.183±0.001
TriMulDTI	0.924±0.002	0.847±0.001	0.896±0.002	0.229±0.003	0.927±0.002	0.814±0.003	0.893±0.003	0.145±0.002
MFR-DTA	0.926±0.003	0.845±0.002	0.905±0.001	0.221±0.001	0.928±0.001	0.816±0.002	0.898±0.002	0.136±0.001
PSC-CPI	0.929±0.002	0.850±0.002	0.903±0.001	0.217±0.001	0.936±0.001	0.824±0.001	0.901±0.001	0.139±0.001
R-DTI	0.937±0.001	0.868±0.002	0.911±0.001	0.212±0.001	0.935±0.001	0.830±0.002	0.906±0.001	0.127±0.001

表 2：戴维斯模型和 KIBA 模型的 AUC-ROC、AUC-PR、CI 和 MSE 与最先进模型的比较。

模型	蛋白质结构	特征联合	黎曼	辅助	BindingDB		药物库	
	特征提取器	区块	分类器	分类器	AUC-ROC↑	AUC-PR↑	AUC-ROC↑	AUC-PR↑
模型-1	✗	✗	✗	✓	0.952±0.003	0.950±0.004	0.857±0.004	0.855±0.003
模型-2	✓	✗	✗	✓	0.960±0.002	0.961±0.002	0.871±0.003	0.873±0.003
模型-3	✓	✓	✗	✓	0.965±0.001	0.968±0.002	0.883±0.001	0.886±0.001
模型-4	✓	✗	✓	✗	0.963±0.001	0.967±0.002	0.884±0.001	0.885±0.001
模型-5	✓	✓	✓	✗	0.977±0.001	0.979±0.002	0.906±0.001	0.908±0.001
模型-6	✗	✓	✓	✗	0.962±0.002	0.963±0.002	0.891±0.001	0.894±0.001
R-DTI	✓	✓	✓	✓	0.983±0.001	0.982±0.002	0.914±0.001	0.912±0.001

表 3：BindingDB 和 DrugBank 上以 AUC-ROC 和 AUC-PR 表示的消融研究结果。

它适用于一般情况。尽管黎曼分类器的预测性能较好，但二阶相关性计算的梯度计算复杂，影响了其上游特征提取器的参数优化。因此，我们引入了一个辅助分类器来帮助训练特征提取器，最终得到的模型，*w*/R-DTI 达到了最佳性能。

蛋白质结构特征提取分析 为了证明黎曼网络提取蛋白质隐藏结构特征的有效性，我们比较了图 5 (a) 中提取特征的分布情况。我们首先根据三维结构描述将训练过程中未涉及的蛋白质样本聚类为四类，即 $P^a = \{(\mathbf{p}^a, \mathbf{c}^{(a)})\}$ 。这四种颜色表示不同的蛋白质来分析相应特征的分布。显然，由于初始序列嵌入缺乏结构信息，序列表示是无序的。ⁱ⁼¹为了补充这些信息

通过对比学习和重构学习，我们训练了基于序列的特征提取器，并将隐藏特征划分为欧氏和黎曼 SPD 两个空间。

黎曼 SPD 特征由上述预先训练好的提取器提取，欧氏特征由类似的提取器提取，后者使用零填充使氨基酸结构表征等长。图 5 (a) 显示，这两种方法都能帮助基于序列提取器学习结构形成。然而，欧氏隐性特征散点图会被原始结构特征轻微扭曲，也就是说，当原蛋白特征被欧氏提取器转换后，结构信息会出现偏差。相比之下，黎曼 SPD 隐藏特征与结构特征的分布更为一致。在这种情况下拟议的预训练提取器使用原子矢量的二阶释放来表示氨基酸，从而将表示压缩到更稳定的黎曼空间。此外，我们使用 ReEig 层 f' 来确保




图 5: 左 (a) : 在欧氏空间和黎曼空间提取的蛋白质隐藏特征的可视化比较。右 (b): 蛋白质氨基酸和药物原子之间的联合 SPD 特征和响应的可视化。

因为转换后的特征是对称正定的，这就防止了由于秩的变化而导致的特征空间偏移。因此，黎曼 SPD 隐藏特征在 BindingDB 上有更好的表现，AUC-ROC 和 AUC-PR 分别提高了 1.2% 和 0.9%。

联合特征分析和 DTI 可视化 从联合特征中，我们提取了两个二阶黎曼相关性特征，包括基于通道的 $F_{r,c}$ 和基于长度的 $F_{r,l}$ 黎曼特征。基于通道的特征的作用很直观，因为每个特征都是由蛋白质和药物特征共同作用决定的。因此，在推理过程中，决策模型的参数不会偏向蛋白质或药物，从而有效提高了模型的鲁棒性。同时，基于长度的特征可以进一步增强蛋白质和药物之间的二阶相关性，同时提高决策的可解释性。

根据基于长度的黎曼特征，我们将 BindingDB 和药物库中的两对样本虚拟化，如图 5 (b) 所示。通过可视化基于长度的黎曼特征，我们可以很容易地观察到蛋白质中的氨基酸和药物中的原子之间的相互影响程度。

特征， $F_{r,l} \in \mathbb{R}^{(L) \times L_j}$ ，及其压缩特征、 $F_{(r)}^{(l)} \in \mathbb{R}^{C_k(l) \times C_k(l)}$ 。压缩后的特征热图可以

基于长度的特征可以放大相互作用的部分，重点关注蛋白质和药物之间的相互作用关系。在此基础上，我们将蛋白质和药物的结构可视化，突出它们的

高响应区域分别为黄色和橙色。尽管这些高响应区域与实际的结合位点或功能基团无关，但它们也能帮助我们深度模型中找到感兴趣的区域。有趣的是，与注意力机制相比，协方差矩阵能让模型更直接地学习到感兴趣的区域。

结论

我们提出了一种基于二阶相关性探索的新型 R-DTI 模型，以实现更好的特征提取和预处理。首先，我们构建了一个基于序列的蛋白质结构特征提取器，它可以从预先训练的知识边缘提取保留空间的结构特征。值得注意的是，提取的特征包含原子的二阶相关性，能更全面、更稳定地表达蛋白质结构信息。然后，我们开发了一种黎曼分类器，避免了参数偏置的蛋白质问题，同时明确了 DTI 特征的语义信息，从而使其更加稳定。我们还将二阶黎曼相关性和生物分子的高响应区域可视化，以探索它们之间的相关性。实验结果表明与最先进的应用相比，R-DTI 更具优势。

在六个基准数据集中采用的方法。然而，我们仍有改进的余地，例如设计更好的蛋白质里曼数表示法和更高效的 DTI 模式。未来，我们将进一步探索 DTI 预测的特征提取和预测表述中的二阶相关性，以增强人工智能在药物发现中的作用。

致谢

这项工作得到了国家重点研发计划（2023YFE0116300、2023YFF1105102）的支持、2023YFF1105105）、国家自然科学基金（62106089、62336004）、社会科学基金重大项目（21&ZD166）和江苏省自然科学基金（BK20221535）。

参考资料

Abbasi, K.; Razzaghi, P.; Poso, A.; Amanlou, M.; Ghasemi, J.B.; and Masoudi-Nejad, A. 2020.DeepCDA: 通过 LSTM 和卷积神经网络进行深度跨域化合物-蛋白质亲和力预测。《生物信息学》，36（17）：4633-4642。

Arsigny, V.; Fillard, P.; Pennec, X.; and Ayache, N. 2007.对称正定矩阵上新颖向量空间结构中的几何手段。《SIAM matrix analysis and applications journal》，29(1): 328-347。

Berman, H. M.; Westbrook, J.; Feng, Z.; Gilliland, G.; Bhat, T.N.; Weissig, H.; Shindyalov, I. N.; and Bourne, P. E. 2000.蛋白质。《Nucleic acids research》，28(1): 235-242。

Cao, D.-S.; Liu, S.; Xu, Q.-S.; Lu, H.-M.; Huang, J.-H.; Hu, Q.-N.; and Liang, Y.-Z.2012.利用蛋白质序列和药物拓扑结构大规模预测药物与靶点的相互作用。《Analytica chimica acta》，752: 1-10。

Chen, L.; Tan, X.; Wang, D.; Zhong, F.; Liu, X.; Yang, T.; Luo, X.; Chen, K.; Jiang, H.; and Zheng, M. 2020.TransformerCPI: Improving compound-protein interaction prediction by sequence-based deep learning with self-attention mechanism and label reversal experiments.《生物信息学》，36（16）：4406-4414。

Coelho, E. D.; Arrais, J. P.; and Oliveira, J. L. 2016.通过药物与靶点相互作用预测，共同发现药物重新定位的潜在线索。《PLOS computational biology》，12(11): e1005219。

Davis, M. I.; Hunt, J. P.; Herrgard, S.; Ciceri, P.; Wodicka, L. M.; Pallares, G.; Hocker, M.; Treiber, D. K.; and Zarrinkar, P. P. 2011.激酶抑制剂选择性的综合分析。《自然生物技术》，29(11): 1046-1051。

Dehghan, A.; Razzaghi, P.; Abbasi, K.; and Gharaghani, S. 2023.TripletMultiDTI: 利用三重损失函数进行药物-靶点相互作用预测的多模态表征学习（Multimodal Representation Learning in Drug-Target Interaction Prediction with Triplet Loss Function）。《专家系统与应用》，120754。

Detlefsen, N. S.; Hauberg, S.; and Boomsma, W. 2022.学习蛋白质序列的有意义表征。《Nature communications》，13(1): 1914。

Elnaggar, A.; Heinzinger, M.; Dallago, C.; Rehawi, G.; Wang, Y.; Jones, L.; Gibbs, T.; Feher, T.; Angerer, C.; Steinegger, M.; et al.Protrans: 通过自我监督学习理解生命语言。《IEEE patterns analysis and machine intelligence》，44(10): 7112-7127。

Helgason, S. 1965.Radon-Fourier transforms on symmetric spaces and related group representations.《Bulletin of American Mathematical Society》，71(5): 757-763。

Hua, Y.; Feng, Z.; Song, X.; Li, H.; Xu, T.; Wu, -J.; and Yu, D.-J. 2024.APMG: 3D Molecule Generation Driven by Atomic Chemical Properties.《IEEE/ACM Transactions on Computational Biology and Bioinformatics》。

Hua, Y.; Feng, Z.; Song, X.; Wu, -J.; and Kittler, J. 2025.MMDG-DTI: 通过多模态特征融合和领域泛化进行药物-靶标相互作用预测。《Pattern Recognition》，157: 110887。

Hua, Y.; Song, X.; Feng, Z.; and Wu, X. 2023a.MFR-DTA: 用于预测药物与靶点结合亲和力和区域的多功能稳健模型。《生物信息学》，39（2）：BTAD056。

Hua, Y.; Song, X.; Feng, Z.; Wu, X.-J.; Kittler, J.; and Yu, D.-J. 2023b.CPInformer for Efficient and Robust Compound-Protein Interaction Prediction.《IEEE/ACM Transactions on Computational Biology and Bioinformatics》，20(1): 285-296。

Huang, Z.; and Van Gool, L. 2017.用于 spd 矩阵学习的黎曼网络。《美国人工智能学会会议论文集》，第 31 卷。

Jacob, L.; and Vert, J.-P. 2008.蛋白质配体相互作用预测：一种改进的化学基因组学方法。《Bioinformatics》，24(19): 2149-2156。

Landrum, G.; et al. 2016.RdKit: 开源化学信息学软件。2016. doi: <http://www.rdkit.org/>, <https://github.com/rdkit/rdkit>, 149(150): 650。

Lee, I.; Keum, J.; and Nam, H. 2019.DeepConv-DTI: Prediction of drug-target interactions via deep learning with convolution on protein sequences.《PLOS Computational Biology》，15(6): 1-21。

Lim, J.; Ryu, S.; Park, K.; Choe, Y. J.; Ham, J.; and Kim, W.Y. 2019.利用三维结构嵌入图表示的新型图神经网络预测药物与靶标的相互作用。《Journal of chemical information and modeling》，59(9): 3981-3988。

Öztürk, H.; Özgür, A.; and Ozkirimli, E. 2018.DeepDTA: 深度药物靶点结合亲和力预测。《生物信息学》，34（17）：i821-i829。

Song, Y.; Wang, X.; Yao, J.; Liu, W.; Zhang, J.; and Xu, X. 2024.ViTGaze: 视觉转换器中带有交互特征的凝视跟踪。《视觉智能》，1（2）：31。

Tang, J.; Szwarda, A.; Shakyawar, S.; Xu, T.; Hintsanen, P.; Wennerberg, K.; and Aittokallio, T. 2014.大规模激酶抑制剂生物活性数据集的意义：比较和综合分析。《化学信息与建模杂志》，54（3）：735-743。

Tang, J.; Wang, J.; and Hu, J.-F.2023.通过递归神经网络预测人体姿势。《视觉智能》，1（1）：18。

Tsubaki, M.; Tomii, K.; and Sese, J. 2019.针对图和序列的端到端神经网络学习的化合物-蛋白质相互作用预测。《生物信息学》，35（2）：309-318。

Wang, S.; Guo, Y.; Wang, Y.; Sun, H.; and Huang, J. 2019.Smiles-bert：用于分子性质预测的大规模无监督预训练。In *Proceedings of the 10th ACM international conference on bioinformatics, computational biology and health informatics*, 429-436.

Wang, Y.; Shen, Y.; Chen, S.; Wang, L.; Fei, Y.; and Zhou, H.2022.学习黎曼曼体上的谐波分子表征In *The Eleventh International Conference on Learning Representations*.

Wu, L.; Huang, Y.; Tan, C.; Gao, Z.; Hu, B.; Lin, H.; Liu, Z.; and Li, S. Z. 2024.PSC-CPI: PSC-CPI: 多尺度蛋白质序列-结构对比，用于高效、通用的化合物-蛋白质相互作用预测。In *AAAI Conference on Artificial Intelligence*.

Xu, T.; Zhu, X.-F.; and Wu, X.-J. 2023.基于仿射子空间的虚拟物体跟踪时空判别模型学习.《视觉智能》，1（1）：4.

Yamanishi, Y.; Araki, M.; Gutteridge, A.; Honda, W.; and Kanehisa, M. 2008.从化学和基因组空间的整合中预测药物-靶点相互作用网络。《生物信息学》，24（13）：i232-i240。

Zhao, Q.; Zhao, H.; Zheng, K.; and Wang, J. 2022.HyperAttentionDTI：通过基于序列的深度学习和注意力机制改进药物-蛋白质相互作用预测。《生物信息学》，38（3）：655-662.