


DTIAM：预测药物-靶点相互作用、结合亲和力和药物机制的统一框架

收到：2023 年 9 月 18 日

接受：2025 年 2 月 26 日

Published online: 15 March 2025

Zhangli Lu^{1,6}, Guoqiang Song^{2,6}, Huimin Zhu⁽¹⁾, Chuqi Lei⁽¹⁾, Xinliang Sun⁽¹⁾, Kaili Wang⁽¹⁾, Libo Qin⁽¹⁾, Yafei Chen², Jing Tang^(1,3) & Min Li^(1,4,5)✉

准确而稳健地预测药物与靶点的相互作用（DTIs）在药物发现中起着至关重要的作用，但由于标记数据有限、冷启动问题以及对作用机制（MoA）的了解不足，预测工作仍具有挑战性。在临床应用中，区分激活和抑制机制尤为重要。在此，我们提出了 DTIAM，一个预测药物与靶点之间相互作用、结合亲和力以及激活/抑制机制的统一框架。DTIAM 通过自监督预训练从大量无标签数据中学习药物和靶点表征，从而准确提取它们的亚结构和上下文信息，从而有利于基于这些表征的下游预测。在所有任务中，特别是在冷启动场景中，DTIAM 的性能都比其他最先进的方法有了大幅提高。此外，独立验证证明了 DTIAM 强大的泛化能力。所有这些结果表明，DTIAM 可以为预测新型 DTI 和进一步区分候选药物的 MoA 提供实用的工具。

准确预测药物-靶点相互作用（DTIs）是药物发现和开发的重要步骤⁽¹⁾⁽²⁾。尽管各种实验检测方法在新药研发中得到了广泛应用，但大规模鉴定新 DTIs 的生化实验方法仍然既昂贵又耗时⁽³⁾⁽⁴⁾⁽⁵⁾。各种计算方法已被应用于药物发现，并成功预测了新的 DTIs，它们可以大大减少开发时间和成本⁽⁶⁾⁽⁷⁾⁽⁹⁾。目前的计算方法主要集中在 DTI 的二元预测或药物-靶点结合亲和力（DTA）的回归预测。

在基于二元分类的 DTI 预测研究中，目标是预测药物与靶点之间存在相互作用。一般来说，硅学 DTI 预测方法可分为四大类：基于结构的方法、

基于配体的方法、基于网络的方法和基于机器学习的方法。化合物-蛋白质复合物的结构测定可以让人们深入了解其作用模式，从而极大地促进基于靶点的药物发现中先导化合物的选择和优化⁽¹⁰⁾⁽¹¹⁾。目前有许多基于结构的方法，如分子对接¹²、分子动力学模拟¹³、药效学建模¹⁴和 GOLD¹⁵，这些方法被广泛应用于药物与蛋白质结合的虚拟筛选。然而，当目标蛋白质的三维（3D）结构未知时，这些方法通常无法预测结合亲和力，而且需要巨大的计算资源。而基于配体的方法，如定量结构活性关系（QSAR），则是将候选配体与特定靶蛋白的已知配体进行比较，以预测潜在的相互作用。

¹中南大学计算机科学与工程学院，中国长沙 410083。 ²河北工业大学健康科学与生物医学工程学院，中国天津 300401。 ³赫尔辛基大学医学院系统肿瘤学研究项目，芬兰赫尔辛基 00290。 ⁴湘江实验室，中国长沙 410205。 ⁵中南大学芙蓉实验室，中国长沙 410013。 ⁶这些作者的贡献相同：✉e-mail: limin@mail.csu.edu.cn

然而，这些方法的预测能力受到特定目标蛋白质已知配体数量的限制。为了克服目前基于结构和配体的方法的局限性，人们开发了各种用于 DTI 预测的计算模型^{(16)–(19)}。其中一个例子是基于网络的推断 (NBI) 方法，该方法从多种数据来源（如化学、基因组学、蛋白质组学和药理学）中构建可靠的网络，并利用网络中的拓扑和结构信息进行潜在关联预测^{(20)–(24)}。Luo 等人²⁵开发了一种名为 DTINet 的计算管道，通过整合各种药物相关信息构建的异构网络预测新型 DTI。预测 DTI 的另一种有前途的方法是基于机器学习的方法，主要包括两个步骤：特征提取和 DTI 预测^{(26)–(29)}。这类方法充分利用已知药物组合和靶蛋白输入数据中的潜在特征来预测它们之间的相互作用^{(30)–(31)}。基于二元分类的 DTI 预测模型可以成功预测药物与靶标之间是否存在相互作用，并且性能强大。药物与靶点的相互作用并不是简单的二元开关关系，而是一个连续的值，称为结合亲和力，它反映了药物化合物与特定靶蛋白结合的紧密程度³²。

为了进一步预测相互作用的推定强度，人们提出了各种基于回归的模型来推断药物与靶点之间的结合亲和力^{(32)–(35)}。结合亲和力反映了药物与特定靶点结合的紧密程度，可通过抑制常数 (K_i)、解离常数 (K_d) 和半最大抑制浓度 IC_{50} 等指标量化。DTA 预测方法侧重于亲和力评分，常用于虚拟筛选和对接活动之后。最近，深度学习方法成功地改变了评分函数，采用了各种深度神经网络架构，如卷积神经网络 (CNN) 和递归神经网络 (RNN)。这些方法可以从输入的原始数据中充分提取上下文特征并学习药物和靶点的表征，从而进行 DTA 预测。例如，Öztürk 等人提出的 DeepDTA³⁶，利用 CNN 从简化的分子输入行输入系统 (SMILES) 的化合物字符串和蛋白质的氨基酸序列中学习表征，并输入到全连接层以预测它们的亲和力。Karimi 等人³⁷提出了一种名为 DeepAffinity 的半监督深度学习模型，它将 RNN 和 CNN 结合起来，共同编码分子和蛋白质表征并预测亲和性。虽然这些方法可以成功预测药物与靶点之间的结合亲和力，但其可解释性仍然有限。因此，人们应用注意力机制，通过给“重要”特征分配更大权重来提高模型的可解释性^{(38)–(40)}。例如，Li 等人⁴¹开发了一种名为 MONN 的多目标神经网络，利用非共价相互作用作为额外的监督信息，引导模型捕捉关键的结合位点。

虽然人们在预测 DTI 和 DTA 方面投入了大量精力，但以往的研究仍存在一些局限性。首先，大多数现有方法严重依赖于高质量标注数据的规模。只有大规模的标注数据才能帮助模型取得优异的性能。遗憾的是，现有的标注数据并不充分，而且数据标注既昂贵又耗时。此外，当发现复杂疾病的新药或焦油时，这些方法往往表现出有限的泛化能力，这与推荐系统中的冷启动问题类似。更重要的是，最近的方法未能阐明化合物的作用机制 (MoA)。作用机制是指药物如何作用于靶点以产生预期效果，其中涉及两个主要作用：激活机制和抑制机制。区分药物和靶点之间的激活和抑制作用机制在药物发现和开发过程中以及在临床应用中都是至关重要和极具挑战性的。

应用⁴²。它有助于制药科学家识别潜在的药物相互作用和不良反应，开发安全有效的疾病治疗方法^{(43)–(44)}。例如，激活多巴胺受体的药物可以治疗帕金森病，而抑制多巴胺受体的药物可以治疗精神病⁴⁵。最近，一些基于蛋白质化学计量学建模和基因表达谱的方法被提出来预测药物与靶点之间的激活和抑制关系^{(45)–(48)}。然而，目前显然需要开发一种更强大的深度学习模型来预测和解读 MoA，这是药物开发中至关重要且极具挑战性的科学研究。

在这项工作中，我们开发了 DTIAM，这是一个用于预判定 DTI、DTA 和 MoA 的统一框架。DTIAM 通过多任务自我监督预训练从大量无标记数据中学习药物和靶标代表，只需输入药物化合物的分子图和靶标蛋白质的主序列。在预训练过程中，它能从海量化合物和蛋白质数据中准确提取子结构和上下文信息，从而提高泛化性能，并为下游任务带来益处。在不同类型的任务和三种常见的真实实验设置（即热启动、药物冷启动和目标冷启动）下进行的综合比较测试中，DTIAM 在所有任务中的表现都优于其他基线方法，尤其是在冷启动场景中。此外，我们还成功地从高通量分子库（1000 万个化合物）中识别出了 TMEM16A 的有效抑制因子，并通过全细胞膜片钳实验进行了验证。此外，对 EGFR、CDK 4/6 和 10 个特定靶点的独立验证表明，DTIAM 可以为预测新型 DTIs 进一步区分潜在药物的作用机制提供实用的工具。此外，鲁棒性实验表明，即使训练时标注的数据有限，预训练模型学习到的表征也能很好地转移到下游任务中。所有这些结果表明，DTIAM 可以为有效预测潜在药物分子或靶蛋白提供准确的表征，从而极大地促进药物发现过程。

成果

DTIAM 概览

我们提出的 DTIAM 是一个基于自我监督学习的通用框架，用于预测 DTI、DTA 和 MoA。DTIAM 的整体架构如图 1 所示。DTIAM 并不是一个端到端的神经网络模型，它由三个模块组成：（1）基于多任务自我监督学习的药物分子预训练模块，用于从海量分子图中提取单个亚结构和整个化合物的特征（图 1A）；（2）基于多任务自我监督学习的药物分子预训练模块，用于从海量分子图中提取单个亚结构和整个化合物的特征（图 2B）；（3）基于多任务自我监督学习的药物分子预训练模块，用于从海量分子图中提取单个亚结构和整个化合物的特征（图 2C）。图 1A）；（2）基于 Transformer 注意图的目标蛋白质预训练模块，直接从蛋白质序列中提取单个残基的特征（图 1B）；（3）统一的药物-目标预测模块，利用之前学习到的药物分子和目标蛋白质特征，预测给定药物和目标之间的 DTI、DTA 和 MoA（图 1C）。

药物分子预训练模块将分子图作为输入，然后将其分割成若干子结构。然后，该模块根据多个自监督模型学习药物分子的表示。具体来说，对于具有 n 个子结构的药物分子，它们的表征被定义为一个 $n \times d$ 嵌入矩阵，其中每个子结构被嵌入到一个 d 维向量中。这些嵌入矩阵被送入 Transformer 编码器进行特征提取，并通过三个自我监督任务进行学习：屏蔽语言建模、分子描述符预测和分子官能团预测。药物分子预训练模块利用注意力机制和自监督学习的力量，从大量无标记数据中有效提取上下文信息和隐含特征。




图 1| DTIAM 的架构概览。该框架主要由三个模块组成。A 药物分子预训练模块。该模块将分子图分割成若干子结构，并通过三个自监督模型从海量无标签数据中学习其表示。

B 目标蛋白质预训练模块该模块使用变形注意

力。C 下游药物-目标预测模块。该模块结合了药物和靶标表征，并通过自动机器学习模型预测 DTI、DTA 和 MoA。

分子子结构之间的关系。这一过程使模块能够学习药物分子的有意义表征，而无需依赖明确的标签。通过使用注意力机制，该模块可以在训练过程中优先处理相关的子结构和它们之间的关系，从而实现更有效的特征提取。同样，目标蛋白质预训练模块使用 Transformer 注意力图，基于无监督语言建模从大量蛋白质序列数据中学习蛋白质的表征和接触。药物-靶标预测模块的基本思想是整合药物和靶标信息，以改进 DTI、DTA 和 MoA 预测。该模块将化合物和蛋白质的表征结合在一起，以捕捉它们之间复杂的相互作用，并使用各种机器学习模型，如神经网络模型和语言模型。

网络，学习它们之间的关系和属性，以进行准确可靠的预测。这些模型集成在一个自动机器学习框架内，该框架采用了多层堆叠和套袋技术。有关 DTIAM 各模块和训练过程的详细信息，请参见“方法”部分。

DTIAM 在 DTI 预测任务中的表现

在 DTI 预测任务中，目标是预测给定的药物与目标配对是否相互作用，这是一个二元分类问题。我们在 Yamanishi_08's 和 Hetionet 基准数据集上比较了 DTIAM 与 CPI_GNN⁴⁹、TransformerCPI⁵⁰、MPNN_CNN⁵¹和 KGE_NFM⁹等四种基线方法，并采用了三种常用且更符合实际情况的交叉验证设置：暖启动

设置、药物冷启动设置和目标冷启动设置（图 2，补充材料表 2）。训练数据和测试数据通过 10 倍交叉验证进行分割，正负样本比例为 1:10。

首先，在较小的 Yamanishi_08 数据集上，我们观察到 DTIAM 在三种不同的实验设置下取得了更高更稳健的预测性能，尤其是在冷启动设置下。具体来说，在暖启动场景中，DTIAM（AUPR = 0.931）的表现明显优于所有其他基线方法，与 CPI_GNN（AUPR = 0.431）相比，DTIAM 的 AUPR 显著领先 50%。在端到端方法中，Trans-formerCPI（AUPR = 0.816）和 MPNN_CNN（AUPR = 0.802）以及基于网络的方法 KGE_NFM（AUPR = 0.817）取得了相当的预测性能。这些结果表明，端到端方法和基于网络的方法需要更多的标注数据，而 DTIAM 可以部分克服这一限制，这要归功于在预训练阶段学到的知识。在冷启动场景中，我们观察到所有方法的 AUPR 和 AUROC 值有不同程度的降低，而 DTIAM 仍然实现了相对较高的预测性能，尤其是在目标冷启动中。这一结果凸显了 DTIAM 的潜在能力，即从大规模无标记数据中捕捉化合物子结构和蛋白质序列的潜在特征，从而即使对未知药物或靶点也能实现更高精度和更稳健的预测。

，在更大的 Hetionet 数据集中，我们观察到 DTIAM 分别在热启动、药物冷启动和目标冷启动中取得了更好、最佳和第二好的预判性性能。具体来说，在热启动场景中，DTIAM 的平均 AUPR 得分（AUPR = 0.808）高于其他基线方法。而对于基于网络的方法，由于可用数据量的增加，KGE_NFM（AUPR = 0.789）取得了相当的预测性能。在药物冷启动场景中，DTIAM（AUPR = 0.529）的表现明显优于 CPI_GNN（AUPR = 0.219）和 MPNN_CNN（AUPR = 0.453）、和 KGE_NFM（AUPR = 0.391）。这一现象表明所提出的药物预训练模型强大的表达能力和特征学习能力，为 DTIAM 在未知药物预测中提供了巨大的优势。在目标冷启动场景，KGE_NFM（AUPR = 0.651）的表现优于 CPI_GNN（AUPR = 0.433）、MPNN_CNN（AUPR = 0.470）和 DTIAM = 0.614。这主要归功于基于网络的方法 KGE_NFM 有足够的目标相关关联信息。而 DTIAM 和端到端方法只将化合物 SMILES 和蛋白质序列作为输入，没有额外的关联信息。此外，我们在 Yamanishi_08's 和 Hetionet 数据集上也发现了类似的现象，即所有方法在目标冷启动时的预测性能都优于药物冷启动时的预测性能。这一发现似乎可能归因于目标的可用数据量，因为这两个数据集的目标数量都多于药物数量。例如，Hetionet 数据集中有 5763 个目标，而药物只有 1384 个（补充材料表 1）。

DTIAM 在 DTA 预测任务中的表现

DTA 预测任务的目标是预测给定的一对药物靶标之间的结合亲和力，这是一项回归任务。在性能比较中使用了四种基线模型，包括 DeepDTA³⁶、MONN⁴¹、BACPI⁴⁰和 GraphDTA³⁴。我们在两个基准数据集（Kinase 数据集 Davis 和 KIBA 数据集）上对我们的模型和所有基线方法进行了评估，共有三种实验设置（图 3，补充材料表 3）。在每个实验设置中，我们使用 5 倍交叉验证来评估 DTIAM 和基线方法的 DTA 预测性能。

从图 3 中可以看出，DTIAM 在两个数据集的所有实验设置下都取得了更好的预测性能，尤其是在冷启动设置下。在暖启动的情况下

DTIAM 和三种基于图的方法（MONN、BACPI 和 GraphDTA）在两个数据集上都取得了相对较高的预测性能。而在基于序列的方法中，DeepDTA 由于模型结构的限制，无法从序列信息中提取准确的特征，因此表现不佳。在冷启动的情况下，我们观察到与 DTI 预测任务类似的情况，即所有方法的预测性能都有不同程度的下降。GraphDTA 在药物冷启动设置中取得了相对较高的预测性能，但在目标冷启动设置中表现不佳。相比之下，MONN 在目标冷启动设置中的表现优于药物冷启动设置。这些结果表明，GraphDTA 更适合新药的结合亲和力预测，而 MONN 更适合靶标冷启动的情况。DeepDTA 和 BACPI 在两种冷启动情况下的表现更为稳定，这表明预测的鲁棒性。对于预训练模型，DTIAM 在暖启动设置和两种冷启动设置中的表现都最好。所有这些比较结果都证明了 DTIAM 强大预测能力，它可以成功预测药物与靶点之间的结合亲和力，即使对新药物或新靶点的预测也有很强的泛化能力。

DTIAM 在 MoA 预测任务中的表现

为了评估 DTIAM 在 MoA 预测任务中的预测性能，我们将 MoA 预测作为两个不同的二元分类任务来处理。具体来说，我们的目标是预测给定的药物-靶标配对是表现出激活效应还是抑制效应。因此，我们的两个分类问题是预测给定药物-目标配对是否存在激活和抑制作用。评估使用了两种不同类型的 MoA（即激活和抑制）每种类型的 MoA 都有一个从治疗靶点数据库中收集的相应数据集。我们在三种实验设置下对这两个数据集进行了 5 倍交叉验证，比较 DTIAM 和 AI-DTI⁽⁴⁸⁾（图 4A-D，补充材料表 4）。

如图 4A-D 所示，在激活和抑制数据集上，DTIAM 在所有三种实验设置中的表现都明显优于 AI-DTI。具体来说，在较小的激活数据集上，DTIAM 在热启动、药物冷启动和目标冷启动场景下的 AUPR 分别比 AI-DTI 高出 16.1%、17.9% 和 26.8%。这些结果表明，通过自我监督预训练学习到的表征可以很好地转移到下游任务中，只需少量标注训练数据。特别是，在 Inhibition 数据集上，当标注的药物-目标对规模较大时，DTIAM 和 AI-DTI 的评估性能比在 Activation 数据集上的评估性能有很大提高。而在热启动和药物冷启动的情况下，DTIAM 的表现略好于 AI-DTI。而当实验设置为目标冷启动时，DTIAM 的 AUPR 显著领先 AI-DTI 34%。这一结果表明，目标蛋白质预训练模型具有从大规模蛋白质氨基酸序列中学习模式的潜力，从而有利于 DTIAM 在目标冷启动情况下的下游预测。此外，我们还在激活和抑制数据集中观察到一个有趣的现象，即两种方法在药物冷启动中的预测性能都优于目标冷启动。造成这一结果的原因可能是，在这两个 MoA 数据集中，药物的数量多于目标。这一发现证明了冷启动场景中预测对象大小的影响，预测对象数量越多，预测性能越好。

区分药物与其靶点之间的激活/抑制机制具有重要的生物学意义，因为这可以决定药物产生的生物反应类型。以 α -1A 肾上腺素能受体（ADRA1A）为例，美他明醇等药物可激活 ADRA1A，用于治疗低血压⁵²、




图 2| DTI 预测任务的性能评估。在 Yamanishi_08's 和 Hetionet 数据集上，在三种实验设置下，根据 AUPR 和 AUROC 评估了 DTIAM 和基线模型的性能。A, B 在三种实验设置下，不同预测模型在 Yamanishi_08's 和 Hetionet 数据集上的 AUPR。C, D 不同预测模型在 Yamanishi_08's 和 Hetionet 数据集上的 AUROC

Yamanishi_08 数据集和 Hetionet 数据集的三种实验设置。所有结果均通过 10 倍交叉验证得出。正负样本的比例为 1:10。方框图以中位数为中心线，上四分位数和下四分位数为，须线为最大值和最小值，点代表异常值。




图 3| DTA 预测任务的性能评估。在戴维斯和 KIBA 数据集上，在三种实验设置下，根据 MSE 和皮尔逊相关性评估了 DTIAM 和基线模型的性能。A, B 在三种实验设置下，不同预测模型在 Davis 和 KIBA 数据集上的 MSE。C、D 戴维斯和 KIBA 数据集上不同预测模型在三种实验设置下的皮尔逊相关性。所有结果均通过 5 倍交叉得出。方框图以中位数为中心线，上四分位数和下四分位数为框线，须线为最大值和最小值，点代表异常值。




图 4| MoA 预测任务性能评估。A-D DTIAM 与 AI-DTI 在激活和抑制数据集上的性能比较，以 AUPR 和 AUROC 为准。所有结果均通过 5 倍交叉验证得出。正负样本的比例为 1:10。方框图以中位数为中心线，上下四分位数为，须线为最大值和最小值，点代表异常值。

E-H 在 10 个特定目标上验证 DTIAM。E 每个靶标的预测准确率，条形图顶部为得分，内部的比率表示在总数中正确预测的药物。F-G 激活和抑制的召回率，顶部的数值表示召回率，内部的比率表示在总数中正确预测的激活剂或抑制剂的数量。H 每个目标的 AUROC 分数。

而抑制 ADRA1A 的药物则用于良性前列腺增生症、高血压、精神分裂症和双相情感障碍⁽⁵³⁾ (.)⁽⁵⁴⁾。为了证明 DTIAM 在区分激活和抑制相互作用方面的可靠性,我们将所有激活和抑制 DTIs 结合起来训练 DTIAM,并将其用于预测 10 个特定靶点(包括 ADRA1A、ADRA1B、ADRA1D、CYP3A43、CYP3A5、CYP3A7、DRD1、HTR1B、HTR1D 和 HTR2A)的激活和抑制关系。这些靶点可分为四个不同的亚家族:α-1 肾上腺素能受体(ADRA1)、细胞色素 P450 3A 酶(CYP3A)、多巴胺受体(DR)和 5-羟色胺受体(HTR)。这些亚家族中的每一个都拥有相当多的已知激动剂和拮抗剂,以及不同治疗适应症相一致的独特作用机制。探索这些亚家族与药物之间的相互作用机制在神经系统调节、催化反应等领域具有极其重要的意义。我们从 DrugBank 收集了这 10 个靶点的激活/抑制关系,所有这些关系都独立于 DTIAM 使用的所有训练数据。

我们在补充数据 1 中列出了所有预测结果,并在图 4E-H 中显示了准确率、激活召回率、抑制召回率和 AUROC 的结果。我们发现,所有靶标的预测准确率都超过了 93%,其中 HTR1D 的预测准确率为 100%,9 个靶标的 AUROC 值超过了 0.96。这些结果表明,DTIAM 可以准确区分药物和靶点之间的激活和抑制关系。此外,我们观察到激活的召回率明显低于抑制的召回率。是因为 DTIAM 使用的数据集样本不平衡(激活样本远远少于抑制样本),导致模型在预测抑制结果时偏差较大。

DTIAM 确定了 TMEM16A 的潜在抑制剂

为了更好地证明 DTIAM 的有效性,我们利用 DTI、DTA 和 MoA 预测模型从高通量筛选分子库中预测了 TMEM16A 的潜在抑制剂,并输出了预测结果最高的抑制剂列表。TMEM16A 广泛表达于各种细胞,包括上皮细胞、平滑肌细胞、内皮细胞和神经细胞,并调节液体分泌、平滑肌收缩、肠道蠕动、细胞体积调节、细胞凋亡和疼痛等关键功能⁽⁵⁵⁾ (.)⁽⁵⁶⁾。其功能障碍可导致多种疾病,包括各种癌症、胃肠道疾病、高血压和囊性纤维化⁵⁷。TMEM16A 抑制剂可用于治疗高血压、中风和膀胱过度活动症,而激活剂则可治疗囊性纤维化和干眼症等上皮功能障碍疾病⁵⁸。因此,TMEM16A 是一个重要的药理学靶点。通过计算模型确定靶向 TMEM16A 的潜在药物是一项具有挑战性的任务,对治疗各种疾病具有重要意义。首先,我们应用 DTIAM 的 DTI 预测模型对商业现成的高通量筛选分子库中的化合物进行评分,该分子库包含约 1000 万个化合物,我们根据预测的相互作用概率选出了前 5 万个分子(约前 0.5%,确保了化合物的多样性)。其次,我们根据 Lipinski 规则对这些化合物进行筛选,并过滤检测干扰化合物,根据指纹相似性对这些分子进行聚类,得到约 350 个聚类。最后,根据预测的相互作用、亲和力和干扰得分,从排名靠前的聚类中选出 75 个具有代表性的化合物。

预测的抑制 TMEM16A 通道的潜在化合物见补充数据 2。我们发现,Daidzein(在预测的潜在中排名第二)经 Wang 等人⁵⁹验证是一种高效的 TMEM16A 抑制剂,其 IC_{50} 为 $1.39 \pm 0.59 \mu M$,而 DTIAM 推断其与 TMEM16A 的相互作用概率为 0.994,抑制概率为 0.999、

其亲和力为 0.121。可以看出,0.121 μM 和 1.39 μM 之间存在一定的差异。亲和力越低,说明结合强度越高。达依泽因与 TMEM16A 之间的亲和力预测值低于实际值,表明 DTIAM 对达依泽因有更高的信心。预测的相互作用概率和抑制概率都超过了实际值也说明了这一点。

0.99。此外,我们还利用自动对接 Vina 软件对预测的潜在化合物进行了验证,以选择候选药物进行进一步的实验评估,并选择了 Vina 评分较高、合成相对容易的脱氢木香内酯进行湿实验室验证。我们发现,脱氢木香内酯(在预测的潜在化合物中排名第12位)通过湿实验室实验验证了其对于 TMEM16A 的抑制作用,DTIAM 推断其与 TMEM16A 的相互作用概率为 0.977,抑制概率为 0.989,亲和力为 205.84 nM。具体来说,为了研究脱氢木香内酯对 TMEM16A 通道的抑制作用,我们在转染了 TMEM16A 质粒的 HEK293T 细胞中进行了全细胞膜片钳记录。采用含有 600 nM Ca^{2+} 的移液管溶液来激发转染 HEK293T 细胞中的 TMEM16A 电流。如图 5B 和 C 所示, TMEM16A 电流具有明显的外向整流和慢激活动力学特征。通过绘制暴露于不同浓度脱氢木香内酯后+80 mV 保持电位下的归一化电流值,建立了剂量-反应关系。我们的研究表明,去氢木香内酯对 TMEM16A 电流的 IC_{50} 值为

去氢木香内酯对转染 TMEM16A 的 HEK293T 细胞的抑制作用为 111.97 ± 22.96 nM(图 5D)。我们进一步用外向型膜片钳验证了去氢木香内酯对 TMEM16A 的抑制作用。结果表明,100 μM 的去氢木香内酯可以完全抑制 TMEM16A 的电流(图 5EF),这表明去氢木香内酯对 TMEM16A 的抑制作用是直接发挥的。此外,我们还在内源性高表达 TMEM16A 的 LA795 细胞上进行了实验,也证明了脱氢木香内酯对 TMEM16A 的抑制作用(补充材料图 1)。脱氢木香内酯抑制 LA795 细胞中 TMEM16A 的 IC_{50} 为 161.64 ± 61.96 nM。所有这些实验结果表明,DTIAM 预测的脱氢木香内酯是一种高效的 TMEM16A 抑制剂。

为了评估我们的框架在 TMEM16A 的已知抑制剂上的性能,我们还应用 DTIAM 推断了 TMEM16A 与五种已知抑制剂(包括 1PBC⁶⁰、烟酰胺⁶¹、苯溴马隆⁶²、crofelemer⁶³和 $CaCC_{inh}-A01$ ⁶⁴)之间的相互作用、亲和力和抑制分数。预测结果见补充数据 2。我们发现,所有五种抑制剂都被预测为具有很高的抑制 TMEM16A 的可能性,其中四种抑制剂的相互作用概率超过了 0.95。此外,这五种抑制剂的预测结合亲和力得分与实验测量结果非常吻合,这表明 DTIAM 在筛选 TMEM16A 抑制剂方面具有强大的预测能力。

预测表皮生长因子受体和 CDK 4/6 虚拟筛选的潜在药物

为了进一步测试药物虚拟筛选的适用性,我们测试了 DTIAM 是否能识别表皮生长因子受体(EGFR)和细胞周期蛋白依赖性激酶 4/细胞周期蛋白依赖性激酶(cyclin-dependent kinase 4/cyclin-dependent kinase)潜在药物的 DTIs。6 (CDK 4/6)。表皮生长因子受体是一种跨膜蛋白,在癌细胞中含量异常高,其抑制剂可用于治疗由表皮生长因子受体上调引起的癌症,如非小细胞肺癌和胰腺癌。CDK 是一种调节细胞在细胞周期中进展的酶。CDK 4/6 抑制剂通过与 CDK4 和 CDK6 酶结合并阻断其活性而发挥作用,常用于治疗乳腺癌和 CDK 4/6 活性过强导致的其他类型癌症。

我们使用 Yamanishi_08 的数据集(去除含有表皮生长因子受体的 DTI)来训练 DTIAM,并预测表皮生长因子受体与所有 DTI 之间潜在的相互作用。




图 5| 去氢木香内酯以浓度依赖性方式抑制 TMEM16A 重组 HEK293T 细胞中的 TMEM16A 电流。A 电压刺激波形图。B HEK293T 重组系统全细胞膜片钳中代表性的 TMEM16A 电流被 600 nM Ca^{2+} 激活, 并被不同浓度的 Dehydrocostus Lactone ($n=3$) 抑制, 20 μM $\text{CaCC}_{\text{inh}}\text{-A01}$ 为阳性对照。C 不同浓度脱氢木内酯抑制 TMEM16A 的 I-V 曲线 ($n=3$) 每组进行三个独立的生物重复。数据以平均值表示 $\pm$ SD。D TMEM16A 电流在 +80 mV 与指定浓度的脱氢木香内酯孵育时的剂量反应曲线。

$n=3$), 每组进行三个独立的生物重复。去氢木香内酯对 TMEM16A 通道的 IC_{50} 为 $111.97 \pm 22.96 \text{ nM}$ 。数据以平均值 $\pm$ SD 表示。E 在 HEK293T 重组系统中, 600 nM Ca^{2+} 激活并被 100 μM dehydrocostus lactone ($n=3$) 抑制的代表性 TMEM16A 电流, 20 μM $\text{CaCC}_{\text{inh}}\text{-A01}$ 为阳性对照。F 100 μM dehydrocostus lactone ($n=3$) 与 20 μM $\text{CaCC}_{\text{inh}}\text{-A01}$ 抑制 TMEM16A 的 I-V 曲线。每组 $n=3$, 每组进行三个独立的生物重复。数据以平均值表示 $\pm$ SD。

表 1| 预测的表皮生长因子受体（EGFR）潜在药物前 15 位

等级	KEGG ID	药物名称	预测得分	验证
1	D01441	甲磺酸伊马替尼	0.9962	布兰达
2	D01977	吉非替尼	0.9961	药物库
3	D04023	盐酸厄洛替尼	0.9954	KEGG,BRENDA
4	D04024	拉帕替尼	0.9941	药物库
5	D03218	阿西替尼	0.9937	布兰达
6	D04025	Mubritinib	0.9918	KEGG
7	D03252	博舒替尼	0.9914	KEGG
8	D03350	盐酸卡奈替尼	0.9851	布兰达, 药物银行
9	D09883	达科米替尼	0.9750	药物库
10	D10766	奥希替尼	0.9359	药物库
11	D08950	奈拉替尼	0.9308	药物库
12	D09724	阿法替尼	0.9143	药物库
13	D07907	厄洛替尼	0.9099	药物库
14	D10866	瑞格替尼	0.8799	药物库
15	D12001	Mobocertinib	0.8106	药物库

注: 加粗的药物是从 DrugBank 收集的已批准的表皮生长因子受体抑制剂, 其他药物是 Yamanishi_08 数据集中的药物。Pred_Score 一栏表示潜在药物与表皮生长因子受体发生相互作用的预测概率。

数据集中的药物之间的相互作用。我们还预测了表皮生长因子受体与药物库中 13 种已获批准的药物（阿法替尼、奥西莫替尼、吉非替尼、厄洛替尼、拉帕替尼、奈拉替尼、布瑞加替尼、达科米替尼、莫博克替尼、万达尼布、福司他替尼、扎鲁替尼和利多卡因）之间的相互作用, 这些药物都被用作表皮生长因子受体抑制剂。表 1 列出了前 15 种潜在药物的预测结果。我们发现, 通过我们的方法, 13 种表皮生长因子受体抑制剂中的 9 种成功地被重新发现在前 15 种潜在药物中, 13 种表皮生长因子受体抑制剂中的 12 种进入了 802 项结果的前 50 名（更多详情见补充数据 3）。此外, 前 15 名潜在药物名单中的其他 6 种药物均通过了外部数据库（如KEGG⁶⁵、BRENDA⁶⁶和DrugBank⁶⁷）的验证。

同样, Yamanishi_08 的数据集（去除含有 CDK 4 和 CDK 6 的 DTI）被用来训练 DTIAM, DTIAM 被用来预测 CDK 4/6 与数据集中的所有药物以及 DrugBank 中用作 CDK 4 和 CDK 6 抑制剂的 4 种已批准药物（Ribociclib、Abemaciclib、Trilaciclib 和 Palbociclib）之间的相互作用。表 2 列出了与 CDK 4/6 发生相互作用的前 15 种潜在药物, 并按照 CDK 6 的预测得分进行了排序。我们发现, DTIAM 成功预测了 4 种已批准的 CDK 4/6 抑制剂。此外, 外部数据库（CTD⁶⁸和 KEGG⁶⁵）也验证了甲磺酸伊马替尼、Alvociclib 和盐酸 Alvociclib 与 CDK 4/6 的相互作用。此外, 对接研究表明, 五种药物（即格拉司琼、阿昔替尼、盐酸卡奈替尼、多拉氨啉啉和穆布替尼）能够与 CDK 6 发生对接（图 6B-F）。其中, 格拉司琼与残基 D163(A)相互作用, 阿昔替尼与残基 V101(A)相互作用（图 6B, C）, 这与高选择性 CDK4/6 抑制剂 Palbociclib（图 6A）相似。所有这些结果表明, DTIAM可以有效地应用于药物虚拟筛选, 为加快药物开发进程提供了有力的工具。

消融研究

如上所述, 得益于预训练模型, DTIAM 在下游任务中即使只有少量标注数据也能取得优异的性能。为了测试我们提出的预训练模型的有效性, 我们在 DTI、DTA 和 MoA 预测任务中使用不同规模的标注数据将 DTIAM 与最先进的基线模型

进行了比较。我们在六个不同任务的数据集上分配了 20%、40%、60% 和 80% 的样本进行训练, 并在热启动设置下使用剩余样本进行验证。

从图 6G 可以看出,随着训练样本数的增加,所有方法的预测性能都有不同程度的提高。在所有数据分区下,DTIAM 的性能都是最好的,而且明显优于其他模型,尤其是在训练数据较少的情况下(20% 和 40%)。值得注意的是,DTIAM 在仅使用 20% 的样本进行监督训练的情况下,也能超越使用 60% 甚至 80% 的样本进行训练的其他模型。所有结果都表明,我们提出的预训练模型可以从海量未标记数据中提取准确的特征,即使只有少量未标记数据,也能有效地应用于下游预测任务。

为了分析使用不同的自我监督任务组合对分子表征学习预训练的影响,我们对我们提出的分子预训练模型的三种自我监督任务的七种组合进行了消融实验。这三种自我监督任务是(1)屏蔽语言建模(MLM);(2)分子描述符预测(MDP);(3)分子官能团预测(MFGP)。有关每项自我监督任务的详细信息,请参阅“自我监督分子表征学习”部分。

如表 3 所示,我们发现 MFGP 任务对性能的影响最大,尤其是在药物冷启动情况下,单独使用 MFGP 任务(AUPR = 0.305)与单独使用 MDP 任务(AUPR = 0.203)相比,在 AUPR 方面有 50% 的显著领先优势。这表明分子的局部官能团信息对 DTI 预测非常有帮助。我们的分子表征学习模型能够准确捕捉关键的官能团信息。在两个自我监督任务的组合中,以 MLM 和 MFGP 训练的分子模型表现最佳。虽然在 MLM、MDP 和 MFGP 的组合中训练出的模型表现最佳,但 MDP 任务带来的附加收益相对较小。

讨论

准确预测 DTI 可为药物发现和开发提供巨大优势。现有方法大多只关注 DTI 二元分类或 DTA 回归预测,而忽略了药物 MoA 信息。MoA 预测有助于了解药物的作用模式,并为药物研发提供新的见解。在本研究中,我们结合药物和靶点预训练模型以及 AutoML 技术,开发了一个统一的框架,称为 DTIAM,用于预测 DTI、DTA 和 MoA。预训练模型通过自监督学习从海量无标注数据中提取亚结构和上下文信息,并可用于包括 MoA、DTI、DTA 等在内的各种预测任务。预训练模型的高扩展性和泛化能力已在不同类型的预测任务中得到广泛验证。综合比较测试表明,在三种交叉验证设置下,DTIAM 在不同类型的数据集上取得了优异的性能,并明显优于其他最先进的机器学习方法。进一步的药物筛选实际应用证明了 DTIAM 预测的可靠性,DTIAM 预测的 TMEM16A 候选抑制剂得到了湿实验室实验的验证。此外,我们还验证了 DTIAM 在表皮生长因子受体(EGFR)和 CDK 4/6 靶点药物虚拟筛选中的适用性,结果表明预测的前 15 种潜在药物大多得到了外部数据库和文献的验证。所有这些结果表明,DTIAM 可以有效地用于各种药物靶点预测任务,为药物开发提供了强有力的工具。

DTIAM 仅使用分子 SMILES 和蛋白质序列作为输入,通过使用海量无标记数据进行自我监督预训练,有效提高了下游预测任务的性能。然而,蛋白质靶标对特定化合物的敏感性受到蛋白质之外的许多因素的影响。

表 2| CDK 4 和 CDK 6 的前 15 种预测潜在药物

等级	KEGG ID	药物名称	Pred_Score1	预测分数2	验证
1	D01441	甲磺酸伊马替尼	1.0000	1.0000	CTD
2	D10883	Ribociclib	0.9995	1.0000	药物库
3	D02880	盐酸阿伐替尼	1.0000	1.0000	KEGG
4	D01840	盐酸法舒地尔	0.9997	1.0000	-
5	D10688	Abemaciclib	0.9843	0.9999	药物库
6	D09868	Alvociclib	0.9998	0.9999	KEGG
7	D11130	Trilaciclib	0.9347	0.9995	药物库
8	D03350	盐酸卡奈替尼	0.9735	0.9994	-
9	D04370	格拉司琼	0.9920	0.9992	-
10	D03736	多拉帕莫德	0.9974	0.9986	-
11	D03218	阿西替尼	0.9901	0.9986	-
12	D03115	盐酸法舒地尔水合物	0.9964	0.9973	-
13	D02217	盐酸雷洛昔芬	0.9971	0.9942	-
14	D10372	Palbociclib	0.5924	0.9832	药物库
15	D04025	Mubritinib	0.9755	0.9758	-

注：加粗的药物是从 DrugBank 收集的已批准的 CDK 4 和 CDK 6 抑制剂，其他药物是 Yamanishi_08 数据集中的药物。Pred_Score1 和 Pred_Score2 栏分别表示潜在药物与 CDK 4 和 CDK 6 发生相互作用的预测概率。潜在药物根据 Pred_Score2 排序。

序列信息。这些因素包括蛋白质动力学、蛋白质突变、细胞和膜环境等，都会改变化合物的结合效率和药效。在未来的工作中，我们将在模型中考虑蛋白质的动态变化，以提高模型的鲁棒性和可解释性，并整合蛋白质突变信息，提高模型在关键突变位点的灵敏度。

方法
DTIAM 的工作流程

DTIAM 由三个主要部分组成：(1) 自我监督预训练用于药物预训练的常规表征学习；(2) 用于药物预训练的无监督用于目标预训练的蛋白质表征学习；(3)

通过自动机器学习（AutoML）进行表征整合和下游药物靶点推断任务。

自监督分子表征学习。我们采用BERT-style⁶⁹方法进行药物预训练，并开发了一种分子表征学习模型，称为BERMol，即Bidirectional Encoder Representations of Molecular。BERMol 利用语言模型和领域相关的辅助任务，从大规模无标记数据中学习分子子结构的向量表征。该数据集包含从 ChEMBL^{70,71}数据库中收集的 160 万种化合物。为了将语言模型应用到分子领域，我们定义了以下子结构

摩根算法⁷²提取每个分子半径为 1 的所有子结构。在生成化合物语料库后，可使用

Transformer³⁸架构用于学习分子所有子结构的低秩代表。具体来说，分子可以抽象为一个句子 $S = (x_1, \dots, x_n)$ ，其中 x_i 是第 i 个单词

n 是句子长度，然后将句子中的每个单词嵌入 d 维向量空间 $Z = \{\vec{z}_1, \dots, \vec{z}_n\}$ ，其中 $\vec{z}_i \in \mathbb{R}^d$ 是第 i 个词的 d 维嵌入。在使用转换器架构进行编码的步骤中，我们将所有嵌入式转换成三个矩阵（ Q, K, V ），分别代表查询、键和值，然后计算词与词之间的自关注权重，如下所示：

其中 β 是用于平滑 softmax 函数梯度的缩放因子，注意力机制的输出是一个矩阵，代表不同词语之间的全局关系。为了整合来自不同表征子空间的信息，多头注意力采用了不同的线性投影，最终的输出矩阵可以写为

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_k) W^O \quad (2)$$

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \quad (3)$$

其中， W_i^Q, W_i^K, W_i^V 是第 i 个头的投影矩阵。该组合完整的编码器是由多个块堆叠而成，并结合了多头自注意机制和全连接前馈网络。为了学习灵活、高质量的分子表征，我们结合了三个自监督任务进行预训练：（1）屏蔽语言建模（MLM）；（2）分子描述符预测MDP）；（3）分子功能组预测（MFGP）。MLM 任务由 BERT 提出，即模型随机屏蔽部分标记，并通过训练预测屏蔽标记真实身份。在这项任务中，屏蔽标记的最终表示被输入一个神经网络模型，进行多分类预判定。该任务使用交叉熵损失进行优化，具体如下：

$$\text{损失} = - \sum_{j=1}^N \sum_{i \in \text{掩码}} (y_i \log(p_{ij})) \quad (4)$$

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\beta}\right) \frac{V}{V(1)}$$

其中, N_{mask} 是被屏蔽的数量, V 是词汇量的大小, 即子结构集的大小, y_i 是代表词汇量中第 i 个被屏蔽标记的真实分布的单击向量, p_j 是词汇量中第 j 个标记正确替代第 i 个被屏蔽词的预测概率。总之, MLM 任务的训练损失是平均屏蔽语言建模可能性的总和。MDP 任务目标是预测一组化学特征的实值描述符, 这是一项回归任务。分子描述符编码了许多物理化学特性, 可通过 RDKit 轻松计算⁷³。在这项任务中, 第一个标记的最终表示结合了整个分子的全局特征并输入神经网络模型以预测归一化描述符集。该任务使用平均




图 6 | 不同规模标记数据的相互作用预测对接结果和性能比较。A-F 六种潜在药物 (即 Palbociclib、Granisetron、Axitinib、Canertinib dihydrochloride、Doramapimod 和 Mubritinib, 其中

G DTIAM 和基线模型在不同规模的标记数据上的表现 (即 20%、40%、60% 和 80%) 的 DTI、DTA 和 MoA 预测任务。

所有预测值的平方误差如下:

$$\text{损失}_{MDP} = \frac{1}{N_{desc}} \sum_i (y_i - \hat{y}_i^2)$$

其中, N_{desc} 是本研究中使用的分子描述符的数量。

任务, y_i 是第 i 个描述符的归一化值, $\hat{y}_i$ 是第 i 个描述符的预测值。MFGP 任务可以理解成一种多标签分类, 其目的是

输入分子中的官能团。功能基团包含丰富的分子领域知识, RDKit 也能轻松检测到。第一个标记的最终表示也会输入

的神经网络模型进行多标签分类。这项任务利用交叉熵损失进行了如下优化

$$\text{损失}_{MFGP} = \frac{1}{N_{fun}} \sum_i y_i \log(\hat{y}_i) + (1 - y_i) (1 - \log(\hat{y}_i)) \quad (6)$$

表 3 不同自我监督任务组合对分子表征学习预训练的影响

MLM	MDP	MFGP	温暖 开始	药物冷启 动	目标冷启 动
✓	×	×	0.697	0.247	0.543
×	✓	×	0.586	0.203	0.509
×	×	✓	0.783	0.305	0.594
✓	✓	×	0.82	0.418	0.673
✓	×	✓	0.902	0.527	0.802
×	✓	✓	0.851	0.489	0.769
✓	✓	✓	0.931	0.568	0.865

注：MLM、MDP 和 MFGP 是用于分子预训练的三个自监督任务，分别代表屏蔽语言建模、分子描述符预测和分子官能团预测。消融实验是在 Yamanishi 08 数据集的三种实验设置下进行的，评价指标为 AUPR。粗体数字代表最佳性能，数值越大越好。

其中， N_{fun} 是这项任务中使用的分子官能团的数量， y_i 是表示分子中是否含有第 i 个官能团的真实标签， y_i^p 是第 i 个官能团的预测概率。

功能组。自我监督的最终训练损失
分子表征学习模型由加权
所有单项任务损失的总和如下

损失 = Loss_{MLM} + αLoss_{MDP} + βLoss_(MFGP) (7)

其中，α 和 β 是两个权重系数。训练目标是
最小化损失，并使用反向传播来优化模型和更新表征。

无监督蛋白质表征学习。在目标蛋白质
在表征学习步骤中，我们采用了ESM-2⁷⁴来提取目标蛋白质的嵌入，ESM-2是一个大规模语言模型系列，范围从800万到150亿。
ESM-2语言模型还使用带有变压器^{69,38}的BERT式编码器架构来训练屏蔽语言建模。
ESM-2的目标是根据上下文预测蛋白质序列中随机屏蔽氨基酸的原始身份。UniRef⁷⁵ 蛋白序列数据库用于训练 ESM-2 模型，其中包括约 1.38 亿个 UniRef90 序列和约 6500 万个独特序列。

预先训练好的 ESM-2 模型可以直接预测从 Transformer 自我关注模式中提取的蛋白质残基-残基接触图。具体来说，给定一个有 L 层、 K 头的模型，设 c_{ij} 为二元随机变量，表示氨基酸 i 、 j 是否接触。那么位置 i 和 j 之间的接触概率就定义为逻辑回归：

$$p(c_{ij}|\beta) = \frac{1}{1 + \exp(-\beta_0 - \sum_l \mathbf{P}_l^T \mathbf{P}_K^T \beta_{kl} (a_j^{(kl)}))}$$
 (8)

其中， $a_j^{(kl)}$ 是变换器第 l 层第 k 个注意力头中 i 和 j 氨基酸之间的注意力得分。

ESM-2语言模型还能根据蛋白质序列生成高分辨率的蛋白质三维结构预测（ESMFold）。在这项工作中，我们采用了其中一个拥有 33 层和 6.5 亿个参数的 ESM-2 模型，并将其最后一层的隐藏状态作为目标蛋白质的表征。

下游药物-靶点预测。最后一步是整合药物和靶标表征，并通过 AutoGluon⁷⁶ 进行各种下游预测。AutoGluon 是一个用于结构化数据的 AutoML 框架，它能自动利用最先进的技术，无需频繁的人工干预，就能实现强大的预测功能

在许多应用中都具有预测性能。之前的 AutoML 框架主要侧重于组合算法选择和超参数优化 (CASH)，以便从众多可能性中找到最佳模型，而 AutoGluon 则不同，它执行高级数据处理和强大的多层模型集合，以训练高精度的机器学习模型。AutoGluon 集成了各种类型的模型（如神经网络、LightGBM 提升树和随机森林），并基于多层堆叠和重复 k 折袋装的新颖组合对这些模型进行集合。

在多层堆叠中，第一层有多个基础模型，其输入是原始数据特征，输出则与数据特征结合，然后输入下。最后堆叠利用集合选择，以加权方式汇总堆叠模型的预判定。在重复的 k 折袋装法中，训练数据被随机分成 k 个不相交的块，每个块作为测试集生成折外预测（OOF），剩余的块作为训练集训练模型。为了减少 OOF 预测中的过拟合现象，AutoGluon 会在训练数据的 n 个不同随机分区上重复 k 折袋过程，并对重复袋的所有 OOF 预测取平均值。更具体地说，训练数据 (X, Y) 首先被随机分割为

分成 k 块 $\{X_i^{(j)}, Y_i^{(j)}\}_{i=1}^k$ 在第 i 次重复中，然后在 $(X_i^{(j)}, Y_i^{(j)})$ 并对每个模型的 OOF 数据 $X_{m,i}^{(j)}$ 进行预测 $Y_i^{(j)}$ 对每个模型的 OOF 数据 $X_{m,i}^{(j)}$ 堆叠层 l 中模型类型 m 的输出是通过对重复袋的所有 OOF 预测值取平均值计算得出的，即

$$\hat{y}_i^{(j)} = \frac{1}{n} \sum_{m=1}^n y_{m,i}^{(j)}$$
 (9)

与输入连接起来，然后输入下一个堆叠层，即

$$X' \text{ concatenate}(X, \{\hat{y}_i^{(j)}\}_{m \in M})$$
 (10)

最终预测结果是堆栈机模型预预测结果的加权汇总。

这项工作中的框架具有很强的适应性，可用于各种药物靶点预测任务，包括 DTI、DTA 和 MoA。该框架采用了可在不同任务中共享的预训练药物和靶标代表学习模型，然后以监督学习的方式使用不同的标记数据集对其进行微调。预训练阶段使模型能够从大量未标记数据中学习精确的表征，从而在下游任务中取得优异的性能。

基准数据集
在这项研究中，三个预测任务的六个基准数据集（即...、DTI、DTA 和 MoA），即 Yamanishi_08、Hetionet、Davis、KIBA、Activation 和 Inhibition，用于综合评估。

我们模型的性能和能力。

Yamanishi_08 数据集和 Hetionet 是 DTI 数据集，其中的标签是药物与靶点之间的二元相互作用。Yamanishi_08 数据集最初由 Yamanishi 等人提出¹⁶，由四个子数据集组成：G-Protein Coupled Receptors (GPCR)、Ion Channels (IC)、Nuclear Receptors (NR) 和 Enzymes (E)，分别来自 KEGG BRITE、BRENDA、SuperTarget 和 DrugBank 数据库^{(65) (-) (67) (-) (77)}。在本研究中，我们使用了 Ye 等人构建的四个子数据集的合并数据集⁹。该数据集总共包含 791 种药物、989 个靶点和 5127 个已知 DTI（即阳性样本）。Hetionet 数据集由 Himmelstein 等人构建⁷⁸，整合了 29 个公共资源中的生物医学数据。该数据集包括 1384 种药物、5763 个靶点和 49942 个 DTI。

Davis 和 KIBA 是两个 DTA 数据集，也是以前用于 DTA 预测评估的常用标准数据集^{(36) (.) (79)}。Davis 数据集包含激酶蛋白家族和相关抑制剂的结合强度，这些强度是使用解离常数 (K_d) 值测量的。它包括 68 种药物和 442 个靶点，由 Davis 等人构建⁸⁰。KIBA 是一个大规模激酶抑制剂生物活性数据集，由 Tang 等人构建⁸¹。它结合了不同的测量类型，如 K_i 、 K_d 和 IC_{50} ，包含 2111 种药物和 229 个靶点。

激活 (Activation) 和抑制 (Inhibition) 是两个从治疗靶点数据库 (⁸²Therapeutic Target Database, TTD) 中获得的 MOA 数据集。我们选择了那些明确定义为激活 (如 "激活剂"、"前 nist") 或抑制 (如 "抑制剂"、"拮抗剂") 的 MOA。在活化数据集中，我们总共获得了 1426 种药物和 281 个靶点之间的 1913 个活化 MoAs；在抑制数据集中，我们总共获得了 14,049 种药物和 1088 个靶点之间的 21,055 个抑制 MoAs。

基线

在这项工作中，三种基线模型被用于 DTI、DTA 和 MoA 预测任务的性能比较，其中 CPI_GNN⁴⁹、TransformerCPI⁵⁰、MPNN_CNN⁵¹ 和 KGE_NFM⁹ 用于 DTI 预测，DeepDTA³⁶、MONN⁴¹、BACPI⁴⁰ 和 GraphDTA³⁴ 用于 DTA 预测，AI-DTI⁴⁸ 用于 MoA 预测。CPI_GNN、TransformerCPI、MPNN_CNN、DeepDTA、BACPI 和 GraphDTA 以及 DTIAM 只需要将化合物的 SMILES 字符串和蛋白质的主序列作为输入。KGE_NFM 需要从多组学数据中提取异构信息来构建知识图谱，并使用药物的摩根指纹和靶标的 CTD 描述符作为附加信息。MONN 不仅需要 SMILES 字符串和蛋白质序列，还需要化合物原子和蛋白质残基之间成对的非共价作用作为额外的监督信息。在这项工作中，由于戴维斯数据集和 KIBA 数据集的非共价相互作用标签不可用，我们没有为 MONN (原论文中称为 MONN_{single}) 提供额外的监督信息。AI-DTI 需要将化合物的 SMILES 字符串和目标基因的基因扰动转录组数据作为输入。请注意，MPNN_CNN 和 DeepDTA 模型是用 DeepPurpose⁸³ 构建的。

实验设置 DTIAM 和这些基线方法在三

种不同的交叉验证设置下进行了评估，即热启动设置、药物冷启动设置和目标冷启动设置。为了解释这些设置，我们分别用 D_{train} 和 D_{test} 表示训练和测试药物集，用 T_{train} 和 T_{test} 表示训练和测试药物集，并用 (d_i, t_j) 表示第 i 种药物和第 j 个目标之间的药物-目标对。

在热启动设置中，对于来自测试集 $(d_{(j)} \in D_{\text{test}}$ 和 $t_{(j)} \in T_{\text{test}})$ 的药物-目标对 $(d_{(j)}, t_{(j)})$ ， $d_{(j)}$ 和 $t_{(j)}$ 都会在训练集 $(d \in D_{\text{train}}$ 和 $t \in T_{\text{train}})$ 中遇到。也就是说，测试集和训练集有共同的药物和目标。这种情况适用于识别已知药物和靶点之间的潜在相互作用。

在药物冷启动设置，对于来自测试集的药物-靶标对 (d_i, t_j) ，药物 $d_{(j)}$ 在训练阶段没有出现 $(d_i \in D_{\text{test}}, d_i \notin D_{\text{train}})$ ，而靶标 t_j 在训练集和测试集中都存在 $(t_{(j)} \in T_{\text{test}}, t_j \in T_{\text{train}})$ 。如果我们发现新药的潜在候选靶标，那么这种实验设置就非常重要。

在目标冷启动设置中，对于测试集中的药物-目标对 (d_i, t_j) ，我们已经看到了药物 $d_{(j)} (d_{(j)} \in D_{\text{train}})$ ，但目标 t_j 在训练阶段尚未看到 $(t_{(j)} \notin T_{\text{train}})$ 。这种情况经常应用于新靶点的虚拟药物筛选。

请注意，DTI 预测任务是在 10 倍交叉验证下进行评估的，DTA 和 MoA 预测任务是在 5 倍交叉验证下进行评估的。此外，对于 KGE_NFM 模型，药物/目标冷

启动设置的训练-测试分割方案只知识图谱中存在的药物/蛋白质，但没有任何已知的 DTI 关系。

评估指标

在本研究中，我们使用接收者操作特征曲线下面积（AUROC）和精确度-召回曲线下面积（AUPR）的平均分来评估每种方法在 DTI 和 MoA 预测任务中的性能。在这项工作中，我们将阳性样本和阴性样本的比例设定为 1:10，因为这更符合真实世界的场景。在此，我们采用 AUPR 作为主要评估指标，因为它能更准确地评估方法在不平衡数据集中的性能。在 DTA 预测任务中，每种方法的性能都是通过均方误差（MSE）和皮尔逊相关性来评估的。

TMEM16A 抑制剂的鉴定

细胞培养和转染。HEK293T 细胞用 Dulbecco 改良鹰培养基（DMEM）（Gibco）培养，添加 10% 血清（FBS）（Gibco）和 1% 青霉素-链霉素溶液（100 U/ml 青霉素和 100 µg/ml 链霉素），培养箱为 37 °C、5% CO₂。使用 Lipofectamine 3000 转染试剂（赛默飞世尔科技公司）以 1:3 的比例瞬时转染小鼠 TMEM16A 的 cDNA（mTMEM16A）。小鼠 cDNA 克隆 mTMEM16A（ANO1，Accession Number: NM_178642.5）由 Young Duk Yang 教授（韩国首尔国立大学）赠送，并亚克隆到表达载体 pEGFPN1 中。转染后，细胞在 37 °C 下保持 24 小时，然后进行膜片钳记录。TMEM16A 的 UniProt ID 是 A0A0A0MQF2。LA795 细胞使用 RPMI 1640 培养基（Gibco）和 10% 胎牛血清（FBS）（Gibco）以及 1% 青霉素-链霉素溶液培养，培养条件为 37 °C、5% CO₂。LA795 细胞是一种小鼠肺腺癌细胞系，具有较高的 TMEM16A 内源性表达量。

电生理学。使用 EPC10 放大器和带有 Digi LIH1600 接口的 Pulse 软件（HEKA，德国兰布雷希特）记录电流。P-97 拉拔器（Sutter Instruments，Novato，USA）拉拔电阻为 3-5 MΩ 的硼硅玻璃贴片移液管（Sutter Instruments，Novato，）。串联电阻小于 20 MΩ，在全细胞膜片钳中的补偿率为 60% 至 80%。液体交界处电位未经校正，其幅度约为 10 mV。玻璃吸管经过火抛光处理。数据经过 2.9 kHz 低通滤波后以 10 kHz 的频率采样。刺激过程包括从 0 mV 保持电位开始的 150 毫秒容量步长和从 -80 到 +80 mV 的 20 mV 增量的膜电压（mV）箝位，-80 mV 保持在室温（22-25 °C）下。用于记录 TMEM16A 电流的浴液包含以下成分（单位：mM）：NaCl 150 mM、MgCl₂·6H₂O 1 mM、HEPES 10 mM、葡萄糖 10 mM 和甘露醇 10 mM，用 NaOH 调节 pH 值至 7.4。移液管溶液中含有以下成分（单位：毫摩尔）：CsCl 130 mM、EGTA 10 mM、MgATP 1 mM、MgCl₂·6H₂O 1 mM 和 HEPES 10 mM，用 CsOH 调节 pH 值至 7.3。600 nM 游离 Ca²⁺溶液是通过加入标准 CaCl₂溶液（1 M，Sigma-Aldrich，St. Louis，MO，USA）制备的，最终浓度为 8.69 mM，并用 CsOH 调节 pH 值至 7.3。渗透压用 OM815 渗透压仪测定。移液管和溶液的渗透压范围分别为 290-300 mOsm/L 和 300-310 mOsm/L。在建立全细胞记录后，将膜片移液管从细胞中逐渐移出，就形成了膜外膜片。这样做的效果是引出一缕膜，这缕膜甚至会断裂，并经常重新闭合，使其细胞外表面朝向记录室。附着在移液管上的膜随着移液管的后退而后退，当膜断裂并切除一个外向膜片时，应再次形成千兆欧姆的密封。通过灌注系统给药时，记录 TMEM16A 的单通道电流。外向型膜片钳的水浴和移液管溶液与内向型膜片钳的相同。

全细胞膜片钳记录。在浴液中配制不同浓度的去氢木香内酯，并通过灌注系统给药。具体全细胞膜片钳和体外膜片钳来研究去氢木香内酯对TMEM16A的抑制作用。

报告摘要

有关研究设计的更多信息，请参阅本文链接的自然 投资组合报告摘要。

数据可用性

用于训练和评估模型的六个数据集的源数据，网址为<https://github.com/CSUBioGroup/DTIAM/tree/main/data>。MoA数据集是从治疗靶标数据库 (<https://db.idrblab.net/ttd/>) 中构建的。用于预训练分子表征学习模型的 GuacaMol 数据集的源数据见<https://github.com/BenevolentAI/guacamol>。我们的案例中提到的靶点包括 ADRA1A、ADRA1B、ADRA1DDRD1、CYP3A43、CYP3A5、CYP3A7、HTR1B、HTR1D、HTR2A、TMEM16A、表皮生长因子受体、CDK4 和 CDK6 可在 Uniprot 资源库 (<https://www.uniprot.org/>) 中查阅其加入代码。虚拟筛选结果见补充数据。本文的原始数据通过 Figshare <https://doi.org/10.6084/m9.figshare.27896790> 提供。

代码可用性

DTIAM 的源数据和代码可在 GitHub 上获取：<https://github.com/CSUBioGroup/DTIAM>，也已存入 Zenodo，加入代码为<https://zenodo.org/records/14847966>。ESM-2 v1.0.3 (<https://github.com/facebookresearch/esm>) 用于计算目标蛋白质表征。AutoGluon v0.5.2 (<https://github.com/autogluon/autogluon>) 用于构建预测模型。数据分析使用 numpy v1.21.2 (<https://numpy.org/>)、pandas v1.3.5 (<https://pandas.pydata.org/>) 和 Matplotlib v3.5.1 (<https://matplotlib.org/>)。结构可视化使用 PyMol v2.5.2 (<https://www.pymol.org/>)。

参考资料

- Chen, X. et al. 药物-靶点相互作用预测：数据库、网络服务器和计算模型。 *Brief.Bioinforma.* 17, 696-712 (2016).
- Wen, M. et al. Deep-learning-based drug-target interaction prediction. *J. Proteome Res.* 16, 1401-1409 (2017).
- DiMasi, J. A., Hansen, R. W. & Grabowski, H. G. The price of innovation: new estimates of drug development costs. *J. Health Econ.* 22, 151-185 (2003).
- Paul, S. M. et al. How to improve R&D productivity: the pharmaceutical industry's grand challenge. *Nat.Rev. Drug Discov.* 9, 203-214 (2010).
- Pushpakom, S. et al. 药物再利用：进展、挑战和 建议。 *Nat.Rev. Drug Discov.* 18, 41-58 (2019).
- Zhang, P., Wei, Z., Che, C. & Jin, B. DeepMGT-DTI: transformer network incorporating multilayer graph information for drug-target interaction prediction. *Comput.Biol.Med.* 142, 105214 (2022).
- Shin, B., Park, S., Kang, . & Ho, J. C. 基于自我注意的分子表征预测药物靶点相互作用。 In *Machine Learning for Healthcare Conference* 230-248 (PMLR, 2019).
- Zhu, H., Zhou, R., Cao, D., Tang, J. & Li, M. A pharmacophore-guided deep learning approach for bioactive molecular generation. *Nat.* 14, 6234 (2023). 14, 6234 (2023).
- 基于知识图谱和推荐系统的统一药物靶点相互作用预测框架。 *Nat.Nat.* 12,

- 1-12 (2021).
10. Batool, M., Ahmad, B. & Choi, S. A structure-based drug discovery paradigm. *Int.J. Mol.* 20, 2783 (2019).

11. Yang, D. et al. G 蛋白偶联受体：基于结构和功能的药物发现。 *Signal Transduct. Target. Ther.* 6, 7 (2021).
12. Saikia, S. & Bordoloi, M. Molecular docking: challenges, advances and its use in drug discovery perspective. *Curr. Drug Targets* 20, 501-521 (2019).
13. 药物发现和药物开发中的分子动力学模拟。 *过程* 9, 71 (2020).
14. Schaller, D. 等. 下一代三维药理模型。 *Wiley Interdiscip. Rev. : Comput. Mol.* 10, 1468 (2020).
15. Pagadala, N. S., Syed, K. & Tuszynski, J. Software for molecular docking: a review. *Biophys. Rev.* 9, 91-102 (2017).
16. Yamanishi, Y., Araki, M., Gutteridge, A., Honda, W. & Kanehisa, M. Prediction of drug-target interaction networks from the integration of chemical and genomic spaces. *Bioinformatics* 24, 232-240 (2008).
17. Cichonska, A. et al. 药物-靶点相互作用图谱的计算-实验方法：激酶抑制剂案例研究。 *PLoS Comput.* 13, 1005678 (2017).
18. Mei, J.-P., Kwok, C.-K., Yang, P., Li, X.-L. & Zheng, J. Drug-target interaction prediction by learning from local information and neighbors. *生物信息学* 29, 238-245 (2013).
19. Olayan, R. S., Ashoor, H. & Bajic, V. B. DDR：利用图挖掘和机器学习方法预测药物靶点相互作用的高效计算方法。 *Bioinformatics* 34, 1164-1173 (2018).
20. Cheng, F. et al. 通过基于网络的推理预测药物靶点相互作用和药物重新定位。 *PLoS Comput.* 8, 1002503 (2012).
21. Fakhræi, S., Huang, B., Raschid, L. & Getoor, L. 基于网络的药物-目标相互作用概率软逻辑预测。 *IEEE/ ACM Trans. Comput. Biol. Bioinforma.* 11, 775-787 (2014).
22. Wu, Y., Gao, J., Zeng, M., Zhang, J. & Li, M. Bridgedpi: 用于预测药物与蛋白质相互作用的新型图神经网络。 *Bioinformatics* 38, 2571-2578 (2022).
23. Wu, Z., Li, W., Liu, G. & Tang, Y. 基于网络的药物-靶点相互作用预测方法。 *Front. Pharmacol.* 9, 1134 (2018).
24. Lu, Z., Wang, Y., Zeng, M. & Li, M. Hnedti: 基于异构网络嵌入的药物靶点相互作用预测。 In *2019 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)*, 211-214 (IEEE, 2019).
25. Luo, Y. et al. 从异构信息中预测药物靶点间作用和计算药物重新定位的网络整合方法。 *Nat.* 8, 1-13 (2017).
26. Bagherian, M. et al. 预测药物靶点相互作用的机器学习方法和数据库：调查报告。 *Brief. Bioinforma.* 22, 247-269 (2021).
27. Ding, H., Takigawa, I., Mamitsuka, H. & Zhu, S. 基于相似性的机器学习方法预测药物-靶点相互作用：简要综述。 *Brief. Bioinforma.* 15, 734-747 (2014).
28. Chen, R., Liu, X., Jin, S., Lin, J. & Liu, J. Machine learning for drug-target interaction prediction. *分子* 23, 2208 (2018).
29. D'Souza, S., Prema, K. & Balaji, S. Machine learning models for drug-target interactions: current knowledge and future directions. *Drug Discov. Today* 25, 748-756 (2020).
30. Liu, H., Sun, J., Guan, J., Zheng, J. & Zhou, S. Improving compound-protein interaction prediction by building up highly credible negative samples. *生物信息学* 31, 221-229 (2015).
31. Shi, H. et al. 基于进化信息和化学结构使用套索与随机森林预测药物-靶标相互作用。 *Genomics* 111, 1839-1852 (2019).
32. Pahikkala, T. et al. *Brief. Bioinforma.* 16, 325-337 (2015).
33. Wang, K. & Li, M. 基于融合的深度學習架構，利用靶点和藥物檢測藥

- 序列和结构. *IEEE J. Biomed. Health Inform.* 27, 6112-6120 (2023).
34. Nguyen, T. 等. GraphDTA: 预测药物与目标的结合亲和力图神经网络. *生物信息学* 37, 1140-1147 (2021).
35. Jiang, M. 等. 利用图神经网络和接触图预测药物靶点亲和力. *RSC Adv.* 10, 20701-20712 (2020).
36. Öztürk, H., Özgür, A. & Ozkirimli, E. DeepDTA: Deep drug-target binding affinity prediction. *Bioinformatics* 34, 821-829 (2018).
37. Karimi, M., Wu, D., Wang, Z. & Shen, Y. DeepAffinity: 通过统一的循环和卷积神经网络对化合物-蛋白质亲和力进行可解释的深度学习. *Bioinformatics* 35, 3329-3338 (2019).
38. Vaswani, A. et al. Attention is all you need. In *Advances in Neural Information Processing Systems* 30 (2017).
39. Gao, K. Y. 等. 使用深度神经表征进行可解释的药物靶点预测. In *IJCAI* Vol. 2018, 3371-3377 (2018).
40. Li, M., Lu, Z., Wu, Y. & Li, Y. BACPI: a bi-directional attention neural network for compound-protein interaction and binding affinity prediction. *Bioinformatics* 38, 1995-2002 (2022).
41. Li, S. et al. Monn: 用于预测化合物-蛋白质相互作用和亲和力的多目标神经网络. *Cell Syst.* 10, 308-322 (2020).
42. Zhang, S. et al. Drugai: a multi-view deep learning model for predicting drug-target activating/inhibiting mechanisms. *Brief. Bioinform.* 24, 526 (2023).
43. Schenone, M., Dančik, V., Wagner, B. K. & Clemons, P. A. 化学生物学和药物发现中的靶点识别和作用机制. *Nat. Nat.* 9, 232-240 (2013).
44. Gibbs, J. B. Mechanism-based target identification and drug discovery in cancer research. *Science* 287, 1969-1973 (2000).
45. Sawada, R., Iwata, M., Tabei, Y., Yamato, H. & Yamanishi, Y. Pre-通过化学和基因扰动转录组特征确定抑制性和激活性药物靶标. *Sci.* 1-9 (2018).
46. Wikberg, J. et al. Melanocortin receptors: ligands and proteochemometrics modeling. *Ann. N. Y. Acad.* 994, 21-26 (2003).
47. Mervin, L. H., Afzal, A. M., Brive, L., Engkvist, O. & Bender, A. Extending in silico protein target prediction models to include functional effects. *Front. Pharmacol.* 9, 613 (2018).
48. Lee, W.-Y., Lee, C.-Y. & Kim, C.-E. 基于结构化合物表征和基因扰动转录组预测激活和抑制药物与靶点的相互作用. *PLoS One* 18, e0282042 (2023).
49. Tsubaki, M., Tomii, K. & Sese, J. 利用神经网络端到端学习图和序列的化合物-蛋白质相互作用预测. *Bioinformatics* 35, 309-318 (2019).
50. Chen, L. et al. TransformerCPI: Improving compound-protein interaction prediction by sequence-based deep learning with self attention mechanism and label reversal experiments. *Bioinformatics* 36, 4406-4414 (2020).
51. Gilmer, J., Schoenholz, S. S., Riley, P. F., Vinyals, O. & Dahl, G. E. Neural message passing for quantum chemistry. In *International Conference on Machine Learning* 1263-1272 (PMLR, 2017).
52. Kee, V. R. 静脉注射血管加压剂的血流动力学药理学. *Crit. Care Nurse* 23, 79-82 (2003).
53. Yono, M. et al. 多沙唑嗪诱导的大鼠下尿路 α_{1A} -肾上腺受体 mRNA 上调. *Can. J. Physiol. Pharmacol.* 82, 872-878 (2004).
54. Corena-McLeod, M. Risperidone 和 Risperidone 的比较药理学. 帕利哌酮. *Drugs RD* 15, 163-174 (2015).
55. Wang, H. et al. TMEM16A Ca^{2+} -activated 氯离子通道在癌症中的细胞特异性机制. *Mol. Cancer* 16, 1-17 (2017). *Cancer* 16, 1-17 (2017).
56. Liu, Y., Liu, Z. & Wang, K. Ca^{2+} -activated chloride channel ANO1/ TMEM16A: an emerging therapeutic target for epithelium-originated diseases? *Acta Pharm. Sin. B* 11, 1412-1433 (2021).
57. White, W., Liu, M. & Xiao, Q. The diverse roles of TMEM16A Ca^{2+} -activated Cl^- channels in inflammation. *J. Adv.* 33, 53-68 (2021).
58. Al-Hosni, R., Ilkan, Z., Agostinelli, E. & Tammam, P. The pharmacology of the TMEM16A channel: therapeutic opportunities. *Trends Pharmacol.* 43, 712-725 (2022).
59. Wang, X. et al. 麦冬苷对钙激活氯通道 TMEM16A 的抑制作用及其抗肿瘤活性. *Int. J. Biol. Macromol.* 253, 127261 (2023).
60. Lam, A. K., Rutz, S. & Dutzler, R. 孔阻断剂 1PBC 对氯离子通道 TMEM16A 的抑制机制. *Nat. Nat.* 13, 2798 (2022).
61. Miner, K. 等. 药物再利用: 抗蠕虫药尼可刹米和硝唑沙尼是强效的 TMEM16A 拮抗剂, 能充分扩张. *Front. Pharmacol.* 10, 51 (2019).
62. Huang, F. 钙激活的氯离子通道 TMEM16A 调节粘蛋白分泌和气道平滑肌收缩. *Proc. Natl Acad. USA* 109, 16354-16359 (2012).
63. Tradtrantip, L., Namkung, W. & Verkman, A. S. Crofelemer, 一种从 croton lechleri 提取的抗腹泻原花青素低聚物, 针对两种不同的肠道氯化物通道. *Mol. Pharmacol.* 77, 69-78 (2010).
64. De La Fuente, R., Namkung, W., Mills, A. & Verkman, A. S. Small-molecule screen identifies inhibitors of a human intestinal calcium-activated chloride channel. *Mol. Pharmacol.* 73, 758-768 (2008).
65. Kanehisa, M. et al. From genomics to chemical genomics: new developments in KEGG. *Nucleic Acids Res.* 34, 354-357 (2006).
66. Schomburg, I. et al. BRENDA, the enzyme database: updates and major new developments. *Nucleic Acids Res.* 32, 431-433 (2004).
67. Wishart, D. S. et al. DrugBank: a knowledgebase for drugs, drug actions and drug targets. *Nucleic Acids Res.* 36, 901-906 (2008).
68. Davis, A. P. et al. 比较毒物基因组学数据库 (CTD): 2021 年更新. *Nucleic Acids Res.* 49, 1138-1143 (2021).
69. Devlin, J., Chang, M.-W., Lee, K. & Toutanova, K. Bert: 用于语言理解的深度双向变换器的预训练. In *Proc. of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies*, Vol. 1, 4171-4186 (2019).
70. Brown, N., Fiscato, M., Segler, M. H. & Vaucher, A. C. GuacaMol: 全新分子设计的基准模型. *J. Chem. Inf. Model.* 59, 1096-1108 (2019).
71. Gaulton, A. et al. 2017 年的 ChEMBL 数据库. *Nucleic Acids Res.* 45, 945-954 (2017).
72. Rogers, D. & Hahn, M. Extended-connectivity fingerprints. *J. Chem. Inf. Model.* 50, 742-754 (2010).
73. Landrum, G. et al: *开放源码化学信息学* (2006 年)。
74. Lin, Z. 等人. 利用语言模型对原子级蛋白质结构进行进化级预测. *Science* 379, 1123-1130 (2023).
75. Suzeck, B. E. et al. Uniref clusters: a comprehensive and scalable alternative for improving sequence similarity. *Bioinformatics* 31, 926-932 (2015).
76. Erickson, N. et al. Autogluon-tabular: 用于结构化数据的稳健而精确的自动表. Preprint at <https://arxiv.org/abs/2003.06505> (2020).
77. Günther, S. et al. Supertarget and matador: resources for exploring 药物靶标关系. *核酸研究*, 36, 919-922 (2007 年)。
78. Himmelstein, D. S. et al. *Elife* 6, 26726 (2017).
79. He, T., Heidemeyer, M., Ban, F., Cherkasov, A. & Ester, M. SimBoost: a read-across approach for predicting drug-target binding affinities using gradient boosting machines. *J. Cheminform.* 9, 1-14 (2017).
80. Davis, M. I. et al. *Nat. Biotechnol.* 29, 1046-1051 (2011).
81. Tang, J. et al. Making sense of large-scale kinase inhibitor bioactivity data sets: a comparative and integrative analysis. *J. Chem. Inf. Model.* 54, 735-743 (2014).

82. Zhou, Y. et al. 治疗靶标数据库更新 2022：通过丰富的靶向比较数据促进药物发现。 *Nucleic Acids Res.* 50, 1398-1407 (2022).

83. Huang, K. et al. DeepPurpose: a deep learning library for drug-target interaction prediction. *Bioinformatics* 36, 5545-5547 (2020).

致谢

本研究得到国家自然科学基金项目(No. 62225209 to M.L.)、湘江实验室项目(No. 24XJCYJ01003 to M.L.)、芬兰科学院项目(No. 359752 to J.T.)和湖南省研究生科研创新项目(No. 359752 to J.T.)的资助。

CX20230260 to Z.L.)。感谢中南大学高性能计算中心的支持。

作者供稿

M.L. 指导研究工作。Z.L.和M.L.构思了最初的想法。

Z.L. 设计了模型并进行了测试实验。G.S. 和

Y.C. 进行了湿实验室实验。L.Q.、K.W.和C.L.帮助手稿。Z.L.、G.S.、H.Z.、X.S.、J.T.和M.L.撰写并修改了手稿。所有作者阅读并批准了手稿。

利益冲突

作者声明不存在利益冲突。

其他信息

补充信息 在线版本包含补充材料，可从 <https://doi.org/10.1038/s41467-025-57828-0> 获取。

来信和索取资料请寄：Min Li。

同行评议信息 《自然-通讯》感谢匿名审稿人对本作品的同行评议所做的贡献。可提供同行评审文件。

转载和授权信息请访问 <http://www.nature.com/reprints>。

出版者注 Springer Nature 对出版地图中的司法主张和机构隶属关系保持中立。

开放存取 本文采用知识共享署名-非商业性-禁止衍生 4.0 国际许可协议进行许可，该协议允许以任何媒介或格式进行任何非商业性使用、共享、分发和复制，只要您适当注明原作者和来源，提供知识共享许可协议的链接，并说明您是否修改了许可材料。根据本许可协议，您无权分享源自本文或本文部分内容的改编材料。本文中的图片或其他第三方材料均包含在文章的知识共享许可协议中，除非在材料的信用栏中另有说明。如果材料未包含在文章的知识共享许可协议中，且您打算使用的材料不符合法律规定或超出了许可使用范围，则需要直接获得版权所有者的许可。要查看该许可的副本，请访问 <http://creativecommons.org/licenses/by-nc-nd/4.0/>。

©作者：2025