



用于蛋白质组规模相互作用预测的深度学习方法

Min Su Yoon^{1,a}, Byunghyun Bae^{2,3,a}, Kunhee Kim^{1,a}, Hahnbeom Park^{3,4} and Minkyung Baek¹

蛋白质组规模的相互作用预测对于理解蛋白质功能和疾病机制至关重要。传统实验方法往往受限于规模和复杂性，这促使人们需要采用计算方法。深度学习作为一种强大的工具应运而生，能够实现高通量、准确的蛋白质相互作用预测。本综述重点介绍了蛋白质-蛋白质和蛋白质-配体相互作用筛选的深度学习方法的最新进展，以及用于模型训练的数据集。尽管深度学习取得了进展，但诸如数据质量和验证偏差等挑战仍然存在。我们还讨论了整合结构信息以提高预测准确性的重要性日益增加，以及基于结构的深度学习方法如何帮助克服当前的局限性，从而推动生物学研究和药物发现的发展。

地址

¹ 韩国首尔国立大学生命科学系，首尔 08826，韩国

² 韩国首尔国立大学化学系，首尔 08826，韩国

³ 生物医学研究部，韩国科学技术院，韩国首尔 02792

⁴ 韩国科学技术院 - 成均馆大脑研究中心，成均馆大学融合研究院，成均馆大学，韩国水原市 16419 号

通讯作者：Baek, Minkyung (minkbaek@snu.ac.kr)；Park, Hahnbeom (hahnbeom@kist.re.kr)

(朴 H.)，(白 M.)

* 这些作者对本工作贡献相同。



《结构生物学最新观点》2025 年，第 90 卷：102981

这篇综述出自关于结构生物学中人工智能 (AI) 方法学的专题 (2025 年)。

由 Chaok Seok 和 Pratyush Tiwary 编辑

欲全面了解本节内容，请参阅文章合集——《结构生物学中的人工智能 (AI) 方法论 (2025)》

2025 年 1 月 22 日上线

<https://doi.org/10.1016/j.sbi.2024.102981>

0959-440X/© 2024 爱思唯尔有限公司保留所有权利，包括但不限于文本和数据挖掘、人工智能训练以及类似技术的权利。

于理解疾病的分子基础、识别潜在的治疗靶点以及开发新药至关重要。然而，传统的研究蛋白质相互作用的实验方法往往费时费力且规模有限。为了解决这些局限性，基于模板的计算方法已被开发出来[1,2]。然而，这些方法的准确性往往受到限制，并且依赖于已知相互作用的扩展，这限制了它们在没有实验先例的相互作用研究中的应用。因此，迫切需要高通量、蛋白质组规模的相互作用筛选方法，以便高效地绘制细胞内蛋白质相互作用的广阔图谱。

在这一背景下，深度学习已崭露头角，成为一种变革性的工具，有望克服传统实验筛选方法的诸多局限性。深度学习驱动的方法能够以前所未有的速度和精度分析大规模数据集[3,4]，识别新的相互作用模式，并预测仅通过实验技术难以检测到的相互作用[5e7]。通过将深度学习融入蛋白质组规模的筛选，研究人员能够加快新蛋白质功能的发现，更深入地了解疾病的分子基础，并简化药物开发流程。

在这篇综述中，我们重点关注可用于蛋白质组规模筛选的深度学习模型，主要集中在两个关键领域：蛋白质-蛋白质相互作用 (PPI) 和蛋白质-配体相互作用 (PLI)。主要方法总结在表 1 中。PPI 预测的主要目的是识别并理解生物系统内蛋白质之间的相互作用方式。这些相互作用对于大多数细胞过程至关重要，例如信号转导、代谢途径、细胞通讯和免疫反应。通过绘制这些相互作用图谱，研究人员能够构建详细的生物网络，推断未表征蛋白质的功能，并揭示各种疾病背后的机制。鉴于实验方法的复杂性和高昂成本，用于 PPI 预测的计算方法对于加快实验验证和深化对生物过程的理解具有不可估量的价值。

介绍

蛋白质通过复杂的相互作用网络发挥作用，这些网络几乎调控着所有的生物过程。破译这些相互作用网络对

表 1		
2021 年以来用于蛋白质 - 蛋白质相互作用（PPI）和蛋白质 - 配体相互作用（PLI）筛选的深度学习方法的综述。		
对于蛋白质 - 蛋白质相互作用（PPIs）		
方法	除了预测蛋白质相互作用外，还能预测复杂结构吗？	相关参考文献
D-SCRIPT	否	[8]
RAPPPID	否	[9]
颠倒乾坤	否	[10]
TT3D	否	[11]
金枪鱼	否	[12]
生产者价格指数（PPI）前值	是	[13]
泽皮	是	[14]
AlphaFold 系列	是	[3, 15–18]
RoseTTAFold 系列	是	[4, 5, 7]
对于蛋白质 - 配体相互作用（PLIs）		
Methods ^a	受体结构的明确利用？	相关参考文献
康普莱克斯	否	[19]
DrugCLIP	否	[20]
激酶-CPI-重新分析	否	[21]
超注意力DTI	否	[22]
禁药令	否	[23]
DeepPS	是	[24]
STAMP-DPI	是	[25]
注意力位点扩散张量成像	是	[26]
未应用于筛选研究的方法（例如 AlphaFold3）未被纳入。		

在蛋白质组水平筛选中，与目标小分子的相互作用是另一个研究重点。蛋白质-小分子相互作用（PLI）的主要目的是识别与给定小分子配体相互作用的受体。受体筛选在药物再利用方面很有用，使研究人员能够利用已经过实验分析的药物的吸收、分布、代谢和排泄（ADME）特性。此外，受体筛选有助于早期识别小分子潜在的毒性，这是临床试验失败的主要原因之一。与配体虚拟筛选相比，受体筛选的重要性尚未得到充分强调。

生物测定和数据库

与 PPI 或 PLI 相关的数据库见表 2。表中列出了数据集名称、数据条目数量、适用于蛋白质 - 蛋白质（PP）或蛋白质 - 配体（PL）、最新版本、提供的数据格式及其网址。这些数据集可用于验证计算方法或训练网络。虽然 PDB、BioGRID 和 STRING 一直是研究一般 PPI 的最标准数据库，但在 PLI 领域却不存在这样的数据集，因此需要自行构建数据集或借鉴以往的研究成果。

数据集的主要来源是各种生物测定法。酵母双杂交（Y2H）、亲和纯化质谱（APMS）和免疫共沉淀（co-IP）等高通量实验

技术为多种生物提供了大量的蛋白质相互作用（PPI）数据集[31,43,44]。除了这些实验方法外，蛋白质相互作用数据库还通过共表达、共定位、同源性和文本挖掘等手段推断潜在的相互作用，从而扩大了已知的相互作用空间。蛋白质组水平的蛋白质-配体相互作用（PLI）数据则来自蛋白质组水平的测定，例如基于亲和力的蛋白质谱分析（ABPP）[45]和药物亲和力响应靶标稳定性（DARTS）测定[46]。针对特定靶点的测定提供了特定蛋白质家族与潜在配体之间的相互作用数据，例如用于激酶谱分析的多路复用抑制剂珠（MIB）测定和激酶活性测定（KAYAK）[47]，以及用于 G 蛋白偶联受体（GPCR）的放射性结合测定和均相时间分辨荧光（HTRF）IP1测定[48]。此外，对于蛋白质相互作用和蛋白质-配体相互作用，来自不同研究小组的单个测定数据在通用数据集中占了很大一部分。其中，符合自身标准的子集被收集起来并存入表中列出的数据集。

全蛋白质组范围内的蛋白质相互作用筛选

图 1 展示了两​​种使用基于深度学习的方法进行蛋白质 - 蛋白质相互作用（PPI）预测的常见途径。一种主要途径是构建一个基于深度学习的分类器，该分类器结合了来自预训练的蛋白质语言模型、预先计算的结构数据库或已知实验数据的各种特征。另一种主要途径则是利用蛋白质结构预测方法。

表 2
可用的蛋白质相互作用数据库类型及数量。

通用数据库						
数据库	条目数量	条目（蛋白质）	适用性	版本（日期）	数据类型	网址
PDB [27]	224 千字节	220 千伏	PP, PL	2024.09	结构	https://www.rcsb.org/
UniProt [28]	246 兆	246 兆	PP, PL	2024.04	序列	https://www.uniprot.org/
BioGRID [29]	2.8 米 (PP)	89.8 千 (PP)	PP, PL	4.4.237 (2024 年 9 月)	序列	https://thebiogrid.org/
字符串 [30]	31 千 (波兰语)	2.7 千 (波兰兹罗提)	PP	12.0 版 (2023 年 7 月)	序列	https://string-db.org/
HuRI [31]	20 B	59 米	PP	2020	序列	http://www.interactome-atlas.org/
ChEMBL [32]	64 千字节	900	PP	2020	序列	http://www.interactome-atlas.org/
ChEMBL [32]	1.8 M ^a	15 千 (元)	PL	ChEMBL34 (2024 年版)	SMILES	https://www.ebi.ac.uk/chembl/
PubChem [33]	149 M	248 千字节	PL	2024.09	结构	https://pubchem.ncbi.nlm.nih.gov/
DrugBank [34]	17 k ^c	22 千 (字节)	PL	2024.09	SMILES	https://go.drugbank.com/
二级数据库						
PDBbind [35]	157 千帕 (PDB) (PL: 19.4 千帕, PP: 2.8 千帕)	3.4 千	PP, PL	版本 2020	结构	http://www.pdbbind.org.cn/
Q-BioLiP [36]	290 万 (PL: 48.8 万, PP: 3.27 万)	212 千 (单位)	PP, PL	2024 年 8 月 30 日 版	结构	https://yanglab.qd.sdu.edu.cn/Q-BioLiP/
戴维斯 [37]	72 k ^c	442	PL	2011	序列与 SMILE S 表示法	https://doi.org/10.1038/nbt.1990
STITCH [38] (此部分为专有名词或编号, 通常不翻译)	9.6 兆 (字节)		PL	5.0 版 (2016 年)	序列	http://stitch.embl.de/
GalaxyDB [25]	381 千字节	372	PL	2022	结构	https://github.com/biomed-AI/STAMP-DPI?tab=readme-ov-file
“PLINDER” [39]	449 年 k ^a	74 k ^d	PL	2024.06	结构	https://www.plinder.sh
BindingDB [40]	2.9 兆	9.3 千	PL	2024.09	序列	https://www.bindingdb.org/cwd/
LIT-PCBA [41]	1.3 M ^a				& 微笑	https://www.bindingdb.org/cwd/
	7.7 k ^d	15	PL	2024.09	结构	https://drugdesign.unistra.fr/LIT-PCBA/
DUD-E [42]	22 k ^c	102	PL	2024.09	结构	https://dude.docking.org/

若干化合物。
^b 活性化合物的数量。
^c 通过处理通用初级数据库收集。^d 冗余集的数量。


例如 AlphaFold 和 RoseTTAFold。结构预测方法所需的计算资源大约是基于分类器的方法的 1000 倍。不过，经过一些小的改进[5,7]，这些方法已能够在基因组规模上应用，从而有效地筛选蛋白质相互作用（PPI）。

虽然 PIPR [49] 和 RAPPPID [9] 直接基于蛋白质序列预测给定的两个蛋白质之间的相互作用概率，但 D-SCRIPT [8] 和 TUnA [12] 利用预训练的蛋白质语言模型（如 Bepler 和 Berger 模型 [50] 以及进化尺度模型 2（ESM-2） [51]）来增强从氨基酸序列中提取特征的能力。Topsy-Turvy [10] 在 D-SCRIPT 的基础上，通过结合基于网络的方法来补充基于序列的方法，通过计算 GLIDE [52] 分数来整合来自研究充分的物种的已知 PPI

网络，从而提高预测的准确性。KSGPPI [53] 采用混合方法，结合了 ESM-2 预训练的蛋白质语言模型以及从 STRING 数据库中检索到的已知相互作用网络信息。

自从诸如 AlphaFold [3] 和 RoseTTAFold [4] 这类高精度蛋白质结构预测方法问世以来，许多深度学习模型已被开发出来，利用结构信息来预测蛋白质 - 蛋白质相互作用（PPI）。Topsy-Turvy 3D（TT3D） [11] 进一步扩展了 Topsy-Turvy，通过联合建模氨基酸序列和 3D 相互作用字母表（3Di）序列 [54] 来获取结构特征，该字母表编码了蛋白质主链上距离和角度的结构信息。PrePPI [13] 受模板建模的启发，利用与查询蛋白质具有结构相似性的模板复合物结构中提取的特征来预测 PPI。泽皮

图 1



当前蛋白质 - 蛋白质相互作用预测方法的示意图。

[14] 是 PrePPI 的一个扩展，它利用成对的多序列比对来验证所提出的界面是否与协同进化信息相一致。

其他方法则侧重于将蛋白质结构预测方法拓展以预测蛋白质相互作用。协同进化预测方法，如 EVcomplex2 [55]，为识别表明潜在相互作用的进化残基耦合奠定了基础。在此基础上，能够捕捉协同进化模式的 RoseTTAFold 和 AlphaFold 被用于预测蛋白质相互作用。自 RoseTTAFold 和 AlphaFold 首次用于预测酵母相互作用组以来[5]，许

多方法已应用这些模型及其变体，如 RF2-Lite [7]、AlphaFold-multimer [15] 和 FoldDock [16]，来绘制包括人类线粒体蛋白质[6]、人类病原体蛋白质[7]、非洲猪瘟病毒蛋白质[56]、癌症驱动蛋白质[57]和果蝇蛋白质[17]在内的各种系统中的相互作用网络。在这些研究中，应用了诸如链间接触概率[5]、平均链间预测对齐误差（pAE）[58]、预测对接质量得分（pDockQ）[16]和机器学习分类器[18]等各种指标来评估相互作用的可能性。这种基于蛋白质结构预测的人工智能相互作用筛选方法提供了

不仅能够预测蛋白质是否相互作用，还能预测其结合界面的具体结构，这具有显著的优势。

全蛋白质组范围内的配体结合受体筛选

在本节中，我们将探讨配体结合受体筛选方法的当前状况。筛选方法主要依据受体结构信息的利用情况进行分类，并且还重点关注核心方法（传统方法与基于深度学习的方法）（见图 2）。

基于配体相似性的方法

一类被称为基于配体的方法主要以配体信息作为输入。这些方法基于已知复合物中的配体相似性搜索，其假设是相似的配体极有可能作用于相似的蛋白质。传统的研究方向是选择最适合进行相似性比较的配体信息类型（即分子指纹）。这些方法采用原始的相似性度量或简单的机器学习模型来组合它们，以预测配体结合受体。

自从基于深度学习的方法出现以来，将蛋白质序列作为配体信息的补充输入变得很常见。这类研究通常被称为药物靶点相互作用（DTI）[19e21,59,60]。已发表了一组相关方法，其中包含 5 种


分子表示的不同形式和深度学习架构。例如，在早期阶段，采用了基于一维表示的卷积神经网络（CNN）架构[22]，后来又出现了使用现代深度学习技术的方法[23]。药物-靶点相互作用（DTI）的优势在于能够使用大量训练数据，但其局限性在于预测分辨率；例如，在最近一次激酶筛选的基准测试中，基于非结构的 DTI 方法在各项指标和测试集上的表现普遍不如基于结构的方法[24]。

基于受体结构的方法

早期利用受体结构信息的方法基于分子对接。李等人[61]的研究是早期的范例之一，后来 GalaxySagittarius[2]也发表了。这些方法相较于基于配体的方法，具有提供相互作用结构基础的优势，但由于需要原子级别的受体结构，因此应用范围仍然较小。

首先是受体结构数据库规模的增加。通过纳入dI预测的蛋白质结构，原始方法的适用性得到了相应的扩展[62]。第二是引进先进的深度学习技术。现代技术从蛋白质结构预测，如注意机制或图

图 2



受体筛选及方法类型的示意图。

基于结构的网络中，已有多重表征方法得到实验验证[25,26]。尽管有这些工作，但目前大多数基于结构的蛋白质-配体相互作用网络仍主要侧重于对接[63e65]，我们预计这类网络在不久的将来会发展成为筛选工具。

受体类型特异性研究

一些研究集中于特定的蛋白质家族而非整个蛋白质组。这些研究仍值得提及，因为它们在特定目标方面卓有成效。针对某些家族的研究对于药物再利用或副作用评估具有重要意义。激酶作为重要的癌症治疗靶点，在这一领域得到了最为广泛的研究。在一些案例研究中，已获批药物被筛选针对数百种激酶，以揭示新的激酶作用机制[66]。另一些家族则被用于虚拟毒性筛选，以辅助临床试验。例如细胞色素 P450 (CYP) 和 hERG；它们的意外抑制可能会导致严重的不良反应，如心脏毒性或肝毒性。针对这些受体家族开发特异性逆向筛选方法引起了广泛兴趣[67e69]。

讨论

许多研究声称，其方法如今能够在特定的验证条件下有效地筛选出大多数相互作用和非相互作用的蛋白质对。然而，有大量证据表明，这些说法存在夸大成分，这是由于特定的验证条件所致[70]。我们强调在数据集准备过程中有两个关键领域需要改进，以开发出更具通用性的蛋白质组规模筛选模型。

首先，数据标注需要改进。相互作用通常是短暂且依赖于上下文的。实验技术也已知容易出现假阳性。Topsy-Turvy 的作者认为，其相对于 D-SCRIPT 的性能提升可能源于 GLIDE 分数降低了错误标注数据的影响。明确“相互作用”的定义有助于减少错误标注。例如，STRING 数据库[30]将功能关联视为相互作用，而许多方法则侧重于物理相互作用。区分这些定义可以阐明不同模型的应用。PLI 数据集也存在类似问题。在不同条件下测定的实验值（例如 IC50、EC50、Ki、Kd）被收集并一起使用，但缺乏足够的谨慎。此外，从非结合物中区分结

合物的标准往往是随意设定的，因为实验值往往连续变化。

其次，验证设置应当加以改进。伯内特等人[70]认为，目前对 PPI 模型性能的估计存在夸大现象。他们提供的证据表明，当训练/测试集划分正确地考虑了数据泄露问题时，大多数方法都无法提取出具有物理意义的特征，而是随机预测相互作用。同样，在 PLI 中，广泛使用的非结合数据（称为诱饵）存在可轻易捕获的伪影[71]。在这两个领域中，由于数据划分不当导致的数据泄露一直是性能高估的常见原因。

尽管仍处于早期阶段，基于结构的深度学习方法却具有巨大的潜力。例如，在蛋白质-蛋白质相互作用（PPI）预测方面，已有研究表明，先采用非基于结构的方法进行初步筛选，这种方法能够实现快速、高通量的分析，然后再进行基于结构的筛选，是一种高效的方法[5]。对于蛋白质-靶点相互作用（PLI）也测试了类似的方法[72]。这些方法不仅能够实现大规模预测，还能基于复杂的结构信息提供更多的见解。

然而，尽管这种方法前景广阔，但由于数据限制，对于某些类型的蛋白质-蛋白质相互作用（PPI）或蛋白质-小分子相互作用（PLI）而言，其应用仍具挑战性。要准确确定最终的 PPI 结构，需要有关化学计量比的信息。尽管已开发出几种方法[73,74]来解决这一问题，但它们的适用性和准确性仍有限。此外，涉及内在无序区域的 PPI 在蛋白质数据库（PDB）中代表性不足。在 PLI 研究中，数据限制更为明显。即使使用严格的相似性过滤（如精确配对索引匹配），也仅有约 64,000 个非冗余的 PLI 复合物结构可用，而且这些结构主要以“靶点为中心”，即各种配体仅与少数蛋白质家族（如激酶）结合。

一个关键的挑战在于如何获取足够的结构数据集以支持广泛的模型训练。一旦实现了对蛋白质相互作用（PPIs）和蛋白质-配体相互作用（PLIs）的高精度蛋白质复合物结构预测，结构数据集中的目标覆盖问题可以通过自蒸馏方法来解决[3]。基于深度学习的复合物结构预测的最新进展表明，这一愿景可能很快就会成为现实[65]。

利益冲突声明

作者声明不存在利益冲突。

致谢

M.S.Y、K.K 和 M.B. 由 IITP/MSIT (RS- 项目资助。

2023-00220628), 韩国国家研究基金会/韩国科学与信息通信技术部 (RS-2023-00210147, RS-

(项目编号: 2024-00440824)。B.B 和 H.P 的研究得到了韩国国家研究基金会 (NRF) 的资助 (项目编号: 2022R1C1C1007817)。

数据可用性

该文章所述研究未使用任何数据。

参考文献

在审阅期间发表的特别引人关注的论文已标注为:

* 特别有趣的事物 ** 极其有趣的事物 *

1. Singh R, Park D, Xu J, Hosur R, Berger B: Struct2Net: a web service to predict protein-protein interactions using a structure-based approach. *Nucleic Acids Res* 2010, 38: W508–W515.
 2. Yang J, Kwon S, Bae S-H, Park KM, Yoon C, Lee J-H, Seok C: GalaxySagittarius: structure- and similarity-based prediction of protein targets for druglike compounds. *J Chem Inf Model* 2020, 60:3246–3254.
 3. Jumper J, Evans R, Pritzel A, Green T, Figurnov M, Ronneberger O, Tunyasuvunakool K, Bates R, Zidek A, Potapenko A, et al.: Highly accurate protein structure prediction with AlphaFold. *Nature* 2021, 596:583–589.
 4. Baek M, DiMaio F, Anishchenko I, Dauparas J, Ovchinnikov S, Lee GR, Wang J, Cong Q, Kinch LN, Schaeffer RD, et al.: Accurate prediction of protein structures and interactions using a three-track neural network. *Science* 2021, 373:871–876.
 5. Humphreys IR, Pei J, Baek M, Krishnakumar A, Anishchenko I, Ovchinnikov S, Zhang J, Ness TJ, Banjade S, Bagde SR, et al.: Computed structures of core eukaryotic protein complexes. *Science* 2021, 374, eabm4805.
 6. Pei J, Zhang J, Cong Q: Human mitochondrial protein complexes revealed by large-scale coevolution analysis and deep learning-based structure modeling. *Bioinformatics* 2022, 38: 4301–4311.
 7. Humphreys IR, Zhang J, Baek M, Wang Y, Krishnakumar A, Pei J, Anishchenko I, Tower CA, Jackson BA, Warrier T, et al.: Protein interactions in human pathogens revealed through deep learning. *Nat Microbiol* 2024, 9:2642–2652.
- This study describes a PPI prediction pipeline that utilizes structure prediction deep learning models. The authors analyzed 78 million protein pairs from 19 human pathogens, identifying 1923 complexes involving essential genes and 256 with virulence factors. Experimental validation confirmed half of the 12 tested predictions, offering insights into pathogen biology and potential drug targets.
8. Sledzieski S, Singh R, Cowen L, Berger B: D-SCRIPT translates genome to phenotype with sequence-based, structure-aware, genome-scale predictions of protein-protein interactions. *Cell Syst* 2021, 12:969–982.e6.
 9. Szymborski J, Emad A: RAPPPID: towards generalizable protein-protein interaction prediction with AWD-LSTM twin networks. *Bioinformatics* 2022, 38:3958–3967.
 10. Singh R, Devkota K, Sledzieski S, Berger B, Cowen L: Topsy-Turvy: integrating a global view into sequence-based PPI prediction. *Bioinformatics* 2022, 38:i264–i272.
 11. Sledzieski S, Devkota K, Singh R, Cowen L, Berger B: TT3D: leveraging precomputed protein 3D sequence models to predict protein-protein interactions. *Bioinformatics* 2023, 39.

Topsy-Turvy 与 Foldseek 引入的 3Di 字母表相结合, 通过将蛋白质语言模型嵌入与 3Di 一热编码进行连接实现。两个查询蛋白质之间的嵌入结合方式与 D-SCRIPT 相同, 并使用 Topsy-Turvy 损失函数进行训练, 从而在性能上优于 Topsy-Turvy 和 D-SCRIPT。这表明结合结构信息能够改善蛋白质相互作用概率预测。

12.Ko YS, Parkinson J, Liu C, Wang W: TUNA: 一种用于基于序列的蛋白质-蛋白质相互作用预测的不确定性感知的 Transformer 模型。《生物信息学简报》2024 年, 第 25 卷, bbae359。

TUNA 利用 ESM2 嵌入以及谱归一化神经高斯过程方法来处理蛋白质相互作用预测中的不确定性, 从而在性能上优于 Topsy-Turvy 和 D-SCRIPT。ESM2 嵌入通过两个独立的编码器进行处理, 其中第一个编码器分别处理两个查询蛋白质, 而第二个编码器处理这两个蛋白质嵌入的拼接结果。此外, 对隐藏层应用了谱归一化, 并且用高斯过程层替代了传统的全连接层。

13. Petrey D, Zhao H, Trudeau SJ, Murray D, Honig B: PrePPI: 一个基于结构的全蛋白质组蛋白质-蛋白质相互作用数据库。《分子生物学杂志》2023 年, 435 卷, 168052 页。

Pre-PPI 通过提取预测的查询蛋白质结构的结构特征, 提供了一种利用预计算结构进行蛋白质-蛋白质相互作用 (PPI) 筛选的方法。查询蛋白质的预测结构从 AlphaFold 蛋白质结构数据库中获取, 并通过结构比对在 PDB 中找到相关的蛋白质复合物。基于结构的序列比对被用作计算 PPI 概率的特征。

14. Zhao H, Petrey D, Murray D, Honig B: ZEPPI: proteome-scale sequence-based evaluation of protein-protein interaction models. *Proc Natl Acad Sci U S A* 2024, 121, e2400260121.

15. Evans R, O'Neill M, Pritzel A, Antropova N, Senior A, Green T, Zidek A, Bates R, Blackwell S, Yim J, et al.: Protein complex prediction with AlphaFold-Multimer. *bioRxiv* 2022, <https://doi.org/10.1101/2021.10.04.463034>.

16. Bryant P, Pozzati G, Elofsson A: Improved prediction of

*** protein-protein interactions using AlphaFold2. *Nat Commun* 2022, 13: 1265.**

AlphaFold2 is widely used to predict the structure of protein complexes, detecting positive protein-protein interactions. The authors developed a new method to predict the quality of complex structures named pDockQ. The new method can identify interacting proteins with 51% accuracy at a 1% false positive rate.

17. Kim A-R, Hu Y, Comjean A, Rodiger J, Mohr SE, Perrimon N: Enhanced protein-protein interaction discovery via AlphaFold-multimer. *bioRxiv* 2024, <https://doi.org/10.1101/2024.02.19.580970>.

18. Mischley V, Maier J, Chen J, Karanicolas J: PPIscreenML: structure-based screening for protein-protein interactions using AlphaFold. *Elife* 2024, 13.

19. Singh R, Sledzieski S, Bryson B, Cowen L, Berger B: Contrastive learning in protein language space predicts interactions between drugs and protein targets. *Proc Natl Acad Sci USA* 2023, 120, e2220778120.

20. Gao B, Qiang B, Tan H, Ren M, Jia Y, Lu M, Liu J, Ma W, Lan Y: DrugCLIP. Contrastive Protein-Molecule Representation Learning for Virtual Screening 2023.

21. Goldman S, Das R, Yang KK, Coley CW: Machine learning modeling of family wide enzyme-substrate specificity screens. *PLoS Comput Biol* 2022, 18, e1009853.

22. Zhao Q, Zhao H, Zheng K, Wang J: HyperAttentionDTI: improving drug-protein interaction prediction by sequence-based deep learning with attention mechanism. *Bioinformatics* 2021, 38:655–662.

23. Bai P, Miljkovi

c F, John B, Lu H: Interpretable bilinear attention network with domain adaptation improves drug-target prediction. *Nat Mach Intell* 2023, 5: 126–136.

24. D'Souza S, Prema KV, Balaji S, Shah R: Deep learning-based

*** modeling of drug-target interaction prediction incorporating binding site information of proteins. *Interdiscip Sci* 2023, 15: 306–315.**

本研究展示了将受体的结构信息隐式地融入到配体相互作用预测网络中的一个实例。在激酶筛选的基准测试中，作者表明其利用结合位点信息的方法比以往基于序列相似性的方法取得了更优的结果。

25. Wang P, Zheng S, Jiang Y, Li C, Liu J, Wen C, Patronov A,

** Qian D, Chen H, Yang Y: Structure-aware multimodal deep learning for drug-protein interaction prediction. *J Chem Inf Model* 2022, 62: 1308–1317.

This study has two contributions: first, an unbiased dataset named GalaxyDB was established for PLI benchmarking to mitigate dataset issues in the PLI screening. Second, the authors built a structure-aware DL model for receptor screening using the receptor contact map as an input.

26. Yazdani-Jahromi M, Yousefi N, Tayebi A, Kolanthai E, Neal CJ,

* Seal S, Garibay OO: AttentionSiteDTI: an interpretable graph-based model for drug-target interaction prediction using NLP sentence-level relation classification. *Briefings Bioinf* 2022, 23, bbac272.

The authors introduced an interpretable graph attention mechanism and took receptor pocket information as input to build a PLI prediction network. This work is one of a few methods in which receptor structure information was implicitly considered.

27. Berman HM, Westbrook J, Feng Z, Gilliland G, Bhat TN, Weissig H, Shindyalov IN, Bourne PE: The protein Data Bank. *Nucleic Acids Res* 2000, 28:235–242.

28. Consortium The UniProt, Bateman A, Martin M-J, Orchard S, Magrane M, Ahmad S, Alpi E, Bowler-Barnett EH, Britto R, Bye A-Jee H, et al.: UniProt: the universal protein knowledgebase in 2023. *Nucleic Acids Res* 2022, 51:D523–D531.

29. Oughtred R, Rust J, Chang C, Breitkreutz B-J, Stark C, Willems A, Boucher L, Leung G, Kolas N, Zhang F, et al.: The BioGRID database: a comprehensive biomedical resource of curated protein, genetic, and chemical interactions. *Protein Sci* 2021, 30:187–200.

30. Szklarczyk D, Kirsch R, Koutrouli M, Nastou K, Mehryary F, Hachilif R, Gable AL, Fang T, Doncheva NT, Pyysalo S, et al.: The STRING database in 2023: protein-protein association networks and functional enrichment analyses for any sequenced genome of interest. *Nucleic Acids Res* 2023, 51: D638–D646.

31. Luck K, Kim D-K, Lambourne L, Spirohn K, Begg BE, Bian W, Brignall R, Cafarelli T, Campos-Laborie FJ, Charloreaux B, et al.: A reference map of the human binary protein interactome. *Nature* 2020, 580:402–408.

32. Zdrzil B, Felix E, Hunter F, Manners EJ, Blackshaw J, Corbett S, de Veij M, Ioannidis H, Lopez DM, Mosquera JF, et al.: The ChEMBL Database in 2023: a drug discovery platform spanning multiple bioactivity data types and time periods. *Nucleic Acids Res* 2023, 52:D1180–D1192.

33. Kim S, Chen J, Cheng T, Gindulyte A, He J, He S, Li Q, Shoemaker BA, Thiessen PA, Yu B, et al.: PubChem 2023 update. *Nucleic Acids Res* 2022, 51:D1373–D1380.

34. Knox C, Wilson M, Klinger CM, Franklin M, Oler E, Wilson A, Pon A, Cox J, Chin NE, Lucy, Strawbridge SA, et al.: DrugBank 6.0: the DrugBank knowledgebase for 2024. *Nucleic Acids Res* 2023, 52: D1265–D1275.

35. Liu Z, Su M, Han L, Liu J, Yang Q, Li Y, Wang R: Forging the basis for developing protein–ligand interaction scoring functions. 2017, <https://doi.org/10.1021/acs.accounts.6b00491>.

36. Wei H, Wang W, Peng Z, Yang J: Q-BioLiP: a comprehensive resource for quaternary structure-based protein–ligand interactions. *genom proteom bioinform* 2024, 22, qzae001.

37. Davis MI, Hunt JP, Herrgard S, Ciceri P, Wodicka LM, Pallares G, Hocker M, Treiber DK, Zarrinkar PP: Comprehensive analysis of kinase inhibitor selectivity. *Nat Biotechnol* 2011, 29: 1046–1051.

38. Szklarczyk D, Santos A, von Mering C, Jensen LJ, Bork P, Kuhn M: Stitch 5: augmenting protein–chemical interaction networks with tissue and affinity data. *Nucleic Acids Res* 2016, 44:D380–D384.

39. Durairaj J, Adeshina Y, Cao Z, Zhang X, Oleinikovas V, Duignan T, McClure Z, Robin X, Studer G, Kovtun D, et al.: PLINDER: the protein–ligand interactions dataset and evaluation resource. *bioRxiv* 2024, <https://doi.org/10.1101/2024.07.17.603955>.

40. Gilson MK, Liu T, Baitaluk M, Nicola G, Hwang L, Chong J: BindingDB in 2015: a public database for medicinal chemistry, computational chemistry and systems pharmacology. *Nucleic Acids Res* 2016, 44:D1045–D1053.

41. Tran-Nguyen V-K, Jacquemard C, Rognan D: LIT-PCBA: an unbiased data set for machine learning and virtual screening. *J Chem Inf Model* 2020, <https://doi.org/10.1021/acs.jcim.0c00155>.

42. Mysinger MM, Carchia M, Irwin JJ, Shoichet BK: Directory of useful decoys. Enhanced (DUD-E): Better Ligands and Decoys for Better Benchmarking 2012, <https://doi.org/10.1021/jm300687e>.

43. Collins SR, Kemmeren P, Zhao X-C, Greenblatt JF, Spencer F, Holstege FCP, Weissman JS, Krogan NJ: Toward a comprehensive atlas of the physical interactome of *Saccharomyces cerevisiae*. *Mol Cell Proteomics* 2007, 6:439–450.

44. Berggård T, Linse S, James P: Methods for the detection and analysis of protein–protein interactions. *Proteomics* 2007, 7: 2833–2842.

45. Ma N, Zhang Z-M, Lee J-S, Cheng K, Lin L, Zhang D-M, Hao P, Ding K, Ye W-C, Li Z: Affinity-based protein profiling reveals cellular targets of photoreactive anticancer inhibitors. *ACS Chem Biol* 2019, 14:2546–2552.

46. Pai MY, Lomenick B, Hwang H, Schiestl R, McBride W, Loo JA, Huang J: Drug affinity responsive target stability (DARTS) for small-molecule target identification. *Methods Mol Biol* 2015, 1263: 287–298.

47. Yu Y, Anjum R, Kubota K, Rush J, Villen J, Gygi SP: A site-specific, multiplexed kinase activity assay using stable-isotope dilution and high-resolution mass spectrometry. *Proc Natl Acad Sci USA* 2009, 106:11606–11611.

48. Homogeneous time-resolved fluorescence assay to probe folded G protein-coupled receptors. In *Methods in enzymology*. Academic Press; 2013:169–189.

49. Chen M, Ju CJ-T, Zhou G, Chen X, Zhang T, Chang K-W, Zaniolo C, Wang W: Multifaceted protein–protein interaction prediction based on Siamese residual RCNN. *Bioinformatics* 2019, 35:i305–i314.

50. Bepler T, Berger B: Learning protein sequence embeddings using information from structure. 2019.

51. Lin Z, Akin H, Rao R, Hie B, Zhu Z, Lu W, Smetanin N, Verkuil R, Kabeli O, Shmueli Y, et al.: Evolutionary-scale prediction of atomic-level protein structure with a language model. *Science* 2023, 379:1123–1130.

52. Devkota K, Murphy JM, Cowen LJ: GLIDE: combining local methods and diffusion state embeddings to predict missing interactions in biological networks. *Bioinformatics* 2020, 36: i464–i473.

53. Hu J, Li Z, Rao B, Thafar MA, Arif M: Improving protein–protein interaction prediction using protein language model and protein network features. *Anal Biochem* 2024, 693, 115550.

54. van Kempen M, Kim SS, Tumescheit C, Mirdita M, Lee J, Gilchrist CLM, Söding J, Steinegger M: Fast and accurate protein structure search with Foldseek. *Nat Biotechnol* 2024, 42: 243–246.

55. Green AG, Elhabashy H, Brock KP, Maddamsetti R, Kohlbacher O, Marks DS: Large-scale discovery of protein interactions at residue resolution using co-evolution calculated from genomic sequences. *Nat Commun* 2021, 12: 1–12.

56. Fenster JA, Azzinaro PA, Dinobol M, Borca MV, Spinard E, Gladue DP: African swine fever virus protein–protein interaction prediction. *Viruses* 2024, 16:1170.

57. Zhang J, Pei J, Durham J, Bos T, Cong Q: Computed cancer interactome explains the effects of somatic mutations in cancers. *Protein Sci* 2022, 31, e4479.
 58. Bennett NR, Coventry B, Goresnik I, Huang B, Allen A, Vafeados D, Peng YP, Dauparas J, Baek M, Stewart L, et al.: Improving de novo protein binder design with deep learning. *Nat Commun* 2023, 14 2625.
 59. Huang K, Xiao C, Glass LM, Sun J: MolTrans: molecular Interaction Transformer for drug–target interaction prediction. *Bioinformatics* 2020, 37:830–836.
 60. Lee I, Keum J, Nam H: DeepConv-DTI: prediction of drug-target interactions via deep learning with convolution on protein sequences. *PLoS Comput Biol* 2019, 15, e1007129.
 61. Li H, Gao Z, Kang L, Zhang H, Yang K, Yu K, Luo X, Zhu W, Chen K, Shen J, et al.: TarFisDock: a web server for identifying drug targets with docking approach. *Nucleic Acids Res* 2006, 34:W219–W224.
 62. GalaxySagittarius-AF: Predicting targets for drug-like compounds in the extended human 3D proteome. *J Mol Biol* 2024.
- This work highlights to what extent ligand-binding receptor screening can benefit from the advancement in the recent structure prediction networks. The method itself was inherited from the original GalaxySagittarius, but its applicability has been broadly expanded by taking AlphaFold models for the entire human proteome.
63. Corso G, Stärk H, Jing B, Barzilay R, Jaakkola T: DiffDock. *Diffusion Steps, Twists, and Turns for Molecular Docking* 2022.
 64. Krishna R, Wang J, Ahern W, Sturmfels P, Venkatesh P, Kalvet I, Lee GR, Morey-Burrows FS, Anishchenko I, Humphreys IR, et al.: Generalized biomolecular modeling and design with RoseT-TAFold All-Atom. *Science* 2024, 384, eadl2528.
 65. Abramson J, Adler J, Dunger J, Evans R, Green T, Pritzel A, Ronneberger O, Willmore L, Ballard AJ, Bambrick J, et al.: Accurate structure prediction of biomolecular interactions with AlphaFold 3. *Nature* 2024, 630:493–500.
 66. Preynat-Seauve O, Nguyen EB-V, Westermaier Y, Héritier M, Tardy S, Cambet Y, Feyeux M, Caillon A, Scapozza L, Krause K-H: Novel mechanism for an old drug: phenazopyridine is a kinase inhibitor affecting autophagy and cellular differentiation. *Front Pharmacol* 2021, 12, 664608.
 67. Prediction of potential toxicity and side effect protein targets of a small molecule by a ligand–protein inverse docking approach. *J Mol Graph Model* 2001, 20: 199–218.
 68. Weiser B, Genzling J, Burai-Patrascu M, Rostaing O, Moitessier N: Machine learning-augmented docking. 1. CYP inhibition prediction. *Dig Dis* 2023, 2:1841–1849.
 69. Creanza TM, Delre P, Ancona N, Lentini G, Saviano M, Mangiatordi GF: Structure-based prediction of hERG-related cardiotoxicity: a benchmark study. *J Chem Inf Model* 2021, <https://doi.org/10.1021/acs.jcim.1c00744>.
 70. Bernett J, Blumenthal DB, List M: Cracking the black box of deep sequence-based protein–protein interaction prediction. *Briefings Bioinf* 2024, 25, bbae076.
 71. Chen L, Cruz A, Ramsey S, Dickson CJ, Duca JS, Hornak V, Koes DR, Kurtzman T: Hidden bias in the DUD-E dataset leads to misleading performance of deep learning in structure-based virtual screening. *PLoS One* 2019, 14, e0220113.
 72. Gorgulla C, Nigam A, Koop M, Çönaroglu SS, Secker C, Haddadnia M, Kumar A, Malets Y, Hasson A, Li M, et al.: VirtualFlow 2.0 - the next generation drug discovery platform enabling adaptive screens of 69 billion molecules. *bioRxiv* 2023, <https://doi.org/10.1101/2023.04.25.537981>.
 73. Kshirsagar M, Meller A, Humphreys I, Sledzieski S, Xu Y, Dodhia R, Horvitz E, Berger B, Bowman G, Ferres JL, et al.: Rapid and accurate prediction of protein homo-oligomer symmetry with Seq2Symm. *Res Sq* 2024, <https://doi.org/10.21203/rs.3.rs-4215086/v1>.
 74. Avraham O, Tsaban T, Ben-Aharon Z, Tsaban L, Schueler-Furman O: Protein language models can capture protein quaternary state. *BMC Bioinf* 2023, 24:1–18.