

## 1. 研究问题

### 1) 在预研究的基础上提出所要研究的科学问题

开放式场景客观存在环境复杂，无人驾驶车辆的运动易受到有人驾驶车辆、路边障碍物、红绿灯、行人等外部干扰的影响，造成车群耦合度低，实时性、鲁棒性和持续性无法保证等缺陷，无法满足未来无人驾驶汽车广泛应用的需求。因此，本文立足于国家政策和社会发展对无人驾驶技术的迫切需求，从阻碍无人驾驶发展的核心瓶颈问题出发，凝练出无人驾驶车群自协的一个关键科学问题：在外部干扰的情况下实现无人驾驶车群内部实现信息保真和自协忠实

(1) 针对开放式无人驾驶车群环境复杂形态的感知需求，保障数据解析准确、准确地刻画和反映感知环境，满足车群运动行为决策智能化的信息输入要求，达成信息保真；(2) 针对无人驾驶车群环境的多变性需求，保持感知需求卸载、感知贡献持续稳定，实现车群动态演化及其内部自协的实时与稳定的执行过程，满足车群运动行为智能化的预期目标达成自协忠实。实现无人驾驶车群完备性（实时性，耦合性，持续性，演变性，收敛性，鲁棒性，稳定性）自协，从而使得无人驾驶车群依靠持续、稳定、实时的感知贡献快速实现车群的自治协同，达到运动行为智能化的目的，围绕关键科学问题，本文拟从设计方法、理论模型以及优化方法三个层面开展研究。将为无人驾驶车群能够自协的有序行驶和合理汇聚提供解决方案，为推动未来无人驾驶车群运动行为智能化发展提供重要的理论基础和应用价值。

围绕无人驾驶车群信息保真执行忠实关键科学问题，本文基于边缘计算的思想研究无人驾驶车群自协方法。首先，在开放式环境下客观存在多维特征的基础上，利用深度学习技术解析无人驾驶边缘节点与边缘数据的时空关系，并构建基于无人驾驶车辆边缘节点与感知环境时空关系的边缘数据解析模型。然后，利用边缘数据解析模型求解车辆节点间感知贡献的影响因素。基于边缘数据解析模型求解得到的遮挡度，对边缘感知数据进行量化。为了度量车辆节点之间通过感知贡献需要贡献给其他车辆节点的感知信息，构建感知贡献模型从而得到感知贡献度。之后，基于感知贡献影响因素与感知贡献模型得到的感知贡献度进一步构造无人驾驶车辆节点之间可以持续进行感知需求卸载与感知贡献的车群。同时，基

于车群的贡献度以及车群的实时性、耦合性和持续性构建无人驾驶车群模型并基于多目标优化方法对无人驾驶车群模型进行求解。之后，为了深入剖析车群的动态演化行为，挖掘车群的内部变化的一般性规律，揭示车群的演变性，达到自协忠实的目的。全面综合考虑开放式环境下动态演化过程，本文把开放式无人驾驶车群动态演化事件分为五类：加入，离开，消亡，合并，分裂；将无人驾驶车群状态分为四类：增长状态，平衡状态，收缩状态和消亡状态并分别提出无人驾驶车群动态演化过程的处理算法。然后，基于车群动态演化行为，考虑车群的演变性，稳定性，鲁棒性，收敛性构建无人驾驶车群自协理论模型。最后，本文设计一个包含无人驾驶车辆、有人驾驶车辆、障碍物和红绿灯的模拟应用场景，验证无人驾驶车群自协方法的有效性和正确性。

## 2) 研究背景及选题依据

当前，人工智能飞速发展，汽车产业迈入汽车+人工智能的生态。被视为 21 世纪公路交通智能化标志的无人驾驶技术，将从根本上改变人类的驾驶方式，或许将全面颠覆传统汽车行业。它也是衡量一个国家科研实力和工业水平的一个重要标志，在国防和国民经济领域具有广阔的应用前景。无人驾驶汽车受到空前重视，国内外巨头企业纷纷投入重金研发相关技术。然而，现阶段无人驾驶仍停留在功能完善，技术实现，道路测试和试乘阶段。在开放式路网环境下，无人驾驶与有人驾驶共存，并受到红绿灯、障碍物等外界因素的“干扰”，也导致了新的交通安全、交通拥堵、空气污染等问题。

- **交通安全** 世界卫生组织统计表明，全球范围内每天都有几千人死于人为误操作引发的车祸。随着无人驾驶汽车的出现，也将会为交通安全增加新的难题。密歇根大学交通运输研究所研究报告指出，谷歌与特斯拉等自动驾驶测试过程中每行驶 100 万英里交通事故率是普通汽车的 5 倍。尽管大部分是第三方责任，但究其细责可以发现，目前无人驾驶技术存在很多还不够合理的逻辑：比如在变线时总是默认后车会礼让；在探测到障碍物时做出自认为完全正确且合理的行为，即及时刹车停稳，没有任何处理措施，相较于有人驾驶可以轻易避免的事故，无人驾驶却没能做到。造成上述问题原因在于，目前无人驾驶独立依靠自身传感设备获取周围信息来识别理解情境后进行决策。

● **交通拥堵** 目前，我国大城市面临日益严重的交通拥堵问题，已经影响到城市的整体发展水平，缓解交通拥堵是保障和促进经济社会发展、改善民生的必然要求，也是政府必须履行的重要职责。道路拥堵成本也在连年上升，40%的车主每天至少被拥堵问题困扰一次，交通拥堵已成为阻碍社会经济发展的重大问题之一<sup>[1]</sup>。目前解决交通拥挤的方法是以减少单位面积道路内的汽车数量为原则。无人驾驶汽车是一种可以以较高速度或高速运动的机器人，能够感知行驶环境，进行自主决策，依靠运动学或者动力学规划行驶路径，并控制车辆跟踪期望路径，达到设定的目的地，完成预定任务<sup>[2,3]</sup>。根据一份来自毕马威会计事务所的研究报告，无人驾驶汽车能够将高速公路的汽车容量增加 5 倍。斯坦福大学计算机科学家，同时也是前谷歌无人驾驶汽车团队成员 Sebastian Thrun 表示，一旦无人驾驶汽车成为主流，仅需要目前路面上 30%的车辆。尽管如此，现今无人驾驶模式缺少交互认知能力，正如李德毅院士指出，一旦受到外界环境因素的干扰（如人类驾驶车辆），这个自动驾驶的门槛立马崩溃，几乎全部转为人工驾驶<sup>[4]</sup>，从而为交通拥堵又增加了新的难题。

● **空气污染** 近年来随着汽车经济的飞速发展，汽车的生产和使用量急剧增长，汽车排气对环境的污染日趋严重，许多大城市的空气污染已由燃煤型污染转向燃煤和汽车混合型污染，汽车排气污染对环境和人们身体健康的危害已相当严重。据各地监测分析，汽车尾气排放量已占大气污染源 85%左右。根据麦肯锡一份报告，无人驾驶汽车每年能够帮助减少 3 亿吨汽车二氧化碳排放量。然而，随着无人驾驶技术的日益成熟，无人驾驶汽车数量也将日益增长。

● **国家政策** 近年国务院办公厅 2020 年 10 月发布的《新能源汽车产业发展规划（2021—2035 年）》提出，到 2025 年，高度自动驾驶汽车实现限定区域和特定场景商业化应用，力争经过 15 年的持续努力，高度自动驾驶汽车实现规模化应用。尽管如此，我国人工智能整体发展水平与发达国家相比仍存在差距，缺少重大原创成果，在基础理论、核心算法等方面差距较大，亟需建立新一代人工智能基础理论体系。

本文立足于国家政策和社会发展对无人驾驶技术的迫切需求，从阻碍无人驾驶发展的核心瓶颈问题出发，凝练出一个关键科学问题：无人驾驶车群的信息保

真和自协忠实，基于边缘计算思想，针对开放式无人驾驶车群环境复杂形态的感知需求，保障信息解析准确、准确地刻画和反映路网环境，满足车群运动行为决策智能化的信息输入要求，达成信息保真；针对无人驾驶车群环境的多变性需求，保持感知贡献持续稳定，实现车群动态演化及其内部自协的实时与稳定的执行过程，满足车群运动行为智能化的预期目标达成自协忠实。从而使得无人驾驶车群根据当前复杂环境快速实现自治协同，达到运动行为智能化的目的。围绕关键科学问题，本文拟从设计方法、理论模型以及优化方法三个层面开展研究。将为无人驾驶车群能够持续进行感知贡献且自协的有序行驶和合理汇聚提供解决方案，为推动未来无人驾驶车群运动行为智能化发展提供重要的理论基础和应用价值。

### 3) 研究目标

本文针对无人驾驶车群自协，结合开放式无人驾驶车群路网环境复杂形态的特点，利用边缘计算，深度学习和动态演化等方法，从需求的多样性和环境的多变性出发，围绕无人驾驶车群复杂形态的动态演化行为和自协模型展开研究，从而为无人驾驶车群的运动行为在开放式路网环境下能够自协提供理论体系和方法保障，满足无人驾驶车辆得以大规模应用的需求。预期达到以下目标：

- ① 引入深度学习技术解析开放式场景下无人驾驶边缘感知数据，保障数据解析和感知贡献真实准确，解决信息保真问题；
- ② 提出一个基于边缘计算思想求解车群节点之间感知贡献关系随时间变化仍然能够持续感知贡献的自协理论模型，以解决自协忠实问题；
- ③ 建立一套适合于新型无人驾驶车群自协理论体系，有效支撑以“数据解析→感知贡献→车群构建→动态演化→模型自协”为主导思想的无人驾驶车群运动行为智能化；
- ④ 提出一种基于模拟应用场景的无人驾驶车群自协验证方法，验证了自协模型的正确性。

### 4) 理论意义或应用价值

本文在开放式路网环境下无人驾驶车群动态演化过程中保持自协的设计方法上的突破对提升无人驾驶技术创新能力有着重要的支撑意义。无人驾驶车群是

由节点之间相互协调、渗透和制约而构成的一个复杂系统，车群内部任何一个节点的微弱变化都会引起无人驾驶车群的相应变化，同时任何一个节点又无时不受自身感知信息变化的影响。边缘计算是为应用开发者和服务提供商在网络的边缘侧提供云服务和 IT 环境服务；目标是在靠近数据输入或用户的地方提供计算、存储和网络带宽。边缘计算将计算能力下沉，在靠近终端用户的网络边缘对时延敏感信息进行及时地处理，大大缩短了时延且实现了计算资源的弹性利用；通过分析发现，边缘计算思想的在复杂的开放式无人驾驶车群系统结构合理应用可以更好的实现车车协同中的感知需求的实时卸载与分析动态演化中感知贡献关系的变化。因此，本文从边缘计算思想出发，力图描述无人驾驶车群系统在内外外部作用下其感知贡献变化的条件和行为，并对车群的状态改变进行描述并分析其变化的原因和机制，从新的角度审视复杂形态的无人驾驶车群动态演化问题，从而为开放式无人驾驶车群动态演化过程中保持自协提供新的解决方法。

其次，本文研究和建立的无人驾驶车群自协理论模型对未来无人驾驶车群运动行为智能化发展有着重要的理论指导意义。目前无人驾驶的科学研究和设计开发主要集中于单智能体独立识别理解情境后进行决策以及封闭式无人驾驶车群自协，适用于小尺度闭环系统中的理论和方法，难以有效解决无人驾驶车群在有人驾驶，障碍物以及红绿灯等干扰情况下的自协问题，不能支持车群内部实现数据真实准确和动态演化实时与稳定。因此，本文针对开放式无人驾驶车群自协问题展开研究，形成规范系统的无人驾驶车群自协理论模型，这对无人驾驶汽车大规模应用的发展有着重要的理论指导意义。

最后，开放式无人驾驶车群理论体系和关键技术的研究是无人驾驶应用发展的“重中之重，急中之急”。正是在上述背景下，本文提出了开放式路网环境下无人驾驶车群动态演化行为的设计方法和理论模型，解决无人驾驶车群自协问题，对促进无人驾驶健康快速发展、满足国家经济和科技发展需求，以及提升我国在无人驾驶领域的核心竞争力上有着重要的理论和技术支撑意义。

## 2. 文献综述（不得少于 3000 字）

### 1) 无人驾驶智能化与网联化发展现状

自动驾驶汽车是一种可以以较高速度或高速运动的机器人，能够感知行驶环境，进行自主决策，依靠运动学或者动力学规划行驶路径，并控制车辆跟踪期望路径，达到设定的目的地，完成预定任务<sup>[2,3]</sup>。自动驾驶车辆能够在交通事故发生之前进行预防<sup>[5]</sup>，改变传统车辆安全技术采用的被动保护机制<sup>[6]</sup>。

2013 年，美国国家公路交通安全管理在“关于自动化汽车的初步政策声明”中，将自动驾驶分为五个阶段来实现：L0：非自动化，传统驾驶汽车；L1：特定功能自动化，驾驶员有全面的控制权，自动化系统可以帮助或增加驾驶员对某项主要控制系统操作；L2：半自动化驾驶，在某些特定驾驶情景下，自动化系统能完成紧急自动刹车、车道辅助、自动泊车等，一般称为高级驾驶辅助系统(ADAS)；L3：高度自动化驾驶，驾驶员在某些路况或环境下可以不用完全掌控所有安全攸关的功能；L4：无人驾驶，汽车能在全程完全掌控所有与安全攸关的驾驶功能，并监视道路环境。

国际自动机械工程师学会(Society of Automotive Engineers, SAE)按汽车自动化程度分为 6 级，分别对应完全手动驾驶，辅助驾驶，部分模块自动化，特定条件下自动化，高度自动化以及全自动化的无人驾驶。此外，欧洲道路交通研究咨询委员会发布“自动驾驶路线图”，与 SAE 划分方式较为相似，也将自动驾驶技术分为了 6 级。

2016 年，中国汽车工程学会将智能网联汽车按智能化与网联化两个层面进行分级。在智能化方面，划分为五级：第一级为驾驶资源辅助阶段 DA，通过环境信息对一项车辆操作提供支持；第二级是部分自动化阶段 PA，通过环境信息对多项车辆操作提供支持；第三级是有条件自动化阶段 CA，由无人驾驶完成基本操作，必要时由人进行控制，已经开始处于小规模研发和实验阶段，如在高速公路等特别条件下实现无人驾驶，但紧急情况下仍需要驾驶员的干预；第四阶段是高度自动化阶段 HA，无人驾驶完成所有操作，特定环境下会对驾驶员提出响应要求，但驾驶员可以不进行响应；第五级是完全的自动化阶段 FA，车辆自动系统可以在人类驾驶员可操作的所有条件和环境下完成所有驾驶操作。在网联化方

面按照通信内容不同，可以划分为三个层级：第一级为网联辅助信息交互，传输相关交通信息等；第二级为网联协同感知，实现车与车、车与路实时状态信息发送，与车载传感器感知信息融合，作为自主决策与控制系统的输入；第三级为网联决策与控制，基于 V2X 通信，实时并可靠获取车辆周边交通环境及车辆决策信息，车-车、车-路等各交通参与者之间信息进行交互融合，形成车-车、车-路等各交通参与者之间的协同决策与控制<sup>[7]</sup>。

## 2) 无人驾驶单智能体运动行为研究现状

无人驾驶车辆利用传感设备感知周围车辆的运动变化，根据自身单体智能行为，对环境变化做出准确的判断，实时对车辆控制，保证车辆行驶安全。目前相关研究人员在行驶轨迹规划，运动规划，节点移动模型方面进行了相关研究。具体如下：

### ① 行驶轨迹规划

现今研究主要通过车辆运动学与动力学来设立模型预测控制器，实现车辆的轨迹跟踪功能<sup>[8]</sup>，主要体现在巡航定速、强行换道以及保持安全车距等方面。其中，Kim 和 Malik<sup>[9]</sup>考虑在车辆动力学约束下车辆轨迹规划，实现了连续曲率轨迹规划。Elkabbany<sup>[10]</sup>根据车辆动力学参数，速度-曲率方式来计算运动轨迹。Gao 等<sup>[11]</sup>为了减少系统复杂度，在车辆动力学约束下，以车辆质心为原点，建立车辆圆点模型下的轨迹规划，同时也考虑车辆侧向受力对轨迹规划影响。Ansari 和 Murphey<sup>[12]</sup>提出了一种基于线上计算和闭环最优控制的应用于传统非线性控制的算法，实现在一个较长的时间跨度内提高跟踪目标精度。Kayacan 等<sup>[13]</sup>提出一个考虑估计跟踪误差的模型，在基于轨迹跟踪误差模型中设计了线性预测控制器，实现减少误差，提高系统精度的目的。

### ② 运动规划

运动规划的主要目的是规划出驱使机器人从当前位置运动到目标位置的一系列指令。随着智能汽车的兴起，以无人车为研究对象的运动规划问题也越来越受到研究者的重视。目前研究者对车辆运动规划算法开展了研究，取得了如下成果：

Bohren 等<sup>[14]</sup>提出了一个基于陆上无人驾驶汽车传感、规划、导航和驱动系统的设计方案,以使得车辆能够在不确定的城市环境中行驶。Chen 等<sup>[15]</sup>描述了参赛车辆的整体系统架构、传感器以及传感器信息的处理过程、任务规划系统以及车辆的自主行为控制。Patz 等<sup>[16]</sup>论述了传感器数据的处理方法、车辆的转向控制方法并提出了一种无人驾驶汽车在城市环境中进行有效导航的实用方法。Anderson 等<sup>[17]</sup>提出了一种应用于半自治性的无人驾驶车辆危险避免以及稳定性控制的新方法。Bacha 等<sup>[18]</sup>采用了一个混合的协商/反应架构来分析当前的情况并选择适当的行为,使得车辆能在面临交叉路口、道路合并、自动泊车以及障碍规避时规划出一条安全的路径。Kala 与 Warwick<sup>[19]</sup>提出了一个 4 层规划算法,包括道路选择,路径选择,路径分布和轨迹生成。Michael 等<sup>[20]</sup>提出了一种无人驾驶汽车的架构模型,能够感知并与其他车辆进行相互作用、执行各种城市环境下的驾驶操作。Dolgov 等<sup>[21]</sup>使用改进后的 A\*算法来获得可行的运动轨迹并通过数值非线性优化来提高轨迹的质量。Gu 等<sup>[22]</sup>提出了一种新颖的双层运动计划系统,在单一框架下解决城市和高速公路这两种情况下的无人驾驶问题。Werling 等<sup>[23]</sup>提出了半反应式规划策略,有效实现了车辆的长期机动任务,例如换道,合并,保持距离,保持速度,精确停止等并能够长期避免碰撞。

Kuwata 等<sup>[24]</sup>提出了一种在快速探索随机树中使用闭环预测的实时运动规划算法,适用于在城市环境中运行的无人驾驶车辆。Ryu 等<sup>[25]</sup>对高速公路上的无人驾驶车辆就障碍规避开发了远程地形感知、实时路径规划和高速车辆运动控制算法。Jeon 等<sup>[26]</sup>研究了基于 RRT 的最优运动规划算法在高速无人驾驶中的应用,并讨论基于车辆动力学模型的 RRT 的实现。Kala 和 Warwick<sup>[27]</sup>在多种交通场景下利用快速探索随机树对多辆车进行规划,其中每辆车的规划器使用 RRT 来试图找出车辆可以行驶的最大速度和相应的路径。

Broggi 等<sup>[28]</sup>针对在未知环境中运行的无人驾驶车辆设计了一个通用路径规划器。Vorobieva 等<sup>[29]</sup>对无人驾驶汽车的平行停车问题提出了一个基于车辆运动学模型的路径规划算法。Fuji 等<sup>[30]</sup>使用状态路线图来计算由正向和反向运动组成的复杂停车轨迹。Brezak 和 Petrovic<sup>[31]</sup>提出了一个实时计算回旋坐标的方法,可以保证在大范围的回旋参数上产生很小的近似误差。Coombs 等<sup>[32]</sup>通过基于动态可行的梭形曲线规划器规划车辆的直接路径,并以更高的速度增加障碍物的横向



间隙，从而确保在定速巡航下的障碍规避以及车辆控制。Petrov 和 Nashashibi<sup>[33]</sup>提出了一个双车辆自动超车的机动非线性自适应控制器，并且论述了在超车操作期间车辆的一般运动学模型。Christoph 等<sup>[34]</sup>结合传感、情景分析、决策以及车辆控制提出了对行人行为进行预测的安全系统，能够在较高车速的情况下在短时间内快速决定车辆是否执行自动制动或回避转向操作。Rastelli 等<sup>[35]</sup>在考虑了直线段和弯曲段结构变化的基础上提出了一种在城市环境中动态生成路径的算法，能够生成平滑和安全的路径，并保证了舒适的横向加速度。Pérez 等<sup>[36]</sup>在结合参数方程的城市场景下考虑了真实车辆的贝塞尔曲线和周长参数提出了一种实时的无人驾驶车辆轨迹生成新方法。Han 等<sup>[37]</sup>提出了一种基于贝塞尔曲线的路径规划器，可以通过估计周围物体的轨迹和行为来实现无人驾驶汽车的防撞行为。Liang 等<sup>[38]</sup>对停车轨迹进行规划，利用贝塞尔曲线对圆弧上产生的轨迹进行平滑处理，最终生成具有连续曲率的轨迹。

### ③ 无人驾驶车辆节点移动模型

车辆移动过程并不是一种随机过程，车辆节点在行驶过程中，运行轨迹是在道路中进行，不仅需要考虑物理学规律中力作用下的运动方式，还需要考虑路网环境变化对自身刺激作出相应的反应和动作。因此，必须考虑车辆的加速，减速，停止，跟驰，以及换道等行为参数，建立车辆节点模拟人类驾驶行为的模型，根据移动模型控制车辆来保证车辆间的安全行驶距离，进行避险。Fiore 等<sup>[39]</sup>在 IDM 模型基础上进行了发展，将单车道 IDM 扩展到可以适应多车道以及交叉路口等交通场景。Zheng 等<sup>[40]</sup>提出了一种在快车道与慢车道环境下执行车辆换道模型，不会因车速差异导致车辆换道的失败。

## 3) 边缘计算在无人驾驶中应用研究现状

“边缘计算是为应用开发者和服务提供商在网络的边缘侧提供云服务和 IT 环境服务；目标是在靠近数据输入或用户的地方提供计算、存储和网络带宽”。边缘计算将计算能力下沉，在靠近终端用户的网络边缘对时延敏感信息进行及时地处理，大大缩短了时延且实现了计算资源的弹性利用，是目前公认的可以辅助无人驾驶达到实时性指标的关键技术之一。

Jie 等<sup>[41]</sup>将边缘计算技术应用至无人驾驶中高精地图的探测上，将服务下沉

到网络边缘,为高精地图提供了业务近距离部署和本地化的条件,极大地节省了链路数据资源,提高地图服务业务效率,支持更优的用户体验<sup>[42]</sup>。Feng 等<sup>[43]</sup>介绍了一种分布式的车辆边缘计算解决方案,自动车辆边缘(AVE),它使相邻车辆的可用资源通过车对车(V2V)通信成为可能。然后,将这一概念扩展到一种更通用的在线解决方案,混合车辆边缘云(HVC),通过使用多接入网络,它能够有效地共享所有可访问的计算资源,包括路边设备(rsu)和云。并且展示了这两种分散边缘计算解决方案对任务执行性能的影响。Bhatnagar 等<sup>[44]</sup>基于边缘计算的思想提出了一种新颖而简单的空间域多车辆传感器融合技术,该技术相较于传统技术有着更快的速度,可以更好的适用于无人驾驶的应用场景。Cui 等<sup>[45]</sup>提出了基于边缘计算的多车协同建图方法,能够有效地负载均衡,在保证单个车辆精准定位的同时,增加多个车辆之间的地图重用性。

#### 4) 无人驾驶车群自治协同研究现状

开放式无人驾驶复杂路网的环境,使得无人驾驶车辆节点运动行为存在高度的易变性,如何采取有效机制发掘无人驾驶车群动态演化的一般性规律和相互作用下的影响机制,构筑完备的自协系统,是保证无人驾驶车群行驶稳定有序所面临的一个难点。

Ploeg<sup>[46]</sup>设计了 CACC 系统并提出一种新的非线性级联系统的协同稳定性定义,采用前方车辆信息作为基础进行分析,强化了系统协同的稳定性。Alonso 等<sup>[47]</sup>设计了 DRIVERTIVE 算法,采用状态估计、数据融合、数据退化等技术,对自动驾驶车群的合并和通过路口的情况进行了研究实验,证明了协同自动驾驶的可行性。Obst 和 Reisdorf<sup>[48]</sup>基于 V2V 通信以及数据融合方法,提出了一种用于增强观测范围的多目标追踪算法,融合多车辆的传感器观测信息,保证了无人驾驶车群的协同驾驶。Themann 等<sup>[49]</sup>采用了离散动态优化的方法对无人驾驶车辆的协同性进行优化,并结合 V2X 信息对车辆的纵向动力学进行分析,使得车群能够实现协同。Hao<sup>[50]</sup>等针对目前无人驾驶运动智能行为存在的问题,基于高速公路场景,提出了一种车辆节点之间可以有目的的信息交互,保持互联互通的车群模型架构,从而有效满足未来无人驾驶运动行为智能化所需要的模型和方法。Minjun<sup>[51]</sup>在图嵌入算法和有限状态自动机的理论支持下,给出了在封闭式场景无人驾驶车群模型,保障了车群、车群与车群之间能够有序、稳定的运行。

#### 4) 无人驾驶动态演化环境下高维数据的复杂关系处理的研究现状

无人驾驶路网环境的复杂性，决定了无人驾驶动态演化过程存在高维数据的复杂关系，如何采取有效机制发掘车辆节点之间数据中的一般性规律和关联性特征，是解决无人驾驶自协问题所面临的一个难点。近些年，由于深度学习的优势，在无人驾驶领域取得了一些进展，主要体现在三个方面：图像识别、运动控制、行为决策。

##### ① 图像识别

图像识别是无人驾驶进行环境感知的基础。得益于深度学习技术在图像识别中的日益成熟，无人驾驶技术也随之得到快速发展。Viola 和 Jones<sup>[52]</sup>提出基 AdaBoost 算法框架，使用 Haar-like 小波特征分类，然后采用滑动窗口搜索策略实现准确有效地定位。Dalal 等<sup>[53]</sup>提出使用图像局部梯度方向直方图作为特征，利用支持向量机作为分类器进行行人检测。自然界的大部分物体具有运动能化会发生非刚体形变，为此 Felzenszwalb 等<sup>[54]</sup>化 W 提出了目标类别检测最具影响力的方法之一，多尺度形变部件模型。Malisiewicz 等<sup>[55]</sup>提出一种简单高效的集成学习算法用于目标类别检测，该方法分别为每个正样本训练一个使用图像局部梯度方向直方图特征的线性支持向量机，通过集成每个样本的线性支持向量机结果达到优良的泛化性能。Kai 等<sup>[56]</sup>认为先前基于图像局部梯度方向直方图特征的检测方法图像局部梯度方向直方图特征是人为设计的，判别能力弱且不直观，为此提出一种基于稀疏表达学习理论的稀疏编码直方图特征。Krizhevsky 等<sup>[57]</sup>提出基于深度学习理论的深度卷积神经网络的图像分类算法，使图像分类的准确率大幅提升，同时也带动了目标检测准确率的提升。Erhan 等<sup>[58]</sup>使用深度卷积神经网络对目标的包围盆进行回归预测，并给出每个包围盒包含类别无关对象的置信度。Krizhevsky<sup>[59]</sup>等设计了 Alexnet 深度学习模型，在 Imagine 图像识别竞赛中大放异彩，证明了深度学习在复杂模型下进行图像识别的有效性。He 等<sup>[60]</sup>提出了一种新型的深度学习模型，通过残差映射的方式，解决神经网络中由于层次加深导致的精准度下降问题，大大提高了图像识别的准确度。

##### ② 运动控制

在无人驾驶的运动控制研究领域，深度学习主要应用在端到端模型中。动作

控制试图解决在一定的约束条件下优化局部范围内的时空路径问题。端到端直接学习从输入到输出的映射关系，在无人驾驶中指的是输入视频序列、输出刹车油门方向盘等操作序列。LeCun 等<sup>[61]</sup>采用卷积神经网络技术设计出 DAVE 无人驾驶系统，通过深度学习控制运动行为，可以学习无人驾驶中的整个流程，展示了深度学习在无人驾驶中的潜能。普林斯顿大学提出的 DeepDriving 模型<sup>[62]</sup>，通过对驾驶行为的预估，将深度学习与规则控制相结合，提高了对无人驾驶场景的抽象能力，有效加强了无人驾驶运动控制的鲁棒性。百度自动驾驶开放平台 RoadHackers<sup>[63]</sup>与 Santana 等<sup>[64]</sup>针对传统卷积网络对纵向控制不敏感的缺点，采用 LSTM 与 CNN 相结合的技术，强化了无人驾驶车辆对纵向控制的预测。Codevilla 等<sup>[65]</sup>提出在深度网络中引入条件模仿学习，实现了通过高阶的运动意图对低阶的实际驾驶操作进行条件控制。

### ③ 行为决策

无人驾驶中，行为决策是指根据给定路网文件获得的交通环境信息和自身行驶状态，自主产生遵守行驶规则的决策过程。由于真实环境下很难模拟出所有突发情况，因此需要诸如强化学习的方法在训练和测试过程中学习一系列正确的行为，从而保证无人驾驶行为决策的安全性。Shalev-Shwartz 等<sup>[66]</sup>在 2016 年提出强化学习在无人驾驶中的应用，针对无人驾驶中的安全保障和存在未知因素等问题，通过对未来场景进行预判，训练强化学习模型，从而解决了长期驾驶策略的问题。Such 等<sup>[67]</sup>在 2017 年提出利用神经演化方法进行训练的强化学习模型，解决了局部最优等欺骗性问题，使得无人驾驶模型能够应对更多传统机器学习算法难以处理的突发情况。Intel<sup>[68]</sup>利用已有控制数据训练网络，完成端到端的自动驾驶。其在网络中考虑了方向性的控制指令（直行、左转、右转），使得网络可以在车道保持的同时完成转弯等操作。Comma.ai<sup>[69]</sup>利用 CNN，并且几乎只用 CNN 来构造决策系统。该系统将图像导入网络，通过网络输出命令调整转向盘和车速，从而使车辆保持在车道内。根据 Comma.ai 公布的数据，该公司目前已经累计行驶约  $1.35 \times 10^6$  km，累计行驶时间为 22000h，累计用户 1909 人。将深度强化学习<sup>[70]</sup>应用于自动驾驶中，从随机初始化的参数，该模型使用单一的单眼图像作为输入，提供一个通用且容易获得的奖励：车辆行驶的距离。该模型使用一种连续的、无模型的深度强化学习算法，所有的探索和优化都在车上进行。提出了一个新的

自动驾驶框架，它摆脱了对定义的逻辑规则、映射和直接监督的依赖。部分研究使用一个卷积神经网络<sup>[71]</sup>，将单个前置摄像头的原始像素直接映射到转向指令。通过最少的训练数据，该系统学会了在有或没有车道标记的地方道路和高速公路上驾驶。相对于车道标记检测、路径规划和控制等问题的显式分解，该端到端系统同时优化了所有处理步骤。Bojarski 等<sup>[72]</sup>研究的网络能够学习类似车道标记、道路边界和其他车辆形状的特征。Gurghian 等<sup>[73]</sup>通过使用两个侧面安装的摄像头，以端到端的方式估计车道内的位置，从而以横向车道位置的输出来控制车辆。类似地，Chen 等<sup>[74]</sup>训练了一个网络来输出可视性指标，即车道内的位置和方向以及相对于其他车辆的其他度量。基于这种简单的表示，控制器随后计算速度和转向命令。Xu 等<sup>[75]</sup>利用大规模驾驶视频数据集训练端到端的全卷积长短时记忆网络，在基于任务的水平上预测多模态离散行为(如直线、停止、左转、右转)和连续驾驶行为(如方向盘角度控制)。端到端运动规划也被应用到机器人技术中，例如，从操作员那里模拟学习导航策略<sup>[76]</sup>。为了在连续动作空间上进行操作，Lillicrap 等<sup>[77]</sup>提出了一种基于确定性梯度策略的深度强化学习算法。该算法能够在模拟的汽车驾驶环境中让车辆学习如何保持在赛道上。

## 5) 无人驾驶路网环境下仿真与实验环境的研究现状

目前在开放式实际场景下无人驾驶仿真实验的数据集和环境仿真器方面，研究人员做了大量工作并取得了一些研究成果。

### ① 仿真实验数据集

RobotCar 数据集<sup>[78]</sup>包含时间范围超过 1 年，测试超过 100 次的相同路线的驾驶数据。数据集采集了天气、交通、行人、建筑和道路施工等不同组合的数据。德国卡尔斯鲁厄理工学院和丰田美国技术研究院联合创办了 KITTI 大规模数据集<sup>[79]</sup>，通过多种传感器采集包括市区、乡村和高速公路等场景真实图像数据，是目前国际上最大的自动驾驶场景评测数据集。

### ② 仿真框架

无人驾驶仿真实验框架主要包括两部分：交通仿真和网络仿真。交通仿真负责生成车辆节点移动轨迹的拓扑图。目前存在多种移动模型来模拟车辆节点的移动，包括：合成模型(Synthetic Model)，基于调查的模型(Survey-based Model)，基

于真实轨迹的模型(Trace-based Model)，基于交通流仿真器的模型(Traffic Simulator-based Model)<sup>[80]</sup>。网络仿真主要通过网络仿真器完成。目前常用的网络仿真器有：OPNET<sup>[81-83]</sup>、QualNet<sup>[84,85]</sup>、ns-2<sup>[86-88]</sup>、ns-3<sup>[89-91]</sup>、J-Sim<sup>[92,93]</sup>、OMNeT++<sup>[94-97]</sup>、OMNEST<sup>[98]</sup>和 SWANS<sup>[99,100]</sup>。

### ③ 环境仿真器

无人驾驶仿真包括环境和网络两方面：前者模拟真实场景下无人驾驶车辆的周边环境，并根据相应环境产生车辆的运动轨迹；后者利用环境仿真器产生的运动轨迹记录，对无人驾驶车辆的网络进行仿真。Harri 等<sup>[101]</sup>将车辆移动模型分为四类：合成模型，即通过数学模型来确定车辆移动；基于调查的模型，即根据调查提取移动规律；基于轨迹的模型，即通过真实的轨迹来产生移动规律；基于交通仿真的模型，即从一个交通仿真器中提取移动轨迹。Van 等<sup>[102]</sup>调研了常用的信道模型并从实现的角度将它们分成两类：确定型模型；概率模型。Sommer 等<sup>[103]</sup>通过在真实道路的测量发现，常用的双径地面反射路径损耗模型并不比基本的自由空间模型好，而双径干涉模型有更好的拟真度。

附：参考文献

序号	文献目录
1	Cohn N, Kools E, Mieth P. The tomtom congestion index[C]// 19th ITS World Congress. 2012.
2	龚建伟, 姜岩, 徐威. 无人驾驶车辆模型预测控制[M]. 北京理工大学出版社, 2014.
3	熊光明, 高利, 吴绍斌. 无人驾驶车辆智能行为及其测试与评价[M]. 北京理工大学出版社, 2015.
4	李德毅. 交互认知[R]. 科大讯飞年度发布会, 2016.11.23.
5	Fraher M J. Scour Evaluations of Existing Bridges—U.S. Department of Transportation Federal Highway Administration, Region 6 Forth Worth, Texas[C]// Hydraulic Engineering@sSaving a Threatened Resource—In Search of Solutions. ASCE, 2011:64-69.
6	胡爱军, 王朝晖. 汽车主动安全技术[J]. 机械设计与制造, 2010(7):97-99.
7	工业和信息化部. 关于征求《国家车联网产业体系建设指南（智能网联汽车）（2017年）》（征求意见稿）意见的通知[EB/OL]. [2017-06-13].
8	Rajamani R. Vehicle Dynamics and Control[M]. Springer Science, 2006.
9	Kim Z W, Malik J. High-quality vehicle trajectory generation from video data based on vehicle detection and description[C]// Intelligent Transportation Systems, 2003. Proceedings. IEEE Xplore, 2007:176-182 vol.1.
10	Elkabbany A. Terrain Assessment for High Speed Navigation of Unmanned Ground Vehicles[J]. Engineering--MechanicalRobotics, 2014.
11	Gao Y, Lin T, Borrelli F, et al. Predictive Control of Autonomous Ground Vehicles With Obstacle Avoidance on Slippery Roads[C]// ASME 2010 Dynamic Systems and Control Conference. 2010:265-272.
12	Ansari A R, Murphey T D. Sequential Action Control: Closed-Form Optimal Control for Nonlinear and Nonsmooth Systems[M]. IEEE Press, 2016.

13	Kayacan E, Ramon H, Saeys W. Robust Trajectory Tracking Error Model-Based Predictive Control for Unmanned Ground Vehicles[J]. IEEE/ASME Transactions on Mechatronics, 2016, 21(2):806-814.
14	Bohren J, Foote T, Keller J, et al. Little Ben: The Ben Franklin Racing Team's entry in the 2007 DARPA Urban Challenge[J]. Journal of Field Robotics, 2008, 25(9):598–614.
15	Chen Y L, Sundareswaran V, Anderson C, et al. TerraMax™: Team Oshkosh urban robot[J]. Journal of Field Robotics, 2008, 25(10):841–860.
16	Patz B J, Papelis Y, Pillat R, et al. A Practical Approach to Robotic Design for the DARPA Urban Challenge[J]. Journal of Field Robotics, 2008, 25(8):528–566.
17	Anderson S J, Karumanchi S B, Iagnemma K. Constraint-based planning and control for safe, semi-autonomous operation of vehicles[C]// Intelligent Vehicles Symposium. IEEE, 2012:383-388.
18	Bacha A, Bauman C, Faruque R, et al. Odin: Team victortango's entry in the darpa urban challenge[J]. Journal of field Robotics, 2008, 25(8): 467-492.
19	Kala R, Warwick K. Multi-Level Planning for Semi-autonomous Vehicles in Traffic Scenarios Based on Separation Maximization[J]. Journal of Intelligent & Robotic Systems, 2013, 72(3-4):559-590.
20	Michael Montemerlo, Jan Becker, Suhrid Bhat, et al. Junior: The Stanford Entry in the Urban Challenge[J]. Journal of Field Robotics, 2008, 25(9):569-597.
21	Dolgov D, Thrun S, Montemerlo M, et al. Path Planning for Autonomous Vehicles in Unknown Semi-structured Environments[J]. International Journal of Robotics Research, 2010, 29(5):485-501.
22	Gu T, Snider J, Dolan J M, et al. Focused Trajectory Planning for autonomous on-road driving[J]. 2013, 36(1):547-552.



23	Werling M, Kammel S, Ziegler J, et al. Optimal trajectories for time-critical street scenarios using discretized terminal manifolds[J]. International Journal of Robotics Research, 2012, 31(3):346-359.
24	Kuwata Y, Teo J, Fiore G, et al. Real-Time Motion Planning With Applications to Autonomous Urban Driving[J]. IEEE Transactions on Control Systems Technology, 2009, 17(5):1105-1118.
25	Ryu J H, Ogay D, Bulavintsev S, et al. Development and experiences of an autonomous vehicle for high-speed navigation and obstacle avoidance[M]//Frontiers of Intelligent Autonomous Systems. Springer, Berlin, Heidelberg, 2013: 105-116.
26	Jeon J H, Cowlagi R V, Peters S C, et al. Optimal motion planning with the half-car dynamical model for autonomous high-speed driving[C]// American Control Conference. IEEE, 2013:188-193.
27	Kala R, Warwick K. Planning of multiple autonomous vehicles using RRT[C]// IEEE, International Conference on Cybernetic Intelligent Systems. IEEE, 2011:20-25.
28	Broggi, P. Medici, P. Zani, et al. Autonomous vehicles control in the VisLab Intercontinental Autonomous Challenge ☆[J]. Annual Reviews in Control, 2012, 36(1):161-171.
29	Vorobieva H, Minoiu-Enache N, Glaser S, et al. Geometric continuous-curvature path planning for automatic parallel parking[C]// IEEE International Conference on Networking, Sensing and Control. IEEE, 2013:418-423.
30	Fuji H, Xiang J, Tazaki Y, et al. Trajectory planning for automated parking using multi-resolution state roadmap considering non-holonomic constraints[C]// Intelligent Vehicles Symposium Proceedings. IEEE, 2014:407-413.

31	Brezak M, Petrovic I. Real-time Approximation of Clothoids With Bounded Error for Path Planning Applications[J]. IEEE Transactions on Robotics, 2014, 30(2):507-515.
32	Coombs D, Murphy K, Lacaze A, et al. Driving autonomously off-road up to 35 km/h[C]// Intelligent Vehicles Symposium, 2000. IV 2000. Proceedings of the IEEE. IEEE, 2000:186-191.
33	Petrov P, Nashashibi F. Modeling and Nonlinear Adaptive Control for Autonomous Vehicle Overtaking[J]. IEEE Transactions on Intelligent Transportation Systems, 2015, 15(4):1643-1656.
34	Christoph G. Keller, Thao Dang, Hans Fritz, et al. Active Pedestrian Safety by Automatic Braking and Evasive Steering[J]. IEEE Transactions on Intelligent Transportation Systems, 2012, 12(4):1292-1304.
35	Rastelli J P, Lattarulo R, Nashashibi F. Dynamic trajectory generation using continuous-curvature algorithms for door to door assistance vehicles[C]// Intelligent Vehicles Symposium Proceedings. IEEE, 2014:510-515.
36	Pérez J, Godoy J, Villagrà J, et al. Trajectory generator for autonomous vehicles in urban environments[C]// IEEE International Conference on Robotics and Automation. IEEE, 2013:409-414.
37	Han L, Yashiro H, Nejad H T N, et al. Bézier curve based path planning for autonomous vehicle in urban environment[C]// Intelligent Vehicles Symposium. IEEE, 2010:1036-1042.
38	Liang Z, Zheng G, Li J. Automatic parking path optimization based on Bezier curve fitting[C]// IEEE International Conference on Automation and Logistics. IEEE, 2012:583-587.
39	Fiore M, Härri J, Filali F, et al. Vehicular mobility simulation for VANETs[J]. 2007:301-309.

40	Zheng Z, Ahn S, Chen D, et al. The effects of lane-changing on the immediate follower: Anticipation, relaxation, and change in driver characteristics[J]. Transportation Research Part C Emerging Technologies, 2013, 26(26):367-379.
41	唐洁,刘少山.面向无人驾驶的边缘高精地图服务[J].中兴通讯技术,2019,25(03):58-67+81.
42	胡蓉,成彬.车路协同路侧边缘计算系统设计思路[J].中国信息化,2021(10):51-52.
43	FENG J Y, LIU Z, WU C, et al. Mobile EdgeComputing for the Internet of Vehicles:Offloading Framework and Job Scheduling[J]. IEEE Vehicular Technology Magazine,2019, 14(1): 28-36. DOI:10.1109/mvt.2018.2879647
44	BHATNAGAR G, LIU Z. Multi-Sensor FusionBased on Local Activity Measure[J]. IEEE Sensors Journal, 2017, 17(22): 7487-7496.DOI:10.1109/jsen.2017.2759195.
45	崔明月,钟仕鹏,刘思瑶,李博洋,吴成昊,黄凯.利用边缘计算的多车协同激光雷达 SLAM[J].中国图象图形学报,2021,26(01):218-228.
46	Tanner H G, Jadbabaie A, Pappas G J. Stable Flocking of Mobile Agents, Part II: Dynamic Topology[M]// Departmental Papers (ESE). 2003.
47	Savkin A V. Coordinated collective motion of Groups of autonomous mobile robots: analysis of Vicsek's model[J]. Automatic Control IEEE Transactions on, 2004, 49(6):981-982.
48	Zhang H T, Zhai C, Chen Z. A General Alignment Repulsion Algorithm for Flocking of Multi-Agent Systems[J]. IEEE Transactions on Automatic Control, 2011, 56(2):430-435.
49	Leonard N E, Fiorelli E. Virtual leaders, artificial potentials and coordinated control of groups[C]// Decision and Control, 2001. Proceedings of the, IEEE Conference on. IEEE Xplore, 2001:2968-2973 vol.3.
50	米浩.高速公路场景中无人驾驶车群模型及其动态演化方法研究 [D].同济大学.

51	陈敏军. 封闭式场景下无人驾驶车群自协模型研究[D].同济大学.
52	Viola P A , Jones M J . Rapid Object Detection using a Boosted Cascade of Simple Features[C]// Computer Vision and Pattern Recognition, 2001. CVPR 2001. Proceedings of the 2001 IEEE Computer Society Conference on. IEEE, 2001.
53	Dalal, Navneet, Triggs, et al. Histograms of Oriented Gradients for Human Detection[C]// IEEE Computer Society Conference on Computer Vision & Pattern Recognition. 2005.
54	Felzenszwalb P F , Girshick R B , Mcallester D , et al. Object Detection with Discriminatively Trained Part-Based Models[J]. IEEE Transactions on Software Engineering, 2010, 32(9):1627-1645.
55	Malisiewicz T , Gupta A , Efros A A . Ensemble of exemplar-SVMs for object detection and beyond[C]// IEEE International Conference on Computer Vision, ICCV 2011, Barcelona, Spain, November 6-13, 2011. IEEE, 2011.
56	Kai L, Barth E, Martinetz T. Robust and Fast Learning of Sparse Codes With Stochastic Gradient Descent[J]. IEEE Journal of Selected Topics in Signal Processing, 2011, 5(5):1048-1060.
57	Krizhevsky A , Sutskever I , Hinton G . ImageNet Classification with Deep Convolutional Neural Networks[C]// NIPS. Curran Associates Inc. 2012.
58	Erhan D , Szegedy C , Toshev A , et al. Scalable Object Detection using Deep Neural Networks[J]. 2013.
59	Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[C]// International Conference on Neural Information Processing Systems. Curran Associates Inc. 2012:1097-1105.
60	He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[J]. 2015:770-778.

61	LeCun Y, Cosatto E, Ben J, et al. DAVE: Autonomous off-road vehicle control using end-to-end learning[R]. Technical Report DARPA-IPTO Final Report, Courant Institute/CBLL, <a href="http://www.cs.nyu.edu/yann/research/dave/index.html">http://www.cs.nyu.edu/yann/research/dave/index.html</a> , 2004.
62	Chen C, Seff A, Kornhauser A, et al. DeepDriving: Learning Affordance for Direct Perception in Autonomous Driving[C]// IEEE International Conference on Computer Vision. IEEE, 2015:2722-2730.
63	百度. 百度自动驾驶开放平台 RoadHackers[EB/OL]. <a href="http://roadhackers.baidu.com">http://roadhackers.baidu.com</a> .
64	Santana E, Hotz G. Learning a Driving Simulator[J]. 2016.
65	Codevilla F, Müller M, Dosovitskiy A, et al. End-to-end Driving via Conditional Imitation Learning[J]. 2017.
66	Shalev-Shwartz S, Shammah S, Shashua A. Safe, Multi-Agent, Reinforcement Learning for Autonomous Driving[J]. 2016.
67	Such F P, Madhavan V, Conti E, et al. Deep Neuroevolution: Genetic Algorithms Are a Competitive Alternative for Training Deep Neural Networks for Reinforcement Learning[J]. 2017.
68	Codevilla F, Müller M, López A, et al. End-to-end Driving via Conditional Imitation Learning[J]. 2017.
69	Santana E, Hotz G. Learning a Driving Simulator[J]. 2016.
70	Alex Kendall, Jeffrey Hawke, David Janz, Przemyslaw Mazur, Daniele Reda, John-Mark Allen, Vinh-Dieu Lam, Alex Bewley, Amar Shah, "Learning to drive in a day", arXiv preprint arXiv:1807.00412, 2018.
71	Bojarski, M., Del Testa, D., Dworakowski, D., Firner, B., Flepp, B., Goyal, P., Jackel, L.D., Monfort, M., Muller, U., Zhang, J., Zhang, X., Zhao, J., Zieba, K.: End to end learning for self-driving cars. arXiv:1604.07316 (2016).

72	Bojarski M, Yeres P, Choromanska A, Choromanski K, Firner B, et al. 2017. Explaining how a deep neural network trained with end-to-end learning steers a car. arXiv:1704.07911.
73	Gurghian A, Koduri T, Bailur SV, Carey KJ, Murali VN. 2016. DeepLanes: end-to-end lane position estimation using deep neural networks. In 2016 IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), pp. 38–45. New York: IEEE.
74	Chen C, Seff A, Kornhauser A, Xiao J. 2015. DeepDriving: learning affordance for direct perception in autonomous driving. In 2015 IEEE International Conference on Computer Vision (ICCV), pp. 2722–30. New York: IEEE.
75	Xu H, Gao Y, Yu F, Darrell T. 2016. End-to-end learning of driving models from large-scale video datasets. arXiv:1612.01079.
76	Pfeiffer M, Schaeuble M, Nieto J, Siegwart R, Cadena C. 2017. From perception to decision: a datadriven approach to end-to-end motion planning for autonomous ground robots. In 2017 IEEE International Conference on Robotics and Automation (ICRA), pp. 1527–33. New York: IEEE.
77	Lillicrap TP, Hunt JJ, Pritzel A, Heess N, Erez T, et al. 2015. Continuous control with deep reinforcement learning. arXiv:1509.02971.
78	Maddern, William P. et al. “1 year, 1000 km: The Oxford RobotCar dataset.” The International Journal of Robotics Research 36 (2017): 15 - 3.
79	A Geiger, P Lenz, C Stiller, et al. Vision meets robotics: The KITTI dataset[J]. International Journal of Robotics Research, 2013, 32(11):1231-1237.
80	Riverbed Technology. Network Planning & Simulation (OPNET). (2013-10-19). <a href="http://www.riverbed.com/products-solutions/products/network-performance-management/network-planning-simulation/">http://www.riverbed.com/products-solutions/products/network-performance-management/network-planning-simulation/</a> .

81	Chang X. Network simulations with OPNET[C]//WSC'99. 1999 Winter Simulation Conference Proceedings.'Simulation-A Bridge to the Future'(Cat. No. 99CH37038). IEEE, 1999, 1: 307-314.
82	Lu Z, Yang H. Unlocking the power of OPNET modeler[M]. Cambridge University Press, 2012.
83	Sethi A S, Hnatyshin V Y. The practical OPNET user guide for computer network simulation[M]. Chapman and Hall/CRC, 2012.
84	Shuaib K A. A performance evaluation study of WIMAX using Qualnet[C]//proceedings of the World Congress on Engineering. 2009, 1: 1-3.
85	Subramanya Bhat M, Shwetha D, Devaraju J T. A performance study of proactive, reactive and hybrid routing protocols using qualnet simulator[J]. International Journal of Computer Applications, 2011, 28(5): 10-17.
86	Chen Q, Schmidt-Eisenlohr F, Jiang D, et al. Overhaul of IEEE 802.11 modeling and simulation in ns-2[C]//Proceedings of the 10th ACM Symposium on Modeling, analysis, and simulation of wireless and mobile systems. ACM, 2007: 159-168.
87	Henderson T R, Lacage M, Riley G F, et al. Network simulations with the ns-3 simulator[J]. SIGCOMM demonstration, 2008, 14(14): 527.
88	Xie P, Zhou Z, Peng Z, et al. Aqua-Sim: An NS-2 based simulator for underwater sensor networks[C]//OCEANS 2009. IEEE, 2009: 1-7.
89	Henderson T R, Lacage M, Riley G F, et al. Network simulations with the ns-3 simulator[J]. SIGCOMM demonstration, 2008, 14(14): 527.
90	Afanasyev A, Moiseenko I, Zhang L. ndnSIM: NDN simulator for NS-3[J]. University of California, Los Angeles, Tech. Rep, 2012, 4.
91	Riley G F, Henderson T R. The ns-3 network simulator[M]//Modeling and tools for network simulation. Springer, Berlin, Heidelberg, 2010: 15-34.

92	Sobeih A, Hou J C, Kung L C, et al. J-Sim: a simulation and emulation environment for wireless sensor networks[J]. IEEE Wireless Communications, 2006, 13(4): 104-119.
93	Sobeih A, Chen W P, Hou J C, et al. J-sim: A simulation environment for wireless sensor networks[C]//38th Annual Simulation Symposium. IEEE, 2005: 175-187.
94	Varga A. OMNeT++[M]//Modeling and tools for network simulation. Springer, Berlin, Heidelberg, 2010: 35-59.
95	Varga A, Hornig R. An overview of the OMNeT++ simulation environment[C]//Proceedings of the 1st international conference on Simulation tools and techniques for communications, networks and systems & workshops. ICST (Institute for Computer Sciences, Social-Informatics and Telecommunications Engineering), 2008: 60.
96	Varga A. Using the OMNeT++ discrete event simulation system in education[J]. IEEE Transactions on Education, 1999, 42(4): 11 pp.
97	Köpke A, Swigulski M, Wessel K, et al. Simulating wireless and mobile networks in OMNeT++ the MiXiM vision[C]//Proceedings of the 1st international conference on Simulation tools and techniques for communications, networks and systems & workshops. ICST (Institute for Computer Sciences, Social-Informatics and Telecommunications Engineering), 2008: 71.
98	Simulcraft Inc. OMNEST. (2013-07-30). <a href="http://www.omnest.com">http://www.omnest.com</a> .
99	Sutaria T, Mahgoub I, Humos A, et al. Implementation of an energy model for JIST/SWANS wireless network simulator[C]//Sixth International Conference on Networking (ICN'07). IEEE, 2007: 24-24.
100	Tippanagoudar V, Mahgoub I, Badi A. Implementation of the Sensor-MAC Protocol for the JIST/SWANS Simulator[C]//2007 IEEE/ACS International Conference on Computer Systems and Applications. IEEE, 2007: 225-232.



101	Harri J, Filali F, Bonnet C. Mobility models for vehicular ad hoc networks: a survey and taxonomy[J]. IEEE Communications Surveys & Tutorials, 2009, 11(4):19-41.
102	Van Eenennaam E M. A survey of propagation models used in vehicular ad hoc network (VANET) Research[J]. Paper written for course Mobile Radio Communication, University of Twente, 2008: 1-7.
103	Sommer C, Dressler F. Using the right two-ray model? A measurement based evaluation of PHY models in VANETs[C]//Proc. ACM MobiCom. 2011: 1-3.

### 3. 研究内容

本文拟从无人驾驶车群运动行为入手，结合开放式环境的复杂形态特点，引入深度学习和边缘计算思想，对无人驾驶车群的自协方法和理论模型展开研究，并通过理论证明，数值计算，仿真实验进行验证，从而达到保障信息解析准确、准确地刻画和反映路网环境，满足车群运动行为决策智能化的信息输入要求，达成信息保真信息；保持感知贡献持续稳定，实现车群动态演化及其内部自协的实时与稳定的执行过程，满足车群运动行为智能化的预期目标达成自协忠实。具体的研究内容如图 3.1 所示。我们认为：① 信息保真和自协忠实是无人驾驶车群运动行为稳定有序的基石；② 开放式环境下复杂形态的边缘数据解析是解决信息真实准确问题的必要手段；③ 无人驾驶车群动态演化方法及其自协理论模型是深层次解决动态演化实时与稳定问题的有效途径；④ 对无人驾驶车群自协机理的合理性进行验证和评价是改进和完善无人驾驶车群运动行为智能化的需要。因此，这几个部分构成了开放式无人驾驶车群自协机理的完整体系。

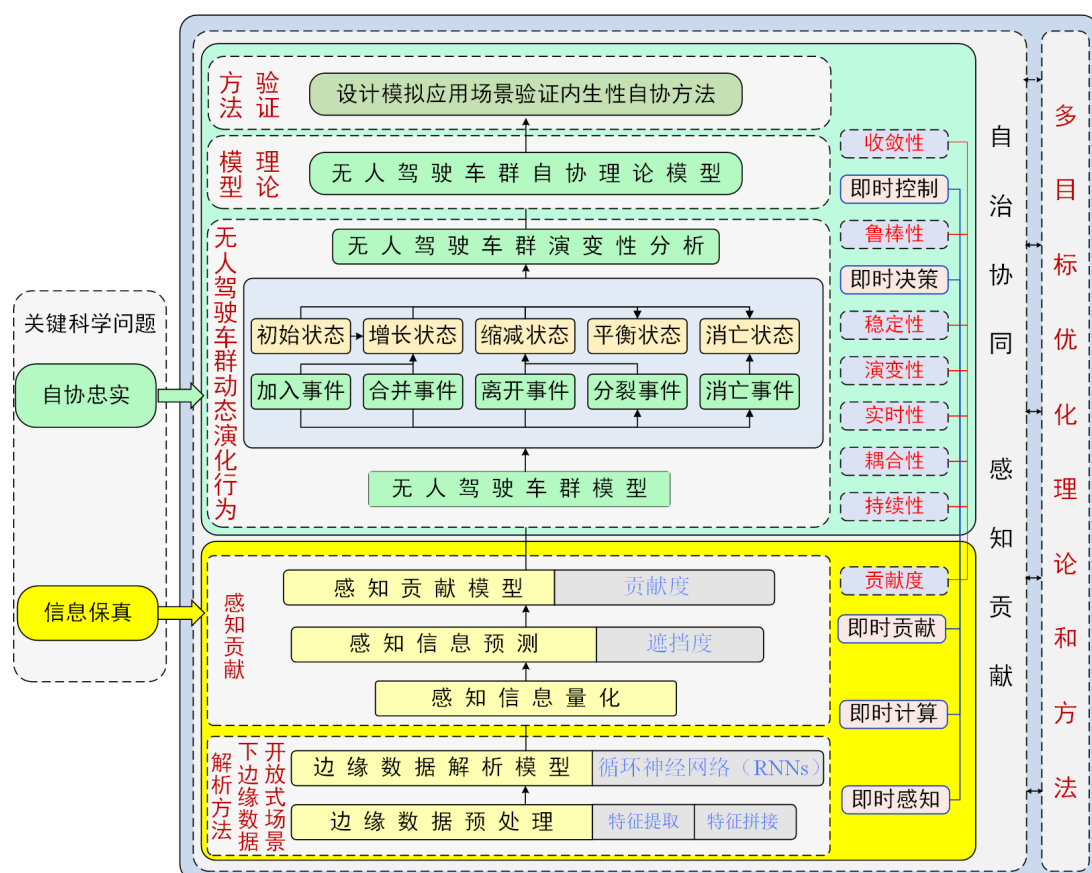


图 3.1 研究内容框架

### 1) 开放式场景下边缘数据解析方法

在无人驾驶车辆行驶环境下客观存在无人驾驶车群，有人驾驶车辆，障碍物，红绿灯，路边指示牌以及行人等的干扰；不同无人驾驶车辆通过自身多种车载传感器获取到的感知数据具有冗余性、多样性、复杂性、不一致性的问题；为了能够克服以上无人驾驶在车体域、物理空间域以及信息域中存在的问题，构造可应用于实际场景中快速构造感知贡献并稳定有序的无人驾驶车群，我们首先对已有的无人驾驶边缘数据进行数据解析，提取数据之间的内在特征，降低数据处理的时空复杂度。研究无人驾驶车辆节点与感知信息之间的关联关系，构造边缘数据解析模型，从而减轻实际场景中无人驾驶车辆节点感知贡献的负担，为后续基于边缘计算的车群构造提供了有效、完整、一致的基础支持，达到自协的信息保真的目的。为此，需要研究的内容如下：

- ① 预处理无人驾驶车辆节点边缘数据；
- ② 建立无人驾驶车辆边缘节点与感知环境之间的内在联系和相互作用；
- ③ 利用深度学习构造开放式环境下的边缘数据解析模型。

### 2) 感知贡献

在无人驾驶车群运动过程中，客观存在有人驾驶车辆、路边障碍物、红绿灯、行人等外部干扰的影响。对无人驾驶单智能体节点对感知环境的感知能力有所阻碍，为了无人驾驶单智能体更好的将感知需求卸载至无人驾驶车辆边缘节点上，实现对无人驾驶感知信息的贡献，根据边缘数据解析模型输出结果，构建基于感知贡献模型，将其用于挖掘无人驾驶车辆边缘节点感知贡献的关系，提高无人驾驶车辆对行驶环境的理解程度。为此，需要研究：

- ① 量化无人驾驶边缘节点感知信息；
- ② 挖掘感知贡献的变化与无人驾驶车辆边缘节点和感知环境之间的一般规律；
- ③ 求解无感知贡献模型获得感知贡献度。

### 3) 基于边缘计算的无人驾驶车群构造方法

开放式环境下客观存在有人驾驶车辆、路边障碍物、红绿灯、行人等外部干扰的影响。造成车辆间感知贡献时刻变化的问题，本文研究的无人驾驶车群指开放式场景下局部区域内位置邻近的车辆节点之间各自贡献对方需要的感知范围外信息的群体。我们利用感知贡献模型挖掘感知贡献的变化的一般规律，并且考虑车群的持续性，耦合性以及实时性，构建无人驾驶车群模型，并且使用贡献容量对无人驾驶的规模进行约束，从而达到自协中的自协忠实的目的。为此，需要研究：

- ① 基于感知贡献度求解无人驾驶车群的贡献度；
- ② 研究基于边缘计算思想的无人驾驶车群形成方法；
- ③ 考虑车群的贡献度，车群的实时性、耦合性、持续性构建无人驾驶车群模型；
- ④ 研究无人驾驶车群模型的规模上限；
- ⑤ 利用多目标优化算法对无人驾驶车群模型进行求解。

#### 4) 无人驾驶车群动态演化方法

开放式场景下客观存在有人驾驶车辆、路边障碍物、红绿灯、行人等外部干扰的影响，使得无人驾驶车群边缘节点之间的感知贡献的关系发生动态变化。为了解决上述问题，深入剖析无人驾驶车群在开放式环境下动态演化机制，将无人驾驶车群的动态演化行为分为五类：加入，合并，分离，分裂，消亡，探寻车群动态演化事件与车群状态的关联关系，进而挖掘无人驾驶车群动态演化规律，即演变性。为此，需要研究如下内容：研究车群内部变化的一般性规律和相互作用下的影响机制；

- ① 研究感知贡献对车群发生动态变化的影响机制
- ② 研究车群的动态演化行为和状态的分类及其形式化表示
- ③ 研究车群动态演化事件：加入，合并，分离，分裂和消亡的相关算法
- ④ 研究车群不同状态的关联关系以及状态转换的一般性规律
- ⑤ 构造演变性度量函数并证明其合理性

## 5) 开放式无人驾驶车群自协方法

为了保证车群自协系统的完备性，遵循自协准则，使得车群始终表现出智能行为特征，本文基于车群动态演化行为，考虑车群的演变性，稳定性和收敛性构建车群自协模型。为此，需要研究的内容如下：

- ① 研究车群自协系统的完备性特征及其条件；
- ② 研究车群内部作用下的自协影响机制；
- ③ 基于车群自协的完备性及其准则，研究动态演化过程的自协模型；
- ④ 针对开放式无人驾驶路网环境，研究自协模型的约束性条件。

## 6) 设计模拟应用场景验证自协方法

本文所研究的开放式无人驾驶车群自协机理在设计方法和理论模型上，可能会产生一些不相关的需求因子，对研究结果实施应用之前，本文设计模拟应用场景，对提出的方法和理论模型进行可靠性与置信度高的正确性检测和性能评估。为此，需要研究的内容如下：

- ① 研究开放式路网环境的特征；
- ② 基于开放式路网环境的特征，设计模拟应用场景；
- ③ 研究数据真实准确的条件，在模拟应用场景中进行仿真实验，评估和分析开放式路网环境下的数据解析方法的性能和有效性；
- ④ 研究无人驾驶车群动态演化的实时与稳定的条件，在模拟应用场景中进行仿真实验，分析无人驾驶车群动态演化方法及其自协模型的有效性。

#### 4. 研究方法及技术路线

##### 1) 研究方法

本文拟采用理论分析、数值计算、仿真实验综合研究方法进行研究。

- ① 理论分析：以理论推导为主，在模型求解方面，利用多目标优化理论进行理论分析和推导；利用随机理论和优化理论推导车群动态演化过程中状态转变的原因，并论证结果的合理性；
- ② 数值计算：以开放式环境下高维数据的复杂关系通过深度学习后的输出结果为主，分析计算节点经过训练模型得到的最终输出节点新特征及其属性以及节点相互之间的关联关系，为边缘数据解析模型以及自协理论模型的建立提供数据真实准确的保证。
- ③ 仿真实验：本文采用 KITTI 数据集(来源于德国卡尔斯鲁厄理工学院和丰田美国技术研究院：<http://www.cvlibs.net/datasets/kitti/>) 以及 Oxford RobotCar 数据集，作为离线状态下训练场景以及开放式车群环境下实时场景的数据集，分别构造边缘数据解析模型，感知贡献模型以及车群模型，并对模型的正确性和合理性进行仿真实验验证；对本文动态演化行为机制以及自协理论模型的正确性和合理性进行仿真实验验证。

##### 2) 技术路线

本文针对未来无人驾驶汽车得以大规模广泛应用所面临的主要技术难点，凝练出关键科学问题，通过多领域交叉融合，研究基于边缘计算的开放式无人驾驶车群自协方法。本文依据深度学习和边缘计算思想和方法，围绕无人驾驶领域中的关键问题，研究理论方法，突破关键技术，以理论分析、数值计算、仿真实验等验证研究成果，反馈需求，注重研究内容的衔接和关联，形成贯穿运动行为稳定有序的无人驾驶车群自协系统的全生命周期的研究主线：混沌无序状态训练集→边缘数据解析模型→动态演化行为（加入事件，合并事件，离开事件，分裂事件，消亡事件）→车群自协理论模型→模拟应用场景验证→稳定有序行驶。研究主线的提出有利于明确研究内容的定位，促进技术的衔接，如图 4.1 所示，具体技术路线如下：

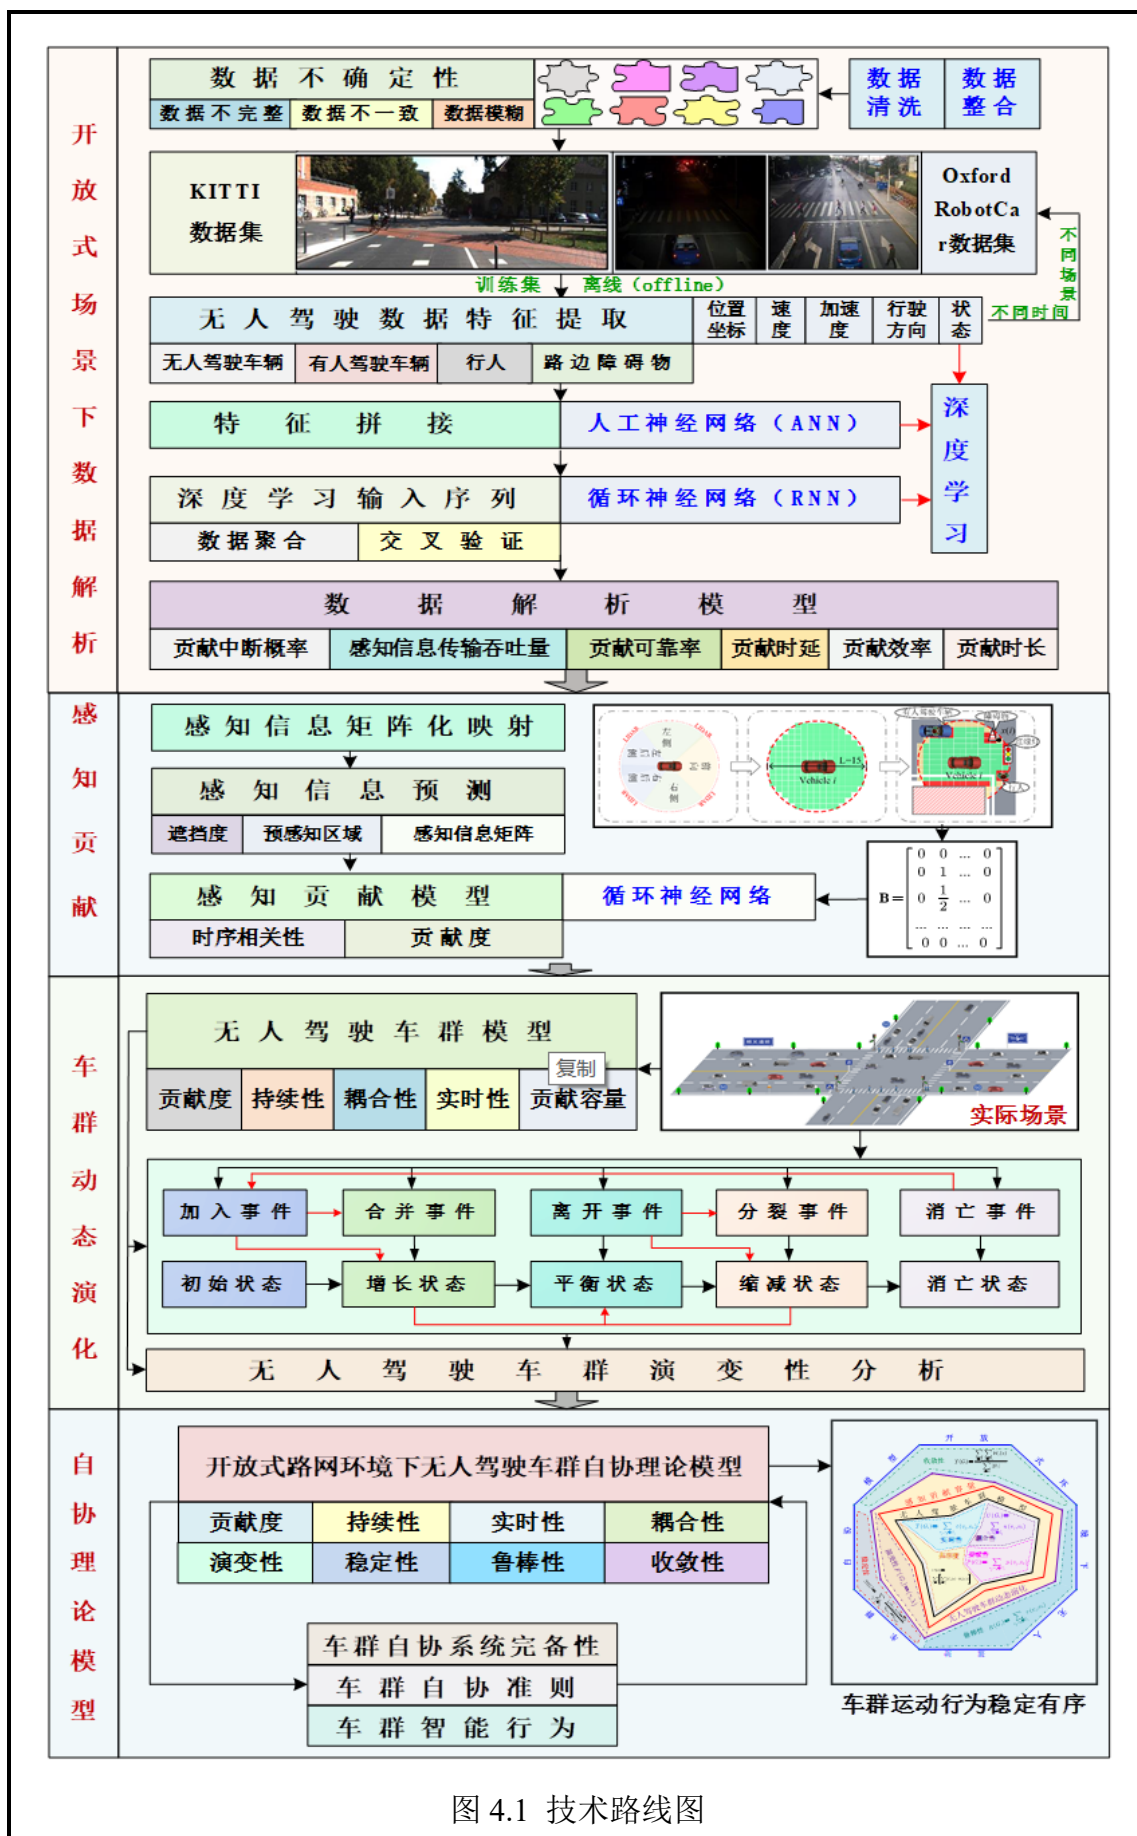


图 4.1 技术路线图

### ① 开放式环境下的数据解析方法

无人驾驶路网环境客观存在无人驾驶车群，有人驾驶车辆，路边障碍物，以及红绿灯等无意“干扰”特性。为了能够克服无人驾驶边缘数据存在复杂的高维数据造成的困扰，构建感知贡献模型并求解可应用于实际场景中快速构建实时感知贡献的无人驾驶车群，我们首先对已有的无人驾驶路网环境的数据集（KITTI 数据集）和 Oxford RobotCar 数据集进行离线下的深度学习，对高维复杂数据进行处理，提取数据之间的内在特征，降低数据处理的时间复杂度。研究无人驾驶边缘节点与感知信息之间的关系，构造边缘数据解析模型，从而减轻实际场景中无人驾驶车辆节点感知贡献的负担，为后续基于边缘计算的车群构造提供了有效、完整、一致的数据支持。具体研究思路如下：

#### a) 数据预处理

无人驾驶车辆行驶环境复杂多变，车载传感器规格及采集方式不一，容易造成数据缺失、数据噪声、数据不一致、数据冗余、以及数据重复等问题，其中，数据噪声主要是由于天气、遮挡或自身传感器缺陷导致的数据成像模糊存在噪声点等问题，可以表示为：

$$Data(A_1, A_2, A_3, \dots, A_m^{noise}, A_k^{noise}, \dots, A_n)$$

其中， $A_m^{noise}, A_k^{noise}$  表示含有噪声的数据。

数据不一致是因为无人驾驶的动态特性使得不同车辆节点、不同时刻、不同角度的信息可能存在不一致的情况，可以表示为：

$$Data(v_i) = \begin{cases} Data^1(v_i) = A_1, A_2, A_3, \dots, A_i, A_k, \dots, A_n \\ Data^2(v_i) = A_1, A_2, A_3, \dots, A_m, A_j, \dots, A_n \\ \dots \end{cases}$$

其中， $A_i \neq A_k, A_m \neq A_j$  为数据不一致的具体表现形式。

数据冗余是因为在无人驾驶数据集中可能会存在对于车群本身没有价值的信息，例如同一个障碍物的多个重复的图像信息，可以表示为：

$$Data(O_i) = \begin{cases} Data^1(O_i) = A_1, A_2, A_3, \dots, A_n \\ Data^2(O_i) = A_1, A_2, A_3, \dots, A_m \\ \dots \end{cases}$$



b) 特征拼接

无人驾驶车辆  $v_i$  在  $t$  时刻的特征可表示为:

$$Feature^t(v_i) = \{\nu, a, (x, y), \epsilon, \mathbf{B}, M, O, P, H\}$$

其中,  $\nu$  表示无人驾驶车辆  $v_i$  在  $t$  时刻时的速度,  $a$  表示其加速度;  $(x, y)$  表示其所处的地理位置;  $\epsilon$  则表示其行驶的方向;  $\mathbf{B}$  表示无人驾驶车辆  $v_i$  在  $t$  时刻的感知建模矩阵;  $M$  为无人驾驶车辆  $v_i$  在  $t$  时刻时有人驾驶车辆集合;  $O$  为无人驾驶车辆  $v_i$  在  $t$  时刻时周围障碍物集合;  $P$  为无人驾驶车辆  $v_i$  在  $t$  时刻时周围行人集合;  $H$  为无人驾驶车辆  $v_i$  在  $t$  时刻时周围红绿灯集合。

无人驾驶车辆  $v_i$  在  $t$  时刻时周围有人驾驶车辆集合  $M^t(v_i)$  的特征可表示为:

$$M^t(v_i) = \{\nu, a, (x, y), \epsilon\}$$

其中,  $\nu$  表示有人驾驶车辆的速度,  $a$  表示其加速度;  $(x, y)$  表示其所处的地理位置;  $\epsilon$  则表示其行驶的方向。找到一种无人驾驶车辆节点与周围环境和其他无人驾驶车辆节点之间的关联关系

无人驾驶车辆  $v_i$  在  $t$  时刻时周围障碍物集合  $O^t(v_i)$  的特征可表示为:

$$O^t(v_i) = \{(x, y), w, l, h\}$$

其中,  $(x, y)$  表示障碍物所处的地理位置;  $w, l, h$  则分别表示其长、宽、高。

无人驾驶车辆  $v_i$  在  $t$  时刻时周围行人物集合  $P^t(v_i)$  的特征可表示为:

$$P^t(v_i) = \{\nu, (x, y), \epsilon\}$$

其中,  $\nu$  表示行人的速度,  $a$  表示其加速度;  $(x, y)$  表示其所处的地理位置;  $\epsilon$  则表示其行进方向。

无人驾驶车辆  $v_i$  在  $t$  时刻时周围行人物集合  $H^t(v_i)$  的特征可表示为:

$$H^t(v_i) = \{(x, y), I\}$$

其中,  $(x, y)$  表示红绿灯所处的地理位置;  $I = \{0, 1, 2\}$  分别表示其所处的交通信号灯状态。

根据上述无人驾驶车辆  $v_i$  在  $t$  时刻的特征可以得到贡献影响因素解析模型的输入:

$$Feature_{input}^t = Feature^t(v_i) \oplus Feature^t(v_j)$$

其中， $\oplus$ 表示将 $Feature^t(v_i)$ 与 $Feature^t(v_j)$ 进行特征拼接操作。

### c) 边缘数据解析模型

贡献影响因素时空解析模型是为了找到一种无人驾驶车辆边缘节点与周围感知环境和其他无人驾驶车辆节点之间的关联关系，主要基于 GNN 得到节点间和节点与周围感知环境间的空间相关性，基于 RNN 得到其时序相关性，如图 4.2 所示，可以表示如下，其中：

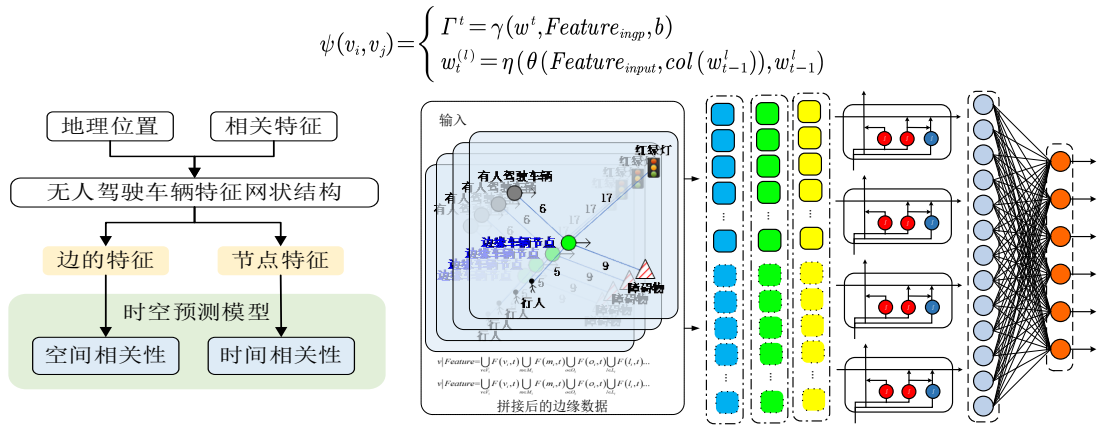


图 4.2 边缘数据解析模型

基于边缘数据解析模型，得到以下八个感知贡献的影响因素，为后文感知贡献模型和车群构建提供基础支持。

贡献中断概率：衡量无人驾驶车辆的贡献是否可以一直保持的概率；

感知信息传输吞吐量：衡量单位时间内通过车辆之间的链路能够成功贡献的感知信息总量；

贡献可靠率：衡量无人驾驶车辆之间在未来时刻感知信息交付是否可靠的概率；

贡献时延：无人驾驶车辆  $v_i$  向  $v_j$  发送感知数据， $v_j$  接收到  $v_i$  发送的感知数据时的时间差；

贡献效率：无人驾驶车辆  $v_i$  向  $v_j$  发送数据， $v_i$  发送单位测试数据所需要的时间长短；

贡献时长：预测正在通信的两辆无人驾驶车辆之间的通信链路能够保持连通的最长时间；

遮挡度：表示无人驾驶车辆边缘节点感知范围内是否存在遮挡。

## ② 感知贡献

为了无人驾驶单智能体将感知需求卸载至无人驾驶车辆边缘节点上，实现对无人驾驶感知信息的贡献，过程如图 4.3 所示。根据边缘数据解析模型输出结果，构建基于感知贡献模型，将其用于挖掘无人驾驶车辆边缘节点感知贡献的关系，提高无人驾驶车辆对行驶环境的理解程度感知贡献为此，需要研究：

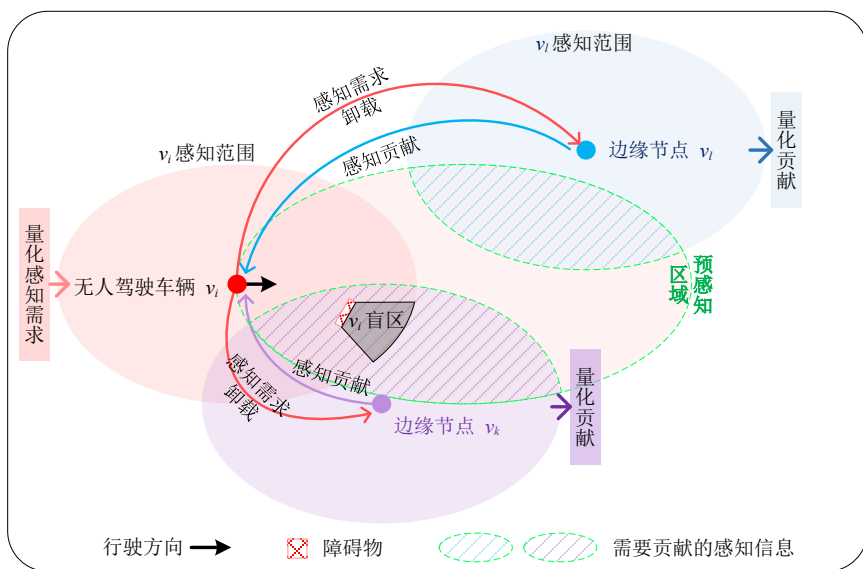


图 4.3 感知贡献

### a) 感知信息量化：

为了量化每辆无人驾驶车辆的感知信息，为后续感知贡献提供基础，我们通过以下方式将每个无人驾驶车辆的感知进行量化：




图 4.4 车辆感知范围量化

如图 4.4 所示，车辆视觉传感器一般由前向、左右侧以及后侧构成，而激光雷达一般为 360°环绕，这里我们将无人驾驶车辆的感知范围比做一个半径为  $R$  标准圆形。图 4.4(b)为单无人驾驶车辆  $i$  的感知信息建模，我们采用  $R/m$  为边长模拟无人驾驶车辆  $i$  的感知范围。如图 4.4(c)所示，黄色为传感器无法感知到的区域，绿色表示感知到为畅通的区域，而红色则为有障碍的区域；这样，可以定义位置  $x(i)$  遮挡度为：

$$O_i(x) = \begin{cases} 1 & \text{if } c_i(x) = \hat{c} \\ 0 & \text{if } c_i(x) = c \\ 1/2 & \text{if } c_i(x) = \tilde{c} \end{cases}$$

其中， $c_i(x) = \hat{c}$  为无人驾驶车辆传感设备感知到有遮挡时记为 1；畅通时记为 0；未知区域记为 1/2；则无人驾驶车辆  $v_i$  在  $t$  时刻时的感知信息矩阵可以表示为：

$$\mathbf{B} = \begin{bmatrix} 0 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ 0 & \frac{1}{2} & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & 0 \end{bmatrix}$$

其中矩阵的行列数为  $m$ ；

#### b) 感知信息预测：

在开放式场景下，无人驾驶车辆周围客观存在障碍物，有人驾驶车辆，行人，以及红绿灯等干扰因素，车辆的感知信息矩阵不断变化，导致车辆节点的感知信息矩阵也会随之相应发生变化，为了探寻车辆间感知信息矩阵的变化规律，我们利用循环神经网络构造感知信息预测模型提取其时序相关性，得到车辆  $i$  的在  $t+1$  时刻的感知信息矩阵，为得到车辆之间感知贡献规律提供基础：




图 4.5 感知信息预测模型

可以表示为：

$$\mathcal{F}(v_i, v_j) = w_i^{(l)} = \eta((A_i^t, \text{col}(w_{i-1}^l)), w_{i-1}^l)$$

其中,  $\eta$ 表示循环神经网络激活函数,  $w_i^{(0)}$ 表示层间权重,  $A_i^t$ 表示感知信息的矩阵表征,  $A_i^{t+1}$ 表示车辆  $i$  的在  $t+1$  时刻的感知信息矩阵。

c) 贡献度:

**感知度:** 首先基于感知信息预测模型当中得到的感知信息矩阵来计算无人驾驶车辆感知范围中位置  $x(i)$  的遮挡度, 我们定义位置  $x(i)$  对于车辆  $i$  的感知度  $W_i(x)$  为:

$$W_i(x) = |2O_i(x) - 1| \varphi^{\Delta t}$$

其中,  $O_i(x)$  为位置  $x(i)$  的遮挡度,  $\varphi^{\Delta t}$  是可变参数, 为了衡量感知信息的时效性。

**干扰度:** 一般来说, 如图 3(a)所示, 车辆如果能预先得到与本身行驶方向相似, 距离越近的区域的结果, 则更有利于车辆本身的自动驾驶。定义核心节点车辆的预感知区域为以  $v_i t$  为直径的圆, 我们认为在预感知区域外部的区域对车辆  $i$  影响较小, 而在预感知区域内部, 与车辆本身行驶方向越相似, 距离越近的区域对车辆  $i$  的影响越大。如图 3(b)所示, 设定位置  $x(k)$  对于车辆  $i$  的干扰度为:

$$I_i(x) = \begin{cases} \frac{v_i \hat{t} \cdot \cos \theta - l}{v_i \hat{t} \cdot \cos \theta} & v_i \hat{t} \cdot \cos \theta > l \\ 0 & otherwise \end{cases}$$

其中,  $v_i t$  为汽车的最小制动距离,  $l$  为位置  $x$  与车辆之间的距离。




图 4.6 (a)预感之区域 (b)干扰度示例

接下来，可以求得位置  $x(k)$  对无人驾驶车辆  $i$  的贡献度为：

$$C_i(x(j)) = I_i(x(j)) \cdot (1 - W_i(x(j)))$$

其中， $I_i(x(j))$  是  $x(j)$  对于无人驾驶车辆  $i$  的干扰度， $W_i(x(j))$  为  $x(j)$  对无人驾驶车辆  $i$  的感知度。最后，基于位置  $x(k)$  对无人驾驶车辆  $i$  的贡献度可以求得边缘车辆节点  $k$  对核心节点车辆  $i$  的贡献度  $C_{ki}$  为：

$$C_{ki} = \sum_{x \in B_k} (C_k(x) \cdot W_i(x))$$

### ③ 基于边缘计算的无人驾驶车群构造方法

无人驾驶车群指开放式场景下局部区域内位置邻近的车辆节点之间各自贡献对方需要的感知范围外信息的群体。我们利用感知贡献模型挖掘感知贡献的变化的一般规律，并且考虑车群的持续性，耦合性以及实时性，构建无人驾驶车群模型，如图 4.7 所示，并且使用贡献容量对无人驾驶的规模进行约束，从而达到自协中的自协忠实的目的。具体研究思路如下：

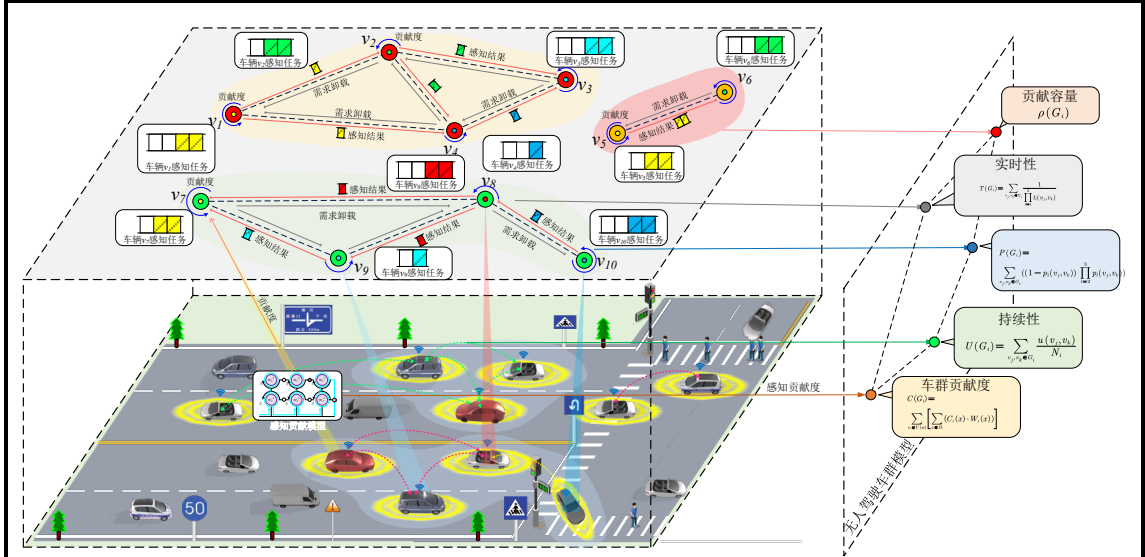


图 4.7 无人驾驶车群模型

#### a) 车群贡献度

车群贡献度：基于感知贡献度，定义车群的贡献度：车群通过节点之间的感知贡献提升整体对周围行车环境的理解能力。为此，我们考虑车群贡献度用来度量车群对周围环境的感知程度，可表示为：

$$C(G_i) = \sum_{v_i \in V(w)} \left[ \sum_{x \in B_i} (C_i(x) \cdot W_i(x)) \right]$$

其中， $W_i(x)$ 为车辆  $i$  的感知度， $C_i(x)$ 为车辆  $i$  的贡献度。

#### b) 车群性质

(1) 持续性：采用边缘数据解析模型得到的贡献时长度度量车群节点之间能够保持感知贡献的持续性：

$$U(G_i) = \sum_{v_j, v_k \in G_i} \frac{u(v_j, v_k)}{N_i}$$

其中， $u(v_j, v_k)$ 表示车辆  $v_j$  和  $v_k$  之间的贡献时长。

(2) 耦合性：采用贡献中断率、贡献可靠度、贡献吞吐量用来度量车群节点之间相互依赖的程度，即耦合性，可表示为：

$$P(G_i) = \sum_{v_j, v_k \in G_i} ((1 - p_1(v_j, v_k)) \prod_{l=2}^3 p_l(v_j, v_k))$$

其中,  $p_1(v_j, v_k)$  表示车辆节点  $v_j$  和  $v_k$  之间的贡献中断率,  $p_2(v_j, v_k)$  表示车辆节点  $v_j$  和  $v_k$  之间的贡献可靠率,  $p_3(v_j, v_k)$  表示车辆节点  $v_j$  和  $v_k$  之间的贡献吞吐量

(3) 实时性: 考虑使用感知贡献传输延迟用来度量车群节点之间感知贡献的实时性:

$$T(G_i) = \sum_{v_j, v_k \in G_i} \frac{1}{t(v_j, v_k)}$$

其中,  $t(v_j, v_k)$  表示车辆  $v_j$  与  $v_k$  之间贡献传输延迟。

#### c) 无人驾驶车群模型

综上所述, 无人驾驶车群可以表示为:

$$\begin{aligned} \Pi(G_i) &= [C(G_i), U(G_i), P(G_i), T(G_i)] \\ \left\{ \begin{aligned} C(G_i) &= \sum_{v_j \in V} \left[ \sum_{x \in B_i} (C_i(x) \cdot W_i(x)) \right] \\ U(G_i) &= \sum_{v_j, v_k \in G_i} \frac{u(v_j, v_k)}{N_i} \\ P(G_i) &= \sum_{v_j, v_k \in G_i} ((1 - p_1(v_j, v_k)) \prod_{l=2}^3 p_l(v_j, v_k)) \\ T(G_i) &= \sum_{v_j, v_k \in G_i} \frac{1}{t(v_j, v_k)} \end{aligned} \right. \end{aligned}$$

其中,  $\Pi(G_i)$  表示无人驾驶车群模型,  $C(G_i), U(G_i), P(G_i), T(G_i)$  分别表示车群贡献度, 持续性, 耦合性和实时性, 车群的约束条件可表示为:

$$\rho(G_i) \leq \rho_{th}$$

其中,  $\rho(G_i)$  表示车群的贡献容量,  $\rho_{th}$  表是车群贡献容量最大值。

#### d) 基于多目标优化的无人驾驶车群模型求解

在贡献容量约束下, 考虑无人驾驶车群的车群贡献度, 耦合性, 持续性, 实时性, 进行多目标优化问题建模, 基于帕累托最优思想, 利用进化算法对无人驾驶车群进行求解, 具体求解过程如图 4.8 所示:

目标函数:



$$\begin{cases} f_1 = \sum_{v_j \in V} \left[ \sum_{x \in B_i} (C_i(x) \cdot W_i(x)) \right] \\ f_2 = \sum_{v_j, v_k \in G_i} \frac{u(v_j, v_k)}{N_i} \\ f_3 = \sum_{v_j, v_k \in G_i} ((1 - p_1(v_j, v_k)) \prod_{l=2}^3 p_l(v_j, v_k)) \\ f_4 = \sum_{v_j, v_k \in G_i} \frac{1}{t(v_j, v_k)} \end{cases}$$

约束条件：在车群形成过程中，不仅受到感知贡献容量的约束，还受到例如车辆动力学、交通规则、道路行驶准则等约束，可表示如下：

$$\mathbb{H} = \{\rho, \omega, \gamma, \delta, \dots\}$$

其中，其中， $\mathbb{H}$ 为约束条件集， $\rho$ 表示感知贡献容量限制， $\omega$ 表示车辆动力学约束条件， $\gamma$ 则是开放式路网环境交通规则， $\delta$ 为车辆行驶准则。

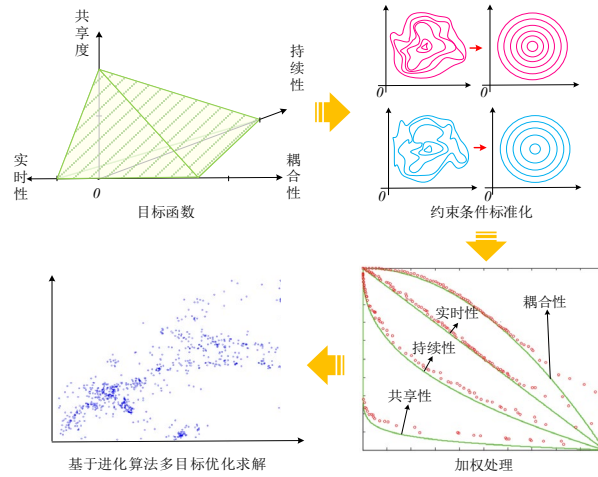


图 4.8 无人驾驶模型求解

#### ④ 无人驾驶车群动态演化方法

由于开放式无人驾驶场景下客观存在有人驾驶车辆、行人、路边障碍物、红绿灯等不确定性干扰，使得车群中边缘节点需要处理的边缘数据不断变化，且在感知贡献时，车间的感知需求卸载也会受到不确定性干扰因素的影响，车群一直是处于动态变化状态，为此，我们需要全面考虑开放式无人驾驶路网环境下的动态演化过程包括节点的加入，分离，消亡，合并，分裂等行为，即车群的改变事件，如图 4.9 所示。具体概括如下：

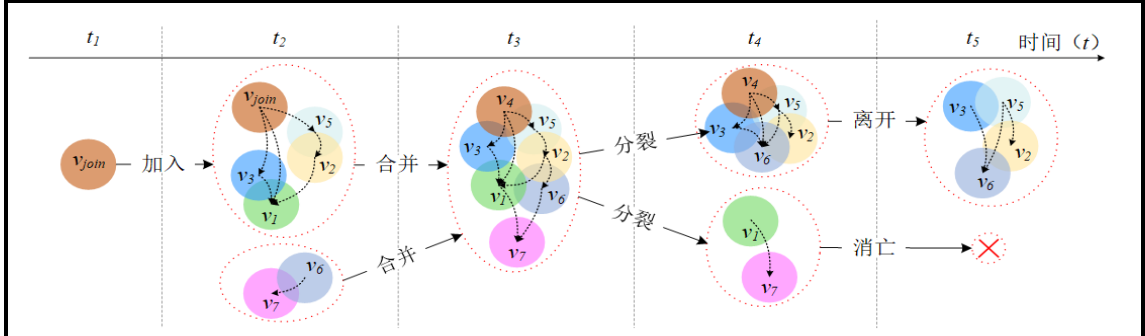


图 4.9 车群改变事件类型

#### a) 加入事件

加入事件是开放式路网环境下存在单智能体节点，包括新出现的无人驾驶车辆节点或者其他车群分离出的节点，具备成为边缘节点的条件但是没有呈现出为作为感知需求卸载的对象或为车群中节点提供感知贡献信息的特征，此时，需要考虑加入事件。新节点的加入使得该节点可以为车群中某个或多个车辆节点贡献感知信息，使得车群的贡献度、持续性、耦合性、实时性会相应的发生变化，且将被加入的车群的贡献容量小于贡献容量上限时，该车群可以且需要执行加入事件，如图 4.10 所示，可表示为：

$$\left\{ \begin{array}{l} \forall v_i \in \{v_{join} | i \in 1, 2, 3, \dots\} \Rightarrow \vartheta(v_i) = 1 \\ \rho(G_t) < \rho_{th} \\ \forall v_i \in \{v_{join} | i \in 1, 2, 3, \dots\} \Rightarrow \zeta(v_i, v_j) = 1, v_j \in G_t \\ C(G_{t+1}) > C(G_t) \vee U(G_{t+1}) > U(G_t) \vee P(G_{t+1}) > P(G_t) \vee T(G_{t+1}) > T(G_t) \\ \exists v_{join} \notin G_t \cap v_{join} \in G_{t+1} \cap |G_{t+1}| > |G_t| \end{array} \right.$$

其中， $\forall v_i \in \{v_{join} | i \in 1, 2, 3, \dots\} \Rightarrow \vartheta(v_i) = 1$  表示待加入无人驾驶车辆节点处于游离状态； $\rho(G_t) < \rho_{max}$  表示车群  $G_t$  的贡献容量保持在最大贡献容量之内； $\forall v_i \in \{v_{join} | i \in 1, 2, 3, \dots\} \Rightarrow \zeta(v_i, v_j) = 1, v_j \in G$  当表示所有待加入的无人驾驶车辆节点在车群内至少一个节点的通讯范围之内； $C(G_{t+1}) > C(G_t) \vee U(G_{t+1}) > U(G_t) \vee P(G_{t+1}) > P(G_t) \vee T(G_{t+1}) > T(G_t)$  表示当一个或者多个车辆节点在  $t$  时刻加入车群  $G_t$  集合中的某个车群，在  $t+1$  时刻可能形成新的车群集合  $G_{t+1}$ ，新车群  $G_{t+1}$  的贡献度、持续性、耦合性、实时性至少其中一个获得提高； $\exists v_{join} \notin G_t \cap v_{join} \in G_{t+1} \cap |G_{t+1}| > |G_t|$  表示在车群  $G_{t+1}$  存在无人驾驶车辆节点集合  $v_{join}$  而在  $G_t$  中不存在，且车群  $G_{t+1}$  中的无人驾驶车辆节点数量大于  $G_t$ 。

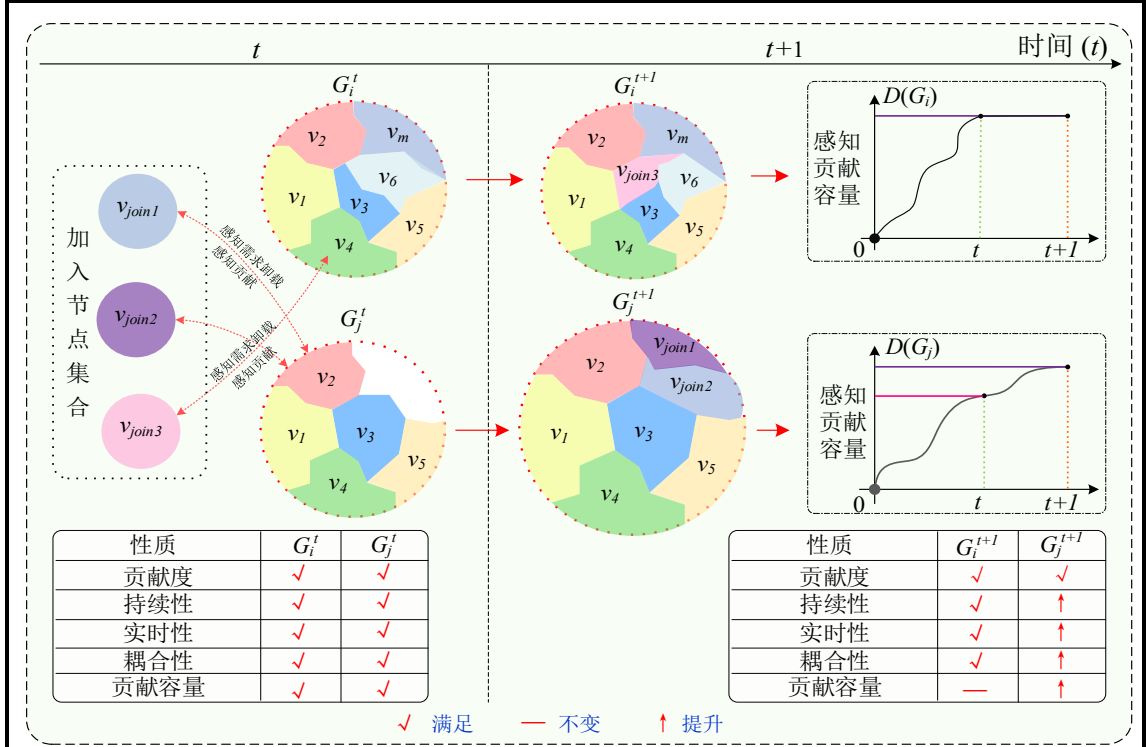


图 4.10 加入事件

#### b) 离开事件

离开事件是在开放式路网环境下中车群中的某个或者多个边缘节点受到有人驾驶车辆的干扰、红绿灯、路边交通标志、路口转弯、行人等的影响，呈现出与无人驾驶车群持续性，耦合性，实时性相背离的特征，已经不能作为车群中某节点感知需求卸载的对象，不满足车群感知贡献的条件，如图 4.11 所示，具体表示如下：

$$\begin{cases} \forall v_i \in \{v_{leave} | i \in 1, 2, 3 \dots\} \Rightarrow \vartheta(v_i) = 0 \\ C(G_{t+1}) > C(G_t) \vee U(G_{t+1}) > U(G_t) \vee P(G_{t+1}) > P(G_t) \vee T(G_{t+1}) > T(G_t) \\ \exists v_{leave} \in G_t \cap v_{leave} \notin G_{t+1} \cap |G_{t+1}| < |G_t| \end{cases}$$

其中， $\forall v_i \in \{v_{leave} | i \in 1, 2, 3 \dots\} \Rightarrow \vartheta(v_i) = 0$  表示待离开节点处于贡献状态； $C(G_{t+1}) > C(G_t) \vee U(G_{t+1}) > U(G_t) \vee P(G_{t+1}) > P(G_t) \vee T(G_{t+1}) > T(G_t)$  意味着当一个或者多个车辆节点在  $t$  时刻离开车群  $G_t$  集合中的某个车群，在  $t+1$  时刻可能形成新的车群集合  $G_{t+1}$ ，新车群  $G_{t+1}$  的贡献度、持续性、耦合性、实时性至少其中一个获得提高； $\exists v_{leave} \in G_t \cap v_{leave} \notin G_{t+1} \cap |G_{t+1}| < |G_t|$  表示在车群  $G_t$  存在无人驾驶车辆节点集合  $v_{leave}$  而在  $G_{t+1}$  中不存在，且车群  $G_{t+1}$  中的无人驾驶车辆节点数量小于

$G_t$ 。

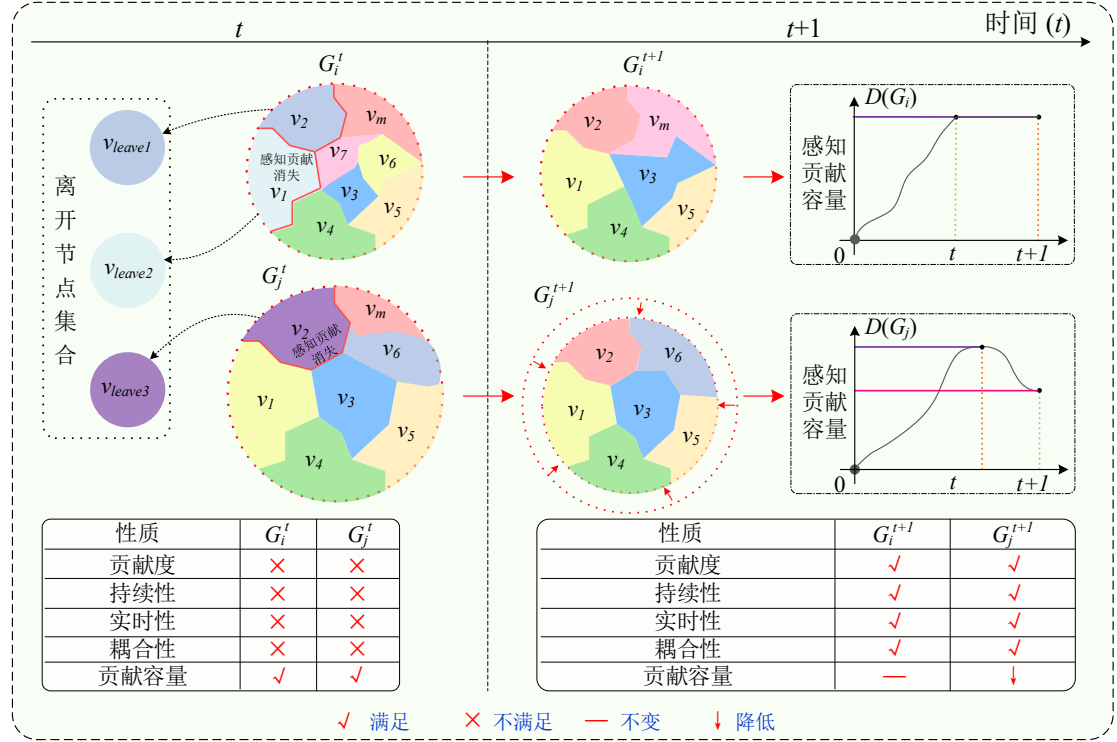


图 4.11 离开事件

### c) 分裂事件

分裂事件是在开放式路网环境下中车群中的多个节点同时受到有人驾驶车辆的干扰、红绿灯、路边交通标志、路口转弯、行人等的影响，呈现出与无人驾驶车群持续性，实时性，耦合性相背离的特征，不能满足车群感知贡献的智能行为，我们认为其发生分裂事件，具体表示如下：

$$\begin{cases} \forall v_i \in \{v_{join} | i \in 1, 2, 3 \dots\} \Rightarrow \vartheta(v_i) = 1 \\ \rho(G_t) < \rho_{th} \\ \forall v_i \in \{v_{join} | i \in 1, 2, 3 \dots\} \Rightarrow \zeta(v_i, v_j) = 1, v_j \in G_t \\ C(G_{t+1}) > C(G_t) \vee U(G_{t+1}) > U(G_t) \vee P(G_{t+1}) > P(G_t) \vee T(G_{t+1}) > T(G_t) \\ \exists v_{join} \notin G_t \cap v_{join} \in G_{t+1} \cap |G_{t+1}| > |G_t| \end{cases}$$

其中， $\forall v_i \in \{v_{leave} | i \in 1, 2, 3 \dots\} \Rightarrow \vartheta(v_i) = 0$  表示待分裂的车群节点处于通信范围之内； $(T_{G_i}^{t+1} \geq T_{G_m}^t) \wedge (T_{G_j}^{t+1} \geq T_{G_m}^{t+1})$  和  $(P_{G_i}^{t+1} \geq P_{G_m}^t) \wedge (P_{G_j}^{t+1} \geq P_{G_m}^{t+1})$  表示分裂后子车群实时性、持续性提高， $(U_{G_i}^{t+1} \geq U_{G_m}^t) \wedge (U_{G_j}^{t+1} \geq U_{G_m}^{t+1})$  表示分裂后子车群耦合性提高， $\Gamma$  表示车群相似度函数， $\Gamma(G_i^{t+1} \cup G_j^{t+1}) / \Gamma(G_m^t) = 1$  表示分裂后车群  $G_i^{t+1}$  和  $G_j^{t+1}$  中的

车群成员均来自于车群  $G_m^t$ 。

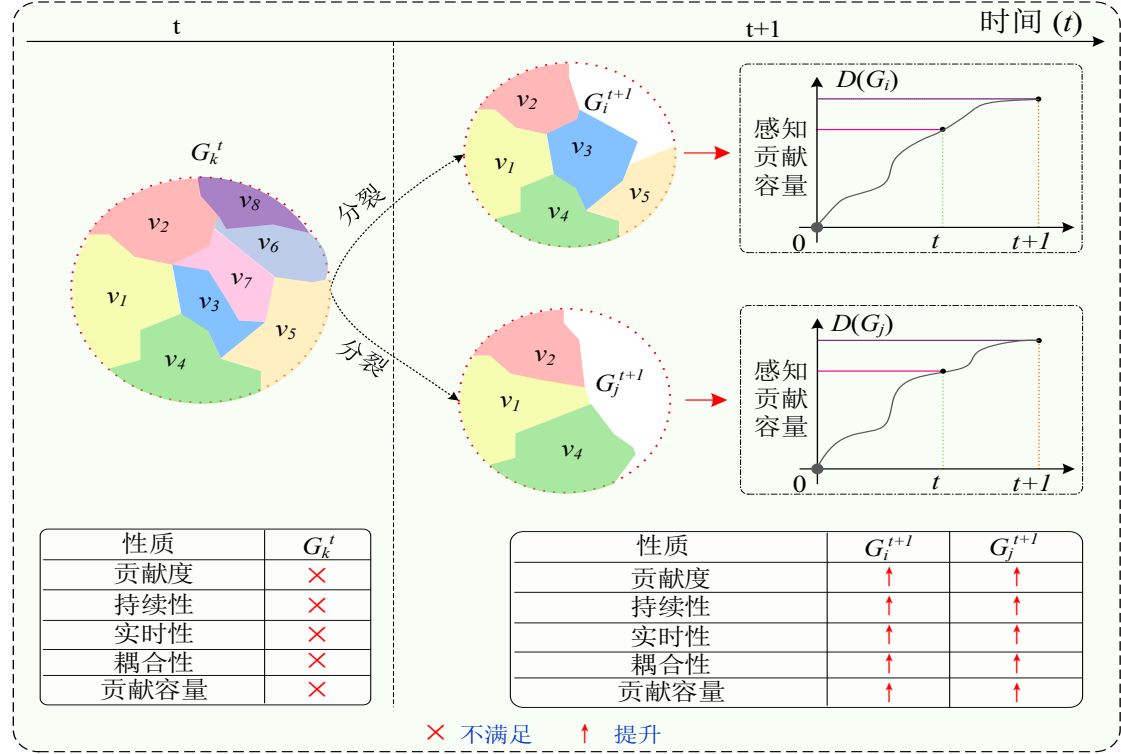


图 4.12 分裂事件

#### d) 合并事件

合并事件是在开放式路网环境下中存在两个或两个以上的车群，两个车群中的不同节点由于受到有人驾驶车辆的干扰、红绿灯、路边交通标志、路口转弯、行人等的影响，表现出与另一车群相似的运动状态，若两者进行合并可以使得形成后车群的贡献度、持续性、耦合性、实时性增加，更好的完成车群中感知需求卸载实现车群整体感知；则该车群可以且需要执行合并事件，具体表示如下：

$$\left\{ \begin{array}{l} \forall v_i \in \{G_i^t\} \Rightarrow \zeta(v_i, v_j) = 1, v_j \in G_j^t \\ T_{G_m}^{t+1} > \max(T_{G_i}^t, T_{G_j}^t) \\ P_{G_m}^{t+1} > \max(P_{G_i}^t, P_{G_j}^t) \\ U_{G_m}^{t+1} > \max(U_{G_i}^t, U_{G_j}^t) \\ \rho(G_m^{t+1}) \leq \rho_{th} \\ \forall v_i \in G_{t+1} \Rightarrow v_i \in G_t \end{array} \right.$$

其中， $T_{G_m}^{t+1} > \max(T_{G_i}^t, T_{G_j}^t)$  表示车群合并后持续性提高， $P_{G_m}^{t+1} > \max(P_{G_i}^t, P_{G_j}^t)$  表示车群合并后耦合性提高， $U_{G_m}^{t+1} > \max(U_{G_i}^t, U_{G_j}^t)$  表示车群合并后贡献度提高。 $\rho(G_m^{t+1}) \leq \rho_{th}$  合并之后的无人驾驶车群的贡献容量要保持在最大贡献容量之下；

$\forall v_i \in \{G_i^t\} \Rightarrow \zeta(v_i, v_j) = 1, v_j \in G_i^t$  表示即将发生合并事件的两个或者多个车群中至少存在一对出游感知信息贡献状态； $\forall v_i \in G_{t+1} \Rightarrow v_i \in G_t$  则表示合并之后的无人驾驶车群  $G_{t+1}$  中的所有节点均来自于车群集合。

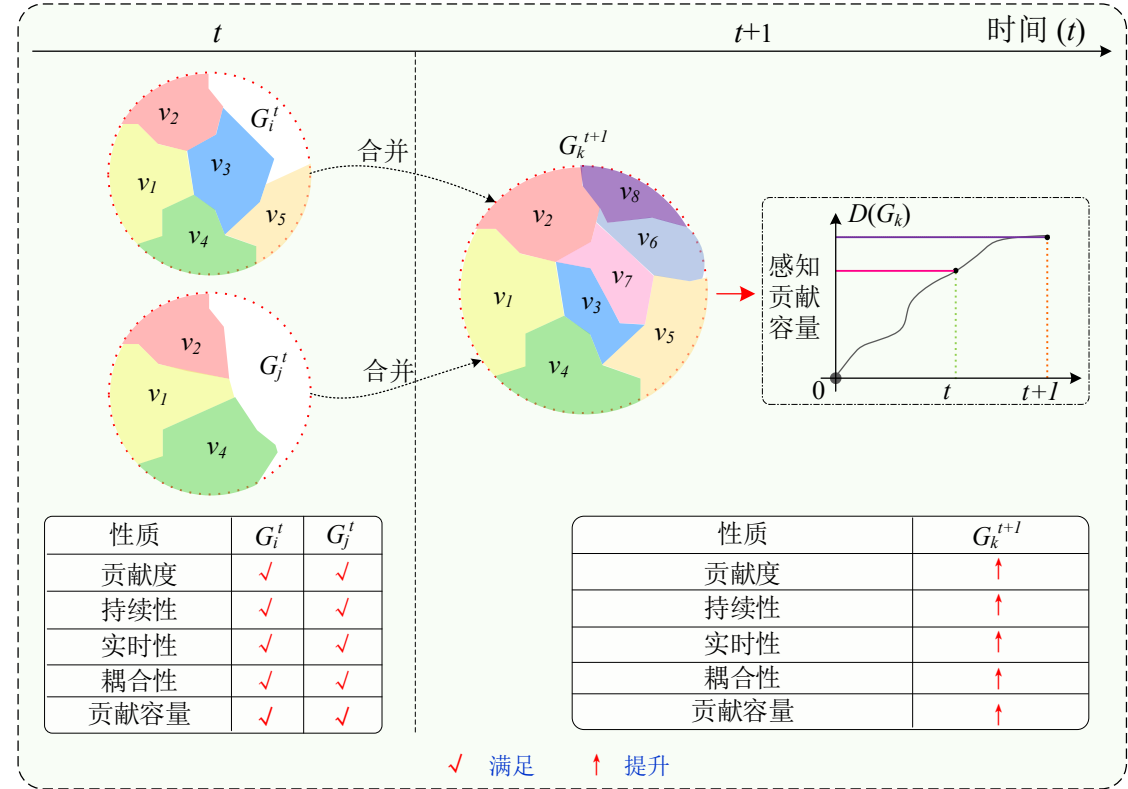


图 4.13 合并事件

### e) 消亡事件

消亡事件是在开放式路网环境下中车群集合受到有人驾驶车辆的干扰、红绿灯、路边交通标志、路口转弯、行人等的影响，会发生分裂、离开等动态演化事件，而在  $t$  时刻时，车群内部成员只有一辆无人驾驶车辆且周围没有其他可以有效感知贡献的车辆时，这时车群消亡，具体表示如下：

$$\begin{cases} \forall v_j \in \{U\} \Rightarrow \zeta(v_i, v_j) = 1, v_i \in G_t \\ |G_t| = 1 \\ (T_{G_i}^{t+1} \leq T_{min}) \cup (P_{G_i}^{t+1} \leq P_{min}) \cup (U_{G_i}^{t+1} \leq U_{min}) \end{cases}$$

其中， $|G_t| = 1$  表示车群数目为 1； $\forall v_j \in \{U\} \Rightarrow \zeta(v_i, v_j) = 1, v_i \in G_t$  表示车群节点  $v_i$  周围没有其他任何可以为  $v_i$  提供有效感知信息贡献的车辆节点；

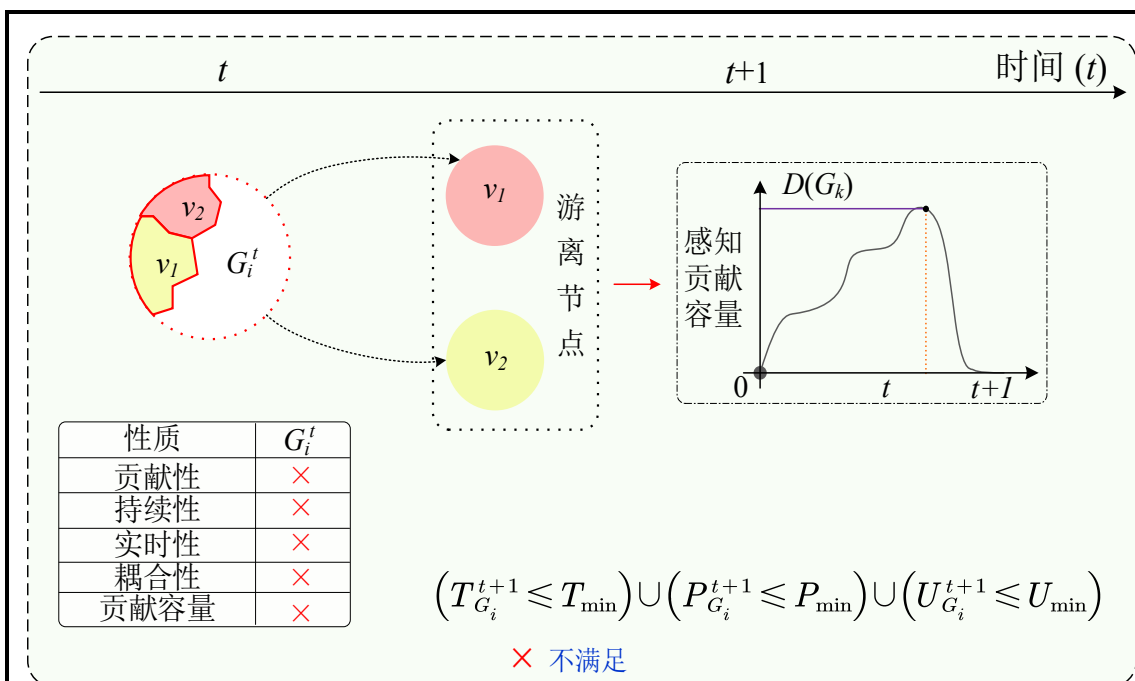


图 4.14 消亡事件

f) 无人驾驶车群的演变性:

在开放式路网环境下车群集合会受到有人驾驶车辆的干扰、红绿灯、路边交通标志、路口转弯、行人等的影响，发生节点离开、加入，车群分裂、合并、消亡等动态演化事件。导致无人驾驶车群处于不同的状态。我们分析无人驾驶车群动态演化行为，建立车群动态演化事件与车群状态的关联关系，挖掘无人驾驶车群动态演化规律，探求无人驾驶车群的演变性。具体研究思路如下：

车群状态：随着无人驾驶车群动态演化事件的发生，车群将在不同状态之间转换，如图 4.15 所示，无人驾驶车群主要包含初始状态 $s_1$ ，增长状态 $s_2$ ，收缩状态 $s_3$ ，平衡状态 $s_4$ 以及消亡状态 $s_5$ 五种状态。

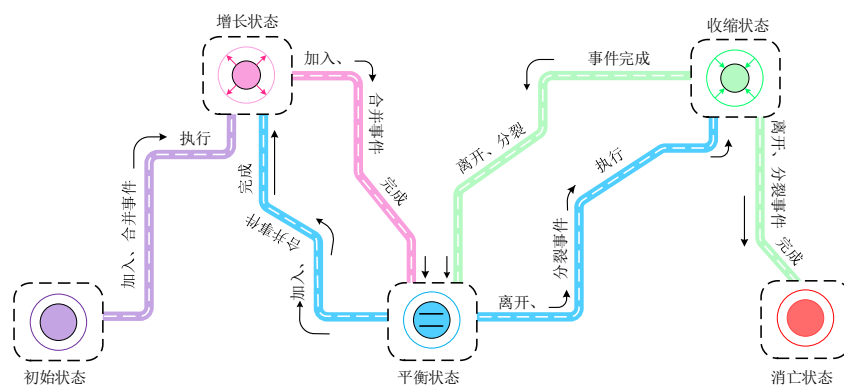


图 4.15 无人驾驶车群状态转换

由于动态演化事件的发生，车群会在不同状态之间转换，主要有以下 5 中状态：

**初始状态：**当无人驾驶车群诞生事件发生后，游离节点转换为无人驾驶车群的边缘节点开始为其他无人驾驶车辆节点贡献有效感知信息。此时，无人驾驶车群处于初始状态。

**增长状态：**当无人驾驶车辆通过车群内任一节点贡献有效感知数据即成为车群内某一或多个车辆节点的边缘节点时，这时该节点计算当前无人驾驶车群的贡献容量，若该车群的贡献容量在车群贡献容量的保持上限之内，则该无人驾驶车群将发生加入事件；又当另一无人驾驶车群  $G_2$  内任一或多个无人驾驶车辆节点通过无人驾驶车群  $G_1$  内任一节点贡献有效感知数据时，这时该节点同样根据当前无人驾驶车群的贡献容量，若该车群的贡献容量在车群贡献容量的保持上限之内，则该无人驾驶车群将发生合并事件。此时无人驾驶车群处于增长态，无人驾驶车群的规模随着节点加入、车群合并时间的发生而增长。

**收缩状态：**当无人驾驶车群发生普通节点离开、车群分裂事件时，无人驾驶车群规模随普通节点离开、车群分裂事件的发生而减少。此时，无人驾驶车群处于收缩状态。

**平衡状态：**当外界干扰因素对无人驾驶车群结构影响较小时，没有无人驾驶车群动态演化事件发生，无人驾驶车群成员之间的贡献不发生变化。此时，无人驾驶车群处于均衡态，无人驾驶车群规模、度保持不变。

**消亡状态：**当无人驾驶车群发生消亡事件时，无人驾驶车群处于消亡状态。此时无人驾驶车群的规模和度均为 0。

**演变性：**无人驾驶车群的演变性指开放式场景下的动态演化规律，即车群状态转换与车群动态演化事件的关联关系。对于车群的动态演化过程  $\mathcal{B}_t \rightarrow \mathcal{B}_{t+1}$ ，我们构造演变性度量函数，得到车群  $G_i^t$  演化为车群  $G_j^{t+1}$  时发生的演化事件类型，以及状态转换过程。因此，车群的演变性  $F$  可表示为：

$$F: (G_i^t, G_j^{t+1}, \mathcal{B}_t \rightarrow \mathcal{B}_{t+1}, \Phi(G^t)) \rightarrow F = (\gamma, \lambda)$$

$$s.t. \begin{cases} \Phi(G_i^t) = \{s_1, s_2, s_3, s_4, s_5\} \\ \gamma < \gamma_{th}, \lambda < \lambda_{th} \end{cases}$$



其中,  $G^t = \{G_i^t | i \in 1, 2, 3, \dots\}$  与  $G^{t+1} = \{G_i^{t+1} | i \in 1, 2, 3, \dots\}$  分别表示  $t$  和  $t+1$  时刻的车群集合,  $\Phi(G_i^t) = \{s_1, s_2, s_3, s_4, s_5\}$  表示车群  $G_i^t$  的状态,  $\gamma$  和  $\lambda$  分别表示车群动态演化和状态转换的车群改变程度。

无人驾驶车群演变性如图 4.16 所示, 当发生加入事件时, 演变性随车群规模的增大而增大, 然后车群进入平衡状态, 车群规模保持不变, 演变性在一定范围内波动; 当车群发生合并事件时, 演变性随车群规模的增大而增大; 当车群发生分裂事件时, 演变性随车群规模的减小而减小。




图 4.16 无人驾驶车群的演变性

#### ⑤ 无人驾驶车群自协方法

通过对开放式场景下车群的动态演化过程中相关改变事件的具体分析, 为了在外部干扰下车群仍然可以表现出智能协同的特征, 我们需要考虑车群自协的完备性: 稳定性, 鲁棒性, 收敛性, 构建无人驾驶车群自协理论模型, 达到自协的自协忠实的目的。为此我们需要研究:

a) 车群的稳定性: 用来衡量动态演化过程中车群贡献度随感知贡献关系变化的波动量。

$$S(G_i) = \sum_{v_j, v_k \in G_i} \frac{(c(v_j, v_k) - \bar{c})}{c_{\max} - c_{\min}}$$

其中,  $S(G_i)$  表示车群的稳定性,  $\bar{c}$  表示车辆节点  $v_j$  和  $v_k$  之间贡献度平均值,

$c_{\max}$  和  $c_{\min}$  分别表示车辆节点  $v_j$  和  $v_k$  之间贡献度的最大值和最小值。

b) 车群的鲁棒性：用来衡量在动态演化中车群的抗干扰能力，可表示为：

$$R(G_i) = \sum_{f \in I} \sum_{v_j, v_k \in G_i} \frac{e(v_j, v_k | f)}{H(v_j, v_k | f)}$$

c) 车群的收敛性：用来度量在动态演化过程中车群对周围行车环境的理解程度，可表示为：

$$\Upsilon(G_i) = \frac{\sum_{i \in G} \sum_{x \in B_i} W_i(x)}{\sum_{i \in G} |B_i|}$$

d) 自协理论模型：

基于车群自协的性质，给出车群自协理论模型。如图 4.17 所示，具体描述为：

$$\Lambda(G_i) = \max(E(G_i), P(G_i), T(G_i), C(G_i), F(G_i), S(G_i), R(G_i), \Upsilon(G_i))$$

$$s.t. \quad \rho(G_i) \leq \rho_{th}$$

其中， $\Lambda(G_i)$  表示车群自协理论模型； $\rho_{th}$  表示车群感知贡献容量的最大值。




图 4.17 无人驾驶车群自协模型

## ⑥ 设计模拟应用场景验证自协方法

本文所研究的开放式无人驾驶车群自协机理在设计方法和理论模型上,可能会产生一些不相关的需求因子,对研究结果实施应用之前,必须对提出的方法和理论模型进行可靠性与置信度高的正确性检测和性能评估。我们设计一个模拟应用场景,验证自协方法。具体描述如下:

### a) 设计模拟应用场景

基于 SUMO 仿真器设计一个包含无人驾驶车辆、有人驾驶车辆、障碍物、红绿灯的模拟应用场景,如图 4.18 所示;基于 KITTI 数据集对场景内每一辆无人驾驶车辆的感知数据进行仿真;基于 OMNeT++对实时路网环境、信息交互进行仿真模拟。

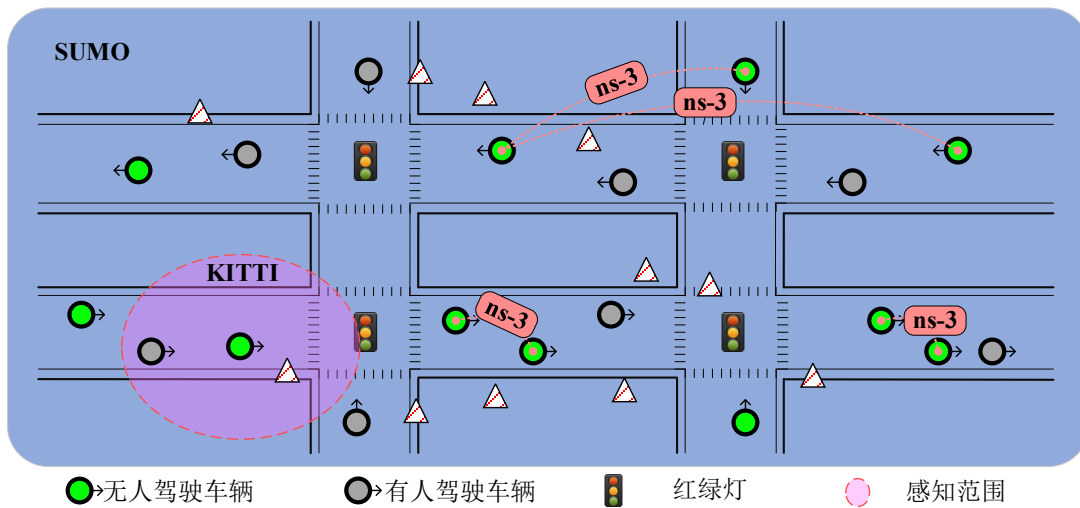


图 4.18 模拟应用场景

### b) 仿真实验仿真

仿真框架 Veins 包括交通仿真器 SUMO 和网络仿真器 OMNeT++, 它们之间通过一条 TCP 连接进行双向通信, Veins 的研究人员开发了完整的 IEEE 802.11p 和 IEEE 1609.4 的 DSRC/WAVE 仿真模型, 可以完整的模拟 WAVE 的所有特性。因此, 我们采用 Veins 框架进行仿真实验, 具体步骤如下: 首先需要将开放式无人驾驶路网数据集转换成 SUMO 可以识别的格式; 通过 SUMO 与 Veins 进行信息交互, 实现仿真任务。

### c) 数据解析的仿真实验与分析

统计无人驾驶车辆节点间性质预测模型的浮点计算量、参数量大小、训练代价、准确率、平均误差等，分析得到该模型在具体应用场景下的表现。动态演化实时与稳定的仿真实验与分析。与现有的预测方法在各对比指标下进行对比，得出本文方法相较于现有的预测方法在浮点计算量、参数量大小、训练代价、准确率、平均误差等方面展现的优势。

分别统计该模型在不同时刻下的平均误差分布，分析得到在不同时刻预测模型的表现。

#### d) 无人驾驶车群模型的实验与分析

拟采用以下指标对无人驾驶车群进行评估：

无人驾驶车群平均数目：统计在仿真过程中，无人驾驶车群的数量。

车群成员平均寿命：无人驾驶车辆节点从成为车群节点到放弃车群节点的平均时长。

变更车群的成功率：车群成员离开一个车群后，成功加入另一个车群的比例。

变更车群的平均延迟：车群成员离开一个车群后，加入另一个车群所需要的平均时长。

车群平均生存时间：车群从形成到消亡平均存亡时长。

车群耦合系数：使用车群耦合系数来对车群网络结构质量进行评价。

#### e) 无人驾驶车群动态演化方法及自协模型的实验与分析

拟采用以下指标对无人驾驶车群进行评估：

平均车群切换次数：平均车群切换次数表示无人驾驶车辆节点在其生命周期中进行车群切换的平均次数。

车群生存时长：车群生存时长表示车群从形成到消亡之间生存的平均时长，车群生存时长越长，说明车群动态演化方法在保障车群顺利演化的同时，也能够更好的维持车群的结构稳定。

节点稳定时长：节点稳定时长表示节点每次加入车群后稳定生存的平均时长，节点稳定时长越短，表明节点每次加入车群很快会再次离开车群。

### 3) 关键技术或难点

① 如何刻画开放式环境下无人驾驶车辆边缘节点与边缘数据之间非线性相互作用的表示方法。无人驾驶车群边缘数据是由若干不同种类、维度的信息构成的一个复杂的数据集合。准确提取和分析无人驾驶车辆边缘数据是本文首要解决的一个难点。

② 如何基于边缘计算思想深刻剖析车辆节点间感知需求卸载与感知贡献的关系，同时，构造感知贡献模型从而获得无人驾驶车辆边缘节点在感知贡献时的一般规律是本文需要解决的一个难点。

③ 如何基于边缘计算思想在感知贡献模型的基础上建立无人驾驶车群模型，使得无人驾驶车群在运动过程中可以持续进行感知贡献，时刻保持运动行为智能化的特点是本文需要解决的一个难点。

④ 如何建立适用于开放式环境下复杂形态的无人驾驶车群的动态演化行为机制。开放式无人驾驶路网环境的复杂性，使得无人驾驶车群在运动过程中，随着无人驾驶车辆节点感知信息的不断变化和周围环境的不确定性干扰，车群处于动态演化状态。如何利用边缘计算思想，深入剖析无人驾驶车群动态演化行为，揭示车群内部变化的一般性规律，是本文拟解决的一个难点。

⑤ 如何建立基于边缘计算的开放式无人驾驶车群自协理论模型。结合构建的无人驾驶车群动态演化行为机制及其车群状态，从整体角度出发，考虑车群的演变性，稳定性，收敛性，鲁棒性，提供统一的数学模型及其计算和分析方法，有效地分析在高动态演变环境下的自协性能，达到无人驾驶车群运动行为智能化的目标，是本文拟解决的一个难点。

⑥ 如何设计模拟应用场景验证无人驾驶车群自协方法。开放式无人驾驶车群是一个复杂的系统，无论是感知信息，节点数目，外部环境以及通信技术等环节，均与目前已有研究的无人驾驶小尺度闭环系统有所不同。因此，如何设计一个包含无人驾驶车辆，有人驾驶车辆，障碍物，红绿灯等节点的模拟应用场景，并从数据真实准确和动态演化实时稳定两个层面验证无人驾驶车群自协方法，是本文拟解决的一个难点。

## 5. 创新点

本文针对未来无人驾驶车群在开放式环境下运动所面临的关键科学问题，从需求的多样性和环境的多变性出发，围绕无人驾驶车群复杂形态的动态演化行为和自协模型展开研究，具体创新点主要体现在如下四点：

(1) 引入深度学习技术解析开放式场景下无人驾驶边缘感知数据，保障数据解析和感知贡献真实准确，以解决信息保真问题，丰富和拓展了无人驾驶领域的研究方法。。

(2) 利用感知贡献的思想求解车群节点之间感知贡献关系随时间变化仍然能够保持贡献动态感知结果的自协理论模型，以解决自协忠实问题，有效支撑无人驾驶车群运动过程稳定有序。

(3) 提出一种基于模拟应用场景的无人驾驶车群自协验证方法，验证了自协模型的正确性，丰富了无人驾驶仿真实验的研究方法。

(4) 提出一套适用于开放式场景下无人驾驶复杂形态的“数据解析→感知贡献→车群构建→动态演化→模型自协”的理论体系，满足无人驾驶车群完备性自协的要求，从而可以实现无人驾驶车群运动行为智能协同的目标。

## 6. 可行性分析与研究基础

### 1) 可行性分析

#### ① 理论可行性

**边缘计算：**边缘计算是为应用开发者和服务提供商在网络的边缘侧提供云服务和IT环境服务；低时延、去中心化、高带宽，作为边缘计算的优势，将边缘计算思想应用至无人驾驶车辆节点之间的感知贡献、车群自协模型构建上，有利于无人驾驶车群更好的达成自协忠实的目的。

**深度学习：**处理复杂数据的优势是一般方法所不能比拟的。首先，深度学习可以将数据低层特征形成更加抽象的高层表示，抽取原始数据重要信息的同时达到数据降维，降低数据的复杂度，提高处理效率；其次，深度学习具有多层非线性映射的深层结构，可以完成复杂的函数逼近，发掘数据中的一般性规律和数据间的关联性特征，从而有利于实时根据节点相似性特征进行归类。

#### ② 研究方案可行性

研究方法和技术路线是在国家自然科学基金面上项目研究过程中发现的无人驾驶领域的新问题的基础上的发展与创新，以理论分析与证明、数值分析、仿真实验相互结合及交叉验证，符合当前国内外技术发展趋势和理论需求。

#### ③ 仿真实验数据可行性

KITTI数据集是目前国际上最大的自动驾驶场景下的计算机视觉算法评测数据集，它包括市区、乡村和高速公路等场景采集的真实图像数据，利用KITTI数据集的开发工具Development Kit可以获取传感器感知信息以及后期标注信息，包括：激光雷达点云，GPS数据，右边彩色摄像机数据以及灰度摄像机图像等多模态数据，以及读写标签、2D/3D框等标注信息。

表1 常用的无人驾驶环境仿真器

环境仿真器	VI-Grade	AirSim	Apollo	ROS	ProSiVIC	PRESCAN	Udacity
发布单位	VI-Grade	Microsoft	百度	Rethink Robotics	ESI Group	TASS International	Udacity
仿真编程语言	Unknown	C/C++	C/C++	Python	Unknown	Matlab	Python
是否图形界面	是	是	否	否	是	否	否
官方支持操作系统	Windows/ Linux	Windows/ Linux	Windows/ OS X/Linux	Windows/ Linux	Windows/ Linux	Windows/ Linux	Windows/ OS X/Linux
提供源代码	否	是	是	是	否	否	是
主要针对对象	无人驾驶	无人飞行器/无人驾驶	人工智能/无人驾驶	机器人/无人驾驶	无人驾驶	无人驾驶	无人驾驶
是否包括 GPS 信息	是	是	是	否	是	是	是

#### ④ 仿真实验环境可行性

通过调研分析，我们总结了经常使用的无人驾驶环境仿真器，如表1所示，为本文环境仿真器的选择提供依据，其中，选择Udacity（表1最右边栏）作为本文环境仿真器。

通过调研发现，目前在无人驾驶方面还没有可用的网络仿真器和仿真框架。考虑到本文研究无人驾驶车群的动态演化行为以及自协理论模型等，包括无人驾驶车辆节点之间，以及与外部环境之间的通信，其网络仿真环境类似于车联网节点之间的通信，因此，我们总结了七个常用的车联网网络仿真器，如表2所示，选择OMNeT++（表2最右边栏）作为本文网络仿真器。

表2 常用的车联网网络仿真器

网络仿真器	OPNET	QualNet	ns-2	ns-3	J-Sim	SWANS	OMNeT++
许可协议	商业/ RPM Modeler	商业/ SCALABLE	GNU GPLv2	GNU GPLv2	BSD 协议	学术	学术/商业
仿真编程语言	C/C++	C/C++	C++/OTcl	C++/ Python	Java/Tcl/ Perl/Python	Java/Python	C++/NED
是否图形界面	是	是	否	否	否	否	是
官方支持操作系统	Windows	Windows/ Linux	Windows/ OS X/Linux	Windows/ Linux	Windows/ OS X/ Linux	Windows/ OS X/ Linux	Windows/ OS X/Linux
是否提供源代码	仅仿真模块	是	是	是	是	是	是
官方支持的无线通信技术	WiFi/LTE/UMTS/WiMAX/Zigbee/卫星	WiFi/LTE/WiMAX/GSM/UMTS/Zigbee	Wi-Fi/卫星/蜂窝	Wi-Fi/WiMAX/LTE	Wi-Fi	Wi-Fi (IEEE 802.11b)	MiXiM:Wi-Fi/Zigbee/Venis:WAVE
是否包括移动模型	否	是	否	否	否	否	否

此外，我们总结了现有的紧密集成的仿真框架，如表3所示，选择最接近开放式无人驾驶实际场景并包含网络仿真器OMNeT++的Veins（表3最下面栏）作为本文的网络仿真框架。

表3 紧密集成的仿真框架

仿真框架名	通信方向	移动模型	网络仿真器	特点与缺陷
SWANS++	单向	STRAW	SWANS	采用简单路段间移动和起讫点技术管理车辆行进路线
GrooveNet	单向	Roadnav	自行开发	能够结合仿真车辆与真实车辆
TraNS	单向/双向	SUMO	ns-2	采用 TraCI 接口，将 ns-2 的移动命令转换成包括停止、换道和变速等原始命令的队列，并发送至 SUMO
ITETRIS	单向	SUMO	ns-3	TraNS 的后继
NCTUns4.0	单向	自行开发	自行开发	有预指定模式和自动导航模式；扩展能力差
Gorgorin	单向	VISSIM	自行开发	移动模型经由德国和美国公路采集的轨迹的验证；提供用来计算燃料消耗和污染物排放的模型
ASH	单向	IDM 汽车移动模型 MOBIL 车道变换模型	SWANS	有移动通信、移动静默、固定通信和固定静默等节点类型
VNS	单向	DIVERT 2.0	ns-3	基于四叉树的无线通信快速邻居搜索算法
Veins	单向	SUMO	OMNeT++	包括完整 WAVE 特性的模型

综上所述，本文研究方案是切实可行的，可以达到预期目标。



## 2) 研究基础

### ① 自己的专业基础

本人具有一定的无人驾驶相关的研究基础，研究过关于深度学习，无人驾驶车群，动态演化，边缘计算相关的论文。同时，在导师的指导下进行了许多相关的实验和研究，具有一定的理论和技术基础。

### ② 导师的专业把控能力

导师长期从事移动计算、移动互联网和车联网等领域的研究工作，并承担多项国家级、省部级重点科研项目，包括国家 973 计划项目、国家科技支撑计划项目以及上海市科委项目等。导师在车联网领域有丰富的经验，承担了国家自然科学基金项目“面向车联网大规模网络动态演化过程的通达性机理研究”和上海市自然科学基金“基于耗散结构特征的车联网网络动态演化机理研究”，有很强的专业把控能力。

### ③ 研究条件和实验条件

实验室具有一台高性能GPU运算能力的计算机。机器搭载Linux系统，能够运行开源车联网仿真器以及深度学习相关实验。

## 7. 预期成果

本文的预期研究成果主要是：

① 针对无人驾驶车群在开放式环境下应用受限的复杂形态，将边缘计算思想引入到无人驾驶车群实时动态演化过程，在此基础上，建立一个较为规范、系统、科学的自协理论模型，建立一套支持开放式无人驾驶车群运动行为智能化的理论体系和方法，从而为无人驾驶车群行驶过程稳定有序提供理论支撑，也为人工智能基础理论和关键共性技术体系探索新的理论和方法。

② 在 SCI/EI 检索的国内外高水平期刊和学术会议上发表学术论文 4-6 篇。

③ 对研究成果中的关键技术和方法申请国家发明专利 4-8 项。

## 8. 研究进度

起讫日期	主要研究内容	预期结果
2022 年 5 月 -2023 年 1 月	① 预处理无人驾驶车辆节点边缘数据； ② 探索无人驾驶车辆边缘节点与感知环境之间的内在联系和相互作用； ③ 利用深度学习构造开放式环境下的边缘数据解析模型。 ④ 数据解析模型仿真实验	① 规整输入数据 ② 获得模型输入 ③ 提供数据预测模型 ④ 构建边缘数据解析模型 ⑤ 发表 1-2 篇学术论文，申请国家发明专利 1-2 项
2023 年 1 月 -2023 年 7 月	① 基于感知贡献度求解无人驾驶车群的贡献度； ② 研究基于边缘计算思想的无人驾驶车群形成方法； ③ 考虑车群的贡献度，车群的实时性、耦合性、持续性构建无人驾驶车群模型； ④ 利用多目标优化算法对无人驾驶车群模型进行求解。 ⑤ 车群模型设计与仿真实验分析	① 得到无人驾驶车群贡献度的计算方法 ② 构建无人驾驶车群形成方法 ③ 建立无人驾驶车群模型 ④ 无人驾驶车群魔性求解 ⑤ 发表 2-4 篇学术论文，申请国家发明专利 2-4 项
2023 年 7 月 -2024 年 4 月	① 研究车群的动态演化行为和状态的分类及其形式化表示 ② 研究车群不同状态的关联关系以及状态转换的一般性规律 ③ 研究车群自协系统的完备性特征及其条件； ④ 研究车群内部作用下的自协影响机制； ⑤ 基于车群自协的完备性及其准则，研究动态演化过程的自协模型； ⑥ 车群自协系统完备性特征及其条件 ⑦ 自协理论模型的约束性条件 ⑧ 设计模拟应用场景验证自协方法	① 构造无人驾驶车群动态演化方法 ② 建立无人驾驶车群自协理论模型 ③ 形成一套适合于开放式无人驾驶车群运动行为智能化的理论体系 ④ 发表 1-2 篇学术论文，申请国家发明专利 1-2 项
2024 年 5 月 -2024 年 9 月	撰写学位论文	完成学位论文