

BindingDB: 一个可在线访问的实验测定的蛋白质 - 配体结合亲和力数据库

Tiqing Liu, Yuhmei Lin, Xin Wen, Robert N. Jorissen and Michael K. Gilson*

美国马里兰大学生物技术研究所高级生物技术研究中心, 地址: 美国马里兰州罗克维尔市古德尔斯基大道 9600 号, 邮编: 20850

收稿日期: 2006 年 8 月 11 日; 修改日期: 2006 年 10 月 18 日; 接受日期: 2006 年 10 月 20 日

摘要

BindingDB (<http://www.bindingdb.org>) 是一个公开可访问的数据库, 目前包含 20000 个实验测定的蛋白质-配体复合物的结合亲和力数据, 涉及 110 种蛋白质靶点 (包括同工型和突变型), 以及 11000 种小分子配体。这些数据是从科学文献中提取的, 数据收集主要针对那些作为药物靶点或候选药物靶点且其结构数据已存在于蛋白质数据库 (Protein Data Bank) 中的蛋白质。BindingDB 网站支持多种查询类型, 包括通过化学结构、子结构和相似性; 蛋白质序列; 配体和蛋白质名称; 亲和力范围和分子量进行搜索。通过 BindingDB 查询生成的数据集可以以注释的 SD 文件形式下载, 以便进一步分析, 或者作为用户上传的化合物数据库进行虚拟筛选的基础。BindingDB 中的数据通过 PDB ID 与蛋白质数据库中的结构数据相链接, 通过 PubMed ID 与 PubMed 中的文献相链接, 同时还可以通过化学和序列搜索进行链接。

介绍

现代药物研发项目的早期步骤通常包括确定在疾病过程中起关键作用的生物大分子, 并寻找能以高亲和力与其结合从而使其失活的低分子量化合物。尽管计算机辅助药物设计取得了进展, 但配体发现仍包含大量的尝试与错误, 因此针对每个靶点都会产生大量的结合数据。配体发现项目不仅会生成药物的结合数据, 还会生成那些本身不会成为药物的化合物的结合数据。这些

数据发表后, 不仅对研究相同生物大分子靶点的科学家来说是宝贵的资源, 对那些寻求开发改进的分子识别计算模型的人来说也是如此。

目前, 结合数据几乎完全通过科学期刊发布, 这些期刊提供了不可或缺的存档服务, 现在也有了电子格式, 并且能够以有用的方式进行搜索。然而, 期刊也施加了严格的限制, 这一点最近已被强调 (1)。例如, 它们没有提供以数值形式访问数据的机制, 无法根据化学结构进行查询, 无法下载化学结构的计算机表示, 无法详细发布大型数据集, 也无法在结合、结构和序列数据之间进行导航。通过提供这些缺失的功能, 特别是为那些无法获得大型制药公司资源的学术界和小型公司的研究人员提供这些功能, 一个测量结合亲和力的数据库应该能够加速靶向配体的发现。结合数据库的潜在应用包括:

- 针对特定靶点的配体分析, 以发现与亲和力相关的化学特征或药效团。
- (2) 定量构效关系的发展。
- (3) 结合受体三维结构对所测得的结合熵和结合焓的阐释。
- (4) 适用于配体设计的通用方法的参数化及验证。
- (5) 通过寻找已知能与类似蛋白质结合的配体, 来确定针对新药物靶点的候选先导化合物。
- (6) 通过检查类似化合物是否与多种受体结合, 来识别具有高副作用风险的候选药物。
- (7) 阐明一种生物效应分子的作用机制; 例如, 如果某种天然化合物能抑制细胞增殖, 可在数据库中搜索

*To whom correspondence should be addressed. Tel: +1 240 314 6217; Fax: +1 240 314 6255; Email: gilson@umbi.umd.edu

The authors wish it to be known that, in their opinion, the first two authors should be regarded as joint First Authors

2006 年作者 (们)

This is an Open Access article distributed under the terms of the Creative Commons Attribution Non-Commercial License (<http://creativecommons.org/licenses/by-nc/2.0/uk/>) which permits unrestricted non-commercial use, distribution, and reproduction in any medium, provided the original work is properly cited.

化学性质相似的化合物可能会表明，一种类似的化合物能够与已知参与细胞周期调控的蛋白质结合。

一个具有约束力的数据库还提供了发布不适合在期刊上发表的数据的可能性，例如非常大的数据集以及原始实验数据，这些数据在评估数据质量时可能很有用。

BindingDB (<http://www.bindingdb.org>) 正是为满足这些需求而创建的。目前，它已收录了 20000 项测量数据，成为最全面的公开蛋白质-配体结合亲和力数据库之一，并且仍在不断扩充。本文总结了这些数据资源以及网站的新功能和特性；BindingDB 的基本技术方面已在先前的文献中有所描述 (2-4)。

数据库内容

目前的数据收集主要针对那些三维结构可在蛋白质数据库 (5,6) (PDB) 中获取或能够被准确建模的目标。这类数据特别有价值，因为它们适合进行结构分析，并且适用于结合计算模型的开发和验证。2003 年对 PDB 的统计抽样显示，其中约 150 种非冗余蛋白质被认为是当前或潜在的药物靶点（未发表数据），因此适合由 BindingDB 进行数据收集。该分析未涵盖那些可通过比较建模构建结构的其他药物靶点。将注意力限制在已知结构的蛋白质上，使得 BindingDB 能够补充而非重叠其他收集膜蛋白结合数据的数据库，这些膜蛋白的 3D 结构大多不可用；例如 GPCRDB [www.gpcr.org (7)]、IUPHAR 受体数据库 (www.iuphar-db.org) 和 GLIDA [<http://gdds.pharm.kyoto-u.ac.jp/services/glida/index.php> (8)]。

蛋白质的选择依据其作为药物靶点或模型系统的重要性以及是否有合适的数据而定。一旦选定蛋白质，就会查找相关的科学文献，提取数据并存入 BindingDB 数据库。为了获得针对目标蛋白质的多种化学类型的数据，会从多个实验室和公司获取数据。数据来源的期刊包括《药物化学杂志》、《生物有机与药物化学通讯》和《生物化学》。网络可访问的表格也允许实验人员直接提交数据，但这种方式尚未产生大量条目。大部分数据基于酶抑制研究（超过 19000 项测量），但也包含少量来自更具信息量的等温滴定量热法的数据（416 项测量）。每个数据条目都包含详细的实验条件，如溶液成分、pH 值和温度，因为这些因素会影响测量的亲和力。

BindingDB 目前收录了 20000 条结合数据，涉及 11000 种不同的小分子配体和 110 种不同的药物靶点；若不单独计算突变体和同工型，则为 74 个靶点。这些靶点包括炭疽致死因子、各种半胱氨酸天冬氨酸蛋白酶和激酶以及 HIV 蛋白酶和逆转录酶。或许最相似的公开项目是 KiBank (9)，它提供了一个较为简洁的用户界面。




图 1. BindingDB 中针对各类靶点及靶点类别的测量数量。

包含 5900 种小分子配体和 50 种蛋白质靶点的 16000 K_i 条数据的庞大数据库，其中显然包括一些没有结构数据的蛋白质。为了了解 BindingDB 当前的数据持有情况，图 1 展示了各种靶点和靶点类别中的结合测量值数量，图 2 则提供了所有条目中小分子的 K_i 和 IC_{50} 值以及分子量的直方图。尽管 BindingDB 中包含的每个蛋白质靶点都有结构数据，但它收集了许多在 PDB 中没有代表的配体的数据。例如，PDB 中有 50 种乙酰胆碱酯酶的结构，而 BindingDB 中有与乙酰胆碱酯酶结合的 250 种不同配体的亲和力数据。更普遍地说，BindingDB 中约 2% 的配体在 PDB 中有完全匹配的配体，而基于 PDB 的搜索标准，BindingDB 中约 15% 的配体与 PDB 中的配体有 90% 的相似性。因此，BindingDB 的数据收集与那些仅收集 PDB 中蛋白质-配体复合物亲和力的数据库有很大不同，尤其是 BindingMOAD (10) 拥有 1400 条数据，PDBBind (11,12) 拥有 1600 条数据，以及 AffinDB (13) 拥有 750 条数据。

网络界面：查询、下载和虚拟化合物筛选

BindingDB 网站提供了一套日益丰富的工具，用于查询、分析和下载结合数据。搜索功能包括按靶点名称、配体名称、亲和力范围、化学结构、子结构和相似性以及通过 BLAST 进行靶点序列查询。查询结果以摘要表的形式呈现，用户可以选择深入查看特定测量的更多详细信息。可获取的详细信息包括引文数据（附有 PubMed 链接）以及从同一出版物获取所有结合数据的选项；序列数据和 SMILES 字符串 (15, 16) 以及化学物质的详细信息。




图 2. BindingDB 中配体的结合亲和力直方图 (1 M 标准浓度) 及分子量。

这些结构。链接到 PDB 的超链接可让用户轻松导航至给定配体、蛋白质或复合物的结构数据。其他工具还允许用户构建一个“数据集”，该数据集可以下载为 MDL SD 文件，其中包含化学结构、靶点信息和亲和力。

该网站还提供了用于候选配体虚拟筛选的网络访问工具；据我们所知，没有其他公共网站提供此功能。用户通过使用查询来形成 BindingDB 数据集，或者从磁盘上传 SD 文件，提供针对给定靶点或靶点类别的活性配体训练集。然后，用户上传自己的候选配体 SD 文件，选择安装在 BindingDB 服务器上的三种机器学习方法之一，并开始计算。软件会返回用户候选配体的排名，排名靠前的化合物最有可能具有训练集中活性化合物的活性。结果可以以包含每个化合物得分的 SD 文件形式下载；可选地，SD 文件中的化合物可以根据得分进行排序。这三种机器学习方法如下。

最大相似度

对于每个活性化合物和每个候选配体，使用默认参数计算 JChem (17) 化学指纹。该软件计算每个候选化合物与每个活性化合物的 Tanimoto 相似度[例如，参见 (18)]，并根据候选化合物与任何活性化合物的最大相似度对其进行排序。

二元核判别

JChem 化学指纹图谱是为每个活性化合物以及一组假定为无活性的诱饵化合物，按照默认参数计算得出的。诱饵化合物可以由用户提供，或者由 BindingDB

从 Zinc 化合物数据库中随机抽取一组类药物化合物 (19)。然后，BKD 方法 (20) 在已知活性化合物和诱饵化合物的一个子集上进行训练，并在其余的活性化合物和诱饵化合物上进行测试。测试结果以已知活性化合物在排名前 2% 和前 10% 的测试集化合物中的富集倍数的形式报告给用户。如果获得了较高的富集度 (例如 10 倍富集)，则可以合理地使用训练好的模型对用户的候选配体进行筛选。当用户上传这些化合物时，会为它们计算 JChem 指纹图谱，并对化合物进行评分和排序。候选配体的得分可以与测试集中的活性化合物和诱饵化合物的得分进行比较，后者也是输出的一部分。

支持向量机

对于 BKD，会建立一组活性化合物和一组诱饵。然后向用户展示可用于筛选过程的一系列定量分子描述符；网站会建议一组合理的默认描述符以帮助用户。使用 Molconn-Z (eduSoft LC) 计算所有化合物的描述符，然后对描述符集进行优化，以避免使用高度相关的冗余描述符 (21)。接着使用 LibSVM 软件 (22) 对活性化合物和诱饵的子集进行训练，并将其应用于剩余的活性化合物和诱饵化合物，以生成训练集和测试集的排名，如前所述 (21)。这些结果的质量以富集因子的形式报告，对于 BKD 也是如此，用户随后可以上传一个 SD 文件，其中包含要使用训练好的 SVM 模型进行排名的化合物。

最大相似度法是三种方法中速度最快的，因此对于非常大的筛选集来说可能最为便捷。BKD 方法速度较慢，但能找回更多多样化的活性物质。SVM 方法也比最大相似度法慢。

相似性,但可以说在寻找与用于训练算法的已知活性物质有显著差异的活性物质方面表现最佳。

可用性和引用

BindingDB 可在 <http://www.bindingdb.org> 免费访问,也可通过 PubChem 中化合物的链接访问。要下载 SD 文件,用户必须完成简单的注册流程,并同意未经明确许可不重新发布数据。欢迎用户通过“联系我们”链接与我们联系,并参与用户论坛 <http://www.bindingdb.org/forum/forum.jsp>。关于应从 BindingDB 中提取并存入的数据集以及网站功能的建议,我们均欢迎提出。使用 BindingDB 的研究成果应引用本文中的参考文献(2-4)。

致谢

作者衷心感谢美国国家标准与技术研究院和美国国家自然科学基金会(项目编号 9808318)此前提供的支持,以及美国国立卫生研究院下属的国家普通医学科学研究所(项目编号 GM070064)目前提供的支持。本文内容仅由作者负责,不一定代表资助方的官方观点。本文的开放获取出版费用由 NIH 项目 GM070064 提供。

利益冲突声明:无。

参考文献

- Bourne,P. (2005) Will a biological database be different from a biological journal? *PLoS Comput. Biol.*, 1, 179–181.
- Chen,X., Liu,M. and Gilson,M.K. (2002) BindingDB: A Web-accessible molecular recognition database. *Comb. Chem. High Throughput Screen.*, 4, 719–725.
- Chen,X., Lin,Y., Liu,M. and Gilson,M.K. (2002) The binding database: Data management and interface design. *Bioinformatics*, 18, 130–139.
- Chen,X., Liu,M. and Gilson,M.K. (2002) The binding database: Overview and user's guide. *Biopolymers/Nucleic Acid Sci.*, 61, 127–141.
- Bernstein,F.C., Koetzle,T.F., Williams,T.F., Meyer,G.J.B., Jr, Brice,M.D., Rodgers,J.R., Kennard,O., Shimanouchi,T. and Tasumi,M. (1977) The Protein Data Bank: A computer-based archival file for macromolecular structures. *J. Mol. Biol.*, 112, 535–542.
- Berman,H.M., Westbrook,J., Feng,Z., Gilliland,G., Bhat,T.N., Weissig,H., Shindyalov,I.N. and Bourne,P.E. (2000) The protein data bank. *Nucleic Acids Res.*, 28, 235–242.
- Horn,F., Weare,J., Beukers,M., Horsch,S., Bairoch,A., Chen,W., Edvardsen,O., Campagne,F. and Vriend,G. (1998) GPCRDB: an information system for G protein-coupled receptors. *Nucleic Acids Res.*, 26, 275–279.
- Okuno,Y., Yang,J., Taneishi,K., Yabuuchi,H. and Tsujimoto,G. (2006) GLIDA: GPCR-ligand database for chemical genomic drug discovery. *Nucleic Acids Res.*, 34, D673–D677.
- Zhang,J., Aizawa,M., Amara,S., Iwasawa,Y., Nakanoc,T. and Nakata,K. (2004) Development of KiBank, a database supporting structure-based drug design. *Comput. Biol. Chem.*, 28, 401–407.
- Hu,L., Benson,M.L., Smith,R.D., Lerner,M.G. and Carlson,H.A. (2006) Binding moad (mother of all databases). *Prot. Struct. Func. Bioinf.*, 60, 333–340.
- Wang,R., Fang,X., Lu,Y. and Wang,S. (2004) The PDBBind database: collection of binding affinities for protein–ligand complexes with known three-dimensional structures. *J. Med. Chem.*, 47, 2977–2980.
- Wang,R., Fang,X., Lu,Y., Yang,C. and Wang,W. (2005) The PDBBind database: Methodologies and updates. *J. Med. Chem.*, 48, 4111–4119.
- Block,P., Sotriffer,C.A., Drumburg,I. and Klebe,G. (2006) AffinDB: A freely accessible database of affinities for protein–ligand complexes from the PDB. *Nucleic Acids Res.*, 34, D522–D526.
- Altschul,S.F., Gish,W., Miller,W., Myers,E.W. and Lipman,D.J. (1990) Basic local alignment search tool. *J. Mol. Biol.*, 214, 1–8.
- Weininger,D. (1988) SMILES, a chemical language and information-system. 1. Introduction to methodology and encoding rules. *J. Chem. Inf. Comp. Sci.*, 28, 31–36.
- Weininger,D., Weininger,A. and Weininger,J.L. (1989) SMILES 2. Algorithm for generation of unique SMILES notation. *J. Chem. Inf. Comp. Sci.*, 29, 97–101.
- Csizmadia,F. (2000) JChem: Java applets and modules supporting chemical database handling from web browsers. *J. Chem. Inf. Comput. Sci.*, 40, 323–324.
- Willett,P., Barnard,J.M. and Downs,G.M. (1998) Chemical similarity searching. *J. Chem. Inf. Comput. Sci.*, 38, 983–996.
- Irwin,J.J. and Shoichet,B.K. (2005) ZINC—a free database of commercially available compounds for virtual screening. *J. Chem. Inf. Model*, 45, 177–182.
- Harper,G., Bradshaw,J., Gittins,J.C., Green,D.V. and Leach,A.R.J. (2001) Prediction of biological activity for high-throughput screening using binary kernel discrimination. *J. Chem. Inf. Comput. Sci.*, 41, 1295–1300.
- Jorissen,R.N. and Gilson,M.K. (2005) Virtual screening of molecular databases using a Support Vector Machine. *J. Chem. Inf. Model*, 45, 569–561.
- Chang,C.-C. and Lin,C.-J. LIBSVM: a library for support vector machines 2001. Software available at <http://www.csie.ntu.edu.tw/~cjlin/libsvm>.