


2024 年的 BindingDB:蛋白质-小分子结合数据的 FAIR 知识库Tiqing Liu1、 Linda Hwang1、 Stephen K. Burley2、 Carmen I. Nitsche3、 Christopher Southan4、 W. Patrick Walters5和 Michael K. Gilson 1,6, *

1美国加州大学圣地亚哥分校斯卡格斯药学院,加利福尼亚州拉霍亚 92093,美国2美国新泽西州立大学罗格斯大学定量生物医学研究所结构生物信息学蛋白质数据库研究合作实验室,新泽西州皮斯卡塔韦 08854,美国;新泽西州立大学罗格斯大学化学与化学生物学系,新泽西州皮斯卡塔韦 08854,美国;罗格斯大学癌症研究所,罗伯特·伍德·约翰逊医学院,新泽西州新不伦瑞克 08903,美国;美国加州大学圣地亚哥分校超级计算机中心结构生物信息学蛋白质数据库研究合作实验室,加利福尼亚州拉霍亚 92093,美国;罗格斯人工智能与数据科学 (RAD) 合作实验室,新泽西州立大学罗格斯分校,美国新泽西州皮斯卡塔韦 08854 3 剑桥晶体数据中心有限公司,美国马萨诸塞州波士顿 02108 4爱丁堡大学生物医学科学院,英国爱丁堡 EH8 9XD 5 Relay Therapeutics, 美国马萨诸塞州剑桥 02141 6 加州大学圣地亚哥分校化学与生物化学系,美国加利福尼亚州拉霍亚 92093 * 联系方式:电话:+1 858 822 0622;电子邮箱:mgilson@ucsd.edu

抽象的

BindingDB (bindingdb.org) 是一个公开的、可通过网络访问的数据库,其中包含通过实验测量的小分子与蛋白质之间的结合亲和力,支持多种应用,包括药物化学、生化途径注释、人工智能模型训练和计算化学方法开发。本次更新报告了自我们 2016 年上次审核以来的显著增长和改进。值得注意的是,该数据库目前包含 290 万个结合测量值,涵盖 130 万种化合物和数千个蛋白质靶点。这一增长主要归功于我们专注于整理美国专利数据,这带来了大量新的结合数据。最近的改进包括:根据响应式网页设计原则重新设计了网站;增强了搜索和过滤功能;新增了数据下载选项和网络服务;以及建立了一个在分散站点之间复制的长期数据存档。我们还讨论了 BindingDB 相对于相关资源的定位、其开放数据共享政策、从数据集中获取的洞见以及未来的发展规划。

图解摘要



介绍

大多数FDA批准的新药都是小分子有机分子(1),而鉴定出能够以足够亲和力结合目标蛋白的小分子或配体是许多药物研发项目的早期步骤。这个过程需要大量的反复试验,一个典型的药物研发项目需要测量数百或数千种化合物的亲和力。虽然最终获得的结合数据本质上是生成少数几种强效结合物而付出的努力的副产品,但其中一些

这些研究将通过药物发现流程推进,但它们仍然非常有用。首先,关于与特定蛋白质结合的化合物的数据可以为发现类似蛋白质的配体提供信息。更有趣的是,汇总涵盖多个蛋白质靶点的药物发现项目数据,对一系列应用具有新兴价值,例如:

· 对药物化学和药物设计的原理有新的见解。

- 测试和训练基于物理的计算机辅助药物发现 (CADD)方法和人工智能 (人工智能)方法。
- 使用已知的结合剂作为可能的化学探针注释信号传导和代谢途径中的蛋白质和毒品。
- 预测生物活性小分子的蛋白质靶点基于化学相似性。

1997 年,国家科学研究所举办了一场研讨会标准与技术 (NIST)和罗格斯大学是为了规划开发一个可以公开访问的非共价结合测量数据的数据库。NIST 和美国国家科学基金会 (NSF) 的初始资金支持了这项工作的第一步,2004 年来自

美国国立卫生研究院 (NIH) 启动了 BindingDB (bindingdb.org),第一个公开的、可通过网络访问的定量蛋白质-配体亲和力数据库 (2)。目前,由美国国立卫生研究院/国家遗传学与医学研究院资助,总部位于加利福尼亚州圣地亚哥,BindingDB 提供对不断增长的数据集包含 290 万个实验蛋白质-小分子结合数据点,涵盖 130 万个化合物和数千种蛋白质靶点。

基于本期刊 2007 年发表的先前报告(3)和 2016 (4),我们现在提供 BindingDB 的 2024 年更新,解决数据集的结构及其持续扩展、其相对于相关资源的定位、其接口

功能、使用模式以及对数据集的洞察本身。

BindingDB数据集

结合亲和力被组织成每个条目文档

BindingDB 中的绝大部分数据是通过实验测量的明确定义的蛋白质 (称为靶标)与小有机分子 (称为化合物或配体)之间的亲和力。然而,BindingDB 也包含少量

蛋白质-蛋白质和宿主-客体结合亲和力,以及等温量热和动力学结合数据。数据被组织成条目,每个条目通常与一篇科学文章或一篇待审或

已授权专利。因此,一个条目中的数据通常来自来自同一机构,并以相同的方式进行测量。每个条目都分配有自己的DOI,并定义着陆点
页面;例如,BindingDB DOI 10.7270/Q2H993SB 解析为<https://www.bindingdb.org/entry/5649>。绑定亲和力通常用浓度来表示,最常见的是 IC50、EC50、解离常数 (Kd)或抑制常数 (Ki),以纳摩尔/升表示 (nM)。在所有情况下,值越低表示亲和力越高。给定的结合测量与给定的蛋白质靶标有关,给定的化合物、所用分析方法的描述,以及作者、机构 (例如大学或公司)、出版信息 (例如 PubMed ID 或美国专利号)

以及与条目相关的任何其他信息 (图 1)。BindingDB 管理程序还添加了注释包含附加信息的条目,例如蛋白质数据库中可查阅的共晶体结构 (5-9),目标的 UniProt ID (10-12)和化合物链接化学数据库和商业化学品目录。Bind-ingDB 不管理实验三维结构。

真实数据,而是向用户提供 RCSB PDB 的链接 (9)针对蛋白质-配体复合物的现有结构,基于取决于配体的化学特性和蛋白质的序列特性。

BindingDB 数据集正在快速增长

图 2 展示了 BindingDB 数据集自诞生以来的增长情况。自我们上次发布报告(4) 以来,我们团队整理的 BindingDB 数据数量增长了四倍多,数据总量 BindingDB 中的增长了三倍多。大约一半提取了当前 BindingDB 中的测量值来自美国专利和 BindingDB 员工的科学文章,以及 BindingDB 中剩余的大部分数据都是从 ChEMBL (13-15),其致力于如下所述,科学文献中也存在类似的情况。最近的表1分析了 2 年流入 BindingDB 的数据,这表明 BindingDB 管理员增加了约 250 000 这一时期的蛋白质-配体结合数据主要是来自美国专利。从 ChEMBL 导入合适的数据又增加了101 000条数据,主要来自文章。每增加一条新数据 BindingDB 每月发布一批数据,提供更新的数据文件可供下载每个日历月初。每个新月的合适数据 ChEMBL 更新 (例如 ChEMBL 34)通常在其初始发布后的一个月内被识别、注释和导入发布。

BindingDB 数据集与其他广泛使用数据库

将 BindingDB 放入相关上下文中很有用数据库工作。ChEMBL 项目有类似的目标,但是不同的范围,因为它不仅收集指定数据,单一蛋白质靶点,以及表型分析结果和 ADMET 数据。此外,ChEMBL 还专注于整理来自科学论文的数据,而 BindingDB 则专注于专利的策展。如 2.2 节所述, BindingDB 导入只有来自 ChEMBL 的数据符合 BindingDB 管理标准,即具有明确定义的蛋白质靶标,而 ChEMBL 已导入由 Bind-ingDB 整理的部分数据,详情如下。截至撰写本文时,BindingDB 已导入所有适用的 ChEMBL 数据 (最高至 ChEMBL 34),并且 ChEMBL 包含由 BindingDB 整理的约 1900 项美国专利的数据。

PubChem 数据库(16-20) 由美国国立卫生研究院国家医学图书馆 (NLM) 运营,是一个整合生物活性和化学数据的全球中心。它目前包含

来自 1000 多个来源的 1.18 亿个化合物结构 (pubchem.ncbi.nlm.nih.gov/docs/statistics)。PubChem 采用无内部管理的提交模式,但保存了来自以下来源的 400 多万种化合物的生物活性数据:

许多精选资源,包括 ChEMBL 和 BindingDB 作为两个最大的贡献者图3。通过合作安排, PubChem 团队下载了 MySQL

每月从 BindingDB 转储数据,并将这些数据整合到 PubChem 中。那些没有

为现有的 PubChem 物质 ID (SID) 分配一个并且 PubChem 中新出现的化合物被指定为化合物 ID (CID) (pubchem.ncbi.nlm.nih.gov/docs/compound-vs-substance),而分析数据用于创建 PubChem

BindingDB Data Structure Overview




图 1. BindingDB 核心数据结构图。典型的结合测量是指测量蛋白质与小分子之间的亲和力,该数据提取自记录了测定方法与特定机构的作者相关的文章或专利。

测量结果可能与PDB (例如共晶结构)中的数据相对应。蛋白质靶标的详细信息包括名称和同义词、UniProt ID及其序列,而小分子配体则由SMILES字符串定义,通常还包含PubChem SID。许多化合物还与化学目录和其他小分子数据库中条目的链接相关联。BindingDB还包含较小的蛋白质-蛋白质和主客体结合数据集。




图 2. BindingDB 2000–2024 中的亲和力测量数量。
该数据集包含由 BindingDB 整理的数据和从 ChEMBL 导入的数据,详见文中。2024 年的水平主要反映了这一年尚未结束的事实。

生物测定 (BioAssay),由测定 ID 标识。因此,如果一个 BindingDB 条目仅包含一种测定类型,则该条目中的所有数据都将归入单个 PubChem 生物测定 (BioAssay)。但是,如果一个条目包含来自多个不同测定的数据,例如用于抑制各种酶,则该条目中每个测定的数据都将映射到其各自独立的 PubChem 生物测定 (BioAssay)。BindingDB 随后会下载并集成新的 SID、CID 和 AID。截至 2024 年 8 月 5 日,BindingDB 已提供 13,514 个生物测定和 1,269,104 种不同的化合物 (以 CID 表示)。由于每个 BindingDB 条目都与一个文章 DOI 相关联,因此在美国国立卫生研究院 (NLM) 的 PubMed 网站上查看文章的用户可以选择右侧空白处的 “LinkOut-more resources” 链接,直接导航到 BindingDB 中的相应数据。

两个密切相关的全球项目 SureChEMBL 和 PDB-Bind 也值得一提。SureChEMBL (21) 是一个从专利中收集化合物并使其可搜索和下载的项目。其自动化管理平台能够广泛覆盖现有专利,但并未将化合物与结合亲和力数据关联起来,因此无法

与 BindingDB 数据库重叠。PatCID (22) 是近期发布的资源,其理念与 SureChEMBL 类似。PDB-Bind 数据库 (23–25) 从蛋白质数据库 (Protein Data Bank) 收集蛋白质-小分子晶体结构,并将它们与各自的结合亲和力数据整合在一起,从而提供一个精选数据集,其中包含约 23 000 个蛋白质-配体复合物的三维结构和亲和力 (<https://www.pdbbind-plus.org.cn/>, 访问日期:2024 年 7 月 3 日)。这个数字远小于 BindingDB 的 290 万个测量范围,因为目前仅有一小部分具有亲和力数据的蛋白质-配体对的共晶体结构被确定。具体而言,BindingDB 包含许多同类配体系列的结合数据,而 PDBBind 预计只包含任何给定同类系列中一个或几个化合物的数据。另一方面,PDBBind 包含 PDB 中许多蛋白质-配体复合物的结合数据,而 BindingDB 中则没有,因此这些资源相互补充。此外,还值得一提的是 PLINDER,这是一个全新的蛋白质-小分子结构数据 (不包括亲和力) 集合,旨在用于训练和测试 AI 方法 (26)。

BindingDB 还与 UniProtKB 蛋白质知识库 (10,12,27) 和 RCSB 蛋白质数据库 (PDB) (7,9) 集成。BindingDB 会将 UniProtKB ID 分配给蛋白质靶标,并使用 UniProtKB 推荐的蛋白质名称。

UniProtKB 则提供其蛋白质记录与 BindingDB 中相应靶标的链接,以及相关的小分子结合数据。我们还将 BindingDB 中的每个蛋白质-配体对与 RCSB PDB 中的蛋白质-配体结构数据进行扫描,以寻找精确的化合物匹配,并确定了两组相关结构。一组 (15 328 个结构) 的蛋白质序列同一性高于 85%,而另一组 (10 126 个结构) 的蛋白质序列同一性则达到 100%。

(请参阅 www.bindingdb.org/rwd/bind/ByPDBIds.jsp 和 www.bindingdb.org/rwd/bind/ByPDBIds_100.jsp。) BindingDB 网站和搜索结果中均提供了这些结构的链接。RCSB PDB 会上传匹配率 >85% 的记录集,并提供从这些结构条目到 BindingDB 中相应绑定数据的链接。

表 1.过去 2 年（2022 年 7 月 1 日至 2024 年 6 月 30 日）流入 BindingDB 的主要数据按精选文档数量细分（文章或专利）、蛋白质靶标、化合物、新化合物（即之前未在 BindingDB 中出现的化合物）和亲和力数据1

来源	文件	目标	化合物	新化合物	亲和力数据
BDB 美国专利	1443	1000	146 681	117 377	241 430
BDB WIPO专利	42	47	2394	2394	3017
BDB 其他	12	11	4335	2893	5003
BDB总计	1497	1016	153 374	122 059	249 450
ChEMBL 32篇文章	491	703	9044	7966	20489
ChEMBL 33 篇文章	1383	1369	24 662	20 183	53019
ChEMBL 34 篇文章	770	1057	14 546	10 522	27,662
ChEMBL总计	2644	3129	48 252	38 671	101 170
全部的	4141	4145	201 626	160 730	350 620

1 标记为 BDB 的行列出了由 BindingDB 项目整理的数据库。ChEMBL 第 32、33 和 34 行列出了每次 ChEMBL 更新后新增的数据。提供了 BindingDB 管理、所有 ChEMBL 导入以及两个项目的总数。




图 3. BindingDB、PubChem 和 ChEMBL 数据集之间的关系。BindingDB 和 ChEMBL 均保持着稳健的数据管理。BindingDB 专注于测量蛋白质-小分子亲和力，而 ChEMBL 也涵盖了广泛的小分子活性通过表型/生物学测定进行测量。BindingDB 和 ChEMBL 数据以 PubChem BioAssays 的形式提供给 PubChem。PubChem 包括更广泛的小分子数据类型，但不能像 BindingDB 和 ChEMBL 那样从文档中提取数据。BindingDB 和 ChEMBL 也相互开放数据以供重新分发。BindingDB 仅从 ChEMBL 导入那些具有明确定义的蛋白质目标，与未定义目标的生物活性数据相反。

BindingDB 整理了来自美国的大量数据专利

目前, BindingDB 策展活动提供了最大的蛋白质-配体结合数据单向流入公共领域数据库。我们最初专注于从科学论文中提取数据, 但 ChEMBL 的优秀

对关键期刊的管理导致了工作重复的风险。此外, 不同期刊的不同文章也提出了数据格式各异, 这使得开发单一、无缝的策展流程。因此, 大约十年前, 我们开始探索专利管理, 这一领域在很大程度上尚未被公共策展活动所利用。它很明显, 美国专利包含大量相关数据并遵循比文章更标准化的格式, 并且更适合自动化。今天, BindingDB 的策展来自美国专利的数据在生态系统中是独一无二的开源知识库, 释放源源不断的重叠最小的公平蛋白质配体结合数据与其他策展工作提供的服务相比。在过去的 2 多年来, 这项工作平均每年处理约 125 000 个亲和力数据年 (表 1)。

每周, BindingDB 都会下载美国专利“红皮书”, 这是新发布的专利申请的数据库以及新授予的专利 (<https://bulkdata.uspto.gov/data/> 专利/授权/红皮书/2024/, [https://bulkdata.uspto.gov/data/XML 格式的patent/application/redbook/2023/](https://bulkdata.uspto.gov/data/XML格式的patent/application/redbook/2023/))。然后我们使用专用软件来识别可能包含合适的数据。标准包括归类到合作专利分类 (CPC) 子类中, 这些子类具有较高的

药物化学 SAR 申报的特异性, 特别是 C07 (有机化学) 和 A61 (医疗、牙科或盥洗用品制剂), 存在所谓的复杂工作

具有分子结构和表格数据的单元与“IC50”和“Kd”等关键词相关。这些专利会自动加载到基于 HTML 的展示初步整理的表格, 包括化合物与表格数据的关联。训练有素的管理员

将初步整理结果与专利文件进行比较, 根据需要更正可治愈专利的数据, 并拒绝那些没有合适数据的专利。(例如, 截至 2024 年中期, 仅包含分箱亲和力数据的专利, 例如“IC50 < 1 μM”, 将被拒绝。)精选数据来自

此步骤将数据加载到暂存服务器中,由第二个管理员将它们与专利文件进行比较,并
任何问题都与第一位策展人协商解决。然后使用 BindingDB 策展软件对

整理数据,例如,通过识别适当的链接
PDB 和 UniProt,然后将数据迁移到
公共数据库服务器。化合物提交至 Pub-Chem,一周后, PubChem 会生成 SID
和 CID
被获取并与 BindingDB 数据关联。这
高度自动化的流程允许少量工作人员在每周下载中整理几乎所有合适的新授予
的美国专利和新的待审专利申请。这一级别

效率至关重要,因为平均数据数量
BindingDB 中每项专利的专利数量为 160,而每项专利的平均数量为
文章数为 40。表 1 反映了这一差异,其中 Bind-ingDB 整理了约 1500 篇专利,
其结果大约是
ChEMBL 整理了约 2600 篇文章,其中包含大量亲和力数据。图
4更详细地展示了这些数据的分布情况
每篇文章和每项专利的结合数据 (左图)以及每篇文章和每项
专利精选的化合物数据 (右图),涵盖所有
BindingDB 的馆藏。数据量非常高的文章
例如,可能包括关于新结构的非常大的报告
针对特定蛋白质靶点的活性关系 (SAR) (28);针对一组激酶的多种化合物的
新数据报告 (29);大型 ADME 相关研究 (30,31);出版物

与 PDSP 数据库中的数据集相关 (32,33);
并审查文章或包含大量数据集的文章
用于定量结构-活性研究 (34)。

尽管我们监测快速崛起的
人工智能技术到策展,我们不知道目前有任何
人工智能方法将消除对人工策展的需求,
和美国专利的结构已经非常完善,以至于人工智能的预处理几
乎不会带来任何价值。截至撰写本文时,我们
正在策划 2024 年中期及以后的下载。

尽管我们的策展人主要针对美国授予的专利
和美国正在申请的专利,一些特定的科学文章
兴趣是经过精心策划的。例如,为了应对 COVID-19 疫情,我们收集了 SARS-
CoV-2 和其他
冠状病毒。这些数据突出显示在
专用网页, [https://www.bindingdb.org/rwd/bind/
Covid19.jsp](https://www.bindingdb.org/rwd/bind/Covid19.jsp)。我们还精选了近期的 WIPO (<https://www.bindingdb.org/rwd/bind/ByWIPO.jsp>)特别感兴趣的专利,例
如 SARS-Cov-2,因为数据通常
在 WIPO 专利中出现,比在
美国专利。然而,我们关注美国专利,因为它们
格式化更适合半自动化管理。

策展错误似乎并不常见

BindingDB 数据集中存在的任何错误都可以分组
分为两大类。第一类是
源文件 (通常是专利或科学文章)可能
由于各种类型的实验误差,
原始数据分析,或作者和编辑的笔误。这类错误我们很难发现并纠正,但在某些
情况下,它们可能会被标记为异常值。

相同的蛋白质-配体亲和力已被测量超过
一次。由于不同的测量程序可能会引入不同的偏差,因此测量的相对

一系列配体对给定蛋白质的亲和力 - 即比率
Kds或 IC50s - 通过一个实验室的一种方法测量
比亲和性本身更准确。第二类错误是由于策展或数据管理中的文书错误造成的。

主要通过 BindingDB 或 ChEMBL 进行。这些似乎最
通常因误算造成 1000 倍误差,例如将 IC50 值写为纳摩尔而不是微摩尔

反之亦然。根据用户反馈,下一个最常见的
错误似乎是对蛋白质靶标的错误识别。这
通常发生在专利或包含数据的文章的策划过程中
对多个目标和/或一个目标的子类型。

BindingDB 网页允许用户报告明显的错误,
我们会根据需要检查并纠正。令人鼓舞的是,我们
每年收到的错误报告少于 10 份。此外,对于
多年来,当科学论文的新数据出现在 BindingDB 中时,我们邀请相应的作者

检查我们版本的文章数据是否存在错误。
然而,我们几乎没有收到任何回复,所以我们结束了这个
实践。

数据集的科学特性和特征

目前 BindingDB 中有 290 万个绑定数据,
其中绝大部分 (即 240 万条)与人类来源的蛋白质靶点相关。接下来最具代表性的
的来源生物体是大鼠 (177 K 条数据)、小鼠 (65 K 条)和人类免疫缺陷病毒
1 型 (29 K 条),之后是一条长尾

560 个额外的来源生物,而且越来越少
结合数据。人类衍生的蛋白质靶点编号为 3410。
表2列出了数据最多的 25 个人类衍生目标
在 BindingDB 中。这些主要包括信号激酶,
细胞表面受体、核激素受体和其他
酶。

BindingDB 中存储的大多数亲和力和数据都会被报告,
因此将其整理为 IC50 (180 万),然后是 Ki 值
(560 K)、EC50s (220 K)和 Kd 值 (100 K)。有趣的是,
从专利中策划的亲和力往往更大 (更强
结合力)比文章中的要高,如图 5 所示,
IC50、Ki 或 Kd 值分布的较低模式约为 10 倍。
此外,从中提取的化合物的分子量
专利往往比化合物专利更高
来自文章 (图6),众数为 450 对 400
Da。这些差异大概反映了专利
与文章中描述的相比,本文提出了更多化学上详细的配体,这些配体具有更多的
探索性。

生成性人工智能方法在提出类药配体 (35-45)的应用方面,经常根据药物相
似性 (QED)的定量估计 (46)来评估其生成的配体的质量,其范围为 0-1。

BindingDB 中化合物的 QED 值峰值约为
0.5,适用于从专利和文章中提取的化合物。
这一结果与早期报道的结果相似
ChEMBL 的版本 (46)。生成式 AI 方法也经常使用合成可及性 (SA) 指标来指
导
生成可进行化学反应的化合物
合成。如图7所示,SA 的度量标准
RDKit 将于 2023 年 3 月发布 (RDKit:开源化学格式, [https://
www.rdkit.org](https://www.rdkit.org)) ; (47)在约 3 处达到峰值,
BindingDB 中所有化合物的评分均为 0-10,表明大多数化合物的合成
都面临不小的挑战。有趣的是,
专利中的化合物被评为略微更具合成性
平均而言,比文章中的化合物更容易获得。

BindingDB 中的大部分数据来自过去 10 年左右发表的文档 (文章和专
利),因为
如图8所示。这体现了 BindingDB
以及 ChEMBL 来整理相对最新的文献,
据推测,随着每年发布的数据数量的增加。




图 4.从文章和专利中整理的结合数据 (左)和化合物 (右)数量直方图,适用于所有非分类数据 (例如 $IC_{50} < 1 \mu M$) 在 BindingDB 中。直方图箱宽为 50,箱计数绘制为 $\log_{10}(N)$ ($N > 0$ 时)和 0 ($N = 0$ 时)。

表 2. BindingDB 中具有最多结合数据的 25 种人类衍生蛋白质靶标,显示了每个靶标测得的亲和力数量1

目标	UniProt 识别码	数量 亲和力
原癌基因酪氨酸蛋白激酶受体Ret	P07949	26810
酪氨酸蛋白激酶JAK2	O60674	26262
表皮生长因子受体	P00533	24745
酪氨酸蛋白激酶BTK	Q06187	23244
含溴结构域蛋白 4	O60885	21446
酪氨酸蛋白激酶JAK1	P23458	21217
核受体ROR-gamma	P51449	18532
钾电压门控通道亚家族H成员2	Q12809	17918
磷脂酰肌醇4,5-二磷酸3-激酶催化亚基δ异构体	O00329	17663
非受体酪氨酸蛋白激酶TYK2	P29597	17097
D(2)多巴胺受体	P14416	16573
β-分泌酶1	P56817	16016
酪氨酸蛋白激酶 JAK3 碳酸酐酶 2 血管内皮	P52333	14947
生长因子受体 2 磷脂酰肌醇 4,5-	P00918	14542
二磷酸 3-激酶催化亚基 α 异构体 组蛋白去乙酰化酶 1 异柠檬酸脱	P35968	14231
氢酶 [NADP] 胞质食欲素受体 2 型 细胞周期蛋白依赖性激酶 2 白细胞介素-1 受体相关激酶 4 钠通道蛋白 9 型亚基 α	P42336	13828
GTP 酶 KRas 大麻素受体 2 碳	Q13547	13751
酸酐酶 1 1请注意,给定的目标行可能隐式包含蛋白质的多种突变形	O75874	13499
式,例如 P07949[G810S]、	O43614	13360
P07949[M918T] 或 P07949[1-	P24941	13328
	Q9NWZ3	13303
	Q15858	13133
	P01116	13088
	P34972	12491
	P00915	12457

999,M918T]。

BindingDB为不同用户提供工具

最近对 BindingDB 用户进行的调查发生在 2020 年,约有 80% 的人在学术界工作,其中其余分布在政府、工业界和其他/无关联机构。当允许选择多个应用领域时,75% 表示他们使用 BindingDB 进行药物研发,30% 用于化学生物学,25% 用于开发基于物理的模型,15% 机器学习/人工智能训练和测试占比15%,系统生物学占比15%,毒理学占比10%。同样,在允许多选的情况下,75%的人表示他们会浏览/查询网站,45%的人表示他们会下载数据,15% 将下载的数据与本地数据库,10% 使用 BindingDB webservice。

BindingDB 提供了一系列工具来支持这些以及其他应用程序。许多应用程序可以通过左侧菜单在我们大多数网页上都有 (图9)。对于例如,人们可以很容易地访问通过浏览目标名称给定蛋白质目标 (<https://www.bindingdb.org/rwd/bind/ByTargetNames.jsp>)或 UniProt ID (<https://www.bindingdb.org/rwd/bind/ByUniProtids.jsp>)。对于每个目标,一个带有 SMILES 的制表符分隔值 (TSV) 文件 (48)和 InChI (49)字符串以及带有二维或计算的三维结构,可立即下载。或者,也可以在线以表格形式查看数据,这在前面已有描述(4)。您可以查看或下载准备好的文件




图 5. 专利和文章的亲和力分布。数据类型 IC50、Ki 和 Kd (M) 组合。分箱或分类数据 (例如省略 'IC50 < 1 μM')。




图8. 文章和专利发表日期直方图
从所有来源精选到 BindingDB。




图 6. BindingDB 中化合物分子量的直方图
摘自专利和文章。




图 7. BindingDB 化合物的 SA 估计值直方图
从专利和文章中提取, 用 RDKit 计算 (见正文)。

来自给定文章的所有数据 (<https://www.bindingdb.org/rwd/bind/ByJournal.jsp>, <https://www.bindingdb.org/rwd/bind/ByPubMed.jsp>) 或专利 (<https://www.bindingdb.org/rwd/bind/ByPatent.jsp>, <https://www.bindingdb.org/rwd/bind/ByWIPO.jsp>)。集成的 ChemAxon 工具允许化学

在 BindingDB 中进行感知搜索, 可选地结合通过亲和力范围进行过滤, 化合物的存在 PDB 和/或与任何蛋白质靶标选择有关 (图10)。

下载页面 (<https://www.bindingdb.org/rwd/bind/chemsearch/marvin/Download.jsp>) 提供带有日期标记的下载文件, 其中包括数据库整个数据库的转储、TSV 文件和 SD 文件以及数据集, 例如所有由 BindingDB 整理的数据库。此外, 我们还提供 RESTful Web 服务以 XML 或 JSON 格式返回数据 (<https://www.bindingdb.org/rwd/bind/BindingDBRESTfulAPI.jsp>)。

整体结构和功能的更多细节 BindingDB 网站的内容可以在我们之前的更新(4) 中找到。以下小节重点介绍了较新的增强功能。

BindingDB 已实现新功能和能力

自 2016 年更新以来新增的主要特性和功能
本期 (4) 中的研究包括以下内容: 图11

· 响应式网页设计: 主页的格式

类型现在使用响应式网页设计 (50), 以优雅地适应不同的屏幕宽度, 从桌面显示器到手机。新的页面设计还简化了 SMILES 和 InChI 字符串的重新检索。

结果过滤器: BindingDB 的表格呈现

搜索结果 (图11) 配备了过滤工具, 允许用户筛选搜索结果

沿着不同的维度。例如, 过滤工具

图11显示, 所有 997 条数据都属于单个蛋白质靶标, 但来自 34 篇出版物; 点击 “34” 会弹出出版物下拉菜单

允许查看每个出版物的数据。同样, 可以根据

各种出版物的来源机构; 在给定的亲和力范围内选择数据; 选择

蛋白质数据库中八种蛋白质-配体对及其对应的共晶体结构; 或选择

BindingDB 已识别出 22 个结果

配体可商购。这些过滤选项对于优化初始搜索或




图 9. BindingDB 主页,显示左侧菜单 (目标、化合物、出版物等)。

浏览操作产生了过大的
一组结果。

·改进了按目标浏览功能按名称列出蛋白质目标列表

姓名:

(bindingdb.org/rwd/bind/ByTargetNames.jsp)有
通过为每个提供标题条目进行了增强
名称后,每个来源生物体和突变体单独占一行。此功能旨在帮助用户

更精确、更快速地定位感兴趣的数据。

· PubChem 生物测定提交:我们启动了所有 BindingDB 数据以生物测定形式完整且定期地上传至 Pub-Chem 的流程。这一流程

目前已生成 13 541 个 Assay ID,其中 10 210 个来自
来自专利。

·增强和扩展的数据下载:准备好的数据下载 ([www.bindingdb.org/rwd/
bind/
chemsearch/marvin/Download.jsp](http://www.bindingdb.org/rwd/bind/chemsearch/marvin/Download.jsp))现在包含
Oracle 和 mySQL 数据转储,所有文件现在都已标注日期和 md5 校验和。
如上所述,
这些文件通常在每个
日历月。

· CSAR 和 D3R 数据集的归档: BindingDB 提供对在 CSAR (51,52)过程中
开发和使用的蛋白质-配体数据集的稳定访问,以及

D3R (53-56)预测挑战 ([www.bindingdb.
org/rwd/bind/ByD3R.jsp](http://www.bindingdb.org/rwd/bind/ByD3R.jsp))。

·通过 PDB 条目 ID 获取数据的 Web 服务:一种新的
webservice 支持检索与 PDB (www.pdb.org)中特定蛋白质结构相关的
BindingDB 数据。
bindingdb.org/rwd/bind/BindingDBRESTfulAPI.jsp。
这提供了所有符合用户定义
亲和力和蛋白质序列同一性标准。
也就是说,蛋白质目标必须与用户指定的PDB蛋白质具有序列同一性

阈值和复合物的结合亲和力

磅号必须大于第二个用户指定的
临界点...

· BindingDB 数据的长期归档:长期、
加州大学圣地亚哥分校图书馆研究数据部门已建立开放存取取的 BindingDB
数据档案
馆藏。数字馆藏的内容
反过来,它们被保存在 Chronopolis (57) 中,这是一个黑暗的保
存系统,其中包括德克萨斯州的节点伙伴和
马里兰州。BindingDB 削减了一个新的存档版本,它
包括每季度的详细元数据 ([https:
//doi.org/10.6075/J0HDTVVF](https://doi.org/10.6075/J0HDTVVF))。

·创建链接文章和
专利数据:我们开发了一种新型网络浏览器扩展程序,当安装在
Chrome,Firefox,Edge 中时
或 Brave,在用户查看文章时标记用户
或与 BindingDB 中的条目相对应的专利,以及
提供在 bindingdb.org 查看数据的链接和/或
以 TSV 文件的形式下载数据,其中包含
每行一个复合 SMILES 字符串,以及
相应的目标和结合数据。这一进展
之所以能够实现,是因为文章的元数据
在线专利包括 DOI 和专利号,
这些映射到 BindingDB 条目。

·用于结构活性分析的 Python 脚本
BindingDB 数据中的关系:我们 (PW)开发了一个交互式教程,演示如何使用开源
从专利数据中提取SAR的软件工具
BindingDB。它使用 Jupyter 笔记本来指导
用户通过下载和分析的过程
专利数据。它可以在流行的 Google Colab 上运行
平台,无需本地安装软件。本教程重点介绍了几个有价值的功能,例如检查活
动分布、利用

Bemis-Murcko 支架(58)理解专利
范围,并通过 R 基团瞄准关键取代基

Structure Search

Draw a structure, paste multiple SMILES or InChIs, and/or upload a file of SMILES or InChIs

Search Type:

- ☒ Similarity: 0.7 (≥ 0.4)
- ☐ Substructure
- ☐ Exact

Activity Filter:

N	none	$\leq K_i$ (nM) $\leq$	none
O	none	$\leq IC_{50}$ (nM) $\leq$	none
S	none	$\leq \Delta G^\circ$ (kcal/mol) $\leq$	none

Molecular Weight Filter:

F	none	$\leq MW \leq$	none
---	------	----------------	------

Limit hits to HETs from the PDB

☒ no ☐ yes

Paste one or more SMILES or InChIs

☒ AND ☐ OR

Browse for and upload your compound file (only first 100 compounds are processed). Acceptable formats are detailed here. Examples include SDfiles and SMILES lists.

Choose File No file chosen

Search

Help Check all Targets to be included in search. If none are checked, all will be included.

0-9 A B C D E F G H I J K L M N O P Q R S T U V W X Y Z

☐ A disintegrin and metalloproteinase with thrombospondin motifs 13 [3] [3D]	☐ A disintegrin and metalloproteinase with thrombospondin motifs 4 (ADAMTS-4) [3] [3D]
☐ A disintegrin and metalloproteinase with thrombospondin motifs 5 (ADAMTS-5) [941] [3D]	☐ A-kinase anchor protein 7 isoform gamma [941] [3D]

图 10.使用 ChemAxon 工具在 BindingDB 中进行化学感知搜索。请注意,可以搜索精确匹配的化合物,例如具有给定化学亚结构的化合物或类似化合物。还可以根据亲和力度、分子量或存在性来优化搜索。PDB 中的化合物,并且可以通过使用化学绘制窗口下方的复选框将搜索限制在一个或多个目标上。

分解。请参阅https://colab.research.google.com/github/PatWalters/practical_cheminformatics_tutorials/blob/main/patent/patent_analysis.ipynb。

BindingDB 是公开共享的,并且记录

BindingDB 被列为 FAIRsharing 资源(<https://doi.org/10.25504/FAIRsharing.3b36hk>) ,以及由 BindingDB 整理的数据在知识共享署名下共享

4.0 许可证 (CC BY 4.0)。这允许非商业以及商业重用和再分发,仅需引用 BindingDB 并注明对

数据。由 ChEMBL 整理的数据 (也是 FAIR 共享资源)在知识共享许可下共享

署名-相同方式共享 3.0 许可证(<https://chembl.gitbook.io/chembl-interface-documentation/about>,访问日期:2024 年 7 月 3 日)。

这增加了要求,任何重复使用的 ChEMBL 数据必须按照相同的许可证重新分发。因此,ChEMBL BindingDB 中的数据受 ChEMBL 许可证约束,并且它们被标记为由 ChEMBL 策划,以便能够

ance。相反,PDBBind 的用户许可证禁止在未经明确许可的情况下重新分发。

(<http://www.pdbbind.org.cn/enroll.php>),我们不收集PDBBind数据集。BindingDB网页提供下载格式的文档(例如 TSV 文件和 SDfiles) 以及所提供的网络服务。

我们的开放访问政策使得 BindingDB 能够广泛使用。在撰写本文之前的一年中,用户下载了 Oracle 和 MySQL 数据转储 1400 份和 1000 份。次,其他综合数据文件的下载量也超过 30 万次。新兴

用于药物研发的人工智能方法引起了人们对用于训练和测试人工智能方法的 BindingDB 数据集,每年贡献约 400 次引用我们之前关于 BindingDB 的文章 (2-4)。

方向

在未来几年,BindingDB 将继续整理测量的蛋白质-配体结合数据,生成独特的机器可读、免费许可的信息,供




图 11.示例 BindingDB 搜索结果,左边距显示新的过滤选项。

全球研究界。我们还计划改进
通过 BindingDB 网站的可靠性和响应时间
硬件和软件升级,以及改进的软件文档,最终目标是成为
CoreTrustSeal (59,60)认证资源。

数据可用性

由 BindingDB 整理的数据在 Creative 下共享
共享署名 4.0 许可证(<https://creativecommons.org/licenses/by/4.0>)。BindingDB中由 ChEMBL 整理的数据根据 Creative Commons Attribution-ShareAlike 3.0 Unported 许可证共享(<http://creativecommons.org/licenses/by-sa/3.0>)。

致谢

我们感谢 NCBI/PubChem 团队的以下成员
对我们的生物测定提交提供宝贵的指导,以及
高级数据查询:Ben Shoemaker、Tiejun Cheng、Paul
蒂森和埃文·博尔顿。

我们感谢加州大学圣地亚哥分校的 Ho Jung Yoo 和 Abigail Pennington
图书馆为存档 BindingDB 提供重要帮助
UCSD 数字馆藏中的数据。

我们感谢 Cadence/Open Eye 和 ChemAxon 根据其学术许可计划提供软件许可。

作者贡献:请参阅 CRediT 对贡献的定义(<https://credit.niso.org/>)列出如下。概念化-

tion:TL.CS.MKG;软件:TL.WPW;验证:
TL.LH.CS.MKG;形式分析:TL.MKG;资源:MKG;数据管理:TL.LH.CS.MKG;

写作 - 原始草稿:MKG;写作 - 审阅和编辑:CIN.CS.SKB.MKG;可视化:MKG;监督:
TL.SKB.CIN.CS.WPW.MKG;项目

管理:MKG;资金获取:MKG

资金

美国国立卫生研究院国家综合医学科学研究所
美国卫生研究院[R24GM144232];美国国家科学基金会[DBI-2321666至SKB];美国
能源部
[DE-SC0019749];美国国立癌症研究所、美国国立过敏和传染病研究所、美国国立卫
生研究院国家综合医学科学研究所

健康[R01GM157729]。本研究仅由作者负责,并不一定代表NIH的官方观点。

利益冲突声明

MKG 持有 VeraChem LLC 的股权,并担任其联合创始人和科学顾问。他还是 Denovicon
Therapeutics、Beren Therapeutics 和 In

Cerebro公司

SKB 是 Har-ington Discovery Institute 的投资顾问委员会成员,也是科学顾问
委员会成员。

由多摩大学全球研究院用户于 2025 年 6 月 1 日从 <https://academic.oup.com/nar/article/53/D1/D1633/7906836> 下载

Perpetual Medicines, Inc. 和 Vincere Biosciences, Inc. 董事会成员。他还担任 HanAll Biopharma Company Ltd. 和 Ligo Analytics, Inc. 的顾问。
WPW 是 Relay Therapeutics 的员工和股东。

参考

1. Mullard,A. (2021) 2020年FDA药品审批。《自然-药物发现评论》, 20,85–90。

2. Chen,X., Liu,M. 和 Gilson,MK (2001) BindingDB: 可通过网络访问的分子识别数据库。Comb . Chem. 高通量筛选, 4,719–725。

3.刘 T.,林 Y.,文 X.,Jorissen,RN 和 Gilson,MK (2007) BindingDB:-一个可通过网络访问的实验确定的蛋白质-配体结合亲和力和数据库。核酸研究, 35, D198–D201。

4. Gilson,MK, Liu,T., Baitaluk,M., Nicola,G., Hwang,L. 和 Chong,J. (2016) 2015 年的 BindingDB:-一个面向药物化学、计算化学和系统药理学的公共数据库。Nucleic Acids Res., 44, D1045–D1053。

5.伯恩斯坦,FC, 科茨勒,TF, 威廉姆斯, GJ, 迈耶, EF Jr., Brice,MD, Rodgers, JR, Kennard, O., Shimanouchi, T. 和 Tasumi, M. (1977) 蛋白质数据库:基于计算机的大分子结构档案文件。J. Mol. Biol., 112, 535–542。

6. Berman,HM,Westbrook,J.,Feng,Z.,Gilliland,G.,Bhat,TN, Weissig,H.,Shindyalov,IN和Bourne,PE (2000)蛋白质数据库。Nucl Acids Res, 28,235–242。

7. Rose,PW, Prlic,A., Bi,C., Bluhm,WF, Christie,CH, Dutta,S., Green,RK,Goodsell,DS,Westbrook,JD 和 Woo,J.等人 (2015 年) RCSB蛋白质数据库:面向基础、应用研究及教育的结构生物学视角。《核酸研究》, 43, D345–D356。

8. Young, JY, Westbrook,JD, Feng,Z., Peisach,E., Persikova,I., Sala,R.,Sen,S.,Berrisford, JM,Swaminathan,GJ,Oldfield,TJ等人(2018) 全球蛋白质数据库生物信息管理支持开放获取高质量的 3D 结构生物学数据。数据库, 2019 年, bay002。

9. Burley,SK,Bhikadiya,C.,Bi,C.,Bittrich,S.,Chao,H.,Chen,L., Craig,PA,Crichlow,GV,Dalenberg,K.,Duarte, JM等人(2023) RCSB蛋白质数据库 (RCSB.org) :提供实验确定的PDB结构以及基于人工智能/机器学习的百万个蛋白质计算结构模型。《核酸研究》, 51, D488–D508。

10. Apweiler, R.,Bairoch,A.,Wu,CH,Barker,WC,Boeckmann,B.,Ferro,S.,Gasteiger,E., Huang,H.,Lopez,R.,Magrane,M.等。(2004)UniProt:通用蛋白质知识库。核酸研究, 32, D115–D119。

11. UniProt 联盟 (2012 年) 通用蛋白质资源 (UniProt)于2013年发表。核酸研究, 41, D43–D47。

12. UniProt联盟 (2015)UniProt:蛋白质信息中心。《核酸研究》, 43, D204–D212。

13. Gaulton,A.,Bellis,LJ,Bento,AP,Chambers,J.,Davies,M.,Hersey,A.,Light,Y.,McGlinchey,S., Michalovich,D.,Al-Lazikani,B.等(2012) ChEMBL:一个用于药物研发的大规模生物活性数据库。《核酸研究》, 40, D1100–D1107。

14. Gaulton,A.,Hersey,A.,Nowotka,M.,Bento,AP,Chambers,J., Mendez,D.,Mutowo,P., Atkinson,F., Bellis,LJ, Cibrián-Uhalte,E., et al. (2017) 2017 年的 ChEMBL 数据库。Nucleic Acids Res., 45, D945–D954。

15. Zdrazil,B.,Felix,E.,Hunter,F.,Manners,EJ,Blackshaw,J., Corbett,S., de Veij,M., Ioannidis,H., Lopez,DM, Mosquera,JF等人(2024) 2023 年的 ChEMBL 数据库:药物发现

涵盖多种生物活性数据类型和时间段的平台。《核酸研究》, 52, D1180–D1192。

16. Bryant,S. (2006) PubChem:一个链接 化学和生物学。Abst . Pap. Am. Chem. Soc., 231,80 –COMP。

17. Wang,Y., Xiao,J., Suzek,TO, Zhang,J., Wang,J., Zhou,Z., Han,L., Karapetyan,K., Dracheva,S., Shoemaker,BA等(2012) PubChem的生物测定数据库。核酸研究, 40, D400–D412。

18. Kim,S., Chen,J., Cheng,T., Gindulyte,A., He,J., He,S., Li,Q., Shoemaker,BA, Thiessen,PA, Yu,B.等人(2019) PubChem 2019 更新:改进了化学数据访问方式。Nucleic Acids Res., 47, D1102–D1109。

19. Kim,S.,Chen,J.,Cheng,T.,Gindulyte,A.,He,J.,He,S.,Li,Q., Shoemaker,BA, Thiessen,PA, Yu,B.等人(2021) 2021 年的 PubChem:新的数据内容和改进的网页界面。《核酸研究》, 49, D1388–D1395。

20. Kim,S.,Chen,J.,Cheng,T.,Gindulyte,A.,He,J.,He,S.,Li,Q., Shoemaker,BA, Thiessen,PA, Yu,B.等人(2023) PubChem 2023 更新。Nucleic Acids Res., 51, D1373–D1380。

21. Papadatos,G.,Davies,M.,Dedman,N.,Chambers,J.,Gaulton,A.,Siddle,J.,Koks,R., Irvine,SA,Petterson,J.,Goncharoff,N.等人。(2016)SureChEMBL:一个大规模化学注释专利文献数据库。核酸研究, 44, D1220–D1228。

22. Morin,L.,Weber,V.,Meijer,GI,Yu,F.和斯塔尔,PWJ (2024) PatCID:专利文献中化学结构的开放获取数据集。《自然通讯》, 15,6532。

23. Wang,R.,Fang,X.,Lu,Y. 和 Wang,S. (2004) PDBBind 数据库:已知三维结构的蛋白质-配体复合物结合亲和力的集合。J . Med. 化学, 47,2977–2980。

24.王瑞,方X,卢Y,杨C.-Y.和王,W. (2005) PDBBind 数据库:方法和更新。J. Med.化学, 48,4111–4119。

25. Liu,Z., Li,Y., Han,L., Li,J., Liu,J., Zhao,Z., Nie,W., Liu,Y. 和 Wang,R. (2015) PDB 范围内的结合数据收集:PDBbind 数据库的当前状态。《生物信息学》, 31,405–412。

26. Durairaj,J.,Adeshina,Y.,Cao,Z.,Zhang,X.,Oleinikovas,V.,Duignan,T., McClure,Z.,Robin,X.,Rossi,E.,Zhou,G. 等。(2024)PLINDER:蛋白质-配体相互作用数据集和评估资源。bioRxiv doi: <https://doi.org/10.1101/2024.07.17.603955>, 2024 年 7 月 17 日,预印本:未经同行评审。

27. UniProt 联盟 (2023 年)UniProt:2023 年的通用蛋白质知识库。核酸研究, 51, D523–D531。

28. Tropmann,K.,Bresinsky,M.,Forster,L.,Mönnich,D.,Buschauer,A., Wittmann,H.-J.,Hübner,H.,Gmeiner,P.,Pockes,S.和斯特拉瑟,A. (2021)消除亚型选择性氨基甲酰胍型组胺H2受体激动剂对多巴胺D2long/D3受体的亲和力和。J. Med. Chem., 64,8684–8709。

29.法比安,MA,比格斯,WH,特雷伯,DK,阿特里奇,CE, Azimioara,MD, Benedetti,MG, Carter,TA, Ciceri,P., Edeen,PT, Floyd,M.等(2005) 临床激酶抑制剂的小分子-激酶相互作用图谱。《自然生物技术》, 23,329–336。

30.摩根,RE,范斯塔登,CJ,陈,Y.,卡利亚纳拉曼,N., Kalanzi,J.,Dunn,RT II,Afshari CA 和 Hamadeh,HK (2013) 多因素肝胆转运蛋白评估方法有助于改进治疗化合物的开发。《毒理学》科学, 136,216–241。

31.华纳,DJ,陈,H.,坎廷,L.-D.,肯纳,JG,斯塔尔,S., Walker,CL 和 Noeske,T. (2012) 减轻药物对人体胆汁盐输出的抑制:物理化学性质调节、计算机模拟和结构修饰带来的机遇。《药物代谢处置》, 40,2332–2341。

32. Boess,FG 和 Martin,IL (1994)5-HT 受体的分子生物学。神经药理学, 33,275–317。

33. Schotte,A.,Janssen,PFM,Gommeren,W.,Luyten,WHML,Van Gompel,P.,Lesage,AS, De Loore,K.和莱森,JE (1996) 利培酮与新型抗精神病药物和参考抗精神病药物的比较

药物:体外和体内受体结合。《精神药理学》(柏林), 124,57-73。

34. Gangjee,A. 和 Lin,X. (2005) CoMFA 和 CoMSIA 分析
卡氏肺囊虫二氢叶酸还原酶、弓形虫二氢叶酸还原酶和大鼠肝二氢叶酸还原酶。
J. Med.化学, 48,1448–1469。

35. Anstine,DM 和 Isayev,O. (2023) 生成模型作为
化学科学的新兴范式。J. Am. Chem. Soc., 145,8736–8750。

36. Gao,W. 和 Coley,CW (2020) 生成模型提出的分子可合成性。J. Chem. Inf. Model., 60,5714–5723。

37. Eckmann,P.,Sun,K.,Zhao,B.,Feng,M.,Gilson,M. 和 Yu,R.
(2022)LIMO:用于靶向分子生成的潜在初始论。见:第 39 届国际机器学习
会议论文集。PMLR,第 5777–5792 页。

38. Tang,B.,Ewalt,J. 和 Ng,H.-L. (2021) 用于药物发现的生成式 AI 模型。收录于:
Saxena,AK (编)《药物发现中的生物物理和计算工具,药物化学专题》。
Springer International Publishing,Cham,第 221–243 页。

39. 罗胜、关建、马建和彭建军 (2021)基于结构的药物设计的3D生成模型。《神经信息处
理系统进展》。Curran Associates, Inc.,第34卷,第6229–6239页。

40. Loeffler,HH,He,J.,Tibo,A.,Janet,JP,Voronov,A.,Mervin,LH 和 Engkvist,O.
(2024) Reinvent 4:现代人工智能驱动的生成分子设计。《化学信息学杂志》,
16,20。

41. Cheng,Y., Gong,Y., Liu,Y., Song,B. 和 Zou,Q. (2021) 药物发现中的分子设计:深度
生成模型的全面回顾。简报。Bioinform., 22, bbab344。

42. Bian,Y. 和 Xie,X.-Q. (2021) 生成化学:基于深度学习生成模型的药物发现。J. Mol.
Model., 27, 71。

43. Gupta,A.,Müller,AT,Huisman,BJH,Fuchs,JA,Schneider,P. 和 Schneider,G.
(2018) 用于从头药物设计的生成循环网络。Mol. Inform., 37,1700111。

44. Walters,WP 和 Murcko,M. (2020)评估生成式人工智能对药物化学的影响。《自然生物技
术》, 38,143–145。

45. Vert,J.-P. (2023)生成式人工智能将如何颠覆药物研发中的数据科学?《自然生
物技术》, 41,750–751。

46. Bickerton,GR,Paolini,GV,Besnard,J.,Muresan,S,和
Hopkins,AL (2012)量化药物的化学美。
天然化学, 4,90–98。

47. Ertl,P. 和 Schuffenhauer,A. (2009) 基于分子复杂性和片段贡献的类药分子
合成可及性评估。J. Cheminform., 1, 8。

48. Weininger,D. (1988) SMILES,一种化学语言和
信息系统。1. 方法论和编码规则简介。J. Chem. Inf. Comp. Sci., 28,31–36。

49. Heller,SR,McNaught,A.,Pletnev,I.,Stein,S,和契诃夫斯科伊,D.
(2015)nChI,IUPAC国际化学标识符。J.
化学信息, 7,23。

50. 响应式网页设计——一篇 A List Apart 文章。

51. Dunbar,JB, Smith,RD, Yang,C.-Y., Ung,PM-U., Lexa,KW,
卡扎诺夫,NA,斯塔基,JA,王,S,和卡尔森,HA (2011)
2010年CSAR基准测试:蛋白质-配体复合物的选择。J. Chem. Inf.
Model., 51,2036–2046。

52. Carlson,HA,Smith,RD,Damm-Ganamet,KL,Stuckey,JA,Ahmed,A.,
Convery,MA,Somers,DO,Kranz,M.,Elkins,PA,Cui,G,等人(2016) CSAR 2014:
使用未发表的 Pharma. J. Chem. Inf. Model. 数据进行的基准测试, 56,
1063–1077。

53. Gathiaka,S.,刘S.,Chiu,M.,Yang,H.,Stuckey,JA,Kang,YN,
Delproposto,J.,Kubish,G.,Dunbar,JB,Carlson,HA等人。(2016)
2015 D3R Grand Challenge:评估蛋白质-配体构型及亲和力预测。J. Comput.
Aided Mol. Des., 30,651–668。

54. Gaieb,Z.,刘S.,Gathiaka,S.,Chiu,M.,Yang,H.,Shao,C.,
Feher,VA,Walters,WP,Kuhn,B.,Rudolph,MG等人(2018)
D3R大挑战2:蛋白质-配体姿势、亲和力等级和相对结合自由能的盲预测。J. Comput.
辅助分子设计, 32,1–20。

55. Gaieb,Z.,Parks,CD,Chiu,M.,Yang,H.,Shao,C.,Walters,WP,Lambert,MH,
Nevins,N.,Bembenek,SD,Ameriks,MK等人。
(2019)D3R大挑战3:蛋白质-配体构型及亲和力排序的盲预测。J. Comput. Aided
Mol. Des., 33,1–18。

56. Parks,CD,Gaieb,Z.,Chiu,M.,Yang,H.,Shao,C.,Walters,WP,Jansen,JM,
McGaughey,G.,Lewis,RA,Bembenek,SD等人。
(2020)D3R重大挑战4:蛋白质-配体构型、亲和力等级和相对结合自由能的盲预测。J.
计算机辅助分子设计, 34,99–119。

57. Minor,D.,Sutton,D.,Kozbial,A.,Westbrook,B.,Burek,M. 和
Smorul,M. (2010) Chronopolis 数字保存网络。国际
J. Digit. Curation, 5,119–133。

58. Bemis,GW 和 Murcko,MA (1996) 已知
药物。1.分子框架。J. Med. Chem., 39,2887–2893。

59. L. Hours,H.,Kleemola,M,和Leeuw,L.de (2019) CoreTrustSeal:从学术合作到可
持续服务。JASSIST Q, 43, 1–17。

60. CoreTrustSeal标准与认证委员会 (2019年)
CoreTrustSeal 可信数据存储库要求 2020–2022。https://doi.org/
10.5281/zenodo.3638211。