

利用图卷积网络对药物联合使用副作用进行建模

Marinka Zitnik¹, Monica Agrawal¹ and Jure Leskovec^{1,2,*}

¹美国加利福尼亚州斯坦福市斯坦福大学计算机科学系，邮编 94305 和 ²美国加利福尼亚州旧金山市陈-扎克伯格生物中心，邮编 94158

请将信件寄往此处。

摘要

动机：药物联合使用（即多药疗法）在治疗患有复杂疾病或合并症的患者时十分常见。然而，多药疗法的一个主要后果是患者出现不良副作用的风险大大增加。多药疗法的副作用之所以会出现，是因为药物之间的相互作用，即一种药物与另一种药物同时服用时，其药效可能会发生有利或不利的变化。由于这些复杂的关系较为罕见，且通常在相对较小的临床试验中难以观察到，因此有关药物相互作用的知识往往有限。因此，发现多药疗法的副作用仍然是一个重要的挑战，对患者的死亡率和发病率有着重大影响。

结果：在此，我们提出了 Decagon 方法，用于建模药物联合使用所产生的副作用。该方法构建了一个多模态图，其中包含蛋白质 - 蛋白质相互作用、药物 - 蛋白质靶点相互作用以及药物联合使用所产生的副作用（这些副作用表示为药物 - 药物相互作用，每种副作用都是不同类型的边）。Decagon 特别设计用于处理具有大量边类型的多模态图。我们的方法开发了一种新的图卷积神经网络，用于多模态网络中的多关系链路预测。与仅能预测简单药物 - 药物相互作用值的方法不同，Decagon 能够预测给定药物组合在临床上具体表现出的副作用（如果有的话）。Decagon 准确预测了药物联合使用的副作用，比基线方法的性能高出多达 69%。我们发现，它能够自动学习出患者中多药联合使用共现情况的副作用表示。此外，Decagon 能够很好地模拟具有强烈分子基础的药物联合使用副作用，而对于主要由非分子因素引起的副作用，它也能取得良好效果，这得益于其在不同边类型之间有效共享模型参数。Decagon 为利用大规模药物基因组学和患者群体数据来标记和优先处理药物联合使用副作用以进行后续的正式药理学研究提供了机会。

可用性和实现：源代码和预处理后的数据集位于：<http://snap.stanford.edu/decagon>。

联系人：jure@cs.stanford.edu

1 简介

大多数人类疾病是由复杂的生物学过程引起的，这些过程对任何单一药物的作用都有抗性（贾等人，2009 年；韩等人，2017 年）。一种很有前景的对抗疾病的方法是联合用药，这是一种组合疗法，涉及同时使用多种药物，也称为药物组合（班萨尔等人，2014 年）。药物组合由多种药物组成，每种药物通常都已被用作单一有效药物用于患者群体。由于药物组合中的药物可以调节不同蛋白质的活性，药物组合可以通过克服潜在生物学过程中的冗余性来提高治

疗效果（孙等人，2015 年）。例如，维奈克拉和伊达萨努林的药物组合最近已被证明在治疗急性髓系白血病方面具有更优越的抗白血病效果（潘等人，2017 年）。在这里，这两种药物以相互补充的方式发挥作用：维奈克拉抑制抗凋亡的 Bcl-2 家族蛋白，而伊达萨努林激活 p53 通路，因此这两种药物的组合通过同时针对互补机制来提高生存率（潘等人，2017 年）。

虽然在许多疾病的治疗中联合使用多种药物可能是一种良好的做法（Liebler 和 Guengerich，2005 年；

塔托内蒂等人 (2012 年) 指出, 药物联合使用对患者的一個主要后果是药物相互作用导致的副作用风险大幅增加。由于药物联合使用的副作用较为罕见, 且几乎不可能对所有可能的药物组合进行测试, 再加上副作用通常在相对较小的临床试验中难以观察到 (班萨尔等人, 2014 年; 塔托内蒂等人, 2012 年), 因此手动识别这些副作用十分困难。此外, 药物联合使用在医疗保健系统中被视为日益严重的问题, 影响了近 15% 的美国人口 (坎托尔等人, 2015 年), 每年在美国治疗药物联合使用副作用的花费超过 1770 亿美元 (恩斯特和格里兹尔, 2001 年)。

体外实验和临床试验可用于识别药物相互作用 (Li 等人, 2016 年; Ryall 和 Tan, 2015 年), 但对药物相互作用候选者的系统组合筛选仍然具有挑战性且成本高昂 (Bansal 等人, 2014 年)。因此, 研究人员试图从科学文献和电子病历中收集药物相互作用 (Percha 等人, 2012 年; Vilar 等人, 2017 年), 并通过网络建模、分子靶点特征分析 (Chen 等人, 2016a; Huang 等人, 2014b; Lewis 等人, 2015 年; Sun 等人, 2015 年; Takeda 等人, 2017 年)、基于统计关联的模型和半监督学习 (Chen 等人, 2016b; Huang 等人, 2014a; Shi 等人, 2017 年; Zhao 等人, 2011 年) 来发现药物相互作用 (相关工作见第 7 节)。虽然这些方法有助于在细胞水平上推导出描述药物相互作用的广泛规则, 但它们无法直接指导药物联合治疗的策略。特别是, 这些方法通过代表相互作用总体概率/强度的分数来表征药物相互作用, 但无法预测确切的副作用类型。更确切地说, 对于药物 i 和 j , 这些方法预测它们的组合是否会产生超出无相互作用情况下预期的加性反应的任何过度反应 S_{ij} , 而不考虑具体类型的副作用 the_number 。也就是说, 它们的目标是回答这样一个问题: $S_{ij} \geq \text{fg}$, 其中 S_{ij} 是所有特定于药物组合 i, j 的多药副作用的集合, 但不是单独使用任一药物所产生的副作用。然而, 更重要且更有用的是回答这样一对药物是否会产生副作用。

药物 i, j 会产生某种特定类型的副作用 $r \in S_{ij}$ 。尽管明确识别药物相互作用所导致的副作用对于改善患者护理至关重要, 但通过预测建模来研究这一问题仍是一项具有挑战性的任务。

1.1 本研究

在此, 我们开发了一种名为 Decagon 的方法, 用于预测药物组合的副作用。我们通过构建一个包含蛋白质-蛋白质相互作用、药物-蛋白质相互作用以及药物-药物相互作用 (即副作用; 图 1) 的大型两层多模态图来对问题进行建模。每种药物-药物相互作用都由不同的边类型进行标注, 以表明副作用的类型。然后, 我们开发了一种新的多关系边预测模型, 该模型利用多模态图来预测药物-药物相互作用及其类型。我们的模型是一种在多关系环境中运行的卷积图神经网络。

为了激励我们的模型, 我们首先进行了探索性分析, 得出了两个重要的观察结果 (第 3 节)。首先, 我们发现联合处方药物 (即药物组合) 比随机药物对拥有更多的共同靶蛋白, 这表明药物-靶蛋白信息对于药物组合建模具有重要价值。其次, 我们发现为了能够对具有共同副作用的药物特征进行建模, 考虑蛋白质-蛋白质相互作用图谱非常重要。这些观察结果促使我们开发了 Decagon 来实现




图 1 从基因组和患者群体数据中得出的药物联合使用副作用示例图。一个多模态图由蛋白质-蛋白质相互作用、药物-蛋白质靶点和药物-药物相互作用组成, 由 964 种不同的药物联合使用副作用 (即边类型 $r_i, i = 1; \dots; 964$) 编码。辅助信息以额外的蛋白质和药物特征向量的形式整合到模型中。环丙沙星 (节点 C) 的突出网络邻居表明, 该药物作用于四种蛋白质, 并与另外三种药物相互作用。该图编码了环丙沙星 (节点 C) 与多西环素 (节点 D) 或辛伐他汀 (节点 S) 联合使用会增加心动过缓副作用风险 (副作用类型 r_2) 的信息, 以及与莫匹罗星 (M) 联合使用会增加胃肠道出血副作用风险 r_1 的信息。我们使用图表示法开发了 Decagon, 这是一种药物联合使用副作用的图卷积神经网络模型。Decagon 预测药物对与副作用之间的关联 (以红色显示), 旨在识别不能归因于药物对中任一药物的副作用。

关于哪些药物组合会产生相互作用以及相互作用/副作用的确切类型是什么的预测 (第 4 节)。

Decagon 开发了一种新的图自动编码器方法 (Hamilton 等人, 2017a), 这使我们能够为多模态图上的链路预测开发一个端到端可训练的模型。相比之下, 生物学中用于链路预测任务的先前基于图的方法 (例如 Chen 等人, 2016b; Huang 等人, 2014b; Zong 等人, 2017) 采用两阶段流水线, 通常由图特征提取模型和链路预测模型组成, 这两个模型都是分别训练的。此外, Decagon 的关键区别特征在于其多关系链路预测能力, 这使我们能够捕捉不同边 (副作用) 类型之间的相互依赖关系, 并确定图中任意两个药物节点之间所有可能的边类型中哪些存在。这与简单链路预测的方法 (Trouillon 等人, 2016) 形成了鲜明对比, 后者仅预测节点对之间边的存在性, 对于建模大量不同的边/副作用类型也至关重要。

我们将 Decagon 的表现与最先进的多关系张量分解方法 (Nickel 等人, 2011 年; Papalexakis 等人, 2017 年)、图表示学习方法 (Perozzi 等人, 2014 年; Zong 等人, 2017 年) 以及为药物联合使用副作用预测任务改编的成熟机器学习方法进行了对比。Decagon 的表现优于其他方法多达 69%, 预测性能平均提高了 20%, 在具有较强分子基础的副作用类型上取得了更大的提升 (第 6 节)。对于若干新预测结果, 我们在生物医学文献中找到了支持证据, 这表明 Decagon 在识别极有可能的预测方面表现尤为出色。

要成为真阳性。综上所述，这项研究首次展示了对药物组合副作用进行建模的能力，并为组合药物疗法的开发开辟了新的机遇。

2 数据集

我们将多药联合用药副作用识别问题表述为一个两层多模态图/网络中的多关系链路预测问题，该图/网络包含两种节点类型：药物和蛋白质。我们构建两层多模态网络的方法如下（图 1）。蛋白质-蛋白质相互作用网络描述了蛋白质之间的关系。药物-药物相互作用网络包含 964 种不同类型的边（每种副作用类型对应一条），描述了哪些药物组合会导致哪些副作用。最后，药物-蛋白质链路描述了给定药物所靶向的蛋白质。

接下来，我们将介绍用于构建网络的数据集。所有数据集的预处理版本均可通过本研究的网站获取：<http://snap.stanford.edu/decagon>。

2.1 蛋白质-蛋白质及药物-蛋白质相互作用

我们使用了 Menche 等人（2015 年）和 Chatr-Aryamontri 等人（2015 年）编制的人类蛋白质-蛋白质相互作用（PPI）网络，并整合了 Szklarczyk 等人（2017 年）和 Rolland 等人（2014 年）提供的额外 PPI 信息。该网络包含了在人类中通过实验记录的物理相互作用，例如代谢酶偶联相互作用和信号传导相互作用。该网络是无权且无向的，包含 19085 种蛋白质和 719402 种物理相互作用。

我们从 STITCH（化学相互作用搜索工具）数据库中获取了蛋白质与药物之间的关系，该数据库整合了各种化学物质和蛋白质网络（Szklarczyk 等人，2016 年）。在本研究中，我们仅考虑了经实验验证的小分子化学物质（即药物）与靶蛋白之间的相互作用。在 8934 种蛋白质和 519022 种化学物质之间存在超过 8083600 种相互作用。

2.2 药物相互作用及副作用数据

我们还从详细记录了单药及药物组合副作用的数据库中获取了相关信息。SIDER（副作用资源）数据库包含了 1556 种药物和 5868 种副作用之间 286399 种药物-副作用关联（Kuhn 等人，2016 年），这些关联是通过从药品说明书文本中挖掘不良事件获得的。我们将它与 OFFSIDES 数据库进行了整合，该数据库详细记录了 1332 种药物与 10097 种副作用之间 487530 种关联（Tatonetti 等人，2012 年）。OFFSIDES 数据库是通过收集医生、患者和制药公司的报告，利用不良事件报告系统生成的。我们消除了副作用的同义词，并使用一个副作用词汇表构建了所有数据集。这种预处理很重要，因为如果某些副作用完全相关，预测问题就会容易得多。整合这些数据集后，每种药物的副作用中位数为 159 种，最常见的副作用是恶心、呕吐、头痛、腹泻和皮炎。

我们从 TWOSIDES 中获取了药物联合使用副作用的信息，该数据库详细记录了 63473 种药物组合所产生的 1318 种副作用类型，这些副作用的发生频率高于组合中任一药物单独使用时的预期（Tatonetti 等人，2012 年）。与 OFFSIDES 类似，TWOSIDES 也是基于不良事件报告系统生成的。常见的副作用，如低血压和恶心，在超过三分之一的药物组合中出现，而像健忘和肌肉痉挛这类副

作用仅出现在少数药物组合中。总体而言，它包含了 4651131 种药物组合与副作用的关联。在本研究中，我们重点关注预测在至少 500 种药物组合中出现的 964 种常见药物联合使用副作用类型。

在将不同数据库所使用的实体词汇表进行关联之后，最终的网络包含 645 个药物节点和 19085 个蛋白质节点，节点之间通过 715612 条蛋白质-蛋白质边、4651131 条药物-药物边以及 18596 条药物-蛋白质边相互连接。

3 基于数据驱动的 Decagon 方法动机

在此，我们对两层多模态图（图 1）的结构提出三点观察结果，这些观察结果对 Decagon 模型的设计具有重要意义。

首先，我们注意到某些药物组合所产生的副作用的发生频率差异很大。我们发现，超过 53% 的药物联合使用所产生的副作用仅在不到 3% 的已记录药物组合中出现（例如脑动脉栓塞、肺脓肿、肉瘤、胶原病）。相比之下，更常见的副作用（如呕吐、体重增加、恶心和贫血）则要常见得多。由于每种副作用所关联的药物组合数量差异很大，可用于独立训练预测不同副作用类型的模型的药物组合数量有限。因此，药物联合使用副作用的预测成为一项具有挑战性的任务，尤其是在预测较为罕见的副作用时，因此开发一种端到端的方法至关重要，以便模型能够共享信息并同时从所有副作用中学习。

其次，我们观察到，在联合处方的药物组合中，药物的副作用并非各自独立出现，这表明对多种副作用进行联合建模有助于预测任务。为了量化副作用之间的共现情况，我们统计了给定副作用与其他副作用在药物组合中共现的次数，然后使用随机共现的零模型进行置换检验。如表 1 中高血压和恶心的示例所示，我们发现大多数常见副作用与恶心/高血压作为药物组合中的副作用共现的频率要么显著高于随机预期，要么显著低于随机预期，显著性水平为 0.05。这一观察结果表明，可能存在一些机制导致副作用具有共同的病理生理学基础，这与疾病共病现象类似（Lee 等人，2008 年）。例如，我们发现高血压与焦虑显著共现，但与发热共现的频率低于随机预期（表 1）。这些关系在整个副作用数据集中都存在。我们得出结论，预测模型应当利用副作用之间的关联，并能够复用关于某一副作用的分子基础所学到的信息，以更好地理解另一副作用的分子基础。

第三，我们探究药物组合所针对的蛋白质与副作用发生之间的关系。设 T_i 表示与药物 i 相关的目标蛋白质集合，然后计算给定药物组合 (i, j) 的目标蛋白质之间的杰卡德相似度。我们有以下几点发现：（i）超过 68% 的药物组合没有共同的目标蛋白质，这表明利用蛋白质-蛋白质相互作用信息来“连接”不同药物所针对的不同蛋白质是很重要的。（ii）随机药物组合的目标蛋白质重叠度小于联合处方药物（图 2，浅灰色）， P 值 = $5e-120$ ，双样本柯尔莫哥洛夫-斯米尔诺夫（KS）检验。（iii）我们发现这种趋势在不同的副作用中观察到的程度不一。例如，高血压更强烈地

表 1.高血压和恶心与药物组合中 50 种最常见副作用的共现百分比，并附有示例说明

多药副作用	过度出现的共现现象	未充分代表的共现	微不足道的共现
高血压	44%（高血糖、焦虑、头晕）	48%（发热、败血症、皮炎）	8%（咳嗽、心动过速）
恶心想吐	54%（腹泻、失眠、乏力）	34%（水肿、贫血、中性粒细胞减少）	12%（发热、呼吸困难）

注意：在与恶心/高血压相关的药物组合中，绝大多数副作用出现的频率要么被显著高估，要么被显著低估，经邦费罗尼校正后，显著性水平为 0.05。

与例如肋骨骨折（图 2 中的紫色部分）相比，有超过 150 种副作用出现在具有相同靶蛋白的药物组合中。通过 2 样本 KS 检验，这些副作用在组合上与其它真正的药物组合存在显著差异（在经过邦费罗尼校正后， $\alpha = 0.05$ ），这表明这些副作用具有很强的分子基础。基于这些发现，我们得出结论，模型应考虑蛋白质之间的相互作用，并能够模拟更长的（间接）相互作用链。

4 图卷积 Decagon 方法

我们将多药联合用药副作用建模视为一个多模态图上的多关系链路预测问题，该图编码了药物、蛋白质和副作用之间的关系（图 1）。更确切地说，这些关系由一个图 $G = (V, R, E)$ 表示，其中包含 N 个节点（例如蛋白质、药物） $v_i \in V$ 和带标签的边（关系） $v_i \xrightarrow{r} v_j$ ，其中 r 是

边的类型（关系类型）：（i）两个蛋白质之间的物理结合，（ii）药物与蛋白质之间的靶向关系，或（iii）两种药物之间特定类型的副作用。如第 2 节所述，我们考虑了药物之间 964 种不同的关系类型（即副作用）。

此外，我们还允许以附加节点特征的形式纳入辅助信息。不同的节点（药物、蛋白质）可以具有不同数量的节点特征，这些特征由分配给图中每个节点的实值特征向量 $x_1; x_2; \dots; x_N$ 给出。

多药联合副作用预测任务。多药联合副作用预测任务旨在解决识别药物组合与副作用之间关联的问题。重要的是，这些关联仅限于不能单独归因于任何一种药物的情况。利用图 G ，该任务旨在预测药物节点之间的有标签边。给定药物对 (v_i, v_j) ，我们的目标是确定类型为 r 的边 $v_i \xrightarrow{r} v_j$ 属于 R 的可能性有多大，即 -

已知在人类患者群体中，同时使用药物 v_i 和 v_j [即使用药物组合 (v_i, v_j)] 与某种类型 r 的多药合用副作用相关。

为此，我们开发了一种直接作用于图 G 的非线性多层卷积图神经网络模型 Decagon。Decagon 有两个主要组成部分：

- 编码器：一个在图 G 上运行的图卷积网络，为图 G 中的节点生成嵌入（图 3A；第 4.1 节）以及
- 解码器：一种使用这些嵌入来建模药物联合使用副作用的张量分解模型（图 3B；第 4.2 节）。

我们通过介绍 Decagon 来展开论述，这是我们一个用于建模药物联合使用副作用的方法。

4.1 图卷积编码器

我们首先描述图编码器模型，该模型以图 G 和附加的节点特征向量 x_i 作为输入，并为图中的每个节点（药物、蛋白质）生成一个 d 维的节点嵌入 $z_i \in \mathbb{R}^d$ 。




图 2.随机药物对、所有药物组合以及与特定副作用相关的药物组合中目标蛋白质的杰卡德相似度。根据给定药物对 (i, j) 中的药物 i 和 j 是否不共享任何目标蛋白质、共享少于 50% 的目标蛋白质或共享超过 50% 的目标蛋白质，将药物对分为三组（即杰卡德 T_{ij} ； $T_{ij} \leq 0$ ； $0 < T_{ij} < 0.5$ 和 $0.5 \leq T_{ij} \leq 1$ ，分别： T_i 是 i 的目标蛋白质集合）。我们观察到大多数药物对中的药物，尤其是随机药物对（即不常联合处方的药物，深灰色）没有共享的目标蛋白质。

我们提出了一种编码器模型，该模型能高效利用图中各区域的信息共享，并为每种关系类型分配单独的处理通道。其理念在于，Decagon 学习如何在图中转换和传播由节点特征向量捕获的信息。每个节点的网络邻域定义了一个不同的神经网络信息传播架构，但这些架构共享定义信息如何共享和传播的函数/参数。我们学习卷积算子，以在图的不同部分和不同关系类型之间传播和转换信息。该模型受到最近一类直接在图上操作的卷积神经网络（Defferrard 等人，2016；Kipf 和 Welling，2016）的启发。对于给定的节点，Decagon 对其邻居的特征向量执行转换/聚合操作。这样，Decagon 只考虑节点的一阶邻域，并在图的所有位置应用相同的转换。这些操作的连续应用实际上在 K 阶邻域内卷积了信息（即节点的嵌入取决于距离其最多 K 步的所有节点），其中 K 是神经网络模型中连续卷积层操作的数量。

在每一层中，Decagon 都会在图的边之间传播潜在的节点特征信息，同时考虑边的类型（关系）（Schlichtkrull 等人，2017 年）。该神经网络模型的单层形式如下：

$$h_i^{(k+1)} = \phi \left(\sum_r \sum_{j \in N_r^+} c_r^{ij} W_r^{(k)} h_j^{(k)} + c_i^i h_i^{(k)} \right), \tag{1}$$

其中， $\{h_i^{(k)}\}_{i \in \mathbb{V}} \in \mathbb{R}^{d \times |\mathbb{V}|}$ 是神经网络第 (k) 层节点 i 的隐藏状态， $d^{(k)}$ 表示该层的维度。




图3. Decagon 模型架构概述。(A) 一个 Decagon 编码器。图中展示的是单个图节点(代表环丙沙星的药物节点, 基于图1中的小示例输入图)的逐层更新。从相邻节点 N_c 收集隐藏状态激活值, 然后针对每种关系类型 r 分别进行转换(即胃肠道出血、心动过缓和药物靶点关系)。将得到的表示进行(归一化)求和, 并通过非线性激活函数(例如 ReLU)处理, 以生成第 $(k+1)$ 层节点 vc 的隐藏状态 $hc(k+1)$ 。这种逐节点更新在整个图中并行计算, 且参数共享。(B) 对于每种关系, Decagon 解码器接收嵌入对(例如隐藏节点表示 z_c 和 z_s 分别代表环丙沙星和辛伐他汀), 并为图中的每条(潜在)边生成一个分数。图中展示的是药物相互作用副作用关系类型的解码器。(C) 一批神经网络, 用于计算输入图中六个药物节点的嵌入。在 Decagon 中, 各节点的神经网络有所不同, 但它们都共享同一组特定关系的可训练参数(即编码器和解码器的参数; 见公式 (1) 和 (2))。也就是说, 具有相同阴影图案的矩形共享参数, 而带有黑白阴影图案的细矩形表示全连接神经网络。

表示形式, r 是一种关系类型, 矩阵 $W_r^{(k)}$ 是特定关系类型参数矩阵。这里, ϕ 表示一个非线性逐元素激活函数(即修正线性单元), 用于将表示形式转换为神经模型层中使用的形式, c_{ij} 和 c_{ji} 是归一化常数, 我们选择其为对称的 $c_{ij} = c_{ji} = 1$ 。

$$c_{ij} = \frac{1}{\sum_{j \in N_i} 1} \text{ 以及 } c_{ji} = \frac{1}{\sum_{i \in N_j} 1}, \text{ 其中 } N_i \text{ 表示集合 } i$$

在关系 r 下节点 v_i 的邻接节点。重要的是要注意, 方程 (1) 中的求和仅针对给定节点的邻接节点 N_i 进行。

节点 i 以及因此的计算架构(即神经网络)对于每个节点都是不同的。图 3A 展示了图 1 中节点 C 的逐层卷积更新方程 (1) 的一个示例。并且, 图 3C 进一步说明了不同的节点具有不同的神经网络结构(因为每个节点的网络邻域都是不同的)。

通过将多个(即 K 个)这样的层(图 3A)串联起来, 并使用适当的激活函数, 可以构建一个更深层的模型。为了得到节点 v_i 的最终嵌入 $z_i \in \mathbb{R}^d$, 我们按如下方式计算其表示: $z_i = \frac{1}{\sqrt{d}} h_i$ 。

然后, 整体编码器会接收

如下形式。我们按照方程 (1) 定义的那样堆叠 K 层, 使得前一层的输出成为下一层的输入。第一层的输入是节点特征向量 h_i 。

$\frac{1}{\sqrt{d}} z_i$, 或者如果图中节点没有特征, 则为每个节点提供一个独特的独热向量。

4.2 张量分解解码器

到目前为止, 我们介绍了 Decagon 的编码器。编码器将每个节点 $v_i \in V$ 映射到一个嵌入, 即一个实值向量表示 $z_i \in \mathbb{R}^d$, 其中 d 是节点表示的维度。接下来, 我们将描述 Decagon 的解码器组件。

解码器的目标是依靠学习到的节点嵌入, 并对每种标签(边类型)区别对待, 从而在图 G 中重建带标签的边。具体而言, 解码器通过一个 v_i, r, v_j 三元组来打分。

函数 g 的目标是为 r 分配一个分数 $g(v_i, r, v_j)$ 以表示其如何

药物 v_i 和 v_j 通过关系/副作用类型 r 相互作用的可能性有多大(图 3B)。利用 Decagon 编码器(第 4.1 节)

返回的节点 i 和 j 的嵌入 z_i 和 z_j , 解码器通过因式分解操作预测候选边 v_i, r, v_j :

$$g(v_i, r, v_j) = \frac{1}{\sqrt{d}} \sum_{i=1}^d z_i^T R_{r,i} z_j$$

如果 v_i 和 v_j 都是蛋白质; 或者; >
: v_i 和 v_j 分别是一种蛋白质和一种药物

然后应用 S 型函数 σ 来计算边 v_i, r, v_j 的概率:

$$p_r^{ij} = p((v_i, r, v_j) \in \mathcal{R}) = \sigma(g(v_i, r, v_j)). \quad (3)$$

接下来, 我们通过区分以下两种情况来解释 Decagon 的解码器:

1. 当 v_i 和 v_j 是药物节点时, 方程 (2) 中的解码器 g 假设了一个药物间相互作用的全局模型(即 R), 其在多药副作用中的变化和重要性由针对每种副作用的对角因子(即 $D_{r,i}$)来描述。这里, R 是一个形状为 $d \times d$ 的可训练参数矩阵, 用于建模所有可能的多药副作用中的药物间全局相互作用。此外, 在 Decagon 中, 代表不同多药副作用的每个关系 r 都与一个对角 $d \times d$ 矩阵 D_r 相关联, 该矩阵描述了 z_i 中每个维度对于副作用 r 的重要性。从另一个角度来看, 这个解码器可以被视为一个三阶张量的张量分解(更具体地说, 是一个秩为 d 的 DEDICOM 张量分解(Nickel 等人, 2011; Trouillon 等人, 2016)), 其中两个模式由药物相同构成, 第三个模式则包含药物组合的多药副作用。然而, Decagon 的一个显著特点是依赖于编码器。与经典的张量分解使用在训练过程中直接优化的节点表示不同, 我们采用端到端的方式计算, 其中节点嵌入与张量分解一起联合优化。

2. 当 v_i 和 v_j 不全是药物节点时, 方程 (2) 中的解码器 g 采用双线性形式从节点解码边。

更确切地说,在这种情况下,解码函数 g 与一个可训练的参数矩阵 M_r 相关联,该矩阵的形状为 $d \times 3 \times d$,用于建模 z_i 和 z_j 中每两个维度之间的相互作用。然后,使用双线性形式(公式 2)计算预测的边概率,随后应用 Sigmoid 函数(公式 3)。

在方程 (2) 中基于节点类型使用不同的边缘解码器至关重要,原因有二:首先,Decagon 解码器可以被视为不同关系类型之间有效参数共享的一种形式。特别是涉及药物对的关系类型使用相同的全局药物-药物相互作用模型(即矩阵 R),其中包含适用于所有药物相关关系类型的模式。我们期望这种解码参数化能够缓解对罕见副作用的过拟合,因为参数在罕见(例如中耳炎或鼻息肉)和常见(例如低血压或贫血)副作用之间共享。其次,我们希望高分 $g(v_i; r; v_j)$ 能够表明药物组合之间的关联。

组合 (v_i, v_j) 以及一种不能单独归因于 v_i 或 v_j 的副作用。为了捕捉药物联合使用的复杂性(Jia 等人, 2009 年),因此重要的是 Decagon 能够通过 R 允许 i 和 j 的嵌入中任意两个维度之间存在非零的相互作用。

综合来看,Decagon 模型的可训练参数包括:(i) 特定关系类型的神经网络权重矩阵 W_r , (ii) 特定关系类型的参数矩阵 M_r , (iii) 一个全局的副作用参数矩阵 R 以及 (iv) 特定副作用的对角参数矩阵 D_r 。因此,Decagon 编码器和解码器共同构成了一个多模态图中多关系链路预测的端到端可训练模型(图 3)。

接下来,我们将描述如何训练 Decagon 方法。具体来说,我们将解释如何使用端到端学习技术来训练神经网络权重和相互作用参数矩阵。

4.3 十边形模型训练

在模型训练期间,我们使用交叉熵损失来优化模型参数:

$$J_r(i, j) = -\log p_r^{ij} - \mathbb{E}_{n \sim P_r(i, j)} \log(1 - p_r^{in}), \quad (4)$$

为促使模型对观测到的边 $v_i; r; v_j$ 赋予更高的概率,而非随机的非边,我们采用与先前研究(Mikolov 等人, 2013 年; Trouillon 等人, 2016 年)相同的方法,通过负采样来估计模型。对于每条药物-药物边 $v_i; r; v_j$ (即一条连接两个药物的边),我们从所有可能的非边中随机抽取一定数量的样本(负样本),并将其与观测到的边一起输入模型进行训练。

在图中,我们从正例中随机选取一条边 $\delta v_i; r; v_n$ (即一个负例),通过随机选择节点 v_n 来实现。具体做法是将边 $v_i; r; v_j$ 中的节点 v_j 替换为节点 v_n , 该节点

根据抽样分布随机选取 P_r (Mikolov 等人, 2013 年)。综合考虑所有边,Decagon 中的最终损失函数为:

$$J = \sum_{(v_i, r, v_j) \in \mathcal{R}} J_r(i, j). \quad (5)$$

近期的研究表明,对图结构数据进行建模时,采用端到端学习方法往往能取得显著的改进(Defferrard 等人, 2016; Gilmer 等人, 2017),因此我们采取端到端的优化方法,对所有可训练参数进行联合优化,并将损失函数的梯度通过 Decagon 的编码器和解码器进行传播。

为了优化模型,我们使用 Adam 优化器(Kingma 和 Ba, 2014 年)以 0.001 的学习率对

其进行最多 100 个周期(训练迭代)的训练,并采用窗口大小为 2 的早停策略,即如果验证损失连续两个周期没有下降,就停止训练。我们使用 Glorot 和 Bengio (2010 年)所描述的初始化方法来初始化权重,并相应地对节点特征向量进行归一化。为了使模型能够很好地泛化到未观测到的边,我们对隐藏层单元应用常规的随机失活(Srivastava 等人, 2014 年)(见公式 1)。在实践中,我们使用复杂度与图 G 中边的数量呈线性关系的高效稀疏矩阵乘法来实现 Decagon 模型。

我们通过从方程 (5) 中边的总和和随机抽取固定数量的损失函数贡献值来使用小批量处理。也就是说,我们处理多个训练小批量,每个小批量仅从方程 (5) 中的总和和抽取固定数量的贡献值,从而形成动态的计算图批次(图 3C)。由于只考虑损失函数的固定数量的贡献值,因此可以移除当前小批量中未出现的数据点。这作为一种有效的正则化手段,减少了训练模型所需的内存,这是为了能够将整个模型装入 GPU 内存(所有数据和代码均在项目网站上发布)。

5 实验装置

我们将预测药物联合使用副作用的问题视为解决一个多关系链路预测任务。在此,每一对药物通过零种、一种或多种关系类型(即副作用类型)相互关联,这些关系类型来自所有关系类型的集合(即所有副作用类型,见第 2 节和图 1)。

对于每种药物联合使用引起的副作用类型,我们将与该副作用相关的药物组合分为训练集、验证集和测试集,确保验证集和测试集各包含 10% 的药物组合。对于每种副作用类型,我们使用 80% 的药物组合来训练模型,并使用 10% 的药物组合来选择模型参数。任务是预测与每种副作用类型相关的药物组合。请注意,我们非常谨慎地确保各折之间不存在信息泄露,并且交叉验证是公平的。

我们应用 Decagon,它针对每一对药物以及每一种副作用类型,计算出给定药物组合与给定副作用相关联的概率。此外,我们将个体药物的副作用信息(第 2 节)以附加特征的形式整合到模型中,作为药物节点 i 的属性。为防止评估过程中出现任何循环性和信息泄露,我们确保:(i) 我们预测的副作用确实是药物联合使用产生的副作用(即给定的药物联合副作用仅与药物组合相关,而不与组合中的任何单个药物相关);(ii) 预测的副作用类型不包含在药物的副作用特征中。例如,恶心是一种药物联合使用的副作用,因此我们将所有作为单个药物副作用的恶心实例都移除。我们注意到,这是一种保守的方法,能够让我们可靠地估计预测性能。

我们尚未发现有其他用于预测药物组合副作用的方法。因此,我们将 Decagon 的性能与以下多关系链路预测方法进行了比较:

· RESCAL 张量分解(Nickel 等人, 2011 年):这是一种考虑多关系结构的张量分解方法。给定 X_i ,即编码药物对 i 和 j 与副作用 r 关联的药物-药物矩阵,矩阵 X_i 可分解为: $X_i \approx A T_r A^T$ ($r = 1, 2, \dots, 964$),其中 T_r 和 A 是模型参数。对于给定的药物 i 和 j ,它们与 r 的关联预测为: $a_i T_r a_j$ 。

- DEDICOM 张量分解 (Papalexakis 等人, 2017 年): 这是一种适用于稀疏数据环境的相关张量分解方法。给定的药物 - 药物矩阵 X_i 可分解为: $X_i \approx A_i U_i T U_i A_i^T$ 。对于给定的药物 i 和 j , 它们与 r 的关联预测为: $a_i U_i T U_j a_j$ 。
- 深度游走神经嵌入 (Perozzi 等人, 2014 年; Zong 等人, 2017 年): 该方法基于探索节点网络邻域的有偏随机游走过程, 为节点学习 d 维神经特征。药物对通过连接所学的药物特征表示来表示, 并作为逻辑回归分类器的输入。对于每种链接类型 (即副作用类型), 我们训练一个单独的逻辑回归分类器。
- 药物特征拼接: 此方法基于药物 - 目标蛋白相互作用矩阵的主成分分析 (PCA) 表示以及单个药物副作用的主成分分析 (PCA) 表示, 为每种药物构建一个特征向量。药物对通过拼接相应的药物特征向量来表示, 并作为梯度提升树分类器的输入, 该分类器随后预测药物对的确切副作用。

对于每种方法, 其参数设置都是通过验证集上对候选参数值进行网格搜索来确定的 (例如, 对于梯度提升树, 所用树的数量从 10 变化到 100)。如果某种方法不是多关系链路预测方法, 我们会针对每种副作用类型分别在验证集上选择性能最佳的参数。具体而言, 在所有实验中, Decagon 使用的是两层神经网络架构, 每层分别有 64 和 32 个隐藏单元, 丢弃率为 0.1, 小批量大小为 512。

性能是针对每种副作用类型分别通过受试者工作特征曲线下面积 (AUROC)、精确率 - 召回率曲线下面积 (AUPRC) 以及 50 时的平均精度 (AP@50) 来计算的。数值越高, 性能越好。

6 结果

Decagon 在多模态图和高度多关系的环境中运行。这种灵活性使得 Decagon 特别适合预测药物组合的副作用, 这一点我们将在下文讨论。

6.1 多药合用副作用的预测

我们首先将 Decagon 的性能与其他方法进行比较。从表 2 的结果来看, 考虑多模态网络表示以及对大量不同副作用进行建模使得 Decagon 相较于其他方法有显著优势。在 964 种副作用类型中, Decagon 的性能比其他方法高出 19.7% (AUROC)、22.0% (AUPRC) 和 36.3% (AP@50)。Decagon 相对于张量分解方法的改进尤为明显, 其在 AP@50 指标上比基于张量的方法高出多达 68.7%。这一发现表明, 直接优化张量分解 (即普通的 RESCAL 和 DEDICOM (Nickel 等人, 2011 年; Papalexakis 等人, 2017 年)) 而不依赖于图结构卷积编码器可能存在局限性。我们还将 Decagon 与另外两种方法 (Perozzi 等人, 2014 年; Zong 等人, 2017 年) 进行了比较, 这两种方法经过了多关系链路预测任务的调整。我们观察到, DeepWalk 神经嵌入和拼接药物特征在 AUROC 指标上比基于张量的方法高出 9.0%, 在 AUPRC 指标上高出 20.1%。然而, 这些方法采用的是两阶段流水线, 包括药物特征提取模型和链路预测模型, 两者都是分别训练的。此外, 它们无法考虑不同副作用之间的相互依赖关系, 而我们在第 3 节中表明这种相互依赖关系包含有

用的信息。这些额外的建模见解使 Decagon 在 AP@50 得分上比 DeepWalk 神经嵌入高出 22.0%, 比拼接药物特征高出 12.8%。

这些发现与以下结果一致: 通过端到端学习, 尤其是使用图自编码器 (Hamilton 等人, 2017a, b; Kipf 和 Welling, 2016), 预测结果往往能得到显著提升。特别是张量分解和神经嵌入基线方法使我们能够量化性能提升中有多少是由于嵌入 (即 Decagon 的编码器) 带来的, 又有多少是由于多任务学习 (即 Decagon 的解码器) 带来的。

为了更好地理解 Decagon 的性能, 我们将表 2 中的汇总统计数据按副作用类型进行分层。对结果的人工审查以及与领域专家的讨论揭示了表 3 中表现最佳的副作用的一个共同特性。我们观察到, Decagon 模型对具有明显分子基础的副作用的预测效果特别好。这一观察结果与我们的预期一致, 因为 Decagon 的多模态图 (图 1) 主要包含药理基因组学信息。我们还注意到, 表现最差的副作用往往是常见副作用, 且/或具有非分子起源, 可能包含重要的环境和行为因素 (表 3)。Decagon 在这些副作用上的竞争性表现可以通过不同副作用类型之间有效共享模型参数来解释。

6.2 对 Decagon 新颖预测的研究

接下来, 我们基于文献对新发现的关联进行评估。我们的目标是评估 Decagon 对药物组合与副作用之间关系的新预测的质量。为此, 我们让 Decagon 对数据集中的每一对药物和每一种副作用类型都进行预测。然后, 我们利用这些预测结果构建一个 (药物 i 、副作用类型 r 、药物 j) 三元组的排序列表, 其中

表 2. 用于多药联合用药副作用预测的受试者工作特征曲线下的面积 (AUROC)、精确率-召回率曲线下的面积 (AUPRC) 以及 50 时的平均精确率 (AP@50)

靠近	AUROC	AUPRC	AP@50
十边形	0.872	0.832	0.803
RESCAL 张量分解	0.693	0.613	0.476
DEDICOM 张量分解	0.705	0.637	0.567
深度游走神经嵌入	0.761	0.737	0.658
串联药物特征	0.793	0.764	0.712

注意: 报告的是 964 种副作用类型的平均性能值。

表 3. Decagon 中表现最佳和最差的副作用

最佳疗效副作用	AUPRC	最严重的副作用	AUPRC
腮腺炎	0.964	出血	0.679
红宝石	0.949	体温升高。	0.680
尾骨痛	0.943	呕吐	0.693
鼓膜穿孔。	0.941	肾病	0.694
汗疱疹	0.938	白细胞减少症	0.695
脊椎病	0.929	腹泻	0.705
分裂情感性障碍	0.919	黄疸	0.707
乳腺增生	0.918	恶心想吐	0.711
神经节	0.909	痒	0.712
子宫息肉	0.908	贫血	0.712

表 4. 由 Decagon 分配最高概率分数的 (药物 i、副作用类型 r、药物 j) 三元组给出的新药物联合使用副作用预测

k	多药效应	药物	药物	证据
1	肉瘤	乙胺嘧啶	阿利吉仑	斯泰奇等人 (2015 年)
4	乳房疾病	托卡朋	乙胺嘧啶	比克尔等人 (2017 年)
6	肾小管性酸中毒	奥美拉唑	阿莫西林	鲁索等人 (2016 年)
8	肌肉炎症	阿托伐他汀	氨氯地平	巴纳赫等人 (2017 年)
9	乳腺炎	阿利吉仑	替奥康唑	帕尔文等人 (2012 年)

注意：对于每个预测结果，我们都会列出其在所有预测结果的排名列表中的排名 k 以及支持该预测关联存在的文献证据。

三元组按照预测概率得分 p_{ijr} (公式 3) 进行排序。然后，我们从排序列表中排除所有已知的药物对与副作用之间的关联，之后研究列表中排名最高的 10 个预测结果。为防止研究偏差，我们不允许分析的不同阶段之间有任何交叉影响。然后，我们查阅生物医学文献，看是否能找到这些新预测的支持证据。

表 4 展示了 Decagon 的预测结果以及支持这些预测的文献证据。我们能够对排名前十的预测副作用中的五种找到文献证据。也就是说，对于这些排名最高的预测，我们的方法不仅正确地识别了药物组合，还准确地预测了副作用类型。这一结果令人瞩目，因为这些预测非常具体，而找到支持这些预测的文献证据，通过随机选择药物组合和副作用关联几乎是不可能的。我们注意到，所引用的文献明确研究了预测的药物组合与预测的副作用之间的相互作用。例如，Decagon 预测阿托伐他汀和氨氯地平的联合使用可能导致肌肉炎症（表 4 中排名第八的预测）。事实上，近期的报告（例如 Banakh 等人，2017 年）也发现了由于阿托伐他汀与氨氯地平的药物相互作用而导致的肌肉组织损伤。Decagon 还指出了一种潜在关联，即抗微生物药物乙胺嘧啶（单独使用时对疟疾治疗有效）与肾素抑制剂阿利吉仑之间存在关联，阿利吉仑的临床试验因发现肾并发症而终止（Parving 等人，2012 年），这表明存在更高的患癌风险（排名第一的预测）。此处的分析表明，Decagon 的预测有可能促进转化科学以及发现新的（无效的）药物组合。

6.3 探索 Decagon 的副作用嵌入

最后，我们希望了解 Decagon 是否达到了第 3 节中提出的设计目标。特别是，我们要测试 Decagon 是否能够捕捉到我们探索性数据分析所揭示的不同副作用类型之间的相互依赖关系（第 3 节中的第二个观察结果）。为此，我们采用对角矩阵 D_r ，这些矩阵专门用于在 Decagon 的多关系链路预测（第 4.2 节）中建模每种副作用类型 r 的相互作用的重要性。我们从每个 D_r 中提取对角线，并将其用作副作用 r 的向量表示。然后，我们使用 t-SNE (Maaten 和 Hinton, 2008) 将这些向量表示嵌入到二维空间中，并在图 4 中进行可视化。

图 4 展示了副作用表示中存在聚类结构。观察该图，我们发现 2D 空间中彼此靠近嵌入的副作用在药物组合中往往同时出现。这一观察结果表明，Decagon 对于在许多药物组合中同时出现的副作用 r_1 和 r_2 推断出了相似的矩阵 D_{r_1} 和 D_{r_2} 。例如，与子宫息肉副作用经常同时出现的前三个副作用是：子宫出血、乳腺增生和绝经后出血。实际上，Decagon 对这三个副作用都推断出了相似的对角因子 D_r ，从而在 2D 空间中形成了局部投影（图 4）。




图 4. Decagon 中副作用的可视化。使用 t-SNE 软件包 (Maaten 和 Hinton, 2008) 将副作用映射到二维空间，输入为学习到的副作用表示 $\{D_r; r = 1, 2, \dots, 964\}$ ，见公式 (2)。所选副作用为子宫息肉、胰腺炎、病毒性脑膜炎和甲状腺疾病。对于每个所选副作用，我们突出显示在药物组合数据集中与所选副作用最常同时出现的三个副作用。

为了检验图 4 中的吸引人模式是否适用于多种副作用类型，我们按以下步骤进行。我们计算每种副作用的向量表示与三种最常共同出现的副作用的向量表示之间的平均欧几里得距离。我们发现共同出现/相关的副作用具有显著更相似的表示（即对角线因素 D_r ），其相似度高于随机出现的预期（P 值 = $1e^{-34}$ ，双样本 KS 检验）。因此，我们得出结论，Decagon 能够实现药物联合副作用建模的设计目标。此外，这里的分析表明，Decagon 的多关系链路预测模型（第 4.2 节）能够捕捉药物组合数据中存在的副作用之间的相互依赖关系。

7 相关工作

我们回顾了有关药物组合计算预测以及用于图结构数据的神经网络的相关研究。

7.1 药物组合建模

计算药理学的方法旨在发现药物与分子靶点之间的关联，预测潜在的药物不良反应，并为现有药物寻找新的用途 (Campillos 等人，2008 年；Hodos 等人，2016 年；Li 等人，2016 年)。与这些方法主要考虑的单个药物和单一药物治疗法（即单药治疗）不同，我们考虑的是药物组合（即多药治疗）。这一点很重要，因为多药治疗是应对复杂疾病的一种有效策略 (Han 等人，2017 年；Jia 等人，2009 年)，对医疗保健系统具有重要影响 (Ernst 和 Grizzle, 2001 年)。

传统上, 有效的药物组合是通过实验筛选一组预先定义的所有可能组合来确定的 (Chen 等人, 2016b)。鉴于药物数量众多, 对药物成对组合进行实验筛选在成本和时间方面都是一项艰巨的任务。例如, 给定 n 种药物, 就有 $n(n-1)/2$ 种成对药物组合, 还有更多高阶组合。为了解决候选药物组合的组合爆炸问题, 开发了计算方法来识别可能相互作用的药物对, 即那些产生超出无相互作用时预期加性反应的药物对 (Ryall 和 Tan, 2015)。该领域的先前研究侧重于通过协同作用和拮抗作用的概念来定义药物相互作用 (Lewis 等人, 2015; Loewe, 1953), 定量测量剂量效应曲线 (Bansal 等人, 2014; Takeda 等人, 2017), 以及根据测量细胞活力的实验来确定给定药物对是否相互作用 (Chen 等人, 2016a, b; Huang 等人, 2014a, b; Shi 等人, 2017; Sun 等人, 2015; Zitnik 和 Zupan, 2016)。所有这些方法都预测药物相互作用的标量值, 代表给定药物组合相互作用的整体概率/强度。与此形成鲜明对比的是, 我们在此开展的研究更进一步, 确定了给定药物组合在患者群体中究竟如何 (如果有的话) 在临床上表现出来。特别是, 我们对那些不能归因于任何一种药物单独作用, 而是由于药物相互作用 (即联合用药的副作用) 而产生的临床表现进行建模。与之前的研究侧重于生成代表细胞活力或实验性药物筛选中密切相关结果的点估计值不同, 我们首次预测当患者同时服用多种药物时, 可能会出现哪些 (如果有的话) 联合用药的副作用, 从而为临床转化提供了更直接的途径。

尽管目前的药物间相互作用预测方法不能直接用于此处所研究的问题, 但我们简要概述一下这些方法所采用的策略。药物间相互作用预测方法可分为基于分类的方法和基于相似性的方法。基于分类的方法将药物间相互作用预测视为一个二分类问题 (Chen 等人, 2016b; Cheng 和 Zhao,

(Huang 等人, 2014a; Shi 等人, 2017; Zitnik 和 Zupan, 2016)。这些方法将已知相互作用的药物对作为正例, 其他药物对作为反例, 训练诸如朴素贝叶斯、逻辑回归和支持向量机之类的分类模型。相比之下, 基于相似性的方法假定相似的药物可能具有相似的相互作用模式 (Gottlieb 等人, 2012; Huang 等人, 2014b; Li 等人, 2016, 2017; Sun 等人, 2015; Vilar 等人, 2012; Zitnik 和 Zupan, 2015)。这些方法使用基于药物化学亚结构、相互作用特征指纹、药物副作用、脱靶效应以及分子靶点连接性的不同类型的药物间相似性度量。这些方法通过聚类或标签传播来聚合相似性度量, 以识别潜在的药物相互作用 (Ferdousi 等人, 2017; Zhang 等人, 2017)。

然而, 所有这些方法都只是生成药物相互作用的分值, 而无法预测具体的药物联合使用副作用, 而这正是我们在此研究的目标。

7.2 图上的神经网络

我们的模型拓展了图神经网络领域现有的研究成果 (Defferrard 等人, 2016 年; Gilmer 等人, 2017 年; Hamilton 等人, 2017a, b; Ki

pf 和 Welling, 2016 年; Schlichtkrull 等人, 2017 年)。图神经网络通过将通常应用于图像数据集的卷积操作的概念推广到可应用于任意图的操作, 从而能够在图结构上进行学习。这些神经网络也可以被视为一种嵌入方法, 能够将每个节点邻域的高维信息提炼为密集的向量嵌入, 而无需手动特征工程。特别是图卷积网络 (Defferrard 等人, 2016 年; Hamilton 等人, 2017a; Kipf 和 Welling, 2016 年) 和消息传递神经网络 (Gilmer 等人, 2017 年) 是相关研究方向, 它们允许逐层学习图中节点的嵌入。

尽管图卷积网络在社交网络和知识图谱中的重要预测问题上取得了最先进的性能, 但它们尚未用于计算生物学中的问题。我们的模型通过支持多种边类型 (每种类型代表一种不同的副作用) 对图卷积网络进行了扩展, 并通过为具有大量边类型的多模态图提供一种高效的权重共享形式来实现这一扩展。

8 结论

我们提出了 Decagon 方法, 用于预测药物组合的副作用。Decagon 是一种通用的图卷积神经网络, 设计用于在大型多模态图上运行, 其中节点可以通过大量不同的关系类型相互连接。我们首次使用 Decagon 推导出一种预测模型, 能够识别药物组合的副作用。Decagon 预测副作用与联合处方药物组合 (即药物组合) 之间的关联, 以识别不能单独归因于任何一种药物的副作用。图卷积模型在多药副作用预测任务中表现出色, 使我们能够整合分子和患者群体数据, 考虑近一千种不同的副作用类型, 并为药物相互作用的临床表现提供见解。

未来的研究方向有多个。我们的方法将分子层面的蛋白质 - 蛋白质和药物 - 靶点网络与人群层面患者的副作用数据整合在一起。其他生物医学信息来源, 例如药物的剂量浓度水平, 可能对药物组合的副作用建模具有相关性, 我们希望研究将它们整合到模型中的效用。由于 Decagon 的图卷积模型是一种适用于任何多模态网络中多关系链路预测的通用方法, 将其应用于其他领域和问题会很有趣, 例如找出患者结果与共病之间的关联, 或者识别突变表型与基因 - 基因相互作用之间的依赖关系。

资金

本研究部分得到了美国国家科学基金会 IIS-1149837、美国国立卫生研究院 BD2K U54EB020405、美国国防高级研究计划局 SIMPLEX、斯坦福大学数据科学计划以及陈-扎克伯格生物中心的支持。

利益冲突: 无。

参考文献

- Banakh, I. et al. (2017) Severe rhabdomyolysis due to presumed drug interactions between atorvastatin with amlodipine and ticagrelor. Case Rep. Crit. Care, 2017, 1.
- Bansal, M. et al. (2014) A community computational challenge to predict the activity of pairs of compounds. Nat. Biotechnol., 32, 1213–1222.
- Bicker, J. et al. (2017) Elucidation of the impact of p-glycoprotein and breast cancer resistance protein on the brain distribution of

- catechol-o-methyltransferase inhibitors. *Drug Metab. Dispos.*, 45, 1282–1291.
- Campillos, M. et al. (2008) Drug target identification using side-effect similarity. *Science*, 321, 263–266.
- Chatr-Aryamontri, A. et al. (2015) The BioGRID interaction database: 2015 update. *Nucleic Acids Res.*, 43, D470–D478.
- Chen, D. et al. (2016) Synergy evaluation by a pathway–pathway interaction network: a new way to predict drug combination. *Mol. BioSyst.*, 12, 614–623.
- Chen, X. et al. (2016b) NLLSS: predicting synergistic drug combinations based on semi-supervised learning. *PLoS Comput. Biol.*, 12, e1004975.
- Cheng, F. and Zhao, Z. (2014) Machine learning-based prediction of drug–drug interactions by integrating drug phenotypic, therapeutic, chemical, and genomic properties. *J. Am. Med. Inform. Assoc.*, 21, e278–e286.
- Defferrard, M. et al. (2016) Convolutional neural networks on graphs with fast localized spectral filtering. In *NIPS*, Vol. 30, pp. 3844–3852.
- Ernst, F.R. and Grizzle, A.J. (2001) Drug-related morbidity and mortality: updating the cost-of-illness model. *J. Am. Pharm. Assoc.*, 41, 192–199.
- Ferdousi, R. et al. (2017) Computational prediction of drug–drug interactions based on drugs functional similarities. *J. Biomed. Inform.*, 70, 54–64.
- Gilmer, J. et al. (2017) Neural message passing for quantum chemistry. *ICML*, 34, 1263–1272.
- Glorot, X. and Bengio, Y. (2010) Understanding the difficulty of training deep feedforward neural networks. In *AISTATS*, Vol. 13, pp. 249–256.
- Gottlieb, A. et al. (2012) INDI: a computational framework for inferring drug interactions and their associated recommendations. *Mol. Syst. Biol.*, 8, 592.
- Hamilton, W.L. et al. (2017a) Inductive representation learning on large graphs. *NIPS*, 31, 1025–1035.
- Hamilton, W.L. et al. (2017b) Representation learning on graphs: methods and applications. *IEEE Data Eng. Bull.*, 40, 52–74.
- Han, K. et al. (2017) Synergistic drug combinations for cancer identified in a CRISPR screen for pairwise genetic interactions. *Nat. Biotechnol.*, 35, 463–474.
- Hodos, R.A. et al. (2016) In silico methods for drug repurposing and pharmacology. *Wiley Interdisc. Rev. Syst. Biol. Med.*, 8, 186–210.
- Huang, L. et al. (2014a) Drugcomboranker: drug combination discovery based on target network analysis. *Bioinformatics*, 30, i228–i236.
- Huang, H. et al. (2014b) Systematic prediction of drug combinations based on clinical side-effects. *Sci. Rep.*, 4.
- Jia, J. et al. (2009) Mechanisms of drug combinations: interaction and network perspectives. *Nat. Rev. Drug Discov.*, 8, 111–128.
- Kantor, E.D. et al. (2015) Trends in prescription drug use among adults in the United States from 1999–2012. *JAMA*, 314, 1818–1830.
- Kingma, D. and Ba, J. (2014) Adam: a method for stochastic optimization. *arXiv*: 1412.6980.
- Kipf, T.N. and Welling, M. (2016) Semi-supervised classification with graph convolutional networks. *ICLR*, 4.
- Kuhn, M. et al. (2016) The SIDER database of drugs and side effects. *Nucleic Acids Res.*, 44, D1075–D1079.
- Lee, D.-S. et al. (2008) The implications of human metabolic network topology for disease comorbidity. *Proc. Natl. Acad. Sci. USA*, 105, 9880–9885.
- Lewis, R. et al. (2015) Synergy maps: exploring compound combinations using network-based visualization. *J. Cheminform.*, 7, 36.
- Li, J. et al. (2016) A survey of current trends in computational drug repositioning. *Brief. Bioinform.*, 17, 2–12.
- Li, X. et al. (2017) Prediction of synergistic anti-cancer drug combinations based on drug target network and drug induced gene expression profiles. *Artif. Intell. Med.*, 83, 35–43.
- Lieber, D.C. and Guengerich, F.P. (2005) Elucidating mechanisms of drug-induced toxicity. *Nat. Rev. Drug Discov.*, 4, 410–420.
- Loewe, S. (1953) The problem of synergism and antagonism of combined drugs. *Arzneimittel-Forschung*, 3, 285–290.
- Maaten, L.V.D. and Hinton, G. (2008) Visualizing data using t-SNE. *J. Mach. Learn. Res.*, 9, 2579–2605.
- Menche, J. et al. (2015) Uncovering disease–disease relationships through the incomplete interactome. *Science*, 347, 1257601.
- Mikolov, T. et al. (2013) Distributed representations of words and phrases and their compositionality. In *NIPS*, Vol. 27, pp. 3111–3119.
- Nickel, M. et al. (2011) A three-way model for collective learning on multi-relational data. In *ICML*, Vol. 11, pp. 809–816.
- Pan, R. et al. (2017) Synthetic lethality of combined Bcl-2 inhibition and p53 activation in AML: mechanisms and superior antileukemic efficacy. *Cancer Cell*, 32, 748–760.
- Papalexakis, E.E. et al. (2017) Tensors for data mining and data fusion: models, applications, and scalable algorithms. *ACM Trans. Intell. Syst. Technol.*, 8, 16.
- Parving, H.-H. et al. (2012) Cardioresenal end points in a trial of aliskiren for type 2 diabetes. *N. Engl. J. Med.*, 367, 2204–2213.
- Percha, B. et al. (2012) Discovery and explanation of drug–drug interactions via text mining. In *Pacific Symposium on Biocomputing*, Vol. 17, pp. 410–421.
- Perozzi, B. et al. (2014) Deepwalk: Online learning of social representations. In *KDD*, Vol. 20, pp. 701–710. *ACM*.
- Rolland, T. et al. (2014) A proteome-scale map of the human interactome network. *Cell*, 159, 1212–1226.
- Russo, M.G. et al. (2016) Looking for the interactions between omeprazole and amoxicillin in a disordered phase. an experimental and theoretical study. *Spectrochim. Acta A*, 156, 70–77.
- Ryall, K.A. and Tan, A.C. (2015) Systems biology approaches for advancing the discovery of effective drug combinations. *J. Cheminform.*, 7, 7.
- Schlichtkrull, M. et al. (2017) Modeling relational data with graph convolutional networks. *arXiv*: 1703.06103.
- Shi, J.-Y. et al. (2017) Predicting combinative drug pairs towards realistic screening via integrating heterogeneous features. *BMC Bioinformatics*, 18, 409.
- Srivastava, N. et al. (2014) Dropout: a simple way to prevent neural networks from overfitting. *J. Mach. Learn. Res.*, 15, 1929–1958.
- Stage, T.B. et al. (2015) A comprehensive review of drug–drug interactions with metformin. *Clin. Pharmacokinet.*, 54, 811–824.
- Sun, Y. et al. (2015) Combining genomic and network characteristics for extended capability in predicting synergistic drugs for cancer. *Nat. Commun.*, 6, 8481.
- Szklarczyk, D. et al. (2016) STITCH 5: augmenting protein–chemical interaction networks with tissue and affinity data. *Nucleic Acids Res.*, 44, D380–D384.
- Szklarczyk, D. et al. (2017) The STRING database in 2017: quality-controlled protein–protein association networks, made broadly accessible. *Nucleic Acids Res.*, 45, D362–D368.
- Takeda, T. et al. (2017) Predicting drug–drug interactions through drug structural similarities and interaction networks incorporating pharmacokinetics and pharmacodynamics knowledge. *J. Cheminform.*, 9, 16.
- Tatonetti, N.P. et al. (2012) Data-driven prediction of drug effects and interactions. *Sci. Transl. Med.*, 4, 125ra31.
- Trouillon, T. et al. (2016) Complex embeddings for simple link prediction. In *ICML*, 33, 2071–2080.
- Vilar, S. et al. (2012) Drug–drug interaction through molecular structure similarity analysis. *J. Am. Med. Inform. Assoc.*, 19, 1066–1074.
- Vilar, S. et al. (2017) Detection of drug–drug interactions through data mining studies using clinical sources, scientific literature and social media. *Brief. Bioinform.*, doi.org/10.1093/bib/bbx010.
- Zhang, P. et al. (2015) Label propagation prediction of drug–drug interactions based on clinical side effects. *Sci. Rep.*, 5, 12339.
- Zhang, W. et al. (2017) Predicting potential drug–drug interactions by integrating chemical, biological, phenotypic and network data. *BMC Bioinformatics*, 18, 18.
- Zhao, X.-M. et al. (2011) Prediction of drug combinations by integrating molecular and pharmacological data. *PLoS Comput. Biol.*, 7, e1002323.
- Zitnik, M. and Zupan, B. (2015) Data fusion by matrix factorization. *IEEE Trans. Patt. Anal. Mach. Intell.*, 37, 41–53.
- Zitnik, M. and Zupan, B. (2016) Collective pairwise classification for multi-way analysis of disease and drug data. In *Pacific Symposium on Biocomputing*, Vol. 21, pp. 81–92.
- Zong, N. et al. (2017) Deep mining heterogeneous networks of biomedical linked data to predict novel drug–target associations. *Bioinformatics*, 33, 2337–2344.