



数据和文本挖掘

MolTrans:用于药物-靶标相互作用预测的分子相互作用转换器

黄可欣¹, 曹晓², 卢卡斯·M·格拉斯 (Lucas M. Glass)²和孙吉猛 (Jimeng Sun)^{3,*}

¹ 健康数据科学,哈佛大学,波士顿,马萨诸塞州 02120,美国, ³和
伊利诺伊大学香槟分校计算机科学系,伊利诺伊州厄巴纳 61801,美国

* 通信地址。
副主编:陆志勇
收到日期:2020年4月24日;修改日期:2020年8月23日;编辑决定日期:2020年9月25日;接受日期:2020年10月7日

抽象的
动机:药物-靶标相互作用 (DTI) 预测是计算机模拟药物发现的一项基础任务,由于需要在庞大的药物化合物空间中进行实验搜索,因此成本高昂且耗时。近年来,深度学习在 DTI 预测方面取得了令人欣喜的进展。然而,仍然存在以下挑战:(i) 现有的分子表征学习方法忽略了 DTI 的子结构特性,导致结果准确性较低且难以解释;(ii) 现有方法侧重于有限的标记数据,而忽略了海量未标记分子数据的价值。

结果:我们提出了一个分子相互作用转换器 (MolTrans) 来解决这些局限性:(i) 受知识启发的子结构模式挖掘算法和交互建模模块,以实现更准确、更易于解释的 DTI 预测;(ii) 增强型转换器编码器,能够更好地提取和捕捉从海量未标记生物医学数据中提取的子结构之间的语义关系。我们在真实数据上对 MolTrans 进行了评估,结果表明,与最先进的基线方法相比,MolTrans 的 DTI 预测性能有所提升。

可用性和实施:模型脚本可在<https://github.com/kexinhuang12345/moltrans>上获取。
联系方式:jimeng@illinois.edu 补充信息:补
充数据可在生物信息学在线查阅。

1 简介

众所周知,药物研发需要对大量药物化合物进行实验搜索,因此成本高昂且耗时。

药物-靶蛋白相互作用 (DTI) 预测是发现新药 (即虚拟筛选)和现有药物新适应症 (即药物重新定位)的基础,因为药物化合物的治疗效果是通过检查 DTI 来检测的(Hughes 等人,2011)。在化合物识别过程中,研究人员通常需要进行分析实验,并在候选数据库中搜索超过 9700 万个可能的化合物(Broach 等人,1996)。

幸运的是,随着海量生物医学数据和知识的收集和利用,以及深度学习技术的进步 (深度学习技术在许多应用领域取得了巨大成功),药物研发过程,尤其是DTI预测,得到了显著提升。近年来,各种深度模型在DTI预测方面表现出色。它们通常以药物和蛋白质数据作为输入,将DTI视为一个分类问题,并通过深度学习模型将输入数据进行预测。

例如深度神经网络 (DNN) (Unterthiner et al., 2014)、深度信念网络 (DBN) (Wen et al., 2017)和卷积神经网络 (CNN) (Mayr et al., 2018; Ozturk et al., 2018, 2019)。

尽管做出了这些努力,但仍存在以下挑战。

1. 相互作用机制建模不足。现有研究 (Gao et al., 2018; Ozturk et al., 2018, 2019)学习分子表征并基于药物和蛋白质的完整分子结构进行预测,忽略了相互作用是子结构的 (仅涉及药物和蛋白质的相关子结构 (Jia et al., 2009; Schenone et al., 2013))。全结构分子表征会引入噪声并影响预测性能。此外,学习到的表征难以解释,因为它们没有提供一条易于处理的路径来指示哪些药物和蛋白质的子结构对相互作用有贡献。

2. 受限于有限的标记数据。先前的研究 (Gao 等人,2018; Lee 等人,2019; Ozturk 等人,2018,2019;

Wen et al., 2017)专注于手头的数据,将范围限制在几千种药物和蛋白质内,同时忽略了有大量 (例如数百万)未标记的生物医学数据可用。之前作品中的模型架构也没有设计实现海量数据集的整合。

当前工作。为了解决这些挑战,我们提出了一种基于变换器 (Vaswani et al., 2017)的生物启发分子数据表示方法[称为分子相互作用Transformer (MolTrans)]利用大量未标记数据进行 in-sil-ico DTI 预测。MolTrans 由以下技术实现贡献:

- 1. 知识启发的表示和交互建模
更准确、更易于解释的预测。受DTI是子结构这一知识的启发, MolTrans衍生出一种数据驱动的方法称为频繁连续子序列 (FCS)挖掘的方法适用于提取高质量、合适尺寸的子结构适用于蛋白质和药物。此外,MolTrans 还包含一个仿生相互作用模块,模拟真实的生物 DTI 过程。新的子结构指纹使可处理的了解哪些子结构组合具有通过清晰的地图与结果更加相关交互模块。
- 2. 利用海量未标记的生物医学数据。MolTrans 矿场
通过来自多个未标记的数据源,以提取高质量的子结构药物和蛋白质。海量数据带来了更高质量的子结构比单独使用小型训练数据集更有用。我们还使用转换器增强表示 (Vaswani 等人, 2017) ,它捕捉大型从未标记的数据。

我们对各种现实药物发现环境中的最新方法进行了全面的性能比较,包括未见过的药物/目标问题和稀缺的训练数据集

设置。我们通过实证研究证明,MolTrans 的预测性能比最先进的基线高出 25%

超过表现最佳的基线。
相关工作。许多计算方法已经为DTI预测问题而开发。基于相似性的方法例如核回归 (Pahikkala et al., 2015)和矩阵分解 (Zheng et al., 2013)方法利用已知的 DTI 药物-靶点相似性信息并推断新的药物。然而,这些方法被证明不能推广到不同的蛋白质类别(Wen et al., 2017)。基于特征的方法将药物和蛋白质的数值描述符输入到下游

预测模型。流行的数值描述符包括 ECFP (Rogers 和 Hahn,2010)和 PubChem (Bolton 等人,2008) 药物,成分-转换-分布 (CTD; Dubchak et al., 1995)和蛋白质序列组成描述符 (PSC; Cao et al., 2013)用于蛋白质。经典的机器学习方法诸如梯度提升 (He et al., 2017)等方法已经展现出前景预测性能。最近,基于深度学习的方法 (Ozturk 等人,2019 年; Tsubaki 等人,2019 年; Unterthiner 等人, 2014; Wen et al., 2017)由于能够捕捉复杂的DTI非线性信号,其性能得到了进一步提升。MolTrans与现有研究的不同之处在于: (i)其

知识驱动的模式架构设计,而不是直接现有深度学习模型的应用; (ii)强调可解释性而不是单独的预测性能,以潜在地帮助医学化学家做出更好的决策; (iii)

使用外部药物和靶标数据来补充相互作用数据集。

Algorithm 1: Frequent Consecutive Sub-sequence Mining

Input: $\mathbb{V}$ as the set of all initial amino acids/SMILES tokens; $\mathbb{W}$ as the set of tokenized proteins/drugs; θ as the specified frequency threshold; ℓ as the maximum size of $\mathbb{V}$.

Output: $\mathbb{W}$, the updated tokenized proteins/drugs; $\mathbb{V}$, the updated token vocabulary set.

```
for  $t = 1 \dots \ell$  do
   $(A, B), \text{freq} \leftarrow \text{scan } \mathbb{W}$ 
  //  $(A, B)$  is the frequentest consecutive tokens.
  if  $\text{freq} < \theta$  then
    break //  $(A, B)$ 's frequency lower than threshold
   $\mathbb{W} \leftarrow \text{find}(A, B) \in \mathbb{W}$ , replace with  $(AB)$ 
  // update  $\mathbb{W}$  with the combined token  $(AB)$ 
   $\mathbb{V} \leftarrow \mathbb{V} \cup (AB)$  // add  $(AB)$  to the token vocabulary set  $\mathbb{V}$ 
```

2 材料和方法

2.1 问题定义
我们将 DTI 预测制定为一个分类任务,以确定一对药物和目标蛋白质是否会相互作用。在我们的设置,药物由简化分子输入线表示进入系统 (SMILES) S_i ,由一系列化学通过对分子图进行深度优先遍历,生成原子和键标记 (例如 C.O.S) 。我们将药物的 SMILES 表示法标记为 S_i ,目标蛋白质标记为 A_i ,由

蛋白质标记序列,其中每个标记是 23 个氨基酸之一。酸。符号表见补充材料 S1。
DTI预测任务定义如下。
问题 1 (DTI 预测)。给定复合序列 $S = s_1 s_2 \dots s_n$; $A = a_1 a_2 \dots a_m$; Sng 为 n 种药物和蛋白质序列 $A = a_1 a_2 \dots a_m$; AMG 为 m 蛋白质。DTI 预测任务可以转换为学习从药物-靶标对到相互作用概率分数的函数映射 $F: S \times A \rightarrow [0,1]$ 。

2.2 MolTrans方法
MolTrans 框架学习预测 DTI 的方法如下,给定输入药物和蛋白质数据后,FCS 挖掘模块首先使用专门的分解算法。然后将输出输入到一个增强 Transformer 嵌入模块,通过 Transformer 编码器为每个子结构获取增强的上下文嵌入(Vaswani 等人,2017)。接下来,在交互中
预测模块,药物子结构与蛋白质子结构配对,并计算成对相互作用分数。随后会有一个 CNN 层应用于交互图来捕获高阶交互。最后,解码器模块输出一个表示概率的分数成对相互作用。方法说明如图1所示。

2.2.1 FCS挖矿模块
在 DTI 发生在子结构层面的领域知识的驱动下,MolTrans 首先分解分子序列
蛋白质和药物分解成子结构。具体来说,我们提出了一种数据驱动的序列模式挖掘算法,称为FCS算法在药物和蛋白质数据库中查找重复的子序列。受到自然语言中子词单元发明的启发处理领域 (Gage,1994; Sennrich 等,2015) , FCS 旨在为序列生成一组频繁子序列的层次结构。
该算法总结于算法 1。FCS 分解
将每个蛋白质/药物序列按层次划分为子序列,更小的子序列和单个原子/氨基酸符号。
FCS 首先初始化一个包含不同氨基酸的词汇集 V

标记或 SMILES 字符串字符,并给出标记,标记化整个药物/蛋白质语料库。我们称之为标记集W。然后,它扫描 W 并识别最常见的连续标记 (A, B)。然后,FCS 使用以下语句更新标记集 W 中的每个 (A, B) 新的标记 (AB),并将此新标记添加到词汇表中集合V。然后重复此扫描,识别,更新的过程,直到没有频繁标记高于阈值 h 或 V 的大小达到预定义的最大值”。通过此操作,频繁子序列合并为一个标记,并且子序列不够频繁的词被分解成一组较短的词。在 最后,对于药物/蛋白质,FCS 产生序列 C ¼ fC1; ... ;大小为 k 的亚结构药物/靶蛋白的Ckg , 其中每个C都来自集合 V。 MolTrans 使用 FCS 算法将输入的药物和靶点 分别对应于显式子结构Cd和Cp序列。 FCS 的意义有三方面:

1. 它与以前的子结构指纹识别方法不同,因为它更具可解释性。显式子结构指纹

例如, PubChem 编码对于一个小分子来说平均有 100 个粒度子结构,其中许多子结构是子集,因此很难知道哪个子结构导致了结果。相比之下, FCS 药物编码

能够给出明确的提示,因为它将每个药物分子分解成离散的、中等大小的子结构分区

如第 3.7 节所示,它能够利用海量未标记数据来改进子结构挖掘。例如,

我们使用 Uniprot 数据集 (Boutet et al., 2007) ,包括 560823个独特蛋白质序列和ChEMBL数据库 (Gaulton 等人,2012) ,其中包括 1 870 461 个药物 SMILES 字符串。我们观察到,挖掘出的子结构的质量源于我们使用的大量未标记数据。在小规模数据集中,许多有用的子结构的出现是低于合理的最小频率,而大型聚合数据集可以成功地以更大的

序列池。我们还表明,与

使用小数据集,在第 3.8 节中。

2. FCS 能够捕捉基本且有意义的生物医学语义。生成的子结构与药物和蛋白质中经常出现的基本单元相关。我们发现

FCS算法识别相似的基本生化子结构给出了不同的数据集特征,例如蛋白质数据集的不同生物类型和药物数据集的药物可能性,表明了FCS算法的稳健性 (补充材料S1)。一般来说,我们采用更

通用数据集 (例如 ChEMBL)而不是重点数据集 (例如 DrugBank 中已批准的药物)因为更大的数据集可以提高下游预测性能 (第 3.8 节)。

2.2.2 增强型 Transformer 嵌入模块 为了捕捉子结构的化学语义, MolTrans 包括一个增强嵌入模块,它首先初始化一个可学习的子结构查找字典,然后扩充通过 Transformer 编码器嵌入上下文子结构信息(Vaswani 等人,2017)。Transformer 是一种最先进的深度学习架构,它利用了自注意力机制

生成上下文嵌入的机制。它最初是开发用于自然语言处理任务。在这里,我们对其进行了调整,用于分子表征学习。在我们的设置中,Transformer 编码器中的自注意力机制会修改每个输入 通过学习所有子结构来实现子结构嵌入来自同一个分子。由此产生的子结构嵌入是更好,因为它考虑到了复杂的上下文相邻子结构之间的化学关系。 具体来说,对于每个输入的药物-靶标对,我们将其转化为子结构Cp和Cd的对应序列分为两个

矩阵Mp 2 RkHp和Md 2 RlHd药物/蛋白质子结构 , 其中 k/l 是 或词汇基数 来自FCS算法的集合V, Hp和Hd是 蛋白质和药物的子结构序列,以及每列Mp 和马里兰州 是对应于子结构索引的独热向量 为蛋白质序列的第 i 个子结构 j 为 药物序列。内容嵌入Ep 康蒂; 埃德 连词 对于每种蛋白质 药物是通过可学习的字典查找矩阵生成的 WP 续 2 R#k和Wd 续 2 R#l使得 埃德 康蒂 ¼ Wp 持续; 埃德 连词 ¼ Wd 续 j ;

其中 # 是每个子结构的潜在嵌入的大小。 由于 MolTrans 使用顺序子结构,我们还包括 位置嵌入Ep 正 : 埃德 波斯特 通过查找字典 (Vaswani 等,2017) Wp 位置 2 R#Hp和Wd 位置 2 R#Hd高清 : 埃德 正 ¼ Wp 正; 埃德 波斯特 ¼ Wd 正; d

我在哪里 2 RHp = d 2 RHd是单个热向量,其中第 i/j 个位置 为 1。 最终嵌入Ep 我; 埃德 是通过内容总和生成的 和位置嵌入:

$$E_{ij} = \frac{1}{2} W_p^T E_{ij} + \frac{1}{2} W_d^T E_{ij} \quad (1)$$

上述模型输出一组独立的子结构 嵌入。然而,这些子结构之间具有化学关系 (例如八隅体规则) ,以捕捉这些上下文

信息,我们进一步使用转换器增强嵌入 编码器层 (Vaswani 等人,2017) :

$$E \leftarrow \frac{1}{2} \text{TransformerProtein} \delta E_p; \quad E \leftarrow \frac{1}{2} \text{TransformerDrug} \delta E_d; \quad (2)$$

2.2.3 交互预测模块 MolTrans 包含一个由两层组成的交互模块: (i)用于模拟成对子结构相互作用的相互作用张量 (二)在交互图上添加 CNN 层,用于提取邻域相互作用。

成对相互作用。为了对成对相互作用进行建模,对于每个 蛋白质中的子序列 i 和药物中的子序列 j,我们有

$$I_{ij} = \frac{1}{2} F \delta E_i \cdot E_j^d; \quad (3)$$

其中 F 是衡量 对。它可以是任何函数,例如求和、平均值和点积。 因此,在这一层之后,我们有一个张量 I 2 RHdHpU,其中 Hd=Hp分别是药物/蛋白质子结构的长度, U 是函数 F 输出的大小,其中 该张量考虑了蛋白质和药物各个子结构的相互作用。为了提供可解释性,我们倾向于

点积作为聚合函数,因为它生成单个 标量明确测量相互作用的强度 单个靶点-药物子结构对。点积输出为 对于每一对来说, I 都是一维的,它变成了一个二维的交互图。如果图中某个值很高,它将在 下游层并且具有更高的 DTI 交互可能性。 通过端到端学习,如果一对子结构确实相互作用,它们将在交互图中相应的子结构对位置上具有较高的交互分数。因此,通过检查

这张图,我们直接看到哪些子结构对有助于 最终结果。 邻域相互作用。邻近的蛋白质亚结构和 药物相互作用会相互影响,从而引发相互作用。因此,除了对单个药物对相互作用进行建模外,还需要对邻近区域的相互作用进行建模。我们实现了这一点

通过交互图 I 顶部的CNN (Krizhevsky 等,2012)层。直觉是,通过应用几个顺序不变的 局部卷积滤波器,与附近区域的交互可以

被捕获并聚合。我们得到输入药物-目标对的输出表示O：

$$O = \frac{1}{4} CNN \tilde{O} P; \tag{4}$$

该交互模块的灵感源自深度交互式推理网络(Gong et al., 2018),得益于这种明确的交互建模,我们之后可以从交互图中可视化单个子结构交互对的强度。为了输出表示交互可能性的概率,我们首先将 O 展平为向量,并使用一个由权重矩阵Wo和偏差向量bo 参数化的线性层：

$$P = \frac{1}{4} r \tilde{O} W_o FLATTEN \tilde{O} P \cdot b_o b; \tag{5}$$

其中 $r \tilde{O} a P = \frac{1}{1 + \exp(-\tilde{O} a P)}$ 。
整个网络的参数为Wp 权重, 西德 偏置, Wp 位置, 西德 位置
Wo; bo, Transformer 编码器权重和 CNN 权重可以通过二分类损失进行联合优化：

$$L = \frac{1}{4} Y \log \tilde{O} P + \frac{1}{4} Y P \log \tilde{O} P; \tag{6}$$

其中 Y 是基本事实标签。

2.3 实现MolTrans 在 PyTorch 中

实现(Paszke et al., 2019)。对于 FCS 算法,我们将数据集中药物和蛋白质子结构的最小出现次数设置为 500,从而产生 23 532 个药物子结构和 16 693 个蛋白质子结构。对于 Transformer 编码器,我们对药物和蛋白质均使用两层 Transformer 编码器。输入嵌入的大小为 384,我们为每个 Transformer 编码器设置 12 个注意力头,中间维度为 1536。我们将药物序列的最大长度设置为 50,蛋白质序列的最大长度设置为 545,以覆盖数据集中 95% 的序列。我们对超过/低于最大长度的部分进行剪切/填充。我们在补充材料中证明了模型性能不会因序列长度而产生偏差。 S2。

对于 CNN,我们使用三个卷积核大小为 3 的滤波器。对于优化超参数,我们使用 Adam 优化器,学习率为 1e5。我们将批大小设置为 64,并允许其运行 30 个 epoch。它在 8 到 15 个 epoch 之间收敛,dropout 率为 0.1。

3 结果

我们设计实验来回答以下问题。

问题 1: MolTrans 是否提高了 DTI 预测性能?

问题 2: MolTrans 对付未见毒品/目标案件的成效如何?

Q3: MolTrans 如何处理大量缺失数据?

Q4: 不同蛋白质家族的性能有何不同?

Q5: MolTrans 是否提供有关 DTI 的有用知识?

Q6: MolTrans 的各个组件如何促进

预测性能增益?

3.1 实验设置数据集。我们使用 BIOSNAP

集合中的 MINER DTI 数据集(Zitnik et al., 2018a)作为主要实验数据集。该数据集包含 4510 个药物节点和 2181 个蛋白质靶点,以及来自 DrugBank 的 13741 个 DTI 对(Wishart et al., 2008)。BIOSNAP数据集仅包含正样本 DTI 对。对于负样本对,我们遵循常规做法(Zhang and Chen, 2018; Zitnik et al., 2018b),从未见过的样本对中进行采样。我们获得了一个正样本和负样本均等的平衡数据集。除了 BIOSNAP 数据集之外,我们还在主要的预测性能比较实验中引入了两个基准数据集。DAVIS 包含68 种药物和 379 种蛋白质的湿实验室测定Kd值(Davis et al., 2011),而 BindingDB 包含10 665 种药物和 1 413 种蛋白质的Kd值(Liu et al., 2007)。Kd值<30 个单位的 DTI 对被

视为正样本。为了平衡训练,我们对训练集中的负样本 DTI 对进行子采样,使其与正样本数量相同。验证集和测试集中保留数据集的负样本比例。数据统计计数数据如表1 所示。

指标: 我们使用 ROC-AUC (受试者工作特征曲线下面积)和 PR-AUC (精确召回率曲线下面积)作为衡量二分类性能的指标。

此外,我们使用敏感性和特异性指标,其中阈值是在验证集中具有最佳 F1 分数的阈值。

评估策略。我们将数据集按 7:1:2 的比例分为训练集、验证集和测试集。对于每个实验,我们分别进行五次独立运行,并使用不同的数据集随机划分。

然后,我们从验证集中根据 ROC-AUC 性能选出性能最佳的模型。之后,我们会在测试集上对验证选定的模型进行评估,并将结果报告如下。

技术。我们使用一台配备 2 台 Intel Xeon E5-2670v2 的服务器 2.5 GHz CPU、128 GB RAM 和 2 个 NVIDIA Tesla P40 GPU。

3.2 基线我们将

MolTrans 与以下基线进行了比较。我们专注于最先进的深度学习模型,因为它们已证明比浅层模型具有更优异的性能。

1. LR (Cao et al., 2013; Rogers and Hahn, 2010)在串联的药物和蛋白质特征向量上应用逻辑回归模型。我们对药物的 ECFP4 (Rogers and Hahn, 2010)和 PubChem (Wang et al., 2009)以及蛋白质的 PSC (Cao et al., 2013)和 CTD (Dubchak et al., 1995)的所有组合进行了实验。我们发现,药物的 ECFP4 和蛋白质的 PSC 性能最佳。

2. DNN 在 ECFP4 和 PSC 连接向量之上使用三层 DNN,隐藏大小为 1024。

3. GNN-CPI (Tsubaki 等人,2019)使用图神经网络编码药物,并使用 CNN 编码蛋白质。然后将潜在向量连接成神经网络,用于预测化合物-蛋白质相互作用。我们遵循论文中描述的超参数设置。

4. DeepDTI (Wen et al., 2017)使用 DBN (Hinton, 2009) 来建模 DTI, DBN 是一组受限玻尔兹曼机(Hinton, 2012)的堆栈。它使用 ECFP2、ECFP4、ECFP6 的串联作为药物特征,并使用 PSC 作为蛋白质特征。我们根据验证集的表现优化了论文中描述的超参数。

5. DeepDTA (O`zturk 等人,2018)将 CNN 应用于原始 SMILES 字符串和蛋白质序列,以提取局部残基模式。其任务是预测结合亲和力和值。我们在最后添加了一个 Sigmoid 激活函数,将其转换为二分类问题,并进行超参数搜索以确保公平性。

6. DeepConv-DTI (Lee 等人,2019)使用 CNN 和全局最大池化层提取蛋白质序列中不同长度的局部模式,并在药物指纹 ECFP4 上应用全连接层。它在不同的数据集上进行了广泛的实验,是 DTI 二分类预测任务中最先进的模型。

我们遵循
纸。

3.3 问题1: MolTrans 的预测性能卓越。为了回答问题1,我们随机选取20%的药物蛋白对作为测试集。

表2显示,MolTrans在DTI预测设置中,所有数据集的ROC-AUC和PR-AUC均具有持续最佳的预测基线。MolTrans的预测基线比最佳表现基线 (DAVIS PR-AUC)提升高达25%。需要注意的是,由于不同方法的阈值不同,灵敏度和特异性可能会有所不同。

3.4 Q2:MolTrans 在以下领域具有竞争力

看不见的药物和目标设定
为了模拟看不见的药物/目标任务,我们随机选择 20% 药物/靶蛋白以及与这些药物相关的所有 DTI 对 和目标作为测试集。结果如表3所示。我们观察到 KronRLS 的性能会因设置而异。这是因为 KronRLS 是一种基于相似性的方法;因此,它容易受到 数据属性。在未见药物的设置中,我们发现单层 LR 优于多层 DNN,但不如

具有更复杂的深度模型设计的 SOTA 方法。这 展示了精心设计模型架构的必要性。我们 还可以看到 MolTrans 相对于 两种设置中的 SOTA 深度学习基线。

3.5 Q3:MolTrans 在数据稀缺的情况下表现最佳

尽管 DTI 数据的可用性正在呈爆炸式增长,但在一些现实世界的药物研发过程中,存在 新的目标蛋白或 由于预算限制,只有少数标签的药物。 因此,在低资源约束下实现稳健的性能是理想的 在 DTI 设置中。我们分别在 5%、10%、20% 和 30% 的数据集,并对其余部分进行预测 (我们使用 10% 的 测试边作为提前停止的验证集)。报告结果 在表4 中,我们发现 MolTrans 是最稳健的方法。在 相比之下,DeepDTI 和 DeepConv-DTI 等 SOTA 基线 随着缺失分数的增加而下降。MolTrans 的一个原因是 在稀缺环境下,MolTrans 的优势在于它利用了嵌入 来自相对丰富的子结构

表 1. 数据集统计数据

数据集	# 药物	# 蛋白质	# 正向相互作用	# 负向相互作用
BIOSNAP 4510			2181 9619/1374/2748	9619/1374/2748
戴维斯	68		379	1043/160/303
绑定数据库	10 665 1413			6334/927/1905 6334/5717/11 384

注意 :对于交互列的数量,我们在数据中包含了训练/验证/测试交互统计数据。

表 2. 性能比较 (五次随机运行)

方法	ROC曲线下面积	PR-AUC	敏感度	特异性	临界点
数据集 1:BIOSNAP					
LR	0:84660:004	0:85060:011	0:75560:039	0:80060:018	0.434
深度神经网络	0:84960:003	0:85560:010	0:77660:040	0:83860:024	0.499
GNN-CPI	0:87960:007	0:89060:004	0:78060:014	0:81960:012	0.349
深度DTI	0:87660:005	0:87660:006	0:78960:027	0:84560:017	0.347
深层DTA	0:87660:005	0:88360:006	0:78160:015	0:82460:012	0.466
深度卷积-DTI	0:88360:002	0:88960:005	0:77060:023	0:83260:016	0.441
莫尔运输公司	0:89560:002	0:90160:004	0:77560:032	0:85160:014	0.431
数据集 2:DAVIS					
LR	0:83560:010	0:23260:023	0:69960:051	0:84260:033	0.399
深度神经网络	0:86460:009	0:25860:024	0:76460:045	0:86060:038	0.489
GNN-CPI	0:84060:012	0:26960:020	0:69660:047	0:84260:039	0.487
深度DTI	0:86160:002	0:23160:006	0:75160:015	0:85360:012	0.387
深层DTA	0:88060:007	0:30260:044	0:76460:045	0:86560:020	0.482
深度卷积-DTI	0:88460:008	0:29960:039	0:75460:040	0:88060:024	0.438
莫尔运输公司	0:90760:002	0:40460:016	0:80060:022	0:87660:013	0.447
数据集 3:BindingDB					
LR	0:88760:002	0:55760:015	0:74160:013	0:89660:011	0.394
深度神经网络	0:90860:003	0:61360:015	0:76960:028	0:91460:021	0.371
GNN-CPI	0:90060:004	0:57860:015	0:75460:015	0:90360:011	0.406
深度DTI	0:84460:002	0:42960:005	0:65160:024	0:89560:023	0.060
深层DTA	0:91360:003	0:62260:012	0:78060:035	0:91560:016	0.305
深度卷积-DTI	0:90860:004	0:61160:015	0:78160:015	0:90560:013	0.318
莫尔运输公司	0:91460:001	0:62260:007	0:79760:005	0:89660:007	0.355

注:MolTrans 在所有数据集中均取得了最佳的预测性能。粗体值对应每个指标的最佳性能方法。

与其他利用整个 药物和蛋白质。

3.6 Q4:MolTrans 在各种蛋白质家族中表现稳健

目标蛋白来自不同的蛋白质家族。重要的是 预测算法不会偏向某一特定 蛋白质家族。在本实验中,我们测试了四个最大的可用药物靶点的预测性能:酶、离子通道、

G蛋白偶联受体 (GPCR)和核受体。我们检索BIOSNAP的一个测试集,并将目标蛋白映射到 使用 GtoPdb 数据库的四个蛋白质家族 (https://www.guideto pharmacology.org/targets.jsp)。我们发现 1908 种酶相互作用, 533 个 GPCR 相互作用、496 个离子通道相互作用和 104 个核受体相互作用。我们发现 MolTrans 在所有 以上单个蛋白质家族 (图2) 。特别是酶, GPCR 和离子通道的性能比整体 蛋白质类别。

3.7 Q5:MolTrans 允许模型理解

为了回答问题5,我们通过示例展示了交互图 我可以提供关于哪个子结构会导致交互的提示。 相互作用图中的高值单元格代表药物与靶标子结构之间可能被激活的相互作用,该相互 作用对最终的相互作用结果至关重要。因此,为了进行可视化,我们

为 1 生成热图,以查看哪些单元格具有高值。我们 然后选择一个阈值来屏蔽掉大多数具有 低值。然后我们查阅文献,看看剩下的细胞 包含交互结果的线索。

我们首先喂食物药 2-壬基氧化物和蛋白质细胞色素 b-c1 复合物单元 1 放入 MolTrans 中,我们将相互作用可视化 通过过滤图3中大于阈值的标量来映射。 我们看到氮氧化物基团 [Np]([O]) 和 KNWV 具有 相互作用系数最高,与之前的研究一致 (Lightbown 和 Jackson,1956)他们证明氮氧化物 基团对于细胞色素抑制活性至关重要。本例 支持 MolTrans 能够提供合理的线索 理解模型预测并可能阐明 DTI 的内部运作。为了增加可信度,我们输入了 Ephrin

A 型受体 4 (Epha4) 靶点和达沙替尼药物进入 MolTrans, 该图显示氨基噻唑基团 S(1/4O)(1/4O)和 N 亚结构以蛋白质基序 KF 和 DVG 突出显示, 具有

与之前描述的 Epha4-达沙替尼复合物重叠
研究 (Farenc et al., 2011)。我们还输入目标蛋白
HDAC2 与输入药物异羟肟酸。相互作用图
NC(1/4O)基团和具有蛋白质亚结构 KK, YG, DIG, DD 的碳链具有高强度。建议的配体

子结构与 HDAC2- 中观察到的相互作用相匹配

SAHA 共复合物 (Lauffer 等人, 2013)。

补充材料 S3 中提供了其他示例。

3.8 Q6: 消融研究

我们对完整数据设置进行了消融研究, 设置如下:

1. -CNN: 我们从交互模块中移除 CNN, 并将交互图 I 输出展平并输入到解码器中。

2. -AugEmbed: 我们删除了增强型中的变压器
嵌入模块, 并将交互模块提供给
位置和内容嵌入。

表 3. MolTrans 在未知药物和
蛋白质设置 (显示五次随机运行的平均 ROC-AUC)
BIOSNAP 数据集

设置	DeepDTI	DeepDTA	DeepConv-DTI	MolTrans
看不见	0.843 6 0.003	0.849 6 0.007	0.847 6 0.009	0.85360:011
药物				
看不见	0.759 6 0.029	0.767 6 0.022	0.766 6 0.022	0.77060:029
蛋白质				

注意: 使用表现最好的三个基线进行比较。

表 4. MolTrans 在高缺失率情况下提供最佳结果
数据 (显示五次随机运行的平均 ROC-AUC)

设置 (%)	DeepDTI	DeepDTA	DeepConv-DTI	MolTrans
70	0.853 6 0.004	0.838 6 0.004	0.845 6 0.003	0.85360:004
80	0.828 6 0.007	0.821 6 0.008	0.825 6 0.003	0.83260:003
90	0.767 6 0.010	0.787 6 0.011	0.792 6 0.004	0.80260:004
95	0.659 6 0.011	0.762 6 0.004	0.726 6 0.008	0.76860:005

注意: 使用表现最好的三个基线进行比较。

3. -交互: 我们进一步从

AugEmbed。它退化为 FCS 指纹之上的解码器。需要注意的是, 仅仅移除交互模块并不是有效的模型设计。

4. 小: 我们使用较小的数据集来训练 FCS: DrugBank 的药物和 BindingDB 中的蛋白质。我们将最小频率调整为输出与 FCS-large 类似数量的子结构。

5. -FCS: 我们用 ECFP4 指纹替换 FCS 嵌入药物和蛋白质的 PSC 描述符。其余模型保持不变, 即它们随后被输入到变压器、交互模块和解码器中。

从表 5 可以看出, CNN、Transformers 和交互模块对模型最终性能有所贡献。FCS 指纹单独使用 -Interaction 就具有很强的预测性能。此外, 从 Small 来看, 我们看到大量未标记数据很有用, 因为它丰富输入并提升性能。从 -FCS, 我们看到我们的模型适用于具有类似特征的其他流行指纹表现强劲。




图 2. MolTrans 在不同的蛋白质家族中表现稳健




图 1. MolTrans 工作流程: (a) MolTrans 利用大量未标记数据。(b) 给定药物 S 和蛋白质 A 的输入对, MolTrans 提取一系列子结构 C_d 和 C_p 通过算法 1 实现。(c) 每个子结构通过公式 (1) 中的可学习嵌入表嵌入到潜在特征向量 E^d 和 E^p 中。然后, 将子结构嵌入的药物/蛋白质序列分别输入药物/目标 Transformer 编码器, 通过公式 (2) 获得增强上下文表示 E^d 和 E^p 。(d) 通过公式 (3) 生成一个相互作用图 I, 用于测量子结构之间的相互作用强度。该相互作用通过一个 CNN 层进一步优化, 该层建模高阶相互作用, 通过公式 (4) 得到张量 O。(e) 然后, 解码器模块将张量输入分类器, 通过公式输出 DTI 概率 P。(f) 所有模块都采用二分类损失函数进行端到端训练, 公式 (6)




图 3. DTI 中子结构贡献的相互作用图,显示药物 2-壬基氧化物与蛋白质细胞色素 b-c1 复合物单元 10 相互作用

表 5. 消融研究 (五次随机运行)

设置	ROC曲线下面积	PR-AUC
莫尔运输公司	0.89560:002	0.90160:004
美国化学文摘	0.876 6 0.003	0.883 6 0.006
八月嵌入	0.876 6 0.004	0.870 6 0.004
相互作用	0.847 6 0.003	0.85960:005
小的	0.888 6 0.001	0.888 6 0.007
融/千编辑	0:88760:004	0.887 6 0.004

4 结论

在这项工作中,我们介绍了 MolTrans,这是一个端到端的受生物启发的基于深度学习的框架,用于模拟 DTI 过程。我们在现实的药物研发环境中进行测试,并使用最先进的基准进行评估。我们通过实证研究证明,MolTrans 在所有环境下都能准确预测 DTI,并具有更佳的可解释性,且性能表现优异。

资金支持:这项工作部分得到了美国国家科学基金会奖 SCH SCH-2014438、IIS-1418511、CCF-1533768、IIS-1838042、美国国立卫生研究院奖 NIH R01 R101NS107291-01 和 R56HL138415 以及 IQVIA 的支持。

利益冲突:无。

数据可用性

本研究使用的所有数据均来自公共资源。BIOSNAP 数据可访问 <http://snap.stanford.edu/biodata/datasets/10002/10002-ChG-Miner.html>;DAVIS 数据可访问 <http://staff.cs.utu.fi/~aatapa/data/DrugTarget/;BindingDB> 数据可访问 <https://www.bindingdb.org/bind/index.jsp>。MolTrans GitHub 代码库中也提供了数据处理脚本。

参考

Bolton,EE 等 (2008) Pubchem:小分子与生物活性集成平台。见:计算化学年度报告。第 3 卷。

4,爱思唯尔,第 217-241 页。
布泰,E 等人。(2007) UniProtkb/瑞士-Prot.在:植物生物信息学。Springer,第 89-112 页。
Broach,JR 等人 (1996 年)用于药物发现的高通量筛选。自然,384,14-16。
Cao,D.-S. et al. (2013) propy:一种生成周氏各种模式的工具生物信息学,29,960-962。
Davis,MI 等人 (2011) 激酶抑制剂选择性的综合分析。天然生物技术,29,1046-1051。
Dubchak,I. 等 (1995) 利用氨基酸序列的全局描述预测蛋白质折叠类别。美国国家科学院院刊,92,8700-8704。

Farenc,C. 等 (2011)羧基蛋白和达沙替尼结合状态下EphA4蛋白酪氨酸激酶结构域的晶体结构。FEBS Lett.,585,3593-3599。
Gage,P. (1994) 一种新的数据压缩算法。C Users J.,12,23-38。
Gao,Y. 等人 (2018) 使用深度神经网络进行可解释的药物靶点预测引自:JCAI,第 3371-3377 页,瑞典斯德哥尔摩。
Gaulton,A. 等 (2012) ChEMBL:用于药物研发的大规模生物活性数据库。《核酸研究》,40, D1100-D1107。
Gong,Y. 等人 (2018) 交互空间上的自然语言推理。在:ICLR,加拿大温哥华。
He,T. 等人 (2017) SimBoost:一种使用梯度增强机预测药物-靶标结合亲和力的横向阅读方法。
J. Cheminform.,9,24。
Hinton,GE (2009) 深度信念网络。Scholarpedia,4,5947。
Hinton,GE (2012)限制玻尔兹曼训练实用指南
机器。神经网络:行业秘诀,599-619。
Hughes,JP 等。(2011)早期药物发现的原理。Br. J. Pharmacol.,162,1239-1249。
Jia,J. 等 (2009) 药物组合机制:相互作用和网络观点。Nat. Rev. Drug Disc.,8,111-128。
Krizhevsky,A. 等 (2012) 基于深度卷积神经网络的 ImageNet 分类。出处:NeurIPS,第 1097-1105 页,美国大盐湖。
Lauffer,BE 等 (2013)组蛋白去乙酰化酶 (HDAC)抑制剂动力学速率常数与细胞组蛋白乙酰化相关,但与转录和细胞活力无关。《生物化学杂志》,288,26926-26943。
Lee,I. 等人 (2019) DeepConv-DTI:通过深度学习结合蛋白质序列卷积预测药物-靶标相互作用。PLoS Comput. Biol.,15,e1007129。
Lightbown,J和Jackson,F. (1956) 双氢链霉素拮抗剂2-烷基-4-羟基嘧啶N-氧化物对心肌和某些细菌细胞色素系统的抑制。《生物化学杂志》,63,130-137。
Liu,T. 等 (2007) BindingDB:一个可通过网络访问的实验测定蛋白质-配体结合亲和力和数据库。核酸研究,35, D198-D201。
Mayr,A. 等人 (2018)在 chEMBL 上对药物靶点预测的机器学习方法进行大规模比较。Chem. Sci., 9, 5441-5451。
O' ztur"rk,H. 等人 (2018) DeepDTA:深度药物-靶点结合亲和力预测。《生物信息学》,34,i821-i829。
O' ztu"rk,H. 等人 (2019) WideDTA:预测药物-靶标结合亲和力。arXiv:1902.04166。
Pahikkala,T. 等人 (2015) 迈向更现实的药物-靶标相互作用预词典。简述。生物信息学,16,325-337。
Paszke,A. 等人 (2019) Pytorch 中的自动微分。出处:NeurIPS,加拿大温哥华。
Rogers,D. 和 Hahn,M. (2010) 扩展连接指纹。J. Chem. Inf. 模型., 50, 742-754。
Schenone,M. 等 (2013) 化学生物学和药物发现中的靶点识别和作用机制。《自然化学生物学》,9, 232-240。
Sennrich,R. et al. (2016) 具有子集的稀有词的神经机器翻译词单位。ACL,第 1715-1725 页,柏林,德国。
Tsubaki,M. 等人 (2019) 通过对图形和序列进行神经网络的端到端学习来预测化合物-蛋白质相互作用。生物信息学,35,309-318。
Unterthiner,T. 等 (2014) 深度学习作为虚拟筛选的契机。NeurIPS 深度学习研讨会,第 27 卷,第 1 页,加拿大蒙特利尔。
Vaswani,A. 等人 (2017) 《注意力就是一切》(Attention is all you need)。刊于:NeurIPS,长滩,美国。
Wang,Y. 等 (2009) PubChem:一个用于分析小分子生物活性的公共信息系统。核酸研究,37,W623-W633。
Wen,M. 等人 (2017) 基于深度学习的药物-靶标相互作用预测。J. Proteome Res.,16,1401-1409。
Wishart,D. 等人 (2008) DrugBank:药物-药物作用知识库和药物靶点。核酸研究,36,D901-D906。
Zhang,M. 和 Chen,Y. (2018) 基于图神经网络的链接预测。引自:NeurIPS,第 5165-5175 页,加拿大蒙特利尔。
Zheng,X. 等人 (2013)利用多相似性协同矩阵分解预测药物-靶标相互作用。出处:KDD,美国芝加哥。
Zitnik,M. 等人 (2018a) BioSNAP 数据集:斯坦福生物医学网络数据集集合。
Zitnik,M. 等人 (2018b) 使用图论模型对多种药物副作用进行建模卷积网络。《生物信息学》,34,i457-i466。