

MGNDTI:基于多模态表征学习与门控机制

Lihong Peng, Xin Liu, Min Chen,* Wen Liao, Jiale Mao, and Liqian Zhou*

引用: J. Chem. Inf. Model. 2024, 64, 6684–6698

在线阅读


使用权

指标及更多

文章推荐

支持信息

摘要 药物-靶标相互作用 (DTI) 预测有助于加速药物发现并促进药物的重新定位。现有的基于深度学习的 DTI 预测方法大多能够更好地提取药物和蛋白质的判别性特征,但很少考虑药物的多模态特征。此外,药物与靶标之间相互作用表征的学习也需要进一步探索。本文,我们基于多模态表征学习和门控机制,提出了一种用于DTI预测的简单多模态门控网络MGNDTI。



MGNDTI 首先利用不同的保留网络学习药物和靶标的序列表征。接下来,它通过图卷积网络提取药物的分子图特征。

随后,设计了一个多模态门控网络来获取药物和靶标的联合表征。最后,构建一个全连接网络来计算相互作用概率。MGNDTI 使用四个数据集 (即人类、秀丽隐杆线虫、BioSNAP 和 BindingDB),在四种不同的实验环境下,与七种最先进的 DTI 预测模型 (CPI-GNN、TransformerCPI、MolTrans、BACPI、CPGL、GIFDTI 和 FOTF-CPI)进行了基准测试。通过 AUROC、AUPRC、准确率、F1 分数和 MCC 的评估,MGNDTI 显著优于上述七种方法。MGNDTI 是一个强大的 DTI 预测工具,在多种数据集和不同的实验环境下展现出卓越的鲁棒性和泛化能力。MGNDTI 可在 <https://github.com/plhnu/MGNDTI> 免费获取。

1. 引言

准确识别药物-靶标相互作用 (DTI) 有利于药物的发现和重新定位。基于湿实验室 (wet-lab) 的 DTI 预测方法成本高昂、费力且耗时。¹⁻⁴因此,越来越多的计算方法被设计出来用于自动解读新的 DTI。这些方法主要包含两类:基于模拟的方法和基于机器学习的方法。⁵基于模拟的方法通常包括分子对接^{6,7}和分子动力学模拟。⁸基于模拟的方法充分利用蛋白质的三维结构来推断相互作用位点和结合姿势。尽管这些方法取得了显著进展,但它们严重依赖已知的蛋白质三维结构信息,并且需要非常高的计算资源。

基于机器学习的方法在各种关联预测任务中效果显著,例如 lncRNA 与疾病的关联^{9,10}配体-受体相互作用¹¹⁻¹⁴以及药物诱导的肝毒性¹⁵。尤其值得一提的是,机器学习显著提升了 DTI 推断。这些方法包括最近邻¹⁶网络嵌入^{17,18}半监督学习¹⁹三重协作矩阵分解²⁰旋转森林²¹以及特征处理方案²²。

近年来,随着相互作用的药物-靶标对 (DTPs)的不断积累,深度学习在 DTI预测方面取得了巨大成功,许多端到端深度学习

为了发现DTI候选药物,已经设计出23,24种模型。这些方法首先从两个不同的角度,基于药物和靶点的分子图或一维序列分别对其进行编码,然后将编码的特征连接起来作为分类器的输入。^{25,26}例如,GraphDTA²⁷DeepConv-DTI²⁸MMDTA²⁹和GraphCL-DTA³⁰采用一维卷积神经网络 (1D-CNN)从蛋白质的氨基酸序列中学习蛋白质的特征。GNN-PT³¹INGNN-DTI³²增强图神经网络³²和DruBAN³³使用图神经网络 (GNN)获取分子表征。此外,其他模型也被用于预测新的DTI和药物重新定位,例如双线性注意力网络³⁴图卷积网络³⁵基于双向编码器表征的对比学习³⁶全局-局部视角³⁷以及BiLSTM与2D-CNN的组合³⁸。

深度学习极大地提高了DTI预测。然而,大多数基于深度学习的DTI识别模型分别表示和处理药物和靶点,并且

收到日期: 2024年6月6日
修订日期: 2024年7月20日
接受日期: 2024年8月1日
发布日期: 2024年8月13日



极难理解它们的相互作用
上下文。注意机制39可以有效地解决这个问题
problem.40 HyperAttentionDTI41构建了一个注意力向量
每个氨基酸或原子。AttentionSiteDTI42采用了
自我注意机制来发现
配体和蛋白质。CoaDTI43利用共同注意机制来结合药物和蛋白质模
式。
DrugBAN33通过深度
具有领域自适应的双线性注意力网络。MCANet44
采用交叉注意力机制来增强模型
特征表示能力。
深度学习模型已证明具有良好的前景
DTI 预测取得了进展,但大多数现有的深度
基于学习的 DTI 预测模型考虑了药物各种特征的聚合。45此外,相互

药物和靶标之间的影响需要进一步探索。40注意机制强调重要的

通过分配不同大小的注意力权重来
特征。46但门控机制47,48有助于
保留有用的特征,同时过滤无效的特征
学习任务。为了解决这一局限性,我们提出了一种新的
DTI 预测模型 (称为 MGNDTI)通过结合
多模态表征学习和门控机制。
这项工作的主要贡献如下:

- 两个保留网络 (RetNets) 旨在
从 SMILES 字符串中提取药物的特征,并
根据蛋白质的氨基酸序列来识别蛋白质的特征。
- 一个简单的多模态表示学习模型是
设计用于整合药物 SMILES 序列特征
和分子图特征。
- 开发了多模态门控网络来学习
DTP 的陈述。据我们所知,
这是第一个融合多模式的模型
表征学习和门控机制
DTP 表示学习。

2.材料和方法

2.1. 数据集。使用四个 DTI 数据集来训练和
评估模型的性能,即人类、秀丽隐杆线虫、
BioSNAP 和 BindingDB。前两个数据集是
由参考文献49创建,包含高度可信的负面 DTI。
BioSNAP 数据集由参考文献50和51构建,来自
DrugBank 数据库52并提供相同数量的
已验证的阳性 DTI 和随机选择的阴性 DTI
来自未见过的 DTP。BindingDB 数据集53主要关注
实验验证的小分子之间的结合亲和力和
分子和蛋白质。在本研究中,BindingDB 使用由文献54构建的低偏差
版本。上述关于
表1显示了四个数据集。关于人类和
BioSNAP数据集,图1为统计直方图
蛋白质长度和化合物原子数。统计
C.elegans和 BindingDB 数据集的直方图有
已在支持信息图 S1 中提供。

表 1. DTI 数据集描述

数据集	药品	蛋白质相互作用	正 负		
人类	2,726	2,001	5,997	2,633	3,364
秀丽隐杆线虫	1,767	1,876	7,785	3,893	3,892
BioSNAP	4,505	2,181	27,464	13,830	13,634
绑定数据库	14,643	2,623	49,199	20,674	28,525

2.2. MGNDTI.预测新的 DTI,如图所示
2.MGNDTI 首先从药物的
SMILES 序列和蛋白质的氨基酸特征
酸序列来获得它们的序列表示
不同的 RetNets。也就是说,两个 RetNets 使用不同的
参数。此外,药物的分子图特征是
通过提取获得药物的结构表示
GCN。随后,开发了一个多模态门控网络
得到每个DTP的特征表示。最后,
构建四层全连接网络 (FCN)
对每个 DTP 进行分类。
2.2.1. 问题表述。假设一种药物
表示为 (s, G) , 其中 s 表示 SMILES 序列, G 表示分子图,其中原子集
 V 以及原子之间的无向边集。每个
蛋白质表示为 (a, a) 。因此,潜在的 DTI 识别任务是学习, $*$ 含 m 氨基

函数: $\times [0, 1]$ 用于计算 $P \rightarrow$
每个 DTP 的概率。
2.2.2. 编码药物和蛋白质序列特征
保留网络。RetNet55是一个强大的架构,
大型语言模型。它实现了训练并行性,成本低
预测,并获得更好的性能。在这里,我们采用 RetNet 进行
获取药物和蛋白质的特征表示
它们的序列信息。

一种药物的 SMILES 字符串由 64 个不同的
字符,蛋白质由23种不同的氨基酸组成。
MGNDTI 首先将每个 SMILES 符号转换为
和氨基酸 a_j 到基于两个的嵌入向量
嵌入层。因此,嵌入
药物的嵌入尺寸为 d 的矩阵和 $F_S \in \mathbb{R}^{n \times d}$
 $F_P \in \mathbb{R}^{m \times d}$ 因为获得了蛋白质。

接下来,药物和蛋白质特征通过
RetNet。L层 RetNet 模块由堆叠多尺度
保留 (MSR)和前馈网络 (FFN)。它需要
特征矩阵作为输入,输出药物潜在 $F_S^{(l)}$
特征矩阵= M_S $M_S^{(左)}$ 根据公式1:

$$\begin{aligned} \text{和 } S^{(0)} &= \text{MSR}(\text{LN}()) M_S^{(0)} + M_S^{(0)} \\ * \\ \text{和 } S^{(t)} &= \text{FNN}(\text{LN}()) \text{和 } S^{(t-1)} + \text{和 } S^{(t-1)} \end{aligned} \tag{1}$$

其中 $\text{LN}(\cdot)$ 和 $\text{MSR}(\cdot)$ 表示 LayerNorm56和多尺度
保留率分别为55。 $M_S^{(左)} \in \mathbb{R}^{n \times d}$, $Y(l) \in \mathbb{R}^{n \times k}$, 和
 $\text{FNN}(X) = \text{gelu}(XW_1)W_2(X \in \mathbb{R}^{n \times k})$ 与参数矩阵
在1 $\in \mathbb{R}^{d/2 \times k}$ 和在2 $\in \mathbb{R}^{d/2 \times d}$ 。

类似地,它采用特征矩阵输出蛋白质潜在 $M_P^{(0)} = F_P$ 作为输入和
特征矩阵= M_P $M_P^{(左)}$ 根据公式2:

$$\begin{aligned} \text{和 } P^{(0)} &= \text{MSR}(\text{LN}()) M_P^{(0)} + M_P^{(0)} \\ * \\ \text{和 } P^{(t)} &= \text{FNN}(\text{LN}()) Y(l) + \text{和 } P^{(t-1)} \end{aligned} \tag{2}$$

其中(l) $M_P \in \mathbb{R}^{m \times d}$ 和 $Y(l) \in \mathbb{R}^{m \times k}$ 。

2.2.3. 使用编码药物分子图特征
GCN。为了编码药物分子图特征,受到
在之前的工作中,3,33我们将其 SMILES 字符串转换为 2D
分子图。 G 每个 G 原子节点通过
根据其化学特性,选择DGL-LifeSci57包。




图 1. Human 和 BioSNAP 上的蛋白质和化合物直方图。




图 2. MGNDTI 示意图。(a)MGNDTI 的架构主要包括基于 RetNets 的药物和蛋白质特征编码以及 GCN、基于多模态门控网络的DTP特征表示学习,以及基于FCN的DTP分类。(b)架构保留网络。(c)门控线性单元架构。(d)多模态表征学习架构。

因此,每种药物的分子图都表示为

作为 $\mathbb{R}^{n \times 74}$ 。此外,线性变换

$M \in \mathbb{R}^{d \times d}$ (西德 $\mathbb{R}^{d \times 4}$) 用于计算实值

稠密矩阵 $\mathcal{M}_G \in \mathbb{R}^{nd \times}$ 作为GCN的输入。

接下来,设计一个 K 层 GCN 来初始化 $H = M^{(0)}$,通过公_g 和式3对药物的分子图特征进行编码:

$$H^{(k+1)} = f(H^{(k)}, A) \text{ReLU}(\text{D} \text{AD} \text{HW}) \quad (3)$$

这里, $\tilde{A} = A + I$, 其中分别为 $\tilde{A} \in \mathbb{R}^{n \times n}$ 和 $I \in \mathbb{R}^{n \times n}$ 表示邻接矩阵和单位矩阵。

表示与A对应的度矩阵。

和分 $H(k) \in \mathbb{R}^{n \times k}$ 表示第k层的权重和输入,

别为

最后,药物的分子图可以表示为

$$M_G = H(K).$$

2.2.4. 使用多模态学习DTP表征

门控网络。为了更好地表征每种药物,如图所示

图2(d),我们通过以下方式学习药物多模态表征

结合其 SMILES 序列和分子图。

此外,我们开发了一个多模态门控网络

通过结合多模态表示学习和门控机制来学习 DTP 特征。

如图2(c)所示,我们采用简单的门控线性

单元 (GLU) 过滤不重要的特征并使用最大

通过公式4对特征进行池化下来采样:

$$\begin{aligned} V_S &= \text{max}(\text{GLU}(M_{S \rightarrow S} \odot \sigma(M_{S \rightarrow S} + V_S))) \\ V_G &= \text{max}(\text{GLU}(M_{G \rightarrow G} \odot \sigma(M_{G \rightarrow G} + V_G))) \\ V_P &= \text{max}(\text{GLU}(M_{P \rightarrow P} \odot \sigma(M_{P \rightarrow P} + V_P))) \end{aligned} \quad (4)$$

其中 $V_S \in \mathbb{R}^d$ 和 $V_G \in \mathbb{R}^d$ 指示药物特征向量

通过其 SMILES 序列和分子图获得,

V表示基于 $p \in \mathbb{R}^d$

序列。可学习参数, $W \in \mathbb{R}^{d \times d}$, $b \in \mathbb{R}^d$, $c \in \mathbb{R}^d$, 和 $d \in \mathbb{R}^d$ 是

$\sigma(\cdot)$, $\odot$ 和 $\text{max}(\cdot)$ 表示

S 型函数、元素乘积和最大池化,

分别。

我们通过结合药物来获取药物的序列特征

RetNet 和 GLU 的最大池化及其分子

结合 GCN 和 GLU 来绘制特征图,最大

池化。在训练过程中,我们通过均方误差 (MSE) 损失来学习药物多模态表示。我们可以更好地

保留药物在 SMILES 序列中的独特特征

和分子图通过多模态表示学习获得其共同表示时,如公式5所示:

$$\mathcal{L}_{\text{DTP}} = \frac{1}{n} \sum_{i=1}^n (V_i - V_i')^2 \quad (5)$$

其中 V_i 和 V_i' 分别表示 V 和 V' 的第 i 个特征。

最后,DTP 可以根据药物表示为

序列特征和蛋白质序列特征以及

在 $G_P \in \mathbb{R}^d$ 药物分子图特征与蛋白质

通过简单的元素与元素的乘积对序列特征进行

操作。因此, a 的最终表示

可以通过公式6将 V 和 V' 连接起来得到 DTP:

$$\begin{aligned} V_{\text{DTP}} &= \text{max}(\text{GLU}(M_{S \rightarrow S} \odot \sigma(M_{S \rightarrow S} + V_S))) \\ V_{\text{DTP}} &= \text{max}(\text{GLU}(M_{G \rightarrow G} \odot \sigma(M_{G \rightarrow G} + V_G))) \\ V_{\text{DTP}} &= \text{max}(\text{GLU}(M_{P \rightarrow P} \odot \sigma(M_{P \rightarrow P} + V_P))) \end{aligned} \quad (6)$$

2.2.5. 推理和训练。用于计算

每个DTP的相互作用概率 p , 其特征向量 f 为

通过公式7输入到 FCN:

$$p = \sigma(\delta(\delta(W + b)W + b)) \quad (7)$$

在哪里

$$W_1 \in \mathbb{R}^{4 \times 4}, W_2 \in \mathbb{R}^{4 \times 4}, W_3 \in \mathbb{R}^{4 \times 4}, W_4 \in \mathbb{R}^{4 \times 4}, b_1 \in \mathbb{R}^4, b_2 \in \mathbb{R}^4, b_3 \in \mathbb{R}^4, b_4 \in \mathbb{R}^4$$

表示可学习参数。 $\sigma(\cdot)$ 和 $\delta(\cdot)$ 表示 S 型函数

函数和 ReLU 函数。此外,我们使用

使用二元交叉熵 (BCE) 损失通过公式8来训练模型:

$$\mathcal{L}_{\text{BCE}} = \frac{1}{n} \sum_{i=1}^n -y_i \log(\hat{y}_i) - (1 - y_i) \log(1 - \hat{y}_i) + \lambda \|\Theta\|^2 \quad (8)$$

其中 y_i 和 $\hat{y}_i$ 分别表示真实标签和预测标签,

分别表示所有可学习的

参数、用于训练模型的 DTP 数量,以及

L2正则化系数。

综上所述,MGNDTI 模型的损失函数为

表示为公式9:

$$\mathcal{L}_{\text{总}} = \mathcal{L}_{\text{DTP}} + \frac{1}{M_j} \sum_{j=1}^M \mathcal{L}_{\text{BCE}}^j \quad (9)$$

最后,我们最小化 $\mathcal{L}_{\text{总}}$ 来训练 MGNDTI。

3. 结果

3.1. 实验设置。为了更好地证明

MGNDTI 性能,我们采用了

接收者操作特性 (ROC) 曲线 (AUROC),

精确召回率 (PR) 曲线下面积 (AUPRC),

准确度、F1 分数和马修斯相关系数

(MCC) 作为评价指标。

给定药物集 D_{train} 和蛋白质集 P_{train}

训练集,推断是否存在相互作用

药物 d 和蛋白质 p 在测试集中,我们进行了

通过以下综合对比实验

四种不同的设置:

- E1. 将 DTI 数据集随机划分为训练集、验证集、测试集的比例为7:1:2。
- E2. 在训练期间,药物 d 没有用于训练模型,而蛋白质 p 用于训练模型: $d \notin D_{\text{train}}$ 且 $p \in P_{\text{train}}$ 。
- E3. 在训练期间,使用药物 d 来训练模型而蛋白质 p 没有用于训练模型: $d \in D_{\text{train}}$ 且 $p \notin P_{\text{train}}$ 。
- E4. 在训练过程中,既没有使用 d 也没有使用 p 来训练模型: $d \notin D_{\text{train}}$ 且 $p \notin P_{\text{train}}$ 。

对于 E2、E3 和 E4,首先随机选择 20% 的 DTP

用于测试,其余的用于训练。接下来,

根据三种不同的设置,药物或蛋白质

分别删除。最后,剩余的测试样本

删除后,分为验证集和测试集

设定比例为1:2。

在每种情况下,我们进行了 10 次独立运行

在对数据进行分区时使用不同的随机种子

集。并根据以下因素选择了最佳性能模型

验证集中最高的 AUROC,并被评估

在测试集上。

对于 MGNDTI,我们设置 $\text{epoch_size} = 50$, $\text{batch_size} = 64$,

学习率 $= 1e-4$,学习衰减 $= 0.5$,衰减间隔 $=$

20,权重衰减 $= 1e-5$,原子维度 $= 128$,注意力头 $=$

8,GCN_layers $= 3$,RetNet_layers $= 1$,氨基酸维度 $=$

表 2. MGNDTI 与人类七条基线的比较结果 (10 次随机运行)a

方法	奥洛克	莫尔运输公司	准确性	F1分数	中冶集团
E1					
CPI-GNN	0.9329±0.0085	0.9174±0.0164	0.8899±0.0084	0.8858±0.0098	0.7798±0.0170
TransformerCPI	0.9795±0.0036	0.9745±0.0052	0.9316±0.0071	0.9223±0.0092	0.8613±0.0147
莫尔运输公司	0.9799±0.0028	0.9785±0.0044	0.9418±0.0099	0.9207±0.0291	0.8823±0.0196
巴克比	0.9670±0.0058	0.9608±0.0087	0.9181±0.0110	0.9070±0.0130	0.8341±0.0225
CPGL	0.9674±0.0052	0.9673±0.0079	0.9092±0.0123	0.9055±0.0141	0.8191±0.0238
GIFDTI	0.9690±0.0047	0.9645±0.0084	0.9091±0.0099	0.8967±0.0120	0.8161±0.0200
FOTF-CPI	0.9834±0.0024	0.9803±0.0035	0.9413±0.0074	0.9326±0.0090	0.8811±0.0149
MGNDTI	0.9855 ± 0.0031	0.9820 ± 0.0059	0.9481 ± 0.0056	0.9485 ± 0.0057	0.8951 ± 0.0111
E2					
CPI-GNN	0.7642±0.0496	0.7765±0.0444	0.7231±0.0440	0.6967±0.0540	0.4519±0.0874
TransformerCPI	0.8689±0.0140	0.8920±0.0131	0.8390 ± 0.0114	0.8110±0.0166	0.6766±0.0207
莫尔运输公司	0.8856±0.0133	0.8783±0.0152	0.8219±0.0170	0.7769±0.0263	0.6438±0.0334
巴克比	0.8286±0.0225	0.8152±0.0309	0.7518±0.0250	0.6957±0.0373	0.4992±0.0529
CPGL	0.8952±0.0119	0.9068±0.0087	0.8180±0.0187	0.8061±0.0292	0.6431±0.0286
GIFDTI	0.8698±0.0246	0.8749±0.0181	0.8010±0.0232	0.7586±0.0344	0.6022±0.0429
FOTF-CPI	0.9016±0.0087	0.8995±0.0086	0.8201±0.0224	0.7739±0.0434	0.6461±0.0370
MGNDTI	0.9162 ± 0.0188	0.9073 ± 0.0187	0.8361±0.0183	0.8481 ± 0.0196	0.6797 ± 0.0383
E3					
CPI-GNN	0.9674±0.0103	0.9656±0.0165	0.9364±0.0166	0.9305±0.0179	0.8737±0.0320
TransformerCPI	0.9569±0.0069	0.9495±0.0063	0.8934±0.0140	0.8661±0.0218	0.7836±0.0249
莫尔运输公司	0.9738±0.0054	0.9699±0.0080	0.9448 ± 0.0115	0.9199±0.0211	0.8874 ± 0.0233
巴克比	0.9790±0.0090	0.9790 ± 0.0077	0.9410±0.0158	0.9279±0.0192	0.8800±0.0307
CPGL	0.9240±0.0166	0.9326±0.0139	0.8478±0.0284	0.8239±0.0471	0.7023±0.0467
GIFDTI	0.9413±0.0103	0.9357±0.0127	0.8711±0.0170	0.8469±0.0213	0.7379±0.0345
FOTF-CPI	0.9734±0.0070	0.9728±0.0059	0.9221±0.0099	0.9014±0.0150	0.8426±0.0196
MGNDTI	0.9795 ± 0.0079	0.9785±0.0061	0.9401±0.0178	0.9395 ± 0.0151	0.8789±0.0335
E4					
CPI-GNN	0.6929±0.0562	0.6771±0.0450	0.6265±0.0351	0.4985±0.0551	0.2800±0.0691
TransformerCPI	0.7387±0.0201	0.7475±0.0212	0.7095±0.0209	0.5835±0.0350	0.4261±0.0370
莫尔运输公司	0.6969±0.0187	0.6377±0.0198	0.5891±0.0426	0.3258±0.1520	0.2760±0.0680
巴克比	0.7682±0.0283	0.7186±0.0327	0.6365±0.0442	0.3516±0.1836	0.2599±0.1331
CPGL	0.7658±0.0245	0.7390±0.0267	0.5725±0.0659	0.2447±0.2166	0.1784±0.1534
GIFDTI	0.7475±0.0298	0.7406±0.0241	0.6918±0.0180	0.5545±0.0471	0.3856±0.0345
FOTF-CPI	0.7250±0.0315	0.6766±0.0353	0.6222±0.0294	0.3301±0.1123	0.2496±0.0525
MGNDTI	0.8106 ± 0.0228	0.7780 ± 0.0278	0.7180 ± 0.0446	0.7708 ± 0.0219	0.4862 ± 0.0618

注:最好结果以粗体标记,次好结果以下划线标记。

128,FCN_hidden_size = 512。此外,我们选择了以最佳 F1 分数下的阈值作为分类临界点。

3.2. 基线方法。评估 MGNDTI

性能方面,我们将其与七条基线进行了比较。他们的来源代码是从相应的存储库下载的,并且在同一个实验中重新评估了表演环境。它们的超参数明确设置为相应的默认值。

- CPI-GNN:58 个CPI-GNN 首先编码了药物的特征分别使用 GNN 和 1D-CNN 来识别蛋白质,并研究了子序列的重要性蛋白质与具有单侧注意机制的药物,最后通过 FCN 预测 DTI。
- TransformerCPI:59 TransformerCPI 采用 CNN 和 GCN 从氨基酸中提取蛋白质特征来自 SMILES 的序列和药物特征序列。然后利用 Transformer 解码器将学习到的特征转换成

FCN 用于预测。

- MolTrans:50 种MolTrans 编码的药物和蛋白质根据 Transformer 序列的特征,

构建了一个基于编码的交互矩阵特征,并最终通过 CNN 进行预测和 FCN。

- BACPI:60 BACPI 掺入药物和蛋白质双向注意神经网络的表征并用分类器实现预测。
- CPGL:61 CPGL 优化药物特征表示通过图形注意网络和蛋白质特征通过长期短期记忆进行表征神经网络增强鲁棒性和模型的泛化能力。
- GIFDTI:62 个GIFDTI 从他们的 SMILES 序列和蛋白质特征通过 CNN 和 Transformer 的氨基酸序列,然后提取全局特征以及 DTP 的分子间相互作用特征分类。
- FOTF-CPI:63 FOTF-CPI 合并了基于传输的最优碎片模型和融合注意力预测机制。

3.3. MGNDTI 与 7 条基线的比较。在本节中,我们将 MGNDTI 与 7 个基线进行了比较

表 3. MGNDTI 与 7 条基线在秀丽隐杆线虫上的比较结果 (10 次随机运行)a

方法	奥洛克	莫尔运输公司	准确性	F1分数	中冶集团
E1					
CPI-GNN	0.9536±0.0079	0.9422±0.0121	0.9146±0.0100	0.9185±0.0088	0.8292±0.0201
TransformerCPI	0.9919 ± 0.0015	0.9916±0.0018	0.9608±0.0045	0.9608±0.0044	0.9217±0.0089
莫尔运输公司	0.9918±0.0024	0.9920 ± 0.0028	0.9670±0.0032	0.9626±0.0047	0.9342±0.0064
巴克比	0.9864±0.0044	0.9869±0.0039	0.9489±0.0114	0.9487±0.0117	0.8981±0.0227
CPGL	0.9757±0.0034	0.9797±0.0029	0.9265±0.0117	0.9288±0.0103	0.8538±0.0224
GIFDTI	0.9827±0.0068	0.9843±0.0056	0.9435±0.0110	0.9435±0.0116	0.8873±0.0221
FOTF-CPI	0.9919±0.0030	0.9909±0.0054	0.9663±0.0051	0.9661±0.0052	0.9328±0.0101
MGNDTI	0.9912±0.0022	0.9916±0.0020	0.9682 ± 0.0051	0.9682 ± 0.0050	0.9365 ± 0.0102
E2					
CPI-GNN	0.6830±0.0649	0.7278±0.0391	0.6320±0.0584	0.6038±0.0763	0.2844±0.1126
TransformerCPI	0.8076±0.0151	0.8657±0.0122	0.7623±0.0244	0.7299±0.0453	0.5551±0.0285
莫尔运输公司	0.8259±0.0290	0.8595±0.0259	0.7465±0.0298	0.7202±0.0314	0.5014±0.0616
巴克比	0.8083±0.0280	0.8315±0.0294	0.7079±0.0272	0.6653±0.0427	0.4435±0.0526
CPGL	0.8625±0.0231	0.8897±0.0130	0.7546±0.0323	0.7335±0.0587	0.5464±0.0500
GIFDTI	0.8516±0.0244	0.8819±0.0143	0.7656±0.0174	0.7399±0.0219	0.5549±0.0281
FOTF-CPI	0.8712±0.0213	0.8913±0.0188	0.7861±0.0228	0.7605±0.0415	0.5993±0.0334
MGNDTI	0.8985 ± 0.0161	0.9134 ± 0.0084	0.8188 ± 0.0232	0.8215 ± 0.0229	0.6410 ± 0.0481
E3					
CPI-GNN	0.8998±0.0330	0.9007±0.0419	0.8351±0.0409	0.8199±0.0531	0.6797±0.0810
TransformerCPI	0.9470±0.0141	0.9486±0.0159	0.8523±0.0439	0.8262±0.0660	0.7204±0.0728
莫尔运输公司	0.9457±0.0166	0.9542±0.0116	0.9034±0.0164	0.8330±0.0508	0.8069±0.0324
巴克比	0.9438±0.0166	0.9528±0.0106	0.8657±0.0183	0.8422±0.0232	0.7494±0.0292
CPGL	0.8641±0.0231	0.8868±0.0234	0.7644±0.0456	0.7133±0.0743	0.5666±0.0759
GIFDTI	0.9408±0.0122	0.9444±0.0126	0.8523±0.0314	0.8273±0.0441	0.7192±0.0529
FOTF-CPI	0.9438±0.0096	0.9514±0.0082	0.8497±0.0211	0.8181±0.0306	0.7238±0.0349
MGNDTI	0.9636 ± 0.0096	0.9684 ± 0.0055	0.9193 ± 0.0111	0.9181 ± 0.0107	0.8388 ± 0.0222
E4					
CPI-GNN	0.5842±0.0588	0.5717±0.0515	0.5166±0.0423	0.3096±0.1012	0.0625±0.1052
TransformerCPI	0.6262±0.0608	0.6213±0.0643	0.5537±0.0358	0.2706±0.1324	0.1414±0.0973
莫尔运输公司	0.5983±0.0279	0.6174±0.0347	0.5089±0.0150	0.2489±0.1162	0.0779±0.0440
巴克比	0.6662±0.0405	0.6583±0.0342	0.5621±0.0333	0.2974±0.1069	0.1715±0.0724
CPGL	0.6827±0.0608	0.6942±0.0759	0.5028±0.0389	0.0852±0.1722	0.0385±0.0873
GIFDTI	0.7172±0.0342	0.7146±0.0391	0.6221±0.0495	0.4623±0.1736	0.2856±0.0930
FOTF-CPI	0.6561±0.0355	0.6430±0.0423	0.5577±0.0254	0.2914±0.1338	0.1653±0.0635
MGNDTI	0.7301 ± 0.0427	0.7252 ± 0.0382	0.6555 ± 0.0514	0.7239 ± 0.0238	0.3601 ± 0.0826

注:最好结果以粗体标记,次好结果以下划线标记。

在四种不同的实验环境下对人类、秀丽隐杆线虫、BioSNAP 和 BindingDB 基准数据集进行分析。

如表 2和表 3所示,我们提出的 MGNDTI 方法

表现优于基于 AUROC 的七个基线,

AUPRC、准确率、F1 分数和 MCC 在人类和

在四种不同的实验环境下对秀丽隐杆线虫进行了检测。尤其值得一提的是,MGNDTI 的性能得到了显著提升

在 E4 条件下对人类进行研究。其计算的 AUROC 提高了 4.24% (从 0.7682 到 0.8106) ,AUPRC 增长 3.05% (从 0.7475 至 0.7780) ,准确率提高 0.85% (从 0.7095 至 0.7180) , F1 得分提高 18.73% (从 0.5835 提高到 0.7708) ,MCC 提高 6.01% (从 0.4261 到 0.4862) 。

在秀丽隐杆线虫上, MGNDTI 在所有方面都超过了七条基线 E2、E3 和 E4 下的评估指标。在 E1 下,虽然 MGNDTI 在 AUROC 和 AUPRC 上的表现略逊于其他公司,下降幅度很小,只有 0.07% (从 0.9919 到 0.9912)和0.04%(从0.9920到0.9916),更多重要的是,它提高了准确率、F1 分数和 MCC,准确率提高 0.12% (从 0.9670 到 0.9682) ,F1-得分提高 0.21% (从 0.9661 提高到 0.9682) ,MCC 提高 0.23% (从 0.9342 到 0.9365) 。

图 3描绘了 MGNDTI 和

BioSNAP 和 BindingDB 上的七个基线在四个

实验设置。在 E1 和 E2 设置下,MGNDTI

显著优于七种基线方法

BindingDB 数据集,其性能与

BioSNAP 数据集上的最佳基线方法。在 E3

和 E4 设置,MGNDTI 达到基线水平

两个数据集。AUROC、AUPRC、准确率、MGNDTI 和基线的 F1 分数和 MCC 列于

表 S1 和 S2支持信息和

<https://github.com/plhnnu/MGNDTI/tree/main/results>

综上所述,我们提出的 MGNDTI 模型阐明了

与四项七项基线相比,性能出色

四种不同实验设置的数据集,表现出强大的鲁棒性和泛化能力

做出 DTI 预测。

3.4. 消融实验。评估特征

编码器 (即 GCN 和 RetNet) 、多模态表示

药物和 DTI 上的多模态门控网络

预测,我们进行了以下三次消融

实验:




图 3. MGNDTI 和七个基线在 BioSNAP 和 BindingDB 上的 AUROC 和 AUPRC (10 次随机运行)。

- (1)为了验证特征提取器 GCN 和 RetNet 在模型中的贡献,我们研究了 MGNDTI 的三种变体:TransDTI (即用 Transformer 替换 RetNet)、SRetDTI (即两个具有共享权重的 RetNet)和 GATDTI (即用 GAT 替换 GCN)。

如图4所示,在四种实验设置下,MGNDTI的AUROC和AUPRC值均高于 TransDTI和SRetDTI。在提取药物和蛋白质特征时,两个不共享参数的 RetNet特征提取器比两个共享参数的RetNet更有效。

此外,RetNet 在提取药物和蛋白质特征方面优于 TransDTI 和 Transformer。此外,MGNDTI 在 Human 和 BindingDB 数据集上的表现优于 GATDTI。在C.elegans 和 BioSNAP 数据集上,MGNDTI 和 GATDTI 的表现基本相当。因此,我们基于 RetNet 和 GLU 提取药物序列特征,并基于 GCN 和 GLU 进行药物分子图特征编码,并采用最大池化。

- (2)为了比较药物单模态和多模态对 DTI 预测的作用,我们研究了两种基于药物单模态和多模态的 MGNDTI 变体:SGNDTI (药物 SMILES 序列 + 蛋白质序列)和 GGNDTI (药物分子图 + 蛋白质序列)。

图 5展示了 MGNDTI 在药物单模态和多模态下的表现。如图5 所示, MGNDTI 的表现明显优于其他

在所有四种实验设置下都存在两种单模态变体。因此,多模态有助于提高DTI 预测准确性。

- (3)为了分析多模态门控网络及其具有 MSE 损失的 GLU 在药物多模态学习中的作用,我们考虑了 MGNDTI 的另外三种变体:CatDTI (即没有多模态门控网络的 MGNDTI)、MSEDTI (即没有 GLU 的 MGNDTI)和 GLUDTI (即没有多模态表征学习的 MGNDTI)。

类似地,如图6所示,采用多模态门控网络 (GLU + MSE损失)的MGNDTI对其他三个变体获得了最佳预测,证明了多模态门控网络强大的学习能力。在BioSNAP和 BindingDB上的消融实验列于支持信息中的图S2,S3和S4中。以及<https://github.com/plhnu/MGNDTI/tree/main/ablation>。

3.5 可视化与模型分析为了研究具有或不具有 MSE 损失的 MGNDTI (即具有多模态表示学习的 MGNDTI)中的多模态特征 (即来自其 SMILES 字符串的药物特征,来自其分子图的药物特征以及来自其序列的蛋白质特征)的分布,我们对四个数据集执行了特征可视化操作:我们首先在训练集上训练 MGNDTI,然后随机选择 1,200 个样本并使用测试集上预先训练的 MGNDTI 提取它们的多模态特征,最后通过 UMAP 降低这些特征的维数并进行可视化分析。




图 4.在四种实验设置 (10 次随机运行)下对人类和秀丽隐杆线虫的特征编码器 (GCN 和 RetNet)进行的消融实验。

图 7展示了 MGNDTI 中三类特征在人类和秀丽隐杆线虫上 (有无 MSE 损失)的分布情况。在人类上,对于无 MSE 损失的 MGNDTI,所得特征分布相对稀疏,而来自其 SMILES 序列的药物特征分布则极其稀疏。然而,在有 MSE 损失的 MGNDTI 中,这些分布变得相对密集,并形成了三个聚类。在秀丽隐杆线虫上,无论 MGNDTI 是否有 MSE 损失,来自其 SMILES 序列的药物特征分布始终稀疏,但其他两种分布始终密集。BioSNAP 和 BindingDB 上的特征可视化分布列于支持信息中的图 S5 中。以及<https://github.com/plhnu/MGNDTI/tree/main/feature>。

模型在训练过程中的复杂度。模型复杂度通过参数数量和浮点运算次数 (FLOP)来评估。

表 4展示了 MGNDTI 与 7 种基线方法在 FLOPs、参数数量和 GPU 内存使用情况方面的比较: (1)FLOPs:MGNDTI 的 FLOPs 为 6.542G,远少于 MolTrans、BACPI、GIFDTI 和 FOTF-CPI。 (2)参数数量:MGNDTI 的参数数量为 0.655M,少于 MolTrans、GIFDTI 和 FOTF-CPI。 (3)

GPU内存占用:MGNDTI的GPU内存占用为4.038GB,远低于Trans-formerCPI、MolTrans、BACPI、GIFDTI和FOTF-CPI。综合来看,MGNDTI在计算效率和资源占用方面优于大多数基线,且参数数量适中。

此外,我们分析了训练过程中随着epoch数变化的MSE Loss、BCE Loss和Total Loss (Total Loss = MSE Loss + BCE Loss)。如图8所示,MSE Loss急剧下降后迅速趋于稳定,而BCE Loss下降相对较慢。此外,Total Loss在两个小型数据集 (例如Human和C.elegans)上在Epoch = 20时趋于稳定,在两个较大的数据集 (BioSNAP和BindingDB)上在Epoch = 40时趋于稳定。更重要的是,BCE Loss和Total Loss在BioSNAP和BindingDB上分别在Epoch = 20和Epoch = 40时显著下降。此外,decay_interval = 20的学习率衰减可以加速模型训练。

最后,我们分析了 MGNDTI 和基线方法的 GPU 内存消耗和模型复杂度。GPU 内存消耗是通过

3.6. 案例研究。为了进一步验证 MGNDTI 的有效性,我们从以下几个方面进行了案例研究:预测奥氮平 (DrugBank ID:DB00334)和丙戊酸 (DrugBank ID:DB00313)两种药物的潜在相互作用靶点,并基于预训练的 MGNDTI 模型推断 CYP2D6 (UniProt ID:P10635)和 CYP2C8 (UniProt ID:P10632)两种靶点的潜在药物。并通过 DrugBank 数据库进一步验证了预测的相互作用。

奥氮平是一种抗精神病药物,用于治疗精神分裂症和 1 型双相情感障碍。64,65丙戊酸是一种抗惊厥药,用于控制复杂部分性癫痫发作以及简单和复杂的失神发作。66,67




图 5.在四种实验设置下对人类和秀丽隐杆线虫进行药物多模态消融实验（10 次随机运行）。




图 6.在四种实验设置下对人类和秀丽隐杆线虫的多模态门控网络进行消融实验（10 次随机运行）。




图 7.多模态特征可视化分布。在 MGNDTI 中,使用 UMAP 对人类和秀丽隐杆线虫的多模态特征进行可视化,无论是否带有 MSE 损失。

如表5所示, MGNDTI成功预测了两种药物的前10个候选靶点。奥氮平预测的前10个靶点均已通过DrugBank数据库验证。丙戊酸预测的前10个靶点中,大多数也已通过DrugBank数据库验证。

我们预测两个蛋白质 (即P15509和P04183)可能与DB00313相互作用。为了进一步验证上述结果,如图9所示,我们使用分子对接工具CB-Dock268对这两个蛋白质与DB00313进行了分子对接。它们的结合亲和力均为-5.0 kcal/mol,进一步说明它们与丙戊酸具有更高的相互作用概率。

CYP2D6 和 CYP2C8 蛋白是重要的药物代谢酶。CYP2D6 参与了临床上 25% 以上常用药物的代谢。69 CYP2C8 代谢 100 多种药物,在人体肝脏中高表达。70

如表6所示, MGNDTI推断出了CYP2D6和CYP2C8的前10个候选药物。所有预测的候选药物均经DrugBank数据库验证与这两个靶点存在相互作用。综上所述,案例研究结果表明, MGNDTI能够从大量样本中精准识别未知药物与靶点的潜在相互作用候选药物,展现了其对药物重新定位的重要意义。

4.讨论

在本研究中,我们提出了一种基于多模态表征学习和门控机制的深度学习模型 MGNDTI,用于 DTI 预测。MGNDTI 首先学习

该方法通过使用不同的RetNets来构建药物和靶序列的表征。接下来,该方法通过GCN提取药物分子图特征。随后,设计了一个简单的多模态门控网络来获取DTP特征向量。最后,构建了一个FCN来对DTP进行分类。

我们进行了深入的对比实验。首先,在四种不同的实验设置下,使用四个数据集 (即Human、*C. elegans*、BioSNAP和BindingDB) ,将MGNDTI与七个基线DTI预测模型 (CPI-GNN、TransformerCPI、MolTrans、BACPI、CPGL、GIFDT和FOTF-CPI)进行了对比。通过AUROC、AUPRC、准确率、F1分数和MCC的评估, MGNDTI的表现优于上述七个基线模型,展现了其强大的鲁棒性和泛化能力。此外,与四种基于注意力机制的方法 (即CPI-GNN、TransformerCPI、BACPI和FOTF-CPI)相比, MGNDTI获得了最佳性能,验证了多模态门控网络有助于学习药物与靶标之间的相互作用表征。

此外,我们进行了三次消融实验。结果表明, RetNet 和 GCN 能够有效提取药物或蛋白质序列及分子图特征,且药物多模态特征相较于其单模态特征可以进一步提升 DTI 预测效果。此外,相比 MGNDTI 的其他三种变体: CatDTI、MSEDTI 和 GLUDTI,采用多模态门控网络的 MGNDTI 能够更高效地学习 DTP 特征。随后,我们对药物多模态特征和蛋白质序列特征进行了可视化,可视化结果清晰地描绘了三类特征的分布。最后,结果




图 8. Human、C.elegans、BioSNAP 和 BindingDB 数据库。

表 4. MGNDTI 与七种基线的比较
基于 GPU 内存使用情况的方法，
参数和 FLOP

方法	失败次数	参数	GPU内存
CPI-GNN	1.649克	0.003 米	0.459 GB
TransformerCPI	2.232克	0.349 米	6.037 GB
莫尔运输公司	137.373克	47.163 米	14.024 GB
巴克比	15.305克	0.195 米	10.877 GB
CPGL	0.728克	0.012 米	2.564 GB
GIFDTI	619.523克	20.759 米	24.370 GB
FOTF-CPI	135.493克	36.128 米	11.326 GB
MGNDTI	6.542克	0.655 米	4.038 GB

表 5. 预测与
MGNDTI 的奥氮平和丙戊酸

秩	奥氮平 (DB00334)		丙戊酸 (DB00313)	
	UniProt 识别码	结果	UniProt 识别码	结果
1	P11229	真的	P15509	未知
2	P41595	真的	P05177	真的
3	P78334	真的	Q92769	真的
4	P05177	真的	P08684	真的
5	P10635	真的	P23219	真的
6	P28221	真的	Q99250	真的
7	P50406	真的	P33260	真的
8	Q9UN88	真的	Q9HAW8	真的
9	Q99928	真的	P04183	未知
10	P14416	真的	P22310	真的

案例研究表明,所有预测的前 10 个目标
奥氮平、丙戊酸的大多数预测目标,以及
CYP2D6 和 CYP2C8 的所有前 10 个预测都已
经 DrugBank 数据库验证。

我们仍然比较了 FLOP、模型参数数量、
MGNDTI 和 7 个 GPU 内存消耗
基线方法。结果表明, MGNDTI

优于大多数基于
计算效率和资源利用率。此外,
MGNDTI 具有适度数量的参数。在
训练时,训练损失会随着 epoch 数的变化而变化。
此外,学习率衰减加快了模型训练。
在优化过程中, MGNDTI 相对容易
训练,其训练损失稳步下降,阐明了其
稳健性和可靠性。

MGNDTI 可以准确推断潜在的 DTI,并且可能
归因于以下两个特点。(i)大多数现有的药物
特征提取方法基于单峰策略
并且无法完全学习药物丰富的特征。相比之下,我们
使用 RetNet 和 GCN 提取药物多模态特征
并学习药物多模态表征。(ii)大多数 DTI
预测方法利用注意力机制来学习
药物与靶标之间的相互作用表示,
导致计算负担过重。在这种情况下,我们
设计了一个简单的多模态网络,以降低计算复杂度并减轻计算
负担。

综上所述,我们提出的 MGNDTI 模型准确
捕获了 DTI 候选。考虑到 3D 结构
蛋白质有助于它们的特征学习,在未来,
我们将充分利用它们的 3D 结构进行 DTI 预测
通过 DeepMind 的 AlphaFold.71此外,非编码




图 9.使用 CB-Dock2 对两种蛋白质 (P15509 和 P04183) 和 DB00313 进行分子对接。

表 6. 预测与药物相互作用的前 10 种候选药物
MGNDTI 的 CYP2D6 和 CYP2C8

秩	CYP2D6 (P10635)		CYP2C8 (P10632)	
	DrugBank ID	结果	DrugBank ID	结果
1	DB00521	真的	DB01050	真的
2	DB00627	真的	DB00945	真的
3	DB00316	真的	DB01435	真的
4	DB01182	真的	DB01201	真的
5	DB05109	真的	DB00495	真的
6	DB05271	真的	DB00938	真的
7	DB01151	真的	DB08901	真的
8	DB00281	真的	DB08828	真的
9	DB01698	真的	DB00451	真的
10	DB01191	真的	DB00604	真的

RNA 一直是一类重要的药物靶点。因此,我们将进一步分析药物与非编码RNA。具体来说,在MGNDTI模型中,我们将用非编码RNA取代蛋白质作为输入模型并重新设计 RetNet 以提取非编码特征 RNA 用于预测相互作用的概率药物和非编码RNA。

5. 结论

在本文中,我们提出了一种端到端深度学习基于 MGNDTI 的 DTI 识别模型多模态表征学习和门控机制。MGNDTI 在四个不同的实验条件下的四个基准数据集设置。此外,它预测 P15509 和 P04183 可以与丙戊酸有相互作用,需要进一步验证。我们预计提出的 MGNDTI 模型可以促进药物发现和重新利用。

■相关内容

数据可用性声明

所有数据均来自公开资源。BindingDB 和 BioSNAP 数据集可以从<https://github.com/peizhenbai/DrugBAN>下载。人类和秀丽隐杆线虫数据集可以从https://github.com/masashitsubaki/CPI_预测下载。支持信息源代码可在<https://github.com/plhnnu>获取。MGNDTI。

支持信息

支持信息可在以下网址免费获取
<https://pubs.acs.org/doi/10.1021/acs.jcim.4c00957>。

(1) C.elegans 和 BindingDB 数据集的统计直方图。

(2) AUROC, AUPRC, 准确率, F1-分数, 以及由 MGNDTI 和七个在 BindingDB 和 BioSNAP 上的基线方法四种实验设置。(3) 消融结果 MGNDTI 在 BindingDB 和 BioSNAP 上的实验。

(4) UMAP 可视化特征分布 BindingDB 和 BioSNAP (PDF)

■作者信息

通讯作者

陈敏一 计算机科学与工程学院
Hunan Institute of Technology, Hengyang, Hunan 421002,
中国; 邮箱: chenmin@hnit.edu.cn
周立乾一 湖南省生命科学与化学学院
株洲工业大学, 湖南株洲 412007;
邮箱: zhoulq11@163.com

作者

彭立红一 湖南省生命科学与化学学院
株洲工业大学, 湖南株洲 412007;
orcid.org/0000-0002-2321-3901

刘欣—湖南省生命科学与化学学院
株洲工业大学,湖南株洲 412007;
orcid.org/0009-0009-8661-9288
廖文—湖南大学计算机学院
Technology, Zhuzhou, Hunan 412007, China
毛家乐—湖南大学计算机学院
Technology, Zhuzhou, Hunan 412007, China

完整的联系信息请访问: <https://pubs.acs.org/10.1021/acs.jcim.4c00957>

资助项

目:周立乾获得国家自然科学基金(项目编号:62072172)资助。彭立红获得国家自然科学基金(项目编号:61803151)、湖南省自然科学基金(项目编号:2023JJ50201)和湖南省教育厅科研项目(项目编号:23A0418)资助。陈敏获得湖南省自然科学基金(项目编号:2024JJ7115)资助。

笔记

作者声明不存在竞争性经济利益。

参考文献

(1) 王琳;游志华;陈晓;闫晓玲;刘刚;张伟。
Rfdt:一种基于旋转森林的预测器,利用药物结构和蛋白质序列信息预测药物-靶标相互作用。
Curr. Protein Pept. Sci. 2018, 19, 445–454。
(2) Baruah, S.;Devi, D.使用机器学习模型集成对药物-靶标相互作用检测方法进行比较分析。生物化学和生物信息学2024,21-29。
(3) 彭玲;刘晓玲;杨玲;刘琳;白哲;陈敏;陆晓玲;景玲。BINDTI:一种基于注意力机制的药物-靶标相互作用识别双向意向网络。IEEE 生物医学和健康信息学杂志2024。
(4) Song, W.;Xu, L.;Han, C.;Tian, Z.;Zou, Q.基于多视图相似性网络融合策略和深度交互注意机制的药物-靶标相互作用预测。生物信息学2024, 40, No. btae346, DOI:10.1093/bioinformatics/btae346。
(5) Iliadis, D.;De Baets, B.;Pahikkala, T.;Waegeman, W.嵌入聚合策略在药物-靶标相互作用预测中的比较。BMC Bioinf.2024,25,59。
(6) Trott, O.;Olson, A.J. AutoDock Vina :通过新的评分函数、高效的优化和多线程技术提高对接的速度和准确性。J. Comput. Chem. 2010, 31, 455–461。
(7) Pinzi, L.;Rastelli, G.分子对接:药物发现的范式转变。国际分子科学杂志2019,20,4331。
(8) Hollingsworth, SA;Dror, RO, 《面向所有人的分子动力学模拟》神经元2018,99, 1129–1143。
(9) 彭, L.;任, M.;黄, L.; Chen, M. GENDDn: lncRNA-基于双网络的疾病关联识别框架
神经架构和深度神经网络。跨学科科学:计算生命科学2024, 16, 418。
(10) 彭玲;黄玲;苏倩;田刚;陈敏;韩刚。LDA-VGHB:使用奇异值分解、变分图自动编码器和异构牛顿增强机识别潜在的 lncRNA 疾病关联。简报Bioinf.2023, 25, bbad466。
(11) 彭玲;谭建;熊伟;张琳;王哲;袁荣;李哲;陈霞。基于集成深度学习和单细胞转录组数据联合评分策略解读配体-受体介导的细胞间通讯。计算机生物学。

和。2023,163,107137。

(12) Peng, L.; Yuan, R.; Han, C.; Han, G.; Tan, J.; Wang, Z.; Chen, M.; Chen, X. Cellenboost:一种基于增强的配体受体

用于细胞间通讯推断的相互作用识别模型。IEEE 传输。纳米生物科学。2023, 22, 705–715。

(13) Peng, L.; Xiong, W.; Han, C.; Li, Z.; Chen, X. CellDialog:用于配体-受体介导的细胞间通讯分析的框架。IEEE 生物医学和健康信息学杂志2024, 28, 580–591。

(14) Peng, L.; Gao, P.; Xiong, W.; Li, Z.; Chen, X. 基于梯度增强神经网络和可解释增强机识别潜在的配体-受体相互作用以进行细胞间通讯分析。计算。生物。医学。2024, 171, 108110。

(15) 苏瑞; 吴华; 刘晓玲; 魏玲。基于生物特征图谱和多样化分类策略预测药物引起的肝毒性。简报Bioinf.2021,22,428–437。

(16) He, Z.; Zhang, J.; Shi, X.-H.; Hu, L.-L.; Kong, X.; Cai, Y.-D.; Chou, K.-C.根据功能组和生物学特征预测药物-靶标相互作用网络。PLoS One 2010,5, e9603。

(17) 范拉厄霍芬, T.; 纳布尔斯, SB; Marchiori, E. 高斯相互作用轮廓核用于预测药物-靶标相互作用。
生物信息学2011,27,3036-3043。

(18) 季秉英;游志华;姜华军;郭志华;郑凯。
基于LINE网络表示方法的多分子网络预测药物-靶标相互作用。J.翻译。医学。2020年18月1–11日。

(19) 彭丽;廖斌;朱伟;李哲;李凯。利用多信息融合预测药物-靶标相互作用。IEEE 生物医学和健康信息学杂志2017,21,561-572。

(20) Ding, Y.; Tang, J.; Guo, F.; Zou, Q. 通过基于多个核的三重协作矩阵分解识别药物-靶标相互作用。简报Bioinf.2022, 23, bbab582。

(21) Li, Y.; Liu, X.-Z.; You, Z.-H.; Li, L.-P.; Guo, J.-X.; Wang, Z. 一种根据蛋白质序列和药物亚结构指纹信息预测药物-靶标相互作用的计算方法。

国际智能系统杂志2021,36,593–609。

(22) Ru, X.; Zou, Q.; Lin, C. 通过特征处理方案优化药物靶标亲和力和预测方法。生物信息学2023, 39, btad615。

(23) 谢哲;涂胜;徐玲。具有半监督领域自适应的多层注意力网络用于药物靶点预测。AAAI 2024人工智能会议论文集, 38,329-337。

(24) Xu, J.; Xu, J.; Meng, Y.; Lu, C.; Cai, L.; Zeng, X.; Nussinov, R.; Cheng, F. 图嵌入和高斯混合变分自动编码器网络用于单细胞 RNA 测序数据的端到端分析。Cell Reports Methods 2023, 3, 100382。

(25) 孙英;李英;梁志强;胡平。iNGNN-DTI:使用可解释的嵌套图神经网络和预训练分子模型预测药物-靶标相互作用。生物信息学2024, 40, btae135。

(26) 吴玲;黄燕;谭晨;高哲;胡斌;林华;刘哲;李思哲PSC-CPI:多尺度蛋白质序列结构对比,实现高效、可推广的化合物-蛋白质相互作用预测。AAAI 2024人工智能会议论文集, 38,310-319。

(27) Nguyen, T.; Le, H.; Quinn, TP; Nguyen, T.; Le, TD; Venkatesh, S. GraphDTA:使用图神经网络预测药物-靶标结合亲和力。生物信息学2021, 37, 1140–1147。

(28) Lee, I.; Keum, J.; Nam, H. DeepConv-DTI:通过对蛋白质序列进行卷积深度学习来预测药物-靶标相互作用。PLoS Comput. Biol. 2019, 15, e1007129。

(29) Zhong, K.-Y.; Wen, M.-L.; Meng, F.-F.; Li, X.; Jiang, B.; Zeng, X.; Li, Y. MMDTA:一种具有混合融合策略的药物-靶点亲和力和多模态深度模型。J. Chem. Inf. Model. 2024, 64, 2878–2888。

(30) Yang, X.; Yang, G.; Chu, J. GraphCL-DTA:用于药物-靶标结合亲和力和预测的具有分子语义的A-Graph对比学习。IEEE 生物医学和健康信息学杂志2024,1-10。

(31) Wang, J.; Li, X.; Zhang, H. GNN-PT:通过整合蛋白质转换器增强化合物-蛋白质相互作用的预测。arXiv 2020.Doi:10.48550/arXiv.2009.00805

(32)孟宇;王.Y.;徐.J.;卢.C.;唐.X.;彭.T.;张.B.;田.G.; Yang,J.基于加权局部信息增强图神经网络的药物重新定位.简报 Bioinf. 2023,25 , bbad431。

(33) Bai, P.;Miljkovic, F.;John, B.;Lu, H.具有领域自适应性的可解释双线性注意力网络改善了药物靶标预测.自然机器学习2023,5,126-136。

(34) Tang, X.; Zhou, C.; Lu, C.; Meng, Y.; Xu, J.; Hu, X.; Tian, G.; Yang, J. 通过双线性注意力网络的局部交互学习增强药物重新定位。IEEE 生物医学和健康信息杂志; 2023 年。

(35) Zeng, P.; Zhang, B.; Liu, A.; Meng, Y.; Tang, X.; Yang, J.; Xu, J. 基于三部分跨网络嵌入和图卷积网络的药物重新定位。专家系统及其应用2024,252, 124152。

(36)Wang,R.;Jin,J.;Zou,Q.;Nakai,K.;Wei,L.通过可解释的深度学习预测蛋白质-肽结合残基.生物信息学2022, 38, 3351—3360。

(37) Zhou, Z.; Liao, Q.; Wei, J.; Zhuo, L.; Wu, X.; Fu, X.; Zou, Q. 重新审视药物-蛋白质相互作用预测:一种新颖的全局-局部视角.生物信息学2024, 40, btae271。

(38)郑S.;李.Y.;陈.S.;徐.J.。 Yang, Y.使用准视觉问答系统预测药物-蛋白质相互作用。自然机器学习2020,2,134-140。

(39)Vaswani,A.;沙泽尔,N.;帕玛尔,N.; Uszkoreit,J.;琼斯,L.;戈麦斯,AN;凯撒,.; Polosukhin,J. 你所需要的只是关注.神经信息处理系统的进展; Curran Associates,2017 年;卷30。

(40) Li,F.;Zhang,Z.;Guan,J.;Zhou,S. 利用相互作用神经网络有效预测药物-靶标相互作用。生物信息学2022, 38, 3582—3589。

(41)Zhao, Q.;Zhao, H.;Zheng, K.;Wang, J. HyperAttentionDTI:通过基于序列的深度学习和注意力机制改进药物-蛋白质相互作用预测.生物信息学2022, 38, 655—662。

(42) Yazdani-Jahromi,M.;Yousefi,N.;Tayebi,A.;Kolanthai,E.;Neal,CJ;Seal,S.;Garibay, OO AttentionSiteDTI:一种基于图的可解释模型,使用 NLP 句子级关系分类进行药物-靶标相互作用预测.简报Bioinf.2022 , 23, bbac272。

(43)Huang, L.;Lin, J.;Liu, R.;Zheng, Z.;Meng, L.;Chen, X.;Li, X.;Wong, K.-C. CoaDTI:基于多模态共同注意的药物-靶标相互作用注释框架.简报Bioinf.2022 , 23, bbac446。

(44) Bian, J.;Zhang, X.;Zhang, X.;Xu, D.;Wang, G. MCANet:基于共享权重的 MultiheadCrossAttention网络,用于药物-靶标相互作用预测.简报Bioinf.2023,24 , bbad082。

(45)Qian, Y.; Li, X.; Wu, J.; Zhang, Q. MCL-DTI:利用药物多模态信息和双向交叉注意力学习方法预测药物-靶标相互作用。BMC Bioinf.2023,24,323。

(46) Hong,Z.;Zeng,X.;Wei,L.;Liu,X.基于预训练的DNA载体和注意力机制,利用神经网络识别增强子-启动子相互作用.生物信息学2020, 36, 1037—1043。

(47) De, S.;Smith, SL;Fernando, A.;Botev, A.;Cristian-Muraru, G.;Gu, A.; Haroun, R.;Berrada, L.;Chen, Y.;Srinivasan, S.;Desjardins, G.;Doucet, A.;Budden, D.;Teh, YW;Pascanu, R.;Freitas, ND;Gulcehre, C. Griffin:《将门控线性递归与局部注意力相结合,实现高效语言模型》。arXiv 2024。(48) van den Oord, A.;Kalchbrenner, N.;Espeholt, L.;kavukcuoglu, k.;Vinyals, O.;Graves, A. 使用 PixelCNN 解码器进行条件图像生成.神经信息处理系统的进展; Curran Associates,2016 年;第 29 卷。

(49)刘华;孙建;关建;郑建;周胜.通过建立高可信度负样本改进化合物-蛋白质相互作用预测.生物信息学2015, 31, i221—i229。

(50) Huang, K.;Xiao, C.;Glass, LM;Sun, J. MolTrans:用于药物-靶标相互作用预测的分子相互作用转换器。生物信息学2021, 37, 830—836。

(51)Zitnik,M.;索西克,R.; Leskovec,J. BioSNAP 数据集:斯坦福生物医学网络数据集集合。 <https://snap.stanford.edu/biodata/index.html> 2018年。

(52) Wishart, DS;Knox, C.;Guo, AC;Cheng, D.;Shrivastava, S.;Tzur, D.;Gautam, B.; Hassanali, M. DrugBank:一个有关药物、药物作用和药物靶点的知识库.核酸研究.2008,36 , D901 -D906。

(53) Gilson, MK;Liu, T.;Baitaluk, M.;Nicola, G.;Hwang, L.;Chong, J. BindingDB,2015 年:一个药物化学、计算化学和系统药理学的公共数据库。核酸研究.2016,44 , D1045 —D1053。

(54)白,P.; Miljkovic,F.;葛,Y.;格林,N.;约翰,B.;卢,H. 用于低偏差评估药物-靶标相互作用预测的层次聚类分割.2021年 IEEE 国际生物信息学和生物医学会议 (BIBM) , 2021,641—644。

(55)孙燕;董玲;黄胜;马胜;夏燕;薛建;王建;魏峰.保留网络:大型语言模型 Transformer 的继任者。arXiv 2023.DOI :10.48550/arXiv.2307.08621 (56)巴,JL;基罗斯,JR; Hinton,GE层标准化。arXiv。2016.DOI :10.48550/arXiv.1607.06450 (57) 李 M.;周,J.;胡,J.;范,W.;张,Y.;顾,Y.;卡里皮斯,G. Dgl-lifesci:用于生命科学图表深度学习的开源工具包。ACS 欧米伽2021, 6, 27233—27238。

(58) Tsubaki,M.;Tomii,K.;Sese,J.使用针对图形和序列的神经网络端到端学习来预测化合物-蛋白质相互作用.生物信息学2019,35,309-318。

(59)陈琳;谭鑫;王丹;钟锋;刘鑫;杨婷;罗鑫;陈凯;姜华;郑明.TransformerCPI :通过基于序列的深度学习,结合自注意力机制和标签反转实验,改进化合物-蛋白质相互作用预测。

生物信息学2020, 36, 4406—4414。

(60) Li, M.;Lu, Z.;Wu, Y.;Li, Y. BACPI:一种用于化合物-蛋白质相互作用和结合亲和力预测的双向注意力神经网络.生物信息学2022, 38, 1995—2002。

(61)赵明;表明;杨勇;徐绍轩, CPGL:通过将图注意力网络与长短期记忆神经网络相结合来预测化合物-蛋白质相互作用。IEEE/ACM Trans. Comput. Biol. Bioinf. 2023, 20, 1935—1942。

(62) Zhao, Q.; Duan, G.; Zhao, H.; Zheng, K.; Li, Y.; Wang, J. GIFDTI:基于全局分子和分子间相互作用表征学习的药物-靶标相互作用预测。IEEE/ACM Trans. Comput. Biol. Bioinf. 2023, 20, 1943—1952。

(63) Yin, Z.; Chen, Y.; Hao, Y.; Pandiyan, S.; Shao, J.; Wang, L. FOTF-CPI:基于最优传输片段融合的化合物-蛋白质相互作用预测变换器。iScience 2024, 27, 108756。

(64)Citrome,L.;McEvoy,JP;Todtenkopf,MS;McDonnell,D.;Weiden,PJ,《奥氮平治疗精神分裂症的疗效评论:过去、现在和未来》。神经精神病学.迪斯.对待。2019, 15, 2559—2569。

(65)科莫萨,K.;拉梅尔-克鲁格,C.;饥饿,H.;施密德,F.;施瓦茨,S.;杜根,L.;基斯林,W.; Leucht, S.奥氮平与其他治疗精神分裂症的非典型抗精神病药。Cochrane 系统评价数据库2010.DOI :10.1002/14651858.CD006654.pub2 (66)普拉萨德,M.;克里希南,公关;塞奎拉,R.;阿尔-鲁米,K. 癫痫持续状态的抗惊厥治疗。Cochrane 系统评价数据库2014.DOI :10.1002/14651858.CD003723.pub3 (67)Rosenberg,G.丙戊酸在神经精神疾病中的作用机制:我们能否透过树木看到森林?细胞。Mol.生命科学.2007,64,2090—2103。

(68)刘英;杨晓;甘建;陈珊;肖志雄;曹颖.CB-Dock2:通过整合腔检测、对接和同源模板拟合改进蛋白质-配体盲对接.核酸研究。2022,50 , W159—W164。

(69)欧文,RP;桑格尔,K.;克莱因,T.E.;奥特曼,R.B. 细胞色素 P450 2D6.药物基因组学.基因组学2009,19,559—562。

(70)巴克曼,J.T.;菲尔普拉,A.M.尼米,M.;诺伊沃宁,P.J.

细胞色素 P450 2C8 在药物代谢和相互作用中的作用。
药理学评论2016,68,168–241。

(71)艾布拉姆森法官;阿德勒,J.;Dunger,J.;埃文斯,R.;格林,T.;普里策尔,A.;
Ronneberger,O.;威尔莫尔,L.;巴拉德,AJ;班布里克,J.;等人
使用AlphaFold 3准确预测生物分子相互作用的结构。自然2024,630,493。