

通过建立高度可信的阴性样本来改进化合物-蛋白质相互作用预测

刘辉^{1,2,†}, 孙建江^{3,†}, 关继红⁴, 郑洁²和周水耕^{3,*}

¹常州大学信息管理实验室, 江苏 213164

南洋理工大学, 新加坡 639798, 新加坡,

复旦大学计算机科学与技术学院, 上海 200433

同济大学计算机科学与技术学院, 上海 201804

²计算机工程学院

³上海市智能信息重点实验室

⁴系

* 通信地址。

[†]作者希望大家知道, 在他们看来, 前两位作者应该被视为共同第一作者。

抽象的

动机: 化合物-蛋白质相互作用 (CPI) 的计算预测对于药物设计和开发至关重要, 因为基因组规模的 CPI 实验验证不仅耗时, 而且成本高昂。随着已验证相互作用数量的不断增加, 可靠的 CPI 阴性样本的缺乏严重阻碍了计算预测方法的性能。筛选可靠阴性样本的系统方法对于提高计算机预测方法的性能至关重要。

结果: 本文旨在通过计算机模拟筛选方法建立一套高可信度的 CPI 阴性样本。由于大多数现有计算模型假设相似的化合物可能与相似的靶蛋白相互作用并取得显著效果, 因此基于逆向假设 (即与化合物所有已知/预测靶标不同的蛋白质不太可能被该化合物靶向, 反之亦然) 来识别潜在的阴性样本是合理的。我们将各种资源整合到一个系统的筛选框架中, 包括化合物的化学结构、化学表达谱和副作用、氨基酸序列、蛋白质相互作用网络以及蛋白质的功能注释。

我们首先在六个经典分类器上测试了筛选出的负样本, 结果表明, 所有这些分类器在我们提出的负样本上取得的分类性能都显著高于随机生成的人类和秀丽隐杆线虫负样本。然后, 我们分别在二分局部模型、高斯核函数和贝叶斯矩阵分解这三种现有的预测模型上验证了这些负样本, 发现这些模型在筛选出的负样本上的性能也得到了显著提升。此外, 我们还在药物活性数据集上验证了筛选出的负样本。最后, 我们利用 DrugBank 中标注的正相互作用和我们筛选出的负相互作用训练支持向量机分类器, 得到了两组新的相互作用。筛选出的负样本和预测的相互作用为科研界提供了识别新药物靶点的有用资源, 也为现有的化合物-蛋白质数据库提供了有益的补充。

可用性: 补充文件可在以下网址获取: <http://admis.fudan.edu.cn/negative-cpi/>。

联系方式: sgzhou@fudan.edu.cn 补充信

息: [补充数据](#)可在生物信息学在线查阅。

1 简介

化合物-蛋白质相互作用 (CPI)对于通过筛选候选化合物来发现新药至关重要,也有助于了解现有药物副作用的原因。

尽管有各种生物学检测方法可用,但CPI的实验验证仍然耗时且昂贵。因此,开发能够准确检测CPI的计算方法有着强烈的动机。同时,随着公共化学和生物数据库的快速增长,例如PubChem (Wheeler等,2006)、DrugBank (Wishart等,2008)、SIDER (Kuhn等,2010)、STITCH (Kuhn等,2014)、STRING (Franceschini等,2013)和基因本体 (GO) (Ashburner等,2013),各种资源,包括药物特征 (例如化学结构、副作用和药物治疗下的基因表达谱)以及蛋白质特征 (例如氨基酸序列、蛋白质-蛋白质相互作用 (PPI)网络和功能注释)可供研究界使用,巩固了计算CPI预测的基础。

传统的计算方法大致分为两类:基于结构和基于配体。基于结构的方法依赖于目标蛋白质的结构信息,而大多数蛋白质家族通常无法获得这些信息。对于已知配体很少或完全未知的蛋白质,基于配体的方法效果不佳。近年来,各种基于机器学习的方法被提出,并取得了显著成功,这些方法借鉴了化学基因组学 (Jaroch and Weinmann, 2006)的观点,将药物化合物的化学属性、蛋白质的基因组属性和已知的关键相互作用因子 (CPI)整合到一个统一的数学框架中。化学基因组学方法的主要原理是相似的化合物倾向于与相似的蛋白质结合,因此,给定蛋白质已知配体的缺乏可以通过相似蛋白质已知配体的可用性来弥补,反之亦然。

遵循化学基因组学的理念,已经提出了许多利用各种类型的特征和分类算法的方法 (Tabei and Yamanishi,2013; Yabuuchi等,2011; Yamanishi等,2010)。利用化学结构相似性和蛋白质序列相似性度量, Bleakley 和 Yamanishi (2009)提出了二分局部模型 (BLM),通过基于已知相互作用训练局部支持向量机 (SVM)分类器来推断 CPI。van Laarhoven 等人 (2011)提出了高斯相互作用概况 (GIP)核,利用 CPI 网络的拓扑结构。然而,这些方法仍然缺乏药物和目标蛋白质之间的已知相互作用,这常常导致预测失败。因此, Mei 等人 (2013)通过利用邻居的已知相互作用来弥补相互作用信息的不足,从而改进了 BLM。van Laarhoven 和 Marchiori (2013)也利用加权最近邻的交互概况来改进 GIP 方法。

越来越多的研究人员不再分别利用药物和蛋白质的属性,而是通过连接或张量积运算符将这些属性组合成一个特征向量,然后基于整合的特征和已知的关键绩效指标 (CPI) 构建分类器。例如, Jacob 和 Vert (2008)提出了 SVM 分类器,其成对核分别源自药物和蛋白质的相似性度量。Yamanishi等人 (2008)提出了二分图推理,将药物和蛋白质映射到统一的欧几里得特征空间中,其中通过已知相互作用连接的药物和蛋白质之间的距离最小化,反之则最大化。最初为个性化推荐提出的基于网络的推理(Zhou 等人,2010)也

用于识别CPI (Alaimo等,2013; Cheng等,2012)。其他方法包括基于核的数据融合 (Wang等,2011)、变生核的核化贝叶斯矩阵分解 (KBMF2K) (Gonen, 2012)、限制玻尔兹曼机 (Wang和Zeng,2013)和半监督方法 (Chen和Zhang, 2013; Xia等,2010)相继被提出。除了化学结构和蛋白质序列外,研究者还利用药物和蛋白质的其他属性来揭示它们之间的相互作用,包括药物的表达谱 (Carrella et al., 2014; Iorio et al., 2010; Wolpaw et al., 2011)、药物的功能基团 (He et al., 2010)和副作用 (Campillos et al., 2008; Mizutani et al., 2012)、蛋白质的信号通路和GO注释 (Jaeger et al., 2014),甚至是这些属性的组合 (Gottlieb et al., 2011, 2012; Perlman et al., 2011)。

先前的大多数方法使用经实验验证的CP作为正样本,并随机生成负样本来学习预测模型。然而,随机生成的负样本可能包含尚未发现的真正样本。使用此类随机生成的负样本训练的分类器可能获得较高的交叉验证准确率,但在独立的真实测试数据集上的表现可能不佳。因此,筛选高可靠性的负样本对于提高计算预测方法的准确性至关重要。真-负相互作用的重要性最近被强调为预测药物-靶标相互作用的未来发展方向之一 (Ding et al., 2014)。受此启发,我们着手在计算机上筛选高可靠性的CPI负样本。大多数预测CPI的计算方法都假设相似的药物化合物可能与相似的靶标蛋白相互作用。我们的方法基于逆命题,即与给定化合物的每个已知/预测靶标都不相似的蛋白质不太可能被该化合物靶向,反之亦然。我们将各种化合物和蛋白质资源 (包括化学结构、化合物的化学表达谱和副作用、氨基酸序列、PPI 网络和蛋白质的GO 功能注释)整合到一个系统的筛选框架中。我们在人类和秀丽隐杆线虫数据上评估了我们的方法。我们首先在六个经典分类器上测试了我们筛选出的负样本,包括随机森林、L1 和 L2 正则化的逻辑回归、朴素贝叶斯、SVM 和 k 最近邻 (kNN)。所有这些分类器在我们的负样本上取得的性能明显高于随机生成的负样本。我们还在三种现有的预测模型上验证了我们的负样本,包括BLM (Bleakley and Yamanishi, 2009)、高斯核函数 (van Laarhoven et al.,2011)和贝叶斯矩阵分解 (Gonen, 2012),发现这些模型在筛选出的负样本上的性能也得到了显著提升。此外,我们还使用药物生物活性数据集验证了我们筛选出的负样本。

最后,我们利用 DrugBank 中标注的正相互作用和我们筛选出的负相互作用训练 SVM 分类器,得到了两组新的关键相互作用指数 (CPI)。这些筛选出的负相互作用样本和预测的相互作用可以作为研究界识别新药物靶点的有用资源,并作为现有化合物-蛋白质数据库的有益补充。

2 材料

2.1 化合物-蛋白质相互作用CPI 取自 DrugBank

4.1 (Wishart 等,2008)、Matador (Gnther 等,2008)和 STITCH 4.0 (Kuhn 等,2014)。

DrugBank 和 Matador 是人工整理的数据库,STITCH 是一个综合性数据库,从四个不同的来源收集 CPI:实验、数据库、文本挖掘和预测的相互作用。同时,STITCH 为每个相互作用提供了一个从 0 到 1000 的分数,该分数表示由四种类型的证据支持的 CPI 的置信度,即实验验证、人工整理的数据库、文本挖掘和预测的相互作用。我们将 DrugBank 和 Matador 中的相互作用分配到最高分 1000,因为这些相互作用得到了生化实验和文献的支持。总共我们得到了 367 142 种独特化合物与人类的 19 342 种蛋白质之间的 2 290 630 种相互作用,以及 276 294 种独特化合物与秀丽隐杆线虫的 11 234 种蛋白质之间的 2 141 740 种相互作用。为简单起见,我们将创建的 CPI 组装称为 K,并用三重δci; pj; wij▷ 2 K 药物ci 和蛋白质pj之间的相互作用,以及文章其余部分的置信度得分wij。

2.2 化学数据

2.2.1 化学结构相似性药物的化学结构 (也称为指纹)从PubChem数据库 (Wheeler et al., 2006)中获得。我们计算指纹的Jaccard得分 (Jaccard, 1908)作为化合物之间的化学结构相似性。化合物c和c0之间的Jaccard得分定义为jcc \ c0j = jcc [c0j,它是c和c0之间共同子结构的数量与c和c0中子结构总数的比例。我们在分析中总共使用了881种人类和秀丽隐杆线虫的子结构。将此操作应用于所有药物对,从而构建了化学相似性矩阵。

2.2.2 副作用相似性 药物的副作用数据

从SIDER数据库下载 (Kuhn et al., 2010) 。对于涉及CPI但未收录于SIDER数据库的药物,我们采用了最近提出的基于化学片段预测副作用的方法 (Pauwels et al., 2011)来预测副作用。同样,我们根据已知的药物副作用或预测的前10个副作用 (如果副作用未知)计算每对药物的Jaccard评分作为副作用相似性 (Perlman et al., 2011) 。

2.3 蛋白质数据2.3.1 序列相

似性 蛋白质的氨基酸序列来自UCSC 表格浏览器。我们使用标准化的Smith-Waterman评分 (Smith and Waterman, 2010)计算蛋白质之间的序列相似性。标准化的Smith-Waterman评分为

个蛋白质 g 和g0是 swδg; g0 p= swδ::;▷p 表示原始 swδg; g▷p 两swδg0; g0▷p p Smith-Waterman 得分。将此操作应用于所有蛋白质对,我们得到了蛋白质的相似性矩阵

序列。

2.3.2 功能注释语义相似度从GO数据库下载GO注释

(Ashburner 等人,2013) 。每对蛋白质之间的语义相似度得分是根据与两种蛋白质相关的 GO 术语的重叠度计算得出的(Coutoa 等人,2007)。由于相似的药物预期会与在相似生物过程中起作用,具有相似分子功能或位于相似区室的蛋白质相互作用,因此三种类型的本体均用于计算。我们根据每对蛋白质的 GO 术语计算 Jaccard 得分作为它们的相似度。

2.3.3 蛋白质结构域相似性 从 PFAM 数据库

(Punta et al., 2012)中提取蛋白质结构域。每个蛋白质由一个结构域指纹 (二元向量)表示,其元素分别用 1 或 0 编码每个保留的 PFAM 结构域的存在与否。人类和秀丽隐杆线虫的 PFAM 结构域数量分别为 1331 和 3837。我们通过结构域指纹计算任意两个蛋白质的 Jaccard 得分作为它们的相似性。

3 种方法

3.1 多重相似度的整合如上所述,我们根据药物和蛋白质的不同特征

计算了多个相似度量。对于药物ci和cj,我们将它们公式化为一个综合的相似度量,如下所示:

CSij¼1Yδ1csδn▷Pn (1)

其中csδn▷ (n=1,2)分别表示基于化学结构和副作用特征的相似性度量。

值得注意的是,STITCH (Kuhn et al., 2014)也采用了类似的公式,因为它可以轻松扩展以整合更多相似性度量。类似地,我们通过以下公式计算了蛋白质pi和pj之间的综合相似性:

PSij=1Y▷; δ1psδn▷Pn (2)

其中psδn▷ (n= 1, 2, 3) 分别表示基于序列相似性、功能注释语义相似性和蛋白质域相似性的相似性度量。

3.2 筛选框架现有的大多数CPI (阳性样本)预测方法

都基于这样的假设:相似的化合物很可能与与相应已知靶蛋白相似的蛋白质发生相互作用。我们的基本思路源于该假设的逆命题。具体而言,我们假设与化合物所有已知/预测靶标都不相似的蛋白质不太可能被该化合物靶向;另一方面,与任何已知/预测靶标蛋白质的化合物都不相似的化合物也不太可能靶向该蛋白质。为简便起见,我们分别将其称为蛋白质相异性规则和药物相异性规则。我们的筛选框架同时应用这两条规则,以识别最可靠的CPI阴性样本。与现有的通常依赖已知CPI进行可靠预测的预测方法不同,我们的阴性样本筛选框架同时利用了已验证的CPI和预测的CPI。图1展示了我们方法的流程图。这里,三个绿色虚线框显示了我们筛选框架中使用的资源,分别计算蛋白质差异性和药物差异性,从而为每个候选阴性样本获得综合得分。我们总结了筛选步骤如下:

- 1. 通过公式 (1) /公式 (2) 计算每对化合物/蛋白质的综合相似度,构建如上所述的已知/预测CPI的集合K。
- 2. 从所有可能的交互中构建候选负面交互集,排除已创建的已知/预测 CPI 集合 K。我们取候选负面交互




图1. 我们的负面CPI筛选框架流程图。三个绿色虚线框显示了我们筛选过程中使用的数据资源,以及红色虚线框表示包含多个操作的筛选步骤

化合物 k 和蛋白质 j 之间,表示为 $\delta ck; p_j; dkj_P$

dkj_P 表示化合物 k 和蛋白质 j 之间的距离,即

举例说明筛选过程。图2是为了

说明 dkj_P 的计算过程。

a. 对于 K 中 ck 靶向的任何蛋白质 p_l , 我们计算

加权得分 $spc_{jkl} = w_{kl} PS_{jl}$, 表示

考虑化合物 ck 所针对的蛋白质 p_j

p_j 和 p_l 之间的相似性。考虑到

p_j 与化合物 ck 靶向的每个已知/预测蛋白质 p_l 之间的相似性,即 $(ck; p_l; w_{kl} \mid 2 K)$, 我们计算

将加权得分 spc_{jkl} 相加得到综合得分

相对于 l , 从而得到 $SPC_{jk} = \sum_l spc_{jkl}$ 。

b. 类似地, 我们计算加权分数 $scp_{kji} = w_{ij} CS_{ik}$

这代表了复合 ck 靶向的可能性

p_j 考虑到 ck 和 c_i 的相似性。

考虑 ck 与每个已知/

预测化合物 c 靶向蛋白质 p_j , 即

$(c_i; p_j; w_{ij} \mid 2 K)$, 我们通过求和来计算综合得分

对 i 加权得分 scp_{kji} , 从而得到 $SCP_{kj} = \sum_i scp_{kji}$ 。

c. 对于化合物 ck 和蛋白质 p_j , 我们定义 ck 和 p_j 之间的距离如下:

$$dkj = e^{\delta SPC_{jk} - SCP_{kj}} \quad (3)$$

dkj 是最终得分, 代表化合物 ck 不靶向蛋白质 p_j 的可能性。 dkj 越大,

ck 不瞄准 p_j 的可能性越高。

3. 从两个手动策划的

数据库: DrugBank (Wishart 等, 2008) 和 Matador (Gnther 等人, 2008年)。

4. 按照公式 (3) 得到的得分对潜在的负面CPI进行排序, 得分最高的是

以形成负样本候选集。

5. 利用化合物和蛋白质的特征散度进一步筛选负样本候选, 如

第 3.3 节。

6. 结合正向互动和负向互动,

我们得到了一套黄金标准的消费者物价指数。基于化学




图2. 候选化合物-蛋白质样本 $\delta ck; p_j; dkj_P$ 得分 dkj_P 计算示意图。图中蓝色和红色两种颜色分别表示用于区分计算两个组合的权重和相似性得分。蓝色表示 SPC_{jk} , 红色表示 SCP_{kj} 。

子结构和蛋白质 PFAM 结构域, 我们为每个 CPI 构建张量积, 以便表示每个相互作用

通过化学基因组空间中的向量。

7. 使用化学基因组特征向量训练分类器 (例如 SVM), 通过交叉验证调整模型参数, 并最终预测新的CPI。

从概念上讲, 已知/预测相互作用 w_{kl} 和 w_{ij} 的置信度值通过步骤 2(a) 和步骤

2(b). 蛋白质相似性连接化合物 ck 和蛋白质 j 通过

蛋白质 p_l 由步骤 2(a) 中的 spc_{jkl} 表示, 化学相似性连接蛋白质 p_j 和化合物 ck 的 c_i 表示

在步骤 2(b) 中, scp_{kji} 计算得出。在步骤 2(c) 中, 根据公式 (3) 将两个得到的分数合并, 该公式通过负

指数函数。特别是, 已知/预测的相互作用

充当连接化合物和蛋白质的桥梁,

形成高概率的潜在相互作用。

3.3 根据特征差异性筛选众所周知,具有相似化学特征的化

合物可能具有截然不同的结合生物活性 (活性悬崖) (Sun and Bajorath,2012)。另一方面,具有完全不同核心结构的化合物可能靶向相似的蛋白质 (支架跳跃) (Sun et al. ,2012)。当特定化合物的已验证/预测靶蛋白数量较少,从而涵盖有限的蛋白质组学特征时,基于所有已知靶蛋白通过蛋白质组特征差异性筛选出的一些蛋白质很可能实际上是该化合物的靶标。从蛋白质的角度来看,当针对某个蛋白质的已验证/预测化合物数量较少时,可能存在类似的情况。因此,我们要求每个阴性样本候选化合物与蛋白质参与的已验证/预测相互作用的数量应大于某个预定阈值。将阈值设为15,得到人类23 392个化合物和10 757个蛋白质,秀丽隐杆线虫33 353个化合物和7 584个蛋白质,以此构建阴性样本。

此外,我们希望特定化合物所针对的蛋白质的特征彼此之间尽可能地不同,以便我们的相异性规则能够排除更多与已知目标蛋白质具有相似特征的似是而非的候选化合物。同样,针对特定蛋白质的化合物的化学特征差异越大,我们的相异性规则就能排除越多的假阳性靶向化合物。换句话说,筛选出的阴性样本的可信度与与特定化合物 (蛋白质)相关的已验证/预测相互作用中蛋白质 (化合物)的特征差异呈正相关。

因此,我们利用特征散度进一步筛选候选负样本。由于方差是衡量数据散度的常用指标,我们进行了统计检验,以检查候选负样本中与每个化合物 (蛋白质)相关的相互作用的蛋白质 (化合物)子集的相似性方差是否显著大于总体方差。以化合物为例,化合物总体的相似性方差为 0.0335,可以根据CSi轻松计算得出 (参见公式1) 。对于与蛋白质相互作用的n个化合物子集,零假设是样本方差小于化合物总体方差,备择假设与零假设相反,则样本方差服从自由度为n-1的v2分布。在显著性水平0.05下,我们将dkj的阈值设置为0.9 (e0:1) ,过滤掉较为似是而非的候选样本,最终在14 613个独特化合物和2 229个独特蛋白质之间获得了384 916个阴性样本。对于秀丽隐杆线虫,我们将dkj的阈值设置为0.9 (e0:1) ,最终在2 224个独特蛋白质和5 278个独特化合物之间获得了88 261个阴性样本。

至 0.368。

4 结果

4.1 性能评估方案 :为了客观公正地评估我们方法筛选出的阴性化合物-蛋白质对 (CPI) ,我们首先从手动整理的数据库 DrugBank 和 Matador 中构建阳性样本,然后生成两组阴性样本:-一组是通过随机抽取阳性样本中未包含的化合物-蛋白质对生成的,另一组是从我们方法筛选出的阴性样本列表中提取的。我们通过比较六个经典分类器的性能来评估筛选出的阴性样本。

以及三种现有的预测方法,分别在同一组正样本上,结合筛选出的负样本和随机生成的负样本进行预测。我们选取了排名前 384,916 个筛选出的负样本 (数据集可在补充材料中找到) 。从排名列表中 选择一些作为候选对象,并在实验中使用其中一些。

如补充图S1所示,相互作用的频率分布仅偏向于一小部分化合物/蛋白质,这表明对所有相互作用进行随机抽样可能仅覆盖有限数量的化合物和蛋白质。因此,与Tabei 和 Yamanishi (2013)和 Yamanishi 等人 (2014) 一样,我们使用了两种协议 :成对交叉验证和块交叉验证,以评估我们的负样本与随机生成的负样本。具体而言,成对交叉验证假设目标是在已知配体化合物和已知靶蛋白之间具有相互作用伙伴信息的前提下检测缺失的相互作用,而块交叉验证假设目标是在不知道相互作用伙伴信息的情况下检测新配体化合物和靶蛋白之间的新相互作用。成对交叉验证分 3 个步骤进行 : (i) 将金标准集中的 CPI 随机分成 5 个大小大致相等的子集; (ii) 依次将每个子集作为测试集,并使用剩余四个子集训练预测模型,然后评估该模型在测试集上的预测准确率; (iii) 将5倍预测的平均准确率作为最终性能指标。与拆分相互作用不同,块交叉验证将金标准集中的化合物和蛋白质分别随机拆分为五个子集。

依次选取每个化合物子集和每个蛋白质子集,并将其组合成测试集,然后对剩余四个化合物子集和四个蛋白质子集中包含的化合物-靶标对训练预测模型,并在测试集上进行进一步评估。最后,计算5 倍的平均预测准确率。

以下实验中使用了几种性能指标。TP 和 FP 表示正确和错误预测的正 CPI 数量,TN 和 FN 表示正确和错误预测的负 CPI 数量,这些指标包括精确度[或阳性预测值 (PPV)] = TP/(TP + FP),召回率 (或灵敏度) = TP/(TP+FN),特异度 = TN/(FP+TN) 和 AUC (ROC 曲线下面积) 。特别地,PPV 指标反映了当负样本数量远大于正样本数量时分类器区分真阳性的能力。此外,我们报告精确度-召回率曲线,因为当正样本数量较少时,该曲线更具参考价值。

4.2 在经典分类器上的评估

4.2.1 成对交叉验证

我们使用的人类数据集包括 1052 种独特化合物和 852 种独特蛋白质之间的 3369 个正相互作用,而 C.elegans 数据集包括 1434 种独特化合物和 2504 种独特蛋白质之间的 4000 个正相互作用 (数据集可在补充材料中找到) 。与Tabei 和 Yamanishi (2013)的方法类似,我们评估了负样本与正样本的比例从 1 增加到 5 时每个分类器的性能。随机生成的负样本是通过随机抽取正样本中未包含的化合物和蛋白质对生成的。对于筛选出的负样本,我们从我们方法生成的排名列表中的前 384,916 个候选对象中获取所需的相互作用数量。我们生成了

表 1. 六种经典分类器在人类（成对）筛选和随机生成的阴性样本上的 AUC/召回率/准确率值交叉验证

测量负面	样本比例	朴素贝叶斯		kNN		随机森林		L1物流		L2物流		支持向量机	
		筛选	随机	筛选	随机	筛选	随机	筛选	随机	筛选	随机	筛选	随机
		筛选	随机	筛选	随机	筛选	随机	筛选	随机	筛选	随机	筛选	随机
曲线下面积	1	0.672	0.622	0.860	0.563	0.940	0.647	0.908	0.874	0.911	0.868	0.910	0.752
	3	0.672	0.622	0.904	0.593	0.954	0.694	0.917	0.879	0.920	0.873	0.942	0.705
	5	0.671	0.622	0.913	0.589	0.967	0.709	0.916	0.877	0.920	0.872	0.951	0.713
精确	1	0.624	0.591	0.798	0.570	0.861	0.613	0.881	0.858	0.891	0.862	0.966	0.733
	3	0.361	0.338	0.716	0.458	0.847	0.529	0.823	0.786	0.837	0.787	0.969	0.700
	5	0.252	0.237	0.684	0.500	0.830	0.514	0.793	0.732	0.804	0.739	0.969	0.732
记起	1	0.575	0.413	0.927	0.564	0.897	0.599	0.893	0.836	0.913	0.850	0.950	0.745
	3	0.560	0.376	0.882	0.306	0.824	0.306	0.749	0.622	0.773	0.631	0.883	0.261
	5	0.555	0.364	0.844	0.205	0.825	0.199	0.649	0.524	0.666	0.522	0.861	0.112

粗体数字代表每种方法所达到的最高性能指标。

阳性和阴性样本的化学基因组学特征
执行化学子结构和蛋白质的张量积域。

我们对六个经典分类器进行了性能评估
通过将我们筛选出的负样本与随机生成的负样本进行比较,可以得到六个经典分类器:
朴素贝叶斯、
随机森林、L1-逻辑回归、L2-逻辑回归、SVM
和 kNN。朴素贝叶斯、随机森林和 kNN 由
使用 Weka 3.7 (Hall et al., 2009), L1 和 L2 逻辑回归
由 liblinear 1.94 (Fan et al., 2008)运行,SVM 由
libsvm 3.17 (Chang and Lin, 2011)。所有这些方法均在
除kNN外,其余均为默认设置,kNN分别设置为1、3和5。由于不同k值的结果相似,我们
仅报告k=1的结果。表1展示了AUC、召回率和

六个分类器在人类数据上的精度测量。我们发现
所有六个分类器的性能都显著
与我们的筛选阴性样本相比有所改善
随机生成的负样本。例如,对于从朴素贝叶斯到 SVM 的六个分类器,平均 AUC 改进

在我们筛选的底片上实现的随机生成的
阴性样本的比例分别为8.0%、53.4%、39.7%、4.2%、5.3%和29.6%。
随着阴性样本比例的增加,AUC值
大多数分类器的保持稳定或略有增加。然而,我们也
注意到大多数分类器的召回率和准确率随着负样本比例的增加而降低,这是

主要是由于负样本与正样本的比例越来越不平衡,导致

分类决策边界与正样本的比较。此外,我们在秀丽隐杆线虫上也获得了类似的结果,如下图所示
补充表 S1。这些实证结果表明
我们筛选出的阴性样本可靠性高。

4.2.2 块交叉验证

这里的正样本与pairwise中使用的相同
交叉验证。使用相同数量的随机负样本
通过随机抽样程序选出阳性样本
如上所述。此外,从前 384 916 个候选样本中随机抽取等量的筛选负样本

我们的排名列表。六个经典分类器在同一
如上所述,精确召回曲线和 AUC
直方图如图 3和补充图 S2所示。
与成对验证相比,这六个分类器表现
在筛选和随机的块交叉验证中表现更差
生成的负样本,但在筛选出的负样本上,其性能仍然有显著提高。特别是在




图 3. 六个经典分类器在人类筛选和随机生成的负样本上的精确召回率曲线（块交叉验证）

随机生成的负样本,每个分类器的性能在块交叉验证下急剧下降,

但除了朴素贝叶斯和 kNN 之外的大多数分类器仍然能够实现
筛选出的阴性样本的AUC值相对较高:
L1 和 L2 逻辑回归和 SVM 实现的 AUC 值更大
大于 0.8。如补充图 S3 所示,所有六个分类器在筛选出的负样本上都获得了比

在秀丽隐杆线虫的随机阴性样本上,这些分类器的整体性能与

在人类数据集上。

4.3 对现有预测方法的评估

我们进一步检查了现有的预测方法是否可以实现
筛选阴性样本的表现比随机
生成的负样本。评估的现有方法包括
BLM (Bleakley 和 Yamanishi,2009)、RLS-avg 和 RLS-Kron
采用 GIP 核的分类器(van Laarhoven et al., 2011)、KBMF2K 分类和
KBMF2K 回归(Gonen, 2012)。RLS平均和
通过设置两组不同的参数来运行 RLS-Kron,
(0.5, 0.5)和 (1,1),其他按默认运行
设置。所有这些方法最初都是在四个广泛使用的平台上进行评估的。
使用涉及酶、离子通道、GPCR 和
Yamanishi 等人 (2008)提出了核受体。但这些
四个数据集规模较小,仅涵盖了我们的方法筛选出的少量负面样本,因此我们构建了另一个相对
更大的人类数据集来评估这些方法。我们从 DrugBank 获取阳性样本,然后提取阴性
样本




图 4. 三个现有预测方法的 AUC 值直方图
方法对人类的筛选和随机生成的阴性样本

化合物和蛋白质均参与的样品

来自我们排名列表的正样本。由此产生的人类数据集

包括 2315 次积极互动和 2576 次消极互动

821 种独特化合物和 846 种独特蛋白质之间,以及

C.elegans 数据集包括 543 种化合物和 504 种蛋白质之间的 463 个正相互作用和 1561 个负相互作用样本 (数据集

可在补充材料中找到)。由于这些比较

方法以化学结构相似性矩阵、蛋白质序列相似性矩阵和 CPI 矩阵作为输入,我们构建了相似性矩阵和相互作用矩阵,如第 2 节所述。

这些预测方法所实现的 AUC 值

筛选并随机生成人体阴性样本

如图 4 所示。显然,所有方法都取得了显著的

筛选阴性样本上的表现比

随机生成的负样本。特别是 BLM 有

随机生成的负样本的 AUC 最小 (0.679),但

取得了与其他方法相当的 AUC (0.932)

筛选阴性样本。KBMF2K 分类和 KBMF2K 回归在

随机生成的负样本,但它们的表现

在筛选出的阴性样本上也得到了显著改善。

C.elegans,性能提升比

除 KBMF2K 分类外,所有方法均为人类

KBMF2K 回归,如补充图 S4 所示。

虽然 BLM 和四种 RLS 算法在随机生成的负样本上表现一般,但在筛选出的负样本上,其性能得到了大幅提升。

这个结果再次表明我们筛选出的负样本有助于提高现有预测方法的性能。

4.4 药物生物活性数据集评估

激酶抑制剂的定量药物靶标生物活性测定

提供药物分子结合的实验观察

目标,使我们能够得出积极和消极的

相互作用。正如 Pahikkala 等人 (2015) 所建议的,最近的激酶

Davis 等人 (2011) 的生物活性测定数据可作为药物性能评估的独立基准测试集。

目标预测方法。该分析报告了定量

相互作用亲和力和解离常数 (Kd),它反映了

药物分子与靶蛋白的结合紧密程度。分子越小,

Kd 越大,化合物与靶蛋白的相互作用亲和力和越高。

生物活性测定包括 68

独特药物和 442 种独特蛋白质,其中 20931




图 5. 训练的 SVM 和 L2-logistic 分类器的准确率-召回率曲线
在筛选和随机生成的阴性样本上进行评估
激酶生物活性测定数据 (Davis 等人, 2011)

与 Kd10 000 的相互作用被提取为阴性样本。

我们筛选出的阴性样本与实验支持的样本之间有 3564 个重叠相互作用。我们计算

重叠负样本的频率分布相对于置信度得分的截止阈值的增加

我们筛选出的阴性样本,如补充材料所示

图 S5。可以看出,置信度得分约为 80%

重叠负样本超过 0.5,即筛选出的

置信度得分较高的负样本更有可能得到药物生物活性实验的支持,这表明

我们筛选出的阴性样本的可信度。此外,我们使用

采用 Davis 等 (2011) 建议的 Kd 阈值 30.00 nM 提取阳性样品,得到了 1867 个阳性相互作用。

加上同样数量的负面互动,我们得到了

独立测试集,用于评估 SVM 和 L2-

分别在筛选和随机生成的负样本上训练逻辑分类器。我们选择了 SVM 和 L2-逻辑

回归

用于绩效评估,因为它们分别是二进制的

分类和现实回归代表。图 5 展示了它们的精确度-召回率曲线,表明分类器

在我们筛选的负面样本上进行训练,效果大大优于那些

在随机负样本上进行训练。

4.5 新相互作用的预测

在确认了我们筛选出的阴性样本的质量后,我们

建立了两组关于人体潜在 CPI 的预测。第一组是

基于 DrugBank 中收录的化合物和蛋白质子集构建的相对小规模预测集。具体来说,我们从 DrugBank 中提取了 2675 个相互作用作为阳性样本,并

从我们筛选出的排序列表中选择相同数量的阴性样本,然后基于化学基因组学特征训练一个 SVM 分类器来预测潜在的相互作用。训练好的 SVM

分类器从所有可能的

896 304 种相互作用,其化合物和蛋白质包含在

DrugBank。我们提取了每种化合物的前 50 种相互作用

得到一组 35425 个相互作用,其中 1093 个预测

DrugBank 中有注释,预测结果为 3224 条 (3224/35 4259.2%)

在 STITCH 中进行了注释。请注意,只有 18 580 个相互作用

STITCH 中记录了所有可能的 896 304 (18 580/

896 3042.1%),因此我们的预测将这些精心策划的互动排在较高位置,并优先考虑可信度高的互动。

作为一个确认性的例子,我们检查了关于多奈哌齐的预测相互作用,多奈哌齐是一种中枢作用的可逆性乙酰胆碱酯酶抑制剂化合物,在治疗上用于

阿尔茨海默病的姑息治疗 (Birks 和 Harvey,

2006)。我们的方法预测了 253 个目标蛋白,包括




图6. 多奈哌齐预测的靶蛋白及相关功能注释,包括神经活性配体-受体相互作用途径、记录的疾病在 DrugBank 和 STITCH

胆碱酯酶编码基因 *ACHE* 和 *BCHE*,它们是两个 DrugBank 和 STITCH 中注释的多奈哌齐的主要目标。事实上,目标蛋白质组涵盖了注释的所有 17 种相互作用在 STITCH 中,其相关蛋白质包含在测试集中,如图6所示。为了确认其他新的预测,我们检查了使用 DAVID (Huang et al., 2009)发现 45 种蛋白质高度富含神经活性配体-受体相互作用途径 (P值 $\frac{1}{4}$ 4.7E-32)。这些蛋白质与许多疾病密切相关,包括多种精神障碍。此外,这些蛋白质与各种精神和神经疾病有显著相关性,如高血压 (P 值 = 1.5E-11)、阿尔茨海默氏症疾病 (P 值 = 3.1E-4)、帕金森病 (P 值 = 3.0E-4) 和动脉硬化性血管疾病 (P值 $\frac{1}{4}$ 1.3E-3)。图6给出了多奈哌齐的靶蛋白和相关功能注释的说明 (有关参与该过程的蛋白质的详细列表) 途径和疾病,请参阅补充表S2)。

此外,为了方便研究社区,我们通过构建一个大型训练集 (包含 DrugBank 中包含的所有 6354 个相互作用)来构建第二组 (大规模)预测,并且

等量的筛选负样本。训练好的SVM分类器预测了超过6340000个CPI (请参阅补充材料详情)。这些新的预测将是有助于在新药设计中识别真正可用药的靶点。

5 讨论与结论

化合物与蛋白质之间相互作用的鉴定在基因组药物研发中发挥着重要作用。然而,CPI 的实验验证仍然费力且昂贵,尽管有各种高通量生化检测方法可用。计算机预测方法有助于指导实验设计并为实验结果提供支持证据。

基于机器学习的方法已经被提出并展示了令人鼓舞的性能。然而,它们的性能鲁棒性取决于训练集,其中负样本与阳性样本具有同等重要性。不幸的是,我们的

关于CPI负样本的知识极其有限,这严重限制了计算方法的性能。这

问题促使我们提出一个系统的筛选工作流程识别可靠的负CPI。据我们所知,这是第一项致力于筛选可靠的CPI负样本的工作。

我们的筛选框架基于以下假设:与给定化合物的任何已知/预测靶标不同的蛋白质不太可能被该化合物靶向,反之亦然。反之亦然。从化学基因组学空间的角度来看,我们设法找到那些远离化学基因组空间中所有阳性样本的化合物-蛋白质对作为阴性样本,这实际上有助于提升经典分类器和现有计算方法的性能。此外,与少量已知

排除相互作用,以减少采取真实由于活动悬崖和脚手架,相互作用为负面相互作用跳跃。特征发散过滤进一步巩固了我们的差异规则的强度。大量的实验表明,我们筛选出的负样本具有很高的可信度,并且有助于识别CPI。

在筛选出的阴性样本和阳性样本的基础上从 DrugBank 获得的数据,我们对潜在的 CPI 进行了预测通过训练 SVM 分类器对化学基因组学特征进行分析,我们得到了人类和秀丽隐杆线虫的基因组图谱。此外,我们还给出了一个验证性的例子,表明新方法多奈哌齐的预测靶蛋白在精神以及神经通路和疾病。总而言之,我们筛选的阴性样本和预测为研究界提供了有用的识别药物靶点的资源,并对当前的化合物-蛋白质数据库提供有益的补充。

资金

该项工作得到了国家自然科学基金委的支持中国,授权号 31300707.61272380 和 61173118,中国,以及教育部 AcRF Tier 2 拨款 ARC 39/13 (MOE2013-T2-1-079),教育部教育,新加坡。

利益冲突:无。

参考

Alaimo,S. 等 (2013) 通过领域调优网络推理预测药物-靶标相互作用.生物信息学 ,29,2004–2008。

Ashburner,M. 等人 (2013) 基因本体:统一生物学的工具。天然遗传学 ,25,25-29。

Birks,J. 和 Harvey, RJ (2006) 多奈哌齐用于治疗阿尔茨海默病引起的痴呆症疾病.《Cochrane数据库系统评价》,1,CD001190。

Bleakley,K. 和 Yamanishi,Y. (2009)使用二分局部模型监督预测药物-靶标相互作用.生物信息学 ,25,2397–2403。

Campillos,M. et al. (2008) 利用副作用相似的药物靶点识别科学,321,263-266。

Carrella,D. 等 (2014) Mantra 2.0:一个基于网络分析的药物作用机制及药物再利用的在线协作资源。《生物信息学》, 30,1787–1788。

Chang,CC 和 Lin,CJ (2011) LIBSVM:支持向量机库.《ACM 智能系统技术汇刊》,2,1-27。

Chen,H. 和 Zhang,Z. (2013) 一种用于网络中药物-靶标相互作用一致性预测的半监督方法。PLoS One ,8,e62975。

Cheng,F. 等 (2012) 通过基于网络的推理预测药物-靶标相互作用和药物重新定位.《PLoS Comput. Biol.》,8,e1002503。

Coutoa,FM 等 (2007)测量基因本体术语之间的语义相似性.《数据知识工程》,61,137–152。

Davis,MI 等人 (2011) 激酶抑制剂选择性的综合分析。天然生物技术 ,29,1046–1051。

Ding,H. 等 (2014) 基于相似性的机器学习方法预测药物-靶标相互作用:简要回顾。《生物信息简报》,15,734–747。

Fan,RE 等人 (2008) LIBLINEAR:一个用于大型线性分类的库。J.机器学习研究 ,9,1871-1874。

Franceschini,A. 等 (2013) STRING v9.1:蛋白质-蛋白质相互作用网络,覆盖范围和集成度均有所提升。《核酸研究》,41 (数据库期刊) ,D808–D815。

Gonen,M. (2012) 使用贝叶斯矩阵分解从化学和基因组核预测药物-靶标相互作用.生物信息学 ,28, 2304–2310。

Gottlieb,A. 等 (2011) PREDICT:一种推断新型药物适应症并应用于个性化医疗的方法。《分子系统生物学》,7, 496。

Gottlieb,A. 等 (2012) INDI:推断药物相互作用及其相关建议的计算框架.《Mol. Syst. biol.》,8, 592。

Gnther,S. 等人 (2008) SuperTarget 和 Matador:探索资源药物-靶点关系.《核酸研究》,36,D919–D922。

Hall,M. 等人 (2009) WEKA 数据挖掘软件:更新.《SIGKDD 探索新闻》,11,10-18。

He,Z. et al. (2010) 基于功能预测药物-靶标相互作用网络民族群体和生物学特征.《PLoS One》,5,e9603。

Hu,Y. 和 Bajorath,J. (2012) 扩展活动悬崖概念:活动悬崖的结构分类以及在 ChEMBL 数据库中不同类型悬崖的系统识别.《J. Chem. Inf. Model.》,52,1806–1811。

Huang,DW等 (2009)利用DAVID生物信息学资源对大型基因列表进行系统性和综合性分析。Nat. Protoc. ,4,44–57。

Iorio,F. 等 (2010) 从转录反应中发现药物作用模式和药物重新定位.《美国国家科学院院刊》,107, 14621–14626。

杰卡德,P. (1908) 《花卉分布新研究》.布尔.苏克。沃杜瓦科学.国家,44,223-270。

Jacob,L.和Vert,JP (2008) 蛋白质-配体相互作用预测:一种改进的化学基因组学方法.生物信息学 ,24, 2149–2156。

Jaeger,S. 等 (2014) 用于预测癌症化合物靶点及其驱动途径的因果网络模型.《J. Biomol. Screen.》,19, 791–802。

Jaroch,SE 和 Weinmann,H. (编) (2006) 化学基因组学:小分子探针研究细胞功能.恩斯特·谢林研究基金会研讨会.《Springer》,柏林,第 1-20 页。

Kuhn,M. et al. (2010) 副作用资源,用于捕捉药物.《Mol. Syst. Biol.》,6,343。

Kuhn,M. 等人 (2014) STITCH 4:蛋白质-化学相互作用与用户数据的整合.《核酸研究》,42(D1), D401–D407。

Lamb,J. 等 (2006) 连接图谱:利用基因表达特征连接小分子、基因和疾病.《Science》, 313, 1929–1935。

Mei,JP 等人 (2013) 通过学习局部信息和邻居。《生物信息学》,29,238-245。

Metz,JT 等人 (2011)探索激酶组。《自然-化学-生物学》,7,200–202。

Mizutani,S. et al. (2012) 将药物-蛋白质相互作用网络与药物副作用.生物信息学 ,28,i522–i528。

Pahikkala,T. 等人 (2015) 迈向更现实的药物-靶标相互作用预测词典.《简明生物信息》,16,325–337。

Pauwels,E. 等人 (2011) 预测药物副作用概况:化学碎片基于方法.《BMC 生物信息学》,12,169。

Perlman,L. 等人 (2011) 结合药物和基因相似性测量药物靶点阐明.《J. Comput. Biol.》,18,133–145。

Punta,M. 等 (2012) Pfam 蛋白质家族数据库。《核酸研究》,40 (数据库期刊) ,D290–D301。

Smith,TF 和 Waterman,M. (1981) 鉴定常见分子亚序列.《J. Mol. Biol.》,147,195-197。

Sun,H. 等人 (2012) 骨架跃迁方法的分类.《药物。《发现今日》,17,44–57。

Tabei,Y. 和 Yamanishi,Y. (2013) 复合蛋白质的可扩展预测使用 minwise 哈希进行交互.《BMC Syst. Biol.》,7,S3。

van Laarhoven,T. 和 Marchiori,E. (2013) 使用加权最近邻轮廓预测新药物化合物的药物-靶标相互作用.《PLoS One》,8, e66952. van Laarhoven,T. 等人 (2011) 高斯相互作用轮廓核用于预测药物-靶标相互作用.生物信息学 ,27,3036–3043。

Wang,Y. 和 Zeng,J. (2013) 使用重新预测药物-靶标相互作用严格玻尔兹曼机。《生物信息学》,29,i126–i134。

Wang,YC 等人 (2011) 基于核的数据融合改进了药物-蛋白质相互作用预测.《计算机生物化学》,35,353-362。

Wheeler,DL 等人 (2006) 美国国家生物技术中心数据库资源技术信息.《核酸研究》,34,D173–D180。

Wishart,DS 等人 (2008) DrugBank:药物、药物作用知识库和药物靶点.《核酸研究》,36,D901–D906。

Wolpaw,AJ 等 (2011)调节分析识别小分子诱导细胞死亡的机制.《美国国家科学院院刊》,108, E771–E780。

Xia,Z. et al. (2010) 半监督药物-蛋白质相互作用预测异质生物空间.《BMC Syst. Biol.》,4 (补充2) ,S6。

Yabuuchi,H. 等人 (2011) 多种化合物-蛋白质相互作用分析揭示新型生物活性分子.《分子系统生物学》,7,472。

Yamanishi,Y. 等 (2008) 从化学和基因组空间的整合预测药物-靶点相互作用网络.生物信息学 ,24,i232–i240。

Yamanishi,Y. 等人 (2010) 在综合框架中从化学、基因组和药理学数据预测药物-靶标相互作用。生物信息学 ,26,i246–i254。

Yamanishi,Y. 等 (2014) DINIES:基于监督分析的药物-靶点相互作用网络推理引擎。《核酸研究》,42,W39–W45。

Zhou,T. et al. (2010) 二分网络投影与个人推荐tion. Phys. Rev. E Stat. Nonlin. Soft Matter Phys.,76,046115。