

数据和文本挖掘

基于图和序列的端到端神经网络学习的复合蛋白质相互作用预测

Masashi Tsubaki^{1,*}, Kentaro Tomii^{1,2} and Jun Sese^{1,2}

¹日本东京都先进工业科学技术振兴机构人工智能研究中心, 邮编 135-0064, 日本和 ²东京工业大学先进工业科学技术振兴机构现实世界大数据计算开放创新实验室, 邮编 152-8550, 日本

*请将信件寄给此收件人。副主编: 乔纳森·雷恩

收稿日期: 2018 年 1 月 9 日; 修订日期: 2018 年 6 月 26 日; 编辑部决定日期: 2018 年 6 月 26 日; 接受日期: 2018 年 7 月 3 日

摘要

动机: 在生物信息学领域, 基于机器学习的化合物 - 蛋白质相互作用 (CPI) 预测方法在药物发现的虚拟筛选中发挥着重要作用。近来, 利用深度神经网络对离散符号数据 (例如自然语言处理中的单词) 进行端到端表示学习在各种难题上展现出了卓越的性能。对于 CPI 问题, 数据以离散符号数据的形式提供, 即化合物以图的形式表示, 其中顶点为原子, 边为化学键, 而蛋白质则以序列的形式表示, 其中字符为氨基酸。在本研究中, 我们探究了化合物和蛋白质的端到端表示学习的使用, 整合了这些表示, 并通过结合用于化合物的图神经网络 (GNN) 和用于蛋白质的卷积神经网络 (CNN) 开发了一种新的 CPI 预测方法。

结果: 我们使用三个 CPI 数据集进行的实验表明, 所提出的端到端方法在性能上与现有的各种 CPI 预测方法相当或更优。此外, 在不平衡数据集上, 所提出的方法显著优于现有方法。这表明通过端到端的 GNN 和 CNN 获得的化合物和蛋白质的数据驱动表示比从数据库中获取的传统化学和生物学特征更具鲁棒性。尽管由于深度学习模型的黑箱性质, 对其进行分析较为困难, 但我们通过神经注意力机制解决了这一问题, 该机制使我们在预测药物化合物与蛋白质的相互作用时, 能够考虑蛋白质中的哪些子序列对药物化合物更为重要。神经注意力机制还提供了有效的可视化, 这使得即使在使用实值表示而非离散特征进行建模时, 也更容易对模型进行分析。

可用性和实现: <https://github.com/masashitsubaki>

联系人: tsubaki.masashi@aist.go.jp

补充信息: [补充数据](#)可在《生物信息学》在线获取。

1 简介

化合物与蛋白质之间的相互作用对于安全有效药物的发现和开发至关重要 (Keiser 等人, 2009 年)。揭示未知的化合物 - 蛋白质相互作用 (CPI) 有

助于预测潜在的副作用, 并为现有药物寻找新的用途, 即药物再定位 (Lounkine 等人, 2012 年; Medina-Franco 等人, 2013 年)。然而, 通过实验来确定 CPI 耗时且成本高昂。

为了有效地识别潜在的化合物-蛋白质相互作用 (CPI), 从化学基因组学的角度出发, 人们开发了基于机器学习的预测方法 (Bredel 和 Jacoby, 2004), 该方法将化学空间、基因组空间及其相互作用纳入统一框架。基于这一思路, 人们研究了各种化合物和蛋白质特征以及预测 CPI 的算法。例如, Jacob 和 Vert (2008) 使用了化学子结构与蛋白质家族之间的张量积特征, 然后应用了具有成对核函数的支持向量机 (SVM)。此外, Yamanishi 等人 (2008) 提出了一种二分图学习方法, 将化合物和蛋白质映射到一个共同的特征向量空间, 并最小化由已知相互作用连接的向量之间的欧几里得距离 (否则最大化)。再者, Bleakley 和 Yamanishi (2009) 提出了一种二分局部模型 (BLM), 该模型利用化学结构与蛋白质序列之间的相似性度量, 然后应用具有已知相互作用的支持向量机。最近, 为了降低化学基因组学空间的高维度, Cheng 等人 (2012 年) 在训练支持向量机 (SVM) 之前应用了特征选择技术, 而 Tabei 和 Yamanishi (2013 年) 则专注于利用最小哈希算法改进线性支持向量机的预测性能, 以获得化合物-蛋白质对的紧凑指纹。van Laarhoven 等人 (2011 年) 基于化合物-蛋白质相互作用 (CPI) 网络拓扑结构使用了高斯相互作用轮廓 (GIP) 核, Go`nen (2012 年) 则使用了具有双核的核化贝叶斯矩阵分解。

近来, 在众多机器学习方法中, 深度神经网络 (DNN) 在诸如语音识别和视觉对象识别等各种问题上取得了卓越的成效。特别是端到端学习作为一种强大的表示学习技术, 在诸如机器翻译 (Sutskever 等人, 2014 年) 等自然语言处理问题中得到了广泛应用。端到端表示学习技术包含三个步骤: (i) 将离散输入符号 (如单词) 嵌入到低维实值向量空间中; (ii) 根据数据结构 (例如序列和图) 设计各种神经网络; (iii) 通过反向传播学习所有网络参数, 包括离散输入符号的嵌入向量。需要注意的是, 这种技术可用于各种离散符号数据。在化合物-蛋白质相互作用 (CPI) 问题中, 数据以离散符号数据的形式提供, 即化合物以图的形式表示, 其中顶点为原子, 边为化学键, 而蛋白质以序列的形式表示, 其中字符为氨基酸。基于这些观察, 可以考虑 CPI 表示的端到端学习。尽管深度神经网络 (DNN) 已被用于化合物和蛋白质的研究 (Hamanaka 等人, 2017 年; Tian 等人, 2016 年; Wan 和 Zeng, 2016 年), 但这类基于 DNN 的方法并未采用端到端的表示学习, 而是依赖于分子指纹和蛋白质家族数据库作为输入特征, 这些特征在 DNN 训练过程中是固定的。

在本文中, 我们研究了化合物和蛋白质的端到端表示学习的使用, 整合这些表示并开发了一种新的化合物-蛋白质相互作用 (CPI) 预测方法。具体而言, 我们提出使用图神经网络 (GNNs) (Kearnes 等人, 2016; Scarselli 等人, 2009) 和卷积神经网络 (CNNs) (Kim, 2014), 它们能够学习分子图和蛋白质序列的低维实值向量表示 (第 3 节和第 4 节)。请注意, 大多数现有方法在例如支持向量机 (SVM) 的训练过程中使用固定的输入特征 (即二进制值)。我们认为这会导致在不平衡的 CPI 数据集上表现不佳; 实际上, 处理不平衡数据集, 即包含少量正样本 (即相互作用) 和大量负样本 (即不相互作用) 的数据集, 是 CPI 预测中的常见问题 (Tabei 和 Yamanishi, 2013), 现有方法的性能因此受到影响。




图 1. 所提出的 CPI 预测方法概述。化合物向量和蛋白质向量是通过图神经网络 (第 3 节) 和卷积神经网络 (第 4 节) 获得的低维实值表示, 它们被连接起来并输入到分类器 (第 5 节) 中, 以预测化合物和蛋白质是否相互作用。所提出的方法基于端到端表示学习, 仅使用化合物和蛋白质的原始输入 (即 SMILES 和氨基酸序列), 而不是从数据库中提取的诸如分子指纹和蛋白质结构域之类的特征。更确切地说, 我们分别将使用 RDKit 预处理的 SMILES 获得的分子图和基于 n-gram 氨基酸分割的蛋白质序列输入到 GNN 和 CNN 中。

相对而言效果较差 (Liu 等人, 2015 年)。另一方面, 端到端表示学习能够在深度神经网络训练过程中学习输入特征 (即实数值), 而非将其固定, 从而有可能获得数据驱动的特征。因此, 端到端表示学习能够从大规模训练数据集中获益, 而无需考虑正负样本之间的平衡。也就是说, 即使没有任何化学和生物学特征, 我们期望通过端到端表示学习在平衡和不平衡数据集上都能取得更稳健的性能。此外, 图神经网络 (GNN) 和卷积神经网络 (CNN) 的结合能够自然地处理具有不同结构的数据对, 即分子图和蛋白质序列, 并且我们可以将它们输入到统一的框架中, 即端到端学习化学基因组学表示空间。最后, 我们将具有相同维度的化合物和蛋白质表示作为输入提供给分类器, 以预测它们是否相互作用 (第 5 节)。所提出的 CPI 预测方法的概述如图 1 所示。

尽管由于深度学习模型的黑箱特性, 对其进行分析颇具难度, 但我们证明了利用神经注意力机制 (Bahdanau 等人, 2014 年) 可以解决这一问题。该机制通过使用权重来帮助我们确定蛋白质中的哪些子序列对于药物化合物预测 CPI (即相互作用位点) 至关重要, 这些权重也是在所提出的神经网络中学习得到的 (第 5.1 节)。此外, 通过利用所获得的权重, 神经注意力机制能够提供清晰的可视化效果, 这使得即使在使用实值向量表示而非离散特征进行建模时, 模型也更容易分析 (图 9)。

在我们使用三个 CPI 数据集 (Liu 等人, 2015 年; Mysinger 等人, 2012 年) 进行的实验中, 我们证明了所提出的基于 GNN 和 CNN 端到端学习的方法能够取得与现有方法相当或更高的性能: 基于特征的经典机器学习方法 (如支持向量机)、专门用于 CPI 预测的其他方法、一种非机器学习方法 (即虚拟筛选和对接), 以及最近提出的基于结构的深度学习模型。特别是, 在不平衡数据集上, 所提出的方法显著优于这些方法; 这表明通过 GNN 和 CNN 的端到端学习获得的数据驱动表示更具优势。

与传统的化学和生物学特征相比,数据驱动的特征更为稳健。我们认为,与在训练过程中固定的化学和生物学特征相比,数据驱动的特征更具灵活性;这使得即使在大规模、不平衡的训练数据集上也能提供稳健的性能。此外,我们还可视化了药物与蛋白质亚结构之间的相互作用位点。需要强调的是,我们能够基于二维分子图和一维蛋白质序列的信息,通过表征学习获得三维结构相互作用位点的信息。

2 材料

用于评估基于机器学习的细胞色素 P450 (CPI) 预测方法的大多数数据集 (Hamanaka 等人, 2017 年; Tian 等人, 2016 年; Wan 和 Zeng, 2016 年) 都包含阳性样本 (即相互作用) 和随机生成的阴性样本 (即不相互作用)。然而,这种随机生成的阴性样本可能包含未知的阳性样本。即使使用这样的数据集训练的分类器表现良好,但在实际测试数据集上也可能表现不佳。基于这一观察结果,筛选出真正的阴性样本对于创建高度可信的 CPI 数据集至关重要 (Ding 等人, 2014 年)。

首先,我们对两组最近由 Liu 等人 (2015 年) 创建的 CPI 数据集进行了实验,一组是人类的,另一组是秀丽隐杆线虫的。这些数据集包含了通过系统筛选框架获得的化合物-蛋白质配对的高可信度负样本,其依据的假设是“对于给定化合物,与任何已知或预测靶点不相似的蛋白质不太可能是该化合物的靶点,反之亦然 (Liu 等人, 2015 年)。”数据集的正样本是从两个经过人工整理的数据库中获取的: DrugBank 4.1 (Wishart 等人, 2008 年) 和 Matador (Gu'ntner 等人, 2008 年)。最终,人类数据集包含 1052 种独特化合物与 852 种独特蛋白质之间的 3369 种正相互作用;秀丽隐杆线虫数据集包含 1434 种独特化合物与 2504 种独特蛋白质之间的 4000 种正相互作用。

在上述筛选框架中, Liu 等人 (2015 年) 假设相似的化合物会与已知蛋白质相似的蛋白质相互作用。然后,他们定义了蛋白质和药物的差异规则,并将这些规则应用于其筛选框架,以识别更可靠的阴性样本。此外,还已知具有相似 (或不同) 特征的化学化合物可能会与不同的 (或相似的) 靶蛋白相互作用。基于这一观察,他们认为针对特定化合物 (蛋白质) 的靶蛋白 (化合物) 候选预测相互作用的数量应大于某个预定义的阈值。通过设置阈值,他们获得了用于构建阴性样本的化合物和蛋白质。此外,他们期望与特定化合物 (蛋白质) 相互作用的蛋白质 (化合物) 的特征应尽可能不同。由于方差是评估数据离散程度的常用度量,他们进行了统计检验,以检查阴性样本中每个化合物 (或蛋白质) 对应的蛋白质 (或化合物) 的相似性方差是否大于总体方差。最后,他们剔除了虚假的候选对象,获得了可靠的 CPI 负面样本。

在 CPI 预测实验中,由于实际的 CPI 数据集通常不平衡,我们使用不平衡数据集来评估所比较方法的稳健性。在我们的实验中,正负样本的比例分别为 1:1、1:3 和 1:5,而正样本的数量保持不变。这种实验设置由 Tabei 和 Yamanishi (2013) 提出,并在其他研究中得到应用。

实验中使用的负样本是从 Liu 等人 (2015) 所获分数的候选样本中提取的。由于 CPI 预测是一个分类问题,其性能通过 AUC、准确率和召回率来评估。

除了各种机器学习方法外,我们还在 DUD-E 数据集上将所提出的方法与“非机器学习”方法进行了比较。DUD-E 数据集是 DUD (有用的诱饵目录) 的增强和重建版本 (Mysinger 等人, 2012 年)。DUD-E 基准是一个具有挑战性和稳健性的基于结构的虚拟筛选方法的数据集,包含 102 种不同的目标蛋白质 (以 PDB 文件形式提供)、22886 对蛋白质和化合物的活性配对 (以 SMILES 格式提供),平均每种目标蛋白质有 224 种化合物。在本文中,我们遵循 Wallach 等人 (2015 年) 的实验设置。我们将 102 个 DUD-E 目标随机分为 72 个作为训练数据集,30 个作为测试数据集。请注意,我们仅使用 DUD-E 数据集中的 1D 蛋白质序列和 2D 分子图,因为我们的模型不需要蛋白质的 3D 信息,尽管 DUD-E 目标是以 PDB 文件形式提供的。另外需要注意的是,我们使用的是 DUD-E 的平衡数据集,即训练样本的数量为 22886 个活性 (即正样本) 和 22886 个诱饵 (即负样本)。预测性能也使用 AUC 进行评估。

3 用于分子图的图神经网络

记号。在整篇论文中,向量用小写粗体字母表示 (例如 $\mathbf{v} \in \mathbb{R}^d$), 矩阵用大写粗体字母表示 (例如 $\mathbf{M} \in \mathbb{R}^{m \times n}$), 标量以及诸如图、顶点和边之类的离散符号用非粗体字母表示 (例如 G 、 v 和 e)。


如图 1 所示,我们使用图神经网络 (GNN) 处理分子图。在本节中,我们将描述这种 GNN,它能够获取分子图的低维实值向量表示。GNN 通过两个函数,即过渡函数和输出函数,将图 G 映射到向量 $\mathbf{y} \in \mathbb{R}^d$,这两个函数最初由 Scarselli 等人 (2009 年) 提出。其中,过渡函数会考虑每个顶点 (即分子中的原子) 的相邻顶点和边 (即分子中的化学键) 来更新每个顶点的信息,而输出函数则将顶点集映射到向量 $\mathbf{y}$ 。需要注意的是,这两个函数均通过神经网络实现。在我们的 GNN 中,组合的过渡和输出函数 $\mathbf{y} = f(G)$ 是可微的,并且通过反向传播学习函数 f 中的所有参数,包括输入特征。这是端到端的学习,并且这种可微函数 f 对于任意大小、形状和复杂结构的图都具有对称性和同构性不变性。

3.1 基于 r 半径子图的嵌入


图 G 可表示为 $G = (V, E)$, 其中 V 是顶点集, E 是边集。在分子中, $v_i \in V$ 是第 i 个原子, $e_{ij} \in E$ 是第 i 个原子和第 j 个原子之间的化学键。对于给定的图 G ,我们首先考虑这些类型,将所有原子和化学键嵌入到 d 维实值向量空间中。然而,在分子中,原子的种类 (例如氢和碳) 和化学键的种类 (例如单键和双键) 非常少,因此由于模型中的学习参数数量较少,表示学习效果不佳。

为了解决这个问题,我们使用 r 半径子图 (Costa 和 De Grave, 2010), 它由距离顶点 i 距离在 r 内的所有相邻顶点和边所诱导。这里的 r 值也假定等于从顶点 i 出发的跳数。更确切地说,对于给定的图 $G = (V, E)$,我们表示距离第 i 个顶点在 r 半径内的所有相邻顶点的索引集合为 $N(i, r)$ 。请注意

Sec 3.1: Embeddings based on r -radius subgraphs



Sec 3.2: Two transition functions



Sec 3.3: Molecular vector representation




图 2 基于子图向量、两个转换函数和一个输出函数的分子图 GNN 概述。嵌入（第 3.1 节）：我们首先考虑使用 r 半径子图（由距离顶点 r 半径内的相邻顶点和边诱导）来学习表示。我们将分子的 r 半径子图嵌入到低维实值向量空间中。转换（第 3.2 节）：我们在 GNN 中开发了两个转换函数，即顶点转换和边转换。基本思想是通过 (i) 对相邻嵌入求和以及 (ii) 迭代该过程，在图中传播顶点和边的局部信息。输出（第 3.3 节）：我们使用顶点隐藏向量的总和来获得输出（即分子向量表示）。

设 $N(i)$ 为顶点 i 的邻居索引集。然后，我们对顶点 v_i 的 r 半径子图定义如下：

$$\mathcal{V}_i^{(r)} = \{v_j \mid j \in N(i, r)\}, \quad (1)$$

$$\mathcal{E}_i^{(r)} = \{e_{mn} \in \mathcal{E} \mid (m, n) \in N(i, r) \times N(i, r-1)\}.$$

在本文中，我们提及 v_i 和 e_{ij} 作为半径为 r 的顶点和边。例如，

$\text{CH}_3\text{-CHO}$ （乙醛）包含 1 半径的边，例如 $\text{CH}_3\text{-C}$ 和 C-CHO 。此外，我们对边 e_{ij} 的 r 半径子图定义如下：

$$\mathcal{V}_{ij}^{(r)} = \left(\mathcal{V}_i^{(r-1)} \cup \mathcal{V}_j^{(r-1)}, \mathcal{E}_i^{(r)} \cap \mathcal{E}_j^{(r)} \right). \quad (2)$$

在本文中，我们将 e_{ij} 称为 r 半径边。例如，

$\text{CH}_3\text{-CHO}$ 包含 1 半径的边，例如 C-H 和 C=O 。然后，对于每种 r 半径的顶点和 r 半径的边，我们分配一个嵌入 -

取决于类型的不同，即 v_i 向量（i.e. vector）

该网络在监督学习过程中（第 5.2 节）通过反向传播进行随机初始化和后续训练。图 2 的左侧展示了 r 半径顶点、 r 半径边及其分配的嵌入向量的示例。

为简便起见，顶点嵌入 v_i 和边嵌入 e_{ij}

以下为了便于解释，我们使用这些术语来描述我们的 GNN 程序，而在我们的实现和实验（第 6 节和第 7 节）中则使用基于 r 半径子图的嵌入。

3.2 图神经网络中的两个转换函数

在此，我们首先描述我们图神经网络中顶点的转换函数（即顶点转换）。此外，由于边也如

第 3.1 节所述由向量嵌入表示，所以我们还考虑边的转换函数（即边转换）。

顶点转换：给定一个图 G 以及随机初始化的顶点和边的嵌入，我们将时间步 t 时第 i 个顶点的嵌入表示为 $v_i^{(t)} \in \mathbb{R}^d$ 。然后，我们使用以下方式更新 $v_i^{(t+1)}$ ：

以下转换函数：

$$v_i^{(t+1)} = \sigma \left(v_i^{(t)} + \sum_{j \in N(i)} h_{ij}^{(t)} \right), \quad (3)$$

其中 σ 是逐元素的 S 型函数： $\sigma(x) = 1/(1 + e^{-x})$ ， $N(i)$ 是节点 i 的相邻节点索引集，而 $h_{ij} \in \mathbb{R}^d$ 是隐藏向量。

邻域向量。此隐藏向量可通过考虑相邻顶点 v_j 和边 e_{ij} ，利用以下神经网络进行计算：

$$h_{ij}^{(t)} = f \left(W_{neighbor} \begin{bmatrix} v_j^{(t)} \\ e_{ij}^{(t)} \end{bmatrix} + b_{neighbor} \right), \quad (4)$$

其中 f 是一个非线性激活函数，例如 ReLU（LeCun 等人，2015 年）： $f(x) = \max(0, x)$ ， $W_{neighbor} \in \mathbb{R}^{d \times 2d}$ 是权重矩阵， $b_{neighbor} \in \mathbb{R}^d$ 是偏差向量，而 $e_{ij} \in \mathbb{R}^d$ 是边嵌入。

因此，在时间步长 t 时，第 i 个顶点和第 j 个顶点之间存在连接。通过将相邻的隐藏向量相加，并在时间步长上进行迭代，顶点嵌入可以逐渐收集到图上的更多全局信息。

边缘转换：上述迭代过程也可以以类似的方式应用于边缘嵌入。在此，我们使用两侧顶点嵌入来更新 e_{ij} 。

和 v_j 如下：

$$e_{ij}^{(t+1)} = \sigma \left(e_{ij}^{(t)} + g_{ij}^{(t)} \right), \quad (5)$$

$$g_{ij}^{(t)} = f \left(W_{side} \begin{bmatrix} v_i^{(t)} \\ v_j^{(t)} \end{bmatrix} + b_{side} \right), \quad (6)$$

其中 $W_{side} \in \mathbb{R}^{d \times 2d}$ 是权重矩阵， $b_{side} \in \mathbb{R}^d$ 是偏差向量。请注意，我们计算 v_i 和 v_j 。

在式 (6) 中，因为边是

在分子图中，例如 C=O 和 O=C 是无方向的。换句话说， C=O 和 O=C 是相同的，这些向量是相同的表示形式。

因此，在我们的图神经网络中，通过顶点和边的转换函数，对这两种嵌入进行同等考虑，并同时更新。图 2 的右侧展示了这两种转换函数。

3.3 输出：分子向量表示

要从顶点向量组中获取最终输出 $y_{molecule} \in \mathbb{R}^d$ ，

这是一串无法翻译的文字，可能是乱码或特殊字符。请提供正确的文本以便翻译。

通过转换函数获得的顶点向量，即 $v_1, v_2, \dots, v_{|V|}$ ，我们按如下方式使用顶点向量的平均值：

$$y_{molecule} = \frac{1}{|V|} \sum_{i=1}^{|V|} v_i^{(t)}, \quad (7)$$

其中 $|V|$ 是分子图中的顶点数。虽然这是获取分子向量的最简单操作，但我们还提出了另一种输出函数，用于考虑蛋白质间的相互作用（第 5 节）。

4 用于蛋白质序列的卷积神经网络

如图 1 所示，我们使用卷积神经网络（CNN）来处理蛋白质序列。在本节中，我们将介绍这种卷积神经网络，它能够获取蛋白质序列的低维实值向量表示。用于蛋白质序列的卷积神经网络




图 3. 具有分层滤波功能的蛋白质序列卷积神经网络概述

序列将序列 C 映射到向量 $y \in \mathbb{R}^d$ ，使用多个滤波函数。请注意，蛋白质序列的维度 d 与第 3.3 节中描述的分子图的维度相同。通过滤波函数，我们的卷积神经网络（CNN）从 C 的子序列（输入特征）和权重矩阵（学习参数）计算出隐藏向量，以分层方式应用滤波函数，然后生成输出向量 y 。请注意，所有滤波函数均由神经网络实现。在我们的 CNN 中，总函数 $y = f(C)$ 是可微的，并且 f 中的所有参数，包括输入特征，都通过反向传播进行学习。与我们的图神经网络（GNN）类似，此 CNN 也是端到端学习。

4.1 基于 n -gram 氨基酸的嵌入

要将卷积神经网络（CNN）应用于蛋白质，我们首先将蛋白质序列中的“单词”定义为 n -gram 氨基酸（Dong 等人，2006 年）。然后将蛋白质序列分割成重叠的 n -gram 氨基酸。由于有 20 种氨基酸，所以可能的 n -gram 总数为 20^n 。在本研究中，为了使词汇表的规模易于处理，并避免学习表示中的低频词，我们将 n -gram 的数量 n 设为 3。例如，我们可以将蛋白质序列 MAAVRM 分割成重叠的 3-gram 氨基酸序列，如下所示：MAA VRM LDLK $\rightarrow$ “MAA”；“AAV”；“AVR”；...；“LDL”；“DLK”

给定一个蛋白质序列 $S = x_1 x_2 \dots x_{|S|}$ ，其中 x_i 是第 i 个单词， $|S|$ 是序列长度，我们首先将所有单词转换为随机初始化的嵌入向量，我们将其称为“单词嵌入”。在此，设单词嵌入的序列为：

$$\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3, \dots, \mathbf{x}_{|S|-1}, \mathbf{x}_{|S|},$$

其中 $\mathbf{x}_i \in \mathbb{R}^d$ 是第 i 个单词的 d 维嵌入。或者，我们也可以考虑一个序列，其元素由拼接的单词嵌入组成。例如，由三个连续嵌入拼接而成的序列如下所示：

$$[\mathbf{x}_1; \mathbf{x}_2; \mathbf{x}_3], [\mathbf{x}_2; \mathbf{x}_3; \mathbf{x}_4], \dots, [\mathbf{x}_{|S|-2}; \mathbf{x}_{|S|-1}; \mathbf{x}_{|S|}],$$

其中， $\frac{1}{2}x_i; x_{i+1}$ ； $x_{i+2} \in \mathbb{R}^{3d}$ 是 $x_i; x_{i+1}$ 和 x_{i+2} 的连接。这里， $x_{i+1} \in \mathbb{R}^d$ 指的是 $\frac{1}{2}x_i$ ； x_{i+2} ，其中 w 是要连接的窗口大小。在所提出的方法中，这样的序列被输入到卷积神经网络（CNN）中。

4.2 卷积神经网络中的滤波器功能

我们的卷积神经网络（CNN）采用了一个滤波函数，其输入为 $x_{i:i+w-1} \in \mathbb{R}^{dw}$

2 个 $\mathbb{R}^{dw}$ 的输出是一个隐藏向量 $c_i \in \mathbb{R}^d$ ，其表达式如下：

$$c_i^{(1)} = f(W_{conv} c_i^{(0)} + b_{conv}), \quad (8)$$

其中 f 是一个非线性激活函数（例如 ReLU）

， $W_{conv} \in \mathbb{R}^{d \times dw}$ 是权重矩阵， b_{conv} 是偏置向量。请注意，此滤波函数使我们能够从一个 dw 维的输入向量中获取一个 d 维的隐藏向量。因此，我们可以分层应用该函数，即我们计算第 t 个隐藏向量作为 c_i

四分之一 $\frac{1}{4} W_{conv} c_{i-1}^{(1)} + b_{conv}$ 获得一组隐藏向量：

$$C = \{c_1^{(1)}; c_2^{(1)}; \dots; c_{|C|}^{(1)}\}.$$

美国有线电视新闻网

4.3 输出：蛋白质向量表示

要从隐藏向量集 C 中获得最终输出 $y_{protein} \in \mathbb{R}^d$

对于集合 $C = \{c_1^{(1)}; c_2^{(1)}; \dots; c_{|C|}^{(1)}\}$ 中的元素，我们按如下方式计算 C 的平均值：

$$y_{protein} = \frac{1}{|C|} \sum_{i=1}^{|C|} c_i^{(1)}. \quad (9)$$

请注意， $y_{protein}$ 与 $y_{molecule}$ 具有相同的维度（第 3 节）。虽然这是获取蛋白质向量的最简单操作，但在第 5 节中，我们提出了另一种输出函数，考虑分子间的相互作用。

5 复合蛋白质相互作用预测

在本节中，利用所获得的化合物和蛋白质的向量表示（分别见第 3.3 节和第 4.3 节），我们提出了一种化合物-蛋白质相互作用（CPI）预测模型。在所提出的模型中，我们考虑化合物与蛋白质序列中子序列之间的相互作用。为了对这种相互作用进行建模，我们采用了最近提出的神经注意力机制，该机制在机器学习中得到了广泛应用（Bahdanau 等人，2014 年）。接下来我们将描述这种机制、分类器以及训练过程。

5.1 利用神经注意力机制捕捉化合物与蛋白质之间的相互作用位点

给定一个分子向量 $y_{molecule}$ 以及蛋白质 C 中一系列子序列的隐藏向量集合 $C = \{c_1^{(1)}; c_2^{(1)}; \dots; c_{|C|}^{(1)}\}$ ，我们希望对其进行加权处理。

是一串无法翻译的文字，可能是乱码或特殊字符。请提供正确的文本以便翻译。

考虑 $y_{molecule}$ 。换句话说，我们通过给予序列分配更大的权重来计算蛋白质中的哪些子序列对分子更重要。这种权重可以使用神经网络进行建模，即神经注意力机制（Bahdanau 等人，2014 年）。

更确切地说，给定 $y_{molecule}$ 和 c_i ，我们通过以下基于点积的标量值来计算权重：

$$\begin{aligned} h_{molecule} &= f(W_{inter} y_{molecule} + b_{inter}), \\ h_i &= f(W_{inter} c_i + b_{inter}), \\ \alpha_i &= \sigma(h_{molecule}^T h_i), \end{aligned}$$

其中 W_{inter} 是权重矩阵， b_{inter} 是偏差向量。被称为注意力的权重值 α_i 可以假设为表示分子与蛋白质子序列之间的相互作用强度。利用注意力权重，我们可按如下方式获得 h_i 的加权求和：

$$y_{protein} = \sum_{i=1}^{|C|} \alpha_i h_i. \quad (10)$$

因此，通过使用注意力机制，我们能够灵活地对化合物与蛋白质之间的相互作用进行建模，而非仅仅获得一个简单的总和。图 4 展示了用于 CPI 预测的注意力机制。请注意，注意力机制使我们能够通过可视化权重值来分析 CPI（第 7.2 节，图 9）。




图4. 使用化合物和蛋白质嵌入的加权和，并结合神经注意力机制的CPI预测模型，该机制考虑了分子图中子图之间的相互作用以及蛋白质序列中子序列之间的相互作用。

5.2 分类器

我们将 y_{molecule} 和 y_{protein} 连接起来，即 $\frac{1}{2}y$ 分子； y 蛋白质，并得到一个输出向量 $z \in \mathbb{R}^2$ ，这是CPI分类器的输入：

$$z = W_{\text{output}} [y_{\text{molecule}}; y_{\text{protein}}] + b_{\text{output}},$$

其中 $W_{\text{output}} \in \mathbb{R}^{2 \times 2d}$ 是权重矩阵， $b_{\text{output}} \in \mathbb{R}^2$ 是偏差向量。最后，在输出向量 $z \in \mathbb{R}^2$ 之上添加一个 softmax 层，以如下方式对CPI概率进行建模：

$$p_t = \frac{\exp(y_t)}{\sum_i \exp(y_i)},$$

其中 $t \in \{0, 1\}$ 是二元标签（即是否互动）， p_t 是 t 的概率。因此，我们使用 softmax 分类器来进行CPI预测。

5.3 培训

给定训练数据集中所有复合蛋白对的集合以及标签，训练目标是使损失函数 ℓ 最小化，该损失函数采用交叉熵损失，如下所示：

$$\ell(\Theta) = - \sum_{i=1}^N \log p_{t_i} + \frac{\lambda}{2} \|\Theta\|_2^2,$$

其中， Θ 是我们 GNN、CNN 中所有权重矩阵和偏差向量的集合，以及 r 半径内顶点和边的嵌入表示，还有 n 元氨基酸的嵌入表示， N 是训练数据集中分子-蛋白质对的总数， t_i 是第 i 个标签， λ 是 L2 正则化超参数。然后，我们使用反向传播来训练 Θ 。

6 实验

6.1 实施与培训

我们的图神经网络（GNN）以 SMILES 作为输入，这是一种分子的字符串编码。请注意，SMILES 是使用 RDKit 转换为图表示形式的。然后，我们从分子图中提取了各种信息，例如原子类型、化学键以及原子的邻接列表。对于蛋白质，无需进行预处理，因为我们的卷积神经网络（CNN）直接以原始氨基酸序列作为输入。

我们使用 Chainer（版本 3.2.0）（Tokui 等人，2015 年）实现了我们的图神经网络（GNN）

和卷积神经网络（CNN），这些神经网络的训练细节如下：优化算法：ADAM（Kingma 和 Ba，2014 年），这是一种基于随机梯度下降（SGD）的算法；半径 r ：0（即每个原子和化学键）、1 或 2； n 元组：1（即 20 种氨基酸）、2 或 3；窗口大小：11（固定）；顶点和 n 元组的向量维度：5、10、20 和 30；GNN 中的时间步数（即深度）：2、3 或 4；CNN 中的层数（即深度）：2、3 或 4；正则化系数 λ ： $1e-5$ 、 $1e-6$ 和 $1e-7$ 。需要注意的是，批处理大小为 1；一个批次包含一个分子，而分子包含相对较多的顶点和边。此外，使用批处理大小为 1，我们在精度收敛方面取得了最佳性能。

我们通过五折交叉验证对上述超参数组合进行网格搜索。虽然深度学习模型通常需要仔细调整超参数，但我们只需在相对较小的范围内调整超参数就能获得较高的性能。在第 6 节中，我们分析了这些超参数对 CPI 预测性能提升的影响。

6.2 主要结果：平衡数据集和不平衡数据集上的 AUC、准确率和召回率

表 1 和表 2 展示了使用 Liu 等人（2015 年）提供的平衡和不平衡数据集，各种传统机器学习方法以及所提出方法的 AUC、准确率和召回率结果。首先，在平衡且规模较小的数据集（即正样本：负样本为 1:1）上，所提出的方法在人类数据集上的表现低于（在秀丽隐杆线虫数据集上高于）其他方法： k 近邻（ k -NN）、随机森林（RF）、L2 对数回归（L2）和支持向量机（SVM），这些结果来自 Liu 等人（2015 年）的研究，实验设置如下： k -NN 和 RF 由 Weka 3.7 运行，L2 由 liblinear 1.94 运行，SVM 由 libsvm 3.17 运行。每个分类器均采用各软件的默认设置进行学习，例如 SVM 使用径向基函数（RBF）作为非线性核函数。另一方面，在不平衡且规模较大的数据集（即正样本：负样本为 1:5）上，所提出的方法在人类和秀丽隐杆线虫数据集上的表现均优于现有方法。这表明所提出的方法即使在数据集不平衡且规模较大时也具有较强的鲁棒性。这也意味着，通过图神经网络（GNN）和卷积神经网络（CNN）获得的端到端学习表示，即数据驱动特征，能够反映化合物和蛋白质对于预测相互作用的有用属性。需要注意的是，所提出的 GNN 和 CNN 并不依赖于现有方法中使用的分子图和蛋白质序列的任何化学和生物学特征，例如 PubChem 指纹和 Pfam 结构域。

6.3 与各种专门用于 CPI 预测方法的比较

在其他实验中，我们将所提出的方法与专门用于 CPI 预测的其他现有方法进行了比较，即 BLM（Bleakley 和 Yamanishi，2009 年）、使用 GIP 核的 RLS-avg 和 RLS-Kron 分类器（van Laarhoven 等人，2011 年）以及 KBMF2K-classification 和 KBMF2K-regression（Gonen，2012 年），这些方法均采用与 Liu 等人（2015 年）相同的实验设置。请注意，这些方法均以化学结构相似性矩阵、蛋白质序列相似性矩阵和 CPI 矩阵作为输入。图 5 和图 6 分别展示了在人类和秀丽隐杆线虫数据集上的 AUC 得分。可以看出，在这两个数据集上，所提出的方法也取得了与这些方法相当或更优的性能。

表 1. 在人类数据集上的主要结果: k 近邻 (k-NN)、随机森林 (RF)、L2 逻辑回归 (L2)、支持向量机 (SVM) 以及所提出的方法在 Liu 等人 (2015 年) 创建的平衡和不平衡数据集上的 AUC、准确率和召回率。

测量	负比率	k 近邻算法	射频	L2	支持向量机	我们的
AUC	1	0.860	0.940	0.911	0.910	0.970
	3	0.904	0.954	0.920	0.942	0.950
	5	0.913	0.967	0.920	0.951	0.970
精度	1	0.798	0.861	0.891	0.966	0.923
	3	0.716	0.847	0.837	0.969	0.949
	5	0.684	0.830	0.804	0.969	0.969
召回	1	0.927	0.897	0.913	0.950	0.918
	3	0.882	0.824	0.773	0.883	0.913
	5	0.844	0.825	0.666	0.861	0.975

注意: 现有的方法使用基于 PubChem 指纹和 Pfam 结构域的特征。所提出的方法使用通过 GNN 和 CNN 的端到端学习获得的特征, 即化合物和蛋白质的数据驱动特征表示。上述性能是在以下实验设置下实现的: r 半径为 2, n 元组为 3, 窗口大小为 11, 向量维度为 10, GNN 中的时间步数为 3, CNN 中的层数为 3。

表 2. 秀丽隐杆线虫数据集的主要结果

测量	负比率	k 近邻算法	射频	L2	支持向量机	我们的
AUC	1	0.858	0.902	0.892	0.894	0.978
	3	0.892	0.926	0.896	0.901	0.971
	5	0.897	0.928	0.906	0.907	0.971
精度	1	0.801	0.821	0.890	0.785	0.938
	3	0.787	0.836	0.875	0.837	0.916
	5	0.774	0.830	0.863	0.896	0.920
召回	1	0.827	0.844	0.877	0.818	0.929
	3	0.743	0.705	0.681	0.576	0.921
	5	0.690	0.639	0.582	0.519	0.836

注意: 实验设置与上述人类数据集的相同。

6.4 在 DUD-E 数据集上与非机器学习方法及其他深度学习模型的比较

作为最终实验, 我们将我们的模型与一些非机器学习方法以及近期提出的深度学习模型进行了比较。在本实验中, 我们采用了 DUD-E 基准, 实验设置依照 Wallach 等人 (2015 年) 在第 2 节中所述。我们将我们的模型与非机器学习方法 AutoDock Vina (Trott 和 Olson, 2009 年) 和 Smina (Koes 等人, 2013 年) 以及深度学习模型 AtomNet (Wallach 等人, 2015 年) 和 3D-CNN (Ragoza 等人, 2017 年) 进行了比较。AutoDock Vina 是一个开源的小分子配体与靶蛋白对接程序, 而 Smina 也是一个分子对接程序, 它是 AutoDock Vina 的一个分支, 增加了对评分函数和最小化的更好控制。AtomNet (Wallach 等人, 2015 年) 是一个基于 3D 结构的卷积神经网络, 它结合了蛋白质和化合物的 3D 信息, 用于预测小分子的生物活性以用于药物发现。AtomNet 结合了配体的信息和靶蛋白的结构, 这需要靶蛋白结合位点中每个原子的坐标。3D-CNN (Ragoza 等人, 2017 年) 也是一种基于三维结构的卷积神经网络, 它将蛋白质-配体结构离散化为网格, 基于网格整合蛋白质和配体的三维信息, 并预测相互作用。这与以图像作为输入的卷积神经网络类似。




图 5. 各种方法在人类数据集上针对细胞色素 P450 抑制 (CPI) 预测的 AUC 得分。我们取得了更高的或具有竞争力的 AUC 得分。




图 6. 在秀丽隐杆线虫数据集上针对 CPI 预测的各种方法的 AUC 分数。我们取得了更高或具有竞争力的 AUC 分数。




图 7. AutoDock Vina、Smina、AtomNet、3D-CNN 以及我们所提出模型的 AUC 得分。在 DUD-E 数据集上, 我们所提出的方法仅需二维分子图和一维蛋白质序列作为输入, 其 AUC 得分高于需要蛋白质和化合物三维信息的上述四种方法。请注意, AutoDock Vina、Smina、AtomNet 和 3D-CNN 的 AUC 得分分别来自 Wallach 等人 (2015 年) 和 Ragoza 等人 (2017 年) 的研究。

在场景被离散化为具有红、绿、蓝值 (RGB) 的像素的情况下。当我们基于 DUD-E 数据集, 使用 72 个目标作为训练数据集, 30 个目标作为测试数据集来评估我们提出的模型时, 我们发现, 如图 7 所示, 就 AUC 分数而言, 我们的模型比这些方法表现更佳。

请注意, 由于输入信息的不同, 这并非是一次完整的比较, 即 Vina、Smina、AtomNet 和 3D-CNN 使用的是蛋白质的三维结构信息, 而我们仅使用蛋白质的一维序列信息。我们认为, 仅基于蛋白质序列的方法对于诸如大规模的化合物-蛋白质相互作用预测和筛选等应用来说是合理的。

7 讨论与结论

7.1 模型分析

在本节中, 我们通过学习曲线来分析模型超参数对 CPI 预测性能的影响, 其中 x 轴表示训练轮次, y 轴表示使用测试数据获得的 AUC 值 (图 8)。为了描述学习曲线, 我们使用了 DUD-E 数据集。此外, 我们通过突出神经注意力机制获得的高权重值来可视化 CPI 位点 (图 9)。

r 半径子图和 n 元氨基酸的效果: 如图 8 中的第一条学习曲线所示, 当 r=0 且 n=1 时, 即




图 8. 在 DUD-E 数据集上使用不同超参数的学习曲线。在所有学习曲线中, 除非另有说明, 我们使用以下超参数: r 半径为 2, n 元语法为 3, 窗口大小为 11, 向量维度为 10, GNN 中的时间步数为 3, CNN 中的层数为 3。

当我们使用原子、化学键和氨基酸而非半径顶点、边和 n 元氨基酸时, 这些向量表示无法被正确学习。请注意, 当 $r = 0$ 且 $n = 1$ 时, AUC 分数约为 0.8, 这低于 3D-CNN 的 AUC 分数 (见图 7)。另一方面, $r = 2$ 的半径顶点、边和 $n = 3$ 的 n 元氨基酸能显著提高性能; AUC 分数约为 0.95, 这高于 3D-CNN 的分数。有趣的是, 在我们的 GNN 和 CNN 的各种组件中, r 和 n 值是最为重要的超参数; 也就是说, 基于子图和子序列的表示学习对于提高 CPI 预测性能至关重要。从学习曲线可以看出, 在训练过程的早期就已达到高性能。

向量维度的影响: 如图 8 中的第二条学习曲线所示, 当化合物和蛋白质的向量维度相对较低时, 获得了较高的 AUC 分数。此外, 更高的维度向量并未带来进一步的提升。令人惊讶的是, 当我们使用极低维度 (五维) 的向量时, 也取得了较高的 AUC 分数。这些结果表明, 基于端到端表示学习的 CPI 预测可以使用小维度的神经网络进行建模。

GNN/CNN 中时间步长/层数的影响: 如图 8 中的第三条学习曲线所示, GNN/CNN 中时间步长/层数的影响相对较小, 即这两种神经网络的深度对于提升性能并非关键因素。实际上, 在量子化学研究中, Gilmer 等人 (2017 年) 表明, GNN 中的时间步长对于预测分子的量子力学性质并不重要。此外, Schütt 等人 (2017 年) 表明, 在预测分子能量时, GNN 的性能在时间步长为 3 时就已饱和。图 8 中的第三条学习曲线表明, 我们认同这些发现并得出相同结论。此外, 由于我们在 GNN 和 CNN 的输入端考虑了图和序列的全局信息, 即使使用了半径为 r 的子图和 n 元子序列, 因此可能不需要很深的神经网络。

7.2 带有注意力权重的 CPI 可视化

本研究的目标是利用深度学习实现高性能, 并证明即使对于黑箱模型 (即使用实值向量建模), 深度学习也是可以进行分析的。神经注意力机制 (第 5.1 节) 最有趣的一点在于, 所获得的注意力权重使我们能够更深入地了解输出, 并解释模型从数据中学到了什么。换句话说, 神经注意力机制可以通过突出高值注意力权重, 为考虑蛋白质中哪些区域对于药物化合物与蛋白质之间的相互作用至关重要提供有用的线索。




图 9. 带有注意力权重的 CPI 可视化示例。展示了两个已知复合物结构的 CPI, 即伊马替尼-Syk (a; PDB 编号 1XBB) 和阿司匹林-磷脂酶 A2 (b; PDB 编号 1TGM)。药物化合物以绿色突出显示, 通过神经注意力机制获得高权重值的蛋白质区域以红色突出显示。 α -螺旋和 β -折叠的二级结构分别以黄色和蓝色显示。与化合物直接接触的残基以棒状模型表示。

为了说明这一点, 我们将神经注意力机制计算出的权重值较高的区域映射到已知的 3D 蛋白质结构上进行可视化。图 9 展示了药物化合物与蛋白质之间相互作用的示例, 这些相互作用区域用神经注意力机制获得的权重值进行了突出显示。图 9 (a) 展示的是伊马替尼与脾酪氨酸激酶 (Syk) 的复合物 (PDB 编号: 1XBB (Atwell 等人, 2004 年)), 图 9 (b) 展示的是阿司匹林与 II 型磷脂酶 A2 的复合物 (PDB 编号: 1TGM)。请注意, 用于生成这些图的超参数如下: r 半径: 2; n 元语法: 3; 窗口大小: 11; 向量维度: 10; GNN 中的时间步数: 3; CNN 中的层数: 3。在这两种情况下, 权重值高于 0.8 的区域与相互作用位点有很大程度的重叠。

在药物化合物与蛋白质之间存在这样的区域。以 1XBB (图 9(a)) 为例, 有四个这样的区域。其中两个区域位于结合位点, 包含与伊马替尼形成氢键和范德华力的残基。另一个区域包含两个磷酸化位点 S579 和 T582, 但这些残基的作用尚不明确。以 1TGM (图 9(b)) 为例, 有两个这样的区域, 几乎与配体识别位点 (Singh 等人, 2007 年) 的 1 和 2 亚位点相对应, 即包含 L2、A18 和 I19 的区域, 它们与阿司匹林形成范德华力。

此外, 我们还研究了神经注意力机制是否能够利用人尿激酶型纤溶酶原激活剂 (u-PA) 催化结构域捕获多面手结构域。我们发现, 当使用两种不同的化合物和 u-PA 作为输入, 对使用人类数据集训练的所提出的模型进行测试时 (补充图 S1), 神经注意力机制能够突出每种化合物的独特结合位点。这一结果表明, 所提出模型中的神经注意力机制有助于发现多面手结构域, 并识别每种化合物的独特结合位点。再次强调, 该模型通过从二维图和一维序列信息以及所提出的端到端表示学习中获取的化合物与蛋白质之间的三维结构相互作用位点来突出显示这些位点。

7.3 结论与未来工作

在本文中, 我们提出了端到端的图神经网络 (GNN) 和卷积神经网络 (CNN) 表示学习方法来预测 CPI。实验结果表明, 在平衡和不平衡数据集上, 相对低维且浅层的神经网络有可能超越现有的各种方法。此外, 我们的注意力机制提供了清晰的可视化效果, 使实值向量更易于分析。我们相信, 我们的研究将为生物信息学中构建通用机器学习的端到端表示学习提供新的见解, 而不是依赖特征工程。

还值得注意的是, 我们也可以将 GNN 应用于 DUDE 数据集中以 3D 结构数据形式表示的蛋白质, 而在本研究中我们则是将 CNN 应用于以 1D 序列数据形式表示的蛋白质。原因在于, 实际上 (i) 3D 结构数据的数量少于 1D 序列数据, (ii) 深度学习需要相对大量的训练数据样本, (iii) 仅基于蛋白质序列的模型在诸如大规模 CPI 预测和筛选等实际应用中颇具吸引力。此外, 化学化合物通常以 SMILES 格式提供, 使用 RDKit 可以轻松将其转换为 2D 分子图。基于这些观察结果, 在本文中我们提出了使用 CNN 处理蛋白质序列以及使用 GNN 处理分子图的方法, 并取得了较高的预测性能。然而, 开发用于 3D 结构蛋白质的 GNN 是一个重要的挑战; 特别是, 我们认为这种“三维图神经网络”将使我们能够实现更高的性能, 提供更详细的分析, 并从数据驱动的机器学习方法的角度获取化合物与蛋白质之间三维相互作用位点的更多有用信息。我们将图神经网络的扩展探索留待未来的工作。

资金

本研究得到了日本新能源产业技术综合开发机构 (NEDO)、日本学术振兴会 (JSPS) KAKENHI 项目编号 JP17H07392、日本文部科学省 (AMED) 的药物发现与生命科学研究支持平台项目 (创新药物发现与生命科学研究支持基础 (BINDS)) 项目编号 JP18am0101110 以及日本科学技术振兴机构 (JST) CREST

项目编号 JPMJCR1689 和日本学术振兴会 (JSPS) KAKENHI 项目编号 15H01717 对 JS 的资助。

利益冲突: 无。

参考文献

- Atwell, S. et al. (2004) A novel mode of gleevec binding is revealed by the structure of spleen tyrosine kinase. *J. Biol. Chem.*, 279, 55827–55832.
- Bahdanau, D. et al. (2014) Neural machine translation by jointly learning to align and translate. In: *International Conference on Learning Representations*.
- Bleakley, K. and Yamanishi, Y. (2009) Supervised prediction of drug–target interactions using bipartite local models. *Bioinformatics*, 25, 2397–2403.
- Bredel, M. and Jacoby, E. (2004) Chemogenomics: an emerging strategy for rapid target and drug discovery. *Nat. Rev. Genet.*, 5, 262–275.
- Cheng, F. et al. (2012) Prediction of chemical–protein interactions: multitarget-qsar versus computational chemogenomic methods. *Mol. BioSyst.*, 8, 2373–2384.
- Costa, F. and De Grave, K. (2010) Fast neighborhood subgraph pairwise distance kernel. In: *International Conference on Machine Learning*.
- Ding, H. et al. (2014) Similarity-based machine learning methods for predicting drug–target interactions: a brief review. *Brief. Bioinf.*, 15, 734–747.
- Dong, Q.-W. et al. (2006) Application of latent semantic analysis to protein remote homology detection. *Bioinformatics*, 22, 285–290.
- Gilmer, J. et al. (2017) Neural message passing for quantum chemistry. In: *International Conference on Machine Learning*.
- Goñen, M. (2012) Predicting drug–target interactions from chemical and genomic kernels using Bayesian matrix factorization. *Bioinformatics*, 28, 2304–2310.
- Guñther, S. et al. (2008) Supertarget and matador: resources for exploring drug–target relationships. *Nucleic Acids Res.*, 36, D919–D922.
- Hamanaka, M. et al. (2017) Cgbvs-dnn: prediction of compound–protein interactions based on deep learning. *Mol. Inf.*, 36, 1600045.
- Hinton, G. et al. (2012) Deep neural networks for acoustic modeling in speech recognition: the shared views of four research groups. *IEEE Signal Process. Mag.*, 29, 82–97.
- Jacob, L. and Vert, J.-P. (2008) Protein–ligand interaction prediction: an improved chemogenomics approach. *Bioinformatics*, 24, 2149–2156.
- Kearnes, S. et al. (2016) Molecular graph convolutions: moving beyond fingerprints. *J. Comput. Aided Mol. Des.*, 30, 595–608.
- Keiser, M. J. et al. (2009) Predicting new molecular targets for known drugs. *Nature*, 462, 175–181.
- Kim, Y. (2014) Convolutional neural networks for sentence classification. *arXiv Preprint arXiv*, 1408, 5882.
- Kingma, D. and Ba, J. (2014) Adam: A method for stochastic optimization. In: *International Conference on Learning Representations*.
- Koes, D. R. et al. (2013) Lessons learned in empirical scoring with smina from the csar 2011 benchmarking exercise. *J. Chem. Inf. Model.*, 53, 1893–1904.
- Krizhevsky, A. et al. (2012) Imagenet classification with deep convolutional neural networks. In: *Advances in Neural Information Processing Systems*, pp. 1097–1105.
- LeCun, Y. et al. (2015) Deep learning. *Nature*, 521, 436–444.
- Liu, H. et al. (2015) Improving compound–protein interaction prediction by building up highly credible negative samples. *Bioinformatics*, 31, i221–i229.
- Lounkine, E. et al. (2012) Large-scale prediction and testing of drug activity on side-effect targets. *Nature*, 486, 361–367.
- Medina-Franco, J. L. et al. (2013) Shifting from the single to the multitarget paradigm in drug discovery. *Drug Discovery Today*, 18, 495–501.
- Mysinger, M. M. et al. (2012) Directory of useful decoys, enhanced (dud-e): better ligands and decoys for better benchmarking. *J. Med. Chem.*, 55, 6582–6594.
- Ragoza, M. et al. (2017) Protein–ligand scoring with convolutional neural networks. *J. Chem. Inf. Model.*, 57, 942–957.
- Scarselli, F. et al. (2009) The graph neural network model. *IEEE Trans. Neural Netw.*, 20, 61–80.

- Schütt, K.T. et al. (2017) Quantum-chemical insights from deep tensor neural networks. *Nat. Commun.*, 8, 13890.
- Singh, N. et al. (2007) Structural elements of ligand recognition site in secretory phospholipase a2 and structure-based design of specific inhibitors. *Curr. Top. Med. Chem.*, 7, 757–764.
- Sutskever, I. et al. (2014) Sequence to sequence learning with neural networks. In: *Advances in Neural Information Processing Systems*, pp. 3104–3112.
- Tabei, Y. and Yamanishi, Y. (2013) Scalable prediction of compound–protein interactions using minwise hashing. *BMC Syst. Biol.*, 7, S3.
- Tian, K. et al. (2016) Boosting compound–protein interaction prediction by deep learning. *Methods*, 110, 64–72.
- Tokui, S. et al. (2015) Chainer: a next-generation open source framework for deep learning. In: *Proceedings of Workshop on Machine Learning Systems (LearningSys) in the Conference on Neural Information Processing Systems*.
- Trott, O. and Olson, A.J. (2009) Autodock vina: improving the speed and accuracy of docking with a new scoring function, efficient optimization, and multithreading. *J. Comput. Chem.*, 31, NA–461.
- van Laarhoven, T. et al. (2011) Gaussian interaction profile kernels for predicting drug–target interaction. *Bioinformatics*, 27, 3036–3043.
- Wallach, I. et al. (2015) Atomnet: a deep convolutional neural network for bioactivity prediction in structure-based drug discovery. *arXiv Preprint arXiv*, 1510.02855.
- Wan, F. and Zeng, J. (2016) Deep learning with feature embedding for compound–protein interaction prediction. *bioRxiv*, 086033.
- Wishart, D.S. et al. (2008) Drugbank: a knowledgebase for drugs, drug actions and drug targets. *Nucleic Acids Res.*, 36, D901–D906.
- Yamanishi, Y. et al. (2008) Prediction of drug–target interaction networks from the integration of chemical and genomic spaces. *Bioinformatics*, 24, i232–i240.