

BINDTI: 基于注意机制的药物-目标相互作用识别双向意向网络

彭丽红¹, 刘昕¹, 杨龙¹, 刘龙龙¹, 白宗政¹, 陈敏¹, 卢旭¹、
和聂立波¹

摘要 药物与靶点相互作用 (DTIs) 的鉴定是药物发现的一个重要步骤。体外实验方法昂贵、费力且耗时。深度学习在 DTI 预测方面取得了可喜的进展。然而，如何精确地再现药物和蛋白质特征是 DTI 预测面临的一大挑战。在此，我们开发了一种基于双向意向网络的端到端 DTI 识别框架，称为 BINDTI。首先，根据 SMILES 字符串获得的二维分子图，用图卷积网络对药物特征进行编码。其次，根据蛋白质的氨基酸序列，通过自注意机制和卷积的混合模型 ACmix 对蛋白质特征进行编码。第三，通过双向注意力网络融合药物和目标特征，该网络结合了注意力和多头注意力。最后，根据融合后的 DT 特征，通过多层感知器对未知药物-目标 (DT) 对进行分类。结果表明，BINDTI 在 BindingDB、BioSNAP、DrugBank 和 Human 数据集上的表现大大优于四种基线方法（即 CPI-GNN、TransfomerCPI、MolTrans 和 IIFDTI）。更重要的是，在不平衡数据集上，它比四种基线方法更适合预测新的 DTI。消融实验结果表明，双向 Intention 和 ACmix 都能极大地促进 DTI 预测。融合特征可视化和案例研究表明，BINDTI 预测的结果与真实结果基本一致。我们期待所提出的 BINDTI 框架能找到新的低成本候选药物，改进药物的虚拟筛选，进一步促进药物的重新定位和药物发现。

收到日期: 2023 年 9 月 28 日; 修订日期: 2024 年 1 月 1 日和 2 月 21 日。

出版日期: 2024 年 3 月 12 日; 当前版本日期: 2025 年 3 月 7 日。发表日期: 2024 年 3 月 12 日; 当前版本日期: 2025 年 3 月 7 日。本研究得到国家自然科学基金 61803151 和 62172158 的资助 (刘昕为共同第一作者)。(通讯作者: 陈敏; 陆旭; 聂立波。

彭立宏、刘昕、杨龙、刘龙龙、白宗政、聂立波，湖南工业大学生命科学与化学学院，株洲 412007 (电子邮箱: plhnu@163.com; liuxinhut@163.com; yl_hut@163.com; soulorlong@163.com; zozeba@163.com; nielib@hntu.edu.cn)。

陈敏，湖南理工学院计算机学院，中国衡阳 421002 (电子邮箱: chenmin@hntu.edu.cn)。

徐璐，广东理工学院计算机学院，中国广州 510665; 广东省知识产权大数据重点实验室，中国广州 510665 (电子邮箱: bruda@126.com)。

BINDTI 可通过 <https://github.com/plhnu/BINDTI>。公开获取数字对象标识符 10.1109/JBHI.2024.3375025

索引词 药物与目标相互作用、双向意向网络、注意力、卷积、图卷积网络。

1. 引言

识别药物与靶点之间的潜在联系在药物发现中起着重要作用[1]。[3][2, 4][5, 6, 7]。体外实验可以筛选出许多可信的药物-靶点相互作用 (DTIs)。然而，实验室技术耗时、耗力且昂贵[8]、[10]9]。因此，人们开发了越来越多的计算工具来识别潜在的 DTIs。这些工具主要包括基于对接的方法、基于网络的方法以及基于机器学习的方法 [11]。

基于分子对接的 DTI 预测方法主要预测两种小分子的结合能力[12]。Shaikh 等人[13]利用分子对接计算化学作用间的亲和力，用于 DTI 预测。Yang 等[14]提出了一种名为FitDock的配体-蛋白质对接模型，通过分层多特征配准算法拟合初始构象，然后输出配体和蛋白质之间的精确对接姿势。分子对接方法需要高质量的三维结构信息来计算配体-蛋白质对接的亲和力。然而，它们的共晶体结构很难确定，导致基于对接的方法非常耗费计算资源，并且过度依赖三维结构信息[15]、[16]。

基于网络的方法首先将药物和蛋白质描绘成节点，将 DTI 描绘成边，然后计算药物和靶点的相似性矩阵，最后使用图论算法预测候选 DTI [11]。这些方法包括随机游走[17]、概率率逻辑模型[18]、殷勤元路径提取[19]、非负矩阵因式分解[20]、异质信息网络[21]、不平衡双随机游走与拉普拉斯正则化最小二乘法的结合以及基于网络的虚拟筛选[22]。基于网络的方法完全采用了药物和蛋白质的相似性，但无法在没有相互作用信息的情况下推断出新药和/或靶点的 DTIs。

最近，机器学习技术因其良好的性能在生物信息学领域受到广泛关注 [23]。[25]24, [26]。特别是，深度学习可以

2168-2194© 2024 IEEE。允许个人使用，但再版/再发行须经 IEEE 许可。

更多信息，参见 <https://www.ieee.org/publications/rights/index.html>。

深度学习可以利用各种生物医学数据，并已获得广泛应用，如 lncRNA 与蛋白质相互作用预测 [27]、蛋白质结构建模 [28]、[29]、[[35]30]、识别各种 RNA 数据与疾病之间的联系 [31]、[32]、[33]、[34]、[36]、[37]、[38]，以及单细胞数据分析 [39]、[40]、[41]、[42]。值得注意的是，深度学习已被广泛应用于 DTI 推断。这些方法主要包括两个步骤：药物和蛋白质特征表示以及基于深度学习的 DTI 分类。一般来说，药物和/或靶点的物理化学特性以及生物学和拓扑学特征已被用于生成药物-靶点（DT）特征向量。这些方法包括堆叠式自动编码器[43][44][45]、组合式自动编码器和基于深度学习的自动编码器。

多头注意和跳过连接[44]、带子图匹配的元学习框架[45]。更重要的是，图卷积网络（GCN）[46]、图注意力网络（GAT）[15]、[[49]47]和图神经网络（GNN）[48]、[50]已被广泛应用于根据药物的二维分子图编码药物的局部结构。而卷积神经网络（CNN）[8]、[46]、[51]、[53]52]、[54]则被用于根据蛋白质序列获得蛋白质特征。特别是单侧注意，即神经注意机制[48]，要求联合表示药物的分子结构和蛋白质的子序列。最新的研究 [15]、[[54]46]、[55]、

[56]基于双面注意机制，融合了药物和目标特征。

在本手稿中，我们开发了 BINDTI，这是一种端到端确定 DTI 候选者的框架。本研究有四大贡献：

- 开发了一个名为 BINDTI 的端到端框架，用于根据注意力机制预测潜在的 DTI。
- 一个名为 ACmix 的混合模型旨在编码通过结合卷积和自我关注，获得蛋白质特征。
- 提出了一种双向意向网络来融合药物以及基于多头注意力和意图的蛋白质特征。
- 对融合特征的可视化显示了预测的 DTI 与真实的 DTI 基本一致。

II. 材料与方法

A. 数据集

BINDTI 的性能在四个公开可用的数据集上进行了评估：这四个数据集分别是 DrugBank [52]、BindingDB [57]、BioSNAP [58] 和 Human [59]，测试集由未观察到的 DT 对组成。DrugBank 数据集由 Zhao 等人[52]根据 DrugBank 数据库[60]中的 DTI 数据创建。BindingDB [57] 包含经实验验证的结合亲和力，主要包括小分子药物与蛋白质之间的相互作用。BioSNAP 数据集是一个平衡数据集，由 Huang 等人[61]和 Marinka 等人[58]根据 DrugBank 数据库[60]中的 DTI 数据创建。在该数据集中，阳性 DTI 已经过验证，而阴性 DTI 则是从未见过的数据对中随机选择的。人类[59]包含可信度很高的阴性

表 I 显示了四个 DTI 数据集的统计数据。表 I 显示了四个 DTI 数据集的统计数据。

表 I
四个 DTI 数据集介绍

Dataset	Drug	Protein	Interaction	Positive	Negative
BindingDB	14643	2623	49199	20674	28525
BioSNAP	4505	2181	27464	13830	13634
DrugBank	6636	4254	34992	17501	17491
Human	2726	2001	5997	2633	3364

B. 宾迪

在本手稿中，我们开发了 BINDTI，一个预测新 DTI 的端到端框架。BINDTI 主要包括四个程序：(i) 根据由 SMILES 字符串获得的二维分子图，用 GCN 对药物特征进行编码；

(ii) 根据氨基酸序列用 ACmix 编码蛋白质特征；(iii) 通过双向 Intention 网络融合药物和蛋白质特征，并将一个 DT 对作为特征向量；(iv) 根据融合后的 DT 对特征，通过多层感知器对未知 DT 对进行分类。BINDTI 流程如图 1 所示。

1) 问题的提出: 对于具有 n 个 DT 对的 DTI 数据集 $D=\{(\mathcal{G}_i, \mathcal{P}_i, y_i) \mid i=1, 2, \dots, n\}$ ，让 $(\cdot, \cdot)$ 表示某个 DT 对（即一个样本）， y 表示其标签。如果 DT 对有交互作用，则 $y=1$ ，否则 $y=0$ 。接下来，基于具有注意机制的双向意向网络和多层感知器确定 DT 对是否存在联系。

2) 用 GCN 对药物特征进行编码: 为了获取药物特征，受参考文献[46]提出的药物特征提取方法的启发，BINDTI 首先将药物的 SMILES 字符串[62]转换成二维分子图。[46]的启发，BINDTI 首先将药物的 SMILES 字符串[62]转换为二维分子图 $(\mathcal{V}, \mathcal{E})$ ，其中 $\mathcal{V}$ 和 $\mathcal{E}$ 分别表示顶点集（即原子）和边集（即化学键）。首先，通过 DGL-LifeSci 软件包[63]，（根据每个节点的化学性质对其进行初始化，从而确定分子图， $\mathcal{V}$ ）中每个节点的特征。因此，每个节点都以 74 维的整数向量表示。接下来，由于每种药物含有不同的原子数，因此设定了最大原子数 N_d ，以便将每种药物转换为具有相同维度的张量。特别是当药物所含原子数较少时，我们会在得到的 74 维向量的每个节点上填充 0。因此，每种药物可表示为

$\mathbf{M}_d \in \mathbb{R}^{N_d \times 74}$ 。最后，一个具有实值的稠密矩阵 $\mathbf{Z}_d \in \mathbb{R}^{(N) \times (d) \times (D) \times (d)}$ 通过简单的线性变换模型 $\mathbf{Z}_d = \mathbf{W}_{(0)}^{(d)} \mathbf{M}_d^{(d)}$ 计算得出，并进一步用作 GCN 中的输入。

随后，构建三层 GCN 来学习药物的图表示。每个原子的特征向量都是通过聚合原子邻近原子的信息更新的。原子及其邻近原子均通过化学键相连。因此，我们可以根据邻近原子自动获取药物化合物的子结构信息。因此，药物编码器表示为 (1)：

$$\mathbf{H}_G^{(l+1)} = \text{ReLU} \left(\tilde{\mathbf{D}}^{-\frac{1}{2}} \tilde{\mathbf{A}} \tilde{\mathbf{D}}^{-\frac{1}{2}} \mathbf{H}_G^{(l)} \right) \quad (1)$$




图 1. 拟议的 BINDTI 模型示意图。它包含以下四个步骤：(i) 根据药物的 SMILES 字符串，用 GCN 对药物特征进行编码；(ii) 根据蛋白质的氨基酸序列，用 ACmix 对蛋白质特征进行编码；(iii) 用双向意向网络融合药物和蛋白质特征；(iv) 根据多层感知器预测每对 DT 的相互作用概率。

其中, $\tilde{A} = A + I$ 表示无向图对应的邻接矩阵, 其中 A 和 I 分别表示图 G 的邻接矩阵和身份矩阵。 $\tilde{D}_{ii} = \sum_j A_{ij}$, $W^{(l)}$ 表示 GCN 第 l 层的可训练权重, 其激活量为

函数 $ReLU$, $H^{(l)}$ 表示第 l 层的输出, 其中

$$H^{(0)} = \frac{Z_d}{3}$$

) 利用 ACmix 编码目标蛋白质特征: 卷曲

ACmix [64] 是一种混合模型, 它具有较少的组合性和较高的可扩展性。

ACmix[64]是一种混合模型, 具有较低的组合性。

通过享受卷积技术的优势来降低计算开销

和自我关注。为编码蛋白质特征, 首先将所有 23 种氨基酸初始化为可学习的特征矩阵

$E_{(p)} \in \mathbb{R}^{23 \times (D)}^{(p)}$, 其中 D_p 表示基于词嵌入原理的潜空间维度。接下来, 根据嵌入矩阵 $E_p \in \mathbb{R}^{23 \times (D)}^{(p)}$, 由 m 个氨基酸组成的蛋白质序列 P 可初始化为 $X \in \mathbb{R}^{(D) \times 1 \times (N)}^{(p)}$

特别是 N_p , 它代表蛋白质的最大氨基酸数, 用于获取所有蛋白质序列长度相同的序列进行批量训练。当蛋白质序列的长度小于 N_p 时, X 中的相应列会被填充为零。因此, 我们学习蛋白质特征

根据上述得到的蛋白质特征张量 X

和两个阶段的标准卷积操作 (2):

$$\begin{aligned} \text{I: } Y_{ij}^{(p,q)} &= K_{p,q} X_{ij} \\ \text{II: } Y_{ij}^{(p,q)} &= \text{Shift } Y_{p,q}^{p,q} - \lfloor k/2 \rfloor, q - \lfloor k/2 \rfloor \\ Y_{ij} &= \sum_{p,q} (Y)_{ij}^{p,q} \end{aligned}$$

其中 $K_{p,q} \in \mathbb{R}^{C_{in} \times C_{out}}^{(p,q)}$ ($p, q \in \{0, 1, \dots, k-1\}$) 表示对应于内核分区 (p, q) 索引的内核权重, C_{in} 和 C_{out} 代表内核分区 (p, q) 中的通道大小。

的邻接矩阵

G

分别为输入层和输出层。张量 $X \in \mathbb{R}^{C_{in} \times (H) \times W}$ 和 $Y \in \mathbb{R}^{C_{out} \times H \times (W)}$ 的高度值为 H , 宽度值为 W , 分别表示输入层和输出层的特征图。 $X_{ij} \in \mathbb{R}^{C_{in}}$ 和 $Y_{ij} \in \mathbb{R}^{C_{out}}$ 分别表示第 i 个和第 j 个特征图。

第 j 个氨基酸的特征张量与 X 和 Y 。 Shift 运算 $\tilde{f}$, $\text{Shift}(f, \Delta x, \Delta y)$ 定义为 $\tilde{f} = f(i + \Delta x, j + \Delta y)$, i, j 分别为 Y 。

此外, 我们还获得了每个蛋白质的特征张量 Y_{att}

基于 X 和两个阶段的多头自我关注 (3):

$$\begin{aligned} \text{I: } Q_{ij}^{(l)} &= W_q^{(l)} X_{ij}, K_{ij}^{(l)} = W_k^{(l)} X_{ij}, V_{ij}^{(l)} = W_v^{(l)} X_{ij} \\ \text{II: } \text{Att}(\frac{Q}{K})_{ij}^{(l)} &= \text{softmax} \left(\frac{Q_{ij}^{(l)} K_{ij}^{(l)}}{d} \right) \\ Y_{ij} &= \sum_{l=1}^L \text{Att}(\frac{Q}{K})_{ij}^{(l)} V_{ij}^{(l)} \end{aligned} \quad (3)$$

其中, $\|$ 表示对 $N_{(k)} \setminus$ 注意力头的输出进行连接运算, d 表示 $Q^{(0)}$ 的特征维度、

$W_q^{(l)}$ 、 $W_k^{(l)}$ 和 $W_v^{(l)}$ 是三个投影矩阵, 分别涉及多头注意力模块中的查询、键和值。 $N_{(k)}(i, j)$ 表示以 (i, j) 为中心、由 k 个节点组成的区域, $\text{Att}(Q^{(l)}, K^{(l)})$ 表示相关的注意力权重。与 $N_{(k)}(i, j)$ 中的特征相对应。

如图 1 所示, 上述操作优雅地整合了卷积和自我注意。由于它们执行的是相同的 1D 卷积操作, 因此只能进行一次投影。我们同时执行卷积

投影后的聚合运算 (即 (2) II) 和自我注意聚合运算 (即 (3) II)。最后, 蛋白质编码器的定义为 (4), 基于输出 Y_{conv} 和 Y_{att} 对




图2. 意图模块。

卷积和自我关注

$$H_P = \alpha Y_{conv} + \beta Y_{att} \quad (4)$$

其中, α 和 β 是两个可学习的参数, 分别用于表示通过卷积 lution 和自我关注获得的蛋白质特征张量对最终蛋白质特征编码的重要性。它们的初始值设为 0.5。

4) 利用双向注意力网络融合药物和目标特征: 多头注意力[65]和意图[66]是强大的深度学习技术。为了融合药物和目标特征, 我们通过整合多头注意力和 Intention 开发了双向 Intention 网络。与 以前的工作[44]、[48]不同, 我们充分利用了原子对蛋白质的注意力和氨基酸对药物的注意力, 并利用双向注意力有效地整合了每个 DT 的生物特征。通过神经网络进行配对。

多头关注[65]有助于模型共同处理来自不同特征表示子空间的信息。添加残差模块后, 多头注意力的鲁棒性明显增强[16]。受 trans- former [65] 和 ResNet [67] 的启发, 我们设计了一种多头自 注意残差模块, 通过 (5) 来增强药物的特征表示:

$$H_D = \text{MultiHead}(Q, K, V) + H_G \quad (5)$$

其中 Q 、 K 和 V 是通过基于输入 H_G 的投影函数 $f = w^T x + b$ 生成的, 其中 w 和 b 分别表示权重和偏置。

同样, 我们通过 (6) 增强目标蛋白质的特征表示:

$$H_T = \text{MultiHead}(Q, K, V) + H_P \quad (6)$$

Garnel 等人[66]提出了 KVQ 空间和 Intention 模块。Intention 作为注意力的泛化版本, 可以作为许多其他方法的统一联系。如图 2 所示, 我们通过 (7) 建立了一个 Intention 模块, 用于药物和蛋白质特征融合:

$$\text{提示 } (k, v, q) = e_q \quad (h) E(\kappa^{\eta} E(\kappa_0) + \gamma I^{-1} E^T E \kappa \quad v \quad i) \quad (7)$$

其中, γ 是一个可学习的参数。 E_K 、 E_V 和 E_Q 分别表示基于多层感知器的可学习嵌入式 K 、 V 和 Q 。 I 是标识矩阵。

基于意图模块, 融合药物特征矩阵 f_D 和蛋白质特征矩阵 f_T 可表示为 (8) 和 (9):

$$f_D = \eta_1 H(D) \sigma(H(\text{int})(H(T), H(D))) \quad (8)$$

$$f_T = \eta_2 H(T) \sigma(H(\text{int})(H(D), H(T))) \quad (9)$$

其中, η_1 和 η_2 是两个可学习的参数, σ 表示非线性激活函数 *softmax*。

最后, 药物和蛋白质的融合特征矩阵 f_D 和 f_T 将通过最大池化层 (10) 进行合并:

$$f = \text{Concat}(\text{maxpool}(f_{(D)}), \text{maxpool}(f_{(T)})) \quad (10)$$

5) 推理和训练: 我们根据双向意向网络获得每个 DT 对的特征代表 f 。然后, 将融合的 DT 特征 f 送入具有四个全连接层的多层感知器。最后, 根据 (11) 计算出每对 DT 的交互概率 p :

$$p = \text{Sigmoid}(Wf + b) \quad (11)$$

给定交互概率阈值 δ , 当 $p > \delta$ 时, DT 对被视为有交互, 否则, DT 对被视为无交互。

在训练过程中, 我们通过 (12) 最小化以下交叉熵损失来获得 BINDTI 的最优解:

$$\arg \min_{\Theta} \sum_i (y_i \log(p_i) + (1 - y_i) \log(1 - p_i)) + \lambda \|\Theta\|_2^2 \quad (12)$$

其中, Θ 表示所有可学习权重矩阵和偏置向量的集合, y_i 和 $p_{(i)}$ 分别表示第 i 个 DT 对的地面实况标签和预测标签, λ 表示用于 L2 正则化的超参数。

III. 结果

A. 实验装置

AUC、AUPRC、准确率、F1-分数和马修斯相关系数 (MCC) 是评估 BINDTI 性能的评价指标。BINDTI 使用 Pytorch 实现。我们首先训练了 BINDTI 模型, 并在人类数据集上获得了最佳超参数组合。然后对 BINDTI 中的其他参数进行训练, 并在 BINDTI 在验证集上计算出最佳性能时确定其最佳值。BINDTI 的最终性能是在测试集上获得的。在 BINDTI 中, 我们设置了 epoch_size= 100、batch_size= 64、learning_rate= 1e-4、learning_decay= 0.5、weight_decay= 1e-5、atom_dim= 128、amino_acid_dim 128、amino_acid_dim 1e-5、=128, ACmix_layers= 3, GCN_layers= 3, attention_heads =8, 以及 MLP_hidden_size= 512。

模拟真实的 DTI 预测应用场景, 评估模型的泛化能力和可靠性、

我们将 BINDTI 与其他四种基线方法在两种不同的实验设置下进行了比较 [46], [61]:

E_1 : 每个数据集按 7:1:2 的比例随机分为三组: 训练集、验证集和测试集。在这种情况下, 验证集/训练集/测试集中药物 (即原子数) 和靶标 (即氨基酸数) 的大小分布以分类散点图的形式进行描述。结果可在以下网址获得: <https://github.com/plhnu/BINDTI/tree/main/Distributions/distributions>。此外, 我们还评估了训练集和测试集之间药物相似性的分布情况, 以及两个集之间目标相似性的分布情况。药物之间的相似性使用 RDKit python 工具包计算, 该工具包可在 <https://www.rdkit.org/> 上获取。原蛋白之间的相似性根据参考文献[68]提供的方法计算。[68]因此, 训练集和测试集之间的药物相似性分布和靶标相似性分布可在以下网址获得: <https://github.com/plhnu/BINDTI/tree/main/Distributions/Similarity>。

E_2 : 对于每个数据集, 首先从所有 DT 对中随机抽取 10%, 按 1:2 的比例分成验证集和测试集; 然后, 将剩余的 90% 的 DT 对作为训练集; 最后, 从训练集中删除在验证集和测试集中出现过药物和/或目标的 DT 对。

在 E_1 和 E_2 条件下, 我们通过不同的随机种子对每个数据集进行了五次独立分区, 并将每次得到的分区在 BINDTI 和四种基线方法上独立运行。也就是说, 评估 BINDTI 和四种基线方法的实验重复了五次。五次独立运行结果的平均值 (标准偏差) 被视为最终性能。

此外, 我们还进行了 5 倍交叉验证来评估 BINDTI 性能。在 5 倍交叉验证中, 所有 DT 对被随机分成大致相等的五个部分, 即每轮随机抽取 80% 的 DT 对作为训练集, 剩余的 20% 作为测试集。

B. 基准方法

BINDTI 的性能与以下四种基线进行了比较: (1) CPI-GNN [48]: CPI-GNN 利用 GNN 和 CNN 分别对药物和蛋白质特征进行编码, 然后将得到的两个潜向量并入神经网络进行化合物-蛋白质关联推断; (2) Trans-formerCPI [69]: TransformerCPI 将药物和蛋白质作为两类不同的序列, 然后通过 CNN 和 GCN 分别生成药物原子表示和蛋白质序列表示, 最后利用去编码器获取 DT 特征, 并利用线性层计算每个 DT 对的相互作用概率; (3) MolTrans [61]: MolTrans 首先通过频繁连续子序列方法将药物和蛋白质解构为具有明确子序列的两组, 然后基于 Trans-former 嵌入模块获取药物和蛋白质的增强上下文嵌入表示, 随后对 DTI 地图进行建模

通过点积, 最后结合 CNN 和全连接网络实现新的 DTI 识别[52];

(4) IFDTI [70]: IFDTI 首先通过双向编码器-解码器架构根据药物和蛋白质的子结构提取其交互特征, 然后通过 GAT 和 CNN 分别提取其独立特征, 最后将所有提取的特征融合并输入多层全连接网络进行 DTI 推断。上述基线是经典的基于深度学习的 DTI 预测模型, 其 DTI 分类性能优于浅层模型[61]。其参数设置与相应出版物提供的参数设置相同。

C. 结果比较

在 BindingDB、BioSNAP 和 DrugBank 数据集上, BINDTI 与 CPI-GNN、TransformerCPI、MolTrans 和 IFDTI 四种 E_1 条件下的基线方法进行了比较。如表 II 所示, 与上述四种基线方法相比, BINDTI 计算出了最佳的 AUC、AUPRC、准确度、F1-score 和 MCC, 其次是 IFDTI。特别是在 BindingDB 上, BINDTI 的 AUC、AUPRC 和 MCC 值分别比 MolTrans 好 2.53%、3.62% 和 8.92%。GNN-CPI、TransformerCPI、MolTrans 和 IFDTI 是端到端的代表学习框架, 其性能明显优于传统的 DTI 分类方法。BINDTI 获得了最佳性能, 从而阐明了其卓越的端到端学习能力。

人类数据集是一个不平衡数据集。在人类数据集上, BINDTI 与上述四种基线方法在 E_1 和 E_2 条件下进行了比较。在 E_2 条件下, 正 DT 对和负 DT 对的比例设定为 1:2。如表 III 所示, 在 E_1 条件下, BINDTI 的性能排名第二。在 E_2 条件下, 五种 DTI 预测方法的 AUC、AUPRC、准确率、F1-分数和 MCC 都大大降低, 而 BINDTI 在很大程度上超过了其他四种基线方法。这表明 BINDTI 可以更精确、更有效地推断未知药物与未知蛋白质之间的潜在相互作用。此外, 与其他四种方法相比, BINDTI 更适合处理不平衡数据集。

表 IV 显示了 BINDTI 和所有四个基线在四个 DTI 数据集上进行 5 倍交叉验证的性能。如表四所示, 在 5 倍交叉验证下, BINDTI 在 BindingDB、BioSNAP 和 DrugBank 数据集上获得了最佳的 AUC、AUPRC、准确率、F1-score 和 MCC, 明显优于四个基线。虽然 BINDTI 在人类数据集上的计算性能略低, 但差距非常小。因此, BINDTI 可以从未知的 DT 对中有用地识别出潜在的 DTI。

此外, 我们还在 E_1 和 5 倍交叉验证条件下对 BINDTI 和四个基线模型进行了统计检验。我们根据基线模型的 AUC 值对其与 BINDTI 进行了 t 检验, 并分别计算了平均 AUC 的差值、t 值和 p 值。差值和 t 值越大, 说明 BINDTI 优于相应的基线方法。p 值越小, 说明 BINDTI 与四种方法之间的显著差异越大。

表 II
e1条件下BINDINGDB、BIOSNAP和DRUGBANK的性能比较

方法	AUC	亚太区 域中心	准确性	F1 分数	MCC
绑定数据库					
CPI-GNN	0.6087-1-0.0089	0.5174-1-0.0147	0.5972-£0.0080	0.3731- 0.0567	0.1321- 0.0120
TransformerCPI	0.8953-1-0.0023	0.8601-1-0.0030	0.8115-1-0.0037	0.7806-1-0.0036	0.6161-1-0.0067
MolTrans	<u>0.9354-1-0.0033</u>	<u>0.9084-1-0.0044</u>	<u>0.8642-1-0.0080</u>	<u>0.8398-1-0.0095</u>	<u>0.7222-1-0.0163</u>
IIFDTI	0.9242-1-0.0026	0.9014-1-0.0048	0.8329-£0.0033	0.8179-£0.0033	0.6743-£0.0043
BINDTI	0.9607-1-0.0019	0.9446-1-0.0024	0.9073-1-0.0026	0.9080-1-0.0018	0.g114-1-0.0045
BioSNAP					
CPI-GNN	0.7071-1-0.0042	0.7237-1-0.0049	0.6656-1-0.0055	0.6457-1-0.0104	0.3349-1-0.0115
TransformerCPI	0.8436-1-0.0216	0.8590-1-0.0157	0.7709-1-0.0210	0.7668-1-0.0270	0.5431-1-0.0415
MolTrans	0.8796-1-0.0060	0.8829-1-0.0071	<u>0.800J- 0.0045</u>	0.8018-£0.0125	0.6034-£0.0073
IIFDTI	<u>0.8953-1-0.0038</u>	<u>0.8981-1-0.0056</u>	0.7980-1-0.0037	<u>0.8157-1-0.0020</u>	<u>0.6062-1-0.0050</u>
BINDTI	0.9027-1-0.0044	0.9020-1-0.0065	0.8333-1-0.0090	0.8355-1-0.0056	0.6675-1-0.0171
药物库					
CPI-GNN	0.6951-1-0.0056	0.7344-1-0.0029	0.6599-1-0.0057	0.6097-1-0.0098	0.3331-1-0.0096
TransformerCPI	0.8557-1-0.0073	0.8J84-1-0.0077	<u>0.7768-1-0.0078</u>	0.7801-1-0.0109	0.5540-1-0.0159
MolTrans	0.8600-J-0.0049	0.8661-1-0.0065	0.7726-£0.0178	0.7790-£0.0037	0.5497-£0.0273
IIFDTI	<u>0.8712-1-0.0025</u>	<u>0.8726-1-0.0029</u>	0.7765-1-0.0081	<u>0.7974-1-0.0035</u>	<u>0.5641-1-0.0128</u>
BINDTI	0.8819-1-0.0038	0.8830-1-0.0044	0.8093-1-0.0056	0.8132-1-0.0035	0.6195-1-0.0101

注：最佳结果以粗体标出，次佳结果以下划线标出。

表 III
e1 和 e2 条件下人类数据集的性能比较

方法	AUC	亚太区域中心	准确性	F1 分数	MCC
设置+1					
CPI-GNN	0.9582-1-0.0024	0.9554-1-0.0081	0.8946-1-0.0040	0.8909-1-0.0035	0.7893-1-0.0078
TransformerCPI	0.9654-1-0.0040	0.9J99-1-0.0062	0.9120-1-0.0055	0.9030-1-0.0076	0.8228-1-0.0107
MolTrans	0.9838-1-0.0044	0.9G31-1-0.0044	0.9428-1-0.0126	<u>0.9364-1-0.0127</u>	0.g850-1-0.0246
IIFDTI	<u>0.9813-1-0.0031</u>	<u>0.9771-1-0.0039</u>	0.9285-1-0.0125	0.9216-1-0.0122	0.8574-1-0.0236
BINDTI	<u>0.9813-1-0.0040</u>	0.9769-1-0.004J	<u>0.940J-1-0.0087</u>	0.9385-1-0.0092	<u>0.8796-1-0.0175</u>
设置+z					
CPI-GNN	<u>0.7369-1-0.0343</u>	<u>0.7217-1-0.0668</u>	<u>0.6545-1-0.0518</u>	0.5137-1-0.1105	0.3437-1-0.1134
TransformerCPI	0.7174-J-0.0457	0.6899-1-0.0587	0.6406- 0.0530	0.3715- 0.1840	0.2770-£0.1135
MolTrans	0.7198-1-0.0276	0.6652-1-0.0284	0.6270-1-0.0354	0.3719-1-0.1079	0.2481-1-0.0639
IIFDTI	0.7232-1-0.0239	0.7163-1-0.0174	0.6745-1-0.0197	<u>0.5054-1-0.0458</u>	<u>0.3541-1-0.0272</u>
BINDTI	0.7655-J-0.0402	0.7556-1-0.0350	0.6424-£0.0686	0.7235-CO.0269	0.3555- 0.0990

注：最佳性能和次佳性能分别以粗体和下划线标出。


表 IV
在 BINDINGDB、BIOSNAP、DRUGBANK 和 HUMAN 5 倍交叉验证下的性能比较

方法	AUC	亚太区 域中心	准确性	F1 分数	MCC
绑定数据库					
CPI-GNN	0.6808-1-0.1498	0.6187-1-0.1756	0.6476-£0.1299	0.5034-£0.2150	0.2622-£0.2746
TransformerCPI	0.9409-1-0.0033	<u>0.9248-1-0.0045</u>	0.8748-1-0.0066	0.8540-1-0.0081	0.7445-1-0.0133
MolTrans	<u>0.9418-1-0.0049</u>	0.9238-1-0.0102	<u>0.8767-1-0.0111</u>	<u>0.8561-1-0.0147</u>	<u>0.7504-1-0.0222</u>
IIFDTI	0.9272-1-0.0071	0.9057-1-0.0098	0.8363-1-0.0119	0.8260-1-0.0112	0.6835-1-0.0199
BINDTI	0.9655-1-0.0036	0.9519-1-0.0045	0.9130-1-0.0085	0.9141-1-0.0061	0.8242-1-0.0162
BioSNAP					
CPI-GNN	0.7109-1-0.0161	0.7295-1-0.0132	0.6730-1-0.0162	0.6522-1-0.0118	0.3506-1-0.0336
TransformerCPI	0.8966-1-0.0066	<u>0.9030-1-0.0089</u>	<u>0.8212-1-0.0074</u>	<u>0.8235-1-0.0071</u>	<u>0.6430-1-0.0144</u>
MolTrans	0.8895-1-0.0072	0.8949-1-0.0041	0.8105-£0.0074	0.8114- 0.0079	0.6239- 0.0136
IIFDTI	<u>0.8968-1-0.0082</u>	0.8990-1-0.0132	0.7945-1-0.0110	0.8160-1-0.0082	0.6030-1-0.0163
BINDTI	0.9046-1-0.0028	0.9061-1-0.0041	0.8341-1-0.0066	0.8373-1-0.0028	0.6694-1-0.0118
药物库					
CPI-GNN	0.7244-1-0.0801	0.7674-1-0.0621	0.6780-1-0.0615	0.6504-1-0.0772	0.3665-1-0.1183
TransformerCPI	0.8718-1-0.0044	0.8773-1-0.0071	<u>0.7926-1-0.0070</u>	0.7991-1-0.0093	<u>0.5856-1-0.0140</u>
MolTrans	0.8709-1-0.0080	<u>0.8790-1-0.0092</u>	0.7892-1-0.0097	0.7983-1-0.0101	0.5803-1-0.0183
IIFDTI	<u>0.8736-1-0.0030</u>	0.8756-1-0.0065	0.7827-1-0.0121	<u>0.8057-1-0.0092</u>	0.5738-1-0.0183
BINDTI	0.8881-1-0.0066	0.8884-1-0.0097	0.8223-1-0.0071	0.8249-1-0.0045	0.6451-1-0.0142
人类					
CPI-GNN	0.9649-1-0.0069	0.9611-1-0.0081	0.8997-1-0.0180	0.8926-1-0.0237	0.8016-1-0.0341
TransformerCPI	<u>0.9820-J-0.0046</u>	0.9774-1-0.0046	0.9360- 0.0084	0.9273- 0.0083	0.8706-£0.0162
MolTrans	0.9809-1-0.0078	0.9799-1-0.0063	0.9500-1-0.0087	0.9328-1-0.0173	0.g989-1-0.0174
IIFDTI	0.9834-1-0.0036	0.9798-1-0.0054	<u>0.9423-1-0.0079</u>	<u>0.9353-1-0.0090</u>	<u>0.8840-1-0.0155</u>
BINDTI	0.9794-J-0.0036	0.9753-1-0.0102	0.9407-£0.0075	0.959g-CO.0055	0.8800- 0.0147

表 V

在 E_1 和 5 倍交叉验证条件下对 BINDINGDB、BIO SNAP、DRUGBANK 和人类进行的统计测试

Method	Setting E_1			5-fold cross-validation		
	<i>difference</i>	<i>t</i>	<i>p</i>	<i>difference</i>	<i>t</i>	<i>p</i>
BindingDB						
CPI-GNN	0.3520	77.5286	<0.001	0.2847	4.2480	<0.01
TransformerCPI	0.0654	43.6206	<0.001	0.0246	11.2497	<0.001
MolTrans	0.0253	13.2450	<0.001	0.0237	8.6735	<0.001
IIFDTI	0.0365	22.6115	<0.001	0.0383	10.7751	<0.001
BioSNAP						
CPI-GNN	0.1956	64.7855	<0.001	0.1937	26.4411	<0.001
TransformerCPI	0.0592	5.3759	<0.001	0.0080	2.4991	0.0370
MolTrans	0.0232	6.2478	<0.001	0.0151	4.3492	<0.01
IIFDTI	0.0074	2.5842	0.0324	0.0078	2.0308	0.0768
DrugBank						
CPI-GNN	0.1868	55.2741	<0.001	0.1637	4.5541	<0.001
TransformerCPI	0.0262	6.3739	<0.001	0.0163	4.6013	<0.01
MolTrans	0.0219	7.1005	<0.001	0.0172	3.7028	<0.01
IIFDTI	0.0108	4.7466	<0.01	0.0146	4.5204	<0.01
Human						
CPI-GNN	0.0231	9.9007	<0.001	0.0145	4.1605	<0.01
TransformerCPI	0.0159	5.5660	<0.001	-0.0026	-0.9944	0.3491
MolTrans	-0.0025	-0.8413	0.4246	-0.0015	-0.4007	0.6991
IIFDTI	0.0000	0.0033	0.9974	-0.0040	-1.7540	0.1175

图 3. 在 E_1 条件下, 不同 ACmix 层数的 BINDTI 在人类数据集上的性能。

一般来说, P 值小于 0.05 表示差异显著。一般来说, P 值小于 0.05 表示差异显著。如表 V 所示, BINDTI 在 BindingDB、BioSNAP 和 DrugBank 上的表现明显优于四种基线, 在 Human 上的表现也不相上下。

D. 消融实验

在本节中, 我们进行了多项消融实验。首先, 如图 3 所示, 我们评估了不同 ACmix 层数对 Human 数据集上 BINDTI 性能的影响。结果表明, 当 BINDTI 使用 3 层 ACmix 时, 性能最佳。

接下来, 我们在 BioSNAP 数据集上进行了消融实验, 以评估 BINDTI 框架中双向 Intention 网络的有效性。我们考虑了 BINDTI 的三个变量: 单侧药物意向、单侧蛋白质意向以及它们的线性组合 [46]。两个单侧 Intention 类似于 CPI-GNN 提出的神经注意机制[48]。

表 VI

双向机制的消融实验
 E_1 级生物物联网计划

Method	AUC	AUPRC	MCC
Linear concatenation	<u>0.8979±0.0031</u>	<u>0.9007±0.0039</u>	<u>0.6567±0.0071</u>
One side protein Intention	0.8842±0.0062	0.8824±0.0081	0.6236±0.0187
One side drug Intention	0.8934±0.0016	0.8976±0.0022	0.6482±0.0091
Bi-directional Intention	0.9027±0.0044	0.9020±0.0065	0.6675±0.0171

Note: The best performance and the second-best performance are highlighted in bold and underlined, respectively.

矩阵我们在 BINDTI 中使用单侧关注取代了双向 Intention, 从而获得了上述两种变体。线性串联是在最大池化层之后对药物和蛋白质特征向量进行的简单串联操作[46]。如表 VI 所示, 双向 Intention (即 BINDTI) 比线性连接和单侧药物或目标注意力更能有效地融合药物和蛋白质特征。

最后, GCN 展示了强大的药物特征再现能力。为了评估 GCN 在 BINDTI 框架中的有效性, 我们用 GAT 取代了 GCN, 并评估了 BINDTI 在三种不同组合下的性能, 即 GAT+ACmix、GAT+CNN 和 GCN+ACmix (即 BINDTI)。

在四个数据集上的计算结果。如表 VII 所示, 当 BINDTI 结合 GCN 和 ACmix 时, BINDTI 计算出了最佳的 AUC、AUPRC 和 MCC。因此, 我们选择 GCN 作为模型中的药物特征编码器。

E. 融合特征的可视化

为了研究融合特征的分布情况, 并更直观地展示 BINDTI 的卓越性能, 我们在人类数据集和 BioSNAP 数据集上对 BINDTI 融合特征进行了可视化处理。我们首先从测试集中随机抽取了 1,200 个 DT 对, 然后用 UMAP[71] 对融合特征进行了降维处理。降维后的结果




图 4.融合特征的可视化。(a) 人类数据集的可视化。(b) BioSNAP 数据集的可视化。两个数据集上从左到右的三个子图分别对应于(1)通过意图（Intention）融合蛋白质特征的药物特征和通过意图（Intention）融合药物特征的蛋白质特征；(2)带真实标签的 DT 对联合特征；(3)带预测标签的 DT 对联合特征。0 代表没有相互作用的 DT 对，1 代表有相互作用的 DT 对。

表 VII

E1 下四个数据集的 GCN 消融实验

Method	AUC	AUPRC	MCC
BindingDB			
GAT+ACmix	0.9575±0.0021	0.9407±0.0023	0.7967±0.0074
GAT+CNN	0.9576±0.0023	0.9404±0.0050	0.8028±0.0072
GCN+ACmix	0.9607±0.0019	0.9446±0.0024	0.8114±0.0045
BioSNAP			
GAT+ACmix	0.8968±0.0026	0.8929±0.0034	0.6658±0.0048
GAT+CNN	0.8993±0.0033	0.8966±0.0079	0.6646±0.0052
GCN+ACmix	0.9027±0.0044	0.9020±0.0065	0.6675±0.0171
DrugBank			
GAT+ACmix	0.8725±0.0022	0.8698±0.0048	0.6026±0.0069
GAT+CNN	0.8764±0.0016	0.8757±0.0041	0.6158±0.0053
GCN+ACmix	0.8819±0.0038	0.8830±0.0044	0.6195±0.0101
Human			
GAT+ACmix	0.9765±0.0014	0.9717±0.0042	0.8724±0.0060
GAT+CNN	0.9771±0.0030	0.9700±0.0043	0.8694±0.0125
GCN+ACmix	0.9813±0.0040	0.9769±0.0045	0.8796±0.0175

Note: The best performance and the second-best performance are highlighted in bold and underlined, respectively.

图 4 显示了这些数据集的可视化情况。具体而言，每个数据集都通过三类数据进行了可视化：（1）通过意图融合蛋白质特征的药物特征和通过意图融合药物特征的蛋白质特征；（2）带真实标签的 DT 对联合特征；以及（3）带预测标签的 DT 对联合特征。结果表明，BINDTI 可以将融合了药物和蛋白质特征的特征映射到不同的区域，从而形成更密集的药物簇和蛋白质簇。两个 DT 联合特征在空间中的分布相对稀疏。此外，DT 联合特征的可视化结果与

预测的标签与真实标签基本一致，这表明它为下游预测学习到了有用的 DT 特征。

F. 案例研究

虽然 BINDTI 在每个基准数据集上都表现出了良好的 DTI 分类能力，但这还不足以说明它是否能有效识别新型 DTI。为了确定其可信度，我们分别从药物和靶标的角度进行了两个案例研究。首先，在 DrugBank 数据集上对 BINDTI 进行训练，去除案例研究中查询药物/靶点的所有 DTI。随后，计算查询药物/靶点与其他所有靶点/药物之间的相互作用概率，并根据其关联概率对 DT 对进行排序。最后，通过 DrugBank 数据库[60]对预测的 DTIs 进行验证。

我们选择了 NADH 和 Beta-D-Glucose 这两种药物进行基于药物的案例研究。口服补充 NADH（DB00157）可以减少单纯性疲劳和能量损耗性疾病，如慢性疲劳综合征和纤维肌痛。补充 NADH 还能增强注意力和记忆力，并提高运动耐力 [60]、[72]、[73]。β-D-葡萄糖（DB02379）是生物体的主要能量来源[60]。与这两种药物相互作用的前 10 个已发现靶点如表 VIII 所示。结果表明，在 DrugBank 数据库中，所有前 10 个预测靶点都与这两种药物有真正的联系。

表 VIII
预测与 NADH 和 NADH 相互作用的 10 大靶标
BETA-D-GLUCOSE BY BINDTI

Rank	NADH (DB00157)		Beta-D-Glucose (DB02379)	
	UniProt ID	Result	UniProt ID	Result
1	P48163	True	Q60053	True
2	P49821	True	P14090	True
3	Q16798	True	O07653	True
4	P11586	True	P26827	True
5	Q13630	True	Q9BW91	True
6	P07327	True	P17802	True
7	Q92781	True	Q54331	True
8	P31937	True	P23904	True
9	P17516	True	P05162	True
10	Q13423	True	Q701N4	True

表 IX
BINDTI 预测与 H1R 和 ADRA1C 发生相互作用的 10 大候选药物

Rank	H1R (P35367)		ADRA1C (P35348)	
	DrugBank ID	Result	DrugBank ID	Result
1	DB06698	True	DB00943	Unconfirmed
2	DB04905	True	DB00540	True
3	DB01237	True	DB01151	True
4	DB09167	True	DB00661	True
	DB04837	True	DB00458	True
5		True		True
6	DB00719	True	DB00211	True
	DB00726	True		True
7	DB00366	True	DB04948	True
8		True	DB06207	True
9	DB00283	True	DB06207	True
10	DB04946	True	DB00575	True

同样，我们选择了 H1R 和 ADRA1C 这两个靶点进行基于靶点的病例研究。H1R (P35367) 在中枢神经系统中介导神经传递 [60]，[74]。ADRA1C (P35348) 通过与 G 蛋白的结合发挥其作用 [75]。与这两个靶点相互作用的前 10 种预测药物见表 IX。结果表明，除 DB00943 外，其他 9 种预测药物均已在 DrugBank 数据库中证实与两个靶点有真正的相互作用。结果进一步证明了 BINDTI 在发现新药或新靶点的 DTI 方面的可靠性。

IV. 讨论

DTI 鉴定对促进药物研发非常重要。目前基于深度学习的 DTI 预测方法大致可分为非端到端方法和端到端方法。非端到端方法根据药物和靶蛋白的化学结构和生物学信息提取药物和靶蛋白的特征描述符。然而，端到端 DTI 预测方法可以从原始生物数据中提取高质量的特征，而无需人工干预。因此，基于生化数据监督的端到端深度学习框架为 DTI 预测提供了前景广阔的见解。

在本手稿中，我们开发了 BINDTI，这是一个用于识别新 DTI 的端到端框架。BINDTI 首先使用 GCN 根据 SMILES 字符串获得的二维分子图编码药物特征。接着，BINDTI 利用 ACmix 根据氨基酸序列对蛋白质特征进行编码。第三、

BINDTI 可通过双向意图网络，并将一个 DT 对描述为一个向量。最后，True BINDTI 根据融合的 DT 特征，通过多层 perceptron 对未知 DT 对进行分类。

我们进行了多项实验来评估 BINDTI 的性能。在 BindingDB、BioSNAP 和 DrugBank 数据集上，在 E_1 条件下，BINDTI 的性能大大优于四种基线方法（CPI-GNN、TransfomerCPI、MolTrans 和 IIFDTI）。在人类数据集上，BINDTI 的计算性能良好

在 E_1 和 E_2 条件下与上述四种基线方法进行比较。

5 倍交叉验证的实验结果进一步表明

验证了其良好的 DTI 分类性能和泛化能力。此外，消融实验结果表明，双向 Intention、ACmix 和 GCN 可以明显提高 DTI 预测性能。最后

融合特征可视化和案例研究表明

BINDTI 预测的结果与以下结果基本一致

真正的拟议的 BINDTI 框架获得了良好的 DTI 识别能力，这可归因于以下特点：

(i) 通过综合考虑药物的化学结构，GCN 可以提取丰富的药物特征表征。

特征和邻近信息；(ii) ACmix，该完美聚合了 CNN 和自注意力机制，有效提取蛋白质特征；(iii) 双向意图网络，其中包含多头注意力和

意图，大大增强了药物和蛋白质的特征表示，更好地融合了药物和靶标特征，并提高了模型的可解释性和概括能力。

在我们提出的 BINDTI 框架中，我们使用药物的二维分子图来提取其特征，从而得到了许多药物分子的稀疏特征。今后，我们将根据词嵌入的概念，结合药物的 SMILES 字符串，进一步改进药物的特征表示。此外，BINDTI 通过蛋白质序列学习蛋白质表征，并没有考虑其三维结构。DeepMind 的 AlphaFold 可以生成丰富的蛋白质三维结构，为基于蛋白质三维结构的 DTI 预测打开了大门[76], [77]。因此，我们还将扩展基于三维结构的蛋白质特征编码的思路，进一步提高 DTI 预测性能，增加其可解释性。

此外，近年来，越来越多的非编码 RNA (ncRNA) 被发现，越来越多的证据表明它们可能影响基因表达和疾病进展，使其成为一类新的药物靶点。因此，了解 ncR-NA 与药物靶点之间的关系变得非常重要 [78]。因此，Wang 等人[79]通过结合 γ 规范正则化建立了一个稳健的 PCA 模型，用于预测小分子和 microRNA 之间的潜在关联。Liu 等人[80]提出了一种用于推断 circRNA 与耐药性关联的多模态图神经网络。与靶蛋白的特征表示类似、

非编码 RNA (如 microRNA 或 circRNA) 可以根据其核苷酸序列来, 因此 BINDTI 可能适合预测 小分子药物与非编码 RNA 之间的关联。今后, 我们将结合药物分子结构、非编码 RNA 序列和双向意向网络来预测小分子药物 与非编码 RNA 之间的关系。

V. 结论

在本手稿中, 我们通过整合 GCN、ACmix 和双向 Intention 网络, 开发了端到端 DTI 预研框架 BINDTI。对比实验 结果表明, BINDTI 为识别潜在的 DTI 提供了一个强大而稳健的工具。我们预计, 我们提出的 BINDTI 模型可以找到新的低成本候选药物, , 促进药物的虚拟筛选, 进一步推动药物的重新定位和药物发现。

参考资料

- [1] L.Peng, B. Liao, W. Zhu, Z. Li, and K. Li, "Predicting drug-target interactions with multi-information fusion," *IEEE J. Biomed.*, vol. 21, no. 2, pp.
- [2] X.Chen 等人, "药物-靶点相互作用预测: 数据库、网络服务器 和计算模型," *Brief*, vol. 17, no.4, pp. 696-712, 2016.
- [3] C.-C. Wang, Y. Zhao, and X. Chen, "Drug-pathway association prediction: Drug-pathway association prediction.Wang, Y. Zhao, and X. Chen, "Drug-pathway association prediction: 从实验结果到计算模型," *Brief.Bioinf.*, vol. 22, no.3, 2021, Art.
- [4] J. Hu 等人, "DrugormerDTI: 用于药物 - 靶点相互作用预测的药物图解析器", *Comput.Biol.Med.*, vol. 161, 2023, Art.
- [5] T.-H. Li, C.-C.Li, C.-C.Wang, L. Zhang, and X. Chen, "Snrmpacdc: Computational model focused on siamese network and random matrix projection for anticancer synergistic drug combination prediction," *Brief*, vol. 24, no. 1, 2023, Art.
- [6] H.Hu 等人, "基于单细胞组学数据的基因功能和细胞表面蛋白关联分析", 《*计算生物学*》(*Comput.Biol.Med.*, vol. 157, 2023, Art.
- [7] Y. Zhang, Y. Hu, N. Han, A. Yang, X. Liu, and H. Cai, "A survey of drug-target interaction and affinity prediction methods via graph neural networks," *Comput.Biol.Med.*, 2023, Art.
- [8] Q.Zhao, G. Duan, H. Zhao, K. Zheng, Y. Li, and J. Wang, "GIFDTI: Prediction of drug-target interactions based on global molecular and inter- molecular interaction representation learning," *IEEE/ACM Trans.Comput.Biol.Bioinf.*, pp.
- [9] L.Peng 等人, "从单细胞转录组学推断和分析土木微环境中的细胞-细胞通讯: 数据资源和计算策略", 《*Bioinf.Bioinf.*, 2022, Art. no. bbac234.
- [10] S.-H. Wang, C.-C.Wang, C.-C. Wang, L. Huang, L.-Y.Wang, C.-C. Wang, L. Huang, L.-Y.Miao, and X. Chen, "Dual- network collaborative matrix factorization for predicting small molecule- mirna associations," *Brief.Bioinf.*, 第 23 卷, 第 1 期, 2022 年, 艺术编号: bbab500.
- [11] Y.-S.Jung, Y. Kim, and Y.-R. Cho, "Comparative analysis of network- based approaches and machine learning algorithms for predicting drug- target interactions," *Methods*, vol. 198, pp.Cho, "Comparative analysis of network- based approaches and machine learning algorithms for predicting drug- target interactions," *Methods*, vol. 198, pp.
- [12] S.Singh, Q. B. Baker, and D. B. Singh, "Molecular docking and molecular dynamics simulation," *Bioinformatics*, pp.
- [13] N.Shaikh, M. Sharma, and P. Garg, "An improved approach for predicting drug-target interaction : Proteochemometrics to molecular docking," *Mol. BioSyst.BioSyst.*, vol. 12, pp.
- [14] X.Yang, Y. Liu, J. Gan, Z.-X.Xiao, and Y. Cao, "FitDock: Bioinf.Bioinf., vol. 23, 2022" Art. no.
- [15] M.Li, Z. Lu, Y. Wu, and Y. Li, "BACPI: 用于化合物-蛋白质相互作用和结合亲和力预测的双向注意神经网络", 《*生物信息学*》, 第 38 卷, 第 1995-2002 页, 2022 年。
- [16] L.Huang 等人, "CoaDTI: 基于多模态协同注意的药物-靶点相互作用注释框架", 《*生物信息*》, 第 23 卷, 2022 年, 艺术编号 bbac446. *生物信息*》, 第 23 卷, 2022 年, 艺术编号: BBAC446.
- [17] X.Chen, M.-X. Liu, and G.-Y.Liu, and G.-Y. Yan, "Drug-target interaction prediction by random walk on the heterogeneous network," *Mol.BioSystems*, vol. 8, no. 7, pp.
- [18] S.Fakhraei, B. Huang, L. Raschid, and L. Getoor, "Network-based drug- target interaction prediction with probabilistic soft logic," *IEEE/ACM Trans.Comput.Biol.Bioinf.*, pp.
- [19] H.Wang, F. Huang, Z. Xiong, and W. Zhang, "A heterogeneous network- based method with attentive meta-path extraction for predicting drug- target interactions," *Brief.Bioinf.*, 2022, Art.
- [20] S.Sadeghi, J. Lu, and A. Ngom, "A network-based drug repurposing method via non-negative matrix factorization," *Bioinformatics*, vol. 38, no.5, pp.
- [21] X.Su, P. Hu, H. Yi, Z. You, and L. Hu, "Predicting drug-target interactions over heterogeneous information network," *IEEE J. Biomed.*, vol. 27, no. 1, pp.
- [22] Z.Wu 等人, "wSDTNBI: 基于网络的新型虚拟筛选推理方法", 《*化学科学*》, 第 13 卷, 第 2 期, 13, no.4, pp.
- [23] M.M.Bagherian, E. Sabeti, K. Wang, M. A. Sartor, Z. Nikolovska-Coleska 和 K. Najarian, "预测 药物靶点相互作用的机器学习方法和数据库: Bioinf.22, no. 1, pp.
- [24] X.Chen, Y. Gong, D.-H. Zhang, Z.-H.Zhang, Z.-H. You, and Z.-W.You, and Z.-W.Li, "DRMDA: Deep Representations-based miRNA-disease association prediction," *J. Cellular Mol.Med.*, vol. 22, no. 1, pp.
- [25] L.Peng, X. He, X. Peng, Z. Li, and L. Zhang, "STGNnks: 基于图神经网络、去噪自动编码器和 k-sums 聚类的空间转录组学数据中的细胞类型识别", *Comput.Biol.Med.*, vol. 166, 2023, Art.
- [26] L.Peng, W. Xiong, C. Han, Z. Li, and X. Chen, "CellDialog: A computational framework for ligand-receptor-mediated cell-cell communication analysis III," *IEEE J. Biomed. 健康信息*》, 第 28 卷, 第 2 期, 第 580-591 页, 2024 年 1 月。
- [27] L.Peng, J. Tan, X. Tian, and L. Zhou, "EnANNDDeep: An ensemble-based lncRNA-protein interaction prediction framework with adaptive k-nearest neighbor classifier and deep models," *Interdiscipl.Sci.: Comput.*, vol. 14, no. 1, pp.
- [28] S.-S.Guo, J. Liu, X.-G. Zhou, and G.-J. Zhang, "Deepumqa: Deepumqa.Zhou, and G.-J. Zhang, "Deepumqa: 利用深度学习进行基于超快形状识别的蛋白质模型质量评估", 《*生物信息学*》, 第 38 卷, 第 7 期, 第 1895-1903 页, 2022 年。
- [29] C.-X. Peng, X.-G.Peng, X.-G.Zhou, Y.-H. Xia, J. Liu, M.-H.Xia, J. Liu, M.-H. Hou, and G.-J.Hou, and G.-J. Zhang, "Structural analogue-based protein structure domain assembly assisted by deep learning," *Bioinformatics*, vol. 38, no.
- [30] J.Liu, K. Zhao, and G. Zhang, "Improved model quality assessment using sequence and structural information by enhanced deep neural networks," *Brief.生物信息*》, 第 24 卷第 1 期, 2023 年, 艺术编号: BBAC507.
- [31] X.Chen, T.-H. Li, Y. Zhao, C.-C.Li, Y. Zhao, C.-C. Wang, and C.-C.Wang, and C.-C. Zhu, "Deep-belief net- work for predicting potential miRNA-disease association," *Brief.Zhu, "Deep-belief network for predicting potential miRNA-disease associations," Brief.Bioinf.*, 2021, Art.
- [32] L.Peng, L. Huang, Q. Su, G. Tian, M. Chen, and G. Han, "LDA-VGHB: Identifying potential lncRNA-disease associations with singular value decomposition, variational graph auto-encoder and heterogeneous Newton boosting machine," *Brief.生物信息*》, 第 25 卷, 2024 年, 艺术编号: BBAD466.
- [33] L.Zhang, X. Chen, and J. Yin, "Prediction of potential miRNA-disease associations through a novel unsupervised deep learning framework with variational autoencoder," *Cells*, vol. 8, no. 9, 2019, Art.
- [34] Y.Wang, G. Yu, J. Wang, G. Fu, M. Guo, and C. Domeniconi, "Weighted matrix factorization on multi-relational data for lncRNA-disease association prediction," *Methods*, vol. 173, pp.
- [35] F.Sun, J. Sun, and Q. Zhao, "A deep learning method for predicting metabolite-disease associations via graph neural network," *Brief.Bioinf.*, 2022, Art.
- [36] W.Wang, L. Zhang, J. Sun, Q. Zhao, and J. Shuai, "Predicting the potential human lncRNA-miRNA interactions based on graph convolution network with conditional random field," *Brief.Bioinf.*, 第 23 卷, 第 6 期, 2022 年, 艺术编号: BBAC463.
- [37] G. Fu, J. Wang, C. Domeniconi, and G. Yu, "Matrix factorization-based data fusion for the prediction of lncRNA-disease associations," *Bioinformatics*, vol. 34, no. 9, pp.
- [38] L.Peng, M. Ren, L. Huang, and M. Chen, "GeNDDN: A deep learning framework for lncRNA-disease association identification based on graph attention auto-encoder, dual-net neural architecture, and deep neural network," *Interdiscipl.Sci.: Comput.生命科学*》, 2024, doi: 10.1007/s12539-024-00619-w.
- [39] T.Wang, J. Sun, and Q. Zhao, "Investigating cardiotoxicity related with herg channel blockers using molecular fingerprints and graph attention mechanism," *Comput.Biol.医学*》, 第 153 卷, 第 2023 期, 艺术编号 106464.

- [40] P.Zhang, Y. Wu, H. Zhou, B. Zhou, H. Zhang, and H. Wu, "CLNN-loop: 不同细胞系和 CTCF 结合位点 (CBS) 配对类型中预测 CTCF 介导的染色质环的深度学习模型", 《生物医学》, 第 38 卷, 第 19 期, 第 4497-4504 页, 2022 年。
- [41] H.Wu 等人, "scHiCstack1: 基于堆叠集合学习的使用细胞嵌入的单细胞 Hi-C 分类方法", "Brief.生物信息", 第 23 卷, 第 1 期, 2022 年, 艺术编号: bbab396。
- [42] L.Peng, P. Gao, W. Xiong, Z. Li, and X. Chen, "Identifying potential ligand-receptor interactions based on gradient boosted neural network and interpretable boosting machine for intercellular communication analysis," *Comput. Biol.Biol.Med.*, 2024, Art.
- [43] L.Wang 等人, "基于计算的叠加自动编码器深度神经网络预测药物与目标相互作用的方法", *J. Comput.Biol.*, vol. 25, no.3, pp.
- [44] L.Zhang, C.-C. Wang, and X. Chen, "Predicting drug-target binding affinity through molecule representation block based on multi-head attention and skip connection," Brief.Wang, and X. Chen, "Predicting drug-target binding affinity through molecule representation block based on multi-head attention and skip connection," *Brief.生物信息*, 第 23 卷, 第 6 期, 2022 年, 艺术编号: bbac468。
- [45] Y.Wang, Y. Xia, J. Yan, Y. Yuan, H.-B. Shen, and X. Pan, "Zerobind: A protein-specific zero-shot predictor with subgraph matching for drug-target interactions," *Nature Commun.*, vol. 14, no. 1, 2023, Art.
- [46] P.Bai, F. Miljkovic, B. John, and H. Lu, "Interpretable bilinear attention network with domain adaptation improves drug-target prediction," *Nature Mach.Intell.*, vol. 5, pp.
- [47] M.Li, X. Cai, S. Xu, and H. Ji, "Metapath-aggregated heterogeneous graph neural network for drug-target interaction prediction," *Brief.生物信息*, 第 24 卷, 2023 年, 艺术编号: BBAC578。
- [48] M.Tsubaki, K. Tomii, and J. Sese, "Compound-protein interaction prediction with end-to-end learning of neural networks for graphs and sequences," *Bioinformatics*, vol. 35, pp.
- [49] X.Lin, Z. Quan, Z.-J. Wang, Y. Guo, X. Zeng, and P. S. Yu, "Effectively identifying compound-protein interaction using graph neural representation," *IEEE/ACM Trans.Comput.Biol.Bioinf.*, vol. 1, 20, pp.
- [50] Y.Luo, Y. Liu, and J. Peng, "Calibrated geometric deep learning improves kinase-drug binding predictions," *Nature Mach.Intell.*, vol. 5, no. pp.1390-1401, 2023.
- [51] I.Lee, J. Keum, and H. Nam, "Deepconv-DTI: Prediction of drug-target interactions via deep learning with convolution on protein sequences," *PLoS Comput.Biol.*, vol. 15, pp.
- [52] Q.Zhao, H. Zhao, K. Zheng, and J. Wang, "HyperAttentionDTI: Improving drug-protein interaction prediction by sequence-based deep learning with attention mechanism," *Bioinformatics*, vol. 38, pp.
- [53] S.Zheng, Y. Li, S. Chen, J. Xu, and Y. Yang, "Predicting drug-protein interaction using quasi-visual question answering system," *Nature Mach.Intell.*, vol. 2, pp.
- [54] Q.Zhao, G. Duan, M. Yang, Z. Cheng, Y. Li, and J. Wang, "AttentionDTA: Drug-target binding affinity prediction by sequence-based deep learning with attention mechanism," *IEEE/ACM Trans.Comput.Biol.Bioinf.*, vol. 20, pp.
- [55] M.Zhao, M. Yuan, Y. Yang, and S. X. Xu, "CPGL: Prediction of compound-protein interaction by integrating graph attention network with long short-term memory neural network," *IEEE/ACM Trans.Comput.Biol.Bioinf.*, vol. 20, pp.
- [56] J.Bian, X. Zhang, X. Zhang, D. Xu, and G. Wang, "MCANet: weight-based MultiheadCrossAttention network for drug-target interaction prediction," *Brief.生物信息*, 第 24 卷, 2023 年, 艺术编号: BBAD082。
- [57] M.M. K. Gilson, T. Liu, M. Baitaluk, G. Nicola, L. Hwang, and J. Chong, "BindingDB in 2015: A public database for medicinal chemistry, computational chemistry and systems pharmacology," *Nucleic Acids Res.*, vol. 44, pp.D1045-D1053, 2015.
- [58] M.Zitnik, R. Susic, and J. Leskovec, "BioSNAP datasets: 斯坦福生物医学网络数据集", 第 5 卷, 第 1 期, 2018 年。[Online].Available: <http://snap.stanford.edu/biodata>
- [59] H.Liu, J. Sun, J. Guan, J. Zheng, and S. Zhou, "Improving compound-protein interaction prediction by building up highly credible negative sample," *Bioinformatics*, vol. 31, pp.
- [60] D.S. Wishart 等人, "DrugBank: *Nucleic Acids Res.*, vol. 34, pp.D668-D672, 2006.
- [61] K.Huang, C. Xiao, L. M. Glass, and J. Sun, "MolTrans: *生物信息学*", 第 37 卷, 第 830-836 页, 2020 年。
- [62] D.Weininger, "Smiles, a chemical language and information system.方法和编码规则介绍", 《*J. Chem.Inf.Comput.科学*》, 第 28 卷, 第 31-36 页, 1988 年 2 月。
- [63] M.Li et al., "DGL-LifeSci: An open source toolkit for deep learning on graphs in life science," *ACS Omega*, vol. 6, no.41, pp.
- [64] X.Pan 等人, "论自我注意与卷积的整合", 《*Proc. IEEE/CVF Conf.计算.模式识别*》, 2022 年, 第 815-825 页。
- [65] A.Vaswani 等人, "Attention is all you need," in *Proc.Conf.Neural Inf.Process.Syst.*, 2017, pp.
- [66] M.Garnelo and W. M. Czarnecki, "探索带意图的键值查询模型空间", 2023, *arXiv:2305.10203*。
- [67] K.He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proc.Comput.Vis.Pattern Recognit.*, pp.770-778.
- [68] K.Bleakley and Y. Yamanishi, "Supervised prediction of drug-target interactions using bipartite local models", 《*生物信息学*》, 第 25 卷, 第 18 期, pp.2397-2403, 2009.
- [69] L.Chen 等人, "TransformerCPI: 通过基于序列的深度学习与自我注意机制和标签反转实验改进化合物-蛋白质相互作用预测", 《*生物信息学*》, 第 36 卷, 第 4406-4414 页, 2020 年。
- [70] Z.Cheng, Q. Zhao, Y. Li, and J. Wang, "HIFDTI: Predicting drug-target interactions through interactive and independent features based on attention mechanism," *Bioinformatics*, vol. 38, pp.
- [71] L.McInnes, J. Healy, and J. Melville, "UMAP: Uniform manifold approximation and projection for dimension reduction," 2018, *arXiv:1802.03426*.
- [72] P.P. Belenky, K. L. Bogan, and C. Brenner, "Nad metabolism in health and disease," *Trends Biochem.科学*, 第 32 卷, 第 1 期, 第 12-19 页, 2007 年。
- [73] S.-J. Lin and L. Guarente, "烟酰胺腺嘌呤二核苷酸, 转录、长寿和疾病的代谢调节器", *Curr.细胞生物学*, 第 15 卷, 15, no. 2, pp.
- [74] M.Debacker 等人, "人类组胺 h1 受体的基因组克隆、异源表达和药理学特征", 《*生物化学.生物物理研究公报*》, 第 197 卷, 第 1 期, 197, no.3, pp.
- [75] C.C. D. Wright, S. C. Wu, E. F. Dahl, A. J. Sazama, and T. D. O'Connell, "Nuclear localization drives adrenergic receptor oligomerization and signaling in cardiac myocytes," *Cellular Signalling*, vol. 24, no.3, pp.
- [76] J.Jumper 等人, 《使用 AlphaFold 进行高精度蛋白质结构预测》, 《*自然*》, 第 596 卷, 第 7873 期, 第 583-589 页, 2021 年。
- [77] K.Zhao, Y. Xia, F. Zhang, X. Zhou, S. Z. Li, and G. Zhang, "Protein structure and folding pathway prediction based on remote homologs recognition using pathreader," *Commun.*, no. 1, 2023, Art.
- [78] X.Chen, N.-N. Guan, Y.-Z.Guan, Y.-Z.Sun, J.-Q.Li, and J. Qu, "MicroRNA-small molecule association identification: From experimental results to computational models," *Brief.*, no. 1, pp.
- [79] S.Wang, C. Ren, Y. Zhang, Y. Li, S. Pang, and T. Song, "Identifying potential small molecule-miRNA associations via robust PCA based on γ -norm regularization," *Brief.Bioinf.*, 2023, Art.
- [80] Z.Liu, Q. Dai, X. Yu, X. Duan, and C. Wang, "Predicting circRNA-drug resistance associations based on a multimodal graph representation learning framework," *IEEE J. Biomed.Health Informat.*, early access, 2023, doi: [10.1109/JBHI.2023.3299423](https://doi.org/10.1109/JBHI.2023.3299423)。