

数据库和本体论

GLASS: 经实验验证的 GPCR 配体关联综合数据库

Wallace K. B. Chan^{1,†}, Hongjiu Zhang^{2,†}, Jianyi Yang²,
Jeffrey R. Brender², Junguk Hur³, Arzucan Ögür⁴ and Yang Zhang^{1,2,*}

⁽¹⁾ 美国密歇根大学生物化学系; ⁽²⁾ 美国密歇根州安阿伯市 48109 号密歇根大学计算医学与生物信息学系; ⁽³⁾ 美国北达科他大学医学与健康科学学院基础科学系; ⁽⁴⁾ 土耳其伊斯坦布尔博加齐齐大学计算机工程系

* 通信收件人:

[†] 作者们希望大家知道, 他们认为前两位作者应被视为共同第一作者, 副主编: 乔纳森·沃伦

2015年3月21日收到; 2015年4月17日修订; 2015年5月7日接受

摘要

动机: G 蛋白偶联受体 (GPCR) 可能是最有吸引力的药物靶标膜蛋白, 在当代药物发现行业中占药物靶标的近一半。虽然大多数药物发现研究都是利用现有的 GPCR 和配体之间的相互作用来鉴定新化合物, 但仍然缺乏精确注释 GPCR-配体关联的特定数据库。

结果我们开发了一个新的数据库--GLASS, 旨在为经实验验证的 GPCR 配体关联提供全面的人工编辑资源。我们提出了一种新的文本挖掘算法来收集生物医学文献中的 GPCR 配体相互作用, 然后与五个主要药理学数据集进行交叉检验, 以提高 GPCR 配体关联数据识别的覆盖面和准确性。该数据库设计了一个特殊的架构, 允许用户使用灵活的生物活性参数进行同源配体搜索。目前的数据库包含约 500,000 个独特的条目, 其中绝大多数来自配体以及与视网膜素和胰泌素样受体的关联。GLASS 数据库的最大用途是用于各种 GPCR 的 *硅学* 筛选和功能注释研究。

可用性和实施: GLASS 数据库的网站可在 <http://zhanglab.ccmb.med.umich.edu/GLASS/> 免费查阅。

联系方式 zhng@umich.edu

补充信息: [补充数据](#)可在 *Bioinformatics* online 上获取。

1 导言

G 蛋白偶联受体 (GPCR) 是最大的跨膜蛋白家族之一, 可结合细胞外分子并激活细胞内信号转导途径, 通过与异三聚 G 蛋白的相互作用介导多种生理功能。许多人类疾病、

包括癌症和糖尿病在内的许多疾病都与 GPCRs 的生物作用失常有关 (Dorsam 和 Gutkind, 2007 年)。目前, ~, 市场上 30-50% 的药物都以 GPCR 为靶点, 这使得它们成为药物开发中最具吸引力的膜受体之一 (Klabunde 和 Hessler, 2002; Overington 等人, 2006)。虽然基于实验的新型

虽然化学合成仍是药物发现的标准程序，但作为缩小药物搜索范围和指导实验设计的重要补充方法，*硅学*筛选正被越来越多的人接受。计算方法的另一个优势是速度快、成本低，可以进行高通量和大规模的数据库筛选 (Lipinski 等人, 2001 年)。

实验和计算药物发现方法都依赖于现有的 GPCR 配体实验数据，为筛选和选择新药提供洞察力。目前已开发出多种面向 GPCR 的数据库，如 GPCRDB (Hom 等人 1998 年, 等 1999 年)、TinyGRAP (Beukers 人, 等人,)、GPCR-OKB (Khelashvili 2010 年)、GDD (Gatica 和 Cavasotto, 2012 年) 以及 GPCR-RD (Zhang 和 Zhang, 2010 年)，这些数据库对阐明 GPCR 结构和功能的各种分子级研究产生了重要影响。

然而，能为 GPCR 配体相互作用提供全面资源的数据库却少之又少，而这些资源对协助 GPCR 虚拟筛选研究至关重要 (van Laarhoven 等人, 2011 年; Weill 和 Rognan, 2009 年; Zhou 和 Skolnick, 2012 年)。开发此类数据库的一个困难是，GPCR 可与大量配体以不同的结合亲和力发生关联，而许多化学文库中的 GPCR 配体关联数据往往混杂着各种假阳性结果。为了确保数据集的质量，收集 GPCR 与配体的关联数据必须经过严格的实验验证和精心的人工整理。其次，随着测序和结构基因组学项目的成功，可用的 GPCR 和配体相互作用的数量迅速增加。但大多数新研究都散见于各种出版物和档案中，这给数据库的更新带来了困难。例如，GLIDA (Okuno 等人, 2008 年) 是一个有用的 GPCR 配体结合数据库，专为化学基因组药物发现而设计；但自 2010 年 10 月起，该数据库停止了服务器更新。目前的 GLIDA 库包含约 39,000 条 GPCR 配体条目，而根据我们对药理学数据库和文献检索的结合估计，文献中可获得的不同 GPCR 配体相互作用的数量超过 500,000 条。如此大量新数据的缺失大大降低了数据库对实验和计算药物发现研究的实用性。

在这项研究中，我们开发出了一种新的 GPCR 配体关联技术。(GLASS) 数据库，作为协助 GPCR 相关药物筛选研究的通用平台。GLASS 数据库从多个原始数据来源中汲取养分，重点收集经实验验证的具有强亲和力的 GPCR 配体相互作用的全面而精确的数据。为了确保数据库的完整性并不断更新，我们采用了一种新开发的文本挖掘管道，通过搜索 PubMed 文献来发现新的 GPCR 配体相互作用，然后与主要药理学数据集进行交叉检查，以确保数据收集的质量。所有 GPCR 配体关联数据都经过人工整理，并免费提供给社区使用。

2 数据和方法

GLASS 中的 GPCR 配体关联数据由两个主要资源组成。第一个资源由 ChEMBL (Gaulton 等人, 2012)、BindingDB (Liu 等, 2007 人)、IUPHAR (Sharman 等人, 2011)、DrugBank ((Knox 等人, 2011) 和 PDSP (<http://pdsp.med.unc.edu/pdsp.php>) 五个主要药理数据集组成，其中包含各种生物活性配体和蛋白质相互作用数据。其次是从 PubMed 中进行 GPCR 特定文本挖掘。

摘要图 1 是 GLASS 结构的流程图。

2.1 数据库重组管道

首先从 UniProtKB (Magrane 和 Consortium, 2011 年) 中收集 GPCR 相关的所有已审查 UniProt ID 列表。同时提取每个 GPCR 的相关数据，如物种、基因名称和主序列。我们使用了 IUPHAR 和 UniProtKB 中的同义 GPCR 名称组合。

第二步，从 ChEMBL、BindingDB、IUPHAR、DrugBank 和 PDSP 等药理学数据库下载平面数据库。使用 UniProt ID 仅过滤与 GPCR 相关的数据条目，并将其汇编在一起。剔除了没有化学标识符的配体。同时，对 K_i 、 K_d 、 IC_{50} 和 EC_{50} 值的分布进行统计分析后发现，大多数配体-GPCR 关联实验 (> 95%) 的活性值低于 10 mM (补充图 S1)。因此，我们采用了活性过滤器、

即剔除 K_i 、 K_d 、 IC_{50} 和 EC_{50} 值高于 10 mM 的条目，以筛选出弱的和可疑的 GPCR-配体关联。一旦条目通过了所有标准，就会从原始药理学数据库中收集有关药理学数据 (如配体活性)、研究的原始文献参考文献以及化学标识符 (如 SMILES 或 InChI) 的记录。

2.2 文本挖掘管道

所有文献的摘要都是使用 BioPython (Cock 等人, , 2011 年 2009 年 等人) 通过 NCBI Entrez 系统 (Maglott) 收集的。从检索到的文本中挖掘 GPCR 与配体关联的过程包括两个步骤：识别 GPCR 名称、配体名称和结合触发器，以及识别 GPCR 与配体的相互作用 (图 1)。

步骤-1: 识别 GPCR 名称、配体名称和结合触发器。从摘要中提取 GPCR 和配体名称时使用了两种命名实体识别工具。首先，使用 SciMiner (Hur 等人, 2009 年) 识别基因和蛋白质的名称。然后将这些名称与 HGNC [HUGO (人类基因组组织) 基因命名委员会] 的官方符号 (Gray *et al.*) 由于 SciMiner 可同时识别 GPCR 蛋白和与 GPCR 结合的小肽，因此 SciMiner 返回的名称分为两类。存在于 UniProt GPCR 列表中的条目作为受体收集，不存在的条目作为可能配体收集。由于多个不同的受体可以共享同一个蛋白质缩写，因此 SciMiner 采用了基于缩写符号和较长描述在同一文档中共同出现的评分方法，以克服缩写的模糊性。

其次，我们利用 ChemSpot 2.0 (Rocktaschel 等人, 2012 年) 来提取小分子和短肽的化学名称通常被认为比蛋白质名称识别更具挑战性，因为不同文献使用的命名系统各不相同。为了提高化学识别的灵敏度，ChemSpot 使用了一个混合管道，该管道整合了一个为 IUPAC 条目识别而训练的条件随 (CRF) 模型，以及一种基于词典的方法，该方法由 ChemIDplus 建立，用于提取药物、缩写、分子式和琐碎名称。然后将识别出的化学名称与 InChI 字符串 (Rocktaschel *et al.*




图 1.构建 GLASS 数据库的流程图

对于这两组 GPCR 和配体实体,我们计算了每份摘要的出现频率,随后将其与原始摘要文本和命名实体的位置一起存储在数据库中。命名频率数据随后用于对蛋白质和配体查询页面中的文本挖掘结果进行排序。所有 ChemSpot 鉴定结果都被视为可能的配体,并在步骤 2 中进行测试。

结合触发器是明确描述配体和 GPCR 名称之间生物学关系的关键词,通过正则表达式匹配从目标句中识别出来。我们的正则表达式词典涵盖了三类触发词: (i) 描述生物现象的动词,如“结合”、“激活”、“拮抗”; (ii) 描述配体和 GPCR 名称的名词和形容词,如“结合”、“激活”、“拮抗”。

(iii) 描述相互作用属性的名词,包括 K_i 、“ K_d ”、“亲和力”、“ EC_{50} ”、“ IC_{50} ”。对 200 篇人工标注摘要进行的基准测试表明,正则表达式可以检索到正确的配体-GPCR 结合触发器,精确度为 78.8%,召回率为 86.0%。

第二步: 配体-GPCR 关联识别。使用基于依赖树的机器学习模型识别 GPCR 和配体名称之间的关联,该模型是在一组已知配体-GPCR 关联的摘要中训练出来的。Ozgur 和同事曾提出过基于依赖树的分类方法,用于从文本挖掘中提取蛋白质与蛋白质之间的相互作用。




图 2. 根据句子“我们的研究表明，HM74A（而非 HM74）与烟酸的结合亲和力很强”解析出的依存语法树示例。在这里，HM74A 和烟酸有关联，而 HM74 和烟酸没有关联。箭头从原点（或父节点）指向在句法上依赖于原点的词（或子节点）。箭头带有标签，说明子节点对父节点的贡献属性。修剪依赖关系树后，只剩下粗体的边，这些边连接着一边的受体名称和另一边的配体名称，并以单词和标记链或路径的形式表示。句子中每一对可能的 GPCR 和可能的配体都会生成路径

(Erkan 等人, 2007 年; Ozgur 和 Radev, 2009 年)。在此，我们将这一想法扩展到 GPCR 与配体的关联识别。

首先，我们收集所有至少包含一个 GPCR 名称、一个配体名称和一个结合触发器的句子。然后，我们使用斯坦福 CoreNLP 解析器 (Manning 等, 2014 年人) 将这些句子解析成一棵具有语义谓词-参数关系的结构词树，称为类型化依存解析树 (见图 2)。对于每个句子以及 GPCR 名称、配体名称和结合触发器的每个组合，都会对 Stanford CoreNLP 返回的依赖解析树进行剪枝，以保留连接所有三个词的最简单的树。

如图 2，从剪枝树中提取了三条路径：(i) 一端连接 GPCR 名称，另一端连接配体名称；(ii) 连接 GPCR 名称和结合触发器；(iii) 连接配体名称和结合触发器。从训练集中的 100 篇摘要中提取出 3310 组路径，然后从文献中将这三种路径分组，并根据路径中是否存在真正的相互作用进行人工标注。按照 Ozgur 等人 (Erkan 等人, 2007 年; Ozgur 和 Radev, 2009 年) 的方法，每给定两组路径，一组中的每条路径都使用编辑距离方法与另一组中的相应路径进行对齐。这种对齐可以增强句子结构的一致性，从而提高分类效率。

计算出的三个相似度得分是所有三对排列路径之间的编辑距离。利用这些成对相似度构建了一个 $N \times 3N$ 矩阵 ($N \approx 3310$ 为训练集中的路径数)，并将其作为一个 $3N$ 维空间用于梯度提升决策树 (GBDT) 模型的训练。训练从在初始数据上训练的初始决策树分类器开始，其分支在第三级停止。在这个弱分类器的基础上，GBDT 根据训练集反复计算预测误差，根据预测误差构建新的决策树分类器，并将其添加到模型中 (Friedman, 2001 年)。

GBDT 模型在文本挖掘中识别的 GPCR 配体关联会与数据集中的数据进行交叉检查。在将数据整合到 GLASS 之前，将通过人工检查核实两个来源之间的任何冲突。在这一步骤中，通常需要人工阅读原始文章并与原始数据库进行比较，以确保数据的质量。经过人工交叉验证后，近 20% 的 GPCR 配体关联已从文献中排除，这些关联未包含在当前的药理学数据集中。

2.3 GLASS 图书馆的结构

GLASS 数据库是使用 MySQL 建立的，而互联网网页则使用 Perl 和 Python CGI 脚本组合进行扩充，以方便界面与 MySQL 数据库进行通信。

对于每种 GPCR 配体关联，相关的化学信息，如 XlogP、分子量、氢键受体和供体、二维结构图、同义词和 IUPAC 名称等，都是通过 PubChem 的化学标识符交换服务，使用每种配体的化合物标识符 (CID) 从 PubChem 中获取的。三维 SDF 文件是使用 Open Babel (O'Boyle 等人, 2011 年) 从各自的规范 SMILES 字符串生成的。

对于人类基因组中 GPCR，如果有相关的实验条件和疾病，则从 TTD (Qin 等, 2014 年人) 中汇编。如果实验三维结构可用，则通过与 PDB 的交叉连接为每个 GPCR 提供三维结构信息。为每个 GPCR 绘制 JSmol 图像，以便用户查看受体的三维结构。

为促进相互作用比较研究，GLASS 提供了一个交互式搜索引擎，允许用户通过实验验证数据中的亚结构或化学相似性收集同源配体/化合物。用户可以使用 JSME 分子编辑器 (Bienfait 和 Ertl, 2013 年) 绘制化合物的化学结构，然后将其转换为 SMILES 字符串。随后，该字符串将被传输到 Open Babel，以便对照索引配体进行子结构或相似性搜索。为了加快搜索过程，我们预先创建了一个包含所有配体索引的 SDF 文件。对于化学相似性搜索，用户可以选择 Tanimoto 系数截止值。搜索结果以 SMILES 字符串的形式返回。最后，SMILES 字符串作为探针在数据库中进行搜索，以收集同类配体，并以化学结构图像和名称的形式返回。如果选择了相似性搜索，还会返回谷本系数。

3 成果

3.1 玻璃的数量

截至本文提交之时，GLASS 包含 913 908 个 GPCR 配体 条目，，收集自 多个 来源的 。

表 1.GLASS 数据库概要

条目类型	参赛作品数量
所有 GPCR	3048
与配体结合	681
无配体结合	2367
独特的配体	277 651
类药物配体	190 145
所有 GPCR 配体关联	913 908
独特的联系	513 246




图 3.GLASS 中各族 GPCR 配体数据的分布情况。所有数值均以占总数的百分比表示。图中不包括真菌、环磷酸腺苷、OA 和 T2R 受体，这些受体的数据不足 (<10 条) 或没有数据。

实验。有些关联在不同的实验中出现不止一次。去除冗余条目后，513 246 个独特的关联，每个关联都包含一个物种特异的 GPCR 与一个相互作用的配体配对（如果去除物种间的冗余并计算同源物，则仍有 460 439 个独特的关联）。

GLASS 中共有 3048 个 GPCR 条目是从 UniProt (Magrane 和 Consortium, 2011 年) 中提取的，其中 681 个 GPCR 至少有一个配体关联。其他 2367 个 GPCR 条目在目前的实验文献中还没有配体关联数据。在有配体关联的 GPCR 中，平均每个受体有~754 种不同类型的配体/化合物关联；但由于几个受体家族的配体关联数量明显较多（见下文），因此中值仅为 77。GLASS 中独特配体的总数为 277 651 个。表 1 列出了当前 GLASS 数据库的摘要。

GLASS 中的大部分配体关联都偏向于 GPCR 的 A 类视网膜素样家族，该家族构成了

~85% 的关联数据（图 3）。The top five receptors in the rhodopsin-like family, all of which have more than 65 000 ligand associations, are from serotonin, adenine and adenosine nucleotide, adrenergic, opioid and dopamine receptors. 由于这些受体在医药应用和再中的重要性，它们也是文献中最常研究的 GPCR。整个 A 类家族的配体关联直方图见补充图 S2。




图 4.显示搜索选项的 GLASS 主页截图、浏览和下载数据库相关数据

在配体关联中，非眼色素类 GPCR 家族所占的比例要小得多。不过，在所有人类 GPCR 中，B 类胰泌素家族中的人类胰高血糖素样肽 1 受体含有最丰富的 GPCR 配体关联，包含 100 000 多个条目。其他拥有超过 2 000 个 GPCR 配体关联的非眼色素样 GPCR 是代谢谷氨酸受体和信息素受体家族，它们都属于 C 类代谢谷氨酸/信息素家族。只有 F 类家族的两个成员 (UniProt ID: Q88935 和 P56726) 有相关的实验数据，而真菌交配信息素 (D 类)、环磷酸腺苷 (E 类)、粘菌、眼白化病 (OA) 和味觉受体 (T2R) 家族的 GPCR 几乎没有发现 GPCR 与配体的关联。补充图 S3-S5 列出了 B 类、C 类和 F 类家族配体关联的详细数据分布。配体关联分布极不均匀，这也是每个受体的配体数量中位数远低于平均数的原因。

3.2 数据库功能

GLASS 数据库每月更新一次，所有数据均可在 <http://zhanglab.cmb.med.umich.edu/GLASS/>。免费获取如图 4 所示，GLASS 开发了三种功能，用于搜索、浏览或下载 GPCR 配体关联数据，下文将对此进行概述。

S.2.1 搜索玻璃

高效的搜索功能对生物医学数据库的开发至关重要。GLASS 在主页上提供了三个选项，用于根据三种查询类型搜索数据库：(i) 基于 GPCR，(ii) 基于配体，(iii) 基于 GPCR 配体。用户可以在输入所需输入内容之前或之后选择感兴趣的单选按钮来选择这些选项（图 4）。

使用基于 GPCR 的搜索，用户可以使用各种输入信息搜索感兴趣的 GPCR，包括 UniProt ID、基因名称或相关医疗条件。点击 "搜索" 按钮后，用户将进入一个页面，该页面列出了与查询相匹配的所有 GPCR；点击并跟随感兴趣的 GPCR 链接后，用户将进入一个包含 GPCR 相关信息的详细页面，其中包括 GPCR 名称、种类、基因名称、同义词、相关疾病、主序列及其长度、原子结构模型和数据库标识符。页面底部列出了与 GPCR 相关的所有配体。图 5 展示了基于人 b2 肾上腺素能受体的 GPCR 搜索输出示例。

基于配体的搜索要求了解相关配体的名称、化学标识符或 PubChem ID。点击 "搜索" 按钮后，用户将进入与查询结果相匹配的所有配体的结果页面。点击并跟随感兴趣配体的链接，就会出现包含配体名称的详细页面、

GPCR

Name

Beta-2 adrenergic receptor

Species

Homo sapiens (Human)

Gene

ADRB2

Synonym

Adrb-2
ADRB2R
ADRB1R
Gpcr7
Adrenergic beta 2- receptor surface
[Show all]

Disease

Respiratory distress syndrome
Obstructive airway disease
Skeletal muscle wasting
Multiple sclerosis
Skeletal muscle weakness
[Show all]

Length

413

Amino acid sequence

MQQPGNGSAFLAPNGSHAPDHVTQERDEWVVGNGIVMSLIVLAVFGNVLVITAIKFERLQTVNYFITSLACADLVNGLAVVPFGAAHILMKMTWFGNCFWPTSIDVLCVTASITELCVIADRYFAITSPFKYQSLTKNKARVILNHWIVSGLTSLFPIQNMHYRATHQEAICYANETCDFFTNQAYIASSIVSYFPLVIMVFYYSRVFOEAKRQLQIDKSEGRFHVQNLQSQVEDQGRTHGLRRSSKFLCKEHKALKTLGIINGFTFLCWLPFFIYVNIHVHIDQNLIRKEVYILLNMWYGVNSGFNPLIYCRSPDFRIFAQELLCRRSSLKAYGNGYSSNGNTGEQSGYHVEQEKENKLLCEDLPGTDFVGHQGTVPNDISQGRNCSTNDSLL

UniProt

P07550

Protein Data Bank

2rh1, 3d4s, 3ny8, 3ny9, 3nva, 3pds, 4abr, 4ide, 4idc, 4gkx

GPCR-HGmod model

P07550

BioLIP

BL0185746, BL0113951, BL0113950, BL0192128, BL0185748, BL0232997, BL0257080, BL0257081, BL0257082, BL0192129, BL0113952, BL0113953, BL0185745, BL0185744, BL0185743, BL0185742, BL0185740, BL0185747, BL0147311, BL0147310, BL0113954, BL0257063, BL0257084, BL0257085, BL0147312, BL0283869, BL0185741

Therapeutic Target Database

TTDS00037

CHEMBL

CHEMBL2111388, CHEMBL210, CHEMBL2096974, CHEMBL2094118

IUPHAR

29

DrugBank

BE0000694

Known ligands

You can:

Click GLASS IDs to check the association information.

Click ligand names to check details of the ligands.

Download a TSV version of all interaction information.

Download a SDF structure collection of all known ligands.

Total entries: 4192

First

Prev

Page: 1

/ 210

Next

Last

GLASS ID

Name

Formula

Molecular weight

H-bond acceptor / donor

XlogP

Lipinski's druglikeness

8769

CHEMBL102611

C24H29NO6S

487.569

9 / 4

2.3

Yes

8770

T0512-2064

C10H14ClN3S2

275.821

3 / 2

3.6

Yes

8771

AGN-PC-00RB1S

C21H30N8O2

426.515

7 / 3

2.0

Yes

8772

STK860027

C18H31N3S

321.524

2 / 2

3.7

Yes

8773

AGN-PC-00KJGP

C20H29NO5

387.43

6 / 4

1.4

Yes

8774

CHEMBL168023

C20H31NO2

317.466

3 / 2

3.5

Yes

8775

ML5001250385

C18H22N2O5

346.378

5 / 0

3.7

Yes

图 5. GLASS 基于 GPCR 的搜索输出示意图。该示例来自人类 b2 肾上腺素能受体，页面底部列出了与该受体相关的配体。所示三维结构来自 Cherezov 等人 (2007 年) 解决的 PDB (ID: 2RH1)。


分子式、IUPAC 名称、同义词、物理化学性质、化学标识符、数据库标识符、二维化学结构和带有实验数据的 GPCR 靶标列表。涉及配体普萘洛尔的大量输出结果如图 6 所示，页面底部列出了与配体结合的所有 GPCR。

虽然可以通过基于 GPCR 和配体的搜索来检索 GPCR-配体关联信息，但如果已知相互作用的相应 GLASS ID，GLASS 还提供了第三种基于 GPCR-配体的搜索选项。在上例中，人类 b2 肾上腺素能受体和普萘洛尔相互作用的 GLASS ID 是 "8792"。通过搜索 "8792"，用户将进入包含 GPCR 和配体信息以及实验结合亲和力和数据的页面。在本例中，PubMed ID 为 24063433 的参考文献中报告的结合自由能为 9.76 kcal/mol。

Ligand	
Name	Prenaltolol
Molecular formula	C12H19NO3
IUPAC name	4-[(2S)-2-hydroxy-3-(propan-2-ylamino)propoxy]phenol
Molecular weight	225.284
Hydrogen bond acceptor	4
Hydrogen bond donor	3
XlogP	1.4
Synonyms	H-80-62 4-[(2S)-2-hydroxy-3-[(propan-2-yl)amino]propoxy]phenol H 133/22 LS-104700 61260-05-7 (hydrochloride) [Show all]
Inchi Key	ADUKCCWBEDSMEB-NSHDSACASA-N
Inchi ID	InChI=1S/C12H19NO3/c1-9(2)13-7-11(15)8-16-12-5-3-10(14)4-6-12/h3-6,9,11,13-15H,7-8H2,1-2H3(11-1m/s1
PubChem CID	42396
CHEMBL	CHEMBL1160714
IUPHAR	537
BindingDB	50421716
DrugBank	N/A

Structure

[SDF download](#)



Lipinski's druglikeness

This ligand satisfies Lipinski's rule of five.

Known GPCRs

You can:

- Click GLASS IDs to check the association information.
- Click protein names to check details of the GPCRs.
- Download a TSV version of all interaction information.

Total entries: 4

First

Prev

Page: 1

/ 1

Next

Last

GLASS ID	Name	UniProt	Gene	Species	Length
23822	Beta-1 adrenergic receptor	P08588	ADRB1	Homo sapiens (Human)	477
8792	Beta-2 adrenergic receptor	P07550	ADRB2	Homo sapiens (Human)	413
439172	Beta-2 adrenergic receptor	Q28044	ADRB2	Bos taurus (Bovine)	418
143161	Beta-3 adrenergic receptor	P26255	Adrb3	Rattus norvegicus (Rat)	400

图 6. 基于配体的 GLASS 搜索输出页面示意图。图中图 5 所示配体为普萘洛尔，是人类 b2 肾上腺素能受体的关联配体之一。页面底部列出了与普萘洛尔结合的 GPCR

除了基于配体、GPCR 和配体-GPCR 的搜索选项外，GLASS 还希望通过化学相似性或亚结构匹配找到特定配体的用户提供了基于目标的搜索 (图 7)。用户可以使用 JSME 化学编辑器手动绘制感兴趣的配体或导入 MOL 或 SDF 文件。亚结构搜索查询应针对化学复杂性足够高的配体，否则会匹配过多配体，导致搜索时间过长。通过化学相似性进行搜索时，可以选择百分比截止值。搜索结果将与相应配体和二维化学结构图像一起返回；还会为相似性搜索提供谷本系数。所有找到的配体都可以下载到 SDF 文件。图 7 举例说明了吗啡的同源性搜索。

S.2.2 浏览玻璃

主页上提供了 GLASS 中 GPCR 和配体的综合列表，以便批量浏览所有条目。



图 7. 使用亚结构相似性 (左图) 或化学相似性 (右图) 在 GLASS 数据库中搜索配体。用户首先通过导入 MOL 或 SDF 文件或在 JSME 分子编辑器中绘制分子来指定配体。在本例中, 吗啡是查询分子。点击“Fetch (获取化合物)”按钮后, 亚结构搜索管道将查找化学结构中包含用户指定分子的配体; 化学相似性搜索管道将返回所有与查询分子化学结构至少有 70% 相同的配体 (截止值可调)。虽然在这两种搜索中都为用户提供了配体名称和化学结构, 但只有在化学相似性搜索中才能看到谷本系数。

此外, 用户还可以按照 UniProt (Magrane 和 Consortium, 2011 年) 指定的各自家族浏览所有 GPCR。根据这一模式, 由于条目的数量较多, 类视网膜色素家族 GPCR 条目被进一步划分为亚家族级别, 而其他家族则被重新主要划分为一个级别。

S.2.S 下载 GLASS

GPCR 数据表、GPCR 配体数据表和配体数据表均以 TSV 文件格式提供下载。所有 GLASS 配体的三维格式 SDF 文件均已压缩, 可用于分子对接实验; 理化性质和分子描述符均包含在性质标签中, 方便用户使用。

4 摘要

我们开发了一个新数据库--GLASS, 它包含了从多种数据源和 PubMed 文献挖掘中收集到广泛的 GPCR 相关药理学数据。GLASS 所包含的配体和 GPCR 与配体相互作用数据是领先数据库的十倍以上, 这使得 GLASS 成为该领域最全面、最新的 GPCR 与配体关联数据库。然而, GLASS 数据库的独特之处并不在于数据量的庞大, 而在于数据收集和特征设置的新颖性。

首先, 利用新颖的文本挖掘管道增强了数据提取程序, 从而使自动

数据库更新。更重要的是, 对现有数据集和文本挖掘数据进行仔细的人工交叉检查, 提高了 GPCR 配体数据收集的准确性和覆盖面。在自动匹配文本挖掘过程之后, 经过人工文献验证, 从文献挖掘中收集到近 20% 的配体关联数据。我们注意到, 许多生物活性配体关联在文献中已有描述, 但在大多数药理学数据库中却被遗漏。为了解决这个问题, 我们为用户提供了浏览文本挖掘结果的选项, 以便发现遗漏的 GPCR 配体相互作用。如果遗漏的数据为某个感兴趣的 GPCR 提供了生物活性配体, 而这些配体的化学结构与目前数据库中的配体截然不同, 那么这将被证明是非常有价值的。

其次, GLASS 数据库的现有结构已经这样, 用户就可以为某些实验参数 (如结合常数) 选择合适的截止值。这将避免任何限制用户灵活性的主观预设截止值。某些 GPCR 配体数据库, 如 GLIDA (Okuno 等人, 2008 年), 只提供具有生物活性而非实验参数的配体列表。例如, 配体可能被指定为 GPCR 的激动剂, 但我们却不知道它是如何被指定为激动剂的。预先设定的截止值使得我们很难按实验值定制配体数据集进行分析。GLASS 数据库的设计旨在确保所有提取的数据都可供用户操作。有了这个选项, 就可以对单个 GPCR 进行分析, 根据不同的截止值来阐明它们对配体的偏好。

全球导航卫星系统的重点之一是为各种实验和计算虚拟筛选研究。例如, GPCR 虚拟筛选的一个重要方法是从同源配体-GPCR 相互作用中收集配体谱 (Zhou 和 Skolnick, 2012 年), GLASS 中配体-GPCR 关联的完整性对于提高配体谱的灵敏度和识别能力至关重要。凭借其全面的数据集覆盖范围和持续的数据更新, 我们期望 GLASS 成为重要的主要 GPCR 再资源, 并将其应用于许多其他生物医学研究, 包括 GPCR 药物发现、GPCR 去态化和功能注释。

致谢

我们感谢 Jim Cavalcoti 博士在数据规范化方面提出的建议, 感谢 Alex Ade、Dragomir Radev 博士和 Rahul Jha 博士在自然语言处理方面进行的多次有益讨论。

资金筹措

这项工作得到了美国国立综合医学科学研究所 (GM083107 和 GM084222) 的部分支持。W.C. 获得了美国国立癌症研究所管理的 T32 培训基金 (CA140044) 中癌症蛋白质组信息学培训项目的支持。

利益冲突: 无。

参考资料

- Beukers, M.W. et al. (1999) TinyGRAP 数据库: 挖掘 G 蛋白偶联受体突变体数据的生物信息学工具. *Trends Pharmacol. Sci.*, 20, 475-477.
- Bienfait, B. and Ertl, P. (2013) JSME: a free molecule editor in JavaScript. *J.S.*, 24.

- Cherezov,V. 等人 (2007 年) 工程人类 beta2 肾上腺素能 G 蛋白偶联受体的高分辨率晶体结构. *科学*, S18, 1258-1265。
- Cock,P.J. *et al.* (2009) Biopython: Free available Python tools for computational molecular biology and bioinformatics. *生物信息学*, 25, 1422-1423。
- Dorsam,R.T. and Gutkind,J.S. (2007) G 蛋白偶联受体 and cancer. *Nat.Rev. Cancer*, 7, 79-94.
- Erkan,G. *et al.* (2007) Semi-supervised classification for extracting protein interaction sentences using dependency parsing. *EMNLP-CoNLL*, 228-237。
- Friedman,J.H. (2001) Greedy function approximation: a gradient boosting machine. *Ann.Statist.*, 29, 1189-1232。
- Gatica,E.A. and Cavasotto,C.N. (2012) 与 G 蛋白偶联受体对接的配体和诱饵集. *J. Chem.Inf.Model.*
- Gaulton,A. *et al.* (2012) ChEMBL: a large-scale bioactivity database for drug discovery. *核酸研究*, 40, D1100-1107。
- Gray,K.A. *et al.* (2014) Genenames. org: the HGNC resources in 2015. *Nucleic Acids Res.*, gku1071.
- Horn,F. *et al.* (1998) GPCRDB: an information system for G protein-coupled receptors. *Nucleic Acids Res.*, 24, 275-279。
- Hur,J. *et al.* (2009) SciMiner: web-based literature mining tool for target identification and functional enrichment analysis. *Bioinformatics*, 25, 838-840。
- Khelashvili,G. 等人 (2010) GPCR-OKB: G 蛋白偶联受体寡聚知识库. *Bioinformatics*, 24, 1804-1805.
- Klabunde,T. and Hessler,G. (2002) Drug design strategies for targeting G protein coupled receptors. *ChemBiochem*, 3, 928-944。
- Knox,C. *et al.* (2011) DrugBank 3.0: a comprehensive resource for 'omics' research on drugs. *Nucleic Acids Res.*, S9, D1035-1041。
- Lipinski,C.A. *et al.* (2001) Experimental and computational approaches to estimate solubility and permeability in drug discovery and development settings. *Adv Drug Delivery Rev.*, 41, 3-26.
- Liu,T. *et al.* (2007) BindingDB: a web-accessible database of experimentally determined protein-ligand binding affinities. *Nucleic Acids Res.*, S5, D198-D201.
- Maglott,D. *et al.* (2011) Entrez Gene: gene-centered information at NCBI. *核酸研究*, S9, D52-D57。
- Magrane,M. and Consortium,U. (2011) UniProt Knowledgebase: a hub of integrated protein data. *数据库*, 2011 年, bar009.
- Manning,C.D. *et al.* (2014) The Stanford CoreNLP natural language processing toolkit. In: *第 52 届计算语言学协会年会论文集: 系统演示*, 第 55-60 页。
- O'Boyle,N.M. *et al.* (2011) Open Babel: an open chemical toolbox. *J.Cheminf.*, 3, 33.
- Okuno,Y. *et al.* (2008) GLIDA: GPCR-ligand database for chemical genomics drug discovery-database and tools update. *Nucleic Acids Res.*, S1, D907-D912.
- Overington,J.P. 等人 (2006) 药物靶点有多少? *Nat.Rev. Drug Discov.*, 5, 993-996。
- Ozgun,A. and Radev,D.R. (2009) Supervised classification for extracting biomedical events. In: *生物医学自然语言处理当前趋势研讨会论文集: 共同任务*. 计算语言学协会, 第 111-114 页。
- Qin,C. *et al.* (2014) Therapeutic target database update 2014: a resource for targeted therapeutics. *核酸研究*, 42, D1118-1123。
- Rocktaschel,T. 等人 (2012 年), ChemSpot: 化学命名实体识别混合系统. *生物信息学*, 28, 1633-1640。
- Sharman,J.L. *et al.* (2011) IUPHAR-DB: 用于轻松搜索和可视化药理学数据的新受体和工具. *核酸研究*, S9, D534-D538。
- van Laarhoven,T. 等人 (2011 年) 用于预测药物-靶点相互作用高斯相互作用轮廓. *生物信息学*, 27, 3036-3043。
- Weill,N. and Rognan,D. (2009) 用于挖掘化学基因组空间的新型蛋白质配体指纹的开发和验证: 应用于 G 蛋白偶联受体及其配体. *J. Chem.Inf.Model.*, 49, 1049-1062.
- Zhang,J. and Zhang,Y. (2010) GPCRDRD: 用于三维结构建模和功能注释的 G 蛋白偶联受体空间约束数据库. *Bioinformatics*, 24, 3004-3005.
- Zhou,H. and Skolnick,J. (2012) FINDSITE(X): 一种基于结构的小分子虚拟筛选方法, 适用于所有已确定的人类 GPCR. *Mol.* 9, 1775-1784.