
基于图神经网络的链路预测

Muhan Zhang
圣路易斯华盛顿大学计算机科
学与工程系

Yixin Chen
圣路易斯华盛顿大学计算机
科学与工程系

muhan@wustl.edu (此邮件地址无需翻译) chen@cse.wustl.edu

摘要

链路预测是网络结构化数据中的一个关键问题。链路预测启发式方法使用一些评分函数，例如共同邻居和 Katz 指数，来衡量链路存在的可能性。由于其简单性、可解释性以及部分方法的可扩展性，它们在实际应用中得到了广泛使用。然而，每种启发式方法都对两个节点何时可能建立链路做出了很强的假设，这限制了它们在这些假设不成立的网络中的有效性。在这方面，一种更合理的方法应该是从给定的网络中学习一种合适的启发式方法，而不是使用预定义的方法。通过提取每个目标链路周围的局部子图，我们旨在学习一个将子图模式映射到链路存在的函数，从而自动学习一种适合当前网络的“启发式方法”。在本文中，我们研究了这种用于链路预测的启发式学习范式。首先，我们开发了一种新颖的衰减启发式理论。该理论在一个单一框架中统一了广泛的启发式方法，并证明了所有这些启发式方法都可以从局部子图中很好地近似。我们的结果表明，局部子图保留了与链路存在相关的丰富信息。其次，基于衰减理论，我们提出了一种新的方法，利用图神经网络（GNN）从局部子图中学习启发式算法。其实验结果表明，该方法性能卓越，在各种问题上均表现良好。

1 简介

链路预测是指预测网络中两个节点之间是否有可能存在链路[1]。鉴于网络无处不在，它在诸如好友推荐[2]、电影推荐[3]、知识图谱补全[4]以及代谢网络重建[5]等方面有着诸多应用。

一类简单却有效的链接预测方法被称为启发式方法。启发式方法通过计算某些启发式的节点相似度得分来表示链接的可能性[1, 6]。现有的启发式方法可以根据计算得分所需的最大邻居跳数进行分类。例如，共同邻居（CN）和优先连接（PA）[7]属于一阶启发式方法，因为它们仅涉及两个目标节点的一跳邻居。Adamic-Adar（AA）和资源分配（RA）[8]属于二阶启发式方法，因为它们是从目标节点的最多两跳邻域计算得出的。我们将需要了解目标节点最多 h 跳邻域的启发式方法定义为 h 阶启发式方法。还有一些高阶启发式方法需要了解整个网络。例如，Katz、根 PageRank（PR）[9] 和 SimRank（SR）[10]。附录 A 中的表 3 总结了八种流行的启发式方法。

尽管在实践中效果良好，但启发式方法对可能存在连接的情况有着很强的假设。例如，共同邻居启发式方法假设如果两个节点有许多共同邻居，那么它们更有可能连接。这种假设在社交网络中可能是正确的，但在蛋白质 - 蛋白质相互作用（PPI）网络中已被证明是错误的——两个共享许多共同邻居的蛋白质实际上相互作用的可能性更低[11]。




图 1: SEAL 框架。对于每个目标链接, SEAL 都会在其周围提取一个局部封闭子图, 并使用图神经网络 (GNN) 来学习用于链接预测的一般图结构特征。请注意, 方框内列出的启发式方法仅作参考说明之用——所学特征可能与现有的启发式方法完全不同。

实际上, 启发式方法属于一个更通用的类别, 即图结构特征。图结构特征是指位于网络中观察到的节点和边结构内部的那些特征, 可以直接从图中计算得出。由于启发式方法可以被视为预定义的图结构特征, 因此一个自然的想法是从网络中自动学习此类特征。张和陈[12]首次研究了这个问题。他们提取链接周围的局部封闭子图作为训练数据, 并使用全连接神经网络来学习哪些封闭子图对应于链接的存在。他们提出的方法称为 Weisfeiler-Lehman 神经机 (WLNM), 在链路预测性能方面达到了最先进的水平。节点对 (x, y) 的封闭子图是由 x 和 y 的邻居在 h 跳内的并集从网络中诱导出的子图。图 1 展示了 (A, B) 和 (C, D) 的 1 跳封闭子图。这些封闭子图对于链路预测非常有用——所有一阶启发式方法, 如共同邻居, 都可以直接从 1 跳封闭子图中计算得出。

然而, 研究表明, 诸如根 PageRank 和 Katz 这样的高阶启发式算法通常比一阶和二阶算法表现得好得多[6]。为了有效地学习到良好的高阶特征, 似乎我们需要一个非常大的跳数 h , 使得包围子图成为整个网络。这会导致大多数实际网络无法承受的时间和内存消耗。但我们真的需要如此大的 h 来学习高阶启发式算法吗?

幸运的是, 作为我们的首个贡献, 我们证明了学习高阶图结构特征不一定需要非常大的 h 值。我们深入研究了链路预测启发式算法的内在机制, 发现大多数高阶启发式算法都可以通过一个衰减理论来统一。我们证明, 在温和的条件下, 任何衰减启发式算法都可以从一个 h 跳邻接子图中有效地近似得到, 其中近似误差至少以指数形式随 h 减小。这意味着我们可以放心地使用较小的 h 值来学习良好的高阶特征。这也表明这些高阶启发式算法的有效阶数并不高。

基于我们的理论成果, 我们提出了一种新颖的链路预测框架 SEAL, 用于从局部封闭子图中学习通用的图结构特征。SEAL 改进了 WLNM 的多个缺陷。首先, SEAL 使用图神经网络 (GNN) [13, 14, 15, 16, 17] 替代了 WLNM 中的全连接神经网络, 从而具备了更强的图特征学习能力。其次, SEAL 不仅能够从子图结构中学习, 还能从潜在和显式的节点特征中学习, 从而吸收多种类型的信息。我们通过实验验证了其性能的显著提升。

我们的贡献总结如下。1) 我们提出了一个新的用于学习链路预测启发式方法的理论, 证明了从局部子图而非整个网络中学习是合理的。2) 我们提出了 SEAL, 这是一种基于图神经网络 (GNN) 的新型链路预测框架 (如图 1 所示)。SEAL 在很大程度上优于所有启发式方法、潜在特征方法以及近期的网络嵌入方法。SEAL 还优于之前的最先进方法 WLNM。

2 预备知识

记号 设 $G = (V, E)$ 为一个无向图, 其中 V 是顶点集, $E \subseteq V \times V$ 是观测到的边集。其邻接矩阵为 A , 其中 $A_{ij} = 1$ 当 $(i, j) \in E$, 否则 $A_{ij} = 0$ 。

否则。对于任何节点 $x, y \in V$, 设 $N(x)$ 为 x 的 1 跳邻居, $d(x, y)$ 为 x 和 y 之间的最短路径距离。一条路径 $w = hv_0, \dots, v_k$ 是节点的序列, 其中 $(v_i, v_{i+1}) \in E$ 。我们用 $|hv_0, \dots, v_k|$ 表示路径 w 的长度, 此处为 k 。

潜在特征和显式特征 除了图结构特征外, 潜在特征和显式特征也被用于链路预测的研究。潜在特征方法[3, 18, 19, 20]对网络的某些矩阵表示进行因式分解, 以学习每个节点的低维潜在表示/嵌入。例如矩阵分解[3]和随机块模型[18]等。最近, 提出了许多网络嵌入技术, 如 DeepWalk[19]、LINE[21]和node2vec[20], 它们也是潜在特征方法, 因为它们也隐式地对某些矩阵进行了因式分解[22]。显式特征通常以节点属性的形式存在, 描述了关于各个节点的各种侧面信息。研究表明, 将图结构特征与潜在特征和显式特征相结合可以提高性能[23, 24]。

图神经网络 图神经网络 (GNN) 是一种用于图数据学习的新类型神经网络[13, 14, 15, 16, 25, 26]。由于本文并非关于 GNN 的创新, 而是其一种新颖的应用, 所以这里仅简要介绍 GNN 的组成部分。GNN 通常由 1) 图卷积层构成, 该层用于提取单个节点的局部子结构特征; 2) 图聚合层构成, 该层将节点级特征聚合为图级特征向量。许多图卷积层都可以统一到一个消息传递框架中[27]。

监督启发式学习 在链接预测方面, 此前有一些尝试学习监督启发式方法的研究。与我们的工作最为接近的是 Weisfeiler-Lehman 神经机 (WLNM) [12], 它同样从局部子图中学习。然而, WLNM 存在一些缺陷。首先, WLNM 在子图的邻接矩阵上训练全连接神经网络。由于全连接神经网络仅接受固定大小的张量作为输入, WLNM 需要将不同大小的子图截断为相同大小, 这可能会丢失大量结构信息。其次, 由于邻接矩阵表示的局限性, WLNM 无法从潜在或显式特征中学习。第三, 理论依据也有所缺失。我们在附录 D 中对 WLNM 进行了更多讨论。另一条相关研究路线是训练一个监督学习模型来组合不同的启发式方法。例如, 路径排序算法 [28] 在不同路径类型的概率上训练逻辑回归来预测知识图谱中的关系。Nickel 等人 [23] 提出将启发式特征纳入张量分解模型。然而, 这些模型仍然依赖于预先定义的启发式方法——它们无法学习到通用的图结构特征。

3 统一链路预测启发式方法的理论

在本节中, 我们旨在更深入地理解各种链路预测启发式方法背后的机制, 从而激发从局部子图中学习启发式方法的想法。由于图学习技术种类繁多, 请注意我们并不关注特定方法的泛化误差, 而是关注用于计算现有启发式方法的子图中保留的信息。

定义 1. (包围子图) 对于图 $G = (V, E)$, 给定两个节点 $x, y \in V$, 对于 (x, y) 的 h 跳包围子图是通过节点集 $\{i \mid d(i, x) \leq h \text{ 或 } d(i, y) \leq h\}$ 从 G 中诱导出的子图 $G_{hx, y}$ 。

下面的子图描述了点 (x, y) 的“ h 跳邻域环境”。由于 $G_{hx, y}$ 包含了 x 和 y 的所有 h 跳邻居, 因此我们自然有以下定理。

定理 1. 对于 (x, y) 的任何 h 阶启发式算法都可以从 $G_{hx, y}$ 准确计算得出。

例如, 一个两跳的包围子图将包含计算任何一阶和二阶启发式所需的所有信息。然而, 尽管一阶和二阶启发式可以通过局部包围子图很好地覆盖, 但学习高阶启发式似乎仍需要一个非常大的 h 。令人惊讶的是, 我们接下来的分析表明, 使用较小的 h 来学习高阶启发式也是可行的。我们首先通过定义 - 衰减启发式来支持这一观点。我们将证明, 在某些条件下, - 衰减启发式可以从 h 跳包围子图中很好地近似得出。此外, 我们还将证明几乎所有著名的高阶启发式都可以统一到这个 - 衰减启发式框架中。

定义 2. (- 衰减启发式) 对于 (x, y) 的 - 衰减启发式具有以下形式:

$$\mathcal{H}(x, y) = \eta \sum_{l=1}^{\infty} \gamma^l f(x, y, l), \quad (1)$$

其中, γ 是介于 0 和 1 之间的一个衰减因子, $\mathcal{H}$ 是一个正的常数或关于 h 的上界为常数的正函数, f 是给定网络下关于 x, y, l 的非负函数。

接下来, 我们将证明, 在某些条件下, 一个 γ -衰减启发式算法可以从一个 h 跳包围子图中进行近似, 并且近似误差至少以指数形式随 h 减小。

定理 2. 给定一个衰减因子为 γ 的启发式函数 $H(x, y) = \mathcal{H}_{\text{Pill}} f(x, y, l)$, 若 $f(x, y, l)$ 满足:

(性质 1) 当 $0 < l < 1$ 时, $f(x, y, l) \leq 1$; 和

(性质 2) 对于 $l = 1, 2, \dots, g(h)$, 其中 $g(h) = ah + b$, a, b 为自然数且 $a > 0$, $f(x, y, l)$ 可由 $G_{hx, y}$ 计算得出。

那么, $H(x, y)$ 可以由 $G_{hx, y}$ 进行近似, 并且近似误差至少以 h 的指数形式递减。

证明。我们可以通过对其前 $g(h)$ 项求和来近似这种以 γ -衰减的启发式算法。

$$\tilde{H}(x, y) := \eta \sum_{l=1}^{g(h)} \gamma^l f(x, y, l). \quad (2)$$

近似误差可按如下方式加以限定。Bounded as follows.

$$|H(x, y) - \tilde{H}(x, y)| = \eta \sum_{l=g(h)+1}^{\infty} \gamma^l f(x, y, l) \leq \eta \sum_{l=ah+b+1}^{\infty} \gamma^l \lambda^l = \eta(\gamma\lambda)^{ah+b+1}(1-\gamma\lambda)^{-1}. \quad \square$$

实际上, 较小的 γ 和较大的 λ 都会导致衰减速度加快。接下来, 我们将证明三个流行的高阶启发式算法: Katz、根 PageRank 和 SimRank, 都是 γ -衰减启发式算法, 满足定理 2 中的性质。首先, 我们需要以下引理。

引理 1. 任意长度不超过 $2h + 1$ 的从 x 到 y 的路径都包含在 $G_{hx, y}$ 中。

证明。对于任意长度为 l 的路径 $w = hx, v_1, \dots, v_{l-1}, y$, 我们将证明每个节点 v_i 都包含在 $G_{hx, y}$ 中。考虑任意节点 v_i 。假设 $d(v_i, x) > h + 1$ 且 $d(v_i, y) > h + 1$ 。那么, $2h + 1 < l = |hx, v_1, \dots, v_{l-1}, y| = |hv_i, \dots, v_{l-1}, y| = d(v_i, x) + d(v_i, y) > 2h + 2$, 这与前提矛盾。因此, 要么 $d(v_i, x) \leq h$, 要么 $d(v_i, y) \leq h$ 。根据 $G_{hx, y}$ 的定义, 节点 v_i 必须包含在 $G_{hx, y}$ 中。 $\square$

接下来我们将逐一分析 Katz 指数、根 PageRank 和 SimRank。

3.1 卡茨指数

对于点 (x, y) , 卡茨指数 [29] 定义为

$$\text{Katz}_{x, y} = \sum_{l=1}^{\infty} \beta^l |\text{walkshli}(x, y)| = \sum_{l=1}^{\infty} \beta^l [A^l]_{x, y}, \quad (3)$$

其中, $\text{walkshli}(x, y)$ 表示 x 和 y 之间长度为 l 的所有路径的集合, A 是网络邻接矩阵的 1 次幂。Katz 指数对 x 和 y 之间所有路径的集合求和, 其中长度为 l 的路径会因 β^l 而衰减 ($0 < \beta < 1$), 从而赋予较短路径更大的权重。

Katz 指数直接以衰减启发式的形式定义, 其中 $\mathcal{H} = 1, \beta = \gamma$, 且 $f(x, y, l) = |\text{walkshli}(x, y)|$ 。根据引理 1, 对于 $l \leq 2h + 1$, $|\text{walkshli}(x, y)|$ 可从 $G_{x, y}$ 计算得出, 因此定理 2 中的性质 2 得以满足。现在我们来证明性质 1 成立的情况。

命题 1. 对于任何节点 $i, j, [A^l]_{i, j}$ 由 d^l 界定, 其中 d 是网络的最大节点度。

证明。我们通过归纳法来证明。当 $l = 1$ 时, 对于任意的 (i, j) 都有 $A_{i, j} \leq d$ 。因此, 基本情况成立。现在, 假设归纳假设成立, 即对于任意的 (i, j) 都有 $[A^l]_{i, j} \leq d^l$, 我们有

$$[A^{l+1}]_{i, j} = \sum_{k=1}^{|V|} [A^l]_{i, k} A_{k, j} \leq d^l \sum_{k=1}^{|V|} A_{k, j} \leq d^l d = d^{l+1}. \quad \square$$

取 $d = 1/\gamma$, 我们可以看出, 只要 $d < 1/\gamma$, Katz 指数就会满足定理 2 中的性质 1。在实际应用中, 阻尼因子通常被设置为非常小的值, 比如 $5E-4$ [1], 这意味着 Katz 指数可以很好地从 h 跳包围子图中近似得出。

3.2 PageRank

节点 x 的根 PageRank 计算的是从 x 出发的随机游走者的平稳分布，该游走者以概率 α 迭代移动到其当前位置的随机邻居，以概率 $1 - \alpha$ 返回 x 。设 π_x 表示平稳分布向量。设 $[\pi_x]_i$ 表示在平稳分布下随机游走者处于节点 i 的概率。

设 P 为转移矩阵，其中 $P_{i,j} = \frac{1}{|\Gamma(j)|}$ 当 $(i, j) \in E$ 时，否则 $P_{i,j} = 0$ 。设 e_x 为一个向量，其 x^{th} 元素为 1，其余元素为 0。平稳分布满足

$$\pi_x = \alpha P \pi_x + (1 - \alpha) e_x. \quad (4)$$

在用于链接预测时， (x, y) 的得分由 $[\pi_x]_y$ (或 $[\pi_x]_y + [\pi_y]_x$ 以保证对称性) 给出。为了表明根 PageRank 是一个 α -衰减启发式算法，我们引入了逆 P 距离理论 [30]，该理论表明 $[\pi_x]_y$ 可以等效地写成如下形式：

$$[\pi_x]_y = (1 - \alpha) \sum_{w: x \rightsquigarrow y} P[w] \alpha^{\text{len}(w)}, \quad (5)$$

其中求和是对所有从 x 出发并以 y 结束的路径 w 进行的 (可能多次经过 x 和 y)。对于路径 $w = hv_0, v_1, \dots, v_{k-1}, y$ ， $\text{len}(w) := |hv_0, v_1, \dots, v_{k-1}|$ 表示路径的长度。术语 $P[w]$ 定义为 $\frac{1}{|\Gamma(v_1)|}$ ，这可以解释为行进路径 w 的概率。现在我们有以下定理。

定理 3. 根植的 PageRank 启发式算法是一种 α -衰减启发式算法，满足定理 2 中的性质。

证明。我们首先将 $[\pi_x]_y$ 写成如下形式。

$$[\pi_x]_y = (1 - \alpha) \sum_{l=1}^{\infty} \sum_{w: x \rightsquigarrow y, \text{len}(w)=l} P[w] \alpha^l. \quad (6)$$

定义 $f(x, y, l) := \sum_{w: x \rightsquigarrow y, \text{len}(w)=l} P[w]$ 可得衰减启发式的形式。请注意， $f(x, y, l)$ 是随机游走者从 x 出发恰好走 l 步停在 y 的概率，满足 $\sum_{y \in V} f(x, y, l) = 1$ 。因此， $f(x, y, l) \leq 1$ (property 1)。根据引理 1，对于 $l \leq 2h + 1$ ， $f(x, y, l)$ 也可由 $G[x, y]$ 计算得出 (性质 2)。

3.3 SimRank

SimRank 分数 [10] 的定义基于这样一种直觉：如果两个节点的邻居节点也相似，那么这两个节点就是相似的。其定义如下递归方式给出：如果 $x = y$ ，则 $s(x, y) := 1$ ；否则，

$$s(x, y) := \gamma \frac{\sum_{a \in \Gamma(x)} \sum_{b \in \Gamma(y)} s(a, b)}{|\Gamma(x)| \cdot |\Gamma(y)|} \quad (7)$$

其中 $0 < \gamma < 1$ 为常数。根据文献 [10]，SimRank 有一个等价定义：has an equivalent definition:

$$s(x, y) = \sum_{w: (x, y) \rightsquigarrow (z, z)} P[w] \gamma^{\text{len}(w)}, \quad (8)$$

其中 $w: (x, y) \rightsquigarrow (z, z)$ 表示所有同时进行的路径，其中一条路径从 x 出发，另一条从 y 出发，并且它们首次相遇于任意顶点 z 。对于同时路径 $w = h(v_0, u_0), \dots, (v_k, u_k) i$ ， $\text{len}(w) = k$ 表示该路径的长度。术语 $P[w]$ 同样定义为 $\frac{1}{|\Gamma(v_1)| |\Gamma(u_1)|}$ ，描述了此路径的概率。现在我们有以下定理。

定理 4. SimRank 是一种 γ -衰减启发式算法，满足定理 2 中的性质。

证明。我们将 $s(x, y)$ 写作如下形式。

$$s(x, y) = \sum_{l=1}^{\infty} \sum_{w: (x, y) \rightsquigarrow (z, z), \text{len}(w)=l} P[w] \gamma^l, \quad (9)$$

定义函数 $f(x, y, l) := \sum_{w: (x, y) \rightsquigarrow (z, z), \text{len}(w)=l} P[w]$ 可知，SimRank 是一种衰减因子为 γ 的启发式算法。注意 $\text{len}(w)=1$ 时， $f(x, y, l) \leq 1$ 。很容易看出，对于 $l \leq h$ 的情况， $f(x, y, l)$ 也可以从 $G[x, y]$ 中计算得出。

讨论 存在若干基于路径计数或随机游走的其他高阶启发式算法[6]，它们同样可以纳入 - 衰减启发式框架。此处不再赘述。我们的研究表明，大多数高阶启发式算法本质上都具有相同的 - 衰减启发式形式，因此可以从 h 跳包围子图中进行有效近似，且近似误差呈指数级减小。我们认为 - 衰减启发式算法的普遍存在并非偶然——这意味着成功的链路预测启发式算法最好对远离目标的结构赋予指数级较小的权重，因为从直观上看，网络的远程部分对链路的存在贡献甚微。我们的研究结果为从局部子图中学习启发式算法奠定了基础，因为它们表明局部包围子图已经包含了足够的信息来学习用于链路预测的良好图结构特征，这在很大程度上是可取的，因为从整个网络中学习往往是不可行的。总之，从围绕链接提取的小封闭子图中，我们能够准确计算一阶和二阶启发式算法，并以较小的误差近似各种高阶启发式算法。因此，只要所用模型具备足够的特征学习能力，从这样的封闭子图中学习有望实现至少与各种启发式算法相当的性能。有一些相关工作通过实证验证了局部方法通常能够很好地估计 PageRank 和 SimRank [31, 32]。另一项相关理论工作 [33] 建立了 h 达到普通 PageRank 某固定近似误差的条件。

4 SEAL：一种基于图神经网络（GNN）的理论实现

在本节中，我们将介绍用于链路预测的 SEAL 框架。SEAL 并不限制所学习的特征必须是某些特定形式（如衰减启发式），而是学习用于链路预测的一般图结构特征。它包含三个步骤：1) 封闭子图提取，2) 节点信息矩阵构建，以及 3) 图神经网络学习。给定一个网络，我们的目标是自动学习一个能最好地解释链路形成过程的“启发式”函数。受理论结果的启发，该函数以链路周围的局部封闭子图为输入，并输出链路存在的可能性。为了学习这样的函数，我们在封闭子图上训练一个图神经网络（GNN）。因此，SEAL 的第一步是从一组采样的正链路（已观测到的）和一组采样的负链路（未观测到的）中提取封闭子图，以构建训练数据。

图神经网络（GNN）通常将 (A, X) 作为输入，其中 A （稍有记号滥用）是输入包围子图的邻接矩阵， X 是节点信息矩阵，其每一行对应一个节点的特征向量。SEAL 的第二步是为每个包围子图构建节点信息矩阵 X 。这一步对于训练成功的 GNN 链接预测模型至关重要。接下来，我们将讨论这一关键步骤。在 SEAL 中，节点信息矩阵 X 有三个组成部分：结构节点标签、节点嵌入和节点属性。

4.1 节点标注

在 X 中的第一个组成部分是每个节点的结构标签。节点标记是一个函数 $f_l: V \rightarrow N$ ，它为封闭子图中的每个节点 i 分配一个整数标签 $f_l(i)$ 。其目的是使用不同的标签来标记节点在封闭子图中的不同角色：1) 中心节点 x 和 y 是位于链接之间的目标节点。2) 相对于中心节点处于不同位置的节点对于链接具有不同的结构重要性。适当的节点标记应当标出这些差异。如果不标记这些差异，图神经网络将无法确定链接存在应预测的两个目标节点的位置，并且会丢失结构信息。

我们的节点标记方法基于以下标准：1) 两个目标节点 x 和 y 始终具有独特的标签“1”。2) 如果 $d(i, x) = d(j, x)$ 且 $d(i, y) = d(j, y)$ ，则节点 i 和 j 具有相同的标签。第二个标准是因为，直观地说，节点 i 在一个封闭子图中的拓扑位置可以通过其相对于两个中心节点的半径来描述，即 $(d(i, x), d(i, y))$ 。因此，我们让处于相同轨道上的节点具有相同的标签，这样节点标签就能反映节点在子图中的相对位置和结构重要性。

基于上述标准，我们提出一种双半径节点标记（DRNL）方法，具体如下。首先，将 x 和 y 节点标记为 1。然后，对于任何节点 i ，若其与 x 和 y 的距离 $(d(i, x), d(i, y))$ 为 $(1, 1)$ ，则标记为 $f_l(i) = 2$ 。半径为 $(1, 2)$ 或 $(2, 1)$ 的节点标记为 3。半径为 $(1, 3)$ 或 $(3, 1)$ 的节点标记为 4。半径为 $(2, 2)$ 的节点标记为 5。半径为 $(1, 4)$ 或 $(4, 1)$ 的节点标记为 6。半径为 $(2, 3)$ 或 $(3, 2)$ 的节点标记为 7。依此类推。换句话说，我们依次为相对于两个中心节点距离更大的节点分配更大的标签，其中标签 $f_l(i)$ 与双半径 $(d(i, x), d(i, y))$ 满足

- 1) if $d(i, x) + d(i, y) \neq d(j, x) + d(j, y)$, then $d(i, x) + d(i, y) < d(j, x) + d(j, y) \Leftrightarrow f_l(i) < f_l(j)$;
- 2) if $d(i, x) + d(i, y) = d(j, x) + d(j, y)$, then $d(i, x)d(i, y) < d(j, x)d(j, y) \Leftrightarrow f_l(i) < f_l(j)$.

DRNL 的一个优点是它具有完美的哈希函数。

$$f_l(i) = 1 + \min(d_x, d_y) + (d/2)[(d/2) + (d\%2) - 1], \quad (10)$$

其中 d_x 表示 $d(i, x)$, d_y 表示 $d(i, y)$, d 表示 $d_x + d_y$, $(d/2)$ 和 $(d\%2)$ 分别是 d 除以 2 的整数商和余数。这种完美的哈希方式使得快速的闭式计算成为可能。

对于距离 $\backslash(i\backslash)$ 与 $\backslash(x\backslash)$ 或 $\backslash(y\backslash)$ 为 1 的节点, 我们给它们赋予空标签 0。请注意, DRNL 并非节点标记的唯一可能方式, 但我们通过实验证明了其性能优于不进行标记以及其他简单的标记方式。关于节点标记的更多内容, 请参见附录 B。获取标签后, 我们使用它们的一热编码向量来构建 $\backslash(X\backslash)$ 。

4.2 融合潜在特征和显性特征

除了结构节点标签外, 节点信息矩阵 X 还提供了纳入潜在特征和显式特征的机会。通过将每个节点的嵌入/属性向量连接到 X 中对应的行, 我们可以使 SEAL 同时从这三种类型的特征中学习。

为 SEAL 生成节点嵌入并非易事。假设我们已知观测到的网络 $G = (V, E)$ 、一组抽样得到的正训练链接 $E_p \subseteq E$ 以及一组抽样得到的负训练链接 E_n , 且 $E_n \cap E = \emptyset$ 。如果我们直接在 G 上生成节点嵌入, 这些嵌入将记录训练链接的连接存在信息 (因为 $E_p \subseteq E$)。我们观察到, GNN 能够迅速找出这些连接存在信息, 并仅通过拟合这部分信息进行优化。这导致我们在实验中观察到其泛化性能不佳。我们的技巧是临时将 E_n 添加到 E 中, 并在 $G_0 = (V, E \cup E_n)$ 上生成嵌入。这样一来, 正训练链接和负训练链接在嵌入中记录的连接存在信息相同, GNN 就无法仅通过拟合这部分信息来对链接进行分类。我们通过实验证明了这一技巧对 SEAL 性能的显著提升。我们将这一技巧称为“负链接注入”。

我们将所提出的框架命名为 SEAL (从子图、嵌入和属性中学习以进行链路预测), 突出了其能够从三种类型的特征中联合学习的能力。

5 实验结果

我们进行了大量实验来评估 SEAL。实验结果表明, SEAL 是一个出色的、稳健的链路预测框架, 在各种网络中均取得了前所未有的强劲表现。我们使用 AUC 和平均精度 (AP) 作为评估指标。所有实验均重复 10 次, 并报告平均 AUC 结果及标准差。AP 和时间结果见附录 F。SEAL 对所使用的 GNN 或节点嵌入具有很高的灵活性。因此, 我们选择近期架构 DGCNN [17] 作为默认 GNN, 选择 node2vec [20] 作为默认嵌入。代码和数据可在 <https://github.com/muhanzhang/SEAL> 获取。

数据集 所使用的八个数据集分别为: USAir、NS、PB、Yeast、C.ele、Power、Router 和 E.coli (详情请参见附录 C)。我们从每个数据集中随机移除 10% 的现有链接作为正测试数据。按照基于学习的链路预测的标准方式, 我们随机抽取相同数量的不存在的链接 (未连接的节点对) 作为负测试数据。我们使用剩余的 90% 的现有链接以及相同数量的额外抽取的不存在的链接来构建训练数据。

与启发式方法的比较 我们首先将 SEAL 与仅使用图结构特征的方法进行比较。我们纳入了八种流行的启发式方法 (见附录 A 表 3): 共同邻居 (CN)、杰卡德系数 (Jaccard)、优先连接 (PA)、阿达米-阿达 (AA)、资源分配 (RA)、卡茨 (Katz)、PageRank (PR) 和 SimRank (SR)。我们还纳入了集成方法 (ENS), 它基于这八种启发式得分训练逻辑回归分类器。此外, 我们还纳入了两种启发式学习方法: 魏斯费勒-莱赫曼图核 (WLK) [34] 和 WLNLM [12], 它们也从 (截断的) 包围子图中学习。我们未纳入路径排序方法 [28] 以及其他专门针对知识图谱或推荐系统的近期方法 [23, 35]。由于所有基线方法仅使用图结构特征, 我们限制 SEAL 不包含任何潜在或显式特征。在 SEAL 中, 跳数 h 是一个重要的超参数。在此, 我们仅从 $\{1, 2\}$ 中选择 h , 因为一方面我们通过实证验证发现性能通常不会增加。

在 $h = 3$ 之后，这验证了我们的理论结果，即最有用的信息存在于局部结构中。另一方面，即使 $h = 3$ ，有时如果包含枢纽节点，也会导致非常大的子图。这引发了在子图中采样节点的想法，我们将其留作未来的工作。选择原则非常简单：如果二阶启发式 AA 在 10% 的验证数据上优于一阶启发式 CN，那么我们选择 $h = 2$ ；否则我们选择 $h = 1$ 。对于 PB 和 E.coli 数据集，我们始终使用 $h = 1$ 以适应内存。关于基线 and 超参数的更多细节见附录 D。

表 1: 与启发式方法的比较 (AUC)

数据	中国	雅卡尔	PA	AA	RA	卡茨	公关	SR	ENS	巫妖王之怒	WLNLM	海豹
全美航空	93.80±1.22	89.79±1.61	88.84±1.45	95.06±1.03	95.77±0.92	92.88±1.42	94.67±1.08	78.89±2.31	88.96±1.44	96.63±0.73	95.95±1.10	96.62±0.72
NS	94.42±0.95	94.43±0.93	68.65±2.03	94.45±0.93	94.45±0.93	94.85±1.10	94.89±1.08	94.79±1.08	97.64±0.25	98.57±0.51	98.61±0.49	98.85±0.47
PB	92.04±0.35	87.41±0.39	90.14±0.45	92.36±0.34	92.46±0.37	92.92±0.35	93.54±0.41	77.08±0.80	90.15±0.45	93.83±0.59	93.49±0.47	94.72±0.46
酵母	89.37±0.61	89.32±0.60	82.20±1.02	89.43±0.62	89.45±0.62	92.24±0.61	92.76±0.55	91.49±0.57	82.36±1.02	95.86±0.54	95.62±0.52	97.91±0.52
C.ele	85.13±1.61	80.19±1.64	74.79±2.04	86.95±1.40	87.49±1.41	86.34±1.89	90.32±1.49	77.07±2.00	74.94±2.04	89.72±1.67	86.18±1.72	90.30±1.35
力量	58.80±0.88	58.79±0.88	44.33±1.02	58.79±0.88	58.79±0.88	65.39±1.59	66.00±1.59	76.15±1.06	79.52±1.78	82.41±3.43	84.76±0.98	87.61±1.57
路由图	56.43±0.52	56.40±0.52	47.58±1.47	56.43±0.51	56.43±0.51	38.62±1.35	38.76±1.39	37.40±1.27	47.58±1.48	87.42±2.08	94.41±0.88	96.38±1.45
大肠杆菌	93.71±0.39	81.31±0.61	91.82±0.58	95.36±0.34	95.95±0.35	93.50±0.44	95.57±0.44	62.49±1.43	91.89±0.58	96.94±0.29	97.21±0.27	97.64±0.22

表 1 展示了结果。首先，我们观察到从包含子图中学习的方法（WLK、WLNLM 和 SEAL）通常比预定义的启发式方法表现得要好得多。这表明学习到的“启发式方法”比人工设计的更能捕捉网络特性。在基于学习的方法中，SEAL 的表现最佳，这表明 GNN 在图特征学习方面比图核和全连接神经网络更具优势。从 Power 和 Router 的结果来看，尽管现有的启发式方法的表现与随机猜测类似，但基于学习的方法仍能保持较高的性能。这表明，即使在现有启发式方法不起作用的网络中，我们也能发现新的“启发式方法”。

表 2: 与潜在特征方法的比较 (AUC)

数据	MF	SBM	N2V	线	SPC	VGAE	海豹
全美航空	94.08±0.80	94.85±1.14	91.44±1.78	81.47±10.71	74.22±3.11	89.28±1.99	97.09±0.70
NS	74.55±4.34	92.30±2.26	91.52±1.28	80.63±1.90	89.94±2.39	94.04±1.64	97.71±0.93
PB	94.30±0.53	93.90±0.42	85.79±0.78	76.95±2.76	83.96±0.86	90.70±0.53	95.01±0.34
酵母	90.28±0.69	91.41±0.60	93.67±0.46	87.45±3.33	93.25±0.40	93.88±0.21	97.20±0.64
C.ele	85.90±1.74	86.48±2.60	84.11±1.27	69.21±3.14	51.90±2.57	81.80±2.18	89.54±2.04
力量	50.63±1.10	66.57±2.05	76.22±0.92	55.63±1.47	91.78±0.61	71.20±1.65	84.18±1.82
路由图	78.03±1.63	85.65±1.93	65.46±0.86	67.15±2.10	68.79±2.42	61.51±1.22	95.68±1.22
大肠杆菌	93.76±0.56	93.82±0.41	90.82±1.49	82.38±2.19	94.92±0.32	90.81±0.63	97.22±0.28

同样使用了图神经网络（GNN）。请注意 VGAE 和 SEAL 之间的区别：VGAE 使用节点级别的 GNN 来学习能够最佳重构网络的节点嵌入，而 SEAL 则使用图级别的 GNN 对封闭式图进行分类。因此，VGAE 仍属于潜在特征方法。对于 SEAL，我们还在节点信息矩阵 X 中额外加入了 128 维的 node2vec 嵌入。由于数据集没有节点属性，所以没有包含显式特征。

表 2 展示了结果。正如我们所见，SEAL 相较于潜在特征方法有了显著的提升。其中一个原因是 SEAL 同时从图结构和潜在特征中学习，从而增强了那些仅使用潜在特征的方法。我们观察到，使用 node2vec 嵌入的 SEAL 大幅优于纯 node2vec。这表明仅靠网络嵌入可能无法捕捉到位于局部结构中的最有用的链路预测信息。有趣的是，与未使用 node2vec 嵌入的 SEAL（表 1）相比，联合学习并非总是能提升性能。更多实验和讨论见附录 F。

6 结论

自动学习链路预测启发式算法是一个新兴领域。在本文中，我们从理论上论证了从局部封闭式图中学习的合理性。特别是，我们提出了一个衰减理论，以统一广泛的高阶启发式算法，并证明了它们可以从局部子图中进行近似。受该理论启发，我们提出了一种新颖的链路预测框架 SEAL，它基于图神经网络同时从局部封闭式图、嵌入和属性中学习。实验表明，与各种启发式算法、潜在特征方法和网络嵌入算法相比，SEAL 实现了前所未有的强大性能。我们希望 SEAL 不仅能激发链路预测研究，还能为知识图谱补全和推荐系统等其他关系机器学习问题开辟新的方向。

与潜在特征的比较

方法 接下来我们将 SEAL 与六种最先进的潜在特征模型进行比较

方法：矩阵分解（MF）、随机块模型（SBM）[18]、节点 2 谓词（N2V）[20]、LINE [21]、谱聚类（SPC）以及变分图自编码器（VGAE）[36]。其中，VGAE

致谢

该研究部分得到了美国国家科学基金会 III-1526012 和 SCH-1622678 项目以及美国国立卫生研究院 1R21HS024581 项目的资助。

参考文献

- [1] David Liben-Nowell and Jon Kleinberg. The link-prediction problem for social networks. *Journal of the American society for information science and technology*, 58(7):1019–1031, 2007.
- [2] Lada A Adamic and Eytan Adar. Friends and neighbors on the web. *Social networks*, 25(3):211–230, 2003.
- [3] Yehuda Koren, Robert Bell, and Chris Volinsky. Matrix factorization techniques for recommender systems. *Computer*, (8):30–37, 2009.
- [4] Maximilian Nickel, Kevin Murphy, Volker Tresp, and Evgeniy Gabrilovich. A review of relational machine learning for knowledge graphs. *Proceedings of the IEEE*, 104(1):11–33, 2016.
- [5] Tolutola Oyetunde, Muhan Zhang, Yixin Chen, Yinjie Tang, and Cynthia Lo. Boostgapfill: Improving the fidelity of metabolic network reconstructions through integrated constraint and pattern-based methods. *Bioinformatics*, 2016.
- [6] Linyuan Lü and Tao Zhou. Link prediction in complex networks: A survey. *Physica A: Statistical Mechanics and its Applications*, 390(6):1150–1170, 2011.
- [7] Albert-László Barabási and Réka Albert. Emergence of scaling in random networks. *Science*, 286(5439): 509–512, 1999.
- [8] Tao Zhou, Linyuan Lü, and Yi-Cheng Zhang. Predicting missing links via local information. *The European Physical Journal B*, 71(4):623–630, 2009.
- [9] Sergey Brin and Lawrence Page. Reprint of: The anatomy of a large-scale hypertextual web search engine. *Computer networks*, 56(18):3825–3833, 2012.
- [10] Glen Jeh and Jennifer Widom. Simrank: a measure of structural-context similarity. In *Proceedings of the eighth ACM SIGKDD international conference on Knowledge discovery and data mining*, pages 538–543. ACM, 2002.
- [11] István A Kovács, Katja Luck, Kerstin Spirohn, Yang Wang, Carl Pollis, Sadie Schlabach, Wenting Bian, Dae-Kyum Kim, Nishka Kishore, Tong Hao, et al. Network-based prediction of protein interactions. *bioRxiv*, page 275529, 2018.
- [12] Muhan Zhang and Yixin Chen. Weisfeiler-lehman neural machine for link prediction. In *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 575–583. ACM, 2017.
- [13] Joan Bruna, Wojciech Zaremba, Arthur Szlam, and Yann LeCun. Spectral networks and locally connected networks on graphs. *arXiv preprint arXiv:1312.6203*, 2013.
- [14] David K Duvenaud, Dougal Maclaurin, Jorge Iparraguirre, Rafael Bombarell, Timothy Hirzel, Alán Aspuru-Guzik, and Ryan P Adams. Convolutional networks on graphs for learning molecular fingerprints. In *Advances in neural information processing systems*, pages 2224–2232, 2015.
- [15] Thomas N Kipf and Max Welling. Semi-supervised classification with graph convolutional networks. *arXiv preprint arXiv:1609.02907*, 2016.
- [16] Mathias Niepert, Mohamed Ahmed, and Konstantin Kutzkov. Learning convolutional neural networks for graphs. In *International conference on machine learning*, pages 2014–2023, 2016.
- [17] Muhan Zhang, Zhicheng Cui, Marion Neumann, and Yixin Chen. An end-to-end deep learning architecture for graph classification. In *AAAI*, pages 4438–4445, 2018.
- [18] Edoardo M Airoldi, David M Blei, Stephen E Fienberg, and Eric P Xing. Mixed membership stochastic blockmodels. *Journal of Machine Learning Research*, 9(Sep):1981–2014, 2008.

- [19] Bryan Perozzi, Rami Al-Rfou, and Steven Skiena. Deepwalk: Online learning of social representations. In *Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining*, pages 701–710. ACM, 2014.
- [20] Aditya Grover and Jure Leskovec. node2vec: Scalable feature learning for networks. In *Proceedings of the 22nd ACM SIGKDD international conference on Knowledge discovery and data mining*, pages 855–864. ACM, 2016.
- [21] Jian Tang, Meng Qu, Mingzhe Wang, Ming Zhang, Jun Yan, and Qiaozhu Mei. Line: Large-scale information network embedding. In *Proceedings of the 24th International Conference on World Wide Web*, pages 1067–1077. International World Wide Web Conferences Steering Committee, 2015.
- [22] Jiezhong Qiu, Yuxiao Dong, Hao Ma, Jian Li, Kuansan Wang, and Jie Tang. Network embedding as matrix factorization: Unifying deepwalk, line, pte, and node2vec. *arXiv preprint arXiv:1710.02971*, 2017.
- [23] Maximilian Nickel, Xueyan Jiang, and Volker Tresp. Reducing the rank in relational factorization models by including observable patterns. In *Advances in Neural Information Processing Systems*, pages 1179–1187, 2014.
- [24] He Zhao, Lan Du, and Wray Buntine. Leveraging node attributes for incomplete relational data. In *International Conference on Machine Learning*, pages 4072–4081, 2017.
- [25] Yujia Li, Daniel Tarlow, Marc Brockschmidt, and Richard Zemel. Gated graph sequence neural networks. *arXiv preprint arXiv:1511.05493*, 2015.
- [26] Hanjun Dai, Bo Dai, and Le Song. Discriminative embeddings of latent variable models for structured data. In *Proceedings of The 33rd International Conference on Machine Learning*, pages 2702–2711, 2016.
- [27] Justin Gilmer, Samuel S Schoenholz, Patrick F Riley, Oriol Vinyals, and George E Dahl. Neural message passing for quantum chemistry. *arXiv preprint arXiv:1704.01212*, 2017.
- [28] Ni Lao and William W Cohen. Relational retrieval using a combination of path-constrained random walks. *Machine learning*, 81(1):53–67, 2010.
- [29] Leo Katz. A new status index derived from sociometric analysis. *Psychometrika*, 18(1):39–43, 1953.
- [30] Glen Jeh and Jennifer Widom. Scaling personalized web search. In *Proceedings of the 12th international conference on World Wide Web*, pages 271–279. Acm, 2003.
- [31] Yen-Yu Chen, Qingqing Gan, and Torsten Suel. Local methods for estimating pagerank values. In *Proceedings of the thirteenth ACM international conference on Information and knowledge management*, pages 381–389. ACM, 2004.
- [32] Xu Jia, Hongyan Liu, Li Zou, Jun He, Xiaoyong Du, and Yuanzhe Cai. Local methods for estimating simrank score. In *Web Conference (APWEB), 2010 12th International Asia-Pacific*, pages 157–163. IEEE, 2010.
- [33] Ziv Bar-Yossef and Li-Tal Mashiach. Local approximation of pagerank and reverse pagerank. In *Pro-ceedings of the 17th ACM conference on Information and knowledge management*, pages 279–288. ACM, 2008.
- [34] Nino Shervashidze, Pascal Schweitzer, Erik Jan van Leeuwen, Kurt Mehlhorn, and Karsten M Borgwardt. Weisfeiler-lehman graph kernels. *Journal of Machine Learning Research*, 12(Sep): 2539–2561, 2011.
- [35] Federico Monti, Michael Bronstein, and Xavier Bresson. Geometric matrix completion with recurrent multi-graph neural networks. In *Advances in Neural Information Processing Systems*, pages 3700–3710, 2017.
- [36] Thomas N Kipf and Max Welling. Variational graph auto-encoders. *arXiv preprint arXiv:1611.07308*, 2016.
- [37] Ulrike V Luxburg, Agnes Radl, and Matthias Hein. Getting lost in space: Large sample analysis of the resistance distance. In *Advances in Neural Information Processing Systems*, pages 2622–2630, 2010.
- [38] Leonardo FR Ribeiro, Pedro HP Saverese, and Daniel R Figueiredo. struc2vec: Learning node representations from structural identity. In *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 385–394. ACM, 2017.
- [39] Will Hamilton, Zhitaoy Ying, and Jure Leskovec. Inductive representation learning on large graphs. In *Advances in Neural Information Processing Systems*, pages 1025–1035, 2017.

- [40] Yi-An Lai, Chin-Chi Hsu, Wen Hao Chen, Mi-Yen Yeh, and Shou-De Lin. Prune: Preserving proximity and global ranking for network embedding. In *Advances in Neural Information Processing Systems*, pages 5263–5272, 2017.
- [41] Alberto Garcia Duran and Mathias Niepert. Learning graph representations with embedding propagation. In *Advances in Neural Information Processing Systems*, pages 5125–5136, 2017.
- [42] Yehuda Koren. Factorization meets the neighborhood: a multifaceted collaborative filtering model. In *Proceedings of the 14th ACM SIGKDD international conference on Knowledge discovery and data mining*, pages 426–434. ACM, 2008.
- [43] Steffen Rendle. Factorization machines. In *10th IEEE International Conference on Data Mining (ICDM)*, pages 995–1000. IEEE, 2010.
- [44] Vladimir Batagelj and Andrej Mrvar. <http://vlado.fmf.uni-lj.si/pub/networks/data/>, 2006.
- [45] Mark EJ Newman. Finding community structure in networks using the eigenvectors of matrices. *Physical review E*, 74(3):036104, 2006.
- [46] Robert Ackland et al. Mapping the us political blogosphere: Are conservative bloggers more prominent? In *BlogTalk Downunder 2005 Conference, Sydney*. BlogTalk Downunder 2005 Conference, Sydney, 2005.
- [47] Christian Von Mering, Roland Krause, Berend Snel, Michael Cornell, Stephen G Oliver, Stanley Fields, and Peer Bork. Comparative assessment of large-scale data sets of protein–protein interactions. *Nature*, 417(6887):399–403, 2002.
- [48] Duncan J Watts and Steven H Strogatz. Collective dynamics of ‘small-world’ networks. *Nature*, 393(6684): 440–442, 1998.
- [49] Neil Spring, Ratul Mahajan, David Wetherall, and Thomas Anderson. Measuring isp topologies with rocketfuel. *IEEE/ACM Transactions on networking*, 12(1):2–16, 2004.
- [50] Muhan Zhang, Zhicheng Cui, Shali Jiang, and Yixin Chen. Beyond link prediction: Predicting hyperlinks in adjacency space. In *AAAI*, pages 4430–4437, 2018.
- [51] Christopher Aicher, Abigail Z Jacobs, and Aaron Clauset. Learning latent block structure in weighted networks. *Journal of Complex Networks*, 3(2):221–248, 2015.
- [52] Steffen Rendle. Factorization machines with libfm. *ACM Transactions on Intelligent Systems and Technology (TIST)*, 3(3):57, 2012.
- [53] Rong-En Fan, Kai-Wei Chang, Cho-Jui Hsieh, Xiang-Rui Wang, and Chih-Jen Lin. Liblinear: A library for large linear classification. *Journal of machine learning research*, 9(Aug):1871–1874, 2008.
- [54] S Vichy N Vishwanathan, Nicol N Schraudolph, Risi Kondor, and Karsten M Borgwardt. Graph kernels. *Journal of Machine Learning Research*, 11(Apr):1201–1242, 2010.
- [55] Mahito Sugiyama and Karsten Borgwardt. Halting in random walk kernels. In *Advances in neural information processing systems*, pages 1639–1647, 2015.
- [56] Fabrizio Costa and Kurt De Grave. Fast neighborhood subgraph pairwise distance kernel. In *Proceedings of the 26th International Conference on Machine Learning*, pages 255–262. Omnipress, 2010.
- [57] Nils Kriege and Petra Mutzel. Subgraph matching kernels for attributed graphs. In *Proceedings of the 29th International Conference on Machine Learning (ICML-12)*, pages 1015–1022, 2012.
- [58] Karsten M Borgwardt and Hans-Peter Kriegel. Shortest-path kernels on graphs. In *Data Mining, Fifth IEEE International Conference on*, pages 8–pp. IEEE, 2005.
- [59] Marion Neumann, Roman Garnett, Christian Bauckhage, and Kristian Kersting. Propagation kernels: efficient graph kernels from propagated information. *Machine Learning*, 102(2):209–245, 2016.
- [60] Jure Leskovec and Andrej Krevl. {SNAP Datasets}:{Stanford} large network dataset collection. 2015.
- [61] Reza Zafarani and Huan Liu. Social computing data repository at asu, 2009. URL <http://socialcomputing.asu.edu>.
- [62] Matt Mahoney. Large text compression benchmark, 2011.
- [63] Chris Stark, Bobby-Joe Breitkreutz, Teresa Regul, Lorrie Boucher, Ashton Breitkreutz, and Mike Tyers. Biogrid: a general repository for interaction datasets. *Nucleic acids research*, 34(suppl_1): D535–D539, 2006.