

AttentionSiteDTI: 一种基于图的可解释模型, 利用自然语言处理的句子级关系分类进行药物-靶点相互作用预测

Mehdi Yazdani-Jahromi[†], Niloofar Yousefi[†], Aida Tayebi, Elayaraja Kolanthai, Craig J. Neal, Sudipta Seal and Ozlem Ozmen Garibay

通讯作者: 奥兹勒姆·加里贝伊·奥兹门, 美国佛罗里达中央大学工业工程与管理学院, 美国奥兰多市佛罗里达中央大道 4000 号, 邮编 32816; 电子邮箱: ozlem@ucf.edu

[†]梅赫迪·亚兹达尼·贾赫罗米和尼卢法尔·尤瑟菲对本文的贡献相同。

摘要

在本研究中, 我们引入了一种可解释的基于图的深度学习预测模型 AttentionSiteDTI, 该模型利用蛋白质结合位点以及自注意力机制来解决药物 - 靶点相互作用预测的问题。我们提出的模型受到自然语言处理领域句子分类模型的启发, 将药物 - 靶点复合物视为具有其生化实体 (即蛋白质口袋和药物分子) 之间关系意义的句子。AttentionSiteDTI 通过识别对药物 - 靶点相互作用贡献最大的蛋白质结合位点来实现可解释性。在三个基准数据集上的结果表明, 与当前最先进的模型相比, 性能有所提高。更重要的是, 与以往的研究不同, 当在新蛋白质上进行测试时, 我们的模型表现出更优越的性能 (即具有更高的泛化能力)。通过多学科合作, 我们进一步通过实验评估了所提出方法的实际潜力。为实现这一目标, 我们首先通过计算预测一些候选化合物与目标蛋白质之间的结合相互作用, 然后在实验室中对这些配对的结合相互作用进行实验验证。计算预测结果与实验观察 (测量) 到的药物 - 靶点相互作用之间高度一致, 这表明我们的方法在药物再利用应用中具有作为有效预筛选工具的潜力。

关键词: 深度学习、自注意力机制、结合位点、机器学习、药物靶点相互作用、严重急性呼吸综合征冠状病毒 2 型、药物靶点相互作用软件、药物靶点相互作用数据库。

介绍

药物-靶点相互作用 (DTI) 描述了药物与其靶点之间的结合情况, 这对于新药的发现以及现有药物的再利用至关重要。高通量筛选仍是检测药物与靶点亲和力最可靠的方法。然

而, 由于化学化合物、靶点和混合物的空间巨大, 对每一对可能的化合物-蛋白质进行实验表征很快变得不切实际。这促使人们采用计算方法来进行药物-靶点相互作用的预测。分子模拟和分子对接是早期采用的方法。

Mehdi Yazdani-Jahromi is a second year PhD student at University of Central Florida. His current research interests include Graph Neural Networks, Algorithmic Fairness.

Niloofar Yousefi is a Postdoctoral Research Associate at UCF's Complex Adaptive Systems (CAS) laboratory in the collage of Engineering and Computer Science. Her research areas include Machine Learning, Artificial Intelligence and Statistical Learning Theory to develop data analytics solutions with more transparency and explainability.

Aida Tayebi is a second year PhD student at University of Central Florida. Her current research interests include Algorithmic Fairness, and bias mitigation techniques in DTI.

Ozlem Ozmen Garibay is an Assistant Professor of Industrial Engineering and Management System at the University of Central Florida where she directs the Human-Centered Artificial Intelligence Research Lab (Human-CAIR Lab). Prior to that, she served as the Director of Research Technology. Her areas of research are big data, social media analysis, social cybersecurity, artificial social intelligence, human-machine teams, social and economic networks, network science, STEM education analytics, higher education economic impact and engagement, artificial intelligence, evolutionary computation and complex systems.

Sudipta Seal is currently the chair of the Department of Materials Science and Engineering at University of Central Florida, as well as a Pegasus Professor and a University Distinguished Professor. He joined the Advanced Materials Processing and Analysis Center and UCF in 1997. He has been consistently productive in research, instruction and service to UCF since 1998. He has served as the Nano Initiative coordinator for the vice president of research and commercialization. He served as the director of AMPAC and the NanoScience Technology Center from 2009 to 2017.

Elayaraja Kolanthai is a Postdoctoral Research Associate at UCF's Materials Science and Engineering. His current research interests include Development of nanoparticles, layer-by-layer antimicrobial/antiviral nanoparticle coating, polymer composites for tissue engineering and gene/drug delivery application. **Craig J. Neal** is a Postdoctoral Research Associate at UCF's Materials Science and Engineering. His current research interests include Wet chemical synthesis and surface engineering of nanoparticles for biomedical applications and electrochemical devices. Electroanalysis of nanomaterials and bio-nano interactions. **Received:** February 18, 2022. **Revised:** May 1, 2022. **Accepted:** June 10, 2022

计算方法通常需要目标蛋白质的三维结构来评估药物-靶点相互作用 (DTI)，但这类基于结构的方法的应用受到限制，因为有许多蛋白质的三维结构未知，而且其过程成本高昂。机器学习 (ML) 算法的出现解决了药物设计和发现过程中的一些难题。传统的基于浅层机器学习的模型，如 KronRLS [1] 和 SimBoost [2]，需要手工设计特征，这极大地影响了模型的性能。深度学习由于能够自动捕捉有用的潜在特征，改进了这些传统模型，从而形成了具有高度灵活性的模型，能够广泛地识别、处理和外推分子数据中的复杂模式。用于药物-靶点相互作用的深度学习模型主要可以分为两类。一类是为基于序列的输入数据表示而设计的模型，例如卷积神经网络

(CNNs) 和循环神经网络 (RNNs)。这类模型无法捕捉分子的结构信息，导致预测能力下降。这种局限性促使人们采用更自然的分子表示方法，并引入了第二类深度学习模型，即图神经网络 (GNN)。GNN 使用分子的图描述，其中原子和化学键分别对应节点和边。图卷积神经网络 (GCNN) 和图注意力网络 (GAT) [3] 是计算机辅助药物设计和发现中广泛使用的基于 GNN 的两种模型[4-6]。所有这些基于图的模型都使用氨基酸序列表示蛋白质，但无法捕捉到预测药物-靶点相互作用 (DTIs) 的关键因素——蛋白质的 3D 结构特征。获取蛋白质的高分辨率 3D 结构是一项具有挑战性的任务，而且蛋白质包含大量原子，需要大规模的 3D (稀疏) 矩阵来捕捉其整体结构。为了解决这个问题，人们采用了另一种策略，即用 2D 接触 (或距离) 图来表示蛋白质，该图以矩阵形式展示蛋白质残基对之间的相互作用[7, 8]。值得一提的是，接触图 (或距离图) 通常是蛋白质结构预测的输出结果，其基于启发式方法，仅提供蛋白质真实结构的近似抽象；通常与通过 X 射线晶体学或核磁共振光谱 (NMR) 实验确定的结构不同[9]。综合考虑所有这些因素，并考虑到蛋白质与许多分子的结合通常发生在不同的结合口袋而非整个蛋白质上，在本文中，我们提出了 AttentionSiteDTI，这是一种基于图的深度学习模型，将小分子和蛋白质结合位点的结构特征以图的形式纳入药物-靶点相互作用 (DTI) 预测任务的流程中。模型自动学习到的小分子和蛋白质的结构特征

将更有利于下游任务。我们的方法受到自然语言处理 (NLP) 领域中用于句子分类的模型的启发，其动机在于药物 - 靶点复合物的结构与自然语言句子的结构非常相似，即实体的结构和关系信息对于理解句子中的关键信息至关重要。在这方面，每个蛋白质口袋或药物都类似于一个单词，而每个药物 - 靶点对都类似于一个句子。我们的 AttentionSiteDTI 利用了自注意力双向长短期记忆 (LSTM) 机制，由于其自注意力机制，具有很高的可解释性。本质上，自注意力机制能够理解蛋白质的哪些部分最有可能与给定药物结合。所提出框架的可视化结果见图 1。计算结果表明，我们的模型在多个评估指标上优于许多最先进的模型。我们的消融研究表明，注意力机制在捕捉决定药物 - 靶点相互作用的重要因素方面非常有效。此外，我们实验室内的实验验证表明，七种候选化合物与刺突 (或 ACE2) 蛋白之间计算预测的结合相互作用与实验观察结果高度一致。

贡献

我们研究的主要贡献总结如下。

我们提出了一种受自然语言处理 (NLP) 领域最新进展启发的药物靶点相互作用 (DTI) 预测问题的新颖表述方法，该方法实现了最先进的性能，同时具有很高的泛化能力和可解释性。我们的方法类似于 NLP 中的句子分类问题，将药物 - 靶点复合物视为一个句子，其中的生化实体 (即蛋白质口袋和药物分子) 之间存在关系意义。我们使用端到端的基于图卷积神经网络 (GCNN) 的模型来解决我们的句子分类问题，该模型能够同时学习 (1) 从分子和蛋白质口袋的图中获取上下文敏感嵌入 (即嵌入不是固定的，而是根据其出现的上下文 (即句子) 而变化)，以及 (2) 用于捕获生化序列 (药物 - 靶点复合物) 中最重要上下文语义或关系信息的预测模型，以进行关系分类，类似于 NLP 中的句子分类。有关我们基于 GCNN 的模型的详细信息，请参阅“图注意力嵌入模块”子部分。

我们所提出的模型具有很强的泛化能力，这得益于我们对目标蛋白质输入的表达方式，即采用将蛋白质口袋编码为图的形式。这有助于模型专注于从蛋白质口袋中学习通用的拓扑特征，从而能够推广到与训练数据中的蛋白质不相似的新蛋白质上。我们模型的泛化能力




图 1. 我们提出的框架包含五个主要模块：（1）预处理模块，包括寻找蛋白质的结合位点；（2）AttentionSiteDTI 深度学习模块，在此模块中，我们构建了配体 SMILE 和蛋白质结合位点的图表示，并创建了一个配备注意力池化机制的图卷积神经网络，从图中提取可学习的嵌入，以及一个自注意力机制来学习配体与蛋白质结合位点之间的关系；（3）预测模块，用于预测药物-靶点对中的未知相互作用，能够处理分类和回归任务；（4）解释模块，用于更深入地理解目标蛋白质的哪些结合位点更有可能与给定的配体结合；（5）实验室验证模块，我们将计算预测的结果与实验室中观察到（测量到）的药物-靶点相互作用进行比较，以测试和验证我们所提出模型的实际潜力。

这在 BindingDB 数据集上的未见蛋白质上的卓越表现得到了具体体现（见图 4）。数据准备和图构建这两个小节详细介绍了我们如何为模型准备和使用蛋白质输入。

我们提出的模型是首个能够用蛋白质结合位点的语言进行解释的模型。这一点很重要，因为它将帮助药物设计人员识别关键的蛋白质位点及其功能特性。这是通过设计一种自注意力机制实现的，该机制使模型能够学习蛋白质的哪些部分与配体相互作用，同时还能达到最先进的预测性能。自注意力子部分解释了该机制是如何通过有选择地聚焦于输入中最相关的部分来发挥作用的。

最后，我们验证了所构建模型在预测实际应用中结合相互作用方面的潜在实用性。我们进行了实验室实验，以测量几种化合物与刺突（或 ACE2）蛋白之间的结合相互作用，并将计算预测的结果与实验室中观察到的实验结果进行了比较。有关实验室验证实验的详细信息，请参阅“实验室验证”部分。

相关工作

基于深度学习的方法已成功应用于解决药物-靶点相互作用（DTI）预测的问题。深度学习方法之间的主要区别在于其架构以及输入数据的表示方式。如前所述，

药物的小分子可以很容易且有效地在一维空间中表示，但蛋白质是更大的分子，具有复杂的相互作用，一维表示可能不够充分。尽管包含蛋白质三维结构的数据集有限，但一些近期基于深度学习的研究文献已将其用于研究。例如，AtomNet [10] 是首个将蛋白质的三维结构作为输入，通过三维卷积神经网络（3D CNN）并使用二分类器来预测药物-靶点对结合情况的研究。Ragoza 等人 [11] 提出了一种卷积神经网络评分函数，该函数采用蛋白质-配体复合物的三维表示，并学习了在结合预测中至关重要的特征。该模型在区分和排序结合姿势方面优于 AutoDock Vina 评分。Pafnucy [12] 是一种 3D CNN，用于预测药物-靶点对的结合亲和力值。该研究采用三维网格来表示输入，并将蛋白质和配体的原子视为相似。通过使用一种正则化技术，他们设计的网络专注于捕捉蛋白质与配体之间相互作用的一般特性。

所有这些研究都存在局限性。例如，实验获取高质量的蛋白质三维结构是一项极具挑战性的任务，这也解释了为何包含三维结构信息的数据集数量非常有限 [8]。大多数利用三维结构信息的研究采用卷积神经网络（CNNs），但这些方法不仅计算成本高昂，而且对三维结构的不同取向也很敏感。为了克服这些局限性，近期的研究

例如在[13-15]中所提出的图卷积网络方法，将蛋白质的三维结构作为输入用于药物-靶点相互作用预测任务。还有其他研究将 GCNN 应用于蛋白质-配体复合物的三维结构。在这些研究中，GraphBAR [6] 是首个使用回归方法预测药物-靶点结合亲和力的三维图卷积神经网络。他们使用图来表示蛋白质-配体复合物，而非三维体素化网格立方体。这些图以多个邻接矩阵的形式存在，矩阵中的元素是根据原子的分子属性的距离和特征矩阵计算得出的。此外，他们还使用了对接模拟方法来扩充模型的数据。Lim 等人[5]提出了一种图卷积网络模型，结合了距离感知图注意力机制，直接从对接软件生成的药物-靶点复合物的三维结构中提取相互作用结合构象的特征。他们的模型在虚拟筛选和构象预测任务方面优于对接方法和几种基于深度学习的模型。然而，他们的方法存在一些局限性，比如可解释性较差，以及在深度学习模型中增加了额外的对接误差。Torng 等人[4]提出了 Pocket Feature 这一无监督自编码器模型，用于从目标蛋白的结合位点中学习表示。该模型使用了蛋白质口袋的 3D 图形表示以及药物的 2D 图形表示。他们训练了一个 GCNN 模型来从蛋白质口袋和药物 SMILES 的图形中提取特征。他们的模型优于 3DCNN（如[11]中所述）以及诸如 AutoDock Vina [16]、RF-Score [17] 和 NNScore [17] 等对接模拟模型。Zheng 等人[8]指出直接输入三维结构的效率较低，并利用 2D 距离图来表示蛋白质。他们进一步将药物-靶点相互作用（DTI）预测问题转化为经典的视觉问答（VQA）问题，即给定一个蛋白质的距离图，问题在于给定的药物是否与目标蛋白质相互作用。尽管他们的模型优于几个最先进的模型，但他们的视觉问答系统仅能解决一个分类任务，即预测药物与靶点之间是否存在相互作用。

材料与方法概述

我们引入了一种端到端的基于图的深度学习框架 AttentionSiteDTI，以解决药物-靶点相互作用（DTI）预测的问题。我们将 DTI 预测任务视为一个二分类问题。其目标是学习一个预测函数 $\gamma(\cdot)$ ，该函数以药物和蛋白质的图输入为依据，输出二元预测结果，表明相互作用的存在与否。AttentionSiteDTI 的整体架构如图 1 所示。它由四个模块组成：数据准备、图嵌

入学习模块、预测模块和解释模块。在数据准备阶段，我们使用文献[18]中提出的算法来确定蛋白质的结合位点。接下来，构建蛋白质口袋和配体的图，并将其输入到图卷积神经网络（graph CNN）中，以从相应的图中学习嵌入。然后将药物和蛋白质的特征向量进行整合，以获得结合了它们结构特征的药物-靶点复合物表示。最后，将拼接后的表示输入到二分类器中，以预测药物-靶点相互作用。网络中的自注意力机制将药物-靶点对的拼接嵌入作为输入来计算注意力输出，这使得模型能够学习给定药物-靶点对中蛋白质的哪些部分与配体相互作用，从而具有可解释性。

Algorithm 1 AttentionSiteDTI Training Procedure

P : Protein graph convolution network
 P_P : Protein Pooling Layer
 L : Ligand graph convolution network
 P_L : Ligand pooling Layer
 MLP : Multi-layer perceptron classification layers
 A : Self-Attention Layer
 $LSTM$: Bi-LSTM Layer
 N : Number of epochs
 G_l : Graph of ligand in data instance
 G_p : List of graphs of protein binding sites in data instance
 F_p : List of feature vectors for protein binding sites in data instance
 F_l : Feature vector of ligand in data instance
 S : Sequence of protein binding sites features and ligand feature
 y_i : Label of the data instance = 0, 1
 $p(y_i)$: Predicted label
while Epoch < N **do**
 for $(G_l, G_p, label)$ in data **do**
 $F_p = []$
 for graph in G_p **do**
 $F_p \leftarrow F_p \cup [P_P(P(graph))]$
 end for
 $F_l \leftarrow P_L(L(G_l))$
 $S \leftarrow F_p \cup F_l$
 $S \leftarrow LSTM(S)$
 $S \leftarrow A(S)$
 $p(y_i) \leftarrow MLP(Concat(S))$
 Update P, P_P, L, P_L, A, MLP by descending
 $-\nabla y_i \log(p(y_i)) + (1 - y_i) \log(1 - p(y_i))$
 end for
end while

数据准备

我们使用从蛋白质数据库（PDB）文件中提取的蛋白质的三维结构。PDB 数据是提交的实验值（例如来自核磁共振、X 射线衍射、冷冻电子显微镜）的集合。为了找到蛋白质的结合位点，我们使用了 Saberi Fathi 等人提出的算法[18]，这是从蛋白质的三维结构中提取结合位点的最简单方法之一。该方法是一种基于模拟的模型，可在将数据输入端到端架构之前使用，有助于降低模型的复杂性。




图 2. 图示为 PDB 编号为 6M0J 的新冠病毒刺突蛋白与 ACE2 复合物；表面颜色代表通过 Saberi Fathi 等人的算法计算得出的结合位点。这些结合位点用于生成输入到我们的图嵌入学习模块的数据。所有蛋白质可视化均使用 UCSF Chimera 软件生成[19]。

如文献[18]所示，尽管该模型十分简单，但其性能可与复杂度更高的其他基于仿真的方法相媲美。

该算法会为蛋白质的每个结合位点计算边界框坐标。然后利用这些坐标将完整的蛋白质结构缩减为肽片段的子集。图 2 展示了使用文献 [18] 中算法提取的蛋白质结合位点的可视化效果。

图构建

蛋白质

在提取蛋白质的结合位点之后，我们将它们表示为单独的图，其中每个原子都是一个节点，原子之间的连接则是图中的边。通过使用原子类型、原子度、所连接的氢原子总数以及原子隐式价态的一热编码来计算每个原子的特征向量。这种方法为每个节点生成大小为 1×31 的向量。这些特征总结在表 1 中。由于存在多个图，分别代表给定蛋白质的不同结合口袋，因此会为该特定蛋白质生成多个嵌入。

配体

对于药物相互作用 (DTI) 数据集中以简化分子线性输入规范 (SMILES) 格式表示的每个配体，都会构建一个双向图。请注意，在本研究中，氢原子并未在图中明确表示为节点。同样，会构建一个向量来表示图中每个原子的特征。

表 1. 对每个提取的片段中的原子特征进行编码

类型	编码
原子类型	C、N、O、S、F、P、Cl、Br、B、H (独热编码)
原子度	0、1、2、3、4、5、6、7、8 (独热编码)
氢原子数	0、1、2、3、4 (独热编码)
隐式价电子	0、1、2、3、4、5 (独热编码)
有芳香的	0、1 (独热编码)

配体的图。更具体地说，原子类型的一热编码、原子度、原子的电荷、原子的自由基电子数、原子的杂化状态、原子的芳香性以及原子的总氢原子数被用于构建配体中每个原子的特征。这种方法为每个节点生成一个大小为 1×74 的向量。生成的蛋白质和配体的图随后被输入到一个图卷积神经网络 (GCNN) 中以学习相应的嵌入。

图注意力嵌入模块 拓扑自适应图卷积网络

我们使用拓扑自适应图卷积神经网络 (TAGCN) [20]，它是图卷积网络[21]的一种变体，其工作原理是同时在输入图上滑动一组固定大小的可学习滤波器，以生成滤波器输出的加权和，从而表示图顶点之间的强度相关性以及顶点特征本身[20]。换句话说，卷积层的输出是不同大小 k 的滤波器所产生特征图的加权和，其中 $k = 1, \dots, K$ 。TAGCN 的图卷积层定义为

$$H^k = \sum_{k=1}^K \left((D^{-1/2} A D^{-1/2})^k X \Theta_k + b_k \right), \quad (1)$$

其中 A 表示邻接矩阵， $D_{ii} = \sum_j A_{ij}$ 是其对应的对角度矩阵， X 是节点的输入特征矩阵， Θ_k 是线性权重向量，用于聚合给定节点 k 跳距离内所有相邻顶点的结果。此外， b_i 是可学习的偏差，在每次跳跃后的求和中使用。

池化机制

一旦将蛋白质和药物的图输入一系列图卷积层，我们便使用 Yujia Li 等人[22]提出的方法从相应的图中提取嵌入。对于图级表示，他们定义了一个向量作为

$$h_g = \tanh \left(\sum_{v \in V} \sigma(i(H_v^{(T)}, x_v)) \odot \tanh(j(H_v^{(T)}, x_v)) \right), \quad (2)$$

其中， $\odot$ 表示逐元素相乘， i 和 j 是线性神经网络层，它们是可训练的，用于学习

用于分类的最佳图表示。此外，节点 v 上的 $H^{(l)}v$ 的串联是图卷积层的输出，而 $x_{v,i}$ 是节点 v 的特征向量。请注意，输入和输出均为实值向量， $\sigma(i(H^{(l)}v, x_v))$ 是一种软注意力机制。

注意力机制决定了哪个节点应更多地为最终的图嵌入做出贡献，这使得能够学习到更好的图表示[22]。这种方法之所以被选中，是因为相较于最大池化和平均池化等其他方法，它通过向架构中添加更多参数，能够学习到图中的高阶关系。

自注意力模块序列处理

提取嵌入向量后，我们将该问题视为文本分类问题。我们采用 Zhou 等人[23]提出的方法来学习一个分类器： $X \rightarrow C$ ，其中 X 是蛋白质口袋和配体的嵌入空间， $C = \{0, 1\}$ 是一组分类标签，0 表示药物-靶点对中无活性的相互作用，1 表示有活性的相互作用。对于具有标签 $c \in C$ 的蛋白质-配体复合物 $d \in X$ ，我们定义 $d, c \in X \times C$ 为

$$\langle d, c \rangle = \langle \text{sequence}(\text{protein pockets embeddings}, \text{ligand embedding}), c \rangle. \quad (3)$$

自注意力机制

自注意力机制是一种有选择地聚焦于输入向量中最相关部分的方法。它通过将查询和一组键值对映射为加权值的总和来完成此任务，该加权值由查询与相应键之间的关系计算得出[24]。Vaswani 等人[24]描述了一种称为“缩放点积注意力”的特定注意力机制，其中输入由查询 (Q)、键 (K) 和值 (V) 组成。他们使用线性层将输入序列投影到 Q、K 和 V 上。然后，如[24]所述，将查询向量矩阵乘以键向量矩阵的转置。接着，每个元素除以键维度的平方根进行归一化。在此，我们进一步应用掩码以防止蛋白质的结合位点相互关注。换句话说，我们构建掩码的方式是让每个结合位点仅关注自身和相互作用的配体。这可以通过创建一个与 K 和 Q 维度相同的矩阵来实现，其中对角线元素全部设为 1。此外，矩阵的最后一列，对应于配体的位置，也设为 1。该矩阵中的所有其他值均设置为较小的值 9×10^{-15} ，以防止结合位点相互关注。然后将此掩码与缩放后的结果相乘。接着，将逐行应用 Softmax 函数，从键 K 和查询 Q 计算注意力图。最后，将计算得到的矩阵相乘。




图 3. 自注意力缩放点积。

通过这些值 (V) 进行计算以得出最终结果。这些操作的顺序在图 3 中有所展示，以便更清晰地说明。

$$\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V. \quad (4)$$

这种自注意力机制将一系列嵌入作为输入来提取 Q、K 和 V。然后使用公式 4 计算注意力输出。

双向长短期记忆网络

长短期记忆网络 (LSTM) 是循环神经网络 (RNN) 的一种变体，具有记忆单元，通过在其架构中加入“附加门”能够学习长期依赖关系。传统的 LSTM 仅能保留过去的信息，因为网络仅按原始的正向顺序接收序列输入。双向 LSTM 网络在 LSTM 网络中增加了一层，通过让序列输入在正向和反向两个方向流动，从而保留过去和未来的信息[23]。这种双向 LSTM 的特性在我们的特定应用中特别有用，因为蛋白质结合位点和配体之间没有有意义的相互作用顺序。因此，序列中的未来上下文与过去上下文同样重要。我们使用元素级求和来合并正向和反向传递的输出。

表 2.三个基准数据集（DUD-E 数据集、Human 数据集和 BindingDB 数据集）的描述和统计信息

数据集	毒品	蛋白质	DT 对	活跃的	不活跃的
嘟嘟-E	二万二千八百八十六	102	1429 790	二万二千六百四十五	1407 145
人类	2726	2001	6728	3364	3364
Bindingdb	九百八十九 三百八十三	8536	二千二百八十六 三百一十九	三万九千七百四十七	三十一万二千一百八

预测模块 分类器

先前计算出的特征被连接成一个一维向量 I ，然后传递给分类层。在本研究中，使用了两个全连接层将提取的特征映射到最终的分类输出。我们使用具有 Relu 激活函数的多层感知机。此外，在每个线性层之前使用了 dropout 来提高泛化能力。

我们在最后一层使用逻辑 S 型函数来以概率的形式预测输出。此外，通过将误差反向传播到网络来更新模型的所有参数，采用平均二元交叉熵损失（公式 5）以端到端的方式训练模型。

$$\mathcal{L}(y, \hat{y}) = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]. \quad (5)$$

实验

数据集

我们通过一系列对比实验展示了所提出模型的优势。我们使用三个基准数据集将我们的 AttentionSiteDTI 与几种最先进的方法进行了比较，这些数据集提供了我们模型所需的靶蛋白的 3D 结构信息。这些数据集包括 DUD-E 数据集、Human 数据集和定制的 BindingDB 数据集。表 2 总结了这些数据集的统计信息。我们使用 [18] 中提出的一种简单的基于对接的模型来寻找靶蛋白的结合位点。值得一提的是，我们期望使用更先进的预测/计算方法来寻找蛋白质的结合位点，从而进一步提升我们模型的性能。

DUD-E 数据集 [25] 包含来自八个蛋白质家族的 102 个靶点。每个靶点约有 224 种活性化合物和超过 10000 种诱饵分子，这些诱饵分子是通过计算生成的，其物理属性与活性化合物相似，但拓扑结构不同。遵循 Ragoza 等人 [11] 和 Zheng 等人 [8] 的先前工作，并为了与基准模型进行直接比较，我们在该数据集中进行了 3 折交叉验证，并报告了评估指标的平均性能。每个折分组都是基于靶点进行的，即相似的靶点被保留在同一折

中。我们对诱饵分子进行了随机欠采样以使训练集平衡，并使用不平衡的测试集进行评估。

该数据集是通过系统性的计算机虚拟筛选方法将一组高度可信且可靠的药物 - 蛋白质负样本与已知的正样本相结合而构建的 [26]。该数据集包含 5423 个相互作用。为了进行直接对比，我们采用了与 DrugVQA [8] 相同的训练集、验证集和测试集划分比例（80%、10%、10%）。

BindingDB 这个数据集 [27] 包含了小分子与蛋白质之间相互作用的实验性检测结果。依照 DrugVQA [8] 中的工作，我们使用了该数据集的一个小子集，其中包含 39747 个正样本和 31218 个负样本。此外，为了验证我们所提出模型的泛化能力，测试集被分为两类蛋白质：一类是在训练期间模型见过的蛋白质，另一类是模型未曾见过的蛋白质。

实施与评估策略

实验策略。我们在实现中使用了 Pytorch 1.8.2（长期支持版本）。我们以 100 为批次大小训练模型，训练 30 个周期，并使用学习率为 0.001 的 Adam 优化器训练网络。此外，为了提高泛化能力，在每个全连接层之前使用了概率为 0.3 的 dropout 层。我们用于实验的 GPU 是 Nvidia RTX 3090，其内存为 24GB。在 TAGCN 中，蛋白质的跳数设为 4，配体的跳数设为 2。我们模型中 BiLSTM 层的隐藏状态大小设为 31，这是图卷积层（TAGCN）的输出。我们使用零填充将每个矩阵重塑为数据集中最大结合口袋的数量。所有超参数均经过调整以获得每个数据集的最佳结果，具体可见表 3。此超参数调整是通过在表 4 所示的值范围内进行简单的网格搜索来完成的。

评估指标。我们从多个指标对模型进行了评估，其中包括受试者工作特征曲线下的面积（AUC）。此外，对于人类数据集，我们还报告了精确率和召回率；对于 BindingDB 数据集，报告了准确率；对于 DUD-E 数据集，报告了 ROC 富集度指标（RE），其定义为

$$RE = \frac{TPR}{FPR} \text{ at a given FPR threshold.} \quad (6)$$

表 3.数据集的训练超参数 (FC 表示全连接层的数量, L-GCN 和 P-GCN 分别表示用于提取配体和蛋白质结合位点嵌入的图卷积层的数量)

数据集	FC	L-GCN	P-GCN
嘟嘟-E	2	18	16
人类	6	4	3
Bindingdb	6	4	3

表 4.网格搜索考虑的用于超参数调整的值

TAGCN 跳数	FC	L-GCN	P-GCN	LR	辍学	批量大小
[1 - 8]	[1 - 8]	[4 - 20]	[4 - 20]	10^{-4} , 10^{-3} , 10^{-2} , 10^{-1}	0.1 - 0.6	[40, 60, 80, 120]

选择不同的性能指标以及针对不同数据集的不同基准模型, 主要是为了与文献中报告的结果进行直接对比。不过, 所报告的这些指标是药物靶点相互作用 (DTI) 文献中基于分类模型最常用的评估指标[28]。此外, 为了进行比较, 我们还纳入了一系列不同的计算模型, 包括 (a) 传统的基于机器学习的方法, 如 K 近邻 (KNN)、L2-逻辑回归 (L2)、NN-score [29] 和随机森林得分 (RF-score) [30]; (b) 开源分子对接程序, 如 AutoDock Vina [16] 和 Smina [31]; (c) 基于字符串表示的深度学习模型, 如 AtomNet [10] 和 3D-CNN [11]; 以及 (d) 为解决 DTI 预测问题而开发的基于图表示的深度学习模型, 如图卷积神经网络 (GCN) [21]、CPI-GNN [32]、DrugVQA [8]、TransformerCPI [33]、PocketGCN [4]、GNN [34] 和 GraphDTA [15]。

消融实验 消融实验展示了我们提出的 AttentionSiteDTI 框架中几种文本分类技术的有效性。我们报告了所有实验的 AUC 和 ROC, 这是文献中广泛使用的指标。该研究的结果见表 5, 表明注意力机制是文本分类中最有效的方法, 而且由于其强大的可解释性, 具有明显的优势。双向长短期记忆 (Bi-LSTM) 架构无法仅关注配体与结合位点之间的相互作用, 因此其结果不如其他提出的架构。

结果表明, 除了在 DUD-E 数据集上, 自注意力机制的表现优于 Bi-LSTM + 自注意力机制。这可以解释为, 本质上 DUD-E 是一个更具挑战性的数据集, 因为 DUD-E 中的诱饵分子 (具有负相互作用的配体) 在物理化学性质上与具有正相互作用的配体相匹配 (在分子量、预测的 logP 值、可

旋转键的数量以及氢键供体和受体的数量方面)。诱饵分子不应真正结合, 以履行其作为阴性对照的职责。因此, DUD-E 使用了 2D 相似性指纹来降低诱饵分子与配体之间的拓扑相似性。简而言之, DUD-E 中的诱饵分子在物理上模拟具有正相互作用的配体 (从而难以对接), 同时在拓扑结构上也有所不同, 以降低实际结合的可能性[25]。这些诱饵分子的相似性对于利用配体物理结构的方法 (如基于图的神经网络) 来说尤其具有挑战性。因此, 单个注意力模块难以生成对分类器头部来说具有足够区分度的特征。因此, 额外使用双向长短期记忆 (Bi-LSTM) 层有助于生成更丰富的特征, 从而在这一具有挑战性的数据集上提升了模型的性能。更具体地说, 我们在 DUD-E 数据集上使用 Bi-LSTM 层来捕捉短程关系, 随后采用自注意力机制进一步提高特征质量, 从而获得了更高的准确率。由于另外两个数据集 (Human 和 BindingDB) 不像 DUD-E 数据集那样具有挑战性, 添加 Bi-LSTM 层不仅似乎没有优势, 还可能导致模型过拟合。

在 DUD-E 数据集上的比较 在 DUD-E 数据集上, 我们将所提出的模型与几个最先进的模型进行了比较, 这些模型可分为四类: (1) 基于机器学习的方法, 如 NN-score [29] 和随机森林评分 (RF-score) [30]; (2) 开源分子对接程序, 包括 AutoDock Vina [16] 和 Smina [31]; (3) 基于深度学习的模型, 如 AtomNet [10] 和 3D-CNN [11], 它们使用神经网络从 3D 结构信息中提取特征; (4) 基于图的模型, 如 PocketGCN [4]、GNN [34] 和 DrugVQA [8], 它们均基于图表示。PocketGCN 利用两个 Graph-CNN 自动从蛋白质口袋和配体的图中提取特征, 以捕捉蛋白质-配体的结合相互作用。CPI-GNN [32] 是一种预测模型, 它结合了用于配体的图神经网络和用于靶点的 CNN。DrugVQA 利用 2D 距离图在视觉问答系统中表示蛋白质, 其中图像为蛋白质的距离图, 问题为药物的 SMILES 表示, 答案为药物-靶点对是否会相互作用。请注意, 这些模型的得分均来自 [8] 中的工作。此外, 我们还采用了 F1 分数和在 0.5%、1%、2% 和 5% 阈值下的 ROC 富集度 (RE) 指标。如表 6 所示, 我们的模型在所有指标上均实现了最先进的药物靶点相互作用 (DTI) 预测性能, 在 0.5% 的 RE 阈值下有显著提升。此外, 我们推测 AtomNet 和 3D-CNN 的表现不佳可能是由于三维空间的稀疏性, 因为它们使用的是蛋白质的整个三维结构。

在“人类”数据集上的比较 在“人类”数据集上, 我们将我们的模型与几种传统机器学习模型 (如 K 近邻算法 (KNN)) 进行了比较。

表 5.消融研究结果

消融试验	BindingDB		人类		嘟嘟-E	
	AUC	“ROC”	AUC	“ROC”	AUC	“ROC”
双向长短期记忆网络	0.863	0.889	0.976	0.979	0.954	0.562
自注意力机制	0.940	0.981	0.991	0.990	0.961	0.602
双向长短期记忆网络 + 自注意力机制	0.925	0.973	0.984	0.982	0.971	0.623

表 6.DUD-E 数据集比较

	AUC	0.5% RE	1.0% RE	2.0% 钨 (RE 代表稀土元素)	5.0% 回收率
NN得分	0.584	4.166	2.980	2.460	1.891
RF 分数	0.622	5.628	4.274	3.499	2.678
维纳	0.716	9.139	7.321	5.811	4.444
斯米娜	0.696	-	-	-	-
三维卷积神经网络	0.868	42.559	26.655	19.363	10.710
原子网络	0.895	-	-	-	-
掌上GCN	0.886	44.406	29.748	19.408	10.735
图神经网络	0.940	-	-	-	-
DrugVQA	0.972	88.17	58.71	35.06	17.39
注意力位点扩散张量成像	0.971	101.74	59.92	35.07	16.74

随机森林 (RF)、L2-逻辑回归 (L2) (这些结果来自 [17])；以及一些最近开发的基于图的方法，包括图卷积神经网络 (GCN) [21]、CPI-GNN [32]、DrugVQA [8]、TransformerCPI [33] 以及 GraphDTA [15]。GraphDTA 最初是为回归任务设计的，后来在[35]中被调整用于二分类任务。为了与其他模型进行直接比较，我们遵循了[34, 36]中的相同实验设置。此外，我们使用三个不同的随机种子重复了实验，这与 DrugVQA [8] 类似。上述模型的性能数据来自 [35]，总结在表 7 中。可以看出，我们所提出模型的预测性能优于所有基于机器学习和图神经网络的模型，并且在精度和召回率方面与 DrugVQA 的表现相当。基于机器学习的模型性能相对较低，这确实符合我们的预期，原因是它们使用的特征质量较低，无法捕捉到药物靶点相互作用 (DTI) 中的复杂非线性关系。另一方面，深度学习模型在提取药物 - 靶点对中复杂相互作用的重要特征方面非常强大。在此基础上，我们的模型进一步提高了准确性，这表明通过我们 AttentionSiteDTI 的端到端学习的反向传播，所学习到的药物 - 靶点相互作用信息的质量是有保障的。

在 BindingDB 数据集上的比较 在 BindingDB 数据集上，我们进一步将我们的模型与 Tiresias [37]、DBN [38]、CPI-GNN [32]、E2E [39]、DrugVQA [8] 和 Bridge-DPI [35] 进行了对比，将这些作为基准模型。Tiresias 使用药物与靶点对的相似性度量。DBN 使用堆叠受限玻尔兹曼机，输入形式为扩展连接性指纹。如前所述，CPI-GNN 结合了图神经网络用于

表 7.人类数据集比较

	AUC	精度	召回	F1 分数
K 近邻算法	0.86	0.798	0.927	0.858
射频	0.940	0.861	0.897	0.879
L2	0.911	0.861	0.913	0.902
支持向量机	0.910	0.966	0.950	0.958
图深度学习药物相互作用预测模型	0.960	0.882	0.912	0.897
图卷积网络	0.956	0.862	0.928	0.894
CPI-GNN	0.970	0.923	0.918	0.920
端到端/GO	0.970	0.893	0.914	0.903
DrugVQA	0.979	0.954	0.961	0.957
桥接深度包检测	0.990	0.963	0.949	0.956
注意力位点扩散张量成像	0.991	0.951	0.975	0.963

化合物和用于目标的卷积神经网络 (CNN) 来捕获药物 - 靶点相互作用 (DTIs)。E2E 是一种基于图神经网络 (GNN) 的模型，它使用长短期记忆网络 (LSTM) 来学习带有基因本体论注释的药物 - 靶点对信息。如前所述，DrugVQA 是一个视觉问答系统，其中图像为蛋白质的距离图，问题为药物的简化分子线性输入规范 (SMILES)，答案为药物 - 靶点对是否会相互作用。最后，BridgeDPI 使用卷积神经网络 (CNN) 获取药物和蛋白质的嵌入，并使用图神经网络 (GNN) 通过一些作为蛋白质/药物之间连接的超节点来学习蛋白质/药物之间的关联。

请注意，所有这些模型的得分均来自[35]。此外，按照先前研究的建议，我们在测试集上以 AUC (曲线下面积) 和准确率 (ACC) 的形式报告预测结果，该测试集分为未见蛋白质集 (即训练集中未出现的蛋白质) 和已见蛋白质集 (即训练集中出现过的蛋白质)。




图 4. AttentionSiteDTI 与六个基线模型的对比：（左）展示了测试中已见蛋白质和未见蛋白质的曲线下面积（AUC）；（右）展示了测试中已见蛋白质和未见蛋白质的准确率。请注意，Tiresias 在未见蛋白质情况下的准确率未显示，因为它低于 y 轴下限（0.5）。请注意，为了与包括我们模型在内的所有模型进行直接比较，我们按照我们的实验设置实现了 BridgeDPI 模型。我们的模型在未见蛋白质上的表现优于所有其他方法，这意味着我们的模型比其他模型具有更好的泛化能力。在已见蛋白质的情况下，我们的模型与其他模型相当，而已见蛋白质情况下的高 AUC 和高准确率表明模型存在过拟合现象。

这确实使得定制的 BindingDB 数据集适合用于评估模型对未知蛋白质的泛化能力，而这应当是预测问题（即冷启动问题）的重点，因为在自然界中存在大量的未知蛋白质。

如图 4 所示的实验结果表明，所有模型在已见蛋白质上的表现总体良好，AUC 值均在 0.9 以上，准确率超过 0.85。然而，这些模型在未见蛋白质上的表现则差异较大且明显较差，这反映了这种更贴近现实的学习场景的复杂性。Tiresias 是一种基于相似性的模型，它使用一组专家设计的相似性度量作为蛋白质和药物的特征。Tiresias 在未见蛋白质上的表现不佳，可能是因为这些手工设计的特征不足以捕捉药物 - 靶点对之间的相互作用，从而导致其在未见蛋白质上的准确率甚至低于 0.5。另一方面，包括 DBN、CPI-GNN、E2E、DrugVQA、BridgeDPI 以及我们的 AttentionSiteDTI 在内的基于深度学习的模型表现良好，这表明这些模型在捕捉对药物 - 靶点相互作用预测至关重要的相关特征方面是有效的。结果表明，我们的模型表现最佳，在已见和未见蛋白质上的 AUC 值分别为 0.97 和 0.94。此外，在准确性方面，我们的 AttentionSiteDTI 模型优于所有其他模型，在未见过的蛋白质上的准确率达到 0.89。这表明我们基于注意力机制的双向 LSTM 网络确实能够通过学习蛋白质结合位点（口袋）与药物之间关系的更深层次的相互作用规则，有效地进行药物 - 靶点（蛋白质口袋）的关系分类。此外，基线模型在已见过的蛋白质上看似良好的表现可能是过拟合的一个迹象。

讨论

我们认为，我们所提出模型性能的提升可归因于几个因素，包括：（1）输入表示，正如文献[40]所论述的，这会显著影响模型的预测性能。采用更先进的输入特征表示，例如结构化图，有助于捕捉分子的结构信息；（2）预测技术。例如，传统的基于机器学习的技术，如 NNScore 和 FRscore，往往依赖于手工设计特征的质量，而这些特征通常无法学习药物-靶点相互作用（DTI）中的复杂非线性关系[35]。相比之下，自注意力机制提供了一种强大且自动化的特征提取机制，能够学习更高阶的非线性关系。此外，使用字符串表示作为模型输入的深度学习无法捕捉药物和/或蛋白质的结构信息[41]。另一方面，基于图的神经网络（使用药物和蛋白质的图表示）能够有效地捕捉药物分子和靶蛋白的拓扑关系，从而进一步提高性能[41]，最重要的是（3）我们针对药物 - 靶点复合物的上下文敏感嵌入方法。在我们的方法中，药物 - 靶点复合物被视为一个句子，其生化实体（即蛋白质口袋和药物分子）之间存在关系意义；这使得能够捕获生化序列（即句子）中最重要的上下文语义和关系信息，以进行类似于自然语言处理中句子分类的关系分类。

除了性能提升之外，我们的模型还通过探究蛋白质的哪些结合位点与给定配体相互作用，从而实现了可解释性。这在新药的设计和开发中尤为重要。




图 5. (左) 展示了在所提出的方法中, 以达芦那韦作为配体, 以新冠病毒刺突蛋白与 ACE2 的复合物作为蛋白质输入时, 每个结合位点的自注意力机制权重的热图和折线图, 这表示了蛋白质中每个计算出的结合位点与该特定配体结合的概率。(右) 展示了新冠病毒刺突蛋白与 ACE2 复合物上自注意力权重的投影热图。此图表明了我们模型的可解释性, 能够为我们指出与配体结合概率最大的结合位点。

在药物活性分子方面, 了解分子的哪些部分对其生物特性至关重要是关键所在。

解释模块

配体与蛋白质的某些部位(活性位点)结合, 要么阻止其他配体的结合, 要么引起蛋白质结构的变化, 从而产生治疗效果。在其他部位结合且无治疗价值的称为“非活性”结合, 通常不会直接产生生物学效应。在我们的研究系统中, 配体与活性位点结合并引起蛋白质结构(构象)变化的情况较少见, 可能对构建模型帮助不大(通常, 当患者患有某种疾病导致体内自然生化物质生成不足时, 才会使用/考虑这些配体/治疗剂)。

在这项工作中, 注意力机制使模型能够预测哪些蛋白质结合位点更有可能与给定的配体结合。这些概率包含在注意力矩阵中, 由模型计算得出。注意力可视化结果见图 5, 为 SARS-CoV2 刺突蛋白与表达 ACE2 的人类宿主细胞形成的复合物与名为达芦那韦的药物相互作用时蛋白质的热图。该图还展示了热图在蛋白质上的投影。

实验室验证

SARS-CoV-2 病例研究

为了进一步评估我们所提出模型的实际应用潜力, 我们通过实验测试并验证了刺突(或 ACE2)蛋白与七种候选化合物(N-乙酰神经氨酸、3 α , 6 α -甘露五糖、N-乙酰神经氨酸、2-酮-3-脱氧辛酸、N-乙酰乳糖胺、胞苷5-单磷酸-N-乙酰神经氨酸钠盐和达芦那韦)之间的结合相互作用。评估使用了结合抑制检测试剂盒进行。在此, 候选分子被用作抑制剂化合物, 以阻止刺突蛋白与 ACE2 形成复合物。在这些实验中, 候选分子表现越出色, 其潜在的治疗价值就越高, 因为刺突蛋白与 ACE2 形成复合物已被确定为 SARS-CoV2 病毒感染宿主细胞的第一步。这两种蛋白质之间的相互作用是由宿主细胞表面的糖链所促进的。这些表面蛋白的糖链修饰在组成、表面密度以及连接类型(即“O”型和“N”型)方面都是独特的; 并且通常具有细胞类型和组织特异性。ACE2 上的聚糖修饰在呼吸系统细胞(口腔、肺上皮细胞)中很常见, 这使得某些上呼吸道感染病毒(如 SARS-CoV2、猪流行性腹泻病毒和冠状病毒属的传染性胃肠炎病毒)能够识别它[43, 44]。已有研究表明, SARS-CoV2 能特异性地与神经氨酸结合。

表 8. 在新冠病例研究中对 AttentionSiteDTI 的实验验证

化合物	注意力位点扩散张量成像	实验室结果
2-酮-3-脱氧壬酸	非相互作用的	相互作用的
N-乙酰神经氨酸	非相互作用的	相互作用的
胞苷-5'-单磷酸-N-乙酰神经氨酸钠盐	相互作用的	相互作用的
达芦那韦	相互作用的	相互作用的
N-乙酰神经氨酸	非相互作用的	非相互作用的
N-乙酰乳糖胺	非相互作用的	非相互作用的
3,6-甘露五糖	非相互作用的	非相互作用的

ACE2 宿主细胞表面的酸性修饰。因此，在我们的研究中，我们选择了 N-乙酰神经氨酸作为模型/标准抑制剂分子（即游离/可溶性 N-乙酰神经氨酸能够与刺突蛋白结合，从而阻止复合物的形成）。为了评估我们模型的敏感性，我们选择的候选分子集合反映了标准 N-乙酰神经氨酸参考物在化学/结构上的细微变化。N-乙酰神经氨酸也被称为唾液酸，是唾液酸类化合物中最简单的组成形式。我们选择的几个候选分子就来自这个化学家族。胞苷 5-单磷酸 N-乙酰神经氨酸具有简单的核苷酸修饰，其与神经氨酸（通过互补性）对常见结合伙伴分子的结合特性相似。N-糖酰神经氨酸在结构和组成上与 N-乙酰神经氨酸高度相似，仅在乙酰基氧化为羧基这一点上有所不同。2-酮-3-脱氧辛酸是一种唾液酸，其不具备 N-乙酰神经氨酸所具有的氮乙酰基取代基，从而改变了分子的亲水性。在很多情况下，聚糖是以寡糖的形式形成的。因此，在评估集中加入了二糖 N-乙酰乳糖胺分子以及多环的 3,6-甘露五糖类。最后，为了评估对 SARS-CoV2 治疗药物的通用识别潜力，还加入了小分子药物达芦那韦。如表 8 所示，预测的药物靶点相互作用（DTI）与实验测量结果高度一致（七个结果中有五个匹配），这表明我们的 AttentionSiteDTI 作为有效的辅助预筛选工具，具有加速探索和推荐具有理想相互作用特性的先导化合物以作用于其靶点的潜力。在我们的实验中，我们将活性阈值设定为 15 nM，以仅捕获高活性化合物，从而限制了邻近位点相互作用以及结合位点中心协调性差的弱相互作用的影响。

结论

在这项工作中，我们提出了一种基于图卷积神经网络（GCNN）的端到端

模型，该模型基于自注意力机制构建，能够捕捉给定蛋白质的结合位点与药物之间的任何关系，这种关系类似于句子中生化实体（即蛋白质口袋和药物分子）之间的关系。我们提出的框架能够学习蛋白质的哪些结合位点与给定配体相互作用，从而具有可解释性和更好的泛化能力，同时在药物靶点相互作用（DTI）预测方面优于最先进的方法。我们通过实验验证了七种候选化合物与刺突（或 ACE2）蛋白之间的预测结合相互作用。我们实验室的验证结果表明，计算预测的结合相互作用与实验观察到的结合相互作用高度一致。我们的模型表现出最先进的性能，具有高度的泛化能力，提供可解释的输出，并且在实验室实验验证中表现良好。因此，我们预计它将成为药物发现应用中有效的虚拟筛选工具。

要点

我们提出了一种新的药物-靶点相互作用（DTI）预测问题的表述方式，类似于自然语言处理（NLP）中的句子分类。在这种新的表述方式中，我们将生化序列（药物-靶点复合物）视为自然语言句子。这使得能够捕捉句子中包含的上下文和关系信息。

开发了一种基于图的深度学习模型，以端到端的方式解决药物-靶点相互作用（DTI）预测问题，其中图嵌入和 DTI 预测模型同时学习。这使得整个网络能够通过最小化一个损失函数实现更高效和有效的训练。

我们提议将药物和靶点的图表示作为网络的输入。更具体地说，我们使用蛋白质口袋的图表示作为靶点蛋白质的输入，这有助于提高模型的泛化能力。

我们设计了一种自注意力机制，通过识别给定配体与蛋白质最有可能的结合位点，从而实现可解释性。

我们所提出的模型在三个基准数据集上，依据若干性能指标，其表现优于许多最先进的模型。

我们通过实验室验证来确认计算模型的实际应用潜力，在此过程中，我们测量了几种化合物与刺突（ACE2）蛋白之间的结合相互作用，并将结果与计算预测进行了比较。

我们观察到计算预测的结合相互作用与实验观察到的结合相互作用高度一致，这表明我们的模型在虚拟筛选任务中具有潜力。

数据和代码可用性

所有数据集均可公开获取。DUD-E 数据集可在 <http://dude.docking.org> 获取，Human 数据集可在 <https://github.com/IBMInterpretableDTIP> 获取，最后自定义的 BindingDB-IBM 数据集

可在 https://github.com/masashitsubaki/CPI_prediction/tree/master/ 找到。我们使用了来自 <https://github.com/prokia/drugVQA> 的 Human 数据集的蛋白质 3D 结构。此外, 我们实验的所有说明和代码均可在 <https://github.com/yazdanimehdi/AttentionSiteDTI> 获取。

致谢

我们感谢卡塔利娜·比昂迪女士就本文稿的早期版本与我们进行的讨论, 以及她提出的宝贵意见和建议。

参考文献

- Pahikkala T, Airola A, Pietilä S, *et al.* Toward more realistic drug–target interaction predictions. *Brief Bioinform* 2015;**16**(2):325–37.
- He T, Heidemeyer M, Ban F, *et al.* Simboost: a read-across approach for predicting drug–target binding affinities using gradient boosting machines. *J Chem* 2017;**9**(1):1–14.
- Velicković P, Cucurull G, Casanova A, *et al.* Graph attention networks. *arXiv preprint arXiv:1710.10903*. 2017.
- Torng W, Altman RB. Graph Convolutional Neural Networks for Predicting Drug-Target Interactions. *J Chem Inf Model* 2019;**59**(10):4131–49.
- Lim J, Ryu S, Park K, *et al.* Predicting drug–target interaction using a novel graph neural network with 3d structure-embedded graph representation. *J Chem Inf Model* 2019;**59**(9):3981–8.
- Son J, Kim D. Development of a graph convolutional neural network model for efficient prediction of protein–ligand binding affinities. *PloS one* 2021;**16**(4):e0249404.
- Jiang M, Li Z, Zhang S, *et al.* Drug–target affinity prediction using graph neural network and contact maps. *RSC Adv* 2020;**10**(35):20701–12.
- Zheng S, Li Y, Chen S, *et al.* Predicting drug–protein interaction using quasi-visual question answering system. *Nature Machine Intelligence* 2020;**2**(2):134–40.
- Tradigo G. *Protein Contact Maps*. New York, NY: Springer New York, 2013, 1771–3.
- Wallach I, Dzamba M, Heifets A. Atomnet: a deep convolutional neural network for bioactivity prediction in structure-based drug discovery. *arXiv preprint arXiv:1510.02855*. 2015.
- Ragoza M, Hochuli J, Idrobo E, *et al.* Protein–ligand scoring with convolutional neural networks. *J Chem Inf Model* 2017;**57**(4): 942–57.
- Stepniewska-Dziubinska MM, Zielenkiewicz P, Siedlecki P. Development and evaluation of a deep learning model for protein–ligand binding affinity prediction. *Bioinformatics* 2018;**34**(21):3666–74.
- Gomes J, Ramsundar B, Feinberg EN, *et al.* Atomic convolutional networks for predicting protein–ligand binding affinity. *arXiv preprint arXiv:1703.10603*. 2017.
- Karimi M, Wu D, Wang Z, *et al.* Deepaffinity: interpretable deep learning of compound–protein affinity through unified recurrent and convolutional neural networks. *Bioinformatics* 2019;**35**(18):3329–38.
- Nguyen T, Le H, Quinn TP, *et al.* Graphdta: Predicting drug–target binding affinity with graph neural networks. *Bioinformatics* 2021;**37**(8): 1140–7.
- Trott O, Olson AJ. Autodock vina: improving the speed and accuracy of docking with a new scoring function, efficient optimization, and multithreading. *J Comput Chem* 2010;**31**(2):455–61.
- Liu H, Sun J, Guan J, *et al.* Improving compound–protein interaction prediction by building up highly credible negative samples. *Bioinformatics* 2015;**31**(12):221–9.
- Saberi Fathi SM, Tuszynski JA. A simple method for finding a protein’s ligand-binding pockets. *BMC Struct Biol* 2014;**14**(1):18.
- Pettersen EF, Goddard TD, Huang CC, *et al.* Ucsf chimera-a visualization system for exploratory research and analysis. *J Comput Chem* 2004;**25**(13):1605–12.
- Du J, Zhang S, Wu G, *et al.* Topology adaptive graph convolutional networks. *arXiv preprint arXiv:1710.10370*. 2017.
- Kipf TN, Welling M. Semi-supervised classification with graph convolutional networks. *arXiv preprint arXiv:1609.02907*. 2016.
- Li Y, Tarlow D, Brockschmidt M, *et al.* Gated graph sequence neural networks. *arXiv preprint arXiv:1511.05493*. 2015.
- Zhou P, Shi W, Tian J, *et al.* Attention-based bidirectional long short-term memory networks for relation classification. In: *Proceedings of the 54th annual meeting of the association for computational linguistics (volume 2: Short papers)*, 207–12.
- Vaswani A, Shazeer N, Parmar N, *et al.* Attention is all you need. *Advances in neural information processing systems* 2017;**30**.
- Mysinger MM, Carchia M, Irwin JJ, *et al.* Directory of useful decoys, enhanced (dud-e): better ligands and decoys for better benchmarking. *J Med Chem* 2012;**55**(14):6582–94.
- Liu H, Sun J, Guan J, *et al.* Improving compound–protein interaction prediction by building up highly credible negative samples. *Bioinformatics* 2015;**31**(12):i221–9.
- Gilson MK, Liu T, Baitaluk M, *et al.* Bindingdb in 2015: a public database for medicinal chemistry, computational chemistry and systems pharmacology. *Nucleic Acids Res* 2016;**44**(D1): D1045–53.
- Rayhan F, Ahmed S, Shatabda S, *et al.* idti-esboost: identification of drug target interaction using evolutionary and structural features with boosting. *Sci Rep* 2017;**7**(1):1–18.
- Durrant JD, McCammon JA. NNScore 2.0: A Neural-Network Receptor–Ligand Scoring Function. *J Chem Inf Model* 2011;**51**(11):2897–903.
- Ballester PJ, Mitchell JBO. A machine learning approach to predicting protein–ligand binding affinity with applications to molecular docking. *Bioinformatics* 2010;**26**(9):1169–75.
- Koes DR, Baumgartner MP, Camacho CJ. Lessons Learned in Empirical Scoring with smina from the CSAR 2011 Benchmarking Exercise. *J Chem Inf Model* 2013;**53**(8):1893–904.
- Wang E, Wang F, Yang Z, *et al.* A Graph Convolutional Network-Based Method for Chemical–Protein Interaction Extraction: Algorithm Development. *JMIR Med Inform* 2020;**8**(5):e17643.
- Chen L, Tan X, Wang D, *et al.* TransformerCPI: improving compound–protein interaction prediction by sequence-based deep learning with self-attention mechanism and label reversal experiments. *Bioinformatics* 2020;**36**(16):4406–14.
- Tsubaki M, Tomii K, Sese J. Compound–protein interaction prediction with end-to-end learning of neural networks for graphs and sequences. *Bioinformatics* 2018;**35**(2):309–18.
- Wu Y, Gao M, Zeng M, *et al.* BridgeDPI: A Novel Graph Neural Network for Predicting Drug–Protein Interactions. *arXiv*. 2021.
- Lim H, Gray P, Xie L, *et al.* Improved genome-scale multi-target virtual screening via a novel collaborative filtering approach to cold-start problem. *Sci Rep* 2016;**6**(1):1–11.
- Fokoue A, Sadoghi M, Hassanzadeh O, *et al.* Predicting drug–drug interactions through large-scale similarity-based link prediction. In: *European Semantic Web Conference*. Springer, 774–89.
- Wen M, Zhang Z, Niu S, *et al.* Deep-learning-based drug–target interaction prediction. *J Proteome Res* 2017;**16**(4):1401–9.

39. Gao KY, Fokoue A, Luo H, *et al.* Interpretable drug target prediction using deep neural representation. *IJCAI* 2018; 3371–7.
40. Thafar M, Raies AB, Albaradei S, *et al.* Comparison study of computational prediction tools for drug-target binding affinities. *Front Chem* 2019;782.
41. Abdel-Basset M, Hawash H, Elhoseny M, *et al.* Deep-dta: deep learning for predicting drug-target interactions: a case study of covid-19 drug repurposing. *Ieee Access* 2020;8: 170433–51.
42. Varki A. Sialic acids in human health and disease. *Trends Mol Med* 2008;14(8):351–60.
43. Vlasak R, Luytjes W, Spaan W, *et al.* Human and bovine coronaviruses recognize sialic acid-containing receptors similar to those of influenza c viruses. *Proc Natl Acad Sci* 1988;85(12):4526–9.
44. Schultze B, Kreml C, Ballesteros ML, *et al.* Transmissible gastroenteritis coronavirus, but not the related porcine respiratory coronavirus, has a sialic acid (n-glycolylneuraminic acid) binding activity. *J Virol* 1996;70(8):5634–7.