

DeepGCNs: 让图卷积网络 (GCNs) 像卷积神经网络 (CNNs) 一样实现深度化

Guohao Li, Matthias Mueller, Guocheng Qian, Itzel C. Delgadillo, Abdullellah Abualshour, Ali Thabet, and Bernard Ghanem

摘要 - 卷积神经网络 (CNN) 在解决诸如物体分类与检测、语义分割、活动理解等多种计算机视觉任务方面取得了巨大成功。其出色表现的关键因素之一在于能够训练非常深的网络。尽管 CNN 在许多任务中表现出色, 但对于非欧几里得数据 (在许多实际应用中普遍存在) 却效果不佳。图卷积网络 (GCN) 提供了一种替代方案, 能够将非欧几里得数据输入到神经网络中。尽管 GCN 已经取得了令人鼓舞的结果, 但目前它们仍局限于层数相对较少的架构, 这主要是由于训练过程中梯度消失的问题。本研究将残差/密集连接和膨胀卷积等概念从 CNN 转移到 GCN 中, 以成功训练非常深的 GCN。我们通过实验在多个数据集和任务中展示了使用深度 GCN (多达 112 层) 的优势。具体而言, 在点云的部件分割和语义分割以及生物蛋白质-蛋白质相互作用 (PPI) 图中蛋白质功能的节点分类方面, 我们取得了非常有前景的性能。我们相信, 这项工作中的见解将为未来关于图卷积网络 (GCN) 的研究及其在本文未探索的更多任务中的应用开辟道路。本工作的源代码分别在 https://github.com/lightaime/deep_gcns_torch (PyTorch 实现) 和 https://github.com/lightaime/deep_gcns (TensorFlow 实现) 上可用。

关键词 - 图卷积网络、非欧几里得数据、三维语义分割、节点分类、深度学习

C

简介

近年来, 图卷积神经网络 (GCNs) 已成为一个重要的研究课题。出现这一趋势的原因有很多, 但最重要的是, GCNs 为卷积神经网络 (CNNs) 在非欧几里得数据上的应用提供了自然的扩展。虽然 CNNs 在处理网格状结构数据 (如图像) 时表现出色, 但在处理更不规则的数据 (如点云、图等) 时, 其性能欠佳。由于许多实际应用需要利用此类数据, GCNs 就显得非常合适。目前, GCNs 已在预测社交网络中的个体关系[1]、为药物发现建模蛋白质[2]、[3]、增强推荐引擎的预测能力[4]、[5]以及高效分割大型点云[6]等方面取得了一些成功。尽管这些研究取得了令人鼓舞的成果, 但它们所依赖的网络架构都较为简单且较浅。

对于卷积神经网络 (CNNs) 而言, 其在众多计算机视觉任务中持续成功并保持顶尖性能的主要原因在于能够可靠地训练非常深的网络架构。令人惊讶的是, 目前还不清楚如何训练深度图卷积网络 (GCN) 架构, 许多现有研究也一直在探讨这一局限性以及图卷积网络的其他不足之处[7]、[8]、[9]。与卷积神经网络类似, 在图卷积网络中堆叠多层也会导致梯度消失问题。过度平滑问题也可能出现。

反复应用多个 GCN 层[7]。在这种情况下, 人们观察到每个连通分量内的顶点特征会收敛到相同的值, 从而彼此无法区分。因此, 大多数最先进的 GCN 仅限于浅层网络架构, 通常不超过 4 层[9]。

在卷积神经网络 (CNN) 领域, 梯度消失问题广为人知且备受研究。事实上, 在 ResNet [10] 提出了一种简单却有效的解决方案之前, 这是深度卷积网络的关键限制。通过在连续层之间引入残差连接 [10], 为梯度提供了额外的传播路径, 从而解决了梯度消失问题。这使得拥有超过一百层的深度残差网络 (例如 ResNet-152) 能够可靠地进行训练。这一理念在 DenseNet [11] 中得到了进一步拓展, 其中在各层之间添加了更多的连接。

训练深度网络揭示了另一个瓶颈, 这对于依赖输入图像空间组合的任务 (例如对象检测、语义分割、深度估计等) 尤其相关。随着网络深度的增加, 在池化过程中可能会丢失更多的空间信息。理想情况下, 感受野应随着网络深度的增加而增大, 同时不损失分辨率。对于卷积神经网络 (CNN), 引入了膨胀卷积[12]来解决这个问题。其思想同样简单却有效。本质上, 随着网络深度的增加, 卷积是在更远的邻域上进行的。这样, 多个分辨率就可以在更深的 CNN 中无缝编码。一些创新, 特别是残差/密集连接和膨胀卷积, 使得非常深的 CNN 能够可靠地训练, 并在许多任务中达到最先进的性能。这就引出了以下问题: 这些创新在图卷积网络 (GCN) 领域是否有对应的方法?

The authors are with the Visual Computing Center, KAUST, Thuwal 23955, Saudi Arabia.
E-mail: {guohao.li, matthias.mueller.2, guocheng.qian, itzel.delgadilloperrez, abdullellah.abualshour, ali.thabet, bernard.ghanem}@kaust.edu.sa.

Manuscript received 15 Oct. 2019; revised 12 Mar. 2021; accepted 5 Apr. 2021. Date of publication 19 Apr. 2021; date of current version 5 May 2023. (Corresponding author: Guohao Li.)

Recommended for acceptance by S. Bai, P.H.S. Torr, R. Krishna, F.-F. Li, A. Gupta, and S.-C. Zhu.

Digital Object Identifier no. 10.1109/TPAMI.2021.3074057




图 1. 训练深度 GCN。(上图) 我们展示了具有 7 层、14 层、28 层、56 层和 112 层的 GCN 在 100 个周期内的训练损失的平方根, 包括有和没有残差连接的情况。我们注意到, 在没有残差连接的情况下增加更多的层会导致损失大幅上升, 对于非常深的网络 (例如 112 层), 甚至会导致发散。(下图) 相比之下, 使用残差连接训练 GCN 可以在所有深度上保持稳定的训练过程。所有训练损失均通过在 S3DIS 数据集上使用相同的超参数训练不同深度的 ResGCN 进行语义分割任务获得。

在这项工作中, 我们对能够训练非常深的图卷积网络 (GCN) 的方法进行了广泛的研究。我们借鉴了在训练深度卷积神经网络 (CNN) 方面取得成功的概念, 特别是残差连接、密集连接和扩张卷积。我们展示了如何将这些概念融入到图框架中。为了量化这些添加内容的效果, 我们对每个组件及其对深度 GCN 准确性和稳定性的影响进行了全面分析。为了展示这些概念在 GCN 上的潜力, 我们将它们应用于点云的语义分割和部分分割以及生物图的节点分类等热门任务。通过结合残差连接或密集连接与扩张卷积, 我们成功训练了深度达 112 层的 GCN (参见图 1)。所提出的深度 GCN 在具有挑战性的点云数据集 S3DIS [13] 上将基线模型的 mIOU 提高了 3.9%, 并且在 PartNet [14] 的许多类别中超越了先前的方法。同样的深度 GCN 架构在非常不同的 PPI 数据集 [2] 上实现了 99.43 的 F1 分数。

贡献。本工作的贡献有三个方面。(1) 我们将残差连接、密集连接和扩张卷积这些为卷积神经网络 (CNN) 引入的概念应用于图卷积网络 (GCN), 从而构建了深度 GCN 架构, 记为 DeepGCNs。(2) 我们在点云和生物图数据上进行了大量实验, 展示了每个组件对深度 GCN 训练的稳定性性能的影响。我们使用点云的语义分割和部分分割, 以及生物网络的节点分类作为实验平台。(3) 我们展示了这些新概念如何成功训练出一个 112

层的 GCN, 这是目前最深的 GCN 架构, 领先幅度很大。仅用 28 层, 我们在 S3DIS 数据集 [13] 上的 mIOU 指标就比之前的最佳性能提高了近 4%; 在 PartNet [14] 的许多类别部分分割任务中, 我们也超越了之前的最佳方法。同样, 在生物网络节点分类任务的 PPI 数据集 [2] 上, 我们也取得了更优的结果。

本文的初步版本已发表于[15]。本期刊稿件在多个方面对初始版本进行了扩展。首先, 我们更深入地研究了超过 100 层的 DeepGCN 架构。有趣的是, 我们发现训练 112 层的 PlainGCN 时会出现发散, 而我们提出的带有跳跃连接和膨胀卷积的 ResGCN 则能顺利收敛 (见图 1)。其次, 为了探究我们 DeepGCN 框架的通用性, 我们在 PartNet 的部件分割任务和 PPI 的节点分类任务上进行了大量额外实验。第三, 我们通过在 PPI 数据集上进行的全面实验, 考察了我们提出的内存高效的 GCN 聚合器 MRGCN 的性能和效率。我们的结果表明, DeepMRGCN 模型能够超越先前的方法。我们还通过 GPU 内存使用实验证明, 与其它 GCN 操作符相比, MRGCN 的内存效率非常高。最后, 为了确保实验的可重复性, 并为图学习研究社区做出贡献, 我们发布了在 TensorFlow 和 PyTorch 中用于训练、测试和可视化的代码, 以及几个预训练模型。据我们所知, 我们的工作首次成功训练超过 100 层的深度 GCN, 并在点云和生物图数据上均取得了卓越成果。

2 相关工作

大量现实世界的应用涉及非欧几里得数据, 而这些数据通常无法通过卷积神经网络 (CNNs) 进行系统且可靠的处理。为克服 CNNs 的不足, 图卷积网络 (GCNs) 为非欧几里得数据处理提供了十分合适的解决方案, 这使得人们对其在各种应用中的使用兴趣大增。在社交网络中[1], 图表示基于共同兴趣/关系的个体之间的连接。这些连接是非欧几里得且高度不规则的。GCNs 能够更好地估计社交网络图中顶点之间的边强度, 从而更准确地反映个体之间的联系。图还被用于建模化学分子结构[2]、[3]。了解这些分子的生物活性对药物研发具有重大影响。图在推荐引擎中的应用也很普遍[4]、[5], 其中对用户交互的准确建模可提升产品推荐的精准度。在自然语言处理中, 图也是常见的表示形式[16]、[17], 用于表示大型文本单元之间的复杂关系。

图卷积网络 (GCNs) 在计算机视觉领域也有诸多应用。在场景图生成中, 物体之间的语义关系通过图来建模。该图用于检测和分割图像中的物体, 并预测物体对之间的语义关系[18]、[19]、[20]、[21]。场景

图还促进了逆向过程，即给定场景的图表示来重建图像[22]。图还用于对视频中的人体关节进行建模以实现动作识别[23]、[24]。此外，图卷积网络（GCN）是处理 3D 点云的绝佳选择，尤其是由于点云的非结构化特性给系统研究带来了表示上的挑战。从 3D 数据中构建结构的尝试有多种，要么用多个 2D 视图来表示[25]、[26]、[27]、[28]，要么通过体素化[29]、[30]、[31]、[32]。最近的工作则侧重于直接处理无序的点云表示[33]、[34]、[35]、[36]、[37]。王等人[6]提出的最近的 EdgeConv 方法将 GCN 应用于点云。特别是，他们提出了一种动态边卷积算法，用于点云的语义分割。该算法在每个图层动态计算节点邻接关系，依据的是点特征之间的距离。这项工作展示了 GCN 在点云相关应用中的潜力，并在点云分割任务中超越了现有技术。与大多数其他工作不同，Edge-Conv 不依赖于 RNN 或复杂的点聚合方法。

当前的图卷积网络（GCN）算法，包括 EdgeConv，都局限于较浅的深度。近期的研究尝试训练更深的 GCN。例如，Kipf 等人训练了一个用于节点分类的半监督 GCN 模型，并展示了使用超过 3 层时性能会下降[38]。Pham 等人[39]提出了用于关系学习中集体分类的列网络（CLN），他们表明在 10 层时性能达到峰值，而更深的图会导致性能下降。Rahimi 等人[40]开发了一种用于社交媒体图中用户地理定位的高速公路 GCN，在层与层之间添加了“高速公路”门以促进梯度流动。即便如此，作者也证明了在超过 6 层深度时性能会下降。Xu 等人[41]开发了一种跳跃知识网络用于表示学习，并设计了一种基于图结构为每个节点选择图邻居的替代策略。与其它工作类似，它们的网络仅限于少量的层（6 层）。最近，Li 等人[7]研究了 GCN 的深度限制，并表明深度 GCN 可能导致过度平滑，这会导致每个连通分量内顶点的特征收敛到相同的值。其他工作[8]、[9]也表明堆叠 GCN 层存在局限性，特别是高度复杂的反向传播和常见的梯度消失问题。

如今图卷积网络（GCN）面临的许多难题（例如梯度消失和感受野有限）在卷积神经网络（CNN）发展的早期阶段也存在[10]、[12]。我们填补了这一空白，并表明通过借鉴 CNN 的一些正交技巧，这些缺陷中的大多数都可以得到解决。随着残差网络（ResNet）[10]的引入，深度 CNN 的性能得到了大幅提升。通过在层的输入和输出之间添加残差连接，ResNet 有助于缓解梯度消失问题。密集网络（DenseNet）[11]在此基础上更进一步，在层与层之间也添加了连接。扩张卷积[12]是另一种近期的方法，它在诸如语义分割等图像到图像的转换任务中带来了显著的性能提升，通过扩大感受野而不损失分辨率

。在本研究中，我们展示了如何从为 CNN 引入的概念中获益，主要是残差/密集连接和扩张卷积，以训练非常深的 GCN。我们通过这些概念应用于不同的 GCN 变体，将其扩展为更深的版本，从而显著提高其性能，以此来支持我们的论点。在点云的语义分割和部件分割以及生物图中的节点分类等任务上进行的大量实验，验证了这些想法在一般图场景中的有效性。

3 方法论

3.1 图上的表示学习

图的定义。图 G 由元组 $G = (V, E)$ 表示，其中 V 是无序顶点的集合， E 是表示顶点 $v \in V$ 之间连接关系的边的集合。如果 $e_{ij} \in E$ ，则顶点 v_i 和 v_j 由边 e_{ij} 相互连接。

图卷积网络。受卷积神经网络（CNNs）启发，图卷积网络（GCNs）旨在通过聚合顶点邻域内顶点的特征来在顶点处提取更丰富的特征。GCNs 通过将每个顶点 v 与一个特征向量 $h_v \in \mathbb{R}^D$ 相关联来表示顶点，其中 D 表示特征维度。因此，整个图 G 可以通过将所有无序顶点的特征进行拼接来表示，即 $h_G = [h_{v_1}; h_{v_2}; \dots; h_{v_N}] \in \mathbb{R}^{N \times D}$ ，其中 N 是集合 V 的基数。在第 l 层的一般图卷积操作 F 可以通过以下聚合和更新操作来表示。

$$\begin{aligned} G_{l+1} &= F(G_l, W_l) \\ &= \text{Update}(\text{Aggregate}(G_l, W_l^{\text{agg}}), W_l^{\text{update}}). \end{aligned} \quad (1)$$

$G_l \in \mathbb{R}^{N \times D_l}$; E_l 和 $G_{l+1} \in \mathbb{R}^{N \times D_{l+1}}$; $E_{l+1} \in \mathbb{R}^{N \times D_{l+1}}$ 分别是第 l 层的输入图和输出图。Wagg

W_l^{agg} and W_l^{update} are

分别是聚合函数和更新函数的可学习权重，它们是图卷积网络（GCN）的核心组成部分。在大多数 GCN 框架中，聚合函数用于汇集顶点邻域的信息，而更新函数则对聚合后的信息进行非线性变换，以计算新的顶点表示。这两种函数存在不同的变体。例如，聚合函数可以是均值聚合器[38]、最大池化聚合器[6]、[33]、[42]、注意力聚合器[43]或长短期记忆聚合器[44]。更新函数可以是多层感知机[42]、[45]、门控网络[46]等。更具体地说，每一层顶点的表示是通过聚合所有邻居顶点的特征来计算的，如下所示：

$$h_{v_{l+1}} = \phi(h_{v_l}, \rho(\{h_{u_l} | u_l \in \mathcal{N}(v_l)\}, h_{v_l}, W_\rho), W_\phi), \quad (2)$$

其中 ρ 是顶点特征聚合函数， ϕ 是顶点特征更新函数， h_{v_l} 和 $h_{v_{l+1}}$ 分别表示第 l 层和第 $(l+1)$ 层的顶点特征。 $\mathcal{N}(v)$ 是顶点 v 在第 l 层的邻接顶点集合，而 h_{u_l} 是这些邻接顶点的特征，由 W_ρ 参数化。 W_ϕ 包含这些函数的可学习参数。为简单起见且不失一般性，我们使用最大池化顶点特征聚合器，且不包含可学习参数。

参数，以汇集顶点 v_i 与其所有邻居之间的特征差异： $r\delta: \mathbb{P} \rightarrow \mathbb{P}$ 。然后，我们将顶点特征更新器 f 建模为具有批量归一化 [47] 和 ReLU 激活函数的多层感知机 (MLP)。此 MLP 将 h_{v_i} 与其从 $r\delta: \mathbb{P}$ 获得的聚合特征进行拼接，以形成其输入。

动态边。如前所述，大多数图卷积网络 (GCN) 具有固定的图结构，并且仅在每次迭代时更新顶点特征。最近的研究 [6]、[48]、[49] 表明，动态图卷积 (即允许图结构在每一层发生变化) 相比具有固定图结构的 GCN 能够生成更好的图表示。例如，ECC (边条件卷积) [48] 使用动态边条件滤波器来学习特定于边的权重矩阵。此外，EdgeConv [6] 在每一层 EdgeConv 之后都会在当前特征空间中找到最近邻来重建图。为了学习生成点云，图卷积生成对抗网络 (Graph-Convolution GAN) [49] 也在每一层中应用 k 近邻图来构建每个顶点的邻域。我们发现，在考虑更深的 GCN 时，GCN 中动态变化的邻居会导致有效感受野增大。在我们的框架中，我们提出通过每一层特征空间中的膨胀 k 近邻函数重新计算顶点之间的边，以进一步增大感受野。

设计深度图卷积网络 (GCN) 架构 [8]、[9] 是图学习领域的一个开放性问题。近期的研究 [7]、[8]、[9] 表明，GCN 在深度架构上扩展性不佳，因为堆叠多层图卷积会导致反向传播的复杂度很高。因此，大多数最先进的 GCN 模型通常都很浅 [9]。受 ResNet [10]、DenseNet [11] 和膨胀卷积 [12] 的巨大成功的启发，我们将这些理念引入 GCN，以充分发挥其潜力。这使得能够构建更深的 GCN，这些模型在训练时能够可靠地收敛，并在推理时取得更优的性能。接下来，我们将详细描述三种能够使 GCN 更深的操作：残差连接、密集连接和膨胀聚合。

3.2 GCN 的残差连接

在原始的图学习框架中，会学习一个底层映射 F ，它以图作为输入并输出新的图表示 (见公式 (1))。在此，我们提出了一种图残差学习框架，通过拟合另一个映射 F 来学习底层映射 H 。在 G_l 经过 F 变换后，执行逐顶点相加操作以获得 G_{l+1} 。残差映射 F 学习以图作为输入，并为下一层输出残差图表示 G_{l+1}^{res} 。 W_l 是第 l 层的可学习参数集。在我们的实验中，我们将残差模型称为 ResGCN。

$$\begin{aligned} G_{l+1} &= \mathcal{H}(G_l, W_l) \\ &= \mathcal{F}(G_l, W_l) + G_l = G_{l+1}^{\text{res}} + G_l. \end{aligned} \quad (3)$$

用于 GCN 的密集连接。DenseNet [11] 提出利用层之间的密集连接，这改善了网络中的信息流，并实现了层间特征的有效

效复用。受 DenseNet 启发，我们将类似的想法应用于 GCN，以利用来自不同 GCN 层的信息流。具体来说，我们有

$$\begin{aligned} G_{l+1} &= \mathcal{H}(G_l, W_l) \\ &= \mathcal{T}(\mathcal{F}(G_l, W_l), G_l) \\ &= \mathcal{T}(\mathcal{F}(G_l, W_l), \dots, \mathcal{F}(G_0, W_0), G_0). \end{aligned} \quad (4)$$

操作符 $\mathcal{T}$ 是一种顶点级的拼接函数，它将输入图 G_0 与所有中间 GCN 层的输出进行密集融合。为此， G_{l+1} 包含了来自前几层的所有 GCN 转换。由于我们对 GCN 表示进行了密集融合，我们将这种密集模型称为 DenseGCN。DenseGCN 的增长率等于输出图的维度 D (类似于 CNN 中的 DenseNet [11])。例如，如果 F 生成一个 D 维的顶点特征，而输入图 G_0 的顶点维度为 D_0 ，则 G_{l+1} 中每个顶点特征的维度为 $D_0 + D \cdot (l + 1)$ 。

3.3 GCN 的扩张聚合

膨胀波浪卷积是一种源自小波处理领域的算法 [50]、[51]。为了缓解池化操作导致的空间信息损失，Yu 等人 [12] 提出了膨胀卷积，作为在密集预测任务 (例如语义图像分割) 中替代连续池化层的一种方法。他们的实验表明，使用膨胀卷积聚合多尺度上下文信息能够显著提高语义分割任务的准确性。其背后的原因在于膨胀操作在不损失分辨率的情况下扩大了感受野。我们认为膨胀操作也能有助于扩大 DeepGCNs 的感受野。

因此，我们将膨胀聚合引入到图卷积网络 (GCN) 中。构建膨胀邻域的方法有很多。我们使用膨胀 k 近邻

(Dilated k -NN) 在每个 GCN 层之后找到膨胀邻域，并构建膨胀图。具体来说，对于输入图 $G = (V; E)$ ，采用膨胀 k 近邻和膨胀率 d ，膨胀 k 近邻操作会在跳过每个 d 个邻居的情况下，返回 $k \cdot d$ 邻域区域内的 k 个最近邻。最近邻是根据预先定义的距离度量来确定的。在我们的实验中，我们在当前层的特征空间中使用 L2 距离。设 $N_{\delta d \mathbb{P}}(v)$ 表示顶点 v 的 d 膨胀邻域。如果 $u_1; u_2; \dots; u_{kd}$ 是排序后的前 $k \cdot d$ 个最近邻，则顶点 $u_1; u_1 + d; u_1 + 2d; \dots; u_1 + (k-1)d$ 是顶点 v 的 d 膨胀邻域 (见图 3)，即

$$\mathcal{N}^{(d)}(v) = \{u_1, u_1 + d, u_1 + 2d, \dots, u_1 + (k-1)d\}. \quad (5)$$

因此，输出图的边 $E_{\delta d \mathbb{P}}$ 是在 d 倍膨胀顶点邻域 $N_{\delta d \mathbb{P}}(v)$ 上定义的。具体来说，对于每个顶点 $u \in N_{\delta d \mathbb{P}}(v)$ ，都存在一条从顶点 v 指向 u 的有向边 $e \in E_{\delta d \mathbb{P}}$ 。通过使用由膨胀 k 近邻创建的边 $E_{\delta d \mathbb{P}}$ ，应用 GCN 聚合和更新函数 (如公式 (1) 所示)，以生成输出顶点集 $V_{\delta d \mathbb{P}}$ 中每个顶点的特征 $h_{\delta d \mathbb{P}}(v)$ 。我们将这一层操作表示为膨胀率为 d 的膨胀图卷积，更正式地表示为： $G_{\delta d \mathbb{P}} = \mathcal{G}_{\delta d \mathbb{P}}(V_{\delta d \mathbb{P}}; E_{\delta d \mathbb{P}})$ 。我们对其进行可视化，并将其与 CNN 中使用的传统膨胀卷积进行比较。




图 2.用于点云语义分割的所提 GCN 架构。(左) 我们的框架由三个模块组成: GCN 主干模块(输入点云的特征变换)、融合模块(全局特征生成与融合)以及 MLP 预测模块(逐点标签预测)。(右) 我们研究了三种类型的 GCN 主干模块(PlainGCN、ResGCN 和 DenseGCN), 并使用了两种层连接方式(ResGCN 中使用的顶点级加法或 DenseGCN 中使用的顶点级拼接)。

图 3.为了提高泛化能力, 我们在实践中使用随机膨胀。在训练期间, 我们以高概率 δ 1 P 执行上述膨胀聚合操作, 同时留有小概率 从 k d 个邻居集合 $fu_1; u_2; \dots; u_{kd}g$ 中均匀采样 k 个邻居进行随机聚合。在推理时, 我们执行确定性的膨胀聚合, 不引入随机性, 即膨胀邻居是基于方程 (5) 以概率 1 进行采样。

3.4 深度 GCN 变体

在本文的实验中, 我们主要使用基于 EdgeConv [6] 的图卷积网络 (GCN) 来展示如何训练非常深的 GCN。然而, 利用上述相同的概念 (例如残差/密集图连接和膨胀图卷积) 构建其他深度 GCN 也是相当直接的。为了表明这些概念是通用的操作符, 并且可以用于一般的 GCN, 我们还进行了额外的实验。具体来说, 我们基于 GraphSAGE [42] 和图同构网络 (GIN) [52] 构建了残差 GCN。在实践中, 我们发现 EdgeConv 学习到的表示优于其他实现方式, 但在内存和计算效率方面表现较差。因此, 我们还提出了一种简单的 GCN 操作。




图 3.图卷积网络中的膨胀卷积。在网格状结构图 (例如 2D 图像) 和一般结构图上进行膨胀卷积的可视化。(上) 卷积核大小为 3, 膨胀率为 1、2、4 的 2D 卷积 (从左至右)。(下) 膨胀率为 1、2、4 的动态图卷积 (从左至右)。

结合两者的优点, 我们将其称为 MRGCN (最大相对 GCN)。接下来, 我们将详细讨论每个 GCN 操作符。

EdgeConv。EdgeConv [6] 并非直接聚合邻域特征, 而是首先通过将每个邻点的特征与其中心顶点的特征相减来获取每个邻点的局部邻域信息。为了训练更深的图卷积网络 (GCN), 我们在 EdgeConv 中添加了残差/密集图连接和膨胀图卷积。

$$\begin{aligned} \mathbf{h}_{v_{l+1}}^{\text{res}} &= \max \left(\{ \text{mlp}(\text{concat}(\mathbf{h}_{v_l}, \mathbf{h}_{u_l} - \mathbf{h}_{v_l})) | u_l \in \mathcal{N}^{(d)}(v_l) \} \right), \\ \mathbf{h}_{v_{l+1}} &= \mathbf{h}_{v_{l+1}}^{\text{res}} + \mathbf{h}_{v_l}. \end{aligned} \quad (6)$$

GraphSAGE。GraphSAGE [42] 提出了不同类型的聚合器函数, 包括均值聚合器、LSTM 聚合器和池化聚合器。他们的实验表明, 池化聚合器的表现优于其他聚合器。我们采用 GraphSAGE 并结合最大池化聚合器, 从而得到 ResGraphSAGE。

$$\begin{aligned} \mathbf{h}_{\mathcal{N}^{(d)}(v_l)}^{\text{res}} &= \max \left(\{ \text{mlp}(\mathbf{h}_{u_l}) | u_l \in \mathcal{N}^{(d)}(v_l) \} \right), \\ \mathbf{h}_{v_{l+1}}^{\text{res}} &= \text{mlp} \left(\text{concat} \left(\mathbf{h}_{v_l}, \mathbf{h}_{\mathcal{N}^{(d)}(v_l)}^{\text{res}} \right) \right), \\ \mathbf{h}_{v_{l+1}} &= \mathbf{h}_{v_{l+1}}^{\text{res}} + \mathbf{h}_{v_l}, \end{aligned} \quad (7)$$

在原始的 GraphSAGE 论文中, 顶点特征在聚合之后进行了归一化处理。我们实现了两种变体, 一种不进行归一化 (见公式 (7)), 另一种进行归一化处理, 即 $\text{hresvl}p1 \frac{1}{4}\text{hresvl}p1 \frac{1}{4}\text{hresvl}p1$ 。

GIN 的主要区别在于, 与其他 GCN 相比, GIN [52] 在每个 GCN 层都会学习一个, 以便为中心节点和聚合的邻域特征赋予不同的权重。因此, ResGIN 的公式如下:

$$\begin{aligned} \mathbf{h}_{v_{l+1}}^{\text{res}} &= \text{mlp} \left((1 + \epsilon) \cdot \mathbf{h}_{v_l} + \text{sum}(\{ \mathbf{h}_{u_l} | u_l \in \mathcal{N}^{(d)}(v_l) \}) \right), \\ \mathbf{h}_{v_{l+1}} &= \mathbf{h}_{v_{l+1}}^{\text{res}} + \mathbf{h}_{v_l}. \end{aligned} \quad (8)$$

MRGCN。我们发现, 首先使用最大聚合器来聚合邻域相对特征 $\delta \mathbf{h}_{u_l} \mathbf{h}_{v_l} \mathbf{P}; u_l \in \mathcal{N}^{(d)}(v_l)$

比聚合原始的邻域特征更有效率和效果 $\mathbf{h}_{v_l}$; $\mathbf{u}_l \in \mathcal{N}^{(d)}(v_l)$ 在非线形变换后聚合特征。我们将这种简单的 GCN 称为 MRGCN (最大相对 GCN)。MRGCN 的残差版本如下所示

$$\begin{aligned}\mathbf{h}_{\mathcal{N}^{(d)}(v_l)}^{res} &= \max(\{\mathbf{h}_{u_l} - \mathbf{h}_{v_l} | u_l \in \mathcal{N}^{(d)}(v_l)\}), \\ \mathbf{h}_{v_{l+1}}^{res} &= \text{mlp}\left(\text{concat}\left(\mathbf{h}_{v_l}, \mathbf{h}_{\mathcal{N}^{(d)}(v_l)}^{res}\right)\right), \\ \mathbf{h}_{v_{l+1}} &= \mathbf{h}_{v_{l+1}}^{res} + \mathbf{h}_{v_l}.\end{aligned}\quad (9)$$

这里, $\mathbf{h}_{v_{l+1}}$ 和 $\mathbf{h}_{v_l}$ 分别是顶点 v 在第 l 层和第 $l+1$ 层的隐藏状态, 而 $\mathbf{h}_{res}$

$\mathbf{h}_{v_{l+1}}^{res}$ 是残差的隐藏状态

图。所有多层感知器 (MLP) 函数均采用 ReLU 作为激活函数; 上述所有最大值和求和函数均为顶点级特征操作符; 拼接函数将两个顶点的特征拼接成一个特征向量。Nöððððv denotes 从膨胀 k 近邻算法中获得的顶点 v_l 的邻域。MRGCN 比 EdgeConv 和 GraphSAGE 更高效。MRGCN 对每个顶点仅应用一次 MLP 变换, 而 EdgeConv 则需要对每个顶点的每个邻居都应用此变换。与 GraphSAGE 相比, MRGCN 在最大值聚合前无需对邻域特征应用 MLP 变换, 且额外的减法计算量可以忽略不计。

4 关于三维点云的实验

我们提出了 ResGCN 和 DenseGCN 来解决图卷积网络 (GCN) 中的梯度消失问题。为了扩大感受野, 我们为 GCN 定义了一个膨胀图卷积算子。为了评估我们的框架, 我们在大规模 3D 点云数据集上进行了语义分割和部件分割任务的大量实验, 并证明我们的方法显著提高了性能。此外, 我们还进行了全面的消融研究, 以展示我们框架中不同组件的效果。

4.1 三维点云上的图学习

点云分割是一项具有挑战性的任务, 原因在于 3D 点云的无序和不规则结构。通常, 点云中的每个点都由其 3D 空间坐标表示, 并且可能还带有诸如颜色和/或表面法线之类的辅助特征。我们将点云中的每个点视为有向图 G 中的一个顶点 v , 并在每个 GCN 层使用 k -NN 构建点之间的有向动态边 (参见第 3.1 节)。在第一层, 我们通过应用膨胀的 k -NN 搜索在 3D 坐标空间中找到最近邻来构建输入图 G_0 。在后续层中, 我们在特征空间中使用膨胀的 k -NN 动态构建边。对于分割任务, 我们在输出层预测所有顶点的类别。

4.2 实验设置

我们使用所有类别上的总体准确率 (OA) 和平均交并比 (mIoU) 作为评估指标。对于每个类别, 交并比 (IoU) 的计算公式为:

$$TP \div (TP + FP + FN)$$

TP

——其中 TP 代表

真阳性点的数量为 T , T 代表该类别的真实点数, P 代表预测的阳性点数量。我们在

S3DIS 数据集上对点云的语义分割进行了大部分实验。为了说明使用深度图卷积网络 (DeepGCNs) 的必要性, 我们在该数据集的 5 区进行了全面的消融研究, 以分析每个组件并提供见解。然后, 我们在所有 6 个区域上评估了我们提出的参考模型 ResGCN-28 (具有 28 层骨干网络、残差图连接和随机膨胀图卷积), 并与浅层 DGCNN 基线[6]及其他最先进的方法进行了比较。为了验证我们的方法具有通用性且不依赖于特定数据集, 我们还在 PartNet 上展示了点云部件分割任务的结果。

4.3 网络架构

如图 2 所示, 我们实验中所有网络架构均包含三个模块: GCN 主干模块、融合模块和 MLP 预测模块。GCN 主干模块是实验中唯一不同的部分。例如, PlainGCN 和 ResGCN 的唯一区别在于 ResGCN 对所有 GCN 层使用了残差跳连。两者参数数量相同。我们随着网络深度线性增加膨胀 k 近邻的膨胀率 d 。为了公平比较, 所有架构的融合和 MLP 预测模块保持一致。GCN 主干模块以包含 4096 个点的点云作为输入, 通过连续应用 GCN 层来提取特征, 以聚合局部信息, 并输出具有 4096 个顶点的学习图表示。融合和 MLP 预测模块的架构与 PointNet [33] 和 DGCNN [6] 类似。融合模块用于融合全局和多尺度局部特征。它以 GCN 主干模块在每个 GCN 层提取的顶点特征作为输入, 将这些特征进行拼接, 然后通过一个 1×1 卷积层, 再进行最大池化。后一层将整个图的顶点特征聚合为一个单一的全局特征向量, 该向量再与来自所有先前 GCN 层的每个顶点的特征进行拼接 (全局信息与局部信息的融合)。MLP 预测模块对每个顶点/点的融合特征应用三个 MLP 层来预测其类别。实际上, 这些层是 1×1 卷积。

PlainGCN。该基线模型由一个 PlainGCN 主干块、一个融合块和一个 MLP 预测块组成。主干部分堆叠了带有动态 k 近邻的 EdgeConv [6] 层, 每一层都类似于 DGCNN [6] 中使用的那一层。这里没有使用跳跃连接。

ResGCN。我们通过在 PlainGCN 中添加动态膨胀 k 近邻和残差图连接来构建 ResGCN。GCN 主干块中所有 GCN 层之间的连接不会增加参数数量。

DenseGCN。同样, DenseGCN 是通过在 PlainGCN 中添加动态膨胀 k 近邻和密集图连接构建而成的。如 3.2 节所述, 密集图连接是通过将来自前一层的所有中间图表示进行拼接来创建的。我们的 DenseGCN 的膨胀率安排与 ResGCN 相同。

4.4 实施

对于 S3DIS [13] 上的语义分割, 我们使用 TensorFlow 实现了我们的模型, 而对于部件分割

在 PartNet [14] 上, 我们使用 PyTorch 实现这些模型。为了公平比较, 我们在所有实验中都使用初始学习率为 0.001 的 Adam 优化器, 并采用相同的学习率衰减计划; 每 3 $\times 10^5$ 次梯度下降步骤, 学习率衰减 50%。对每一层都应用了批量归一化。在 MLP 预测块的第二层 MLP 中使用了丢弃率 0.3 的丢弃层。如第 3.3 节所述, 对于具有膨胀的 GCN, 我们使用随机均匀采样概率 $1/40:2$ 的膨胀 k-NN。为了单独考察所提出的 DeepGCN 架构的效果, 我们不使用任何数据增强或后处理技术。我们从头开始对模型进行端到端训练, 共训练 100 个周期。每 10 个周期在测试集上进行一次评估, 并报告每个模型的最佳结果。在 S3DIS 上进行语义分割时, 我们使用两个 NVIDIA Tesla V100 GPU 通过数据并行化训练网络, 每个 GPU 的批处理大小设置为 8。对于 PartNet 上的部件分割, 我们将批处理大小设置为 7, 并使用一个 NVIDIA Tesla V100 GPU 进行训练。

4.5 结果

为了便于引用, 我们采用“骨干块-层数”的命名规则来表示我们分析中的关键模型。我们专注于残差图连接进行分析, 因为 ResGCN-28 更容易且更快地进行训练, 但我们预计我们的观察结果对于密集图连接也同样适用。

4.5.1 S3DIS 上的语义分割

为了全面评估本文提出的方法, 我们在斯坦福大规模 3D 室内空间数据集 (S3DIS) 上进行了大量实验, 该数据集是一个用于点云 3D 语义分割的大规模室内数据集。S3DIS 覆盖面积超过 6000 平方米, 包含语义标注的 3D 网格和点云。特别地, 该数据集包含 6 个大型室内区域, 以彩色 3D 点云的形式呈现, 总共有 695,878,620 个点。按照惯例, 我们在 6 个区域中的 5 个区域上训练网络, 并在剩余的区域上进行评估。

我们首先进行广泛的消融研究, 在其他区域训练模型后, 将其在区域 5 上进行评估。我们的目的是阐明我们新颖网络架构中每个组件的贡献。为此, 我们研究了不同 ResGCN 架构的性能, 例如具有动态膨胀 k-NN 的架构、具有常规动态 k-NN (无膨胀) 的架构以及具有固定边的架构。我们还研究了不同参数的影响, 例如 k-NN 邻居的数量 (4、8、16、32)、滤波器的数量 (32、64、128) 以及层数 (7、14、28、56)。为了确保我们的贡献 (残差/密集连接和膨胀图卷积) 具有通用性, 我们将它们应用于文献中提出的多种 GCN 变体。总体而言, 我们进行了 25 次实验, 并在表 1 中报告了详细结果。我们还在图 4 中总结了消融研究中最重要见解。接下来, 我们将讨论每个实验组。

残差图连接的影响。我们在表 1 (参考) 中的实验表明, 残差图连接在训练更深的网络时起着至关重要的作用, 因为它们往往能带来更稳定的梯度。这与卷积神经网络 (CNN) 中的见解类似 [10]。ResNet [10] 在每两个卷积块之间

添加了跳跃连接; 我们对两种跳跃连接变体 ResGCN-28 和 ResGCN-28y 进行了实验。ResGCN-28 在每个图卷积层之间添加跳跃连接, 而 ResGCN-28y 则在每两个图卷积层之间添加跳跃连接。我们发现 ResGCN-28 的 mIOU 比 ResGCN-28y 高出 1.63 个百分点 (参见表 1)。因此, 对于所有其他 ResGCN 架构, 我们在每层之间都采用跳跃连接。当层之间的残差图连接被移除 (即在 PlainGCN-28 中) 时, 性能会大幅下降 (mIoU 下降 12.18 个百分点)。图 5 非常清晰地展示了残差图连接的重要性。随着网络深度的增加, 跳跃连接对于收敛变得至关重要。我们还展示了通过将残差图连接与膨胀图卷积与其他类型的图卷积层相结合所获得的类似性能提升。这些结果可在消融研究表 1 (GCN 变体) 中看到, 并将在本节后面进一步讨论。

扩张效果。表 1 (扩张) [12] 中的结果表明, 扩张图卷积使平均交并比 (IoU) 提高了 2.85% (第 3 行), 这主要是由于网络感受野的扩大。我们发现, 向扩张的 k 近邻添加随机性确实有助于性能提升, 但提升幅度不大。我们还研究了随机扩张对性能的影响, 并在表 1 (随机 ϵ) 中报告了结果。我们发现, 模型对不同值的 ϵ 具有鲁棒性。不同 ϵ 下的 mIOU 变化幅度约为 1%。通过仔细调整, 有可能获得更好的性能。例如, 将 ResGCN-28 中的 ϵ 设为 0.4 时, 与 ϵ 等于 0.2 的参考模型相比, mIOU 提高了 0.49%。有趣的是, 表 1 中的结果还表明, 当与残差图连接相结合时, 扩张尤其有助于深度网络 (第 1 行、第 13 行)。如果没有这种连接, 使用扩张图卷积实际上可能会导致性能下降。其原因可能是这些变化的邻居导致了“更差”的梯度, 这在没有使用残差图连接时进一步阻碍了收敛。

扩张卷积与下采样。我们提出的扩张图卷积在无需下采样的情况下扩大了感受野。为了展示扩张图卷积相较于下采样的优势, 我们使用 U-Net 风格的 [53] ResGCN 模型进行了实验, 并在表 1 (下采样) 中报告了结果。对于 U-Net 变体, 我们在 ResGCN-28 的骨干网络中插入了下采样模块。每 7 层后, 顶点数量减少一半。最终特征被输入到顺序插值层中, 逐步将特征上采样回其原始分辨率。我们实验了点云文献中两种流行的下采样方法, 即随机下采样 [54] 和最远点采样 (FPS) [34]。我们分别将这两种架构标记为 ResGCN-28-random 和 ResGCN-28-FPS。我们观察到, 采用扩张图卷积的 ResGCN-28 模型分别比 ResGCN-28-random 和 ResGCN-28-FPS 模型高出 4.51% 和 9.06%, 这清楚地表明了扩张的优势。不过值得一提的是, 在诸如 KPConv [55] 和 RandLA-Net [54] 等近期的最先进方法中, 采用了类似 U-Net 的下采样结构, 并取得了非常有前景的结果。ResGCN-28-random 和 ResGCN-28-FPS 的结果

表 1 S3DIS 数据集区域 5 的消融研究

Ablation	Model	Operator	mIoU	Δ mIoU	dynamic	connection	dilation	sto. eps.	# NNs	# filters	# layers
Reference	<i>ResGCN-28</i>	EdgeConv	52.49	0.00	✓	$\oplus$	✓	0.2	16	64	28
Dilation		EdgeConv	51.98	-0.51	✓	$\oplus$	✓	0.0	16	64	28
		EdgeConv	52.98	0.49	✓	$\oplus$	✓	0.4	16	64	28
		EdgeConv	51.92	-0.57	✓	$\oplus$	✓	0.6	16	64	28
		EdgeConv	52.35	-0.14	✓	$\oplus$	✓	0.8	16	64	28
		EdgeConv	51.40	-1.08	✓	$\oplus$	✓	1.0	16	64	28
		EdgeConv	49.64	-2.85	✓	$\oplus$			16	64	28
	<i>PlainGCN-28</i>	EdgeConv	40.31	-12.18	✓				16	64	28
Downsampling	<i>ResGCN-28-FPS</i>	EdgeConv	47.98	-4.51	✓	$\oplus$		0.2	16	64	28
	<i>ResGCN-28-random</i>	EdgeConv	44.30	-8.19	✓	$\oplus$		0.2	16	64	28
Fixed k -NN		EdgeConv	48.38	-4.11		$\oplus$			16	64	28
		EdgeConv	43.43	-9.06					16	64	28
Connections	<i>DenseGCN-28</i>	EdgeConv	51.27	-1.22	✓	$\boxtimes$	✓	0.2	8	32	28
	<i>ResGCN-28[†]</i>	EdgeConv	50.86	-1.63	✓	$\oplus$	✓	0.2	16	64	28
		EdgeConv	40.47	-12.02	✓		✓	0.2	16	64	28
		EdgeConv	38.79	-13.70	✓		✓	0.2	8	64	56
		EdgeConv	49.23	-3.26	✓		✓	0.2	16	64	14
		EdgeConv	47.92	-4.57	✓		✓	0.2	16	64	7
Neighbors		EdgeConv	49.98	-2.51	✓	$\oplus$	✓	0.2	8	64	28
		EdgeConv	49.22	-3.27	✓	$\oplus$	✓	0.2	4	64	28
		EdgeConv	49.18	-3.31	✓	$\oplus$	✓	0.2	32	32	28
Depth	<i>ResGCN-112</i>	EdgeConv	51.97	-0.52	✓	$\oplus$	✓	0.2	4	64	112
	<i>ResGCN-56</i>	EdgeConv	53.64	1.15	✓	$\oplus$	✓	0.2	8	64	56
	<i>ResGCN-14</i>	EdgeConv	49.90	-2.59	✓	$\oplus$	✓	0.2	16	64	14
	<i>ResGCN-7</i>	EdgeConv	48.95	-3.53	✓	$\oplus$	✓	0.2	16	64	7
Width	<i>ResGCN-28W</i>	EdgeConv	53.78	1.29	✓	$\oplus$	✓	0.2	8	128	28
		EdgeConv	48.80	-3.69	✓	$\oplus$	✓	0.2	16	32	28
		EdgeConv	45.62	-6.87	✓	$\oplus$	✓	0.2	16	16	28
GCN Variants		GraphSAGE	49.20	-3.29	✓	$\oplus$	✓	0.2	16	64	28
		GraphSAGE-N	49.02	-3.47	✓	$\oplus$	✓	0.2	16	64	28
		GIN- ϵ	42.81	-9.68	✓	$\oplus$	✓	0.2	16	64	28
	<i>ResMRGCN-28</i>	MRGCN	51.17	-1.32	✓	$\oplus$	✓	0.2	16	64	28

我们将具有 28 层、残差图连接和膨胀图卷积的参考网络 (ResGCN-28) 与几个消融变体进行了比较。所有模型均使用相同的超参数在除用于评估的区域 5 之外的所有区域上训练了 100 个周期。我们分别用 $\oplus$ 和 $\boxtimes$ 符号表示残差连接和密集连接。y 表示在每两个 GCN 层之间添加了残差连接。我们将最重要的结果用粗体突出显示。DmIoU 表示与参考模型 ResGCN-28 的 mIoU 差异。

每秒帧数可能不是最优的。我们推测，通过更复杂的架构设计和超参数调整，类似 U-Net 的图卷积网络架构能够达到更合理的性能。

动态 k 近邻算法的效果。尽管在每次更新 k 个最近邻点后我们观察到了性能的提升，




图 4. 在 S3DIS 数据集的第 5 区域进行消融研究。我们将我们的参考网络 (具有 28 层、残差图连接和膨胀图卷积的 ResGCN-28) 与几个消融变体进行了比较。除了 S3DIS 数据集的第 5 区域外，所有模型均使用相同的超参数训练 100 个周期。

在此，我们还想指出，这一层的计算成本相对较高。表 1 展示了不同变体 (固定 k 近邻) 在没有动态边的情况下的情况。

密集图连接的效果。我们在表 1 (连接) 中观察到，使用密集图连接 (DenseGCN-28) 时性能也有类似的提升。然而，如果采用简单的实现方式，内存消耗会非常大。因此，我们能够装入 GPU 内存的最大模型仅使用 32 个滤波器和 8 个最近邻节点，而其残差连接的对应模型 ResGCN-28 则使用 64 个滤波器和 16 个最近邻节点。由于这两种深度 GCN 变体的性能相似，残差连接对于大多数应用场景来说更实用，因此我们在消融研究中主要关注它们。不过，我们预计同样的见解也适用于密集图连接的情况。

最近邻点的影响。表 1 (最近邻点) 中的结果表明，通常来说，邻点数量越多越好。当邻点数量分别减少 2 倍和 4 倍时，性能分别下降 2.51% 和 3.27%。然而，只有当网络容量足够大时，邻点数量多才会带来性能提升。这一点在我们将邻点数量增加 2 倍并同时滤波器数量减少 2 倍时变得明显 (请参见“最近邻点”中的第 3 行)。




图 5. 在 S3DIS 数据集的第 5 区域, PlainGCN 与 ResGCN 的对比。我们比较了不同深度且有无残差图连接的网络。除了第 5 区域外, 所有模型均使用相同的超参数在所有区域上训练了 100 个周期。只有使用残差图连接时, 随着深度的增加结果才会得到改善。

网络深度的影响。表 1 (深度) 表明, 只有在使用残差图连接和膨胀图卷积的情况下, 增加网络层数才能提升网络性能, 这一点在表 1 (连接) 中清晰可见。

网络宽度的影响。表 1 (宽度) 中的结果表明, 增加滤波器的数量所带来的性能提升与增加网络层数的效果相似。总体而言, 更高的网络容量能够学习到在极端情况下取得成功所必需的细微差别。

GCN 变体。我们在表 1 (GCN 变体) 中的实验展示了使用不同 GCN 操作符的效果。结果清楚地表明, 具有残差图连接和膨胀图卷积的不同深度 GCN 变体比 PlainGCN 收敛得更好。使用我们提出的 MRGCN 操作符实现了与依赖于 EdgeConv 的 ResGCN 参考模型相当的性能, 但仅使用了一半的 GPU 内存。GraphSAGE 操作符的表现稍差, 我们的结果还表明使用归一化 (即 GraphSAGE-N) 并非必要。有趣的是, 当使用 GIN- 操作符时, 网络在训练阶段收敛良好且训练精度高, 但在测试集上泛化能力差。这一现象在原始论文 [52] 中也有观察到, 其中当 设置为 0 时性能最佳。




图 6. 在 S3DIS 数据集的区域 5 上, ResGCN 带 BN 与 ResGCN 不带 BN 的对比。我们比较了带有和不带有批量归一化的 ResGCN 模型。除了区域 5 之外, 所有模型都在所有区域上使用相同的超参数训练了 100 个周期。批量归一化对于训练深度模型的重要性得以体现。

表 2
基于组距离比和实例信息增益的过平滑分析

模型	组间差异比率	实例信息收益	mIoU
ResGCN-28	1.73	0.46	52.49
无扩张	1.67	0.43	49.64
无连接	1.12	0.01	40.47

我们通过测量组距离比和实例信息增益来分析残差图连接和膨胀图卷积对深度图卷积网络 (GCN) 过度平滑问题的影响。除区域 5 外, 所有模型均在所有区域上使用相同的超参数训练 100 个周期。结果表明, 残差连接和膨胀对于缓解过度平滑问题十分有效。

批量归一化的效果。批量归一化 (BN) [47] 是一种在训练深度卷积神经网络时用于减少内部协变量偏移的常用技术。在表 1 所示的所有模型中, 我们默认在每个 GCN 块中都采用 BN。为了展示 BN 的效果, 我们在区域 5 进行了进一步的实验, 从 ResGCN-28 和 ResGCN-7 中移除了 BN。图 6 中的结果表明, 当移除 BN 后, ResGCN-28 和 ResGCN-7 的性能分别下降了 6.1% 和 4.0%。ResGCN-28 无 BN 的表现甚至不如 ResGCN-7 有 BN 的表现。这表明 BN 对于训练深度 GCN 是必不可少的。

过度平滑分析。为了研究残差图连接和膨胀图卷积对过度平滑问题的影响, 我们采用文献[56]中提出的两个定量指标, 即组距离比和实例信息增益, 来衡量最后一层 GCN 学习到的节点表示的过度平滑程度。组距离比衡量的是最终表示在欧几里得空间中的组间距离与组内距离的比值。实例信息增益衡量的是输入节点特征与最终表示之间的互信息。组距离比或实例信息增益越高, 表示过度平滑的程度越低。我们测量了训练好的参考模型 (ResGCN-28) 以及相应地去掉膨胀 (w/o dilation) 或去掉残差连接 (w/o connection) 的消融模型的组距离比和实例信息增益。如表 2 所示, ResGCN-28 的组距离比 (1.73 对比 1.12) 和实例信息增益 (0.46 对比 0.01) 显著高于无残差的对应模型。对于扩张操作也可以得出类似的观察结果, 尽管其影响不太明显。这表明 ResGCN-28 学习到的特征更清晰, 受过度平滑的影响更小。然而, 当前的过度平滑度量无法将优化难度所导致的影响单独分离出来。我们认为, 将过度平滑和梯度消失的影响区分开来, 是更好地理解深度 GCN 架构的一个有前景的方向。

定性结果。图 7 展示了在 S3DIS [13] 的区域 5 上的定性结果。正如表 1 中的结果所预期的那样, 我们的 ResGCN-28 和 DenseGCN-28 在诸如板、梁、书架和门等困难类别上表现尤为出色。第 1 至 4 行清晰地表明, ResGCN-28 和 DenseGCN-28 分别能够对板、梁、书架和门进行准确分割, 而 PlainGCN-28 则完全失败。请参阅补充材料, 可在计算机协会数字图书馆 (<http://doi.>) 上找到。




图 7.S3DIS 半监督语义分割的定性结果。这里展示了在深度图卷积网络（GCN）中添加残差和密集图连接的效果。PlainGCN-28、ResGCN-28 和 DenseGCN-28 除了分别在 ResGCN-28 中加入了残差图连接以及在 DenseGCN-28 中加入了密集图连接之外，其余完全相同。我们注意到，残差和密集图连接对于诸如板子、书架和沙发这类难以分类的类别有着显著的影响。这些类别在 PlainGCN-28 的结果中表现不佳。

更多定性结果请参见 ieeecomputersociety.org/10.1109/TPAMI.2021.3074057。

与现有最佳方法的比较。最后，我们在表 3 中将我们的参考网络（ResGCN-28）与几个现有最佳基线进行了比较，该网络融合了方法论中提出的思想。结果清楚地表明，具有残差图连接和膨胀图卷积的更深模型是有效的。ResGCN-28 在平均交并比（mean IoU）上比 DGCNN [6] 高出 3.9 个百分点（绝对值）。DGCNN 与 ResGCN-28 具有相同的融合和多层感知机（MLP）预测模块，但其骨干网络类似于较浅的 PlainGCN。此外，在 13 个类别中的 9 个类别上，我们的表现优于所有基线。在诸如板凳（board）等困难对象类别上，我们的表现

尤为出色，达到了 51.1%，在沙发（sofa）类别上，我们比现有最佳方法的平均交并比（mIoU）提高了约 10%。

在这些困难类别上取得的显著性能提升，可能是由于网络容量的增加，这使得网络能够学习到区分棋盘和墙壁等细微的细节。图 7 中的第一行就是一个典型的例子。我们的性能提升完全归功于我们在网络架构上的创新，因为我们使用了与基线 DGCNN [6] 相同的超参数，甚至学习率计划也相同，只是将最近邻的数量从 20 减少到了 16，将批量大小从 24 减少。

表 3
ResGCN-28 与 S3DIS 半监督语义分割领域最新技术的对比

方法	OA mIoU天花板地板墙壁梁柱窗户门桌子椅子沙发书柜杂乱														
PointNet [33]	78.5	47.6	88.0	88.7	69.3	42.4	23.1	47.5	51.6	54.1	42.0	9.6	38.2	29.4	35.2
MS +铜[35]	79.2	47.8	88.6	95.8	67.3	36.9	24.9	48.6	52.3	51.9	45.1	10.6	36.8	24.7	37.5
G+RCU [35]	81.1	49.7	90.3	92.1	67.9	44.7	24.2	52.3	51.2	58.1	47.4	6.9	39.0	30.0	41.9
PointNet++ [34]	-	53.2	90.2	91.7	73.1	42.7	21.2	49.7	42.3	62.7	59.0	19.6	45.8	48.2	45.6
3DRNN + CF [37]	86.9	56.3	92.9	93.8	73.1	42.5	25.9	47.6	59.2	60.4	66.7	24.8	57.0	36.7	51.6
DGCNN [6]	84.1	56.1	-	-	-	-	-	-	-	-	-	-	-	-	-
ResGCN-28 (我们的)	85.9	60.0	93.1	95.3	78.2	33.9	37.4	56.1	68.2	64.9	61.0	34.6	51.5	51.1	54.4
深度 LPN [57]	85.7	60.0	91.0	95.6	76.1	50.3	25.9	55.1	56.8	66.3	74.3	25.8	54.0	52.3	55.3
ShellNet [58]	87.1	66.8	90.2	93.6	79.9	60.4	44.1	64.9	52.9	71.6	84.7	53.8	64.6	48.6	59.4
RandLA-Net [54]	88.0	70.0	93.1	96.1	80.6	62.4	48.0	64.4	69.4	69.4	76.4	60.0	64.2	65.9	60.1
KPConv [55]	-	70.6	93.6	92.4	83.1	63.9	54.3	66.1	76.6	64.0	57.8	74.9	69.3	61.3	60.3

我们报告了参考模型 ResGCN-28 以及最先进的基线模型在所有区域的平均类别结果。具有 28 层 GCN、残差图连接和膨胀图卷积的 ResGCN-28 比之前的最佳模型高出近 4%。它在 13 个类别中的 9 个类别上都优于所有基线模型。所展示的指标为总体点准确率（OA）和平均交并比（mIoU）。“-”表示未报告，加粗表示最佳性能。近期的相关工作 [57]、[58]、[54]、[55] 不是灰色的。




图 8.关于 PartNet 部件分割的定性结果。这里展示了在深度图卷积网络 (GCN) 中添加残差连接的效果。PlainGCN-28 和 ResGCN-28 除了 ResGCN-28 中存在残差连接外, 其余完全相同。我们注意到, 与 PlainGCN-28 相比, 残差连接对部件分割有积极影响。使用 PlainGCN-28 时, 许多重要部件的分类都不正确。

由于内存限制, 将该值设为 16。我们在很大程度上超越了最先进的方法, 并且预计通过调整超参数 (尤其是学习计划) 还能进一步提高性能。在表 3 中, 我们还列出了 Deep LPN [57]、ShellNet [58]、RandLA-Net[54] 和 KPConv[55] 的最新最先进结果以供参考。这些方法采用了不同的数据预处理和增强流程, 并且是在我们论文的短版发表之后发表的。我们将这些结果用灰色标注。

4.5.2 PartNet 中的零件分割

我们进一步在零件分割任务上对我们的架构进行实验, 并在最近提出的大型 PartNet [14] 数据集上对其进行评估。PartNet 包含来自 24 个对象类别的超过 26,671 个 3D 模型, 以及 573,585 个标注的零件实例。该数据集为 3D 对象的零件分割建立了三个基准任务: 细粒度语义分割、层次语义分割和实例分割。在接下来的实验中, 我们专注于细粒度级别的语义分割, 其中包括 PartNet 数据集中存在的 24 个对象类别中的 17 个。

我们使用与在 S3IDS 数据集上进行实验时相同的参考架构 ResGCN-28。我们将它的性能与基线架构 PlainGCN-28 进行比较, 以展示我们的残差连接和随机膨胀卷积的影响。我们还与 PartNet 论文 [14] 中报告的最新技术进行了比较, 即 PointNet [33]、PointNet++ [34]、SpiderCNN [59] 和 PointCNN [60]。按照 PartNet [14] 的建议, 我们使用 10,000 个采样点作为输入。我们为每个类别训练单独的网络, 并使用 Adam 优化器进行 500 个周期的训练, 不使用权重衰减。初始学习率为 0.005, 每 50 个周期衰减 0.9 倍。我们使用在验证集上表现最佳的预训练模型报告结果。

定性结果。图 8 展示了在 PartNet [14] 的 4 个类别 (瓶子、床、微波炉和冰箱) 上的定性结果。正如表 4 中的结果所预期的那样, ResGCN-28 相较于没有层间残差连接的基线 PlainGCN-28 表现得非常出色, 尽管 ResGCN-28 产生了一些

尽管在诸如微波炉和床等类别中与真实情况相比存在错误输出, 但它仍优于 PlainGCN-28 并能分割出物体的重要部分。我们在线提供的补充材料中有更多定性结果。

与现有最佳方法的比较。我们在表 4 中总结了 ResGCN-28 的结果, 并将其与 PlainGCN-28 以及其他现有最佳方法进行了比较。ResGCN-28 大幅优于 PlainGCN-28, 这表明我们提出的残差连接和随机膨胀卷积能够训练深度 GCN 架构。ResGCN-28 也显著优于 PointNet [33]、PointNet++ [34] 和 SpiderCNN [59]。请注意, PointCNN 专门设计了一种针对点云的点卷积, 而 ResGCN-28 是适用于任何图 (例如点云、生物网络、引文网络等) 的通用框架。尽管存在这一巨大劣势, ResGCN-28 在包括瓶子、刀具、灯具和桌子在内的某些类别上的表现仍与 PointCNN [60] 相当, 甚至更优。我们还列出了 Deep LPN [57] 和 Pos-Pool [61] 的最新 SOTA 结果以供参考。这些方法采用了不同的数据预处理和增强流程, 并且是在我们论文的短版发表之后发表的。我们将这些结果用灰色标注。

4.5.3 ModelNet40 上的对象分类

我们还将我们的架构应用于物体分类任务, 并在流行的物体分类数据集 ModelNet40 [62] 上对其进行了评估。该数据集包含来自 40 个不同类别的 12,311 个 CAD 模型。尽管已趋于饱和, 但 ModelNet40 仍被视为 3D 物体分类任务的重要基准。表 5 中的结果表明, 我们的 ResGCN 和 DenseGCN 架构优于基准 PlainGCN 和最先进的方法。与基准 PlainGCN 相比, 可以观察到

我们的残差连接、密集连接和扩张卷积所产生的积极影响。此外, ResGCN 和 DenseGCN 架构在整体测试准确率方面超越了所有最先进的方法。特别是, ResGCN-14 在 ModelNet-40 上的整体准确率达到了 93.6%。在此, 我们指出近期的一项工作

表 4
ResGCN-28 在 PartNet 零件分割任务中的与其他方法的比较

方法	平均 床 瓶子 椅子 闹钟 洗碗机 门 耳机 水龙头 刀 灯 微波炉 冰箱 沙发 桌子 拖把 垃圾桶 花瓶																		
PointNet [33]	35.6	13.4	29.5	27.8	28.4	48.9	76.5	30.4	33.4	47.6	32.9	18.9	37.2	33.5	38.0	29.0	34.8	44.4	
PointNet++ [34]	42.5	30.3	41.4	39.2	41.6	50.1	80.7	32.6	38.4	52.4	34.1	25.3	48.5	36.4	40.5	33.9	46.7	49.8	
蜘蛛卷积神经网络 [59]	37.0	36.2	32.2	30.0	24.8	50.0	80.1	30.5	37.2	44.1	22.2	19.6	43.9	39.1	44.6	20.1	42.4	32.4	
PointCNN [60]	46.5	41.9	41.8	43.9	36.3	58.7	82.5	37.8	48.9	60.5	34.1	20.1	58.2	42.9	49.4	21.3	53.1	58.9	
PlainGCN-28	31.3	20.1	29.4	(由于原文仅包含数字, 因此翻译时保持不变。)					36.4	42.2	32.5	16.7		35.6	29.8	30.1	15.1	33.8	28.2
ResGCN-28 (我们的)	45.1	35.9	49.3	41.1	33.8	56.2	81.0	31.1	45.8	52.8	44.5	23.1		51.8	34.9	47.2	33.6	50.8	54.2
深度 LPN [57]	38.6	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-
PosPool [61]	53.8	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-

我们报告了在细粒度分割级别上的部分类别平均交并比 (mIoU)。具有 28 层图卷积层、残差图连接和膨胀图卷积的 ResGCN-28 在平均 mIoU 方面优于 PlainGCN-28 以及大多数先前的方法。近期的相关工作 [57]、[61] 不在灰色显示。‘-’ 表示原始论文中未报告结果。

如表 5 所示, KPConv [55] 所使用的可训练参数数量远多于我们的参考模型 ResGCN-28。然而, 即使是我们较浅的变体 ResGCN-14, 在使用几乎少一个数量级的可训练参数的情况下, 其性能也优于 KPConv。

5 生物网络实验

为了展示我们所做贡献的通用性, 特别是我们的深度 ResGCN 架构, 我们在通用图数据上进行了进一步的实验。我们选择了在生物图数据上进行节点分类这一流行任务, 这与点云数据有很大的不同。在接下来的实验中, 我们主要研究了跳跃连接、GCN 层的数量 (即深度)、每层的滤波器数量 (即宽度) 以及不同的图卷积算子的影响。

表 5

在 ModelNet40 点云分类任务上, 我们的 GCN 变体与当前最优方法的比较

模型	O.A. (%) : 开口率 (C.A. (%))		参数 (M)
3DmFV-Net [62]	91.6	-	45.77
PointNet [33]	89.2	86.2	3.5
PointNet++ [34]	90.7	-	1.48
SO-Net [63]	90.9	87.3	-
基于 Ext 的 PCNN [64]	92.3	-	8.2
SpecGCN [65]	91.5	-	2.05
蜘蛛卷积神经网络 [59]	90.5	-	-
MCCConv [66]	90.9	-	-
FlexConv [67]	90.2	-	0.35
PointCNN [60]	92.2	88.1	0.6
DGCNN [6]	92.9	90.2	1.84
KPConv 刚性 [55]	92.9	-	14.3
KPConv 变形 [55]	92.7	-	15.2
PlainGCN-14	90.5	85.1	2.2
PlainGCN-28	91.4	86.8	3.3
ResGCN-14 (我们的)	93.6	90.9	2.2
ResGCN-28 (我们的)	93.3	89.5	3.3
密集 GCN-14 (我们的)	93.3	89.4	8.8
密集 GCN-28 (我们的成果)	93.2	90.3	30.9

我们报告了我们模型和最先进的模型的整体分类测试准确率 (O.A.) 和平均类别准确率 (C.A.), 以及每个模型的参数总数。可以看出, 我们的 ResGCN 和 DenseGCN 架构优于最先进的模型。

5.1 生物网络中的图学习

生物网络与点云数据的主要区别在于生物网络具有固有的边信息和高维输入特征。对于生物网络上的图学习任务, 我们使用 PPI [2] 数据集来评估我们的架构。PPI 是一个流行的多标签节点分类数据集, 包含 24 个图, 其中 20 个在训练集, 2 个在验证集, 2 个在测试集。PPI 中的每个图对应于不同的人体组织, 图中的每个节点代表一种蛋白质, 边代表蛋白质之间的相互作用。每个节点具有位置基因集、基序基因集和免疫学特征作为输入特征 (总共 50 个), 以及 121 个基因本体集作为标签。该任务的输入是一个平均包含 2373 个节点的图, 目标是预测每个节点包含哪些标签。

我们基本上使用与第 4.1 节中描述的点云分割相同的参考架构, 但要预测多个标签。我们更改了第一层和最后一层的滤波器数量以适应此任务。我们直接使用 PPI 提供的边, 而不是通过 k-NN 构建边。如果动态构建边, 可能会丢失初始边所提供的丰富信息。

5.2 实验设置

按照常规流程, 我们采用微平均 F1 (m-F1) 分数作为评估指标。对于每个图, F1 分数的计算方式如下:

$$F1\text{-score} = 2 \times \frac{(precision \times recall)}{(precision + recall)}, \tag{10}$$

其中, 当精度 $\frac{1}{4}TP_p$ 为 0, 召回率 $\frac{1}{4}T_r$ 为 0 时, TP 是总数

在所有类别的真正例点中, $T_{\checkmark}$ 表示真正正例点的数量, $p_{\checkmark}$ 表示预测的正例点的数量。我们在训练阶段找到最佳模型, 即在验证集上准确率 (m-F1 分数) 最高的模型, 然后计算测试集中所有图的 m-F1 分数。

我们展示了所提出的 MRGCN 的性能和 GPU 内存使用情况, 并将其与其他图卷积 (例如 EdgeConv [6]、GATConv [43]、SemiGCN [38] 和 GINConv [52]) 进行了比较。我们还针对滤波器数量和进行了广泛的消融研究。

表 6
关于图连接、网络宽度和网络的消融研究

工作深度				
滤波器数量	32	64	128	256
PlainMRGCN-3	95.84	97.60	98.58	99.13
PlainMRGCN-7	97.35	98.69	99.22	99.38
PlainMRGCN-14	97.55	99.02	99.31	99.34
PlainMRGCN-28	98.09	99.00	99.02	99.31
普通MRGCN-56	92.70	97.43	97.31	97.61
PlainMRGCN-112	60.75	71.97	89.69	91.50
ResMRGCN-3	96.04	97.60	98.53	99.09
ResMRGCN-7	97.00	98.43	99.19	99.30
ResMRGCN-14	97.75	98.88	99.26	99.38
ResMRGCN-28	98.50	99.16	99.29	99.41
ResMRGCN-56	98.62	99.27	99.36	99.40
ResMRGCN-112	98.41	99.34	99.38	99.39
密集型多关系图卷积网络-3	95.96	97.85	98.66	99.11
密集型 MRGCN-7	97.87	98.47	99.31	99.36
密集型多关系图卷积网络-14	98.93	99.00	99.01	99.43
密集型 MRGCN-28	99.16	99.29	99.42	-
密集型 MRGCN-56	99.22	-	-	-

m-F1 分数被用作评估指标（以百分比表示）。我们发现，残差连接和密集连接能够帮助深度网络比没有任何连接的相同模型更好地收敛。此外，网络宽度与网络性能呈正相关。请注意，“-”表示由于内存限制而不适用的模型。加粗字体突出显示了在该多标签 PPI 节点分类问题中优于所有现有基线模型的模型。

为了展示 GCN 层的数量在骨干网络中的效果，我们在消融研究中进行了相关实验。我们的消融研究还包括实验以展示残差图连接和密集图连接在我们的 DeepGCN 框架中的重要性。为了确保公平比较，消融研究中的所有网络都采用相同的架构。最后，我们将我们的最佳模型与该任务的几种最先进的方法进行了比较。

5.3 实施

对于这个生物网络节点分类任务，我们基于 PyTorch Geometric [68] 实现了所有模型。在所有实验中，我们均使用 Adam 优化器，初始学习率均为 0.0002，学习率衰减策略为每 2000 次梯度下降步骤后学习率降低 80%。网络使用一块 NVIDIA Tesla V100 GPU 进行训练，批处理大小为 1。预测模块的第一层和第二层多层感知机（MLP）使用了 0.2 的丢弃率。为了公平比较，我们未使用任何数据增强或后处理技术。我们的模型从头开始端到端地进行训练。

5.4 结果

我们研究了残差连接和密集图连接对多标签节点分类性能的影响。我们还研究了不同参数（例如，滤波器数量（32；64；128；256）和层数（3；7；14；28；56；112））的影响。为了展示我们框架的通用性，我们还将所提出的残差连接应用于多个 GCN 变体。

图连接的效果。表 6 中的结果表明，残差连接和密集连接都有助于训练更深的网络。当网络较浅时，模型

表 7 网络深度和 GCN 变体的消融研究

层数	3	7	14	28	56
PlainSemiGCN	97.82	90.40	80.55	41.00	50.75
ResSemiGCN	97.88	95.05	93.50	90.60	90.54
PlainGAT	98.52	80.92	56.88	42.40	48.95
ResGAT	98.63	97.86	98.99	99.06	63.25
PlainGIN	97.86	57.78	40.79	35.82	0.26
ResGIN	97.80	96.44	98.22	97.44	97.18
PlainEdgeConv	99.16	99.27	99.30	99.33	98.99
ResEdgeConv	99.03	99.19	99.26	99.30	99.04
PlainMRGCN	99.13	99.38	99.34	99.31	97.61
ResMRGCN	99.09	99.30	99.38	99.41	99.40

m-F1 分数被用作评估指标（以百分比表示）。我们将骨干网络中每层的滤波器数量设置为 256，并改变层数。当网络加深时，残差图连接通常能帮助不同的 GCN 操作符比 PlainGCN 取得更好的性能。加粗部分突出显示了在该多标签 PPI 节点分类问题中优于所有最新基线模型的模型。

在没有图连接的情况下，模型也能取得与有图连接的模型相似的性能。然而，随着网络深度的增加，没有图连接的模型性能急剧下降，而有图连接的模型性能则保持稳定甚至进一步提升。例如，当滤波器数量为 32 且深度为 112 时，ResMRGCN-112 的 m-F1 分数比 PlainMRGCN-112 高出近 37.66%。我们注意到，在相同的网络深度和宽度下，DenseMRGCN 的性能略优于 ResMRGCN。

网络深度的影响。表 6 中的结果表明，如果使用残差或密集图连接，增加层数会提高网络性能。尽管当层数达到 112 时，ResMRGCN 的性能略有下降，但其 m-F1 分数仍远高于相应的 PlainMRGCN。DenseMRGCN 的性能随着网络深度的增加而可靠地提升；然而，由于特征图的拼接，DenseMRGCN 比 ResMRGCN 更消耗内存。由于内存问题，我们无法训练某些模型，并在表 6 中用“-”表示。同时，没有图连接的 PlainMRGCN，随着网络深度从 3 层增加到 14 层，性能仅略有提升。对于超过 14 层的深度，性能则显著下降。显然，使用图连接能提升性能，对于更深的网络而言，这一点尤为重要。

网络宽度的影响。表 6 中每一行的结果均表明，增加滤波器的数量能够持续提升性能。更多的滤波器数量还有助于较深网络的收敛。然而，滤波器数量过多会非常消耗内存。因此，在我们的实验中，仅考虑最多 256 个滤波器的网络。

GCN 变体的效果。表 7 展示了使用不同 GCN 操作符且模型深度不同时的效果。当层数保持不变时，残差图连接和 GCN 操作符是唯一的不同之处。结果清楚地表明，残差图连接在




图 9.不同 GCN 模型在 PPI 节点分类中的内存使用情况。我们对不同模型使用相同的参数,并比较它们的 m-F1 分数和总内存使用量。所有参与比较的模型每层都有 256 个滤波器,且有 56 层。我们注意到,我们的模型 ResMRGCN 所使用的内存约为 ResEdgeConv 的 1/6,且 m-F1 分数更高。

深度网络能够帮助不同的 GCN 操作符取得比 PlainGCN 更好的性能。有趣的是,当网络加深时,PlainSemiGCN、PlainGAT 和 PlainGIN 的性能急剧下降;与此同时,PlainEdgeConv 和 PlainMRGCN 的性能仅出现相对较小的下降。相比之下,我们提出的 MRGCN 操作符在所有模型中取得了最佳性能。

GCN 变体的内存使用情况。在图 9 中,我们比较了不同 GCN 操作符的总内存使用量和性能。所有这些模型除了 GCN 操作之外,架构都相同。它们都使用具有 56 层和 256 个滤波器的残差图连接。我们使用 PyTorch Geometric 实现了所有模型,并使用一块 NVIDIA Tesla V100 对每个模型进行训练。GPU 内存使用量是在内存使用稳定时测量的。我们提出的 ResMRGCN 实现了最佳性能,而其 GPU 内存使用量仅约为 ResEdgeConv 的 15%。

与最先进的方法的比较。最后,我们在表 8 中将我们的 DenseMRGCN-14 和 ResMRGCN-28 与几个最先进的基线方法进行了比较。结果清楚地表明,具有残差和密集图连接的更深模型是有效的。DenseMRGCN-14 和 ResMRGCN-28 分别比之前的最先进的 Cluster-GCN [69] 高出 0.07 和 0.05 个百分点。值得一提的是,表 6 中总共有十个模型超过了 Cluster-GCN。

6 结论

这项工作展示了如何将卷积神经网络 (CNN) 中经过验证的概念 (例如残差/密集连接和扩张卷积) 转移到图卷积网络 (GCN) 中,从而使 GCN 能够像 CNN 一样实现更深的网络结构。在 GCN 中添加跳跃连接和扩张卷积可缓解训练难度,这曾是阻碍 GCN 向更深发展并进而阻碍其进步的因素。在 3D 点云的语义分割和部件分割以及生物图的节点分类方面进行的大量实验表明,更深的架构具有优势,因为它们达到了最先进的水平。

表 8

DenseMRGCN-14 与最新技术在 PPI 节点分类上的比较

模型	m-F1 分数 (%)
GraphSAGE[42]	61.20
GATConv [43]	97.30
VR-GCN [70]	97.80
氯化镓 [71]	98.71
GeniePath [72]	98.50
Cluster-GCN [69]	99.36
ResMRGCN-28 (我们的)	99.41
密集型 MRGCN-14 (我们的成果)	99.43

我们遵循惯例,根据 m-F1 分数来比较模型。我们的模型 DenseMRGCN-14,它有 14 个 MRGCN 层,第一层有 256 个滤波器,并且具有密集图连接,其表现优于所有基线模型。我们的 ResMRGCN-28,它有 28 个 MRGCN 层,每层有 256 个滤波器,并且具有残差图连接,其性能也优于之前的最先进水平。

艺术表演。我们还表明,我们的方法适用于多种图卷积神经网络 (GCN) 操作符。

对于点云任务,我们使用 EdgeConv [73] 作为骨干网络的 GCN 操作符,取得了最佳效果。此外,我们发现扩张图卷积有助于获得更大的感受野,同时不会损失分辨率。即使最近邻数量较少,DeepGCNs 在点云语义分割任务上也能取得高精度。ResGCN-112 和 ResGCN-56 在该任务上表现非常出色,尽管它们分别只使用了 4 个和 8 个最近邻,而 ResGCN-28 使用了 16 个。对于生物图任务,我们使用 MRGCN 操作符取得了最佳效果,这是我们在 EdgeConv 基础上提出的一种新颖且内存高效的替代方案。我们成功训练了 ResMRGCN-112 和 DenseMRGCN-56,这两个网络都收敛良好,并在 PPI 数据集上取得了非常有前景的结果。

7 未来工作

我们的研究结果表明,在解决了困扰深度图卷积神经网络 (GCN) 的梯度消失问题之后,我们可以通过增加 GCN 的深度或宽度来获得更好的性能。我们期望 GCN 能够成为处理计算机视觉、自然语言处理和数据挖掘中图结构数据的强大工具。我们展示了将卷积神经网络 (CNN) 中的概念 (例如跳跃连接和膨胀卷积) 成功应用于 GCN 的案例。未来,探索如何将其他操作符 (例如可变形卷积[74])、其他架构 (例如特征金字塔架构[75]) 等转移到 GCN 中将是值得的。研究不同的距离度量来计算膨胀 k 近邻、在每一层构建具有不同 k 值的图、GCN 的更优膨胀率调度[73]、[76]以及结合残差和密集连接也将是有趣的。

我们还指出,对于点云语义分割这一特定任务而言,通常采用的以 1 米 1 米列表形式处理数据的方法对于图表示而言并非最优。采用更合适的采样方法应当能在此任务上带来进一步的性能提升。对于节点分类任务,现有的数据集相对而言

规模较小。我们预计在更大规模的数据集上进行实验将进一步释放 DeepGCNs 的全部潜力。

致谢

作者们要感谢阿德尔·比比和哈尼·伊塔尼对本项目提供的帮助。本研究得到了沙特阿卜杜拉国王科技大学 (KAUST) 研究资助办公室通过视觉计算中心 (VCC) 提供的资金支持。李国豪、马蒂亚斯·穆勒和钱国成对本研究的贡献相同。

参考文献

- [1] L. Tang and H. Liu, "Relational learning via latent social dimensions," in Proc. 15th ACM SIGKDD Int. Conf. Knowl. Discov. Data Mining, 2009, pp. 817–826.
- [2] M. Zitnik and J. Leskovec, "Predicting multicellular function through multi-layer tissue networks," *Bioinformatics*, vol. 33, no. 14, pp. i190–i198, 2017.
- [3] N. Wale, I. A. Watson, and G. Karypis, "Comparison of descriptor spaces for chemical compound retrieval and classification," *Knowl. Inf. Syst.*, vol. 14, no. 3, pp. 347–375, 2008.
- [4] F. Monti, M. Bronstein, and X. Bresson, "Geometric matrix completion with recurrent multi-graph neural networks," in Proc. Int. Conf. Neural Inf. Process. Syst., 2017, pp. 3697–3707.
- [5] R. Ying, R. He, K. Chen, P. Eksombatchai, W. L. Hamilton, and J. Leskovec, "Graph convolutional neural networks for web-scale recommender systems," in Proc. 24th ACM SIGKDD Int. Conf. Knowl. Discov. Data Mining, 2018, pp. 974–983.
- [6] Y. Wang, Y. Sun, Z. Liu, S. E. Sarma, M. M. Bronstein, and J. M. Solomon, "Dynamic graph CNN for learning on point clouds," *ACM Trans. Graph.*, vol. 38, no. 5, Oct. 2019, Art. no. 146.
- [7] Q. Li, Z. Han, and X.-M. Wu, "Deeper insights into graph convolutional networks for semi-supervised learning," in Proc. 32nd AAAI Conf. Artif. Intell., 2018, pp. 3538–3545.
- [8] Z. Wu, S. Pan, F. Chen, G. Long, C. Zhang, and P. S. Yu, "A comprehensive survey on graph neural networks," *IEEE Trans. Neural Netw. Learn. Syst.*, vol. 32, no. 1, pp. 4–24, 2021, doi: [10.1109/TNNLS.2020.2978386](https://doi.org/10.1109/TNNLS.2020.2978386).
- [9] J. Zhou, G. Cui, Z. Zhang, C. Yang, Z. Liu, and M. Sun, "Graph neural networks: A review of methods and applications," *AI Open*, vol. 1, pp. 57–81, 2020. [Online]. Available: <https://doi.org/10.1016/j.aiopen.2021.01.001>
- [10] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit., 2016, pp. 770–778.
- [11] G. Huang, Z. Liu, L. Van Der Maaten, and K. Q. Weinberger, "Densely connected convolutional networks," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit., 2017, pp. 4700–4708.
- [12] F. Yu and V. Koltun, "Multi-scale context aggregation by dilated convolutions," in Proc. Int. Conf. Learn. Representations, 2016.
- [13] I. Armeni, S. Sax, A. R. Zamir, and S. Savarese, "Joint 2D-3D-Semantic data for indoor scene understanding," 2017, ArXiv e-prints.
- [14] K. Mo et al., "PartNet: A large-scale benchmark for fine-grained and hierarchical part-level 3D object understanding," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit., 2019, pp. 909–918.
- [15] G. Li, M. Müller, A. Thabet, and B. Ghanem, "DeepGCNs: Can GCNs go as deep as CNNs?," in Proc. IEEE Int. Conf. Comput. Vis., 2019, pp. 9266–9275.
- [16] J. Bastings, I. Titov, W. Aziz, D. Marcheggiani, and K. Simaan, "Graph convolutional encoders for syntax-aware neural machine translation," in Proc. Conf. Empir. Methods Natural Lang. Process., 2017, pp. 1957–1967.
- [17] D. Marcheggiani and I. Titov, "Encoding sentences with graph convolutional networks for semantic role labeling," in Proc. Conf. Empir. Methods Natural Lang. Process., 2017, pp. 1506–1515.
- [18] X. Qi, R. Liao, J. Jia, S. Fidler, and R. Urtasun, "3D graph neural networks for RGBD semantic segmentation," in Proc. IEEE Int. Conf. Comput. Vis., 2017, pp. 5209–5218.
- [19] D. Xu, Y. Zhu, C. B. Choy, and L. Fei-Fei, "Scene graph generation by iterative message passing," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit., 2017, pp. 3097–3106.
- [20] J. Yang, J. Lu, S. Lee, D. Batra, and D. Parikh, "Graph R-CNN for scene graph generation," in Proc. Eur. Conf. Comput. Vis., 2018, pp. 670–685.
- [21] Y. Li, W. Ouyang, B. Zhou, J. Shi, C. Zhang, and X. Wang, "Factorizable net: An efficient subgraph-based framework for scene graph generation," in Proc. Eur. Conf. Comput. Vis., 2018, pp. 335–351.
- [22] J. Johnson, A. Gupta, and L. Fei-Fei, "Image generation from scene graphs," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit., 2018, pp. 1219–1228.
- [23] S. Yan, Y. Xiong, and D. Lin, "Spatial temporal graph convolutional networks for skeleton-based action recognition," in Proc. 32nd AAAI Conf. Artif. Intell., 2018, pp. 7444–7452.
- [24] A. Jain, A. R. Zamir, S. Savarese, and A. Saxena, "Structural-RNN: Deep learning on spatio-temporal graphs," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit., 2016, pp. 5308–5317.
- [25] H. Su, S. Maji, E. Kalogerakis, and E. Learned-Miller, "Multi-view convolutional neural networks for 3D shape recognition," in Proc. IEEE Int. Conf. Comput. Vis., 2015, pp. 945–953.
- [26] J. Guerry, A. Boulch, B. Le Saux, J. Moras, A. Plyer, and D. Filliat, "SnapNet-R: Consistent 3D multi-view semantic labeling for robotics," in Proc. IEEE Int. Conf. Comput. Vis. Workshops, 2017, pp. 669–678.
- [27] A. Boulch, B. Le Saux, and N. Audebert, "Unstructured point cloud semantic labeling using deep segmentation networks," in Proc. Workshop 3D Object Retrieval, 2017, pp. 17–24.
- [28] Z. Li, Y. Gan, X. Liang, Y. Yu, H. Cheng, and L. Lin, "LSTM-CF: Unifying context modeling and fusion with LSTMs for RGB-D scene labeling," in Proc. Eur. Conf. Comput. Vis., 2016, pp. 541–557.
- [29] A. Dai, A. X. Chang, M. Savva, M. Halber, T. A. Funkhouser, and M. Nießner, "ScanNet: Richly-annotated 3D reconstructions of indoor scenes," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit., 2017, Art. no. 10.
- [30] C. R. Qi, H. Su, M. Nießner, A. Dai, M. Yan, and L. J. Guibas, "Volumetric and multi-view CNNs for object classification on 3D data," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit., 2016, pp. 5648–5656.
- [31] G. Riegler, A. O. Ulusoy, and A. Geiger, "OctNet: Learning deep 3D representations at high resolutions," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit., 2017, pp. 6620–6629.
- [32] L. Tchapmi, C. Choy, I. Armeni, J. Gwak, and S. Savarese, "SEGCloud: Semantic segmentation of 3D point clouds," in Proc. Int. Conf. 3D Vis., 2017, pp. 537–547.
- [33] R. Q. Charles, H. Su, M. Kaichun, and L. J. Guibas, "PointNet: Deep learning on point sets for 3D classification and segmentation," in Proc. Comput. Vis. Pattern Recognit., 2017, pp. 77–85.
- [34] C. R. Qi, L. Yi, H. Su, and L. J. Guibas, "PointNet++: Deep hierarchical feature learning on point sets in a metric space," in Proc. Int. Conf. Neural Inf. Process. Syst., 2017, pp. 5099–5108.
- [35] F. Engelmann, T. Kontogianni, A. Hermans, and B. Leibe, "Exploring spatial context for 3D semantic segmentation of point clouds," in Proc. IEEE Int. Conf. Comput. Vis., 2017, pp. 716–724.
- [36] Q. Huang, W. Wang, and U. Neumann, "Recurrent slice networks for 3D segmentation of point clouds," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit., 2018, pp. 2626–2635.
- [37] X. Ye, J. Li, H. Huang, L. Du, and X. Zhang, "3D recurrent neural networks with context fusion for point cloud semantic segmentation," in Proc. Eur. Conf. Comput. Vis., 2018, pp. 415–430.
- [38] T. N. Kipf and M. Welling, "Semi-supervised classification with graph convolutional networks," in Proc. 5th Int. Conf. Learn. Representations, 2017.
- [39] T. Pham, T. Tran, D. Phung, and S. Venkatesh, "Column networks for collective classification," in Proc. 31st AAAI Conf. Artif. Intell., 2017, pp. 2485–2491.
- [40] A. Rahimi, T. Cohn, and T. Baldwin, "Semi-supervised user geolocation via graph convolutional networks," in Proc. 56th Annu. Meeting Assoc. Comput. Linguistics, 2018, vol. 1, pp. 2009–2019, doi: [10.18653/v1/P18-1187](https://doi.org/10.18653/v1/P18-1187).
- [41] K. Xu, C. Li, Y. Tian, T. Sonobe, K.-I. Kawarabayashi, and S. Jegelka, "Representation learning on graphs with jumping knowledge networks," in Proc. 35th Int. Conf. Mach. Learn., 2018, vol. 80, pp. 5453–5462.
- [42] W. Hamilton, Z. Ying, and J. Leskovec, "Inductive representation learning on large graphs," in Proc. Int. Conf. Neural Inf. Process. Syst., 2017, pp. 1024–1034.

- [43] P. Velickovic, G. Cucurull, A. Casanova, A. Romero, P. Lio, and Y. Bengio, "Graph attention networks," in *Proc. Int. Conf. Learn. Representations*, 2018.
- [44] N. Peng, H. Poon, C. Quirk, K. Toutanova, and W.-T. Yih, "Cross-sentence N-ary relation extraction with graph LSTMs," *Trans. Assoc. Comput. Linguistics*, vol. 5, pp. 101–115, 2017.
- [45] D. K. Duvenaud et al., "Convolutional networks on graphs for learning molecular fingerprints," in *Proc. Int. Conf. Neural Inf. Process. Syst.*, 2015, pp. 2224–2232.
- [46] Y. Li, R. Zemel, M. Brockschmidt, and D. Tarlow, "Gated graph sequence neural networks," in *Proc. Int. Conf. Learn. Representations*, 2016.
- [47] S. Ioffe and C. Szegedy, "Batch normalization: Accelerating deep network training by reducing internal covariate shift," in *Proc. 32nd Int. Conf. Mach. Learn.*, 2015, vol. 37, pp. 448–456.
- [48] M. Simonovsky and N. Komodakis, "Dynamic edge-conditioned filters in convolutional neural networks on graphs," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2017, pp. 3693–3702.
- [49] D. Valsesia, G. Fracastoro, and E. Magli, "Learning localized generative models for 3D point clouds via graph convolution," in *Proc. Int. Conf. Learn. Representations*, 2019.
- [50] M. Holschneider, R. Kronland-Martinet, J. Morlet, and P. Tchamitchian, "A real-time algorithm for signal analysis with the help of the wavelet transform," in *Wavelets*. Berlin, Germany: Springer, 1990, pp. 286–297.
- [51] M. J. Shensa, "The discrete wavelet transform: Wedding the a trous and Mallat algorithms," *IEEE Trans. Signal Process.*, vol. 40, no. 10, pp. 2464–2482, Oct. 1992.
- [52] K. Xu, W. Hu, J. Leskovec, and S. Jegelka, "How powerful are graph neural networks?" in *Proc. Int. Conf. Learn. Representations*, 2019.
- [53] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional networks for biomedical image segmentation," in *Proc. Int. Conf. Med. Image Comput. Comput.-Assisted Intervention*, 2015, pp. 234–241.
- [54] Q. Hu et al., "RandLA-Net: Efficient semantic segmentation of large-scale point clouds," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2020, pp. 11 105–11 114.
- [55] H. Thomas, C. R. Qi, J.-E. Deschaud, B. Marcotegui, F. Goulette, and L. J. Guibas, "KPConv: Flexible and deformable convolution for point clouds," in *Proc. IEEE/CVF Int. Conf. Comput. Vis.*, 2019, pp. 6410–6419.
- [56] K. Zhou, X. Huang, Y. Li, D. Zha, R. Chen, and X. Hu, "Towards deeper graph neural networks with differentiable group normalization," in *Adv. Neural Inform. Process. Syst.*, vol. 33, pp. 4917–4928, 2020.
- [57] E.-T. Le, I. Kokkinos, and N. Mitra, "Going deeper with lean point networks," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2020, pp. 9500–9509.
- [58] Z. Zhang, B.-S. Hua, and S.-K. Yeung, "ShellNet: Efficient point cloud convolutional neural networks using concentric shells statistics," in *Proc. IEEE/CVF Int. Conf. Comput. Vis.*, 2019, pp. 1607–1616.
- [59] Y. Xu, T. Fan, M. Xu, L. Zeng, and Y. Qiao, "SpiderCNN: Deep learning on point sets with parameterized convolutional filters," in *Proc. Eur. Conf. Comput. Vis.*, 2018.
- [60] Y. Li, R. Bu, M. Sun, W. Wu, X. Di, and B. Chen, "PointCNN: Convolution on X-transformed points," in *Proc. 32nd Int. Conf. Neural Inf. Process. Syst.*, 2018, pp. 828–838.
- [61] Z. Liu, H. Hu, Y. Cao, Z. Zhang, and X. Tong, "A closer look at local aggregation operators in point cloud analysis," in *Proc. Eur. Conf. Comput. Vis.*, 2020, pp. 326–342.
- [62] Y. Ben-Shabat, M. Lindenbaum, and A. Fischer, "3DmFV: Three-dimensional point cloud classification in real-time using convolutional neural networks," *IEEE Robot. Autom. Lett.*, vol. 3, no. 4, pp. 3145–3152, Oct. 2018.
- [63] J. Li, B. M. Chen, and G. H. Lee, "SO-Net: Self-organizing network for point cloud analysis," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2018, pp. 9397–9406.
- [64] M. Atzmon, H. Maron, and Y. Lipman, "Point convolutional neural networks by extension operators," *ACM Trans. Graph.*, vol. 37, pp. 1–12, 2018.
- [65] C. Wang, B. Samari, and K. Siddiqi, "Local spectral graph convolution for point set feature learning," in *Proc. Eur. Conf. Comput. Vis.*, 2018, pp. 56–71.
- [66] P. Hermosilla, T. Ritschel, P.-P. Vazquez, A. Vinacua, and T. Ropinski, "Monte Carlo convolution for learning on non-uniformly sampled point clouds," *ACM Trans. Graph.*, vol. 37, pp. 1–12, 2018.
- [67] F. Groh, P. Wieschollek, and H. P. A. Lensch, "Flex-convolution -million-scale point-cloud learning beyond grid-worlds," in *Proc. 14th Asian Conf. Comput. Vis.*, 2018, pp. 105–122.
- [68] M. Fey and J. E. Lenssen, "Fast graph representation learning with PyTorch Geometric," 2019, arXiv:1903.02428.
- [69] W.-L. Chiang, X. Liu, S. Si, Y. Li, S. Bengio, and C.-J. Hsieh, "ClusterGCN: An efficient algorithm for training deep and large graph convolutional networks," in *Proc. 25th ACM SIGKDD Int. Conf. Knowl. Discovery Data Mining*, 2019, pp. 257–266, doi: [10.1145/3292500.3330925](https://doi.org/10.1145/3292500.3330925).
- [70] J. Chen, J. Zhu, and L. Song, "Stochastic training of graph convolutional networks with variance reduction," in *Proc. 35th Int. Conf. Mach. Learn.*, 2018, vol. 80, pp. 942–950.
- [71] J. Zhang, X. Shi, J. Xie, H. Ma, I. King, and D.-Y. Yeung, "GaAN: Gated attention networks for learning on large and spatiotemporal graphs," in *Proc. Conf. Uncertainty Artif. Intell.*, 2018.
- [72] Z. Liu et al., "GeniePath: Graph neural networks with adaptive receptive paths," in *Proc. AAAI Conf. Artif. Intell.*, 2019, pp. 4424–4431.
- [73] P. Wang et al., "Understanding convolution for semantic segmentation," in *Proc. IEEE Winter Conf. Appl. Comput. Vis.*, 2018, pp. 1451–1460.
- [74] J. Dai et al., "Deformable convolutional networks," in *Proc. IEEE Int. Conf. Comput. Vis.*, 2017, pp. 764–773.
- [75] H. Zhao, J. Shi, X. Qi, X. Wang, and J. Jia, "Pyramid scene parsing network," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2017, pp. 2881–2890.
- [76] L.-C. Chen, G. Papandreou, F. Schroff, and H. Adam, "Rethinking atrous convolution for semantic image segmentation," 2017, arXiv: 1706.05587.



李国豪于 2015 年在中国哈尔滨工业大学获得通信工程学士学位，2018 年在中国北京的中国科学院获得通信与信息系统硕士学位。目前，他在沙特阿拉伯图瓦勒的阿卜杜拉国王科技大学攻读计算机科学博士学位。他曾是商汤科技的研究实习生。他的主要研究兴趣包括计算机视觉、机器人技术和深度学习。



危翰平于 2019 年在沙特阿拉伯图瓦勒的阿卜杜拉国王科技大学获得计算机视觉博士学位。目前，他在英特尔智能系统实验室担任研究科学家。他的研究兴趣在于计算机视觉、机器人技术和机器学习领域，在顶级会议和期刊上发表了十多篇论文。他因在 CVPR'18 会议上的出色评审工作而获得认可，并在 ECCV'18 的 UAvision 工作坊上获得了最佳论文奖。



钱国成于 2018 年在中国西安的西安交通大学获得工学学士学位（一等奖）。目前，他在沙特阿拉伯图瓦勒的阿卜杜拉国王科技大学计算机科学攻读硕士学位。他的研究兴趣包括计算机视觉、计算摄影和神经网络架构搜索。



伊泽尔·C·德尔加迪洛于 2019 年在墨西哥泛美大学获得人工智能学士学位。她目前是沙特阿卜杜拉国王科技大学的访问学生研究实习生。她的研究兴趣包括计算机视觉和神经架构搜索。



阿卜杜勒拉赫曼·阿布阿尔舒尔于 2018 年在新泽西州新不伦瑞克的罗格斯大学（新泽西州立大学）获得计算机科学学士学位。目前，他正在攻读硕士学位，并且是沙特阿拉伯图瓦尔阿卜杜拉国王科技大学视觉计算中心图像与视频理解实验室（IVUL）的一员。他曾获得阿卜杜拉国王科技大学英才学生计划（KGSP）奖学金。他的研究兴趣包括计算机视觉和深度学习。



阿里·塔贝特目前是沙特阿卜杜拉国王科技大学（KAUST）视觉计算中心（VCC）图像与视频理解实验室（IVUL）的研究科学家。他的研究兴趣包括与三维计算机视觉相关的问题。总的来说，他对机器学习的算法应用，尤其是深度学习在诸如 RGB-D 相机、激光雷达等传感器的帮助下理解三维世界感兴趣。此外，他还对将深度学习应用于图像重建、三维物体检测与生成以及自动驾驶汽车等领域感兴趣。



伯纳德·加内姆目前是沙特阿卜杜拉国王科技大学（KAUST）计算机、电气与数学科学部的副教授，视觉计算中心（VCC）的主题负责人，以及该校人工智能计划的临时负责人。他的研究兴趣包括计算机视觉和机器学习，重点研究视频理解、三维识别以及深度学习的理论基础等课题。他于 2005 年获得贝鲁特美国大学（AUB）学士学位，并在（此处原文缺失，未给出其硕士和博士学位的授予院校）获得了硕士和博士学位。

2010 年毕业于伊利诺伊大学厄巴纳 - 香槟分校（UIUC）。他的工作获得了多项奖项和荣誉，包括 2013 年和 2019 年 CVPR 以及 2018 年和 2020 年 ECCV 的四个最佳论文奖，2015 年谷歌研究奖（中东和北非地区机器感知领域首位获奖者），以及 2020 年阿卜杜勒·哈米德·舒曼阿拉伯大数据与机器学习研究奖。他在其领域共发表 120 多篇同行评审的会议和期刊论文，并拥有三项已授权专利。他是《IEEE 模式分析与机器智能汇刊》（TPAMI）的副主编，并曾担任 CVPR 2018/2021、ICCV 2019/2021、ICLR 2021 和 AAAI 2021 的领域主席（AC）。

欲了解有关此主题或任何其他计算机技术主题的更多信息，请访问我们的数字图书馆：www.computer.org/csdl。