

数据和文本挖掘

DTI-Voodoo：基于交互网络和基于本体的背景知识的机器学习预测药物-靶点相互作用

Tilman Hinnerichs* and Robert Hoehndorf



沙特阿拉伯图瓦尔市沙特阿卜杜拉国王科技大学 4700 号，沙特阿卜杜拉国王科技大学计算机、电气与数学科学与工程学部计算生物科学研究中心，邮编 2395

*请将信件寄往此处。副主编：乔纳森·雷恩

收稿日期：2021 年 4 月 28 日；修改日期：2021 年 7 月 14 日；编辑部决定日期：2021 年 7 月 23 日；接受日期：2021 年 7 月 26 日

摘要

动机：药物 - 靶点相互作用（DTI）的计算机模拟预测对于药物发现和药物再利用至关重要。预测 DTI 的方法可以间接进行，自上而下，利用药物的表型效应来识别潜在的靶点；也可以直接进行，自下而上，利用分子信息直接预测结合亲和力。这两种方法都可以与相互作用网络的信息相结合。

结果：我们开发了 DTI-Voodoo 这种计算方法，它将药物的分子特征和本体编码的表型效应与蛋白质 - 蛋白质相互作用网络相结合，并使用图卷积神经网络来预测药物 - 蛋白质相互作用（DTI）。我们证明了药物效应特征能够利用相互作用网络中的信息，而分子特征则不能。DTI-Voodoo 被设计用于预测给定蛋白质的候选药物；我们使用这种形式来表明常见的 DTI 数据集存在内在偏差，这对 DTI 预测方法的性能评估和比较产生了重大影响。通过使用改进的评估方案，我们证明 DTI-Voodoo 相较于现有的 DTI 预测方法有了显著提升。

可用性和实现：可在 <https://github.com/THinnerichs/DTI-VOODOO> 免费获取 DTI-Voodoo 源代码以及重现结果所需的数据。

联系人：tilman.hinnerichs@kaust.edu.sa

补充信息：[补充数据](#)可在《生物信息学》在线获取。

1 简介

识别药物与靶点的相互作用（DTIs）是药物研发中的关键步骤；为已获批药物寻找新的靶点相互作用可用于药物再利用，即为已知靶点寻找新药，或者为疾病过程中的新靶点寻找药物。推断药物与其靶点之间的相互作用有助于分析和识别潜在的预期或不良药物作用以及理想的治疗效果。虽然体外 DTI 预测耗时较长，但计算的计算机模拟 DTI 预测器能够在短时间内筛选数百万种相互作用。因此，通过计算确定 DTIs 可以帮助降低药物开发的成本和风险。

计算方法被广泛应用于预测药物 - 靶点相互作用（DTIs），并且已经开发出了许多计算方法。这些方法大致可以分为“自上而下”和“自下而上”两种方法。自上而下的方法从药物 - 靶点相互作用所产生的可观察特征（如副作用或药物治疗的疾病）入手，利用

这些观察结果推断可能的分子机制（即相互作用）。自下而上的方法从分子特征（如药物和蛋白质的分子结构或指纹）入手，并根据这些信息预测相互作用。

无论是自下而上还是自上而下的药物-靶点相互作用（DTI）预测方法，都各有其优势和局限性。通常来说，自下而上的方法面临这样一个挑战：即根据分子特性来预测某种化学结构是否能与蛋白质结合；而两种实体是否相互作用不仅取决于实体的分子结构（其中需要确定结合位点和分子力才能进行准确预测），还取决于诸如蛋白质在哪些细胞类型和解剖结构中表达等特性。自上而下的方法则利用药物的生理效应信息来进行 DTI 预测，例如副作用相似性（Campillos 等人，2008 年），这在很大程度上是对从分子特性中获得的知识的补充。虽然依赖分子信息的方法直接预测两种分子是否可能相互作用，但自上而下的方法则基于更间接的手段，从相互作用产生的可观察效应来推断 DTI。

这两种方法均可与网络推断结合使用 (Chen 等人, 2016 年)。用于药物-靶点相互作用预测的生物网络包括蛋白质-蛋白质相互作用网络 (Feng 等人, 2017 年; Lee 和 Nam, 2018 年) 以及包含其他多种生物关系的网络, 包括所表示实体之间的相似性 (Ding 等人, 2014 年; Gottlieb 等人, 2011 年)。基于网络的药物-靶点相互作用预测方法采用“连坐”原则 (Oliver, 2000 年), 并假定如果药物的许多邻接蛋白质在相互作用网络中是该药物的靶点, 那么该蛋白质也很可能是该药物的靶点 (Gillis 和 Pavlidis, 2012 年)。基于网络的方法已成功应用于药物-靶点相互作用预测。然而, 如果将药物-靶点相互作用视为药物与蛋白质之间的直接物理相互作用, 那么基于网络的“连坐”假设是否成立, 或者药物与蛋白质的相互作用是否扰乱了蛋白质的多个相互作用伙伴, 从而导致并非直接相互作用而是相互作用的下游效应, 这仍然是一个未解决的问题。

利用图神经网络在机器学习方面取得的进展, 我们可以检验这一假设, 并在一个单一的机器学习模型中将自下而上和自上而下的特征结合起来。特别是, 图卷积网络 (Kipf 和 Welling, 2016) 及其变体可以在不同类型的核上运行 (Bianchi 等人, 2019; Defferrard 等人, 2016), 包括注意力机制 (Veličković 等人, 2017), 以及探索节点邻域的不同形式 (Hamilton 等人, 2017; Klicpera 等人, 2018), 能够将不同类型的特征和基于图的信息结合起来。它们此前已被应用于多种任务, 包括蛋白质功能预测 (Zitnik 和 Leskovec, 2017)、癌症药物反应 (Liu 等人, 2020) 以及药物-靶点亲和力预测 (Nguyen 等人, 2020)。

潜在的数据集偏差 (Pahikkala 等人, 2015 年) 可能会影响模型评估和比较, 这给药物靶点相互作用 (DTI) 预测带来了挑战。首先, 新药通常是通过改变药物的非功能成分来开发的, 从而导致针对相同蛋白质设计出两种或更多非常相似的药物 (Overington 等人, 2006 年)。这可能会导致偏差, 即隐藏的重叠项或高度相似的化合物分布在训练集和评估集中, 从而导致比模型应用于识别尚未有药物作用的蛋白质时预期更好的 (测量) 预测性能。其次, 某些蛋白质 (我们称之为枢纽蛋白) 与药物的已知相互作用比其他蛋白质多得多。在 STITCH 数据库中, 5% 的蛋白质具有 40% 的相互作用, 其他数据集也存在类似的分布 (Wishart 等人, 2007 年, 2017 年); 优先预测这些蛋白质可能会提高预测性能, 但并不能反映应用于新蛋白质 (即没有已知相互作用的蛋白质) 时的实际性能。针对某些蛋白质的药物数量存在差异, 这可能是研究偏差所致, 即由于某些“更有价值”的蛋白质与更常见疾病 (或药物) 可从中获取更高利润的疾病) 相关联, 因此针对这些蛋白质设计的药物更多。这可能会影响常见的评估方案, 因为有可能在药物-目标相互作用预测中利用这些偏差 (Wang 和 Kurgan, 2019)。van Laarhoven 和 Marchiori (2014) 表明, 在 Yamanishi 等人 (2008) 的数据集中存在多种可被利用的偏差。

我们开发了 DTI-Voodoo 作为预测药物-靶点相互作用 (DTIs) 的方法。我们采用基于本体论的机器学习方法 (Chen 等人, 2021 年) 对药物-靶点相互作用的表型后果进行编码, 并使用深度学习方法对分子特征进行编码。我们借助蛋白质相互作用网络将两者结合起来, 并借助图神经网络加以利用。我们使用此模型来测试分子特征或表型特征是否能从网络信息中获益, 结果发现只有表型特征能定位在图上, 而分子特征则不能。我们进一步评估并比较了 DTI-Voodoo 与几种药物-靶点相互作用预测方法, 并证明 DTI-Voodoo 在预测针对蛋白质的药物方面比现有技术有了显著的改进。我们还识别并描述了在训练和评估药物-靶点相互作用预测方法时存在的若干偏差, 并就如

何避免这些偏差提出了建议。DTI-Voodoo 作为免费软件可在 <https://github.com/THinnerichs/DTI-VOODOO> 获取。

2 材料与方法

2.1 问题描述

DTI-Voodoo 旨在解决以下问题: 对于给定的药物和给定的蛋白质, 我们想要确定它们是否相互作用。我们不区分诸如激活和抑制之类的相互作用类型, 也不预测相互作用的强度。我们将所有没有已知相互作用的药物-蛋白质对视为阴性, 因此将该问题表述为一个二分类任务。

2.2 数据集

我们从 STRING 数据库 (Szklarczyk 等人, 2014 年) 获取了一个包含 12884 种人类蛋白质及 340627 条关联链的数据集。对于药物-靶点相互作用 (DTIs), 我们使用了来自 STITCH 数据库 (Szklarczyk 等人, 2016 年) 的 229870 条关联链。由于 STRING 和 STITCH 都为每种关联提供了置信度评分, 我们按照建议的 700 分阈值对其进行过滤, 从而仅保留高置信度的相互作用。

我们使用了 PhenomeNET 本体 (Hoehndorf 等人, 2011 年), 这是一个整合了诸如人类表型本体 (Köhler 等人, 2018 年)、基因本体 (Ashburner 等人, 2000 年; Carbon 等人, 2020 年)、哺乳动物表型本体 (Smith 和 Eppig, 2009 年) 等本体的本体。我们从 SIDER (Kuhn 等人, 2016 年) 获取了副作用及其与药物的关联; SIDER 中的副作用使用来自 MedDRA 数据库 (Mozzicato, 2009 年) 的标识符进行编码。我们通过 Phenomebrowser.net 将副作用映射到 PhenomeNET 本体, 该网站为上述资源提供了 SPARQL 查询端点。整体结构见补充图 S1。

为了进行比较评估, 我们使用了由 Yamanishi 等人 (2008 年) 引入的黄金标准数据集, 其中包含 708 种药物与 1512 种蛋白质之间的 1923 种相互作用, 以及由 Zitnik 等人 (2018 年) 提出的 BioSnap 数据集, 该数据集包含 5017 个药物节点、2324 个基因节点和 15138 条边。

在我们的分析中, 仅使用在 STRING 中至少有一个链接或在 PhenomeNET 中至少有一个关联的蛋白质, 以及至少有一种副作用的药物。因此, 这些资源的交集产生了 1428 种药物和 7368 种人类蛋白质, 其中 STITCH 数据集包含 32212 种相互作用, Yamanishi 数据集包含 680 种药物与 1458 种蛋白质之间的 1837 种相互作用, BioSnap 数据集包含 949 种药物与 2221 种蛋白质之间的 6498 种关联。我们在 Github 代码库中提供了获取和处理所需数据的链接及方法。

2.3 模型

我们的模型结合了“自上而下”和“自下而上”的信息来进行药物靶点识别。当利用药物 (如药物作用) 或蛋白质 (如蛋白质功能或功能缺失导致的表型) 的可观察特征来提供有关分子机制的信息时, 我们认为这种方法是“自上而下”的; 当利用结构或其他分子信息来确定机制时, 我们认为这种方法是“自下而上”的。为了构建一种同时包含自上而下和自下而上特征的方法, 我们首先分别创建每种特征的模型。对于自下而上的模型, 我们使用来自 SmilesTransformer (Honda 等人, 2019 年) 的药物分子结构衍生特征以及来自 DeepGOPlus (Kulmanov 和 Hoehndorf, 2020 年) 的蛋白质分子特征。SmilesTransformer 是一个基于 SMILES 字符串训练的自动编码器, 因此能够以无监督的方式捕获 (药物分子组织的某些方面)。DeepGOPlus 提供了从蛋白质氨基酸序列衍生的特征, 这些特征有助于预测蛋白质功能。

由于表型和功能是通过本体论进行编码的，我们使用 DL2Vec (Chen 等人, 2021 年) 来获取基于本体论的表示，用作自上而下的特征。DL2Vec 通过为每个本体类引入节点以及为本体公理引入边来构建一个图，然后从图中的每个节点开始进行随机游走。这些游走使用 Word2vec (Mikolov 等人, 2013 年) 模型进行编码。因此，DL2Vec 生成的表示能够编码药物效应或蛋白质功能，同时保留它们在该图中的语义邻域。

2.3.1 半孪生神经网络与特征转换

由于我们希望从药物副作用与蛋白质表型的相似性中学习，因此我们使用了一个带有余弦相似度对比损失的深度半孪生神经网络。半孪生神经网络旨在学习两个维度可变的嵌入之间的相似性。由于原始特征空间的维度可能各不相同，我们首先使用全连接神经网络层对其进行处理，该层以嵌入为输入，并输出特定大小的表示，即我们使用此层作为可训练的特征转换，并分别应用于药物和蛋白质的嵌入以减小其表示大小。两种类型特征的示例结构可在补充图 S2 中找到。使用这种可训练的特征转换层能够进行灵活的实验，因为药物和蛋白质的本体论和分子特征都被转换为相同维度，从而可以适应不同大小的输入；这使得在不同的实验设置中具有很高的模块化程度，可以通过向模型添加不同类型的特征来实现。此外，生成的特征还可用于其他任务。我们遵循 DL2vec (Chen 等人, 2021 年) 的研究成果，采用 $r: \frac{1}{4}$ LeakyReLU 作为激活函数，这相较于其他激活函数能带来性能的提升。

2.3.2 图卷积层

我们将这些基于分子和本体论的子模型纳入图神经网络 (GNN) (Kipf 和 Welling, 2016)。GNN 所基于的图是基于蛋白质-蛋白质相互作用 (PPI) 图。PPI 数据集由图 $G = (V, E)$ 表示，其中每个蛋白质由顶点 $v \in V$ 表示，每条边 $e \in V \times V$ 表示两个蛋白质之间的相互作用。此外，我们引入映射 $x: V \rightarrow \mathbb{R}^d$ 为每个顶点 v 投影到其节点特征 $x(v)$ ，其中 d 表示节点特征的维度。

图卷积层 (Kipf 和 Welling, 2016) 由一个可学习的权重矩阵和随后的聚合步骤组成，形式化表示为

$$\mathbf{X}' = \hat{\mathbf{D}}^{-1/2} \hat{\mathbf{A}} \hat{\mathbf{D}}^{-1/2} \mathbf{X} \Theta \quad (1)$$

对于给定的图 $G = (V, E)$ ， $\mathbf{A} \in \mathbb{R}^{|V| \times |V|}$ 表示伴随矩阵

度矩阵 $\mathbf{D}$ 是通过在每个顶点处添加自环来描述的。

记作 $\mathbf{A}_{ii} = 1$ ，这是一个对角矩阵，展示了每个的度

节点， $\mathbf{H}$ 表示可学习的权重矩阵。添加的自环强制每个节点的表示直接依赖于其自身的前一个表示。图卷积层堆叠的数量等于图中每个顶点相关节点的半径。

每个节点的更新规则由一种消息传递方案给出，该方案由以下公式形式化表述：

$$\mathbf{x}'_i = \Theta \sum_j \frac{1}{\sqrt{d_i d_j}} \mathbf{x}_j \quad (2)$$

其中 d_i, d_j 均取决于图的边权重 e_{ij} 。对于简单的单值边权重，例如 $e_{ij} \in \{0, 1\}$ ，所有 d_i 都会简化为 d_i ，即每个顶点 i 的度。我们将这种类型的图卷积神经网络层表示为 GCNConv。

虽然在 GCNConv 的这种初始表述中，节点级的更新步骤是由所有相邻节点表示的总和来定义的，但我们可以通过这种表述将其修改为其他的消息传递方案。正如 Li 等人 (2020 年) 所提出的，我们可以

用这种表述重新排列激活函数 r 、聚合 AGG 和线性神经层 MLP 的顺序：

$$\mathbf{x}'_i = \text{MLP}(\mathbf{x}_i + \text{AGG}(\{\sigma(\mathbf{x}_j + \mathbf{e}_{ji}) + \epsilon : j \in \mathcal{N}(i)\})) \quad (3)$$

这里我们仅考虑 $r \in \{\text{ReLU}, \text{LeakyReLU}\}$ 。我们按照 PyTorch Geometric (Fey 和 Lenssen, 2019) 的记法将这种广义层类型表示为 GENConv。虽然重新排序主要对数值稳定性很重要，但这种改变也解决了深度卷积网络中的梯度消失问题 (Li 等人, 2020)。此外，我们还可以将聚合函数泛化，允许为每个顶点的输入信号使用不同的加权函数，例如可学习的 SoftMax 或 Power 函数，以替代 GCNConv 中的平均步骤。因此，尽管 GCNConv 在大规模和高度连接的图中会同时出现梯度消失和信号衰减的问题，但在 GENConv 中，每个传播步骤都会强调值接近 0 和 1 的信号。相同的卷积滤波器和权重矩阵会同时应用于所有节点并进行学习。我们还采用另一种机制来避免堆叠图卷积网络中的冗余和信号衰减，使用残差连接和归一化方案 (Li 等人, 2019, 2020)，如补充图 S3 所示。残差块是可复用的，并且可以多次堆叠。

2.3.3 组合预测模型

结合半孪生网络和图卷积神经网络，我们将所有蛋白质表示映射到各自的节点特征，初始化图卷积更新步骤。所得表示用于相似性预测。当将本体论和分子特征与或不与图模型结合时，我们先将两种蛋白质特征和两种药物特征进行拼接，然后再将其输入图模型进行相似性计算。结合两种特征类型的模型架构概述见补充图 S4。在此，原始表示通过一个密集层进行转换，然后作为具有 3 层高度的残差图卷积块堆栈的输入。

2.3.4 超参数调整

由于所考虑的药物和蛋白质的数量与药物靶点的数量相比稀少，因此训练、验证和测试数据集是不平衡的。由于所考虑的 STITCH 子集仅有 22,336 个链接，其比例

$$w := \frac{\text{drugs} \cdot \text{proteins}}{\text{dti}_{\text{links}}} \approx 360, \quad (4)$$

因此，在计算损失函数时需要合适的补偿，并采用恰当的指标进行评估。

因此，我们通过引入以下基于二元交叉熵的损失函数，用该比率对所有正的药物-蛋白质配对本进行加权：

$$l(x, y) = -w[y \cdot \log x + (1 - y) \cdot \log(1 - x)] \quad (5)$$

对于给定的预测值 x 和目标值 y ，以及由方程 (4) 定义的正权重 w 。我们在训练集中所有药物-蛋白质对之间对该损失取平均值，从而为 Adam 优化算法 (Kingma 和 Ba, 2015) 提供了一个稳定的环境。我们在蛋白质之间实施了 5 折交叉验证拆分。此外，在训练过程中我们还使用了提前停止法。

为了找到所提模型的最佳超参数配置，我们进行了网格搜索以找到最具表现力且无冗余的表示形式。我们分别对自下而上和自上而下的模型进行了预训练，并以我们的评估指标为依据，力求获得性能最佳的模型。我们通过广泛的、手动的网格搜索对嵌入大小、神经网络深度、优化器、学习率和层类型进行了优化。从嵌入大小为 10 的浅层特征变换开始，我们将网络扩展到具有多达 10 个隐藏层的残差结构，从而

将其映射到大小为 4000 的嵌入中，针对每种配置测试不同的网络宽度和学习率。

2.4 评估与指标

2.4.1 分割方案

由于药物 - 目标相互作用 (DTI) 预测同时依赖于药物和蛋白质，因此确定用于评估每个模型的训练集、验证集和测试集的配对方式有多种。对于交叉验证，我们可以在 DTI 配对、药物或蛋白质上分别进行划分；当在药物或蛋白质上进行划分时，将实体（药物或蛋白质）分开，并将其所有关联包含在划分中。只有在按蛋白质或药物划分时，才能保证在验证和测试阶段向模型展示未见过的实体。由于在训练和测试阶段已知的信息不同，因此不同划分方案得出的模型可能具有不同的表达能力和利用 DTI 预测中的不同信息。

2.4.2 指标

为了评估每个模型，我们计算了二分类中常见的多种指标。由于数据集严重不平衡，我们在训练集、验证集和测试集上使用了受试者工作特征曲线下的面积 (AUROC)。

我们通过在不同的假阳性率阈值下计算真阳性率来计算 AUROC，并使用梯形近似法来估计曲线下面积。我们将此度量称为宏平均 AUROC。

我们还计算了 MicroAUC 分数。对于给定的药物列表 D 和蛋白质列表 P 以及已知相互作用集 $Int: \frac{1}{4} f \delta d_i; p_i P g$ ，MicroAUC 被计算为每个实体的 AUROC 分数的平均值。例如，以蛋白质为中心的分数的形式化为：给定标签 $l: D \rightarrow \{0, 1\}$ 和预测 $y: P \rightarrow \{0, 1\}$ ，我们定义

$$\text{MicroAUC}_p(l, y) := \text{mean}_{p \in P} \left(\{ \text{AUROC}(\{l(d_i, p), y(d_i, p)\} | d_i \in D) \} \right)$$

在某些情况下，由于某些数据集中某些蛋白质或药物之间不存在相互作用，导致所有阈值下的真正例率 (TPR) 均为 0，从而使得该实体的 AUROC 得分未定义。由于这种情况在药物 - 蛋白质相互作用 (DTI) 数据集中相当常见，我们不会将其忽略，而是通过线性插值使用该子集的准确率来估算这些实体的 MicroAUC 得分。

$$\text{MicroAUC}_p(l, y) := \begin{cases} \text{MicroAUC}_p(l, y) & \text{if } \sum_{d_i \in D} l(d_i, p) \neq 0 \\ \text{Accuracy}(l, y) & \text{otherwise} \end{cases}$$

在这种配方中，药物和蛋白质可以相互替换。我们将不同的测量方法分别称为以蛋白质为中心的微 AUC (MicroAUC_p) 和以药物为中心的微 AUC (MicroAUC_d)。我们还在补充表 S1 中将 MicroAUC_p 与插补方法进行了比较，并将 MicroAUC_p^0 与未插补的未定义微 AUC 值（但省略这些值）进行了比较。

此外，我们选择曲线下面积 (AUROC) 而非其他指标（如精确率召回率曲线下的面积 (AUPRC)）作为主要指标来比较不同的方法；AUPRC 对数据不平衡较为敏感 (Jeni 等人, 2013 年)，因此在比较不同的 DTI 预测方法时应用起来更具挑战性。

3 结果

3.1 DTI-Voodoo：用于识别针对特定蛋白质的药物的计算模型

我们开发了 DTI-Voodoo 计算模型来预测药物-靶点相互作用 (DTIs)。具体来说，给定一种蛋白质，DTI-Voodoo 能够识别并排序可能作用于该蛋白质的药物。DTI-Voodoo 结合了两类特征：可用于确定药物与蛋白质是否发生物理相互作用的药物和蛋白质的结构信息，以及药物的表型效应信息和蛋白质功能变化信息，这些信息可能在相互作用网络中“定位”（即

相邻节点将共享其中一些特征或表型相似。作为结构特征，DTI-Voodoo 使用来自 SMILES 变换器 (Honda 等人, 2019 年) 的药物结构表示以及来自 DeepGOPlus (Kulmanov 和 Hoehndorf, 2020 年) 的蛋白质氨基酸序列表示。DTI-Voodoo 使用基于本体的机器学习方法 DL2Vec (Chen 等人, 2021 年) 和药物及蛋白质的基于本体的注释来学习药物作用和蛋白质功能的表示。

我们构建一个以蛋白质为节点、以蛋白质 - 蛋白质相互作用为边的图，将蛋白质特征映射到每个目标作为节点特征。DTI-Voodoo 然后利用图卷积步骤在 PPI 网络中传播信息，计算药物和蛋白质表示的相似度，并预测是否存在相互作用。完整的工作流程方案如图 1 所示。

我们采用不同的方法和数据集来评估模型识别药物靶点相互作用 (DTIs) 的能力。首先，我们对蛋白质进行交叉验证，并对结果进行验证。蛋白质交叉验证旨在评估模型在识别可能作用于“新”蛋白质（即训练期间未见过的蛋白质）的药物或预测针对特定蛋白质的药物方面的表现。

我们在 STITCH 数据集上使用基于蛋白质的 5 折交叉验证对所有考虑的模型进行了训练、验证和最终测试；然后，我们选择了表现最佳的模型（关于 MicroAUC_p ，见第 2.4.2 节），并在 Yamanishi 基准数据集上重新从头开始进行 5 折蛋白质分割交叉验证训练，以避免验证过拟合并获得更真实的测试结果。为了分别评估不同特征的影响，并确定它们是否“定位”在 PPI 图上（因此可以被图神经网络成功利用），我们分别训练和评估了具有不同类型特征的模型，以及包含和不包含 PPI 图的模型。我们比较了分子 (MolPred) 和基于表型 (OntoPred) 的预测模型，以及将这两种类型的特征进行拼接的组合模型。表 1 展示了这些实验的结果。

我们发现，在 STITCH 数据集上，使用基于本体论特征的模型 (OntoPred) 的表现优于仅使用分子特征的模型。我们还注意到，只有该模型




图 1. 基于预训练的可学习特征转换的完整 DTI 预测模型，该转换适用于分子结构或基于本体论的特征。转换后的蛋白质表示被添加到每个对应的蛋白质中，作为图卷积步骤的节点特征。

表 1. 在 STITCH 和 Yamanishi 数据集上使用 5 折交叉验证评估的 DTI-Voodoo 结果

DTI-Voodoo 结果	(a) STITCH 结果				(b) 山下研究结果			
	PPI 图表				PPI 图表			
	没有		和……在一起		没有		和……在一起	
	宏平均AUC	微型 AUC _p	宏平均AUC	微型 AUC _p	宏平均AUC	微 AUC	宏平均AUC	微型 AUC _p
MolPred	0.69	0.65	0.69	0.67	0.66	0.67	0.66	0.64
OntoPred	0.88	0.87	0.92	0.93	0.80	0.79	0.83	0.82
DTI-Voodoo (无需翻译, 这是0.89) 专有名词或产品名称	0.89	0.89	0.93	0.94	0.83	0.82	0.84	0.84

注意：我们称仅使用分子特征模型为 MolPred，仅使用基于本体论特征模型为 OntoPred。DTI-Voodoo 则结合了这两种类型的特征。

使用基于本体论的特征在结合 PPI 图时可提高性能。这种性能提升在不同的图神经网络架构和配置中均有体现 (补充表 S2)。尽管 GCNConv 和 GENConv 架构已显示出一些较小的改进，但使用 ResGraphConv 则带来了更大的性能提升。ResGraphConv 块为网络增加了大量额外的可学习参数，从而增强了表达能力。为了测试所观察到的改进是由于添加的可学习参数数量增加，还是更好地利用了 PPI 信息，我们实验了一种图模型，在该模型中，残差块中的所有图卷积神经层都被移除，从而得到一个参数数量相似但无法利用图信息的模型。这个经过修剪的网络，在没有蛋白质 - 蛋白质相互作用信息的情况下，其结果与原始的 OntoPred 模型非常相似，并且没有显示出任何改进 (补充表 S2)。在此，DTI-Voodoo 在 STITCH 数据集上显著优于 OntoPred (MacroAUC: t¼6.9, MicroAUC_p: t¼5.6) (单侧 t 检验)，并且在 Yamanishi 数据集上相对于 MicroAUC_p (P<10⁻²) 也有显著提升 (MacroAUC: t¼41.2, MicroAUC_p: t¼42.4)。

只有包含 ResGraphConv 块的 GENConv 图卷积方案在加入图结构时才能带来性能提升；即使结合了残差块，GCNConv 和其他图卷积方法与纯 OntoPred 的性能相比也没有任何提升。GENConv 与其他图卷积方法之间的差异可能是由于数值不稳定和信号衰减造成的 (Li 等人, 2020)。

我们的研究表明，在使用基于本体论的特征时，纳入图信息能够提升性能，但在仅使用分子特征时则不然。这一观察结果使我们得出结论：有关蛋白质功能的信息集中在图上，而分子特征则不具备这一特点。

我们进一步研究了在 STITCH 数据库中可用的特定相互作用类型 (抑制和激活) 上的性能。结果总结在补充表 S3 中；我们发现，在特定相互作用类型上的性能与未区分相互作用类型的完整数据集上的性能没有差异。

3.2 以蛋白质为中心的评估

DTI-Voodoo 的目标是找到针对特定蛋白质的候选药物；然而，到目前为止，我们并未评估这一应用，而是评估 DTI-Voodoo 在所有可能的相互作用中找到合理的药物-靶点相互作用 (DTI) 的能力 (因为我们使用 MacroAUC 作为主要评估指标)。这种评估并不对应于 DTI-Voodoo 在寻找针对特定蛋白质的药物方面的应用。为了更好地估计 DTI-Voodoo 在针对单个蛋白质靶点时的表现，我们计算蛋白质之间的微平均值并得出 MicroAUC (见 2.4.2 节)；确定 MicroAUC 时，我们是将每种蛋白质的性能 (真阳性率和假阳性率) 进行平均，而非对所有药物-蛋白质对进行平均；因此，这种衡量方式能够更好地

估计 DTI-Voodoo 在寻找针对特定蛋白质的药物时的表现。

此外，我们假设机器学习模型有可能利用药物-靶点相互作用 (DTI) 数据中的偏差，在未获取任何具有生物学意义的信号的情况下实现相对较高的预测性能。例如，枢纽蛋白可能具有大量的相互作用，或者某些药物与许多蛋白质相互作用，优先预测这些相互作用可能会提高预测性能，即便不存在任何生物学特征。为了验证这一假设，我们设计了一个“天真”的基线模型，该模型仅基于蛋白质已知的 DTI 数量为每种药物预测相同的蛋白质列表。具体而言，给定药物列表 D 和蛋白质列表 P 以及已知相互作用集 I: ¼ f (d_i; p_j)g, 我们构建一个相互作用矩阵 M_{int} 2 f0; 1g^{|D||P|}，其中

M_ij = { 1 if (d_i, p_j) ∈ I, 0 otherwise

对于所有药物 - 蛋白质组合，描述是否存在已知的相互作用。现在，我们将所有蛋白质按其药物相互作用者的数量降序排列，方法是对 M_{ij} 的列求和，然后对这些和进行排序：

f : P → N with f : p_j ↦ ∑_{i=1}^{|D|} M_ij

我们的“天真”预测器 P_k 预测所有药物都会与按照所引入的排名位列前 k 位的靶点发生相互作用：

P_k : D × P → {0, 1} with P_k : d_i, p_j ↦ { 1 if p_j ∈ Top_k(P), 0 otherwise

仅有一个超参数 k。

该预测 P_k 并不依赖于药物 d_i，对于所有蛋白质而言，它都会预测出相同的药物排名列表；因此，这种简单的预测器不依赖任何生物学特征，也不会预测出有关药物与蛋白质相互作用的任何新信息；这种简单的预测器只是利用评估集中存在的不平衡来进行预测，从而可能取得较好的效果。由于我们对这种简单预测器的设定方式，它不适用于蛋白质拆分交叉验证，因为在验证集中每个蛋白质的相互作用数量是未知的。

我们对 STITCH 和 Yamanishi 数据集都应用了这种朴素预测器，使用完整数据集以及针对药物和药物 - 蛋白质对的 5 折交叉验证，以便直接将预测结果与 DTI-Voodoo 进行比较。对于每个折次，我们逐步增加 k 值以确定每个折次的最佳性能。使用完整数据集、药物 - 蛋白质对拆分和药物拆分方案，我们获得了以下 MacroAUC 结果：对于 STITCH 数据库，整个数据集的性能为 0.76，药物 - 蛋白质对为 0.70，药物拆分方案为 0.73；对于 Yamanishi 数据集，总数据集、药物 - 蛋白质对和药物拆分方案的 MacroAUC 分别为 0.88、0.84 和 0.85。朴素预测器在 Yamanishi 数据集上的表现优于 STITCH 数据集，并且与预期相比有显著提升。

在两个数据集上都使用随机预测器。接下来，我们将这种简单的预测器作为基准，将其性能与最先进的模型和 DTI-Voodoo 进行比较。

为了与最先进的方法进行比较，我们选择了之前在 Yamanishi 基准数据集上评估过的 DTI 预测的最佳方法。这些方法包括 DTIGEMS_p (Thafar 等人, 2020 年) 和 DTI-CDF (Chu 等人, 2021 年)，它们在众多研究中表现出了更优的结果。此外，我们还加入了 DTINet (Luo 等人, 2017 年) 作为比较方法，该方法已被用于开发诸如 NeoDTI (Wan 等人, 2019 年) 等具有类似方法学的众多方法。

我们根据各模型推荐的拆分方案选择、超参数以及交叉验证中的折数来评估所有模型，并测量各自的 AUROC 值。我们还通过执行基于蛋白质的交叉验证来进一步评估每个模型，确定其 MacroAUC 和 MicroAUC_p 值。在此次评估中，我们允许在训练过程中对负样本进行子采样，但在验证和测试阶段不允许，因为这些模型在实际应用中可能需要处理不平衡的数据。

我们的实验结果总结在表 2 中；我们计算了所有对比方法在原始分割方案和蛋白质分割方案下的性能。我们发现，与蛋白质分割相比，在药物 - 靶点对分割上评估时性能差异很大，使用药物 - 靶点对分割通常能取得更高的性能。其次，在蛋白质分割上评估相同的方法时，我们发现其性能与每种方法原始评估中使用的分割方案相比有显著差异。DTI-CDF 原本在所有三种分割方案下进行了评估，这一点也得到了印证 (Chu 等人, 2021)。虽然 DTI-Voodoo 在 MacroAUC 方面与朴素预测器和 DTI-CDF 的性能相当，但在 MicroAUC_p 方面却取得了显著更好的结果。我们还发现，使用蛋白质分割训练的方法通常比使用药物 - 靶点对分割训练的方法具有更高的 MicroAUC_p，这表明它们可能对未见过的蛋白质靶点具有更好的泛化能力，而使用药物 - 靶点对分割训练的方法可能利用了隐藏的偏差，因此泛化能力较差。

由于不同分割方案之间的性能差异相当大，我们进一步评估了在其他数据集上训练和评估的其他 DTI 和药物 - 靶点亲和力预测方法。根据 MolTrans (Huang 等人, 2021 年) 的结果，我们重新评估了 DeepDTI (Wen 等人, 2017 年) 和 DeepDTA (O

2018 年)、DeepConv-DTI (Lee 等人, 2019 年) 以及 MolTrans 本身在 BioSnap 数据集 (Zitnik 等人, 2018 年) 上进行了评估，并将其与我们的“天真”预测器以及 DTI-Voodoo 进行了比较 (见表 3)。我们在药物 - 靶点对和蛋白质拆分上对 MolTrans 进行了评估；我们能够重现 MolTrans 的结果 (表 3)，表明基于拆分方案存在显著差异。我们还计算了所有考虑方法的 MicroAUC_p 得分，结果与在 Yamanishi 数据集上观察到的结果相似。我们检验 DTI-Voodoo 是否优于我们所比较的方法，或者观察到的 MicroAUC_p 和 MacroAUC 值是否在预期范围内；我们为此测试使用了一尾 T 检验，并进行了邦费罗尼校正。

从宏观 AUC 值来看，DTI-Voodoo 在 BioSnap 数据集上显著优于 MolTrans (t = 36.6)、DeepDTI (t = 40.5)、Deep

DTA (t = 36.6) 和 DeepConv-DTI (t = 40.5) (P < 10⁴，单侧 t 检验)，在 Yamanishi 数据集上显著优于 DTINet (t = 20.8) 和 DTIGEMS_p (t = 18.0) (P < 10⁴，单侧 t 检验)；DTI-CDF 的表现优于 DTI-Voodoo (P = 0.1；t = 1.3，单侧 t 检验)。我们进一步进行了另一项单侧 t 检验以比较 MicroAUC_p 性能。我们发现，DTI-Voodoo 在 BioSnap 数据集上显著优于 MolTrans (t = 21.2)、DeepDTI (t = 31.0)、DeepDTA (t = 33.4) 和 DeepConv-DTI (t = 23.7) (P < 10⁴)，在 Yamanishi 数据集上显著优于 DTINet (t = 29.6)、DTIGEMS_p (t = 28.0) 和 DTI-CDF (t = 9.5) (P < 10⁴)。

在我们所有的实验中，DTI-Voodoo 在 MicroAUC_p 方面均优于其他所有方法，这表明 DTI-Voodoo 能够比其他方法更准确地识别针对特定蛋白质的药物。有些方法在使用药物 - 靶点对拆分方案评估时，其 MacroAUC 值高于 DTI-Voodoo；我们使用“天真”预测方法得出的结果表明，基于药物 - 靶点拆分训练的模型可能会利用数据集中的某些偏差，而未必能产生新的生物学见解。

4 讨论

4.1 “自下而上”和“自上而下”的药物靶点相互作用预测

预测药物 - 靶点相互作用 (DTIs) 的计算方法有很多。这些方法大致可分为两类；第一类，我们称之为“自下而上”的方法，从药物和蛋白质的分子信息入手，根据它们的分子特性来预测相互作用；第二类，我们称之为“自上而下”的方法，从生物体的可观察特征入手，推断出可能的分子机制来解释这些观察结果，从而预测药物 - 靶点相互作用。

对于这两种方法的另一种看法是，它们分别是直接和间接预测药物 - 靶点相互作用 (DTIs) 的方式。一方面，分子信息可用于直接确定两个分子 (如药物和蛋白质) 是否具有相互作用的能力，而关于药物的表型后果 (药物效应) 或蛋白质功能破坏的信息则可用于间接提示候选药物 - 靶点相互作用。分子特征将特定于药物 - 靶点对，我们不期望这种信息能通过蛋白质 - 蛋白质相互作用网络传播；从蛋白质间相互作用中能获取的主要关于药物 - 靶点相互作用的信息是蛋白质间结合位点的信息，这些位点也可能被药物分子所利用 (即，蛋白质 P₁ 与蛋白质 P₂ 相互作用的信息揭示了 P₁ 和 PP₂ 的分子结构信息)。另一方面，蛋白质功能变化或药物效应的表型后果通常是异常通路或网络活动的结果，并且涉及不止一种蛋白质；因此，我们预计这些特征将更多地受益于包含蛋白质 - 蛋白质相互作用的信息。此外，由于蛋白质 - 蛋白质相互作用关系不具有传递性 (蛋白质 P₁ 与 P₂ 相互作用，以及 P₂ 与 P₃ 相互作用并不意味着 P₁ 与 P₃ 相互作用)，我们主要将信息传递给 PPI 图中每个蛋白质的直接邻域。我们的结果 (表 1) 证实了第一个假设，并表明分子特征并未因包含相互作用网络而获益，而间接的、顶部的

表 2. 在 Yamanishi 数据集上将 DTI-Voodoo 与最先进的 DTI 预测方法进行比较；我们在交叉验证中评估了原始数据集和基于蛋白质的数据集划分。

靠近	请给出需要翻译的词汇。	原方案	蛋白质水解	
	分裂方案	宏平均AUC	宏平均AUC	微型 AUC _p
朴素预测器	毒品	0.85	-	-
DTINet	动态规划对	0.91	0.74	0.67
DTIGEMS _p	动态规划对	0.93	0.72	0.68
DTI-CDF (直接给出缩写，无需翻译)	蛋白质	0.85	0.85	0.79
DTI-Voodoo (无需翻译，这是一个专有名词或蛋白质名称)		0.84	0.84	0.84

表 3. DTI-Voodoo 与最先进的 DTI 预测方法在 BioSnap 数据集上的比较；我们在交叉验证中评估了原始数据集和基于蛋白质的数据集划分情况。

靠近	请给出需要翻译的词汇。	原方案		
	分裂方案	宏平均AUC	宏平均AUC	微型 AUC _p
朴素预测器	动态规划对	0.79	–	–
DeepDTI	毒品	0.88	0.76	0.70
深度药物靶点相互作用预测模型	动态规划对	0.88	0.77	0.69
DeepConv-DTI	动态规划对	0.88	0.76	0.73
MolTrans	动态规划对	0.90	0.77	0.74
DTI-Voodoo（无需翻译，这是一个专有名词或 蛋白质 名称）		0.85	0.85	0.82

低层特征得益于在交互网络中的传播。虽然我们选择的图是基于蛋白质之间的相互作用，且我们的结果对于这样的图是成立的，但也可以选择其他类型的实体和相互作用，特别是相似性网络（[Gottlieb 等人，2011 年](#)）；在这样的网络中，节点之间的信息传递方式可能与 DTI-Voodoo 中的不同。

还有其他类型的间接特征可以添加到我们的模型中。一种常见的特征是药物适应症，它可能对药物靶点相互作用具有预测性（[Gottlieb 等人，2011 年](#)）。然而，我们并未将药物适应症纳入模型，因为纳入药物适应症会使我们的模型仅基于记忆哪些靶点常用于哪些适应症，就能做出许多简单的预测；而加入网络信息可能会使基于药物适应症的预测受益，因为不同的药物可能通过不同的机制作用于相同的通路。

在单一模型中结合自下而上和自上而下的方法可以采用不同的策略。交互网络被广泛用于确定分子变化的间接效应并预测药物 - 靶点相互作用（DTIs）（[Shahreza 等人，2017 年](#)）。我们的工作依赖于图神经网络，以此将有关相互作用的定性信息与额外特征（分子相互作用、表型和功能特征）相结合；即使只有部分特征能从图中获取信息，图神经网络也将允许我们在未来进一步扩展模型以纳入更多特征。

据我们所知，DTI-Voodoo 是首个传播基于本体论的蛋白质相互作用网络特征的药物-靶点相互作用（DTI）预测模型；虽然此前曾有将本体论嵌入与相互作用网络相结合的方法用于分析基因表达（[Trebacz 等人，2020 年](#)），但 DTI-Voodoo 将此方法拓展到了 DTI 预测领域。此外，DTI-Voodoo 的新颖之处在于它通过蛋白质间相互作用的图表示，明确整合了“自下而上”和“自上而下”的特征；尽管存在其他结合这些特征的 DTI 预测方法（[Gottlieb 等人，2011 年](#)），但 DTI-Voodoo 利用了图来整合异质性特征的能力，并通过使用图神经网络在机器学习中利用这种图的能力。

4.2 评估 DTI 预测的挑战

我们实验的一个主要部分是确定机器学习模型在训练期间可用的信息如何影响模型的性能。与之前的研究（[Chu 等人，2021 年](#)；[Huang 等人，2021 年](#)；[Lee 等人，2019 年](#)）类似，我们发现不同的划分方案在预测性能方面存在显著差异。

药物靶点相互作用（DTI）预测中最常见的方案是将药物 - 靶点对进行划分（[Wang 和 Kurgan，2019](#)），在这种情况下，模型验证和测试阶段所包含的大多数药物和靶点可能也已在训练阶段出现（作为其他药物 - 靶点对的一部分）。这种方案容易产生多种偏差。如果某种药物或蛋白质的相互作用数量不平衡，即某些药物或蛋白质的相互作用数量远多于其他药物或蛋白质，那么在训练过程中这些药物或蛋白质出

现的频率会更高，它们在测试和验证集中的相互作用数量也可能更多；由于某些实体的相互作用数量更多，即它们更有可能相互作用，因此任何优先预测这些实体作为相互作用伙伴的模型都会提高其预测性能。虽然这准确地反映了分布情况，但在将模型应用于新实体时，基于相互作用伙伴数量的偏差进行预测是不可取的。我们已经证明，即便是新提出的仅通过利用相互作用伙伴数量不平衡来做出预测的“天真”分类器，其性能也能接近最先进的方法（以宏平均 AUC 为衡量标准）。在不平衡数据上训练机器学习模型时，最终会过度拟合这种不平衡。按实体（蛋白质或药物）进行划分可以减少这些虚假关联的影响，但不能完全消除，因为相似的实体仍会表现出相似的相互作用模式。在我们的实验中，我们观察到按蛋白质划分训练集和评估集会导致整体性能（宏平均 AUC）下降，这在一定程度上表明使用这种划分方案训练的模型对这种偏差的过度拟合不太敏感。

训练和评估数据的生成方式与模型的评估方式有关。基于宏平均 AUC 的评估适用于给定一组药物和蛋白质，在所有可能的配对中识别出更有可能相互作用的配对的应用场景。然而，这并不符合大多数药物再利用的场景，在这些场景中，需要识别出针对特定蛋白质（例如与某种疾病相关的蛋白质）的药物。我们引入了一种基于每种蛋白质的微平均值的评估方法（微 AUC_p）来评估这种场景，并且通常会发现使用宏平均 AUC 和微 AUC_p 评估时预测性能存在显著差异。一般来说，基于药物 - 靶点配对进行划分训练的模型在微 AUC_p 评估中的表现不如基于蛋白质进行划分训练的模型，这进一步证明了药物 - 靶点划分会导致过度拟合数据集偏差。

最后，模型性能差异的一个潜在来源在于评估（以及训练）过程中对负样本的识别和处理方式。经过验证的负向药物-靶点相互作用（DTI）的大规模数据集很少；因此，许多模型（包括 DTI-Voodoo）将所有未知的相互作用都视为负样本。由于负向相互作用的数量远多于正向相互作用，所以在训练过程中会对负样本进行子抽样，以使训练集中的正负样本数量达到平衡（或保持一定的比例）。虽然这种策略对于处理不平衡数据是合理的，但如果在模型评估集中也采用同样的子抽样方法，可能会导致问题，因为这会过度简化评估过程。使用 ROC 曲线时，这种性能差异通常不明显，但会导致不切实际的高精度，从而导致高精度-召回率曲线下面积。

我们在评估药物-靶点相互作用（DTI）预测方法时所发现的若干偏差此前已有报道。基于训练数据和评估数据的划分方式（按相互作用对、按药物或按蛋白质）所产生的性能差异，此前已通过宏平均 AUC（MacroAUC）指标得到证实（[Huang 等人，2021 年](#)；[Pahikkala 等人，2015 年](#)；[van Laarhoven 和 Marchiori，2014 年](#)）；在此基础上，我们进一步引入基于微平均的性能度量（微平均 AUC_p 和微平均 AUC_d），以更清晰地展示评估数据不平衡时预测性能的变化情况。我们有

在此基础上, 我们进一步引入了一个“天真”的分类器, 该分类器明确利用了一种数据偏差来进行预测, 从而表明这种偏差对药物-靶点相互作用 (DTI) 方法有着显著的影响。我们通过“天真”分类器所识别出的这种偏差, 与 Gillis 和 Pavlidis (2012 年) 在基因网络中使用基于“有罪推定”原则的方法时发现的偏差类似, 但据我们所知, 这种偏差在药物-靶点相互作用预测的背景下尚未得到证实。

总之, 药物-靶点相互作用 (DTI) 预测并非生物信息学中的单一计算问题, 而是一组相关问题。设 P 为蛋白质集合, D 为药物集合; 一项任务可能是识别任意一对 (p, d) , 其中 $p \in P$ 且 $d \in D$ 之间存在相互作用, 另一项任务是为每个 $p \in P$ 确定一组相互作用的药物, 还有一项任务是为每个 $d \in D$ 确定一组蛋白质。当不考虑特定药物或蛋白质时, 第一项任务可能最有用; 当寻找针对特定 (疾病相关) 蛋白质的药物时, 第二项任务最有用; 而当旨在为给定药物寻找新用途时, 第三项任务最有用。第一项任务最好使用宏 AUC 进行评估, 第二项和第三项任务则分别使用微 AUC_p 和微 AUC_d 进行评估。

4.3 药理学新创性

由于基于目标的预测能力, DTI-Voodoo 相较于其他方法有了显著提升, 我们利用该模型预测了蛋白质家族的新药类别。为此, 我们收集了每种药物的二级 ATC (解剖治疗化学) 组以及每种蛋白质的所有 InterPro (Blum 等人, 2020 年) 顶级家族。利用 STITCH 相互作用, 我们在每个 InterPro 家族内对蛋白质进行拆分, 并对所有可用药物进行预测。最终, 我们通过将每组的新相互作用数量除以相应 ATC 组中的药物数量来进行标准化。该分析结果的热图可在补充图 S5 中找到。DTI-Voodoo 可以为广泛的 ATC 类别以及蛋白质家族预测新的候选药物-靶点相互作用。

例如, ATC 分组 A07 (止泻药) 获批的药物总数相对较少 (补充图 S6), 但 DTI-Voodoo 预测了几个候选靶点, 这些靶点来自具有 PHD 型锌指结构域 (IPR001965) 的蛋白质。例如, 用于治疗炎症性肠病但对结肠癌具有诱导细胞凋亡和化学预防作用的药物美沙拉嗪 (Bus 等人, 1999 年; Ishikawa 等人, 2021 年); DTI-Voodoo 预测美沙拉嗪会与五个具有 PHD 型锌指结构域的蛋白质相互作用: BRPF1、TRIM33、BAZ1A、RSF1 和 DPF2。RSF1 的过表达与结直肠癌的不良预后相关, 而敲低 RSF1 会导致细胞增殖减少 (Liu 等人, 2012 年), 这表明美沙拉嗪除了具有抗炎作用外, 可能还通过抑制 RSF1 发挥其对结肠癌的化学预防作用。我们在网站上提供了所有预测结果, 包括药物的 ATC 分类和预测靶点的 Interpro 家族, 以便进一步探索 DTI-Voodoo 的预测结果。

5 结论

我们开发了 DTI-Voodoo 机器学习模型, 该模型将分子特征和功能信息与交互网络相结合, 利用图神经网络来预测可能针对特定蛋白质的药物。在这一任务中, DTI-Voodoo 超越了多种最先进的方法。我们证明了功能和表型信息在交互网络中具有局部性, 而分子信息则没有。此外, 我们还表明, DTI 预测数据集存在一些固有的偏差, 会影响模型的性能。这使我们得出结论, DTI 预测并非单一的计算问题, 而是一系列不同的问题。对 DTI 预测方法的实验评估必须精心设计, 以反映模型旨在解决的问题, 并且对性能结果的解读应与具体问题相一致。

致谢

作者感谢沙特阿卜杜拉国王科技大学超级计算核心实验室提供的计算资源。

资金

本研究得到了沙特阿卜杜拉国王科技大学 (KAUST) 科研项目办公室 (OSR) 资助, 项目编号为 URF/1/3790-01-01 和 URF/1/4355-01-01。

利益冲突: 无。

参考文献

- Ashburner,M. et al. (2000) Gene ontology: tool for the unification of biology. *Nat. Genet.*, 25, 25–29.
- Bianchi,F.M. et al. (2019) Graph neural networks with convolutional ARMA filters. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 1–1.
- Blum,M. et al. (2020) The InterPro protein families and domains database: 20 years on. *Nucleic Acids Res.*, 49, D344–D354.
- Bus,P.J. et al. (1999) Mesalazine-induced apoptosis of colorectal cancer: on the verge of a new chemopreventive era? *Alimentary Pharmacol. Therap.*, 13, 1397–1402.
- Campillos,M. et al. (2008) Drug target identification using side-effect similarity. *Science*, 321, 263–266.
- Carbon,S. et al. (2020) The gene ontology resource: enriching a GOLD mine. *Nucleic Acids Res.*, 49, D325–D334.
- Chen,J. et al. (2021) Predicting candidate genes from phenotypes, functions and anatomical site of expression. *Bioinformatics*, 37, 853–860.
- Chen,X. et al. (2016) Drug–target interaction prediction: databases, web servers and computational models. *Brief. Bioinf.*, 17, 696–712.
- Chu,Y. et al. (2021) DTI-CDF: a cascade deep forest model towards the prediction of drug–target interactions based on hybrid features. *Brief. Bioinf.*, 22, 451 462.
- Defferrard,M. et al. (2016) Convolutional neural networks on graphs with fast localized spectral filtering. In: *Proceedings of the 30th International Conference on Neural Information Processing Systems, NIPS’ 16*, Curran Associates Inc., Red Hook, NY, USA, pp. 3844–3852.
- Ding,H. et al. (2014) Similarity-based machine learning methods for predicting drug–target interactions: a brief review. *Brief. Bioinf.*, 15, 734–747.
- Feng,Y. et al. (2017) Drug target protein-protein interaction networks: a systematic perspective. *BioMed Res. Int.*, 2017, 1289259–1289213.
- Fey,M. and Lenssen,J.E. (2019) Fast graph representation learning with pytorch geometric. *arXiv*, (abs/1903.02428).
- Gillis,J. and Pavlidis,P. (2012) “guilt by association” is the exception rather than the rule in gene networks. *PLoS Comput. Biol.*, 8, e1002444.
- Gottlieb,A. et al. (2011) PREDICT: a method for inferring novel drug indications with application to personalized medicine. *Mol. Syst. Biol.*, 7, 496.
- Hamilton,W.L. et al. (2017) Inductive representation learning on large graphs. In: *NIPS*.
- Hoehndorf,R. et al. (2011) PhenomeNET: a whole-phenome approach to disease gene discovery. *Nucleic Acids Res.*, 39, e119.
- Honda,S. et al. (2019) SMILES transformer: pre-trained molecular fingerprint for low data drug discovery. *arXiv*, (abs/1911.04738).
- Huang,K. et al. (2021) MolTrans: molecular interaction transformer for drug–target interaction prediction. *Bioinformatics*, 37, 830–836.
- Ishikawa,H. et al. (2021) Chemoprevention with low-dose aspirin, mesalazine, or both in patients with familial adenomatous polyposis without previous colectomy (j-FAPP study IV): a multicentre, double-blind, randomised, two-by-two factorial design trial. *Lancet Gastroenterol. Hepatol.*, 6, 474–481.
- Jeni,L.A. et al. (2013) Facing imbalanced data–recommendations for the use of performance metrics. In: *2013 Humaine Association Conference on Affective Computing and Intelligent Interaction*, pp. 245–251.
- Kingma,D.P. and Ba,J. (2015) Adam: a method for stochastic optimization. *arXiv*, abs/1412.6980.
- Kipf,T.N. and Welling,M. (2016) Semi-supervised classification with graph convolutional networks. *arXiv*, abs/1609.02907.
- Klicpera,J. et al. (2018) Personalized embedding propagation: combining neural networks on graphs with personalized pagerank. *arXiv*, abs/1810.05997.

- Köhler, S. et al. (2018) Expansion of the human phenotype ontology (HPO) knowledge base and resources. *Nucleic Acids Res.*, 47, D1018–D1027.
- Kuhn, M. et al. (2016) The SIDER database of drugs and side effects. *Nucleic Acids Res.*, 44, D1075–D1079.
- Kulmanov, M. and Hoehndorf, R. (2020) DeepGOPlus: improved protein function prediction from sequence. *Bioinformatics*, 36, 422–429.
- Lee, I. and Nam, H. (2018) Identification of drug–target interaction by a random walk with restart method on an interactome network. *BMC Bioinf.*, 19, 208.
- Lee, I. et al. (2019) DeepConv-DTI: prediction of drug–target interactions via deep learning with convolution on protein sequences. *PLOS Comput. Biol.*, 15, e1007129.
- Li, G. et al. (2019) Deepgcns: can GCNS go as deep as CNNs? *Proceedings of The IEEE International Conference on Computer Vision (ICCV)*.
- Li, G. et al. (2020) Deeppergcn: all you need to train deeper GCNS. *arXiv, abs/2006.07739*.
- Liu, Q. et al. (2020) DeepCDR: a hybrid graph convolutional network for predicting cancer drug response. *Bioinformatics*, 36, i911–i918.
- Liu, S. et al. (2012) Rsf-1 overexpression correlates with poor prognosis and cell proliferation in colon cancer. *Tumor Biol.*, 33, 1485–1491.
- Luo, Y. et al. (2017) A network integration approach for drug–target interaction prediction and computational drug repositioning from heterogeneous information. *Nat. Commun.*, 8, 573–513.
- Mikolov, T. et al. (2013) Distributed representations of words and phrases and their compositionality. *arXiv, abs/1310.4546*.
- Mozzicato, P. (2009) MedDRA. *Pharmaceutical Med.*, 23, 65–75.
- Nguyen, T. et al. (2020) GraphDTA: predicting drug–target binding affinity with graph neural networks. *Bioinformatics*, 37, 1140–1147.
- Oliver, S. (2000) Guilt-by-association goes global. *Nature*, 403, 601–602.
- Overington, J.P. et al. (2006) How many drug targets are there? *Nat. Rev. Drug Discov.*, 5, 993–996.
- Ozturk, H. et al. (2018) DeepDTA: deep drug–target binding affinity prediction. *Bioinformatics*, 34, i821–i829.
- Pahikkala, T. et al. (2015) Toward more realistic drug–target interaction predictions. *Brief. Bioinf.*, 16, 325–337.
- Shahreza, M.L. et al. (2017) A review of network-based approaches to drug repositioning. *Brief. Bioinf.*, 19, 878–892.
- Smith, C.L. and Eppig, J.T. (2009) The mammalian phenotype ontology: enabling robust annotation and comparative analysis. *Wiley Interdiscip. Rev. Syst. Biol. Med.*, 1, 390–399.
- Szklarczyk, D. et al. (2014) STRING v10: protein–protein interaction networks, integrated over the tree of life. *Nucleic Acids Res.*, 43, D447–D452.
- Szklarczyk, D. et al. (2016) STITCH 5: augmenting protein–chemical interaction networks with tissue and affinity data. *Nucleic Acids Res.*, 44, D380–D384.
- Thafar, M.A. et al. (2020) DTiGEMS: drug–target interaction prediction using graph embedding, graph mining, and similarity-based techniques. *J. Cheminf.*, 12, 44.
- Trebacz, M. et al. (2020) Using ontology embeddings for structural inductive bias in gene expression data analysis. *arXiv, abs/2011.10998*.
- van Laarhoven, T. and Marchiori, E. (2014) Biases of drug–target interaction network data. In: *Pattern Recognition in Bioinformatics*, Springer International Publishing, pp. 23–33.
- Velickovic, P. et al. (2017) Graph attention networks. *arXiv, abs/1710.10903v3*.
- Wan, F. et al. (2019) NeoDTI: neural integration of neighbor information from a heterogeneous network for discovering new drug–target interactions. *Bioinformatics*, 35, 104–111.
- Wang, C. and Kurgan, L. (2019) Review and comparative assessment of similarity-based methods for prediction of drug–protein interactions in the druggable human proteome. *Brief. Bioinf.*, 20, 2066–2087.
- Wen, M. et al. (2017) Deep-learning-based drug–target interaction prediction. *J. Proteome Res.*, 16, 1401–1409.
- Wishart, D.S. et al. (2007) DrugBank: a knowledgebase for drugs, drug actions and drug targets. *Nucleic Acids Res.*, 36, D901–D906.
- Wishart, D.S. et al. (2017) DrugBank 5.0: a major update to the DrugBank database for 2018. *Nucleic Acids Res.*, 46, D1074–D1082.
- Yamanishi, Y. et al. (2008) Prediction of drug–target interaction networks from the integration of chemical and genomic spaces. *Bioinformatics*, 24, i232–i240.
- Zitnik, M. and Leskovec, J. (2017) Predicting multicellular function through multi-layer tissue networks. *arXiv, abs/1707.04638*.
- Zitnik, M. et al. (2018) Biosnap datasets: Stanford biomedical network dataset collection. <http://snap.stanford.edu/biodata> (01 July 2020, date last accessed).