



通过构建高度可信的负样本提高复合蛋白质相互作用预测的准确性

Hui Liu^{1,2,†}, Jianjiang Sun^{3,†}, Jihong Guan⁴, Jie Zheng² and Shuigeng Zhou^{3,*}

¹中国江苏常州大学信息管理实验室，邮编 213164，²新加坡南洋理工大学计算机工程学院，邮编 639798，³上海智能信息处理重点实验室及复旦大学计算机科学学院，上海 200433，中国和 ⁴同济大学计算机科学与技术系，上海 201804，中国

请将信件寄往此处。

[†]The 作者希望明确指出，在他们看来，前两位作者应被视为共同第一作者。

摘要

动机：化合物-蛋白质相互作用（CPI）的计算预测对于药物设计和开发至关重要，因为全基因组规模的 CPI 实验验证不仅耗时，而且成本高昂。随着越来越多的已验证相互作用数据的可用性，计算预测方法的性能受到可靠负 CPI 样本缺乏的严重阻碍。因此，系统筛选可靠负样本的方法对于提高计算机预测方法的性能至关重要。

结果：本文旨在通过计算机模拟筛选方法建立一套高可信度的化合物-蛋白质相互作用（CPI）负样本。鉴于大多数现有的计算模型都假定相似的化合物可能与相似的靶蛋白相互作用，并且取得了显著的性能，因此基于相反的负命题，即与已知/预测化合物靶点不相似的蛋白质不太可能成为该化合物的靶点，反之亦然，来识别潜在的负样本是合理的。我们将各种资源，包括化合物的化学结构、化学表达谱和副作用、氨基酸序列、蛋白质-蛋白质相互作用网络以及蛋白质的功能注释，整合到一个系统的筛选框架中。我们首先在六种经典分类器上测试了筛选出的负样本，结果表明，对于人类和秀丽隐杆线虫，所有这些分类器在我们的负样本上的性能都显著高于在随机生成的负样本上的性能。然后，我们在现有的三种预测模型（包括二部局部模型、高斯核轮廓和贝叶斯矩阵分解）上验证了负样本，发现这些模型在筛选后的负样本上的性能也得到了显著提高。此外，我们在药物生物活性数据集上验证了筛选的阴性样本。筛选的阴性样品和预测的相互作用为研究界提供了一个有用的资源来确定新的药物靶点，并对目前的化合物蛋白质数据库进行了有益的补充。

可用性：补充文件可在以下网址获取：<http://admis.fudan.edu.cn/negative-cpi/>。联系方式：sgzhou@fudan.edu.cn

补充信息：[补充数据](#)可在《生物信息学》在线获取。

1 简介

复合蛋白质相互作用 (CPIs) 对于通过筛选候选化合物来发现新药至关重要, 也有助于理解现有药物副作用的成因。尽管有各种生物学检测方法可用, 但实验验证 CPIs 仍然耗时且成本高昂。因此, 开发能够准确检测 CPIs 的计算方法具有很强的激励作用。与此同时, 随着诸如 PubChem (Wheeler 等人, 2006 年)、DrugBank (Wishart 等人, 2008 年)、SIDER (Kuhn 等人, 2010 年)、STITCH (Kuhn 等人, 2014 年)、STRING (Franceschini 等人, 2013 年) 和基因本体论 (GO) (Ashburner 等人, 2013 年) 等公共化学和生物数据库的迅速增长, 包括药物化学结构、副作用以及药物处理下的基因表达谱等药物特征, 以及氨基酸序列、蛋白质-蛋白质相互作用 (PPI) 网络和功能注释等蛋白质特征在内的各种资源, 已向研究界开放, 为计算 CPI 预测奠定了基础。

传统的计算方法大致可分为两类: 基于结构的方法和基于配体的方法。基于结构的方法依赖于目标蛋白质的结构信息, 而这些信息对于大多数蛋白质家族来说往往是不可用的。基于配体的方法对于那些已知配体很少或没有已知配体的蛋白质来说效果不佳。最近, 基于机器学习的方法已被提出, 并通过化学基因组学的观点取得了相当大的成功 (Jaroch 和 Weinmann, 2006 年), 该观点将药物化合物的化学属性、蛋白质的基因组属性以及已知的化合物-蛋白质相互作用整合到一个统一的数学框架中。化学基因组学方法的主要原理是相似的化合物往往与相似的蛋白质结合, 因此, 对于给定蛋白质缺乏已知配体的情况, 可以通过相似蛋白质的已知配体来弥补, 反之亦然。

遵循化学基因组学的理念, 通过利用各种类型的特征和分类算法, 提出了许多方法 (Tabei 和 Yamanishi, 2013; Yabuuchi et al., 2011; Yamanishi et al., 2010)。van Laarhoven 等人 (2011) 提出了利用 CPI 网络拓扑结构的高斯交互剖面 (GIP) 核。然而, 这些方法仍然缺乏已知的药物和感兴趣的蛋白质之间的相互作用, 这往往导致预测失败。因此, Mei 等人 (2013) 通过利用已知的邻居相互作用来弥补相互作用信息的不足, 从而改进了 BLM。van Laarhoven 和 Marchiori (2013) 也使用加权近邻的相互作用概况来改进 GIP 方法。

越来越多的研究人员不再单独利用药物和蛋白质的属性, 而是通过串联或张量积运算符将这些属性整合为一个单一的特征向量, 然后基于整合后的特征和已知的药物-蛋白质相互作用 (CPI) 构建分类器。例如, 雅各布和维特 (2008 年) 提出了基于成对核函数的支持向量机分类器, 这些核函数分别源自药物和蛋白质的相似性度量。山岸等人 (2008 年) 提出了二部图推断方法, 将药物和蛋白质映射到一个统一的欧几里得特征空间, 在该空间中, 已知相互作用所连接的药物和蛋白质之间的距离被最小化, 而其他药物和蛋白质之间的距离则被最大化。最初用于个人推荐的基于网络的推断方法 (周等人, 2010 年) 也被用于识别药物-蛋白质相互作用 (Alaimo

等人, 2013 年; 程等人, 2012 年)。其他方法还包括基于核的数据融合 (王等人, 2011 年)、具有双核的核化贝叶斯矩阵分解 (KBMF2K) (Gonen, 2012 年)、受限玻尔兹曼机 (王和曾, 2013 年) 以及半监督方法 (陈和张,

2013 年; Xia 等人, 2010 年) 相继被提出。除了化学结构和蛋白质序列, 研究人员还借助药物和蛋白质的其他属性来揭示它们的相互作用关系, 包括药物表达谱 (Carrella 等人,

2014 年; 伊奥里奥等人 (2010 年); 沃尔普等人 (2011 年), 药物的功能团 (何等人, 2010 年) 和副作用 (坎皮洛斯等人, 2008 年; 水谷等人, 2012 年), 蛋白质的信号通路和 GO 注释 (耶格尔等人, 2014 年), 甚至这些属性的组合 (戈特利布等人, 2011 年、2012 年; 珀尔曼等人, 2011 年)。

以往的方法大多采用实验验证的 cpi 作为正样本和随机生成的负样本来学习预测模型。然而, 随机生成的阴性样本可能包含未知的真实阳性样本。因此, 筛选高可靠的阴性样本对于提高计算预测方法的准确性至关重要。真负相互作用的重要性最近被强调为预测药物-靶标相互作用的未来发展之一 (Ding et al., 2014)。受此激励, 我们开始在计算机上筛选高可信度的 cpi 负样本。预测 cpi 的大多数计算方法的一个基本假设是, 类似的药物化合物可能与类似的靶蛋白相互作用。我们的方法基于反向否定命题, 即与给定化合物的每个已知/预测靶标不同的蛋白质不太可能被该化合物靶向, 反之亦然。我们将化合物和蛋白质的各种资源, 包括化合物的化学结构、化学表达谱和副作用、蛋白质的氨基酸序列、蛋白质相互作用网络以及 GO 功能注释整合到一个系统的筛选框架中。我们在人类和秀丽隐杆线虫的数据上对我们的方法进行了评估。首先, 我们在六种经典分类器 (包括随机森林、L1 和 L2 正则化逻辑回归、朴素贝叶斯、支持向量机和 k 近邻 (kNN)) 上测试了筛选出的阴性样本, 发现所有这些分类器在我们的阴性样本上的表现都显著优于在随机生成的阴性样本上的表现。我们还在三个现有的预测模型 (包括 BLM (Bleakley 和 Yamanishi, 2009 年)、高斯核谱 (van Laarhoven 等人, 2011 年) 和贝叶斯矩阵分解 (Gonen, 2012 年)) 上验证了我们的阴性样本, 并发现这些模型在筛选出的阴性样本上的性能也显著提高。此外, 我们还用一个药物生物活性数据集对筛选出的阴性样本进行了验证。

这些筛选的阴性样本和预测的相互作用可以作为研究团体确定新药物靶点的有用资源, 并作为对当前策划的化合物-蛋白质数据库的有益补充。

2 材料

2.1 复合蛋白质相互作用

从 DrugBank 4.1 (Wishart 等人, 2008 年)、Matador (Gnther 等人, 2008 年) 和 STITCH 4.0 (Kuhn 等人, 2014 年) 中获取了化学物质-蛋白质相互作用 (CPI) 数据。

DrugBank 和 Matador 是人工整理的数据库，而 STITCH 则是一个综合性的数据库，它从四个不同的来源收集化合物-蛋白质相互作用 (CPI)：实验、数据库、文本挖掘和预测的相互作用。同时，STITCH 为每个相互作用提供了一个从 0 到 1000 的评分，该评分表明了由四种证据类型支持的 CPI 的可信度，即实验验证、人工整理的数据库、文本挖掘和预测的相互作用。由于 DrugBank 和 Matador 中的相互作用均得到了生化实验和文献的支持，因此我们将其相互作用的评分设为最高分 1000。总共，我们获得了 367142 种独特化合物与 19342 种人类蛋白质之间 2290630 种相互作用，以及 276294 种独特化合物与 11234 种秀丽隐杆线虫蛋白质之间 2141740 种相互作用。为简便起见，在本文余下部分，我们将所构建的 CPI 集合称为 K ，并用三元组 $\delta c_i p_j$ ； w_{ij} 表示药物 c_i 与蛋白质 p_j 之间的相互作用，其置信度评分为 w_{ij} 。

2.2 化学数据

2.2.1 化学结构相似性

药物的化学结构（也称为指纹）从 PubChem 数据库（Wheeler 等人，2006 年）中获取。我们计算了指纹的杰卡德得分（Jaccard，1908 年）作为化合物之间的化学结构相似度。化合物 c 和 c_0 之间的杰卡德得分定义为 $j c \setminus c_0 = j c \cap c_0$ ，即 c 和 c_0 之间共有子结构的数量与 c 和 c_0 中子结构总数的比值。在对人类和秀丽隐杆线虫的分析中，我们总共使用了 881 种子结构。对所有药物对执行此操作后，我们构建了一个化学相似度矩阵。

2.2.2 副作用相似性

药物的副作用信息从 SIDER 数据库（Kuhn 等人，2010 年）中下载。对于涉及 CPI 但未包含在 SIDER 数据库中的药物，我们采用了一种最近提出的基于化学片段预测副作用的方法（Pauwels 等人，2011 年）来预测其副作用。同样地，我们根据每对药物已知的副作用或在未知情况下根据预测的前 10 种副作用（Perlman 等人，2011 年），计算每对药物的杰卡德相似度作为副作用相似度。

2.3 蛋白质数据

2.3.1 序列相似性

蛋白质的氨基酸序列是从 UCSC 表格浏览器中获取的。我们使用归一化后的史密斯-沃特曼得分（Smith 和 Waterman，2010）来计算蛋白质之间的序列相似度。两个蛋白质 g 和 g_0 之间的归一化史密斯-沃特曼得分是 $sw\delta g; g_0$ =

$$\frac{\max_{p \in \{1, \dots, |g| \}} \sum_{i=1}^{|g|} \min_{j \in \{1, \dots, |g_0|\}} \{ \delta g_i p_j, \delta g_0 p_j \} }{|g| + |g_0|}$$

其中， δ 表示原始的史密斯-沃特曼得分。对所有蛋白质对应用此操作，我们得到了蛋白质序列的相似性矩阵。

$sw\delta$ ； $g; g_0$ 表示原始的史密斯-沃特曼得分。对所有蛋白质对应用此操作，我们得到了蛋白质序列的相似性矩阵。

2.3.2 功能注释语义相似度

GO 注释是从 GO 数据库（Ashburner 等人，2013 年）中下载的。每对蛋白质之间的语义相似度得分是根据与这两条蛋白质相关的 GO 术语的重叠部分计算得出的（Couto 等人，2007 年）。在计算中使用了所有三种类型的本体论，因为预期相似的药物会与在相似的生物学过程中起作用、具有相似分子功能或位于相似细胞区室的蛋白质相互作用。我们根据每对蛋白质的 GO 术语计算了杰卡德得分，将其作为它们的相似度。

2.3.3 蛋白质结构域相似性

蛋白质结构域从 PFAM 数据库（Punta 等人，2012 年）中提取。每个蛋白质都通过一个结构域指纹（二进制向量）来表示，其元素分别用 1 或 0 编码每个保留的 PFAM 结构域的存在与否。人类和秀丽隐杆线虫的 PFAM 结构域数量分别为 1331 和 3837。我们通过计算任意两个蛋白质的结构域指纹的杰卡德得分来衡量它们的相似度。

3 方法

3.1 多种相似性的整合

如上文所述，我们已针对药物和蛋白质的不同特征计算了多种相似性度量。对于药物 c_i 和 c_j ，我们将其整合为一个综合的相似性度量，具体如下：

$$CS_{ij} = 1 - \prod_n (1 - cs_{ij}^{(n)}) \quad (1)$$

其中 $cs_{ij}^{(n)}$

($n = 1, 2$) 表示所推导出的相似性度量。

分别从化学结构特征和副作用方面进行。请注意，STITCH（Kuhn 等人，2014 年）也采用了类似的公式，因为它可以很容易地扩展以整合更多的相似性度量。同样地，我们通过以下方式计算了蛋白质 p_i 和 p_j 之间的综合相似性：

$$PS_{ij} = 1 - \prod_n (1 - ps_{ij}^{(n)}), \quad (2)$$

其中 $ps_{ij}^{(n)}$

($n = 1, 2, 3$) 分别代表由序列相似性、功能注释语义相似性和蛋白质结构域相似性得出的相似性度量。

3.2 筛选框架

大多数现有的针对化合物-蛋白质相互作用 (CPI，阳性样本) 的预测方法都是基于这样一个假设：相似的化合物很可能与相似的已知目标蛋白相互作用。我们的基本思路则受到了这一假设的反命题的启发。具体来说，我们假设与某化合物的所有已知/预测目标蛋白都不相似的蛋白不太可能成为该化合物的靶点，另一方面，与任何已知/预测的针对某蛋白的化合物都不相似的化合物也不太可能成为该蛋白的靶点。为简便起见，我们将这两条规则分别称为蛋白质不相似性规则和药物不相似性规则。这两种规则在我们的筛选框架中同时应用，以识别最可靠的 CPI 负样本。与现有的预测方法不同，这些方法通常依赖已知的 CPI 来做出可靠的预测，我们的负样本筛选框架同时利用了经过验证的和预测的 CPI。图 1 展示了我们方法的流程图。这里，三个绿色虚线框展示了我们筛选框架中所使用的资源，并分别计算蛋白质差异性和药物差异性，从而为每个候选负样本获得一个综合得分。我们总结筛选步骤如下：

1. 通过公式 (1) / 公式 (2) 计算每对化合物/蛋白质的综合相似度。按照上述方法构建已知/预测的化合物-蛋白质相互作用 (CPI) 集合 K 。
2. 从所有可能的相互作用中构建候选的负相互作用集，排除已知/预测的 CPI 组装机 K 。我们选取候选的负相互作用




图 1. 我们负 CPI 筛选框架的流程图。三个绿色虚线框展示了我们筛选过程中所使用的数据资源，而红色虚线框则代表了包含多项操作的筛选步骤。

以化合物 k 与蛋白质 j 之间的距离为例，用 $\delta c_k; p_j; d_{kj}$ 表示化合物 k 与蛋白质 j 之间的距离，以此来展示筛选过程。图 2 用于说明 d_{kj} 的计算过程。

- 对于 K 中被 c_k 所靶向的任何蛋白质 p_l ，我们计算加权得分 $spc_{kjl} = \frac{1}{4} w_{kl} PS_{jl}$ ，该得分表明蛋白质 p_j 被化合物 c_k 靶向的可能性，同时考虑了 p_j 和 p_l 之间的相似性。考虑到 p_j 与化合物 c_k 已知/预测靶向的每个蛋白质 p_l （即 $(c_k; p_l; w_{kl}) \in K$ ）之间的相似性，我们通过将关于 l 的加权得分 spc_{kjl} 相加来计算组合得分，从而得到 $SPC_{jk} = \sum_l spc_{kjl}$ 。
- 同样地，我们计算加权得分 $scp_{kji} = \frac{1}{4} w_{ij} CS_{ik}$ ，该得分代表了考虑化合物 c_k 与靶点 p_j 之间相似性的情况下，化合物 c_k 对靶点 p_j 的作用可能性。考虑到 c_k 与每个已知/预测化合物 c_i 作用于蛋白质 p_j 的相似性，即 $(c_i; p_j; w_{ij}) \in K$ ，我们通过将针对 i 的加权得分 scp_{kji} 相加来计算综合得分，从而得到 $SCP_{kj} = \sum_i scp_{kji}$ 。
- 对于复合物 c_k 和蛋白质 p_j ，我们定义 c_k 和 p_j 之间的距离如下：

$$d_{kj} = e^{-(SPC_{jk} + SCP_{kj})}. \quad (3)$$

d_{kj} 是最终得分，代表化合物 c_k 不作用于蛋白质 p_j 的可能性。 d_{kj} 值越大，表明 c_k 不作用于 p_j 的可能性就越高。

- 从两个经过人工整理的数据库（DrugBank（Wishart 等人，2008 年）和 Matador（Gnther 等人，2008 年））构建积极相互作用的集合。
- 根据方程（3）所得的分数对潜在的负面 CPI 进行排序，选取分数最高的那些来构成负面样本候选集。
- 如第 3.3 节所述，通过使用化合物与蛋白质的特征差异对负样本候选进行进一步筛选。
- 将正负相互作用结合起来，我们便得到了一组标准的化学蛋白质相互作用（CPI）。在此基础上，我们能够进一步研究




图 2. 计算候选化合物-蛋白质负样本 $\delta c_k; p_j; d_{kj}$ 得分 d_{kj} 的示意图。使用蓝色和红色两种颜色分别区分用于计算两个组合得分 SPC_{jk} 和 SCP_{kj} 的权重和相似性。

对于每个细胞色素 P450 酶抑制剂（CPI），我们基于其亚结构和蛋白质 PFAM 结构域构建张量积，从而在化学基因组空间中用一个向量来表示每种相互作用。

从概念上讲，在步骤 2(a) 和步骤 2(b) 中，已知/预测相互作用 w_{kl} 和 w_{ij} 的置信值通过相似的蛋白质和化合物传播到候选的负相互作用。步骤 2(a) 中，通过蛋白质 p_l 将化合物 c_k 与蛋白质 j 相连的蛋白质相似性由 spc_{kjl} 表示；步骤 2(b) 中，通过化合物 c_i 将蛋白质 p_l 与化合物 c_k 相连的化学相似性由 scp_{kji} 表示。在步骤 2(c) 中，根据方程（3）将这两个结果得分进行组合，该方程通过负指数函数体现了蛋白质差异规则和药物差异规则。特别地，已知/预测的相互作用充当桥梁，将那些不太可能形成潜在相互作用的化合物和蛋白质连接起来。

3.3 按特征差异筛选

众所周知, 具有相似化学特征的化合物可能具有截然不同的结合生物活性 (活性悬崖) (Sun 和 Bajorath, 2012)。另一方面, 具有完全不同核心结构的化合物也可能作用于相似的蛋白质 (支架跳跃) (Sun 等人, 2012)。当特定化合物的已验证/预测靶蛋白数量较少, 从而涵盖的蛋白质组学特征有限时, 通过基于所有已知靶蛋白的蛋白质组学特征差异筛选出的一些蛋白质实际上可能是该化合物的靶点。从蛋白质的角度来看, 当针对某一蛋白质的已验证/预测化合物数量较少时, 也可能存在类似的情况。因此, 我们要求每个负样本候选化合物和蛋白质参与的已验证/预测相互作用数量应大于某个预定义的阈值。将阈值设为 15 时, 我们获得了 23392 种人类化合物和 10757 种人类蛋白质, 以及 33353 种秀丽隐杆线虫化合物和 7584 种秀丽隐杆线虫蛋白质, 用于构建负样本。

此外, 我们期望特定化合物所靶向的蛋白质的特征尽可能地不同, 这样我们的差异性规则就能排除更多与已知靶向蛋白质具有相似特征的虚假候选物。同样, 针对特定蛋白质的化合物的化学特征差异越大, 我们的差异性规则就能排除越多的假阳性靶向化合物。换句话说, 筛选出的阴性样本的可信度与特定化合物 (蛋白质) 所关联的已验证/预测相互作用中蛋白质 (化合物) 的特征差异呈正相关。因此, 我们利用特征差异进一步筛选候选阴性样本。由于方差是评估数据差异的常用指标, 我们进行了统计检验, 以检查候选阴性样本中与每个化合物 (蛋白质) 相关的相互作用子集中蛋白质 (化合物) 的相似度方差是否显著大于总体方差。以化合物为例, 化合物群体的相似度方差为 0.0335, 这很容易根据 CS_{ij} 计算得出 (见公式 1)。对于与蛋白质相互作用的 n 个化合物的子集, 零假设是样本方差小于化合物群体方差, 备择假设则与零假设相反, 那么样本方差遵循自由度为 $n-1$ 的 χ^2 分布。在显著性水平为 0.05 的情况下, 我们通过将 d_{ij} 的阈值设为 0.9 过滤掉了更多虚假的候选者, 最终在 14613 种独特的化合物和 2229 种独特的人类蛋白质之间获得了 384916 个负样本 ($e^{0.1}$)。对于秀丽隐杆线虫, 我们通过将 d_{ij} 的阈值设为 0.368, 最终在 2224 种独特的蛋白质和 5278 种独特的化合物之间获得了 88261 个负样本。

4 结果

4.1 绩效评估协议

为了对通过我们方法筛选出的负向 CPI 进行客观公正的评估, 我们首先从人工整理的 DrugBank 和 Matador 数据库中构建了正样本, 然后生成了两组负样本: 一组是从未包含在正样本中的化合物-蛋白质对中随机抽取的, 另一组是从我们方法筛选出的负样本列表中提取的。我们通过将六种经典分类器和三种现有预测方法在相同正样本

集上分别结合筛选出的负样本和随机生成的负样本的性能进行比较, 来评估筛选出的负样本。我们从排名列表选取了排名前 384916 的筛选出的负样本 (数据集可在补充材料中获取) 作为候选样本, 并在实验中使用了其中的一部分。

如补充图 S1 所示, 相互作用的频率分布偏向于仅一小部分化合物/蛋白质, 这表明在整个相互作用中进行随机抽样可能仅能涵盖有限数量的化合物和蛋白质。因此, 正如 Tabei 和 Yamanishi (2013) 以及 Yamanishi 等人 (2014) 所做的那样, 我们采用了两种协议: 成对交叉验证和分块交叉验证, 以评估我们的负样本与随机生成的负样本。具体而言, 成对交叉验证假设目的是利用已知配体化合物和已知靶蛋白的信息来检测缺失的相互作用, 而分块交叉验证假设目标是利用无相互作用伙伴信息来检测新配体化合物和新靶蛋白的新相互作用。成对交叉验证分三步进行: (i) 将金标准集中的 CPI 随机分为大小大致相等的五个子集; 与分割相互作用不同, 块交叉验证将金标准集中的化合物和蛋白质随机分成五个子集。最后, 计算了 5 倍的平均预测精度。

在以下实验中使用了若干性能度量指标。设 TP 和 FP 分别表示正确预测和错误预测为正 CPI 的数量, TN 和 FN 分别表示正确预测和错误预测为负 CPI 的数量, 这些度量指标包括: 精确率 (或正预测值, PPV) = $TP/(TP + FP)$ 、召回率 (或灵敏度) = $TP/(TP + FN)$ 、特异度 = $TN/(FP + TN)$ 以及 AUC (ROC 曲线下面积)。特别地, 当负样本数量远多于正样本数量时, PPV 度量指标反映了分类器区分真正正样本的能力。此外, 由于在正样本数量较少时, 精确率-召回率曲线具有较高的信息量, 因此我们还报告了该曲线。

4.2 对经典分类器的评估

4.2.1 成对交叉验证

我们所使用的包含人类数据的集合中, 有 1052 种独特化合物与 852 种独特蛋白质之间存在 3369 种积极相互作用, 而秀丽隐杆线虫的数据集中则有 1434 种独特化合物与 2504 种独特蛋白质之间存在 4000 种积极相互作用 (数据集可在补充材料中获取)。与 Tabei 和 Yamanishi (2013 年) 的研究类似, 我们评估了在负样本与正样本的比例从 1 增加到 5 时, 每个分类器的性能。随机生成的负样本是通过从不在正样本中的化合物和蛋白质对中随机抽样得到的。对于筛选出的负样本, 我们从我们的方法生成的排名列表中的前 384916 个候选者中获取所需数量的相互作用。我们生成了

表 1. 六种经典分类器在经过筛选的人类负样本和随机生成的负样本上的 AUC/召回率/准确率值（成对交叉验证）

测量	负样本比例	朴素贝叶斯		kNN		随机森林		L1 逻辑回归		L2 逻辑回归		支持向量机	
		随机筛选	随机生成	随机筛选	随机生成	随机筛选	随机生成	随机筛选	随机生成	随机筛选	随机生成	随机筛选	随机生成
AUC	1	0.672	0.622	0.860	0.563	0.940	0.647	0.908	0.874	0.911	0.868	0.910	0.752
	3	0.672	0.622	0.904	0.593	0.954	0.694	0.917	0.879	0.920	0.873	0.942	0.705
	5	0.671	0.622	0.913	0.589	0.967	0.709	0.916	0.877	0.920	0.872	0.951	0.713
精度	1	0.624	0.591	0.798	0.570	0.861	0.613	0.881	0.858	0.891	0.862	0.966	0.733
	3	0.361	0.338	0.716	0.458	0.847	0.529	0.823	0.786	0.837	0.787	0.969	0.700
	5	0.252	0.237	0.684	0.500	0.830	0.514	0.793	0.732	0.804	0.739	0.969	0.732
召回	1	0.575	0.413	0.927	0.564	0.897	0.599	0.893	0.836	0.913	0.850	0.950	0.745
	3	0.560	0.376	0.882	0.306	0.824	0.306	0.749	0.622	0.773	0.631	0.883	0.261
	5	0.555	0.364	0.844	0.205	0.825	0.199	0.649	0.524	0.666	0.522	0.861	0.112

粗体数字代表每种方法所达到的最高性能指标。

通过化学亚结构与蛋白质结构域的张量积运算，获取正样本和负样本的化学基因组学特征。

我们将筛选出的阴性样本与随机生成的阴性样本进行对比，对六种经典分类器进行了性能评估。这六种经典分类器分别是朴素贝叶斯、随机森林、L1-逻辑回归、L2-逻辑回归、支持向量机（SVM）和 k 近邻（kNN）。朴素贝叶斯、随机森林和 k 近邻使用 Weka 3.7（Hall 等人，2009 年）运行，L1 和 L2 逻辑回归使用 liblinear 1.94（Fan 等人，2008 年）运行，支持向量机使用 libsvm 3.17（Chang 和 Lin，2011 年）运行。除了 k 近邻的 k 值分别设置为 1、3 和 5 外，所有方法均在默认设置下运行。由于不同 k 值下结果相似，我们仅报告了 k = 1 的结果。表 1 展示了这六种分类器在人类数据上的 AUC、召回率和准确率指标。我们发现，与随机生成的阴性样本相比，所有六种分类器在我们筛选出的阴性样本上的性能都有显著提高。例如，从朴素贝叶斯到支持向量机这六种分类器，在我们筛选出的阴性样本上相对于随机生成的阴性样本的平均 AUC 提升分别为 8.0%、53.4%、39.7%、4.2%、5.3% 和 29.6%。当负样本的比例增加时，大多数分类器的 AUC 值保持稳定或略有上升。然而，我们也注意到，随着负样本比例的增加，大多数分类器的召回率和准确率会下降，这主要是由于负样本与正样本的比例越来越不平衡，导致分类决策边界对正样本的偏向性越来越大。此外，在秀丽隐杆线虫（C. elegans）上我们也得到了类似的结果，如补充表 S1 所示。这些实证结果表明我们筛选出的负样本具有很高的可靠性。

4.2.2 分块交叉验证

这里，正样本与成对交叉验证中所用的样本相同。通过上述随机抽样程序，选取了与正样本数量相等的随机负样本。此外，还从我们的排名列表中前 384916 名候选者中随机抽取了数量相等的筛选负样本。六种经典分类器以与上述相同的方式运行，其精确率 - 召回率曲线和 AUC 直方图分别展示在图 3 和补充图 S2 中。与成对验证相比，在块交叉验证中，这六种分类器在筛选负样本和随机生成的负样本上的表现均有所下降，但在筛选负样本上的表现仍得到了显著提升。特别是，




图 3. 六种经典分类器在经过筛选和随机生成的人类负样本上的精度 - 召回率曲线（分块交叉验证）

在分块交叉验证下，对于随机生成的负样本，每个分类器的性能都大幅下降，但除了朴素贝叶斯和 kNN 之外，大多数分类器在筛选后的负样本上仍取得了相对较高的 AUC 值：L1 和 L2 逻辑回归以及支持向量机的 AUC 值均大于 0.8。如补充图 S3 所示，这六种分类器在筛选后的负样本上的 AUC 值均高于在秀丽隐杆线虫随机负样本上的 AUC 值，然而与在人类数据集上的整体性能相比，这些分类器的性能略有下降。

4.3 对现有预测方法的评估

我们进一步检验了现有的预测方法在筛选出的阴性样本上是否比在随机生成的阴性样本上表现更优。所评估的现有方法包括 BLM（Bleakley 和 Yamanishi，2009 年）、采用 GIP 核的 RLS-avg 和 RLS-Kron 分类器（van Laarhoven 等人，2011 年）、KBMF2K-classification 和 KBMF2K-regression（Gonen，2012 年）。RLS-avg 和 RLS-Kron 分别通过设置两组不同的参数（0.5, 0.5）和（1, 1）来运行，其余方法则采用默认设置。所有这些方法最初是在 Yamanishi 等人（2008 年）提出的四个广泛使用的涉及酶、离子通道、GPCR 和核受体的人类数据集上进行评估的。但这些四个数据集规模较小，仅涵盖我们方法筛选出的少量阴性样本，因此我们构建了另一个相对较大的人类数据集来评估这些方法。我们从 DrugBank 获取了阳性样本，然后提取了阴性样本。




图4. 三种现有预测方法在筛选出的人类样本和随机生成的阴性样本上所取得的 AUC 值的直方图

我们从排名列表中选取了化合物和蛋白质均呈阳性的样本。最终构建的人类数据集包含 821 种独特化合物与 846 种独特蛋白质之间的 2315 个阳性相互作用和 2576 个阴性相互作用，而秀丽隐杆线虫的数据集包含 543 种化合物与 504 种蛋白质之间的 463 个阳性相互作用和 1561 个阴性样本（数据集可在[补充材料](#)中获取）。由于这些对比方法的输入为化学结构相似性矩阵、蛋白质序列相似性矩阵和 CPI 矩阵，因此我们按照第 2 节所述构建了相似性矩阵和相互作用矩阵。

图 4 展示了这些预测方法在经过筛选的人类负样本和随机生成的人类负样本上所取得的 AUC 值。显然，所有方法在经过筛选的负样本上的表现都显著优于在随机生成的负样本上的表现。特别是 BLM 在随机生成的负样本上的 AUC 值最低（0.679），但在经过筛选的负样本上却取得了与其他方法相当的 AUC 值（0.932）。KBMF2K-classification 和 KBMF2K-regression 在随机生成的负样本上取得了较高的 AUC 值（分别为 0.868 和 0.846），但在经过筛选的负样本上其表现也有了显著提升。在秀丽隐杆线虫（*C.elegans*）上，除了 KBMF2K-classification 和 KBMF2K-regression 之外，所有方法的表现提升都比在人类样本上更为显著，如补充图 S4 所示。尽管 BLM 和四种 RLS 算法在随机生成的负样本上的表现仅属中等，但在经过筛选的负样本上其表现有了大幅提高。这一结果再次表明，我们筛选出的负样本有助于提升现有预测方法的性能。

4.4 药物生物活性数据集评估

针对激酶抑制剂的定量药物-靶点生物活性测定为药物分子与靶点的结合提供了实验观察结果，这使我们能够推导出正负相互作用。正如 Pahikkala 等人（2015 年）所建议的，来自 Davis 等人（2011 年）的最新激酶生物活性测定数据可用作独立基准测试集，以评估药物-靶点预测方法的性能。该测定报告了定量相互作用亲和力和，即解离常数 (K_d)，它反映了药物分子与靶蛋白结合的紧密程度。解离常数 K_d 越小，化合物与靶蛋白之间的相互作用亲和力就越高。

该生物活性测定涵盖了 68 种独特药物与 442 种独特蛋白质之间的相互作用，从中得出了 20931 个结果。




图5所示。

与 K_d 10000 的相互作用作为阴性样品提取。我们在筛选的阴性样本和实验支持的样本之间得到了 3564 个重叠相互作用。我们计算了重叠负样本的频率分布，相对于我们筛选的负样本置信度分数的不断增加的截止阈值，如图 5 所示。可以看出，约 80% 重叠阴性样本的置信度得分大于 0.5，即筛选出的置信度得分越大的阴性样本越有可能得到药物生物活性实验的支持，说明我们筛选出的阴性样本可信度较高。此外，我们使用 Davis et al. (2011) 提出的 30.00nM K_d 阈值提取阳性样品，获得了 1867 个正相互作用。我们选择 SVM 和 L2-logistic 回归进行性能评价，因为它们分别是二元分类和现实回归的代表。

4.5 新相互作用的预测

在确认我们筛选的阴性样本的质量后，我们建立了两套对人类潜在 cpi 的预测。第一个是基于 DrugBank 中包含的化合物和蛋白质集建立的相对小规模预测集。我们提取每个化合物的前 50 个相互作用，得到一组 35 425 个相互作用，其中在 DrugBank 中注释了 1093 个预测，在 STITCH 中注释了 3224 个预测（3224/35 4259.2%）。请注意，对于所有可能的 896 304，在 STITCH 中只记录了 18580 个交互（18580 / 896 3042.1%），因此我们的预测将这些策划的交互排在很高的位置，并优先考虑高度可信的交互。

作为一个确认性示例，我们对多奈哌齐（一种中枢作用的可逆性乙酰胆碱酯酶抑制剂化合物，用于阿尔茨海默病的姑息治疗（Birks 和 Harvey, 2006 年））的预测相互作用进行了研究。我们的方法预测了 253 种靶蛋白，其中包括




图 6. 多奈哌齐的预测靶蛋白及相关功能注释, 包括神经活性配体 - 受体相互作用通路、DrugBank 和 STITCH 中记录的疾病

多奈哌齐在 DrugBank 和 STITCH 中的两个主要作用靶点是编码胆碱酯酶的基因 *ACHE* 和 *BCHE*。实际上, 所确定的靶蛋白集涵盖了 STITCH 中注释的 17 种相互作用, 其相关蛋白均包含在测试集中, 如图 6 所示。为了确认其他新的预测结果, 我们使用 DAVID (Huang 等人, 2009 年) 检查了排名前 125 位的靶蛋白的功能注释, 发现其中 45 种蛋白在神经活性配体 - 受体相互作用通路中高度富集 (P 值 = $4.7E-32$)。这些蛋白与多种精神疾病密切相关, 包括多种精神障碍。此外, 这些蛋白在各种精神和神经疾病中显著相关, 如高血压 (P 值 = $1.5E-11$)、阿尔茨海默病 (P 值 = $3.1E-4$)、帕金森病 (P 值 = $3.0E-4$) 和动脉粥样硬化性心血管疾病 (P 值 = $1.3E-3$)。图 6 展示了多奈哌齐的靶蛋白及其相关功能注释 (有关通路和疾病中涉及的蛋白质详细列表, 请参见补充表 S2)。

这些新的预测将有助于在新药设计中确定真正的可药物靶点。

5 讨论与结论

化合物与蛋白质之间相互作用的鉴定在基因组药物发现中起着重要作用。然而, CPIs 的实验验证仍然是费力且昂贵的, 尽管各种高通量生化分析是可用的。计算机预测方法对指导实验设计和为实验结果提供支持证据具有重要意义。基于机器学习的方法已经被提出并证明了令人鼓舞的性能。不幸的是, 我们对 cpi 负样本的了解非常有限

, 这严重限制了计算方法的性能。这个问题促使我们提出一个系统的筛选工作流程, 以确定可靠的负 cpi。据我们所知, 这是第一个致力于筛选可靠的 cpi 负样本的工作。

我们的筛选框架基于这样一个假设: 对于给定化合物而言, 与任何已知/预测靶点不相似的蛋白质不太可能成为该化合物的靶点, 反之亦然。从化学基因组空间的角度来看, 我们设法找到了那些在化学基因组空间中远离所有阳性样本的化合物 - 蛋白质对作为阴性样本, 这确实有助于提高传统分类器和现有计算方法的性能。此外, 排除了与少量已知相互作用相关的化合物和蛋白质, 以减少由于活性悬崖和支架跳跃而将真实相互作用误判为阴性相互作用的可能性。特征差异过滤进一步巩固了我们不相似性规则的效力。大量实验表明, 我们筛选出的阴性样本具有很高的可信度, 有助于识别化合物 - 蛋白质相互作用。

此外, 我们还给出了一个证实的例子, 即新预测的多奈哌齐靶蛋白在精神和神经通路和疾病中高度富集。总之, 我们筛选的阴性样本和预测为研究界提供了一个有用的资源来确定药物靶点, 并构成了对当前策划的化合物蛋白质数据库的有益补充。

资金

本研究得到了中国国家自然科学基金 (项目编号: 31300707、61272380 和 61173118) 以及新加坡教育部 MOE AcRF 二级资助 (项目编号: ARC 39/13, MOE2013-T2-1-079) 的支持。

利益冲突: 无。

参考文献

- Alaimo, S. et al. (2013) Drug-target interaction prediction through domain-tuned network-based inference. *Bioinformatics*, 29, 2004–2008.
- Ashburner, M. et al. (2013) Gene ontology: tool for the unification of biology. *Nat. Genet.*, 25, 25–29.
- Birks, J. and Harvey, R.J. (2006) Donepezil for dementia due to Alzheimer's disease. *Cochrane Database Syst. Rev.*, 1, CD001190.
- Bleakley, K. and Yamanishi, Y. (2009) Supervised prediction of drug-target interactions using bipartite local models. *Bioinformatics*, 25, 2397–2403.
- Campillos, M. et al. (2008) Drug target identification using side-effect similarity. *Science*, 321, 263–266.
- Carrella, D. et al. (2014) Mantra 2.0: an online collaborative resource for drug mode of action and repurposing by network analysis. *Bioinformatics*, 30, 1787–1788.
- Chang, C.C. and Lin, C.J. (2011) LIBSVM: a library for support vector machines. *ACM Trans. Intell. Syst. Technol.*, 2, 1–27.
- Chen, H. and Zhang, Z. (2013) A semi-supervised method for drug-target interaction prediction with consistency in networks. *PLoS One*, 8, e62975.
- Cheng, F. et al. (2012) Prediction of drug-target interactions and drug repositioning via network-based inference. *PLoS Comput. Biol.*, 8, e1002503.
- Couto, F.M. et al. (2007) Measuring semantic similarity between Gene Ontology terms. *Data Knowl. Eng.*, 61, 137–152.
- Davis, M.I. et al. (2011) Comprehensive analysis of kinase inhibitor selectivity. *Nat. Biotechnol.*, 29, 1046–1051.
- Ding, H. et al. (2014) Similarity-based machine learning methods for predicting drug-target interactions: a brief review. *Brief Bioinform.*, 15, 734–747.
- Fan, R.E. et al. (2008) LIBLINEAR: a library for large linear classification. *J. Machine Learning Res.*, 9, 1871–1874.
- Franceschini, A. et al. (2013) STRING v9.1: protein-protein interaction networks, with increased coverage and integration. *Nucleic Acids Res.*, 41(Database issue), D808–D815.
- Gonen, M. (2012) Predicting drug-target interactions from chemical and genomic kernels using Bayesian matrix factorization. *Bioinformatics*, 28, 2304–2310.
- Gottlieb, A. et al. (2011) PREDICT: a method for inferring novel drug indications with application to personalized medicine. *Mol. Syst. Biol.*, 7, 496.
- Gottlieb, A. et al. (2012) INDI: a computational framework for inferring drug interactions and their associated recommendations. *Mol. Syst. Biol.*, 8, 592.
- Gnther, S. et al. (2008) SuperTarget and Matador: resources for exploring drug-target relationships. *Nucleic Acids Res.*, 36, D919–D922.
- Hall, M. et al. (2009) The WEKA data mining software: an update. *SIGKDD Explor. Newsl.*, 11, 10–18.
- He, Z. et al. (2010) Predicting drug-target interaction networks based on functional groups and biological features. *PLoS One*, 5, e9603.
- Hu, Y. and Bajorath, J. (2012) Extending the activity cliff concept: structural categorization of activity cliffs and systematic identification of different types of cliffs in the ChEMBL database. *J. Chem. Inf. Model.*, 52, 1806–1811.
- Huang, D.W. et al. (2009) Systematic and integrative analysis of large gene lists using DAVID bioinformatics resources. *Nat. Protoc.*, 4, 44–57.
- Iorio, F. et al. (2010) Discovery of drug mode of action and drug repositioning from transcriptional responses. *Proc. Natl. Acad. Sci. USA*, 107, 14621–14626.
- Jaccard, P. (1908) Nouvelles recherches sur la distribution florale. *Bul. Soc. Vaudoise Sci. Nat.*, 44, 223–270.
- Jacob, L. and Vert, J.P. (2008) Protein-ligand interaction prediction: an improved chemogenomics approach. *Bioinformatics*, 24, 2149–2156.
- Jaeger, S. et al. (2014) Causal network models for predicting compound targets and driving pathways in cancer. *J. Biomol. Screen.*, 19, 791–802.
- Jaroch, S.E. and Weinmann, H. (eds) (2006) Chemical genomics: small molecule probes to study cellular function. Ernst Schering Research Foundation Workshop. Springer, Berlin, pp. 1–20.
- Kuhn, M. et al. (2010) A side effect resource to capture phenotypic effects of drugs. *Mol. Syst. Biol.*, 6, 343.
- Kuhn, M. et al. (2014) STITCH 4: integration of protein-chemical interactions with user data. *Nucleic Acids Res.*, 42(D1), D401–D407.
- Lamb, J. et al. (2006) The connectivity map: using gene-expression signatures to connect small molecules, genes, and disease. *Science*, 313, 1929–1935.
- Mei, J.P. et al. (2013) Drug-target interaction prediction by learning from local information and neighbors. *Bioinformatics*, 29, 238–245.
- Metz, J.T. et al. (2011) Navigating the kinome. *Nat. Chem. Biol.*, 7, 200–202.
- Mizutani, S. et al. (2012) Relating drug-protein interaction network with drug side effects. *Bioinformatics*, 28, i522–i528.
- Pahikkala, T. et al. (2015) Toward more realistic drug-target interaction predictions. *Brief Bioinform.*, 16, 325–337.
- Pauwels, E. et al. (2011) Predicting drug side-effect profiles: a chemical fragment-based approach. *BMC Bioinformatics*, 12, 169.
- Perlman, L. et al. (2011) Combining drug and gene similarity measures for drug-target elucidation. *J. Comput. Biol.*, 18, 133–145.
- Punta, M. et al. (2012) The Pfam protein families database. *Nucleic Acids Res.*, 40(Database issue), D290–D301.
- Smith, T.F. and Waterman, M. (1981) Identification of common molecular subsequences. *J. Mol. Biol.*, 147, 195–197.
- Sun, H. et al. (2012) Classification of scaffold-hopping approaches. *Drug. Discov. Today*, 17, 44–57.
- Tabei, Y. and Yamanishi, Y. (2013) Scalable prediction of compound-protein interactions using minwise hashing. *BMC Syst. Biol.*, 7, S3.
- van Laarhoven, T. and Marchiori, E. (2013) Predicting drug-target interactions for new drug compounds using a weighted nearest neighbor profile. *PLoS One*, 8, e66952.
- van Laarhoven, T. et al. (2011) Gaussian interaction profile kernels for predicting drug-target interaction. *Bioinformatics*, 27, 3036–3043.
- Wang, Y. and Zeng, J. (2013) Predicting drug-target interactions using restricted Boltzmann machines. *Bioinformatics*, 29, i126–i134.
- Wang, Y.C. et al. (2011) Kernel-based data fusion improves the drug-protein interaction prediction. *Comput. Biol Chem.*, 35, 353–362.
- Wheeler, D.L. et al. (2006) Database resources of the national center for biotechnology information. *Nucleic Acids Res.*, 34, D173–D180.
- Wishart, D.S. et al. (2008) DrugBank: a knowledgebase for drugs, drug actions and drug targets. *Nucleic Acids Res.*, 36, D901–D906.
- Wolpaw, A.J. et al. (2011) Modulatory profiling identifies mechanisms of small molecule-induced cell death. *Proc. Natl. Acad. Sci. USA*, 108, E771–E780.
- Xia, Z. et al. (2010) Semi-supervised drug-protein interaction prediction from heterogeneous biological spaces. *BMC Syst. Biol.*, 4(Suppl 2), S6.
- Yabuuchi, H. et al. (2011) Analysis of multiple compound-protein interactions reveals novel bioactive molecules. *Mol. Syst. Biol.*, 7, 472.
- Yamanishi, Y. et al. (2008) Prediction of drug-target interaction networks from the integration of chemical and genomic spaces. *Bioinformatics*, 24, i232–i240.
- Yamanishi, Y. et al. (2010) Drug-target interaction prediction from chemical, genomic and pharmacological data in an integrated framework. *Bioinformatics*, 26, i246–i254.
- Yamanishi, Y. et al. (2014) DINIES: drug-target interaction network inference engine based on supervised analysis. *Nucleic Acids Res.*, 42, W39–W45.
- Zhou, T. et al. (2010) Bipartite network projection and personal recommendation. *Phys. Rev. E Stat. Nonlin. Soft Matter Phys.*, 76, 046115.