



引用本文:《化学科学》, 2022
年, 13 卷, 816 页。

本文的所有出版费用

由英国皇家化学学会支付费用

MGraphDTA: 用于可解释药物-靶点结合亲和力预测的深度多尺度图神经网络†

Ziduo Yang, ‡^a Weihe Zhong, ‡^a Lu Zhao^{ab} and Calvin Yu-Chian Chen^{*acd}



预测药物与靶点的亲和力 (DTA) 有助于加快药物研发进程。图神经网络 (GNN) 已被广泛应用于 DTA 预测。然而, 现有的浅层 GNN 无法充分捕捉化合物的整体结构。此外, 基于图的 DTA 模型的可解释性高度依赖于图注意力机制, 该机制无法揭示分子中每个原子之间的全局关系。在本研究中, 我们提出了一种基于化学直觉的用于 DTA 预测的深度多尺度图神经网络 (MGraphDTA)。我们在 GNN 中引入了密集连接, 并构建了一个具有 27 个图卷积层的超深 GNN, 以同时捕获化合物的局部和全局结构。我们还开发了一种新颖的可视化解释方法——梯度加权亲和力激活映射 (Grad-AAM), 从化学角度分析深度学习模型。我们使用七个基准数据集对我们的方法进行了评估, 并将所提出的方法与最先进的深度学习 (DL) 模型进行了比较。MGraphDTA 在各种数据集上的表现均显著优于其他基于深度学习的方法。此外, 我们还表明, Grad-AAM 所生成的解释与药理学家观点一致, 这可能有助于我们直接从超出人类感知的数据中获得化学方面的见解。这些优势表明, 所提出的方法提高了 DTA 预测建模的泛化能力和解释能力。

收稿日期: 2021 年 9 月 18 日
接受日期: 2021 年 12 月 17 日

DOI: 10.1039/d1sc05180f

rsc.li/化学科学

1 简介

药物研发旨在发现能够与靶点结合并改变疾病进程的药物。药物与靶点相互作用的识别是开发新药及了解其副作用的重要步骤。¹ 结合亲和力提供了药物与靶点配对之间相互作用强度的信息, 通常以解离常数 (K_d)、抑制常数 (K_i) 或半数最大抑制浓度 (IC_{50})² 等指标来表示。蛋白质微阵列³ 和亲和层析⁴ 是两种用于测量结合亲和力的生物学实验方法。为了识别

对于给定蛋白质的有效且安全的药物, 药理学家必须测试数千种化学化合物。⁵ 然而, 药物与靶点亲和力 (DTA) 的实验测量既耗时又耗费资源。由于其高效性和低成本, 基于计算机的 DTA 预测方法受到了极大的关注。现有的基于计算机的方法主要可以分为三类: 基于结构的方法、基于特征的方法和深度学习方法。

基于结构的方法可以通过考虑小分子和蛋白质的三维结构来探索潜在的结合位点。对接是一种成熟的基于结构的方法, 它使用多种模式定义和评分函数来最小化结合的自由能。分子动力学模拟是另一种流行的基于结构的方法, 能够提供有关单个粒子随时间运动的最详细信息。⁶ 然而, 基于结构的方法耗时较长, 如果蛋白质的三维结构未知, 则无法使用。⁷

基于特征的药物-靶点相互作用 (DTA) 预测建模方法也被称为蛋白质化学计量学 (PCM),⁸⁻¹⁰ 它依赖于显式配体和蛋白质描述符的组合。任何药物和靶点的组合都可以用具有特定长度的生物特征向量来表示, 通常带有二进制标签, 以确定药物是否能与靶点结合。提取的生物特征向量可用于训练诸如前馈神经网络等机器学习模型。

^aArtificial Intelligence Medical Center, School of Intelligent Systems Engineering, Sun Yat-sen University, Shenzhen, 510275, China. E-mail: chenychian@mail.sysu.edu.cn; Tel: +862039332153

^bDepartment of Clinical Laboratory, The Sixth Affiliated Hospital, Sun Yat-sen University, Guangzhou, 510655, China

^cDepartment of Medical Research, China Medical University Hospital, Taichung, 40447, Taiwan

^dDepartment of Bioinformatics and Medical Engineering, Asia University, Taichung, 41354, Taiwan

† Electronic supplementary information (ESI) available: Details of machine learning construction, vertex features of graphs, data distributions, hyperparameters tuning, and additional visualization results. See DOI: 10.1039/d1sc05180f

‡ Equal contribution.

网络 (FNNs)、支持向量机 (SVM)、随机森林 (RF) 以及其他基于核函数的方法 methods.^{11–19} 例如, Deep-DTIs²⁰ 选择了最常见且简单的特征: 扩展连接性指纹 (ECFP) 和蛋白质序列组成描述符 (PSC) 来表示药物和靶点, 并使用深度信念网络进行药物-靶点相互作用 (DTA) 预测。Lenselink 等人¹¹ 在一个标准化的数据集上将 FNNs 与逻辑回归、RF 和 SVM 等不同的机器学习方法进行了比较, 发现 FNNs 是表现最佳的分类器。Mayr 等人的一项研究¹² 也得出了类似的结果, 即 FNNs 的表现优于其他竞争方法。MDeePred²¹ 通过结合序列、结构、进化和物理化学性质等多种类型的蛋白质特征来表示蛋白质描述符, 并使用混合深度神经网络从化合物和蛋白质描述符中预测结合亲和力。MoleculeNet²² 引入了一种称为网格特征化器的特征化方法, 该方法利用了配体和靶点的结构信息。网格特征提取器不仅考虑蛋白质和配体各自的特征, 还考虑结合口袋内的化学相互作用。

在过去的几年里, 由于诸如高通量筛选、平行合成等新型实验技术的出现, 可用的化合物活性和生物医学数据量显著增加。对海量数据进行探索和分析的高需求推动了诸如深度学习等数据密集型算法的发展。在药物靶点相互作用 (DTA) 预测中, 已采用了多种深度学习框架。DeepDTA² 建立了两个卷积神经网络 (CNN) 分别学习药物和蛋白质的表示。然后将学习到的药物和蛋白质表示进行拼接, 并输入到多层感知机 (MLP) 中进行 DTA 预测。WideDTA²⁸ 通过整合两个额外的基于文本的输入, 并使用四个 CNN 将其编码为四个表示, 进一步提高了 DeepDTA 的性能。Lee 等人²⁹ 还在蛋白质序列上使用了 CNN 来学习局部残基模式, 并进行了大量实验以证明基于 CNN 方法的有效性。另一方面, DEEPScreen 将化合物表示为二维结构图像, 并使用卷积神经网络 (CNN) 从这些二维结构图中学习复杂特征, 从而生成高度准确的药物-靶点相互作用 (DTA) 预测。³⁰

尽管基于卷积神经网络 (CNN) 的方法在药物-靶点相互作用 (DTA) 预测方面取得了显著成效, 但这些模型大多将药物表示为字符串, 这并非化合物的自然表示方式。³¹ 使用字符串时, 分子的结构信息会丢失, 这可能会削弱模型的预测能力以及所学潜在空间的功能相关性。为解决这一问题, 图神经网络 (GNN) 已被应用于 DTA 预测 prediction.^{31–36} 基于 GNN 的方法将药物表示为图, 并使用 GNN 进行 DTA 预测。例如, Tsubaki 等人³⁴ 提出使用 GNN 和 CNN 分别学习化合物图和蛋白质序列的低维向量表示。他们将 DTA 预测表述为一个分类问题, 并在三个数据集上进行了实验。实验结果表明, 基于 GNN 的方法优于 PCM 方法

。GraphDTA³¹ 评估了包括 GCN、GAT、GIN 和 GAT-GCN 在内的几种 GNN 类型在 DTA 预测中的表现, 其中 DTA 被视为一个回归问题。实验结果证实, 深度学习方法能够进行药物-靶点相互作用 (DTA) 预测, 并且将药物表示为图结构能够进一步提高预测效果。DGraphDTA³⁷ 将化合物和蛋白质都表示为图, 并在化合物和蛋白质两侧使用图神经网络 (GNNs) 来获取它们的表示。此外, 为了提高模型的可解释性, 在 DTA 预测中引入了注意力机制 models.^{32,36,38–40}

另一方面, 一些研究侧重于通过使用蛋白质的结构相关特征作为输入来改进 DTA 预测。^{37,41} 例如, DGraphDTA³⁷ 利用从蛋白质序列预测得到的接触图作为蛋白质编码器的输入, 以提高 DTA 预测的性能。由于蛋白质结构信息并非总是可用, 因此它们使用从序列预测得到的接触图, 这使得模型能够接受各种蛋白质作为输入。

总体而言, 基于浅层图神经网络 (GNN) 的药物-靶点相互作用 (DTA) 预测的许多新模型已被开发出来, 并在各种数据集上表现出良好的性能。然而, 基于 GNN 的 DTA 预测方法至少存在三个尚未得到很好解决的问题。首先, 我们认为, 层数较少的 GNN 不足以捕捉化合物的全局结构。如图 1(a) 所示, 两层的 GNN 无法知晓分子中是否存在环, 生成的图嵌入将不考虑环的信息。为了捕捉由 k 跳邻居构成的结构, 应堆叠 k 层图卷积层。⁴² 然而, 由于过度平滑和梯度消失问题, 目前构建深层 GNN 架构是不可行的。^{43,44} 因此, 大多数最先进的 (SOTA) GNN 模型的层数不超过 3 或 4 层。其次, 一个构建良好的 GNN 应当能够保留化合物的局部结构。如图 1(b) 所示, 甲基羧酸酯基团对于癸酸甲酯至关重要, GNN 应当将其与不太重要的取代基区分开来, 以便做出合理的推断。第三, 基于图的 DTA 模型的可解释性高度依赖于注意力机制。尽管注意力机制提供了有效的可视化解释, 但它增加了计算成本。此外, 图注意力机制仅考虑顶点的邻域 (也称为掩码注意力), ^{45,46} 无法捕捉分子中每个原子之间的全局关系。

为解决上述问题, 我们提出了一种多尺度图神经网络 (MGNN) 以及一种名为梯度加权亲和激活映射 (Grad-AAM) 的新型视觉解释方法, 用于药物-靶点相互作用 (DTA) 预测及解释。所提出的 MGraphDTA 概览如图 2 所示。分别使用具有 27 个图卷积层的 MGNN 和多尺度卷积神经网络 (MCNN) 来提取药物和靶点的多尺度特征。这些多尺度特征




图 1 全局和局部结构信息对于图神经网络 (GNN) 都很重要。(a) 以橙色碳为中心, 绿色部分展示了 GNN 第二层的视野。在这个例子中, 两层的 GNN 无法识别玉米赤霉烯酮的环状结构。(b) GNN 应该保留局部结构信息, 以便将甲基羧酸酯基团 (橙色椭圆) 与其他不太重要的取代基区分开来。

该药物所含的丰富信息涵盖了分子结构的不同尺度, 使图神经网络能够做出更准确的预测。分别提取药物和靶点的多尺度特征, 然后进行拼接, 以获得给定药物-靶点对的组合描述符。将组合描述符输入多层感知机 (MLP) 以预测结合亲和力。Grad-AAM 利用亲和力在最终图卷积层的梯度, 生成概率图, 突出显示对药物-靶点相互作用 (DTA) 贡献最大的重要原子。所提出的 Grad-AAM 受到梯度加权类激活映射 (Grad-CAM) 的启发, Grad-CAM 可以生成粗略的定位图, 突出图像中的重要区域。⁴⁷然而, Grad-CAM 是为基于卷积神经网络 (CNN) 的神经网络分类任务而设计的。与 Grad-CAM 不同, Grad-AAM 是由

基于图神经网络的结合亲和力评分。本文的主要贡献有两方面:

(a) 我们构建了一个非常深的图神经网络用于药物-靶点相互作用预测, 并从化学角度对其进行了合理解释。

(b) 我们提出了一种简单但有效的可视化方法, 称为 Grad-AAM, 用于探究图神经网络在药物-靶点相互作用预测中是如何做出决策的。

2 方法

2.1 输入表示

输入的分子是 SMILES (简化分子线性输入规范), 这是一种使用简短的 ASCII 字符串来描述化学物质结构的系统, 而输入的目标则是蛋白质序列 (字符串), 其中每个字符代表




图 2 展示了所提出的 MGraphDTA 模型的概貌。MGNN 和 MCNN 分别用于提取输入药物图和蛋白质序列的多尺度特征。将两个编码器输出的多尺度特征分别融合, 然后拼接, 以获得药物-靶点对的组合表示。最后, 将组合表示输入到多层感知机 (MLP) 中以预测结合亲和力。Grad-AAM 利用流入 MGNN 最后一个图卷积层的梯度信息来理解每个神经元对于亲和力决策的重要性。






图 3 分子表示与图嵌入。(a) 将分子表示为图。(b) 对应于公式 (1) 的图消息传递阶段。(c) 对应于公式 (2) 的读出阶段。
$$x_i^{(t+1)} = \sigma \left(W_1 x_i^{(t)} + W_2 \sum_{j \in N(i)} x_j^{(t)} \right) \quad (1)$$

一种氨基酸。我们使用 RDkit⁴⁸ 将 SMILES 预处理为具有顶点（或节点）特征和邻接矩阵的图，如图 3(a) 所示。有关顶点特征的更多详细信息，请参见 ESI 表 S1 和 S2。[†] 对于蛋白质序列，我们首先构建了一个词汇表，将每个字符映射到一个整数（例如，丙氨酸 (A) 是 1，半胱氨酸 (C) 是 2，谷氨酸 (E) 是 4，依此类推），以便将蛋白质表示为整数序列。为了便于训练，我们决定将蛋白质序列的最大长度固定为 1200，这样最大长度至少能涵盖 80% 的蛋白质，这是根据先前的研究建议得出的。² 然后，我们通过一个嵌入层^{2,29} 将每个整数映射为一个可学习的 128 维向量（即每个氨基酸都可以用一个 128 维的嵌入向量来表示）。虽然也可以使用独热向量来编码蛋白质，但它们无法描述两个不同氨基酸之间的语义相似性。例如，每对不同的独热向量的余弦相似度都为零。

2.2 图神经网络

图 G 可表示为 $G = (V, E)$ ；其中 V 是顶点集， E 是边集。在分子中， $v_i \in V$ 是第 i 个原子， $e_{ij} \in E$ 是第 i 个和第 j 个原子之间的化学键。图神经网络 (GNN) 将图 G 映射到向量 y_G ，通常包含消息传递阶段和读出阶段。消息传递阶段通过考虑 G 中每个顶点的相邻顶点来更新每个顶点的信息，而读出阶段则为整个图计算特征向量 y 。

2.2.1 消息传递阶段。给定一个图 G ，我们用 $x_i(t) \in \mathbb{R}^d$ 表示在时间步 t 时的第 i 个顶点嵌入。然后，我们使用以下图卷积层将 $x_i(t)$ 更新为 $x_i(t+1) \in \mathbb{R}^d$ ：⁵⁰

其中， $(W_1; W_2 \in \mathbb{R}^{h \times d})$ 是所有顶点共享的可学习权重矩阵， $N(i)$ 是顶点 i 的邻域集合， $\sigma(\cdot)$ 包含一个节点级别的批量归一化⁴⁴，后面跟着一个 ReLU 激活函数，其中批量归一化对于非常深的模型至关重要。⁵¹ 通过使用公式 (1) 聚合邻域消息，并在时间步长上进行迭代，顶点嵌入可以逐渐收集图上的更多全局信息。

2.2.2 读出阶段。为了从图 G 中的顶点向量集合中获得最终的输出向量 y ，我们对顶点嵌入取平均值：

$$y_G = \frac{1}{|V|} \sum_{v \in V} x_v^{(L)} \quad (2)$$

其中， $|V|$ 是分子图中的顶点数量， L 是最终的时间步长。读出阶段将顶点嵌入聚合为统一的图嵌入。

2.3 用于药物编码的多尺度图神经网络

将药物化合物表示为图形后，我们基于化学直觉设计了一种多尺度图神经网络 (MGNN)，能够有效地从图形数据中学习。图 4 展示了所提出的 MGNN 的网络架构。该 MGNN 包含三个多尺度模块，每个多尺度模块后面都跟着一个过渡层，如图 4 (a) 所示。

2.3.1 多尺度块。一个多尺度块包含 N 个由公式 (1) 描述的图卷积层。受 DenseNet 的启发，^{43,52} 我们在图神经网络中引入了密集连接。密集连接将每一层与其他所有层相连。






图 4 多尺度图神经网络 (MGNN) 概述。(a) 所提出的 MGNN 的网络架构。(b) 多尺度模块的详细设计。

如图 4(b) 所示, 以前馈方式堆叠层。密集连接使所有层都能直接获取损失函数关于每个权重的梯度, 从而避免梯度消失问题, 并能够训练非常深的 GNN。形式上, 我们可以将多尺度块表示为

$$\begin{aligned} x_i^{(1)} &= \mathcal{H}(x_i^{(0)}, \Theta_1) \\ x_i^{(2)} &= \mathcal{H}(x_i^{(0)} \parallel x_i^{(1)}, \Theta_2) \\ x_i^{(3)} &= \mathcal{H}(x_i^{(0)} \parallel x_i^{(1)} \parallel x_i^{(2)}, \Theta_3) \\ x_i^{(N)} &= \mathcal{H}(x_i^{(0)} \parallel x_i^{(1)} \parallel \dots \parallel x_i^{(N-1)}, \Theta_N) \end{aligned} \quad (3)$$

其中 $\mathcal{H}$ 是由公式 (1) 描述的图卷积层, 其参数为 Q_n (包含 W_1 和 W_2), 其中 n 表示第 n 层, k 表示拼接操作)。多尺度块提取了多尺度特征, 这些特征描述了分子在局部和全局上下文中的结构信息。

2.3.2 过渡层。为了增加多尺度图神经网络 (MGNN) 的深度, 我们使用过渡层来

连接两个相邻的多尺度块。过渡层旨在整合来自前一个多尺度块的多尺度特征, 并减少特征图的通道数。具体而言, 对于在时间步长 $N+1$ 处的输入多尺度特征 $x_i^{(0)} \parallel x_i^{(1)} \parallel \dots \parallel x_i^{(N)} \in \mathbb{R}^{d+(N-1)h}$, 我们将其过渡层表示如下:

$$\begin{aligned} x_i^{(N+1)} &= \sigma \left(\Phi_1(x_i^{(0)} \parallel x_i^{(1)} \parallel \dots \parallel x_i^{(N)} \right. \\ &\quad \left. + \Phi_2 \sum_{j \in N(i)} (x_j^{(0)} \parallel x_j^{(1)} \parallel \dots \parallel x_j^{(N)}) \right) \end{aligned} \quad (4)$$

其中 $F_1, F_2 \in \mathbb{R}^{d \times d}$ 是在所有顶点间共享的可学习权重矩阵, 其中 $M = d + (N \rightarrow 1)h$ 。通过使用转换层, 我们将通道数减少到输入的一半以节省计算成本。最后, 使用由公式 (2) 描述的读出层将整个图转换为特征向量 $y_G \in \mathbb{R}^d$ 。



2.4 用于目标编码的多尺度卷积神经网络

遵循 MGNN 的思路，我们使用 MCNN 来提取蛋白质的多尺度特征，如图 5 所示。具体而言，我们设计了一个包含三个分支的网络，每个分支由具有不同感受野的卷积层组成，以检测蛋白质在不同尺度下的局部残基模式。我们通过堆叠 3×3 的卷积层来增加感受野，三个分支的感受野分别为 3、5 和 7。由于在 DTA 中，只有蛋白质的某些部分，如特定的结构域或基序，参与其中，而非整个蛋白质结构。²⁹ 因此，为了

DTA 预测而将感受野扩大到覆盖整个蛋白质序列似乎不太合适，因为这会引入未参与 DTA 的序列部分的噪声信息。²⁹ 正式来说，对于长度为 1200 的整数蛋白质序列输入，我们首先使用嵌入层^{2,28,29,31} 将每个整数映射为 128 维向量，遵循先前的研究^{2,28,31} 并获得输入矩阵 $S \in \mathbb{R}^{1200 \times 128}$ ；然后，我们使用 MCNN 将 S 映射为特征向量 $y_S \in \mathbb{R}^d$ ，如下所示

$$y_S = W(m(\mathcal{F}_1(S)) \parallel m(\mathcal{F}_2(S)) \parallel m(\mathcal{F}_3(S))) \quad (5)$$




图 5 所提 MCNN 的网络架构。



其中, (F_i) 是第 (i) 个分支, 包含 $(i \geq 3)$ 个卷积层, 将 (S) 映射为 $(C \in \mathbb{R}^{1200 \times h})$ 矩阵, 每个卷积层后都接有 ReLU 激活函数, (m) 表示将 (C) 映射为 (h) 维向量的最大池化操作, $(W \in \mathbb{R}^{d \times 3h})$ 是一个可学习的矩阵。

2.5 MGraphDTA网络架构

在获得药物和靶点的向量表示后, 将这两种表示进行拼接, 并输入到多层感知机 (MLP) 中以预测结合亲和力得分, 如图 2 所示。具体而言, 该多层感知机包含三个线性变换层, 用于将组合表示映射为亲和力得分, 其中每个线性变换层后面都跟着一个 ReLU 激活层和一个丢弃率为 0.1 的丢弃层, 这与之前的研究一致。² MGraphDTA 包含用于药物编码的 MGNN、用于靶点编码的 MCNN 以及用于 DTA 预测的 MLP, 如图 2 所示。我们使用均方误差 (MSE) 作为损失函数, 如下所示。

$$MSE = \frac{1}{n} \sum_{i=1}^n (P_i - Y_i)^2 \quad (6)$$

其中 P_i 和 Y_i 分别为第 i 个药物-靶点对的预测得分和真实得分, n 为样本数量。我们还将 DTA 预测视为一个二分类问题, 只需将均方误差损失替换为交叉熵损失即可。⁵³

2.6 梯度加权亲和力激活映射

为了提升 DTA 建模的解释能力, 我们提出了一种无需注意力机制的可视化解释方法, 称为 Grad-AAM。Grad-AAM 利用存储在 MGNN 最后一层图卷积层中的梯度信息来理解每个神经元对于亲和力决策的重要性。图卷积层自然保留了全连接层中丢失的空间信息。因此, 我们可以期望最后一层图卷积层在高级语义和详细的空间信息之间达到最佳平衡。⁴⁷ 具体来说, 设最后一层图卷积层的特征图为 A , 为了获得给定分子的化学概率图 PGrad-

AAM $\in \mathbb{R}^n$ (顶点数为 n), 我们首先计算亲和力得分 P 对于 A 中第 k 通道第 v 顶点的神经元 A_{vk} 的梯度。然后可以计算通道重要性权重 α_k 。

$$\alpha_k = \frac{1}{|V|} \sum_{v \in V} \frac{\partial P}{\partial A_v^k} \quad (7)$$

然后, 我们对前向激活图进行加权组合, 随后应用 ReLU 激活函数。

$$P_{\text{Grad-AAM}} = \sum_k \alpha_k A^k \quad (8)$$

最后, 采用了最小-最大归一化方法将概率图 $P_{\text{Grad-AAM}}$ 映射到 0 到 1 的范围内。化学概率图 $P_{\text{Grad-AAM}}$ 可以被视为由图神经网络捕获的分子重要几何子结构的加权聚合, 如图 6 所示。

2.7 数据集

本研究中用于回归任务的基准数据集为 Metz、⁵⁴KIBA、⁵⁵Davis⁵⁶ 数据集。这三个数据集的结合亲和力分别以抑制常数 (K_i)、KIBA 分数、⁵⁵和解离常数 (K_d) 衡量。需要注意的是, Davis 数据集在实验无法测量活性的所有药物-靶点对方面存在高度偏差, 这些都被标记为 10 mM 生物活性值 (即 pK_d 值 5), 符合这一定义的数据点数量极高 (如图 S1† 所示)。因此, 我们还评估了模型在过滤掉 10 mM 生物活性数据点后的 Davis 数据集²¹ 中的表现。

我们还将 DTA 预测表述为一个二分类问题, 并在两个广泛使用的分类数据集 (人类和秀丽隐杆线虫 (*C. elegans*)) 中对所提出的 MGraphDTA 进行了评估。^{34,38,46}

此外, 我们利用 ToxCast 数据集对 Grad-AAM 进行了案例研究评估。³⁵ 由于 ToxCast 数据集




图 6 化学概率图是通过图神经网络捕获的分子中关键子结构的加权总和。



表 1 七个数据集的摘要

数据集	任务类型	化合物	蛋白质	互动
戴维斯	回归	68	442	30056
过滤后的戴维斯	回归	68	379	9125
KIBA	回归	2111	229	118254
梅斯	回归	1423	170	35259
人类	分类	2726	2001	6728
秀丽隐杆线虫	分类	1767	1876	7786
ToxCast	回归	3098	37	114626

包含多种测定方法，这意味着一种药物 - 靶点对可能因测定方法的不同而具有不同的结合亲和力。为简便起见，我们仅选取了包含药物 - 靶点对数量最多的其中一种测定方法。表 1 总结了这些数据集。图 S1 - S3† 分别展示了这些数据集的结合亲和力分布、SMILES 长度和蛋白质序列长度。

2.8 实验装置

实验是在配备 11GB 内存的 NVIDIA GeForce GTX 2080TI 上进行的。使用了学习率为 0.0005 的 Adam 优化器²⁷来更新模型参数。批处理大小设置为 512。我们使用自动超参数优化软件 Optuna，在 Davis 训练集的五折交叉验证下对 MGraphDTA 进行了超参数优化。⁵⁸ 优化后的超参数在所有其他数据集上保持不变。表 S3† 列出了详细的超参数设置。MGNN 包含 27 个图卷积层，其中有多尺度块，每个块包含 8 个图卷积层，以及三个过渡层。

3 结果与讨论

3.1 与最先进的 DTA 预测模型在分类任务中的比较

对于分类任务，我们沿用先前研究中的做法，使用曲线下面积（AUC）、准确率和召回率作为性能指标来评估模型。^{34,38,46} 我们将 MGraphDTA 与最先进的图神经网络（GNN）模型、³⁴GraphDTA、³¹TrimNet、⁴⁶VQA

-seq、⁴¹TransformerCPI³⁸进行了比较。需要指出的是，DrugVQA⁴¹ 使用了蛋白质的结构相关特征作为输入，而其仅使用蛋白质序列信息的替代版本 VQA-seq⁴¹ 也在此列出，以作公平比较。为确保比较的公平性，我们使用了与先前研究相同的数据集和数据划分方案。^{34,46} GraphDTA³¹ 最初是为回归任务设计的，后经 Chen 等人改编用于分类任务，³⁸ 我们使用了他们报告的结果进行比较。所有实验均重复三次，每次使用不同的随机种子，以符合先前研究的惯例。^{38,41} 最终，我们在 DTA 预测中报告了结果的均值和标准差。

表 2 总结了定量结果。对于人类数据集，所提出的方法在药物 - 靶点相互作用（DTA）预测的精度方面显著高于其他方法。对于秀丽隐杆线虫数据集，所提出的方法在精度和召回率方面都有了显著的提升。这些结果揭示了 MGraphDTA 在药物发现的分子表示学习方面具有巨大潜力。此外，我们还观察到用 MCNN 替代 CNN 可以带来轻微的改进，这证实了所提出的 MCNN 的有效性。

3.2 与回归任务中的最先进 DTA 预测模型进行比较

对于 Davis、KIBA 和 Metz 数据集上的回归任务，我们沿用先前研究中的做法，使用均方误差（MSE，越小越好）、一致性指数（CI，越大越好）⁵⁹ 以及 rm2 指数（越大越好）⁶⁰ 作为性能指标来评估模型。^{2,28,31} 我们将所提出的 MGraphDTA 与 SOTA 模型 DeepDTA、WideDTA、GraphDTA、DeepAffinity^{32,33} 进行了比较。我们排除了 DGraphDTA³⁷，因为它使用了蛋白质的结构相关特征作为输入，以确保比较的公平性。我们还将所提出的方法与五种传统的 PCM 模型进行了比较，包括 KronRLS、SimBoost、随机森林（RF）、支持向量机（SVM）和前馈神经网络（FNN）。KronRLS 和 SimBoost 的结果取自 DeepDTA，² 而其他三种方法则使用 sklearn⁶¹ 和 PyTorch⁶² 实现（有关 PCM 模型构建的详细信息，请参阅 ESI† 中的 S1 部分）。对于 Davis 和 KIBA 数据集，我们使用了与 DeepAffinity 相同的训练集和测试集。

表 2 所提出的 MGraphDTA 与基准方法在人类和秀丽隐杆线虫数据集上的比较结果（分类）

数据集	模型	精度	召回	AUC
人类	GNN-CNN（图神经网络-卷积神经网络）	0.923	0.918	0.970
	TrimNet-CNN	0.918	0.953	0.974
	图深度学习药物相互作用预测模型	0.882 (0.040)	0.912 (0.040)	0.960 (0.005)
	药物问答系统（序列型视觉问答）	0.897 (0.004)	0.948 (0.003)	0.964 (0.005)
	变压器CPI	0.916 (0.006)	0.925 (0.006)	0.973 (0.002)
	MGNN-CNN（我们的）	0.953 (0.006)	0.950 (0.004)	0.982 (0.001)
	MGNN-MCNN（我们的）	0.955 (0.005)	0.956 (0.003)	0.983 (0.003)
	GNN-CNN（图神经网络-卷积神经网络）	0.938	0.929	0.978
	TrimNet-CNN	0.946	0.945	0.987
秀丽隐杆线虫	图深度学习药物相互作用预测模型	0.927 (0.015)	0.912 (0.023)	0.974 (0.004)
	变压器CPI	0.952 (0.006)	0.953 (0.005)	0.988 (0.002)
	MGNN-CNN（我们的）	0.979 (0.005)	0.961 (0.002)	0.991 (0.002)
	MGNN-MCNN（我们的）	0.980 (0.004)	0.967 (0.005)	0.991 (0.001)

为了进行公平的比较，我们使用了 GraphDTA 和之前的模型。由于之前的研究所提供的实验结果中没有涉及 Metz 数据集，我们随机将 Metz 数据集划分为训练集（28207 个样本）和测试集（7052 个样本），并使用他们提供的源代码^{2,31} 以及已发布的超参数网格重新训练了模型。所有实验均重复三次，每次使用不同的随机种子。

对于过滤后的 Davis 数据集上的回归任务，我们将所提出的 MGraphDTA 与该数据集中的 SOTA 方法（即 MDeePred、²¹CGKronRLS、⁶³和 DeepDTA）进行了比较。²我们沿用 MDeePred 的做法，采用均方根误差（RMSE，越小越好）、CI 和斯皮尔曼等级相关系数（越高越好）作为性能指标。整个数据集被随机分为六部分；其中五部分用于五折交叉验证，剩余部分用作独立测试集。最终性能在独立测试集上进行评估，与 MDeePred 保持一致。请注意，每折中的数据点与 MDeePred 完全相同，以确保公平比较。

表 3 和表 4 总结了 MGraphDTA 以及先前模型在 Davis、KIBA 和 Metz 数据集上的预测性能。基于图的方法超越了基于卷积神经网络（CNN）和循环神经网络（RNN）的方法，这表明图神经网络在药物靶点相互作用（DTA）预测方面具有潜力。由于基于 CNN 和 RNN 的模型将化合物表示为字符串，如果不考虑分子的结构信息，模型的预测能力可能会减弱。相比之下，基于图的方法将化合物表示为图，并通过图顶点之间的消息传递来捕捉图的依赖关系。与其他基于图的方法相比，MGraphDTA 在表 3 和表 4 中取得了最佳性能。配对的学生 t 检验表明，在 Metz 数据集上，MGraphDTA 与其他基于图的方法之间的差异具有统计学意义（ $p < 0.05$ ）。此外，MGraphDTA 在三个数据集上均显著优于传统的 PCM 模型（ $p < 0.01$ ）。值得注意的是，FNN 明显优于其他传统 PCM 模型（ $p < 0.01$ ），这表明了其在预测中的优势。

表 3 在 Davis 和 KIBA 数据集上提出的 MGraphDTA 与基线方法的比较结果（回归）

数据集			戴维斯			KIBA		
模型	蛋白质	化合物	均方误差	CI	删除 index 文件夹中的内容	均方误差	CI	删除第 2 行索引
DeepDTA ^a	CNN	美国有线电视新闻网	0.261	0.878	0.630	0.194	0.863	0.673
WideDTA ^b	CNN 加 PDM	CNN 加上 LMCS	0.262	0.886	—	0.179	0.875	—
GraphDTA ^c	美国有线电视新闻网	图卷积网络	0.254	0.880	—	0.139	0.889	—
GraphDTA ^c	CNN	GAT	0.232	0.892	—	0.179	0.866	—
GraphDTA ^c	CNN	金酒	0.229	0.893	—	0.147	0.882	—
GraphDTA ^c	CNN	GAT-GCN	0.245	0.881	—	0.139	0.891	—
DeepAffinity	循环神经网络	循环神经网络	0.253	0.900	—	0.188	0.842	—
DeepAffinity	循环神经网络	图卷积网络	0.260	0.881	—	0.288	0.797	—
DeepAffinity	CNN	图卷积网络	0.657	0.737	—	0.680	0.576	—
DeepAffinity	HRNN	图卷积网络	0.252	0.881	—	0.201	0.842	—
DeepAffinity	HRNN	金酒	0.436	0.822	—	0.445	0.689	—
KronRLS ^a	SW	PS	0.379	0.871	0.407	0.411	0.782	0.342
SimBoost ^d	SW	PS	0.282	0.872	0.655	0.222	0.836	0.629
射频	ECFP	港口国监督	0.359 (0.003)	0.854 (0.002)	0.549 (0.005)	0.245 (0.001)	0.837 (0.000)	0.581 (0.000)
支持向量机	ECFP	PSC	0.383 (0.002)	0.857 (0.001)	0.513 (0.003)	0.308 (0.003)	0.799 (0.001)	0.513 (0.004)
前馈神经网络	ECFP	港口国监督	0.244 (0.009)	0.893 (0.003)	0.685 (0.015)	0.216 (0.010)	0.818 (0.005)	0.659 (0.015)
MGraphDTA	MCNN	MGNN	0.207 (0.001)	0.900 (0.004)	0.710 (0.005)	0.128 (0.001)	0.902 (0.001)	0.801 (0.001)

^a 这些结果取自 DeepDTA。^{2b} 这些结果取自 WideDTA。^{2c} 这些结果取自 GraphDTA。^{31d} 这些结果取自 DeepAffinity。³² - 这些结果并非来自原始研究。

表 4 在 Metz 数据集上提出的 MGraphDTA 与基线方法的比较结果（回归）

模型	蛋白质	化合物	均方误差	CI	删除第 2 行索引
深度药物靶点相互作用预测模型	美国有线电视新闻网	美国有线电视新闻网	0.286 (0.001)	0.815 (0.001)	0.678 (0.003)
图深度学习药物相互作用预测模型	美国有线电视新闻网	图卷积网络	0.282 (0.007)	0.815 (0.002)	0.679 (0.008)
图深度学习药物相互作用预测模型	美国有线电视新闻网	GAT	0.323 (0.003)	0.800 (0.001)	0.625 (0.010)
图深度学习药物相互作用预测模型	美国有线电视新闻网	金酒	0.313 (0.002)	0.803 (0.001)	0.632 (0.001)
图深度学习药物相互作用预测模型	美国有线电视新闻网	GAT-GCN	0.282 (0.011)	0.816 (0.004)	0.681 (0.026)
射频	ECFP	PSC	0.351 (0.002)	0.793 (0.001)	0.565 (0.001)
支持向量机	ECFP	港口国监督	0.361 (0.001)	0.794 (0.000)	0.590 (0.001)
FNN	ECFP	港口国监督	0.316 (0.001)	0.805 (0.001)	0.660 (0.003)
MGraphDTA	MCNN	MGNN	0.265 (0.002)	0.822 (0.001)	0.701 (0.001)

表 5 在经过筛选的 Davis 数据集上所提出的 MGraphDTA 与基线方法的比较结果 (回归)

模型	均方根误差	CI	斯皮尔曼
MDeePred ^a	0.742 (0.009)	0.733 (0.004)	0.618 (0.009)
CGKronRLS ^a	0.769 (0.010)	0.740 (0.003)	0.643 (0.008)
DeepDTA ^a	0.931 (0.015)	0.653 (0.005)	0.430 (0.013)
MGraphDTA	0.695 (0.009)	0.740 (0.002)	0.654 (0.005)

这些结果取自 MDeePred。²¹

与之前的研究结果一致。^{11,12}表 5 总结了在经过筛选的 Davis 数据集上四种方法的结果。可以看出, MGraphDTA 的均方根误差 (RMSE) 最低。总体而言, MGraphDTA 在四个基准数据集上取得了

令人瞩目的成绩, 显著优于其他最先进的药物靶点相互作用 (DTA) 预测模型, 这证明了所提出的 MGraphDTA 的有效性。

3.3 在更贴近实际的实验环境中进行性能评估

第 3.1 节和第 3.2 节描述了使用随机分割设置 (即训练集和测试集共享相同的药物和靶点) 的实验结果。然而, 值得注意的是, 随机分割设置可能会导致过于乐观的结果, 因为它会导致信息泄露 (例如药物或靶点信息) 到测试集。¹² 为了进一步证明所提出的 MGNN 的有效性, 我们除了使用先前研究中采用的随机分割设置外, 还在另外三种分割方案中评估了 MGraphDTA: ^{2,28,31,32}




图 7 展示了 MGNN 与其他七种模型在 Davis、KIBA 和 Metz 数据集上的比较结果, 比较指标为均方误差 (MSE)、置信区间 (CI) 和 r_m^2 指数 (从左至右), 分别采用 (a) 孤儿药物、(b) 孤儿靶点和 (c) 基于聚类的划分设置。

孤儿目标分离：测试集中的每个蛋白质在训练集中均不存在。

(2) 孤儿药分离：测试集中的每种药物在训练集中均无法获取。

(3) 基于聚类的拆分：训练集和测试集中的化合物在结构上存在差异（即，两组在结构相似性方面保证了最小距离）。我们依照先前的研究，使用二值化 ECFP4 特征的杰卡德距离来衡量任意两个化合物之间的距离。¹² 单连接聚类¹² 被用于找到任意两个聚类之间具有保证最小距离的聚类。

鉴于 DTA 预测模型通常用于发现训练集中不存在的药物或靶点，孤儿集分割为模型提供了更贴近实际且更具挑战性的评估方案。基于聚类的分割进一步防止了化合物的结构信息泄露到测试集中。我们将所提出的 MGraphDTA 与 GraphDTA 以及三种传统的 PCM 模型（RF、SVM 和 FNN）进行了比较。为了公平起见，我们使用 GraphDTA 提供的源代码将 MGraphDTA 中的 MGNN 替换为 GCN、GAT、GIN 和 GAT-GCN，并采用了他们所报告的超参数。我们采用了五折交叉验证策略来分析模型性能。在每一轮中，所有方法都使用相同的训练集、验证集和测试集。请注意，这八种方法的实验设置保持一致。

图 7 展示了使用孤儿药物分割和聚类分割设置的八种方法的实验结果。与表 3 和表 4 中使用随机分割设置的结果相比，我们发现模型在孤儿药物分割和聚类分割设置下的性能大幅下降。此外，如图 7(a) 和 (c) 所示，在 Davis、KIBA 和 Metz 数据集上使用孤儿药物分割时，MGraphDTA 的均方误差分别为 0.572 0.088、0.3

90 0.023 和 0.555 0.043，而使用聚类分割时分别为 0.654 0.207、0.493 0.097 和 0.640 0.078。换句话说，与孤儿药物分割相比，聚类分割对 DTA 预测模型更具挑战性，这与聚类分割设置能够防止化合物的结构信息泄露到测试集这一事实相符。这些结果表明，提高 DTA 模型的泛化能力仍然是一个挑战。从图 7(a) 可以看出，在 Davis 数据集上使用孤儿药物分割设置时，MGNN 显著优于其他方法 ($p < 0.01$)。另一方面，在 KIBA 数据集中，MGNN、GAT 和 RF 之间没有统计学差异 ($p > 0.05$)，但这些方法显著优于其他方法 ($p < 0.01$)。此外，在 Metz 数据集中，SVM 和 FNN 方法显著优于其他方法 ($p < 0.01$)。总体而言，传统的 PCM 模型在 KIBA 和 Metz 数据集使用孤儿药物分割设置时表现出色，甚至超过了基于图的方法，如图 7(a) 所示。这些结果表明，在这种情况下，使用像 RF 这样简单的基于特征的方法可能就足够了，这与最近的一项研究结果一致。⁶⁴ 由于 Davis 数据集中的药物数量明显少于 KIBA 和 Metz 数据集，如表 1 所示，因此在有限药物上训练的模型对于未见过的药物的泛化能力无法得到保证。图 8 展示了在 Davis 数据集上使用孤儿药物分割时，五个基于图的模型的预测值与真实值之间的相关性。如图 8(a) 所示，MGNN 的预测值范围比其他基于图的模型更广。我们还注意到，如图 8(b) 所示，MGNN 的真实值和预测值分布最为相似。GCN、GAT、GIN、GAT-GCN 和 MGNN 对 DTA 进行预测的皮尔逊相关系数分别为 0.427、0.420、0.462、0.411 和 0.552。这些结果表明




图 8 (a) 为使用孤儿药物划分设置的 Davis 数据集预测值与真实值之间结合亲和力的散点图，(b) 为核密度估计图。

进一步证实了 MGNN 有潜力提升 DTA 模型的泛化能力。从图 7(b) 可以看出, 在使用孤儿靶点分割设置的三个数据集中, MGNN 显著优于其他模型 ($p < 0.01$)。如图 7(c) 所示, 在使用基于聚类的分割设置的 KIBA 和 Metz 数据集中, MGNN 也显著优于其他方法 ($p < 0.05$)。值得注意的是, 如表 3 和表 4 所示, 在随机分割设置中, 基于图的方法优于传统的 PCM 模型, 而在基于孤儿和基于聚类的分割设置中, 基于图的方法的优势则不太明显, 如图 7 所示。总体而言, 结果表明 MGNN 在不同的分割设置方案中具有鲁棒性, 并证明了给定分子的局部和非局部属性对于 GNN 进行准确预测都是必不可少的。

3.4 消融研究

在我们的设计中, 构建非常深的 GNN 的成功高度依赖于密集连接和批量归一化。密集连接通过缓解过度平滑和梯度消失问题来提升模型性能, 而批量归一化则能够减少非常深模型的过拟合。⁵¹ 进行了一项消融研究, 以探究密集连接和批量归一化各自的贡献。实验从两个方面进行; 在第一种情况下, 我们移除了密集连接, 在第二种情况下, 我们移除了批量归一化。表 6 总结了在经过筛选的 Davis 数据集上的实验结果。结果表明, 密集连接和批量归一化对于 MGNN 来说都是必不可少的。

此外, 我们还在经过筛选的 Davis 数据集上进行了消融实验, 以探究 MCNN 的感受野对模型性能的影响。具体而言, 我们通过使用具有越来越大卷积核 (即 7、15、23、31) 的卷积层, 逐步增大感受野。从表 7 所示的结果可以看出, 随着感受野的增大, 模型性能略有下降。由于通常只有少量残基参与蛋白质与配体的相互作用,⁶⁶ 增大感受野以覆盖更多区域可能会将未参与 DTA 的序列部分的噪声信息引入模型。

我们还进行了一项实验, 以证明 MGraphDTA 在进行药物-靶点相互作用 (DTA) 预测时, 会同时利用化合物和蛋白质的信息, 而非像先前研究中所报道的那样, 只是学习数据集固有的偏差。^{66,67} 具体而言, 我们计算了最后一层中每个单元的激活值。

表 7 MCNN 最大感受野对过滤后的 Davis 数据集 (回归) 的影响

最大感受野	均方根误差	CI	斯皮尔曼
31	0.718 (0.002)	0.732 (0.005)	0.636 (0.013)
23	0.713 (0.008)	0.732 (0.004)	0.635 (0.008)
15	0.710 (0.006)	0.734 (0.005)	0.639 (0.011)
7	0.695 (0.009)	0.740 (0.002)	0.654 (0.005)

在 Davis、过滤后的 Davis、KIBA 和 Metz 数据集中, 分别对两个编码器 (即第 2.3 节和 2.4 节中描述的 yG 和 yS) 进行了研究。激活值越高, 表明该单元在模型决策中的贡献越大。⁶⁸ 图 9 展示了来自蛋白质和配体编码器的这些激活值的分布情况。可以看出, MGraphDTA 同时利用了蛋白质和配体的信息来进行推断。然而, 在 Davis 数据集中, 该模型更倾向于蛋白质信息。这种偏差部分是由于 Davis 数据集中结合亲和力 (标签) 的分布不均衡所致, 如图 S1† 所示, 因为在过滤后的 Davis 数据集中这种偏差有所减轻, 如图 9 所示。更确切地说, Davis 数据集包含 63 种蛋白质, 与这些蛋白质相关的任何药物-靶点对都被标记为 10 mM 的生物活性值 (即 pK_d 值为 5)。因此, 预测模型可能会简单地与这些蛋白质相关的药物-靶点对输出大约 10 mM 的结合亲和力值, 从而导致模型偏向于蛋白质编码器。而在过滤后的 Davis 数据集中, 这些蛋白质被移除, 因此偏差得以减轻。另一个可能的原因是, 戴维斯数据集仅包含 68 种化合物, 数量不足, 无法学习到一个稳健的药物编码器。

3.5 Grad-AAM 提供了视觉解释

深度学习通常被称为黑箱模型, 因为很难追溯预测结果是由哪些特征所决定的。这种不可解释性限制了深度学习方法的应用, 尤其是在计算机辅助药物发现领域。为了使基于图的模型更具合理性, 我们基于 Grad-AAM 可视化了分子中原子的重要性。我们在 ToxCast 数据集上将 Grad-AAM 与图注意力机制进行了比较, 以探究基于图的模型是否能够检测出导致特定毒性的关键子结构 (也称为结构 alerts^{69,70})。我们进行了以下三组实验:

基于 Grad-AAM 的 MGNN 模型可视化。

(2) 基于 Grad-AAM 的 GAT 模型可视化。

表 6 研究密集连接和批量归一化各自的贡献 (回归)

模型	均方根误差	CI	斯皮尔曼
无密集连接	0.726 (0.008)	0.726 (0.008)	0.620 (0.019)
无批次 标准化	0.746 (0.032)	0.719 (0.014)	0.604 (0.008)
MGraphDTA	0.695 (0.009)	0.740 (0.002)	0.654 (0.005)






图9 在 Davis、过滤后的 Davis、KIBA 和 Metz 数据集上，配体编码器和蛋白质编码器的最后几层的激活值分布情况。

(3) 基于图注意力机制的 GAT 模型可视化。

具体来说，我们首先用两层 GAT 替换了 MGNN，其中第一层图卷积层使用了 GraphDTA 提供的源代码设置了十个并行注意力头。³¹ 然后，我们在五折交叉验证策略下，采用随机分割设置训练了基于 MGNN 和基于 GAT 的 DTA 预测模型。最后，我们利用 Grad-AAM 和图注意力机制计算了原子的重要性，并使用 RDkit 展示了概率图。⁴⁸

表 8 展示了 MGNN 和 GAT 的定量结果。MGNN 明显优于 GAT ($p < 0.01$)，这进一步证实了所提出的 MGNN 的优越性。图 10 展示了基于 Grad-AAM (MGNN)、Grad-AAM (GAT) 和图注意力机制的一些分子的可视化结果（更多示例见 ESI 图 S4 和 S5†）。根据先前的研究，studies,^{71–75} 环氧化物、⁷³ 脂肪酸、^{72,75} 磷酸盐、⁷¹ 芳香硝基化合物⁷⁴ 是与特定毒理学终点相关的结构警示。我们发现 Grad-AAM (MGNN) 确实对这些结构警示赋予了最高的权重。Grad-AAM (MGNN) 不仅能识别

出重要的小基团，如图 10(a)–(d) 所示，还能揭示出大基团，如图 10(f) 所示，这证明了 MGNN 能够同时捕捉局部和全局结构。Grad-AAM (GAT) 也能辨别出结构警示，如图 10(b)、(c)、(e) 和 (f) 所示。然而，Grad-AAM (GAT) 有时未能检测到结构警示，如图 10(a) 和 (d) 所示，我们还注意到突出显示的区域涉及更广泛的区域，并且与图 10(b)、(c) 中所示的精确结构警示并不对应。并且 (e) 这些结果表明，GAT 学习到的隐藏表示不足以很好地描述分子。另一方面，图注意力机制只能揭示出一些结构警戒基团中的原子，如图 10 (c)、(d) 和 (f) 所示。由于图注意力机制仅考虑原子的邻域，因此其注意力图包含的有关分子全局结构的信息较少。⁴⁵ 图注意力机制的优势在于它能够同时突出原子和键，而 Grad-AAM 只能突出原子。图 11 展示了 Grad-AAM (MGNN)、Grad-AAM (GAT) 和图注意力机制下原子重要性的分布情况。Grad-AAM (MGNN) 的分布呈左偏态，这表明 MGNN 更关注那些对毒性贡献最大的特定取代基，同时抑制了不太重要的部分。

表 8 在 ToxCast 数据集 (回归) 上所提出的 MGNN 与 GAT 的对比结果

模型	蛋白质	化合物	均方误差	CI	删除第 2 行索引
图深度学习药物相互作用预测模型	MCNN	GAT	0.215 (0.007)	0.843 (0.005)	0.330 (0.007)
MGraphDTA	MCNN	MGNN	0.176 (0.007)	0.902 (0.005)	0.430 (0.006)




图 10 由 Grad-AAM (MGNN)、Grad-AAM (GAT) 和结构警戒团中的图注意力揭示的原子重要性: (a) 和 (b) 环氧化物, (c) 和 (d) 脂肪酸, (e) 磺酸盐, 以及 (f) 芳香族亚硝基。

我们还发现, Grad-AAM (GAT) 倾向于突出分布中的大量原子, 这与图 10 (b)、(c) 和 (e) 所示的结果一致。相反, 图注意力的分布较窄, 大多数值小于 0.5, 这表明图注意力往往未能检测到重要的子结构。值得注意的是, 一些研究利用全局注意力机制, 同时丢弃图的所有结构信息来可视化模型, 并且也可能提供合理的视觉

解释。^{46,76}然而, 这些基于全局注意力的方法是针对特定模型的, 因此这些方法难以转移到其他图模型。相反, Grad-AAM 是一种通用的可视化解释方法, 可以轻松转移到其他图模型。此外, 通过在 MGraphDTA 的训练过程中应用正则化技术, Grad-AAM 产生的视觉解释结果可能会进一步得到改善。⁷⁷




图 11 展示了 Grad-AAM (MGNN)、Grad-AAM (GAT) 和图注意力机制下原子重要性的分布情况。请注意，对于 Grad-AAM (GAT)，我们未考虑键的重要性。

总体而言，Grad-AAM 生成的解释往往比图注意力机制更准确，这可能有助于从生物学角度解释基于深度学习的药物-靶点相互作用预测。图 12 展示了 Grad-AAM (MGNN) 在具有对称结构的化合物上的表现。Grad-AAM (MGNN) 的分布也呈对称性，这表明将化合物表示为图并使用 GNN 提取化合物的模式能够保留化合物的结构。

3.6 MGNN 如何解决过度平滑问题？

正如我们之前提到的，非常深的图神经网络 (GNN) 旨在同时捕捉化合物的全局和局部结构。然而，非常深的 GNN 可能会导致顶点表示的过度平滑。换句话说，我们为获得更具表达力且更了解图结构的模型（通过增加更多层，使顶点具有更大的感受野）所做的努力，可能会变成一个将所有顶点视为相同的模型（顶点表示收敛为无法区

分的向量）。⁷⁸ 消息传递框架从邻居处收集特征向量，并将其与顶点特征相结合以更新其表示。因此，过度平滑表现为顶点嵌入之间的相似性。如图 13 所示，随着模型深度的增加，越来越多的原子被纳入顶点表示的计算中。同时，原子 C2 和 C1 的顶点嵌入变得越来越相似，并且我们可以观察到在第 3 层中唯一的区别在于原子 C5。因此，随着模型深度的增加，GNN 可能无法区分分子中的不同子结构。所提出的 MGNN 通过整合给定顶点或原子的不同感受野的特征来解决过度平滑问题，如图 4(b) 所示。通过在 GNN 中引入密集连接，尽管模型深度不断增加，但分子的不同尺度的子结构仍能得以保留。密集连接还增加了每个顶点嵌入之间的区分度，从而缓解了过度平滑问题。表 6 显示，密集连接能显著提高模型性能 ($p < 0.01$)。图 14 展示了由 Grad-AAM (MGNN) 突出显示的具有相似结构的分子。Grad-AAM (MGNN) 检测到了这四个分子之间的细微差异，这表明 MGNN 能够缓解过度平滑问题。

3.7 局限性

尽管 MGraphDTA 在 DTA 预测任务中已展现出显著的改进，但本研究仍存在一些局限性。首先，本研究仅关注相对较小的数据集。未来的工作中，我们将对大规模数据集进行 MGraphDTA 的测试^{11,12}。其次，值得注意的是，许多含有结构警戒基团的化合物是无活性的（不具有特定毒性）。为了确定化合物对特定靶点是否具有毒性，我们应当分析药物-靶点的结合模式。未来的工作将侧重于使用 Grad-AAM 进行结合模式的可视化。




图 12 具有对称结构的分子的 Grad-AAM (MGNN)






图 13 化合物 4-丙基环己酮中 GNN 第 1 层、第 2 层和第 3 层的感受野。(a) 原子 C2 的感受野。(b) 原子 C1 的感受野。




图 14 结构相似分子的 Grad-AAM (MGNN)

4 结论

这项工作提出了一种基于化学直觉的新型图框架，称为 MGraphDTA，用于药物-靶点相互作用 (DTA) 预测。MGraphDTA 利用具有 27 层图卷积层的多图神经网络 (MGNN) 来捕捉分子的多尺度结构，并采用 Grad-AAM 进行可视觉解释。大量实验验证了所提出方法的优越性，在七个数据集上显著优于最先进的方法。此外，我们使用来自 ToxCast 数据集的毒性标签，通过 Grad-AAM 可视化了某些分子的原子重要性，并表明 MGNN 能够检测结构警报。我们的结果表明，MGraphDTA 是一种强大的工具，能够提高 DTA 预测建模的泛化能力和解释能力。

代码可用性

MGraphDTA 和 Grad-AAM 的演示、说明和代码可在 <https://github.com/guaguabujianle/MGraphDTA> 获取。

数据可用性

本文所用的所有数据均为公开数据，可从以下网址获取：Davis 和 KIBA 数据集在 <https://github.com/hkmztrk/DeepDTA/tree/master/data>，过滤后的 Davis 数据集在 <https://github.com/cansyl/MDeePred>，Metz 数据集和 ToxCast 数据集在 <https://github.com/simonfqy/PADME>，人类和秀丽隐杆线虫数据集在 https://github.com/masashitsubaki/CPI_prediction。



作者贡献

陈宇谦 (Calvin Yu-Chian Chen) 设计了研究方案。杨子铎 (Ziduo Yang) 和钟伟和 (Weihe Zhong) 共同完成了实验并分析了数据。陈宇谦 (Calvin Yu-Chian Chen) 参与了分析工具的开发。杨子铎 (Ziduo Yang)、钟伟和 (Weihe Zhong)、赵璐 (Lu Zhao) 和陈宇谦 (Calvin Yu-Chian Chen) 共同撰写了论文。

利益冲突

作者声明他们不存在利益冲突。

致谢

本研究得到了国家自然科学基金 (项目编号: 62176272)、广州市科技计划项目 (项目编号: 201803010072)、深圳市科技创新委员会 (项目编号: JCYL 20170818165305521) 以及中国医科大学附属第一医院 (项目编号: DMR-111-102、DMR-111-143、DMR-111-123) 的支持。我们还感谢中山大学“百人计划”提供的启动资金。

参考文献

- 1 T. Zhao, Y. Hu, L. R. Valsdottir, T. Zang and J. Peng, *Brief. Bioinform.*, 2021, 22, 2141–2150.
- 2 H. O. Zhang, A. O. Zhang, E. Ozkirimli, *Bioinformatics*, 2018, 34, i821–i829.
- 3 H. Lee and J. W. Lee, *Arch. Pharm. Res.*, 2016, 39, 1193–1201.
- 4 M. Schirle and J. L. Jenkins, *Drug Discov. Today*, 2016, 21, 82–89.
- 5 J. Peng, Y. Wang, J. Guan, J. Li, R. Han, J. Hao, Z. Wei and X. Shang, *Brief. Bioinform.*, 2021, 22(5), DOI: 10.1093/bib/bba430.
- 6 M. Karplus and J. A. McCammon, *Nat. Struct. Biol.*, 2002, 9, 646–652.
- 7 Y. Yamanishi, M. Araki, A. Gutteridge, W. Honda and M. Kanehisa, *Bioinformatics*, 2008, 24, i232–i240.
- 8 B. J. Bongers, A. P. IJzerman and G. J. P. Van Westen, *Drug Discov. Today Technol.*, 2019, 32, 89–98.
- 9 G. J. P. van Westen, J. K. Wegner, A. P. IJzerman, H. W. T. van Vlijmen and A. Bender, *Medchemcomm*, 2011, 2, 16–30.
- 10 I. Cortés-Ciriano, Q. U. Ain, V. Subramanian, E. B. Lenselink, O. M'endez-Lucio, A. P. IJzerman, G. Wohlfahrt, P. Prusis, T. E. Malliavin, G. J. P. van Westen and others, *Medchemcomm*, 2015, 6, 24–50.
- 11 E. B. Lenselink, N. Ten Dijke, B. Bongers, G. Papadatos, H. W. T. Van Vlijmen, W. Kowalczyk, A. P. IJzerman and G. J. P. Van Westen, *J. Cheminform.*, 2017, 9, 1–14.
- 12 A. Mayr, G. Klambauer, T. Unterthiner, M. Steijaert, J. K. Wegner, H. Ceulemans, D.-A. Clevert and S. Hochreiter, *Chem. Sci.*, 2018, 9, 5441–5451.
- 13 R. S. Olayan, H. Ashoor and V. B. Bajic, *Bioinformatics*, 2018, 34, 1164–1173.
- 14 T. He, M. Heidemeyer, F. Ban, A. Cherkasov and M. Ester, *J. Cheminform.*, 2017, 9, 1–14.
- 15 Y. Chu, A. C. Kaushik, X. Wang, W. Wang, Y. Zhang, X. Shan, D. R. Salahub, Y. Xiong and D. Q. Wei, *Brief. Bioinform.*, 2021, 22, 451–462.
- 16 A. Ezzat, M. Wu, X.-L. Li and C.-K. Kwok, *Methods*, 2017, 129, 81–88.
- 17 T. Pahikkala, A. Airola, S. Pietilä, S. Shakyawar, A. Szajda, J. Tang and T. Aittokallio, *Brief. Bioinform.*, 2015, 16, 325–337.
- 18 Q. Kuang, Y. Li, Y. Wu, R. Li, Y. Dong, Y. Li, Q. Xiong, Z. Huang and M. Li, *Chemom. Intell. Lab. Syst.*, 2017, 162, 104–110.
- 19 Y. Chu, X. Shan, T. Chen, M. Jiang, Y. Wang, Q. Wang, D. R. Salahub, Y. Xiong and D.-Q. Wei, *Brief. Bioinform.*, 2021, 22(3), DOI: 10.1093/bib/bba205.
- 20 M. Wen, Z. Zhang, S. Niu, H. Sha, R. Yang, Y. Yun and H. Lu, *J. Proteome Res.*, 2017, 16, 1401–1409.
- 21 A. S. Rifaioğlu, R. Cetin Atalay, D. Cansen Kahraman, T. Dogan, M. Martin and V. Atalay, *Bioinformatics*, 2021, 37(5), 693–704.
- 22 Z. Wu, B. Ramsundar, E. N. Feinberg, J. Gomes, C. Geniesse, A. S. Pappu, K. Leswing and V. Pande, *Chem. Sci.*, 2018, 9, 513–530.
- 23 M. K. Gilson, T. Liu, M. Baitaluk, G. Nicola, L. Hwang and J. Chong, *Nucleic Acids Res.*, 2016, 44, D1045–D1053.
- 24 G. Papadatos, A. Gaulton, A. Hersey and J. P. Overington, *J. Comput. Aided. Mol. Des.*, 2015, 29, 885–896.
- 25 S. Kim, P. A. Thiessen, E. E. Bolton, J. Chen, G. Fu, A. Gindulyte, L. Han, J. He, S. He, B. A. Shoemaker and others, *Nucleic Acids Res.*, 2016, 44, D1202–D1213.
- 26 H. Chen, O. Engkvist, Y. Wang, M. Olivecrona and T. Blaschke, *Drug Discov. Today*, 2018, 23, 1241–1250.
- 27 H. Altae-Tran, B. Ramsundar, A. S. Pappu and V. Pande, *ACS Cent. Sci.*, 2017, 3, 283–293.
- 28 H. O. Zhang, E. Ozkirimli and A. O. Zhang, *arXiv Preprint*, 2019, arXiv:1902.04166.
- 29 I. Lee, J. Keum and H. Nam, *PLoS Comput. Biol.*, 2019, 15, e1007129.
- 30 A. S. Rifaioğlu, E. Nalbat, V. Atalay, M. J. Martin, R. Cetin-Atalay and T. Dogan, *Chem. Sci.*, 2020, 11, 2531–2557.
- 31 T. Nguyen, H. Le, T. P. Quinn, T. Nguyen, T. D. Le and S. Venkatesh, *Bioinformatics*, 2021, 37, 1140–1147.
- 32 M. Karimi, D. Wu, Z. Wang and Y. Shen, *J. Chem. Inf. Model.*, 2020, 61, 46–66.
- 33 M. Karimi, D. Wu, Z. Wang and Y. Shen, *Bioinformatics*, 2019, 35, 3329–3338.
- 34 M. Tsubaki, K. Tomii and J. Sese, *Bioinformatics*, 2019, 35, 309–318.
- 35 Q. Feng, E. Dueva, A. Cherkasov and M. Ester, 2018, *arXiv Preprint*, arXiv:1807.09741.
- 36 W. Torng and R. B. Altman, *J. Chem. Inf. Model.*, 2019, 59, 4131–4149.
- 37 M. Jiang, Z. Li, S. Zhang, S. Wang, X. Wang, Q. Yuan and Z. Wei, *RSC Adv.*, 2020, 10, 20701–20712.
- 38 L. Chen, X. Tan, D. Wang, F. Zhong, X. Liu, T. Yang, X. Luo, K. Chen, H. Jiang and M. Zheng, *Bioinformatics*, 2020, 36, 4406–4414.



- 39 B. Agyemang, W.-P. Wu, M. Y. Kpiebaareh, Z. Lei, E. Nanor and L. Chen, *J. Biomed. Inform.*, 2020, 110, 103547.
- 40 Z. Yang, W. Zhong, L. Zhao and C. Y.-C. Chen, *J. Phys. Chem. Lett.*, 2021, 12, 4247–4261.
- 41 S. Zheng, Y. Li, S. Chen, J. Xu and Y. Yang, *Nat. Mach. Intell.*, 2020, 2, 134–140.
- 42 G. S. Na, H. W. Kim and H. Chang, *J. Chem. Inf. Model.*, 2020, 60, 1137–1145.
- 43 G. Li, M. Muller, A. Thabet and B. Ghanem, in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2019, pp. 9267–9276.
- 44 Y. Li, P. Li, X. Yang, C.-Y. Hsieh, S. Zhang, X. Wang, R. Lu, H. Liu and X. Yao, *Chem. Eng. J.*, 2021, 414, 128817.
- 45 P. Velickovic, A. Casanova, P. Li, G. Cucurull, A. Romero and Y. Bengio, 6th International Conference on Learning Representations, ICLR 2018 - Conference Track Proceedings, 2018.
- 46 P. Li, Y. Li, C.-Y. Hsieh, S. Zhang, X. Liu, H. Liu, S. Song and X. Yao, *Brief. Bioinform.*, 2021, 22(4), DOI: 10.1093/bib/bbaa266.
- 47 R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh and D. Batra, in *Proceedings of the IEEE international conference on computer vision*, 2017, pp. 618–626.
- 48 A. P. Bento, A. Hersey, E. Felix, G. Landrum, A. Gaulton, F. Atkinson, L. J. Bellis, M. De Veij and A. R. Leach, *J. Cheminform.*, 2020, 12, 1–16.
- 49 J. Gilmer, S. S. Schoenholz, P. F. Riley, O. Vinyals and G. E. Dahl, in *International Conference on Machine Learning*, 2017, pp. 1263–1272.
- 50 C. Morris, M. Ritzert, M. Fey, W. L. Hamilton, J. E. Lenssen, G. Rattan and M. Grohe, in *Proceedings of the AAAI Conference on Artificial Intelligence*, 2019, vol. 33, pp. 4602–4609.
- 51 K. He, X. Zhang, S. Ren and J. Sun, in *European conference on computer vision*, 2016, pp. 630–645.
- 52 G. Huang, Z. Liu, L. Van Der Maaten and K. Q. Weinberger, in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2017, pp. 4700–4708.
- 53 Z. Yang, L. Zhao, S. Wu and C. Y.-C. Chen, *IEEE J. Biomed. Heal. Informatics*, 2021, 25, 1864–1872.
- 54 J. T. Metz, E. F. Johnson, N. B. Soni, P. J. Merta, L. Kiefer and P. J. Hajduk, *Nat. Chem. Biol.*, 2011, 7, 200–202.
- 55 J. Tang, A. Szwajda, S. Shakyawar, T. Xu, P. Hintsanen, K. Wennerberg and T. Aittokallio, *J. Chem. Inf. Model.*, 2014, 54, 735–743.
- 56 M. I. Davis, J. P. Hunt, S. Herrgard, P. Ciceri, L. M. Wodicka, G. Pallares, M. Hocker, D. K. Treiber and P. P. Zarrinkar, *Nat. Biotechnol.*, 2011, 29, 1046–1051.
- 57 D. P. Kingma and J. L. Ba, 3rd International Conference on Learning Representations, ICLR 2015 - Conference Track Proceedings, 2015.
- 58 T. Akiba, S. Sano, T. Yanase, T. Ohta and M. Koyama, in *Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining*, 2019, pp. 2623–2631.
- 59 M. Gonen and G. Heller, *Biometrika*, 2005, 92, 965–970.
- 60 K. Roy, P. Chakraborty, I. Mitra, P. K. Ojha, S. Kar and R. N. Das, *J. Comput. Chem.*, 2013, 34, 1071–1082.
- 61 F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg and others, *J. Mach. Learn. Res.*, 2011, 12, 2825–2830.
- 62 A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimelshein, L. Antiga, A. Desmaison, A. Kopf, E. Yang, Z. DeVito, M. Raison, A. Tejani, S. Chilamkurthy, B. Steiner, L. Fang, J. Bai and S. Chintala, *Adv. Neural Inf. Process. Syst.*, 2019, 32, 8026–8037.
- 63 A. Airola and T. Pahikkala, *IEEE Trans. neural networks Learn. Syst.*, 2017, 29, 3374–3387.
- 64 Q. Ye, C.-Y. Hsieh, Z. Yang, Y. Kang, J. Chen, D. Cao, S. He and T. Hou, *Nat. Commun.*, 2021, 12, 6775.
- 65 B. K. C. Dukka, *Comput. Struct. Biotechnol. J.*, 2013, 8, e201308005.
- 66 L. Chen, A. Cruz, S. Ramsey, C. J. Dickson, J. S. Duca, V. Hornak, D. R. Koes and T. Kurtzman, *PLoS One*, 2019, 14, e0220113.
- 67 J. Sieg, F. Flachsenberg and M. Rarey, *J. Chem. Inf. Model.*, 2019, 59, 947–961.
- 68 C. Cao, X. Liu, Y. Yang, Y. Yu, J. Wang, Z. Wang, Y. Huang, L. Wang, C. Huang, W. Xu and others, in *Proceedings of the IEEE international conference on computer vision*, 2015, pp. 2956–2964.
- 69 Z. Wu, D. Jiang, J. Wang, C.-Y. Hsieh, D. Cao and T. Hou, *J. Med. Chem.*, 2021, 64, 6924–6936.
- 70 A. Mukherjee, A. Su and K. Rajan, *J. Chem. Inf. Model.*, 2021, 61, 2187–2197.
- 71 M. D. Barratt, D. A. Basketter, M. Chamberlain, G. D. Admans and J. J. Langowski, *Toxicol. Vit.*, 1994, 8, 1053–1060.
- 72 A. S. Kalgutkar and J. R. Soglia, *Expert Opin. Drug Metab. Toxicol.*, 2005, 1, 91–142.
- 73 M. P. Payne and P. T. Walsh, *J. Chem. Inf. Comput. Sci.*, 1994, 34, 154–161.
- 74 J. Kazius, R. McGuire and R. Bursi, *J. Med. Chem.*, 2005, 48, 312–320.
- 75 V. Poitout, J. Amyot, M. Semache, B. Zarrouki, D. Hagman and G. Fontès, *Biochim. Biophys. Acta, Mol. Cell Biol. Lipids*, 2010, 1801, 289–298.
- 76 Z. Xiong, D. Wang, X. Liu, F. Zhong, X. Wan, X. Li, Z. Li, X. Luo, K. Chen, H. Jiang and others, *J. Med. Chem.*, 2019, 63, 8749–8760.
- 77 R. Henderson, D.-A. Clevert and F. Montanari, in *Proceedings of the 38th International Conference on Machine Learning*, ed. M. Meila and T. Zhang, PMLR, 2021, vol. 139, pp. 4203–4213.
- 78 K. Oono and T. Suzuki, 2019, *arXiv Prepr*, arXiv1905.10947.