

基于 Transformer-CNN-OMBO 算法的分子亚结构模式发现及其在药物-靶点相互作用(DTI)预测中的应用

K. Nandhini Research Scholar

计算机科学系,韦尔斯科学技术与高级研究院
印度泰米尔纳德邦金奈市帕拉瓦拉姆

kgnandhugopi@gmail.com (电子邮件地址无需翻译)

Dr. P.Mayilvahanan Professor & Director,

计算机科学系

印度泰米尔纳德邦金奈市帕拉瓦拉姆的 Vels 科学、
技术与高级研究院

mayil.scs@velsuniv.ac.in (此邮件地址无需翻译)

摘要 - 预测药物 - 靶点相互作用 (DTI) 在药物发现和再定位中至关重要,因为它能确定化学分子与靶点蛋白之间的反应。目前,研究人员使用基于机器学习 (ML) 的监督学习方法来处理预测问题。药物 - 靶点相互作用的预测受到不平衡数据集的阻碍。现有的分子表示学习算法未包含 DTI 的子结构,这导致了精度不足和难以表述。本研究提出了用于 DTI 相互作用预测的 Transformer-CNN-OMBO 技术。首先,需要使用改进的频繁子序列挖掘 (IFSM) 技术将输入的药物和蛋白质数据集转换为明确的子结构。然后将这些子结构送入 Transformer 绑定阶段,为每个结构生成上下文绑定。通过添加最优卷积神经网络 (CNN) 层来提取邻域相互作用,并预测由此产生的相互作用。在训练过程中,采用基于反对派的帝王蝶优化 (OMBO) 算法来优化卷积神经网络 (CNN) 层的超参数。利用 BindingDB 数据集,对 Transformer+CNN 和 MPNN+CNN 模型进行了所建议技术的测试。推荐的 Transformer-CNN-OMBO 技术在准确率、灵敏度和特异性等指标上均有所提升。

关键词 - 药物 - 靶点相互作用(DTI)、分子子结构、改进的频繁子序列挖掘(IFSM)、卷积神经网络(CNN)、基于对立面的帝王蝶优化算法(OMBO)、Transformer

I. 简介

药物与靶点的相互作用表明,药物的作用与行为改变的部位有关。当药物被摄入或吸收时,药物或必要的治疗手段可能包含一种能以物质形式影响人体的化合物。任何与药物生理效应相关的机体部位都是靶点。为生物目的检测新的药物化合物取决于对药物与靶点相互作用的预测。蛋白质偶联受体、酶和离子通道是

如今,预测药物 - 靶点相互作用 (DTIs) 对于发现新药和药物再定位至关重要,因为它能确定化学分子与靶点之间的反应。用于识别药物 - 靶点相互作用的实验成本高昂且耗时很长,往往在有效药物被确定之前就需要耗费大量时间和资金。

体内的小分子物质可能会成为生物大分子的靶点,这些大分子能够与它们结合并产生特定的生理或药理作用。它们被用于多种用途,包括疾病预防和治疗。离子通道、酶、受体和其他分子是最常见的靶点。确定新的靶点以及重新定位现有的靶点是新药开发的关键步骤。药物发现和药物再定位是两个独立的过程,分别用于识别新药和现有药物的新靶点。到目前为止,数据集中仅有一小部分相互作用关系得到了验证。

药物学和治疗药物设计在很大程度上依赖于药物 - 目标相互作用 (DTI) 预测。解决这一问题有几种方法。第一步是为已有的药物化合物确定新的作用靶点。其次,如果您心中已有某种蛋白质,您可以从药物库中寻找潜在的药物。或者,可以评估一对药物和一种靶蛋白,以查看它们之间是否存在相互作用。

目前,研究人员采用基于机器学习 (ML) 的监督学习方法来解决预测问题。药物预测的复杂性在于数据集不平衡。药物靶点之间已确认的相互作用很少,因此大多数技术将不熟悉的相互作用视为负值,从而导致负值占主导地位。另一个问题是药物 - 靶点对在输入数据集中的存储方式。使用 ML 技术预测药物 - 靶点相互作用通常使用药物的分子特征和蛋白质序列数据[4]。

深度学习 (DL) 及其他机器学习技术已被应用于诸如 CT 图像自动分割等各类医疗应用中[12][13]。弥散张量成像 (DTI) 预测是

基于深度学习的方法在生物学领域的一种应用，能够学习具有众多抽象类别的数据架构。最近，诸如 DeepDTI 和 GraphDTA 等基于深度学习的大规模药物-靶点相互作用预测方法已被开发出来。[5][6]

A. 目标

这项研究工作的主要目标是

- 设计基于深度学习的亚结构模式发现算法，以实现更准确的药物-靶点相互作用预测。
- 确定从海量未标注数据中提取的子结构之间的语义关系。

II. 文献综述

Farshid Rayhan 等人开发了一种用于预测药物 - 靶点相互作用的新分类器 FRnet-DTI [4]。正在考虑 FRnet-Encode 和 FRnet-Predict 这两个卷积神经网络。其中一个模型用于处理特征，而另一个用于对特征进行分类。每个数据集有 4096 个特征，第二种方法 FRnet-Predict 利用这些特征来确定两个数据集相互作用的可能性。他们使用了其他研究人员广泛使用的四个金标准数据集来评估其策略。

雷旭等人[7]已经完成了对机器学习如此受欢迎的三个主要原因的分析。他们总结了这些方法在构建机器学习模型的每个步骤中的明确应用，分析了其不足之处，并探讨了几个可以进一步探索的方面。

斯蒂芬·斯科特·麦金农等人[8]对所建议的标准的有效性进行了检验。他们指出，当前文献存在若干缺陷，仅依据其文字描述无法评估所提出的一些策略的实际效果。希望这项工作能够有助于解决这一问题，并提高人们对经常使用的交叉验证技术中可能存在的多种偏见的认识。

玛丽安·巴盖里安等人[9]已经描述了用于药物-靶点相互作用 (DTI) 预测所需的数据，随后列出了已被提出并用于预测 DTI 的机器学习算法和数据集的完整目录。此外，还简要回顾了每组方法的优点和缺点。最后，讨论了使用机器学习算法预测 DTI 时可能出现的困难，并据此强调了一些关键的未来研究方向。

A. 现有研究的局限性

现有的分子表示学习技术没有考虑药物 - 靶点相互作用 (DTI) 的子结构，导致准确性较低且难以表达。

现有的技术大多集中在少量有标签的数据上，从而忽略了大量无标签数据的价值。

III. 建议方法

A. 概述

在本文中，我们提出设计用于药物 - 靶点相互作用 (DTI) 预测的 Transformer CNN - OMBO 算法，其架构如图 1 所示。




图 1 架构 Transformer-CNN-OMBO

对于每一对药物和蛋白质数据，IFSM 算法将原始的药物 - 靶点数据转换为一系列特定的子结构 (SD、ST)。然后将这些子结构输入到一个绑定转换器阶段，以获得每个子结构的上下文绑定。交互预测阶段包含两层：(i) 一个交互层，用于建模蛋白质和药物中每个子序列的交互；(ii) 一个优化的卷积神经网络层 (OCNN)，用于从这些交互中提取邻域交互。因此，在本文中，OMBO 算法被用于在训练过程中调整卷积神经网络层的超参数。

B. 改进的频繁子序列挖掘(IFSM)

在此，我们提供了一种用于识别药物和蛋白质数据库中重复子序列的 IFSM 算法。IFSM 以分层的方式将每个蛋白质或药物序列分解为小型子序列，并分离出原子/氨基酸符号。

在针对完整药物/蛋白质语料库的智能合约中，初始化一组不同的氨基酸标记或 SMILES 字符串的术语集 V 是第一步。将标记化的集合命名为 W 。

重复序列的识别：接着对 W 进行扫描，识别出出现频率最高的标记序列，即 (A, B) 。然后，FCS 将新标记 (AB) 添加到词汇集 V 中，并将标记化集合 W 中的每个 (A, B) 修改为反映新标记 (AB) 。如果不存在出现频率超过上限 h 的频繁标记，或者 V 的大小超过内置的最大值 l ，则重复扫描、识别和更新方法。在此过程中，出现频率最高的子序列被合并为单个标记，而出现频率较低子序列则被分解为一系列较小的标记。

最后，对于每一对，IFSM 返回一个序列 $C =$

{C₁,..., C_k} 这些大小为 k 的子结构对, 其中 C_i ⊆ V。因此, 该算法将输入对转换为一系列已知的子结构 (SD, ST)。

IFSM 能够捕捉到基础且有意义的生物医学语义。在生成的子结构中可以找到药物和蛋白质的重要组成部分。鉴于各种数据集的特征, FCS 算法能够识别出一组相当的基础生化子结构, 而不论蛋白质数据集中包含的生物种类如何, 也不论药物成功的概率大小。

C. 变压器绑定阶段

IFSM 算法的输出会被输入到一个绑定转换器阶段, 以获取每个化学子结构的上下文绑定。它首先为每个子结构初始化一个可学习查找字典 (LLD), 然后使用转换器编码器通过上下文子结构细节来增强绑定。

变压器编码器是一种深度学习架构, 它采用自治理技术生成上下文绑定, 以学习分子结构。自治理技术通过从相似分子的所有其他子结构中探索来改变每个子结构的绑定。

对于每个输入的 (D, T) 对, 相关的 substructures (S_D, S_T) 序列会被转换为矩阵 (M_D 和 M_T)。

设 ZD 和 ZT 分别为药物和靶点的子结构大小。

设 LD 和 LT 分别为 (D, T) 的子结构序列的长度。

每对药物靶点的结合内容 Cont_D 和 Cont_T 是使用 LLD 生成的。

康迪 D = M 康迪 D. 米 D

$$\text{Cont}_{jT} = \text{MCont}_T \cdot \text{M}_{jT} \quad (1)$$

其中 MCont_D 和 MCont_T 分别为 LLD 的矩阵, 而 M_{iD} 和 M_{jT} 则分别代表药物的 ith 子结构和靶点的 jth 子结构的向量。

BContD 和 BContT 的最终绑定生成如下:

$$\begin{aligned} \text{BCont}_D &= \text{Cont}_{iD} + \text{Pos}_{iD} \\ \text{BCont}_T &= \text{Cont}_{jT} + \text{Pos}_{jT} \end{aligned} \quad (2)$$

其中 Pos_{iD} 和 Pos_{jT} 是根据 LLD 确定的位置绑定。

D. 基于卷积神经网络的交互预测

卷积神经网络 (CNN) 是一种复杂程度有限且具有多层结构的网络。它具有一个复合技术模型, 用于以错误模式分析数据。具有

多层的卷积神经网络通常将属性提取和组合任务整合到一个学习实体中。

通常, 卷积神经网络 (CNN) 包含以下层:

卷积层 (CL): 它对特征图使用 n 个滤波器。在复杂运算之后, 使用 ReLU 激活函数为网络引入非线性。

最大池化层 (MPL): 最大池化是将特征图划分为子区域 (大小为 2×2) 的传统方法, 并且仅保留极值。

全连接层 (FCL): 前一层的所有神经元都与后续层相连接。卷积神经网络 (CNN) 将基于从卷积层 (CLs) 提取的特征, 并结合池化层 (PL) 的信息来对标签进行分类。

在传统的卷积神经网络 (CNN) 训练过程中, 会调整卷积核和全连接 (FCL) 层中隐藏神经元的参数。通常, 在 CNN 中使用随机梯度下降 (SGD) 方法来调整卷积层 (CL) 和 FCL 的参数。但 SGD 包含许多可能影响网络性能的超参数。超参数决定了 CNN 的准确性和收敛性[10]。

表 1 展示了用于交互预测的卷积神经网络 (CNN) 架构的详细信息。

表 1 CNN 模型的详细参数

层	权重滤波器	尺寸	大步走
输入	224×224×3		
CL1	64 的 3 次方乘以 3	1 乘 1	
MPL1	2乘2		2乘2
CL2	64:3 乘以 3	1 乘 1	
MPL 2.0	2乘2		2乘2
CL3	32:3 乘以 3	1 乘 1	
MPL3 2×2			2乘2
CL4	16:3 乘以 3	1 乘 1	
MPL4 2×2			2乘2
CL5	8 乘以 3 乘以 3 的结果是 17 乘 1		
FC	输出大小 = 3		
	SoftMax		

E. 利用 OMBO 算法优化卷积神经网络

在本节中, 使用 OMBO 算法对卷积神经网络 (CNN) 的以下超参数进行优化, 以获得最准确的结果。

- 学习率 (LR): 它控制随机梯度下降算法的速度。
- 迭代次数 (E): 它计算次数

由学习算法对网络参数进行更新的过程

· 正则化系数 (RC) : 它可避免网络出现过拟合问题。

根据这些参数推导出适应度函数为

$$\text{Fitness}() = (\alpha.LR + \beta.E + \gamma.RC) \quad (3)$$

其中, α 、 β 、 γ 为权重常数, 取值范围为 (0, 1)。

事实证明, OMBO 算法是解决不同类型优化问题的有效方案。它能够减少排序步骤, 提高计算效率。本研究工作基于重定位算子和蝴蝶调节算子开发了 OMBO 算法。

下面将对用于随机梯度下降 (SGD) 训练中自动调整参数的 OMBO 算法进行解释。通过自适应地改变卷积神经网络 (CNN) 各层的学习率, OMBO 算法能够控制 SGD 的速度。

a. 初始化

根据权重生成初始解, 并计算解的规模大小。

设 SP1 和 SP2 是初始种群 P 的子种群。

以下方程将基于对立面的解与初始解相结合, 作为

$$\begin{aligned} O_i &= x + y - I_i \\ O_i &= x + y - I_i \end{aligned} \quad (4)$$

where $I_1, I_2, I_3, \dots, NP$ 是任意生成的初始结果。

b. 蝴蝶迁移操作员 (BMO)

对于 SP1 中的每个 i , 从 t^{th} 到 $(t+1)^{\text{th}}$ 生成的位置通过公式 (2) 进行更新:

$$x_{i,k}^{t+1} \leftarrow \begin{cases} x_{r1,k}^t & \text{if } r \leq p \\ x_{r2,k}^t & \text{else} \end{cases} \quad (5)$$

其中 $r1$ 、 $r2$ 分别从 SP1 和 SP2 中随机选取, p 为 SP1 中蝴蝶的比例。

r 计算为

$$r = (\text{rand}) * mp$$

其中 mp 表示位移周期。

c. 蝶形调整操作员 (BAO)

对于 SP2 中的每个 i , 从第 t 代到第 $t+1$ 代的位置如下给出:

$$x_{i,k}^{t+1} \leftarrow \begin{cases} x_{best,k}^t & \text{if } \text{rand} \leq p \\ x_{r3,k}^t & \text{if } \text{rand} > p \wedge \text{rand} \leq \text{BAR} \\ x_{i,k}^t + \alpha X(d_{xk} - 0.5) & \text{if } \text{rand} > p \wedge \text{rand} > \text{BAR} \end{cases} \quad (6)$$

其中 X 是当前全局最优解中的第 k 项, $best,k$ 在时刻 t , $r3$ 处的 P 系统解是从 SP2 中随机选取的, BAR 为蝶形调整率。

参数 α 和 dx 是通过以下方程计算得出的权重常数。

$$\alpha = S_{\max} / t^2 \quad (7)$$

$$dx = \text{Levy}(x_i^t) \quad (8)$$

其中 $S_{\max}$ 表示最大步行步数, Levy 表示蝴蝶的莱维飞行运动过程。

d. 基于对立的学习

基于对立的学习 (OBL) 被应用于多种优化策略中, 以处理各种实际问题。由于在优化过程中选择一个解包含一定的随机性, 因此可以同时评估对立解。在大多数情况下, OBL 可以增加找到最佳解的机会并加快收敛速度。这是一种空间变换方法, 结合了广义的基于对立的学习技术。广义的 OBL 可能有很多机会找到更接近全局最优解的候选解。新的对立点 X 表示如下:

$$H(x_i) = \{x_i' | x_i' = r^*(a_i + b_i) - x_i, x_i \in R^N, x_i \in [a_i, b_i], i \in \{1, 2, \dots, n\}\} \quad (9)$$

其中 r 是随机选取的。

由于 OBL 能够提高确定最佳解决方案的可能性并加快收敛过程, 因此 OMBO 优化显著降低了计算复杂度, 并提高了 CNN 预测的准确性。

e. OMBO 算法

开始

1. 按 p_i/w_i 降序对所有项目进行排序, ($1 < i < n$), 并将索引存储在数组 $H[1...n]$ 中。

2. 初始化。

2.1 随机生成 NP 只帝王蝶 $\{<X_1, Y_1>, <X_2, Y_2>, \dots, <X_{NP}, Y_{NP}>\}$ 。

2.2 计算每个解的适应度, $f(Y_i)$, $1 < i < NP$ 。

2.3 将 P 分为 SP1 和 SP2。

2.4. 令 $\max_iter = \text{MaxGen}$ 且迭代次数 $g = 1$ 。

2.5. 设置两个子种群重新组合的生成间隔 RG。

2.5 将 Ga 设为 0.2。

3 当 ($g < \max\text{Gen}$ 或停止准则未满足) 时

3.1 评估群体的适应度, 并存储 $<X_{g\text{best}}, Y_{g\text{best}}>$

3.2 使用 BMO 更新 SP1。

3.3 使用 BAO 更新 SP2。

3.4 用高斯扰动更新最差的 $Ga \cdot NP$ 个体。

3.5 利用贪婪修正算子 (GMO) 来修正不可行的解。

3.6 利用贪婪优化算子 (GOO) 来改进可行解。

3.7 保存最佳解决方案。

3.8 确定当前的最佳 ($Y_{g\text{best}}, f(Y_{g\text{best}})$)。

3.9 $g = g + 1$

3.10. (如果 g 大于等于 MaxGen 的一半)

3.10.1 对后半部分执行 OBL 操作

个人。

3.10.2. 使用以下方法修复不可行的解决方案
转基因生物

3.10.3 利用以下方法改进可行解

GOO

结束 if 语句

3.11 若 $(\text{Mod}(g, \text{RG}) = 0)$

3.11.1 将子种群 1 和子种群 2 合并为一个。

3.11.2 根据适应度值将种群分为两个子种群

结束 if 语句

4. 结束循环

5. 返回最佳结果

6. 结束

IV. 实验结果

A. 数据集规格

我们已在 DeepPurpose 工具包中实现了所提出的分子亚结构模式发现 (MSPD) 算法。DeepPurpose 是一个基于 PyTorch 的深度学习框架, 旨在为药物 - 靶点相互作用 (DTI) 预测提供强大的工具包。

实验中使用了来自 <https://www.bindingdb.org/bind/index.jsp> 的 BindingDB 数据集。模型的输入是一个药物 - 靶点 (DT) 对, 其中药物使用 SMILES 字符串 (d) 表示, 靶点 (t) 使用氨基

酸序列表示。输出 (y) 是 (d,t) 对的结合作用得分。Y=0 或 1 表示相互作用输出, 指示结合值。

训练数据集的格式如下所示:

Drug-1:

CC1=C2C=C(C=CC2=NN1)C3=CC(=CN=C3)OCC(CC4=CC=CC=C4)N

Target-1:

MKKFFDSRREQGSGSLGSGSSGGGGSTSGLGSGYIGRVFGI
GRQQVTVDEVLAEGGFAIVFLVRTSNGMKCALKRMFVNNEH
DLQVCKREIQIMRDLSGHKNIVGYIDSSINNVS SGD VWEVL
ILMDFCRGGQVNL MNQRLQTGFTE NEVLQIFCDTCEAVAR
LHQCKTPIIHRDLKVENILLHDRGHYVLCDFGSATNKFQNP
QTEGVNAVEDEIKKYTTLSYRAPEMVNLYSGKIIITTKADIW
ALGCLLYKLCYFTLPFGESQVAICDGNFTIPDNSRYSQDMH
CLIRYMLEPDPDKRPDIYQVSYSFSLKKECPINPVQNSP
IPAKLPEPVKASEAAAKKTQPKARLTDPITPTETSIAPRQR
PKAGQTQPNPGILPIQPALTPRKRATVQPPPQAAGSSNQPG
LLASVPQPKPQAPPSQPLPQTQAKQPQAPPTPQQTPTSTQAQ
GLPAQAQATPQHQQQLFLKQQQQQQQPPPAQQQPAGTFYQQ
QQAQTQQFQAVHPATQKPAIAQFPVVSQGGSQQQQLMQNFYQ
QQQQQQQQQQQQQLATALHQQLMTQQAALQQKPTMAAGQQ
PQPQPAAPQAPAPAEPAIQAPVRQQPKVQTTTPPAVQGGK
VGSLTPSSPKTQRAGHRRILSDVTHSAVFGVPASKSTQLL
QAAAAEASLNKSKSATTTTPSGSPRTSQNVYNPSEGSTWNP
FDDDNFSKLTAEELLNKDFAKLGEGKHPEKLGGSAESLIPG
FQSTQGDAFATTSFSAGTAEKRKGQTVDSGLPLLSVSDPF
IPLQVPDAPEKLEGLKSPDTSLLLPDLLPMTDPFGSTSDA
VIEKADVAVESLIPGLEPPVPQRLPSQTESVTSNRTDSL TG
EDSLLDCSLLSNPTTDLLEEFAPTAISAPVHKAAEDSNLIS
GFDVPEGSDKVAEDEFDPIPVLTITKNPQGGHSRNSGSSSES
SLPNLARSLLLVDQLIDL

图 2 训练数据集

B. 编码结果

用于药物和靶点的编码器分别是 MPNN 和 CNN。它将数据编码为指定格式, 并提供训练集和测试集的划分比例。药物和靶点编码过程的输出如下所示:

```
in total: 1 drug-target pairs
encoding drug...
unique drugs: 1
drug encoding finished...
encoding protein...
unique target sequence: 1
protein encoding finished...
splitting dataset...
do not do train/test split on the data for already splitted data
predicting...
The predicted score is [5.243870735168457]
```

图 3 编码过程的输出

```
Training at Epoch 96 iteration 0 with loss 0.13490276
Validation at Epoch 96 , MSE: 0.3624646636382893 , Pearson Correlation: 0.763303324402881 with p-value: 0.0 , Concordance
e Index: 0.6716263927735894
Training at Epoch 97 iteration 0 with loss 0.14156697
Validation at Epoch 97 , MSE: 0.2644430110049083 , Pearson Correlation: 0.7694604155905123 with p-value: 0.0 , Concordance
e Index: 0.648523925670295
Training at Epoch 98 iteration 0 with loss 0.0765197
Validation at Epoch 98 , MSE: 0.2624310370215666 , Pearson Correlation: 0.7647669467940375 with p-value: 0.0 , Concordance
e Index: 0.6660733821178346
Training at Epoch 99 iteration 0 with loss 0.0672421
Validation at Epoch 99 , MSE: 0.307560017427849 , Pearson Correlation: 0.7677542563700856 with p-value: 0.0 , Concordance
e Index: 0.6496632822577812
Training at Epoch 100 iteration 0 with loss 0.11071129
Validation at Epoch 100 , MSE: 0.2819463628926039 , Pearson Correlation: 0.76628122176691273 with p-value: 0.0 , Concordance
e Index: 0.6602355339210646
--- Go for Testing ---
Testing MSE: 0.23659545370661100 , Pearson Correlation: 0.8231646722825967 with p-value: 0.0 , Concordance Index: 0.648126
3072861061
--- Training Finished ---
```

图 4 训练过程的输出结果

训练过程的准确性通过 600 至 00 个周期进行了验证, 并且相应的损失值在下图中进行了测量和绘制。




图 5 训练验证图

C. 使用 CNN-OMBO 进行预测的结果

对于来自 BindingDB 数据集的样本数据, 生成具有高结合倾向的配体-靶点 (DT) 对列表如下。

Rank	Drug Name	Target Name	Binding Score
1	Drug 80	Target 80	0.58
2	Drug 86	Target 86	0.85
3	Drug 4	Target 4	0.89
4	Drug 89	Target 89	1.62
5	Drug 44	Target 44	1.67
6	Drug 58	Target 58	1.87
7	Drug 35	Target 35	2.74
8	Drug 43	Target 43	2.98
9	Drug 23	Target 23	3.95
10	Drug 25	Target 25	4.55
11	Drug 15	Target 15	4.86
12	Drug 97	Target 97	5.03
13	Drug 24	Target 24	6.31
14	Drug 47	Target 47	6.53
15	Drug 48	Target 48	11.22
16	Drug 50	Target 50	11.35
17	Drug 92	Target 92	16.71
18	Drug 66	Target 66	17.49
19	Drug 26	Target 26	18.03
20	Drug 87	Target 87	18.64
21	Drug 93	Target 93	19.38
22	Drug 20	Target 20	23.28
23	Drug 49	Target 49	27.10
24	Drug 30	Target 30	28.13
25	Drug 33	Target 33	33.48

图 7 与 BindingDB 数据集结合的虚拟筛选结果

D. 与其他算法的比较

在本节中, 将 Transformer-CNN-OMBO 算法的预测结果与传统的 Transformer+CNN 以及采用消息传递神经网络 (MPNN) 进行编码的 MPNN+CNN 进行了比较。

性能评估依据准确率、灵敏度、特异度、精确率、召回率和 F1 分数这六项指标, F1 分数的计算公式如下。

表 2 与其他算法的性能比较

Metrics	Transformer+CNN+OMBO	Transformer+CNN	MPNN+CNN
Recall	0.90	0.89	0.86
Precision	0.43	0.41	0.39
Accuracy	0.81	0.78	0.76
Sensitivity	0.80	0.77	0.75
Specificity	0.90	0.87	0.84
F1 score	0.59	0.57	0.54




图 8 Transformer+CNN+OMBO 的性能比较

V. 结论

在本文中, 我们提出设计用于药物-靶点相互作用预测的 Transformer CNN-OMBO 算法。首先, 对于输入数据集, 使用 IFSM 算法将药物-靶点对转换为一系列已知的子结构, 然后将这些子结构输入到 Transformer 绑定阶段, 以确定每个子结构的上下文绑定。通过优化的 CNN 层对这些相互作用进行处理, 以提取邻域相互作用。在训练过程中, 应用 OMBO 算法优化 CNN 层的超参数。所提出的算法已在 BindingDB 数据集上进行了应用, 并将其性能与 Transformer+CNN 和 MPNN+CNN 模型进行了比较。结果表明, 所提出的 Transformer-CNN-OMBO 算法在准确率、灵敏度、特异性、召回率、精确率和 F1 值等指标上均优于其他模型。

参考文献

- [1] Heba El-Behery, Abdel-Fattah Attia, Nawal El- Fishawy and Hanaa Torkey, "Efficient machine learning model for predicting drug-target interactions with case study for Covid-19", Elsevier, Computational Biology and Chemistry 93 (2021) 107536, 2021.
- [2] Haswani Ismail, Nurul Hashimah Ahamed Hassain Malim and Siti Zuraidah Mohamad Zobir, "Comparative Studies On Drug-Target Interaction Prediction Using Machine Learning and Deep Learning Methods With Different Molecular Descriptors", IEEE, 2021
- [3] Shuaiqi Liu ,Jingjie An,Jie Zhao, Shuhuan Zhao , Hui Lv,and ShuiHua Wang, "Drug-Target Interaction Prediction Based on Multisource Information Weighted Fusion", Hindawi, Contrast Media & Molecular Imaging, Volume 2021, Article ID 6044256, 10 pages, 2021.
- [4] FarshidRayhana, SajidAhmeda, ZaynabMousavian, Dewan MdFarida and SwakkharShatabda, "FRnet-DTI: Deep convolutional neural network for drug-target interaction prediction", Elsevier,Heliyon 6(2020)e03444, 2020.
- [5] Qing Ye, Chang-Yu Hsieh, Ziyi Yang, Yu Kang , Jiming Chen, Dongsheng Cao,Shibo He and Tingjun Hou, "A unified drug–target interaction prediction framework based on knowledge graph and recommendation system", Nature Communications, 2021.
- [6] Maha A. Thafar, Rawan S. Olayan, Somayah Albaradei, Vladimir B. Bajic, Takashi Gojobori, Magbubah Essack and Xin Gao, "DTi2Vec: Drug–target interaction prediction using network embedding and ensemble learning", Journal of Cheminformatics, Vol-13, No-71, 2021.
- [7] Lei Xu, Xiaoqing Ru and Rong Song, "Application of Machine Learning for Drug-Target Interaction Prediction", Frontiers in Genetics, Vol-21, 2021.
- [8] Stephen Scott MacKinnon, S. A. Madani Tonekaboni and Andreas Windemuth, "Proteome-Scale Drug-Target Interaction Predictions: Approaches and Applications", Current Protocols, Vol-1, 2021.
- [9] Maryam Bagherian, Elyas Sabeti, Kai Wang, Maureen A. Sartor, Zaneta Nikolovska-Coleska and Kayvan Najarian, "Machine learning approaches and databases for prediction of drug–target interaction: a survey paper", Briefings in Bioinformatics, 22(1), 2021, 247–269, 2021.
- [10] Tripti Goel, R. Murugan, Seyedali Mirjalil and Deba Kumar Chakrabarty, "OptCoNet: an optimized convolutional neural network for an automatic diagnosis of COVID-19", Applied Intelligence, Springer, 2020
- [11] Lin Sun, Suisui Chen, Jiucheng Xu and Yun Tian, "Improved Monarch Butterfly Optimization Algorithm Based on Opposition-Based Learning and Random Local Perturbation", Complexity, Hindawi, Volume 2019, Article ID 4182148, 20 pages
- [12] Zitnik, M. et al. "Modeling polypharmacy side effects with graph convolutional networks". Bioinformatics, 2018, 34, i457–i466.
- [13] Sungheetha, Akey, and S. R. Rajesh. "Comparative Study: Statistical Approach and Deep Learning Method for Automatic Segmentation Methods for Lung CT Image Segmentation." J. Innov. Image Process 2 (2020): 187-193
- [14] Balasubramaniam, Vivekanadam. "Future Perspective for Radiation Dose Reduction techniques in Computed Tomography-A Study." Journal of Innovative Image Processing 2, no. 4: 210-216.