

MolLoG: 一种从局部到全局预测药物靶点相互作用的分子层面可解释性模型

Bao-Ming Feng, Yuan-Yuan Zhang,* Xiao-Chen Zhou, Jin-Long Wang, and Yin-Fei Feng



引用格式:《化学信息与建模杂志》2024 年,64 卷,4348–4358 页




Read Online

访问

指标与更多内容

文章推荐



摘要: 开发新药是一项成本高昂且耗时的工作, 其间伴随着巨大的安全风险。药物研究和疾病治疗的一个关键方面在于辨别药物与蛋白质之间是否存在相互作用。近年来, 计算机科学中深度学习 (DL) 的发展在这方面得到了显著助力。然而, 仍存在两个挑战: (一) 在提取深刻、局部的连贯特征的同时避免梯度消失; (二) 全局地表示和理解药物与靶点局部属性之间的相互作用, 这对于提供药物开发所必需的分子层面的见解至关重要。为应对这些挑战, 我们提出了一种深度学习网络结构 MolLoG, 主要由两个模块组成: 局部特征编码器 (LFE) 和全局交互学习 (GIL)。在 LFE 模块中, 图卷积网络和跳跃块分别捕获药物和蛋白质分子的局部特征。GIL 模块能够高效地融合特征信息, 促进全局学习特征结构语义, 并为来自两种模态的抽象特征获取多头注意力权重, 为黑箱结果提供生物学相关的解释。最后, 通过多层感知机对统一表示进行解码以获得预测结果。我们的实验分析表明, MolLoG 在四个数据集上均优于多个前沿基线模型, 整体性能更优, 并在阐明药物 - 靶点相互作用预测的各个方面时提供了令人满意的结果。

1. 简介

药物 - 靶点相互作用 (DTIs) 的预测是药物开发中的关键步骤, 旨在发现能够作用于特定蛋白质的潜在药物。它在药物副作用预测、¹ 药物毒性、² 多药理学、³ 以及药物再利用⁴ 等相关研究中发挥着重要作用。开发一种新药通常需要花费约 20 亿美元, 耗时约 15 年,⁵ 这是一笔巨大的开支, 因此有必要探索高效且安全的方法来加快这一进程。

传统的生物医学体外测试能提供可靠的结果, 但其在处理大规模数据方面的低效性成为了一个重大阻碍。相反, 计算方法能够识别出高概率的药物-靶点相互作用 (DTIs)。这不仅大幅减少了需要研究的候选化合物的数量, 还提供了有价值的见解。

药物组合中的潜在作用。因此, 计算技术受到了极大的关注, 并取得了显著进展。其中, 基于结构和基于配体的虚拟筛选方法⁶ 经历了广泛的检验。然而, 当蛋白质的三维结构未知⁷ 或活性化合物库有限⁸ 时, 这些方法就不再适用了。

Received: January 31, 2024
Revised: April 1, 2024
Accepted: April 24, 2024
Published: May 6, 2024






图 1. MolLoG 的架构。蛋白质序列被映射到特征矩阵，然后嵌入到两个跳跃块中进行编码。输入的药物编码被转换为分子图，通过图卷积网络 (GCN) 对药物分子邻近原子的聚合表示进行编码。所获得的药物和蛋白质的双模态表示被输入到 GIL 模块中以学习它们的全局相互作用，从而获得联合表示 f 和注意力权重 att 。矩阵“ f ”通过多层感知器解码器模块进行解码，以获得预测概率，从而确定 0/1 标签。矩阵“ att ”将用于可解释性研究。

其他突出的方法包括基于机器学习的方法，例如支持向量机 (SVM)⁹ 和随机森林 (RF)¹⁰，但这些方法也存在局限性。这些局限性包括：应用于高维数据时计算效率降低；对参数修改的响应过于敏感，导致预测性能不稳定；以及缺乏足够的可解释性。

作为一种变革性技术，基于深度学习 (DL) 的方法通过将多维信息整合到统一的端到端框架中，在预测药物-靶点相互作用 (DTI) 方面取得了迅速进展。这些方法逐渐成为最优解决方案。许多基于深度学习的模型输入分子序列或图结构，并利用神经网络提取潜在特征信息。Alipanahi 等人¹¹ 采用深度卷积神经网络 (CNN)¹² 来预测 DNA - 蛋白质相互作用。CNN 能够捕捉药物和蛋白质序列中的局部模式。Yuan 等人提出了 FusionDTA¹³，该模型使用前馈层和长短期记忆 (LSTM) 构建编码器层的基本模块，将药物分子和蛋白质的中间体整合到聚合层，以实现结合亲和力的输出载体表示。尽管诸如 CNN 之类的方法在序列和文本方面提高了性能，但能更有效地反映结构信息的图数据更具优势。Nguyen 等人提出了一种基于图的模型 GraphDTA¹⁴，该模型将药物编码转换为具有特征图和邻接矩阵的无向图。图卷积网络 (GCN)、图注意力网络 (GAT) 和图同构网络被设计用于从药物中提取特征。这在执行药物-靶点相互作用 (DTI) 任务期间的局部特征提取方面是一个显著的优势。

相反，由于蛋白质序列比药物编码的序列长得多，其复杂程度也高得多，因此将这些蛋白质序列翻译成类似的结构是一项挑战。

目前，仅能将特定类型蛋白质转换为图结构的模型已存在，例如 GraphProt¹⁸，它专门用于 RNA 结合蛋白。其他方法包括自协方差、组成转换和局部描述符。¹⁹ 这些策略试图封装蛋白质序列的一些其他基本属性。然而，这些方法侧重于蛋白质属性，往往忽略了药物分子与蛋白质之间独特的相互作用模式。这种忽视极大地限制了它们在药物 - 蛋白质相互作用 (DTI) 任务中的适用性。这一问题同样出现在诸如用于预测蛋白质接触图的 ResPRE²⁰ 和用于预测蛋白质二级结构的 DCRNN²¹ 等方法中。

此外，尽管 DeepMind 的 AlphaFold2²² 在预测蛋白质三维结构方面取得了重大进展，最近生成了来自一百万种物种的 20 亿个蛋白质三维结构预测，但实际情况是，高精度三维结构蛋白质的数量仅占已知蛋白质序列的一小部分。这些挑战迫使即使是最先进的模型也继续使用诸如卷积神经网络 (CNN)、循环神经网络 (RNN)²³ 和长短期记忆网络 (LSTM)²⁴ 等方法从序列中提取蛋白质特征，如 MolTrans²⁵、DeepPurpose²⁶、DrugBAN²⁷ 和 MCANet²⁸ 等模型所示。尽管卷积神经网络能够提取类似于图结构的局部聚合特征，但梯度消失问题的出现导致一些浅层的先验知识随着模型的加深而丢失。在考虑更丰富的局部聚合特征的同时，平衡全局语义和内在生物学背景特征嵌入的融合已成为一个复杂的问题。

一个更为紧迫的挑战在于，即便能够通过获取的特征信息成功预测结果，但如果缺乏包括功能单元、残基细节以及药物与其靶点之间相互作用位点等要素在内的全面分子层面分析，

针对靶向药物开发和设计所提供的帮助尚不令人满意。²⁹然而,上述大多数模型尚未克服这一障碍。

解决这一问题的关键在于获取药物和靶点的重要性得分。目前,大多数模型在特征提取阶段仅对药物/靶点自身相关的特征进行评分,而忽略了它们之间的相互作用。近年来,注意力机制作为识别模型预测的靶点和配体中关键子结构的有力工具崭露头角。它使模型能够自主识别并聚焦于与预测结果关联度最高的部分,从而解释预测的来源。另一个显著优势在于它能够促进模型内部联合特征表示的改进,从而提高预测性能。尽管实现两者之间的相互作用学习颇具挑战性,但一些先进的模型还是解决了这一问题。

诸如 Lim 等人所采用的距离感知图注意力算法³⁰以及 DrugBAN 的双线性注意力网络²⁷等前沿方法在解决该问题上取得了显著进展。然而,在真实的生物环境中,蛋白质和药物携带着与上下文相关的关联信息,不同位置之间存在着众多潜在的相互作用。由于氨基酸序列通常较长,上述模型难以有效地学习中长距离依赖关系和全局关联信息。针对如何充分利用注意力机制实现特征的全局联合表示以及解释黑箱结果,我们进行了新的尝试。

在我们的研究中,我们引入了一种基于深度学习方法的新模型,称为 MolLoG。该模型主要由两个模块组成:局部特征编码器(LFE)和全局交互学习(GIL)。通过这种从局部到全局平滑过渡的方法,我们显著提高了药物-靶点相互作用(DTI)预测的准确性及其后续的可解释性,如图1所示。在LFE模块中,我们采用图卷积网络(GCN)结合跳跃块(一种使用残差连接的技术)³¹。这一组合负责将药物分子图和蛋白质序列编码为深度局部特征信息。这些表示随后被输入到GIL模块(注意力机制与多模态全局特征联合交互的创新应用)中,在这里它们经历独特的转换,形成全局子块交互表示,从而全面描绘药物和蛋白质特征的相互作用。

总之,我们的模型 MolLoG 通过两个关键特性与以往的研究区分开来:(一)LFE 模块在特征提取过程中巧妙地融合了局部凝聚性和整体关联性;(二)通过 GIL 模块有效地学习多模态全局交互表示,并利用该模块的加权机制对预测结果进行解释。

2. 材料与方法

2.1. 数据集。我们的评估涵盖了对 MolLoG 以及六个最先进的基准模型在四个公开可用的药物-靶点相互作用(DTI)数据集上的评估:BindingDB、BioSNAP、human 和 DAVIS。BindingDB 数据集主要关注小分子药物类似物与蛋白质之间的相互作用。³²我们使用了

Bai 等人构建的低偏差版本的数据集。³³BioSNAP 数据集是由 Huang 等人 and Zitnik 等人从 DrugBank 数据库中创建的一个平衡数据集。^{25, 34}DAVIS 主要关注药物-蛋白质相互作用数据,在药物发现和计算化学领域具有应用价值。³⁶Human 数据集由 Liu 等人构建。³⁷我们使用了平衡版的 Human 数据集,其中正负样本数量相等。表1提供了这四个数据集的数据统计信息。

表 1. 数据集统计

数据集	#毒品	#蛋白质	#互动
BindingDB	14,643	2623	49,200
BioSNAP	4510	2181	27,465
人类	2726	2001	6728
戴维斯	72	382	11,885

2.2. 评估指标。我们使用了五个指标来评估 MolLoG 的性能。AUROC (受试者工作特征曲线下的面积)和 AUPRC (精确率召回率曲线下的面积)是评估模型分类性能的主要指标。AUROC 测量了在不同阈值下分类器的真正例率和假正例率之间的权衡。AUPRC 则量化了在不同阈值下分类器的精确率和召回率之间的权衡。此外,我们还报告了最优 F1 分数阈值下的准确率、灵敏度和特异性。各指标的定义如下:

$$\text{sensitivity} = \frac{FP}{FP + TN} \quad (1)$$

$$\text{specificity} = \frac{TP}{TP + FN} \quad (2)$$

$$\text{precision} = \frac{TP}{TP + FP} \quad (3)$$

$$\text{accuracy} = \frac{TP + TN}{TP + FP + TN + FN} \quad (4)$$

其中,TP 表示真阳性数,TN 表示真阴性数,FP 表示假阳性数,FN 表示假阴性数。原则上,上述指标的值越高,性能就越好。

2.3. 局部特征编码器模块。**2.3.1. 用于药物特征提取的图卷积网络。**对于药物化合物,每个 SMILES 字符串都会被解析,识别化学键,分配坐标,并移除任何重叠部分,从而转换为一个分子图 = { $\mathcal{V}$, $\mathcal{E}$ }。每个原子节点 (v) 和化学键 (e) 是根据其化学性质进行初始化的。属性。每个原子都由一个包含八项信息的整数向量表示:隐式氢原子数、形式电荷、总氢原子数、原子杂化态、未成对电子数、原子类型、原子度以及该原子是否为芳香族原子。这都是通过 DGL-LifeSci³⁸包实现的。在各种图神经网络(GNN)变体中,GCN 扩展了神经网络在图结构数据表示方面的方法,使其能够基于邻节点特征、自身特征以及拓扑数据来更新节点信息。这种计算能力能够减少

在药物靶点预测中，基于图结构的维度满足了根据相似靶点（药物）预测相似药物（靶点）的计算需求。

我们设定了一个允许的最大节点数量 $\odot^d$ 。如果某个分子的节点数量少于这个最大值，那么我们会在空缺的节点位置填充零，将其转换为虚拟节点。因此，每个图的节点特征矩阵表示为

作为 M_d

$\in \mathbb{R}^{\odot_d}$ 乘以 $\odot_d$ 通过转换来定义 $X_d \in W_d M_d$ ，从而得到一个实数值 $\odot_d$ 的 d 密集矩阵 X_d 作为输入特征。我们可以将 ReLU 激活函数表示为 σ ，并分别用 A 和 D 来表示添加了自连接的邻接矩阵和对角度矩阵。 $W_d^{(l)}$ 表示 $\wedge$ 发送权重矩阵。因此，给定 X_d ，将其通过第 $(l+1)$ 层可以编码为特征矩阵 H_d

$$H_d^{(l+1)} = \sigma(\hat{D}^{-1/2} \hat{A} \hat{D}^{-1/2} H_d^{(l)} W_d^{(l)}), H_d^{(1)} = X_d \quad (5)$$

此外，每一层中第 $(l+1)$ 个节点的特征可以表示为

$$x_i^{(l+1)} = \sigma \left(\sum_{j \in N_i} \frac{1}{C_{ij}} x_j^{(l)} w^{(l)} + b^{(l)} \right) \quad (6)$$

在此上下文中， N_i 表示一个节点及其所有相邻节点， C_{ij} 作为归一化因子， $w^{(l)}$ 表示与第 l 层相关的权重，而 $b^{(l)}$ 则对应于同一层的截距。

经过药物编码器处理后，我们最终获得了药物的多行特征表示。

统称为矩阵 O_p^{GCN} 、 D_{GCN}

$$\in \mathbb{R}^{\odot}$$

表示药物编码器中最终隐藏层的维度。

2.3.2. 蛋白质特征提取的跳跃模块。每个跳跃模块包含三个卷积神经网络（CNN）层。来自蛋白质序列的原始信息与初始模块的特征输出相结合，并传递给后续模块。同样，每个后续模块的输出整合了从原始轨迹中提取的特征以及通过前一个模块得出的特征。这种跨模块的数据传输策略确保随着我们深入到更深层，模型持续挖掘出更深层次的信息，并同时已将提取的浅层特征与全局上下文语义相结合的学习机制加以巩固。并且它有效地解决了蛋白质编码中常见的长距离依赖和梯度消失问题。

起初，我们对包含 25 个字符的蛋白质序列进行整数编码。这源于除了生物学中公认的 20 种标准氨基酸外，还有其他特征用于表示特殊的情况。随后，所有氨基酸都被初始化为一个可学习的嵌入矩阵，记作

$N \times D_p$ M_p 。在此， N 表示氨基酸的数量类型，而 D_p 表示每种氨基酸的潜在维度。通过查找 M_p ，模型需要学习的每个初始蛋白质序列 $p = \{a_1, a_2, \dots, a_n\}$ 都可以映射到其

$p \times D_p$ 对应的特征矩阵 X_p 。这里， $\odot^p$

表示蛋白质序列的最大允许长度，该长度用于对齐不同长度的蛋白质序列以进行批量训练。超过允许长度的蛋白质

序列会被截断，而长度较短的则用零填充。

蛋白质特征编码器由两个跳跃块组成，每个跳跃块包含三个连续的卷积神经网络（CNN）层。每个卷积神经网络层编码器 H_p 的描述如下

$$H_p^{(l+1)} = \sigma(H_p^{(l)} W_p^{(l)} + B_p^{(l)}), H_p^{(1)} = X_p \quad (7)$$

其中 $W_p^{(l)}$ 和 $B_p^{(l)}$ 分别是第 l 层卷积神经网络（CNN）中的可学习权重滤波器（矩阵）和偏差向量。

在第一个跳跃块内，将蛋白质序列视为重叠的 3 个氨基酸组成的片段，例如将“MGAGV...ASESKV”转换为“MGA”、“GAG”、……、“ESK”、“SKV”。接下来，我们将感受野依次增加到 6 和 9，以学习更长蛋白质序列的局部特征。然而，持续增加具有更大感受野的卷积神经网络（CNN）层可能会稀释一些先验知识。相反，如果在此阶段停止，则会忽略更细微和深刻的特征。为解决这一问题，我们将原始序列跳过第一个块，并将其与第一个块的输出融合，作为第二个块的输入。第二个块的操作与第一个块相同。在每个块的末尾，我们使用 1×1 卷积层计算并填充块的输出，以使输入和输出的维度对齐。通过这两个块，我们提取了大量的特征，既能捕捉到更抽象的深层特征，又能保留蛋白质的内在生物学知识和上下文语义。整个过程形式化如下。

$$BL^{(1)}(X_p) = \text{pad}(F(X_p, H_p^{(3)})) \quad (8)$$

$$BL^{(2)}(X_p) = \text{pad}(BL^{(1)}(X_p)) + X_p \quad (9)$$

$$O_p = BL^{(2)}(BL^{(1)}) + BL^{(1)} \quad (10)$$

在此过程中， $(*)$ $BL^{(i)}$ 表示第 i 个跳跃块的工作流程。在第一个块中，利用上述映射得到的特征矩阵 X_p 作为输入，以获得 CNN 编码器第三层的输出。如（7）所述，其中 CNN 的每一层都经过了归一化、正则化以及 ReLU 激活函数的处理。 $F(*)$ 表示这些操作的集合，同时对数据执行填充操作 $\text{pad} (*)$ 以保持输入维度的一致性。

$p \times \odot$ 这里的矩阵 O_p^{in} （即最终输出的）

蛋白质编码器（其中 D_{in} 表示跃迁块中的输出通道数）以及获取的 O_p （药物编码器的最终输出）随后被引入到 GIL 模块中。

$$\in \mathbb{R}^{\odot}$$

2.4. 全球互动学习模块。该模块旨在研究药物与蛋白质之间的相互作用机制，获取它们的联合表示矩阵和注意力权重矩阵。在我们的模型中，药物特征通过图结构提取，蛋白质特征则通过序列信息获取。相互作用过程涉及多模态特征融合，因此我们采用了一种非传统的方法。这种方法应用于计算机视觉和自然语言处理的交叉领域，尤其是在视觉问答（QVA）、图像描述和图像检索等任务中。在这些任务中，通常有两种类型的输入：代表图像视觉内容的视觉特征（VF）和

$$\in \mathbb{R}$$

$$\in \mathbb{R}^{\odot}$$

权重向量, 将此权重向量映射到蛋白质的一维序列上, 从而突出模型认为重要的那些氨基酸残基。同时, 我们仍能定位单个蛋白质片段。这是由于 leap 块内卷积神经网络的滑动窗口^{43,44} 属性所致。

三维结构的可视化是通过 PDB45 网站和 Pymol⁴⁶ 软件实现的。这里仅描述方法, 更多有趣的案例和生物学解释将在第 3.6 节提供。请注意, 在本文中, 我们的重点在于药物原子的可解释性。至于靶点的解释, 我们在文中提供了必要的补充和说明。

3. 结果与讨论

3.1. 实现与超参数。我们的实验环境部署在配备两块 RTX 2080 Ti 显卡的系统上, 每块显卡的规格为 11GB 显存, 12 个虚拟 CPU 以及 40GB 内存。MolLoG 所采用的执行环境和工具版本包括: PyTorch 1.11.0 + CUDA 11.3、Python 3.8.10、DGL 0.9.1post1、Numpy 1.23.5、Pandas 1.5.3 和 RDKit 2022.09.5。我们的模型包含大量的超参数, 其中关键参数在表 2 中突出显示。

表 2. MolLoG 中使用的超参数

超参数	环境
优化器	亚当
学习率	5×10^{-4}
最大轮次	100
批量大小	64
跳跃障碍	2
卷积核大小	[3, 6, 9] (此部分为数字 128 表, 无需翻译)
GCN 维度	128
注意力焦点	翻译
注意力池化大小	3

3.2. 预测性能评估。每个实验数据集均随机划分为训练集、验证集和测试集, 比例为 7:1:2。测试集

被视为“未知”数据用于评估。对于每个数据集, 我们使用不同的随机种子进行了五次独立迭代。在验证集上 AUROC 值最高的模型被视为最佳模型, 随后在测试集上对其进行评估。

在此, 我们通过随机拆分设置将 MolLoG 与六个基线模型进行了比较: 支持向量机 (SVM)、随机森林 (RF)、DeepConv-DTI、Graph-DTA、MolTrans 和 DrugBAN。MolLoG 在 BindingDB 和 BioSNAP 数据集上的性能表现见表 3。表中加粗的数据代表最优值。MolLoG 在 AUROC、AUPRC 和准确率方面始终优于基线模型, 在特异性方面也极具竞争力。

由于人类和 DAVIS 数据集具有一些独特的特征, 我们后来分别对模型在这两个数据集上的表现进行了研究。

3.3. 在人类数据集上使用冷配对分割策略。在标准的随机分割范式下, 基于深度学习的模型在人类数据集上表现稳定且出色 (AUROC > 0.97, 波动 < 0.005)。其中, 只有 MolLoG 和 DrugBAN 的 AUROC 超过 0.98。然而, Chen 等人指出人类数据集中可能存在潜在的隐藏配体偏差, 认为基于此数据集训练的模型可能主要学习的是药物特异性特征, 而非期望的相互作用模式。⁴⁸ 因此, 我们采用冷配对分割策略对我们的模型进行更严格的评估。这包括将 5% 和 10% 的药物-靶点相互作用 (DTI) 对分别随机分配到验证集和测试集, 然后从训练集中移除相应的药物和蛋白质。这种策略确保了数据集基于药物和蛋白质的独立性进行分离, 从而在训练过程中测试集中的药物和蛋白质完全未被模型所见。

图 2 展示了在这一严格策略下所有模型性能的显著下降, 传统模型如支持向量机 (SVM) 和随机森林 (RF) 表现尤为明显。尽管面临如此严峻的挑战, MolLoG 与其他最先进的深度学习基准模型相比仍能取得更优的结果。我们还对剩余的三个数据集应用了冷切分策略。所有模型在所有数据集上的性能均有所下降。关键指标 AUROC 和

表 3. 在 BindingDB 和 BioSNAP 数据集上采用随机划分的性能比较

方法	AUROC	AUPRC	准确性	敏感性	特异性
BindingDB					
支持向量机	0.939 ± 0.001	0.928 ± 0.002	0.825 ± 0.004	0.781 ± 0.014	0.886 ± 0.012
射频	0.942 ± 0.011	0.921 ± 0.016	0.880 ± 0.012	0.875 ± 0.023	0.892 ± 0.020
DeepConv-DTI (2019)	0.945 ± 0.002	0.925 ± 0.005	0.882 ± 0.007	0.873 ± 0.018	0.894 ± 0.009
GraphDTA (2021)	0.951 ± 0.002	0.934 ± 0.002	0.888 ± 0.005	0.882 ± 0.012	0.897 ± 0.008
MolTrans (2021)	0.952 ± 0.002	0.936 ± 0.001	0.887 ± 0.006	0.877 ± 0.016	0.902 ± 0.009
DrugBAN (2023)	0.953 ± 0.005	0.943 ± 0.003	0.896 ± 0.005	0.887 ± 0.012	0.906 ± 0.007
MolLoG	0.962 ± 0.004	0.951 ± 0.006	0.905 ± 0.005	0.898 ± 0.012	0.912 ± 0.005
BioSNAP					
支持向量机	0.862 ± 0.007	0.864 ± 0.004	0.777 ± 0.011	0.711 ± 0.042	0.841 ± 0.028
射频	0.860 ± 0.005	0.886 ± 0.005	0.804 ± 0.005	0.823 ± 0.032	0.786 ± 0.025
DeepConv-DTI (2019)	0.886 ± 0.006	0.890 ± 0.006	0.805 ± 0.009	0.760 ± 0.029	0.851 ± 0.013
GraphDTA (2021)	0.887 ± 0.008	0.890 ± 0.007	0.800 ± 0.007	0.745 ± 0.032	0.854 ± 0.025
MolTrans (2021)	0.887 ± 0.002	0.891 ± 0.005	0.802 ± 0.004	0.755 ± 0.021	0.843 ± 0.023
DrugBAN (2023)	0.896 ± 0.005	0.900 ± 0.004	0.834 ± 0.008	0.828 ± 0.021	0.847 ± 0.010
MolLoG	0.898 ± 0.003	0.902 ± 0.005	0.832 ± 0.006	0.826 ± 0.027	0.856 ± 0.022




图 2.在人类数据集上的表现。图表中的数字代表平均值，而误差线则表示性能波动。

在 BingDB 数据集上，MolLoG 的 AUPRC 下降了约 0.02，在 BioSNAP 数据集上下降了约 0.02，在 DAVIS 数据集上下降了约 0.04。不过，就整体性能而言，MolLoG 仍优于其他模型。

3.4. 小样本数据集验证泛化能力。为了进一步评估模型在处理更多参数和模块时是否具有良好的泛化能力，我们在随机划分条件下使用 DAVIS 数据集进行了实验。

DAVIS 数据集包含了经过实验验证的药物 - 蛋白质相互作用数据。然而，其中仅包含有限数量的药物和蛋白质样本。为了便于研究人员提取所需的药物 - 蛋白质相互作用信息以进行分析和建模，该数据集的结构相对简单。这在平衡模型的泛化能力、参数数量和复杂性方面带来了挑战。

因此，我们摒弃了相对简单的模型，比如支持向量机 (SVM) 和随机森林 (RF)。

从表 4 可以看出，MolLoG 通过其独特的从局部到全局的学习方法，展现出了出色的泛化能力，即便面对结构相对简单且样本较少的数据集，也能如此。尽管其具有复杂的层次结构和

更多的参数，但在两个关键指标——准确率和特异性方面，均有显著提升。

3.5. 消融实验。我们进行了三项消融实验，以探究 LFE 模块和 GIL 模块对 MolLoG 的影响。本研究具体涵盖以下方面：

1. 使用不同变体的图神经网络来提取药物特征对模型性能的影响；
2. 使用跳跃块的影响，以及块和层的数量对蛋白质特征提取的影响；
3. 使用 GIL 模块全局整合数据表示的效果以及该模块中注意力头的数量对性能的影响。

在表 5 中，我们展示了五轮实验中 F1 分数表现最佳的一轮的结果。这

表 5. 三种消融研究

消融试验	AUROC	AUPRC	准确性	敏感性	特异性
第 1 部分：在 DAVIS 数据集上使用不同 GNN 变体进行药物特征提取的影响					
GAT	0.8362	0.8125	0.7592	0.7864	0.7879
图归纳学习 (GraphSAGE)	0.8329	0.8078	0.7842	0.7869	0.7633
MolLoG (图卷积网络)	0.8574	0.8592	0.7996	0.8011	0.8010
第 2 部分：在 DAVIS 数据集上使用跳跃块以及块和层的数量对结果的影响					
仅有 3 个卷积神经网络 (CNN) 的模块	0.8361	0.8022	0.7556	0.7626	0.7636
仅有 6 个卷积神经网络 (CNN) 的模块	0.8311	0.7918	0.7501	0.7523	0.7816
3 个包含 3 个卷积神经网络 (CNN) 的模块	0.8512	0.8488	0.7826	0.7820	0.8028
2 个包含 4 个卷积神经网络的模块	0.8663	0.8592	0.7847	0.7889	0.8055
第 3 部分：在 BioSNAP 数据集上使用 GIL 模块进行全局数据表示整合对结果的影响					
未使用	0.8741	0.8782	0.8045	0.7964	0.8126
旧的	0.9011	0.8971	0.8282	0.8257	0.8473

实验表明，我们所采用的每个模块都为 MolLoG 提升了性能。在实验的某一特定阶段，所有其他模块都与 MolLoG 保持一致。

在第 1 部分中，我们比较了使用注意力机制的图注意力网络 (GAT) 和引入了可学习聚合函数的 GraphSAGE，该函数允许节点在聚合过程中对不同的相邻节点进行加权。实验表明，我们所采用的图卷积网络 (GCN) 是最有效的。

在第 2 部分，我们基于 3 层卷积神经网络继续扩大感受野。引入更多参数并未提升模型性能，反而有所下降，这表明了之前提到的梯度消失问题。当我们加入跳跃连接后，所有指标都有了提升。

表 4. 在 DAVIS 数据集上随机划分数据集后的性能比较

方法	AUROC	AUPRC	准确性	敏感性	特异性
戴维斯					
深度卷积药物相互作用预测模型 (DeepConv-DTI, 2019 年)	0.796 ± 0.029	0.788 ± 0.036	0.724 ± 0.008	0.694 ± 0.033	0.721 ± 0.013
DeepDTA (2021)	0.801 ± 0.016	0.790 ± 0.038	0.731 ± 0.013	0.735 ± 0.039	0.720 ± 0.024
MolTrans (2021)	0.828 ± 0.018	0.796 ± 0.028	0.733 ± 0.015	0.702 ± 0.043	0.803 ± 0.052
DrugBAN (2023)	0.814 ± 0.012	0.825 ± 0.033	0.743 ± 0.015	0.748 ± 0.034	0.776 ± 0.019
MolLoG	0.852 ± 0.005	0.856 ± 0.029	0.782 ± 0.011	0.766 ± 0.028	0.808 ± 0.01

显著增加。请注意，在 MolLoG 中，我们使用了 2 个包含 3 个卷积神经网络（CNN）的模块，因为这样能提供更好的鲁棒性和泛化能力。

在第 3 部分，如果我们不使用 GIL 模块来抽象和全局交互特征，而是直接将特征进行拼接，那么性能会显著下降。

我们还比较了不同注意力头数量对性能的影响。在 BindingDB 数据集下，我们将模型在验证集上的 AUROC 和 AUPRC 值绘制为前 60 个周期的折线图，如图 3 所示：模型的性能表现出显著的




图 3. 在 BindingDB 数据集上，验证集前 60 个周期的 AUROC 和 AUPRC 的折线图。

随着训练轮次的增加，呈现出上升趋势。在这些模型中，当多头注意力模块中的头数设置为四个时，模型表现出最佳性能。

总之，这证实了我们策略的有效性，该策略包括提取局部特征以及促进全局交互。

3.6. 案例研究 3.6.1. 药物靶点相互作用预测。为了评估 MolLoG 的预测效率，我们对药物 D00235（阿替洛尔）和 D00567（塞来昔布）进行了案例研究分析。对于这两种药物，我们手动审查了排名前十的预测靶点，并通过与公开数据库中的数据进行比对，最终得到了完全验证（表 6）。鉴于这些令人鼓舞的结果，我们有理由推测，尽管目前尚未得到证实，但一些高分预测的相互作用靶点有可能与所研究的药物存在实际相互作用。这将有助于新药的开发和改进。

3.6.2. 分子层面的可解释性。我们选取了来自蛋白质数据库的两个共晶配体 3U5J（人类 BRD4 的第一个溴结构域与阿普唑仑的复合物）和 5XPR（人类内皮素受体 B 型与拮抗剂波生坦的复合物）

来进行分子层面可解释性的研究。这两个共晶配体的分辨率分别为 1.60 和 3.60 埃，且均未包含在模型训练集中。药物阿普唑仑和波生坦在特定疾病的治疗中发挥着关键作用，并已成为许多患者提高生活质量、延长生存期不可或缺的药物。

阿普唑仑是一种中效起效的三唑并苯二氮草类药物，常用于治疗惊恐障碍、广泛性焦虑以及伴发抑郁的焦虑症状。⁵² 在阿普唑仑与 BRD4 的复杂相互作用中，我们成功预测了阿普唑仑反应中一些关键原子（图 4B）。我们的模型解释了这些高亮原子会与 I146、L94 和 Y139 结合。但在分析蛋白质时，我们的模型未能准确识别这三个靶点。在 BRD4 载体中，阿普唑仑中的乙酰赖氨酸与保守的酪氨酸残基 Y97 配位，这一点 MolLoG 成功识别。共晶分析显示，三唑环作为乙酰赖氨酸的模拟支架，与保守残基 N140 形成氢键。遗憾的是，我们未能捕捉到 N140 是乙酰化底物氢键锚定点这一事实。文献研究表明，其可能原因是阿普唑仑复合物中与 N140 缺少第二个氢键，这可能导致配体亲和力降低。⁵³

在图 4B 中，绿色原子最初由 MolLoG 标记。然而，当我们用三唑仑（与阿普唑仑相比，其绿色原子处仅多一个氯原子）替代实验药物时，MolLoG 去除了该标记。这是因为苯环 2 位的氯原子替换是不被容忍的。MolLoG 捕捉到了这一细微的变化。

波生坦是一种双重内皮素受体拮抗剂，用于治疗肺动脉高压。⁵⁴ 对于结构复杂的 5XPR，我们的模型同样成功地识别出了波生坦与内皮素受体 B 型（ETB）之间的关键相互作用位点（参见图 4F）。波生坦由多个芳香族基团组成，围绕着一个中心的嘧啶模板和四个取代基：2-嘧啶基、4-磺酰胺基、5-苯酚基和 6-乙二醇基。我们能够预测出高分辨率结构中所指出的若干相互作用（图 4G）。磺酰胺基团与 Lys182^{3,33} 和 Lys273^{5,38}；发生离子相互作用，与磺酰胺基团相连的 4-叔丁基苯基与 Val177^{3,28} 和 Pro178^{3,29}；形成疏水接触，中心嘧啶 2 位的嘧啶基与 Ile372^{7,39}；形成疏水接触，5-苯酚的甲氧基苯氧基醚部分与 Val185^{3,36} 和 Leu277^{5,42} 发生反应。

表 6. 药物“D00235”和“D00567”的前 10 个预测靶点列表

药物ID	目标标识符	预测	证据	药物ID	目标标识符	预测	证据
D00235	P18090	0.932	KEGG	D00567	P23280	0.774	KEGG
D00235	Ch_38603	0.921	KEGG	D00567	P00918	0.968	DrugBank
D00235	Ch_735421	0.745	KEGG	D00567	P23219	0.862	KEGG
D00235	P28564	0.862	KEGG	D00567	P35454	0.813	DrugBank
D00235	Q92887	0.843	KEGG	D00567	P07451	0.719	DrugBank
D00235	P07550	0.910	DrugBank	D00567	第十万七千九百八十三章	0.822	KEGG
D00235	O95342	0.861	DrugBank	D00567	Ch_662815	0.855	KEGG
D00235	P08588	0.793	DrugBank	D00567	O15530	0.842	DrugBank
D00235	P61169	0.878	KEGG	D00567	O76074	0.789	KEGG
D00235	P07550	0.746	DrugBank	D00567	EBL_101485	0.831	KEGG




图 4.对预测结果进行重要的可视化展示和补充生物化学知识。(A、E) 两种复杂结构的概览。黑色半透明椭圆聚焦于药物和配体的反应区域。(B、F) 在两种情况下 MolLoG 预测为反应关键的药物原子。(C) BRD4 载脂蛋白结构(绿色条纹状结构)与阿普唑仑配体复合物(棒状结构)的重叠。⁵⁴ 此图突出了主要的相互作用残基以及阿普唑仑结合位点的细节。(D) 共晶配体的详细描绘。阿普唑仑结合位点以透明白色表面表示。(G) 波生坦(棒状结构)与 ETB(淡黄色)的重叠。

跨膜核心。此外,对 6-乙二醇的预测权重较低,这可能是因为波生坦中携带乙二醇的羟基部分仅形成氢键,从而导致受体相互作用减弱。⁵⁵ 在蛋白质残基定位中,我们仅确定了三个靶点,分别标记为 Lys182^{3.33}、Pro178^{3.29} 和 Val185^{3.36}。

总体而言,由于我们的模型仅基于一维蛋白质序列进行训练,可能会导致对药物原子的预测遗漏和不匹配。解读蛋白质结构这一极具挑战性的任务,凸显了我们模型的局限性。然而,其他预测结果的可解释性却有了显著提升。MolLoG 甚至能够预测某些仅在特定条件下才会发生的生化反应。此外,由于 MolLoG 提供的可解释性是从海量的药物-靶点相互作用数据中内在学习而来的,这种解释可能会揭示此前未曾探索过的潜在见解。这一特性有可能为研究人员在进行高成本的生化实验时提供方向性的指导。

3.7. 局限性与未来工作。在数据预处理阶段,如果出现一种科学有效的将蛋白质编码为类似于药物的二维图结构的方法,将其应用于 MolLoG 将显著提高预测准确性和可解释性。此外,将描述药物靶点相互作用(DTIs)的量子力学特征整合到特征提取中也是一个有趣的方向,因为这种方法可以实现极高的精度。然而,获取这种方法所需数据的成本可能很高。在可解释性方面,准确识别原始片段变得具有挑战性。虽然引入位置编码可以建立相应的关系,但这意

味着巨大的性能成本。在我们的初步实验中,引入位置编码使模型训练时间增加了数十倍。因此,整合位置编码并应用知识蒸馏来减少参数数量可能是一个有效的方向。

4. 结论

作为体外实验的有力补充,在大数据和人工智能时代,我们提出了一个深度学习模型 MolLoG,它能够大规模地学习和预测潜在的药物-靶点相互作用(DTIs),从而以高效且经济的方式加速药物开发进程。MolLoG 主要由“LFE”和“GIL”模块组成。实验结果表明,通过从局部到全局的学习方法,它能够高效地提取局部特征,并提供有效的全局联合表示,优于当前最先进的模型。在此基础上,我们将整合了两种模态的注意力权重映射到蛋白质的子序列和药物化合物的原子上。这种方法使我们能够在分子水平上实现结果的可视化。这种增强的可视化表示能够提供更深入的生物学见解,并为实际的医学实验提供更精准的建议。

■ 相关内容

数据可用性声明

MolLoG 的源代码和实现细节可在 GitHub 代码库中免费获取: <https://github.com/fbbgood/MolLoG.git>。

作者信息

通讯作者

张圆圆 - 青岛理工大学信息与控制工程学院, 山东青岛 266520; orcid.org/0000-0003-3935-3201;
电子邮箱: yyzhang1217@163.com

作者

冯宝明 - 青岛理工大学信息与控制工程学院, 中国山东青岛 266520; orcid.org/0009-0000-3704-1680

周晓晨 - 青岛理工大学信息与控制工程学院, 中国山东青岛 266520

王金龙 - 青岛理工大学信息与控制工程学院, 中国山东青岛 266520

冯银飞 - 青岛理工大学信息与控制工程学院, 山东青岛 266520; orcid.org/0000-0002-0172-3302

完整联系信息可在以下网址获取: <http://pubs.acs.org/10.1021/acs.jcim.4c00171>

笔记

作者声明不存在任何利益冲突。

致谢

本研究部分得到了山东省自然科学基金 [ZR2023MF053] 和国家自然科学基金 [项目编号: 61902430] 的资助。

参考文献

- (1) Mizutani, S.; Pauwels, E.; Stoven, V.; Goto, S.; Yamanishi, Y. Relating Drug-Protein Interaction Network with Drug Side Effects. *Bioinformatics* 2012, 28 (18), i522–i528.
- (2) Liebler, D. C.; Guengerich, F. P. Elucidating Mechanisms of Drug-Induced Toxicity. *Nat. Rev. Drug Discovery* 2005, 4 (5), 410–420.
- (3) Anighoro, A.; Bajorath, J.; Rastelli, G. Polypharmacology: Challenges and Opportunities in Drug Discovery. *J. Med. Chem.* 2014, 57 (19), 7874–7887.
- (4) Tsubaki, M.; Tomii, K.; Sese, J. Compound-Protein Interaction Prediction with End-to-End Learning of Neural Networks for Graphs and Sequences. *Bioinformatics* 2019, 35 (2), 309–318.
- (5) Berdgaliev, N.; Aljofan, M. An Overview of Drug Discovery and Development. *Future Med. Chem.* 2020, 12 (10), 939–947.
- (6) Zheng, S.; Li, Y.; Chen, S.; Xu, J.; Yang, Y. Predicting Drug-Protein Interaction Using Quasi-Visual Question Answering System. *Nat. Mach. Intell.* 2020, 2 (2), 134–140.
- (7) Sieg, J.; Flachsenberg, F.; Rarey, M. In Need of Bias Control: Evaluating Chemical Data for Machine Learning in Structure-Based Virtual Screening. *J. Chem. Inf. Model.* 2019, 59 (3), 947–961.
- (8) Lim, S.; Lu, Y.; Cho, C. Y.; Sung, I.; Kim, J.; Kim, Y.; Park, S.; Kim, S. A Review on Compound-Protein Interaction Prediction Methods: Data, Format, Representation and Model. *Comput. Struct. Biotechnol. J.* 2021, 19, 1541–1556.
- (9) Cortes, C.; Vapnik, V. Support-Vector Networks. *Mach. Learn.* 1995, 20 (3), 273–297.
- (10) Breiman, L. Random Forests. *Mach. Learn.* 2001, 45 (1), 5–32.
- (11) Alipanahi, B.; Delong, A.; Weirauch, M. T.; Frey, B. J. Predicting the Sequence Specificities of DNA- and RNA-Binding Proteins by Deep Learning. *Nat. Biotechnol.* 2015, 33 (8), 831–838.
- (12) Wang, S.; Du, Z.; Ding, M.; Zhao, R.; Rodriguez-Paton, A.; Song, T. LDCNN-DTI: A Novel Light Deep Convolutional Neural Network for Drug-Target Interaction Predictions. In *2020 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)*; IEEE Computer Society, 2020, pp 1132–1136.
- (13) Yuan, W.; Chen, G.; Chen, C. Y.-C. FusionDTA: Attention-Based Feature Polymerizer and Knowledge Distillation for Drug-Target Binding Affinity Prediction. *Briefings Bioinf.* 2022, 23 (1), bbab506.
- (14) Nguyen, T.; Le, H.; Quinn, T. P.; Nguyen, T.; Le, T. D.; Venkatesh, S. GraphDTA: Predicting Drug-Target Binding Affinity with Graph Neural Networks. *Bioinformatics* 2021, 37 (8), 1140–1147.
- (15) Kipf, T. N.; Welling, M. Semi-Supervised Classification with Graph Convolutional Networks. 2017, arXiv February 22, 10.48550/arXiv.1609.02907.
- (16) Velic kovic, P.; Cucurull, G.; Casanova, A.; Romero, A.; Lio, P.; Bengio, Y. Graph Attention Networks. 2018, arXiv February 4, 10.48550/arXiv.1710.10903.
- (17) Xu, K.; Hu, W.; Leskovec, J.; Jegelka, S. How Powerful Are Graph Neural Networks?. 2019, arXiv February 22, 10.48550/arXiv.1810.00826.
- (18) Maticzka, D.; Lange, S. J.; Costa, F.; Backofen, R. GraphProt: Modeling Binding Preferences of RNA-Binding Proteins. *Genome Biol.* 2014, 15 (1), R17.
- (19) You, Z.-H.; Lei, Y.-K.; Zhu, L.; Xia, J.; Wang, B. Prediction of Protein-Protein Interactions from Amino Acid Sequences with Ensemble Extreme Learning Machines and Principal Component Analysis. *BMC Bioinf.* 2013, 14 (S8), S10.
- (20) Li, Y.; Hu, J.; Zhang, C.; Yu, D.-J.; Zhang, Y. ResPRE: High-Accuracy Protein Contact Prediction by Coupling Precision Matrix with Deep Residual Neural Networks. *Bioinformatics* 2019, 35 (22), 4647–4655.
- (21) Zhang, B.; Li, J.; Lu, Q. Prediction of 8-State Protein Secondary Structures by a Novel Deep Learning Architecture. *BMC Bioinf.* 2018, 19 (1), 293.
- (22) Jumper, J.; Evans, R.; Pritzel, A.; Green, T.; Figurnov, M.; Ronneberger, O.; Tunyasuvunakool, K.; Bates, R.; Zidek, A.; Potapenko, A.; Bridgland, A.; Meyer, C.; Kohl, S. A. A.; Ballard, A. J.; Cowie, A.; Romera-Paredes, B.; Nikolov, S.; Jain, R.; Adler, J.; Back, T.; Petersen, S.; Reiman, D.; Clancy, E.; Zielinski, M.; Steinegger, M.; Pacholska, M.; Berghammer, T.; Bodenstern, S.; Silver, D.; Vinyals, O.; Senior, A. W.; Kavukcuoglu, K.; Kohli, P.; Hassabis, D. Highly Accurate Protein Structure Prediction with AlphaFold. *Nature* 2021, 596 (7873), 583–589.
- (23) Rumelhart, D. E.; Hinton, G. E.; Williams, R. J. Learning Representations by Back-Propagating Errors. *Nature* 1986, 323 (6088), 533–536.
- (24) Hochreiter, S.; Schmidhuber, J. Long Short-Term Memory. *Neural Comput.* 1997, 9 (8), 1735–1780.
- (25) Huang, K.; Xiao, C.; Glass, L. M.; Sun, J. MolTrans: Molecular Interaction Transformer for Drug-Target Interaction Prediction. *Bioinformatics* 2021, 37 (6), 830–836.
- (26) Huang, K.; Fu, T.; Glass, L. M.; Zitnik, M.; Xiao, C.; Sun, J. DeepPurpose: A Deep Learning Library for Drug-Target Interaction Prediction. *Bioinformatics* 2021, 36 (22–23), 5545–5547.
- (27) Bai, P.; Miljkovic, F.; John, B.; Lu, H. Interpretable Bilinear Attention Network with Domain Adaptation Improves Drug-Target Prediction. *Nat. Mach. Intell.* 2023, 5 (2), 126–136.
- (28) Bian, J.; Zhang, X.; Zhang, X.; Xu, D.; Wang, G. MCANet: Shared-Weight-Based MultiheadCrossAttention Network for Drug-Target Interaction Prediction. *Briefings Bioinf.* 2023, 24 (2), bbad082.
- (29) Zhang, Y.; Feng, Y.; Wu, M.; Deng, Z.; Wang, S. VGEAEDTI: Drug-Target Interaction Prediction Based on Variational Inference and Graph Autoencoder. *BMC Bioinf.* 2023, 24 (1), 278.
- (30) Lim, J.; Ryu, S.; Park, K.; Choe, Y. J.; Ham, J.; Kim, W. Y. Predicting Drug-Target Interaction Using a Novel Graph Neural Network with 3D Structure-Embedded Graph Representation. *J. Chem. Inf. Model.* 2019, 59 (9), 3981–3988.

- (31) He, K.; Zhang, X.; Ren, S.; Sun, J. Deep Residual Learning for Image Recognition. In *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*; IEEE Computer Society, 2016, pp 770–778.
- (32) Gilson, M. K.; Liu, T.; Baitaluk, M.; Nicola, G.; Hwang, L.; Chong, J. BindingDB in 2015: A Public Database for Medicinal Chemistry, Computational Chemistry and Systems Pharmacology. *Nucleic Acids Res.* 2016, 44 (D1), D1045–D1053.
- (33) Bai, P.; Miljkovic, F.; Ge, Y.; Greene, N.; John, B.; Lu, H. Hierarchical Clustering Split for Low-Bias Evaluation of Drug-Target Interaction Prediction. In *2021 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)*; IEEE Computer Society, 2021; pp 641–644.
- (34) Zitnik, M.; Soscic, R.; Leskovec, J. BioSNAP Datasets: Stanford Biomedical Network Dataset Collection. 2018, Note: <http://snap.stanford.edu/biodataCitedby>.
- (35) Wishart, D. S.; Knox, C.; Guo, A. C.; Cheng, D.; Shrivastava, S.; Tzur, D.; Gautam, B.; Hassanali, M. DrugBank: A Knowledgebase for Drugs, Drug Actions and Drug Targets. *Nucleic Acids Res.* 2008, 36 (suppl_1), D901–D906.
- (36) Farenc, C.; Celie, P. H. N.; Tensen, C. P.; de Esch, I. J. P.; Siegal, G. Crystal Structure of the EphA4 Protein Tyrosine Kinase Domain in the Apo- and Dasatinib-Bound State. *FEBS Lett.* 2011, 585 (22), 3593–3599.
- (37) Liu, H.; Sun, J.; Guan, J.; Zheng, J.; Zhou, S. Improving Compound-Protein Interaction Prediction by Building up Highly Credible Negative Samples. *Bioinformatics* 2015, 31 (12), i221–i229.
- (38) Li, M.; Zhou, J.; Hu, J.; Fan, W.; Zhang, Y.; Gu, Y.; Karypis, G. DGL-LifeSci: An Open-Source Toolkit for Deep Learning on Graphs in Life Science. *ACS Omega* 2021, 6 (41), 27233–27238.
- (39) Agrawal, A.; Lu, J.; Antol, S.; Mitchell, M.; Zitnick, C. L.; Parikh, D.; Batra, D. VQA: Visual Question Answering. 2015, arXiv:1505.00468.
- (40) Kelvin, X.; Jimmy, B.; Ryan, K.; Kyunghyun, C.; Aaron, C.; Ruslan, S.; Rich, Z.; Yoshua, B. Show, Attend and Tell: Neural Image Caption Generation with Visual Attention. In *Proceedings of the 32nd International Conference on Machine Learning*; Bach, F., Blei, D., Eds.; PMLR, 2015; Vol. 37, pp 2048–2057.
- (41) Arandjelovic, R.; Gronat, P.; Torii, A.; Pajdla, T.; Sivic, J. NetVLAD: CNN Architecture for Weakly Supervised Place Recognition. In *IEEE Conference on Computer Vision and Pattern Recognition*; IEEE, 2016, pp 5297–5307.
- (42) Landrum, G. RDKit: Open-Source Cheminformatics. 2006.
- (43) Hendry; Chen, R.-C. Automatic License Plate Recognition via Sliding-Window Darknet-YOLO Deep Learning. *Image Vis. Comput.* 2019, 87, 47–56.
- (44) de Souza Rodrigues, T.; Cardoso, F. C.; Ribeiro Teixeira, S. M.; Oliveira, S. C.; Braga, A. P. Protein Classification with Extended-Sequence Coding by Sliding Window. *IEEE/ACM Trans. Comput. Biol. Bioinf.* 2011, 8 (6), 1721–1726.
- (45) Burley, S. K.; Berman, H. M.; Kleywegt, G. J.; Markley, J. L.; Nakamura, H.; Velankar, S. Protein Data Bank (PDB): The Single Global Macromolecular Structure Archive. In *Protein Crystallography: Methods and Protocols* Wlodawer, A., Dauter, Z., Jaskolski, M., Eds.; Springer: New York, NY, 2017; pp 627–641.
- (46) DeLano, W. L. Pymol: An Open-Source Molecular Graphics Tool. *CCP4 Newsl. Protein Crystallogr.* 2002, 40 (1), 82–92.
- (47) Lee, I.; Keum, J.; Nam, H. DeepConv-DTI: Prediction of Drug-Target Interactions via Deep Learning with Convolution on Protein Sequences. *PLoS Comput. Biol.* 2019, 15 (6), No. e1007129.
- (48) Chen, L.; Tan, X.; Wang, D.; Zhong, F.; Liu, X.; Yang, T.; Luo, X.; Chen, K.; Jiang, H.; Zheng, M. TransformerCPI: Improving Compound-Protein Interaction Prediction by Sequence-Based Deep Learning with Self-Attention Mechanism and Label Reversal Experiments. *Bioinformatics* 2020, 36 (16), 4406–4414.
- (49) Hamilton, W. L.; Ying, R.; Leskovec, J. Inductive Representation Learning on Large Graphs. In *31st Conference on Neural Information Processing Systems*; Curran Associates, Inc., 2017; Vol. 30.
- (50) Kuyper, L. M.; Khan, N. A. Atenolol vs Nonatenolol β -Blockers for the Treatment of Hypertension: A Meta-analysis. *Can. J. Cardiol.* 2014, 30 (5), S47–S53.
- (51) Siu, Y. A.; Hao, M.-H.; Dixit, V.; Lai, W. G. Celecoxib Is a Substrate of CYP2D6: Impact on Celecoxib Metabolism in Individuals with CYP2C9*3 Variants. *Drug Metab. Pharmacokinet.* 2018, 33 (5), 219–227.
- (52) Ait-Daoud, N.; Hamby, A. S.; Sharma, S.; Blevins, D. A Review of Alprazolam Use, Misuse, and Withdrawal. *J. Addict. Med.* 2018, 12 (1), 4–10.
- (53) Filippakopoulos, P.; Picaud, S.; Fedorov, O.; Keller, M.; Wrobel, M.; Morgenstern, O.; Bracher, F.; Knapp, S. Benzodiazepines and Benzotriazepines as Protein Interaction Inhibitors Targeting Bromodomains of the BET Family. *Bioorg. Med. Chem.* 2012, 20 (6), 1878–1886.
- (54) Araz, O. Current Pharmacological Approach to ARDS: The Place of Bosentan. *Eurasian J. Med.* 2020, 52 (1), 81–85.
- (55) Shihoya, W.; Nishizawa, T.; Yamashita, K.; Inoue, A.; Hirata, K.; Kadji, F. M. N.; Okuta, A.; Tani, K.; Aoki, J.; Fujiyoshi, Y.; Doi, T.; Nureki, O. X-Ray Structures of Endothelin ETB Receptor Bound to Clinical Antagonist Bosentan and Its Analog. *Nat. Struct. Mol. Biol.* 2017, 24 (9), 758–764.
- (56) Smith, J. S.; Roitberg, A. E.; Isayev, O. Transforming Computational Drug Discovery with Machine Learning and AI. *ACS Med. Chem. Lett.* 2018, 9 (11), 1065–1069.
- (57) Hinton, G.; Vinyals, O.; Dean, J. Distilling the Knowledge in a Neural Network. 2015, arXiv March 9, 10.48550/arXiv.1503.02531.