



开放

用于精确药物-靶点相互作用映射的多层图注意力神经网络

陆倩雯², 周志恒^{3,4}及王琦^{1*}

在药物发现和再利用这一关键过程中, 精准预测药物-靶点相互作用 (DTI) 至关重要。本研究提出了一种新颖的 DTI 预测方法——多层图注意力神经网络 (MLGANN), 通过一种开创性的计算框架, 有效利用多源信息来提高预测准确性。MLGANN 不仅在构建多层 DTI 网络方面取得了进展, 能够捕捉药物与靶点之间的直接相互作用以及它们的多层次信息, 还融合了图卷积网络 (GCN) 与自注意力机制, 以全面整合各种数据源。在对比实验中, 该方法表现出显著优于现有方法的性能, 凸显了其在提升 DTI 预测效率和准确性方面的巨大潜力。更重要的是, 本研究强调了在药物发现过程中考虑多源数据信息和网络异质性的重要性, 为未来的药物研究提供了新的视角和工具。

药物-靶点相互作用 (DTI) 预测是一项旨在识别化学化合物 (药物) 与生物分子 (靶点, 通常是蛋白质) 之间潜在相互作用的计算任务。DTI 预测是现代药物研发中的关键环节。准确的 DTI 预测能够为药物设计提供有价值的线索, 并加快药物再利用的进程, 约 75% 的药物都适合再利用。传统的体外实验测试可以验证 DTI, 但这种方法既昂贵又耗时。近年来, 计算机辅助的 DTI 预测方法受到了广泛关注, 包括矩阵分解、基于核的方法、图嵌入技术等。这些方法的引入缩小了搜索空间, 减少了体外实验的工作量, 并加快了药物研发的进程。

尽管药物-靶点相互作用 (DTI) 预测的重要性已得到广泛认可, 但目前该领域的大多数研究主要依赖于药物的化学结构和靶点的蛋白质序列来进行 DTI 预测⁵⁻⁷。这种方法忽略了关于药物和靶点的其他重要多源信息, 例如药物的物理化学性质以及靶点与疾病之间的关系^{8,9}, 而这些信息对于 DTI 预测同样至关重要。随着深度学习在各个领域展现出卓越的性能, 一些研究人员也将其应用于 DTI 预测, 并取得了令人鼓舞的成果¹⁰⁻¹²。然而, 基于神经网络或机器学习的方法在整合药物和靶点的信息时, 只能利用来自单个药物或靶点的信息^{3,10}。这种做法会导致药物和靶点之间独特相似性信息的丢失。相比之下, 基于网络的方法能够将药物和靶点之间的相似性以及各种特征建模为一个 DTI 网络。该网络用于表示药物和靶点的多维信息, 并应用于 DTI 预测。

由于图神经网络 (GNN) 方法在网络数据分析方面表现出色, 一些研究人员提出了基于 GNN 的模型, 用于异质性药物-靶点相互作用 (DTI) 网络上的 DTI 预测¹³⁻¹⁵。然而, 大多数工作分别考虑药物网络和靶点网络, 忽略了它们相互作用的信息。此外, 一些模型将异质性 DTI 网络视为同质图进行邻域聚合¹³, 这导致无法捕获 DTI 网络中的异质性信息, 从而导致网络节点表示效果不佳。

为解决上述问题, 在本文中, 我们提出了一种多层图注意力神经网络 (MLGANN), 用于捕捉药物和靶点的多源信息以进行药物-靶点相互作用 (DTI) 预测。具体而言, 我们利用收集到的关于药物和靶点的多源信息构建了一个多层 DTI 网络, 然后利用该网络

1. 中国农业大学理学院, 北京 100083, 中国。2. 山东大学-澳大利亚国立大学联合学院, 山东威海 264209, 中国。3. 中国科学院数学与系统科学研究院, 北京 100190, 中国。4. 中国科学院大学数学科学学院, 北京 100190, 中国。* 电子邮箱: wangqi_math@cau.edu.cn

用于药物-靶点相互作用 (DTI) 预测。多层 DTI 网络不仅包含药物与靶点之间的相互作用信息, 还捕获了药物和靶点的多层次信息。此外, 我们设计了一种基于神经网络的模型, 该模型采用图卷积网络 (GCN) 来捕获多层 DTI 网络中关于药物和靶点的多源信息。随后, 采用自注意力机制来整合多源信息, 并获取药物和靶点的表示。最后, 通过在 DTI 数据集上与多个模型进行比较, 结果表明所提出的方法优于最先进的方法。

总之, 我们所提出方法的主要贡献可总结如下:

我们构建了一个用于药物 - 靶点相互作用 (DTI) 预测的多层 DTI 网络, 该网络不仅封装了药物和靶点的多层次信息, 还捕捉了这些层次之间的相互作用。这种全面的整合提高了 DTI 预测的准确性。我们设计了一种多层图注意力神经网络 (MLGANN), 它能够有效地捕捉多层药物 - 靶点相互作用 (DTI) 网络中的多源药物和靶点信息, 以及它们之间的相互作用, 从而进一步提高 DTI 预测结果。通过对 DTI 数据集上多个模型的比较分析, 我们的实验结果表明所提出的方法在解决药物 - 靶点相互作用预测问题上具有有效性和优越性。

相关工作

药物-靶点相互作用 (DTI) 预测是药物发现与开发中的关键任务, 其目标在于其目的是识别药物与靶蛋白之间潜在的相互作用。多年来, 人们开发了各种计算方法来解决这一问题, 从基于相似性的方法到更先进的基于图的方法不等。

传统的药物-靶点相互作用 (DTI) 预测方法通常依赖于相似性度量, 即假定相似的药物会与相似的靶点相互作用。这些方法通常计算药物与药物、靶点与靶点的相似性矩阵, 然后结合机器学习模型来预测相互作用。然而, 这些方法存在局限性, 比如无法整合关于药物和靶点的多源信息。例如, DTINet 和 deepDTnet 等方法就属于此类, 但难以全面捕捉药物与靶点之间关系的复杂性。

近期的研究进展已将知识图谱应用于药物靶点相互作用 (DTI) 预测¹⁷, 其中生物知识被结构化图, 并用于推断新的相互作用。诸如 ComplEx¹⁸ 和 KGE_NFM¹⁹ 等方法已被开发出来, 利用知识图谱嵌入进行 DTI 预测。尽管这些方法提供了一种整合多种生物信息的途径, 但它们通常需要大量的特定领域知识来构建知识图谱, 这可能会限制其适用性。

图神经网络 (GNNs) 因其能够对网络数据中的复杂关系进行建模而广受欢迎。已有多项基于 GNN 的方法被提出用于药物-靶点相互作用 (DTI) 预测, 包括 IMCHGAN¹⁵、SGCL-DTI¹⁴ 和 MHGNN²⁰。这些方法将药物-靶点对视为异质网络中的节点, 并利用 GNN 学习能够捕捉药物与靶点之间复杂关系的嵌入表示。例如, SGCL-DTI 采用了一种有监督的图协同对比学习方法, 而 MHGNN 则使用异质图注意力网络来提高预测的准确性。

除了上述方法之外, 近期还有几项研究进一步推动了该领域的发展。SGCLDGA²¹ 和 NGCN²² 就是其中的显著例子。SGCLDGA 通过结合图神经网络和对比学习来增强药物-靶点相互作用 (DTI) 预测, 其重点在于图结构。而 NGCN 则利用集成的异质网络来提取相关的生物学特性和关联信息, 同时保持拓扑结构信息。

此外, 诸如 TripletMultiDTI²³、DeepTraSynergy²⁴ 和 HGTDR²⁵ 等方法代表了药物靶点相互作用 (DTI) 预测的前沿。TripletMultiDTI 采用三元组损失来增强相互作用与非相互作用配对之间的区分度。DeepTraSynergy 利用深度学习技术来预测药物协同作用, 这与 DTI 密切相关。HGTDR 则通过异质图变换器有效建模药物 - 靶点相互作用的多关系特性, 从而推进药物再利用工作。

尽管现有的方法在药物 - 靶点相互作用 (DTI) 预测方面取得了显著进展, 但它们在整合多源信息或处理药物 - 靶点相互作用的异质性方面常常面临挑战。为了解决这些问题, 我们提出的多层图注意力神经网络 (MLGANN) 不仅能够捕捉药物与靶点之间的多层次相互作用信息, 还通过一种新颖的多层注意力机制整合了多种数据源。正如我们的实验结果所表明的那样, 这种方法能够更全面、更准确地预测药物 - 靶点相互作用。

方法

多层弥散张量成像网络

给定药物集合 $D = \{d_i\}_{i=1}^{n_d}$ 和靶点集合 $T = \{t_j\}_{j=1}^{n_t}$, 可以从多个角度评估药物 (靶点) 之间的相似性, 这些角度由一组矩阵 $\{A_{D,k}\}_{k=1}^{m_d}, \{A_{T,l}\}_{l=1}^{m_t}$, where $A_{D,k} \in \mathbb{R}^{n_d \times n_d}$, $(A_{T,l} \in \mathbb{R}^{n_t \times n_t})$ 表示, 其中 $m_d(m_t)$ 是药物 (靶点) 相似性的类型数量。令二进制矩阵 $AY \in \{0, 1\}^{n_d \times n_t}$ 表示药物集合 D 中的药物与靶点集合 T 中的靶点之间的相互作用, 其中 $AY_{ij} = 1$ 表示 d_i 和 t_j 相互作用, 否则 $AY_{ij} = 0$ 。如图 1 所示, 药物 D 和靶点 T 的多层药物-靶点相互作用 (DTI) 网络 $GM = (VM, EM)$ 由 $\{A_{D,k}\}_{k=1}^{m_d}, \{A_{T,l}\}_{l=1}^{m_t}$ 和 AY 构成, 其邻接矩阵表示为 τ_Y

如下:




图 1 展示了一个多层药物 - 靶点相互作用 (DTI) 网络, 该网络整合了来自药物 (D) 和靶点 (T) 的多层信息。图的左侧展示了药物关联的不同层次 (标记为 $AD,1, AD,2, AD,3$), 代表药物 D_1, D_2, D_3 和 D_4 之间的各种关系。右侧描绘了靶点关联的类似层次 ($AT, 1$ 和 $AT,2$), 涉及靶点 T_1, T_2 和 T_3 。图的中心部分展示了药物与靶点之间的相互作用, 采用多层网络结构来捕捉不同层次信息之间的复杂交互。这种多层方法通过考虑层内和层间相互作用, 能够更全面地预测 DTI。

$$A^M = \begin{pmatrix} A^{D,1} & I & I & \cdots & A^Y & A^Y \\ I & A^{D,2} & I & \cdots & A^Y & A^Y \\ I & I & A^{D,3} & \cdots & A^Y & A^Y \\ \vdots & \vdots & \vdots & \cdots & \vdots & \vdots \\ A^Y & A^Y & A^Y & \cdots & A^{T,m_t-1} & I \\ A^Y & A^Y & A^Y & \cdots & I & A^{T,m_t} \end{pmatrix}. \quad (1)$$

其中 $\|V_M\| = N = (n_d \times m_d + n_t \times m_t)$ 。

多层注意力图神经网络

我们提出了一种名为多层图注意力神经网络 (MLGANN) 的模型用于药物-靶点相互作用 (DTI) 预测。在 DTI 的多层网络中, 除了药物与靶点之间的相互作用外, 药物和靶点自身内部的各种属性之间也存在相互作用信息。因此, 我们利用所设计的 MLGANN 来捕获药物与靶点之间的相互作用信息以及药物和靶点内部的多源信息。

多层邻居聚合

设 $(X \in \mathbb{R}^{N \times f})$ 表示多层 DTI 网络中节点的初始特征, 其中 f 表示特征的数量。嵌入空间的维度。我们应用图神经网络在多层药物 - 靶点相互作用 (DTI) 网络上学习药物和靶点的嵌入表示。具体来说, 在我们的模型中, 我们采用图卷积网络 (GCN), 因为它们既简单又有效。这些嵌入表示可以通过在整个多层 DTI 网络上应用 P 层 GCN 进行优化:

$$X^{(p)} = \sigma \left(\hat{D}^{-\frac{1}{2}} \hat{A} \hat{D}^{-\frac{1}{2}} X^{(p-1)} W^{(p)} \right), \quad p = 1, 2, \dots, P, \quad (2)$$

其中 $X(0) = X$, $\hat{A} = A + IM$, A 是 multi-layer DTI 网络的邻接矩阵, IM 是与 A 大小相同的单位矩阵, $\hat{D}$ 是一个对角矩阵, 其对角线元素为 $\hat{D}_{ij} = \sum_{j=1} A_{ij}$, $W^{(p)} \in \mathbb{R}^{f \times f}$ 是一个可训练的权重矩阵, σ 是非线性激活函数 ReLU。

对于图 GM 中的一个节点 v (代表药物或靶点), 式 (2) 按如下方式更新该节点的嵌入:

$$x_v^{(p)} = \sigma \left(W^{(p)} \sum_u \frac{1}{\alpha_{vu}} x_u^{(p-1)} \right), \quad u \in \{v \cup N_v \cup C_v\} \quad (3)$$

其中 α_{vu} 是归一化权重, N_v 是节点 v 在 GM 层中的邻居集合, C_v 是与节点 v 对应相同药物/靶点的不同 GM 层中的节点集合。因此, MLGANN 不仅聚合了节点 v 在 GM 层中的邻居 (类似于 GCN 的做法), 还嵌入了对应相同药物/靶点的不同 GM 层中的节点。这使得信息能够在 GM 的不同层之间传递。通过利用来自 GM 不同层的信息, MLGANN 能够为每个节点学习到更好的表示, 特别是对于在 GM 特定层中交互有限的节点。这是 MLGANN 与现有其他网络嵌入方法的主要区别。

多层注意力池化

我们将 P 层 GCN 学习到的所有表示进行拼接, 以获得最终的节点嵌入:

$$\begin{aligned} z_i^{D,k} &= [z_i^{D,k(0)}, z_i^{D,k(1)}, \dots, z_i^{D,k(P)}] \\ z_j^{T,l} &= [z_j^{T,l(0)}, z_j^{T,l(1)}, \dots, z_j^{T,l(P)}], \end{aligned} \quad (4)$$

其中 $z_i^{D,k}$ 表示第 i 种药物在 G^M 的第 k 层的最终嵌入, $z_i^{D,k(p)}$ 表示第 i 种药物在 GCN 第 p 层的第 k 层嵌入 G^M , $z_j^{T,l}$ 表示第 j 个靶点在 G^M 的第 l 层的最终嵌入, $z_j^{T,l(p)}$ 表示第 j 种药物在 GCN 第 p 层的第 l 层嵌入 G^M 。

为了获取药物和靶点的最终表示, 我们设计了一种自注意力机制, 用于在 GM 图中聚合药物和靶点在不同层的表示向量, 以进行药物 - 靶点相互作用预测。计算机处理过程如下:

$$\begin{aligned} e_i^{D,k} &= q^D \cdot \text{LeakyReLU} \left(W^D z_i^{D,k} \right), \quad e_j^{T,l} = q^T \cdot \text{LeakyReLU} \left(W^T z_j^{T,l} \right) \\ \alpha_i^k &= \frac{e_i^{D,k}}{\sum_{k'=1}^{m_d} e_i^{D,k'}}, \quad z_i^D = \sum_{k=1}^{m_d} \alpha_i^k z_i^{D,k}, \quad \beta_j^l = \frac{e_j^{T,l}}{\sum_{l'=1}^{m_t} e_j^{T,l'}}, \quad z_j^T = \sum_{l=1}^{m_t} \beta_j^l z_j^{T,l}, \end{aligned} \quad (5)$$

其中 $z_i^D \in \mathbb{R}$ 和 $z_j^T \in \mathbb{R}$ 是 final representations 药物和靶点的权重矩阵分别为 $W^D \in \mathbb{R}^{f \times f}$ 和 $W^T \in \mathbb{R}^{f \times f}$, $q^D \in \mathbb{R}^f$ 和 $q^T \in \mathbb{R}^f$ 是训练的参数矩阵, W^D, U 和 V 是可训练的参数矩阵, $q^D \in \mathbb{R}^f$ 和 $q^T \in \mathbb{R}^f$ 是训练的参数向量。

DTI预测

设 GY 为由邻接矩阵 AY 得出的 DTI 网络。对于 GY 中的一条边 $d_i t_j$, 其中 z_i^D 和 z_j^T 分别为药物 d_i 和靶点 t_j 的最终表示向量。我们从 GY 中采样一条不存在的边 $d_u t_v$, 其中 z_u^D 和 z_v^T 分别为药物 d_u 和靶点 t_v 的最终表示向量。我们将 DTP $d_i t_j$ 视为正样本, 而 $d_u t_v$ 视为负样本。因此, 我们基于交叉熵设计损失函数如下:

$$\mathcal{L} = -\log(\sigma(\langle z_i^D, z_j^T \rangle)) - \log(\sigma(-\langle z_u^D, z_v^T \rangle)) \quad (6)$$

实验

实验装置

数据集 我们从 DrugBank (版本 5.1.8) 收集了药物 - 靶点相互作用 (DTI) 的数据, 以及有关药物化学结构相似性、药物 - 不良反应关系、药物 - 疾病关系、靶点相互作用关系和靶点 - 疾病关系的相关数据。所有这些数据集均可在 DrugBank 上获取。通过这些数据集的交集, 我们共获得了 201 种药物、252 个靶点以及它们之间的 907 种相互作用。我们使用其中的 607 种相互作用进行训练, 300 种相互作用进行测试。这些数据集的统计信息总结在表 1 中, 其中 D 表示药物, T 表示靶点, D-D-1 表示药物化学结构相似性, D-D-2 表示基于药物 - 不良反应关系的相似性, D-D-3 表示基于药物 - 疾病关系的相似性, T-T-1 表示靶点相互作用关系, T-T-2 表示基于靶点 - 疾病关系的相似性。

基线方法 基线方法可分为三类: (1) 基于相似性的方法, 主要包括 DTINet12、deepDTnet26 和 NEDTP4; (2) 基于知识图谱 (KG) 的模型, 使用 TransE27、CompEx18 和 KGE_NFM19; (3) 基于图神经网络 (GNN) 的方法, 例如 DTI-MGNN8、SGCL-DTI14、MHGNN20 和 IMCHGAN15。

D	T	DTI	D-D-1	D-D-2	D-D-3	T-T-1	T-T-2
201	252	907	5142	1263	1598	12123	23545

表 1. 药物靶点相互作用数据集的统计信息。

模型		AUC	精度	召回	F1 分数	AUPR
基于相似性的	DTNet	0.6811±0.0050	0.6503±0.0042	0.5837±0.0063	0.6287±0.0055	0.6924±0.0037
	深度DT网络	0.6704±0.0078	0.6619±0.0099	0.5736±0.0079	0.5878±0.0108	0.6544±0.0049
	NEDTP	0.8027±0.0041	0.7662±0.0072	0.7018±0.0037	0.7240±0.0061	0.8191±0.0031
基于知识图谱的	TransE	0.6245±0.0045	0.5535±0.0044	0.4980±0.0068	0.5122±0.0073	0.6674±0.0055
	KGE-NFM	0.7584±0.0033	0.6973±0.0030	0.6901±0.0046	0.6784±0.0065	0.7688±0.0041
	ComplEx	0.7061±0.0083	0.6229±0.0057	0.6417±0.0032	0.6527±0.0044	0.7477±0.0067
基于图神经网络的	DTI-MGNN	0.7408±0.0069	0.6894±0.0057	0.6427±0.0073	0.6339±0.0045	0.7540±0.0058
	SGCL-DTI	0.6567±0.0167	0.6639±0.0112	0.5422±0.0089	0.5847±0.0095	0.7111±0.0098
	IMCHGAN	0.6864±0.0071	0.6675±0.0074	0.6149±0.0056	0.6482±0.0044	0.7001±0.0063
	MHGNN	0.7980±0.0056	0.7531±0.0035	0.7618±0.006	0.7252±0.0052	0.8263±0.0036
	MLGANN	0.8699±0.0023	0.8122±0.0037	0.7989±0.0041	0.8018±0.0035	0.8552±0.0026
	P 值	P<0.001	P<0.001	P<0.01	P<0.001	P<0.01

表 2. 我们的模型与基准模型在 DTI 数据集上的比较。各项指标中最高和次高的结果分别用粗体和斜体显示。最佳模型表示与次优性能相比，在 P 值水平上具有显著改进，采用单侧配对 t 检验。** 和 *** 分别表示 1% 和 0.1% 的显著水平。

参数配置 我们模型的隐藏节点嵌入维度设置为 256，输出嵌入维度设置为 64。我们堆叠了两层卷积层。对于模型优化，我们的模型将训练 200 个周期，学习率为 0.01，批处理大小为 256。对于 HAN 和 MAGNN，特征融合中的注意力向量维度设置为 128。其他参数设置与 MLGANN 相同。为了公平比较，所有这些基线模型都采用与 MLGANN 相同的训练集和测试集。所有模型均使用 Adam 优化器。在实验中，所有模型均在 DGL 平台和 PyTorch 框架下进行。

评估指标 我们通过链路预测任务来验证所有模型的性能。在训练和测试阶段，正样本由一个药物 - 靶点相互作用（DTI）组成，相应的负样本由一个未知的药物 - 靶点相互作用（DTI）组成。我们使用准确率得分、召回率得分、F1 分数、曲线下面积（AUC）以及精确率 - 召回率曲线下面积（AUPR）作为评估指标。

整体性能

表 2 展示了 DTI 预测的实验结果，其中所有结果均为 5 次重复运行的平均值。如我们所见，MLGANN 显著优于所有基线方法。在 AUC、精确率、召回率和 F1 值这四个指标上分别提高了 0.0672、0.0460、0.0371 和 0.0766，这表明我们所提出的模型具有优越性。与基于相似性的方法相比，MLGANN 能够利用药物和靶点的多源数据，在多层 DTI 网络中捕获药物和靶点的各种特征信息以进行预测。端到端建模方法在 DTI 预测中也显示出优势。然而，基于相似性的方法在建模时依赖于强假设，导致最终预测结果欠佳。此外，两阶段模型将表示学习与预测过程分开。

模型	AUC	精度	召回	F1 分数	AUPR
无 D-D-1	0.7832±0.0037	0.7478±0.0062	0.7118±0.0043	0.7281±0.0047	0.8069±0.0034
无 D-D-2	0.8393±0.0082	0.7973±0.0067	0.7525±0.0056	0.7490±0.0077	0.8413±0.0050
无 D-D-3	0.8078±0.0057	0.7775±0.0033	0.7402±0.0048	0.7415±0.0072	0.8098±0.0066
无 T-T-1	0.8114±0.0058	0.7726±0.0044	0.7567±0.0039	0.7385±0.0051	0.8284±0.0053
无 T-T-2	0.8235±0.0077	0.8004±0.0031	0.7531±0.0062	0.7306±0.0068	0.8316±0.0047
我们的	0.8699±0.0023	0.8122±0.0037	0.7989±0.0041	0.8018±0.0035	0.8552±0.0039
P 值	P<0.01	P<0.01	P<0.01	P<0.001	P<0.01

表 3. 剔除研究的结果（其中 w/o 表示“无”）。最佳模型表示与第二高表现相比，在 P 值水平上有显著提升，采用单侧配对 t 检验。最佳结果以粗体显示（数值越高越好）。** 和 *** 分别表示 1% 和 0.1% 的显著水平。




图 2. 不同隐藏特征维度的影响。

该任务导致学习到的表示向量与药物 - 靶点相互作用 (DTI) 预测结果相矛盾。与基于知识图谱的方法相比, MLGANN 能够更好地学习药物和靶点的表示。

基于图神经网络 (GNN) 的模型通过将药物和靶点的多源数据建模为异质网络, 并使用元路径和图卷积网络 (GCN) 来处理药物-靶点相互作用 (DTI) 预测任务。SGCL-DTI 构建了两个异质网络, 即拓扑网络和语义网络, 以药物-靶点对 (DTP) 作为节点。网络中节点之间的边由 DTP 的相似性决定, 因为共享相同药物或靶点的 DTP 比没有共享药物或靶点的 DTP 具有更高的相似性。因此, 拓扑网络和语义网络存在显著的重叠。此外, SGCL-DTI 在训练过程中可以获取 DTP 的标签。DTI-MGNN 构建了一个以 DTP 为节点的 DTP 图, 将药物和靶点的表示学习与 DTI 预测任务分开。通过将 MLGANN 与 MHGNN 进行比较, 我们可以得出结论: 直接将异质图嵌入方法应用于 DTI 预测任务并不能获得最优的 DTI 预测结果。

消融实验

为了清晰地展示我们构建的多层图的有效性, 我们通过逐步移除多层药物-靶点相互作用 (DTI) 网络中的每一层进行了消融实验。实验结果见表 3。实验结果表明, 使用 3 层药物和 2 层靶点的多层 DTI 网络所获得的结果优于移除多层 DTI 网络中任何单层后所获得的结果。此外, 移除 D-D-1、D-D-3 和 T-T-1 对实验结果有显著影响, 这表明与药物-疾病关系和靶点-疾病关系相关的相似性相比, 药物化学结构相似性、基于药物-疾病关系的相似性以及靶点相互作用关系更为重要。




图 3. 鲁棒性分析的实验结果。

参数分析

为了分析 DTI 预测的性能，我们将隐藏层的维度从 32 改为 512。不同指标的结果如图 2 所示。从图 2 可以看出，随着特征维度的增加，AUC、准确率和 F1 值先上升后下降，AUC 和准确率在维度为 256 时达到峰值，F1 值在维度为 128 时达到峰值。召回率在维度为 256 时达到峰值结果。这表明隐藏层的维度过小无法捕捉数据的特征信息，而维度过大则会导致模型容易过拟合，影响模型的泛化性能。

稳健分析

为了分析模型的稳健性，我们随机移除 10% 至 50% 的训练数据。不同指标的结果如图 3 所示。从图 3 可以看出，随着移除比例的增加，AUC、F1 分数和 AUPR 的值均有所下降。然而，在这三个模型中，MLGANN 不仅在所有指标上都保持了最高的性能，而且下降幅度最小。这表明 MLGANN 在药物 - 靶点相互作用预测任务中具有良好的稳健性。

结论

在本研究中，我们成功开发了多层图注意力神经网络（MLGANN），旨在阐明多层药物 - 靶点相互作用（DTI）网络中复杂的结构和细微的语义。MLGANN 利用 GCN 捕获药物和靶点的多源信息，并进一步采用自注意力机制获取药物和靶点的表示。我们使用来自 DrugBank 的数据进行了模型训练和验证，结果表明 MLGANN 在 DTI 预测方面是有效的。展望未来，我们准备通过纳入更多数据集来扩大研究范围，从而丰富我们的训练和验证框架。这种策略性的扩充预计将进一步提高我们模型的预测能力，使其成为药物发现和开发领域更强大的工具。

数据可用性

本研究中有关药物 - 靶点相互作用的数据来源于 DrugBank（版本 5.1.8）。如需了解更多信息，请访问 <https://go.drugbank.com/>。

收稿日期：2024 年 2 月 2 日；接受日期：2024 年 10 月 8 日

Published online: 30 October 2024

参考文献

- Nosengo, N. et al. Can you teach old drugs new tricks? *Nature* **534**, 314–316 (2016).
- Ezzat, A., Zhao, P., Wu, M., Li, X.-L. & Kwok, C.-K. Drug-target interaction prediction with graph regularized matrix factorization. *IEEE/ACM Trans. Comput. Biol. Bioinform.* **14**, 646–656 (2016).
- Ding, Y., Tang, J. & Guo, F. Identification of drug-target interactions via dual Laplacian regularized least squares with multiple kernel fusion. *Knowl.-Based Syst.* **204**, 106254 (2020).
- An, Q. & Yu, L. A heterogeneous network embedding framework for predicting similarity-based drug-target interactions. *Brief. Bioinform.* **22**, bbab275 (2021).
- Gao, K. Y. et al. Interpretable drug target prediction using deep neural representation. In *IJCAI Vol. 2018*, 3371–3377 (2018).
- Huang, K., Xiao, C., Glass, L. M. & Sun, J. Moltrans: Molecular interaction transformer for drug-target interaction prediction. *Bioinformatics* **37**, 830–836 (2021).
- Chu, Y. et al. DTI-MLCD: Predicting drug-target interactions using multi-label learning with community detection method. *Brief. Bioinform.* **22**, bbaa205 (2021).
- Liu, B., Pliakos, K., Vens, C. & Tsoumakas, G. Drug-target interaction prediction via an ensemble of weighted nearest neighbors with interaction recovery. *Appl. Intell.* **52**, 1–23 (2022).
- Pliakos, K., Vens, C. & Tsoumakas, G. Predicting drug-target interactions with multi-label classification and label partitioning. *IEEE/ACM Trans. Comput. Biol. Bioinform.* **18**, 1596–1607 (2019).
- Olayan, R. S., Ashoor, H. & Bajic, V. B. DDR: Efficient computational method to predict drug-target interactions using graph mining and machine learning approaches. *Bioinformatics* **34**, 1164–1173 (2018).

11. Zhang, Z.-C. et al. A graph regularized generalized matrix factorization model for predicting links in biomedical bipartite networks. *Bioinformatics* **36**, 3474–3481 (2020).
12. Luo, Y. et al. A network integration approach for drug-target interaction prediction and computational drug repositioning from heterogeneous information. *Nat. Commun.* **8**, 573 (2017).
13. Wan, F., Hong, L., Xiao, A., Jiang, T. & Zeng, J. NeoDTI: Neural integration of neighbor information from a heterogeneous network for discovering new drug-target interactions. *Bioinformatics* **35**, 104–111 (2019).
14. Li, Y., Qiao, G., Gao, X. & Wang, G. Supervised graph co-contrastive learning for drug-target interaction prediction. *Bioinformatics* **38**, 2847–2854 (2022).
15. Li, J., Wang, J., Lv, H., Zhang, Z. & Wang, Z. IMCHGAN: Inductive matrix completion with heterogeneous graph attention networks for drug-target interactions prediction. *IEEE/ACM Trans. Comput. Biol. Bioinform.* **19**, 655–665 (2021).
16. Adasme, M. F., Parisi, D., Sveshnikova, A. & Schroeder, M. Structure-based drug repositioning: Potential and limits. In *Seminars in cancer biology* Vol. 68 192–198 (Elsevier, 2021).
17. Mohamed, S. K., Nounu, A. & Nováček, V. Drug target discovery using knowledge graph embeddings. In *Proceedings of the 34th ACM/SIGAPP Symposium on Applied Computing*, 11–18 (2019).
18. Trouillon, T., Welbl, J., Riedel, S., Gaussier, É. & Bouchard, G. Complex embeddings for simple link prediction. In *International Conference on Machine Learning*, 2071–2080 (PMLR, 2016).
19. Ye, Q. et al. A unified drug-target interaction prediction framework based on knowledge graph and recommendation system. *Nat. Commun.* **12**, 6775 (2021).
20. Li, M., Cai, X., Xu, S. & Ji, H. Metapath-aggregated heterogeneous graph neural network for drug-target interaction prediction. *Brief. Bioinform.* **24**, bbac578 (2023).
21. Fan, Y. et al. SGCLDGA: Unveiling drug-gene associations through simple graph contrastive learning. *Brief. Bioinform.* **25**, bbae231 (2024).
22. Cao, J. et al. NGCN: Drug-target interaction prediction by integrating information and feature learning from heterogeneous network. *J. Cell Mol. Med.* **28**, e18224 (2024).
23. Dehghan, A., Razzaghi, P., Abbasi, K. & Gharaghani, S. TripletMultiDTI: Multimodal representation learning in drug-target interaction prediction with triplet loss function. *Expert Syst. Appl.* **232**, 120754 (2023).
24. Rafiei, F. et al. DeepTraSynergy: Drug combinations using multimodal deep learning with transformers. *Bioinformatics* **39**, btad438 (2023).
25. Gharizadeh, A., Abbasi, K., Ghareyazi, A., Mofrad, M. R. & Rabiee, H. R. HGTDR: Advancing drug repurposing with heterogeneous graph transformers. Preprint at [arXiv:2405.08031](https://arxiv.org/abs/2405.08031) (2024).
26. Zeng, X. et al. Target identification among known drugs by deep learning from heterogeneous networks. *Chem. Sci.* **11**, 1775–1797 (2020).
27. Bordes, A., Usunier, N., Garcia-Duran, A., Weston, J. & Yakhnenko, O. Translating embeddings for modeling multi-relational data. *Adv. Neural Inf. Process. Syst.* **26** (2013).

作者贡献

Q.L. 提出项目构想，开发预测方法，设计实验，实施实验并撰写论文。Z.Z. 提出项目构想，设计实验，分析结果并撰写论文。Q.W. 提出项目构想，分析结果并修订论文。所有作者均已审阅并批准了该稿件。

声明

利益冲突

作者声明不存在利益冲突。

附加信息

来信及索取资料请寄给 Q.W.。

有关重印和转载的信息，请访问 www.nature.com/reprints。

出版者注：施普林格·自然对于所发表的地图中涉及的管辖权主张以及机构隶属关系不持立场。

开放获取 本文遵循知识共享署名 - 非商业性使用 - 禁止演绎 4.0 国际许可协议。该协议允许在任何媒介或格式下进行任何非商业用途的使用、分享、分发和复制，但需注明原作者姓名、来源，并提供指向知识共享许可协议的链接，同时表明是否对许可材料进行了修改。未经许可，您无权根据本许可协议分享基于本文或其部分内容的改编材料。除非文章中另有说明，本文中的图片或其他第三方材料均包含在知识共享许可协议中。如果材料未包含在本文的知识共享许可协议中，且您的使用意图不受法规限制或超出许可范围，您需要直接从版权所有处获得许可。如需查看本许可协议的副本，请访问 <http://creativecommons.org/licenses/by-nc-nd/4.0/>。

© 作者（们） 2024 年