


化学科学

rsc.li/化学科学



国际标准刊号：2041-6539



引用本文:《化学科学》, 2022
年, 13 卷, 3661 页

本文的所有出版费用

由英国皇家化学会支付费用

PIGNet: 一种面向广义药物-靶点相互作用预测的物理信息深度学习模型†

Seokhyun Moon, ‡^a Wonho Zhung, ‡^a Soojung Yang, ‡^a Jaechang Lim^{†b} and Woo Youn Kim^{*ab}

近期, 基于深度神经网络 (DNN) 的药物靶点相互作用 (DTI) 模型因其高精度和可接受的计算成本而备受关注。然而, 这些模型在泛化能力方面的不足仍是计算机辅助药物发现实践中面临的一个难题。我们提出了两种关键策略来增强 DTI 模型的泛化能力。第一种策略是通过用神经网络参数化的物理信息方程来预测原子间成对相互作用, 并将蛋白质-配体复合物的总结合亲和力表示为这些相互作用的总和。我们还通过在训练数据中增加更广泛的结合构象和配体来进一步提高模型的泛化能力。我们在 2016 年的评分函数比较评估 (CASF) 中验证了我们的模型 PIGNet, 结果表明其对接和筛选能力优于以往的方法。我们的物理信息策略还能够通过可视化配体子结构的贡献来解释预测的亲和力, 为配体的进一步优化提供见解。

收稿日期: 2021 年 12 月 13 日
接受日期: 2022 年 2 月 6 日

DOI: 10.1039/d1sc06946b

rsc.li/化学科学

1 简介

深度学习是科学领域中发展迅速的一个分支。深度学习在自然语言处理、视频游戏和计算机视觉等众多应用中的显著成功, 使得人们对其在其他领域取得类似成就充满期待, 从而催生了深度学习算法的广泛应用。尤其是生物医学应用, 因其不仅具有重要的社会影响力, 而且在科学上也极具价值, 因此迅速成为最活跃的领域之一。然而, 尽管人们寄予厚望, 深度学习在该领域尚未展现出其最高潜力, 这主要是由于数据稀缺且严重不平衡导致的泛化能力不足问题。⁴⁵例如, 构建一个可靠的模型来预测药物-靶点相互作用 (DTIs), 这是虚拟筛选新型候选药物的关键技术, 就是这样一个例子。⁶

作为一种理想的药物靶点相互作用 (DTI) 预测方法, 应当既可靠又快速, 因此高预测准确性和低计算成本是两个关键因素。然而, 对接法 methods⁸⁻¹⁶ 作为最常用的常规方法, 虽然速度够快, 但准确性不足 accurate,¹⁷⁻¹⁹ 而基于热力学积分的更严格方法计算成本又过高。^{20,21} 这些基于物理的方法存在一个固有的局限性, 即低计算成本只能通过牺牲准确性来实现。相比之下, 数据驱动的方法仅通过使用更多数据进行学习, 就能在不增加推理成本的情况下提高预测准确性。正是这种数据驱动方法的独特优势, 推动了基于深度学习的药物靶点相互作用 (DTI) 模型的积极发展, 这些模型既实现了高准确性又保持了低 cost。²²⁻³⁰

在众多基于深度学习的模型中, 基于结构的方法因其准确性而脱颖而出; 蛋白质与配体的空间协调对于确定它们之间的相互作用至关重要。³¹ 一些有前景的研究利用三维卷积神经网络 (3D CNNs),³²⁻⁴¹ 图神经网络 (GNNs),⁴¹⁻⁴⁴ 或基于原子环境向量的前馈神经网络。⁴⁵ 这些最先进的方法与对接计算相比, 显著提高了药物-靶点相互作用 (DTI) 预测的准确性。

尽管基于结构的先前模型有所进步, 但其有限的泛化能力仍是实现更优性能的一个棘手问题。特别是蛋白质-配体复合物的 3D 结构数据不足, 可能会导致模型过度记忆训练数据中的特征。这种模型过度拟合于训练数据,

^aDepartment of Chemistry, KAIST, 291 Daehak-ro, Yuseong-gu, Daejeon 34141, Republic of Korea. E-mail: wooyoun@kaist.ac.kr

^bHITS Incorporation, 124 Teheran-ro, Gangnam-gu, Seoul 06234, Republic of Korea [†]KI for Artificial Intelligence, KAIST, 291 Daehak-ro, Yuseong-gu, Daejeon 34141, Republic of Korea

[†]Electronic supplementary information (ESI) available: the algorithm and implementation details of all the models used in the experiments, the details about the benchmark criteria and the physical interpretation result. See DOI: 10.1039/d1sc06946b

‡ These authors contributed equally to this work.

§ Currently at Computational and Systems Biology, MIT, 77 Massachusetts Ave, Cambridge, MA.

数据可能无法在更广泛的背景下进行泛化。⁴⁶多项研究表明, 基于深度学习的模型往往学习的是数据固有的偏差, 而非期望的蛋白质 - 配体相互作用的潜在物理机制。^{37,47,48}例如, Chen 等人⁴⁷报告称, 使用 DUD-E 数据集训练的受体 - 配体模型和仅配体模型在受试者工作特征曲线 (ROC 曲线) 下的面积 (AUC) 方面表现极为相似。这种相似性表明, 这些模型可能仅通过观察配体结构就学会了推断蛋白质 - 配体结合亲和力, 而不管是否将蛋白质结构作为输入。此外, 他们还表明, 这种错误特征的记忆会导致对结构与训练数据差异较大的蛋白质的性能严重下降。该论文还报告称, 在 DUD-E 数据集上训练的 3D CNN 和 GNN 模型在使用 ChEMBL 和 MUV 数据集进行测试时表现明显不佳。^{36,44}对 DTI 模型的这种概括不足可能会导致虚拟筛选场景中的假阳性率上升, 因为这些模型常常无法对未见过的蛋白质 - 配体对做出正确的预测。

在深度学习的物理应用领域, 将适当的物理知识作为归纳偏差纳入模型是一种很有前景的提升模型泛化能力的方法。如果模型在训练过程中被设定遵循某些物理原理, 那么它有望对由相同物理规律支配的未见数据进行泛化。确实有若干研究显示, 这些受物理知识启发的模型对于未见的数据。⁴⁹⁻⁵¹数据仍能保持其泛化能力。

在这方面, 我们提出了两种关键策略来增强药物靶点相互作用 (DTI) 模型的泛化能力。首先, 我们引入了一种新颖的基于物理信息的图神经网络, 名为 PIGNet。它将蛋白质 - 配体复合物的结合亲和力表示为原子 - 原子成对相互作用的总和, 这些相互作用是四种能量成分的组合——范德华 (vdW) 相互作用、氢键、金属 - 配体相互作用和疏水相互作用。每种能量成分都由一个由深度神经网络参数化的物理模型计算得出, 该网络学习了相互作用的特定模式。这种策略能够通过允许模型将未见过的蛋白质 - 配体对分解为蛋白质和配体之间常见相互作用的组合来提高泛化能力。局部相互作用的详细模式使模型能够学习蛋白质 - 配体结合背后的普遍物理规律。此外, 由于该模型为每个原子 - 原子对和每个能量成分提供预测, 因此可以分析单个分子亚结构对结合亲和力的贡献。此信息可用于对候选药物进行修改, 以进一步增强其结合亲和力。

其次, 我们采用了一种数据增强策略。实际上, 筛选库包含各种化合物, 其中大多数化合物在训练集中并未出现。目前可用的蛋白质 - 配体结合结构的实验数据在所有可能的结合复合物的结构多样性方面覆盖范围非常有限。仅使用实验结合结构集 (其中仅包含稳定的结合构象) 训

练的模型, 在推理集中可能无法区分稳定构象和非稳定构象。⁴⁷因此, 我们通过计算生成的蛋白质 - 配体对的随机结合构象来扩充训练数据, 以提高模型的泛化能力。⁴⁸

为了评估所提出模型的泛化能力, 我们重点关注了 CASF-2016 基准测试中的对接和筛选能力。⁵²此前, 药物靶点相互作用 (DTI) 模型的评估主要依据预测的结合亲和力与实验值之间的相关性。^{35,36,42-44}然而, 高相关性并不能自动保证模型具有良好的泛化能力。⁴⁷一个泛化能力强的模型应当能够成功识别能量最低的真实结合构象, 并正确排列出最佳结合分子。前者可以通过对接能力来评估, 而后者则与筛选能力相关。对模型在这两项任务上的表现进行考察对于确保其在诸如虚拟高通量筛选 (vHTS) 等实际应用中的泛化能力至关重要。我们将 PIGNet 的基准测试结果与传统对接计算以及先前的深度学习模型进行了比较, 结果表明我们的模型在对接能力和筛选能力方面均有显著提升。

除了模型性能的提升, 我们还展示了我们模型的可解释性。虽然对药物靶点相互作用 (DTI) 预测背后化学原理解读的解读是药物研发中的关键步骤, 但此前采用完全黑箱方法的深度学习模型在这方面并不实用。^{53,54}相反, 基于物理原理的深度学习模型能够提供可解释性, 因为这些模型中的若干中间变量具有一定的物理意义。⁵⁵由于我们的模型能够预测每个原子对之间的相互作用能, 因此我们可以估算出每个配体子结构对总结合自由能的贡献。这种解释能够为从业者提供指导, 例如将贡献较小的部分改造成结合能力更强的部分。

2 方法

2.1 相关工作

2.1.1 基于结构的深度药物-靶点相互作用模型综述。3D 卷积神经网络 (CNN) 将代表蛋白质-配体复合物中原子坐标的三维矩形网格作为输入 input。³²⁻⁴¹所提出的 3D CNN 模型在 PDBbind 和 DUD-E 数据集上分别在皮尔逊相关系数和 AUC 方面优于对接程序。然而, 三维矩形表示的高维度以及对化学相互作用和键的显式表示的缺失可能会对 3D CNN 模型造成限制。⁵⁶一种有前景的替代方案是图神经网络 (GNN), 它将结构信息表示为分子图。⁵⁷分子中的每个原子和化学相互作用 (或键) 分别在图中表示为节点和边。此外, 分子图可以通过仅将成对欧几里得距离在一定阈值内的原子对视为邻居来纳入三维结构信息。而且,



与 3D CNN 的网格表示不同, 图表示对于平移和旋转具有不变性。图表示相对于网格表示的这些优势可能有助于图神经网络 (GNNs) 在药物-靶点相互作用 (DTI) 方面取得最先进的性能 predictions.^{41–44,58}

2.1.2 物理信息神经网络。格雷达努斯等人⁴⁸提出了哈密顿神经网络, 这是一种对遵循哈密顿力学的系统进行建模的有效方法。他们利用深度神经网络来预测哈密顿方程中的参数, 并展示了比以往神经网络更好的泛化能力。潘等人⁴⁹提出了一种用于原子势能建模的物理信息神经网络。该模型预测每种类型原子间势能的参数, 而非直接预测系统的总能量。这种策略提高了在键合区域之外进行模拟时模型的泛化能力。在本研究中, 我们利用神经网络对源自化学相互作用物理原理的方程进行参数化。

2.2 模型架构

PIGNet 是一种深度学习模型, 用于预测给定蛋白质 - 配体复合物结构的结合自

由能 (图 1)。它以分子图 G 和蛋白质 - 配体复合物中原子对之间的距离 d_{ij} 作为输入。通常, 图 G 可以定义为 (H, A) , 其中 H 是节点特征集, A 是邻接矩阵。在有属性的图中, 节点特征 i^{th} 由向量表示 h_i 。值得注意的是, 我们的图表示包含两个邻接矩阵, 以区分每个分子中的共价键以及蛋白质和配体原子之间的分子间相互作用。初始节点特征和两个邻接矩阵的构建细节在 ESI 中有详细说明。[†]

我们的模型由多个门控图注意力网络 (门控 GAT) 单元和交互网络组成。门控 GAT 和交互网络通过两个分别对应共价键和分子间相互作用的邻接矩阵来更新每个节点的特征。在节点特征更新过程中, 门控 GAT 和交互网络分别学习传递共价键和分子间相互作用的信息。经过多次节点特征更新后, 我们将最终的节点特征输入到基于物理知识的参数化方程中, 以计算范德华相互作用 (E^{vdw})、氢键相互作用 (E^{hbond})、金属-配体相互作用 (E^{metal}) 和疏水相互作用 ($E^{\text{hydrophobic}}$)。具体而言, 对于每个能量分量, 全连接层接收一组




图 1 我们的模型架构。蛋白质 - 配体复合物以图的形式表示, 并根据复合物的结合结构分配邻接矩阵。每个节点特征通过神经网络进行更新, 以携带共价键和分子间相互作用的信息。根据每对原子的距离和最终节点特征, 从基于物理原理的参数化方程中计算出四个能量分量。总结结合亲和力作为成对结合亲和力之和获得, 即四个能量分量之和除以一个熵项。

最终节点特征作为输入，并生成物理信息方程的参数值。我们还通过将总能量除以旋转体惩罚项 (T^{rotor}) 来考虑蛋白质-配体结合的熵损失。总能量可以写成如下形式：

$$E^{\text{total}} = \frac{E^{\text{vdW}} + E^{\text{hbond}} + E^{\text{metal}} + E^{\text{hydrophobic}}}{T^{\text{rotor}}} \quad (1)$$

2.2.1 门控图注意力网络 (门控 GAT)。门控 GAT 根据共价键的邻接矩阵更新一组节点特征。注意力机制旨在根据相邻节点的重要性赋予不同的权重。⁵⁹ 注意力系数表示节点的重要性，它是根据通过共价键相连的两个节点计算得出的，然后在相邻节点间进行归一化处理。门控机制的目的是有效地将前一节点特征的信息传递到下一节点特征。前一节点的贡献程度由一个系数决定，该系数由前一节点特征和新节点特征共同获得。我们将在 ESI 中详细介绍门控 GAT 的细节。[†]

2.2.2 交互网络。交互网络从门控 GAT 中获取更新后的节点特征集以及邻接矩阵，以生成下一组节点特征。与门控 GAT 不同，交互网络采用的邻接矩阵体现了分子间的相互作用。交互网络通过将先前的节点特征集与两个不同的可学习权重相乘，生成两组不同的嵌入节点特征。接下来，我们对每组嵌入节点特征应用最大池化操作，从而获得两组相互作用嵌入节点特征。然后将这些相互作用嵌入节点特征与嵌入节点特征相加，生成新的节点特征。最终的节点特征是新节点特征与先前节点特征的线性组合，其中线性组合通过门控循环单元 (GRU) 来实现。⁶⁰ 交互网络的详细信息见 ESI。[†]

2.3 物理信息参数化函数

PIGNet 由四个能量成分——范德华相互作用、疏水相互作用、氢键相互作用和金属-配体相互作用——以及一个转子惩罚项组成。节点 i^{h} 和节点 j^{h} 之间相互作用的能量成分由两个节点特征 h_i 和 h_j 计算得出。由于节点特征包含了两个原子及其相互作用的信息，因此该模型能够合理地预测药物-靶点相互作用 (DTI)。

能量成分和转子惩罚项的设定是基于 AutoDock Vina 的经验函数。⁸ 总结合力能通过能量成分的加权和来获得，其中权重用于考虑计算出的能量与真实自由结合能之间的差异。PIGNet 利用可学习的参数为每个成分找到最优权重，从而学会考虑不同类型的蛋白质-配体相互作用。

每个能量分量都是根据 $d_{\{ij\}}$ 和 $d_{\{ij\}}$ 计算得出的，其中 $d_{\{ij\}}$ 是第 i 个节点与第 j 个节点之间的原子间距离

，而 $d_{\{ij\}}$ 则是这两个节点的范德华半径的校正和。 d_{ij}^0 可以表示如下：

其中 r 是每个节点的范德华半径，取自 X-Score 参数。¹⁰ b_{ij} 是两个节点之间的校正项，由一个全连接层得出，该层接受两个节点特征 h_i 和 h_j 作为输入。我们使用 0.2 作为常数 c 来缩放校正项。

2.3.1 范德华 (vdW) 相互作用。我们使用 12-6 莱纳斯-琼斯势能来计算范德华相互作用项 E^{vdW} 。我们考虑了除金属原子之外的所有蛋白质和配体原子对，因为金属原子的范德华半径会因原子类型的不同而有很大差异。总的范德华能量是所有可能的原子对范德华能量贡献系数之和。范德华相互作用项 E^{vdW} 可以描述如下：

$$E^{\text{vdW}} = \sum_{ij} c_{ij} \left[\left(\frac{d'_{ij}}{d_{ij}} \right)^{12} - 2 \left(\frac{d'_{ij}}{d_{ij}} \right)^6 \right], \quad (3)$$

其中 c_{ij} 是由一个全连接层预测得出的，表示最小范德华相互作用能，使每个估计的能量分量与真实能量分量相似，从而反映物理现实。

2.3.2 氢键、金属-配体相互作用、疏水相互作用。氢键 (E^{hbond})、金属-配体相互作用 (E^{metal}) 和疏水相互作用 ($E^{\text{hydrophobic}}$) 的成对能量贡献系数 e_{ij} 具有相同的表达式 (如式 (4) 所示)，只是系数 c_1 、 c_2 不同，并且有一个可学习的标量变量 w 。

$$e_{ij} = \begin{cases} w & \text{if } d_{ij} - d'_{ij} < c_1, \\ w \left(\frac{d_{ij} - d'_{ij} - c_2}{c_1 - c_2} \right) & \text{if } c_1 < d_{ij} - d'_{ij} < c_2, \\ 0 & \text{if } d_{ij} - d'_{ij} > c_2 \end{cases} \quad (4)$$

在此，氢键和金属-配体相互作用的 c_1 和 c_2 分别设为 0.7 和 0.0，而疏水相互作用的常数设为 0.5 和 1.5。由于氢键和金属-配体相互作用均源于电子供体-受体相互作用，因此我们为两者选择了相同的 c_1 和 c_2 值。每个能量分量均按式 (5) 所述，作为相应原子对能量贡献系数的总和来计算：

X

$$E = \sum_{ij} e_{ij}. \quad (5)$$

我们将原子分为氢键受体、氢键供体、金属原子和疏水原子。由于氢键出现在氢键供体和氢键受体之间，因此通过 SMARTS⁶¹ 通用描述符的子结构匹配来选择形成氢键的每个原子，这些描述符总结在表 S2 中。[†] 金属原子包括镁、钙、锰、铁、钴、镍、铜和锌。最后，



仅被碳原子或氢原子包围的卤素原子或碳原子中心被归类为疏水原子。¹⁰

2.3.3 转子惩罚项。转子惩罚项 T^{rotor} 旨在考虑结合口袋在蛋白质-配体结合过程中阻碍化学键自由旋转所导致的熵损失。我们假设熵损失与配体分子中可旋转键的数量成正比。 T^{rotor} 可以描述如下：

$$T^{\text{rotor}} = 1 + C_{\text{rotor}} \times N_{\text{rotor}}, \quad (6)$$

其中 N_{rotor} 表示可旋转键的数量， C_{rotor} 是一个可学习的正标量变量。我们使用 RDKit 软件⁶² 来计算 N_{rotor} 。

2.4 蒙特卡罗丢弃法 (MCDO) 与知识不确定性

在测试阶段，总共集成 30 个模型，其丢弃率与训练阶段相同，均为 0.1。我们通过平均各个模型的预测值来获取预测值，并将方差解释为知识不确定性。在此，我们将使用和不使用蒙特卡罗丢弃操作的 PIGNet 分别定义为 PIGNet (集成) 和 PIGNet (单模型)。

2.5 损失函数

PIGNet 的损失函数由三个部分组成，分别为 L_{energy} 、 $L_{\text{derivative}}$ 和 $L_{\text{augmentation}}$ ，如公式 (7) 所示：

$$L_{\text{total}} = L_{\text{energy}} + L_{\text{derivative}} + L_{\text{augmentation}} \quad (7)$$

图 2 解释了基于三个损失函数的 PIGNet 的整体训练方案。 L_{energy} 是模型预测值 y_{pred} 与相应实验结合自由能 y_{true} 之间的均方误差 (MSE) 损失。

$$L_{\text{energy}} = \frac{1}{N_{\text{train}}} \sum_i (y_{\text{pred},i} - y_{\text{true},i})^2, \quad (8)$$

其中 N_{train} 表示训练数据的数量。最小化 L_{energy} 可使模型正确预测实验 3D 结构的结合亲和力。 $L_{\text{derivative}}$ 由能量对原子位置的一阶和二阶导数组成。最小化 $L_{\text{derivative}}$ 旨在使模型能够灵敏地找到相对稳定的构象。 $L_{\text{augmentation}}$ 是与数据增强相关的损失。

2.5.1 衍生损失。蛋白质与配体原子之间的势能曲线形状对区分稳定的结合构象有着巨大的影响。当配体结合稳定时，配体原子位于势能曲线的局部最小值处。此外，适当尖锐的势能曲线使得区分稳定构象体和其他构象体变得更容易，因为原子位置的微小变化会导致大量的能量偏差。由于仅针对 L_{energy} 训练的模型无法控制势能曲线的形状，因此很难




图 2 PIGNet 的训练方案。我们在模型训练中使用了三种类型的数据——真实的结合复合物、计算机生成结合构象中的真实配体-蛋白质配对以及非结合的诱饵复合物。PIGNet 对每个输入预测结合自由能。对于真实的结合复合物，模型学习预测其真实的结合能。模型还学习预测计算机生成结合构象复合物的能量高于真实的结合能，预测非结合诱饵复合物的能量高于阈值能量。最后，PIGNet 通过最小化导数损失来学习配体原子位置与结合亲和力之间的恰当关联。

区分配体是否处于稳定位置。因此，我们通过导数损失函数 $L_{\text{derivative}}$ 引导模型学习成对势能曲线的正确形状——尤其是宽度和最低能量位置。

我们可以假定对于实验验证过的结合结构，配体原子位于势能的局部极小值处。因此，我们通过强制势能对位置的一阶导数为零，将实验结构设定为局部极小值。势能曲线的陡峭程度是通过增加二阶导数来实现的。导数损失 $L_{\text{derivative}}$ 如下给出：

$$L_{\text{derivative}} = \sum_i \left[\left(\frac{\partial E^{\text{total}}}{\partial q_i} \right)^2 - \min \left(\left(\frac{\partial^2 E^{\text{total}}}{\partial q_i^2} \right), C_{\text{der2}} \right) \right], \quad (9)$$

其中 q_i 表示配体原子的位置。过陡峭的势能曲线可能会因配体原子位置的微小变化而导致能量预测出现巨大偏差。因此，我们将二阶导数的最大值设为 C_{der2} ，在我们的模型中其值为 20.0。

2.5.2 数据增强损失。在此，我们构建了三种不同的与数据增强相关的损失函数：对接增强损失、随机筛选增强损失和交叉筛选增强损失。

对接增强损失。

对接增强的目的在于改进模型，使其能够从众多构象中区分出最稳定的结合构象。我们假定来自 PDBbind 数据集的实验结合结构 $\mathbf{x}_{\text{exp}}$ 为最稳定的结合构象。因此，实验结构的能量应低于具有不同于真实结合构象的构象的诱饵结构的预测能量。对接增强的损失函数 L_{docking} 可以写成如下形式：

X

其中 y_{exp} 表示实验结构的能量， y_{decoy} 表示诱饵结构的预测能量。通过最小化 L_{docking} ，该模型能够预测出 y_{decoy} 大于 $y_{\text{exp}} + 1$ 。

随机筛选增强损失。

通常，在庞大的化学空间中，只有极少数分子能够与特定的靶蛋白结合。大多数分子与靶蛋白的结合亲和力较低，解离常数较高， k_d 。基于这一特性，我们假设虚拟筛选库中任意蛋白质-配体对的解离常数会高于 10^{-6} M，因为通常将命中化合物的识别标准设定在微摩尔 (10^{-6} M) 级别。⁶⁴ 参考结合自由能 ΔG 与结合常数 k_a (其与 k_d 互为倒数) 之间的关系，我们可以为蛋白质-配体对的 ΔG 设定如下阈值：

$$\Delta G \geq -1.36 \log K_a = -6.8 \text{ kcal mol}^{-1} \quad (11)$$

使用随机筛选损失 $L_{\text{random_screening}}$ 和非结合的随机分子-蛋白质对训练的模型能够充分学习化学多样性。该模型会将随机分子与目标的结合自由能预测为高于阈值能量 6.8 的值。因此，随机筛选增强的损失 $L_{\text{random_screening}}$ 可以写成如下形式：

X

其中 y_{random} 是从 IBS 分子库中合成化合物的预测能量。⁶⁵ 对于增强而言，对接程序的不准确性不是问题，因为错误结合姿势的结合能通常高于真实结合能。

交叉筛选增强损失。

蛋白质与配体结合的另一个特性是，如果一个配体与某个特定靶点结合力强，那么它与 PDBbind 数据集中其他靶点结合的可能性就较小，因为不同类型的蛋白质具有不同的结合口袋。我们假设 PDBbind 数据集中的真实结合配体不会与该数据集中的其他蛋白质结合。

$$L_{\text{cross_screening}} = \sum_i \max(-y_{\text{cross},i} - 6.8, 0), \quad (13)$$

与随机筛选增强一样，使用非结合配体和蛋白质对进行训练有助于模型学习化学多样性。交叉筛选增强的损失 $L_{\text{cross_screening}}$ 可以写成如下形式：

X

其中 y_{cross} 为交联剂的预测能量。此处也采用了与随机筛选增强相同的结合自由能阈值。

$L_{\text{total}} = L_{\text{energy}} + L_{\text{derivative}} + L_{\text{docking}} + L_{\text{random_screening}} + L_{\text{cross_screening}}$, (14)

2.5.3 总损失函数。总损失 L_{total} 是所有损失项的加权和：Weber 损失 L_{energy} 、方向损失 $L_{\text{derivative}}$ 、位置损失 L_{docking} 、随机筛选损失 $L_{\text{random_screening}}$ 和交叉筛选损失 $L_{\text{cross_screening}}$ 。总损失可以写成如下形式：

其中， $c_{\text{derivative}}$ 、 c_{docking} 、 $c_{\text{random_screening}}$ 和 $c_{\text{cross_screening}}$ 是超参数，分别设置为 10.0、10.0、5.0 和 5.0。

2.6 基准模型

我们构建了两个基于 3D CNN 和 3D GNN 架构的基线 DNN 模型，以与 PIGNet 进行比较，即一个基于 3D CNN 的模型和一个基于 3D GNN 的模型。对于基于 3D CNN 的模型，我们重新实现了 Jiménez 等人的 K_{DEEP} 模型³⁴。我们重建的基于 3D CNN 的模型与 K_{DEEP} 的完全相同，只是将原子特征替换为 PIGNet 的特征。我们还构建了基于 PIGNet 的 3D GNN 模型，但该模型通过全连接层生成最终输出，而非通过物理建模的参数方程。

2.7 数据集

2.7.1 训练数据集与数据增强。我们的主要训练集是 PDBbind 2019 精选集，该集



提供了蛋白质-配体复合物在蛋白质数据库 (PDB) 中的合格结合亲和力和数据及相应结构。⁶⁶我们在训练集中剔除了测试集 (即 PDBbind 2016 核心集) 中的冗余样本。我们使用了 4514 个样本作为训练集, 265 个样本作为测试集, 这些样本是在数据处理后剩余的。在处理过程中, 剔除了与配体最小距离大于 5 埃的氨基酸残基。

是

裁剪以减少蛋白质口袋中的原子数量。

此外, 我们构建了三种不同的数据增强方法: 对接增强、随机筛选增强和交叉筛选增强。我们使用 Smina (它是 Autodock Vina 的一个分支) 来生成诱饵结构。对于对接增强, 我们使用 PDBbind 2016 数据集生成了 292518 个诱饵结构。对于随机筛选增强和交叉筛选增强, 我们分别使用 IBS 分子生成了 831885 个复合物, 并基于随机交叉结合生成了 527682 个复合物。在增强过程中, 测试集中的任何复合物都被排除在外。

2.7.2 基准数据集。CASF-2016 基准数据集⁶⁷源自 PDBbind 2016 核心集。经过数据处理, 我们使用了 283 个样本进行评分和排序, 22340 个样本进行对接, 以及 1612867 个样本进行筛选基准测试。我们还使用 CSAR NRC-HiQ (2010) 1 和 2 基准集评估了模型。⁶⁸我们注意到 CSAR 基准集中的某些蛋白质结构与我们的训练集高度相似。为了确保公平比较, 我们进一步研究了这种重叠是否会导致模型评估出现偏差。对于每个 CSAR NRC-HiQ 基准集, 我们构建了两个子集。首先, 如果训练集中存在相同的键, 则移除样本。排除后, 集 1 和集 2 分别剩下 48 个和 37 个样本。接下来, 我们排除了与训练集中任一样本的蛋白质序列相似度至少为 60% 的样本。排除后, 集 1 和集 2 分别剩下 37 个和 22 个样本。

2.7.3 用于人类 MAPK1 抑制剂的虚拟筛选库

我们进一步构建了针对人类丝裂原活化蛋白激酶 1 (MAPK1) 的虚拟筛选库, 以测试模型从大量分子候选物中发现真正抑制剂的能力。我们建立了一个新的训练集, 排除了人类 MAPK1 的同源物。对于新训练集的扩充, 我们遵循与主要训练集相同的协议。我们使用 CD-HIT^{69,69} 对目标进行聚类, 序列相似度阈值设为 60%。包含人类 MAPK1 的聚类中的目标被视为人类 MAPK1 的同源物。人类 MAPK1 的活性物质和非活性物质从 PubChem 数据库中获取。⁷⁰排除了与训练集或 PubChem 数据库中的任一配体相似度至少为 0.7 的化合物。我们将半最大抑制浓度的负对数 (pIC_{50}) 大于特定阈值的化合物命名为真正抑制剂。总体而言, 当使用 6、7 和 8 作为标准时, 分别有 81、45 和 27 种化合物被视为真正抑制剂。请注意, 标准越高, 真正抑制剂的效力越强。56413 种非活性物质与真正的抑制剂一

起组成了虚拟筛选库。最后, 我们使用 Smina 软件针对人类 MAPK1 蛋白质 (PDB 编号: 3I60) 为每种化合物生成了 20 种诱饵结构。

3 结果与讨论

3.1 模型性能及泛化能力评估

我们主要使用 CASF-2016 基准数据集对模型进行了评估。CASF-2016 基准提供了四种不同的评估任务——评分、排序、对接和筛选, 以从多个方面评估药物-靶点相互作用 (DTI) 模型在虚拟筛选中的表现。评分能力衡量的是预测结合亲和力与实验值之间的线性相关性, 通过皮尔逊相关系数 R 来计算。排序能力衡量的是模型正确排序实际结合构象下真实配体结合亲和力的能力, 通过斯皮尔曼等级相关系数 r 来计算。这两个指标旨在评估模型在稳定且精确的结合结构方面的表现。另一方面, 对接能力和筛选能力则涉及通过计算生成的非天然结构。对接能力衡量的是模型在计算机生成的诱饵中找到配体天然结合构象的能力, 以在前 N 个候选者中找到的比例来量化。筛选能力衡量的是模型在一组随机分子中识别给定目标蛋白的特异性结合配体的能力, 以成功率和在前 $a\%$ 候选分子中的增强因子 (EF) 来量化。每个指标的详细方程总结在 ESI 中。[†]

在虚拟高通量筛选 (vHTS) 方案中, 药物靶点相互作用 (DTI) 模型应当能够识别出最稳定的结合构象, 并同时正确地按照结合亲和力对蛋白质-配体对进行排序。实际上, 如果模型能够准确预测每个给定复合物的结合亲和力值, 即评分能力所追求的目标, 那么排序、对接和筛选能力将会达到最优。然而, 对 CASF-2016 基准的实验分析表明, 高评分能力并不能保证高筛选和对接能力。⁶²我们认为这种不一致是由于 CASF-2016 评分能力基准的局限性所致——评分能力本身不能作为 DTI 模型性能评估的唯一标准。因此, 我们强调模型的对接和筛选能力是模型泛化能力的指标。

表 1 总结了 PIGNets、基准模型以及其他已发表工作的在 CASF-2016 和 CSAR NRC-HiQ 基准测试中的表现。对接方法的参考分数 - AutoDock Vina、⁸ GlideScore-SP、¹³ 和 Chem-PLP@GOLD¹⁵ - 分别取自 Su 等人的研究, 该研究在对接成功率、筛选成功率和筛选 EF 方面分别排名第一。除 K_{DEEP} ³⁴ 外, 其他深度学习方法的性能直接取自其参考文献。由于其原始工作中未包含对接能力, 所以 K_{DEEP} 的分数取自 Kwon 等人的研究。

在 CASF-2016 分子对接和筛选中, 无论是单个模型还是集成模型, PIGNet 的表现都优于之前的所有研究工作。



我们的最佳模型实现了 87% 的最佳对接成功率、55.4% 的前 1% 筛选成功率以及 19.6 的前 1% 平均富集因子。其评分和排序能力优于对接方法，且与其他基于深度学习的方法相当。

对于 CSAR NRC-HiQ 基准集，皮尔逊相关系数显示出与 CASF-2016 评分能力基准一致的结果。有趣的是，从 CSAR 基准集中移除相似度阈值为 60% 的样本，并未影响性能，反而观察到了性能的持续提升。这种细微的改进可能归因于测试集规模较小，少量数据点就能对结果产生较大影响。这样的结果表明，我们的模型并非仅仅过度拟合了训练集目标或同源结构，因为如果存在过度拟合的情况，性能应该会下降。

对于基准模型而言，基于 3D GNN 的模型在排序、对接和筛选能力方面表现优于基于 3D CNN 的模型。这种差异可能源于基于 3D CNN 的模型缺乏化学相互作用信息，而基于 3D GNN 的模型则隐含具备。然而，基于 3D CNN 和 3D GNN 的模型均未能实现较高的对接能力和筛选能力。我们认为这种低对接能力是由于模型过度拟合了真实结合复合物结构和结合亲和力。这些模型对计算机生成的诱饵结构产生了不准确的结合亲和力，而这些诱饵结构主要用于对接和筛选能力测试。低对接能力进而导致了低筛选能力，因为需要识别最稳定的结合构象才能找到真正的结合物。从这些观察结果来看，我们怀疑之前介绍的深度药物靶点相互作用模型的性能报告过于乐观。相比之下，PIGNet

t 在 CASF-2016 的四个指标和 CSAR NRC-HiQ 基准测试中始终表现出色。这些结果表明，我们的模型与训练数据拟合良好，并且已经学习到了正确的特征——蛋白质与配体结合模式的潜在物理规律。此外，这些结果也提醒我们，评分能力不能作为衡量模型性能的唯一标准。在接下来的部分，我们将通过消融研究来分析我们的每种策略对结果的贡献程度。

3.2 两种主要策略的消融研究

我们将模型性能的提升归因于两个主要策略，即前一节中引入的基于物理知识的参数化函数以及数据增强。在本节中，我们进行了消融研究，以分离这两种策略的效果，并将结果总结在表 2 中。

3.2.1 物理信息参数化函数的影响。我们可以通过比较基于 3D GNN 的模型和 PIGNet 的性能来观察物理信息模型的效果，因为除了参数方程外，基于 3D GNN 的模型与 PIGNet 是相同的。正如预期的那样，对于 CASF-2016 的评分和排序能力而言，这种影响并不显著。然而，采用物理信息模型却显著提高了对接和筛选能力。由此可以推断，参数方程的引入有助于增强模型的泛化能力。引入某种形式的方程可能会给模型带来过大的归纳偏差，从而导致模型欠拟合。但从 PIGNet 和基于 3D GNN 的模型相当的评分能力来看，这种情况似乎不太可能发生。特别是，未进行数据增强的 PIGNet 在对接能力方面仍优于基于 3D GNN 的模型。

表 1 为 CASF-2016 和 CSAR NRC-HiQ 数据集上的基准测试结果。R 和 r 分别表示皮尔逊相关系数和斯皮尔曼等级相关系数。对接成功率采用 top 1 分数，平均 EF 和筛选成功率采用 top 1% 分数。由于 $D_{vina}RF_{20}^{71}$ 是基于 PDBbind 2017 数据进行微调的，而该数据集实际上包含了 CASF-2016 测试集的 50% 数据，因此未将其纳入比较。CSAR NRC-HiQ 基准测试中括号内的数字是针对排除了与训练集蛋白质序列相似度高于 60% 的目标的测试集所得的结果。基于 3D CNN、基于 3D GNN 的模型和 PIGNets 的结果是从 4 个模型中平均得出的。每列中的最高值以粗体显示。

模型	CASF-2016				CSAR NRC-HiQ		
	对接	筛选		得分	排名	第一组	第二组
	成功率	平均EF值	成功率	R	r	R	R
AutoDock Vina ⁸	84.6%	7.7	29.8%	0.604	0.528	—	—
GlideScore-SP ¹³	84.6%	11.4	36.8%	0.513	0.419	—	—
ChemPLP@GOLD ¹⁵	83.2%	11.9	35.1%	0.614	0.633	—	—
KDEEP39	29.1%	—	—	0.701	0.528	—	—
AK 分数（单个） ³⁹	34.9%	—	—	0.719	0.572	—	—
AK 分数（集成） ³⁹	36.0%	—	—	0.812	0.67	—	—
AEScore45	35.8%	—	—	0.800	0.640	—	—
D-AE得分 ⁴⁵	85.6%	6.16	19.3%	0.790	0.590	—	—
基于 3D 卷积神经网络的模型	48.2%	3.9	10.1%	0.687	0.580	0.738（0.756）	0.804（0.837）
基于 3D 图神经网络的模型	67.7%	10.2	28.5%	0.667	0.604	0.514（0.566）	0.627（0.723）
PIGNet（单体）	85.8%	18.5	50.0%	0.749	0.668	0.774（0.798）	0.799（0.863）
PIGNet（集成）	87.0%	19.6	55.4%	0.761	0.682	0.768（0.798）	0.800（0.857）



表 2 展示了基于 3D GNN 的模型和 PIGNet（单模型）在使用和未使用数据增强情况下的 CASF-2016 基准测试结果。采用 top 1 分数作为对接成功率，采用 top 1% 分数作为平均富集因子和筛选成功率。同一模型中的最高值以粗体显示。

模型	使用数据增强吗?	CASF-2016				
		对接	筛选	成功率		排名
		成功率	平均EF值	R	r	
基于 3D 图神经网络的模型	否	29.9%	1.4	4.9%	0.772	0.604
	是	66.6%	10.2	28.5%	0.689	0.629
PIGNet（单体）	否	77.4%	6.6	24.6%	0.792	0.672
	是	85.8%	18.5	50.0%	0.749	0.668

使用增强数据进行训练。尽管添加大量增强数据能提升性能，但数据增强策略本身并不能完全替代物理信息模型所带来的泛化效果。相反，数据增强和物理建模以互补的方式改进模型，这一点从以下部分可以看出。

3.2.2 DTI 适配的数据增强策略的效果。PDBbind 数据集是数据驱动的 DTI 模型最具代表性的训练数据集之一，它提供了蛋白质-配体复合物的 3D 结合结构和结合亲和力。⁶³然而，PDBbind 数据集被认为存在内在偏差；⁴⁷其配体的化学多样性不足，且仅提供了处于最低能量构象的结合结构。为了扩大模型学习的化学空间，我们在训练集中额外加入了 1 652 085 个增强样本。特别是，计算生成的结构（这些结构往往比实际结构更不稳定）也被用于学习。表 2 清晰地展示了 DTI 适配的数据增强策略对泛化能力的影响。这种增强显然提高了基于 3D GNN 的模型和 PIGNet 的对接和筛选能力。这表明我们的数据增强策略适用于多种基于 DNN 的 DTI 模型。对于仅包含真实结合复合物的基准测试——评分能力、排序能力和 CSAR NRC-HiQ——数据增强未能提高分数是意料之中的结果，因为模型从增强的数据和相应的损失中学会了准确区分诱饵和真实结合复合物。

3.3 人类 MAPK1 抑制剂的虚拟筛选

为了在虚拟筛选中实际应用，DTI 模型应具有良好的泛化能力，即使对于未见过的靶点和配体也是如此。PIGNet 在常用的对接和筛选基准测试中，在其他对接方法和深度学习方法中表现出了最先进的性能。为了进行更公平的比较，我们注意到训练集和基准测试集中存在常见的蛋白质同源物。在实际应用中，目标及其真正的抑制剂可能与训练数据分布相距甚远。因此，

为了确定我们模型的适用性，我们在更接近实际情况的设置中进行了虚拟筛选案例研究，在训练集中排除了与给定目标及其真正抑制剂相似的靶点和配体。

我们选取了人类 MAPK1 蛋白作为案例研究的重要治疗靶点 target⁷²⁻⁷⁴。将 Smina、3D CNN 和基于 3D GNN 的模型的前 1% 平均 EF 值与 PIGNet 的进行了比较。

表 3 中的虚拟筛选结果与 CASF-2016 筛选基准结果一致，其中 PIGNets 模型的表现优于基线模型和对接方法。无论根据 pIC₅₀ 标准确定的真正抑制剂比例如何，这一趋势都是一致的。虽然这一单一案例研究无法为我们提供统计学意义，但我们仍可考察我们的模型在针对未知靶点的虚拟筛选中的潜在适用性。

3.4 物理模型输出结果的解读

我们方法的一个重要优势在于能够对药物-靶点相互作用（DTI）进行原子对之间的成对解释。要为特定靶点合理设计药物，了解配体结合的主要相互作用很有帮助。由于 PIGNet 计算原子对之间的能量分量，我们可以计算配体中子结构的能量贡献。在此，我们对从 PDBbind 数据集中检索到的两种靶蛋白进行了案例研究；非受体蛋白酪氨酸磷酸酶

表 3 人类 MAPK1 抑制剂的虚拟筛选结果。基于 3D CNN、基于 3D GNN 的模型以及 PIGNets 的结果取自 4 个模型的平均值。采用前 1% 的命中率计算平均富集因子（EF）。每列中的最高值以粗体显示。

模型	pIC ₅₀ 真正抑制剂的评判标准		
	6	7	8
斯米娜6	9.9	13.3	18.5
基于 3D 卷积神经网络的模型	7.7	6.7	9.3
基于 3D 图神经网络的模型	9.3	11.1	12.0
PIGNet（单体）	20.1	21.1	24.1
PIGNet（集成）	21.3	21.7	26.9



受体类型 1 (PTPN1) 和血小板活化因子乙酰水解酶 (PAF-AH)。结果如图 3a 所示, 其中每种蛋白质的两种配体在预测的亚结构能量贡献和抑制常数 K_i 方面进行了比较。每对配体具有很高的结构相似性, 仅在红色圆圈标记的部分有所不同。对于 PTPN1, 模型预测四甲基环己基部分能量贡献大于环己基部分。这样的结果与实验 K_i 值一致。对于 PAF-AH, 带有苯基的配体的 K_i 值低于带有甲基的配体。模型预测苯基的能量贡献大于甲基。对于这两种蛋白质, 蓝色圆圈标记的共同亚结构的能量贡献预测相似。这意味着每个亚结构的预测能量贡献提供了物理上有意义的解释, 这在配体优化过程中可以进一步利用, 以增强与目标蛋白质的总结合亲和力。

大多数对接程序会根据预定义的类别手动为原子-原子对分配不同的评

分函数。当原子对的结合模式不符合现有类别时, 这种手动分配就会出现不足。与这种手工分类不同, 我们的模型利用神经网络自动区分原子-原子对; 通过图注意力网络更新每对原子相互作用的信息。我们在图 3b 和 c 中说明了这种偏差及其物理意义。图 3b 展示了测试集中碳-碳对的范德华力成分的距离-能量分布图。在使用可学习参数训练时, 预测的范德华力相互作用在碳-碳对内自然出现偏差, 而没有可学习参数时, 距离-能量图则遵循一条实线。借助可学习参数, 我们的模型可能以数据驱动的方式学习到了更广泛的成对相互作用。我们在图 S1 中也展示了疏水、氢键和金属-配体能量成分的偏差。

图 3c 表明, 在我们的模型中, 原子对之间自然存在的偏差是学习到足够物理信息的结果。校正后的总和




图 3 预测结果的解释。(a) 针对两种靶蛋白的配体的亚结构分析。蛋白酪氨酸磷酸酶非受体类型 1 (PTPN1) 和血小板活化因子乙酰水解酶 (PAF-AH)。蓝色和红色圆圈分别表示共同和不同的亚结构, 每个亚结构的预测能量贡献 (单位: 千卡/摩尔) 均有标注。抑制常数 K_i 表示配体与靶蛋白结合的强度。(b) 测试集中碳-碳对范德华 (vdW) 能量成分的距离-能量图。红色实线表示未受可学习参数影响的原始距离-能量关系。数据点的颜色越接近黄色, 对应的碳-碳对数量就越多。(c) 不同碳-碳对类型对应的校正范德华半径之和的平均值 d_{ij}^c 。对 $_{SP^2}$, $_{SP^2}-C_{SP^3}$ 和 $_{SP^3}-C_{SP^3}$ 对进行了比较。

结果包括 95% 的置信区间。




图 4 展示了 4 折 PIGNet 模型在有无不确定性估计器的情况下，根据总不确定性分类的数据集上的平均皮尔逊相关系数 R 的曲线图。PIGNet 带不确定性估计器 - 低：不确定性分布的最低三分之一；随机：随机选取的三分之一；高：不确定性分布的最高三分之一。PIGNet 无蒙特卡罗丢弃 - 基线：表 1 中单个 PIGNet 模型的得分。不确定性越低，模型正确预测结果的可能性越大。误差条代表 95% 的置信区间。PIGNet 在 2 300th 训练周期时进行了测试，分别有和无蒙特卡罗丢弃。

范德华半径 (d_{ij}) 包含一个分配给每个原子对的可学习参数，根据碳-碳对类型进行调整。由于两个碳原子之间的相互作用不会显著受到其杂化的影响，我们推测该对的修正范德华半径之和将取决于原子半径。结果表明，从 $C_{sp^2}-C_{sp^2}$ 对到 $C_{sp^3}-C_{sp^3}$ 对，修正后的范德华半径之和呈增加趋势。与推测相符的是，碳原子的 s 性质越大，修正后的范德华半径之和越短。

3.5 PIGNet 的知识不确定性量化

要实现可靠的虚拟筛选，筛选出假阳性结合物并确保真阳性结果至关重要。⁷⁶然而，大多数对接程序的阳性结果最终都被证明是假阳性。⁷⁶基于深度神经网络 (DNN) 的模型也可能存在同样的问题。特别是，训练药物靶点相互作用 (DTI) 模型时数据不足的特性可能会使 DNN 模型对域外复合物的适应性降低，⁴⁷从而产生假阳性。减少假阳性的一种可能方法是利用预测的不确定性，并过滤掉不可靠的阳性预测。我们采用了蒙特卡罗丢弃 (MCDO)，这是一种实用的贝叶斯推理方法，利用丢弃正则化来估计源于模型不确定性的知识不确定性。⁷⁷

我们对三个数据集 (CSAR NRC-HiQ 1 和 2 以及 CASF-2016 评分效力) 中的样本预测不确定性进行了量化。在图 4 中，就预测不确定性而言，“低”、“随机”和“高”批次按皮尔逊相关系数 R 的值降序排列。这一结果与我们的预期相符；不确定性越低，模型正确预测结果的可能性就越大。这一结果表明，我们模型的预测不确定性可以得到恰当的量化。先前的一项研究指出，模型预测的稳健不确定性量化可以作为良好泛化能力的证据。⁷⁸因此，我们模型的高泛化能力或许与不确定性量化的成功有关。

通过比较图 4 中“随机”和“基线”批次的 R 值，可以评估有无不确定性估计器时 PIGNet 的总体性能。结果证实，添加不确定性估计器不会损害模型性能。此外，该比较表明，不确定性量化可用于过滤掉假阳性。

4 结论

在这项工作中，我们研究了深度学习模型在实际应用中经常遇到的泛化不足问题，这些问题通常出现在训练数据非常稀缺且不平衡的情况下。作为一个重要的实际例子，我们专注于药物靶点相互作用 (DTI) 模型，以实现候选药物的快速可靠虚拟筛选。我们所得到的模型名为 PIGNet，与其它深度学习模型相比，它具有更好的泛化能力和更高的准确性。我们将模型的成功归因于以下两个策略。第一个策略是采用基于物理知识的参数化方程。物理建模作为神经模型的适当归纳偏差，引导模型学习化学相互作用的潜在物理规律。我们通过增加来自更广泛的化学和结构多样性的蛋白质-配体复合物来进一步提高模型性能。我们通过消融研究分析了基于物理知识的模型和数据增强的效果，发现两者都对模型的泛化能力有贡献。这些策略可以很容易地应用于其他科学领域，在这些领域中预计会出现类似的数据问题，且相关物理原理已得到充分确立。此类应用将包括材料设计、结构生物学和粒子物理学。在固体材料的原子建模中所报告的类似泛化能力的提升⁹⁰就是一个这样的例子。

我们的模型还能享有诸如对预测的扩散张量成像 (DTI) 值进行物理解释以及通过不确定性量化减少假阳性等进一步的实际优势。为每个原子对获取结合自由能为…… (此处原文似乎不完整，译文也相应未完成)

这为进一步的解释提供了可能。这些有用的信息日后可与伊姆里等人提出的生成模型相结合，以优化候选药物，从而获得更好的结合亲和力。⁸⁰此外，我们还为药物靶点相互作用预测模型引入了一个不确定性估计器，并评估了 PIGNet 的估计质量。由于高不确定性下的预测可能是假阳性，因此不确定性量化在虚拟筛选场景中具有实际意义。

不过，我们的模型在原子成对相互作用的参数化表达方面仍有改进空间。为了进一步提高模型的预测能力，我们可以测试能量组件的其他表达式。例如，对于范德华相互作用，可以使用参数化了可学习哈梅克常数的哈梅克公式来表达。^{80,81}此外，如果设计目标侧重于目标结合亲和力，我们的模型还可以作为分子生成模型的可靠参考。^{82,83}

数据可用性

训练数据集可以从 GitHub 上的代码进行预处理，网址为：<https://github.com/ACE-KAIST/PIGNet>。

作者贡献

概念化：J. L. 和 W. Y. K.；方法论：S. M.、W. Z.、S. Y. 和 J. L.；软件、调查和形式分析：S. M.、W. Z.、S. Y. 和 J. L.；撰写 - 原稿：S. M.、W. Z.、S. Y. 和 J. L.；撰写 - 审查与编辑：S. M.、W. Z.、S. Y.、J. L. 和 W. Y. K.；监督：W. Y. K.

利益冲突

无利益冲突需要声明。

致谢

本研究得到了韩国国家研究基金会（NRF）基础科学研究计划的资助，该计划由韩国科学技术信息通信部提供资金支持（NRF-2017R1E1A1A01078109）。

参考文献

- 1 P. Mamoshina, A. Vieira, E. Putin and A. Zhavoronkov, *Mol. Pharmaceutics*, 2016, 13, 1445–1454.
- 2 C. Cao, F. Liu, H. Tan, D. Song, W. Shu, W. Li, Y. Zhou, X. Bo and Z. Xie, *Genomics, Proteomics Bioinf.*, 2018, 16, 17–32.
- 3 R. Zemouri, N. Zerhouni and D. Racocceanu, *Appl. Sci.*, 2019, 9, 1526.
- 4 M. Wainberg, D. Merico, A. Delong and B. J. Frey, *Nat. Biotechnol.*, 2018, 36, 829–838.
- 5 J. G. Greener, S. M. Kandathil, L. Moffat and D. T. Jones, *Nat. Rev. Mol. Cell Biol.*, 2021, 1–16.
- 6 A. L. Hopkins, *Nature*, 2009, 462, 167–168.
- 7 M. Bagherian, E. Sabeti, K. Wang, M. A. Sartor, Z. Nikolovska-Coleska and K. Najarian, *Briefings Bioinf.*, 2021, 22, 247–269.
- 8 O. Trott and A. J. Olson, *J. Comput. Chem.*, 2010, 31, 455–461.
- 9 S. Ruiz-Carmona, D. Alvarez-Garcia, N. Foloppe, A. B. Garmendia-Doval, S. Juhos, P. Schmidtke, X. Barril, R. E. Hubbard and S. D. Morley, *PLoS Comput. Biol.*, 2014, 10, 1–7.
- 10 R. Wang, L. Lai and S. Wang, *J. Comput.-Aided Mol. Des.*, 2002, 16, 11–26.
- 11 A. N. Jain, *J. Med. Chem.*, 2003, 46, 499–511.
- 12 G. Jones, *J. Mol. Biol.*, 1997, 267, 727–748.
- 13 R. A. Friesner, J. L. Banks, R. B. Murphy, T. A. Halgren, J. J. Klicic, D. T. Mainz, M. P. Repasky, E. H. Knoll, M. Shelley, J. K. Perry, et al., *J. Med. Chem.*, 2004, 47, 1739–1749.
- 14 C. M. Venkatachalam, X. Jiang, T. Oldfield and M. Waldman, *J. Mol. Graphics Modell.*, 2003, 21, 289–307.
- 15 O. Korb, T. Stutzle and T. E. Exner, *J. Chem. Inf. Model.*, 2009, 49, 84–96.
- 16 W. J. Allen, T. E. Balius, S. Mukherjee, S. R. Brozell, D. T. Moustakas, P. T. Lang, D. A. Case, I. D. Kuntz and R. C. Rizzo, *J. Comput. Chem.*, 2015, 36, 1132–1156.
- 17 B. Waszkowycz, D. E. Clark and E. Gancia, *Wires Comput. Mol. Sci.*, 2011, 1, 229–259.
- 18 A. R. Leach, B. K. Shoichet and C. E. Peishoff, *J. Med. Chem.*, 2006, 49, 5851–5855.
- 19 Y. C. Chen, *Trends Pharmacol. Sci.*, 2015, 36, 78–95.
- 20 M. R. Shirts, D. L. Mobley and J. D. Chodera, *Annu. Rep. Comput. Chem.*, 2007, 3, 41–59.
- 21 C. Chipot, X. Rozanska and S. B. Dixit, *J. Comput.-Aided Mol. Des.*, 2005, 19, 765–770.
- 22 A. Fitriawan, I. Wasito, A. F. Syaifandini, M. Amien and A. Yanuar, *International Conference on Computer, Control, Informatics and its Applications, IC3INA*, 2016.
- 23 H. O. Ztork, A. O. Zgur and E. Ozkirimli, *Bioinformatics*, 2018, 34, 821–829.
- 24 M. Thafar, A. B. Raies, S. Albaradei, M. Essack and V. B. Bajic, *Front. Chem.*, 2019, 7, 782.
- 25 C. F. Lipinski, V. G. Maltarollo, P. R. Oliveira, A. B. F. da Silva and K. M. Honorio, *Front. Robot. AI*, 2019, 6, 108.
- 26 M. Tsubaki, K. Tomii and J. Sese, *Bioinformatics*, 2019, 35, 309–318.
- 27 I. Lee, J. Keum and H. Nam, *PLoS Comput. Biol.*, 2019, 15, 1–21.
- 28 S. Zheng, Y. Li, S. Chen, J. Xu and Y. Yang, *Nat. Mach. Intell.*, 2020, 2, 134–140.
- 29 K. Huang, T. Fu, L. M. Glass, M. Zitnik, C. Xiao and J. Sun, *Bioinformatics*, 2020, 36, 5545–5547.
- 30 Y.-B. Wang, Z.-H. You, S. Yang, H.-C. Yi, Z.-H. Chen and K. Zheng, *BMC Med. Inf. Decis. Making*, 2020, 20, 1–9.
- 31 S. K. Panday and I. Ghosh, *Struct. Bioinf.*, 2019, 109–175.
- 32 F. Imrie, A. R. Bradley, M. van der Schaar and C. M. Deane, *J. Chem. Inf. Model.*, 2018, 58, 2319–2330.
- 33 M. M. Stepniewska-Dziubinska, P. Zielenkiewicz and P. Siedlecki, *Bioinformatics*, 2018, 34, 3666–3674.
- 34 J. Jimenez, M. Skalic, G. Martınez-Rosell and G. De Fabritiis, *J. Chem. Inf. Model.*, 2018, 58, 287–296.



- 35 I. Wallach, M. Dzamba and A. Heifets, preprint, arXiv:1510.02855, 2015, <https://arxiv.org/abs/1510.02855>.
- 36 M. Ragoza, J. Hochuli, E. Idrobo, J. Sunseri and D. R. Koes, *J. Chem. Inf. Model.*, 2017, 57, 942–957.
- 37 J. A. Morrone, J. K. Weber, T. Huynh, H. Luo and W. D. Cornell, *J. Chem. Inf. Model.*, 2020, 60, 4170–4179.
- 38 L. Zheng, J. Fan and Y. Mu, *ACS Omega*, 2019, 4, 15956–15965.
- 39 Y. Kwon, W.-H. Shin, J. Ko and J. Lee, *Int. J. Mol. Sci.*, 2020, 21, 8424.
- 40 H. Hassan-Harriou, C. Zhang and T. Lemmin, *J. Chem. Inf. Model.*, 2020, 60, 2791–2802.
- 41 D. Jones, H. Kim, X. Zhang, A. Zemla, G. Stevenson, W. F. D. Bennett, D. Kirshner, S. E. Wong, F. C. Lightstone and J. E. Allen, *J. Chem. Inf. Model.*, 2021, 61, 1583–1592.
- 42 E. N. Feinberg, D. Sur, Z. Wu, B. E. Husic, H. Mai, Y. Li, S. Sun, J. Yang, B. Ramsundar and V. S. Pande, *ACS Cent. Sci.*, 2018, 4, 1520–1530.
- 43 W. Torng and R. B. Altman, *J. Chem. Inf. Model.*, 2019, 59, 4131–4149.
- 44 J. Lim, S. Ryu, K. Park, Y. J. Choe, J. Ham and W. Y. Kim, *J. Chem. Inf. Model.*, 2019, 59, 3981–3988.
- 45 R. Meli, A. Anighoro, M. J. Bodkin, G. M. Morris and P. C. Biggin, *J. Cheminf.*, 2021, 13, 1–19.
- 46 D. M. Hawkins, *J. Chem. Inf. Comput. Sci.*, 2004, 44, 1–12.
- 47 L. Chen, A. Cruz, S. Ramsey, C. J. Dickson, J. S. Duca, V. Hornak, D. R. Koes and T. Kurtzman, *PLoS one*, 2019, 14, e0220113.
- 48 J. Scantlebury, N. Brown, F. Von Del and C. M. Deane, *J. Chem. Inf. Model.*, 2020, 60, 3722–3730.
- 49 S. Greydanus, M. Dzamba and J. Yosinski, *Advances in Neural Information Processing Systems*, Curran Associates, Inc., 2019, vol. 32, pp. 15379–15389.
- 50 G. P. Pun, R. Batra, R. Ramprasad and Y. Mishin, *Nat. Commun.*, 2019, 10, 2339.
- 51 L. Li, S. Hoyer, R. Pederson, R. Sun, E. D. Cubuk, P. Riley and K. Burke, *Phys. Rev. Lett.*, 2021, 126, 036401.
- 52 M. Su, Q. Yang, Y. Du, G. Feng, Z. Liu, Y. Li and R. Wang, *J. Chem. Inf. Model.*, 2019, 59, 895–913.
- 53 T. Pahikkala, A. Airola, S. Pietilä, S. Shakyawar, A. Szajda, J. Tang and T. Aittokallio, *Briefings Bioinf.*, 2015, 16, 325–337.
- 54 K. Y. Gao, A. Fokoue, H. Luo, A. Iyengar, S. Dey and P. Zhang, *Proceedings of the 27th International Joint Conference on Artificial Intelligence*, 2018.
- 55 T. Zubatiuk, B. Nebgen, N. Lubbers, J. S. Smith, R. Zubatyuk, G. Zhou, C. Koh, K. Barros, O. Isayev and S. Tretiak, *J. Chem. Phys.*, 2021, 154, 244108.
- 56 D. S. Karlov, S. Sosnin, M. V. Fedorov and P. Popov, *ACS Omega*, 2020, 5, 5150–5159.
- 57 J. Zhou, G. Cui, S. Hu, Z. Zhang, C. Yang, Z. Liu, L. Wang, C. Li and M. Sun, *AI Open*, 2020, 1, 57–81.
- 58 M. Jiang, Z. Li, S. Zhang, S. Wang, X. Wang, Q. Yuan and Z. Wei, *RSC Adv.*, 2020, 10, 20701–20712.
- 59 P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò and Y. Bengio, *International Conference on Learning Representations*, 2018.
- 60 J. Chung, C. Gulcehre, K. Cho and Y. Bengio, preprint, arXiv:1412.3555, 2014, <https://arxiv.org/abs/1412.3555>.
- 61 R. E. Wunderlich, T. F. Wensch, B. Falsa and J. C. Hoe, *Conference Proceedings – Annual International Symposium on Computer Architecture, ISCA*, 2003, pp. 84–95.
- 62 RDKit: Open-source cheminformatics, <http://www.rdkit.org>.
- 63 Z. Liu, M. Su, L. Han, J. Liu, Q. Yang, Y. Li and R. Wang, *Acc. Chem. Res.*, 2017, 50, 302–309.
- 64 J. P. Hughes, S. Rees, S. B. Kalindjian and K. L. Philpott, *Br. J. Pharmacol.*, 2011, 162, 1239–1249.
- 65 InterBioScreen Ltd, <http://www.ibscreen.com>.
- 66 D. R. Koes, M. P. Baumgartner and C. J. Camacho, *J. Chem. Inf. Model.*, 2013, 53, 1893–1904.
- 67 J. B. Dunbar Jr, R. D. Smith, C.-Y. Yang, P. M.-U. Ung, K. W. Lexa, N. A. Khazanov, J. A. Stuckey, S. Wang and H. A. Carlson, *J. Chem. Inf. Model.*, 2011, 51(9), 2036–2046.
- 68 W. Li and A. Godzik, *Bioinformatics*, 2006, 22, 1658–1659.
- 69 L. Fu, B. Niu, Z. Zhu, S. Wu and W. Li, *Bioinformatics*, 2012, 28, 3150–3152.
- 70 Y. Wang, J. Xiao, T. O. Suzek, J. Zhang, J. Wang and S. H. Bryant, *Nucleic Acids Res.*, 2009, 37, W623–W633.
- 71 C. Wang and Y. Zhang, *J. Comput. Chem.*, 2017, 38, 169–177.
- 72 J. S. Sebolt-Leopold, *Oncogene*, 2000, 19, 6594–6599.
- 73 A. S. Dhillon, S. Hagan, O. Rath and W. Kolch, *Oncogene*, 2007, 26, 3279–3290.
- 74 L. Miao and H. Tian, *J. Drug Targeting*, 2020, 28, 154–165.
- 75 E. H. B. Maia, L. C. Assis, T. A. de Oliveira, A. M. da Silva and A. G. Taranto, *Front. Chem.*, 2020, 8, 343.
- 76 R. Sink, S. Gobec, S. Pecar and A. Zega, *Curr. Med. Chem.*, 2010, 17, 4231–4255.
- 77 Y. Gal and Z. Ghahramani, *Proceedings of the 33rd International Conference on Machine Learning*, New York, USA, 2016.
- 78 G. Scalia, C. A. Grambow, B. Pernici, Y.-P. Li and W. H. Green, *J. Chem. Inf. Model.*, 2020, 2697–2717.
- 79 F. Imrie, A. R. Bradley, M. van der Schaar and C. M. Deane, *J. Chem. Inf. Model.*, 2020, 60, 1983–1995.
- 80 C. M. Roth, B. L. Neal and A. M. Lenhoff, *Biophys. J.*, 1996, 70, 977–987.
- 81 V. A. Parsegian, *van der Waals forces: a handbook for biologists, chemists, engineers, and physicists*, Cambridge University Press, 2005.
- 82 A. Grosnit, R. Tutunov, A. M. Maraval, R.-R. Griffiths, A. I. Cowen-Rivers, L. Yang, L. Zhu, W. Lyu, Z. Chen and J. Wang, et al., arXiv preprint arXiv:2106.03609, 2021.
- 83 S. Yang, D. Hwang, S. Lee, S. Ryu and S. J. Hwang, *Advances in Neural Information Processing Systems*, 2021.