

结构生物信息学

TransformerCPI: 通过基于序列的深度学习与自我关注机制和
标签反转实验改进化合物-蛋白质相互作用预测

陈丽凡^{1,2}、谭小琴^(1,2)、王丁燕^(1,2)、钟飞生^(1,2)、刘晓红^{1,3}、杨天彪^(1,2)、罗晓敏⁽¹⁾、陈凯贤^(1,3)、蒋
华良^{(1,3)*} 和
Mingyue Zheng^{1,*}

¹中国科学院上海药物研究所药物研究国家重点实验室药物发现与设计中心, 中国上海, 201203; ²中国科学院大学, 中国北京, 100049; ³
上海理工大学生命科学与技术学院上海高级免疫化学研究所, 中国上海, 200031

*: 副主编: Arne Elofsson

2020 年 2 月 26 日收到; 2020 年 4 月 13 日修订; 2020 年 5 月 12 日编辑决定; 2020 年 5 月 14 日接受

摘要

研究动机鉴定化合物-蛋白质相互作用 (CPI) 是药物发现和化学基因组学研究中的一项重要任务, 而没有三维结构的蛋白质占潜在生物靶标的很大一部分, 这就需要开发仅使用蛋白质序列信息来预测CPI的方法。然而, 基于序列的 CPI 模型可能会面临一些特定的陷阱, 包括使用不适当的数据集、隐藏配体偏差和不适当地分割数据集, 从而导致预测性能被高估。

为了解决这些问题, 我们在此构建了专门用于 CPI 预测的新数据集, 提出了一种名为 TransformerCPI 的新型变换器神经网络, 并引入了更严格的标签反转实验来检验模型是否能学习到真正的相互作用特征。TransformerCPI在新实验中的性能有了很大提高, 而且它可以去卷积, 突出蛋白质序列和化合物原子的重要相互作用区域, 这可能会为化学生物学研究提供有用的指导, 有助于配体结构的进一步优化。

可用性 和 实施: <https://github.com/lifanchen-simm/transformerCPI>。

联系方式: hliang@simm.ac.cn myzheng@simm.ac.cn

1 引言

鉴定化合物与蛋白质的相互作用 (CPI) 在发现热门化合物方面发挥着重要作用 (Vamathevan *et al.*)。基于结构的虚拟筛选和基于配体的虚拟筛选等传统方法已被研究了数十年, 并在药物发现领域取得了巨大成功。然而, 在某些情况下, 蛋白质三维 (3D) 结构未知或已知配体数据集数量太少, 并不适合应用传统筛选方法。因此, Bredel 和 Jacoby (2004 年) 提出了一种称为化学基因组学的新观点, 在没有蛋白质三维结构的情况下对 CPI 进行预判。从那时起, 各种基于机器学习的算法相继问世。

Bleakley 和 Yamanishi, 2009; Cheng 等人, 2012; Gonen, 2012; Jacob 和 Vert, 2008; van Laarhoven 等人2011, Wang 等人, 2011 等, ; ; Wang 和 Zeng, 2013; Yamanishi (2008)。

随着深度学习的快速发展, 许多类型的端到端框架已被用于 CPI 研究。与传统的机器学习算法相比, 端到端学习将表征学习和模型训练同时集成在一个统一的架构中, 建模前无需定义和计算描述符。虽然深度神经网络已被用于多个 CPI 模型, 但目前的这些方法将预定义的分子指纹和蛋白质描述符作为输入特征, 这些特征在训练过程中是固定的, 与端到端学习相比包含的信息较少 (Hamanaka *et al.*,

2017; Tian 等人, 2016; Wan 和 Zeng, 2016)。将 CPI 问题视为二元分类任务, 化合物可视为一维序列或分子图 (即传统上所说的二维结构), 蛋白质序列可视为一维序列。DeepDTA (Ozturk 等人, 2018 年) 使用卷积神经网络 (CNN) 提取化合物和蛋白质的低维实值特征, 然后将两个特征向量连接起来并通过全连接层计算最终输出。

WideDTA (Ozturk 等人, 2019 年) 和 Conv-DTI (Lee 等人, 2019 年) 随之而来。

WideDTA 也采用了类似的思路, 并利用配体最大共同结构和蛋白质主题与结构域这两个额外特征来提高模型性能。CPI-GNN (Tsubaki 等人, 2019 年) 和 GraphDTA (Nguyen 等人, 2019 年) 从另一个角度将化合物结构视为分子图, 使用图神经网络 (Scarselli 等人, 2009 年) (GNNs) 和图 CNNs (Kipf 和 Welling, 2016 年) (GCNs) 而不是 CNNs 来学习化合物的表示。此外, DeepAffinity (Karimi 等, 2019 年) 中使用了递归神经网络来提取化合物和原蛋白的特征向量, Gao 等人 (2018 年) (Zheng 等人 (2020 年) 和 也将化合物和蛋白质作为连续信息处理。

由于与化学生物学和药物化学高度相关, 许多基于深度学习或机器学习的新模型已经开发出来, 并在各种数据集上显示出令人满意的性能。然而, 在外部测试或实际应用中评估其泛化能力的工作却少得多。由于深度学习是一种数据驱动的技术, 因此了解模型的真实学习内容并避免意外因素的影响至关重要。最近, 谷歌研究人员提出了机器学习中应避免的三个陷阱 (Riley, 2019), 包括不适当地分割数据、隐藏变量和错误目标。受人工智能行业这些警告的启发, 我们想知道基于化学基因组学的 CPI 建模是否也面临类似的问题, 并总结了三个独特的问题。

1.1 使用不恰当的数据集

数据是深度学习模型的核心基础, 从某种程度上说, 一个模型能学到什么主要取决于它所输入的数据集, 如果数据集不合适, 模型就很容易偏离目标。在基于化学基因组学的 CPI 建模中, 建模的总体目标是根据蛋白质和配体特征的抽象表示形式, 预测不同蛋白质和不同配体之间的相互作用。因此, 相互作用信息是模型应从数据集中学习的关键要素。考虑到基于化学基因组学的 CPI 建模是一项二元分类任务, 一个设计合理的数据集应主要包括特定配体与蛋白质 A 发生相互作用但与蛋白质 B 没有相互作用的实例, 这就迫使模型学习蛋白质信息, 最好是相互作用特征, 以区分这些实例。这种适当设计的数据集不能用其他信息而不是相互作用特征 (如配体模式) 来区分。之前基于化学基因组学的 CPI 预测模型使用了适当的数据集来构建深度学习模型, 如 DUD-E 数据集 (Mysinger 等, 2012 年) 和 Human 数据集 (Liu 等, 2015 年; Tsubaki 等人, 2019 年), 其中 DUD-E 数据集是为了训练基于结构的虚拟筛选而收集的。此外, DUD-E、MUV、Human 和 BindingDB 中的大多数配体只出现在一个类别中, 而且阴性样本是由算法生成的, 可能会引入无法检测的噪声 (Liu 等人, 2015 年; Mysinger 等人, 2012 年)。这些数据集可以通过配体信息来区分, 不能保证模型能学习到蛋白质信息或作用间特征。

1.2 隐藏配体偏差

深度学习系统通常被称为黑箱模型, 因此很难解释该模型究竟学习了什么以及该模型根据什么进行预测。在验证集和测试集上获得更好的性能通常意味着研究的结束, 而更少的精力投入到进一步的研究中。

研究模型的学习方式是否符合预期。据报道, DUD-E 和 MUV 数据集存在配体偏向问题 (Sieg 等人, 2019 年), 引起了药物筛选领域的广泛关注。基于结构的虚拟筛选、基于 3D-CNN 的 Chen, 2019 年模型 (人) 和其他基于 DUD-E 数据集训练的模型 (Sieg 等, 2019 年) 被指出主要根据配体模式而非相互作用特征进行预测, 导致理论建模与实际应用不匹配。我们想知道基于化学基因组学的 CPI 建模是否也面临类似的问题, 因此以之前在 Human 数据集上训练的典型模型 CPI-GNN 为例, 重新研究了隐藏配体偏向的潜在影响。

图 1A 显示了在人类数据集上训练的 CPI-GNN 模型的权重分布图。用于提取蛋白质特征的 CNN 块的权重明显集中于 0, 这表明在进行预测时几乎没有考虑蛋白质信息。相比之下, 用于提取化合物特征的 GNN 块的权重分布则比较宽且平缓。因此我们认为, 与蛋白质信息相比, 配体信息起着压倒性的作用。图 1B 阐释了仅配体信息的进一步训练及其与原始模型的比较, 其中数据集被随机分割了 10 次, 两个模型在 10 个不同的轨迹上进行了评估。在双样本 t 检验中, AUC 分布差异的 P 值大于 0.05, 这表明单独使用配体信息可能比同时使用配体和蛋白质信息的 CPI-GNN 原始模型更有竞争力。因此, CPI-GNN 模型主要学习如何对不同配体进行分类, 而不是对不同 CPI 对进行分类, 这就增加了配体被分类为蛋白质的风险。




图 1 常见缺陷分析。(A) CPI-GNN 模型的权重分布图。蓝线表示用于提取蛋白质的 CNN 块的权重分布。橙线表示用于提取复合特征的 GNN 块的权重分布。(B) 两个 CPI-GNN 模型的 AUROC 的 Violin 图, 一个模型同时使用了蛋白质和配体信息, 另一个模型只使用了配体信息。白点为平均 AUROC。黑段的上端点和下端点分别为第一和第三四分位数。小提琴上方显示了 t 检验的 P 值。每个模型在 10 次不同试验中进行了评估, P 值为 0.067

这些结果突出表明,配体模式可能会误导模型。这些结果突出表明,配体模式可能会误导模型。

1.3 不适当地分割数据集

隐藏配体偏差的风险难以消除,但降低。通常,机器学习研究人员会将数据随机拆分为训练集和测试集。然而,在随机拆分的测试集上使用传统的分类测量方法,我们并不清楚模型是否学习到了真正的相互作用特征或其他未检测到的隐藏变量,这可能会产生回答错误问题的精确模型(Riley, 2019)。因此,应根据建模的真正目标及其应用场景来设计测试集。

针对这些缺陷,我们提出了一种名为 TransformerCPI 新型变换器神经网络,构建了专门用于 CPI 建模的新数据集,并引入了更严格的标签反转实验,以评估数据驱动模型是否会陷入人工智能的常见缺陷。结果,TransformerCPI 在三个公共数据集和两个标签反转数据取得了最佳性能。此外,我们还进一步研究了 TransformerCPI 的可解释性,通过将注意力权重映射回蛋白质序列和化合物分子来揭示其潜在的预测机制,结果也证实了 TransformerCPI 的自我注意力机制有助于捕捉所需的相互作用特征。我们希望这些发现能提高我们的关注度,从而提高 CPI 建模的泛化和解释能力。

2 材料和方法

2.1 TransformerCPI 的模型架构

我们提出的模型基于变压器架构(Vaswani 等人, 2017 年),该架构最初是为神经母线翻译任务而设计的。Transformer 是一个自回归编码器-解码器模型,使用多头注意力组合和位置前馈来解决序列到序列(seq2seq)

任务。最近,变压器架构在以下领域取得了巨大成功语言表征学习任务,以及许多新颖而强大的

预训练模型,如 BERT (Devlin 等人, 2019 年)、GPT-2、Transformer-XL (Dai 等人, 2019 年)和 XLnet (Yang 等, 年)。Transformer 也被应用于化学反应预测 (Schwaller 等人, 2019 年),但仍局限于 seq2seq 任务。受其捕捉两个序列之间特征的强能力的启发,我们修改了 Transformer 架构,将化合物和蛋白质视为两种序列,用于预测 CPI。图 2 显示了拟议的 TransformerCPI 的概览,我们保留了变换器的解码器,并修改了其编码器和最终线性层。

为了将蛋白质序列转换为序列表示,我们首先将蛋白质序列分割为重叠的 3 格氨基酸序列,然后通过预训练方法 word2vec (Mikolov 等人, 2013a,b) 将所有单词转换为实值嵌入。Word2vec 是一种无监督技术,用于学习描述复杂句法和语义单词关系的高质量分布式向量表示,包括两种称为 Skip-Gram 和 Continue Bag-of-Words (CBOW) 的预训练技术。Skip-Gram 用于根据上下文预测某个单词,而 CBOW 则用于根据给定单词预测上下文。通过整合 Skip-Gram 和 CBOW, word2vec 最终可以将单词映射为低维实值向量,其中语义相似的单词映射为接近的向量。已有一些研究将 word2vec 应用于表示蛋白质序列 (Kimothi 等人, 2016 年; Kobeissy 等人, 2015 年; Mazzaferro

and Carlo2017,; Yang et

将长度不变的 k 个序列 (k-mers) 拆分为单词和整个氨基酸序列被视为一份文件。我们遵循借鉴这些工作对蛋白质序列进行预处理的经验,将 UniProt 中的所有人类

通过在我们之前建立的大型语料库上对 word2vec 模型进行 30 次历时分析,可以将蛋白质序列推断为实值的 100 二维向量。

然后将蛋白质的序列特征向量传递给编码器,以学习更抽象的蛋白质表征。值得注意的是,我们用相对简单的结构取代了编码器中原有的自我注意层。考虑到传统的转换器结构通常需要大量的训练语料,而且在小规模或中等规模的数据集上容易过拟合 (Qiu 等, 2020 年),我们使用了带有 Conv1D 和门控线性单元的门控卷积网络 (Dauphin 等人, 2016 年),因为它在我们设计的数据集上显示出更好的性能。门控卷积网络的输入是蛋白质特征向量序列。我们计算隐藏层 $h_0, \dots, h_L$ 的计算公式为

$$h_l(X) = (X * W_l + s) \odot r(X * W_l + t_l) \quad (1)$$

其中 $X \in \mathbb{R}^{n \times m_1}$, 是层 h_l 的输入, $W_l \in \mathbb{R}^{k \times m_1 \times m_2}$, $s \in \mathbb{R}^{(m_2)}$, $W_l \in \mathbb{R}^{(k) \times m_1 \times m_2}$, $t \in \mathbb{R}^{(m_2)}$, 为学习参数, L 为隐藏层数, n 为序列长度, m_1 、 m_2 分别是输入和隐藏特征的维数, k 是补丁大小, r 是 sigmoid 函数, 是矩阵之间的元素向积 (Dauphin et al., 2016) 如图 2 所示, 门控共振网络的输出是蛋白质序列的最终表示。在我们的实现中, L 为 3, m_1 为 64, m_2 为编码器的输出是蛋白质序列

$p_1, p_2, \dots, p_b$, 其中 b 是蛋白质序列的长度。

每个原子特征最初都是以一个

表 1 总结了使用 RDKit python 软件包学习到的原子特征列表。然后, 我们使用 GCNs 通过整合相邻原子的特征来学习每个原子的代表性。

GCN 最初是为了解决半超视角节点分类问题而设计的, 它可以用于解决分子表示问题。在此, 我们将化合物分子图表示为 $G = (V, S)$, 其中 $V \in \mathbb{R}^{a \times f}$ 是分子中原子的集合, 每个原子表示为 f 维特征向量; S 是分子中共价键的集合, 表示为邻接矩阵 $A \in \mathbb{R}^{(a) \times a}$ 。传播规则如公式 2 所示:

$$H^{(l+1)} = f(H^{(l)} A + I) \quad (2)$$

其中, $A \sim A + I$, I 是身份矩阵, $H^{(l)} \in \mathbb{R}^{a \times f}$ 是输出矩阵。 $W^{(l)} \in \mathbb{R}^{(f) \times f}$ 是第 l 神经网络的权重矩阵, $p \in \mathbb{R}^{(a) \times a}$ 是 $A \sim \mathbb{R}^{a \times a}$ 的对角节点度矩阵; $r(\cdot)$ 是非线性激活函数。在实施过程中, 我们选择 f 为 34, GCN 层数为 1。经过 GCN 层处理的, 原子序列 $c_1, c_2, \dots$ 得出 c_a , 其中 a 是原子个数。

在获得蛋白质序列表征和原子表征后, 我们成功地将蛋白质和化合物转换成两个序列, 这两个序列符合变换器架构。交互特征通过转换器的解码器学习, 解码器由自注意层和前馈层组成。在我们的工作中, 蛋白质序列是编码器的输入, 而原子序列是解码器的输入, 解码器的输出是交互序列, 其中包含交互特征并具有

表 1. 化合物原子特征列表

原子类型	C、N、O、F、P、S、Cl、Br、I、其他
(一个热原子 原子度	0、1、2、3、4、5、6 (一个热原子)
正式收费	0 或 1
自由基电子数	0 或 1
杂化类型	sp、sp2、sp3、sp3d、sp3d2、其他 (一个热) 芳香族
连接的氢原子数	0 或 1
连接的氢原子数	0、1、2、3、4 (一个热源)

蛋白质序列作为语料对 word2vec 模型进行预训练, 并将隐藏维度设为 100

训练后	手性	0 (假) 或 1 (真)
	配置	R、S (一个热)

与原子序列长度相同。鉴于原子结构向量的顺序对 CPI 建模没有影响，我们在 TransformerCPI 中取消了位置嵌入。解码器的关键技术是多头自我关注

层。多头自我关注层由多个缩放点关注层组成，用于提取以下两个关注层之间的交互信息

编码器和解码器。自关注层接收三个输入，即密钥 K 、值 V 和查询 Q ，并按如下方式计算关注度：

$$\text{attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V, \quad (3)$$


其中， d_k 是一个缩放因子，取决于层的大小。这种机制允许解码器动态地关注编码器输出中的一些关键部分，从而直接捕捉到给定两个序列的动作间特征。此外，最初的变换器是为了解决序列预测任务而设计的，在解码器中利用掩码操作来覆盖每个词的下游上下文。因此，我们修改了解码器的掩码操作，以确保我们的模型可以访问整个序列，这是将变换器架构从自回归任务转移到分类任务的最关键的修改之一（图 2）。

在解码器中提取交互特征后，将得到一组动作间序列 $x_1, x_2, \dots, x_a$ ，每个向量的模数计算如下：

$$x'_i = \frac{\|x_i\|_2}{2}, \quad (4)$$

其中 $i = 1, 2, 3, \dots$ 每个矢量的权重可以计算得出通过 softmax 函数计算如下

$$a_i = \frac{e^{x'_i}}{\sum_{l=1}^a e^{x'_l}}. \quad (5)$$



最终的交互特征向量是由带有注意力权重的交互向量加权求和计算得出的：

$$= \sum_{i=1}^a a_i x_{(i)}. \quad (6)$$

最后，最终的交互特征向量 $y^{\text{交互}}$ 会被输送到下面的全连接层，而概率 $y^{\wedge}$ 则是一个组合的概率

返回与蛋白质相互作用的蛋白质。作为传统的二元分类任务，我们使用二元交叉熵损失来训练 TransformerCPI 模型：

$$\text{损失} = -y \log y^{\wedge} + (1 - y) \log (1 - y^{\wedge}). \quad (7)$$

TransformerCPI 使用 Pytorch 1.2.0 实现，word2vec 模型使用 Gensim 3.4.0 建立和训练。基础转换器模型有 6 层，512 个隐藏维度，而我们将层数从 6 降为 3，隐藏层维度从 512 降为 64。蛋白质表示维度原子表示、隐藏层和 $y^{\text{交互}}$ 为 64。我们保留了八个注意力头，因为这种配置具有更强的泛化能力。在训练中，我们使用了 LookAhead (Zhang 等, 2019) 优化器与 RAdam (刘等人, 2019) 优化器相结合，在没有学习率预热的情况下解决了 Adam 优化器引起的最严重的收敛问题。学习率设置为 0.0001，批次大小设置为 8，梯度在 8 个批次中累积。表 2 总结了 TransformerCPI 的所有设置和超参数。

2.2 数据集

2.2.1 公共数据集

我们在人类数据集、秀丽隐杆线虫数据集 (Tsubaki et al., 2019) 和 BindingDB 数据集 (Gao 等人, 2018)。人类数据集和 C.elegans 数据集包括来自 DrugBank 4.1 (Wishart 等, 2008 年人) 和 Matador (Gunther 等, 2007 年人) 的阳性 CPI 对，以及通过系统筛选框架获得的可信度较高的阴性 CPI 样本 (Liu 等人, 2015 年)。具体来说，人类数据集包含 1052 种独特化合物和 852 种独特蛋白质之间的 3369 次正相互作用；优雅子数据集包含 1434 种独特化合物和 2504 种独特蛋白质之间的 4000 次正相互作用，并且训练集、有效集和测试集是完全分开的 (Tsubaki 等, 2019 年人)。BindingDB 数据集包含来自公开数据库的 39 747 个正例和 31 218 个负例 (Gilson 等人, 2016 年)。BindingDB 的训练集、有效集和测试集都是精心设计的，测试集包括在训练集中未观察到配体或蛋白质的 CPI 对。因此，BindingDB 数据集可以评估模型对未知配体和蛋白质的泛化能力。

2.2.2 标签反转数据集

为了构建专门用于基于化学基因组学的 CPI 建模的数据集，我们遵循了两条规则：(i) 从以下来源收集 CPI 数据

表 2. TransformerCPI 的超参数

名称	价值
图 2. TransformerCPI 的计算图	

编码器层数	3
解码器层数	3
原子表示尺寸	64
注意头数量	8
FFN 内部隐藏大小	512
隐藏尺寸	64
补丁尺寸	7
学习率	1e-4
重量衰减	1e-4
批量大小	8
辍学	0.2

(ii) 每种配体应同时存在于这两类中。以前的许多研究通过 CPI 对的随机交叉组合或使用基于相似性的方法生成阴性样本, 这可能会带来意想不到的噪音和未注意到的偏差。在此, 我们汇编了经过实验验证的阴性数据。

首先, 我们从 GLASS 数据库 (Chan 等人, 2015 年) 中构建了一个 GPCR 数据集。GLASS 数据库提供了大量经过实验验证的 GPCR 配体关联 (Chan 等, 2015 年), 符合我们的第一条规则。GLASS 数据库使用 IC_{50} 、 K_i 和 EC_{50} 作为结合亲和值, 并将其转化为负对数 $pIC_{(50)}$ 、 pK_i 和 $pEC_{(50)}$ 。根据早期研究 (Liu 等人, 2007; Wan 等人, 2019), 我们将阈值设定为 6.0, 将原始数据集分为阳性集和阴性集。然后, 我们选择符合第二条规则的蛋白质-化合物对构建最终的 GPCR 数据集。最终的 GPCR 数据集包含 5359 个配体、356 个蛋白质和 15 343 个 CPI。

其次, 我们基于 KIBA 数据集 (Tang 等人, 2014 年) 构建了一个激酶数据集。KIBA 评分的开发结合了各种生物活性类型, 包括 IC_{50} 、 K_i 和 K_d , 并消除了不同生物活性类型之间的不一致性, 从而大大减少了数据集的偏差 (Tang 等人, 2014 年)。KIBA 数据集包含

我们从 ChEMBL 和 STITCH (Szklarczyk 等, 2016 年) 中收集了 467 个靶标和 52 498 个配体, 这确保了 KIBA 中的数据是经过实验验证的。鉴于大多数配体只出现一次, 我们按照 SimBoost (He 等, 2017 年) 的方法过滤了原始 KIBA 数据集, 使其只包括至少具有以下特征的化合物和蛋白质。

10 个相互作用, 共获得 229 个蛋白质和 2111 个化合物。然后, 我们使用建议的阈值 KIBA 值 12.1 (He 等人, 2017 年; Tang 等人, 2014 年) 将数据集分为正集和负集, 并选择化合物同时出现在正集和负集中的蛋白质-化合物对共得到 1644 个化合物、229 个蛋白质和 111 237 个 CPI。表 3 总结了我们的 GPCR 数据集和激酶数据集。

如前所述, 隐藏配体偏差可能会导致数据驱动模型学习到所需 CPI 信息之外的意外统计线索或数据模式。为了证实模型确实学习到了相互作用的特征, 并准确评估隐藏变量的影响, 我们提出了一个更严格的标签反转实验。图 3A 是标签反转实验的示意图。在训练集中, 配体只出现在一类样本 (正或负相互作用 CPI 对) 中, 而在测试集中, 配体只出现在样本中。这样, 模型就不得不利用蛋白质信息来理解相互作用模式, 并对所选配体做出相反的预测。如果模型只记忆配体模式, 那么它就不可能做出正确的预测, 因为它记忆的配体在测试集中有错误的 (相反的) 标签。因此, 这个标签反转实验是专门为评估基于化学基因组学的 CPI 模型而设计的, 能够显示隐藏配体偏差的影响程度。

对于 GPCR 集和激酶集, 我们分别随机选择了 500 和 300 个配体, 并将涉及这些配体的所有 CPI 阴性样本集中到测试集中。此外, 我们还分别选取了 500 和 300 个配体, 并将其相关的所有阳性样本汇集到测试集中。在这样的实验设计下, 我们最终建立了具有 1537 个相互作用的 GPCR 测试集和具有 19 685 个相互作用的激酶测试集。利用剩余数据集确定超参数, 并选择最佳模型在标签反转实验中进行评估。

2.2.S 标签反转数据集的数据分布

在训练模型之前, 我们研究了 GPCR 集和激酶集的数据分布。由于每种配体都可能出现在多个正负类别中, 代表与不同蛋白质相互作用或不相互作用, 因此我们分析了在正负样本中出现的频率。考虑到这一问题, 我们计算了每种配体的两个类别的对比率, 以描述数据的分布情况:

表 3. 数据集摘要

	蛋白质	化合物	互动	积极的	阴性
GPCR	356	5359	15 343	7989	7354
激酶	229	1644	111 237	23 190	88 047




图 S. (A) 标签反转实验示意图: 训练集中的配体只出现在一类样本中 (正作用间 CPI 对或负作用间 CPI 对), 而在测试只出现在另一类样本中。

(B) 两个数据集的数据分布。红线表示正向相互作用的数量等于负向相互作用的数量。(C) TransformerCPI、CPI-GNN、GraphDTA、GCN 和 TransformerCPI-ablation 对 GPCR 有效集、激酶有效集、GPCR 测试集和激酶测试集的分析结果

$$O = \frac{1}{L} \sum_{i=1}^L \log_{10} \frac{N_{pos}^{(i)}}{N_{neg}^{(i)}} \quad i = 1, 2, 3, \dots, L,$$

其中, $N_{pos}^{(i)}$ 是个配体的正相互作用数, $N_{neg}^{(i)}$ 是第 i 个配体的负相互作用数, L 是配体总数。GPCR 集和激酶集的分布如图 3B 所示。

3 结果和讨论

3.1 公共数据集的性能

许多机器学习方法, 如 K 最近邻 (KNN)、随机森林 (RF)、L2-逻辑 (L2)、支持向量 (support vector) 等, 都能帮助我们提高学习效率。

在这些数据集上评估了基于序列的模型 CPI-GNN (Tsubaki 等人, 2019 年) 和 DrugVQA (Zheng 等人, 2020 年)。GraphDTA (Nguyen 等人, 2019) 最初是为回归任务设计的, 在这里, 我们将其最后一层调整为二元分类任务。值得注意的是, 由于这两个数据集缺乏蛋白质的三维结构信息, 这里不对依赖于蛋白质三维结构信息的模型进行比较。我们采用了与 CPI-GNN (Tsubaki 等, 2019 年) 相同的训练和评估策略, 并重复使用了三种不同的随机种子, 然后用 DrugVQA (Zheng 等, 2020 年) 来评估 TransformerCPI, 各模型的接收者工作特征曲线下面积 (AUC)、预测和召回率见表 4 和表 5。由于 KNN、RF、L2 和 SVM 的实现在文献 (Tsubaki *et al.* 表 6 列出了各模型的精确度回收率曲线下面积 (PRC) 和 AUC。在三个公开数据集上, TransformerCPI 优于其他模型。

3.2 标签反转数据集的性能

我们选择了 CPI-GNN、GraphDTA 和 GCN 作为参照, 并将 TransformerCPI 的性能与这些模型的 AUC 和 PRC () 进行了比较。图 3C 总结了这些模型的 AUC 和 PRC。为了进行公平比较, 每个模型都在相同的有效集上进行了彻底的微调。如图 3C 所示, 所有模型在 GPCR 有效集和激酶有效集上都取得了相似的性能, 但是在测试集上这些模型之间的性能差距很大。虽然这些模型在随机拆分有效集上的表现相似, 但它们学到的知识却大相径庭, 这一点在更严格的标签反转实验中暴露无遗。在 GPCR 集上, TransformerCPI 的 AUC 和 PRC 均优于 CPI-GNN、GraphDTA 和 GCN, 显示出在捕捉化合物和蛋白质之间的相互作用特征方面有更强大的能力。与其他模式相比, CPI-GNN 在标签反转实验中未能先富集阳性样本再富集阴性样本, 因此我们认为配体

表 4. 拟议模型与基线在人类数据集上的比较结果

方法	AUC	精确度	回顾
KNN	0.860	0.927	0.798
射频	0.940	0.897	0.861
L2	0.911	0.913	0.867
SVM	0.910	0.91	0.919
GraphDTA	0.960 6 0.005	0.882 6 0.040	0.912 6 0.040
GCN	0.956 6 0.004	0.862 6 0.006	0.928 6 0.010
CPI-GNN	0.970	0.918	0.923
药物VQA (VQA-seq) ^a	0.964 6 0.005	0.897 6 0.004	0.948 6 0.003
TransformerCPI	0.975 6 0.002	0.916 6 0.006	0.925 6 0.006

^a 应当指出的是, DrugVQA 使用蛋白质结构信息作为输入, 而其替代版本 VQA-seq 仅使用蛋白质序列作为输入。

表 5. 拟议模型与基线模型在 *C.elegans* 数据集上的比较结果

方法	AUC	精确度	回顾
KNN	0.858	0.801	0.827
射频	0.902	0.821	0.844
L2	0.892	0.890	0.877
SVM	0.894	0.785	0.818
GraphDTA	0.974 6 0.004	0.927 6 0.015	0.912 6 0.023
GCN	0.975 6 0.004	0.921 6 0.008	0.927 6 0.006
CPI-GNN	0.978	0.938	0.929
TransformerCPI	0.988 6 0.002	0.952 6 0.001	0.955 6 0.005

GPCR 数据集的模式可能会给 CPI-GNN 带来不可忽视的配体偏差影响。在激酶集上, TransformerCPI 的 AUC 优于 CPI-GNN、GraphDTA 和 GCN, 且参考模型的 PRC 和 AUC 均小于 0.5, 因此我们认为激酶数据集的配体模式可能会对所有参考模型产生不可忽略的影响。此外, GraphDTA 和 GCN 在 GPCR 数据集上取得了良好的性能, 与 TransformerCPI 相近, 但在 Kinase 数据集上的表现要差得多。相比之下, TransformerCPI 在两个数据集上都取得了最佳性能, 显示了其鲁棒性和泛化能力。总之, 这些结果表明我们提出的 TransformerCPI 具有学习蛋白质与配体之间相互作用的能力, 标签反转实验可以有效评估隐藏配体偏差对模型的影响, 更重要的是, 提出的建模方案有助于降低基于化学基因组学的 CPI 任务的常见风险。

3.3 模型的系统依赖性

在比较 GPCR 集和 Kinase 集的结果时, 还值得注意的是, TransformerCPI、GraphDTA 和 GCN 在 GPCR 集上的表现要比 Kinase 集好很多。我们认为, 这种性能差异可能有两个潜在原因。原因是 GPCR 集和 Kinase 集的数据分布不同, 导致两个数据集之间的性能差距。第二个原因是 GPCR 的序列特征对于 TransformerCPI 来说相对更容易学习。

如图 3B 所示, GPCR 组的 log_ratio 分布峰值位于零, 这意味着 GPCR 组中大多数配体的相互作用配对和非相互作用配对数量相等。与此相反, Kinase 组的 log_ratio 分布峰明显向-1 移动, 表明 Kinase 组中大多数配体的非相互作用配对数量几乎是相互作用配对数量的十倍。因此, 阳性配对和阴性配对的分布极不平衡, 可能会给数据集带来严重的配体偏差, 从而增加数据驱动模型记忆配体模式的风险, 导致对 Kinase 集的预测性能下降。

另一个潜在原因是 GPCR 的 CPI 相关序列特征比激酶更容易学习。虽然 GPCR 家族共享大量的 α -螺旋区域和七个跨膜结构, 但整个家族的结合位置和结合口袋更加多样化, 这对于模型学习 CPI 相关序列特征以区分相互作用对和非相互作用对来说相对容易。然而, 与 GPCR 家族相比, 激酶家族的 ATP 结合口袋更为保守, 不同的残基更少。由于模型必须学会检测和理解蛋白质序列上的微小变化, 因此区分相互作用和非相互作用配对对模型具有挑战性。此外, TransformerCPI 的系统依赖性也告诉我们, 基于化学基因组学的 CPI 预测仍有改进空间, 尤其是蛋白质序列的表示。

3.4 模型消融研究

以往基于化学基因组学的 CPI 模型分别独立提取配体和原蛋白特征, 然后将这两个特征向量串联起来作为输入特征。为了验证变压器编码器-解码器架构的作用, 我们接下来评估了变压器 CPI 消减模型, 该模型取代了变压器编码器-解码器架构。

表 6. 拟议模型与基线在 BindingDB 数据集上的比较结果

方法	AUC	中国
GraphDTA	0.929	0.917
GCN	0.927	0.913
CPI-GNN	0.603	0.543
TransformerCPI	0.951	0.949

图 3C 显示了这一消减过程显著降低了 TransformerCPI 在 GPCR 集和激酶集上的性能。如图 3C 所示, 在 GPCR 集和激酶集上, 这种消减过程大大降低了 TransformerCPI 的性能, 这表明自注意机制和编码器-解码器架构在提取两类序列的 CPI 特征方面确实发挥了关键作用。

3.5 模型解读

虽然深度学习被称为黑箱算法, 但了解模型如何做出预测, 以及模型是否能为优化提供建议或指导是至关重要的。由于采用了变压器架构和自我关注机制, 因此可以通过蛋白质序列和化合物原子的关注权重轻松了解模型背后的机制。

如图 4A 所示, 注意力权重被映射到化合物原子上, 以揭示 TransformerCPI 所学到的知识。TransformerCPI 在面对不同的复合蛋白质对时, 会关注不同的原子, 并正确地将复合蛋白质对分为相互作用和非相互作用两类。

在这里, TransformerCPI 生成了与不同蛋白质相关的不同配体特征, 这与配体与不同蛋白质相互作用时的结合模式不同这一事实是一致的。因此, TransformerCPI 很难记住配体模式, 因为配体特征会随着蛋白质的变化而变化。




图 4. 不同化合物中原子的注意力权重。从 TransformerCPI 中提取的注意力分数较高的原子以红色标出。(A) 某配体分别与组胺 H1 受体和 5-HT_{2C} 受体相互作用时, 其注意力分数分布不同。(B) 苯并噻嗪的 SAR 及其注意力得分

到不同的蛋白质。这一结果也解释了为什么 TransformerCPI 在标签反转实验中表现出更好的性能。TransformerCPI 基于特定蛋白质上下文的动态特征提取有助于模型提取相互作用的关键信息, 同时也降低了隐藏配体偏差的概率。此外, TransformerCPI 的解码器动态整合了蛋白质序列和化合物原子的特征, 形成直接相互作用特征, 这与语言翻译任务类似, 并且与配体与蛋白质的结合过程非常吻合。

为了进一步验证原子注意力权重的意义, 我们选择了化合物吩噻嗪来展示 TransformerCPI 的解释。吩噻嗪是一种典型的多巴胺受体抗精神病药物, 其结构-活性关系 (SAR) 已被深入探讨。如图 4B 所示, 吩噻嗪的注意力权重所强调的原子与吩噻嗪的 SAR 非常吻合, 这证明我们的模型能够捕捉到真正的相互作用特征, 并找出与蛋白质相互作用的关键原子。这些极具价值的信息有助于药物化学家推测焦油分子的潜在 SAR, 并为进一步的结构优化提供有用的指导。

在解读了原子层面的关注机制之后, 我们还研究了蛋白质序列的关注权重, 以了解蛋白质序列的哪些部分成为了关注的焦点。因此, TransformerCPI 可以大致推测配体与 GPCR 家族的结合位点是在细胞外区域还是在跨膜区域, 并检测激酶家族的 ATP 结合口袋。我们选择组胺 H1 受体、5-羟色胺_{1B}受体和丝裂原活化蛋白激酶 8 (MAPK8) 及其相应的活性物质作为例子。

如图 5 所示, TransformerCPI 成功定位了配体与组胺 H1 受体在跨膜区的结合位点、配体与 5-HT_{1B}受体在胞外区的结合位点, 并检测到了 MAPK8 的 ATP 结合口袋, 这进一步验证了 TransformerCPI 学习了生物学知识并获得了结构洞察力。这些结果表明, TransformerCPI 可以推测新化合物是结合到 GPCR 靶点的跨膜区还是胞外区, 这对药物设计非常有用, 尤其是在 GPCR 靶点的三维结构未知的情况下。同时, 我们也会注意到, 高亮区域涉及的范围更广, 与确切的结合位点残基并不对应。要解决这个问题, 需要纳入更多具有精确注释的高质量数据, 而新的基于序列的深度表征学习也有助于更好地编码和解码结构信息。例如, Alley 等人 (2019) 最近提出的一种新表征方案就证明了蛋白质序列研究效率的提高。

总之, 基于化学基因组学的 CPI 还有很长的路要走, 我们希望这项工作能引起我们对基于化学基因组学的 CPI 建模问题的关注, 并为进一步的研究提供有益的指导。此外, 实验设计在深度学习中发挥着重要作用, 我们应更加努力地评估深度学习模型真正学到了什么。因此, 在深度学习的未来发展, 不仅要重视新的深度学习方法, 还要重视新的验证策略和实验设计。




图 5. 蛋白质序列的注意力权重。从 TransformerCPI 提取的蛋白质中注意力权重较高的区域以紫色标出。(A) 组胺 H1 受体的注意力权重 (PDB: 3RZE)。(B) 5-HT_{1B}受体的注意力权重 (PDB: 4IAQ)。(C) MAPK8 (PDB: 1UK1) 的注意力权重。

4 结论

在这项工作中,我们对具有自我注意机制的变压器架构进行了修改,以解决基于序列的CPI分类任务,最终产生了一个名为TransformerCPI的模型,在三个基准数据集上表现出了很高的性能。有趣的是,我们将其与之前报道的CPI模型和基于机器学习的传统控制模型进行了比较,发现这些模型大多在这些基准测试中取得了令人印象深刻的结果。鉴于CPI预测的挑战性,我们认为这些模型可能面临深度学习的潜在缺陷。为了解决这些潜在风险,我们构建了新的数据集,专门用于基于化学基因组学的CPI任务,并设计了更严格的标签反转实验,作为基于化学基因组学的CPI建模的新衡量标准。与其他模型相比,TransformerCPI在新实验中的表现明显提高,这表明它可以学习到所需的相互作用特征,并降低隐藏配体偏差的风险。最后,通过将注意力权重映射到蛋白质序列和化合物原子,研究了模型的解释能力,这可以帮助我们确定预测是否可靠,是否具有物理意义。总之,TransformerCPI提供了模型解释的途径,并为化学生物学研究提供了有用的指导,有助于配体结构的进一步优化。

资金筹措

这项工作得到了国家自然科学基金 ion of China (81773634 to M.Z.)、国家科技重大专项“重点新药创制”(编号:2018ZX09711002 to H.J.)和中国科学院战略性优先发展研究计划“个性化药物--基于分子 Signature药物”(XDA12050201 to M.Z.)的支持。

利益冲突:无。

参考资料

- Alley,E.C. 等人(2019) 基于序列的深度表征学习的统一理性蛋白质引擎 ring。*Nat.Methods*, 11, 1315-1322.
- Bleakley,K. and Yamanishi,Y. (2009)(2009) 使用两部分局部模型监督预测 药物与靶点的相互作用。《生物信息学》, 25, 2397-2403。
- Bredel,M. and Jacoby,E. (2004) Chemogenomics: emerging strategy for rapid target and drug discovery.(2004) Chemogenomics: an emerging strategy for rapid target and drug discovery.*Nat.Rev. Genet.*, 5, 262-275.
- Chan,W.K.B. et al. (2015) GLASS: a comprehensive database for experimentally validated GPCR-ligand associations.*Bioinformatics (Oxford, England)*, S1, 3035-3042.
- Chen,L. et al. (2019) DUD-E 数据集中的隐藏偏差导致深度学习在基于结构的虚拟筛选中的表现具有误导性。 *PLoS One*, 14, e0220113.
- Cheng,F. 等人(2012) 化学-蛋白质相互作用的预测: 多目标-QSAR 与计算化学基因组学方法的比较。 *Mol. Biosyst.*8, 2373-2384.
- Dai,Z. et al. (2019) Transformer-XL: 注意语言模型 超越固定长度语境。 In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*. pp. 计算语言学协会。意大利佛罗伦萨。
- Dauphin,Y. et al. (2016) Language modeling with gated convolutional networks.第34届机器学习国际会议论文集, JMLR.org, 澳大利亚新南威尔士州悉尼, 第933-941页。
- Devlin,J. et al. (2019) BERT: 用于语言理解的深度双向变换器预训练。 In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*. pp. 4171-4186. 计算语言学协会, 明尼苏达州明尼阿波利斯。
- Gao,K. et al. (2018) Interpretable drug target prediction using deep neural representation. In *Proceedings of the Twenty-Seventh International Joint Conference*

- Gilson, M.K. et al. (2016) BindingDB in 2015: a public database for medicinal chemistry, computational chemistry and systems pharmacology. *Nucleic Acids Res.*, 44, D1045-1053.
- Gonen, M. (2012) Predicting drug-target interactions from chemical and genomic kernels using Bayesian matrix factorization. *生物信息学*, 28, 2304-2310.
- Gunther, S. et al. (2007) SuperTarget and Matador: resources for exploring drug-target relationships. *Nucleic Acids Res.*, S1, D919-D922. (数据库问题)。
- Hamanaka, M. et al. (2017) CGBVS-DNN: 基于深度学习的化合物-蛋白质相互作用预测. *Mol. Inform. Inform.*
- He, T. et al. (2017) SimBoost: a read-across approach for predicting drug-target binding affinities using gradient boosting machines. *J. Cheminform.*
- Jacob, L. and Vert, J.P. (2008) Protein-ligand interaction prediction: an improved chemogenomics approach. *生物信息学*, 24, 2149-2156.
- Karimi, M. et al. (2019) DeepAffinity: 通过统一的递归和卷积神经网络对组合蛋白亲和性进行可解释的深度预测. *Bioinformatics*, S5, 3329-3338.
- Kimothi, D. et al. (2016) Distributed Representations for Biological Sequence Analysis. In, arXiv e-prints. 2016. p. arXiv:1608.05949.
- Kipf, T. and Welling, M. (2016) Semi-supervised classification with graph convolutional networks. In, arXiv e-prints. 2016. p. arXiv:1609.02907.
- Kobeissy, F.H. 等人 (2015 年) 用于深度蛋白质组学和基因组学的生物逻辑序列连续分布式表示. *PLoS One*, 10, e0141287.
- Lee, I. et al. (2019) DeepConv-DTI: 通过对蛋白质序列进行卷积的深度预测药物与靶点的相互作用. *PLoS Comput. Biol.*, 15, e1007129.
- Liu, H. 等 (2015) 通过建立高可信度的阴性样本改进化合物-蛋白质相互作用预测. *生物信息学*, S1, i221-i229.
- Liu, L. et al. (2019) On the variance of the adaptive learning rate and beyond. In, arXiv e-prints. 2019. p. arXiv:1908.03265.
- Liu, T. et al. (2007) BindingDB: a web-accessible database of experimentally determined protein-ligand binding affinities. *核酸研究*, S5, D198-D201.
- Mazzaferro, C. (2017) Predicting protein binding affinity with word embeddings and recurrent neural networks. <http://dx.doi.org/10.1101/128223>.
- Mikolov, T. et al. (2013a) Efficient estimation of word representations in vector space. In, arXiv e-prints. 2013. p. arXiv:1301.3781.
- Mikolov, T. et al. (2013b) 词和短语的分布式表示及其构成性. *Adv. Process. Syst.*, 21, 3111-3119.
- Mysinger, M.M. et al. (2012) Directory of useful decoys, enhanced (DUD-E): better ligands and decoys for better benchmarking. *J. Med. Chem.*, 55, 6582-6594.
- Nguyen, T. et al. (2019) GraphDTA: prediction of drug-target binding affinity using graph convolutional networks. *bioRxiv*: doi: <http://dx.doi.org/10.1101/684662>.
- Ozturk, H. et al. (2018) DeepDTA: deep drug-target binding affinity prediction. *Bioinformatics*, S4, i821-i829.
- Ozturk, H. et al. (2019) WideDTA: prediction of drug-target binding affinity. In, arXiv e-prints. 2019. p. arXiv:1902.04166.
- Qiu, X. et al. (2020) 用于自然语言处理的预训练模型: A Survey. In, arXiv e-prints. p. arXiv:2003.08271.
- Riley, P. (2019) 机器学习中应避免的三个陷阱. *自然*, 572, 27-29.
- Scarselli, F. et al. (2009) The graph neural network model. *IEEE Trans. 神经网络*, 20, 61-80.
- Schwaller, P. et al. (2019) Molecular Transformer: A Model for Uncertainty-Calibrated Chemical Reaction Prediction. *ACS Central Science*.
- Sieg, J. et al. (2019) In need of bias control: evaluating chemical data for machine learning in structure-based virtual screening. *J. Chem. Inf. Model.*, 59, 947-961.
- Szklarczyk, D. 等人 (2016) STITCH 5: 利用组织和亲和力数据增强蛋白质化学作用网络. *核酸研究*, 44, D380-D384.
- Tang, J. et al. (2014) Making sense of large-scale kinase inhibitor bioactivity data sets: a comparative and integrative analysis. *J. Chem. Inf. Model.*, 54, 735-743.
- Tian, K. 等人 (2016) 通过深度学习提升化合物-蛋白质相互作用预测. *Methods*, 110, 64-72.

- Tsubaki,M. 等人(2019) 利用神经网络对图和序列的端到端学习进行化合物-蛋白质相互作用 预测。《生物信息学》, 55, 309-318。
- Vamathevan,J. 等人 (2019) 机器学习在 药物发现与开发中的应用。《Nat.Rev. Drug Discov.》, 18, 463-477.
- van Laarhoven,T. 等人(201) 高斯相互作用轮廓核 用于预测药物-靶标相互作用。《生物信息学》, 27, 3036-3043。
- Vaswani,A. et al. (2017) Attention Is All You Need.In *Advances in Neural Information Processing Systems*, pp.美国加利福尼亚州长滩, Curran Associates Inc.
- Wan,F. and Zeng,J. (2016) Deep learning with feature embedding for compound-protein interaction prediction. *bioRxiv* doi:10.1101/086033.
- Wan,F. et al. (2019) DeepCPI: a deep learning-based framework for large-scale in silico drug screening.《Genomics Proteomics Bioinf.》, 17, 478-495.
- Wang,F. et al. (2011) Computational screening for active compounds target- ing protein sequences: methodology and experimental validation.《J. Chem.Inf.Model.》, 51, 2821-2828.
- Wang,Y. and Zeng,J. (2013) Predicting drug-target interactions using restricted Boltzmann machines.《生物信息学》, 29, i126-i134。
- Wishart,D.S. et al. (2008) DrugBank: a knowledgebase for drugs, drug actions and drug targets.《Nucleic Acids Res.》, S1, D901-D906.
- Yamanishi,Y. 等人 (2008 年), 通过整合化学空间和基因组空间预测药物-靶标相互作用网络。《生物信息学》, 24, 1232-1240。
- Yang,K.K. et al. (2018) Learned protein embeddings for machine . 《生物信息学》, S4, 2642-2648。
- Yang,Z. et al. (2019) XLNet: 用于语言理解的广义自回归预训练。In *Proceedings of the 57th Conference of the Association for Computational Linguistics, ACL 2019, Florence, Italy, July 28-August , 2019, Volume 1: Long Papers*, pp.计算语言学协会。意大利佛罗伦萨。
- Zhang,M. et al. (2019) Lookahead optimizer: k steps forward, 1 step back.In, arXiv e-prints.2019. p. arXiv:1907.08610.
- Zheng,S. 等人 (2020) 利用准视觉问题解答系统预测药物与蛋白质的相互作用。《Nat.Mach.Intell.》, 2, 134-140.