




图 1.MolLoG 的结构。蛋白质序列被映射为特征矩阵, 然后嵌入两个跃迁块进行编码。输入的药物编码转换为分子图, 药物分子相邻原子的聚合表示通过 GCN 编码。获得的药物和蛋白质的双模表示被输入到 GIL 模块, 以学习它们的全局相互作用, 从而获得联合表示 f 和注意力权重 att 。多层感知器解码模块对矩阵 f 进行解码, 以获得预测概率, 从而确定 0/1 标签。 att 矩阵将用于可解释性研究。

其他著名的方法包括基于机器学习的方法, 如支持向量机 (SVM)⁹ 和随机森林 (RF)¹⁰, 这些方法都有其局限性。这些局限性包括: 当应用于高维数据时, 计算效率会降低; 对参数修改的反应过于敏感, 导致预测性能不稳定; 以及缺乏足够的可解释性。作为一种变革性技术, 基于深度学习 (DL) 的方法通过将多维信息整合到统一的端到端框架中, 在预测 DTI 方面取得了突飞猛进的发展。这些方法已逐渐成为最佳解决方案。许多基于深度学习的模型输入分子序列或图形结构, 并利用神经网络提取潜在特征信息。Alipanahi 等人¹¹ 采用深度卷积神经网络 (CNN)¹² 来预测

DNA-蛋白质之间的相互作用。CNN 可以捕获本地药物和蛋白质序列中的模式。Yuan 等人 FusionDTA¹³ 利用前馈层和长短时记忆 (LSTM) 构建编码器层的基本模块, 将药物分子和蛋白质的中间体整合到聚合物层中, 从而实现结合亲和力的输出载体表示。虽然 CNN 等方法在序列和文本方面的性能有所提高, 但能更有效反映结构信息的图数据更胜一筹。Nguyen 等人提出了一种基于图的模型--GraphDTA¹⁴, 该模型将药物编码转换为带有特征图和无向图。图卷积网络 (GCN)¹⁵ 图注意力网络 (GAT)¹⁶ 和图同构网络¹⁷ 被设计用于从药物中提取特征。这是在执行 DTI 任务期间进行局部特征提取的显著优势。

相反, 由于蛋白质序列比药物编码要长得多, 复杂程度也高得多, 因此将这些蛋白质序列转化为类似结构是一项挑战。

目前, 有一些模型仅能将特定类型的蛋白质转化为图结构, 例如 GraphProt,¹⁸ 它是专门为 RNA 结合设计的。其他方法包括自协方差、位置转换和局部¹⁹。这些策略致力于囊括蛋白质序列的一些额外的基本属性。然而, 这些方法只关注蛋白质的属性, 往往忽略了药物分子与蛋白质之间独特的相互作用模式。这种疏忽大大影响了它们在 DTI 任务领域的适用性。这一问题同样体现在用于预测蛋白质接触图 ResPRE⁽²⁰⁾ 和用于预测蛋白质二级结构的 DCRNN⁽²¹⁾ 等方法中。

此外, 尽管 DeepMind 公司的 AlphaFold²² 在预测蛋白质三维结构方面取得了重大进展, 最近从一百万个物种中预测出了 20 亿个蛋白质三维结构, 但现实情况是, 高精度三维结构蛋白质的数量只占已知蛋白质序列的一小部分。这些挑战迫使即使是最先进的模型也不得不继续使用 CNN、RNN²³ 和 LSTM²⁴ 等方法从序列中提取蛋白质特征, 如 MolTrans、²⁵ DeepPurpose、²⁶ DrugBAN、²⁷ 和 MCANet 等模型。²⁸ 虽然 CNN 可以提取类似图结构的局部聚集特征, 但梯度消失问题的出现导致一些浅层先验知识往往会随着模型的加深丢失。在考虑更丰富的局部聚合特征的同时, 如何平衡全局语义和内在生物背景特征嵌入已成为一个复杂的问题。

一个更紧迫的挑战是, 即使可以通过捕获的特征信息成功预测结果, 但如果没有涉及功能单元、残基细节以及药物与其靶点之间相互作用位点等要素的全面分子水平分析, 也是无法预测结果的、

²⁹然而，上述大多数模型尚未克服这一障碍。

解决这一问题的关键在于获得药物和靶点的重要性评分。目前，大多数模型在特征提取阶段只对与药物/靶点本身相关的特征进行评分，而忽略了它们之间的相互作用。注意力方法已成为识别药物/靶点内部关键亚结构的有效工具。

模型的预测目标和配体。它允许

模型能够自主识别并关注与预测结果最相关的部分，从而解释了

预测的出处。另一个显著优势在于

其促进改进联合特征表征的能力

从而提高模型的预测性能。

互动。尽管实现互动可能具有挑战性

之间学习，一些先进的模型已经

然而，我们还是解决了这个问题。

最先进的方法，如 Lim 等人使用的距离感知图注意力算法⁽³⁰⁾

和 DrugBAN 的双线性注意力网络⁽²⁷⁾在解决这一问题方面取得了长足进步。然而，在真实的生物环境中，蛋白质和药物显然携带着与上下文相关的关联信息，不同位置之间存在着许多潜在的相互作用。氨基酸序列通常长度较大，上述模型难以有效学习中长期依赖关系和全局相关信息。如何充分利用注意力机制进行特征的全局联合表征并解释黑盒结果，我们进行了新的尝试。

在我们的研究中，我们引入了一种基于 DL 方法的新型模型，称为 MolLoG。该模型主要由两个模块组成：局部特征编码器（LFE）和全局交互学习（GIL）。利用这种从局部平滑过渡到全局的方法，我们显著增强了 DTI 预测及其后续可解释性，如图 1 所示。在 LFE 模块中，我们采用了结合跃迁块（一种使用残差连接的技术³¹）的 GCN。这对组合的任务是对药物分子图和蛋白质序列进行编码

将其转化为深度局部特征信息。然后，这些表征被导入 GIL 模块（这是一种结合多模态全局特征联合交互的注意力机制创新应用），在这里，它们经过独特的转换，成为全局、子块交互表征，从而促进了对药物和蛋白质特征交互的整体描述。

总之，我们的模型 MolLoG 有别于以往的研究，它有两个主要特点：(i) LFE 将地方凝聚力和整体性和谐地结合在一起的模块 (ii) 通过 GIL 模块有效学习多模态全局交互表征，并利用该模块的加权机制提供预测解释。

2. 材料和方法

2.1. 数据集。我们的评估包括通过四个公开的 DTI 数据集对 MolLoG 以及六个最先进的基线模型进行评估：BindingDB、BioSNAP、人类和 DAVIS。BindingDB 数据集主要关注小分子类药物与蛋白质的相互作用。

BioSNAP 数据集是由 Huang 等人⁽²⁵⁾和 Zitnik 等人⁽³⁴⁾从 DrugBank 数据库中创建的平衡数据集。

蛋白质相互作用数据，适用于药物发现和

³⁶人类数据集由 Liu 等人构建⁽³⁷⁾。我们使用的是数据集的平衡版本，其中包含相同数量的阳性和阴性样本。表 1 提供了人类数据集的数据统计。四个数据集。

表 1. 数据集统计

数据集	#药物	#蛋白质	#互动
绑定数据库	14,643	2623	49,200
BioSNAP	4510	2181	27,465
人	2726	2001	6728
戴维斯	72	382	11,885

2.2. 评估指标。我们使用了五个指标来评估 MolLoG 的性能。

AUROC（接收者操作特征曲线下面积）和 AUPRC（精确召回曲线下面积）是评估模型分类性能的主要指标。AUROC 衡量分类器在不同阈值下的真阳性率和假阳性率之间的权衡。AUPRC 量化了分类器在不同阈值下的精确度和召回率之间的权衡。此外，我们还报告了最佳 F1 分数阈值的准确度、灵敏度和特异性。指标定义如下

$$\text{灵敏度} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (1)$$

$$\text{特异性} = \frac{\text{TN}}{\text{TN} + \text{FP}} \quad (2)$$

$$\text{精密} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (3)$$

$$\text{精度} = \frac{\text{TP}}{\text{TP} + \text{FP} + \text{TN} + \text{FN}} \quad (4)$$

其中，TP 代表真阳性的数量，TN 代表真阴性的数量，FP 代表假阳性的数量，FN 代表假阴性的数量。原则上，上述指标值越高，性能越好。

2.3. 本地特征编码器模块。2.3.1. 用于

药物特征提取。对于药物化合物，要对每个 SMILES 字符串进行解析，识别化学键，分配坐标，去除重叠部分，然后将其转换为

分子图 $G = \{V, E\}$ 。每个原子节点 (V) 和化学键 (E) 是根据其化学性质初始化的。每个原子都由一个 D^4 维整数向量表示，其中包括八项信息：隐含氢数、形式电荷、总氢数、原子杂化、未配对电子数、原子类型、原子度以及原子是否为芳香族。所有这些都是通过 DGL-LifeSci³⁸ 软件包实现的。在图神经网络 (GNN) 的各种变体中，GCN 扩展了神经网络在图结构数据表示方面方法，使其能够根据邻近特征、自身特征和拓扑数据更新节点信息。计算，，，，减少了计算量。

图结构上的维度满足了在药物靶点预测中根据相似靶点（药物）预测相似药物（靶点）的计算要求。

我们设定了最大允许节点数 $\odot^d$ 。如果一个分子的节点数较少，那么我们对空闲节点转换为虚拟节点。Con-

然后，将每个图的节点特征矩阵表示为

为 $M_d \in \mathbb{R}^{\odot^d \times D^d}$ 。此外，我们还采用了简单的线性

变换来定义 $X_d \in W_d M_d$ ，从而得到一个实值

密矩阵 $X_d \in \mathbb{R}^{\odot^d \times (D)}$ ，作为输入特征。

我们可以用 σ 表示ReLU激活函数，并使用

$\hat{A}$ 和 D 分别表示添加了自连接的邻接矩阵和对角度矩阵。 $W^{(0)(0)}$ 代表权重矩阵。因此，给定 X

$$H^{(l+1)} = \sigma \left(X_d^{1/2} A D^{1/2} H^{(l)(l)} W^{(l)(l)} \right), H^{(1)} = \sigma \left(X_d^{1/2} A D^{1/2} H^{(0)(0)} W^{(0)(0)} \right) \quad (5)$$

此外，每层第 $(l+1)$ 个节点的特征可表示为

$$x_i^{(l+1)} = \sigma_j \sum_{k \in N_i} C_{ij}^{(l)} x_k^{(l)} w + b_z^{(l)} \quad (6)$$

在这种情况下， N_i 表示节点及其整个相邻节点集， $C_{ij}^{(l)}$ 作为归一化因子， $w^{(l)(l)}$ 指第 l 层的相关权重， $b^{(l)(l)}$ 对应于的截距。

通过药物编码器处理后，我们最终得到了多行特征表示的矩阵 $\in \mathbb{R}^{\odot^d \times D_{GCN}}$ ，

代表药物编码器最终隐藏层的维度。

2.3.2.用于提取蛋白质特征的跃迁块。每个跃迁块

区块包含三个CNN层。来自蛋白质序列的原始信息与初始区块的特征输出相结合，并传播到后续区块。同样，每个后续区块的输出都整合了从主要轨迹中提取的特征以及通过前一个区块获得的特征。这种跨模块数据传输策略确保我们在深入研究更深层次时，模型能持续发掘深层信息，同时为已提取的浅层特征植入具有全局上下文语义的学习机制。它还能有效解决

蛋白质编码中经常遇到的长距离依赖性和梯度消失问题。

首先，我们对包含25个字符的蛋白质序列进行整数编码。这是因为除了生物学中公认的标准20个氨基酸外，还有其他表示特殊情况的特征。随后，所有氨基酸被初始化为一个可学习的嵌入矩阵，表示为

$M_p \in \mathbb{R}^{N \times (D)}$ 。这里， N 代表氨基酸的数量。类型，而 D 表示每种类型的潜在维度。氨基酸。通过查询 M_p ，每个初始蛋白质序列=模型需要学习的 $\{a_1, a_2, \dots, a_n\}$ 可以映射到其对应的特征矩阵 $X(p) \in \mathbb{R}^{\odot^p \times D}$ 。这里， $\odot^p$

长度的数据会被剪掉，而较短的数据会被填充为零。

蛋白质特征编码器由两个跃迁块组成，每个跃迁块包含三个连续的CNN层。每个CNN层编码器 H_p 的描述如下

$$H^{(l+1)} = \sigma \left(H^{(l)}(W)^{(l)} + (B)^{(l)} \right), H^{(1)} = (X) \quad (7)$$

其中， $W^{(0)(0)}$ 和 $B^{(0)(0)}$ 是可学习的权重滤波器（矩阵）

和第 l 个CNN层偏置向量。

在第一个跃迁块中，蛋白质序列被感知，

如图所示，将这些转化为重叠的5个聚合氨基酸。将"MGAGV...ASESKV"分为"MGAG"、"GAG"、"V"、"ESK"、"SKV"。之后，我们将感受野增加到6，然后再增加到9，旨在学习更多扩展蛋白质的局部特征

序列。但是，如果继续增加具有更大感受野的CNN层，可能会有稀释某些序列的风险。

先验知识。反之，如果在这一阶段停止，就会使

我们对更细微、更深刻的特征视而不见。对

在此基础上，我们将原始序列越过第一个区块，并与第一个区块的输出融合，从而提供

作为第二个程序的输入。在第二个区块与第一个区块相同。在每个区块，我们使用 1×1 来计算和填充区块的输出。

卷积层，以调整输入和输出的尺寸。

通过这两个模块，我们提取了大量特征，捕捉到了更多微妙抽象的深层特征，同时保留了蛋白质固有的生物学知识和上下文语义。该过程形式化如下

$$BL^{(1)}(X_p) = \text{pad}(F(X_p, H^{(3)})) \quad (8)$$

$$BL^{(2)}(X_p) = \text{pad}(BL^{(1)}(X_p)) + X_p \quad (9)$$

$$O_p = BL^{(2)}(BL^{(1)}) + BL^{(1)} \quad (10)$$

在此过程中， $BL^{(l)(l)}(*)$ 表示第 l 个跃迁块的工作流程。在第一个区块中，我们利用上述映射得到的特征矩阵 X_p ，将其作为CNN编码器第三层输出的输入，即

(7)中所述，其中CNN的三个层中的每一层都经过归一化、正则化和处理，通过

ReLU激活函数。 $F(*)$ 表示这些操作的集合，而填充操作 $\text{pad}(*)$ 则是对数据进行填充，以保持输入维度的一致性。

矩阵 $O \in \mathbb{R}^{\odot^D \times D}$ 这里的（最终输出

的蛋白质编码器， $D_{(LB)}$ 表示输出通道数

跃迁块中的 O_d 和获得的 O_d （药物编码器的最终输出）随后被引入GIL模块。

2.4. 全球互动学习模块。该模块

该模型旨在研究药物与蛋白质之间的相互作用机制，获得它们的联合表示矩阵和注意力权重矩阵。在我们的模型中，药物特征是通过图结构提取，蛋白质特征则是通过序列获取。互动过程涉及多模态特征融合；因此，

采用了一种非常规方法。这种方法应用于计算机视觉和自然语言处理的交叉领域，特别是在视觉问题等任务中。

代表蛋白质序列的最大允许长度，设置该长度是为了对不同长度的蛋白质进行批量训练。超过允许长度的蛋白质序列

在这些任务中，通常有两种类型的输入：代表图像视觉内容的视觉特征（vf）和代表图像视觉内容的视觉特征（sf）。

文本查询 (T_q), 表示用户对图像的询问或疑问。在 VQA 任务中, "T_q" 可以是一个

比如 "图片 (V_f) 中的猫是什么颜色的? 同样, 在我们的 DTI 任务中, 我们需要确定序列 (T_q) 中将发生反应的具体片段与图结构中的相应原子 (V_f) 对应。

考虑到 VQA 和 DTI 面临的类似挑战, 我们设计了 GIL 模块。

药物特征 $O_d(V_f)$ 和蛋白质特征 $O_p(T_q)$ 通过自定义全连接层 (FCNet) 进行处理, 将原始特征映射到新的特征空间。

FCNet 的目的是对获得的特征进行整合和抽象, 以实现更高层次的特征重构。经过

转置后, 我们得到 $O_d' \in \mathbb{R}^{D_{FCN} \times O_d}$ 和 $O_p' \in \mathbb{R}^{D_{FCN} \times O_p}$ 。 D_{FCN} 表示最后一个隐藏层的维度。

FCNet 转置的目的是调整两组的特征矩阵, 以适应随后的

请注意 模块。我们的目标是实现 全球目标。每个药物分子和蛋白质之间的相互作用学习, 而不仅仅是多个分子的某些特征相互作用

分子, 这将毫无意义。

之后, 这两类新特征会被输入到由多头注意力组成的互动模块。

在通常情况下, 注意力机制的核心理念围绕着基于查询 (Q)、键 (K) 和值 (V) 的计算。随后, 计算 Q 和 K 之间的相似度, 生成权重分布, 然后对 V 进行加权求和, 得出输出结果。在我们的工作中, 药物的特征是通过编码同时生成 K 和 V 的。

K (由 O_d' 生成) 通过 Q (由 O_p' 生成), 然后使用相应的 V 生成答案 (也由 O_d' 生成)。这种从不同来源制定键、值和查询的技术尤其有效

当输入数据显示出固有关系或自相关性时。正如我们在 DTI 任务中看到的那样, 在经过自定义 FCNet 抽象后, 药物和蛋白质特征显示出很强的相关性, 从而学习到更丰富的表征。

由于涉及多重线性变换和转置, 在此过程中, 各种矩阵维数会发生多重变化。为了使 方法更加清晰, 我们可以将其数学表达如下。

我们将并行计算的计算头数设为 h (必须能被 h 整除)。对于每个 head_i ($1 \leq i \leq h$), 我们可以定义三个权重矩阵: $W^i \in \mathbb{R}^{L(Q) \times D_{FCN}}$, $W^{(i)} \in \mathbb{R}^{L_K \times D_{FCN}}$ 、

和 $W^i \in \mathbb{R}^{L_V \times D_{FCN}}$, 将用于线性。这里, L_Q 、 L_K 和 L_V 表示 Q 的长度、

K 和 V 向量。一般来说, 这三个值相等。考虑到 O_d' 和 O_p' , 符号 - 表示矩阵乘法。我们可以计算矩阵 Q、 $K_{(i)}$ 和 V_i

$$Q = W^i \cdot O_p', \quad K = W^{(i)} \cdot O_d', \quad V = W^i \cdot O_d' \quad (11)$$

准备就绪后, 我们开始计算

每个头部的注意力权重 (att_i)。然后将这些注意力权重应用于数值 (V_i), 得出每个头部的输出矩阵 (head_{i0})。

$$= \frac{\sum_j Q_{ij} K_{jk} - T_{ij} V_{jk}}{\sqrt{d_i^k} \sqrt{d_j^k}} \quad (12)$$

$$\text{率领} = \frac{\sum_j Q_{ij} K_{jk} - T_{ij} V_{jk}}{\sqrt{d_i^k} \sqrt{d_j^k}} \quad (13)$$

在这种情况下, d_i^k 表示头部 i 中关键向量的维度。用于缩

放注意力权重, 其中

有助于稳定训练过程, 防止梯度变化爆炸或消失, 因为查询和键。采用软最大函数对分数进行归一化处理、

接下来, 。

连接每个头部的注意力权重矩阵 M_{att} 。

$$M_{\text{att}} = \text{concat}(\text{att}_1 \dots \text{att}_h) \cdot W_{(\text{att})} \quad (14)$$

这里, $W_{\text{att}} \in \mathbb{R}^{D_{FCN} \times D_{FCN}}$ 。 $M_{(\text{att})}$ 是 的一个 的重要部分。

对于 的 矩阵 head_i , , 我们还将其连接起来, 以获得联合表示 f'

$$M_{f'} = \text{concat}(\text{head}_1 \dots \text{head}_h) \cdot W_0 \quad (15)$$

这里, $W_0 \in \mathbb{R}^{D_{FCN} \times D_{FCN}}$ 。同时, 我们应用

对 f' 进行三次运算, 以获得最终的联合表示 f , 用于解码。

1. 再次进行平移, 以匹配初始特征图的尺寸。
2. 应用平均池化, 这有助于缩小输入数据的空间大小, 并平滑整体特征。
3. 应用另一个全连接层 (out_net) 生成最终的联合表示。

总之, 我们所采取的三个步骤都致力于进一步加强我们提取的特征之间的相互作用。此外, GIL 模块的独特机制极大地促进了药物特征和蛋白质特征的整合进而提高了模型的预测性能。

2.5. 分子水平可解释性分析我们加载

其中矩阵中的每个值代表每个药物原子对每个目标分子的重要性。我们还获取了注意力权重中超过一定阈值的点在整个矩阵和侧面信息 (相应的蛋白质和药物表示) 中的行列位置。鉴于药物中通常有超过 20% 的原子构成活性官能团, 我们将这一阈值设定为 80%, 目的是找出前 20% 的最

重要的原子。

对于药物的分子阐释, 我们通过 RDKit⁴² 工具包加载 SMILES 编码并创建分子图, 从而获得分子中实际原子的数量和相应的注意力权重。GCN 跨层传播和聚合节点特征信息。在每一层中

更新节点的特征向量, 同时保持

它们在特征矩阵中的位置指数。在绘制分子图像的过程中, 突出显示的原子超出了

某些阈值用鲜艳的橙红色 (E94E4E) 表示, 代表药物中预计主要参与反应的原子。在蛋白质分析中, 我们将 M_{att} 的每一列视为一个注意力

权重向量,将该权重向量映射到蛋白质的一维序列上,从而突出模型认为重要的氨基酸残基。同时,我们仍然可以定位单个蛋白质片段。这得益于跃迁块内 CNN 的滑动窗口^{43(,44)}特性。

三维结构的可视化是通过 PDB⁴⁵网站和 Pymol 实现的。⁴⁶在此仅介绍该方法;更多有趣的案例和生物学解释将在第 3.6 节中提供。请注意,在中,我们主要关注药物原子的可解释性。至于靶标的解释,我们将在文中提供必要的补充和解释。

3. 结果与讨论

3.1. 实施和超参数我们的实验装置部署在配备了两个 RTX 2080 Ti 单元的系统上,每个单元的规格为 11 GB 显存、12 个虚拟 CPU 和 40 GB 内存。MolLoG 采用的执行环境和工具版本如下: PyTorch 1.11.0 + CUDA 11.3、Python 3.8.10、DGL 0.9.1post1、Numpy 1.23.5、Pandas 1.5.3 和 RDKit 2022.09.5。我们的模型包含超参数,主要参数如表 2 所示。

表 2. MolLoG 使用的超参数

超参数	设置
优化器	亚当
学习率	5×10^{-5}
MAX_Epoch	100
批量大小	64
跃块	2
CNN 内核大小	[3, 6, 9]
GCN 尺寸	[128, 128]
注意事项	4
注意力集中规模	3

3.2. 预测性能评估。每个实验数据集被随机分成训练集、验证集和测试,保持 7:1:2 的比例。训练集

为评估目的,测试集被视为“未知”。对于每个数据集,我们使用不同的随机种子进行了五次独立迭代。在验证集上表现出最佳 AUROC 的模型被认为是表现最好的模型,随后在测试集上对其进行评估。

在此,我们将 MolLoG 与随机分割设置下的六种基线进行了比较:表 3 列出了 MolLoG 在 BindingDB 和 BioSNAP 数据集上的表现。表中粗体数据代表最优值。在 AUROC、AUPRC 和准确度方面,MolLoG 始终优于基线,在特异性方面也极具竞争力。

由于人类数据集和 DAVIS 数据集的一些独特性,我们稍后将分别研究模型在这两个数据集上的表现。


3.3. 在人类身上使用冷对拆分策略

数据集。在标准随机拆分范式下,基于 DL 的模型在人类数据集上表现出稳定且值得称赞的性能 (AUROC > 0.97, 波动 < 0.005)。其中,只有 MolLoG 和 DrugBAN 的 AUROC 超过了 0.98。不过,Chen 等人强调了人类数据集固有的潜在隐性配体偏差,提出在该数据集上训练的模型可能主要学习药物特异性特征而非所需的相互作用模式⁽⁴⁸⁾。这包括将 5% 和 10% 的 DTI 对分别随机分配到验证集和测试集中,然后从训练集中移除相应的药物和蛋白质。这一策略确保了数据集基于药物和蛋白质独立性的分离,导致测试集中的药物和蛋白质在训练过程中完全未出现过。

图 2 显示,所有在这种严格的策略下,SVM 和 RF 等传统模型的性能明显下降。尽管这种情况极具挑战性,但与其他最先进的 DL 基线相比,MolLoG 仍能提供出色的结果。我们还对其余三个数据集采用了冷拆分策略。在所有数据集上,所有模型的性能都有所下降。关键指标 AUROC 和

表 3. 随机分割 BindingDB 和 BioSNAP 数据集的性能比较

方法	AUROC	亚太区域中心	精确度	敏感性	特异性
绑定数据库					
SVM	0.939±0.001	0.928±0.002	0.825±0.004	0.781±0.014	0.886±0.012
射频	0.942±0.011	0.921±0.016	0.880±0.012	0.875±0.023	0.892±0.020
DeepConv-DTI ⁽²⁰¹⁹⁾	0.945±0.002	0.925±0.005	0.882±0.007	0.873±0.018	0.894±0.009
GraphDTA ⁽²⁰²¹⁾	0.951±0.002	0.934±0.002	0.888±0.005	0.882±0.012	0.897±0.008
MolTrans ⁽²⁰²¹⁾	0.952±0.002	0.936±0.001	0.887±0.006	0.877±0.016	0.902±0.009
毒品禁令 ⁽²⁰²³⁾	0.953±0.005	0.943±0.003	0.896±0.005	0.887±0.012	0.906±0.007
MolLoG	0.962±0.004	0.951±0.006	0.905±0.005	0.898±0.012	0.912±0.005
BioSNAP					
SVM	0.862±0.007	0.864±0.004	0.777±0.011	0.711±0.042	0.841±0.028
射频	0.860±0.005	0.886±0.005	0.804±0.005	0.823±0.032	0.786±0.025
DeepConv-DTI ⁽²⁰¹⁹⁾	0.886±0.006	0.890±0.006	0.805±0.009	0.760±0.029	0.851±0.013
GraphDTA ⁽²⁰²¹⁾	0.887±0.008	0.890±0.007	0.800±0.007	0.745±0.032	0.854±0.025
MolTrans ⁽²⁰²¹⁾	0.887±0.002	0.891±0.005	0.802±0.004	0.755±0.021	0.843±0.023
毒品禁令 ⁽²⁰²³⁾	0.896±0.005	0.900±0.004	0.834±0.008	0.828±0.021	0.847±0.010
MolLoG	0.898±0.003	0.902±0.005	0.832±0.006	0.826±0.027	0.856±0.022



性能波动。

在 BioGRID 数据集中为 0.03，在 BioSNAP 数据集中约为 0.02，在 DAVIS 数据集中约为 0.04。不过，就整体性能而言，MolLoG 仍然优于其他模型。

3.4. 小样本数据集验证了泛化能力。为了进一步评估该模型在处理更多参数和模块时是否具有良好的泛化能力，我们使用随机分割条件下的 DAVIS 数据集进行了实验。

DAVIS 数据集包含经实验验证的药物-蛋白质相互作用数据。然而，它们只包含数量有限的药物和蛋白质样本。为了加快研究人员提取必要的药物-蛋白相互作用信息进行分析和建模，数据集的结构相对简单。这给平衡模型的泛化能力、参数数量和复杂性带来了挑战。

因此，我们放弃了 SVM 和 RF 等相对简单的模型。

从表 4 中我们可以看出，MolLoG 通过其独特的从局部到全局的学习方法，即使在结构相对简单、样本较少的数据集时，也表现出了值得称道的泛化能力，尽管它的层次结构错综复杂，样本数量较多。

表 4.随机分割 DAVIS 数据集的性能比较

方法	AUROC	亚太区域中心	精确度	敏感性	特异性
DeepConvDTI ⁽²⁰¹⁹⁾	0.796±0.023	0.788±0.036	0.724±0.008	0.694±0.033	0.721±0.013
DeepDTA ⁽²⁰²¹⁾	0.801±0.016	0.790±0.038	0.731±0.013	0.735±0.039	0.720±0.024
MolTrans ⁽²⁰²¹⁾	0.828±0.018	0.796±0.028	0.733±0.015	0.702±0.043	0.803±0.052
毒品禁令 ⁽²⁰²³⁾	0.814±0.012	0.825±0.033	0.743±0.015	0.748±0.034	0.776±0.019
MolLoG	0.852±0.005	0.856±0.029	0.782±0.011	0.766±0.028	0.808±0.011

的数量。值得注意的是，准确性和特异性这两项关键指标都有显著提高。

3.5.消融研究。我们进行了三次消融研究旨在调查 LFE 模块和 GIL 模块对 MolLoG 的影响。这项研究具体包括以下几个方面：

1. 使用不同的 GNN 变体提取药物特征对模型性能的影响；
2. 使用跃迁块以及块和层数对蛋白质特征提取的影响；
3. 使用 GIL 模块对数据表示进行全局整合效果，以及模块中注意力头的数量对性能的影响。

表 5 列出了五轮实验中 F1 分数最高的一轮的表现。表 5

表 5.三种消融研究

消融测试	AUROC	AUPRC	准确性	灵敏度	特异性
第 1 部分.在 DAVIS 数据集下使用不同 GNN 变体提取药物特征的影响					
GAT	0.8362	0.8125	0.7592	0.7864	0.7879
GraphSAGE	0.8329	0.8078	0.7842	0.7869	0.7633
MolLoG (部分)	0.8574	0.8592	0.7996	0.8011	0.8010
DAVIS 数据集下的结果和图层					
只有 3 个 CNN	0.8361	0.8022	0.7556	0.7626	0.7636
只有 6 个 CNN	0.8311	0.7918	0.7501	0.7523	0.7816
3 个 CNN 街区	0.8512	0.8488	0.7826	0.7820	0.8028
2 个街区	0.8663	0.8592	0.7847	0.7889	0.8055
4 个 CNN					
第 3 部分.使用 GIL 模块进行全局数据整合的影响					
BioSNAP 数据集的成果展示					
未使用	0.8741	0.8782	0.8045	0.7964	0.8126
中古	0.9011	0.8971	0.8282	0.8257	0.8473

实验表明，我们使用的每个模块都能提高 MolLoG 的性能。在实验的特定阶段，所有其他模块都与 MolLoG 保持一致。

在第一部分中，我们比较了使用注意力机制的 GAT 和 GraphSAGE⁽⁴⁹⁾，后者引入了可学习的聚合函数，允许节点在聚合过程中对不同的相邻节点进行加权。实验结果表明，我们采用的 GCN 是最有效的。

在第二部分中，我们继续在三层 CNN 的基础扩展感受野。引入更多参数没有提高模型的性能，反而出现了下降，这说明了前面提到的梯度消失问题。当我们添加跃迁块时，所有指标都出现了

明显增加。请注意,在 MoLoG 中,我们使用了 2 个区块和 3 个 CNN,因为它具有更好的鲁棒性和泛化能力。在第 3 部分中,如果我们不使用 GIL 模块来抽象和全局交互特征,而是将特征串联起来直接导致性能大幅下降。

我们还比较了不同注意力头数对性能的影响。在 BindingDB 数据集下,我们以折线图的形式绘制了模型在验证集上前 60 个历时的 AUROC 和 AUPRC,如图 3 所示:模型的性能表现出了明显的“钝化”现象。




图 3. BindingDB 数据集下验证集前 60 个历时的 AUROC 和 AUPRC 折线图。

随着训练历元数的增加,模型的性能呈上升趋势。其中,当多头注意力模块的头数设置为四个时,模型表现出最佳性能。

总之,这验证了我们的策略的有效性,提取局部特征并促进全局互动。

3.6. 案例研究。3.6.1. DTI 预测。评估

为了提高 MoLoG 的预测效率,我们对药物 D00235 (阿替洛尔⁵⁰) 和 D00567 (塞来昔布⁽⁵¹⁾) 进行了案例分析。对于这两种药物,我们通过人工方式仔细检查了最重要的 10 个预测靶点,我们的研究结果与从公开数据库中获得的数据相吻合,从而得到了全面验证(表 6)。考虑到这些令人鼓舞的结果,我们有理由推测,有几个高分互动靶点虽然目前尚未得到证实,但有可能与正在研究的药物发生实际的相互作用。这将有助于新药的开发和改进。

3.6.2. 分子层面的可解释性。我们有

我们选择了 3U5J (与阿普唑仑复合的人类 BRD4 的第一个溴结构域) 和 5XPR (与拮抗剂波生坦复合的人类 B 型内皮素受体) 进行分子水平的可解释性研究。这两种共晶体

蛋白质数据库中的配体分辨率分别为 1.60 Å 和 3.60 Å,两者都不属于模型训练集。阿普唑仑和波生坦这两种药物在治疗特定疾病方面发挥着关键作用,在提高生活质量和生存率方面已成为许多患者不可或缺的药物。

阿普唑仑是一种中间起效的三唑类苯并二氮杂卓,常用于治疗惊恐障碍、广泛性焦虑以及抑郁症伴发的焦虑⁽⁵²⁾。在阿普唑仑与 BRD4 的复杂反应中,我们成功地预测了参与阿普唑仑反应的一些关键原子(图 4B)。我们的模型解释了突出显示的原子将与 I146、L94 和 Y139 结合。在分析蛋白质时,我们的模型未能准确识别这三个目标。在 BRD4 载体中,阿普唑仑中的乙酰基赖氨酸与保守的酪氨酸残基 Y97 配合,MoLoG 成功地确定了这一点。共晶体分析显示,三唑环作为乙酰赖氨酸模拟支架,与保守残基 N140 形成氢键。遗憾的是,我们没有发现 N140 是乙酰化底物的氢键锚点。一项文献研究表明,造成这种情况的可能原因是阿普唑仑复合物中与 N140 形成第二个氢键,这可能导致配体亲和力降低⁽⁵³⁾。

在图 4B 中,绿色原子最初被 MoLoG 标记。然而,当我们用三唑仑(与阿普唑仑相比,三唑仑的绿原子上只多了一个氯原子)替换实验药物时,MoLoG 去掉标记。这是因为苯基环 2 位的氯取代是不耐受的。MoLoG 可以捕捉到这种微妙的变化。

波生坦是一种双重内皮素受体拮抗剂,可用于治疗肺动脉高压。⁵⁴对于结构复杂的 5XPR,我们的模型同样成功地确定了波生坦与 B 型内皮素受体(ETB)之间的关键相互作用位点(参见图 4F): 2-嘧啶基、4-磺酰胺基、5-苯酚基和 6-乙二醇基。我们能够预测高分辨率结构中的几种相互作用(图 4G)。磺酰胺与 Lys182^(3.33) 和 Lys273^(5.38) 发生离子相互作用;与磺酰胺相关的 4-*t*-丁基苯基与 Val177^(3.28) 和 Pro178^(3.29);中心嘧啶 2 位上嘧啶与 Ile372^(7.39) 形成疏水接触;5-苯酚的甲氧基苯氧基基醚分子与 Val185^(3.36) 和 Leu277^(5.42) 残基中的

表 6. 药物 "D00235" 和 "D00567" 的十大预测目标列表

药物标识	目标ID	预报	证据	药物标识	目标ID	预报	证据
D00235	P18090	0.932	KEGG	D00567	P23280	0.774	KEGG
D00235	Ch_38603	0.921	KEGG	D00567	P00918	0.968	药物库
D00235	Ch_735421	0.745	KEGG	D00567	P23219	0.862	KEGG
D00235	P28564	0.862	KEGG	D00567	P35454	0.813	药物库
D00235	Q92887	0.843	KEGG	D00567	P07451	0.719	药物库
D00235	P07550	0.910	药物库	D00567	Ch_107983	0.822	KEGG
D00235	O95342	0.861	药物库	D00567	Ch_662815	0.855	KEGG
D00235	P08588	0.793	药物库	D00567	O15530	0.842	药物库
D00235	P61169	0.878	KEGG	D00567	O76074	0.789	KEGG

D00235

P07550

0.746

药物库

D00567

EBI_101485

0.831

KEGG




图 4.生物和化学知识对预测结果的重要可视化和补充。(A、E) 两个复杂结构的概览。黑色半透明椭圆聚焦于药物和配体反应区域。(B,F) MolLoG 预测在两种情况下反应中起关键作用的药物原子。(C)BRD4脂蛋白结构(绿色条纹状结构)与阿普唑仑配体复合物(杆状结构)的叠加图。⁽⁵⁴⁾ 该图突出了阿普唑仑结合位点的主要相互作用残基和细节。(D) 共晶体配体的详细描述。阿普唑仑结合位点以透明的白色表面表示。(G) bosentan(棒状结构)和 ETB(淡黄色)的叠加。

跨膜核心。⁵⁵在蛋白质残基的定位中,我们只确定了三个目标,分别标记为 Lys182^{3,33}、Pro178^(3,29)和 Val185^(3,36)。

总之,由于我们的模型仅在一维蛋白质序列上进行训练,因此可能导致预测遗漏和与药物原子不匹配。解读蛋白质结构是一项极具挑战性的工作,这也证明了我们模型的局限性。相反,其他预测结果的可解释性有了显著提高。MolLoG 甚至可以预测某些经证实只在特定情况下发生的生化反应。此外,鉴于 MolLoG 提供的可解释性是从庞大的 DTI 数据中学习到的,这种解释可能会发现迄今为止尚未探索到的隐见解。这一特点有可能为研究人员提供进行高成本生化实验的方向性方法。

3.7. 局限性和未来工作。在数据预处理阶段,如果出现一种科学有效的方法将蛋白质编码成类似药物的二维图结构,将其应用于 MolLoG 可以显著提高预测精度和可解释性。此外,将描述 DTI 的量子力学特征⁵⁶整合到特征提取中也是一个有趣的方向,因为这种方法可以达到极高的精度。不过,这种方法的数据获取成本可能很高。在可解释性方面,准确识别原始片段变得具有挑战性。虽然结合位置编码可以建立相应的关系,但这意味着巨大的性能成本。在我们的

初步实验中,引入位置编码使模型训练时间增加了数十倍。因此,将位置编码与知识提炼^{13,57}相结合以减少参数数量可能是一个有效的方向。

4. 结论

作为体外实验的有力补充,在大数据和人工智能时代,我们提出了一种 DL 模型 MolLoG,它可以学习和预测潜在的 DTI,从而以高效、经济的方式加快药物开发进程。MolLoG 主要由 "LFE" 和 "GIL" 模块组成。实验结果表明,通过从局部到全局的学习方法,它能有效地提取局部特征并提供有效的全局联合表征,其性能优于目前最的模型。在此基础上,我们将整合两种模式的注意力权重映射到蛋白质的子序列和药物化合物的原子上。通过这种方法,我们可以在分子水平上实现结果的可视化。这种增强的可视化表现形式可以为实际医学实验提供更深入的生物学见解和更有针对性的建议。

相关内容

数据可用性声明

MolLoG 的源代码和实现细节可在 GitHub 存储库中免费获取:

<https://github.com/fbbgood/MolLoG.git>