

RESEARCH

Open Access



SSELM-neg: 基于球形搜索的极限学习机（负）用于药物靶点相互作用预测的学习机器

Lingzhi Hu¹, Chengzhou Fu^{1,3}, Zhonglu Ren¹, Yongming Cai^{1,3}, Jin Yang^{1,3}, Siwen Xu¹, Wenhua Xu¹ and Deyu Tang^{1,2,3*}

通信作者: sc
utdy@126.com

¹ 广东药科大学医药信息工程学院, 中国广州

² 华南理工大学计算机科学与工程学院, 中国广州, 中华人民共和国

³ 广东省中药精准医学大数据工程技术研究中心, 中华人民共和国广州市

摘要

背景: 药物发现过程的实验验证既昂贵又耗时。因此, 高效、有效地识别药物-靶标相互作用 (DTIs) 一直是研究的重点。目前, 许多机器学习算法被用于预测DTI。然而, 在开发最优的DTI模型之前, 需要解决各种挑战, 如类别不平衡和许多分类器的参数优化。

方法: 在本研究中, 我们提出了一种名为 SSELM-neg 的框架用于药物-靶点相互作用 (DTI) 预测, 在该框架中, 我们采用筛选方法选择高质量的负样本, 并采用球形搜索方法优化极限学习机的参数。

结果表明, 在针对酶数据集、G 蛋白偶联受体数据集、离子通道数据集和核受体数据集的 10 折交叉验证实验中, 所提出的技术在受试者工作特征曲线下面积 (分别为 0.986、0.993、0.988 和 0.969) 和平均精度度下的曲线下面积 (分别为 0.982、0.991、0.982 和 0.946) 方面均优于其他最先进的方法。

结论: 该筛选方法生成了与阳性样本数量相同的高质量阴性样本, 从而解决了类别不平衡的问题。我们采用球形搜索方法优化了极限学习机来识别药物-靶点相互作用。因此, 我们的模型表现优于其他最先进的方法。

关键词: 药物靶点相互作用、药物发现、极限学习机、球形搜索、类别不平衡

介绍

药物-靶点相互作用 (DTI) 预测是药物再定位的一种重要方式[1-4], 它不仅在新药研发中发挥着关键作用[5], 而且对于研究药物的不良反应也至关重要[6, 7]。然而, 采用湿实验方法验证药物-靶点相互作用既耗时又费钱[8, 9]。一个重要的问题是



©The Author(s) 2023. **Open Access** This article is licensed under a Creative Commons Attribution 4.0 International License, which permits use, sharing, adaptation, distribution and reproduction in any medium or format, as long as you give appropriate credit to the original author(s) and the source, provide a link to the Creative Commons licence, and indicate if changes were made. The images or other third party material in this article are included in the article's Creative Commons licence, unless indicated otherwise in a credit line to the material. If material is not included in the article's Creative Commons licence and your intended use is not permitted by statutory regulation or exceeds the permitted use, you will need to obtain permission directly from the copyright holder. To view a copy of this licence, visit <http://creativecommons.org/licenses/by/4.0/>. The Creative Commons Public Domain Dedication waiver (<http://creativecommons.org/publicdomain/zero/1.0/>) applies to the data made available in this article, unless otherwise stated in a credit line to the data.

如何降低药物研发成本是关键所在。因此，基于计算机模拟的方法变得至关重要，因为它能提高发现药物与靶点之间关系的准确性，并节省时间[10]。随着公共数据库数量的不断增加[11]，不同的计算策略能够更有效地应用于药物靶点相互作用的预测[12]。

一般来说，用于药物靶点相互作用（DTI）识别的计算方法可分为三类：基于配体的方法[13]、基于对接的方法[13]以及基于化学基因组学的方法[14]。这些方法在预测药物靶点相互作用方面发挥了重要作用；然而，基于对接的方法利用药物和蛋白质的三维（3D）结构，然后进行模拟以确定它们是否相互作用，但由于已知靶点的 3D 晶体结构有限，因此存在局限性[15-17]。基于配体的方法基于这样一个事实，即相似的分子往往具有相似的性质，并且通常会与相似的蛋白质结合[18]，这意味着当每种蛋白质的已知配体数量不足时，基于配体的方法的预测结果可能会变得不可靠[19]。

化学基因组学方法利用药物和靶点信息，将药物的化学空间和靶点的蛋白质空间整合到一个药理空间中，以预测药物-靶点相互作用（DTIs）。化学基因组学方法的一个优势在于，它们能够利用广泛丰富的生物数据来进行预测[14]。我们将化学基因组学方法分为四类：机器学习方法、矩阵分解方法、基于网络的方法以及混合方法。

预测药物-靶点相互作用（DTIs）的机器学习方法主要有三类：基于相似性的方法、深度学习方法和特征选择方法。基于相似性/距离的方法主要利用样本间的相似性或距离[20-22]。Yamanishi 等人[23]开发了一种二分图模型，通过有监督学习已知的药物-靶点关系来预测 DTIs[24, 25]。Buza 等人提出了 ECKNN/HLM，这是一种带有误差校正的 K 近邻(KNN)方法(中心节点感知回归技术)，用于减轻不良中心节点的有害影响[26-28]。Mei 等人提出了 BLM-NII，这是一种集成到 BLM 方法中的推理方法，用于解决纯 BLM 的新候选问题[29]。然而，这类方法的主要缺点是已知的药物及其相互作用数量有限，数据集中存在大量未标记的数据[30]。由于深度学习[31]在药物发现中的出色表现，其应用不断增加[31, 32]。Wen 等人提出了 DeepDTIs，使用深度信念网络（DBN）[33]提取原始输入向量，并预测 FDA 批准的药物与靶点之间的新 DTIs[34]。李等人提出了 DeepConv-DTI，这是一种深度学习[35]方法，用于获取参与药物-靶点相互作用（DTI）的蛋白质的局部残基模式[35]。尤等人提出了 LASSO-DNN，这是一种基于从 LASSO 回归模型中提取的特征的深度学习[36]方法，使用蛋白质特异性和药物特异性特征进行拟合[36]。这类方法的缺点在于如何选择真正不相互作用的药物-靶点对[37]。基于特征的方法目前是进行药物-靶点相互作用预测的绝大多数机器学习方法。它们包括支持向量机（SVM）、基于树的方法以及其他基于核的方法。已提出了 SVM、KSVM、MH-SVM 等方法。其主要原理是支持向量机构建一个或一组超平面，可用于预测药物与靶点之间是否存在相互作用[19, 38-42]。

夏等人提出了 NetLapRLS, 这是 LapRLS 的改进版本, 通过整合基于已知药物-靶点相互作用网络构建的新核函数实现 [43]。然而, 此类方法面临的问题是, 膜蛋白缺乏三维结构, 这阻碍了关键特征的提取。

矩阵分解方法在药物-靶点相互作用 (DTI) 预测方面取得了更好的效果。Ezzat 等人提出了 GRMF-WGRMF, 这是一种用于提取药物-靶点二分图低维非线性流形的双流形学习器 [44]。Gonen 等人提出了一种将相互作用得分矩阵分解为核矩阵 (相似矩阵) 的方法, 该方法可用作新药物和蛋白质的 DTI 预测器 KBMF2K [45]。这类方法的缺点在于, 与药物和/或靶点相关的数据量和种类迅速增长, 远远超出了基于矩阵的数据表示和许多当前分析算法的能力。基于网络的方法利用图论技术进行 DTI 预测, 具有简单可靠的优势。Luo 等人提出了 DTINet, 这是一种用于 DTI 预测的计算网络集成管道 [46]。Chen 等人提出了 NRRRH, 这是一种基于随机游走重启 (RWR) 框架的二分图网络潜在 DTI 推断方法 [47]。Seal 等人提出的 RWR 方法需要进行矩阵求逆, 并能在基于 DTI 权重的图中为两个节点提供良好的相关性得分 [48]。

混合方法指的是所有使用基于特征的方法、矩阵分解、深度学习和基于网络的方法的任意组合的方法。由 Alaimo 等人提出的领域调优混合方法是一种扩展的 NBI 技术, 它结合了基于领域的知识, 例如药物相似性和靶点相似性 [49]。通过回顾上述方法, 我们发现一个关键问题是如何选择负样本; 因此, 我们在本研究中首先解决的问题是建立一个高度可靠的负样本数据集, 以克服先前方法的不足。负样本的数量远远多于正样本的数量。这会导致类别不平衡问题, 从而影响最终药物靶点相互作用 (DTI) 的预测准确性。因此, 在本研究中, 我们选择了一种筛选方法来构建高度可靠的负样本数据集, 以解决类别不平衡问题。

此外, 我们提出了一种新的预测 dti 的分类器: 基于球面搜索 (SS) 优化的极限学习机 (ELM)。此前, 学者们已经使用 ELM 来预测药物与靶标之间的新关系。然而, 网络参数是随机生成的, 这降低了 ELM 模型的预测性能。因此, 使用群体智能算法对 ELM 的网络参数进行优化是必要的。SS 是一种调整参数较少的群体智能算法; 其准确率、收敛速度、熟练度、有效性均处于世界先进水平; 并且该算法具有投影特性, 可以消除搜索过程中的停滞现象, 有利于消除局部极小值中的粘性。

因此, 我们提出了一种名为 SSELN-neg 的框架用于预测药物-靶点相互作用 (DTI)。本研究的创新之处在于:

- 1 我们提出了一种基于筛选方法和基于 SS 的 ELM 的 DTI 预测框架。
- 2 我们采用一种筛选方法，基于新药与已知（预测）蛋白质相关药物之间差异显著这一原则，构建了一个高置信度的负样本数据集。
- 3 我们提出了一种基于 SS 的极限学习机（ELM）。我们利用 SS 优化 ELM 的参数，以提高药物靶点相互作用（DTIs）的分类性能。

相关工作

在这项研究中，我们专注于机器学习方法来预测 dti。(2)生成可信的负样本；(3)分类器的性能。

基于特征的方法需要进行特征选择；因此，需要将药物-靶标对显式表示为定长特征向量，这可能导致大量复杂的计算。相比之下，基于相似度的方法不需要特征提取或选择，并且比这更容易计算。基于相似度的 DTI 预测方法的原理是通过计算药物的化学结构生成药物的相似矩阵，通过计算蛋白质的特性生成靶点的相似矩阵，最后将这两个相似矩阵用于各种分类方法中，如[51]。

这就导致了数据的不平衡，大大降低了分类器的准确率。传统的方法是随机抽取负样本。近年来，已经提出了一些提取阴性样品的方法。

Mohammad等人提出了BRNS算法来提取平衡可靠的负样本[52]。尤佳莹等人提出了一种选择最可能负dti的新方法。这种方法的假设是基于“联想负罪感”，这表明类似的药物可能具有相似的靶点，反之亦然。然而，这些方法通常计算起来更复杂。因此，在本研究中，我们在Liu等人的研究基础上，采用更简单的筛选方法提取更可信的阴性样本。

此外，在基于机器学习的方法预测药物-靶点相互作用（DTIs）时，分类器的性能尤为重要，一些更经典的分类器，如支持向量机（SVM）[54-56]、K 近邻（KNN）[57,58]和随机森林[59,60]已被使用。极限学习机（ELM）因其出色的性能而备受关注，并且在许多领域[61-63]，如电力和金融领域得到了应用。Xin 等人[64]使用极限学习机进行药物-药物相互作用预测，An 等人[65]则利用核极限学习机基于药物指纹和蛋白质进化信息来识别药物-靶点相互作用。迄今为止，利用极限学习机预测药物-靶点相互作用的研究还很少。一个重要原因是

ELM 网络隐藏层参数的配置需要更好的优化方法。

预备赛

ELM是Huang等人[66]提出的求解单隐层前馈神经网络的算法。它初始化并随机生成输入权重和隐藏层偏差，并使用非线性激活函数将输入数据映射到新的特征空间。

输入样本的数量为 N ，样本为 (x_i, t_i) ，其中 $x_i = [x_{i1}, x_{i2}, \dots, x_{in}]^T \in \mathbb{R}^n$ ， $t_i = [t_{i1}, t_{i2}, \dots, t_{im}]^T \in \mathbb{R}^m$ 。输出层的权重由隐藏层输出矩阵的广义逆表示。因此，ELM 可表示为

$$t_j = \sum_{i=1}^L \beta_i g(x_i W_i + b_i), \quad j = 1, 2, \dots, N, \quad (1)$$

其中 L 表示隐藏层节点的数量， $w_i = [w_{i1}, w_{i2}, \dots, w_{in}]^T$ 是连接输入层和隐藏层的权重向量， $b_i = [b_{i1}, b_{i2}, \dots, b_{in}]^T$ 是隐藏层的偏置向量，而 $\beta_i = [\beta_{i1}, \beta_{i2}, \dots, \beta_{im}]^T$ 是连接隐藏层和输出层的权重向量。 $G(x) = [g(x, w_1, b_1), g(x, w_2, b_2), \dots, g(x, w_n, b_n)]$ 表示隐藏层函数的激活。

单隐层神经网络的学习目标是使输出误差最小化。当输出结果与样本 N 之间的误差为零时，上述公式可简化为

$$H\beta = T, \quad (2)$$

哪里

$$H = \begin{bmatrix} h(x_1) \\ \vdots \\ h(x_N) \end{bmatrix} = \begin{bmatrix} h_1(x_1) & \cdots & h_L(x_1) \\ \vdots & \cdots & \vdots \\ h_1(x_N) & \cdots & h_L(x_N) \end{bmatrix} \quad (3)$$

$$T = \begin{bmatrix} t_1^T \\ \vdots \\ t_n^T \end{bmatrix}, \quad (4)$$

其中 H 是隐藏层节点的输出， β 是输出权重， T 是期望输出。经过摩尔-彭罗斯广义逆运算后，我们得到

$$\beta = H^\dagger T, \quad (5)$$

其中 $H^\dagger$ 是矩阵 H 的广义逆。

方法

问题描述

我们的问题基于这样一个假设：存在药物集合 $D \in \{d_1, d_2, \dots, d_n\}$ 和蛋白质集合 $P \in \{p_1, p_2, \dots, p_m\}$ ，其中 D 包含 n 种药物， P 包含 m 种蛋白质。药物与靶蛋白之间的关系定义为一个 $m \times n$ 的二进制矩阵 Y ，其中药物与蛋白质 p_j 有相互作用时， $y_{ij} = 1$ ；当药物 d_i 与靶蛋白 p_j 无相互作用或相互作用未知时。药物之间的相似性由矩阵 S_d 表示，靶蛋白之间的相似性由矩阵 S 表示。我们计算了每个未相互作用的药物-靶蛋白对的预测得分，并预测了新的药物-靶蛋白对。

构建负样本集

药物靶点相互作用数据集中负样本（未验证样本）的数量明显高于正样本（已验证样本）的数量（如图 1a 所示），这导致了由于数据不平衡，药物靶点相互作用分类的预测性能下降。为了平衡数据集，在以往的研究中，研究人员经常使用随机选择的方法来提取与正样本数量一致的负样本，如图 1b 所示。然而，这忽略了关键问题：未标记的药物靶点相互作用可能具有尚未被发现或论证的相互作用。随机选择负样本可能会将一些未标记的药物靶点相互作用样本选为负样本；然而，它们可能是正样本，这会降低模型的性能。所提出的筛选方法是提取高质量的负样本（这些负样本远离正样本，如图 1c 所示）。我们将所有已知的药物靶点相互作用标签设为 1，将药物靶点空间中所有其他选定的样本（没有已知相互作用的药物靶点对）设为 0。我们将数据集中所有标签为 1 的样本直接作为正样本，将所有标签为 0 的样本作为负样本。




图 1 负样本的选择示例图

如上文所述构建已知/预测的药物-靶点相互作用 (DTI) 的集合 K , 并利用蛋白质差异规则和药物差异规则[42], 我们将药物之间的相似性整合为一个药物综合相似性得分, 对于蛋白质之间的相似性亦是如此。这可以用 (c_k, p_j, d_{kj}) 来表示, 其中 c_k 代表药物 k , p_j 代表蛋白质 j , d_{kj} 代表药物 c_k 和蛋白质 p_j 之间的相互作用。对于集合 K 中由 c_k 靶向的任何蛋白质 p_l , 我们计算加权得分 $spc_{jkl} = w_{kl} * PS_{jl}$, 该得分表明蛋白质 p_j 和每个已知/预测的蛋白质 p_l 被药物 c_k 靶向的可能性, 即 $(c_k, p_l, w_{kl}) \in K$ 。我们通过将针对 l 的加权得分 spc_{jkl} 相加来计算综合得分, 从而得到

$$SPC_{jk} = \frac{\sum_l p_{jl} \times spc_{jkl}}{\sum_l spc_{jkl}}. \quad (6)$$

同样地, 我们计算加权得分 $scp_{kj} = w_{ij} * CS_{ik}$, 该得分代表药物 c_k 作用于靶点 p_j 的可能性, 同时考虑了药物 c_k 与已知/预测的针对蛋白质 p_j 的药物 (即 $(c_i, p_j, w_{kl}) \in K$ 之间的相似性。我们通过将针对 i 的加权得分 spc_{kji} 相加来计算综合得分, 从而得到

$$SCP_{kj} = \frac{\sum_i p_{kj} \times scp_{kji}}{\sum_i scp_{kji}}, \quad (7)$$

其中 p_{kj} 是蛋白质 p_j 与药物 c_k 之间的相互作用值, $andscp_{kji}$ 是药物 c_k 与其他所有药物的相似度。

对于目标药物 c_k 和蛋白质 p_j , 平均加权分数定义为

$$S_{kj} = \frac{SPC_k + SCP_j}{2}. \quad (8)$$

我们根据从式(8)中得到的排序得分选择潜在的负样本, 得分最低的构成负样本候选集。我们在这个数据集上进行了这项研究的实验。数据集 (DTI对) 表示为

$$DTI_{i,G} = [P_{i1}, P_{i2}, \dots, P_{im}; C_{j1}, C_{j2}, \dots, C_{jm}; D_{i,j}], \quad (9)$$

其中 C_i 表示药物, P_i 表示蛋白质, D_{ij} 表示药物 C_i 和蛋白质 P_i 之间的分类标签 (0 或 1)。

在图 1a 中, 黄色圆圈代表已知的药物靶点对, 灰色三角形代表未知或不相关的药物靶点对。灰色三角形离 y 轴越近, 相互关联的可能性就越大。图 1b 展示了随机选取的负样本, 用黑色三角形表示。位于红线左侧附近的黑色三角形可能具有药物 - 靶点相互作用 (DTI), 它们可能是正样本, 但被选为了负样本。图 1c 展示了使用筛选方法选取的负样本, 黑色三角形远离红线。

基于球形搜索的极限学习机

进化算法是一种可用于解决一般优化问题的优化方法，因为它简单灵活、无需求导且不易陷入局部最优解[67]。SS 是一种用于解决非线性有界约束全局优化问题的进化算法[67]。迄今为止，它尚未用于解决极限学习机（ELM）的参数优化问题。在本研究中，我们使用它来优化 ELM 的网络参数。首先，我们通过随机选择来初始化 SS 算法的种群。我们将第 G 次迭代中的种群定义为 Q_x ，其表达式为

$$Q_{x,G} = [x_{1,G}, x_{2,G}, \dots, x_{i,G}, \dots, x_{N,G}], \quad (10)$$

其中 $x_{i,G}$ 表示种群中的一个解， x_{ij} 表示第 i 个解的第 j 个元素， x_{ij} 是极限学习机（ELM）的一个参数。 $x_{i,G}$ 是 D 维搜索空间中的一个向量。 D 表示极限学习机中的参数数量。

解的初始化：在第 j 个元素的上下维度之间选择一个随机分布来初始化解。

$$x_{ij,0} = (x_{uj} - x_{lj}) \times \text{rand}(0, 1) + x_{lj}, \quad (11)$$

其中 x_{uj} 和 x_{lj} 分别是第 j 个元素的上、下维度边界。 $\text{rand}(0, 1)$ 表示生成 $(0, 1]$ 区间内均匀分布的随机数。

试验解的生成：试验解是通过迭代和竞争生成的新潜在解：

$$y_{i,G} = x_{i,G} + v_{i,G} \times m_{i,G} \times z_{i,G}, \quad (12)$$

其中 $m_{i,G}$ 是一个投影矩阵，用于确定 $D - 1$ 维球面边界上 $y_{i,G}$ 的值；不同的 p_i 会导致不同的 $m_{i,G}$ 值：

$$m_{i,G} = \frac{1}{\text{rank}(\text{diag}(p_i))} \times \text{diag}(p_i), \quad (13)$$

其中 A 是一个正交矩阵，

$$AA^T = I, \quad (14)$$

其中 $0 < \text{rank}(\text{diag}(p_i)) < 1$ ，并且

$$0 < \text{rank}(\text{diag}(p_i)) < 1, \quad (15)$$

$y_{i,G}$ 的位置确定了 $D - 1$ 维的球形边界，而 $x_{i,G}$ 是一个特定的解。 $c_{i,G}$ 表示步长控制向量，其值在 $[0.5, 0.7]$ 范围内随机计算得出。

$z_{i,G}$ 表示搜索方向。在优化算法中，新解的质量高度依赖于对搜索空间探索与利用之间的平衡。我们使用两种搜索操作：朝向最优解和朝向随机解。在拥有较好解的一半种群中，我们采用朝向随机解的方法，因为它具有更好的搜索能力；而在另一半种群中，我们采用朝向最优解的方法，因为它同样具有较好的搜索能力。这两种搜索方向的结合提供了一种平衡。

为了探索和利用搜索空间，这不仅提高了更优解的多样性，还迫使较差的解提高适应度：

$$\text{towards - rand} \quad z_{i,G} = x_{p_i,G} + x_{q_i,G} - r_{r_i,G} - x_{i,G} \quad (16)$$

$$\text{towards - best} \quad z_{i,G} = x_{p_{best},G} + x_{q_i,G} - r_{r_i,G} - x_{i,G}, \quad (17)$$

其中 p_i 、 q_i 和 r_i 是从 1 到 N 中随机选取的索引号，而 $x_{p_{best},G}$ 是从当前最优解集中随机选取的一个个体。 $x_{p_{best},G}$ 和 $x_{p_i,G}$ 表示目标点。 $(x_{q_i} - r_{r_i})$ 是差值项，而 x_{q_i} 和 r_{r_i} 是从当前解集中随机选取的个体；因此，实际搜索方向在一定程度上可能会偏离目标搜索方向。

我们使用基于成功历史的控制参数自适应 (SHPA) [68] 在搜索过程中调整两个控制参数： $rank$ 和 c_i 。SHPA 创建一个大小为 $(2 \times H)$ 的历史矩阵 L ，用于保存 H 次迭代中这两个控制参数的值，即参数 $rank$ 和 c 在最近 H 次迭代中的学习值 l_r 和 l_c 。

$rank_{i,g}$ 和 $c_{i,g}$ 的计算方式为

$$rank_{i,g} = \text{Binornd}(D, L_{1,j}) \quad (18)$$

$$c_{i,g} = \text{Cauchyrand}(L_{2,j}, 0.1), \quad (19)$$

其中， Binornd 表示二项分布， j 从矩阵 L 的列中独立选取，每个 i 均为随机数。 Cauchyrand 表示柯西分布， j 从矩阵 L 的列中独立选取，每个 i 均为随机数。

SS 的性能高度依赖于控制参数 c_i 以及种群规模 N 的等级和大小 [67]。在本研究中，我们采用指数种群规模缩减法，在迭代过程中动态调整种群规模。我们根据迭代次数以指数函数的形式不断缩减种群规模。在第一次迭代时种群规模为 N_{init} ，在最后一次迭代时为 N_{min} 。我们使用以下公式来计算第 N_{G+1} 次迭代的种群规模：

$$N_{G+1} = \text{round}(N_{init}(1 - \frac{N_{init} - N_{min}}{nfes_{max}}))_G, \quad (20)$$

其中 $N_{min} = 4$ ， $nfes_{max}$ 为允许的最大函数评估次数。每当 $N_{G+1} < n_G$ 时，我们从种群中移除 $(N_G - N_{G+1})$ 排名最差的个体。

l_r 和 l_c 的计算公式为

$$l_{r,g} = \frac{\sum_{h=1}^{|S_{r,g}|} w_{h,g} r_{h,g}^2}{\sum_{h=1}^{|S_{r,g}|} w_{h,g} r_{h,g}} \quad (21)$$

$$l_{c,g} = \frac{\sum_{h=1}^{|S_{c,g}|} w_{h,g} c_{h,g}^2}{\sum_{h=1}^{|S_{c,g}|} w_{h,g} c_{h,g}}. \quad (22)$$

向量 S_r 和 S_c 分别表示成功试验的等级和数量。 $S_{r,g}$ 和 $S_{c,g}$ 分别表示 S_r 和 S_c 的长度。

为下一次迭代选择新的种群：

$$x_{i,G+1} = \begin{cases} y_{i,G}, & \text{iff } (y_{i,G}) \leq f(x_{i,G}) \\ x_{i,G}, & \text{otherwise.} \end{cases} \quad (23)$$

我们采用贪婪选择法来更新下一代的新种群集合。如果试验解的目标函数值 $f(y_{i,g})$ 不高于解的目标函数值 $f(x_{i,g})$ ，那么 y_i 将替换 x_i 。

适应度函数：

$$t_j = \sum_{i=1}^L \beta_{ig} (DTI_i \times x_j + x_b), \quad j = 1, \dots, N, \quad (24)$$

其中 L 表示隐藏层节点的数量， $x_i = [x_{i1}, x_{i2}, \dots, x_{in}]^T$ 是连接输入层和隐藏层的权重向量， $x_b = [b_{i1}, b_{i2}, \dots, b_{in}]^T$ 是隐藏层的偏置向量， $\beta_i = [\beta_{i1}, \beta_{i2}, \dots, \beta_{in}]^T$ 是连接隐藏层和输出层的权重向量。 β_i 可以通过公式 (5) 计算得出。

$G(x) = [g(DTI_1, x_1, x_{b1}), g(DTI_1, x_2, x_{b2}), \dots, g(DTI_1, x_n, x_{bn})]$ 表示隐藏层函数的激活：

$$Fitness = \sum_{i=1}^k \frac{(AUC_i + AUPR_i)}{2}, \quad k = 10. \quad (25)$$

AUC_i 是使用极限学习机 (ELM) 得到的受试者工作特征曲线 (ROC 曲线) 下的面积 (AUC)， $AUPR_i$ 是使用极限学习机 (ELM) 得到的精确率 - 召回率曲线 (PR 曲线) 下的面积 (AUCPR)。

在本研究中，将一个药物 - 靶点相互作用 (DTI) 对输入到极限学习机 (ELM) 中，即药物相似性、蛋白质相似性以及已知 (或未知) 的药物 - 靶点相互作用输入到 ELM 中，输出预测的新药物 - 靶点关系。在 SSELN-neg 中，输入层与隐藏层之间的连接权重 x_j 以及隐藏层的偏置 x_b 是通过 SS 方法生成的，并确定隐藏层与输出层之间的连接权重。SS 方法生成网络参数以提高网络的预测准确性和泛化能力。在本研究中，我们使用 10 折交叉验证来验证 SSELN-neg 的预测性能。

我们所提出的框架如图 2 所示，伪代码见算法 1。




图 2 SSELM-neg 药物 - 靶点相互作用预测框架

Algorithm 1 SSELM-neg

Input: drug similarity dataset P ; target similarity dataset C ; drug-target interaction dataset D , popsize etc.
Output: best weight and bias for the ELM for the higher AUC and AUPR value.

```

1: Get the average weight scores of all the drugs and targets using Equations(6), (7), and (8);
2: Get the same number of positive samples and negative samples according to the rank using the
   average weight scores;
3: Get the training sets and test sets using Equation (9);
4: Initialize the population using Equations(11) and (12);
5:  $c_i \leftarrow rand(0, 1)$ 
6: while  $FES < FEmax$  do
7:    $A \leftarrow ComputeOrthogonalMatrix()$  // Using Equations (13) and (14);
8:   for  $i = 1$  to  $N$  do
9:      $diag(b_i) \leftarrow ComputeBinaryVector()$  //Using Equation (15)
10:    if  $i < 0.5 * N$  then
11:      //Better exploration using Equation (16)
12:       $z_i \leftarrow TowardsRand(i)$ 
13:    else
14:      //Better exploitation, using Equation (17)
15:       $z_i \leftarrow TowardsBest(i)$ 
16:    end if
17:     $weight_{vec} \leftarrow x_i + c_i A' diag(b_i) A z_i$ 
18:    // Get a new solution using Equation (12)
19:     $Of_i \leftarrow ComputeELM(weight_{vec}, training\_sets, test\_sets)$ 
20:    // Using Equations (5), (24), and (25)
21:     $FES \leftarrow FES + 1$ 
22:     $x_i \leftarrow Selection(x_i, y_i)$  //Using Equation (23)
23:  Get new parameter value  $b_{i,g}$  and  $v_{i,g}$  //Using Equations (21) and (22)
24:  end for
25:  Get new population  $P_1 \leftarrow Sort(P_1)$  //Using Equation (20)
26: end while

```

实验评估

数据集

我们通过将模型在 Yamanishi [23] 编制的金标准数据集上的表现与先前的优秀方法进行比较，来证明我们方法的有效性。这些数据集源自 DRUG BANK 和京都基因与基因组百科全书 8 (KEGG) 等数据库，涵盖了四种重要蛋白质靶点的药物 - 靶点相互作用 (DTI)，即 (i) 酶 (E)；(ii) 离子通道 (IC)；(iii) G 蛋白偶联受体 (GPCR)；(iv) 核受体 (NR)，包含 932 种药物、989 种靶蛋白以及 5127 种药物间的相互关系。在这个金标准数据集中，已知的 DTI 来自多个公共数据库，包括 DrugBank [69]、Super-Target [70]、KEGG BRITE [71] 和 BRENDA [72]。我们通过整合药物的化学结构相似性来获取药物间的相似度。我们从 KEGG LIGAND [71] 数据库下载了药物的化学结构，并使用 SIMCOMP [73] 计算相似度。我们通过整合蛋白质的氨基酸序列相似性来获取蛋白质间的相似度，这些序列是从 KEGG GENES 数据库下载的。我们通过整合从 KEGG GENES 数据库 [74] 下载的蛋白质氨基酸序列相似性来获取蛋白质之间的相似度。表 1 展示了该数据集的一些统计信息，包括药物总数、靶点总数以及相互作用总数。平均而言，离子通道 (ICs) 和酶 (Es) 中每种药物和靶点的相互作用数量多于 G 蛋白偶联受体 (GPCRs) 和核受体 (NRs)。金标准数据集的详细信息见表 1。

在上一步建立高置信度负样本集之后，我们将四个相互作用数据集转换为矩阵形式以描述信息：(i) 正相互作用和 (ii) 负相互作用。

DTI的性能评估

提出的sselm - negative模型旨在增强DTI的预测能力。在实验中，我们评估了SSELM-neg模型对金标准数据集上Es、ic、GPCR和NRs的预测能力，SSELM-neg模型取得了可靠的预测性能。为了确保公平，我们使用了10个交叉验证测试来评估sselm阴性的性能。我们将黄金标准数据集分成10个大小相等的子集。我们重复这个过程10次，每次使用一个不同的子集作为测试子集。最后，我们得到了10次的平均结果。评价指标为AUC和precision-recall curve (AUPR) 下面积。我们计算ROC曲线如图3所示，并以AUC作为主要质量度量。正确率-召回率曲线是真实情况的图表

表 1 金标准数据集

	互动	药物	目标
E	2926	445	664
集成电路	1476	210	204
GPCR (G蛋白偶联受体)	635	223	95
NR	90	54	26

对于给定的每个召回率，真阳性率（TPR）是所有阳性预测中的比率，而 AUPR 值提供了定量估计。AUPR 适用于评估每种方法的性能，并且由于其对假阳性的惩罚比 AUC 更严厉，因此能更好地估计质量。

$$TPR = \frac{TP}{TP + FN'}$$

(26)

$$FPR = \frac{FP}{TN + FP}$$

(27)

ROC 曲线以假阳性率（FPR）为横轴，以真阳性率（TPR）为纵轴。真阳性率是指所有实际为正样本中被正确判定为正样本的比例。假阳性率是指所有实际为负样本中被错误判定为正样本的比例。

与其他方法的比较

为了进一步说明所提出方法的稳健性和有效性，我们选取了四种经典方法和四种近年来的新方法进行比较：Bigram-PSSM [41]、iDTI-ESBoost [75]、NRLMF [76]、BLM-NII [24]、SELF-BLM [77]、NetLapRLS [43]、SPLCMF [78] 和 WNN-GIP [79]。为了公平地比较药物-靶点相互作用（DTI）预测性能，我们将这些方法应用于相同的金标准数据集。我们还采用了随机设置，进行了 10 折交叉验证，使用相同的评估标准，并为每种方法采用了最佳参数。对于 SSELM-neg，最大迭代次数 MaxNfes = 10,000，贪婪 PbestRate = 0.11，种群大小 PopSize = 100，rd = 0.5，c = 0.7，A_r = 1.4，历史记忆存储大小 Ms = 5。其他方法所使用的参数在各自的文章中有提及。对于 BLM-NII，g = max 且 α = 0.5。对于 SELF-BLM，c = 1 且 γ = 1。具体参数详情请参阅原始文章。

表 2 展示了各方法在黄金标准数据集上的 AUC 结果，表 3 则展示了 AUPR 结果。在这些表格中，最佳结果以粗体显示。如表 2 和表 3 所示，SSELM-neg 相较于先前的研究，在 AUC 和 AUPR 性能方面有了显著提升。SSELM-neg 在 E、GPCR 上的 AUPR 值分别为

表 2 验证条件下交互预测的 AUC 结果

方法	数据集 E	数据集 E		
		GPCR	集成电路	NR
二元语法位置特异性矩阵	0.948	0.872	0.889	0.869
iDTI-ES增强版	0.969	0.932	0.937	0.929
NRLMF	0.987	0.969	0.989	0.950
BLM-NII	0.985	0.966	0.984	0.917
SPLCMF	0.970	0.942	0.981	0.828
WNN-GIP	0.964	0.944	0.959	0.901
NetLapRLS	0.969	0.904	0.956	0.844
自我谴责	0.860	0.894	0.925	0.773
SSELM 阴性	0.986	0.993	0.988	0.969

最佳结果以粗体显示

表 3 交互预测验证下的 AUPR 结果

方法	数据集			
	E	GPCR (G蛋白偶联受体)	集成电路	NR
二元语法位置特异性矩阵	0.546	0.282	0.390	0.411
iDTI-ES增强型	0.680	0.500	0.480	0.701
NRLMF	0.892	0.749	0.906	0.701
BLM-NII	0.869	0.709	0.909	0.701
SPLCMF	0.881	0.754	0.938	0.533
WNN-GIP [79]	0.706	0.520	0.717	0.589
NetLapRLS	0.786	0.617	0.820	0.463
自我谴责	0.639	0.599	0.744	0.457
SSELM 阴性	0.982	0.991	0.982	0.946

最佳结果以粗体显示。




图 3 六种方法的 AUC 和 AUPR 结果比较

IC 和 NR 分别为 0.9652、0.9906、0.9762 和 0.9455，均高于其他先进算法的相应值。

图 3（左）显示，在 GPCR 数据集上，SSELM-neg 的 AUC 值分别比 Bigram-PSSM、iDTI-ESBoot、NRLMF、BLM-NII、SPL-CMF、WNN-GIP、NetLapRLS 和 SELF-BLM 高出 12%、6.1%、2.4%、2.7%、5.1%、4.9%、8.9% 和 9.9%（分别为 0.993 对比 0.872、0.932、0.969、0.966、0.942、0.944、0.904 和 0.894）。在 NR 数据集上，SSELM-neg 的 AUC 值分别比 Bigram-PSSM、iDTI-ESBoot、NRLMF、BLM-NII、SPL-CMF、WNN-GIP、NetLapRLS 和 SELF-BLM 高出 10%、4%、1.9%、5.2%、14.1%、1.6%、12.5% 和 19.6%（分别为 0.969 对比 0.869、0.929、0.950、0.917、0.828、0.901、0.844 和 0.773）。在 IC 数据集上，SSELM-neg 的 AUC 值略低于 NRLMF（分别为 0.988 对比 0.989），但仍优于其他方法；分别比 Bigram-PSSM、iDTI-ESBoot、BLM-NII、SPLCMF、WNN-GIP、NetLapRLS 和 SELF-BLM 高出 9.9%、5.1%、0.4%、0.7%、2.9%、3.2% 和 6.3%（分别为 0.988 对比 0.889、0.937、0.984、0.981、0.959、0.956 和 0.925）。对于 Es 数据集，我们的模型比 BLM-NII 略胜一筹，高出 0.01%（分别为 0.986 对比 0.985），略低于 NRLMF（分别为 0.986 对比 0.987），但仍远优于其他模型。我们的模型分别比 Bigram-PSSM、iDTI-ESBoot、SPLCMF、WNN-GIP、NetLapRLS 和 SELF-BLM 高出 3.8%、1.7%、1.6%、2.2%、1.7% 和 12.6%（分别为 0.986 对比 0.948、0.969、0.970、0.964、0.969 和 0.860）。与之相比

表 4 各方法 AUC 结果比较

订单	方法	平均排名
1	二元语法位置特异性矩阵	2.00
2	iDTI-ES增强型	4.63
3	NRLMF	8.50
4	BLM-NII	6.75
5	SPLCMF	4.75
6	WNN-GIP	4.75
7	NetLapRLS	3.63
8	自我谴责	1.50
9	SSELM 阴性	8.50

表 5 各方法 AUC 值的弗里德曼检验

方法	卡方（检验）	渐近显著性
弗里德曼检验	27.240	0.001

在 E 数据集上，我们的模型以及最先进的算法都取得了更高的 AUC 值，这是因为 E 数据集中包含的已知药物 - 靶点相互作用（DTIs）数量最多。图 3（右）显示，在 E 数据集上，SSELM-neg 的 AUPR 值分别比 Bigram-PSSM、iDTI-ESBoot、NRLMF、BLM-NII、SPLCMF、WNN-GIP、NetLapRLS 和 SELF-BLM 高出 43.6%、30.2%、9%、11.3%、10.1%、27.6%、19.6% 和 34.3%（分别为 0.982 对比 0.546、0.680、0.892、0.869、0.881、0.706、0.786 和 0.639）。在 GPCR 数据集上，SSELM-neg 的 AUPR 值分别比 Bigram-PSSM、iDTI-ESBoot、NRLMF、BLM-NII、SPLCMF、WNN-GIP、NetLapRLS 和 SELF-BLM 高出 70.9%、49.1%、24.2%、28.2%、23.7%、47.1%、37.4% 和 39.2%（分别为 0.991 对比 0.282、0.500、0.749、0.709、0.754、0.520、0.617 和 0.599）。在 IC 数据集上，SSELM-neg 的 AUPR 值分别比 Bigram-PSSM、iDTI-ESBoot、NRLMF、BLM-NII、SPLCMF、WNN-GIP、NetLapRLS 和 SELF-BLM 高出 59.2%、50.2%、7.6%、7.3%、4.4%、26.5%、16.2% 和 23.8%（分别为 0.982 对比 0.390、0.480、0.906、0.909、0.938、0.717、0.820 和 0.744）。在 NR 数据集上，SSELM-neg 的 AUPR 值分别比 Bigram-PSSM、iDTI-ESBoot、NRLMF、BLM-NII、SPLCMF、WNN-GIP、NetLapRLS 和 SELF-BLM 高出 53.5%、24.5%、24.5%、24.5%、42.7%、35.7%、48.3% 和 48.9%（分别为 0.946 对比 0.411、0.701、0.701、0.701、0.533、0.589、0.463 和 0.457）。在这四个数据集中，每种药物与靶点之间的平均相互作用次数在 ICs 中最多，在 NRs 中最少。这表明 ICs 的相互作用网络包含的信息比 NRs 的相互作用网络更多；因此，ICs 的网络相似性更高且更具信息量，而 NRs 包含的“新药候选物”比例最大，ICs 包含的比例最小。

表 4 展示了使用弗里德曼检验对不同方法的 AUC 值进行比较的结果，表明我们的方法表现最佳。表 5 显示这些方法的性能存在显著差异。

表 6 各方法 AUPR 结果比较

订单	方法	平均排名
1	二元语法位置特异性矩阵	1.00
2	iDTI-ES增强型	3.50
3	NRLMF	7.00
4	BLM-NII	6.50
5	SPLCMF	6.75
6	WNN-GIP	3.75
7	NetLapRLS	4.50
8	自我谴责	3.00
9	SSELM 阴性	9.00

表 7 各方法 AUPR 值的弗里德曼检验

方法	卡方（检验）	渐近显著性
弗里德曼检验	26.555	0.001

表 6 展示了使用弗里德曼检验对各方法的 AUPR 值进行比较的结果，我们的方法表现最佳。表 7 显示各方法的性能存在显著差异。根据弗里德曼检验的比较结果，SSELM-neg 是最佳的（如表 4 和表 6 所示）。

预测新相互作用

为了进一步展示 SSELM-neg 预测新药物-靶点相互作用（DTI）的能力，我们将所有负样本输入 SSELM-neg 作为测试集，以预测可能的新 DTI。测试数据集中没有已知的相互作用；因此，我们根据预测的高 DTI 分数（可能是正相互作用，但尚未验证）对它们进行排序，并将预测的高分相互作用置于医学生物数据库和科学文献中进行人工排序，包括 DrugBank、KEGG、PubChem 和 STITCH。在该数据集上进行相互作用预测的 ROC 结果如图 4 所示，经过验证存在相互作用的预测结果列于表 8 中，验证方法在证据列中标注。我们所使用的数据集由山下（Yamanishi）编制。E、IC、GPCR 和 NR 数据集中包含的药物 - 靶点相互作用是几年前从 KEGG 中提取的，为了能够对预测技术进行比较，这些数据未作更改[26]。然而，随着技术的发展，越来越多的药物 - 靶点相互作用（DTIs）已通过实验得到验证，并且其结果在各种生物数据库中得到更新。因此，我们可以将预测的新相互作用与各种国际公共数据库中的内容进行比较。如果预测的新相互作用包含在 KEGG、DrugBank 或其他数据库中，那么我们就认为这种相互作用是有效的。表 8 显示，我们的方法发现了许多有效的相互作用，例如阿立哌唑（D01164）与 5-羟色胺受体 1B（hsa3351）的相互作用；相互作用的




图 4 该数据集交互预测的 ROC 结果

表 8 新药物 - 靶点相互作用的预测结果

药物编号	药品名称	KEGG 编号	目标名称	数据库
D01164	阿立哌唑	hsa3351	5-羟色胺受体 1B	DrugBank
D00066	孕酮	hsa367	雄激素受体	DrugBank
D00182	炔诺酮	hsa367	雄激素受体	DrugBank
D00950	左炔诺孕酮	hsa367	雄激素受体	DrugBank
D00954	炔诺孕酮	hsa367	雄激素受体	DrugBank
D00294	二氮嗪	hsa8911	钙电压门控 通道亚基α1 I	DrugBank
D00294	二氮嗪	hsa8913	钙电压门控 通道亚基α1 G	DrugBank

二氮嗪与钙电压门控通道α1I亚基相互作用；二氮嗪与钙电压门控通道α1G亚基相互作用；以及孕酮（D00066）、炔诺酮（D00182）、左炔诺孕酮（D00950）和炔孕酮（D00954）均作用于雄激素受体（hsa367）。迄今为止用于避孕和绝经期激素治疗的合成孕激素要么源自甾酮（19-去甲甾酮衍生物），要么源自孕酮（17-羟孕酮衍生物和 19-去甲孕酮衍生物）。在 19-去甲甾酮衍生物中，雌甾烷类包括炔诺酮及其代谢产物，而甾烷类则包括左炔诺孕酮及其衍生物[80]。

阿立哌唑 (OPC-14597) 是一种新型非典型抗精神病药物, 据报道其为高亲和力的多巴胺 D2 受体部分激动剂[81]。它对 5-羟色胺 1B 受体具有中等亲和力, 亲和力常数的负对数 (pKi) 在 6 到 7 之间[82]。

讨论与结论

在本研究中, 我们提出了一种基于群体智能算法优化极限学习机 (ELM) 的方法, 称为 SSELN-neg, 该方法通过整合药物-药物相似性、蛋白质-蛋白质相似性以及药物-蛋白质相互作用关系来进行新型药物-蛋白质相互作用预测。我们建立了一个高度可信的负样本数据集, 有效地解决了正负样本之间的类别不平衡问题。我们还通过预测涉及激酶、离子通道、G 蛋白偶联受体和核受体的人类药物-靶点相互作用网络的结果, 证明了 SSELN-neg 的优越性能。

小分子是一种具有多种生物功能的低分子量有机化合物。近年来, 越来越多的证据表明, 将微小核糖核酸 (miRNA) 作为小分子 (SM) 药物的靶点对于疾病治疗具有重要意义[4]。陈等人构建了一个用于预测小分子 - miRNA 关联的有界核范数正则化计算模型, 其中利用 miRNA 相似性构建了一个异质性小分子 - miRNA 网络, 并定义了一个表示该异质性网络的矩阵。王等人[83, 84]提出了一种名为双网络协同矩阵分解的新方法, 用于预测潜在的小分子 - miRNA 关联[85]。这些方法使用 miRNA 的相似性矩阵, 而我们的方法使用编码蛋白质的相似性矩阵; 因此, 我们认为将我们的方法改进以应用 miRNA 理论是可行的。药物 - 靶点结合亲和力预测也是我们未来工作的研究方向。CHEN 等人提出了一种名为基于分子表示块的药物 - 靶点结合亲和力预测 (MRBDTA) 的新模型[86], 该模型在预测严重急性呼吸综合征冠状病毒 2 (SARS-CoV-2) 复制相关蛋白的结合亲和力方面表现出色。在未来的工作中, 我们将专注于预测 miRNA 与药物之间的关系以及药物靶点结合亲和力的预测。

基于机器学习的方法用于识别新的 dti。然而, 该方法的性能和鲁棒性依赖于数据; 因此, 固有知识和有限的负样本严重限制了该计算方法的性能。在我们的研究中, 我们使用药物不相似规则和蛋白质不相似规则对阴性样本进行评分, 并排除得分较低的阴性样本, 即药物与蛋白质之间可能存在相互作用但尚未得到验证的阴性样本。然而, 在 ELM 中, 随机分配的输入权重和隐藏的偏差往往会降低泛化性能。在本研究中, 我们使用 SS 方法分配输入权重和隐藏偏差, 以提供 ELM 的优化参数。因此, 寻找 ELM 的最优网络参数是非常合适的。

实验结果验证了该方法的有效性

在识别药物靶点相互作用方面表现最佳。未来，我们将专注于针对药物靶点相互作用预测的分类器的群体智能优化。

致谢

我们衷心感谢所有在药物靶点数据集建立过程中提供帮助的人。我们感谢 Liwen Bianji（艾丹斯）（www.liwenbianji.cn/）对本稿件初稿的英文文本进行编辑。

作者贡献

胡灵芝、付成洲和唐德玉撰写了主要稿件，任忠禄、蔡永明和杨金准备了实验数据集。胡灵芝、付成洲、徐思文和徐文华进行了实验。所有作者都审阅了稿件。

资金

本研究得到了国家自然科学基金（61976239）和广东省自然科学基金（2020A1515010783）的支持。

数据和材料的可用性

本研究中生成和/或分析的数据集可在 <http://web.kuicr.kyoto-u.ac.jp/supp/yoshi/drugtarget/> 获取。

声明

伦理审批及参与同意书

不适用。

发表同意书

不适用。

利益冲突

作者声明他们不存在利益冲突。

收稿日期：2022 年 10 月 3 日 接受日期：2023 年 1 月 18 日

Published online: 03 February 2023

参考文献

- Dudley JT, Deshpande T, Butte AJ. Exploiting drug–disease relationships for computational drug repositioning. *Brief Bioinform.* 2011;12(4):303–11.
- Swamidass SJ. Mining small-molecule screens to repurpose drugs. *Brief Bioinform.* 2011;12(4):327–35.
- Chen X, Yan CC, Zhang X, Zhang X, Dai F, Yin J, Zhang Y. Drug–target interaction prediction: databases, web servers and computational models. *Brief Bioinform.* 2016;17(4):696–712.
- Chen X, Guan N-N, Sun Y-Z, Li J-Q, Qu J. Microrna-small molecule association identification: from experimental results to computational models. *Brief Bioinform.* 2020;21(1):47–61.
- Hopkins AL. Predicting promiscuity. *Nature.* 2009;462(7270):167–8.
- Lounkine E, Keiser MJ, Whitebread S, Mikhailov D, Hamon J, Jenkins JL, Lavan P, Weber E, Doak AK, Côté S, et al. Large-scale prediction and testing of drug activity on side-effect targets. *Nature.* 2012;486(7403):361–7.
- Pauwels E, Stoven V, Yamanishi Y. Predicting drug side-effect profiles: a chemical fragment-based approach. *BMC Bioinform.* 2011;12(1):1–13.
- Whitebread S, Hamon J, Bojanic D, Urban L. Keynote review: in vitro safety pharmacology profiling: an essential tool for successful drug development. *Drug Discov Today.* 2005;10(21):1421–33.
- Haggarty SJ, Koeller KM, Wong JC, Butcher RA, Schreiber SL. Multidimensional chemical genetic analysis of diversity-oriented synthesis-derived deacetylase inhibitors using cell-based assays. *Chem Biol.* 2003;10(5):383–96.
- Manly CJ, Louise-May S, Hammer JD. The impact of informatics and computational chemistry on synthesis and screening. *Drug Discov Today.* 2001;6(21):1101–10.
- Li J, Zheng S, Chen B, Butte AJ, Swamidass SJ, Lu Z. A survey of current trends in computational drug repositioning. *Brief Bioinform.* 2016;17(1):2–12.
- Yue Y, He S. Dti-hene: a novel method for drug–target interaction prediction based on heterogeneous network embedding. *BMC Bioinform.* 2021;22(1):1–20.
- Keiser MJ, Roth BL, Armbruster BN, Ernsberger P, Irwin JJ, Shoichet BK. Relating protein pharmacology by ligand chemistry. *Nat Biotechnol.* 2007;25(2):197–206.
- Ezzat A, Wu M, Li X-L, Kwok C-K. Computational prediction of drug–target interactions using chemogenomic approaches: an empirical survey. *Brief Bioinform.* 2019;20(4):1337–57.
- Li H, Gao Z, Kang L, Zhang H, Yang K, Yu K, Luo X, Zhu W, Chen K, Shen J, et al. Tarfisdock: a web server for identifying drug targets with docking approach. *Nucleic Acids Res.* 2006;34(suppl 2):219–24.
- Pujadas G, Vaque M, Ardevol A, Blade C, Salvado M, Blay M, Fernandez-Larrea J, Arola L. Protein-ligand docking: a review of recent advances and future perspectives. *Curr Pharm Anal.* 2008;4(1):1–19.
- Cheng AC, Coleman RG, Smyth KT, Cao Q, Souillard P, Caffrey DR, Salzberg AC, Huang ES. Structure-based maximal affinity model predicts small-molecule druggability. *Nat Biotechnol.* 2007;25(1):71–5.
- Hendrickson JB. Concepts and applications of molecular similarity. *Science.* 1991;252(5009):1189–90.

19. Jacob L, Vert J-P. Protein–ligand interaction prediction: an improved chemogenomics approach. *Bioinformatics*. 2008;24(19):2149–56.
20. Ban T, Ohue M, Akiyama Y. Nrlmf β : Beta-distribution-rescored neighborhood regularized logistic matrix factorization for improving the performance of drug–target interaction prediction. *Biochem Biophys Rep*. 2019;18: 100615.
21. Wang A, Wang M. Drug–target interaction prediction via dual Laplacian graph regularized logistic matrix factorization. *BioMed Res Int*. 2021;66:2021.
22. Li L, Cai M. Drug target prediction by multi-view low rank embedding. *IEEE/ACM Trans Comput Biol Bioinform*. 2017;16(5):1712–21.
23. Yamanishi Y, Araki M, Gutteridge A, Honda W, Kanehisa M. Prediction of drug–target interaction networks from the integration of chemical and genomic spaces. *Bioinformatics*. 2008;24(13):232–40.
24. Mei J-P, Kwoh C-K, Yang P, Li X-L, Zheng J. Drug–target interaction prediction by learning from local information and neighbors. *Bioinformatics*. 2013;29(2):238–45.
25. Bleakley K, Biau G, Vert J-P. Supervised reconstruction of biological networks with local models. *Bioinformatics*. 2007;23(13):57–65.
26. Buza K, Peñalosa L. Drug–target interaction prediction with bipartite local models and hubness-aware regression. *Neurocomputing*. 2017;260:284–93.
27. Buza K. Drug–target interaction prediction with hubness-aware machine learning. In: 2016 IEEE 11th International Symposium on Applied Computational Intelligence and Informatics (SACI). IEEE; 2016. p. 437–40.
28. Buza K, Nanopoulos A, Nagy G. Nearest neighbor regression in the presence of bad hubs. *Knowl Based Syst*. 2015;86:250–60.
29. Zong N, Kim H, Ngo V, Harismendy O. Deep mining heterogeneous networks of biomedical linked data to predict novel drug–target associations. *Bioinformatics*. 2017;33(15):2337–44.
30. Pahikkala T, Airola A, Pietilä S, Shakyawar S, Szwarda A, Tang J, Aittokallio T. Toward more realistic drug–target interaction predictions. *Brief Bioinform*. 2015;16(2):325–37.
31. Gawehn E, Hiss JA, Schneider G. Deep learning in drug discovery. *Mol Inform*. 2016;35(1):3–14.
32. Ekins S. The next era: deep learning in pharmaceutical research. *Pharm Res*. 2016;33(11):2594–603.
33. Hinton GE, Salakhutdinov RR. Reducing the dimensionality of data with neural networks. *Science*. 2006;313(5786):504–7.
34. Wen M, Zhang Z, Niu S, Sha H, Yang R, Yun Y, Lu H. Deep-learning-based drug–target interaction prediction. *J Proteome Res*. 2017;16(4):1401–9.
35. Lee I, Keum J, Nam H. Deepconv-dti: prediction of drug–target interactions via deep learning with convolution on protein sequences. *PLoS Comput Biol*. 2019;15(6):1007129.
36. You J, McLeod RD, Hu P. Predicting drug–target interaction network using deep learning model. *Comput Biol Chem*. 2019;80:90–101.
37. Rifaioglu AS, Atas H, Martin MJ, Cetin-Atalay R, Atalay V, Doğan T. Recent applications of deep learning and machine intelligence on in silico drug discovery: methods, tools and databases. *Brief Bioinform*. 2019;20(5):1878–912.
38. Bock JR, Gough DA. Virtual screen for ligands of orphan G protein-coupled receptors. *J Chem Inf Model*. 2005;45(5):1402–14.
39. Nagamine N, Sakakibara Y. Statistical prediction of protein–chemical interactions based on chemical structure and mass spectrometry data. *Bioinformatics*. 2007;23(15):2004–12.
40. Shen C, Ding Y, Tang J, Xu X, Guo F. An ameliorated prediction of drug–target interactions based on multi-scale discrete wavelet transform and network features. *Int J Mol Sci*. 2017;18(8):1781.
41. Mousavian Z, Khakabimamaghani S, Kavousi K, Masoudi-Nejad A. Drug–target interaction prediction from pssm based evolutionary information. *J Pharmacol Toxicol Methods*. 2016;78:42–51.
42. Liu H, Sun J, Guan J, Zheng J, Zhou S. Improving compound–protein interaction prediction by building up highly credible negative samples. *Bioinformatics*. 2015;31(12):221–9.
43. Xia Z, Zhou X, Sun Y, Wu L. Semi-supervised drug–protein interaction prediction from heterogeneous spaces. In: The third international symposium on optimization and systems biology, vol 11; 2009. p. 123–31.
44. Ezzat A, Zhao P, Wu M, Li X-L, Kwoh C-K. Drug–target interaction prediction with graph regularized matrix factorization. *IEEE/ACM Trans Comput Biol Bioinform*. 2016;14(3):646–56.
45. Gönen M. Predicting drug–target interactions from chemical and genomic kernels using Bayesian matrix factorization. *Bioinformatics*. 2012;28(18):2304–10.
46. Luo Y, Zhao X, Zhou J, Yang J, Zhang Y, Kuang W, Peng J, Chen L, Zeng J. A network integration approach for drug–target interaction prediction and computational drug repositioning from heterogeneous information. *Nat Commun*. 2017;8(1):1–13.
47. Chen X, Liu M-X, Yan G-Y. Drug–target interaction prediction by random walk on the heterogeneous network. *Mol Biosyst*. 2012;8(7):1970–8.
48. Seal A, Ahn Y-Y, Wild DJ. Optimizing drug–target interaction prediction based on random walk on heterogeneous networks. *J Cheminform*. 2015;7(1):1–12.
49. Alaimo S, Pulvirenti A, Giugno R, Ferro A. Drug–target interaction prediction through domain-tuned network-based inference. *Bioinformatics*. 2013;29(16):2004–8.
50. Wu Y, Zhang Y, Liu X, Cai Z, Cai Y. A multiobjective optimization-based sparse extreme learning machine algorithm. *Neurocomputing*. 2018;317:88–100.
51. Ding H, Takigawa I, Mamitsuka H, Zhu S. Similarity-based machine learning methods for predicting drug–target interactions: a brief review. *Brief Bioinform*. 2014;15(5):734–47.
52. Bagherian M, Sabeti E, Wang K, Sartor MA, Nikolovska-Coleska Z, Najarian K. Machine learning approaches and databases for prediction of drug–target interaction: a survey paper. *Brief Bioinform*. 2021;22(1):247–69.
53. You J, Robert D, Pingzhao M. Predicting drug–target interaction network using deep learning model. *Comput Biol Chem*. 2019;6:66.
54. Bleakley K, Yamanishi Y. Supervised prediction of drug–target interactions using bipartite local models. *Bioinformatics*. 2009;6:66.

55. Ghanbari Sorkhi A, Iranpour Mobarakeh M, Hashemi SMR, Faridpour M. Predicting drug–target interaction based on bilateral local models using a decision tree-based hybrid support vector machine. *Int J Nonlinear Anal Appl.* 2021;12(2): 135–44.
56. Lan W, Wang J, Li M, Liu J, Li Y, Wu F-X, Pan Y. Predicting drug–target interaction using positive-unlabeled learning. *Neurocomputing.* 2016;206:50–7.
57. Jiang J, Wang N, Chen P, Zhang J, Wang B. Drugecs: an ensemble system with feature subspaces for accurate drug– target interaction prediction. *BioMed Res Int.* 2017;6:66.
58. Manoochehri HE, Nourani M. Predicting drug–target interaction using deep matrix factorization. In: 2018 IEEE biomedical circuits and systems conference (BioCAS). IEEE; 2018. p. 1–4.
59. Cao D-S, Zhang L-X, Tan G-S, Xiang Z, Zeng W-B, Xu Q-S, Chen AF. Computational prediction of drug target interactions using chemical, biological, and network features. *Mol Inform.* 2014;33(10):669–81.
60. Shi H, Liu S, Chen J, Li X, Ma Q, Yu B. Predicting drug–target interactions using lasso with random forest based on evolutionary information and chemical structure. *Genomics.* 2019;111(6):1839–52.
61. Wang G, Zhao Y, Wang D. A protein secondary structure prediction framework based on the extreme learning machine. *Neurocomputing.* 2008;72(1–3):262–8.
62. Mohammed AA, Minhas R, Wu QJ, Sid-Ahmed MA. Human face recognition based on multidimensional pca and extreme learning machine. *Pattern Recognit.* 2011;44(10–11):2588–97.
63. Han K, Yu D, Tashev I. Speech emotion recognition using deep neural network and extreme learning machine. In: *Interspeech* 2014;2014.
64. Bi X, Ma H, Li J, Ma Y, Chen D. A positive and unlabeled learning framework based on extreme learning machine for drug– drug interactions discovery. *J Ambient Intell Human Comput.* 2018;66:1–12.
65. An J-Y, Meng F-R, Yan Z-J. An efficient computational method for predicting drug–target interactions using weighted extreme learning machine and speed up robot features. *BioData Min.* 2021;14(1):1–17.
66. Huang G-B, Zhu Q-Y, Siew C-K. Extreme learning machine: a new learning scheme of feedforward neural networks. In: 2004 IEEE international joint conference on neural networks (IEEE Cat. No. 04CH37541), vol 2. IEEE; 2004. p. 985–90.
67. Kumar A, Misra RK, Singh D, Mishra S, Das S. The spherical search algorithm for bound-constrained global optimization problems. *Appl Soft Comput.* 2019;85: 105734.
68. Tanabe R, Fukunaga AS. Improving the search performance of shade using linear population size reduction. In: 2014 IEEE congress on evolutionary computation (CEC). IEEE; 2014. p. 1658–65.
69. Wishart DS, Knox C, Guo AC, Cheng D, Shrivastava S, Tzur D, Gautam B, Hassanali M. Drugbank: a knowledgebase for drugs, drug actions and drug targets. *Nucleic Acids Res.* 2008;36(suppl 1):901–6.
70. Günther S, Kuhn M, Dunkel M, Campillos M, Senger C, Petsalaki E, Ahmed J, Urdiales EG, Gewiess A, Jensen LJ, et al. Supertarget and matador: resources for exploring drug–target relationships. *Nucleic Acids Res.* 2007;36(suppl 1):919–22.
71. Kanehisa M, Goto S, Hattori M, Aoki-Kinoshita KF, Itoh M, Kawashima S, Katayama T, Araki M, Hirakawa M. From genomics to chemical genomics: new developments in Kegg. *Nucleic Acids Res.* 2006;34(suppl 1):354–7.
72. Schomburg I, Chang A, Ebeling C, Gremse M, Heldt C, Huhn G, Schomburg D. Brenda, the enzyme database: updates and major new developments. *Nucleic Acids Res.* 2004;32(suppl 1):431–3.
73. Hattori M, Okuno Y, Goto S, Kanehisa M. Development of a chemical structure comparison method for integrated analysis of chemical and genomic information in the metabolic pathways. *J Am Chem Soc.* 2003;125(39):11853–65.
74. Smith TF, Waterman MS, et al. Identification of common molecular subsequences. *J Mol Biol.* 1981;147(1):195–7.
75. Rayhan F, Ahmed S, Shatabda S, Farid DM, Mousavian Z, Dehzangi A, Rahman MS. idi-esboost: identification of drug target interaction using evolutionary and structural features with boosting. *Sci Rep.* 2017;7(1):1–18.
76. Liu Y, Wu M, Miao C, Zhao P, Li X-L. Neighborhood regularized logistic matrix factorization for drug–target interaction prediction. *PLoS Comput Biol.* 2016;12(2):1004760.
77. Keum J, Nam H. Self-blml: prediction of drug–target interactions via self-training svm. *PLoS ONE.* 2017;12(2):0171839.
78. Xia L-Y, Yang Z-Y, Zhang H, Liang Y. Improved prediction of drug–target interactions using self-paced learning with collaborative matrix factorization. *J Chem Inf Model.* 2019;59(7):3340–51.
79. Luo H, Li M, Yang M, Wu F-X, Li Y, Wang J. Biomedical data and computational models for drug repositioning: a comprehensive review. *Brief Bioinform.* 2021;22(2):1604–19.
80. Sitruk-Ware R. Reprint of pharmacological profile of progestins. *Maturitas.* 2008;61(1–2):151–7.
81. Shapiro DA, Renock S, Arrington E, Chiodo LA, Liu L-X, Sibley DR, Roth BL, Mailman R. Aripiprazole, a novel atypical antipsychotic drug with a unique and robust pharmacology. *Neuropsychopharmacology.* 2003;28(8):1400–11.
82. Nasrallah H. Atypical antipsychotic-induced metabolic side effects: insights from receptor-binding profiles. *Mol Psychiatry.* 2008;13(1):27–35.
83. Wang S-H, Wang C-C, Huang L, Miao L-Y, Chen X. Dual-network collaborative matrix factorization for predicting small molecule-miRNA associations. *Brief Bioinform.* 2022;23(1):66.
84. Wang C-C, Zhu C-C, Chen X. Ensemble of kernel ridge regression-based small molecule-miRNA association prediction in human disease. *Brief Bioinform.* 2022;23(1):66.
85. Chen X, Zhou C, Wang C-C, Zhao Y. Predicting potential small molecule-miRNA associations based on bounded nuclear norm regularization. *Brief Bioinform.* 2021;22(6):66.
86. Zhang L, Wang C-C, Chen X. Predicting drug–target binding affinity through molecule representation block based on multi-head attention and skip connection. *Brief Bioinform.* 2022;23(6):66.

出版者按

施普林格·自然对于已发表地图中的司法管辖区主张以及机构归属关系保持中立。