



基于图神经网络的药物-靶点相互作用及亲和力预测方法综述

Yue Zhang ^{a,*}, Yuqing Hu ^a, Na Han ^a, Aqing Yang ^a, Xiaoyong Liu ^a, Hongmin Cai ^b

^a 中国广州, 广东第二师范学院计算机科学学院, 邮编: 510665

^b 华南理工大学计算机科学与工程学院, 中国广州, 510006

文章信息

索引词:

药物-靶点相互作用 药
物-靶点亲和力 图神经
网络 深度学习

摘要

药物靶点相互作用 (DTI) 和药物靶点亲和力 (DTA) 预测任务在药物发现领域发挥着重要作用。然而, 基于生物实验的方法耗时且成本高昂。近年来, 基于计算的方法加快了药物靶点关系预测的进程。药物和靶点特征以基于结构、基于序列和基于图的方式进行表示。尽管在基于结构的表示和基于序列的表示方面已取得了一些成果, 但所获取的特征信息还不够丰富。基于分子图的表示是一些较为流行的方法, 并且也引起了极大的关注。在本文中, 我们基于图神经网络 (GNNs) 对 DTI 预测和 DTA 预测任务进行了概述。我们简要讨论了药物的分子图、靶点蛋白质的一级序列以及靶点蛋白质的图表示。同时, 我们在多个基础数据集上进行了实验, 以证实利用图神经网络进行 DTI 和 DTA 的合理性。

1. 简介

美国食品药品监督管理局 (FDA) 对一种新药的批准或否决需要 10 至 17 年的时间, 且成本约为 26 亿美元[1-4]。因此, 药物研发极具挑战性, 一旦失败, 损失巨大[5]。随着对上市药物监管的日益严格, 进入市场的新型药物数量持续减少。因此, 一种高效的筛选技术应运而生——药物再利用和再定位。药物再利用和再定位能够为已获批药物找到新的用途, 加快药物研发进程, 并降低研发的财务和时间成本[6]。因此, 上市药物如何与新靶点相互作用以及如何高精度预测药物靶点相互作用 (DTIs) 已成为备受关注的话题。

尽管基于生物试验的方法 (例如高通量筛选实验) 在预测药物靶点相互作用方面可能有效, 但它们过于繁琐, 需要耗费大量资金和时间。

[7]. 同时, 数以百万计的药物化合物的存在

[8] 而且成百上千的潜在目标使得这项技术难以实现。近年来, 生物信息学数据库积累

了大量的生物实验数据。计算方法的出现正是由于这些海量数据的存在。

配体是与蛋白质结合的物质。传统的计算方法大致分为两类: 基于配体的方法和基于结构的方法。基于配体的方法[9]假定具有相似化学特性的配体也具有相似的生物活性, 并且能够与相似的目标蛋白质结合[10-13]。这种方法依赖于目标配体的信息, 而非目标蛋白质的结构和数据。然而, 当配体数量过少时, 预测目标的准确性会降低。基于结构的方法的一个典型例子是对接模拟[14]。通过分子对接和分子动力学模拟, 利用药物分子和目标蛋白质的三维结构来预测药物与目标蛋白质的结合强度[15-18]。这种方法能够实现准确预测, 但在实际操作中非常耗时。

基于序列的方法是计算生物学中的热门研究课题。随着深度学习的发展, 许多早期研究采用神经网络框架来提取蛋白质序列和药物分子的特征。与传统机器学习方法相比, 深度学习能够更好地学习潜在的

* Corresponding author. School of Computer Science, Guangdong Polytechnic Normal University, Guangzhou, China. E-mail address: zhangyue@gpnu.edu.cn (Y. Zhang).

<https://doi.org/10.1016/j.combiomed.2023.107136>

Received 11 March 2023; Received in revised form 29 May 2023; Accepted 4 June 2023 Available online 7 June 2023

0010-4825/© 2023 Elsevier Ltd. All rights reserved.

药物与靶点蛋白质的特征。基于序列的方法将药物与靶点之间的关系分为两类：**药物靶点相互作用（DTIs）和药物靶点亲和力（DTAs）**。**DTI 预测是一个二分类任务，用于确定药物与靶点是否相互作用，也是 DTA 预测的一种简化形式。**例如，Transformer CPI [19] 利用 Transformer 技术挖掘药物和蛋白质序列数据以进行 DTI 预测。NeoDTI [20] 利用异构网络中的数据来保留药物和蛋白质的拓扑结构以进行 DTI 预测。[21] 采用卷积神经网络（CNN）技术获取药物和蛋白质序列的局部特征以进行 DTI 预测。**DTA 预测是一个回归任务，与 DTI 预测不同，其预测过程会得出连续值。**DeepDTA [22] 采用两个 CNN 来学习药物分子和蛋白质序列的特征以进行 DTA 预测。另外添加了两个 CNN 分别学习蛋白质结构域和基序（PDMs）以及配体最大公共子结构（LMCSs）的特征。WideDTA [23] 是 DeepDTA 的改进版本。为了捕捉药物和蛋白质序列的潜在特征以进行亲和力预测，Co-VAE [24] 采用了变分自编码技术。**尽管基于序列的方法已取得一定成效，但它们忽略了药物和蛋白质分子的拓扑结构。**

仅使用卷积神经网络（CNN）技术不足以捕捉药物和蛋白质的序列信息。重要的是要考虑每个原子之间的关系，并自动为其分配不同的权重和注意力。注意力机制已成为解决这一挑战的有前景的方法。近年来，基于注意力机制的众多药物-靶点相互作用（DTI）预测方法被提出，并取得了显著成果。例如，AttentionSiteDTI [25] 利用药物与靶点之间的结构信息构建图，结合自然语言处理（NLP）技术处理文本数据中的关系信息，并应用注意力机制对图中不同节点和边的重要性进行加权。DrugBAN [26] 引入了一种基于双线性注意力网络的模型，以捕捉特征之间的相互作用，并使用注意力机制对不同特征的重要性进行加权。此外，该模型还结合了领域自适应技术，通过适应不同领域的数据来提高预测性能。HyperAttentionDTI [27] 利用卷积神经网络（CNN）和注意力机制来学习药物和靶点的特征，并为每个原子和氨基酸分配注意力向量以进行加权表示。FusionDTA [28] 采用基于注意力的特征融合模块来结合药物和靶点的特征表示，生成更具信息量的特征表示。此外，它还利用知识蒸馏来结合多个模型的预测结果，进一步提高预测的准确性和鲁棒性。

基于矩阵分解的方法是计算药物 - 靶点相互作用（DTI）预测模型中的关键技能。**矩阵分解和矩阵补全技术已在药物再定位和靶点预测任务中得到广泛应用。它们将药物 - 靶点关联矩阵映射到低维表示，从而提取低维特征。具体方法是在 DTI 预测任务中通过矩阵分解将相互作用矩阵分解为药物和靶点的两个低维特征矩阵。这种方法引起了相当大的关注。**例如，DTINet [29] 利用各种药物相关信息构建异质网络，以学习特征的低维向量表示，从而实现 DTI 的预测。NRLMF [30] 引入正则化以纳入邻域信息，促使相似的药物和靶点在特征空间中保持接近。它通过矩阵分解建模 DTI 的概率，以实现准确预测。NRLMF β [31] 在 NRLMF 的基础上解决了 DTI 样本信息有限时预测不准确的问题。KBMF2K [32] 将药物和靶点信息转换为核矩阵，并采用贝叶斯矩阵分解将

核矩阵分解为两个低维特征矩阵，从而获得药物和靶点的潜在表示。SPLCMF [33] 利用自步学习策略逐步选择训练样本并控制特征学习过程，从而提高模型的泛化能力和预测精度。它使用协同矩阵分解技术来预测药物-靶点相互作用。

这些基于矩阵分解的方法在药物 - 靶点相互作用预测方面表现出了令人鼓舞的性能，为药物开发和靶点发现提供了宝贵的见解。通过整合各种数据源并利用先进的技术，这些方法推动了药物 - 靶点相互作用预测领域计算方法的发展。

神经网络学习已在计算机视觉、推荐系统、社交网络分析等领域得到广泛应用。例如，MCSSC [34] 通过为每个视图构建网络来解决不同视图的异质性和结构约束问题，将多视图聚类问题转化为多层网络聚类问题，从而提高了实验精度。网络学习也已应用于生物信息学领域。SLNMF [35] 利用基于网络的结构学习非负矩阵分解，通过细胞间的相互作用来推断细胞类型和轨迹。它基于细胞间的关系建立相似性网络，然后利用细胞网络的拓扑结构提取细胞的潜在特征。TANMF [36] 在时间癌症网络的动态模块中整合了异质性基因组数据，通过向时间网络添加基因属性，不仅利用了网络的拓扑结构，还整合了多模态数据。在 LSNMF [37] 的多层网络中，每一层代表一个数据源，例如基因表达和 DNA 甲基化。它结合了网络表示学习和非负矩阵分解技术，用于检测癌症多层网络中的特定层模块。NMF-DEC [38] 将相互作用组和转录组数据整合起来，构建基因属性的相似性网络，并通过分解相似性网络和相互作用网络来研究基因属性与网络拓扑结构之间的关系。

近期，图神经网络（GNN）[39]在生物信息学领域取得了一定的成功，展现出处理非欧几里得空间数据的卓越能力，效率显著。通过利用节点内在信息及其相互依赖关系，这些网络能够精准提取有价值的特征信息，从而实现对顶点或边的准确识别与预测。同时，由于生物信息数据具有很强的相关性和多样性，分子图非常适合用于生物信息的表示，尤其是分子结构和分子间功能关系的表示。GNN 模型是识别分子特征最有效的方法。GNN 通过聚合邻域信息来学习网络的局部和全局信息。我们将从三个不同方面总结药物分子图和蛋白质图。

1. 图是描述药物分子最有效的方式，我们在此总结了通过图神经网络对药物 - 靶点相互作用及亲和力进行预测的相关内容。
2. 我们根据分子特征的表示方式，利用蛋白质图、药物分子图和蛋白质的一级序列来进行描述。
3. 我们将基于图神经网络的药物 - 靶点相互作用及亲和力预测分为以下三类：基于分子药物图和蛋白质序列的相互作用预测、基于分子药物图和蛋白质序列的亲和力预测以及基于分子药物图和蛋白质图的相互作用和亲和力预测。

2. 药物与靶蛋白的表示形式

2.1. 药物的图示表示

药物序列能够代表药物的信息。简化分子线性输入规范 (SMILES) [40] 是一种常见的药物描述方法, 它使用一维 ASCII 字符串来描述药物的三维化学结构。近来, 许多方法被开发出来以将非欧几里得结构数据应用于图神经网络 (GNNs) [41-45]。例如, 图卷积网络 (GCNs)、图注意力网络 (GATs)、图自编码器 (GAEs)、图生成网络和图时空网络等。在生物信息学领域, 数据分析表明药物分子的分子图非常适合用于图神经网络。通过使用 RDKit [46] 技术 (一种开源化学软件), 药物的 SMILES 可以转换为分子图 $G = (V, E)$, 其中 V 表示药物中的原子集合, 即图的节点, E 表示原子之间的化学键, 即图的边, 以邻接矩阵的形式呈现。药物的 SMILES 转换为分子图的过程如图 1 所示。

在获得药物分子中每个原子的关系图之后, 需要为每个原子节点分配特征以进行进一步处理。图中的每个节点都可以使用由五个特征组成的特征向量来描述: 原子符号、原子的度 (即相邻原子和相邻氢原子数量之和)、氢原子总数、原子的隐式氢原子数以及该原子是否为芳香族原子。这五个特征共同构成一个 78 维的向量, 每个特征占用的维度数如表 1 所示。除了节点的原子符号外, 其余四个特征均为原子常用的化学特征, 使用 RDKit 可以轻松获取。获取原子的独热特征向量的详细过程如表 2 所示, 其中给出了伪代码。

2.2. 蛋白质的一级序列表示

蛋白质由氨基酸组成, 其三维及高维结构难以获取和表示。文献中最常见的方法是利用蛋白质的一级结构: 氨基酸序列。氨基酸序列以文本形式存在, 这在某种程度上类似于自然语言处理 (NLP) 的任务 [47]。卷积神经网络 (CNNs) [48]、长短期记忆网络 (LSTM) [49]、门控循环单元 (GRUs) [50]、Word2Vec [51,52] 以及双向编码器表示来自转换器的模型 (BERT) [53] 是提取文本特征的常用方法, 也适用于获取蛋白质序列信息。序列

蛋白质的表示形式是
如图 2 所示。

2.3. 蛋白质的图表示

蛋白质最常用的分子表示形式是其一级序列, 但如果能采用蛋白质图, 则预测的准确性会有所提高。用整个蛋白质来构建图会导致图结构复杂且训练时间过长, 因为

表 1

药物分子图中对原子特征的描述。

原子特征	维度
原子类型	44
原子度	11
氢原子的总数	11
该原子的隐式氢原子数	11
该原子是否具有芳香性	1
所有	78

蛋白质包含大量的原子。反映蛋白质高维结构的接触图可用于揭示蛋白质残基之间的相互作用。一个蛋白质仅有几百个残基, 这非常适合构建蛋白质图。蛋白质图的构建流程如图 3 所示。此外, 我们还在蛋白质图中引入了节点特征。

蛋白质结构信息包含不同残基对之间的角度和距离, 而接触图是结构预测的结果。通常, 如果欧几里得空间中两个残基的 C_α 原子之间的距离小于某个阈值 [54], 则认为它们相互接触。可以使用 Pcons4 这种开源且高效的工具来预测接触图。此外, 进化尺度模型 (ESM) 也可以用于预测接触图, 且无需蛋白质序列比对, 从而节省比对时间。接下来, 通过使用 0.5 的阈值生成相应的邻接矩阵, 可以得到蛋白质图。在这个图中, 残基代表节点, 残基之间的关系由邻接矩阵表示。为了获得图中每个节点的特征, 还需要进一步处理。每个残基节点的特征由其包含的不同 R 功能团决定。每个节点的特征通过其疏水性、极性、电荷和芳香性来表示, 如表 3 所示。

3. 方法

药物与靶点之间的关系可分为两类: 药物靶点相互作用 (DTIs) 和药物靶点结合 (DTAs)。

3.1. 基于分子药物图和蛋白质序列的相互作用预测

目前最典型且有效的预测方法是

关键在于将药物分子视为图。此类方法利用蛋白质的一级结构是目前最常用的技术。例如 CPGL [49]、GanDTI [55]、GraphCPI [56]、MGraphDTA [57]、SAG-DTA [58]、WGNN-DTA [59]。GanDTI、GraphCPI、MGraphDTA、SAG-DTA、TransformerCPI 以及 [60] 通过 RDKit 技术将药物的 SMILES 转换为分子图 $G = (V, E)$ 。分子图的特征表示通过 GNN (例如 GCN、GAT、图同构网络 (GIN) 等) 进行学习。蛋白质特征则通过不同的技术进行处理。N-gram [61] 分词技术被 GanDTI、GraphCPI 和 TransformerCPI 应用, 该技术将蛋白质序列分割成“生物词”, 以增强语义分析。GanDTI 包含一种技术, 可将注意力集中在与目标药物相互作用最有利的蛋白质区域。GraphCPI 利用 Prot2Vec [62] 将蛋白质序列转换为矩阵, 然后输入到 CNN 中进行特征训练。TransformerCPI 将蛋白质序列提供给 Transformer 的编码层, 以便其学习隐藏表示。SAG-DTA 将全局池化和分层池化以及自注意力方法融入分子图特征提取过程, 以获得具有丰富药物特征表示的两种药物表示。浅层模型不足以捕捉全局特征。受 DenseNet [63] 的启发, 提出了 MGraphDTA 作为深度网络模型, 该模型采用深度结构。




图 1. 药物的简化分子线性输入规范 (SMILES) 被转换为分子图 (序列: CC(=O)NC1=CC=C(O)C=C1)

表 2 获得原子特征向量

量输入:	The SMILES sequence of the molecule S.
代输出:	The atomic feature vector V and the adjacency matrix E of the molecule.
Begin	Obtain the chemical structure mol of S using the MolFromSmiles() function; Obtain the atom set $A_{set} = [a^{(1)}, a^{(2)}, \dots, a^{(n)}]$ corresponding to the molecule mol using the function GetAtoms(); For each atom $a^{(i)}$ in A_{set} do Use the GetSymbol() function to obtain the atomic symbol $f_1^{(i)}$ of $a^{(i)}$; Use the GetDegree() function to obtain the degree $f_2^{(i)}$ of $a^{(i)}$; Use the GetTotalNumHs() function to obtain the total number of hydrogen atoms $f_3^{(i)}$ of $a^{(i)}$; Use the GetImplicitValence() function to obtain the implicit valence $f_4^{(i)}$ of $a^{(i)}$; If $a^{(i)}$ is aromatic do set $f_5^{(i)} = 1$; Else set $f_5^{(i)} = 0$; End if Concatenate the five vectors to obtain the feature vector $V^{(i)}$ for each atom; Add $V^{(i)}$ to V. End for Obtain the edge set $B_{set} = [b^{(1)}, b^{(2)}, \dots, b^{(m)}]$ corresponding to the molecule mol using the function GetBonds(); For each bond $b^{(i)}$ in B_{set} do Get the two end atoms $e_1^{(i)}$ and $e_2^{(i)}$ of the bond $b^{(i)}$ through the function GetEndAtomIdx(); Add $e_1^{(i)}$ and $e_2^{(i)}$ to E. End for End




图 2. 蛋白质的序列表示。本研究使用的蛋白质是酪氨酸蛋白激酶 ABL1 (P00519)，其氨基酸序列长度为 1130。图中所示的氨基酸序列代表该蛋白质序列的前十个字符。

针对药物分子和蛋白质序列的网络学习特征。在小数据集上表现出色的模型在大数据集上可能表现不佳，这是由于可用的蛋白质资源匮乏所致。因此，[60] 对大量蛋白质进行了基于转换器的预训练。

CPGL 和 [64] 利用子图来增强表示学习过程。原子和化学键类型的较少使得在学习特征时有可能忽略关键信息。 R 半径子图 [65] 已被引入作为解决此问题的方法，其中图的顶点聚合了半径 r 内所有相邻顶点和边的数据，如图 4 所示，其中 $r = 1$ 表示顶点 i 的一阶邻居（如顶点 j ）， $r =$

2 表示顶点 i 的二阶邻居（如顶点 k ）。基于一级结构的序列被用于表示蛋白质。为了在文本序列中保持空间上相似的氨基酸处于相同的距离，CPGL 利用 LSTM 处理氨基酸序列信息。LSTM 解决了较长序列中的长期依赖问题，使其非常适合氨基酸的文本序列。[64] 采用了 N -gram 分词，并添加了注意力机制来学习特征表示。

3.2. 基于分子药物图谱和蛋白质序列的亲合力预测

药物与靶点之间存在相互作用这一情况对专家而言或许具有指导意义，但仍然过于简单化。另一方面，能够预测特定药物与靶点的关联值对药物研发团队可能更有帮助。这一任务被称为“药物靶点亲和力预测”。

药物靶点相互作用（DTA）预测方面也取得了显著进展。本节将对药物的分子图和靶点序列的一级结构进行描述。将药物字符串转换为分子图仍是常见的操作，而大多数蛋白质包含序列文本信息。GraphDTA [66] 在图神经网络（GCN、GAT 或 GIN）下使用分子图来获取高级特征。对于蛋白质，采用卷积神经网络（CNN）来学习其隐藏特征。基于这一理念，衍生出了许多方法。例如，DeepGLSTM [67] 和 GDGRU-DTA [50] 均使用长短期记忆网络（LSTM）来学习蛋白质处理的隐藏特征，LSTM 更适用于长序列的文本信息处理。在分子图的处理方面，DeepGLSTM 结合多个 GCN 来学习多种药物特征，而 GDGRU-DTA 不仅采用 GNN，还利用了




图 3. 蛋白质图的构建。蛋白质序列通过开源方法 Pcons4 或 ESM 模型处理以预测接触图。接触图矩阵中的每个值代表两个残基之间的接触程度。然后，通过使用阈值 (0.5) 获得过滤后的接触图矩阵，以满足图神经网络的输入要求。最后，得到蛋白质图，以及各残基之间的连接关系。

图中的每个节点都可以从“过滤器”接触图中推断出来。

表 3
蛋白质图中的残基特征。

节点特征	维度
残基的一热编码	21
PSSM	21
Whether 是脂肪族的吗	1
是否有芳香气味	1
Whether is 极性中性	1
是否带酸性电荷	1
是否基本收费	1
残余重量	1
-COOH 基团的解离常数	1
-NH3基团的解离常数	1
分子中任何其他基团的解离常数	1
等电点的 pH 值	1
疏水性 (pH = 2)	1
疏水性 (pH = 7)	1
所有	54

双向门控循环单元（GRU）[68]用于提取药物特征。GRU 是长短期记忆网络（LSTM）的一种变体，其内部结构更简单，处理相同任务的速度比 LSTM 更快。因此，GDGRU-DTA 采用 GRU 来提取蛋白质的特征。受 Word2Vec 的启发，[51] 使用卷积神经网络（CNN）提取蛋白质特征，并采用 *N-gram* 分词将蛋白质序列转换为有意义的“生物词”。由于氨基酸和药物序列中的上下文信息未被考虑，DeepGS [69] 分别利用 Prot2Vec [62] 和 Smi2Vec [70] 来表征这两种序列信息，同时通过 CNN 和双向 GRU 提取局部信息。之后，将通过分子药物图获得的特征与这些信息相结合进行预测。由于一热编码蛋白质会降低原子之间的相关性，[71] 从自然语言处理中引入了词频-逆文档频率（TF-IDF）[47] 算法来增强蛋白质。GraphDTA 方法已被实现用于构建药物分子图。EmbedDTI [72] 利用两个图来描述药物的化学结构，并推断其全局和局部结构。蛋白质特征通过卷积神经网络（CNN）不断学习。MGraphDTA [57] 即使浅层模型效果更佳，也探索了更深层的网络。作者受 DenseNet 的启发，应用了一个具有 27 层的超深图卷积网络（GCN）来捕捉药物的化学结构。蛋白质序列的结构通过具有不同大小感受野的三个卷积神经网络（CNN）来检测。

3.3. 基于分子药物图和蛋白质图的相互作用及亲和力预测

尽管已经生成了基于蛋白质的一级序列，但仍有改进的空间。蛋白质的最佳表示形式是包含更丰富结构信息的高维结构。然而，这些结构难以获取。可以使用二维图结构来描述蛋白质的三维结构。鉴于输入蛋白质序列的长度，直接将其转换为图结构会增加训练成本。由残基组成的图更为合适，因为每个蛋白质仅包含几百个残基。这一过程如图 3 所示。

近期，一些作者已开始利用蛋白质图而非蛋白质的一级结构来预测药物与靶点之间的关系。例如，DGraphDTA [73] 对蛋白质序列进行处理以生成接触图，进而构建图结构。利用 RDKit，将药物分子从 SMILES 转换为分子图。然后将这两种分子图加载到图神经网络（GNN）中以实现特征学习。为了在获取药物和蛋白质图的同时丰富所学特征，X-DPI [74] 对药物应用 Mol2vec [75] 以获取药物间的关系。接着，它应用一个预训练的模型




图 4. *r* 半径子图。这是药物分子图的一种形式。顶点 *i* 根据 *r* 的值聚合不同的邻域信息。当 *r* 分别为 1 或 2 时，顶点 *j* 和 *k* 分别是顶点 *i* 需要聚合的邻域。圆圈：碳原子。

BERT [76] 模型从 TAPE [77] 提供的大量未标记蛋白质序列中学习嵌入式表示。DGraphDTA 由于处理时间长，特别是在序列比对步骤，需要进行大量的数据库扫描，这极大地降低了预测的准确性。因此，WGNN-DTA [59] 借鉴了进化尺度建模（ESM）[78]，从该模型中提取蛋白质图；这种方法能够高效地完成预测过程，并产生更好的结果。DGraphDTA 由于是基于有限数量的蛋白质进行训练，因此忽略了由药物-靶点相互作用（DTIs）引起的靶点表示变化。为了解决这个问题，[79] 提出了一种名为图早期融合亲和力（GEFA）的新模型，该模型通过注意力机制将药物分子图转移到蛋白质图上进行学习和预测。

我们基于图神经网络（GNNs）对解决药物-靶点相互作用（DTI）预测和药物-靶点亲和力（DTA）预测任务的方法进行了总结，其详细信息见表 4。

蛋白质序列是由氨基酸组成的线性多肽链，提供了蛋白质分子的一级结构信息。蛋白质图是蛋白质高维结构的图形表示，提供了有关蛋白质结构的可视化信息。基于序列的方法可以处理整个序列，并从大量的序列信息中学习其隐藏特征。它不需要对蛋白质的结构特征和拓扑结构有深入的理解，因此在特征工程和模型预测模块中相对耗时较少且速度更快。由于使用了大量的已知蛋白质相互作用信息，其预测准确性是可以接受的。然而，它没有考虑结构

表 4
基于图神经网络的 DTI 和 DTA 预测方法综述。

类型	方法	药物表示	输入蛋白质表示	药物特征学习	蛋白质特征学习	预测
A	GanDTI	分子图	蛋白质序列	残差图神经网络	注意力模块	多层感知机
	图形每时钟周期指令数	分子图	蛋白质序列	图神经网络 (GCN\GAT\GIN)	Prot2Vec [62] + 卷积神经网络 (CNN)	FC
	MGraphDTA	分子图	蛋白质序列	MGNN	MCNN	多层感知机
	SAG-DTA	分子图	氨基酸序列	具有 SAG 池化层的图神经网络	美国有线电视新闻网	FC
	变压器CPI	药物分子	氨基酸序列	图卷积网络	具有门控线性单元的卷积神经网络	变压器
	[60]	分子图	蛋白质序列	GraphNet [85]	Transformer + 卷积神经网络 (CNN)	FC
	CPGL	R 半径子图	蛋白质序列	GAT	双向长短期记忆网络	带注意力机制的全连接网络
	[64]	R 半径子图	蛋白质序列	图神经网络	美国有线电视新闻网	注意 + Softmax
B	GraphDTA	分子图	蛋白质序列	图神经网络 (GCN\GAT\GIN\GAT-GCN)	美国有线电视新闻网	FC
	深度长短期记忆网络	分子图	氨基酸序列	多块图卷积网络	双向长短期记忆网络	FC
	GDGRU-DTA	分子图	蛋白质序列	门控图 [86] + 变换器卷积 [87]	GRU + 双向 GRU	FC
	[51]	分子图	氨基酸序列	图卷积网络	基于 Word2Vec 的二维卷积神经网络 [88]	FC
	DeepGS	SMILES 序列 + 分子图	氨基酸序列	带有 Smi2Vec [70] 的双向门控循环单元 (BiGRU) + 图注意力网络 (GAT)	带有 Prot2Vec 的 CNN	FC
	[71]	分子图	蛋白质序列	图神经网络 (GCN\GAT\GIN\GAT-GCN)	基于 TF-IDF 的 CNN (卷积神经网络)	FC
	嵌入式药物靶点相互作用预测模型	原子图和子结构图	蛋白质序列	带注意力模块的图卷积网络	美国有线电视新闻网	FC
C	DGraphDTA	分子图	蛋白质图谱	图神经网络 (GCN\GAT)	图神经网络 (GCN\GAT)	FC
	WGNN-DTA	分子图	加权蛋白质图	图神经网络 (GCN\GAT)	图神经网络 (GCN\GAT)	FC
	GEFA	分子图	蛋白质图 + 蛋白质序列嵌入	带残差块的图卷积网络	带残差块的图卷积网络	线性层
	X 轴每英寸点数	分子图 + Mol2vec 嵌入	蛋白质图 + TAPE 嵌入	GCN 编码器	GCN 编码器	Transformer 解码器

缩写: DTI _drug-target 相互作用; DTA _drug-target 亲和力; GNN _graph 神经网络; MLP _multilayer 感知器; GCN _graph 卷积网络; GAT - 图注意力网络; GIN - 图同构网络; CNN - 卷积神经网络; FC - 全连接层; MGNN - 多尺度图神经网络; MCNN _multiscale 卷积神经网络; SAG _self-attention 图; Bi-LSTM _bidirectional 长短期记忆; GRU _gated 循环单元; BiGRU _bidirectional 门控循环单元; TF-IDF _term 词频 - 逆文档频率。

基于序列的方法只能获取蛋白质的信息，无法解决序列相似性的问题，例如同源蛋白质会导致预测出现偏差。基于图的方法考虑了图的拓扑和功能信息，能够挖掘蛋白质结构的复杂特征，并且以高可靠性提高了预测的准确性。然而，它不能将蛋白质分子中的每个氨基酸都作为图中的一个节点，导致图的结构非常庞大，需要更多的计算资源和时间来构建和分析蛋白质图。对于未知或罕见的蛋白质结构和功能，其模型预测的有效性可能会受到限制。总之，基于序列和基于图的方法各有优势，应根据研究问题的特点和数据特征进行选择。

4. 实验

4.1. 数据集

我们评估了几个数据集的DTI预测和DTA

表 5 数据集统计信息。

DTA			
	毒品	目标	相互作用
戴维斯	68	442	三万零五十六
KIBA	2111	229	一百一十八万二千五百四
DTI			
人类	2726	2001	6728
秀丽隐杆线虫	1767	1876	7786

缩写: DTI - 药物 - 靶点相互作用; DTA - 药物 - 靶点亲和力。

预测。前者利用了人类和秀丽隐杆线虫的数据集，后者则使用了 Davis 和 KIBA 数据集。我们对这些数据集进行了总结，其统计信息见表 5。

戴维斯数据集: 戴维斯数据集 [80] 提供了 68 种药物与 442 个靶点之间 30056 对相互作用样本。为了衡量药物与靶点的结合程度，可以利用 K_d 值 (酶解离常数)。该值的范围为 0.016 至 10000。由于此值范围过大，对实验精度影响不大，因此将 K_d 值替换为对数函数 (pK_d)，其计算方式如公式 (1) 所示。

$$pK_d = -\log_{10}\left(\frac{K_d}{10^9}\right)$$
 (1)

KIBA 数据集: KIBA 数据集 [81] 通过 KIBA 分数来衡量药物与靶点之间的关系，这些分数由诸如 K_i (抑制常数)、 K_d 和 IC_{50} (半数最大抑制浓度) 等异质信息源计算得出。该数据集包含 2111 种药物、229 个靶点以及 118254 对相互作用，KIBA 分数范围从 0.0 到 17.2。

人类和秀丽隐杆线虫数据集: [82] 为这两个数据集提供了高度可靠的阴性样本。这两个数据集分别按照 1:1 和 1:3 的比例将样本分为平衡样本和不平衡样本 (与 [64] 一致)。人类数据集包含 2726 种药物分子、2001 个靶点以及 6728 个相互作用样本。秀丽隐杆线虫数据集中的 7786 个相互作用样本包括 1767 种药物和 1876 个靶点。

4.2. 评估指标

我们采用三个最常用的评估指标来评估回归任务，即均方误差 (MSE)、相关系数 (concor)

舞蹈指数 (CI) 和 $RM2$ 指数。

均方误差 (**MSE**)：这是一种衡量模型预测值与真实值之间差异的评估指标。其计算方法如公式 (2) 所示。

$$MSE = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2 \tag{2}$$

CI：CI 用于评估不同模型的区分能力如何[83]。CI 值的范围为 0 到 1，其值越接近 1，模型拟合效果越好。其计算形式如公式 (3) 所示。

$$CI = \frac{1}{Z} \sum_{\sigma_i > \sigma_j} \varphi(b_i - b_j) \tag{3}$$

在该方程中， σ_i 的亲值大于 σ_j 的亲值， b_i 和 b_j 分别是与 σ_i 和 σ_j 相对应的预测值。 Z 是一个归一化常数， $\Phi(x)$ 是一个函数，该函数的计算方法如式 (4) 所述。

$$\varphi(x) = \begin{cases} 0, & \text{if } x < 0 \\ 0.5, & \text{if } x = 0 \\ 1, & \text{if } x > 0. \end{cases} \tag{4}$$

r_m^2 指数：在 DeepDTA 中使用了 r_m^2 指数 [84]，它也是回归任务的一个评估指标。该指数可用于评估 QSAR 模型的外部预测性能。其计算方法如公式 (5) 所示。

$$r_m^2 = r^2 \times \left(1 - \sqrt{r^2 - r_0^2}\right) \tag{5}$$

其中，带截距和不带截距的相关系数的平方分别用 r^2 和 r_0^2 表示。我们通过四个指标来评估模型在分类任务中的性能：受试者工作特征曲线下的面积 (AUC)、准确率、召回率和 F1 值。

4.3. 结果

实验中使用的阳性样本是已知的具有相互作用或高亲和力的药物 - 靶点对。阴性样本则由不具有相互作用或亲和力低的药物 - 靶点对组成。实验中所用的数据也是以同样的方式划分的。我们将数据分为训练集、验证集和测试集，以评估药物 - 靶点相互作用预测的能力。训练集用于优化模型的参数和训练过程，验证集用于调整模型的超参数并选择最佳模型，测试集用于评估模型的最终性能。

我们针对药物靶点相互作用 (DTI) 预测和药物靶点亲和力 (DTA) 预测任务，对多个数据集进行了实验。在人类和秀丽隐杆线虫的数据集上，我们采用 AUC、准确率、召回率和 F1 分数等指标来评估 DTI 预测性能。在 Davis 和 KIBA 数据集上，我们使用均方误差 (MSE)、一致性指数 (CI) 和 r_m^2 评估指标来衡量 DTA 的准确性。实验中所用的数据集、模型架构 (包括网络参数) 以及数据处理方法均以原始论文为依据。更多详情请参阅相关文献。

与基于序列的表示方法相比，分子图表示法能够提供更丰富的药物语义信息。一级序列用于描述蛋白质。表 6 和表 7 分别展示了在人类和秀丽隐杆线虫数据集上测试的结果，这些结果基于分子药物图和蛋白质序列获得了相互作用预测结果。表中列出的几种方法取得了更好的实验效果。其他 7 个指标在 AUC、准确率、召回率和 F1 值方面的预测结果如下

表 6
基于药物分子图和蛋白质序列的人类数据集上的相互作用预测。

方法	AUC	精度	召回	F1 分数
GanDTI	0.982	0.943	0.941	0.942
GraphCPIa	0.973	0.940	0.890	–
MGraphDTA	0.983	0.934	0.947	0.943
SAG-DTAa (HierPool)	0.985	0.945	0.933	–
SAG-DTAa (全局池)	0.984	0.946	0.931	–
变压器CPI	0.974	0.928	0.939	0.933
[60]	0.979	0.939	0.955	0.947
CPGL	0.981	0.935	0.929	0.932
[64]	0.955	0.958	0.883	0.919

a 表示实验结果来自原始文献。缩写:AUC - 接收者操作特征曲线下面积。

表 7
基于秀丽隐杆线虫数据集中的药物分子图和蛋白质序列的相互作用预测。

方法	AUC	精度	召回	F1 分数
GanDTI	0.984	0.943	0.947	0.945
GraphCPIa	0.989	0.937	0.955	–
MGraphDTA	0.988	0.961	0.961	0.961
变压器CPI	0.972	0.943	0.930	0.937
[60]	0.991	0.955	0.972	0.964
CPGL	0.988	0.956	0.958	0.957
[64]	0.958	0.927	0.908	0.917

a 表示实验结果来自原始文献。缩写:AUC - 接收者操作特征曲线下面积。

在人类和秀丽隐杆线虫数据集上，所有方法的指标均大于 0.9，除了 GraphCPI 和 [64] 在人类数据集上的召回率分别为 0.890 和 0.883。这表明药物分子图和蛋白质序列均得到了充分的捕捉。

基于 Davis 和 KIBA 数据集中的分子药物图和蛋白质序列所获得的亲和力预测结果分别在表 8 和表 9 中给出。在不同的数据集上，不同的方法会产生不同的结果。例如，在 Davis 和 KIBA 数据集上，GraphDTA 分别产生了 0.251、0.881 和 0.676 以及 0.135、0.894 和 0.772 的均方误差 (MSE)、覆盖率 (CI) 和 r_m^2 值。

一种表示分子的方法是通过图，这种方法能包含比序列更多的信息。通过图来完整地表示蛋白质序列具有挑战性，并且会增加所需的训练时间和内存开销。采用接触图作为蛋白质图能获得更好的预测性能，接触图描绘了蛋白质残基之间的关系。基于药物分子图和蛋白质图对药物-靶点相互作用 (DTI) 和药物-靶点亲和力 (DTA) 预测任务所获得的结果如表 10 所示。由 r_m^2 指标得出的均方误差 (MSE)、覆盖率 (CI) 和 r_m^2 指标结果如下。

表 8
基于药物分子图和蛋白质序列在 Davis 数据集上的亲和力预测。

方法	均方误差	CI (企业形象识别系统 _m)	
GraphDTA	0.251	0.881	0.676
深度长短期记忆网络	0.250	0.891	0.681
GDGRU-DTAa (Transformer-双向门控循环单元)	0.214	0.902	0.697
GDGRU-DTAa (门控图双向GRU)	0.214	0.904	0.708
[51]	0.225	0.892	–
DeepGS	0.252	0.882	0.686
[71]	0.220	0.899	–
嵌入式药物靶点相互作用预测模型	0.402	0.835	0.495

a 表示实验结果来自原始论文。缩写:MSE - 均方误差;CI - 一致性指数。在 Deep-DTA 中使用了 r_m^2 指数,该指数可用于评估定量构效关系模型的外部预测性能。

表 9

基于药物分子图和蛋白质序列在 KIBA 数据集上的亲和力预测。

方法	均方误差	CI (企业形象识别系统) _m	
GraphDTA	0.135	0.894	0.772
DeepGLSTMa	0.133	0.897	0.792
GDGRU-DTAa (Transformer-双向门控循环单元)	0.134	0.894	0.780
GDGRU-DTAa (门控图双向GRU)	0.137	0.892	0.775
[51] [↑]	0.137	0.895	–
DeepGSa	0.193	0.860	0.684
[71] [↑]	0.126	0.901	–
EmbedDTIa	0.133	0.897	–

a 表示实验结果来自原始论文。

缩写:MSE _mean 平方误差;CI _concordance 指数。在 Deep-DTA 中使用了 r_m^2 指数,该指数可用于评估定量构效关系模型的外部预测性能。

表 10

基于多个数据集中的药物分子图和蛋白质序列所实现的相互作用及亲和力预测性能。

方法	数据集	均方误差	CI (企业形象识别系统) _m	
DGraphDTA	戴维斯	0.240	0.890	0.659
	KIBA	0.147	0.891	0.767
GEFAa (预热启动设置)	戴维斯	0.228	0.893	–
	X 轴每英寸点数 (X-DPI)	0.474	–	–
WGNN-DTA	戴维斯	0.215	0.900	0.711
	KIBA	0.140	0.899	0.749
		AUC	精度	召回
	人类	0.978	0.926	0.960
	秀丽隐杆线虫	0.989	0.969	0.954

a 表示实验结果来自原始论文。缩写:MSE - 均方误差;CI - 一致性指数。在 Deep-DTA 中使用了 r_m^2 指数,该指数可用于评估定量构效关系模型的外部预测性能。

在 Davis 和 KIBA 数据集上, DGraphDTA 和 GEFA 方法表现良好。在 Davis 和秀丽隐杆线虫数据集上, WGNN-DTA 分别几乎优于基于药物分子图和蛋白质序列的亲和力预测和相互作用预测方法。此外, 在 KIBA 和人类数据集上, 其表现与其他方法相当。实验结果再次表明, 蛋白质图在药物 - 蛋白质相互作用 (DTI) 和药物 - 蛋白质亲和力 (DTA) 预测中发挥着重要作用。

5. 讨论与结论

我们总结了基于图神经网络 (GNNs) 的药物-靶点相互作用 (DTI) 预测和药物-靶点亲和力 (DTA) 预测。根据药物分子图和蛋白质序列, 将药物分子图、蛋白质一级序列和蛋白质图分类用于相互作用预测、亲和力预测以及基于药物分子图和蛋白质图的整体预测。在几个基础数据集上, 选取了具有代表性的方法进行实验验证。结果表明, 基于分子图的表示优于基于序列的表示。分子图在特征学习方面能够获得比分子序列更多的语义信息。分子网络的拓扑结构能更准确地反映原子间的相互作用。

与分子图不同, 尽管分子序列能够汇集序列信息以用于特征学习, 但分子图中包含的结构信息却被忽略了, 这影响了预测的准确性。目前, 药物特征序列已被分子图所取代, 分子图包含丰富的特征信息。许多

目标蛋白质缺乏三维结构信息, 这使得无法利用其高维特性。此外, 由于目标蛋白质序列较长, 用图来表示它们会导致训练时间增加。实际上, 蛋白质图无法描绘整个蛋白质序列。然而, 随着 AlphaFold 在蛋白质结构预测方面的突破, 现在可以获得高质量的蛋白质结构预测结果。这一进展对蛋白质结构预测领域产生了重大影响, 因为它能够为许多之前缺乏结构信息的目标蛋白质近似出三维结构。因此, 引入了蛋白质结构预测过程的输出——接触图, 该图描述了蛋白质残基配对的邻接矩阵。由接触图构建的蛋白质图被送入神经网络以学习特征。

预测药物分子与蛋白质序列之间的相互作用以及它们之间的亲和力是药物开发中常见的计算方法。基于药物分子图和蛋白质序列使用这些方法的一个典型应用场景是药物发现和设计。在药物发现过程中, 研究人员通常寻找特定的蛋白质作为药物靶点。通过使用这种预测方法, 可以确定药物靶点之间的相互作用, 并识别药物分子的结合位点和相互作用类型。这些预测结果可用于设计新的药物分子、优化现有药物分子或评估不同药物分子的相互作用能力, 以更好地治疗疾病。基于药物分子图和蛋白质序列使用这些方法进行亲和力预测的一个典型应用场景是药物筛选和优化。通过探索药物分子与特定蛋白质之间的亲和力, 可以筛选出亲和力高的药物分子, 并对其活性、选择性和毒性进行评估。这种方法侧重于评估和优化现有的药物分子, 以提高其疗效和安全性。蛋白质图有助于研究人员了解蛋白质的结构和功能。总之, 药物-靶点相互作用 (DTI) 和药物-靶点亲和力 (DTA) 在药物开发中具有重要应用。它们能够帮助药物研究人员在药物开发的不同阶段快速有效地了解药物分子与蛋白质相互作用的机制。

尽管分子图表示比分子序列更丰富, 但仍存在改进的空间。蛋白质接触图的创建是一个耗时的过程。在未来的工作中, 可以采用加速的方法来构建蛋白质图。对于未知的蛋白质结构信息, 研究人员应找到一种方法来确定药物与靶点之间的关系。

此外, 图神经网络 (GNNs) 已被证明在捕捉和利用药物与蛋白质之间的关系方面十分有效, 为药物-靶点相互作用 (DTI) 和药物-靶点亲和力 (DTA) 应用中的生物学可解释性提供了有力支持。GNNs 能够对药物与蛋白质之间的结构关系、功能区域和多模态特征进行建模, 生成可解释的预测和可视化结果。这些能力有助于揭示药物-蛋白质相互作用的机制、功能亚结构以及药物特征的重要性, 为药物设计和开发提供更深入的见解和指导。

在结构特征建模方面, 图神经网络 (GNNs) 能够将药物和蛋白质的结构表示为图中的节点和边。通过学习节点之间的相互作用和信息传播, GNNs 可以提取药物和蛋白质的结构特征, 并解释其在相互作用预测中的重要性。这有助于揭示药物 - 蛋白质相互作用的机制和结构基础。

对于蛋白质亚结构和功能分析, 图神经网络 (GNNs) 能够对蛋白质的亚结构进行建模, 并为预测中的不同功能区域提供解释。通过建模蛋白质的拓扑结构、结构域结构或其他特定特征, GNNs 可以帮助识别与药物结合相关的功能区域, 并对其进行解释, 从而为亚结构和功能区域提供解释能力。

功能。

关于药物的多模态表示, 图神经网络 (GNNs) 能够支持

在图网络中对多种特征进行建模及其融合。这些多模态特征可以包括分子结构、化学性质、药物代谢信息等等。通过学习药物的多模态表示，图神经网络（GNNs）能够解释不同特征的重要性，有助于理解药物与蛋白质相互作用的潜在机制。

此外，在药物-靶点相互作用（DTI）或药物-靶标亲和力（DTA）预测中应用图神经网络（GNNs）能够产生直观且可解释的结果。通过可视化药物与蛋白质之间的关系图、重要节点和边的权重以及与预测结果相关的特征，图神经网络为解释预测结果和预测模型的决策过程提供了一种直观且可解释的方式。

而且，数据的多样性也体现在分子图中，更丰富的节点信息能够带来更有效的预测。单一模式的数据模型可能存在一定的局限性，但多模态数据的结合能够提供更全面的信息。基因表达数据可以提供蛋白质表达水平、细胞状态以及分子亲和力相关的信息。分子图描述了分子之间的化学结构特征，将这两种类型的数据融合起来有助于更好地理解药物分子与蛋白质之间的相互作用。分子的多模态数据不仅限于基因表达；药物分子图还可以携带毒性、副作用等信息，而蛋白质图则可以包含功能区数据等等。所有这些多模态数据都有助于模型预测。

在开发药物靶点相互作用预测模型时，也会考虑诸如数据噪声、缺失数据和未知结构等不确定性因素。这些不确定性可能会降低预测结果，并降低模型的可解释性。贝叶斯网络和概率模型可用于应对这些问题，提高数据的可靠性。模型的可解释性也是一个关键问题，因为它对于指导实验设计、加速新药开发、减少不必要的实验以及降低研发成本至关重要。注意力机制的可视化方法可以观察图中节点对实验结果的贡献。未来，研究人员应通过加深对模型可解释性的理解，设计出更优且更具可解释性的模型来预测药物靶点相互作用（DTI）和药物靶点亲和力（DTA）。此外，在学习药物和靶点特征之后，可以采用更好的结合策略，而非简单的连接方式。

利益冲突声明

作者声明，他们与本文的发表不存在利益冲突。

致谢

本研究部分得到了中国国家重点研发计划（2022YFE0112200）、广东省重点领域研发计划（2022A0505050014、2022B1111050002）以及国家自然科学基金（U21A20520、62172112）的支持。

参考文献

- [1] T.T. Ashburn, K.B. Thor, Drug repositioning: identifying and developing new uses for existing drugs, *Nat. Rev. Drug Discov.* 3 (8) (Aug. 2004) 673–683.
- [2] A.D. Roses, Pharmacogenetics in drug discovery and development: a translational perspective, *Nat. Rev. Drug Discov.* 7 (10) (Oct. 2008) 807–817.
- [3] J.A. DiMasi, H.G. Grabowski, R.W. Hansen, Innovation in the pharmaceutical industry: new estimates of R&D costs, *J. Health Econ.* 47 (May. 2016) 20–33.
- [4] A. Mullard, New drugs cost US\$2.6 billion to develop, *Nat. Rev. Drug Discov.* 13 (12) (Dec. 2014), 12.
- [5] J.C. Pereira, E.R. Caffarena, C.N. dos Santos, Boosting docking-based virtual screening with deep learning, *J. Chem. Inf. Model.* 56 (12) (Dec. 2016) 2495–2506.
- [6] S.M. Strittmatter, Overcoming drug development bottlenecks with repurposing: old drugs learn new tricks, *Nat. Med.* 20 (6) (Jun. 2014) 590–591.
- [7] S. Pathak, X. Cai, Ensemble learning algorithm for drug-target interaction prediction, in: 2017 IEEE 7th International Conference on Computational Advances in Bio and Medical Sciences, ICCABS, Orlando, FL, USA, Oct. 2017, 1–1.
- [8] M. Deshpande, M. Kuramochi, N. Wale, G. Karypis, Frequent substructure-based approaches for classifying chemical compounds, *IEEE Trans. Knowl. Data Eng.* 17 (8) (Aug. 2005) 1036–1050.
- [9] M.J. Keiser, B.L. Roth, B.N. Armbruster, P. Ernsberger, J.J. Irwin, B.K. Shoichet, Relating protein pharmacology by ligand chemistry, *Nat. Biotechnol.* 25 (2) (Feb. 2007) 197–206.
- [10] D.T. Ahneman, J.G. Estrada, S. Lin, S.D. Dreher, A.G. Doyle, Predicting reaction performance in C-N cross-coupling using machine learning, *Science* 360 (6385) (Apr. 2018) 186–190.
- [11] K.V. Balakin, S.E. Tkachenko, S.A. Lang, I. Okun, A.A. Ivashchenko, N.P. Savchuk, Property-based design of GPCR-targeted library, *J. Chem. Inf. Comput. Sci.* 42 (6) (Nov. 2002) 1332–1342.
- [12] F. Napolitano, Y. Zhao, V.M. Moreira, R. Tagliaferri, J. Kere, M. D'Amato, D. Greco, Drug repositioning: a machine-learning approach through data integration, *J. Cheminf.* 5 (1) (Dec. 2013) 30.
- [13] Z. Liu, H. Fang, K. Reagan, X. Xu, D.L. Mendrick, W. Slikker, W. Tong, In silico drug repositioning: what we need to know, *Drug Discov. Today* 18 (3–4) (Feb. 2013) 110–115.
- [14] A.C. Cheng, R.G. Coleman, K.T. Smyth, Q. Cao, P. Souillard, D.R. Caffrey, A. C. Salzberg, E.S. Huang, Structure-based maximal affinity model predicts small-molecule druggability, *Nat. Biotechnol.* 25 (1) (Jan. 2007) 71–75.
- [15] P.T. Lang, S.R. Brozell, S. Mukherjee, E.F. Pettersen, E.C. Meng, V. Thomas, R. C. Rizzo, D.A. Case, T.L. James, I.D. Kuntz, DOCK 6: combining techniques to model RNA-small molecule complexes, *RNA* 15 (6) (Jun. 2009) 1219–1230.
- [16] G.M. Morris, R. Huey, W. Lindstrom, M.F. Sanner, R.K. Belew, D.S. Goodsell, A. J. Olson, AutoDock4 and AutoDockTools4: automated docking with selective receptor flexibility, *J. Comput. Chem.* 30 (16) (Dec. 2009) 2785–2791.
- [17] W. Filgueira de Azevedo, G.C. dos Santos, D.M. dos Santos, J.R. Olivieri, F. Canduri, R. G. Silva, L.A. Basso, G. Renard, I.O. da Fonseca, M.A. Mendes, M. S. Palma, D.S. Santos, Docking and small angle X-ray scattering studies of purine nucleoside phosphorylation, *Biochem. Biophys. Res. Commun.* 309 (4) (Oct. 2003) 923–928.
- [18] N.M.B. Levin, V.O. Pintro, M.B. de Avila, B.B. de Mattos, W.F. De Azevedo, Understanding the structural basis for inhibition of cyclin-dependent kinases. new pieces in the molecular puzzle, *Curr. Drug Targets* 18 (9) (Jun. 2017) 1104–1111.
- [19] L. Chen, X. Tan, D. Wang, F. Zhong, X. Liu, T. Yang, X. Luo, K. Chen, H. Jiang, M. Zheng, TransformerCPI: improving compound-protein interaction prediction by sequence-based deep learning with self-attention mechanism and label reversal experiments, *Bioinformatics* 36 (16) (Aug. 2020) 4406–4414.
- [20] F. Wan, L. Hong, A. Xiao, T. Jiang, J. Zeng, NeoDTI: neural integration of neighbor information from a heterogeneous network for discovering new drug-target interactions, *Bioinformatics* 35 (1) (Jan. 2019) 104–111.
- [21] S. Hu, C. Zhang, P. Chen, P. Gu, J. Zhang, B. Wang, Predicting drug-target interactions from drug structure and protein sequence using novel convolutional neural networks, *BMC Bioinf.* 20 (Suppl 25) (Dec. 2019) 689.
- [22] H. Oztürk, A. Ozgür, E. Ozkirimli, DeepDTA: deep drug-target binding affinity prediction, *Bioinformatics* 34 (17) (Sep. 2018) i821–i829.
- [23] H. Oztürk, E. Ozkirimli, A. Ozgür, WideDTA: Prediction of Drug-Target Binding Affinity, *The Institute of Electronics, Information and Communication Engineers, TOKYO, JAPAN, Feb. 2019* [Online], <https://ui.adsabs.harvard.edu/abs/2019arXiv190204166O>. (Accessed 23 November 2022).
- [24] T. Li, X.-M. Zhao, L. Li, Co-VAE: drug-target binding affinity prediction by co-regularized variational autoencoders, *IEEE Trans. Pattern Anal. Mach. Intell.* 44 (12) (Dec. 2022) 8861–8873.
- [25] M. Yazdani-Jahromi, N. Yousefi, A. Tayebi, E. Kolanthai, C.J. Neal, S. Seal, O. O. Garibay, AttentionSiteDTI: an interpretable graph-based model for drug-target interaction prediction using NLP sentence-level relation classification, *Briefings Bioinf.* 23 (4) (Jul. 2022) bbac272.
- [26] P. Bai, F. Miljković, B. John, H. Lu, Interpretable bilinear attention network with domain adaptation improves drug-target prediction, *Nat. Mach. Intell.* 5 (2) (Feb. 2023) 126–136.
- [27] Q. Zhao, H. Zhao, K. Zheng, J. Wang, HyperAttentionDTI: improving drug-protein interaction prediction by sequence-based deep learning with attention mechanism, *Bioinformatics* 38 (3) (Jan. 2022) 655–662.
- [28] W. Yuan, G. Chen, C.Y.-C. Chen, FusionDTA: attention-based feature polymerizer and knowledge distillation for drug-target binding affinity prediction, *Briefings Bioinf.* 23 (1) (Jan. 2022) bbab506.
- [29] Y. Luo, X. Zhao, J. Zhou, J. Yang, Y. Zhang, W. Kuang, J. Peng, L. Chen, J. Zeng, DTINet: a network integration approach for drug-target interaction prediction and computational drug repositioning from heterogeneous information, *Nat. Commun.* 8 (1) (Dec. 2017) 573.
- [30] Y. Liu, M. Wu, C. Miao, P. Zhao, X.-L. Li, Neighborhood regularized logistic matrix factorization for drug-target interaction prediction, *PLoS Comput. Biol.* 12 (2) (Feb. 2016), e1004760.
- [31] T. Ban, M. Ohue, Y. Akiyama, NRLMFβ: beta-distribution-rescored neighborhood regularized logistic matrix factorization for improving the performance of drug-target interaction prediction, *Biochem. Biophys. Rep.* 18 (Jul. 2019), 100615.

- [32] M. G. Onen, Predicting drug–target interactions from chemical and genomic kernels using Bayesian matrix factorization, *Bioinformatics* 28 (18) (Sep. 2012) 2304–2310.
- [33] L.-Y. Xia, Z.-Y. Yang, H. Zhang, Y. Liang, Improved prediction of drug–target interactions using self-paced learning with collaborative matrix factorization, *J. Chem. Inf. Model.* 59 (7) (Jul. 2019) 3340–3351.
- [34] X. Gao, X. Ma, W. Zhang, J. Huang, H. Li, Y. Li, J. Cui, Multi-View clustering with self-representation and structural constraint, *IEEE Transact. Big Data* 8 (4) (Aug. 2022) 882–893.
- [35] W. Wu, X. Ma, Network-based structural learning nonnegative matrix factorization algorithm for clustering of scRNA-seq data, *IEEE ACM Trans. Comput. Biol. Bioinf* 20 (1) (Jan. 2023) 566–575.
- [36] D. Li, S. Zhang, X. Ma, Dynamic module detection in temporal attributed networks of cancers, *IEEE ACM Trans. Comput. Biol. Bioinf* 19 (4) (Jul. 2022) 2219–2230.
- [37] X. Ma, W. Zhao, W. Wu, Layer-specific modules detection in cancer multi-layer networks, *IEEE ACM Trans. Comput. Biol. Bioinf* 20 (2) (Mar. 2023) 1170–1179.
- [38] Z. Huang, Y. Wang, X. Ma, Clustering of cancer attributed networks by dynamically and jointly factorizing multi-layer graphs, *IEEE ACM Trans. Comput. Biol. Bioinf* 19 (5) (Sep. 2022) 2737–2748.
- [39] J. Zhou, G. Cui, S. Hu, Z. Zhang, C. Yang, Z. Liu, L. Wang, C. Li, M. Sun, Graph neural networks: a review of methods and applications, *AI Open* 1 (Jan. 2020) 57–81.
- [40] D. Weininger, SMILES, a chemical language and information system. 1. Introduction to methodology and encoding rules, *J. Chem. Inf. Comput. Sci.* 28 (1) (Feb. 1988) 31–36.
- [41] M. Sun, S. Zhao, C. Gilvary, O. Elemento, J. Zhou, F. Wang, Graph convolutional networks for computational drug development and discovery, *Briefings Bioinf.* 21 (3) (May 2020) 919–935.
- [42] Z. Wu, S. Pan, F. Chen, G. Long, C. Zhang, P.S. Yu, A comprehensive survey on graph neural networks, *IEEE Transact. Neural Networks Learn. Syst.* 32 (1) (Jan. 2021) 4–24.
- [43] X. Yue, Z. Wang, J. Huang, S. Parthasarathy, S. Moosavinasab, Y. Huang, S.M. Lin, W. Zhang, P. Zhang, H. Sun, Graph embedding on biomedical networks: methods, applications and evaluations, *Bioinformatics* 36 (4) (Feb. 2020) 1241–1251.
- [44] J. Lim, S. Ryu, K. Park, Y.J. Choe, J. Ham, W.Y. Kim, Predicting drug-target interaction using a novel graph neural network with 3D structure-embedded graph representation, *J. Chem. Inf. Model.* 59 (9) (Sep. 2019) 3981–3988.
- [45] Z. Liu, Q. Chen, W. Lan, H. Pan, X. Hao, S. Pan, GADTI: graph autoencoder approach for DTI prediction from heterogeneous network, *Front. Genet.* 12 (Apr. 2021), 650821.
- [46] T.D. Crawford, M. Ruchardt, G. Torrance, RDKit: a Comprehensive Toolkit for Drug Discovery, vol. 46, Academic Press, 2011, pp. 15–28 [Online], <http://rdkit.org/>. (Accessed 5 March 2023).
- [47] J. Kaur, J. Saini, Designing punjabi poetry classifiers using machine learning and different textual features, *Int. Arab J. Inf. Technol.* (2019) 38–44.
- [48] Q. Feng, E.V. Dueva, A. Cherkasov, M. Ester, PADME: a deep learning-based framework for drug-target interaction prediction, *Comput. Res. Repository abs/1807.09741* (2018) [Online], <http://arxiv.org/abs/1807.09741>. (Accessed 23 November 2022).
- [49] M. Zhao, M. Yuan, Y. Yang, S.X. Xu, CPGL: prediction of compound-protein interaction by integrating graph attention network with long short-term memory neural network, *IEEE ACM Trans. Comput. Biol. Bioinf* (2022) 2022, 04.19.488691, Apr.
- [50] L. Zhijian, J. Shaohua, L. Yigao, G. Min, GDGRU-DTA: predicting drug-target binding affinity based on GNN and double GRU, in: *Data Mining and Machine Learning*, Apr. 2022, pp. 25–37.
- [51] M. Xia, J. Hu, X. Zhang, X. Lin, Drug-target binding affinity prediction based on graph neural networks and word2vec, in: D.-S. Huang, K.-H. Jo, J. Jing, P. Premaratne, V. Bevilacqua, A. Hussain (Eds.), *Intelligent Computing Theories and Application, Lecture Notes in Computer Science*, vol. 13394, Springer International Publishing, Cham, 2022, pp. 496–506.
- [52] B.-W. Zhao, Z.-H. You, L. Hu, Z.-H. Guo, L. Wang, Z.-H. Chen, L. Wong, A novel method to predict drug-target interactions based on large-scale graph representation learning, *Cancers* 13 (9) (Apr. 2021) 2111.
- [53] M. Lennox, N. Robertson, B. Devereux, Modelling drug-target binding affinity using a BERT based graph neural network, in: *2021 43rd Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, vol. 2021, Nov. 2021, pp. 4348–4353.
- [54] Q. Wu, Z. Peng, I. Anishchenko, Q. Cong, D. Baker, J. Yang, Protein contact prediction using metagenome sequence data and residual neural networks, *Bioinformatics* 36 (1) (Jan. 2020) 41–48.
- [55] S. Wang, P. Shan, Y. Zhao, L. Zuo, GanDTI: a multi-task neural network for drug-target interaction prediction, *Comput. Biol. Chem.* 92 (Jun. 2021), 107476.
- [56] Z. Quan, Y. Guo, X. Lin, Z.-J. Wang, X. Zeng, GraphCPI: graph neural representation learning for compound-protein interaction, in: *2019 IEEE International Conference on Bioinformatics and Biomedicine*, 2019, pp. 717–722. San Diego, CA, USA, Nov.
- [57] Z. Yang, W. Zhong, L. Zhao, C. Yu-Chian Chen, MGraphDTA: deep multiscale graph neural network for explainable drug–target binding affinity prediction, *Chem. Sci.* 13 (3) (2022) 816–833.
- [58] S. Zhang, M. Jiang, S. Wang, X. Wang, Z. Wei, Z. Li, SAG-DTA: prediction of drug–target affinity using self-attention graph network, *Int. J. Mol. Sci.* 22 (16) (Aug. 2021) 8993.
- [59] M. Jiang, S. Wang, S. Zhang, W. Zhou, Y. Zhang, Z. Li, WGNN-DTA: sequence-based drug-target affinity prediction using weighted graph neural networks, *BMC Genom.* 23 (1) (Dec. 2022) 449.
- [60] Qh Kim, J.-H. Ko, S. Kim, N. Park, W. Jhe, Bayesian neural network with pretrained protein embedding enhances prediction accuracy of drug-protein interaction, *Bioinformatics* 37 (20) (Oct. 2021) 3428–3435.
- [61] Q.-W. Dong, X.-L. Wang, L. Lin, Application of latent semantic analysis to protein remote homology detection, *Bioinformatics* 22 (3) (Feb. 2006) 285–290.
- [62] E. Asgari, M.R.K. Mofrad, Continuous distributed representation of biological sequences for deep proteomics and genomics, *PLoS One* 10 (11) (2015), e0141287.
- [63] G. Li, M. Mueller, G. Qian, I.C. Delgadillo Perez, A. Abualshour, A.K. Thabet, B. Ghanem, DeepGCNs: Making GCNs Go as Deep as CNNs, *IEEE Transactions on Pattern Analysis and Machine Intelligence*, Apr. 2021, 1–1.
- [64] M. Tsubaki, K. Tomii, J. Sese, Compound–protein interaction prediction with end-to-end learning of neural networks for graphs and sequences, *Bioinformatics* 35 (2) (Jan. 2019) 309–318.
- [65] F. Costa, K.D. Grave, Fast neighborhood subgraph pairwise distance kernel, in: *Proceedings of the 27th International Conference on Machine Learning*, Haifa, Israel, Jun. 2010, pp. 255–262. (Accessed 23 November 2022).
- [66] T. Nguyen, H. Le, T.P. Quinn, T. Nguyen, T.D. Le, S. Venkatesh, GraphDTA: predicting drug-target binding affinity with graph neural networks, *Bioinformatics* 37 (8) (May 2021) 1140–1147.
- [67] S. Mukherjee, M. Ghosh, P. Basuchowdhuri, DeepGLSTM: deep graph convolutional network and LSTM based approach for predicting drug-target binding affinity, *arXiv* (Jan. 18, 2022) [Online], <http://arxiv.org/abs/2201.06872>. (Accessed 5 October 2022).
- [68] J. Chung, C. Gulcehre, K. Cho, Y. Bengio, Gated feedback recurrent neural networks, in: *Proceedings of the 32nd International Conference on International Conference on Machine Learning*, vol. 37, Jul. 2015, pp. 2067–2075. Lille, France.
- [69] X. Lin, K. Zhao, T. Xiao, Z. Quan, Z.-J. Wang, P.S. Yu, DeepGS: deep representation learning of graphs and sequences for drug-target binding affinity prediction, in: *ECAL 2020 - 24th European Conference on Artificial Intelligence*, 29 August–8 September 2020 vol. 325, Santiago de Compostela, Spain, 2020, pp. 1301–1308. August 29 - September 8, 2020 - Including 10th Conference on Prestigious Applications of Artificial Intelligence (PAIS 2020).
- [70] Z. Quan, X. Lin, Z.-J. Wang, Y. Liu, F. Wang, K. Li, A system for learning atoms based on long short-term memory recurrent neural networks, in: *IEEE International Conference on Bioinformatics and Biomedicine*, 2018, pp. 728–733. December 3–6, 2018, Madrid, Spain.
- [71] X. Wang, Y. Liu, F. Lu, H. Li, P. Gao, D. Wei, Dipeptide frequency of word frequency and graph convolutional networks for DTA prediction, *Front. Bioeng. Biotechnol.* 8 (Apr. 2020) 267.
- [72] Y. Jin, J. Lu, R. Shi, Y. Yang, EmbedDTI: enhancing the molecular representations via sequence embedding and graph convolutional network for the prediction of drug-target interaction, *Biomolecules* 11 (12) (1783) 2021.
- [73] M. Jiang, Z. Li, S. Zhang, S. Wang, X. Wang, Q. Yuan, Z. Wei, DGraphDTA: drug-target affinity prediction using graph neural network and contact maps, *RSC Adv.* 10 (35) (2020) 20701–20712.
- [74] P. Wang, S. Zheng, Y. Jiang, C. Li, J. Liu, C. Wen, A. Patronov, D. Qian, H. Chen, Y. Yang, X-DPI: a Structure-Aware Multi-Modal Deep Learning Model for Drug-Protein Interactions Prediction, *Cold Spring Harbor Laboratory*, Jun. 2021.
- [75] S. Jaeger, S. Fulle, S. Turk, Mol2vec: unsupervised machine learning approach with chemical intuition, *J. Chem. Inf. Model.* 58 (1) (Jan. 2018) 27–35.
- [76] J. Devlin, M.-W. Chang, K. Lee, K. Toutanova, BERT: pre-training of deep bidirectional transformers for language understanding, in: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, vol. 1, 2019, pp. 4171–4186. June 2–7, 2019, Minneapolis, MN, USA.
- [77] R. Rao, N. Bhattacharya, N. Thomas, Y. Duan, X. Chen, J. Canny, P. Abbeel, Y. S. Song, Evaluating protein transfer learning with TAPE, *Adv. Neural Inf. Process. Syst.* 32 (Dec. 2019) 9689–9701.
- [78] R. Rao, J. Meier, T. Sercu, S. Ovchinnikov, A. Rives, Transformer protein language models are unsupervised structure learners, in: *9th International Conference on Learning Representations*, May 3–7, 2021, Vienna, Austria, 2021.
- [79] T.M. Nguyen, T. Nguyen, T.M. Le, T. Tran, GEFA: early fusion approach in drug-target affinity prediction, *IEEE ACM Trans. Comput. Biol. Bioinf* 19 (2) (Mar. 2022) 718–728.
- [80] M.I. Davis, J.P. Hunt, S. Herrgard, P. Ciceri, L.M. Wodicka, G. Pallares, M. Hocker, D.K. Treiber, P.P. Zarrinkar, Comprehensive analysis of kinase inhibitor selectivity, *Nat. Biotechnol.* 29 (11) (2011) 1046–1051, Nov.
- [81] J. Tang, A. Szwajda, S. Shakyawar, T. Xu, P. Hintsanen, K. Wennerberg, T. Aittokallio, Making sense of large-scale kinase inhibitor bioactivity data sets: a comparative and integrative analysis, *J. Chem. Inf. Model.* 54 (3) (Mar. 2014) 735–743.
- [82] H. Liu, J. Sun, J. Guan, J. Zheng, S. Zhou, Improving compound-protein interaction prediction by building up highly credible negative samples, *Bioinformatics* 31 (12) (Jun. 2015) i221–i229.
- [83] M. Gonen, G. Heller, Concordance probability and discriminatory power in proportional hazards regression, *Biometrika* 92 (4) (2005) 965–970.
- [84] K. Roy, P. Chakraborty, I. Mitra, P.K. Ojha, S. Kar, R.N. Das, Some case studies on application of 'r_m ~2' metrics for judging quality of quantitative structure-activity relationship predictions: emphasis on scaling of response data, *J. Comput. Chem.* 34 (12) (May 2013) 1071–1082.

- [85] P. Battaglia, R. Pascanu, M. Lai, D.J. Rezende, K. kavukcuoglu, Interaction networks for learning about objects, relations and physics, in: *Proceedings of the 30th International Conference on Neural Information Processing Systems*, Red Hook, NY, USA, Dec. 2016, pp. 4509–4517.
- [86] Y. Li, R. Zemel, M. Brockschmidt, D. Tarlow, in: “Gated Graph Sequence Neural Networks,” *Presented at the Proceedings of the 32nd International Conference on International Conference on Machine Learning*, Lille, France, Jul. 2015, pp. 2067–2075 [Online], <http://arxiv.org/abs/1511.05493>. (Accessed 28 November 2022).
- [87] Y. Shi, Z. Huang, S. Feng, H. Zhong, W. Wang, Y. Sun, in: “Masked Label Prediction: Unified Message Passing Model for Semi-supervised Classification,” *Presented at the 29th International Joint Conference on Artificial Intelligence*, Yokohama, Japan, vol. 2, Aug. 2021, pp. 1548–1554.
- [88] T. Mikolov, I. Sutskever, K. Chen, G. Corrado, J. Dean, Distributed representations of words and phrases and their compositionality, in: *Proceedings of the 26th International Conference on Neural Information Processing Systems*, vol. 2, Red Hook, NY, USA, Dec. 2013, pp. 3111–3119.