

药物研发中的人工智能

收到日期: 2024 年 5 月 1 日

接受日期: 2024 年 11 月 25 日

在线发表日期: 2025 年 1 月 20 日

 检查更新

Kang Zhang^{1,2}, Xin Yang^{3,10}, Yifei Wang^{3,10}, Yunfang Yu^{4,5,6,10},
Niu Huang⁷, Gen Li^{1,6,8}, Xiaokun Li², Joseph C. Wu⁹ & Shengyong Yang³



药物研发是一项复杂且耗时的工作，传统上依赖药物研发人员的经验以及反复试验。人工智能（AI）技术的出现，尤其是新兴的大语言模型和生成式人工智能，正准备重新定义这一模式。将人工智能驱动的方法融入药物研发流程，已经为这一过程的效率和效果带来了细微但意义重大的提升。在此，我们概述了人工智能在药物研发整个工作流程中的最新应用进展，涵盖疾病靶点的识别、药物发现、临床前和临床研究以及上市后监测。最后，我们批判性地审视了当前面临的挑战，以突出人工智能增强药物研发的未来研究方向。

药物研发是一个多方面的过程，旨在开发新的药物来治疗疾病。它包括多个阶段，如靶点识别、药物发现、临床前研究、临床试验、监管审批以及上市后监测。目前，药物研发面临着诸多挑战，包括高昂的成本、漫长的时间周期以及较低的成功率^{1,2}。平均而言，开发一种新药需要约 26 亿美元的巨额投资，且可能需要 12 至 15 年才能完成³。不幸的是，即使在临床试验阶段，新药的成功率也低于 10%。造成这种情况的因素有很多。从根本上说，疾病往往复杂且多因素，这给有效治疗手段的确定带来了困难。药物研发过程本身也很复杂，涉及多个阶段，任何一个阶段的挫折都可能导致整个过程的失败。此外，为了寻找潜在的药物候选物，需要探索的化学空间估计在 10^{60-100} 量级，这使得药物发现就如同大海捞针一般⁴。最后，监管要求十分严格，达到安全性、有效性和质量方面的标准可能是一项耗时且成本高昂的工作。为了克服这些挑战，科学家们一直在积极探寻新技术和新方法以改进药物研发流程——人工智能有望从根本上改变这一领域。

人工智能领域的最新进展，包括图像识别、自然语言处理（NLP）和计算机视觉等，已展现出在解决药物研发关键难题方面的巨大潜力。特别是像 ChatGPT 和 Gemini 这样的大型语言模型，以及 Sora 等生成式人工智能，已展现出在某些方面超越人类智能的能力。人工智能处理海量数据的能力有望极大地加速和改进药物研发流程。因此，制药公司、生物技术企业和研究机构越来越多地采用人工智能驱动的方法来克服传统方法固有的障碍。人工智能已被证明在分析复杂的生物系统、识别疾病生物标志物和潜在药物靶点、模拟药物与靶点的相互作用、预测候选药物的安全性和有效性以及管理临床试验等方面具有重要价值。然而，必须认识到，人工智能驱动的药物研发仍面临若干独特的挑战。若不能有效解决这些障碍，人工智能的潜力可能无法得到充分发挥。

这篇综述探讨了自 2019 年以来人工智能在小分子药物开发中的最新应用；对于 2019 年之前的研究成果，建议读者查阅以往的相关资料。

¹Eye Hospital and Institute for Advanced Study on Eye Health and Diseases, Institute for clinical Data Science, Wenzhou Medical University, Wenzhou, China. ²State Key Laboratory of Macromolecular Drugs and Large-Scale Preparation, Wenzhou Medical University, Wenzhou, China. ³Department of Biotherapy, Cancer Center and State Key Laboratory of Biotherapy, West China Hospital, Sichuan University, Chengdu, China. ⁴Sun Yat-Sen Memorial Hospital, Sun Yat-Sen University, Guangzhou, China. ⁵Institute for AI in Medicine and faculty of Medicine, Macau University of Science and Technology, Macau, China. ⁶Guangzhou National Laboratory, Guangzhou, China. ⁷National Institute of Biological Sciences, Beijing, China. ⁸Eye and Vision Innovation Center, Eye Valley, Wenzhou, China. ⁹Cardiovascular Research Institute, Stanford University, Stanford, CA, USA. ¹⁰These authors contributed equally: Kang Zhang, Xin Yang, Yifei Wang, Yunfang Yu. e-mail: kang.zhang@gmail.com; yangsy@scu.edu.cn






图 1 | 人工智能在药物研发流程中的应用概览。药物研发流程涵盖多个关键阶段, 包括靶点识别、药物发现、临床前研究、临床试验、监管机构审查以及上市后监测。人工智能技术具有潜力

涵盖了几乎所有这些阶段的应用。CMC, 化学制造与控制; DMPK, 药物代谢与药代动力学。所有结构图均使用 UCSF ChimeraX 1.7.1 软件⁴⁴。

关于人工智能在天然产物药物发现中的应用, 可参*综述文献^{2,24,25}。如需获取更多详细信息, 请参阅最新综述 20。在*综述中, 我们首先介绍从靶点识别到合成规划的人工智能驱动的药物发现过程, 以及人工智能在药物开发临床阶段的应用, 包括生物标志物发现、药物再利用、药代动力学特性和毒性的预测以及临床试验的开展。最后, 我们讨论了人工智能驱动的药物开发所面临的挑战, 并概述了该领域的未来发展方向。我们希望阐明药物开发的新时代, 这个时代将充满创新、高效和精准, 有望加快为患者提供新药和更优药物的速度。

人工智能驱动的药物研发

近年来, 人工智能在药物研发领域崭露头角, 成为一股变革性的力量, 彻底改变了传统方法, 并在药物研发的多个阶段提高了效率。本节将探讨人工智能对药物研发各个方面的深远影响, 包括靶点识别、虚拟筛选、从头设计、吸收、分布、代谢、排泄和毒性 (ADMET) 预测以及合成规划和自动化合成与药物研发。通过利用先进的算法和技术, 研究人员现在能够加快新型治疗药物的发现, 提高预测的准确性, 并降低药物开发的整体时间和成本。

目标识别

小分子靶点 (如蛋白质或核酸) 的鉴定是药物研发中的关键步骤。传统的亲和力下拉法和全基因组敲低筛选法等方法被广泛采用, 但往往耗时费力, 且失败率较高。

人工智能技术的进步正在通过实现对复杂生物网络中大规模数据集的分析来彻底改变这一领域。人工智能通过构建多组学数据网络, 有助于识别与疾病相关的分子模式和因果关系, 从而促进候选药物靶点的发现^{例如}, 最近的研究利用自然语言处理技术 (如 word2vec 嵌入) 将基因功能映射到高维空间, 尽管基因功能重叠稀疏, 但仍提高

了靶点识别的灵敏度。然而, 高效整合多组学数据以及确保人工智能模型的可解释性仍是具有挑战性的任务。图深度学习技术通过将图结构与深度学习相结合, 专注于与关键特征 (例如原子类型、电荷) 相关的图节点, 从而有效地识别候选靶点。最近的一项研究成功开发了一个可解释的框架, 利用多组学网络图和图注意力机制有效地预测癌症基因。

此外, 将多组学数据与科学和医学文献整合到知识图谱中, 使人工智能能够识别基因与疾病通路之间的关系³³⁻³⁵。当生物医学大语言模型与生物网络或知识图谱功能深度融合时, 为疾病、基因和生物过程之间的关联提供了高效且精准的方法³⁶。例如, PandaOmics 平台 (<https://pharma.ai/pandaomics/>) 成功地利用多组学数据和生物网络分析, 识别出 TRAF2 和 NCK 相互作用激酶是抗纤维化治疗的潜在靶点, 从而开发出了特异性 TRAF2 和 NCK 相互作用激酶抑制剂 (INS018_055)³⁷。然而, 文献中潜在的发表偏倚表明, 需要补充方法来确保识别出新颖且相关的靶点。

真实世界的的数据, 例如医疗记录、自我报告、电子健康记录 (EHR) 和保险理赔数据, 为理解复杂疾病和促进靶点发现提供了重要的背景信息。然而, 真实世界的的数据通常包含非结构化的文本, 缺乏标准化, 并且可能存在偏差, 这限制了它们在这一领域的应用。尽管高质量、经过整理的数据集对于训练模型至关重要, 但真实世界的的数据本质上是嘈杂的, 并且由于多种疾病的相互影响而变得复杂。不过, 最近的研究表明, 尽管存在这些问题, 嘈杂的真实世界数据仍能训练出有效的模型, 从而在嘈杂的医疗记录和非专家疾病标注场景中推进基因发现和候选药物靶点的潜力。在不同人群中提高模型的泛化能力仍然是一个重大挑战, 尤其是对于标注率或患病率较低的疾病。随着真实世界和多组学数据变得越来越丰富, 利用先进的数据挖掘算法和专家知识将进一步促进它们的整合, 显著提高靶点发现的成功率。

虚拟筛选

虚拟筛选是高效识别潜在先导化合物或候选药物的关键策略。化合物库的迅速扩张使得对超大型库进行加速虚拟筛选成为必要，这推动了用于配体对接的人工智能技术的发展。基于人工智能的受体-配体对接模型能够预测配体的空间构型变化，利用诸如等变神经网络之类的算法直接生成复合物的原子坐标，并学习受体-配体距离的概率密度分布以生成结合构象。^{值得注意的}，近期基于 AlphaFold2 和 RosettaFold 的受体-配体共折叠网络在直接从序列信息预测复合物结构方面展现出巨大潜力。然而，由于对物理约束的学习不足，它们可能会生成不切实际的配体构象，因此需要进行后处理（例如能量最小化）或施加几何约束来优化对接构象的有效性。然而，基于深度学习的结合构象预测模型在以口袋为导向的对接任务中尚未超越基于物理的方法⁵⁴，并且它们常常未能充分考虑受体口袋的灵活性。此外，精确预测受体-配体相互作用仍是一项挑战。尽管早期机器学习在亲和力预测方面的成功引发了对深度学习模型的兴趣^{42,55}，并且这些模型通过处理三维结构⁵⁶和非结构化数据⁵⁷⁻⁶⁴可能优于传统的评分函数，但其性能在很大程度上取决于配体构象的准确性，并且主要适用于已知受体结构。

当目标结构缺失或不完整时，直接应用基于对接的虚拟筛选是不切实际的。作为替代方案，人工智能技术可用于基于序列的预测方法。然而，这类方法往往难以捕捉三维蛋白质-配体相互作用的复杂性，从而给准确预测结合构象的变化如何影响相互作用强度带来困难。

尽管针对特定靶点的药物开发对于明确靶点的疾病有效，但许多疾病缺乏这样的靶点。因此，基于表型的虚拟筛选对于靶点未明的疾病（例如罕见病）和广泛表型的疾病（例如衰老）至关重要⁶⁶⁻⁷²。最近的一项研究利用细胞核形态和机器学习来识别诱导癌细胞衰老的化合物⁷³；类似策略在抗生素发现方面也颇具前景⁶⁸。然而，此类模型往往依赖于特定病例的表型数据，并且在泛化方面存在困难。此外，仅依赖配体化学结构的人工智能活性预测面临着数据稀疏、不平衡以及活性悬崖等问题⁷⁴。近期研究⁷⁵表明，整合细胞形态和转录谱等相关的生物学信息能够提升模型性能⁷⁵，为更准确的活性预测提供了新的方向。

当前的虚拟筛选模型通常专注于特定任务，如打分⁷⁶、构象优化⁴⁸或筛选⁷⁷，这凸显了开发能够处理多种任务的通用模型的必要性⁷⁸。引入归纳偏差（即模型倾向于优先选择某些类型的解决方案而非其他类型）或数据增强（即在不收集新数据的情况下用于人工扩大训练数据集多样性的技术）可能会提高模型的泛化能力^{79,80}。此外，商业化合物库呈指数级增长至数十亿规模，使得全面筛选在计算上变得不可行⁸¹。与此同时，现有的分子库仅覆盖了可成药化学空间的一小部分，而这一空间仍在不断扩展——这既带来了机遇，也带来了在导航和筛选生物活性分子方面的挑战。

为应对这些挑战，主动学习和贝叶斯优化等技术是解决化学空间搜索问题的有效方法，成为提高虚拟筛选效率的关键。量子力学与人工智能的结合为化学空间探索提供了新工具，而分子动力学模拟则为蛋白质配体相

互作用增添了深度，解决了结合亲和力和选择性的问题，从而提高了模型的准确性。同时，通过为特定目标或化合物类型生成定制的虚拟库，深度生成模型极大地缩小了搜索空间，提高了筛选效率。例如，我们的条件循环神经网络生成了一个定制库，在细胞和动物模型中识别出了一种高效且具有选择性的 RIPK1 抑制剂。

从头设计

从头药物设计涉及自主创建新的化学结构，以最优方式满足所需的分子特性。传统方法包括基于结构、基于配体和基于药效团的设计，这些方法都是手动操作，依赖于专家设计人员和明确的规则。人工智能，尤其是深度学习，能够自动识别满足特定要求的新结构，从而绕过了传统专业知识。该技术已成功应用于开发小分子抑制剂、PROTACs、肽和功能性蛋白质，这些成果均通过湿实验室实验得到验证，从而开启了更高效、更创新的药物发现时代。

在深度学习驱动的头设计（图 2）中，分子生成组件处于核心地位，通常采用化学语言或基于图的模型。化学语言模型将分子生成任务转化为序列生成任务，例如 SMILES 字符串（“简化分子线性输入规范”，一种以线性文本格式表示化学结构的符号系统）。尽管需要大量的预训练，并且可能会因语法错误而生成无效的 SMILES 字符串，但这些错误有助于通过过滤不太可能的样本实现模型的自我校正。⁸²长短期记忆模型（一种分析序列数据的深度学习模型）这样的模型会面临信息压缩瓶颈，这阻碍了对全局序列属性的学习，这表明需要像 Transformer 这样的架构来更好地捕捉全局特性。最近的研究将结构化的状态空间序列整合到化学语言模型中，揭示了高化学空间相似性以及关键天然产物设计特征的对齐，证明了该模型在头设计中的实用性。

相反，基于图的模型将分子表示为图，使用自回归或非自回归策略生成结构¹⁰⁰⁻¹⁰³。自回归方法逐个原子构建分子，这可能导致化学上不合理中间体并引入偏差^{101,102}。相比之下，非自回归方法一次性生成整个分子图，但需要额外步骤来确保图的有效性，因为这些模型对分子拓扑结构的感知有限，可能会生成有缺陷的结构¹⁰⁴。

鉴于药物类化学空间的广阔性，从头生成通常会引导设计朝着目标特征发展，采用基于与已知活性分子的相似性以及预测生物活性等指标的评分函数等优化机制。将强化学习用于迭代优化是一种有效的方法，但设计合适的评分函数颇具挑战性，因为直接量化合成可行性或药物类特性等目标较为困难，这往往会导致意外后果。此外，强化学习的大量优化步骤凸显了样本效率方面的挑战，而主动学习或课程学习等策略或许能够缓解这一问题。

除了引入评分函数外，纳入诸如疾病相关基因表达特征¹⁰⁹、药效团¹¹⁰、蛋白质序列⁸⁷或结构¹⁰²、¹¹¹⁻¹¹⁴、结合亲和力¹¹⁵以及蛋白质-配体相互作用¹¹⁶、¹¹⁷等约束条件，也能引导模型生成所需的分子。例如，我们的 PocketFlow 模型在蛋白质口袋的条件下，有效地生成了针对 HAT1 和 YTHDC1 目标的经实验验证的活性化合物，展示了其药物设计能力¹⁰²。此外，模型还可以通过

尽管会限制化学多样性，但仍可将输出结果限定在特定的支架结构或期望候选物的片段¹。

ADMET

药物的吸收、分布、代谢、排泄和毒性 (ADMET) 特性在决定药物的有效性和安全性方面起着关键作用。尽管药物上市前的湿实验评估是必不可少的，且无法完全被模拟所取代，但早期的 ADMET 预测有助于减少因药物特性不佳而导致的失败。人工智能已成为一种有价值的工具，能够利用诸如分子指纹或描述符等预定义特征来预测 ADMET 特性。例如，拜耳公司的计算机辅助 ADMET 平台采用随机森林和支持向量机等机器学习技术，并使用诸如圆形扩展连接指纹等描述符来确保预测的准确性和相关性。在过去几十年中，人们开发出了多种用于 ADMET 预测的描述符，然而，这些基于特征的方法所涉及的特征工程仍然复杂，限制了其通用性和灵活性。

深度学习如今推动了 ADMET 预测的发展，能够从简单的输入数据中自动提取有意义的特征。包括用于有效处理序列数据的转换器 (transformers)¹²⁵⁻¹²⁷、常用于图像和视频识别任务的卷积神经网络 (convolutional neural networks)¹²⁸ 以及最近出现的用于处理图结构数据 (如分子结构) 的图神经网络 (graph neural networks)^{78,129} 在内，各种神经网络架构在从 SMILES 字符串和分子图等格式中建模分子特性方面表现出色。其中，SMILES 字符串提供了紧凑的分子表示形式，能够清晰地表达支链、环和手性等子结构，但缺乏拓扑意识——而图神经网络 (如 GeoGNN 模型¹²⁹) 则融合了几何信息，在 ADMET 预测方面表现出色。事实上，最近的一项研究¹²⁶ 表明，使用 SMILES 输入的转换器模型在完整结构识别方面存在困难。对于涉及毒性等性质的预测，这些模型生成的表示的性能可能在训练进行到一定程度时就趋于饱和，在训练后期改进有限。

尽管新型深度学习算法推动了该领域的发展，但其仍面临诸多挑战。高昂的成本和大量的时间投入导致 ADMET 预测中可用的标注数据稀缺，从而可能引发过拟合问题。无监督和自我监督学习提供了应对方案，尽管基于大型转换器的模型在其他领域展现出巨大潜力，但在 ADMET 预测中的应用仍处于探索阶段。最近的一项研究¹³⁰ 表明，尽管 SMILES 语言并未直接编码分子拓扑结构，但通过精心设计的自我监督训练，利用配备线性注意力机制的上下文转换器，能够有效地学习隐含的结构-性质关系，这增强了将大规模自我监督模型应用于 ADMET 预测的信心。


图 2 | 药物研发中基于人工智能的分子生成流程。

分子表示形式——一维 (1D)、二维 (2D) 和三维 (3D) 结构——源自各种化合物、靶点和药物-靶点相互作用数据库，并用于训练诸如生成对抗网络 (一种由生成器和判别器两个相互竞争的网络组成的神经网络架构，二者协同工作以生成逼真的数据样本)、循环神经网络 (用于处理序列数据)、变分自编码器 (学习将输入数据编码到潜在空间，然后再解码以重构原始数据的生成模型)、归一化流 (通过一系列可逆变换将简单概率分布转换为更复杂分布的一类生成模型) 和扩散模型 (通过模拟扩散过程生成数据的生成模型) 等人工智能模型。这些模型生成新的分子，随后对其化学有效性、合成可及性和类药性进行评估，最终实现新类药化合物的识别。所有结构图均使用 UCSF ChimeraX 1.7.1 软件绘制。

此外，分子表示对于人工智能的性能至关重要。高维表示通常比低维表示提供更丰富的信息。然而，近期研究表明，整合分子表示的多个层次能够显著增强学习效果，从而实现更全面、更具通用性和更稳健的 ADMET 预测^{78,131,132}。这表明同时使用多种表示的多模态 ADMET 模型具有前景，尽管最佳的数据类型组合仍有待解决。

数据库

- 化合物数据库: ZINC、GDB-17
- 目标数据库: UniProt、蛋白质数据库 (PDB)
- 电子显微镜数据库 (EMDB)
- 药物靶点相互作用数据库: ChEMBL、DrugBank
- BindingDB, CrossDock2020






图 3 | 药物发现中的人工智能驱动合成规划与自动化。 a, 合成规划。合成规划过程始于逆合成分析, 将目标分子分解为市售或已知的构建模块, 随后进行反应预测, 以预测合成目标分子所需的化学反应和条件。b, 自动化合成。示意图展示了人工智能驱动的软件与实验执行和结果分析在自动化合成过程中的无缝集成。

可解释性仍然是一个重大挑战。理解 ADMET 预测中的模型参数有助于揭示分子亚结构与性质之间的关系^{133,134}。注意力机制能让模型聚焦于输入数据的重要部分, 通过识别关键原子或基团来增强可解释性¹³⁵。整合化学知识¹³⁶可进一步增强可解释性, 但要扩展模型以实现全面的化学理解仍颇具挑战性。

合成规划以及合成与药物发现的自动化

化学合成是小分子药物研发中的瓶颈之一, 是一项技术要求高且极其费力的工作。计算机辅助合成规划 (CASP) 和有机化合物的自动合成能够帮助减轻化学家重复性繁重工作的负担, 使他们能够从事更具创新性的工作。随着人工智能的迅速发展, 制药行业和学术界对实现这一过程的智能化和自动化越来越感兴趣。

计算机辅助合成规划 (CASP) 已被用作辅助化学家通过逆合成分析确定反应路线的工具, 这是一种问题解决技术, 其中目标分子被递归地转化为越来越简单的前体 (图 3a)。早期的 CASP 程序基于规则 (例如, 应用于合成分析、化学合成的模拟和评估¹⁴³ 以及基于逆合成的合成可及性评估¹⁴⁴ 程序的逻辑和启发式方法)。此后, 开发了一系列机器学习技术, 特别是深度学习模型, 从而在人工合成小分子¹⁴⁵⁻¹⁴⁷ 和天然产物^{148,149} 的合成规划方面取得了逐步的改进。最近, Transformer 模型也被应用于逆合成分析^{150,151}、区域选择性预测 (即在具有多个可能反应位点的分子上, 化学反应倾向于在某一特定位置而非其他位置发生) 和立体选

择性预测 (即当存在多种立体异构产物时, 反应倾向于生成一种立体异构体而非另一种¹⁵²) 以及反应指纹提取¹⁵³。对于纯数据驱动的人工智能方法在复杂合成规划中的适用性存在担忧, 这促使了融合化学规则的专家-人工智能混合系统的开发^{145,146}。然而, 目前大多数深度学习方法难以解释, 表现为“黑箱”, 提供的见解有限。为了解决这一挑战, 最近推出了一种新的逆合成预测模型 RetroExplainer, 它采用了一种可解释的深度学习框架, 将逆合成任务重新定义为分子组装过程。与最先进的逆合成方法相比, RetroExplainer 表现出了更优越的性能。值得注意的是, 其分子组装方法增强了可解释性, 能够实现透明的决策制定和定量归因¹⁵⁴。

有机化合物的自动化合成是化学相关领域 (图 3b) 的一个前沿领域, 包括药物化学。一个理想的自动化合成平台应能无缝整合并优化化学开发过程中的各个组成部分, 包括计算机辅助合成规划 (CASP)、自动化实验设置与优化, 以及机器人执行的化学合成、分离和纯化。近来, 用于药物化合物合成的深度学习驱动的自动化流动化学^{145,147,155,156} 和固相合成¹⁵⁷ 技术受到了相当大的关注。特别是, 自动化合成与设计、测试和分析技术相结合, 形成了药物发现中的一个自动化核心流程, 即设计-合成-测试-分析 (DMTA) 循环。通过利用深度学习, DMTA 循环的效率得到了显著提高, 从而加快了药物发现中先导化合物和候选化合物的发现速度^{147,155,158}。例如, 通过使用具有深度学习功能的 AI 驱动的药物分子设计与合成自动化 (DMTA) 平台以及用于芯片上化学合成的微流控技术, 从零开始生成了肝 X 受体激动剂¹⁴⁷。此外, 人们认为大型语言模型 (LLMs)^{159,160} 能够“理解”人类的自然语言, 这使得自动化平台能够根据研究人员提供的简短输入为特定挑战提供量身定制的解决方案。尽管自动化合成和自动化 DMTA 循环具有广阔的前景, 但其发展仍处于起步阶段。许多技术挑战仍然存在, 包括需要减少固体形成以避免堵塞、预测非水溶剂中的溶解度以及不同温度下的溶解度、估计最佳纯化方法以及优化多步反应。

在新药化合物的规划与合成之后, 人工智能技术有助于对新药作用机制 (MOA) 进行体内验证。在高内涵筛选中, 通过监测组学数据的实时变化, 人工智能技术能够归纳这些特征, 并开发出一种模型, 能够解读新化合物的分子和细胞作用机制及其相关的药代动力学、药效学、毒理学和生物利用度特性 (图 4)¹⁶¹⁻¹⁶⁴。

人工智能在临床试验和实际应用中的运用

人工智能通过分析患者数据 (包括基因信息、临床病史和生活方式因素) 在临床试验的各个方面发挥着越来越重要的指导作用。将人工智能方法应用于此类数据有助于识别影响药物反应的生物标志物和患者特征, 从而实现更高效、更有信息量的试验设计。通过优化患者选择、治疗方案和结果测量等参数, 人工智能有可能提高试验成功率, 并加快候选药物向临床实践的转化。真实世界数据也为人工智能应用提供了丰富的信息来源, 可用于预测不良事件、药物相互作用和其他结果。以下各节描述了人工智能在药物开发临床阶段的关键应用。




图 4 | 利用高内涵筛选和多组学数据进行人工智能驱动的药物作用机制预测。 a, 高内涵筛选中, 细胞在多孔板中培养, 用具有已知药物作用机制或信号通路的多种药物 (上) 或全基因组基因表达干扰 (下) 处理不同孔。CRISPR, 成簇规律间隔短回文重复序列; siRNA, 小干扰 RNA。b, 每个孔内, 随时间变化的多组学特征、标记染色模式和细胞形态特征的数据

这些信息与相应的作用机制 (MOA) 或基因信号通路变化的知识相结合, 并用于训练一个人工智能模型, 以了解每种药物对细胞网络的影响。c, 因此, 该人工智能模型将能够预测具有类似多组学和细胞形态特征的新化合物的作用机制。图 b 和 c 中的网络图像改编自 [STRING248](#), 遵循知识共享许可协议 [CC BY 4.0](#)。

生物标志物发现

生物标志物是客观衡量和评估正常生理过程与病理过程以及治疗反应的生物学指标, 在医学、生物技术和生物制药领域具有巨大价值。然而, 传统的基于假设的生物标志物发现方法往往效率低下, 且无法全面应对疾病的复杂性。这些方法耗时且需要大量资源来验证假设, 而样本量有限的限制又阻碍了在不同人群中进行广泛验证。

人工智能的最新进展极大地促进了生物标志物的发现。人工智能模型在识别诊断性生物标志物方面表现出色, 为临床病理学提供了预测性见解和诊断参考¹⁶⁵。一个显著的例子是“nucleio”数字病理学框架¹⁶⁶, 将主动学习与实时的人机交互相结合。通过高效地构建用于各种外科病理学任务的数据集和人工智能模型, 该框架能够基于核统计数据为病理学家提供精确反馈, 从而大幅提高诊断的准确性和效率。

人工智能在识别对预测疾病进展和患者生存至关重要的预后生物标志物方面表现卓越, 从而能够实现有针对性的个性化治疗。例如, 深度学习模型能够描绘出血液样本中 CD8⁺ T 细胞的形态, 将其作为有效的败血症预后指标¹⁶⁷, 区分出标志细胞衰老的核特征¹⁶⁸, 并识别蛋白质组学生物标志物以准确¹⁶⁹预测肝病的结局。人工智能还能预测各种癌症的预后生物标志物, 提供生存、复发和转移的精确风险评分。值得注意的是, 使用图神经网络的生存分析模型优于现有模型, 能够有效地

超越传统的临床分级和分期来区分风险群体^{170,171}——[强调](#)人工智能在改善预后方面的潜力以及病理学家与人工智能之间的关键协作。

在药物研发过程中, 识别预测性生物标志物对于通过筛选最有可能从治疗中获益的患者群体来提高研究成功率至关重要。这些发现需要严格的前瞻性临床验证。尽管基于人工智能的预测性生物标志物尚未在临床上应用, 但概念验证研究表明, 人工智能能够通过预测微卫星不稳定性等已知生物标志物来预测患者对治疗的反应¹⁷²⁻¹⁸³。生物系统的复杂性要求将包括蛋白质-蛋白质相互作用在内的多种类型的生物数据整合到人工智能模型中, 以实现更全面的预测¹⁸⁴。

面对大型标注数据集稀缺的问题, 研究人员正在采用多种策略来优化人工智能在生物标志物发现中的应用。整合来自多个来源的数据集展现出巨大潜力^{171,185,186}。来自可穿戴传感器的数字生物标志物也扩大了发现范围, 提供了丰富的纵向数据集^{187,188}。通过分子诊断、影像组学和组织病理学成像来识别多模态生物标志物为精准医疗开辟了新途径^{23,171,189,190}。此外, 群智学习¹⁹¹和自动化数据¹⁹²处理流程¹⁹²为大规模、安全的数据收集奠定了基础。

然而, 人工智能模型在异质性方面面临挑战, 这阻碍了其在临床试验中的转化效率。一些研究利用深度学习来阐明细胞和组织层面的异质性以及肿瘤生态系统的多样性, 为疾病亚型分类和患者分层提供了新的途径¹⁹³⁻¹⁹⁶。可解释性和可信度对于临床对人工智能模型的接受至关重要¹³³, 并且可以

通过整合先前的医学知识¹⁹⁷ 或将生物学关系嵌入神经网络¹⁹⁸ 来加以增强。解决人工智能驱动的生物标志物发现中的偏见问题¹⁹⁹⁻²⁰¹ 需要采取诸如在地域多样化的患者队列中验证模型²⁰² 以及开发公平透明的算法^{203,204} 等策略。^{稳健} 的验证和负责任的数据管理将有助于生物标志物的识别和应用, 从而支持未来的药物开发和疾病治疗。

预测药代动力学性质

应用人工智能和大数据工具能够有效解决药代动力学问题, 并为事件发生时间分析提供强大的工具, 尤其是在处理高维数据和风险函数中的非线性关系方面。人工智能通过优化剂量反应关系、改善药物安全性特征以及细化治疗窗口来支持个性化治疗, 这些对于解决精准医疗中的药代动力学问题至关重要。基于机器学习对 442 种小分子激酶和 2145 种不良事件的分析, 发现了新的激酶 - 不良事件配对, 有助于降低风险并开发更安全的小分子激酶抑制剂。多组学变分自编码器 (MOVE) 框架整合多组学数据, 揭示药物相互作用 (如^{二甲}双胍与肠道微生物群之间的联系), 并比较不同组学模式下的药物反应。^{PharmBERT} 是一种特定领域的语言模型, 通过从处方标签中提取关键的药代动力学信息来提高药物安全性, 有助于^{识别} 不良反应和药物相互作用。人工智能还通过分析基因和生理数据来优化药物剂量, 从而为患者提供个性化的治疗建议, 改善治疗效果。此外, 人工智能能够分析患者的基因信息、生理特征以及过往治疗反应, 为医生提供个性化的剂量调整建议, 从而优化治疗结果。

药物再利用

除了新药研发, 人工智能还通过利用大规模生物医学数据集重新定位已获批的现有药物, 从而为药物库做出贡献, 加快了针对各种疾病的最优治疗方案的开发。通过发现已获批药物此前未被识别的治疗特性, 人工智能减少了药物研发的时间和成本。例如, 人工智能加速了针对 2019 冠状病毒病的药物再定位 (参考文献 209), 突显了人工智能在为现有药物寻找全新应用方面的价值。人工智能还可以利用真实世界的数据 (包括电子健康记录和保险理赔数据) 模拟临床试验, 以促进药物再定位。作为这种方法的一个实例, 一个深度学习循环神经网络使用因果推断和深度学习来分析医疗理赔数据库, 有效地识别出潜在的药物候选者。当应用于数百万冠状动脉疾病患者队列时, 它确定了能改善预后的药物和药物组合。

另一种基于深度学习的药物再利用方法是将深度神经网络应用于组学数据, 根据药物在体外诱导的转录扰动将其分类到不同的治疗类别中。一项研究利用了来自 LINCS 项目 (<https://lincsproject.org/>) 的扰动样本以及从医学主题词表 (MeSH) 中得出的 12 个治疗类别, 从而实现了较高的分类准确率——尤其是在跨多种生物系统和条件的通路水平数据方面——为药物重新定位提供了可能。特征归因技术与可解释机器学习模型的集成, 有助于识别与药物协同反应相关的基因表达特征。这种策略已被证明能够提高特征的可解释性, 并支持基于分子见解选择最佳的抗癌药物组合。

此外, 基于人工智能的高内涵筛选技术也可应用于药物再利用 (图 4)。开发了一种深度学习模型 M

itoReID, 通过线粒体表型分析来识别药物作用机制 (MOAs)。它为药物发现和再利用提供了一种经济高效、高通量的解决方案, 并通过未见过的药物 (未包含在训练集中) 进行了验证, 且在体外实验中得到了验证¹⁶³。通过分析 570,096 张细胞图像, MitoReID 在识别美国食品药品监督管理局批准药物的 MOAs 方面达到了 76.32% 的准确率, 并成功验证了茶中天然化合物表儿茶素对环氧化酶 -2 的抑制作用。然而, 人工智能驱动的药物开发其他阶段所面临的许多挑战也适用于药物再利用, 包括数据质量问题、模型可解释性、泛化能力、验证成本、监管障碍、与现有流程的整合以及高计算需求, 这些都阻碍了其广泛应用和实际实施。

提高审判效率和预测审判结果

临床试验通常成本高昂、耗时且效率低下, 大多数试验在注册时会遭遇延误, 或者难以招募到足够的志愿者。人工智能 (AI) 具有优化试验设计、简化招募流程以及预测患者反应的潜力, 从而提高试验效率和成功率, 同时降低成本和缩短时间。已开发出一套先进的流程, 该流程整合了多模态数据集, 利用 AI 生成分子先导化合物, 根据有效性和安全性对其进行排序, 并使用深度强化学习生成可申请专利的类似物进行测试。它还能通过估算副作用和通路激活情况来预测 I/II 期临床试验的结果, 从而提高预测准确性, 并识别药物组合中的潜在风险。在真实世界的研究中, AI 可以分析来自电子健康记录 (EHR)、保险理赔和可穿戴设备的数据, 以评估药物的有效性和安全性 (图 5)。例如, 一项使用真实世界数据和 Trial Pathfinder 工具的研究, 从 61,094 名晚期肺癌患者的 EHR 数据中模拟了试验结果, 表明放宽试验标准可以使符合条件的患者数量翻倍, 并改善生存结果。这种方法已在多种癌症中得到验证, 有助于开展更包容、更安全的临床试验。

Unlearn.ai 公司探索了利用数字孪生技术来缓解寻找符合纳入标准的合适患者这一难题。该技术能创建参与者的虚拟复制品, 使其充当对照组, 从而增加实验组的参与者数量, 提高试验效率。2020 年 4 月, Unlearn.ai 获得了 1200 万美元的资助以推进这一应用 (<https://medcitynews.com/2020/04/funding-roundupcompany-creating-digital-twins-for-clinical-trials-raises-12m/>), 而 Novartis 和 Jinkō 等其他公司也在基于数字孪生技术开展针对肺癌等疾病的临床试验模拟 (<https://www.novainsilico.ai/new-demonstration-of-the-predictive-power-of-an-in-silico-clinical-trial-in-oncology/>)。所提出的方法基于基因表达和临床数据进行计算机建模, 结合深度学习和生成对抗网络²¹⁴。通过利用各种健康指标, 这些数字孪生能够为关键过程提供定量见解, 提供动态健康指导并优化治疗策略。这种方法旨在深化对生物机制的数学理解, 彻底变革临床实践, 并全面实现医疗个性化, 例如通过生成基于药物输入预测生存概率的患者特异性模型。这些模型还能实现临床试验的模拟, 并优化试验参数, 从而提高试验成功的可能性。但它们也面临诸多挑战, 包括高昂的计算成本、棘手的工作流程整合、伦理问题以及有限的个性化程度。这些问题影响患者模拟的准确性、试验设计以及监管机构的接受度, 从而减缓了创新的步伐。

在药物研发的临床试验阶段之后, 人工智能还能分析上市后的监测数据, 以支持药物的安全性、有效性和质量。开发并同时使用替代方法, 尽早识别并解决安全问题, 这一点也至关重要。




图 5 | 利用人工智能能力提升临床试验流程和现实医疗实践。**a**, 训练过程: 训练过程涉及使用多样化的临床和试验数据 (电子健康记录、可穿戴设备、基因组学、影像学) 通过多模态嵌入和生成式人工智能开发人工智能语言模型。它评估药物疗效、优化试验方案, 并实现智能的临床前和临床研究。**b**, 验证

验证及预测流程: 通过真实世界数据和临床试验数据对 AI-LLM 进行验证, 并结合治疗效果和不良事件进行微调。它能够预测药物疗效、评估试验方案的可行性并优化试验, 从而实现智能的临床前和临床研究, 加速药物研发进程。

监管审查流程对于推进监管科学以及优化药物研发至关重要。

216,217

挑战

尽管取得了进展, 但目前还没有由人工智能开发的药物进入过二期临床试验之后的阶段, 这凸显了药物研发的复杂性。一个关键的挑战在于高质量训练数据的缺乏, 这是由于获取成本高昂、隐私法规以及数据共享有限 (尤其是对于罕见疾病或新型药物靶点而言) 造成的, 这限制了人工智能在识别靶点、生物标志物和其他功能方面的有效性。此外, 现有的数据往往存在信息缺失、错误和偏差, 进一步降低了人工智能的可靠性。药物发现实验可能会产生不一致的结果, 而节省成本的措施可能会导致数据不完整。另外, 文献中对“负面”数据 (例如, 不成功的实验和负面的试验结果) 的代表性不足, 阻碍了对药物-靶点-疾病相互作用、疗效和其他临床特征的全面理解。

药物设计中的一个关键挑战在于平衡多个成功目标。当前的研究往往过于关注化学空间, 而忽视其他关键因素 (如成药性和可合成性)。尽管多目标设计方法正在改进^{220,221}, 但开发有效的评分函数 (例如亲和力预测和生物活性) 仍然复杂, 且需要大量的实验。缺乏标准化的评估流程进一步使模型评估变得复杂^{222,223}, 尤其在出现冲突目标时, 比如在追求与已知生物活性分子的最大相似度的同时实现结构新颖性。尽管存在像 MOSES224 和

uacamol225 这样的基准平台, 但最佳实践的共识尚未达成。

在生成模型中, 恰当的分子表示至关重要。传统方法如简化分子线性输入规范 (SMILES) 和分子图等较为常见²²⁶, 同时新的数据驱动方法如分层分子图自监督学习^{131,227,228}也逐渐兴起。然而, 捕捉分子的复杂性并确保其可合成性颇具难度。目前评估合成可行性的方法往往不够精确, 导致发现无法合成的分子。将反应知识融入分子生成中颇具前景, 但仍有待改进^{146,208}。模型的可解释性、生成新分子时的不确定性²⁰⁸以及偏差²²⁹等问题已成为学术界关注的焦点。有效结合偏差控制与不确定性估计对于提升生成分子的质量至关重要。

人工智能在应对所谓的“不可成药”靶点方面面临挑战, 这些靶点缺乏合适的结合位点, 包括某些无序蛋白质、转录因子 (如 MYC 和 IRF4) 以及蛋白质-蛋白质相互作用。采用新的人工智能方法和高内涵筛选 (图 4) 来探索其构象空间并识别配体结合位点, 可能有助于克服这些障碍。

最后, 算法和计算能力方面的技术难题限制了人工智能在药物研发中的应用。许多用于药物研发的人工智能算法是为其他领域设计的, 可能并不完全适用; 例如, 需要基于自然语言处理的新算法来捕捉三维空间中的相互作用。此外, 人工智能方法所需的大量计算资源也构成了障碍, 尤其是对于规模较小的研究团队而言。与

云服务供应商以及开发更高效的算法有助于应对这些挑战。此外，由于周期长、成功率低以及回报不确定，人工智能药物研发面临人才短缺和投资风险，这影响了投资者的信心。

未来方向

人工智能正在通过从复杂的多组学生物医学数据中提取关键见解，识别新的生物标志物，检测治疗靶点和异常情况，从而彻底改变药物研发流程，以促进先导化合物和候选药物的发现。此外，人工智能还加快了药物发现、药物再利用和毒性预测的速度，从而减少了时间、成本和安全风险。然而，要完全实现人工智能在这一领域的进步，还有很长的路要走，有许多挑战需要克服，也有巨大的潜力有待挖掘。未来为解决上述挑战所做的努力应特别注重几个关键方向。

首先，开发新的策略以解决人工智能辅助药物研发中的数据稀缺问题应是首要任务。可行的策略包括加强数据共享、建立数据标准以及开发新的 AI 算法，例如能够从极少量数据中生成准确预测的“稀疏”AI 方法。整合文本和化学信息的多模态预训练模型在解决数据稀缺问题方面展现出巨大潜力，尤其是在零样本场景中。通过整合基因组学、转录组学、疾病特异性分子通路、蛋白质相互作用和临床记录等各类数据，AI 还能够识别出可用于治疗被忽视疾病或罕见病的现有药物的再利用机会。

目前的方法通常只关注单一的数据类型，从而忽略了各种生物系统之间的复杂相互关系。建立有效的多模态融合方法可以从不同来源和格式中提取有价值的信息，从而推动药物研发。随着大数据和基于图形处理单元（GPU）而非传统中央处理单元（CPU）的计算技术的兴起，人工智能现在可以应用于包括文本、图像和视频在内的各种数据形式。利用包括基于深度学习的药物分类在内的组学数据的新兴模型，在药物疗效预测、作用机制识别和毒性评估方面展现出巨大潜力，凸显了多模态人工智能在药物研发中的未来前景。

许多当前的人工智能模型完全是数据驱动的，由于缺乏足够高质量的数据，这限制了它们在药物开发中的有效性。因为我们的生命系统都遵循物理原理（也称为第一性原理），药物也不例外地受到物理定律的约束。将物理定律融入现有的数据驱动型人工智能算法是未来的一个研究方向，这有助于降低对数据的依赖，并提高这些模型的准确性和通用性。

人工智能，尤其是大型语言模型，能够通过分析大量文件并紧跟最新要求来确保药物符合相关法规。这提高了效率，降低了违规风险，并避免了药物审批的延误。开发不仅准确而且可解释的人工智能模型对于在药物开发者、监管机构、临床医生和患者之间建立信任至关重要，因为这能确保决策过程的透明度和可理解性。这些模型可以尽早融入，以优化项目资金并指导投资，从而加快药物研发进程。

在未来几十年，人工智能在医学建模和模拟中的作用将发生变革。先进的 AI 模型将创建更精细的虚拟人体模拟，进一步加深我们对疾病机制、药物作用以及个体生物差异的理解。通过模拟，人工智能能够优化临床试验的设计和执​​行，测试不同的场景以确定最佳的选择标准，从而加快患者招募并提高试验的代表性。人工智能还将通过分析健康数据和基因组学，为个性化医疗决策提供支持，实

现精准的风险预测、优化治疗方案以及改进手术指导。医学教育也将受益于人工智能驱动的虚拟现实技术，提供更真实的训练场景，从而提升医疗服务的质量。

结论

总体而言，人工智能技术的持续进步极大地提高了药物研发的效率和成本效益。然而，必须认识到人工智能并非无所不能。人工智能技术的优势在于分析大量复杂的数据，并辅助快速决策，以补充人类的功能并增强人类的能力，但人工智能并非旨在完全取代人类的创造力或权威。由人工智能设计的药物及其预测的特性仍需通过湿实验室实验进行验证，而且在确定人工智能研究和应用的方向方面，仍需要人类的投入。尽管如此，鉴于人工智能能力的不断增强、发展速度的加快以及包括近期的 AlphaFold3（参考文献 246）在内的大型模型的开源，我们有理由对人工智能在加速药物研发和造福人类健康方面的前景保持审慎乐观。

参考文献

1. Paul, S. M. et al. How to improve R&D productivity: the pharmaceutical industry's grand challenge. *Nat. Rev. Drug Discov.* **9**, 203–214 (2010).
2. Vamathevan, J. et al. Applications of machine learning in drug discovery and development. *Nat. Rev. Drug Discov.* **18**, 463–477 (2019).
3. DiMasi, J. A., Grabowski, H. G. & Hansen, R. W. Innovation in the pharmaceutical industry: new estimates of R&D costs. *J. Health Econ.* **47**, 20–33 (2016).
4. Mullard, A. The drug-maker's guide to the galaxy. *Nature* **549**, 445–447 (2017).
5. Wang, H. et al. Scientific discovery in the age of artificial intelligence. *Nature* **620**, 47–60 (2023).
6. Van Dis, E. A., Bollen, J., Zuidema, W., Van Rooij, R. & Bockting, C. L. ChatGPT: five priorities for research. *Nature* **614**, 224–226 (2023).
7. Gemini Team Google. Gemini: a family of highly capable multimodal models. Preprint at <https://arxiv.org/abs/2312.11805> (2023).
8. O'Callaghan, J. How OpenAI's text-to-video tool Sora could change science—and society. *Nature* **627**, 475–476 (2024).
9. Sadybekov, A. V. & Katritch, V. Computational approaches streamlining drug discovery. *Nature* **616**, 673–685 (2023).
10. Savage, N. Tapping into the drug discovery potential of AI. *Biopharm. Deal.* <https://doi.org/10.1038/d43747-021-00045-7> (2021).
11. Dealmakers, B. Generative AI platforms drive drug discovery dealmaking. *Biopharm. Deal.* <https://doi.org/10.1038/d43747-024-00084-w> (2024).
12. Cohen, A. A. et al. A complex systems approach to aging biology. *Nat. Aging* **2**, 580–591 (2022).
13. Neftci, E. O. & Averbeck, B. B. Reinforcement learning in artificial and biological systems. *Nat. Mach. Intell.* **1**, 133–143 (2019).
14. Steyaert, S. et al. Multimodal data fusion for cancer biomarker discovery with deep learning. *Nat. Mach. Intell.* **5**, 351–362 (2023).
15. You, Y. et al. Artificial intelligence in cancer target identification and drug discovery. *Signal Transduct. Target. Ther.* **7**, 156 (2022).
16. Pun, F. W., Ozerov, I. V. & Zhavoronkov, A. AI-powered therapeutic target discovery. *Trends Pharmacol. Sci.* **44**, 561–572 (2023).
17. Bagherian, M. et al. Machine learning approaches and databases for prediction of drug–target interaction: a survey paper. *Brief. Bioinform.* **22**, 247–269 (2021).

18. Zhang, Z. et al. Graph neural network approaches for drug–target interactions. *Curr. Opin. Struct. Biol.* **73**, 102327 (2022).
19. Catacutan, D. B., Alexander, J., Arnold, A. & Stokes, J. M. Machine learning in preclinical drug discovery. *Nat. Chem. Biol.* **20**, 960–973 (2024).
20. Mullowney, M. W. et al. Artificial intelligence for natural product drug discovery. *Nat. Rev. Drug Discov.* **22**, 895–916 (2023).
21. Al-Worafi, Y. M. *Technology for Drug Safety: Current Status and Future Developments* (Springer, 2023).
22. Subbiah, V. The next generation of evidence-based medicine. *Nat. Med.* **29**, 49–58 (2023).
23. Acosta, J. N., Falcone, G. J., Rajpurkar, P. & Topol, E. J. Multimodal biomedical AI. *Nat. Med.* **28**, 1773–1784 (2022).
24. Yang, X., Wang, Y., Byrne, R., Schneider, G. & Yang, S. Concepts of artificial intelligence for computer-assisted drug discovery. *Chem. Rev.* **119**, 10520–10594 (2019).
25. Schneider, P. et al. Rethinking drug design in the artificial intelligence era. *Nat. Rev. Drug Discov.* **19**, 353–364 (2020).
26. Chen, H. et al. Drug target prediction through deep learning functional representation of gene signatures. *Nat. Commun.* **15**, 1853 (2024).
27. Tasaki, S. et al. Inferring protein expression changes from mRNA in Alzheimer’s dementia using deep neural networks. *Nat. Commun.* **13**, 655 (2022).
28. Rodriguez, S. et al. Machine learning identifies candidates for drug repurposing in Alzheimer’s disease. *Nat. Commun.* **12**, 1033 (2021).
29. Schulte-Sasse, R., Budach, S., Hnisz, D. & Marsico, A. Integration of multi-omics data with graph convolutional networks to identify new cancer genes and their associated molecular mechanisms. *Nat. Mach. Intell.* **3**, 513–526 (2021).
30. Hong, C., Cao, Q., Zhang, Z., Tsui, S. K.-W. & Yip, K. Y. Reusability report: capturing properties of biological objects and their relationships using graph neural networks. *Nat. Mach. Intell.* **4**, 222–226 (2022).
31. Ratajczak, F. et al. Speos: an ensemble graph representation learning framework to predict core gene candidates for complex diseases. *Nat. Commun.* **14**, 7206 (2023).
32. Li, H. et al. CGMega: explainable graph neural network framework with attention mechanisms for cancer gene module dissection. *Nat. Commun.* **15**, 5997 (2024).
33. Youn, J., Rai, N. & Tagkopoulos, I. Knowledge integration and decision support for accelerated discovery of antibiotic resistance genes. *Nat. Commun.* **13**, 2360 (2022).
34. Gogleva, A. et al. Knowledge graph-based recommendation framework identifies drivers of resistance in EGFR mutant non-small cell lung cancer. *Nat. Commun.* **13**, 1667 (2022).
35. Ge, Y. et al. An integrative drug repositioning framework discovered a potential therapeutic agent targeting COVID-19. *Signal Transduct. Target. Ther.* **6**, 165 (2021).
36. Luo, R. et al. BioGPT: generative pre-trained transformer for biomedical text generation and mining. *Brief. Bioinform.* **23**, bbac409 (2022).
37. Ren, F. et al. A small-molecule TNIK inhibitor targets fibrosis in preclinical and clinical models. *Nat. Biotechnol.* <https://doi.org/10.1038/s41587-024-02143-0> (2024).
38. Cosentino, J. et al. Inference of chronic obstructive pulmonary disease with deep learning on raw spiromograms identifies new genetic loci and improves risk models. *Nat. Genet.* **55**, 787–795 (2023).
39. Liu, R., Wei, L. & Zhang, P. A deep learning framework for drug repurposing via emulating clinical trials on real-world patient data. *Nat. Mach. Intell.* **3**, 68–75 (2021).
40. Deep learning model improves COPD risk prediction and gene discovery. *Nat. Genet.* **55**, 738–739 (2023).
41. Tingle, B. I. et al. ZINC-22—a free multi-billion-scale database of tangible compounds for ligand discovery. *J. Chem. Inf. Model.* **63**, 1166–1176 (2023).
42. Tran-Nguyen, V.-K., Junaid, M., Simeon, S. & Ballester, P. J. A practical guide to machine-learning scoring for structure-based virtual screening. *Nat. Protoc.* **18**, 3460–3511 (2023).
43. Gentile, F. et al. Artificial intelligence-enabled virtual screening of ultra-large chemical libraries with deep docking. *Nat. Protoc.* **17**, 672–697 (2022).
44. Stärk, H., Ganea, O., Pattanaik, L., Barzilay, R. & Jaakkola, T. Equibind: geometric deep learning for drug binding structure prediction. In *Proc. 39th International Conference on Machine Learning* (eds Chaudhuri, K. et al.) 20503–20521 (PMLR, 2022).
45. Zhang, X. et al. Efficient and accurate large library ligand docking with KarmaDock. *Nat. Comput. Sci.* **3**, 789–804 (2023).
46. Qiao, Z., Nie, W., Vahdat, A., Miller, T. F. III. & Anandkumar, A. State-specific protein–ligand complex structure prediction with a multiscale deep generative model. *Nat. Mach. Intell.* **6**, 195–208 (2024).
47. Peng, X. et al. Characterizing the interaction conformation between T-cell receptors and epitopes with deep learning. *Nat. Mach. Intell.* **5**, 395–407 (2023).
48. Méndez-Lucio, O., Ahmad, M., Rio-Chanona, E. A. D. & Wegner, J. K. A geometric deep learning approach to predict binding conformations of bioactive molecules. *Nat. Mach. Intell.* **3**, 1033–1039 (2021).
49. Lu, W. et al. TANKBind: trigonometry-aware neural networks for drug–protein binding structure prediction. *Adv. Neural Inf. Process. Syst.* **35**, 7236–7249 (2022).
50. Bryant, P., Kelkar, A., Guljas, A., Clementi, C. & Noé, F. Structure prediction of protein–ligand complexes from sequence information with Umol. *Nat. Commun.* **15**, 4536 (2024).
51. Krishna, R. et al. Generalized biomolecular modeling and design with RoseTTAFold All-Atom. *Science* **384**, ead12528 (2024).
52. Tsaban, T. et al. Harnessing protein folding neural networks for peptide–protein docking. *Nat. Commun.* **13**, 176 (2022).
53. Lin, P., Tao, H., Li, H. & Huang, S.-Y. Protein–protein contact prediction by geometric triangle-aware protein language models. *Nat. Mach. Intell.* **5**, 1275–1284 (2023).
54. Yu, Y., Lu, S., Gao, Z., Zheng, H. & Ke, G. Do deep learning models really outperform traditional approaches in molecular docking? In *Proc. ICLR 2023, Machine Learning for Drug Discovery workshop* (ICLR, 2023).
55. Luo, Y., Liu, Y. & Peng, J. Calibrated geometric deep learning improves kinase–drug binding predictions. *Nat. Mach. Intell.* **5**, 1390–1401 (2023).
56. Renaud, N. et al. DeepRank: a deep learning framework for data mining 3D protein–protein interfaces. *Nat. Commun.* **12**, 7068 (2021).
57. Gainza, P. et al. Deciphering interaction fingerprints from protein molecular surfaces using geometric deep learning. *Nat. Methods* **17**, 184–192 (2020).
58. Stebliankin, V. et al. Evaluating protein binding interfaces with transformer networks. *Nat. Mach. Intell.* **5**, 1042–1053 (2023).
59. Réau, M., Renaud, N., Xue, L. C. & Bonvin, A. M. DeepRank-GNN: a graph neural network framework to learn patterns in protein–protein interfaces. *Bioinformatics* **39**, btac759 (2023).
60. Shen, C. et al. Boosting protein–ligand binding pose prediction and virtual screening based on residue–atom distance likelihood potential and graph transformer. *J. Med. Chem.* **65**, 10691–10706 (2022).
61. Shen, C. et al. A generalized protein–ligand scoring framework with balanced scoring, docking, ranking and screening powers. *Chem. Sci.* **14**, 8129–8146 (2023).

62. Zhang, X. et al. Planet: a multi-objective graph neural network model for protein–ligand binding affinity prediction. *J. Chem. Inf. Model.* **64**, 2205–2220 (2023).
63. Yu, J. et al. Computing the relative binding affinity of ligands based on a pairwise binding comparison network. *Nat. Comput. Sci.* **3**, 860–872 (2023).
64. Sverrisson, F., Feydy, J., Correia, B. E. & Bronstein, M. M. Fast end-to-end learning on protein surfaces. In *Proc. 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition* 15267–15276 (IEEE, 2021).
65. Chen, L. et al. Sequence-based drug design as a concept in computational drug design. *Nat. Commun.* **14**, 4217 (2023).
66. Stokes, J. M. et al. A deep learning approach to antibiotic discovery. *Cell* **180**, 688–702 (2020).
67. Liu, G. et al. Deep learning-guided discovery of an antibiotic targeting *Acinetobacter baumannii*. *Nat. Chem. Biol.* **19**, 1342–1350 (2023).
68. Wong, F. et al. Discovery of a structural class of antibiotics with explainable deep learning. *Nature* **626**, 177–185 (2024).
69. Wong, F., Omori, S., Donghia, N. M., Zheng, E. J. & Collins, J. J. Discovering small-molecule senolytics with deep neural networks. *Nat. Aging* **3**, 734–750 (2023).
70. Smer-Barreto, V. et al. Discovery of senolytics using machine learning. *Nat. Commun.* **14**, 3445 (2023).
71. Tong, X. et al. Deep representation learning of chemical-induced transcriptional profile for phenotype-based drug discovery. *Nat. Commun.* **15**, 5378 (2024).
72. Zhu, J. et al. Prediction of drug efficacy from transcriptional profiles with deep learning. *Nat. Biotechnol.* **39**, 1444–1452 (2021).
73. Duran, I. et al. Detection of senescence using machine learning algorithms based on nuclear features. *Nat. Commun.* **15**, 1041 (2024).
74. Tilborg, D. V., Alenicheva, A. & Grisoni, F. Exposing the limitations of molecular machine learning with activity cliffs. *J. Chem. Inf. Model.* **62**, 5938–5951 (2022).
75. Moshkov, N. et al. Predicting compound activity from phenotypic profiles and chemical structures. *Nat. Commun.* **14**, 1967 (2023).
76. Scantlebury, J. et al. A small step toward generalizability: training a machine learning scoring function for structure-based virtual screening. *J. Chem. Inf. Model.* **63**, 2960–2974 (2023).
77. Yu, L., He, X., Fang, X., Liu, L. & Liu, J. Deep learning with geometry-enhanced molecular representation for augmentation of large-scale docking-based virtual screening. *J. Chem. Inf. Model.* **63**, 6501–6514 (2023).
78. Lam, H. Y. I. et al. Application of variational graph encoders as an effective generalist algorithm in computer-aided drug design. *Nat. Mach. Intell.* **5**, 754–764 (2023).
79. Moon, S., Zhung, W., Yang, S., Lim, J. & Kim, W. Y. PIGNet: a physics-informed deep learning model toward generalized drug–target interaction predictions. *Chem. Sci.* **13**, 3661–3673 (2022).
80. Moon, S., Hwang, S.-Y., Lim, J. & Kim, W. Y. PIGNet2: a versatile deep learning-based protein–ligand interaction prediction model for binding affinity scoring and virtual screening. *Digit. Discov.* **3**, 287–299 (2024).
81. Lyu, J., Irwin, J. J. & Shoichet, B. K. Modeling the expansion of virtual screening libraries. *Nat. Chem. Biol.* **19**, 712–718 (2023).
82. Cao, Z., Sciabola, S. & Wang, Y. Large-scale pretraining improves sample efficiency of active learning-based virtual screening. *J. Chem. Inf. Model.* **64**, 1882–1891 (2024).
83. Lilienfeld, O. A. V., Müller, K.-R. & Tkatchenko, A. Exploring chemical compound space with quantum-based machine learning. *Nat. Rev. Chem.* **4**, 347–358 (2020).
84. Korlepara, D. B. et al. PLAS-20k: extended dataset of protein–ligand affinities from md simulations for machine learning applications. *Sci. Data* **11**, 180 (2024).
85. Moret, M. et al. Leveraging molecular structure and bioactivity with chemical language models for de novo drug design. *Nat. Commun.* **14**, 114 (2023).
86. Li, Y. et al. Generative deep learning enables the discovery of a potent and selective RIPK1 inhibitor. *Nat. Commun.* **13**, 6891 (2022).
87. Chenthamarakshan, V. et al. Accelerating drug target inhibitor discovery with a deep generative foundation model. *Sci. Adv.* **9**, eadg7865 (2023).
88. Zheng, S. et al. Accelerated rational PROTAC design via deep learning and molecular simulations. *Nat. Mach. Intell.* **4**, 739–748 (2022).
89. Chen, S. et al. Design of target specific peptide inhibitors using generative deep learning and molecular dynamics simulations. *Nat. Commun.* **15**, 1611 (2024).
90. Pandi, A. et al. Cell-free biosynthesis combined with deep learning accelerates de novo-development of antimicrobial peptides. *Nat. Commun.* **14**, 7197 (2023).
91. Szymczak, P. et al. Discovering highly potent antimicrobial peptides with deep generative model HydrAMP. *Nat. Commun.* **14**, 1453 (2023).
92. Notin, P., Rollins, N., Gal, Y., Sander, C. & Marks, D. Machine learning for functional protein design. *Nat. Biotechnol.* **42**, 216–228 (2024).
93. Torres, S. V. et al. De novo design of high-affinity binders of bioactive helical peptides. *Nature* **626**, 435–442 (2024).
94. Wang, J. et al. Multi-constraint molecular generation based on conditional transformer, knowledge distillation and reinforcement learning. *Nat. Mach. Intell.* **3**, 914–922 (2021).
95. Born, J. & Manica, M. Regression transformer enables concurrent sequence regression and generation for molecular language modelling. *Nat. Mach. Intell.* **5**, 432–444 (2023).
96. Flam-Shepherd, D., Zhu, K. & Aspuru-Guzik, A. Language models can learn complex molecular distributions. *Nat. Commun.* **13**, 3293 (2022).
97. Skinnider, M. A., Stacey, R. G., Wishart, D. S. & Foster, L. J. Chemical language models enable navigation in sparsely populated chemical space. *Nat. Mach. Intell.* **3**, 759–770 (2021).
98. Skinnider, M. A. Invalid SMILES are beneficial rather than detrimental to chemical language models. *Nat. Mach. Intell.* **6**, 437–448 (2024).
99. Özçelik, R., de Ruiter, S., Criscuolo, E. & Grisoni, F. Chemical language modeling with structured state space sequence models. *Nat. Commun.* **15**, 6176 (2024).
100. Zhang, O. et al. Learning on topological surface and geometric structure for 3D molecular generation. *Nat. Comput. Sci.* **3**, 849–859 (2023).
101. Gebauer, N. W., Gastegger, M., Hessmann, S. S., Müller, K.-R. & Schütt, K. T. Inverse design of 3D molecular structures with conditional generative neural networks. *Nat. Commun.* **13**, 973 (2022).
102. Jiang, Y. et al. PocketFlow is a data-and-knowledge-driven structure-based molecular generative model. *Nat. Mach. Intell.* **6**, 326–337 (2024).
103. Godinez, W. J. et al. Design of potent antimalarials with generative chemistry. *Nat. Mach. Intell.* **4**, 180–186 (2022).
104. Hoogeboom, E., Satorras, V. G., Vignac, C. & Welling, M. Equivariant diffusion for molecule generation in 3D. In *Proc. 39th International Conference on Machine Learning* (eds Chaudhuri, K. et al.) 8867–8887 (PMLR, 2022).
105. Renz, P., Rompaey, D. V., Wegner, J. K., Hochreiter, S. & Klambauer, G. On failure modes in molecule generation and optimization. *Drug Discov. Today Technol.* **32**, 55–63 (2019).
106. Dodds, M. et al. Sample efficient reinforcement learning with active learning for molecular design. *Chem. Sci.* **15**, 4146–4160 (2024).

107. Guo, J. et al. Improving de novo molecular design with curriculum learning. *Nat. Mach. Intell.* **4**, 555–563 (2022).
108. Mokaya, M. et al. Testing the limits of SMILES-based de novo molecular generation with curriculum and deep reinforcement learning. *Nat. Mach. Intell.* **5**, 386–394 (2023).
109. Méndez-Lucio, O., Baillif, B., Clevert, D.-A., Rouquié, D. & Wichard, J. De novo generation of hit-like molecules from gene expression signatures using artificial intelligence. *Nat. Commun.* **11**, 10 (2020).
110. Zhu, H., Zhou, R., Cao, D., Tang, J. & Li, M. A pharmacophore-guided deep learning approach for bioactive molecular generation. *Nat. Commun.* **14**, 6234 (2023).
111. Li, Y., Pei, J. & Lai, L. Structure-based de novo drug design using 3D deep generative models. *Chem. Sci.* **12**, 13664–13675 (2021).
112. Feng, W. et al. Generation of 3D molecules in pockets via a language model. *Nat. Mach. Intell.* **6**, 62–73 (2024).
113. Huang, L. et al. A dual diffusion model enables 3D molecule generation and lead optimization based on target pockets. *Nat. Commun.* **15**, 2657 (2024).
114. Zhang, O. et al. ResGen is a pocket-aware 3D molecular generation model based on parallel multiscale modelling. *Nat. Mach. Intell.* **5**, 1020–1030 (2023).
115. Hoffman, S. C., Chenthamarakshan, V., Wadhawan, K., Chen, P.-Y. & Das, P. Optimizing molecules using efficient queries from property evaluations. *Nat. Mach. Intell.* **4**, 21–31 (2022).
116. Zhung, W., Kim, H. & Kim, W. Y. 3D molecular generative framework for interaction-guided drug design. *Nat. Commun.* **15**, 2688 (2024).
117. Atz, K. et al. Prospective de novo drug design with deep interactome learning. *Nat. Commun.* **15**, 3408 (2024).
118. Chen, Z., Min, M. R., Parthasarathy, S. & Ning, X. A deep generative model for molecule optimization via one fragment modification. *Nat. Mach. Intell.* **3**, 1040–1049 (2021).
119. Bhattacharai, B., Walters, W. P., Hop, C. E., Lanza, G. & Ekins, S. Opportunities and challenges using artificial intelligence in ADME/Tox. *Nat. Mater.* **18**, 418–422 (2019).
120. Göller, A. H. et al. Bayer's in silico ADMET platform: a journey of machine learning over the past two decades. *Drug Discov. Today* **25**, 1702–1709 (2020).
121. Li, Z., Jiang, M., Wang, S. & Zhang, S. Deep learning methods for molecular representation and property prediction. *Drug Discov. Today* **27**, 103373 (2022).
122. Atz, K., Grisoni, F. & Schneider, G. Geometric deep learning on molecular representations. *Nat. Mach. Intell.* **3**, 1023–1032 (2021).
123. Boulougouri, M., Vanderghenst, P. & Probst, D. Molecular set representation learning. *Nat. Mach. Intell.* **6**, 754–763 (2024).
124. Qu, S., Huang, S., Pan, X., Yang, L. & Mei, H. Constructing interconsistent, reasonable, and predictive models for both the kinetic and thermodynamic properties of HIV-1 protease inhibitors. *J. Chem. Inf. Model.* **56**, 2061–2068 (2016).
125. Turon, G. et al. First fully-automated AI/ML virtual screening cascade implemented at a drug discovery centre in Africa. *Nat. Commun.* **14**, 5736 (2023).
126. Yoshikai, Y., Mizuno, T., Nemoto, S. & Kusuhara, H. Difficulty in chirality recognition for Transformer architectures learning chemical structures from string representations. *Nat. Commun.* **15**, 1197 (2024).
127. Chen, D. et al. Algebraic graph-assisted bidirectional transformers for molecular property prediction. *Nat. Commun.* **12**, 3521 (2021).
128. Zeng, X. et al. Accurate prediction of molecular properties and drug targets using a self-supervised image representation learning framework. *Nat. Mach. Intell.* **4**, 1004–1016 (2022).
129. Fang, X. et al. Geometry-enhanced molecular representation learning for property prediction. *Nat. Mach. Intell.* **4**, 127–134 (2022).
130. Ross, J. et al. Large-scale chemical language representations capture molecular structure and properties. *Nat. Mach. Intell.* **4**, 1256–1264 (2022).
131. Li, H. et al. A knowledge-guided pre-training framework for improving molecular representation learning. *Nat. Commun.* **14**, 7568 (2023).
132. Chang, J. & Ye, J. C. Bidirectional generation of structure and properties through a single molecular foundation model. *Nat. Commun.* **15**, 2323 (2024).
133. Kundu, S. AI in medicine must be explainable. *Nat. Med.* **27**, 1328 (2021).
134. Jiménez-Luna, J., Grisoni, F. & Schneider, G. Drug discovery with explainable artificial intelligence. *Nat. Mach. Intell.* **2**, 573–584 (2020).
135. Zhong, Y. et al. Learning motif-based graphs for drug–drug interaction prediction via local–global self-attention. *Nat. Mach. Intell.* **6**, 1094–1105 (2024).
136. Fang, Y. et al. Knowledge graph-enhanced molecular contrastive learning with functional prompt. *Nat. Mach. Intell.* **5**, 542–553 (2023).
137. Shen, Y. et al. Automation and computer-assisted planning for chemical synthesis. *Nat. Rev. Methods Prim.* **1**, 23 (2021).
138. Abolhasani, M. & Kumacheva, E. The rise of self-driving labs in chemical and materials sciences. *Nat. Synth.* **2**, 483–492 (2023).
139. Bai, J. et al. A dynamic knowledge graph approach to distributed self-driving laboratories. *Nat. Commun.* **15**, 462 (2024).
140. Vaucher, A. C. et al. Automated extraction of chemical synthesis actions from experimental procedures. *Nat. Commun.* **11**, 3601 (2020).
141. Vaucher, A. C. et al. Inferring experimental procedures from text-based representations of chemical reactions. *Nat. Commun.* **12**, 2573 (2021).
142. Tu, X. et al. Artificial intelligence-enabled discovery of a RIPK3 inhibitor with neuroprotective effects in an acute glaucoma mouse model. *Chin. Med. J.* <https://doi.org/10.1097/CM9.0000000000003387> (2024).
143. Wipke, W., Braun, H., Smith, G., Choplin, F. & Sieber, W. *SECS—Simulation and Evaluation of Chemical Synthesis: Strategy and Planning* (ACS Publications, 1977).
144. Huang, Q., Li, L.-L. & Yang, S.-Y. RASA: a rapid retrosynthesis-based scoring method for the assessment of synthetic accessibility of drug-like molecules. *J. Chem. Inf. Model.* **51**, 2768–2777 (2011).
145. Coley, C. W. et al. A robotic platform for flow synthesis of organic compounds informed by AI planning. *Science* **365**, eaax1566 (2019).
146. Button, A., Merk, D., Hiss, J. A. & Schneider, G. Automated de novo molecular design by hybrid machine intelligence and rule-driven chemical synthesis. *Nat. Mach. Intell.* **1**, 307–315 (2019).
147. Grisoni, F. et al. Combining generative artificial intelligence and on-chip synthesis for de novo drug design. *Sci. Adv.* **7**, eabg3338 (2021).
148. Mikulak-Klucznik, B. et al. Computational planning of the synthesis of complex natural products. *Nature* **588**, 83–88 (2020).
149. Zhang, P. et al. A neural network model informs the total synthesis of clovane sesquiterpenoids. *Nat. Synth.* **2**, 527–534 (2023).
150. Tetko, I. V., Karpov, P., Van Deursen, R. & Godin, G. State-of-the-art augmented NLP transformer models for direct and single-step retrosynthesis. *Nat. Commun.* **11**, 5575 (2020).
151. Fang, L., Li, J., Zhao, M., Tan, L. & Lou, J.-G. Single-step retrosynthesis prediction by leveraging commonly preserved substructures. *Nat. Commun.* **14**, 2446 (2023).
152. Pesciullesi, G., Schwaller, P., Laino, T. & Reymond, J.-L. Transfer learning enables the molecular transformer to predict regio- and stereoselective reactions on carbohydrates. *Nat. Commun.* **11**, 4874 (2020).

153. Schwaller, P. et al. Mapping the space of chemical reactions using attention-based neural networks. *Nat. Mach. Intell.* **3**, 144–152 (2021).
154. Wang, Y. et al. Retrosynthesis prediction with an interpretable deep-learning framework based on molecular assembly tasks. *Nat. Commun.* **14**, 6155 (2023).
155. Koscher, B. A. et al. Autonomous, multiproperty-driven molecular discovery: from predictions to measurements and back. *Science* **382**, eadi1407 (2023).
156. Steiner, S. et al. Organic synthesis in a modular robotic system driven by a chemical programming language. *Science* **363**, eaav2211 (2019).
157. Liu, C. et al. Automated synthesis of prexasertib and derivatives enabled by continuous-flow solid-phase synthesis. *Nat. Chem.* **13**, 451–457 (2021).
158. Schneider, G. Automating drug discovery. *Nat. Rev. Drug Discov.* **17**, 97–113 (2018).
159. Boiko, D. A., MacKnight, R., Kline, B. & Gomes, G. Autonomous chemical research with large language models. *Nature* **624**, 570–578 (2023).
160. Bran, A. M. et al. Augmenting large language models with chemistry tools. *Nat. Mach. Intell.* **6**, 525–535 (2024).
161. Li, X. et al. Ultrasensitive sensors reveal the spatiotemporal landscape of lactate metabolism in physiology and disease. *Cell Metab.* **35**, 200–211 (2023).
162. Simm, J. et al. Repurposing high-throughput image assays enables biological activity prediction for drug discovery. *Cell Chem. Biol.* **25**, 611–618 (2018).
163. Yu, M. et al. Deep learning large-scale drug discovery and repurposing. *Nat. Comput. Sci.* **4**, 600–614 (2024).
164. Tang, Q. et al. Morphological profiling for drug discovery in the era of deep learning. *Brief. Bioinform.* **25**, bbae284 (2024).
165. Claudio Quiros, A. et al. Mapping the landscape of histomorphological cancer phenotypes using self-supervised learning on unannotated pathology slides. *Nat. Commun.* **15**, 4596 (2024).
166. Huang, Z. et al. A pathologist—AI collaboration framework for enhancing diagnostic accuracies and efficiencies. *Nat. Biomed. Eng.* <https://doi.org/10.1038/s41551-024-01223-5> (2024).
167. Sung, M. et al. Three-dimensional label-free morphology of CD8⁺ T cells as a sepsis biomarker. *Light Sci. Appl.* **12**, 265 (2023).
168. Heckenbach, I. et al. Nuclear morphology is a deep learning biomarker of cellular senescence. *Nat. Aging* **2**, 742–755 (2022).
169. Niu, L. et al. Noninvasive proteomic biomarkers for alcohol-related liver disease. *Nat. Med.* **28**, 1277–1287 (2022).
170. Skrede, O.-J. et al. Deep learning for prediction of colorectal cancer outcome: a discovery and validation study. *Lancet* **395**, 350–360 (2020).
171. Lee, Y. et al. Derivation of prognostic contextual histopathological features from whole-slide images of tumours via graph deep learning. *Nat. Biomed. Eng.* <https://doi.org/10.1038/s41551-022-00923-0> (2022).
172. Hoang, D.-T. et al. A deep-learning framework to predict cancer treatment response from histopathology images through imputed transcriptomics. *Nat. Cancer* **5**, 1305–1317 (2024).
173. Wang, S. et al. Machine learning-based extrachromosomal DNA identification in large-scale cohorts reveals its clinical implications in cancer. *Nat. Commun.* **15**, 1515 (2024).
174. Kather, J. N. et al. Deep learning can predict microsatellite instability directly from histology in gastrointestinal cancer. *Nat. Med.* **25**, 1054–1056 (2019).
175. Echle, A. et al. Clinical-grade detection of microsatellite instability in colorectal tumors by deep learning. *Gastroenterology* **159**, 1406–1416 (2020).
176. Yamashita, R. et al. Deep learning model for the prediction of microsatellite instability in colorectal cancer: a diagnostic study. *Lancet Oncol.* **22**, 132–141 (2021).
177. Echle, A. et al. Deep learning for the detection of microsatellite instability from histology images in colorectal cancer: a systematic literature review. *ImmunoInformatics* **3**, 100008 (2021).
178. Bilal, M. et al. Development and validation of a weakly supervised deep learning framework to predict the status of molecular pathways and key mutations in colorectal cancer from routine histology images: a retrospective study. *Lancet Digit.* **3**, e763–e772 (2021).
179. Muti, H. S. et al. Development and validation of deep learning classifiers to detect Epstein-Barr virus and microsatellite instability status in gastric cancer: a retrospective multicentre cohort study. *Lancet Digit.* **3**, e654–e664 (2021).
180. Hong, R., Liu, W., DeLair, D., Razavian, N. & Fenyő, D. Predicting endometrial cancer subtypes and molecular features from histopathology images using multi-resolution deep learning models. *Cell Rep. Med.* **2**, 100400 (2021).
181. Wang, X. et al. Spatial interplay patterns of cancer nuclei and tumor-infiltrating lymphocytes (TILs) predict clinical benefit for immune checkpoint inhibitors. *Sci. Adv.* **8**, eabn3966 (2022).
182. Farahmand, S. et al. Deep learning trained on hematoxylin and eosin tumor region of Interest predicts HER2 status and trastuzumab treatment response in HER2⁺ breast cancer. *Mod. Pathol.* **35**, 44–51 (2022).
183. Li, F. et al. Deep learning-based predictive biomarker of pathological complete response to neoadjuvant chemotherapy from histological images in breast cancer. *J. Transl. Med.* **19**, 348 (2021).
184. Kong, J. et al. Network-based machine learning in colorectal and bladder organoid models predicts anti-cancer drug efficacy in patients. *Nat. Commun.* **11**, 5485 (2020).
185. Pai, S. et al. Foundation model for cancer imaging biomarkers. *Nat. Mach. Intell.* **6**, 354–367 (2024).
186. Fu, Y. et al. Pan-cancer computational histopathology reveals mutations, tumor composition and prognosis. *Nat. Cancer* **1**, 800–810 (2020).
187. Avram, R. et al. A digital biomarker of diabetes from smartphone-based vascular signals. *Nat. Med.* **26**, 1576–1582 (2020).
188. Klonoff, D. C. Diagnosing diabetes mellitus from smartphone-based vascular signals. *Nat. Rev. Endocrinol.* **16**, 681–682 (2020).
189. Boehm, K. M., Khosravi, P., Vanguri, R., Gao, J. & Shah, S. P. Harnessing multimodal data integration to advance precision oncology. *Nat. Rev. Cancer* **22**, 114–126 (2022).
190. Jaume, G., Song, A. H. & Mahmood, F. Integrating context for superior cancer prognosis. *Nat. Biomed. Eng.* **6**, 1323–1325 (2022).
191. Saldanha, O. L. et al. Swarm learning for decentralized artificial intelligence in cancer histopathology. *Nat. Med.* **28**, 1232–1239 (2022).
192. Ávila, C. G. et al. DISCOVER-EEG: an open, fully automated EEG pipeline for biomarker discovery in clinical neuroscience. *Sci. Data* **10**, 613 (2023).
193. AbdulJabbar, K. et al. Geospatial immune variability illuminates differential evolution of lung adenocarcinoma. *Nat. Med.* **26**, 1054–1062 (2020).
194. Dent, A. et al. HAVOC: small-scale histomic mapping of cancer biodiversity across large tissue distances using deep neural networks. *Sci. Adv.* **9**, eadg1894 (2023).
195. Zhao, S. et al. Single-cell morphological and topological atlas reveals the ecosystem diversity of human breast cancer. *Nat. Commun.* **14**, 6796 (2023).

196. Saillard, C. et al. Pacpaint: a histology-based deep learning model uncovers the extensive intratumor molecular heterogeneity of pancreatic adenocarcinoma. *Nat. Commun.* **14**, 3459 (2023).
197. Liang, J. et al. Deep learning supported discovery of biomarkers for clinical prognosis of liver cancer. *Nat. Mach. Intell.* **5**, 408–420 (2023).
198. Hartman, E. et al. Interpreting biologically informed neural networks for enhanced proteomic biomarker discovery and pathway analysis. *Nat. Commun.* **14**, 5359 (2023).
199. Brethauer, M., Løberg, M., Holme, Ø., Adami, H.-O. & Kalager, M. Deep learning and cancer biomarkers: recognising lead-time bias. *Lancet* **397**, 194 (2021).
200. Specogna, A. V. & Sinicope, F. A. Defining colon cancer biomarkers by using deep learning. *Lancet* **395**, 314–316 (2020).
201. Howard, F. M. et al. The impact of site-specific digital histology signatures on deep learning model accuracy and bias. *Nat. Commun.* **12**, 4423 (2021).
202. Kleppe, A. et al. Designing deep learning studies in cancer diagnostics. *Nat. Rev. Cancer* **21**, 199–211 (2021).
203. Pavlović, M. et al. Improving generalization of machine learning-identified biomarkers using causal modelling with examples from immune receptor diagnostics. *Nat. Mach. Intell.* **6**, 15–24 (2024).
204. Terrail, J. O. D. et al. Federated learning for predicting histological response to neoadjuvant chemotherapy in triple-negative breast cancer. *Nat. Med.* **29**, 135–146 (2023).
205. Gong, X. et al. Decoding kinase-adverse event associations for small molecule kinase inhibitors. *Nat. Commun.* **13**, 4349 (2022).
206. Allesøe, R. L. et al. Discovery of drug–omics associations in type 2 diabetes with generative deep-learning models. *Nat. Biotechnol.* **41**, 399–408 (2023).
207. ValizadehAslani, T. et al. PharmBERT: a domain-specific BERT model for drug labels. *Brief. Bioinform.* **24**, bbad226 (2023).
208. Qiang, B. et al. Bridging the gap between chemical reaction pretraining and conditional molecule generation with a unified model. *Nat. Mach. Intell.* **5**, 1476–1485 (2023).
209. Zhou, Y., Wang, F., Tang, J., Nussinov, R. & Cheng, F. Artificial intelligence in COVID-19 drug repurposing. *Lancet Digit.* **2**, e667–e676 (2020).
210. Aliper, A. et al. Deep learning applications for predicting pharmacological properties of drugs and drug repurposing using transcriptomic data. *Mol. Pharm.* **13**, 2524–2530 (2016).
211. Janizek, J. D. et al. Uncovering expression signatures of synergistic drug responses via ensembles of explainable machine-learning models. *Nat. Biomed. Eng.* **7**, 811–829 (2023).
212. Artemov, A. V. et al. Integrated deep learned transcriptomic and structure-based predictor of clinical trials outcomes. Preprint at *bioRxiv* <https://doi.org/10.1101/095653> (2016).
213. Liu, R. et al. Evaluating eligibility criteria of oncology trials using real-world data and AI. *Nature* **592**, 629–633 (2021).
214. Chebanov, D. K. & Misyurin, V. A. Predictive modeling of clinical trial outcomes for novel drugs using digital twin patient cohorts and generative AI. Preprint at *medRxiv* <https://doi.org/10.1101/2023.09.11.23295380> (2023).
215. Zhang, K. et al. Concepts and applications of digital twins in healthcare and medicine. *Patterns* **5**, 101028 (2024).
216. He, J. et al. The practical implementation of artificial intelligence technologies in medicine. *Nat. Med.* **25**, 30–36 (2019).
217. Connor, S. et al. Adaptability of AI for safety evaluation in regulatory science: a case study of drug-induced liver injury. *Front. Artif. Intell.* **5**, 1034631 (2022).
218. Bender, A. & Cortes-Ciriano, I. Artificial intelligence in drug discovery: what is realistic, what are illusions? Part 2: a discussion of chemical and biological data. *Drug Discov. Today* **26**, 1040–1052 (2021).
219. Schrader, M. L., Schäfer, F. R., Schäfers, F. & Glorius, F. Bridging the information gap in organic chemical reactions. *Nat. Chem.* **16**, 491–498 (2024).
220. Luukkonen, S., Maagdenberg, H. W. V. D., Emmerich, M. T. & Westen, G. J. V. Artificial intelligence in multi-objective drug design. *Curr. Opin. Struct. Biol.* **79**, 102537 (2023).
221. Fromer, J. C. & Coley, C. W. Computer-aided multi-objective optimization in small molecule discovery. *Patterns* **4**, 100678 (2023).
222. Coley, C. W., Eyke, N. S. & Jensen, K. F. Autonomous discovery in the chemical sciences part II: outlook. *Angew. Chem. Int. Ed.* **59**, 23414–23436 (2020).
223. Vanhaelen, Q., Lin, Y.-C. & Zhavoronkov, A. The advent of generative chemistry. *ACS Med. Chem. Lett.* **11**, 1496–1505 (2020).
224. Polykovskiy, D. et al. Molecular sets (MOSES): a benchmarking platform for molecular generation models. *Front. Pharmacol.* **11**, 565644 (2020).
225. Brown, N., Fiscato, M., Segler, M. H. & Vaucher, A. C. GuacaMol: benchmarking models for de novo molecular design. *J. Chem. Inf. Model.* **59**, 1096–1108 (2019).
226. Orlando, G. et al. PyUUL provides an interface between biological structures and deep learning algorithms. *Nat. Commun.* **13**, 961 (2022).
227. Wang, Y., Wang, J., Cao, Z. & Farimani, A. B. Molecular contrastive learning of representations via graph neural networks. *Nat. Mach. Intell.* **4**, 279–287 (2022).
228. Zang, X., Zhao, X. & Tang, B. Hierarchical molecular graph self-supervised learning for property prediction. *Commun. Chem.* **6**, 34 (2023).
229. Chan, L., Kumar, R., Verdonk, M. & Poelking, C. A multilevel generative framework with hierarchical self-contrasting for bias control and transparency in structure-based ligand design. *Nat. Mach. Intell.* **4**, 1130–1142 (2022).
230. Alon, U. & Yahav, E. On the bottleneck of graph neural networks and its practical implications. In *Proc. International Conference on Learning Representations 2021 (ICLR, 2021)*.
231. Corso, G., Stark, H., Jegelka, S., Jaakkola, T. & Barzilay, R. Graph neural networks. *Nat. Rev. Methods Prim.* **4**, 17 (2024).
232. Gomes, B. & Ashley, E. A. Artificial intelligence in molecular medicine. *N. Engl. J. Med.* **388**, 2456–2465 (2023).
233. Aliper, A. et al. Prediction of clinical trials outcomes based on target choice and clinical trial design with multi-modal artificial intelligence. *Clin. Pharmacol. Ther.* **114**, 972–980 (2023).
234. Miller, E. B. et al. Enabling structure-based drug discovery utilizing predicted models. *Cell* **187**, 521–525 (2024).
235. Liu, S. et al. Multi-modal molecule structure–text model for text-based retrieval and editing. *Nat. Mach. Intell.* **5**, 1447–1457 (2023).
236. Banerjee, J. et al. Machine learning in rare disease. *Nat. Methods* **20**, 803–814 (2023).
237. Hocky, G. M. Connecting molecular properties with plain language. *Nat. Mach. Intell.* **6**, 249–250 (2024).
238. Jablonka, K. M., Schwaller, P., Ortega-Guerrero, A. & Smit, B. Leveraging large language models for predictive chemistry. *Nat. Mach. Intell.* **6**, 161–169 (2024).
239. Dias, A. L. & Rodrigues, T. Large language models direct automated chemistry laboratory. *Nature* **624**, 530–531 (2023).
240. Izard, S. G., Juanes Méndez, J. A. & Palomera, P. R. Virtual reality educational tool for human anatomy. *J. Med. Syst.* **41**, 76 (2017).
241. Chan, H. S., Shan, H., Dahoun, T., Vogel, H. & Yuan, S. Advancing drug discovery via artificial intelligence. *Trends Pharmacol. Sci.* **40**, 592–604 (2019).
242. Miller, D. D. & Brown, E. W. How cognitive machines can augment medical imaging. *Am. J. Roentgenol.* **212**, 9–14 (2019).

243. Pasquiers, B., Benamara, S., Felices, M., Nguyen, L. & Declès, X. Review of the existing translational pharmacokinetics modeling approaches specific to monoclonal antibodies (mAbs) to support the First-In-Human (FIH) dose selection. *Int. J. Mol. Sci.* **23**, 12754 (2022).
244. Liang, J., He, T., Li, H., Guo, X. & Zhang, Z. Improve individual treatment by comparing treatment benefits: cancer artificial intelligence survival analysis system for cervical carcinoma. *J. Transl. Med.* **20**, 293 (2022).
245. Antel, R., Abbasgholizadeh-Rahimi, S., Guadagno, E., Harley, J. M. & Poenaru, D. The use of artificial intelligence and virtual reality in doctor-patient risk communication: a scoping review. *Patient Educ. Couns.* **105**, 3038–3050 (2022).
246. Abramson, J. et al. Accurate structure prediction of biomolecular interactions with AlphaFold 3. *Nature* **630**, 493–500 (2024).
247. Pettersen, E. F. et al. UCSF ChimeraX: structure visualization for researchers, educators, and developers. *Protein Sci.* **30**, 70–82 (2021).
248. Szklarczyk, D. et al. STRING v10: protein-protein interaction networks, integrated over the tree of life. *Nucleic Acids Res* **43**, D447–D452 (2015).

致谢

本研究得到了温州眼视光医院、温州医科大学眼健康与疾病研究所、温州眼谷、中国国家自然科学基金（W2431057、T2221004、22277085、82404087）、广州国家实验室（YW-SLJC0201、GZNL2024A01005）、中国国家重点研发计划（2023YFF1204905）、天府锦城实验室基金（TFJC2023010009）、广州市科技计划项目（2023A03J0722）以及新基石

科学基金会的支持。分子图形和分析使用 UCSF ChimeraX 完成，该软件由加州大学旧金山分校生物计算、可视化和信息学资源中心开发，得到了美国国立卫生研究院 R01-GM129325 项目以及美国国家过敏和传染病研究所网络基础设施与计算生物学办公室的支持。

利益冲突

作者声明不存在利益冲突。

附加信息

来信及索取材料请寄给张康或杨胜勇。

《自然·医学》感谢南希克·韩（Namshik Han）及其他匿名审稿人对本稿件的评审工作。初审编辑：凯伦·奥利里（Karen O’Leary），与《自然·医学》团队合作完成。

有关转载和使用许可的信息，请访问 www.nature.com/reprints。

出版者注：施普林格·自然对于所发表的地图中涉及的管辖权主张以及机构隶属关系保持中立。

施普林格·自然或其许可方（例如学会或其他合作伙伴）根据与作者或其他权利持有人签订的出版协议，对本文拥有独家权利；作者对本文已接受稿的自存档仅受该出版协议和适用法律的约束。

©施普林格·自然美国公司 2025 年