

药物靶点预测方法的验证指南

齐亚乌尔·拉赫曼·塔诺利、阿隆·舒尔曼和特罗·艾托卡利奥

引用本文: Ziaurrehman Tanoli、Aron Schulman 和 Tero Aittokallio (2025) 《药物靶点预测方法的验证指南》，《药物发现专家意见》，20:1，31 - 45，DOI: 10.1080/17460441.2024.243095

如需链接至本文: <https://doi.org/10.1080/17460441.2024.243095>



© 2024 The Author(s). Published by Informa UK Limited, trading as Taylor & Francis Group.



View supplementary material [↗](#)



Published online: 21 Nov 2024.



Submit your article to this journal [↗](#)



Article views: 1571



View related articles [↗](#)



View Crossmark data [↗](#)

REVIEW



药物靶点预测方法的验证指南

齐亚乌拉赫曼 Tanoli^{a,b}、阿隆 Schulman^a 和特罗 Aittokallio^{a,b,c,d}

^aInstitute 芬兰赫尔辛基大学分子医学研究所 (FIMM), HiLIFE, 芬兰赫尔辛基; ^biCAN 芬兰赫尔辛基大学和赫尔辛基大学医院数字精准癌症医学旗舰项目, 芬兰赫尔辛基; ^cInstitute 挪威奥斯陆大学医院癌症遗传学系癌症研究部, 挪威奥斯陆; ^dOslo 挪威奥斯陆大学医学院生物统计学与流行病学中心 (OCBE), 挪威奥斯陆

摘要

简介: 绘制药物化合物与其分子靶点之间的相互作用图谱是药物发现和再利用的一个基本方面。药物与靶点的相互作用对于阐明作用机制以及优化药物的疗效和安全性特征至关重要。已开发出多种计算方法来系统地预测药物与靶点的相互作用。然而, 不同研究中对药物靶点预测的计算和实验验证差异很大。

涵盖领域: 通过 PubMed 检索, 收集了过去十年间发表的 3286 篇有关药物靶点相互作用预测的文章, 形成了一个语料库。利用自然语言处理技术对这些文章的摘要进行自动分类, 以研究这 3286 篇文章中计算方法、验证策略和性能评估指标的发展演变情况。此外, 对 259 篇进行了计算预测实验验证的研究进行了人工分析, 揭示了常见的实验方案。

专家观点: 自 2014 年以来, 有关药物靶点相互作用预测的文章显著增多。在计算方法中, 对接和回归是使用最广泛的技术, 交叉验证则是常用的计算验证策略。建议采用多种正交验证策略来测试预测结果, 并在针对特定靶点预测的应用中予以报告。实验验证仍相对少见, 应更常规地开展以评估预测的生物学相关性。

文章历史

收稿日期: 2024 年 4 月 30 日
接受日期: 2024 年 11 月 14 日

关键词

药物靶点相互作用预测; 计算验证; 实验验证; 靶点活性图谱绘制; 药物再利用

1. 简介

在药物研发和药物再利用工作中, 分别确定试验化合物和已批准药物的蛋白质靶点是一项基础任务。药物与靶点的相互作用有助于开发更有效、更安全的治疗药物, 降低风险、成本和时间[1]。通过绘制与疾病通路相关的分子靶点图谱, 可以设计出专门调节这些靶点的药物, 从而提高治疗效果。同样, 系统地绘制强效脱靶图谱也有助于避免反靶点, 即可能导致药物副作用的蛋白质或通路。这种靶向方法不仅加快了药物开发速度, 还提高了临床成功结果的可能性, 例如治疗效果和耐受性。此外, 现有药物用于新的治疗适应症的再利用在很大程度上依赖于新疾病靶点的识别。这种脱靶再利用能够在降低成本和时间的情况下探索新的治疗途径[2]。在过去的二十年里, 化合物与靶点活性的实验性图谱绘制工作显著增加[3–6], 同时, 涵盖各类药物和靶点相互作用的

众多数据库也得到了开发[7,8]。这一领域的重大进展凸显了对药物与靶点相互作用相关信息进行编目和传播的重视程度日益提高。

人类蛋白质组提供了大量潜在的治疗靶点。尽管我们对强效药物与靶点相互作用的认识迅速扩展, 但目前的药物仍仅覆盖了潜在可成药靶点空间的一小部分[9]。此外, 许多罕见病仍缺乏针对性治疗, 而离子通道和核受体等蛋白质家族在药物靶点活性图谱中代表性不足。目前, 利用多剂量亲和力或靶点结合试验对所有已批准药物进行全面的蛋白质组测试在实验上尚不可行。此外, 研究性或探针化合物数量不断增加, 以及使用更符合疾病相关性的实验检测方法和模型系统, 使得实验性图谱绘制研究成本高昂且耗时。因此, 迫切需要能够识别小分子新型强效靶点的计算预测算法。理想情况下, 这些算法应能够预测结合情况。

文章要点

在过去十年中，利用回归和对接方法预测生物活性或结合亲和力是药物靶点相互作用预测中最常见的计算方法。近年来，深度学习算法和基于 AlphaFold 的对接也变得流行起来。

- 与独立测试相比，交叉验证和与最先进的方法进行基准测试仍然是更受欢迎的计算验证策略。相关系数在基于回归的研究中被广泛使用，而在活动分类中，准确率是最常用的度量标准。
- 通常采用六种不同的计算交叉验证场景来评估药物靶点预测的泛化准确性。然而，其中一些场景可能会因潜在的数据泄露而导致过于乐观的结果，因此不建议使用。
- 用于实验验证药物靶点预测的各种检测类型包括生化、体外和体内方法。值得注意的是，我们发现大多数用于预测药物靶点相互作用的计算方法仍未经过实验验证。
- 预测模型有可能取代初步的目标活性筛选，并提高结合亲和力谱预测的准确性。只要能获得足够多的感兴趣药物类别目标活性的训练数据，这将降低实验成本。
- 自然语言处理文档分类能够对大量研究文章进行快速自动分类，且分类准确率相对较高。我们已在 GitHub 上提供了相关脚本 (<https://github.com/AronSchulman/DTI-abstractclassifier>)。

药物对涵盖多个蛋白质家族的大量潜在靶点的亲和力。此类算法将显著扩大可靶向的空间，特别是对于已获批药物而言，这将增强其治疗潜力，并扩大药物发现和再利用工作的范围。

在过去十年中，已开发出数千种药物靶点相互作用预测方法，并对其进行了详尽的描述。众多综述涵盖了用于预测药物 - 靶点亲和力或活性类别的计算方法，反映了该领域取得的重大进展。例如，丁等人[10]回顾了基于相似性的机器学习 (ML) 技术在预测药物 - 靶点相互作用中的应用。巴盖里安等人[11]发表了一篇关于用于预测药物 - 靶点相互作用的基于机器学习的方法和数据库的综述，并对其各自的优缺点进行了比较。库图萨斯等人[12]对适用于基于配体的靶点预测的知名数据库进行了调查，并阐述了基于配体生物活性知识和蛋白质结构信息的靶点预测方法。埃扎特等人[13]探讨了各种药物 - 靶点相互作用预测方法，并阐明了用于此类预测的输入数据类型。阿巴斯等人[14]对用于药物 - 靶点预测的深度学习 (DL) 方法进行了全面综述。帕纳宁等人[15]比较了几个利用组学知识的药物靶点发现平台，以识别新的药物靶点。最后，萨赫德夫等人[16]回顾了基于特征的方法，并讨论了在各种药物靶点相互作用预测方法中使用的指标。

据我们所知，此前发表的综述或调查均未专门针对药物靶点预测研究

中所采用的验证策略进行评估。因此，本次调查的主要目的是评估药物靶点相互作用预测研究中所采用的各种计算和实验验证策略。为填补这一空白，我们设计了一个 PubMed 搜索查询，检索到过去十年间发表的 3286 篇药物靶点相互作用预测文章。我们还编写了脚本，自动提取所有文章的相关元数据，包括期刊信息、摘要、标题和发表年份。随后，我们开发了基于自然语言处理的文档分类器，将这 3286 篇文章自动分类为 16 个不同的类别。这些类别与模型类型（例如机器学习或基于对接）、所采用的验证方法（如交叉验证或实验验证）以及研究中使用的评估指标相关。这些自动化方法使我们能够快速进行文献分析，并研究多年来计算方法学和验证策略的发展演变。此外，我们还对 259 项进行了实验分析的研究进行了人工分析，以调查这些研究中用于验证计算模型所预测的药物靶点的各种实验方案。

2. 文献综述与基于自然语言处理的文档分类

2.1. PubMed 搜索查询

为了检索过去十年内发表的有关药物靶点相互作用预测的文章，我们采用了以下 PubMed 检索式：

((“配体受体”或“配体蛋白”或“化合物靶点”或“靶点亲和力”或“药物靶点”或“结合亲和力”或“配体 - 受体结合”或“靶点效力”或“药物 - 靶点相互作用”)与 (“预测”或“算法”) 但不包括 (综述[出版类型]) 且不包括 (新闻[出版类型]) 且不包括 (报纸文章[出版类型]) 且不包括 (系统综述[出版类型]) 且不包括 (社论[出版类型]) 并且 (y_10[筛选条件]))

我们根据 Cichońska 等人[17]在 PubMed 文献扫描部分所概述的方法调整了我们的搜索查询。除了最初的搜索词之外，我们还增加了三个更具体的术语：“配体 - 受体结合”、“靶点效力”和“药物 - 靶点相互作用”。我们的目标是使通过 PubMed 查询检索到的文章与引用三项著名药物 - 靶点相互作用研究的文章之间最大程度地重叠：Yamanishi 等人[4]、Pahikkala 等人[18]和 Tang 等人[19]。这三项研究迄今均已被引用超过 400 次，而我们的 PubMed 搜索查询所检索到的药物 - 靶点相关文章与引用这三项研究的文章在 PubMed 引用方面有超过 42% 的重叠（补充图 S1）。

2.2. 利用 PubMed API 进行数据提取

PubMed 检索得到了过去十年（2014 至 2023 年）发表的 3286 篇文章的 PubMed 编号。为了获取文献分析所需的其他元数据，如期刊名称、摘要、标题和出版年份，我们开发了

利用 PubMed 的 API 编写的脚本。这有助于系统地提取全面的信息，以实现两个主要目标：（1）分析多年来药物-靶点相互作用预测方法的发展演变，（2）训练基于自然语言处理的文档分类器，如后续章节所述。本研究使用的脚本是公开可用的，便于社区将其用于各种应用 (<https://github.com/AronSchulman/DTI-abstractclassifier>)。

在对 3286 篇文章的期刊信息进行程序化提取后，很明显，《生物分子结构与动力学杂志》（占文章总数的 4.38%）、《化学信息与建模杂志》（3.83%）和《生物信息学简讯》（2.89%）成为此次 PubMed 检索中最为突出的三个期刊（图 1）。然而，还有一些更侧重于计算的期刊也发表了若干药物靶点相互作用预测研究，例如《生物信息学》和《BMC 生物信息学》。这些期刊中的大多数不要求对计算模型预测进行实验验证。

2.3. 基于自然语言处理的 PubMed 文档分类器

我们开发了 16 个基于自然语言处理（NLP）的文档二分类器，用于预测与 3286 篇文章相关的 16 种不同情感（是或否分类）。其中 6 种情感与药物靶点相互作用预测方法有关：机器学习、深度学习、基于注意力机制、基于对接、分类和回归。4 种情感侧重于验证方法：实验验证、交叉验证、独立测试和与最新技术的比较。其余 6 种情感涉及所使用的评估指标：相关性（斯皮尔曼或皮尔逊）、均方根误差（RMSE）、AUROC、准确率、F1 度量以及任何其他相关指标。

对于这 16 个文档分类器中的每一个，我们都使用了从 Hugging Face [21] 获得的预训练的 BioMed-RoBERTa [20] 模型作为基础模型。BioMed-RoBERTa 在 268 万篇全文科学论文上进行了预训练，训练用的标记总数达 75.5 亿个。该模型在生物医学领域的自然语言处理任务中取得了最先进的成果，超越了更通用的语言模型。

因此，对于我们的用例而言，这个基础模型显然是一个不错的选择。

这些分类器使用人工标注的训练数据进行了 10 个周期的微调。总共从 PubMed 查询检索到的 3286 篇文章中人工收集了 16 个独立的训练数据集。由于获取所有文章的全文存在困难，我们将每篇文章的标题和摘要连接起来形成一个文档作为输入。模型输出是一个二元标签，表示特定情感的存在（1）或不存在（0）。训练数据集经过平衡处理，以确保正负文档的比例相等，训练数据集的大小从 32 个文档到 180 个文档不等，具体取决于 16 个分类任务的复杂程度（图 2(a)）。

我们通过 20 次随机搜索优化了模型的超参数，包括学习率、权重衰减和批量大小。最佳超参数详见补充表 S1。为了评估模型性能，我们采用了分层 5 折交叉验证，对于 16 个分类任务中的每一个，都获得了合理的准确率（>0.86）和 F1 分数（>0.89）（图 2(b)）。不同分类任务的难度差异体现在模型的准确率上，有些任务在相对较小的训练数据集上表现就很好（例如“对接”），而有些任务则需要更多的训练数据才能取得相对较低的准确率（例如“机器学习”）。值得注意的是，在不同类别中，训练数据集的大小与准确率（皮尔逊相关系数 -0.04）或数据大小与 F1 分数（皮尔逊相关系数 -0.11）之间均无相关性（补充图 S2）。

我们通过人工审查分类结果进一步验证了 50 篇预测的文章。这 50 篇文章是从预测列表中随机选取的，并且不属于用于模型开发的训练数据。由于与药物靶点缺乏相关性或无法获取全文，有 6 篇文章被排除在分析之外。其余 44 篇文章经过了人工验证。该模型能够相对准确地将摘要分类为 16 个类别，这些类别与建模和验证方法相关，准确率超过 0.79，F1 值超过 0.47（补充图 S3）。然而，与……相关的类别




图 1. 我们调查的 3286 种出版物在期刊上的分布情况。这些出版物是通过 PubMed 搜索与药物靶点相互作用预测研究相关的查询结果获取的（见第 2.1 节）。九种最突出的期刊被突出显示，其中《生物分子结构与动力学》期刊出现的频率最高。




图 2. 基于自然语言处理的 PubMed 文档分类器。(a) 每个文档分类器的训练数据组成, 平衡包含相等比例的正样本和负样本, 分别以绿色和红色显示。(b) 使用分层五折交叉验证 (CV) 对每个文档类别进行文档分类器的训练和测试, 即针对每个类别训练并评估五个二元分类器。蓝色和橙色条形分别表示五个分类器的平均准确率和 F1 值, 黑色垂直线表示平均值的标准误差 (SEM)。注意: y 轴从 0.80 开始, 以显示 16 个分类任务之间的差异; 准确率和 F1 值的理论最小值均为零。

性能指标对于自动分类来说更具挑战性, 这可能是由于摘要中对指标的引用不一致所致。独立测试结果可在以下位置找到:

3. 药物靶点相互作用预测的计算验证

图 3 展示了药物靶点预测建模及其验证的整体工作流程。第一阶段代表了用作建模输入的不同类型的化合物和靶点表示形式, 这些表示形式可来自内部资源或公共资源; 第二阶段概述了预测模型类型, 例如机器学习和对接方法; 第三阶段展示了预测标签, 包括活性值或对接得分等排名靠前的命中结果; 最后阶段涵盖了用于评估预测准确性和相关性的计算和实验验证方法。在下文中, 我们首先重点介绍主要的预测方法类型及其计算验证, 而第 4 节将描述主要的实验验证方法。

3.1. 药物靶点预测的分类与回归方法

在药物研发中, 预测药物与其蛋白质靶点的相互作用强度可以通过两种主要的计算方法来实现: 分类法或回归法。分类模型需要来自正类 (活性) 和负类 (非活性) 的训练数据, 这些数据可以从诸如 ChEMBL [22] 和药物靶点公共数据库 (DTC) [23,24] 等数据库中获取。化合物的非活性靶点信息 (即基于生化或细胞实验表明化合物对其无活性的蛋白质靶点) 通常可在这些数据库的 “活性” 表找到, 通常在 “活性注释” 列中被标注为 “非活性”。需要注意的是, 这些信息通常是基于最初进行筛选的研究人员所做的注释, 而非数据库维护人员。此外, 化合物与靶点配对数据的缺失并不一定意味着该化合物对特定蛋白质无活性。相反, 缺失的配对数据仅仅表明数据库中没有该特定化合物与靶点配对的生化或细胞实验数据。这可能是由于该对尚未经过实验研究, 或者是因为相关测量数据尚未被纳入数据库。




图3. 药物-靶点相互作用预测与验证的示意图工作流程。内部或公共生物活性数据资源中可用的药物-靶点对的相关生物学和结构特征被转换为数值表示, 作为计算预测方法的模型输入。模型预测应根据靶点类别和应用, 通过多种计算和实验验证方案进行评估。

另一方面, 回归模型使用整个生物活性值的连续范围, 无需区分正负相互作用类别。这使得训练数据的收集相对容易一些, 因为不需要预先设定活性阈值。然而, 生物活性数据库通常会报告各种类型的剂量反应读数, 例如 IC_{50} 、 ECK_d 和 XCK_i , 这可能会使训练数据集的准备变得复杂。为了解决这个问题, 像 ChEMBL 这样的数据库将这些亲和力统一为一个单一的分值, 例如 pChEMBL 值, 它代表了七种亲和力类型 (IC_{50} 、 EC_{50} 、 XC_{50} 、 AC_{50} 、 K_i 、 K_d 和效力) 的摩尔浓度的负对数。需要注意的是, pChEMBL 值不包含有关特定蛋白质靶点家族或测定类型的信息。为了克服这一局限性, Drug Target Profiler [25] 引入了一个评分系统, 将生物活性亲和力和值映射为从 0 到 1 的连续分数。该系统考虑了靶点家族和测定格式的变化, 为特定的靶点超家族或测定类型分配不同的权重。通过这样做, 它促进了针对众多目标超家族的精确回归模型的发展。

3.2. 药物靶点预测的计算评估策略

通常, 计算验证方法有三种类型: 交叉验证 (CV)、与当前最先进方法 (SOTA) 比较以及独立测试 (即留出验证)。在交叉验证中, 数据集被分为 k 个子集或折。然后在 $k-1$ 个折上训练模型, 并在剩余的一个折上进行测试。这个过程重复 k 次, 每个折都作为测试集使用一次。最后将 k 次运行的性能指标取平均值。与当前最先进方法比较是确定当前最先进方法 (或多种方法), 然后在一种或多种基

准数据集上将所提出的模型与之进行比较。最后, 独立测试是在一个未用于模型开发或训练的独立数据集上评估模型预测的性能。对于不同的蛋白质靶标超家族, 我们建议对每个超家族分别独立应用每种验证方法, 以确保对各种药物靶标类别进行稳健且准确的评估。

靶标超家族通常包含结构多样、具有不同结合口袋和功能机制的蛋白质, 因此在一个超家族中训练的模型在预测另一个超家族的化合物-靶标相互作用时很可能不准确。计算方法需要考虑这种变异性, 以准确预测配体结合亲和力、靶标选择性特征和功能效应。然而, 要根据超家族对现有的基准数据集进行细分, 还需要额外的整理工作。某些超家族 (例如离子通道) 缺乏经过实验验证的化合物-靶标相互作用数据, 这可能会进一步降低针对较小超家族的模型性能。因此, 我们建议实验科学家应针对研究较少的超家族 (包括离子通道、核受体和表观遗传调节剂) 生成更多的药物-靶标活性数据。

计算验证方法在分类和回归问题之间可能存在相似之处, 但所采用的评估指标却大不相同。在药物靶点分类模型中, 通常使用二元指标, 如准确率、F1 分数和受试者工作特征曲线下面积 (AUROC)。相反, 基于回归的模型通常使用斯皮尔曼或皮尔逊相关系数、一致性指数和均方根误差 (RMSE) 进行评估。此外, 还存在针对特定建模目标的其他评估指标[26]。采用多种评估指标能够全面评估模型的性能和

药物靶点预测模型的稳健性。这种多指标方法有助于从分类和回归任务的各个方面深入了解模型的准确性。

3.3. 虚拟筛选方法的计算评估

评估方法也可能与虚拟筛选 (VS) 研究有相似之处。VS 是一种相关的计算过程, 旨在根据分子对特定靶点的预测结合亲和力对大型数据库中的分子进行排序。与基于机器学习的药物靶点相互作用预测类似, VS 的目标是优先选择最有潜力的候选药物进行实验测试, 从而节省时间和成本。VS 算法的准确性可以通过现有的基准数据集进行评估。然而, 包括 DUD-E 基准 [27] 在内的某些基准存在偏差, 可能会奖励记忆能力, 而非真正的学习和泛化能力 [28,29]。偏差的一个常见来源是大量使用诱饵分子, 即假定为无活性的配体, 它们被设计成具有与真正活性分子相似的物理性质, 但拓扑结构不同 [28,30]。DUDE-Z 基准通过改进其生成诱饵分子的方法解决了 DUD-E 的局限性 [31]。此外, DUDE-Z 还引入了 Extrema 和 Goldilocks 基准, 分别解决了电荷不平衡问题, 并考虑了更大对接库的广泛特征 [31]。另一个推荐的、具有偏差意识的基准是 LIT-PCBA [32], 它是 PubChem 生物测定数据库 [33] 中精心挑选的一个子集。值得注意的是, LIT-PCBA 中没有诱饵分子。LIT-PCBA 的无偏性使其成为比许多其他虚拟筛选基准更具挑战性的评估数据集 [32]。

虚拟筛选算法的评估指标应当妥善解决“早期识别问题”, 即活性配体必须在命中列表的最前列, 以确保其能被纳入最终选择。常见的评估指标, 如曲线下面积 (AUROC), 未能充分考虑早期识别问题, 因此不适合作为虚拟筛选方法的评估指标, 尤其是在筛选超大型化合物库时 [34]。罗切斯特曲线下面积的玻尔兹曼增强判别 (BEDROC) [35] 通过指数加权改进了标准的 AUROC, 以适应早期识别的需求。与 AUROC 类似, BEDROC 的最差和最佳值分别为 0 和 1。富集因子 (EF) 是另一种常用的虚拟筛选评估指标, 用于衡量命中列表中预定义的前部比例内活性配体的数量与随机情况下的预期数量之比。尽管 EF 取决于任意选定的阈值, 且可能具有误导性 [31], 但它在虚拟筛选中仍被广泛使用。

3.4. 2014 - 2023 年药物靶点预测方法的发展历程

在对 16 个文档分类器进行微调和优化之后, 我们利用它们对 3286 项药物靶点预测研究中的方法学方面进行了自动情感预测 (补充图 S4)。就预测方法而言, 回归和对接是最常见的

两种情感, 分别出现在 2116 项 (64.4%) 和 1736 项 (52.8%) 研究中。交叉验证和最先进验证策略分别在 758 项 (23.1%) 和 659 项 (20.1%) 研究中得以实施, 这使得它们比仅在 295 项 (9.0%) 研究中出现的独立测试更受欢迎。在基于回归的研究中, 斯皮尔曼/皮尔逊相关系数和均方根误差是使用最广泛的两个指标, 分别出现在 1599 项 (48.7%) 和 1150 项 (35.0%) 研究中。同样, 在活性分类研究中, 准确率是最受欢迎的指标, 在 1593 项 (48.5%) 药物靶点分类研究中得到应用 (补充图 S4)。

为了研究计算方法在这些年的发展演变, 我们对过去十年中使用 16 种情感的药物靶点预测研究趋势进行了可视化 (图 4)。为了使文档分类更加稳健, 我们采用了 5 个模型集成分类器的投票机制, 在 5 折交叉验证中, 预测标签根据至少 5 个模型中的 3 个模型的共识来确定。当使用更严格的预测方案 (所有 5 个模型必须对结果达成一致) 时, 我们发现各情感类别中的正标签数量减少, 尤其是在 CV、斯皮尔曼/皮尔逊相关性、均方根误差、准确率和 F1 值方面 (见补充图 S5)。更严格的方案可能会引入更多的假阴性, 但结果为人工分析文章提供了一个良好的起点, 因为正样本数量较少 ($n = 259$)。未来可以通过增加训练数据集的规模来缓解这一问题。

与药物靶点活性分类相比, 基于回归的方法旨在预测药物与靶点之间连续的结合亲和力。多年来, 专注于基于回归方法的研究论文数量一直多于针对药物靶点相互作用活性分类的研究论文 (图 4)。特别是从 2021 年开始, 采用基于回归技术的文章比例显著上升。这一增长可能归因于可用于各种药物和靶点类别的药物靶点结合亲和力数据集的大幅扩充, 例如 ChEMBL 和其他数据库中整理的数据集。例如, ChEMBL 第 25 版包含 1550 万种生物活性数据 [36], 而其最新版本 (ChEMBL 第 33 版) 则涵盖了约 2000 万种生物活性数据 [22]。

不出所料, 采用深度学习 (DL) 和基于注意力机制方法的研究在 2020 年之后才开始显著增多 (图 4)。值得注意的是, 从 2022 年起, 基于深度学习的研究数量甚至超过了传统的机器学习 (ML) 药物靶点相互作用预测方法, 因为当高质量训练数据集足够大时, 深度学习通常被认为比传统方法具有更高的准确性 [37]。有趣的是, 我们的文献分类器显示, 纯计算预测研究与包含实验验证的研究的比例多年来一直相对稳定 (约 25%; 见补充图 6)。尽管在此期间药物靶点预测研究的数量显著增加, 但包含实验验证的研究数量却没有出现类似的上升。



图4.过去十年间计算药物靶点预测方法及评估实践的发展情况。这些出版物是通过 PubMed 搜索查询获得的（第 2.1 节）。绿色柱状图显示了每年发表的文章总数，而柱状图中彩色部分则表示包含给定方法类别（蓝色）、验证策略（红色）或评估指标（黄色）的研究所占的比例。这些比例是通过我们基于 Transformer 的集成文档分类器预测得出的。

进行实验验证，这应当成为更常规的操作。

在本世纪初（2014 年），有关对接方法的文章（45.2%）远多于基于监督式机器学习方法的药物靶点相互作用预测的文章（27.4%）。2021 年至 2023 年期间，对接研究的数量出现了急剧增长（见图 4）。这种对接研究的激增很可能归因于 2021 年 AlphaFold 的首次发布，这可能促使研究重点转向分子对接。随着 AlphaFold 新版本和扩展版本的不断发布以及预测结果在数据库中的可用性提高[39,40]，预计未来几年将会有更多基于 AlphaFold 的对接研究发表。然而，当将 Alp

haFold 及其他基于深度学习的蛋白质结构预测方法[41]作为药物靶点相互作用预测流程的一部分时[42]，持续评估其预测准确性和置信度也非常重要。

3.5. 用于验证复合靶点预测的数据拆分场景

在监督式机器学习任务中，模型评估通常涉及 k 折交叉验证或独立测试集。在药物靶点预测的背景下，这些验证策略假定待预测的配对在已知（实验测量的）相互作用矩阵中是随机分布的。然而，在成对输入的场景中，例如预测药物与靶点的相互作用时，这种假设并不成立。




图 5.用于验证化合物-靶点预测方法的常见数据拆分场景。1: 生物活性推断, 2: 新化合物, 3: 新靶点, 4: 新化合物和新靶点, 5: 随机拆分, 6: 完全不相似拆分。测试药物-靶点对符合场景 1 的条件是, 成对相互作用涉及的化合物和靶点均存在于训练数据中; 符合场景 2 的条件是, 化合物不在训练数据中而靶点在训练数据中; 符合场景 3 的条件是, 化合物在训练集中而靶点不在训练集中; 符合场景 4 的条件是, 化合物和靶点均不在训练数据中。场景 5 可以包含任何化合物和靶点对之间的相互作用。对于场景 6, 所有测试化合物和靶点在结构上必须与训练数据中的化合物和靶点足够不同。图中化合物和靶点簇代表结构相似性。虚线表示必须从训练和测试中剔除的相互作用, 否则会违反不相似性假设。

在研究药物 - 靶点相互作用时, 考虑不同的预测场景至关重要, 这些场景中训练数据和测试数据要么共享相同的药物或靶点集, 要么使用不同的药物或靶点集。这有助于更准确地评估模型在这些特定情况下的性能。通常采用六种场景来验证药物 - 靶点亲和力的预测 (图 5):

- (1) **生物活性推断**: 测试训练集中所有化合物和靶点之间目前缺失的相互作用。
- (2) **新化合物**: 测试训练集中未出现的化合物与训练数据中目标之间的相互作用。
- (3) **新靶点**: 测试训练集中未出现的靶点 (即训练集中不存在的靶点) 与训练数据中化合物之间的相互作用。
- (4) **新化合物与新靶点**: 测试训练数据中均未出现的未知化合物与未知靶点之间的相互作用。

这四种场景由 Pahikkala 等人[18]提出, 通常应用于与模型训练所用数据集 (无论是通过交叉验证还是留出集) 相分离的独立测试数据。场景 1 和 3 对药物再利用工作特别相关, 其目标是预测已获批药物的新有效靶点, 从而可能将其用于其他疾病, 而新靶点在这些疾病中发挥着作用。另一方面, 场景 2 和 4 更适合基于靶点的药物发现应用, 其主要目的是为特定疾病相关靶点识别新的靶向抑制剂。最后两种场景由 Guvenil

ir 等人[43]推荐, 涉及将原始数据集拆分为训练集和测试集的其他类型方法:

- (5) **随机拆分**: 将数据集随机划分为训练集和测试集。然而, 这往往会导致过于乐观的结果, 因为可能存在药物和靶点相似性方面的数据泄露。训练集和测试集之间高度相似的化合物可能会导致过拟合, 即模型无法推广到新的化学领域。因此, 随机拆分不建议作为通用的验证策略。
- (6) **不同数据集划分**: 训练集和测试集中既没有相同的化合物, 也没有相同的靶点。相似性可以根据化合物结构 (SMILES) 和靶点序列 (fasta) 之间的成对比较来确定。

3.6. 化学性质影响药物靶点预测模型及评估

考虑到化学结构的相似性对于药物靶点的预测和评估至关重要。结构分析有助于计算模型识别分子结构中可能与生物活性相关的模式, 这通常会提高测试集的准确性, 尤其是在训练数据集包含非常相似的化合物时。然而, 训练集和测试集之间高度相似的化合物可能会导致过拟合, 从而使模型无法推广到新的化学领域。因此, 最佳的机器学习模型还可以利用结构多样的化合物集来提供准确的预测。



测试化合物活性预测 [17]。可使用多种指纹算法计算结构相似性，例如分子访问系统 (MACCS) [44] 和 featurized 指纹 [45]。Python 或 R 中的 RDKit 包 [46] 可计算这些及其他结构指纹。通过利用化学结构与生物功能之间的关系，结构相似性分析在命中鉴定和先导化合物优化方面特别有用 [47]。

在开发和评估药物靶点相互作用预测模型时，考虑诸如分子质子化状态和手性等物理化学和几何特性也至关重要 [48]。分子的质子化状态由环境的 pH 值决定，会影响其电荷分布、几何形状和整体稳定性。这种状态可通过影响氢键、静电相互作用以及分子构象，显著影响药物与靶点的结合亲和力 [49]。由于许多药物靶点是特定 pH 范围内运作的酶，质子化状态对于确保药物与酶活性位点的良好契合度至关重要。手性是指分子与其镜像不能重合的化学性质。这些镜像分子，即对映体，分别标记为 R (直) 和 S (左)。对映体可能表现出不同的生物活性：一种可能有益，而另一种可能无效或有害。因此，识别并使用药物的正确手性形式对于其有效性和安全性至关重要 [50]。

许多分子对接软件，例如 Schrodinger [51]，能够预测和优化质子化状态以及手性构型。在 Schrodinger 的 Maestro 界面中，Epik 模块可以预测和优化质子化状态。用户可以将分子导入 Maestro，打开 Epik 工具，设置所需的 pH 范围，然后运行预测。Epik 会分析局部环境和 pKa 值，生成并排列可能的质子化状态，从而选择最相关的状态进行进一步分析。对于手性，可以使用 Maestro 中的 Schrodinger 的 ConfGen 模块。导入分子后，ConfGen 会指定手性中心并生成可能的立体异构体，从而能够评估不同的手性构型。这有助于确定分子的最生物活性形式。这些工具共同提供了质子化状态和手性构型的全面分析，从而提高了药物靶点预测模型的精度。

总之，在构建准确且通用的药物靶点预测模型时，考虑结构相似性、手性以及质子化状态至关重要。因此，在为模型训练和验证拆分数据时，除了考虑配对输入预测问题中的药物和靶点标识符外，还应考虑这些性质。在训练和测试中使用正确的手性形式可提高模型的预测准确性，而使训练集和测试集中的质子化状态保持一致则能提高预测药物靶点相互作用的可靠性。整合这些分子性质有助于开发适用于实际场景的稳健且精确的预测模型。

3.7. 大型语言模型在药物研发中的应用

大型语言模型 (LLMs)，包括转换器模型，在药物发现的多种应用中提供了一种经济高效且有效的解决方案，最近已有多款 LLM 被提出并应用于这一领域。例如，近期的研究 [52,53] 利用了诸如 BERT [54]、SciBERT [55]、BioBERT [56]、BioMed-RoBERTa [57] 和 BlueBERT [58] 等 LLM 从实验文献中识别药物与靶点的相互作用。此外，另一项近期研究成功地将 BERT 应用于预测蛋白质和肽的相互作用，这表明其在生物药物发现中的多功能性 [59]。LLMs 还被用于药物分子与适应症之间的转换 [60]。此外，基于 GPT 的架构也被用于其他药物发现任务，包括从头药物设计 [61] 和生物问题回答 [62]。这些例子突显了 LLMs 在推进药物发现及相关领域的研究和创新方面的广泛适用性。然而，与其它计算方法类似，LLMs 的预测结果需要通过计算和实验方法进行仔细验证。

4. 药物靶点相互作用预测的实验验证

为了进一步验证所预测的药物 - 靶点相互作用在特定疾病或细胞环境中具有生物学或药理学意义，应在湿实验室或动物实验中对这些预测进行验证。理想情况下，应采用多种正交检测方法和疾病模型。尽管实验验证需要专门的基础设施、额外的资源，有时还需要进行耗时的湿实验室或动物实验，而这些可能并非所有研究机构都具备，但至少应针对选定的药物 - 靶点相互作用在细胞模型中进行有针对性的实验研究，例如通过合作或服务的方式。这应当也是科学期刊的要求。药物与靶点的结合或生物活性验证是真正确认计算预测具有潜力推进到药物发现或开发过程下一阶段的唯一途径。理想情况下，药物 - 靶点结合实验应在预测之后设计，从而作为完全盲法验证数据 [63]。这与使用例如交叉验证或实验数据的保留集进行的计算验证策略形成对比。在这些策略中，验证数据在模型训练期间就已经可用 [64]，这可能会导致有意或无意的信息泄露，从而导致预测准确率过于乐观。然而，如果在做出预测之后再设计湿实验，实验验证数据就不会被模型或建模人员看到。这种盲法有助于避免任何潜在的信息泄露，前提是建模人员（训练模型并做出预测的人）和实验人员（进行实验验证的人）在过程中不共享结果信息。理想情况下，正预测（药物 - 靶点活性）和负预测（无活性预测 [52]）都应在实验环境中进行测试和随机化，也就是说，实验人员对预测结果不知情。

许多被自然语言处理分类器归类为“实验验证”的药物靶点相互作用研究，并非直接验证药物与蛋白质之间的相互作用，而是验证了特定细胞或疾病背景下预测的药物活性。在“更严格的预测方案”（见第 3.4 节）列出的 259 篇文章中，也有一些研究中的药物靶点相互作用并非来自特定的对接、统计或机器学习模型。相反，这些药物靶点相互作用的预测是基于生物学假设或对先前收集的生物学或细胞数据的一般性探索，随后通过通路或网络分析得出少量的靶点活性假设。在接下来的部分中，我们将重点关注那些通过实验研究来验证特定计算模型的研究，无论是基于分类还是回归的模型，这些模型都有可能系统地预测化合物与靶点的亲和力或其活性类别，涵盖广泛的化合物类别和/或蛋白质家族。这并不包括只能应用于特定药物或靶点的定向预测模型，例如标准的定量构效关系（QSAR）模型[65]。然而，以下建议对于特定靶点的 QSAR 和其他模型类别的实验验证也应有用。下面选择的具体示例旨在能够应用于各种药物类别和蛋白质家族。我们注意到，所选的研究并非唯一推荐的研究，而是作为对计算模型预测进行了相对严格实验验证的研究示例。

4.1. 生物化学大规模验证研究

生化靶点活性实验可在剂量反应试验中对数百种化合物与靶点的相互作用进行大规模验证。如果仅在单一固定剂量下进行，这些试验可轻松扩展至在高通量筛选

（HTS）中对数千甚至数万种化合物针对数百种蛋白质进行测试。然而，建议采用剂量反应生化试验，因为化合物的活性窗口可能因药物和靶点类别而有极大差异。因此，在选定浓度（例如 1000 纳摩尔）下进行的单剂量试验可能难以在来自不同药物或靶点类别的测试化合物 - 蛋白质对之间进行比较。

相似性集成方法（SEA）是一种定量预测方法，它基于已知药物靶点所注释配体的拓扑化学相似性，对大量蛋白质进行分组[66]。随后，将所得相似性得分的统计显著性以最小生成树的形式表示，可用于将蛋白质靶点集合合并在一起。这种相对简单的统计模型揭示了出乎意料的靶点之间的联系，其中一些联系已通过生化结合试验（以及后来的基于细胞的功能试验，见第 4.2 节）得到了实验验证[66]。SEA 方法还被用于系统地预测 3665 种已获美国食品药品监督管理局（FDA）批准的药物新靶点。总体而言，对 30 种新的脱靶进行了实验测试，涵盖了多个蛋白质家族，使用放射性配体竞争结合试验，其中 23 种（77%）的抑制常数

(K_i) 小于 15 μM ，其中 5 种抑制常数 (K_i 小于 100 nM) [67]。

VirtualKinomeProfiler 扩展了 SEA 策略，利用集成支持向量机（eSVM）算法捕捉化学相似性空间的独特表示，从而实现系统性的激酶活性分类[68]。该网络工具能够同时对化合物在 248 种激酶中的活性进行分析。实验验证采用了单剂量和剂量反应生化活性测定。与单剂量生化筛选相比，eSVM 预测模型的精度提高了 1.5 倍，假发现率降低了 2.8 倍。在对激酶抑制剂靶点活性预测算法进行跨激酶家族的比较基准测试时，采用了类似的验证策略。验证使用了剂量反应解离常数 (K_d) 测定，结果表明，表现最佳的机器学习模型集成的准确性超过了单剂量活性筛选[17]。

近来，许多深度学习模型已被开发用于目标活性预测。目前，蛋白激酶无疑拥有可用于深度学习模型训练和计算验证的最丰富的高质量定量结合亲和力数据。例如，迁移学习模型 ConPLex 通过使用预训练的蛋白质语言模型，能够对多种类型的目标类别进行药物 - 目标结合预测 [69]。它基于学习到的表示之间的距离进行结合预测，从而能够在大规模化合物库和完整的人类蛋白质组的规模上进行预测。对 19 种激酶 - 药物预测的实验测试验证了 12 种相互作用（63%），其中包括四种具有亚纳摩尔亲和力的相互作用，以及一种与 EPHB1 强结合的抑制剂（ $K_d = 1.3 \text{ nM}$ ）。

在抗病毒应用方面，Han 等人开发了一个基于卷积神经网络（CNN）、转换器和注意力机制的网络服务器和深度学习模型 D3AI-Spike，用于快速预测 SARS-CoV-2 刺突受体结合域（RBD）突变与人类血管紧张素转化酶 2（hACE2，即 SARS-CoV-2 的受体）之间的结合亲和力[70]。D3AI-Spike 通过首先预测然后实验测定正在监测的变异株 IHU（B.1.640.2）刺突蛋白中许多突变和缺失的变体的结合亲和力得到了验证。采用非竞争性 ELISA 检测法测量刺突蛋白 RBD 的亲亲和常数 (K_{aff})，证明了 D3AI-Spike 平台具有很强的预测能力。

虽然生化检测能够为化合物具有调节特定靶蛋白的潜力提供初步验证，但此类检测所显示的活性尚不能确认化合物与靶蛋白的相互作用会带来期望的细胞或疾病表型。此外，对大量蛋白质靶点（包括预测为有活性和无活性的靶点）进行药物靶点相互作用的生化检测，对于选择性分析十分重要，即确定化合物对特定靶蛋白（例如感兴趣的疾病靶点）的活性具有多大的靶点特异性[71]。对于预测为无活性的相互作用的阴性结果，也应进行实验验证，以探究计算模型的阴性预测准确性 [63]。

4.2. 细胞模型中的体外验证研究

基于细胞的表型检测为预测的化合物与靶点相互作用会导致期望的细胞表型（例如选择性杀死癌细胞或病毒感染细胞）提供了第二层确认，这种确认是在与疾病相关的细胞环境中进行的。除了抗癌和抗病毒应用外，基于细胞的验证还可用于指导在鉴定具有生物活性的抗菌剂时进行表型筛选。基于针对结核分枝杆菌（Mtb）的大规模筛选，Mugumbate 等人构建了一个由 SEA、朴素贝叶斯分类器和对接算法组成的集成模型，以预测具有抗结核表型效应的潜在靶点[72]。他们确认了两种在分枝杆菌耐药菌株中具有活性的化合物是二氢叶酸还原酶（DHFR）的有效抑制剂，DHFR 是 Mtb 的一个关键基因，已被临床验证为药物靶点。

Ariey-Bonnet 等人使用了一种数据驱动预测工具 MolTarPred [73]，来探究抗蠕虫药物甲苯咪唑（MBZ）在脑瘤治疗中的作用机制（MoA）[74]。MolTarPred 能够向用户提供与查询分子（此处为 MBZ）最相似的目标注释分子，从而基于化学相似性识别潜在目标。在胶质母细胞瘤细胞中进行的热位移和 NanoBRET 目标结合实验验证表明，MBZ 以剂量依赖的方式与 MAPK14/p38 α 结合，并抑制其激酶活性，这种抑制作用在体外和细胞内均存在。此外，通过 RNA 干扰进行基因沉默的实验进一步证实，MAPK14 在 MBZ 对胶质母细胞瘤（GBM）细胞的细胞毒性作用中发挥关键作用，这表明 MAPK14 是 GBM 中一个有前景的可成药靶点。

另一种基于结构的模型 DRUIDom 提出了一种统计方法，通过利用蛋白质的模块化结构来识别药物化合物与其生物靶点之间新的相互作用[75]。该方法能够大规模绘制小分子化合物图谱，并基于分子相似性对其进行聚类。DRUIDom 的预测在一些在多种癌症进展中起关键作用的选定蛋白质上进行了测试，基于细胞的实验表明，预测的抑制剂即使对耐药性癌细胞也有效。特别是，作者表明，预测的针对 LIM 激酶蛋白的化合物，此前已知在调节细胞运动性和细胞周期进程方面发挥作用，通过抑制 LIMK 磷酸化和下游蛋白 cofilin，显著阻断了癌细胞迁移。

DEEPScreen 利用卷积神经网络（CNNs）从化合物的二维表示中学习特征，而非使用结构指纹[76]。DEEPScreen 预测 JAK 蛋白为克拉屈滨的新靶点，克拉屈滨是一种获批用于特定类型淋巴瘤和白血病的抗肿瘤药物。该模型的预测通过肝细胞癌（HCC）细胞系中 JAK 蛋白下游效应器 STAT3 的磷酸化得到了实验验证。实验数据表明，克拉屈滨作用于 JAK/STAT3 信号通路，并诱导 HCC 细胞凋亡。另一个深度学习模型 OverfitDTI 利用深度神经网络（DNNs）学习药物化学空间和靶点分子空间的预测特征[77]。实验表明，两个预测化合物可抑制 TEK 激酶活性并阻断内皮细胞管形成。

虽然基于细胞的检测能够确认在选定的细胞环境中预测的目标调节或目标结合情况，但重要的是要谨慎选择细胞模型，使其能很好地呈现所需的疾病背景，从而使验证具有转化意义。此外，还应纳入多种对照细胞模型，在这些模型中，预计不会观察到计算预测的活性，例如在癌症应用中，具有低/高目标蛋白表达或野生型版本的细胞模型，以评估预测的背景和目标特异性。例如，在突变型和野生型细胞系中抑制相同的目标，表明该化合物可能会对非恶性细胞产生毒性副作用。

4.3. 动物模型中的体内验证研究

动物实验用于研究药物在体内的治疗反应，以及通过分子分析受试动物的生物样本以探究药物的作用机制。此类实验自然只能针对少数选定的药物进行，而且对样本进行治疗后的分析只能为靶点验证提供间接证据。例如，郭等人研究了用于治疗急性心肌梗死（AMI）的传统中药丹红注射液（DHI）的作用机制。作者将分子对接与化合物-靶点和疾病-靶点蛋白质-蛋白质相互作用网络分析相结合，并通过治疗后的 Sprague-Dawley 大鼠心脏组织样本的蛋白质分析来验证预测结果[78]。他们证明了钙信号通路可能是丹红注射液的潜在作用机制。

赵等人开发了一种基于深度学习的药物靶点相互作用预测方法 DLDTI，该方法基于网络表示学习和卷积神经网络（CNN）。使用低维特征向量训练 DLDTI 以实现最优映射空间，并通过根据其最优映射空间的接近程度对新药物靶点相互作用进行排序来推断这些相互作用[79]。在仓鼠身上对四甲基吡嗪（TMPZ）对动脉粥样硬化进展的预测靶点进行了实验验证。更具体地说，通过蛋白质印迹法对血小板进行了蛋白质分析，并通过免疫组织化学法对治疗动物主动脉根部的动脉粥样硬化斑块细胞组成进行了研究。作者得出结论，TMPZ 可通过抑制血小板中的信号转导来减轻动脉粥样硬化。

虽然动物模型能够评估化合物在体内的活性，但需要注意的是，对于许多疾病和药物而言，目前还没有能够预测最终人体内作用和临床结果的代表性动物模型。在大多数动物实验中，对治疗的潜在毒性以及与毒性相关的脱靶效应的研究也并非常规进行，尽管理应如此。还应指出的是，以多种浓度测试药物及其作用机制与动物伦理的“4R”原则（减少、替代、优化、责任）不符，因为每增加一个剂量就需要增加一组动物。此外，根据动物实验数据预测临床适用剂量并非易事，仍需在人体中进行剂量递增研究以评估可耐受剂量和潜在药物不良反应。

5. 结论

在本研究中，我们对药物 - 靶点相互作用预测研究进行了调查，并开发了基于自然语言处理（NLP）的文档分类器，以自动审查过去十年发表的 3286 篇药物 - 靶点相互作用预测相关文章的方法学。自动文档分类的使用有助于相对准确地快速调查大量文献（图 2，补充图 S3）。我们已在 GitHub 上提供了分析脚本（<https://github.com/AronSchulman/DTI-abstract-classifier>），以便其他人能够在未来的研究中采用和扩展类似的方法。此外，我们还对 3286 篇研究中的 259 篇进行了人工分析，这些研究还进行了实验验证，因为自动分析无法区分实验是在计算预测之前还是之后进行的。

基于文献综述，我们发现大多数用于预测药物 - 靶点相互作用的计算算法仍未经过实验验证。尽管严格的计算验证（如交叉验证和留出集）在正确执行时有助于避免报告过于乐观的预测准确性，但实验验证仍然至关重要。实验研究可以证明预测的靶点活性在特定疾病或细胞环境中具有生物学或药理学意义，因此也有可能推进到药物发现或开发过程的下一阶段。因此，分别需要计算验证和实验验证来全面评估预测模型的泛化能力和转化能力。

这篇综述全面概述了用于识别药物 - 靶点相互作用的各种方法类型，涵盖了不同预测方法所采用的不同验证策略和评估指标。我们还描述了用于验证化合物 - 靶点预测的各种数据分割策略的优势和局限性（第 3.5 节），并强调了化学性质对药物 - 靶点预测模型性能和评估的影响（第 3.6 节）。通过深入探讨这些关键方面，该综述强调了选择适当的方法和验证技术对于提高药物 - 靶点相互作用预测的准确性和可靠性的重要性。总体而言，这项分析为指导未来研究和优化药物发现应用中的模型性能提供了资源。

6. 专家意见

我们的分析表明，大多数计算方法都是在相对较小的激酶靶点基准数据集上进行训练和测试的，例如 Davis [6] 和 KIBA [19]，这些数据集仅包含几百个激酶靶点和激酶抑制剂。因此，我们建议未来的开发者应在其预测方法的训练中使用更大的生物活性数据集，例如 ChEMBL [22]、Drug Target Commons [24] 和 BindingDB [80] 中的数据集，这些数据集包含了多个蛋白质家族和药物类别中连续的

靶点活性数据。这些数据可用于研究化合物在不同蛋白质家族中的正确适用范围和潜在交叉活性。全面且严格的验证方法能显著提高模型在药物发现或再利用应用中的可靠性。

此外，我们建议将基准数据集（包括 Davis [6]、Metz [5]、KIBA [19] 和 Yamanishi [4]）要么完全保留用于测试，作为独立验证数据，要么明确报告用于训练和测试的交叉验证折数，如 DTITR 方法 [81] 所示。否则，由于不同研究中数据预处理和划分方式的差异，未来研究中预测准确性的比较可能会变得困难，这可能会使连续的模型性能评估产生偏差。为了能够对现有和新兴方法进行持续的基准测试，还应将训练和测试数据与预测算法的代码一起发布在公共存储库（如 GitHub 或 Zenodo）中，供他人自由使用和扩展。

此外，我们建议在药物靶点预测研究中引入不确定性估计方法，例如通过一致性预测进行置信度评分 [82]。一致性预测是一种轻量级的统计方法，它生成预测集（用于分类）或区间（用于回归），而非单点预测。然后，这些预测集或区间用于量化单个预测的置信度。一致性分类器可以告知终端用户某个特定预测对于结果是否过于不确定。在回归中，很难以高置信度预测出窄且更具操作性的活性区间。模型置信水平与所得预测区间宽度之间的关系将有助于进行严格的模型比较 [83]。

实验验证对于确认化合物与靶点的相互作用在预测的细胞环境中导致期望的细胞表型至关重要。然而，应包含对照实验，包括对照细胞系（例如非恶性或野生型细胞）以及阴性预测（即非活性药物 - 靶点相互作用），以分别测试细胞环境选择性和靶点特异性。在激酶组范围的实验研究中，单剂量生化活性测定通常作为首次高通量筛选，只有那些表现出单剂量活性的药物 - 激酶相互作用才会进一步在剂量反应测定中进行测试 [6]。然而，机器学习预测模型可以替代单剂量筛选，并且在预测亲和力水平时具有更高的准确性 [17,68]。只要针对感兴趣的药物和靶点类别的目标活性训练数据足够大，这将降低实验成本。

资金

T.A. 的研究得到了芬兰科学院（项目编号：326238、340141、344698 和 345803）、挪威东南部卫生局（项目编号：2020026 和 2023105）、芬兰癌症协会、挪威癌症协会以及西格丽德·朱塞利乌斯基金会的支持。ZT 的研究得到了芬兰科学院（项目编号：351507）的支持。

利益声明

作者与任何在经济上有利害关系或存在经济冲突的组织或实体均无相关隶属关系或经济往来。

与手稿中所讨论的主题或材料有关的事项。这包括受雇、咨询工作、酬金、股票所有权或期权、专家证词、已获或待批的资助或专利，以及版税。

审稿人披露

该文稿的审稿人没有需要披露的相关财务或其他关系。

参考文献

Papers of special note have been highlighted as either of interest (·) or of considerable interest (· ·) to readers.

- Schuhmacher A, Hinder M, Und Stein AVS, et al. Analysis of pharma R&D productivity –a new perspective needed. *Drug Discovery Today*. 2023;28(10):103726. doi: 10.1016/j.drudis.2023.103726
- Pushpakom S, Iorio F, Eyers PA, et al. Drug repurposing: progress, challenges and recommendations. *Nat Rev Drug Discov*. 2019;18 (1): 41–58. doi: 10.1038/nrd.2018.168
- · This review presents several approaches and challenges for systematic drug repurposing.
- Reinecke M, Brear P, Vornholz L, et al. Chemical proteomics reveals the target landscape of 1,000 kinase inhibitors. *Nat Chem Biol*. 2024;2023 (5):577–585. doi: 10.1038/s41589-023-01459-3
- Yamanishi Y, Kotera M, Kanehisa M, et al. Drug-target interaction prediction from chemical, genomic and pharmacological data in an integrated framework. *Bioinformatics*. 2010;26(12):i246–i254. doi: 10.1093/bioinformatics/btq176
- Provides binary benchmark datasets for four superfamilies of protein targets.
- Metz JT, Johnson EF, Soni NB, et al. Navigating the kinome. *Nat Chem Biol*. 2011;7(4):200–202. doi: 10.1038/nchembio.530
- Davis MI, Hunt JP, Herrgard S, et al. Comprehensive analysis of kinase inhibitor selectivity. *Nat Biotechnol*. 2011;29(11):1046–1051. doi: 10.1038/nbt.1990
- · One of the first large-scale screens of kinase inhibitor target activities.
- Tanoli Z, Seemab U, Scherer A, et al. Exploration of databases and methods supporting drug repurposing: a comprehensive survey. *Brief Bioinform*. 2020;22(2):1656–1678. doi: 10.1093/bib/bbaa003
- Review presents pros and cons of 102 public resources supporting drug repurposing.
- Carpenter KA, Altman RB. Databases of ligand-binding pockets and protein-ligand interactions. *Comput Struct Biotechnol J*. 2024;23:1320–1338. doi: 10.1016/j.csbj.2024.03.015
- Santos R, Ursu O, Gaulton A, et al. A comprehensive map of molecular drug targets. *Nat Rev Drug Discov*. 2017;16(1):19–34. doi: 10.1038/nrd.2016.230
- Ding H, Takigawa I, Mamitsuka H, et al. Similarity-based machine learning methods for predicting drug–target interactions: a brief review. *Brief Bioinform*. 2014;15(5):734–747. doi: 10.1093/bib/bbt056
- Bagherian M, Sabeti E, Wang K, et al. Machine learning approaches and databases for prediction of drug–target interaction: a survey paper. *Brief Bioinform*. 2021;22(1):247–269. doi: 10.1093/bib/bbz157
- Koutsoukas A, Simms B, Kirchmair J, et al. From in silico target prediction to multi-target drug design: current databases, methods and applications. *J Proteomics*. 2011;74(12):2554–2574. doi: 10.1016/j.jprot.2011.05.011
- Ezzat A, Wu M, Li X-L, et al. Computational prediction of drug–target interactions using chemogenomic approaches: an empirical survey. *Brief Bioinform*. 2019;20(4):1337–1357. doi: 10.1093/bib/bby002
- Abbasi K, Razzaghi P, Poso A, et al. Deep learning in drug target interaction prediction: current and future perspectives. *Curr Med Chem*. 2021;28(11):2100–2113. doi: 10.2174/0929867327666200907141016
- Paananen J, Fortino V. An omics perspective on drug target discovery platforms. *Brief Bioinform*. 2020;21(6):1937–1953. doi: 10.1093/bib/bbz122
- Sachdev K, Gupta MK. A comprehensive review of feature based methods for drug target interaction prediction. *J Biomed Inform*. 2019;93:103159. doi: 10.1016/j.jbi.2019.103159
- Cichońska A, Ravikumar B, Allaway RJ, et al. Crowdsourced mapping of unexplored target space of kinase inhibitors. *Nat Commun*. 2021;12(1):3307. doi: 10.1038/s41467-021-23165-1
- · Crowdsourced community-wide benchmarking of predictive algorithms for kinase inhibitor potencies across multiple kinase families.
- Pahikkala T, Airola A, Pietilä S, et al. Toward more realistic drug–target interaction predictions. *Brief Bioinform*. 2015;16(2):325–337. doi: 10.1093/bib/bbu010
- · The first study that describes the various challenges and gives guidelines for computational evaluation of drug–target interaction predictions.
- Tang J, Szwajda A, Shakyawar S, et al. Making sense of large-scale kinase inhibitor bioactivity data sets: a comparative and integrative analysis. *J Chem Inf Model*. 2014;54(3):735–743. doi: 10.1021/ci400709d
- Gururangan S, Marasovič A, Swayamdipta S, et al. Don't stop pre-training: adapt language models to domains and tasks. *arXiv pre-print arXiv:2004.10964*. 2020.
- Wolf T, Debut L, Sanh V, et al. Huggingface's transformers: state-of-the-art natural language processing. *ArXiv*. arXiv preprint arXiv: 1910.03771. 2019.
- Zdrzil B, Felix E, Hunter F, et al. The ChEMBL database in 2023: a drug discovery platform spanning multiple bioactivity data types and time periods. *Nucleic Acids Res*. 2023;52(D1):D1180–D1192. doi: 10.1093/nar/gkad1004
- Tang J, Tanoli Z-R, Ravikumar B, et al. Drug target commons: a community effort to build a consensus knowledge base for drug-target interactions. *Cell Chem Biol*. 2018;25(2):224–229. doi: 10.1016/J.CHEMBIOL.2017.11.009
- Tanoli Z, Alam Z, Vähä-Koskela M, et al. Drug target commons 2.0: a community platform for systematic analysis of drug–target interaction profiles. *Database*. 2018;2018:1–13. doi: 10.1093/database/bay083
- Tanoli Z, Alam Z, Ianevski A, et al. Interactive visual analysis of drug–target interaction networks using drug target profiler, with applications to precision medicine and drug repurposing. *Brief Bioinform*. 2020;21(1):211–220. doi: 10.1093/bib/bby119
- Steyerberg EW, Vickers AJ, Cook NR, et al. Assessing the performance of prediction models: a framework for traditional and novel measures. *Epidemiology*. 2010;21(1):128–138. doi: 10.1097/EDE.0b013e3181c30fb2
- Mysinger MM, Carchia M, Irwin JJ, et al. Directory of useful decoys, enhanced (DUD-E): better ligands and decoys for better benchmarking. *J Med Chem*. 2012;55(14):6582–6594. doi: 10.1021/jm300687e
- Chen L, Cruz A, Ramsey S, et al. Hidden bias in the DUD-E dataset leads to misleading performance of deep learning in structure-based virtual screening. *PLOS ONE*. 2019;14(8):e0220113. doi: 10.1371/journal.pone.0220113
- Wallach I, Heifets A. Most ligand-based classification benchmarks reward memorization rather than generalization. *J Chem Inf Model*. 2018;58(5):916–932. doi: 10.1021/acs.jcim.7b00403
- Chaput L, Martinez-Sanz J, Saettel N, et al. Benchmark of four popular virtual screening programs: construction of the active/decoy dataset remains a major determinant of measured performance. *J Cheminform*. 2016;8(1):1–17. doi: 10.1186/s13321-016-0112-z
- Stein RM, Yang Y, Balius TE, et al. Property-unmatched decoys in docking benchmarks. *J Chem Inf Model*. 2021;61(2):699–714. doi: 10.1021/acs.jcim.0c00598
- Tran-Nguyen V-K, Jacquemard C, Rognan D. LIT-PCBA: an unbiased data set for machine learning and virtual screening. *J Chem Inf Model*. 2020;60(9):4263–4273. doi: 10.1021/acs.jcim.0c00155

33. Wang Y, Bryant SH, Cheng T, et al. PubChem BioAssay: 2017 update. *Nucleic Acids Res.* 2016;45(D1):D955–D963. doi: [10.1093/nar/gkw1118](https://doi.org/10.1093/nar/gkw1118)
34. Lyu J, Irwin JJ, Shoichet BK. Modeling the expansion of virtual screening libraries. *Nat Chem Biol.* 2023;19(6):712–718. doi: [10.1038/s41589-022-01234-w](https://doi.org/10.1038/s41589-022-01234-w)
35. Truchon J-F, Bayly CI. Evaluating virtual screening methods: good and bad metrics for the “early recognition” problem. *J Chem Inf Model.* 2007;47(2):488–508. doi: [10.1021/ci600426e](https://doi.org/10.1021/ci600426e)
36. Mendez D, Gaulton A, Bento AP, et al. ChEMBL: towards direct deposition of bioassay data. *Nucleic Acids Res.* 2019;47(D1):D930–D940. doi: [10.1093/nar/gky1075](https://doi.org/10.1093/nar/gky1075)
37. LeCun Y, Bengio Y, Hinton G. Deep learning. *Nature.* 2015;521(7553):436–444. doi: [10.1038/nature14539](https://doi.org/10.1038/nature14539)
38. Jumper J, Evans R, Pritzel A, et al. Highly accurate protein structure prediction with AlphaFold. *Nature.* 2021;596(7873):583–589. doi: [10.1038/s41586-021-03819-2](https://doi.org/10.1038/s41586-021-03819-2)
- **The first version of AlphaFold protein structure prediction algorithm.**
39. Varadi M, Bertoni D, Magana P, et al. AlphaFold protein structure database in 2024: providing structure coverage for over 214 million protein sequences. *Nucleic Acids Res.* 2024;52(D1):D368–D375. doi: [10.1093/nar/gkad1011](https://doi.org/10.1093/nar/gkad1011)
40. Abramson J, Adler J, Dunger J, et al. Accurate structure prediction of biomolecular interactions with AlphaFold 3. *Nature.* 2024;2024(8016):493–500. doi: [10.1038/s41586-024-07487-w](https://doi.org/10.1038/s41586-024-07487-w)
41. Terwilliger TC, Liebschner D, Croll TI, et al. AlphaFold predictions are valuable hypotheses and accelerate but do not replace experimental structure determination. *Nat Methods.* 2024;21(1):110–116. doi: [10.1038/s41592-023-02087-4](https://doi.org/10.1038/s41592-023-02087-4)
42. Voitsitskiy T, Stratiichuk R, Koleiev I, et al. 3DProtDTA: a deep learning model for drug-target affinity prediction based on residue-level protein graphs. *RSC Adv.* 2023;13(15):10261–10272. doi: [10.1039/D3RA00281K](https://doi.org/10.1039/D3RA00281K)
43. Atas Guvenilir H, Doğan T. How to approach machine learning-based prediction of drug/compound–target interactions. *J Cheminform.* 2023;15(1):16. doi: [10.1186/s13321-023-00689-w](https://doi.org/10.1186/s13321-023-00689-w)
44. Durant JL, Leland BA, Henry DR, et al. Reoptimization of MDL keys for use in drug discovery. *J Chem Inf Comput Sci.* 2002;42(6):1273–1280. doi: [10.1021/ci010132r](https://doi.org/10.1021/ci010132r)
45. Rogers D, Hahn M. Extended-connectivity fingerprints. *J Chem Inf Model.* 2010;50(5):742–754. doi: [10.1021/ci100050t](https://doi.org/10.1021/ci100050t)
46. Bento AP, Hersey A, Félix E, et al. An open source chemical structure curation pipeline using RDKit. *J Cheminform.* 2020;12(1):1–16. doi: [10.1186/s13321-020-00456-1](https://doi.org/10.1186/s13321-020-00456-1)
47. Yi J, Lee S, Lim S, et al. Exploring chemical space for lead identification by propagating on chemical similarity network. *Comput Struct Biotechnol J.* 2023;21:4187–4195. doi: [10.1016/j.csbj.2023.08.016](https://doi.org/10.1016/j.csbj.2023.08.016)
48. Rudrapal M, Egbuna C. Computer aided drug design (CADD): from ligand-based methods to structure-based approaches. Elsevier; 2022. <https://shop.elsevier.com/books/computer-aided-drug-design-cadd-from-ligand-based-methods-to-structure-based-approaches/rudrapal/978-0-323-90608-1>.
49. Lasham J, Djurabekova A, Zickermann V, et al. Role of protonation states in the stability of molecular dynamics simulations of high-resolution membrane protein structures. *J Phys Chem B.* 2024;128(10):2304–2316. doi: [10.1021/acs.jpcc.3c07421](https://doi.org/10.1021/acs.jpcc.3c07421)
50. Ceramella J, Iacopetta D, Franchini A, et al. A look at the importance of chirality in drug activity: some significative examples. *Appl Sci.* 2022;12(21):10909. doi: [10.3390/app122110909](https://doi.org/10.3390/app122110909)
51. Friesner RA, Banks JL, Murphy RB, et al. Glide: a new approach for rapid, accurate docking and scoring. 1. Method and assessment of docking accuracy. *J Med Chem.* 2004;47(7):1739–1749. doi: [10.1021/jm0306430](https://doi.org/10.1021/jm0306430)
52. Aldahdooh J, Vähä-Koskela M, Tang J, et al. Using BERT to identify drug-target interactions from whole PubMed. *BMC Bioinformatics.* 2022;23(1):1–13. doi: [10.1186/s12859-022-04768-x](https://doi.org/10.1186/s12859-022-04768-x)
53. Aldahdooh J, Tanoli Z, Tang J, et al. Mining drug–target interactions from biomedical literature using chemical and gene descriptions-based ensemble transformer model. *Bioinf Adv.* 2024;4(1):vbae106. doi: [10.1093/bioadv/vbae106](https://doi.org/10.1093/bioadv/vbae106)
54. Devlin J, Chang M-W, Lee K, et al. Bert: pre-training of deep bidirectional transformers for language understanding. *arXiv Prepr arXiv: 1810.04805.* 2018.
55. Beltagy I, Lo K, Cohan A. Scibert: a pretrained language model for scientific text. *arXiv Prepr arXiv: 1903.10676.* 2019.
56. Lee J, Yoon W, Kim S, et al. BioBERT: a pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics.* 2020;36(4):1234–1240. doi: [10.1093/bioinformatics/btz682](https://doi.org/10.1093/bioinformatics/btz682)
57. Liu Y, Ott M, Goyal N, et al. Roberta: a robustly optimized BERT pretraining approach. *arXiv Prepr arXiv: 1907.11692.* 2019.
58. Peng Y, Yan S, Lu Z. Transfer learning in biomedical natural language processing: an evaluation of BERT and ELMo on Ten benchmarking datasets. *arXiv Prepr arXiv: 1906.05474.* 2019.
59. Gurvich R, Markel G, Tanoli Z, et al. Peptriever: a Bi-encoder approach for large-scale protein–peptide binding search. *Bioinformatics.* 2024;40(5):btac303. doi: [10.1093/bioinformatics/btae303](https://doi.org/10.1093/bioinformatics/btae303)
60. Oniani D, Hilsman J, Zang C, et al. Emerging opportunities of using large language models for translation between drug molecules and indications. *Sci Rep.* 2024;14(1):10738. doi: [10.1038/s41598-024-61124-0](https://doi.org/10.1038/s41598-024-61124-0)
61. Zhavoronkov A, Ivanenkov YA, Aliper A, et al. Deep learning enables rapid identification of potent DDR1 kinase inhibitors. *Nat Biotechnol.* 2019;37(9):1038–1040. doi: [10.1038/s41587-019-0224-x](https://doi.org/10.1038/s41587-019-0224-x)
62. Wang C, Long Q, Meng X, et al. BioRAG: a RAG-LLM framework for biological question reasoning. *arXiv Prepr arXiv: 2408.01107.* 2024.
63. Cichonska A, Ravikumar B, Parri E, et al. Computational-experimental approach to drug-target interaction mapping: a case study on kinase inhibitors. *PLoS Comput Biol.* 2017;13(8):e1005678. doi: [10.1371/journal.pcbi.1005678](https://doi.org/10.1371/journal.pcbi.1005678)
64. Halder AK, Cordeiro MNDS. Development of multi-target chemometric models for the inhibition of class I PI3K enzyme isoforms: a case study using QSAR-Co tool. *Int J Mol Sci.* 2019;20(17):4191. doi: [10.3390/ijms20174191](https://doi.org/10.3390/ijms20174191)
65. Tropsha A. Best practices for QSAR model development, validation, and exploitation. *Mol Inform.* 2010;29(6-7):476–488. doi: [10.1002/minf.201000061](https://doi.org/10.1002/minf.201000061)
66. Keiser MJ, Roth BL, Armbruster BN, et al. Relating protein pharmacology by ligand chemistry. *Nat Biotechnol.* 2007;25(2):197–206. doi: [10.1038/nbt1284](https://doi.org/10.1038/nbt1284)
- **Introduction of the similarity ensemble approach (SEA) to rapidly search large compound databases and to build cross-target similarity maps.**
67. Keiser MJ, Setola V, Irwin JJ, et al. Predicting new molecular targets for known drugs. *Nature.* 2009;462(7270):175–181. doi: [10.1038/nature08506](https://doi.org/10.1038/nature08506)
68. Ravikumar B, Timonen S, Alam Z, et al. Chemogenomic analysis of the druggable kinome and its application to repositioning and lead identification studies. *Cell Chem Biol.* 2019;26(11):1608–1622. doi: [10.1016/j.chembiol.2019.08.007](https://doi.org/10.1016/j.chembiol.2019.08.007)
69. Singh R, Sledzieski S, Bryson B, et al. Contrastive learning in protein language space predicts interactions between drugs and protein targets. *Proc Natl Acad Sci.* 2023;120(24):e2220778120. doi: [10.1073/pnas.2220778120](https://doi.org/10.1073/pnas.2220778120)
70. Han J, Liu T, Zhang X, et al. D3AI-Spike: a deep learning platform for predicting binding affinity between SARS-CoV-2 spike receptor binding domain with multiple amino acid mutations and human angiotensin-converting enzyme 2. *Comput Biol Med.* 2022;151:106212. doi: [10.1016/j.compbimed.2022.106212](https://doi.org/10.1016/j.compbimed.2022.106212)
71. Wang T, Pulkkinen OI, Aittokallio T. Target-specific compound selectivity for multi-target drug discovery and repurposing. *Front Pharmacol.* 2022;13:1003480. doi: [10.3389/fphar.2022.1003480](https://doi.org/10.3389/fphar.2022.1003480)
72. Mugumbate G, Abrahams KA, Cox JAG, et al. Mycobacterial dihydrofolate reductase inhibitors identified using chemogenomic methods and in vitro validation. *PLOS ONE.* 2015;10(3):e0121492. doi: [10.1371/journal.pone.0121492](https://doi.org/10.1371/journal.pone.0121492)



73. Peón A, Li H, Ghislat G, et al. MolTarPred: a web tool for comprehensive target prediction with reliability estimation. *Chem Biol Drug Des.* 2019;94(1):1390–1401. doi: [10.1111/cbdd.13516](https://doi.org/10.1111/cbdd.13516)
74. Arieu-Bonnet J, Carrasco K, Le Grand M, et al. In silico molecular target prediction unveils mebendazole as a potent MAPK14 inhibitor. *Mol Oncol.* 2020;14(12):3083–3099. doi: [10.1002/1878-0261.12810](https://doi.org/10.1002/1878-0261.12810)
75. Doğan T, Akhan Güzelcan E, Baumann M, et al. Protein domain-based prediction of drug/Compound–target interactions and experimental validation on LIM kinases. *PLoS Comput Biol.* 2021;17(11):e1009171. doi: [10.1371/journal.pcbi.1009171](https://doi.org/10.1371/journal.pcbi.1009171)
76. Rifaioğlu AS, Nalbat E, Atalay V, et al. Deepscreen: high performance drug–target interaction prediction with convolutional neural networks using 2-D structural compound representations. *Chem Sci.* 2020;11(9):2531–2557. doi: [10.1039/C9SC03414E](https://doi.org/10.1039/C9SC03414E)
77. Xiaolin X, Xiaozhi L, Guoping H, et al. Overfit deep neural network for predicting drug-target interactions. *iScience.* 2023;26(9):107646. doi: [10.1016/j.isci.2023.107646](https://doi.org/10.1016/j.isci.2023.107646)
78. Guo S, Tan Y, Huang Z, et al. Revealing calcium signaling pathway as novel mechanism of danhong injection for treating acute myocardial infarction by systems pharmacology and experiment validation. *Front Pharmacol.* 2022;13:839936. doi: [10.3389/fphar.2022.839936](https://doi.org/10.3389/fphar.2022.839936)
79. Zhao Y, Zheng K, Guan B, et al. DLDTI: a learning-based framework for drug-target interaction identification using neural networks and network representation. *J Transl Med.* 2020;18(1):1–15. doi: [10.1186/s12967-020-02602-7](https://doi.org/10.1186/s12967-020-02602-7)
80. Gilson MK, Liu T, Baitaluk M, et al. BindingDB in 2015: a public database for medicinal chemistry, computational chemistry and systems pharmacology. *Nucleic Acids Res.* 2016;44(D1):D1045–D1053. doi: [10.1093/nar/gkv1072](https://doi.org/10.1093/nar/gkv1072)
81. Monteiro NRC, Oliveira JL, Arrais JP. DTITR: end-to-end drug–target binding affinity prediction with transformers. *Comput Biol Med.* 2022;147:105772. doi: [10.1016/j.combiomed.2022.105772](https://doi.org/10.1016/j.combiomed.2022.105772)
82. Alvarsson J, McShane SA, Norinder U, et al. Predicting with confidence: using conformal prediction in drug discovery. *J Pharm Sci.* 2021;110(1):42–49. doi: [10.1016/j.xphs.2020.09.055](https://doi.org/10.1016/j.xphs.2020.09.055)
83. Orli D, Muc T, Martelli PL. Dynamic applicability domain (DAD): compound–target binding affinity estimates with local conformal prediction. *Bioinformatics.* 2023;39(8):btad465. doi: [10.1093/bioinformatics/btad465](https://doi.org/10.1093/bioinformatics/btad465)