

©2018 IEEE。个人使用本材料是被允许的。对于所有其他用途，包括在任何当前或未来的媒体中使用，如为广告或促销目的重印/再版本材料、创建新的汇编作品、转售或重新分发到服务器或列表，或在其他作品中重复使用本作品的任何受版权保护的部分，均须获得 IEEE 的许可。

利用锚图哈希和集成学习从异构空间预测药物靶点

Yi Zheng*, Hui Peng*, Xiaocai Zhang*, Xiaoying Gao†, and Jinyan Li*

*澳大利亚悉尼科技大学高级分析研究所, 悉尼 2007。

†新西兰惠灵顿维多利亚大学工程与计算机科学学院, 惠灵顿 6140。

电子邮件: Jinyan.Li@uts.edu.au (李金燕) 和 Yi.Zheng-8@student.uts.edu.au (郑毅)

摘要——潜在药物靶点相互作用的计算机预测在药物研究中至关重要。现有的计算方法在预测准确性方面取得了显著成果, 但通常由于计算问题导致预测效率低下。为了提高预测效率, 我们提出了一种基于异构特征整合、锚图哈希和集成学习的药物靶点预测方法。首先, 我们分别利用药物和靶点的异构特征将其编码为 5682 位和 4198 位的向量。然后, 利用锚图哈希将这些向量嵌入到低维汉明空间中。接下来, 将靶点的哈希位附加到药物的哈希位上, 形成一个向量来表示药物 - 靶点对。最后, 使用由已知药物 - 靶点对构成的正样本向量和随机选取的负样本向量来训练和评估集成学习模型。在来自 DrugBank 的 1094 种药物的模拟靶点预测中所提出方法的性能进行了评估。大量的对比实验表明, 所提出的方法能够实现较高的预测效率, 同时保持令人满意的准确度。实际上, 它比文献中表现最佳的“成对核方法”快 99.3 倍, 且 AUC 值仅低 0.001。

索引词 - 药物靶点预测; 异质特征; 锚图哈希; 集成学习。

I. 简介

药物与靶点之间相互作用的识别是药物研发中的关键环节。它有助于为已知靶点寻找新药, 或为现有药物发现新的靶点。尽管如今有多种生物学检测方法可用, 但药物与靶点相互作用的实验鉴定仍然具有挑战性[1]。为了指导并加快昂贵且费力的实验方法, 人们开发了多种计算机模拟预测方法[2]。这些方法可分为两类, 即对接模拟和机器学习。对接模拟是一种强大的方法, 但需要靶蛋白的三维结构信息[3]。此外, 它还耗时, 因为需要大量的计算资源[4]。因此, 很难将其大规模应用。相比之下, 机器学习在大规模预测方面更高效、更适用。

机器学习方法基于这样一个观察结果: 相似的药物往往与相似的靶点相互作用[2]。预测是基于诸如药物化学结构[5

[6]、药物副作用[7]、靶点蛋白质序列[8]以及已知的药物-靶点相互作用等信息来进行的。一种直接的方法是使用二元分类方法, 将药物-靶点对向量化作为二元分类器(例如人工神经网络(ANN)和支持向量机(SVM) [6][8][9][10])的输入。另一种有前景的方法称为二部图局部模型

(BLM), 它将药物和靶点视为二部图。BLM 对于每个待预测的药物-靶点相互作用, 从药物端和靶点端分别构建一个分类器。它能够实现显著的准确性, 但会导致严重的计算问题, 因为必须训练大量的分类器。目前使用机器学习预测药物-靶点相互作用的最先进方法是将药物相似性度量和靶点相似性度量嵌入到核函数中[6][8][11][12]。通过使用核函数, 可以整合多个信息源以实现较高的预测精度。然而, 一个严重的问题是训练集的规模为“训练药物的数量乘以训练靶点的数量”, 这在大规模应用中带来了计算上的困难。

如上所述, 现有的机器学习方法要么使用从药物 - 靶点对中提取的向量, 要么使用相似性矩阵作为预测的输入。输入向量和相似性矩阵的维度相当高, 这通常会导致严重的计算问题。为了解决这个问题, 我们引入了锚图哈希(AGH), 这是一种在速度和准确性方面都表现出色的哈希方法[13]。它可以将数据嵌入到汉明空间中, 使得原始数据空间中的邻域在汉明空间中仍然是邻域[14]。因此, AGH 是一种理想的降维技术。近年来, 集成学习在生物信息学中得到了广泛应用[15]。它结合了多个基础学习器的假设, 以形成更好的假设, 从而产生更好的预测性能。大量的应用已经证明了集成学习的成功[16][17][18]。

在这项工作中, 我们提出使用锚图哈希和集成学习(AGHEL)从异构空间预测药物 - 靶点相互作用。首先, 利用药物的异构特征(包括药物化学结构、药物副作用和药物取代基)将每种药物编码为一个向量。类似地, 利用每个靶点的特征将其编码为一个向量。

相关基因本体论 (GO)。接下来, 利用锚图哈希 (AGH) 将高维的药物和靶点向量压缩为哈密顿空间中的短向量 (即哈希位)。然后, 通过将压缩后的靶点向量附加到压缩后的药物向量上, 我们可以得到任意药物 - 靶点对的压缩向量。最后, 将药物 - 靶点对的压缩向量作为输入来训练和评估集成学习模型。我们采用随机森林 [19] 和 XGBoost [20] 作为集成学习模型的基础学习器。我们的创新之处在于将异质药物和靶点特征整合到统一框架中进行预测, 利用先进的锚图哈希技术降低向量维度, 并采用集成学习来提高预测性能。

II. 相关工作

已经开发出了大量的预测模型来预测药物与靶点的相互作用。我们讨论了三种典型的模型, 将其作为比较方法, 即最近邻 (NN) 算法、成对核方法 (PKM) 和二部图局部模型 (BLM)。

A. 最近邻

NN 通常被用作基准方法[8]。对于一个待测候选药物, NN 预测其会与已知与该药物最近邻药物相互作用的靶点相互作用。同样地, 对于一个待测候选靶点, NN 预测其会与已知与该靶点最近邻靶点相互作用的药物相互作用。然后, 每个相互作用都有两个预测结果/得分, 这些结果/得分将进一步结合以给出最终的预测。NN 简单且高效, 但性能相对较低。

B. 成对核方法

PKM 是一种典型的基于核函数的方法, 它将药物-靶点相互作用作为实例[4]。对于两个药物-靶点对 (d, t) 和 (d^0, t^0) , PKM 首先通过将药物相似度得分与靶点相似度得分相乘来计算它们之间的相似度, 具体计算方式如下:

$$s((d, t), (d', t')) = s_d(d, d') * s_t(t, t') \quad (1)$$

其中, s 、 s_d 和 s_t 分别是相互作用、药物和靶点的相似性函数, d 和 d^0 是药物, t 和 t^0 是靶点。然后, 它使用计算得出的药物-靶点对的相似性矩阵作为自定义核函数来训练支持向量机 (SVM) 分类器。最后, 训练好的 SVM 对测试药物-靶点对进行评分预测。通过使用核函数, PKM 能够整合多个信息源, 并实现较高的预测准确率。然而, 由于训练集的规模, 在大规模问题中会导致计算困难。例如, 在本研究中使用的 1094 种药物和 1556 个靶点, 核矩阵的大小将达到 $(1094*1556)*(1094*1556)$, 规模相当庞大。

C. 二分局部模型

BLM 将药物 - 靶点相互作用视为一个二部图, 其中顶点为药物和靶点, 边为它们之间的相互作用。每个药物 - 靶点相互作用分别从药物侧和靶点侧使用局部模型 (分类器) 进行预测。我们以药物 - 靶点对 (d, t) 的预测为例来说明这一过程。BLM 首先检查训练集中已知与药物 d 相互作用的每个靶点, 如果存在则标记为 “1”, 否则标记为 “0”; 接下来, 使用所有训练靶点的向量或它们的相似矩阵及其标签来训练一个局部模型。然后, 训练好的局部模型预测 t 的标签。类似地, BLM 使用训练集中的药物训练一个局部模型, 并获得 d 的标签。最后, 将 d 和 t 的两个预测分数结合起来给出最终预测。BLM 为每个药物 - 靶点对从药物侧和靶点侧分别构建一个分类器。它能够实现显著的准确性。然而, BLM 会导致严重的计算问题, 因为必须训练大量的分类器 (即待预测相互作用的两倍)。

III. 基于锚图哈希和集成学习的药物靶点预测

为了解决大规模药物靶点预测中的计算问题, 同时保持预测的准确性, 我们引入了两种先进的技术, 即锚图哈希和集成学习来进行预测。锚图哈希能够将高维数据嵌入到低维汉明空间中, 同时保持原始数据空间中的邻域关系在汉明空间中也保持邻域关系。这就是为什么我们采用它来降低原始药物向量和靶点向量的维度。集成学习在生物信息学的许多应用中都显示出了其优势。我们充分利用其优势来更好地捕捉数据特征, 并获得更好的性能。

A. 预测框架

我们的方法框架如图 1 所示。首先, 利用药物的化学子结构 (881 个)、副作用 (4063 个) 和取代基 (738 个) 将每种药物编码为 5682 位的向量, 其中每一位代表相应特征的存在或不存在, 用 1 或 0 表示。同样地, 利用基因本体论将每个靶点编码为 4198 位的向量。然后, 我们采用 AGH 将原始药物和靶点向量嵌入到低维汉明空间 (12/16/24/32/48/64 位)。接下来, 将所有已知的药物 - 靶点相互作用作为正样本, 并从未知相互作用中随机选取相同数量的负样本。之后, 将由药物哈希位和相应靶点哈希位拼接而成的样本向量作为输入, 用于训练和评估集成学习模型。该集成学习模型采用随机森林和 XGBoost 作为基础学习器, 并通过取平均值的方式给出最终的预测分数。最后, 通过 10 折交叉验证对预测结果的准确性和效率进行评估。




图 1.基于锚图哈希和集成学习的药物靶点预测框架。

B. 数据表示

我们收集了 1094 种药物和 1556 个靶点用于实验。每种药物通过其化学结构（881 个）、相关副作用（4063 个）和取代基（738 个）用一个 5682 维的二进制向量来表示。药物的化学结构由 PubMed [21] 中定义的 881 个化学亚结构表示。我们从 SIDER [22] 获得了 4063 个相关副作用，从 DrugBank [23] 获得了 738 个取代基。药物向量的元素通过 1 或 0 来编码每个特征（即化学亚结构/副作用/取代基）的存在与否。我们从 EMBL-EBI 网站 [24] 获得了 4198 个与靶点相关的独特 GO 术语。类似地，我们将每个靶点表示为一个 4198 维的二进制向量，其中每个元素通过 1 或 0 来编码每个 GO 术语的存在与否。

C. 锚图哈希

AGH 的目标是学习短二进制码，使得输入空间中的邻近点在汉明空间中也映射为邻近点 [14]。AGH 通过以下方式输入空间中的 n 个点寻求一个 r 位的汉明嵌入 $Y \in \{1, -1\}^{n \times r}$

最小化

$$\min_Y \frac{1}{2} \sum_{i,j=1}^n \|Y_i - Y_j\|^2 A_{ij} = \text{tr}(Y^T L Y) \quad (2)$$

s.t. $Y \in \{1, -1\}^{n \times r}, 1^T Y = 0, Y^T Y = n I_{r \times r}$

其中 Y_j 是 Y 的 j 行，代表点 x_j 的 r 位编码，而 A_{ij} 是数据对 (x_i, x_j) 的相似度。为了解决上述 NP 难问题，AGH 使用一个包含 m 个点的小子集（称为锚点）来近似数据邻域结构 [25]。具体来说，对所有 n 个点执行 K 均值聚类以获得 m ($m \ll n$) 个聚类中心（锚点） $U = \{u_j \in \mathbb{R}^d\}_m$ 。

首先令 $j=1_0$ 。接下来，AGH 进行计算。所有 n 个数据点与 m 个锚点之间的截断相似度矩阵如下：

$$Z_{ij} = \begin{cases} \frac{\exp(-D^2(x_i, u_j)/t)}{\sum_{j' \in \langle i \rangle} \exp(-D^2(x_i, u_{j'})/t)}, & \forall j \in \langle i \rangle \\ 0 & \text{otherwise} \end{cases} \quad (3)$$

其中， $\langle i \rangle$ 表示根据距离函数 $D(\cdot)$ 在集合 $\{u_j\}$ 中与点 x_i 最近的 s 个锚点的索引， t 为带宽参数。然后，邻接矩阵 A 可近似表示为 $A \approx Z V^{-1}$ ，其中 $V = \text{diag}\{Z^{(1)}\}$ 。[25]. 矩阵 A 的特征向量可以利用其低秩特性可以轻松计算得出。特别是，AGH 求解了一个小的 $m \times m$ 矩阵 $M = V^{(-1/2)} Z V^{(-1/2)}$ 的特征值系统。这会产生 r 个特征向量 - 特征值对 $\{(p_k, \sigma_k)\}_{k=1}^r$ ，其中 $0 < \sigma_1 \leq \dots \leq \sigma_r < 1$ 。最后，AGH 得到了所需的谱嵌入矩阵。

作为

$$Y = \sqrt{n} Z V^{-1/2} P \sum^{-1/2} \quad (4)$$

其中 $P = [p_1, \dots, p_r] \in \mathbb{R}^m \times \mathbb{R}$ 且 $P = \text{diag}(\sigma_1, \dots, \sigma_r) \in \mathbb{R}^r \times \mathbb{R}$ 。

利用 AGH，高维输入向量被压缩为低维哈希位，其中输入空间中的邻域在输出空间中仍保持邻域关系。

D. 样本选择

所有已知的药物 - 靶点对都被用作正样本，并被赋予标签“1”。从未知的药物 - 靶点对中随机选取相同数量的负样本，并赋予标签“0”。为避免偏差，负样本选取过程重复 5 次，取平均结果用于评估。在获得正样本和负样本后，我们将它们表示为向量，方法是将相应的靶点哈希位附加到药物哈希位上。然后将这些向量用作集成学习模型的输入。

E. 集成学习

我们选择随机森林和 XGBoost 作为集成学习模型的基础学习器，因为它们在低维数据上表现良好。我们只是将它们的预测得分取平均值作为最终的预测得分。

F. 10 折交叉验证

性能评估采用 10 折交叉验证：（1）将金标准中的样本大致平均分成 10 个子集；（2）依次将每个子集作为测试集，其余子集作为训练集；（3）将 10 折验证的所有结果用于评估。我们随机选取与阳性样本（已知的药物 - 靶点相互作用）数量相同的阴性样本。为避免偏差，我们分别重复样本选择过程和交叉验证 5 次，这意味着每种方法将运行 25（5×5）次，最终评估采用平均结果。我们采用受试者工作特征曲线（ROC）、ROC 曲线下面积（AUC）以及执行时间作为评估指标来评估预测性能。

IV. 结果

A. 数据资源

由于药物与靶点的相互作用会随着时间的不断被发现，我们没有采用现有文献中的旧数据，而是自行从知名数据库中收集了数据集。具体来说，药物是从综合药物数据库 Drug-Bank [23] 中收集的，靶点则来自 DrugBank 和 DrugCentral [26]。表 I 和图 2 展示了我们数据集（数据集 AGHEL）的详细信息。为了进行对比，我们还列出了 PKM（数据集 PKM）和 BLM（数据集 BLM）所使用的数据集。从表 I 可以看出，我们的数据集包含更多的靶点和已知相互作用。




图 2. 靶点及其相关药物的特征。左图是靶点相关药物数量的直方图，右图是每个靶点相关药物数量的索引图。

表 I
本研究中使用的数据集以及两篇已发表文献中使用的数据集。

数据集	药物数量	目标数量	互动次数
AGHEL 数据集	1094	1556	11,819
数据集 BLM	932	989	5127
数据集 PKM	1205	889	2782

B. 参数优化

锚图哈希的关键参数是其层数和输出哈希位数[14]。因此，我们进行了实验以找出哈希层和输出哈希位的最佳设置。具体来说，我们首先使用 K 均值算法对所有原始药物（靶点）向量进行聚类，得到 100 个聚类中心作为它们的锚点。然后，我们使用不同层数的锚图哈希（AGH）和药物（靶点）的锚点获取 r 位（ $r \in \{12, 16, 24, 32, 48, 64\}$ ）的哈希位。最后，将从相同层数和位数获得的药物哈希位和靶点哈希位组合成向量用于预测和评估。实验结果如图 3 所示。很明显，对于 1 层 AGH 和 2 层 AGH，AUC 值均随哈希位数的增加而增加。此外，在相同的位数下，1 层 AGH 的性能优于 2 层 AGH。基于上述观察，在接下来的实验中，我们将 AGHEL 的 AGH 层设置为 1，输出哈希位数设置为 64。

C. 比较结果

为了展示我们方法的优势，我们在预测准确性和预测效率方面将 AGHEL 与三种现有的不同类型的预测方法进行了比较。这三种对比方法，即 NN、PKM 和 BLM 的详细信息在“相关工作”部分有详细介绍。所有方法均在配备双英特尔至强 3.4GHz 处理器（14 核）和 256GB 内存的 Linux 工作站上运行。

图 4 展示了这四种方法的平均执行时间。我们可以看到，AGHEL 是最快的，在 9.99 秒内完成了 23,638 个药物 - 靶点相互作用的预测（其中哈希压缩耗时 0.53 秒，预测耗时 9.46 秒）。其速度是其他方法的 4.62 倍。




图 3. 不同 AGH 设置下 AGHEL 的 AUC (ROC 分数)。x 轴表示输出哈希位数, y 轴表示 AUC 分数。




图 4. 使用 10 折交叉验证的四种方法的平均执行时间 (秒)。

AGHEL 比第二快的方法 NN 快 5181.44 倍, 比最慢的方法 BLM 快 518144 倍。在现有的三种对比方法中, NN 是最快的, 这得益于其简单的预测原理, 即对于药物 (靶点), 预测其相互作用的目标 (药物) 与与其最近的药物 (靶点) 相同。BLM 是最慢的, 因为对于每一种相互作用都需要训练两个分类器, 这意味着要预测全部 23638 种相互作用, 需要训练 47276 个分类器。相比之下, PKM 比 BLM 更高效, 因为它只需要训练一个分类器。然而, 由于核矩阵的规模较大 (23638×23638), 其速度仍远低于 NN 和 AGHEL。AGHEL 同样只需训练一个分类器来进行所有预测。不过, 与输入向量维度为 23638 的 PKM 相比, AGHEL 通过其 AGH 组件将输入向量维度从 9880 ($5682+4198$) 大幅降低至 128 ($64+64$), 从而大大缩短了预测时间 (0.53 秒)。这解

释了为什么 AGHEL 的执行时间最短。




图 5. 来自 10 折交叉验证实验的四种方法的 ROC 曲线。

为了绘制 ROC 曲线, 我们将每种方法的 25 次重复实验的所有预测得分合并, 并绘制了一条 ROC 曲线。图 5 展示了所得到的 ROC 曲线。从中可以看出, PKM (蓝色) 表现最佳。在一篇关于药物靶点预测的机器学习方法综述中, 它已被证明是最强大的方法[4]。所提出的方法 (红色) AGHEL 表现次优。为了更清晰地展示这四种方法之间的差异, 我们通过计算每种方法 25 次重复实验的 AUC 平均值来获得平均 AUC。平均 AUC 如图 6 所示。可以看出, AGHEL (0.893) 的 AUC 较为理想, 仅比 PKM (0.894) 低 0.001。紧随其后的是 BLM (0.879) 和 NN (0.836)。




图 6.10 折交叉验证实验中四种方法的 AUC 值。

V. 结论

在这项工作中, 我们提出了一种基于异构特征整合、锚图哈希和集成学习来预测药物靶点的方法。所提出方法的贡献在于将药物化学结构、药物副作用、药物取代基和靶点的 GO 术语整合到统一框架中进行预测, 创新性地使用了锚图哈希, 并采用了集成学习。据我们所知, 在药物靶点预测领域, 目前还没有任何工作将上述特征整合在一起。从实验结果来看, 所提出的方法, 即 AGHEL, 在执行时间和预测准确性方面都表现良好。与三种最先进的方法相比, 它是最快的, 并且准确率位居第二。由于引入了锚图哈希, 通过降低输入向量的维度, 预测过程大大加快。借助药物和靶点异构特征的整合以及集成学习的应用, AGHEL 实现了较高的预测准确性。

所提出的方法对于药物发现过程具有重要价值, 该过程旨在为现有药物确定新的作用靶点或为已知靶点寻找新的药物。它能够指导并加快药物与靶点相互作用的实验鉴定这一费时、昂贵且繁琐的过程[1]。在本研究中, 将药物化学结构、药物副作用、药物取代基以及靶点的 GO 术语整合起来以预测药物靶点。需要指出的是, 还可以整合更多的药物和靶点信息, 例如药物适应症和靶点序列。所提出方法的局限性在于其对所用药物和靶点特征的依赖, 而这些特征并非总是对所有药物都可获取且完整。因此, 开发能够利用容易获取的数据高效准确地预测药物靶点的方法将是我们的未来工作。

参考文献

- [1] S. J. Haggarty, K. M. Koeller, J. C. Wong, R. A. Butcher, and S. L. Schreiber, "Multidimensional chemical genetic analysis of diversity-oriented synthesis-derived deacetylase inhibitors using cell-based assays," *Chemistry & biology*, vol. 10, no. 5, pp. 383–396, 2003.
- [2] T. van Laarhoven, S. B. Nabuurs, and E. Marchiori, "Gaussian interaction profile kernels for predicting drug–target interaction," *Bioinformatics*, vol. 27, no. 21, pp. 3036–3043, 2011.
- [3] I. Halperin, B. Ma, H. Wolfson, and R. Nussinov, "Principles of docking: An overview of search algorithms and a guide to scoring functions," *Proteins: Structure, Function, and Bioinformatics*, vol. 47, no. 4, pp. 409–443, 2002.
- [4] H. Ding, I. Takigawa, H. Mamitsuka, and S. Zhu, "Similarity-based machine learning methods for predicting drug–target interactions: a brief review," *Briefings in Bioinformatics*, vol. 15, no. 5, pp. 734–747, 2013.
- [5] Y. C. Martin, J. L. Kofron, and L. M. Traphagen, "Do structurally similar molecules have similar biological activity?" *Journal of medicinal chemistry*, vol. 45, no. 19, pp. 4350–4358, 2002.
- [6] N. Nagamine and Y. Sakakibara, "Statistical prediction of protein–chemical interactions based on chemical structure and mass spectrometry data," *Bioinformatics*, vol. 23, no. 15, pp. 2004–2012, 2007.
- [7] M. Campillos, M. Kuhn, A.-C. Gavin, L. J. Jensen, and P. Bork, "Drug target identification using side-effect similarity," *Science*, vol. 321, no. 5886, pp. 263–266, 2008.
- [8] K. Bleakley and Y. Yamanishi, "Supervised prediction of drug–target interactions using bipartite local models," *Bioinformatics*, vol. 25, no. 18, pp. 2397–2403, 2009.
- [9] J. R. Bock and D. A. Gough, "Virtual screen for ligands of orphan G protein-coupled receptors," *Journal of chemical information and modeling*, vol. 45, no. 5, pp. 1402–1414, 2005.
- [10] J.-L. Faulon, M. Misra, S. Martin, K. Sale, and R. Sapra, "Genome scale enzyme–metabolite and drug–target interaction predictions using the signature molecular descriptor," *Bioinformatics*, vol. 24, no. 2, pp. 225–233, 2007.
- [11] L. Jacob and J.-P. Vert, "Protein-ligand interaction prediction: an improved chemogenomics approach," *Bioinformatics*, vol. 24, no. 19, pp. 2149–2156, 2008.
- [12] A. M. Wassermann, H. Geppert, and J. Bajorath, "Ligand prediction for orphan targets using support vector machines and various target-ligand kernels is dominated by nearest neighbor effects," *Journal of chemical information and modeling*, vol. 49, no. 10, pp. 2155–2167, 2009.
- [13] Y. Zheng, C. Sun, C. Zhu, X. Lan, X. Fu, and W. Han, "Lwcs: A large-scale web page classification system based on anchor graph hashing," in *2015 6th IEEE International Conference on Software Engineering and Service Science (ICSESS)*. IEEE, 2015, pp. 90–94.
- [14] W. Liu, J. Wang, S. Kumar, and S.-F. Chang, "Hashing with graphs," in *Proceedings of the 28th international conference on machine learning (ICML-11)*. Citeseer, 2011, pp. 1–8.
- [15] Z.-H. Zhou, "Ensemble learning," *Encyclopedia of bioinformatics*, pp. 411–416, 2015.
- [16] C. Wong, Y. Li, C. Lee, and C.-H. Huang, "Ensemble learning algorithms for classification of mtDNA into haplogroups," *Briefings in bioinformatics*, vol. 12, no. 1, pp. 1–9, 2010.
- [17] P. Yang, P. D. Yoo, J. Fernando, B. B. Zhou, Z. Zhang, and A. Y. Zomaya, "Sample subset optimization techniques for imbalanced and ensemble learning problems in bioinformatics applications," *IEEE transactions on cybernetics*, vol. 44, no. 3, pp. 445–455, 2014.
- [18] W. Zhang, Y. Niu, Y. Xiong, M. Zhao, R. Yu, and J. Liu, "Computational prediction of conformational B-cell epitopes from antigen primary structures by ensemble learning," *PloS one*, vol. 7, no. 8, p. e43575, 2012.
- [19] C. Tomasi, "Random forest classifiers," 2017.
- [20] T. Chen and C. Guestrin, "Xgboost: A scalable tree

- boosting system,” in *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining*. ACM, 2016, pp. 785–794.
- [21] B. Chen, D. Wild, and R. Guha, “Pubchem as a source of polypharmacology,” *Journal of chemical information and modeling*, vol. 49, no. 9, pp. 2044–2055, 2009.
- [22] M. Kuhn, I. Letunic, L. J. Jensen, and P. Bork, “The sider database of drugs and side effects,” *Nucleic acids research*, p. gkv1075, 2015.
- [23] V. Law, C. Knox, Y. Djoumbou, T. Jewison, A. C. Guo, Y. Liu, A. Maciejewski, D. Arndt, M. Wilson, V. Neveu *et al.*, “Drugbank 4.0: shedding new light on drug metabolism,” *Nucleic acids research*, vol. 42, no. D1, pp. D1091–D1097, 2013.
- [24] G. O. Consortium, “The gene ontology (go) database and informatics resource,” *Nucleic acids research*, vol. 32, no. suppl 1, pp. D258–D261, 2004.
- [25] W. Liu, J. He, and S.-F. Chang, “Large graph construction for scalable semi-supervised learning,” in *Proceedings of the 27th international conference on machine learning (ICML-10)*, 2010, pp. 679–686.
- [26] O. Ursu, J. Holmes, J. Knockel, C. G. Bologa, J. J. Yang, S. L. Mathias, S. J. Nelson, and T. I. Oprea, “Drugcentral: online drug compendium,” *Nucleic acids research*, vol. 45, no. D1, pp. D932–D939, 2017.