

从化学和基因组空间的整合预测药物 - 靶点相互作用网络

Yoshihiro Yamanishi ^{1,*}, Michihiro Araki ², Alex Gutteridge ¹, Wataru Honda ¹ and Minoru Kanehisa ^{1,2}

1. 京都大学化学研究所生物信息学中心, 京都府宇治市御冠所 611-001

日本东京大学医学科学研究所人类基因组中心, 东京都港区白金台 4-6-1, 邮编 108-8639, 日本

摘要

动机: 药物与靶蛋白之间相互作用的识别是基因组药物发现中的关键领域。因此, 开发能够高效检测这些潜在药物 - 靶点相互作用的新方法具有很强的激励性。

结果: 在本文中, 我们对人类中涉及酶、离子通道、G 蛋白偶联受体 (GPCR) 和核受体的四类药物 - 靶点相互作用网络进行了表征, 并揭示了药物结构相似性、靶点序列相似性与药物 - 靶点相互作用网络拓扑结构之间存在显著的相关性。随后, 我们开发了新的统计方法, 能够同时从化学结构和基因组序列信息出发, 在大规模范围内预测未知的药物 - 靶点相互作用网络。所提出方法的创新之处在于将药物 - 靶点相互作用推断形式化为一个二部图的监督学习问题, 无需靶点蛋白质的三维结构信息, 并将化学空间和基因组空间整合到一个我们称之为“药理学空间”的统一空间中。在结果中, 我们展示了所提出方法在预测这四类药物 - 靶点相互作用网络方面的有效性。我们全面预测的药物 - 靶点相互作用网络使我们能够提出许多潜在的药物 - 靶点相互作用, 并提高基因组药物发现的研究效率。

供货情况: 软件需按需提供。

联系人: Yoshihiro.Yamanishi@ensmp.fr

补充信息: 数据集和所有预测结果均可在 <http://web.kuicr.kyoto-u.ac.jp/supp/yoshi/drugtarget/> 获取。

1 简介

药物与靶蛋白之间相互作用的识别是基因组药物发现中的关键领域。与配体的相互作用可以调节许多类药物有用蛋白质靶点的功能, 包括酶、离子通道、G 蛋白偶联受体 (GPCR) 和核受体。通过各种高通量实验项目来分析基因组、转录组和蛋白质组, 我们开始了解这些蛋白质类别的基因组空间。与此同时, 通过各种生物测定法对大规模化学化合物库进行高通量筛选, 使我们能够探索可能化合物的化学空间 (多布森,

化学基因组学研究的目的是将化学空间与基因组空间联系起来, 以识别出诸如成像探针和药物先导化合物等潜在有用化合物。然而, 我们对于化学空间与基因组空间之间关系的了解非常有限。例如, 美国国家生物技术信息中心 (NCBI) 的 PubChem 数据库 (Wheeler 等人, 2006 年) 存储了数百万种化学物质的信息, 但其中具有靶蛋白信息的化合物数量却非常少。这表明化学空间与基因组空间之间存在许多潜在的相互作用尚未被发现。因此, 开发能够高效检测这些潜在药物靶点相互作用的新方法具有很强的激励作用。

由于化合物与蛋白质相互作用或潜在药物靶点相互作用的实验测定仍然极具挑战性 (Haggarty 等人, 2003 年; Kuruvilla 等人, 2002 年), 因此需要开发有效的计算机模拟预测方法。预测的相互作用可以为实验研究提供补充和支持性证据。已经开发出了多种计算方法来分析和预测化合物与蛋白质的相互作用。其中最常用的两种是对接模拟 (Cheng 等人, 2007 年; Rarey 等人, 1996 年) 和文献文本挖掘 (Zhu 等人, 2005 年)。然而, 这两种技术都有其局限性, 例如对接模拟无法应用于三维结构未知的蛋白质, 因此难以大规模应用。文本挖掘方法通常基于关键词搜索, 因此无法检测新的生物学发现, 还存在文献中化合物/基因名称冗余的问题 (Zhu 等人, 2005 年)。

最近, 有人根据靶蛋白配体的结构对其进行了分类 (Keiser 等人, 2007 年), 在相关研究中, 对药物 - 靶点网络进行了分析, 揭示了其网络拓扑结构的特征 (Yildirim 等人, 2007 年)。然而, 在网络分析中, 既未考虑蛋白质序列信息, 也未考虑化学结构信息。下一步是开发更综合的方法, 同时考虑靶蛋白序列、药物化学结构以及现有的已知药物 - 靶点网络信息。

在本文中, 我们探究了药物化学结构、靶蛋白序列以及药物 - 靶点网络拓扑结构之间的关系。随后, 我们开发了一种新的有监督方法, 通过将化学空间和基因组空间整合到一个我们称之为“药理学空间”的统一空间中, 来推断未知的药物 - 靶点相互作用。在所提出的方法中, 化学空间指的是可能化合物的化学结构相似性空间, 基因组空间指的是可能的氨基酸序列相似性空间。

* To whom correspondence should be addressed.

† Present address: Centre for Computational Biology, Ecole des Mines de Paris, 35 rue Saint Honore, 77305 Fontainebleau Cedex, France.




图 1.所提方法的示例。

蛋白质和药物作用空间指的是反映药物 - 靶点相互作用网络的相互作用空间，在此空间中相互作用的药物和靶点蛋白彼此靠近。我们所说的“有监督”是指在推理过程中使用关于已知相互作用的可靠先验知识。图 1 展示了我们方法的示意图。据我们所知，目前还没有计算方法能够同时大规模地从化学结构数据、基因组序列数据和已知药物 - 靶点网络信息的整合中预测药物 - 靶点相互作用。在结果中，我们对人类中涉及酶、离子通道、G 蛋白偶联受体和核受体的四类重要药物 - 靶点相互作用进行了预测。对药物 - 靶点相互作用网络的全面预测使我们能够提出新的潜在药物 - 靶点相互作用。

2 材料

2.1 药物-靶点相互作用数据

我们从 KEGG BRITE (Kanehisa 等人, 2006 年), BRENDA (Schomburg 等人, 2004 年)、SuperTarget (Gunther 等人, 2008 年) 和 DrugBank 数据库 (Wishart 等人, 2008 年) 中获取了药物与靶蛋白相互作用的信息。据我们调查, 已知作用于酶、离子通道、G 蛋白偶联受体 (GPCR) 和核受体的药物数量分别为 445 种、210 种、223 种和 54 种。在撰写本文时, 这些类别中的靶蛋白数量分别为 664 种、204 种、95 种和 26 种, 已知相互作用的数量分别为 2926 个、1476 个、635 个和 90 个。请注意, 在酶类中, 我们关注的是酶与化合物之间的调节性相互作用, 而非代谢性相互作用, 因此酶数据中的所有配体均为抑制剂或激活剂, 而非底物或产物。除了在 BRENDA 数据库中被注释为调节剂的情况外, 辅因子如三磷酸腺苷 (ATP) 和烟酰胺腺嘌呤二核苷酸磷酸 (NADPH) 也不包括在内。此外, 我们不使用分子量小于 100 的化合物, 这意味着离子已从数据集中移除。药物和靶蛋白及其相互作用的数据统计汇总于表 1 中。

已知的药物 - 靶点相互作用集在本研究中被视为“金标准”数据, 用于交叉验证实验中评估所提出方法的性能, 以及在综合预测中作为训练数据。

表 1. 药物-靶点相互作用网络的统计数据

统计学	酶	离子通道	GPCR	核受体
否。毒品的	445	210	223	54
否。目标蛋白质的总数 (人类基因组中)	664 (274 1)	204 (2 92)	95 (75 7)	26 (4 9)
否。药物与靶点相互作用的	2926	1476	635	90
平均药物浓度	6.57	7.02	2.84	1.66
目标的平均度数	4.40	7.23	6.68	3.46
药物聚类系数	0.850	0.871	0.867	0.832
目标聚类系数	0.902	0.897	0.776	0.933
药物之间不可达路径的比例	0.479	0.019	0.345	0.615
目标之间不可达路径的比例	0.447	0.029	0.593	0.778

表 1 展示了金标准数据中靶蛋白、药物及其相互作用的数量。

2.2 化学数据

药物的化学结构从 KEGG LIGAND 数据库 (Kanehisa 等人, 2006 年) 的 DRUG 和 COMPOUND 部分获取。我们使用 SIMCOMP (Hattori 等人, 2003 年) 计算化合物之间的化学结构相似度, SIMCOMP 通过图对齐算法基于两个化合物之间共同子结构的大小提供一个全局相似度得分。化合物 c 和 c' 之间的相似度计算为 $s_c(c, c') = |c \cap c'| / |c \cup c'|$ 。对所有化合物对应应用此操作, 我们构建一个表示为 S_c 的相似度矩阵。相似度矩阵 S_c 被认为代表化学空间。

2.3 基因组数据

目标蛋白质的氨基酸序列来自 KEGG GENES 数据库 (Kanehisa 等人, 2006 年)。本研究重点关注人类蛋白质。我们计算了这些蛋白质之间的序列相似性。

使用归一化的史密斯-沃特曼得分 (Smith 和 Waterman, 1981 年) 版本。计算两个蛋白质 g 和 g' 之间的归一化史密斯-沃特曼得分由于 $sg(g, g') = SW(g, g') / [SW(g, g)SW(g', g')]$ ，其中 $SW(\cdot, \cdot)$ 表示原始的史密斯-沃特曼得分。对所有蛋白质应用此操作，我们构建一个相似性矩阵，记为 S_g 。在本研究中，相似性矩阵 S_g 被认为代表基因组空间。

3 方法

所提出的监督方法是一个两步过程。首先，学习一个模型来解释“黄金标准”。其次，将此模型应用于“黄金标准”中未涉及的化合物和蛋白质，以推断它们之间的相互作用。在这种情况下，监督学习方法是合适的，因为最近许多公共数据库中都有可靠的药物-靶点相互作用的信息。已知药物-靶点相互作用所涉及的化合物和蛋白质的集合被称为训练集。我们首先提出两种“简单”的方法：最近邻谱方法和加权谱方法，最后我们提出了一种更复杂的方法：二部图学习方法。

在每种情况下，假设我们有已知药物的集合 $\{c_i\}_{i=1}^{n_c}$ 和已知靶蛋白的集合 $\{g_j\}_{j=1}^{n_g}$ ，其中 n_c 表示已知药物的数量，而 n_g 表示

已知目标蛋白质的数量。此外， c_i 与目标蛋白质的相互作用模式以及 g_j 与药物的相互作用模式分别由我们称为相互作用概况 $\mathbf{x}_{c_i}$ 和 $\mathbf{y}_{g_j}$ 的位串表示。相互作用概况 $\mathbf{x}_{c_i}$ 被定义为一个位串（大小为 n_g 的向量），其中与目标蛋白质 g_j ($j = 1, 2, \dots, n_g$) 存在或不存在相互作用分别编码为 1 或 0。相互作用概况 $\mathbf{y}_{g_j}$ 被定义为一个位串（大小为 n_c 的向量），其中与药物 c_i ($i = 1, 2, \dots, n_c$) 存在或不存在相互作用分别编码为 1 或 0。假设我们有相互作用概况的集合 $\{\mathbf{x}_{c_i}\}_{i=1}^{n_c}$ 和 $\{\mathbf{y}_{g_j}\}_{j=1}^{n_g}$

请提供需要翻译的原文。给定一个新的目标候选人

对于新的蛋白质 g_{new} 和新的候选药物化合物 c_{new} ，我们想要分别预测其相应的相互作用概况 $\mathbf{x}_{c_{new}}$ 和 $\mathbf{y}_{g_{new}}$ 。

3.1 最近邻点法

一种直接的方法是采用最近邻方法的理念。在这种方法中，我们预测新化合物 c_{new} 具有以下相互作用概况：

$$\mathbf{x}_{c_{new}} = s_c(c_{new}, c_{nearest}) \mathbf{x}_{c_{nearest}}, \quad (1)$$

其中 $\mathbf{x}_{c_{new}}$ 是一个相互作用特征向量， $s_c(\cdot, \cdot)$ 是化学相似性得分， $c_{nearest}$ 是与 c_{new} 最相似的化合物。我们预测新蛋白质 g_{new} 具有以下相互作用特征：

$$\mathbf{y}_{g_{new}} = s_g(g_{new}, g_{nearest}) \mathbf{y}_{g_{nearest}}, \quad (2)$$

其中 $\mathbf{y}_{g_{new}}$ 是一个相互作用特征向量， $s_g(\cdot, \cdot)$ 是序列相似性得分， $g_{nearest}$ 是与 g_{new} 最相似的蛋白质。最后，在相互作用特征向量 $\mathbf{x}_{c_{new}}$ 和 $\mathbf{y}_{g_{new}}$ 中得分高的化合物-蛋白质对 (c_{new}, g_j) 和 (c_i, g_{new}) 被预测会相互作用。在本研究中，该方法被称为最近特征向量法。

3.2 加权概况法

我们考虑上述方法的一个更广义的版本。在此方法中，我们预测新化合物 c_{new} 具有以下加权相互作用特征：

$$\mathbf{x}_{c_{new}} = \frac{1}{z_{c_{new}}} \sum_{i=1}^{n_c} s_c(c_{new}, c_i) \mathbf{x}_{c_i}, \quad (3)$$

其中 $\mathbf{x}_{c_{new}}$ 是一个交互特征向量， $s_c(\cdot, \cdot)$ 是一个化学结构相似性得分，而 $z_{c_{new}}$ 是一个归一化项，定义为

$z_{c_{new}} = \sum_{i=1}^{n_c} s_c(c_{new}, c_i)$ 。我们预测新蛋白质 g_{new} 将具有以下加权相互作用概况：

$$\mathbf{y}_{g_{new}} = \frac{1}{z_{g_{new}}} \sum_{j=1}^{n_g} s_g(g_{new}, g_j) \mathbf{y}_{g_j}, \quad (4)$$

其中 $\mathbf{y}_{g_{new}}$ 是交互配置文件向量， $s_g(\cdot, \cdot)$ 是一个序列相似性得分和 $z_{g_{new}}$ 是一个归一化项，定义为 $z_{g_{new}} = \sum_{j=1}^{n_g} s_g(g_{new}, g_j)$ 。最后，在相互作用概况 $\mathbf{x}_{c_{new}}$ 和 $\mathbf{y}_{g_{new}}$ 中得分高的复合蛋白对 (c_{new}, g_j) 和 (c_i, g_{new}) 被预测会相互作用。在本研究中，该方法被称为加权概况法。

3.3 二部图学习方法

本文所采用的新方法是二部图学习法。在此，我们提出一种新方法来自学习化学/基因组空间与相互作用空间之间的关联，我们将这种空间称为“药理学空间”。所提出的步骤如下：

- (1) 将相互作用网络中的化合物和蛋白质嵌入到我们称之为“药理空间”的统一空间中。
- (2) 学习化学/基因组空间与药理学空间之间的模型，并将任何化合物/蛋白质映射到药理学空间。
- (3) 通过在药理空间中连接距离小于阈值的化合物和蛋白质，预测相互作用的化合物-蛋白质对。

图 1 展示了上述过程的示意图。下面将对每一步骤的细节进行说明。

首先，药物-靶点相互作用网络由一个二部图 $G=(V_1, V_2, E)$ 描述，其中 V_1 是药物的集合， V_2 是靶点蛋白的集合， E 是相互作用的集合。我们提议通过一个欧几里得空间来表示二部图结构，使得化合物和蛋白质都由 q 维特征向量组 $\{\mathbf{u}_{c_i}\}$ 和 $\{\mathbf{u}_{g_j}\}$ 来表示。

图 1

分别地。为此，我们首先构建一个基于图的相似度矩阵 $K = K_{cc} K_{cg}$ ，其中 K_{cc} , K_{cg} 和 K_{gg} 的元素通过使用 K_{cg} 和 K_{gg} 计算得出。

高斯函数如下： $(K_{cc})_{ij} = \exp(-d_{c_i c_j}^2 / h^2)$ 对于 $i, j = 1, \dots, n_c$ ， $(K_{gg})_{ij} = \exp(-d_{g_i g_j}^2 / h^2)$ 对于 $i, j = 1, \dots, n_g$ 和 $(K_{cg})_{ij} = \exp(-d_{c_i g_j}^2 / h^2)$ 对于 $i = 1, \dots, n_c$ ， $j = 1, \dots, n_g$ ，其中 d 是二部图上所有对象（化合物和蛋白质）之间的最短距离，不可达对象对之间的距离视为无穷大， h 是宽度参数。请注意，所得矩阵 K 的大小为 $(n_c + n_g) \times (n_c + n_g)$ 。矩阵 K 不总是正定的，因此向 K 中添加适当的单位矩阵，以使矩阵 K 满足正定性。借鉴核主成分分析 (Scholkopf 等人, 1998 年) 的类似思想，我们对 K 进行特征值分解，即 $K = \frac{1}{2} U U^T$ ，其中矩阵 U 的对角元素为特征值，矩阵 U 的列向量为特征向量， $U = [u_1, \dots, u_{n_c}, u_{n_c+1}, \dots, u_{n_c+n_g}]^T$ 的行向量来表示所有药物和靶蛋白。由特征 u_c 和 u_g 张成的空间称为“药理学特征空间”。

其次，我们考虑一个模型，该模型表示化学/基因组空间与药理学特征空间之间的相关性。为此，我们建议应用核回归模型的一种变体 $f: X \times X \rightarrow \mathbb{R}^q$ ，具体如下：

$$\mathbf{u} = f(x, x_i) = \sum_{i=1}^n s(x, x_i) \mathbf{w}_i + \epsilon, \quad (5)$$

其中 x 是属于集合 X 的一个对象， n 是集合 X 的大小， f 是从相似空间到欧几里得空间的投影， $s(\cdot, \cdot)$ 是一个相似度评分函数， $\mathbf{w}_i$ 是权重向量，是噪声向量。可以通过找到使以下损失函数最小化的 $\mathbf{w}_i$ 来完成优化：

$$L = \|U U^T - S W W^T S^T\|_F^2, \quad (6)$$




图2 药物和靶蛋白的度分布。上方四个面板分别展示了针对酶、离子通道、G 蛋白偶联受体（GPCR）和核受体的药物的度的直方图。下方四个面板则分别展示了相应靶蛋白的度的直方图。

其中 S 是一个 $n \times n$ 的相似矩阵, $W = (w_1, \dots, w_n)^T$, 并且 $\|\cdot\|_F$ 是弗罗贝尼乌斯范数。在本研究中, 我们学习了两个模型: 分别用于化学空间与药理学特征空间之间相关性的模型 f_c 和用于基因组空间与药理学特征空间之间相关性的模型 f_g 。假设我们有一个新的化合物 c_{new} 和一个新的蛋白质 g_{new} 。应用模型 f_c , 我们将新的化合物 c_{new} 映射到

药物的药理特征空间作为

$$u_{c_{new}} = f_c(c_{new}, c_i) = \sum_{i=1}^{n_c} s_c(c_{new}, c_i) w_{c_i}, \quad (7)$$

其中 w_{c_i} 是权重向量, $s_c(\cdot, \cdot)$ 是化学结构相似性得分。应用模型 f_g , 我们将新蛋白质 g_{new} 映射到药理学特征空间中, 结果为

$$u_{g_{new}} = f_g(g_{new}, g_j) = \sum_{j=1}^{n_g} s_g(g_{new}, g_j) w_{g_j}, \quad (8)$$

其中 w_{g_j} 是权重向量, $s_g(\cdot, \cdot)$ 是序列相似性得分。

最后, 基于药物作用空间中的特征, 我们通过计算内积来计算三种化合物-蛋白质对的基于特征的相似度得分: (i) $\text{corr}(c_{new}, g_j) = u_{c_{new}} \cdot u_{g_j}$, (ii) $\text{corr}(c_i, g_{new}) = u_{c_i} \cdot u_{g_{new}}$ 以及 (iii) $\text{corr}(c_{new}, g_{new}) = u_{c_{new}} \cdot u_{g_{new}}$ 。基于特征的相似度得分用作衡量化合物和蛋白质在药物作用特征空间中接近程度的度量。然后, 预测得分高的化合物-蛋白质对相互作用。

4 结果

4.1 药物-靶点相互作用网络构建

在本研究中, 我们重点关注四种具有药物用途的药物-靶点类别之间的相互作用: 酶、离子通道、G 蛋白偶联受体（GPCR）和核受体。我们使用二部图表示法为每种蛋白质类别构建药物-靶点相互作用网络。在二部图中, 异质节点对应于药物或靶点蛋白, 边则对应于它们之间的相互作用。如果某种蛋白质是某种药物的已知靶点, 则在药物节点和靶点节点之间放置一条边。

图2展示了药物-目标相互作用网络中药物和靶蛋白的度分布情况。药物（相应蛋

白质）节点的度是指该药物所作用的靶点数量（相应地, 是作用于该蛋白质的药物数量）。在四个类别中, 离子通道及其对应的药物具有许多度数较大的节点, 与其他蛋白质类别相比, 情况尤为明显。

表1还展示了药物-药物、靶点-靶点和药物-靶点对的平均度、聚类系数以及不可达路径的比例。聚类系数的高值表明药物及其靶点在药物-靶点网络中往往密集聚集。我们观察到离子通道网络中不可达路径的比例往往小于其他蛋白质类别, 这意味着大多数化合物-蛋白质对在网络中是相互连接的。对网络的检查表明, 酶、G 蛋白偶联受体（GPCR）和核受体网络包含许多小的不相连的组件, 而离子通道网络往往形成一个巨大的连通组件。这也表明, 与离子通道相比, 酶、GPCR 和核受体与其配体的结合特异性更强。

4.2 与化学空间和基因组空间的关系

我们还研究了网络拓扑结构与化学和基因组空间之间的关系。

我们使用 SIMCOMP 得分来衡量化合物之间的化学结构相似性, 并使用归一化的 Smith-Waterman 得分来衡量靶蛋白之间的序列相似性。

图3展示了四种靶点类别中, 药物间化学结构相似度和靶点间序列相似度与药物-靶点相互作用网络中它们之间距离的分布情况。从图中我们可以观察到几个特征。首先, 药物间和靶点间的网络距离越大, 药物结构相似度和靶点序列相似度的变异性就越小。其次, 网络距离越大, 药物结构相似度和靶点序列相似度的平均值就越低。这些观察结果表明, 两个




图 3. 分别针对酶、离子通道、G 蛋白偶联受体和核受体，药物化学结构相似性与靶蛋白序列相似性相对于网络距离的箱线图。上部四个面板展示了药物间 SIMCOMP 得分相对于网络距离 ($d = 0, 2, 4, 6, \dots$) 的箱线图。下部四个面板展示了靶蛋白间归一化 Smith-Waterman 得分相对于网络距离 ($d = 0, 2, 4, 6, \dots$) 的箱线图。请注意，此处的距离指的是药物 - 靶点相互作用网络的二部图表示中对象（每种情况下的药物或靶蛋白）之间的最短路径。

具有高度结构相似性的化合物往往与相似的靶蛋白相互作用。同样，两个具有高度序列相似性的靶蛋白往往与相似的药物相互作用，因此在网络中彼此接近。这些观察结果表明，相互作用的伙伴、药物的结构相似性和靶蛋白的序列相似性之间存在很强的相关性。

4.3 所提方法的性能评估

我们对涉及酶、离子通道、G 蛋白偶联受体 (GPCR) 和核受体这四类药物 - 靶点相互作用的三种方法：“最近邻特征”、“加权特征”和“二部图学习”进行了测试。我们执行了以下 10 折交叉验证程序：将金标准集划分为 10 个大小大致相等的子集，然后依次将每个子集作为测试集，对剩余的九个子集进行训练。通过使用受试者工作特征曲线 (ROC; Gribskov 和 Robinson, 1996) 来评估性能，即基于各种阈值绘制真阳性与假阳性之间的关系图，其中真阳性是正确预测的相互作用，假阳性是预测的但不在金标准相互作用中的相互作用。在二部图学习方法中，我们在每个蛋白质类别中将参数 h 设置为 2，因为交叉验证实验表明 $h = 2$ 时预测准确率最佳。

图 4 展示了针对四种药物 - 靶点相互作用类别，二部图学习方法的 ROC 曲线。对于每种药物 - 靶点相互作用类别，根据化合物和/或蛋白质是否在初始训练集中，绘制了不同预测集的 ROC 曲线。训练集中的化合物和蛋白质称为“已知”，而不在训练集中的称为“新”。于是就有四种不同的类别：

(i) 新药物候选化合物与已知靶点蛋白质，(ii) 已知药物与新靶点候选蛋白质，(i)

ii) 新药物候选化合物与新靶点候选蛋白质，以及 (iv) 所有可能的预测（上述三部分的平均值），分别用红色、绿色、蓝色和黑色表示。二部图学习方法似乎能够获取足够的信息，在任何阈值下均能以较高的真阳性率和较低的假阳性率检测出所有四种类型的药物 - 靶点相互作用。在四种药物 - 靶点相互作用类别中，所提出的方法对酶和 GPCR 的预测能力最强，其次是离子通道和核受体。正如人们所料，对于既未在蛋白质训练集中也未在化合物训练集中的预测 (iii)，其准确性最差，但即便如此，仍有可能做出可靠的预测。

我们通过若干统计量对这些方法的性能进行了比较。表 2 展示了当选择预测分数的上百百分位数作为阈值时的 AUC (ROC 曲线下面积)、灵敏度、特异性和 PPV (阳性预测值)，因为在实际应用中高置信度的预测结果更受关注。所有方法的特异性都很高，但其他统计量则有所不同。二部图学习方法不仅 AUC 高，而且灵敏度和 PPV 也高，表现优于其他方法。最近邻谱型和加权谱型方法灵敏度低的一个解释是，它们无法预测新候选药物化合物与新候选靶蛋白之间的相互作用（前面提到的预测类别 (iii)），而二部图学习方法则可以做到这一点。这些结果突显了二部图学习方法的显著性能。

4.4 未知药物-靶点相互作用的综合预测

在确认了我们方法的有效性之后，我们对所有可能的相互作用进行了全面预测。




图 4. 二部图学习方法对四种药物-靶点相互作用类别（酶、离子通道、G 蛋白偶联受体和核受体）的受试者工作特征曲线。

表 2. 预测性能统计

数据	方法	曲线下面积	灵敏度	特异度	阳性预测值
酶	最近的个人资料	0.767	0.538	0.995	0.532
	加权配置文件	0.812	0.386	0.993	0.384
	二部图学习	0.904	0.574	0.995	0.570
离子	最近的个人资料	0.751	0.166	0.995	0.576
	加权剖面	0.811	0.239	0.998	0.826
	二部图学习	0.851	0.271	0.999	0.936
GPCR	最近的个人资料	0.729	0.156	0.994	0.474
	加权配置文件	0.739	0.146	0.994	0.444
	二部图学习	0.899	0.234	0.996	0.681
核的	最近的个人资料	0.710	0.073	0.993	0.440
	受体加权谱型	0.626	0.114	0.998	0.818
	二部图学习	0.843	0.148	0.999	0.954

AUC (ROC 分数) 是 ROC 曲线下的面积, 对于完美的推断其值归一化为 1, 对于随机推断其值归一化为 0.5。灵敏度定义为真阳性数 (TP) 除以 (真阳性数 + 假阴性数 (FN)), 特异性定义为真阴性数 (TN) 除以 (真阴性数 + 假阳性数 (FP)), 阳性预测值 (PPV) 定义为真阳性数 (TP) 除以 (真阳性数 + 假阳性数 (FP)), 这里 TP、FP、TN、FN 分别表示真阳性数、假阳性数、真阴性数和假阴性数。

针对所研究的四类靶蛋白（酶、离子通道、G 蛋白偶联受体和核受体）的化合物和蛋白质。在这些预测的推断过程中, 我们使用了金标准数据中所有已知的药物和靶蛋白作为训练数据, 并预测了所有在 KEGG GENES 中被注释为这四类成员的人类蛋白质与 KEGG LIGAND 中所有化合物之间的潜在相互作用。根据我们基于 KEGG 数据库的调查, 人类基因组中编码的酶、离子通道、G 蛋白偶联受体和核受体的数量至少分别为 2741、292、757 和 49 种, 而用于预测的化合物数量在每种情况下均为 15383 种。所有预测结果和高分辨率图形图片均可从网络补充材料中获取。由于篇幅限制, 以下重点介绍酶和 G 蛋白偶联受体的结果。

4.4.1 预测的酶相互作用网络 图 5 展示了酶数据预测网络的部分图谱, 其中显示了得分最高的前 100 个预测结果。表 3 列出了一些具有高相互作用得分的预测酶-化合物对的示例。酶数据集中得分最高的预测结果主要由涉及少数酶和化合物家族的相互作用构成。这些家族往往是那些酶具有特定功能的家族。




图 5. 预测的酶相互作用网络。蓝色、红色、浅蓝色和橙色节点分别表示已知药物、已知靶点、新预测化合物和新预测蛋白质。灰色和粉色边分别表示已知相互作用和得分最高的 100 个新预测相互作用。

表 3.酶数据中得分最高的预测化合物 - 蛋白质配对

等级	分数	对	注释
1	0.924	C06977 16 36	依那普利 血管紧张素 1 转换酶 1
2	0.857	D01441 244	甲磺酸伊马替尼（通用名） 与 fyn 相关的激酶 [EC:2.7.10.2]
3	0.857	D00160 56 4	ϵ -氨基己酸（JAN） 蛋白酶，丝氨酸，1（胰蛋白酶 1） [EC:3.4.21.4]
4	0.844	C11720 16 36	依那普利拉 血管紧张素 1 转换酶 1
5	0.833	D00160 71 7	ϵ -氨基己酸（JAN） α/β 1 型组织胺酶 [EC:3.4.21.59]
6	0.824	D00043 56 4	异丙威（美国药典） 蛋白酶，丝氨酸，1（胰蛋白酶 1） [EC:3.4.21.4]
7	0.81	D01605 75 9	美特克兰（JP15） 碳酸酐酶 I [EC:4.2.1.1]
8	0.81	D00043 71 7	异丙威（美国药典） α/β 1 型组织胺酶 [EC:3.4.21.59]
9	0.809	D00160 44 0387	ϵ -氨基己酸（JAN） 糜蛋白酶原 B2 [EC:3.4.21.1]
10	0.807	D01441 5753	甲磺酸伊马替尼（通用名） PTK6 蛋白酪氨酸激酶 6 [EC:2.7.10.2]

由于篇幅限制，所有的预测对都放在了补充网站上。

这些酶要么是可成药且研究广泛的，要么是最初的一种药物化合物已被开发出许多衍生物，从而为它们积累了大量的化合物结合信息。最常见的六种酶家族是血管紧张素转换酶（ACE）、酪氨酸激酶、胰蛋白酶相关的丝氨酸蛋白酶、碳酸酐酶、环氧化酶（COX）1/2 和拓扑异构酶。与这六种酶家族的相互作用占了前 50 个预测中的 49 个。有些预测是显而易见的，尤其是在数据集中有许多化学结构几乎相同的化合物的情况下，但也有一些有趣的案例出现。

环氧化酶（COX）是抗炎药物的常见作用靶点，因其在前列腺素合成及后续炎症反应中发挥着重要作用（Rainsford, 2007）。在 COX 的预测结果中，排名靠前的是一种已知的抗炎药物西洛芬（D03489），这表明预测结果令人鼓舞。另外还预测出两种可能与 COX 发生相互作用的物质，分别是 4-羟基苝萆酸（C03080）和 2,2-双（4-羟基苯基）丙酸（C13633），据我们所知，这两种物质此前均未被确认为 COX 抑制剂。

在前 50 项预测中多次出现的一种化合物是甲磺酸伊马替尼（D01441），这是一种用于治疗慢性粒细胞白血病和胃肠道肿瘤的酪氨酸激酶抑制剂。我们的多项顶级预测包括甲磺酸伊马替尼与其他多种相关酪氨酸激酶相互作用的情况。

包括蛋白酪氨酸激酶 6 (PTK6) 和 B 淋巴细胞酪氨酸激酶, 这两种激酶要么已被确认为癌基因, 要么是候选癌基因。

4.4.2 预测的 G 蛋白偶联受体相互作用网络 在预测的 G 蛋白偶联受体相互作用网络中, 存在一些与 G 蛋白偶联受体家族相关的网络组件, 例如肾上腺素能受体、嘌呤能受体、胆碱能受体、组胺受体和多巴胺受体。例如, β_2 肾上腺素能受体与金标准数据集中超过 30 种药物相互作用, 并且预测有超过 100 种配体与 β_2 肾上腺素能受体相互作用。阿片受体也已知与多种镇痛药相互作用, 并且预测有超过 30 种衍生物与阿片受体相互作用。发现我们方法预测的药物和化合物在化学结构上与金标准药物相似, 其中一些是已知的镇痛剂。

某些 GPCR 家族, 如肾上腺素能受体, 其成员 (α_1 、 α_2 和 β_2) 往往聚集在一起, 因为它们彼此之间具有共同的配体。在 α_2 肾上腺素能受体网络中, 预测的配体如噻胺 (D06125) 与所有受体节点 (α_2a 、 α_2b 和 α_2c) 相关联, 而像甲磺酸尼布替罗 (D05171) 这样的配体则更倾向于与 α_2a 肾上腺素能受体相关联。在多巴胺受体网络中, 许多配体更倾向于与多巴胺受体 D2 相关联, 而像盐酸奋乃静 (D04965) 这样的少量配体则在所有多巴胺受体 (D1、D2 和 D3) 中较为常见。多巴胺受体 D1 和 D2 之间的共同配体数量多于 D1 和 D3 之间的数量, 这可能反映了多巴胺受体家族之间的相似性。

5 讨论与结论

在本文中, 我们对人类中涉及酶、离子通道、G 蛋白偶联受体 (GPCR) 和核受体的四类药物-靶点相互作用网络进行了表征, 并揭示了药物结构相似性、靶点序列相似性和药物-靶点相互作用网络拓扑结构之间存在显著的相关性。随后, 我们开发了新的统计方法, 能够同时从化学结构信息和基因组序列信息出发, 在大规模范围内预测未知的药物-靶点相互作用网络。所提出方法的创新之处在于将药物-靶点相互作用推断形式化为一个二部图的监督学习问题, 无需靶点蛋白质的三维结构信息, 并将化学空间和基因组空间整合到一个我们称之为“药理学空间”的统一空间中。在结果中, 我们证明了所提出的方法对于预测这四类药物-靶点相互作用网络的有效性。

迄今为止, 针对候选药物化合物与候选靶蛋白之间相互作用的检测, 已有两个研究方向: 传统的药物发现方法和化学生物学方法。在传统的药物发现方法中, 我们试图为少数感兴趣的特定蛋白质寻找新的候选药物化合物 (或药物先导化合物)。另一方面, 在化学生物学方法中, 我们试图为少数感兴趣的特定化学化合物寻找新的候选靶蛋白。我们提出的方法兼具上述两种方法的优势, 能够同时发现新的候选靶蛋白和新的候选药物化合物。还应指出的是, 我们的方法能够预测先前未见的候选

靶蛋白与先前未见的候选药物化合物之间的相互作用, 这是包括最近邻谱和加权谱方法在内的其他方法所无法做到的。

一个关键的观察结果是, 结构相似度高的两种化合物往往与相似的靶蛋白相互作用, 因此在网络中距离较近。同样, 序列相似度高的两种蛋白质往往与相似的药物相互作用。然而, 也有一些例外情况, 这种趋势并不明显。例如, 在酶的情况下, 存在许多序列相似度低但与相似药物结合的靶蛋白。这反映在最近邻谱和加权谱方法常常无法预测正确的相互作用对, 因为它们直接基于序列和化学结构的相似性。相比之下, 我们的图学习方法能够纠正这种偏差, 这得益于基于部分已知的药物-靶点相互作用网络拓扑结构学习模型。这意味着基于特征的化合物-蛋白质得分与药理学特征空间中的网络距离成反比。

已经开发出了多种计算方法来分析药物与靶点或化合物与蛋白质之间的相互作用。[对接模拟是一种强大的方法 \(Cheng 等人, 2007 年; Rarey 等人, 1996 年\)](#), 但它需要靶蛋白的三维结构信息。大多数具有药用价值的靶蛋白是膜蛋白, 如离子通道和 G 蛋白偶联受体。确定膜蛋白的三维结构仍然相当困难, 这限制了对接模拟的应用。我们的方法不需要三维结构信息, 只需要化合物的化学结构信息和蛋白质的序列信息。因此, 我们的方法的一个优势在于它适合大规模筛选大量的候选药物化合物和靶蛋白。

与本研究相关的先前研究之一是基于配体结构对靶蛋白家族进行分类 ([Keiser 等人, 2007 年](#))。然而, 该研究未考虑序列信息, 且新发现的相互作用仅限于已知配体与不同蛋白家族之间的连接。与本研究最相关的是最近的一项工作, 即利用二部图表示法对包含不同蛋白类别的全球药物-靶点网络进行分析 ([Yildirim 等人, 2007 年](#)), 但作者并未讨论与蛋白序列信息或化学结构信息的关系。另一方面, 我们分别对四类药物-靶点相互作用网络进行了表征, 以研究每种蛋白类别的网络特征, 并揭示了靶点序列相似性、药物结构相似性与药物-靶点相互作用网络拓扑结构之间的显著相关性, 从而开发出预测未知药物-靶点相互作用的方法。

从技术角度来看, 通过采用为基因组序列和化学结构设计的更复杂的核相似性函数, 我们方法的性能可以得到提升 ([Scholkopf 等人, 2004 年](#))。将有关功能位点的信息纳入蛋白质相似性设计中是一个有趣的研究方向 ([Kratichwil 等人, 2005 年](#))。近来, 已开发出几种基于核的监督网络推断方法 ([Vert 和 Yamanishi, 2005 年; Yamanishi 等人, 2004 年](#)), 但它们仅限于同质分子 (例如蛋白质-蛋白质相互作用) 之间的相互作用, 且具有简单的图表示形式。在本研究中, 我们着手解决预测不同分子之间相互作用的问题。

通过将相互作用网络视为二部图来预测异质分子。据我们所知，在有监督的背景下，目前还没有用于预测二部图的统计方法。只要其他生物网络预测问题（如代谢网络重建和宿主 - 病原体蛋白质 - 蛋白质相互作用预测）能用二部图表示，我们的方法就可以应用于这些问题。

在本文的最后部分，我们预测了所有可能的目标候选蛋白与药物候选化合物之间的相互作用。我们全面预测的药物 - 靶点相互作用网络使我们能够提出许多潜在的药物 - 靶点相互作用。我们确认，通过我们的方法检测到的一些相互作用与文献中实验验证的结果相符。为了发现新的生物学发现和潜在有用的药物线索，我们目前正在与合作者进行结合试验。我们相信，我们的方法能够提高基因组药物发现的研究效率。

致谢

资助:本研究得到了日本文部科学省 21 世纪重点学科项目“基因组科学”、日本科学技术振兴机构生物信息学研究及开发研究所以及日本学术振兴会的支持。计算资源由京都大学化学研究所生物信息学中心、京都大学超级计算机实验室以及东京大学医学科学研究所人类基因组中心超级计算机系统提供。

利益冲突:无。

参考文献

Cheng, A.C. et al.(2007) Structure-based maximal affinity model predicts small-molecule druggability. *Nat. Biotechnol.*, **25**, 71–75.

- Dobson, C.M. (2004) Chemical space and biology. *Nature*, **432**, 824–828.
- Gribskov, M. and Robinson, N.L. (1996) Use of receiver operating characteristic (roc) analysis to evaluate sequence matching. *Comput. Chem.*, **20**, 25–33.
- Gunther, S. et al. (2008) Supertarget and matador: resources for exploring drug–target relationships. *Nucleic Acids Res.*, **36**, D919–D922.
- Haggarty, S.J. et al. (2003) Multidimensional chemical genetic analysis of diversity-oriented synthesis-derived deacetylase inhibitors using cell-based assays. *Chem. Biol.*, **10**, 383–396.
- Hattori, M. et al. (2003) Development of a chemical structure comparison method for integrated analysis of chemical and genomic information in the metabolic pathways. *J. Am. Chem. Soc.*, **125**, 11853–11865.
- Kanehisa, M. et al. (2006) From genomics to chemical genomics: new developments in kegg. *Nucleic Acids Res.*, **34** (Database issue), D354–D357.
- Keiser, M.J. et al. (2007) Relating protein pharmacology by ligand chemistry. *Nat. Biotechnol.*, **25**, 197–206.
- Kratochwil, N.A. et al. (2005) An automated system for the analysis of G protein-coupled receptor transmembrane binding pockets: alignment, receptor-based pharmacophores, and their application. *J. Chem. Inf. Model.*, **45**, 1324–1336.
- Kuruvilla, F.G. et al. (2002) Dissecting glucose signalling with diversity-oriented synthesis and small-molecule microarrays. *Nature*, **416**, 653–657.
- Rainsford, K.D. (2007) Anti-inflammatory drugs in the 21st century. *Subcell. Biochem.*, **42**, 3–27.
- Rarey, M. et al. (1996) A fast flexible docking method using an incremental construction algorithm. *J. Mol. Biol.*, **261**, 470–489.
- Schölkopf, B. et al. (1998) Nonlinear component analysis as a kernel eigenvalue problem. *Neural Comput.*, **10**, 1299–1319.
- Schölkopf, B. et al. (2004) *Kernel Methods in Computational Biology*. MIT Press, Cambridge, MA.
- Schomburg, I. et al. (2004) Brenda, the enzyme database: updates and major new developments. *Nucleic Acids Res.*, **32**, D431–D433.
- Smith, T.F. and Waterman, M. (1981) Identification of common molecular subsequences. *J. Mol. Biol.*, **147**, 195–197.
- Stockwell, B.R. (2000) Chemical genetics: ligand-based discovery of gene function. *Nat. Rev. Genet.*, **1**, 116–125.
- Vert, J.-P. and Yamanishi, Y. (2005) Supervised graph inference. *Adv. Neural Inf. Process. Syst.*, **17**, 1433–1440.
- Wheeler, D.L. et al. (2006) Database resources of the national center for biotechnology information. *Nucleic Acids Res.*, **34**, D173–D180.
- Wishart, D.S. et al. (2008) Drugbank: a knowledgebase for drugs, drug actions and drug targets. *Nucleic Acids Res.*, **36**, D901–D906.
- Yamanishi, Y. et al. (2004) Protein network inference from multiple genomic data: a supervised approach. *Bioinformatics*, **20** (Suppl 1), i363–i370.
- Yildirim, M.A. et al. (2007) Drug–target network. *Nat. Biotechnol.*, **25**, 1119–1126.
- Zhu, S. et al. (2005) A probabilistic model for mining implicit ‘chemical compound gene’ relations from literature. *Bioinformatics*, **21** (Suppl 2), ii245–ii251.