

由当前研究现状->研究方向

1.数据集

- 1)Transformer CPI

在进行相互作用二分类预测时，使用了亲和力数据集GLASS及KIBA, 为了获取二分类标签,对亲和力数值基于阈值进行正负样本采样
- 2)MGraphDTA

两个广泛使用的二分类数据集Human及C.elegans被使用
- 3)MlanDTI

二分类数据集Human,C.elegans.bindingdb,Biosnap被使用,其中, Biosnap中的负样本是随机采样的未见过的药物-蛋白质对
- 4)PSI-CPI

使用亲和力数据集Karimi,Davis,KIBA及Mert。其中, 由于Karimi数据集对应的残基-原子交互矩阵已知，因此使用该数据集训练以学习残基-原子交互矩阵及药物-蛋白质亲和力
- 5)DrugBAN

二分类数据集Human,bindingdb,Biosnap被使用,其中, Biosnap中的负样本是随机采样的未见过的药物-蛋白质对
- 6)AttentionSiteDTI

二分类数据集Human,bindingdb及DUD-E被使用，其中, DUD-E是在DUD数据集的基础上进行高可信度样本重建，但是, 由于被证实的负样本数量不足，其中仍存在自动化生成的负样本
- 7)GEFA

使用亲和力数据集Davis及PDBBind进行的亲和力预测
- 8)MMDG-DTI

二分类数据集Human,C.elegans,bindingdb,DrugBank，以及亲和力数据集Dacis,KIBA被使用。其中,对Davis及KIBA的亲和力数值基于阈值进行正负样本采样
- 9)KNU-DTI

该模型同时具有分类及回归任务的预测能力。使用的亲和力数据集包括 BindingDB及Davis.其中，BindingDB的重复对被去除，且两个数据集均基于阈值生成对应的二分类标签。但是，Davis使用了pKi=6.5(以往是5.0)进行了正负样本采样，作者认为这有助于缓解正负样本类别不平衡问题
- 10)MuRL-DTI

使用3个公开的数据集包括Luo's,Yamanishi's及Zheng's进行DTI预测。
Luo's数据集包括四种类型的节点（即药物、蛋白质、疾病和副作用）和六种类型的边（即药物-蛋白质相互作用、药物-药物相互作用、药物-疾病关联、药物-副作用关联、蛋白质-疾病关联和蛋白质-蛋白质相互作用）
Yamanishi's数据集包括药物-靶标二元关系列表(被记录存在关系),DTI邻接矩阵(存在何种关系),药物相似度矩阵及靶标蛋白相似度矩阵，靶标分四类记录(酶，离子通道，GPCRs，核受体)
Zheng's数据集包括药物嵌入集合(化学结构，副作用，取代基，均以二进制向量表示)，蛋白质嵌入集合(GO术语，二进制向量表示)[使用由已知药物-靶点对构成的正样本向量和随机选取的负样本向量来训练和评估集成学习模型。]
与以往不同，上述三个数据集中，正样本被定义为已知相互作用的样本(为0或为1均已被确认)，负样本被定义为未知相互作用的样本(相互作用未得到确认)
- 11)MVCL-DTI

使用Luo's数据集进行训练，所有已知的DTI为正样本，未知的DTI作为负样本
- 12)WAE-DTI

选择Davis,KIBA,DTC,Metz,ToxCast及STITCH作为数据集

研究方向1：提升数据可信度

3),4),5),6),

已知具有相互作用的正样本相较于已知不具有相互作用的负样本之间的数量差距大，实验中往往使用随机选择的未见样本对作为负样本，这引入了假阴性数据。假阴性数据的引入给了模型错误的学习样本，这不利于模型的预测性能及鲁棒性提升。设计策略(如设计新的方法，综合类内及类间信息，对样本数据设立可信度评分标准等)来提高负样本的可信度对于模型真实性能的评估具有重要意义。

10),11)

除了使用模型学习正负样本(存在相互作用为正，不存在为负)的隐藏的相互作用特征，以预测新的未知相互作用。还存在一类数据集及模型学习模式，该类数据集将正样本被定义为已知相互作用的样本，负样本被定义为未知相互作用的样本。这类数据集中往往包含更多的类内网络信息(如蛋白质/药物-蛋白质/药物相似性，副作用等)，但是该类数据集的使用过程中也面临假阴性数据的引入问题。