



一种用于分子性质预测的预训练多表征融合网络

Haohui Zhang ^{a,1}, Juntong Wu ^{a,1}, Shichao Liu ^{a,b,c,d,e,*}, Shen Han ^a

^a 华中农业大学信息学院, 中国武汉

^b 中国教育部农业智能技术工程研究中心

^c 湖北省农业生物信息学重点实验室

^d 湖北省农业大数据工程技术研究中心

^e 农业部智能养殖技术重点实验室, 中国武汉

文章信息

关键词: 分子性质预测 图神经网络 多模态融合 无监督预训练

摘要

在机器学习和化学信息学领域, 分子性质的预测具有重要意义。分子可以通过多种格式表示, 包括 1D 的 SMILES 字符串、2D 图形以及 3D 构象。针对不同的表示形式, 已提出了众多模型来实现分子性质预测。然而, 近期的大多数研究工作要么专注于一种或两种表示形式, 要么以较为简单的方式结合来自不同视角的嵌入向量。为解决这一问题, 我们提出了 PremuNet, 这是一种用于分子性质预测的新型预训练多表示融合网络。PremuNet 能够从多个视角提取全面的分子信息, 并通过预训练和微调实现交互式融合。PremuNet 的框架由两个分支组成: 一个是从小 SMILES 和图形中提取信息的 Transformer-GNN 分支, 另一个是从拓扑和几何中提取信息的融合网络分支, 分别称为 PremuNet-L 和 PremuNet-H。我们采用掩码自监督方法, 使模型能够学习信息融合, 并在下游任务中实现性能提升。所提出的模型已在八项分子属性预测任务上进行了评估, 其中包括五项分类任务和三项回归任务, 在大多数情况下均达到了最先进的性能。此外, 我们还进行了消融研究, 以展示每个视角以及分支组合方法的效果。

1. 简介

分子性质预测在生物信息学[1]和化学信息学[2]领域至关重要。准确的分子特征表示能够有效解决诸如药物发现[3]、药物-靶点相互作用预测[4]和药物-药物相互作用预测[5]等关键任务。分子可以表示为图, 其中原子为节点, 化学键为边。因此, 图神经网络 (GNN) 方法被广泛用于分子嵌入和性质预测等任务。

近年来, 人们提出了多种预测分子性质的方法, 包括 MPNN [6]、GCN [7]、GAT [8]、GIN [9] 等。这些模型是图神经网络, 从二维分子图中提取分子性质。此外, 还可以使用简化分子线性输入规范 (SMILES) [10] 将分子表示为一维符号序列。使用一维序列表示的优势在于可以应用自然语言处理模型, 例如

SMILES-Transformer [11] 和 SMILES-BERT [12]。这些模型可以通过在大规模分子数据集上进行预训练来增强其对新分子的特征提取能力。此外, 由于存在立体异构体, 它们具有相同的图连接但空间排列不同, 例如光学异构体和顺反异构体, 三维结构对于预测分子性质至关重要。立体异构体表现出不同的物理性质、药代动力学和生物活性 [13-16], 这些无法从二维图中获取。因此, 许多研究人员利用 SchNet [17]、DimeNet [18] 和 PAiNN [19] 等三维网络来提取分子特征。这些网络利用每个原子的三维坐标和特性来提取几何信息, 从而对量子特性做出出色的预测。

然而, 依赖单一维度的模型往往无法捕捉到所有分子特征。例如, 消息传递神经网络 (MPNN) 仅允许每个原子使用相邻原子的特征。

*Corresponding author at: College of Informatics, Huazhong Agricultural University, Wuhan, China. E-mail address: scliu@mail.hzau.edu.cn (S. Liu).

¹ These two authors contributed equally to this paper.

在更新过程中,这使得模型难以提取图中远距离原子之间的原子相互作用信息[6]。虽然使用像 SMILES-BERT 这样的自注意力层能让模型计算所有原子之间的自注意力分数,但由于缺乏二维拓扑结构,模型可能会遗漏关键信息。使用三维网络可能是一个相对较好的解决方案,因为它们能够同时从二维拓扑结构和三维空间信息中提取特征。然而,获取分子的精确三维结构是一项具有挑战性且耗时的任务[20]。尽管三维网络在提取分子特征方面很有效,但由于大多数数据集仅提供 SMILES 字符串,它们可能缺乏通用性[21]。

为应对分子性质预测中的挑战,已提出了若干多视角模型。FP-GNN [22] 能够从分子指纹和二维分子表示中学习特征,其性能优于单一的图神经网络。AdvProp [23] 利用 BERT、MPNN 和 SVM 从分子中提取互补嵌入,这些嵌入可组合用于下游任务。3D Infomax [24]、GraphMVP [25] 和 Unified [26] 利用二维分子图和三维坐标信息进行预训练,从二维结构中学习三维信息。这些模型解决了二维网络在学习三维信息方面的局限性以及下游数据集缺乏三维坐标的问题。然而,某些模型在二维数据集上的表现有限(例如 3D Infomax),而其他模型可能在某些维度上信息不足,导致在特定数据集上的表现不佳(例如 GraphMVP 在 Clintox 数据集上的表现不佳)。迄今为止,现有的模型还无法同时有效地从三个维度提取和整合信息。

鉴于这些挑战,我们推出了 PremuNet,这是一种用于分子性质预测的预训练多表征融合网络。PremuNet 能够同时从分子指纹、SMILES 字符串、二维结构和三维几何形状中提取分子嵌入,以预测分子性质。PremuNet 方法还解决了分子性质预测任务中缺少三维坐标的问题,通过在包含二维和三维信息的大规模数据集上进行预训练来实现。该预训练采用了自监督学习技术,使得 PremuNet 在缺乏三维坐标的数据集上也能取得更好的效果。

我们的模型由两个分支组成:低维分支 PremuNet-L,它结合了 SMILES-Transformer 和 GNN;以及高维分支 PremuNet-H,负责提取 2D-3D 融合表示。两个分支均可通过预训练来提升模型性能。在 PremuNet-L 中,我们首先从 SMILES 字符串中提取分子特征和原子特征,然后将原子特征与图形信息结合作为 GNN 的输入,以获得 1D-2D 融合表示。最后,我们将分子特征、融合表示和分子指纹结合起来,形成该分支的输出。PremuNet-H 分支采用自监督预训练技术,以增强模型学习分子 2D 结构与 3D 坐标之间关系的能力。此外,该模型利用 2D 结构生成 3D 特征,即使没有 3D 坐标数据,也能获取 3D 特征。在下游任务中,将 PremuNet-L 和 PremuNet-H 分支的特征结合起来进行预测。在对多种方法进行评估之后,实验表明将低维特征和高维特征进行拼接是最有效的方法。

为了评估我们模型在预测分子特性方面的有效性,我们在包含五个分类任务和三个回归任务的八个数据集上对 PremuNet 进行了测试。实验结果表明,在八个分子特性预测任务中,我们的方法在其中七个任务中达到了最先进的性能,与之前的最佳方法相比,分类任务平均提高了 3.4%,回归任务平均提高了 4.0%。这证明了我们多表示预训练网络的有效性。此外,我们还进行了全面的消融实验,以阐明模型中每个模块的贡献,并研究模块融合对结果

的影响。我们的代码可在以下网址获取: <https://github.com/A-Gentle-Cat/PremuNet>。

我们的贡献可总结如下:

我们的论文提出了一种新颖且先进的分子多模态框架,该框架利用两种通过不同预训练方法获得的互补分子表示来预测分子特性。

我们提出了一种新颖的多模态分子融合交互方案,该方案采用图神经网络(GNN)有效地整合了不同模态的分子特征。

针对八个分子预测任务进行了大量实验,以评估 PremuNet 的性能。与几种最先进的方法相比,PremuNet 在八个任务中的七个任务上取得了显著更优的性能。

2. 相关工作

2.1. 单模态分子表示学习

先前的研究在计算机科学领域开发了多种描绘分子的形式,包括 SMILES 字符串、分子图和 3D 几何结构[27]。由于 SMILES 表示法将构成分子的原子、键和环表示为字符串序列,因此它与自然语言处理(NLP)技术兼容。基于 SMILES 的分子表示学习已提出了众多 RNN 相关模型[28-30]以及 Transformer 相关模型[11,12]。然而,SMILES 表示法无法表达空间化学结构信息,而基于图的方法在从分子图中建模复杂内部连接方面更具优势[31]。通常,大多数用于分子图学习的现有 GNN 模型都遵循 MPNN 框架[6]。MPNN 框架包含两个步骤:消息传递阶段和读出阶段。为了从分子图中挖掘更多结构信息,提出了几种 MPNN 变体,取得了令人鼓舞的性能。CD-MVGNN[32]在原子和键导向的图结构上采用 MPNN 进行多视图分子表示学习。FraGAT[33]提出了一种基于片段的多尺度图注意力模型,用于提取分子结构三个层次的特征。实际上,分子是一种动态的三维结构,而不仅仅是简单的二维分子图,它包含原子位置、距离和键扭转角等复杂的几何元素[34]。近年来,将几何信息融入图架构以提升分子性质预测任务效果的研究受到了关注[35,36]。例如,GEM[36]设计了一种基于几何的图神经网络架构以及几种专门的几何级自监督学习策略,以获取分子几何知识。此外,Mol-BERT[37]提出了一种新颖的预训练框架,采用掩码原子建模,增强了预训练 GNN 的有效性。然而,由于上述方法都无法有效地构建全面的分子图谱,因此多模态分子表示学习因其优于单模态方法的性能而受到更多关注。

2.2. 多模态分子表征学习

受多模态学习领域进展的启发,从不同表征视角融合分子特征已成为分子性质预测的一个热门方向。近期研究主要集中在设计复杂的多模态学习框架[24-26]和模态交互策略[22,23,38]上。例如,GraphMVP[25]和 3D Infomax[24]均采用对比学习作为预训练框架,以最大化不同分子模态表示嵌入之间的互信息。Zhu 等人[26]提出了统一的 2D 和 3D 预训练框架,该框架共同利用了分子的 2D 图结构和 3D 结构信息。




图 1. PremuNet 概述。输入包括分子的三种模态信息：SMILES 字符串、二维结构和三维几何形状。(a) PremuNet-L 包含三个组件：分子指纹、SMILES 变换器和图神经网络 (GNN)。每个组件生成特征向量，随后将这些向量组合起来以表示分子的低维（一维和二维）特征。(b) PremuNet-H 模块旨在通过应用 GNN 整合二维和三维信息来提取分子的高维特征（二维和三维）。

分子及其三维构象的掩码策略。MMSG [38] 在分子图和对应的 SMILES 序列之间交叉引用化学信息，以增强分子语义特征的表征能力。此外，最近的一些研究关注自然语言文本与分子图之间的多模态性 [39]，而 GIT-Mol [40] 提出了一种多模态大型语言模型，能够同时处理图、图像和文本。

3. 方法

3.1. PremuNet

PremuNet 包含两个分支：PremuNet-L 和 PremuNet-H，分别用于提取低维和高维分子特征，如图 1 所示。在 PremuNet-L 分支中，我们采用三种方法从 SMILES 字符串中提取特征，包括分子指纹、SMILES-Transformer 和 GNN。我们使用 SMILES-Transformer 的编码器获取原子级和分子级特征嵌入，然后使用 GNN 实现 1D 到 2D 的信息融合。在 PremuNet-H 分支中，我们采用一个预训练的统一 GNN 同时输入 2D 结构和 3D 几何信息。通过这种方法，我们可以实现 2D 和 3D 信息的融合。之后，将两个分支提取的特征进行整合，以预测分子的性质。

3.2. PremuNet-L

在 PremuNet-L 分支中，我们采用分子指纹、SMILES-Transformer 和 GNN 来提取低维特征。对于分子指纹，我们使用了三种具有互补信息不同指纹，其详细内容在 3.2.1 节中有阐述。

对于 SMILES-Transformer，我们从标记化的 SMILES 字符串中计算出两个特征矩阵，从中可以提取出 SMILES 特征向量和原子特征向量。之后，我们将原子特征与 2D 拓扑信息结合，作为 GNN 的输入，以实现 1D-2D 融合分子特征向量。最后，将分子指纹、SMILES 特征向量和分子特征向量进行拼接，形成 PremuNet-L 的输出。

3.2.1. 分子指纹

我们使用了三种不同的化学分子指纹：MACCS [41]、PubChem [42] 和 ErG [43]。这些指纹能够有效地提取分子的全面特征，提供互补的信息 [22]。每种指纹的详细描述如下。

MACCS 指纹算法通过提取分子结构的结构和功能特征来表征分子结构。这包括各种化学性质，如环、链、官能团、孤对电子等。这些特征随后被表示为 166 位的二进制代码。通过将 MACCS 指纹与分类器相结合，可以高效地评估各种化学化合物的活性。

PubChem 指纹是利用 PubChem 数据集生成的。这些指纹通过将一系列子结构片段与分子进行匹配，然后根据这些子结构是否存在将相应的二进制位设置为 1 或 0 来生成。这一过程最终形成一个 881 位的二进制代码。PubChem 指纹涵盖了大量化学信息，能够快速比较和筛选化合物库中的化合物。因此，它们在药物开发、药物筛选和化学信息检索中发挥着重要作用。

ErG 分子指纹图谱能够识别分子与受体相互作用的关键方面，包括氢键特性、特定尺寸的疏水区域以及值得注意的芳香环和脂肪环。ErG 将这些特征分配给具有不同属性的属性点，将其转换为径向分布函数，并最终整合为描述符向量。这种分子指纹技术被应用于诸如小分子虚拟筛选等领域。

3.2.2. SMILES-Transformer

在本研究中，我们利用 SMILES-Transformer 结构从 SMILES 字符串中提取分子和原子特征向量。我们通过以下步骤从 SMILES 字符串中提取特征向量：SMILES 分词、自注意力信息计算和特征向量提取。在将 SMILES 字符串输入到 Transformer 结构之前，必须先对其进行分词处理。可以从 SMILES 字符串中提取相关信息。

1. 原子信息，例如 “O”、“N”、“Br” 等。
2. 电荷信息，例如 “+2”、“-3” 等。
3. 化学键信息，例如 “=”（双键）、“#”（三键）
4. 手性信息，例如 “@@” 和 “@”
5. 环信息（由成对的数字表示）

我们开发了算法 1 来对 SMILES 字符串进行分词。首先，我们使用 RDKit 将 SMILES 字符串转换为二维分子，然后从二维分子中获取原子列表 $\mathbb{A}$ 。需要注意的是，列表 $\mathbb{A}$ 中原子的顺序与 SMILES 字符串中的顺序相同。使用原子列表有助于消除 SMILES 字符串中的歧义。例如，“Sc” 可以被理解为 “S” 和 “C” 原子，或者作为一个单独的 “Sc” 原子。我们检查 SMILES 字符串的前缀是否与一个分词相匹配，并重复此过程，直到整个 SMILES 字符串都被分词。一旦分词完成，我们便得到分词列表。在算法 1 中，“±NUMBER” 表示电荷信息，例如 “+2”。“ $\mathbb{A}_i$ ” 表示原子列表 $\mathbb{A}$ 中的第 i 个原子。PREFIX($\mathbb{A}$) 表示 $\mathbb{A}$ 的所有前缀。“SINGLENUMBER” 表示环信息，例如 “11”（尽管在 SMILES 字符串中成对出现，但我们每次只能向分词列表中添加一个数字）。 $\mathbb{A}_0$ 表示 $\mathbb{A}$ 的第一个元素。此外，“@@” 表示从 $\mathbb{A}$ 中移除前缀 “@@”。其他 “-” 符号的用法具有相同的含义。

在提取过程之后，我们在标记列表的开头添加 “<BEG>”，在结尾添加 “<END>”。此外，我们用 “<PAD>” 填充列表，直到其达到预定长度，记为 N 。为了将标记列表输入模型，我们使用一个字典将标记列表转换为序列表示 $V \in \mathbb{R}^N$ 。字典可在附录 A 中查看。然后，我们使用嵌入层将序列转换为特征矩阵 $V \in \mathbb{R}^{N \times \mathbb{A}IDDEN}$ ，其中每个 $V_i \in \mathbb{R}^{\mathbb{A}IDDEN}$ 表示 V_i 的特征向量，而 $\mathbb{A}IDDEN$ 是隐藏嵌入的长度。

此外，由于 Transformer 完全摒弃了循环神经网络（RNN）的序列结构，我们需要向 X 中添加位置嵌入 P 以区分不同位置的标记。公式 (1)、(2) 可用于计算位置嵌入向量：

$$P_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/hidden}}\right) \quad (1)$$

$$P_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/hidden}}\right) \quad (2)$$

其中，POS 表示位置， i 表示维度。最终的位置嵌入矩阵 $P \in \mathbb{R}^{N \times \mathbb{A}IDDEN}$ 。最后，我们将特征矩阵与位置嵌入矩阵相加，得到模型输入 $X(0) \in \mathbb{R}^{N \times \mathbb{A}IDDEN}$ 。

$$X^{(0)} = V + P \quad (3)$$

随后，矩阵 X 被送入多层的 Transformer 块中进行特征提取。每个 Transformer 块由两个

Algorithm 1 SMILES Tokenization

Input: SMILES string S of length N ;
Atom List $\mathcal{L}$ of size M ;
function $Prefix(\cdot)$

Output: Token List $\mathcal{T}$

```

1:  $i \leftarrow 0$ 
2:  $\mathcal{T} \leftarrow \{\}$ 
3: while  $S$  is not empty do
4:   if  $i \neq M$  and  $\mathcal{L}_i \in Prefix(S)$  then
5:     Append  $\mathcal{L}_i$  to  $\mathcal{T}$ 
6:      $i \leftarrow i + 1$ 
7:      $S \leftarrow S - \mathcal{L}_i$ 
8:   else if “±Number”  $\in Prefix(S)$  then
9:     Append “±Number” to  $\mathcal{T}$ 
10:     $S \leftarrow S - \text{“±Number”}$ 
11:   else if “@@”  $\in Prefix(S)$  then
12:     Append “@@” to  $\mathcal{T}$ 
13:     $S \leftarrow S - \text{“@@”}$ 
14:   else if “Single Number”  $\in Prefix(S)$  then
15:     Append “Single Number” to  $\mathcal{T}$ 
16:     $S \leftarrow S - \text{“Single Number”}$ 
17:   else
18:     Append  $S_0$  to  $\mathcal{T}$  {Match a single symbol}
19:     $S \leftarrow S - S_0$ 
20:   end if
21: end while
22: return  $\mathcal{T}$ 

```

该模型由多个部分组成，包括一个自注意力层和一个前馈神经网络。自注意力层使每个位置能够学习上下文信息，而前馈神经网络则能进一步提取特征信息。我们采用缩放点积注意力机制来计算注意力得分。形式上，自注意力结果矩阵通过公式 (4)、(5) 计算得出，前馈神经网络则通过公式 (6) 计算。

$$Attention(Q, K, V) = Softmax\left(\frac{Q \cdot K^T}{\sqrt{d_k}}\right)V \quad (4)$$

$$Softmax(z_i) = \frac{e^{z_i}}{\sum_{c=1}^C e^{z_c}} \quad (5)$$

$$FNN(x) = \max(0, xW_1 + b_1)W_2 + b_2 \quad (6)$$

其中， $\backslash(Q = XW_Q)$ ， $\backslash(K = XW_K)$ ， $\backslash(V = XW_V)$ ，并且 $\backslash(W_Q)$ 、 $\backslash(W_K)$ 、 $\backslash(W_V)$ 、 $\backslash(W_1)$ 、 $\backslash(W_2)$ 、 $\backslash(b_1)$ 、 $\backslash(b_2)$ 都是可训练参数，其中 $\backslash(Q)$ 和 $\backslash(K)$ 的维度为 D_k 。此外，为了提高性能，我们使用多头注意力机制来完成自注意力计算。多头注意力机制可以通过公式 (7)、(8) 进行计算。

$$MultiHead(Q, K, V) = Concat(head_1, \dots, head_h)W^O \quad (7)$$

$$head_i = Attention(QW_i^Q, KW_i^K, VW_i^V) \quad (8)$$

其中， $\backslash(h)$ 是注意力头的数量， $\backslash(W_i^Q, W_i^K, W_i^V \in \mathbb{R}^{hidden \times hidden})$ 以及 $\backslash(W_O \in \mathbb{R}^{hidden \times hidden})$ 是新的参数矩阵。

经过 N 层注意力编码器特征提取后，我们得到了 SMILES 字符串的特征矩阵 $X(N) \in \mathbb{R}^{N \times \mathbb{A}IDDEN}$ 。这里， $XI(N)$ 表示对应于第 i 个标记的特征向量。我们应用多头注意力层、前馈神经网络和归一化层来更新 $X^{(i)}$ ，如图 2 所示。

在获得特征矩阵 $X^{(1)} \dots X^{(N)}$ 后，我们可以从中提取分子特征和原子特征。分子特征由四部分组成，每部分长度相同。它们分别是： $XO(N)$ 、 $XO(N-1)$ 、每个 i 的所有 $X_i^{(N)}$ 的平均值以及每个 i 的所有 $XI(N)$ 的最大值。我们选择这些特征嵌入是因为 Lee




图 2. SMILES-Transformer 过程利用多层 Transformer 编码器从 SMILES 字符串中提取分子和原子特征。

et al. [44] 通过实证研究展示了结合均值池化和最大池化的益处。此后，我们便得到了 SMILES 字符串的分子特征向量。此外，我们从 $X^{(n)}$ 中相应索引处提取所有原子的特征向量，这些特征向量将作为输入的一部分提供给图神经网络 (GNN)。

使用 SMILES-Transformer 提取分子和原子特征的过程如图 2 所示。

3.2.3. SMILES-Transformer 的预训练方法

为了提高特征提取能力，为 SMILES-Transformer 开发了两个预训练任务。其中一个任务采用自动编码器方法，利用 Honda 等人[11]提出的预训练权重和字典对原始 SMILES 字符串进行标记化处理。编码过程包括将编码后的字符串通过多层编码器，从而得到特征矩阵。然后，使用多层解码器对矩阵进行解码以获得输出，并使输入和输出之间的差异最小化。这种预训练方法使转换器编码器能够有效地从 SMILES 字符串中提取特征。

另一个预训练任务涉及无监督掩码学习，其目的是从 SMILES 字符串中提取原子特征。在这一部分，我们随机掩码标记列表中的某些元素，将其输入到相同的编码器和解码器中以获得输出序列，并最小化输出序列与未被掩码的标记列表之间的差异。这种预训练方法使多层编码器能够学习标记之间的联系，并可用于获取原子特征。

表 1

RDKit 生成的原子和键的化学特性。

类型	特征	尺寸	描述
节点	原子序数	119	原子类型
	手性列表	4	手性异构体。
	学位名单	12	节点度数
	收费清单	12	原子电荷
	numH 列表	10	相邻氢原子
	激进分子名单	6	自由基电子
	杂交列表	7	杂化轨道类型
边缘	芳香族化合物列表	2	芳香键或非芳香键
	在戒指里	2	戴戒指与否

对于上述提到的两种预训练方法，我们都使用交叉熵损失函数来计算损失值。对于每个位置，我们使用公式 (9) 进行计算，其中 C 表示标记类型的数量， y 表示原始标记列表中的值，而 $y^{\wedge}$ 表示模型的输出值。

$$\mathcal{L} = - \sum_{i=0}^C y_i \log \hat{y}_i \quad (9)$$

3.2.4. 图神经网络

我们的图神经网络 (GNN) 主要承担两项任务：提取分子的图特征以及融合由 SMILES-Transformer 生成的原子特征向量。我们采用 PNA (主邻域聚合) [45] 作为 GNN 框架，如有必要，也可替换。PNA 是一种使用多种聚合器的 GNN，通过标量区分具有不同特征但不同基数的邻居。PNA 的定义如下，基于 MPNN 框架。

$$X_i^{t+1} = U(X_i^{(t)}, \bigoplus_{(j,i) \in E} M(X_i^{(t)}, e_{j,i}, X_j^{(t)})) \quad (10)$$

$$\bigoplus = \begin{pmatrix} I \\ S(D, a=1) \\ S(D, a=-1) \end{pmatrix} \otimes \begin{pmatrix} \mu \\ \sigma \\ \max \\ \min \end{pmatrix} \quad (11)$$

$$S(d, \alpha) = \left(\frac{\log(d+1)}{\delta} \right)^\alpha \quad (12)$$

其中 $E_{j,i}$ 表示边缘特征， M 和 U 均为神经网络 (例如多层感知机)， $\bigoplus$ 表示聚合操作， $\otimes$ 表示张量积，而 $\bigoplus$ 操作是两个矩阵的张量积。初始的 X 是原子的化学特征与 SMILES-Transformer 提供的原子特征的组合。在公式 (11) 中，第一个矩阵表示缩放器，第二个矩阵表示聚合方法。对于聚合方法， μ 表示平均聚合， σ 表示标准差聚合，而 $\max$ 和 $\min$ 分别表示最大值和最小值聚合。缩放器 S 在聚合操作期间用于与聚合值相乘，以放大或缩小消息，从而区分具有相同特征但不同基数的邻域点。经过上述消息传递的若干次迭代后，初始的原子特征 X 将更新为 1D 和 2D 集成的原子特征。

在我们的模型中，我们通过 PNA 集成来自两种不同模态的信息。第一种包括由 RDKit 生成的原子和键的化学特性，详情见表 1。第二种包含使用 SMILES-Transformer 生成的原子特征，如第 3.2.2 节所述。我们将 RDKit 生成的原子特征与 SMILES-Transformer 生成的原子特征向量连接起来作为初始节点特征，并使用 RDKit 生成的化学键特征作为初始边特征。然后，我们将这些节点特征、边特征和拓扑结构输入到 PNA 网络中。最后，我们使用读出方法将 PNA 网络生成的向量聚合为分子特征向量。

3.3. PremuNet-H

PremuNet-H 是一个基于图神经网络 (GNN) 的统一框架, 用于提取二维和三维信息[26,46,47]。它能够融合二维图信息和三维几何信息, 以提取高维分子特征。该网络由两部分组成: 编码器和解码器。编码器的作用是整合二维和三维信息, 以实现增强的分子特征表示。解码器则用于预训练任务和下游任务。

在本文中, 我们使用了三个预训练任务[26]:

- 将所有原子隐藏起来, 并使用 3D 技术重建被隐藏的原子坐标。
- 对所有 3D 坐标进行掩码处理, 并使用 (此处原文缺失, 可能需要补充具体方法) 重建坐标。
- 以概率 P 独立地对原子和原子坐标进行掩码处理, 并利用未掩码原子的特征和三维坐标来重建掩码原子和坐标。

前两个任务分别赋予模型从二维数据中提取三维信息以及从三维数据中提取二维信息的能力。第三个任务将这些能力整合起来, 增强了模型的信息融合能力。通过这三项预训练任务, PremuNet-H 能够充分探索分子的高维特征, 并将其编码为特征向量。

接下来, 我们将分别介绍三个预训练任务的细节。

3.3.1. 基于构象的原子重建

我们对所有原子的化学特性进行掩码处理 (原子特性的详细信息见表 1), 仅将所有原子的三维坐标作为输入来预测所有原子特性信息。请注意, 原子图的拓扑结构得以保留, 但原子和边的化学特性被掩码处理。对于每个原子特性, 我们将其视为一个分类任务, 并使用交叉熵函数作为损失函数, 其定义如下:

$$\mathcal{L}_{3D \rightarrow 2D} = - \sum_{i=1}^m y_i \log \hat{y}_i \quad (13)$$

其中 M 是预测任务的类别数量。我们独立地使用上述损失函数来计算原子每个特征的损失, 然后将它们相加。

经过上述的预训练过程, 该模型获得了提取二维图形信息的能力。

3.3.2. 基于原子特征的构象重建

此预训练任务的目标是使模型具备生成分子 3D 坐标以及提取相关 3D 信息的能力。我们将所有原子的 3D 坐标进行掩码处理, 仅使用原始原子特征作为输入来预测并生成分子的 3D 构象。损失函数定义如下:

$$\mathcal{L}_{2D \rightarrow 3D} = \sum_{i \in V} \|R_i - \phi(\alpha(\hat{R}_i))\|^2 \quad (14)$$

其中 $R_i \in \mathbb{R}^{1 \times 3}$ 表示第 i 个原子的坐标, 而 $\hat{R}_i \in \mathbb{R}^{1 \times 3}$ 表示模型生成的 3D 构象。操作定义为 $\hat{R} = RQ + T$, 其中 $Q \in \mathbb{R}^{3 \times 3}$ 表示旋转矩阵, 而 $T \in \mathbb{R}^{1 \times 3}$ 表示平移向量。通过此操作, $\hat{R}_{2D \rightarrow 3D}$ 具有旋转和置换不变性。

3.3.3. 掩码原子与构象重建

对于输入的分子图 G , 分子图中所有原子的集合记为 V 。对于所有 $V_i \in V$, 使用固定的概率 P 来执行掩码操作。同样的过程也应用于构象。实际上, 掩码任务是前两个预训练任务的软组合, 其中前两个预训练任务代表掩码任务的极端情况。值得注意的是, 在计算损失函数时, 仅使用掩码部分来计算预测值与真实值之间的差异, 而未被掩码的信息不包含在损失函数中。掩码任务的损失函数定义如下:

$$\mathcal{L}_{mask} = - \sum_{i \in I_a} y_i \log \hat{y}_i + \sum_{i \in I_b} \|R_i - \phi(\alpha(\hat{R}_i))\|^2 \quad (15)$$

公式 (15) 中符号的定义已在公式 (14) 和公式 (13) 中给出, 此处不再赘述。

3.3.4. PremuNet-H 架构

编码器 我们的模型与大多数其他 GNN 模型一样, 可以用 MPNN 框架 [6] 来描述。对于节点, 我们用 $X_i \in \mathbb{R}^D$ 表示第 i 个原子的节点信息, 其中 D 表示维度。 χ_i represents 包含第 i 个原子的 3D 信息的扩展特征。首先, 我们通过多层感知机 (MLP) 对原子的坐标进行编码, 以获得节点级别的 3D 嵌入信息, 并将其添加到原子特征中, 从而得到扩展原子特征 χ_i 。

$$\chi_i^{(l)} = x_i^{(l-1)} + MLP(R_i^{(l-1)}) \quad (16)$$

边的特征由 E_{IJ} 表示, 其中 I 和 J 是两个相连的节点。与提取节点的 3D 坐标类似, 我们使用多层感知机 (MLP) 对由边 E_{IJ} 连接的节点 I 和 J 的 3D 坐标之间的欧几里得距离进行编码。此编码器将距离转换为包含 3D 距离信息的边特征。接下来, 我们将边特征添加到距离编码信息中, 以获得具有 3D 信息的扩展边特征 e 。

$$e_i^{(l)} = e_{ij}^{(l-1)} + MLP(\|R_i^{(l-1)} - R_j^{(l-1)}\|) \quad (17)$$

稍后, 我们将介绍如何更新节点和边的特征。在 MPNN 框架中, 消息 M 的定义如下:

$$m_i = MLP(\chi_j^{(l-1)}; e_{ij}^{(l)}) \quad (18)$$

更新节点的方法如下:

$$x_i^{(l)} = x_i^{(l-1)} + W_{node}(x_i^{(l-1)}; \tilde{x}_i; u^{l-1}) \quad (19)$$

$$\tilde{x}_i^{(l)} = \sum_{j \in \mathcal{N}_i} \alpha_j m_j \quad (20)$$

其中 α_j represents 表示注意力得分, χ_j represents 表示使用注意力机制聚合相邻节点的结果。注意力得分 α_j 的计算方式如下:

$$\alpha_j = \text{Softmax}_{i \in \mathcal{N}_j} (W_{attn} \xi(W_q \chi_i^{(l)} + W_k [\chi_j^{(l)}; e_{ij}^{(l)}])) \quad (21)$$

在上述消息传递过程的 L 层之后, 原子特征的编码过程完成, 其中 W_Q, W_K, W_{ATN} are 均为可学习参数。

编码器加载预训练的权重, 使模型能够提取二维和三维信息。通过统一的图神经网络框架, 编码器模块将输入的二维和三维信息编码为高维特征融合向量, 以供下游任务使用。

表 2
下游任务数据集的详细信息。

数据集	实例	描述	3D 百分比	评估
BBBP	2039	分子屏障渗透性的预测。	94.0	ROC 曲线下面积 (AUC)
BACE	1513	一组人类β-分泌酶 1 抑制剂结合结果的预测	99.9	ROC 曲线下面积 (AUC)
克林托克斯	1477	临床试验毒性的预测以及美国食品药品监督管理局 (FDA) 的审批状态预测。	97.6	ROC 曲线下面积 (AUC)
Tox21	7831	对 12 种生物靶点的定性毒性测量值进行预测。	94.9	ROC 曲线下面积 (AUC)
SIDER 侧翼	1427	上市药品不良反应的预测。	83.3	ROC 曲线下面积 (AUC)
ESOL	1128	常见有机小分子水溶性数据的预测。	99.7	均方根误差
Freesolv	642	小分子在水中的水合自由能预测。	99.8	均方根误差
亲脂性	4200	辛醇分配系数实验结果的预测。	99.6	均方根误差

表 2 提供了我们研究中所使用的下游任务数据集的详细信息。具体内容包括每个数据集的规模、所涉及任务的描述、从 GEOM 数据集提取的 3D 信息的比例以及用于评估的指标。

解码器。该模型的解码器由两部分组成：属性解码器 (AttributeDecoder) 和位置解码器 (PosDecoder)。它们用于将编码的信息解码为训练目标。在预训练阶段，属性解码器利用堆叠的多层感知机 (MLP) 将原子嵌入解码为原子重构任务所需的原子属性。同样，位置解码器将原子嵌入解码为原子坐标，用于构象重构任务。在微调阶段，属性解码器丢弃预训练权重，并使用随机初始化在新的下游任务上进行微调。

4. 实验

在实验部分，我们将首先介绍用于预训练和评估的数据集。然后，介绍模型在预训练过程中的参数设置。最后，我们将对我们的模型与其他基线模型进行对比实验，并对实验结果进行分析。

4.1. 数据集

对于用于提取分子特征的 SMILES-Transformer，我们在 ChEMBL 数据库 [48] 上进行预训练，该数据库是一个包含具有类药物质生物活性分子的化学数据库，其中包含 163 万条未标记的 SMILES 数据。对于 PremuNet-H，我们使用 PCQM4Mv2 [49] 作为 PremuNet-H 网络的预训练数据集。PCQM4Mv2 是一个量子化学数据集，包含 338 万个分子，提供 SMILES 信息、二维图信息和三维几何信息。对于数据集的划分，我们使用 95% 的分子进行训练，5% 用于验证。

对于下游任务，我们在 MoleculeNet [21] 提供的五个分类任务和三个回归任务上评估我们的模型。分类任务包括：BBBP、BACE、Clintox、Tox21 和 SIDER；而回归任务包括：ESOL、FreeSolv 和 Lipophilicity。这些任务的数据集仅包含 2D 信息。因此，我们采用了 Axelrod 和 Gomez Bombarelli [50] 提出的方法，从现有的 1D SMILES 数据生成精确的 3D 分子构象。分子的大量 3D 构象信息来自他们提供的数据库。数据集的具体细节见表 2。对于没有 3D 信息的分子，我们用均匀随机分布初始化其 3D 坐标。所有数据集均按照 OGB [49] 提供的支架分割以 8:1:1 的比例进行划分。对于所有模型的每次评估，我们都使用固定的分割。所有数据集和分割方式见附录 B。

4.2. 设置

4.2.1. PremuNet-L 预训练配置

这两个 SMILES-Transformer 模型采用了相同的结构，但使用了不同的数据集和训练策略进行预训练。在预训练过程中，使用了 4 层的 Transformer 结构，包括编码器和解码器层。每一层的隐藏层大小为 256，有 4 个注意力头用于信息聚合。

对于用于提取分子特征的 Transformer 模型，我们在自监督学习中使用 Adam 优化器，学习率为 10^{-4} 。我们使用交叉熵损失来计算输入序列和输出序列之间的差异。由于在训练过程中未对原始序列进行掩码处理，损失值在 12 个周期后降至 0，这意味着从编码表示中实现了完美解码。

对于用于提取原子特征的 Transformer 模型，我们在 PCQM4Mv2 数据集上使用掩码自监督学习对其进行预训练。我们将标记列表中的 15% 的标记掩码作为输入，并使用相同的超参数和模型架构。经过几个训练周期后，该模型能够有效地提取每个标记的特征。

4.2.2. PremuNet-H 预训练配置

在预训练阶段，三个预训练任务独立运行，损失函数的结果相加并一起反向传播。GNN 层的数量设置为 12，隐藏层的向量维度设置为 256，初始学习率设置为 2×10^{-4} ，批处理大小为 128，掩码率 P 设置为 0.25。

4.2.3. 微调配置

在模型的微调阶段，PremuNet-H 和 SMILES-Transformer 分别加载预训练权重，而其他部分随机初始化。值得注意的是，在 PremuNet-H 中，用于预训练任务的解码器被丢弃并随机初始化。我们采用拼接进行聚合，关于不同聚合方法的详细讨论见第 5 节。需要指出的是，GNN 模块是可互换的。在我们的评估中，PNA 作为 GNN。对于参数设置，我们调整并测试了模型的批量大小、学习率、GNN 层的数量以及隐藏层向量维度。详细参数在我们的代码中提供。

4.3. 评估

我们使用 ROC-AUC (受试者工作特征曲线下的面积) 作为分类任务的评估指标，使用 RMSE (均方根误差) 作为回归任务的评估指标。对于多任务数据集，我们对所有任务的评估结果取平均值。每个模型都使用随机种子独立评估五次，记录结果的均值和标准差。

4.4. 基准线

我们通过不同模态对各种流行模型进行全面评估，以充分展示我们模型性能的优越性。我们所选的基准模型分为两类：单模态模型和多模态模型。单模态模型包括仅使用 SMILES 序列信息、二维图信息或分子三维构象信息的模型。多模态模型指的是同时使用多模态信息的模型。

表 3

在 MoleculeNet 上的模型评估结果。我们以**粗体**突出显示最佳结果，以下划线突出显示次佳结果。

方法	BBBP	BACE	TOX21	克林托克斯	SIDER 侧翼	ESOL	Freesolv	亲脂性	AVG _{CLA}	AVG _{REG}
肽核酸	65.0±1.0	76.3±2.3	61.2±0.4	80.8±2.5	57.6±0.5	0.963±0.020	2.894±0.095	0.815±0.020	68.2	1.557
SMILES-TSFM ^a	63.7±0.5	76.0±0.9	66.6±0.3	98.2±0.2	58.7±0.5	1.339±0.017	3.097±0.032	1.215±0.016	72.6	1.884
CD-MVGNN	69.3±0.7	83.9±0.6	77.0 ±0.2	88.8±0.2	61.1±1.0	0.865±0.012	2.048±0.217	0.669±0.014	76.0	<u>1.194</u>
格罗弗	67.9±0.2	79.1±3.4	73.5±0.3	73.1±6.8	61.2±1.3	0.992±0.096	2.470±0.337	0.810±0.033	71.0	1.424
摩尔-伯特	69.0±0.6	79.7±1.4	76.2±0.3	79.4±1.3	62.6±0.7	1.211±0.047	2.878±0.081	0.732±0.008	73.4	1.607
GraphMVP	69.4±0.9	72.9±3.4	75.4±0.3	72.6±8.9	61.8±0.9	1.341±0.004	2.972±0.137	0.769±0.005	70.4	1.694
AdvProp	72.2±0.6	82.2±1.7	75.2±5.0	78.6±2.2	60.3±7.8	0.886±0.016	1.996±0.251	0.715±0.010	73.7	1.199
3D信息最大化	67.7±1.9	80.7±2.9	65.3±1.7	88.5±2.0	60.9±1.6	0.901±0.025	2.601±0.533	1.226±0.970	72.6	1.576
备忘录	71.6±0.1	82.6±0.3	<u>76.7</u> ±0.4	81.6±3.7	61.2±0.6	0.984±0.034	/	0.707±0.001	74.7	/
普瑞姆网-L	72.5±0.2	83.9±0.3	72.2±0.3	95.0±1.7	64.8 ±2.8	1.034±0.020	1.905±0.018	0.764±0.006	<u>77.7</u>	1.234
普瑞姆网-H	65.2±0.9	81.4±1.6	73.9±0.6	73.3±1.4	58.8±1.4	0.871±0.018	2.265±0.078	0.629 ±0.008	70.5	1.255
PremuNet	73.3 ±0.6	84.3 ±0.5	74.0±1.2	99.2 ±0.2	62.6±0.8	0.851 ±0.038	1.858 ±0.285	0.730±0.010	78.7	1.146

^a 一个 SMILES-TSFM 指的是由本田等人[11]提出的 SMILES-Transformer 模型。

^b 该 MEMO 的作者未公开其代码。由于他们使用了与我们在实验中相同的数据集和划分方式，我们直接采用了他们论文中所展示的数据。值得注意的是，他们的数据未包含 Freesolv，这导致我们在分析中有一部分数据缺失。

^c AVG_{CLA}和 AVG_{REG} respectively 分别表示分类任务和回归任务的平均结果。

- **单模态模型**：对于仅接受 SMILES 输入的模型，我们选择 SMILES-Transformer 作为基准模型。对于仅接受二维图信息输入的模型，我们选择 PNA、CD-MVGNN、GROVER [51] 和 Mol-BERT 作为基准模型。
- **多模态模型**：接下来的部分将讨论多模态模型。GraphMVP 在二维拓扑结构和三维几何视图之间进行自监督学习。AdvProp 分别使用 1D 的 SMILES 序列和 2D 图形信息，分别提取特征并进行组合。3DInfomax 利用 2D 图形信息和 3D 构象信息进行预训练，使 GNN 能够提取 3D 信息。MEMO 从四个角度整合分子特征。

4.5. 实验结果

表 3 总结了我们在 MoleculeNet 中的 8 个数据集上模型与基准模型的表现。可以看出，我们的模型表现稳健，在 8 个数据集中有 6 个取得了最佳结果，分类任务的平均提升率为 3.4%，回归任务的平均提升率为 4.0%。这证明了我们模型的优越性。

为了进行更全面的对比分析，我们展示了我们两个分支（PremuNet-L 和 PremuNet-H）的性能。显然，我们提出的 PremuNet-L 模型表现也很出色，在 4 个数据集上超过了之前的最佳方法，这证明了我们模块的有效性，关于 PremuNet-L 的进一步分析在第 5.1 节中描述。通过将 PremuNet-L 与从 PremuNet-H 模型获取的高维信息相结合，我们实现了进一步的改进，并在大多数数据集上获得了更优的结果。

5. 消融研究

为了阐明我们模型中每个组件的贡献，我们进行了消融分析，该分析包含两个部分：不同分子表示形式的性能分析以及不同聚合方法的对比分析。

5.1. PremuNet-L 分子表示性能分析

在本节中，我们将模型进行模块化拆解。我们将 PremuNet-L 分支拆解为其组成部分：传统指纹提取（Traditional-FP）、Transformer 指纹提取（Transformer-FP）以及 PNA+原子指纹提取（PNA+Atom-FP），这些分子指纹提取方法分别在 3.2.1、3.2.2 和 3.2.4 节中介绍。它们分别在五个分类数据集上进行了评估。图 3 展示了这三个组件在五个模型上的性能。可以看出，总体而言，PremuNet-L 的性能优于




图 3. 不同分子表示方法的性能结果。

Results of different aggregation methods




图 4. 不同聚合方法的结果。我们将 Concat 方法的结果作为参考，并计算其他方法的结果与 Concat 方法结果的比值。所得结果如图所示。

这三个成分未进行信息融合。这表明我们的三种分子表示方法具有互补的信息特征，证明了多特征融合机制的必要性和有效性。

5.2. 模块聚合方法比较

图 4 报告了 PremuNet-L 和 PremuNet-H 不同聚合方法（包括拼接、最小值、最大值和求和）的性能。结果表明，基于拼接方法，其他聚合方法在大多数情况下表现更差，而拼接方法

表现出良好的泛化能力，并在大多数情况下取得最优结果。这表明与 Max、Mean 和 Sum 相比，Concat 能够更好地整合不同模态的信息。由于某些数据集的偏差以及不同聚合方法融合的信息组合不同，其他聚合方法偶尔会优于 Concat，从而导致性能有所变化。总体而言，Concat 仍然是最优选择。

6. 结论

在本文中，我们提出了一种新的分子表征学习框架 PremuNet。我们的框架通过两个不同的分支提取分子的低维和高维特征，每个分支采用不同的编码器。此外，我们针对这些编码器专门引入了预训练策略和信息融合技术，以增强下游任务的预测能力。在低维特征分支中，我们使用三种不同的编码器从三个独特的角度提取低维特征。在公开可用的分子性质预测数据集上进行的全面性能评估表明，我们的预训练多表征分子框架能够有效地学习和融合来自各种分子表征的特征，在七个分子预测数据集上均优于当前最先进的方法（分类任务平均提升 3.4%，回归任务平均提升 4.0%）。这也证实了多模态分子表征在预测分子性质方面的优越性。

尽管我们取得了成功，但仍存在改进的空间。我们的模型参数数量相对较多，需要大量的计算资源，而且预测速度也有待提高。此外，我们的低维和高维分支之间没有深刻的特征交互，只有初步的融合。在未来的研究中，我们可以探索特征之间的相关性，并引入参数共享机制来解决这些局限性。

CRediT 作者贡献声明

张浩辉: 概念化、软件开发、方法论、撰写初稿。**吴俊通**: 软件开发、方法论、形式分析、撰写初稿。**刘世超**: 概念化、监督、项目管理、审稿与编辑。**韩申**: 形式分析、审稿与编辑。

利益冲突声明

作者声明，他们不存在任何已知的可能影响本论文所述研究工作的财务利益冲突或个人关系。

数据可用性

数据将根据要求提供。

致谢

本研究得到了国家自然科学基金（项目编号：62102158）、中央高校基本科研业务费专项资金（项目编号：2662022JC004）以及 2021 年佛山市促进高校科技成果转化服务业发展扶持项目（2021DZXX05）的支持。

附录 A. 用于将标记列表转换为整数序列的词典

钥匙	价值	钥匙	价值	钥匙	价值
乞求	0	银	46	-	92
结束	1	金	47	@	93
平板电脑	2	光盘	48	.	94
UNK	3	Te	49	(	95
MSK	4	铂	50	*	96
Sc	5	锡	51	)	97
钠	6	铽	52	\$	98
铬	7	c	53	:	99
s	8	铈	54	0	100
o	9	氟	55	1	101
钴	10	鲁	56	2	102
镁	11	再; 又; 重新	57	3	103
Sm	12	李	58	4	104
西	13	加	59	5	105
te	14	钯	60	6	106
K	15	吉	61	7	107
V	16	b	62	8	108
C	17	巴	63	9	109
哈	18	镱	64	@@	110
锰	19	你	65	+1	111
N	20	S	66	-1	112
W	21	Sr	67	+2	113
铅	22	p	68	-2	114
Se	23	比	69	+3	115
钛	24	铯	70	-3	116
Ac	25	汞	71	+4	117
莫	26	O	72	-4	118
P	27	欧	73	+5	119
在	28	作为	74	-5	120
Dy	29	钙	75	+6	121
拉	30	锌	76	-6	122
H	31	Tl	77	+7	123
Y	32	se	78	-7	124
锶	33	参见	79	+8	125
钪	34	n	80	-8	126
B	35	铁	81	百分之十	127
锆	36	钹	82	百分之十一	128
I	37	某人	83	百分之十二	129
是	38	/	84	百分之十三	130
铝	39	=	85	百分之十四	131
拉	40	+	86	百分之十五	132
铜	41	%	87	百分之十六	133
Br	42	#	88	百分之十七	134
F	43	[	89	百分之十八	135
Cs	44	]	90	百分之十九	136
U	45	好的, 请提供您需要翻译的英文内容。			

附录 B. 数据和代码获取途径

在我们的实验中，MoleculeNet 的数据集和划分可在 http://snap.stanford.edu/ogb/data/graphproppred/csv_mol_download/ 获取。对于 GEOM 数据集，可以从 <https://github.com/learningmatter-mit/geom> 获得。

参考文献

[1] Xiao-Meng Zhang, Li Liang, Lin Liu, Ming-Jing Tang, Graph neural networks and their current applications in bioinformatics, Front. Genet. 12 (2021) 690049.
[2] Kevin Yang, Kyle Swanson, Wengong Jin, Connor Coley, Philipp Eiden, Hua Gao, Angel Guzman-Perez, Timothy Hopper, Brian Kelley, Miriam Mathea, et al., Analyzing learned molecular representations for property prediction, J. Chem. Inf. Model. 59 (8) (2019) 3370–3388.

- [3] Laurianne David, Amol Thakkar, Rocío Mercado, Ola Engkvist, Molecular representations in ai-driven drug discovery: a review and practical guide, *J. Cheminform.* 12 (1) (2020) 1–22.
- [4] Xing Chen, Chenggang Clarence Yan, Xiaotian Zhang, Xu Zhang, Feng Dai, Jian Yin, Yongdong Zhang, Drug-target interaction prediction: databases, web servers and computational models, *Brief. Bioinform.* 17 (4) (2016) 696–712.
- [5] Oliver Wieder, Stefan Kohlbacher, Méline Kuenemann, Arthur Garon, Pierre Ducrot, Thomas Seidel, Thierry Langer, A compact review of molecular property prediction with graph neural networks, *Drug Discov. Today: Technol.* 37 (2020) 1–12.
- [6] Justin Gilmer, Samuel S. Schoenholz, Patrick F. Riley, Oriol Vinyals, George E. Dahl, Neural message passing for quantum chemistry, in: Doina Precup, Yee Whye Teh (Eds.), *Proceedings of the 34th International Conference on Machine Learning, ICML 2017, Sydney, NSW, Australia, 6–11 August 2017*, in: *Proceedings of Machine Learning Research*, vol. 70, PMLR, 2017, pp. 1263–1272.
- [7] David Duvenaud, Dougal Maclaurin, Jorge Aguilera-Iparraguirre, Rafael Gómez-Bombarelli, Timothy Hirzel, Alán Aspuru-Guzik, Ryan P. Adams, Convolutional networks on graphs for learning molecular fingerprints, in: Corinna Cortes, Neil D. Lawrence, Daniel D. Lee, Masashi Sugiyama, Roman Garnett (Eds.), *Advances in Neural Information Processing Systems 28: Annual Conference on Neural Information Processing Systems 2015, December 7–12, 2015, Montreal, Quebec, Canada, 2015*, pp. 2224–2232.
- [8] Petar Velickovic, Guillem Cucurull, Arantxa Casanova, Adriana Romero, Pietro Liò, Yoshua Bengio, Graph attention networks, in: *6th International Conference on Learning Representations, ICLR 2018, Vancouver, BC, Canada, April 30 - May 3, 2018, Conference Track Proceedings*, OpenReview.net, 2018.
- [9] Keyulu Xu, Weihua Hu, Jure Leskovec, Stefanie Jegelka, How powerful are graph neural networks? in: *7th International Conference on Learning Representations, ICLR 2019, New Orleans, LA, USA, May 6–9, 2019*, OpenReview.net, 2019.
- [10] David Weininger, Smiles, a chemical language and information system. 1. introduction to methodology and encoding rules, *J. Chem. Inf. Comput. Sci.* 28 (1) (1988) 31–36.
- [11] Shion Honda, Shoi Shi, Hiroki R. Ueda, Smiles transformer: Pre-trained molecular fingerprint for low data drug discovery, 2019, arXiv preprint, [abs/1911.04738](https://arxiv.org/abs/1911.04738).
- [12] Sheng Wang, Yuzhi Guo, Yuhong Wang, Hongmao Sun, Junzhou Huang, Smilesbert: large scale unsupervised pre-training for molecular property prediction, in: *Proceedings of the 10th ACM International Conference on Bioinformatics, Computational Biology and Health Informatics*, 2019, pp. 429–436.
- [13] E.J. Ariens, Chirality in bioactive agents and its pitfalls, *Trends Pharmacol. Sci.* 7 (1986) 200–205.
- [14] F. Jamali, R. Mehvar, F.M. Pasutto, Enantioselective aspects of drug action and disposition: therapeutic pitfalls, *J. Pharma. Sci.* 78 (9) (1989) 695–715.
- [15] Lien Ai Nguyen, Hua He, Chuong Pham-Huy, Chiral drugs: an overview, *Int. J. Biomed. Sci.: IJBS* 2 (2) (2006) 85.
- [16] Naveen Chhabra, Madan L. Aseri, Deepak Padmanabhan, A review of drug isomerism and its significance, *Int. J. Appl. Basic Med. Res.* 3 (1) (2013) 16.
- [17] Kristof Schütt, Pieter-Jan Kindermans, Huziel Enoc Saucedo Felix, Stefan Chmiela, Alexandre Tkatchenko, SchNet: A continuous-filter convolutional neural network for modeling quantum interactions, in: Isabelle Guyon, Ulrike von Luxburg, Samy Bengio, Hanna M. Wallach, Rob Fergus, S.V.N. Vishwanathan, Roman Garnett (Eds.), *Advances in Neural Information Processing Systems 30: Annual Conference on Neural Information Processing Systems 2017, December 4–9, 2017, Long Beach, CA, USA, 2017*, pp. 991–1001.
- [18] Johannes Klicpera, Janek Groß, Stephan Günnemann, Directional message passing for molecular graphs, in: *8th International Conference on Learning Representations, ICLR 2020, Addis Ababa, Ethiopia, April 26–30, 2020*, OpenReview.net, 2020.
- [19] Kristof Schütt, Oliver T. Unke, Michael Gastegger, Equivariant message passing for the prediction of tensorial properties and molecular spectra, in: Marina Meila, Tong Zhang (Eds.), *Proceedings of the 38th International Conference on Machine Learning, ICML 2021, 18–24 July 2021, Virtual Event*, in: *Proceedings of Machine Learning Research*, vol. 139, PMLR, 2021, pp. 9377–9388.
- [20] Minkai Xu, Shitong Luo, Yoshua Bengio, Jian Peng, Jian Tang, Learning neural generative dynamics for molecular conformation generation, in: *9th International Conference on Learning Representations, ICLR 2021, Virtual Event, Austria, May 3–7, 2021*, OpenReview.net, 2021.
- [21] Zhenqin Wu, Bharath Ramsundar, Evan N. Feinberg, Joseph Gomes, Caleb Geniesse, Aneesh S. Pappu, Karl Leswing, Vijay Pande, Moleculenet: a benchmark for molecular machine learning, *Chem. Sci.* 9 (2) (2018) 513–530.
- [22] Hanxuan Cai, Huimin Zhang, Duancheng Zhao, Jingxing Wu, Ling Wang, Fp-gnn: a versatile deep learning architecture for enhanced molecular property prediction, *Brief. Bioinform.* 23 (6) (2022) bbac408.
- [23] Zhengyang Wang, Meng Liu, Youzhi Luo, Zhao Xu, Yaochen Xie, Limei Wang, Lei Cai, Qi Qi, Zhuoning Yuan, Tianbao Yang, et al., Advanced graph and sequence neural networks for molecular property prediction and drug discovery, *Bioinformatics* 38 (9) (2022) 2579–2586.
- [24] Hannes Stärk, Dominique Beaini, Gabriele Corso, Prudencio Tossou, Christian Dallago, Stephan Günnemann, Pietro Liò, 3D infomax improves gnn for molecular property prediction, in: Kamalika Chaudhuri, Stefanie Jegelka, Le Song, Csaba Szepesvári, Gang Niu, Sivan Sabato (Eds.), *International Conference on Machine Learning, ICML 2022, 17–23 July 2022, Baltimore, Maryland, USA*, in: *Proceedings of Machine Learning Research*, vol. 162, PMLR, 2022, pp. 20479–20502.
- [25] Shengchao Liu, Hanchen Wang, Weiyang Liu, Joan Lasenby, Hongyu Guo, Jian Tang, Pre-training molecular graph representation with 3d geometry, in: *The Tenth International Conference on Learning Representations, ICLR 2022, Virtual Event, April 25–29, 2022*, OpenReview.net, 2022.
- [26] Jinhua Zhu, Yingce Xia, Lijun Wu, Shufang Xie, Tao Qin, Wengang Zhou, Houqiang Li, Tie-Yan Liu, Unified 2d and 3d pre-training of molecular representations, in: *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, 2022*, pp. 2626–2636.
- [27] Daniel S. Wigh, Jonathan M. Goodman, Alexei A. Lapkin, A review of molecular representation in the age of machine learning, *WIREs Comput. Mol. Sci.* 12 (5) (2022) e1603.
- [28] Zhichun Guo, Wenhao Yu, Chuxu Zhang, Meng Jiang, Nitesh V. Chawla, Graseq: Graph and sequence fusion learning for molecular property prediction, in: *CIKM '20*, Association for Computing Machinery, New York, NY, USA, 2020, pp. 435–443.
- [29] Cheng-Kun Wu, Xiao-Chen Zhang, Zhi-Jiang Yang, Ai-Ping Lu, Ting-Jun Hou, Dong-Sheng Cao, Learning to SMILES: BAN-based strategies to improve latent representation learning from molecules, *Brief. Bioinform.* 22 (6) (2021) bbab327.
- [30] Cheng-Kun Wu, Xiao-Chen Zhang, Zhi-Jiang Yang, Ai-Ping Lu, Ting-Jun Hou, Dong-Sheng Cao, Learning to smiles: Ban-based strategies to improve latent representation learning from molecules, *Brief. Bioinform.* 22 (6) (2021) bbab327.
- [31] Zhen Li, Mingjian Jiang, Shuang Wang, Shugang Zhang, Deep learning methods for molecular representation and property prediction, *Drug Discov. Today* (2022) 103373.
- [32] Hehuan Ma, Yatao Bian, Yu Rong, Wenbing Huang, Tingyang Xu, Weiyang Xie, Geyan Ye, Junzhou Huang, Cross-dependent graph neural networks for molecular property prediction, *Bioinformatics* 38 (7) (2022) 2003–2009.
- [33] Ziqiao Zhang, Jihong Guan, Shuigeng Zhou, Fragat: a fragment-oriented multi-scale graph attention model for molecular property prediction, *Bioinformatics* 37 (18) (2021) 2981–2987.
- [34] Sebastian Mai, Leticia González, Molecular photochemistry: recent developments in theory, *Angew. Chem. Int. Ed.* 59 (39) (2020) 16832–16846.
- [35] Yoni Choukroun, Lior Wolf, Geometric transformer for end-to-end molecule properties prediction, 2021, arXiv preprint [arXiv:2110.13721](https://arxiv.org/abs/2110.13721).
- [36] Xiaomin Fang, Lihang Liu, Jieqiong Lei, Donglong He, Shanzhuo Zhang, Jingbo Zhou, Fan Wang, Hua Wu, Haifeng Wang, Geometry-enhanced molecular representation learning for property prediction, *Nat. Mach. Intell.* 4 (2) (2022) 127–134.
- [37] Jun Xia, Chengshuai Zhao, Bozhen Hu, Zhangyang Gao, Cheng Tan, Yue Liu, Siyuan Li, Stan Z. Li, Mole-bert: Rethinking pre-training graph neural networks for molecules, in: *The Eleventh International Conference on Learning Representations*, 2022.
- [38] Tianyu Wu, Yang Tang, Qiyu Sun, Luolin Xiong, Molecular joint representation learning via multi-modal information of smiles and graphs, *IEEE/ACM Trans. Comput. Biol. Bioinform.* (2023).
- [39] Carl Edwards, ChengXiang Zhai, Heng Ji, Text2mol: Cross-modal molecule retrieval with natural language queries, in: *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, 2021, pp. 595–607.
- [40] Pengfei Liu, Yiming Ren, Zhixiang Ren, Git-mol: A multi-modal large language model for molecular science with graph, image, and text, 2023, arXiv preprint [arXiv:2308.06911](https://arxiv.org/abs/2308.06911).
- [41] Joseph L. Durant, Burton A. Leland, Douglas R. Henry, James G. Nourse, Reoptimization of mdl keys for use in drug discovery, *J. Chem. Inf. Comput. Sci.* 42 (6) (2002) 1273–1280, PMID: 12444722.
- [42] Evan E. Bolton, Yanli Wang, Paul A. Thiessen, Stephen H. Bryant, Chapter 12 - Pubchem: Integrated Platform of Small Molecules and Biological Activities, in: *Annual Reports in Computational Chemistry*, vol. 4, Elsevier, 2008, pp. 217–241.
- [43] Nikolaus Stiefl, Ian A. Watson, Knut Baumann, Andrea Zaliani, Erg: 2d pharmacophore descriptions for scaffold hopping, *J. Chem. Inf. Model.* 46 (1) (2006) 208–220, PMID: 16426057.
- [44] Chen-Yu Lee, Patrick W. Gallagher, Zhuowen Tu, Generalizing pooling functions in convolutional neural networks: Mixed, gated, and tree, in: Arthur Gretton, Christian C. Robert (Eds.), *Proceedings of the 19th International Conference on Artificial Intelligence and Statistics, AISTATS 2016, Cadiz, Spain, May (2016) 9–11*, in: *JMLR Workshop and Conference Proceedings*, vol. 51, JMLR.org, 2016, pp. 464–472.
- [45] Gabriele Corso, Luca Cavalleri, Dominique Beaini, Pietro Liò, Petar. Velickovic, Principal neighbourhood aggregation for graph nets, in: Hugo Larochelle, Marc Aurelio Ranzato, Raia Hadsell, Maria-Florina Balcan, Hsuan-Tien Lin (Eds.), *Advances in Neural Information Processing Systems 33: Annual Conference on Neural Information Processing Systems 2020, NeurIPS 2020, December 6–12, 2020, Virtual*, 2020.
- [46] Ravichandra Addanki, Peter W Battaglia, David Budden, Andreea Deac, Jonathan Godwin, Thomas Keck, Wai Lok Sibon Li, Alvaro Sanchez-Gonzalez, Jacklyn Stott, Shantanu Thakoor, et al., Large-scale graph representation learning with very deep gnn and self-supervision, 2021, arXiv e-prints, pages [arXiv-2107](https://arxiv.org/abs/2107.00018).

- [47] Jinhua Zhu, Yingce Xia, Chang Liu, Lijun Wu, Shufang Xie, Tong Wang, Yusong Wang, Wen.gang Zhou, Tao Qin, Houqiang Li, Tie-Yan Liu, Direct molecular conformation generation, *Trans. Mach. Learn. Res.* (2022) 2022.
- [48] David Mendez, Anna Gaulton, A. Patrícia Bento, Jon Chambers, Marleen De Veij, Eloy Félix, María Paula Magariños, Juan F Mosquera, Prudence Mutowo, Michał Nowotka, et al., ChEMBL: towards direct deposition of bioassay data, *Nucl. Acids Res.* 47 (D1) (2019) D930–D940.
- [49] Weihua Hu, Matthias Fey, Hongyu Ren, Maho Nakata, Yuxiao Dong, Jure Leskovec, OGB-LSC: a large-scale challenge for machine learning on graphs, in: Joaquin Vanschoren, Sai-Kit Yeung (Eds.), *Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks 1*, NeurIPS Datasets and Benchmarks 2021, December 2021, Virtual, 2021.
- [50] Simon Axelrod, Rafael Gomez-Bombarelli, Geom, energy-annotated molecular conformations for property prediction and molecular generation, *Sci. Data* 9 (1) (2022) 185.
- [51] Yu Rong, Yatao Bian, Tingyang Xu, Weiyang Xie, Ying Wei, Wenbing Huang, Junzhou Huang, Self-supervised graph transformer on large-scale molecular data, in: Hugo Larochelle, Marc Aurelio Ranzato, Raia Hadsell, Maria-Florina Balcan, Hsuan-Tien Lin (Eds.), *Advances in Neural Information Processing Systems 33: Annual Conference on Neural Information Processing Systems 2020*, NeurIPS 2020, December 6-12, 2020, Virtual, 2020.