

实用诱饵目录增强版 (DUD-E) : 更优质的配体和诱饵, 助力更精准的基准测试


Michael M. Mysinger,[†] Michael Carchia,[†] John. J. Irwin,^{*,†} and Brian K. Shoichet^{*,†}[†] 美国加利福尼亚大学旧金山分校药物化学系, 加利福尼亚州旧金山市 94158-2330, 美国

* 支持性信息

摘要: 评估分子对接的一个关键指标是针对具有挑战性的假受体的配体富集情况。尽管有用假受体目录 (DUD) 已被广泛使用, 但仍有明显的优化空间。在此, 我们描述了一个改进的基准测试集, 其中包含更多样化的靶点, 如 G 蛋白偶联受体 (GPCRs) 和离子通道, 总计 102 种蛋白质, 从 ChEMBL 中提取了 22886 个聚类配体, 每种配体对应 50 个从 ZINC 中提取的性质匹配的假受体。为确保化学类型多样性, 我们根据 Bemis–Murcko 原子框架对每个靶点的配体进行聚类。我们在匹配的物理化学性质中增加了净电荷, 并仅纳入与配体拓扑结构差异最大的假受体。一个在线自动化工具 (<http://decoys.docking.org>) 生成这些数据。

针对用户提供的配体改进了匹配诱饵。我们进行了测试

通过将所有 102 个靶点进行对接, 利用所得结果改进 DOCK 3.6 中配体脱溶与静电作用之间的平衡。完整的 DUD-E 基准测试集可免费获取, 网址为 <http://dude.docking.org>。



■ 引言

尽管分子对接筛选通常利用蛋白质结构来发现新的分子, 但对其性能的定量评估仍存在问题。虽然对接性能的前瞻性评估不可替代, 但它既耗时又昂贵。由于当前的方法无法建立对接分数与亲和力之间的普遍关联, 因此该领域依靠对接命中列表中的配体富集度来进行回顾性评估。富集度衡量的是已知配体相对于背景诱饵分子的排名情况, 因此不仅取决于配体的性质, 还取决于背景诱饵分子。因此, 要比较对接富集度, 就需要一套基准配体和诱饵分子。

最初的有用诱饵目录 (DUD) 旨在满足这一基准测试需求, 同时控制对富集度的诱饵偏差。^{15,16} 针对一组随机的类药物诱饵, Verdonk 等人表明, 那些能与高分子量配体结合的靶点, 由于大分子与更好的对接得分之间存在关联, 自然会获得更高的富集度。¹⁷ 相比之下, 实际的配体结合亲和力仅对非常小的分子与分子大小之间存在关联。¹⁸ 由于无法将有助于前瞻性配体发现的简单分子属性的真实关联与因偏差而产生的虚假关联区分开来, 因此很有必要探究分子对接在这些属性之外还能带来什么价值。为此, DUD 诱饵是根据每个靶点的配体物理化学性质进行匹配的: 通过以下性质

会分子量、计算得到的 logP 值、可旋转键的数量以及氢键供体和受体的数量。为了起到阴性对照的作用, 诱饵分子不应实际结合, 因此 DUD 使用了二维相似性指纹图谱来尽量减少诱饵分子与配体之间的拓扑相似性。简而言之, DUD 诱饵分子在物理性质上与配体相似, 从而对对接构成挑战, 但同时在拓扑结构上又与配体不同, 以尽量降低实际结合的可能性。

在最初的 DUD 数据集中, 由于存在严重的缺陷, 导致配体和诱饵分子都出现了问题。戈德和奥普雷亚指出, 在许多配体集合中, 少数几种化学类型占据了主导地位, 这使得一种骨架的高排名就能带来整体较好的富集效果。为解决这一问题, 一种方法是采用化学类型检索指标, 另一种方法是通过基于配体骨架的聚类来消除数据库中的“类似物偏差”。对 40 个靶点进行聚类后, 戈德的 DUD 子集仅包含 13 个拥有超过 15 种配体的靶点, 这表明需要更多拥有更多配体的靶点。另一个重要目标是增加靶点的多样性, 例如, 可以加入膜域蛋白, 而 DUD 中目前没有此类蛋白。

由于 DUD 配体存在缺陷, 诱饵也是如此。有几位研究人员指出, 尽管在 logP 值上进行了匹配, 但 DUD 中的净形式电荷仍不平衡; 所有配体中有 42% 带电, 而诱饵中仅有 15% 带电。诱饵与配体的性质匹配可能会

Received: May 16, 2012

Published: June 20, 2012

通过选择更嵌入配体属性空间的诱饵分子，也可以提高筛选的严格性。^{32,33} 尽管采用了二维化学差异过滤器来防止诱饵分子具有活性，但一些原始 DUD 诱饵分子似乎仍能结合，这些假诱饵分子会人为地降低对接富集度。³² 为了解决假诱饵分子和诱饵分子属性嵌入的问题，Vogel 等人发布了针对原始 40 个 DUD 目标的 DEKOIS。Gatica 和 Cavasotto 为 147 个 G 蛋白偶联受体（GPCRs）生成了配体和诱饵分子集，同时增加了净电荷属性匹配。³⁴ 最近，一个 Python 图形用户界面应用程序被宣布用于生成属性匹配的诱饵分子。³⁵ 通过忽略合成可行性，Wallach 和 Lilien 为原始 DUD 目标生成了具有更严格属性匹配的虚拟诱饵分子集。³³ MUV 集合不是生成计算诱饵分子，而是为 17 个在公共高通量筛选中呈阴性的目标选择诱饵分子。³⁶ 而 REPROVIS-DB 则完全不生成诱饵分子，而是从早期成功的虚拟筛选中收集配体和数据库数据，这些筛选被认为是可重复的。³⁷

在此，我们介绍了一个新版本的 DUD，它解决了上述缺陷并开发了新的功能。通过参考 ChEMBL09 数据库，³⁸ 每个 DUD 增强版（DUD-E）配体都有一个由文献支持的实测亲和力。尽管现在通常通过 Bemis-Murcko 原子框架³⁹ 对配体进行聚类以减少化学类型偏差，但每个靶点平均仍有 224 个配体。靶点列表从 40 个扩展到 102 个，更倾向于具有大量配体和多种结构的靶点。新增加的靶点包括几种与药物相关的膜蛋白：五个 G 蛋白偶联受体、两个离子通道和两个细胞色素 P450。同时，通过更严格的拓扑差异过滤，减少了假阴性配体。在可能的情况下，还纳入了实测的实验假阴性配体。最后，我们探讨了 DUD-E 作为基准相对于原始 DUD 的表现，并研究了其作为评估和优化分子对接工具的用途。

■ 结果

理想的基准测试集的目标应该经过充分研究，具有大量已测定的配体亲和力以及多种多样的共晶配体结构。为此，增强版 DUD 数据库（DUD-E）主要基于 ChEMBL 和 RCSB PDB 的交集，前者提供配体注释和亲和力，后者提供结构。在扩充基准测试集时，我们首先考虑了最初的 40 个 DUD 目标，其中 38 个被纳入。血小板源性生长因子受体 β 被排除在外，因为它是一个同源模型。在 DUD-E 中，雌激素受体 α （ESR1）是一个单一目标，而此前它被分为激动剂和拮抗剂两类。为了扩大基准测试集，我们采用了三个主要标准。首先，我们倾向于选择具有药理学先例的新靶点类别。其次，我们寻找具有大量配体和晶体结构的靶点，因为它们可能同时反映了靶点的相关性和易于研究的特点。第三，我们更倾向于那些使用全自动对接能够适度丰富已知配体的靶点，因为这些靶点可能既容易准备又适合对接。相反，主要含有共价配体的靶点则被置于较低优先级。

DUD-E 的靶点通过其 UniProt⁴¹ 基因前缀来定义，来自每个物种的数据被合并为一个数据集。虽然 ChEMBL 将配体注释到特定的 UniProt 访问代码，但同源靶点之间的配体重叠却出奇地少。例如，在对人类多巴胺 D3 受体具有低于 1 μ M 亲和力的 1555 种独特配体和大鼠同源物的 744 种配体中，只有 85 种配体同时存在于这两个集合中。这两个同源物的跨膜序列同源性为

97%（总体同源性为 79%），因此这种低重叠表明 ChEMBL 配体注释较为稀疏，通常不能反映物种特异性。因此，我们将所有物种的数据合并，将 DUD-E 靶点定义为 UniProt 基因前缀（例如 DRD3），而不是完整的基因_物种对（例如 DRD3_HUMAN 或 P35462）。

这 102 个靶点涵盖了多种蛋白质类别，包括 26 种激酶、15 种蛋白酶、11 种核受体、5 种 G 蛋白偶联受体、2 种离子通道、2 种细胞色素 P450、36 种其他酶以及 5 种杂项蛋白质（图 1）。总计 66695 个原始数据




图 1. DUD-E 目标分类。属于八大蛋白质类别中的 102 个目标的数量。

从 ChEMBL09（或 AmpC β -内酰胺酶文献）中提取了配体，其定义是对靶点的亲和力注释值优于 1 μ M、分子量小于 600 且旋转键少于 20 个的配体（表 1）。平均而言

表 1. DUD-E 的特点

	总计	ChEMBL	手册	
否。目标	102	101	1	1
	总计	平均的	最小值	最大值
否。未修饰配体	66695	653.9	40	3090
否。聚集配体	22886	224.4	40	592
否。实验性诱饵	9219	90.4	1	1070
否。聚集配体独特的电荷态	28377	278.2	46	1030
否。计算诱饵	1411214	13835	2300	51500

每个靶点平均有 654 种配体，最少 40 种，最多 3090 种。尽管负结合现象很少被报道，但我们还发现了 9219 种实验性假配体（即在 30 微摩尔浓度下没有可测量的亲和力），其中环氧氧化酶-1（PGH1）最多，达 1070 种。

选定目标后，我们在对接研究中为每个目标选择了一个单一的 X 射线结构（表 2，补充信息表 S1）。为了找到最适合对接的结构，我们使用自动对接方案对 3690 个 PDB 结构及其聚类配体和属性匹配的诱饵进行了筛选（见下文）。优先考虑分辨率更高、自动化富集度更高以及人类同源物的结构。我们避免使用突变体结构、未解析的活性位点环、多余的结合肽或对目标的许多配体来说过于受限的结构。在具备领域知识的情况下，优先选择最具代表性的结构，例如 DFG-in 结构。

表 2.代表性目标概述

目标类	基因ID	描述	总配体	聚集配体	实验性诱饵	匹配诱饵	蛋白质数据库	对数曲线下面积 (%)	ROC E F1	AUC (%)
细胞色素 P450	CP2C9	细胞色素 P450 2C9	145	120	176	7450	一九零	7	3	60
	CP3A4	细胞色素 P450 3A4	302	170	267	11800	三组克斯	7	2	63
GPCR	AA2A 受体	腺苷 A2a 受体	3057	482	192	31550	3EML	28	22	83
	肾上腺素能受体β-1	肾上腺素能受体β-1	648	247	69	15850	二VT四	19	11	76
	CXCR4	C-X-C 趋化因子受体 4 型	40	40	14	3406	三光盘驱动器 (3CHU)	18	18	90
离子通道	GRIA2	谷氨酸受体离子型 AMPA 2	476	158	201	11845	3千克碳	23	23	71
	GRIK1	谷氨酸受体离子型海人藻酸盐 1 型	136	101	235	6550	1VSO	35	27	86
激酶	AKT1	丝氨酸/苏氨酸蛋白激酶 AKT	585	293	53	16450	3 cqw	27	29	72
	MK10	c-Jun 氨基末端激酶 3	199	104	23	6600	2 zdt	24	11	82
	MK14	p38α 丝裂原活化蛋白激酶	2205	578	73	35850	二七得九	17	10	74
杂项	KIF11	驱动蛋白样蛋白 1	272	116	29	6850	3CJO	34	35	77
	X 连锁凋亡抑制蛋白 3	凋亡抑制蛋白 3	100	100	7	5150	三HL5	52	55	88
核受体	ESR1	雌激素受体α	1297	383	136	20685	1 sj0	18	15	67
	MCR	盐皮质激素受体	201	94	2	5150	2AA2	−4	2	36
	泰珠	甲状腺激素受体β-1	246	103	29	7450	一 Q 四 X	36	38	79
	PPARD	过氧化物酶体增殖物激活受体δ	699	240	79	12250	2ZNP	32	20	89
其他酶	FNTA	I 型法尼基转移酶α亚基	1430	592	132	51500	3E37	16	7	76
	组蛋白去乙酰化酶 8	组蛋白去乙酰化酶 8	309	170	73	10450	三楼 07 号	29	24	80
	HIVINT	人类免疫缺陷病毒 1 型整合酶	167	100	268	6650	三NF7	8	2	64
	KITH	胸苷激酶	57	57	68	2850	2 b8t	15	0	80
	PARP1	聚 (ADP - 核糖) 聚合酶 - 1	1031	508	12	30050	3 l3m	25	21	79
	PUR2	GAR 转甲酰酶	50	50	12	2700	1新泽西	51	50	92
蛋白酶	DPP4	二肽基肽酶 IV	1939	533	167	40950	二一七八	41	41	87
	FA10	凝血因子X	3090	537	176	28325	3KL6	39	36	87
	LKHA4	白三烯 A4 水解酶	343	171	21	9450	3 chp	18	4	82
	MMP13	基质金属蛋白酶 13	1632	572	26	37200	830C	12	5	71

针对 102 个靶点中的 57 个，DUD-E 直接使用了 DOCK Blaster⁴² 自动工具链准备的结构。另外 45 个靶点则需要人工干预，多数是因为自动化准备过程中出现的简单错误（例如，金属原子准备不完整、辅因子缺失或非标准氨基酸）。少数几个靶点需要专家干预才能实现适度的富集，比如添加晶体水、改变组氨酸的质子化状态、翻转如天冬酰胺等模棱两可的侧链，或者增加特定残基的局部偶极矩（这是我们经常前瞻性地用于改善极性互补性的技术^{43,44}）。在五个靶点中，我们采用了先前用于前瞻性配体发现的对接准备：腺苷 A_{2A} 受体（AA2AR）、β⁴⁴ 肾上腺素能受体（ADRB1）、AmpC β-内酰胺酶（AMPC）、C-X-C 趋化因子受体 4（CXCR4）、多巴胺 D₃ 受体（DRD3）。⁴⁵

为了增加支架的多样性并构建更小、更易于管理的配体集，我们根据 Bemis–Murcko 原子框架对原始 ChEMBL 配体进行了聚类。³

⁹这些基于原子类型的框架包括分子的环系统和连接的连接体，但不包括任何侧链片段。例如，在驱动蛋白样蛋白 1（KIF11）中，第七大 Murcko 聚类包含 7 个配体，均为结构相近的类似物（图 2A）。如果存在至少 100 种框架，则我们仅从每个框架中选取亲和力和最高的配体。如果框架数量较少，则我们从每个框架中选取更多配体，直至总数超过 100 种，以数量换取多样性。回到驱动蛋白样蛋白 1，我们仅提取了 70 种 Murcko 框架（图 2B）。在 276 种原始配体中，最大的 5 个 Murcko 聚类包含 146 种配体（53%）。从每个框架中选取亲和力和最高的 2 种或 3 种配体，分别得到 98 种和 118 种配体，所以我们决定每个框架选取 3 种配体。在此过程中，我们仍成功从高度冗余的聚类中剔除了 158 种亲和力和较低的化合物。在一些靶点中，即便经过聚类处理，仍有超过 600 种配体存在，因此我们将亲和力阈值依次降低（300、100、30、10 和 3 纳摩尔），直至找到的骨架少于 600 种。例如，在腺苷 A_{2A} 受体中，存在




图2.配体聚类。(A) 动力蛋白样蛋白1 (KIF11) 的第七大 Murcko 聚类, 展示了支架(左)和所有七个成员配体。(B) 70 个 KIF11 Bemis-Murcko 原子框架中每个框架内的配体数量。我们移除了亲和力较低且在某些聚类中过度代表的化合物(位于线之上), 同时保留了 100 个配体。(C) 腺苷 A_{2A} 受体 (AA2AR) Murcko 聚类的数量与亲和力阈值的关系图。使用 30 nM 的亲和力阈值时, 存在的聚类少于 600 个。

在 1 μ M 浓度下, 3096 种原始配体产生了 1099 种框架结构, 但若采用 30 nM 的亲和力阈值, 可将框架结构的数量减少至 483 种(图 2C)。

为了研究聚类对对接富集度的影响, 我们对具有足够配体以从每个 Murcko 聚类中选取一个配体的靶点中, 富集度最高和最低的三个靶点进行了对接。为了衡量对接性能, 我们使用了 LogAUC, 这是一种综合指标, 对早期富集度赋予了更大的权重。如前所述,³¹ LogAUC 与 AUC 完全类似, 只是在对 x 轴取半对数后, 将早期富集度放大了。在富集度最高的靶点—— β 1 型肥大细胞色苷酸酶 (TRYB1) 中, 聚类使 LogAUC 显著降低了 6%, 而在其他五个靶点中, 聚类则提高了 LogAUC (见支持信息表 S2)。六个靶点的平均绝对偏差为 3.7% LogAUC, 但在所有情况

下, 原始和聚类后的 ROC 曲线形状相似(数据未显示)。总体而言, 我们认为聚类后的集合能更好地衡量对接性能, 且对接工作量更小, 因此在本研究的其余部分将使用聚类后的集合。

原 DUD 诱饵的一个关键问题是, 它们有时与配体极为相似, 甚至有时被确认为结合物。从理论上讲, 强制诱饵与配体在二维拓扑结构上不同应能解决这一问题, 但在实践中, 从 ZINC 中选择的诱饵集中往往仍存在关键的配体结合“活性基团”, 例如在因子 Xa (FA10) 中的脒基团。通过在三个目标中识别这些活性基团(图 3A), 我们研究了如何消除假诱饵。在最初的 DUD 中, 使用 CACTVS 指纹选择与配体的 Tanimoto 系数 (T_c) 低于 0.9 的诱饵, 这大致相当于使用 Daylight 指纹时的 T_c 低于 0.7。15 在最近的工作中, 31 我们使用 Daylight 指纹并设置




图 3. 诱饵生成。(A) 来自因子 Xa (FA10)、甘氨酸核糖核苷酸甲酰基转移酶 (PUR2) 和胸苷激酶 (KITH) 的三个关键“弹头”组。(B) 剩余弹头的比例与差异度量方法的关系图。差异度量方法包括指纹 (Daylight 或 ECFP4) 以及硬截止值或保留的最不相似诱饵的比例。(C) 雌激素受体 α (ESR1) 的性质分布, 包括 383 种配体 (蓝色) 和 20685 种性质匹配的诱饵 (红色)。

更严格的 $T_c < 0.5$ 过滤条件。在增强型 DUD 配体集上使用此过滤器, 我们仍分别在因子 Xa (FA10)、甘氨酸核糖核苷酸甲酰基转移酶 (PUR2) 和胸苷激酶 (KITH) 中看到 39%、53% 和 96% 的可能带有战斗部的分子通过 (图 3B)。使用 Daylight 且 $T_c < 0.325$ 时, FA10 战斗部减少到 1% 以下, 但在 PUR2 和 KITH 中仍分别有 14% 和 34%。显然, 不同的靶点甚至不同的配体需要不同的绝对阈值。为解决此问题, 我们针对每个配体移除了相似性最高的一定比例的诱饵分子, 按与任何配体的最大 T_c 值排序。这使得有效绝对阈值能够变化。在 KITH 中, 移除 50% 的 Daylight 诱饵效果更好, 而在 FA10 和 PUR2 中, 移除 50% 的 ECFP4 诱饵效果更好。最终采用 ECFP4 指纹并移除 75% 的诱饵, 剩余战斗部的比例分别为 0.2%、0%

和 5.8%, 大幅减少了假诱饵的数量。在能够定义战斗部的三个靶点上优化了诱饵差异性筛选流程后, 我们将其应用于所有生成的诱饵分子。为了确保生成的诱饵分子在拓扑结构上确实与配体有显著差异, 我们采用了一种部分与拓扑结构无关的度量标准进行比较, 即考察有多少诱饵分子与配体具有相同的支架结构。在 DUD-E 中所有 805136 种诱饵支架结构中, 仅有 692 种 (0.086%) 出现在 25503 种配体支架结构中, 这表明尽管两者物理性质匹配度较高, 但在拓扑结构上仍存在显著差异。

除了减少假诱饵外, DUD-E 诱饵生成程序也经过了全面修订。每个从特定配体衍生出来的诱饵, 其性质范围围绕配体的性质调整为七种可能的宽度。这适应了每个配体周围的局部化学空间, 从而能够生成与配体更匹配的诱饵。此外, 净电荷也被添加到性质匹配中, 因为电荷在静电学中至关重要。

并且去溶剂化。在雌激素受体 α (ESR1) (图 3C) 的属性直方图以及所有目标的平均值和标准偏差 (支持信息表 S3) 中可以看到改进后的属性匹配情况。使用 ZINC⁴⁶ 作为潜在的诱饵库, 使它们能够购买, 从而能够对实际与目标的结合进行实验测试。由于这项工作, 这种增强的诱饵生成程序已完全自动化, 并且可以在 <http://decoys.docking.org> 在线获取, 为任何用户提供的输入配体列表生成 DUD-E 风格的诱饵。

最初的 DUD 论文¹⁵表明, 与随机分子集合相比, 属性匹配的诱饵集对接更具挑战性。因此, 我们将使用属性匹配诱饵集的富集度与使用随机类药背景 (由 ChEMBL12 中亲和力优于 10 μ M 的所有配体组成) 的富集度进行了比较。从类药背景切换到 DUD-E 属性匹配诱饵集, 102 个靶点的平均富集度从 26.8% 降至 24.4% LogAUC (支持信息表 S4)。然而, 对于三个靶点, 属性匹配集却意外地带来了更好的富集度, 提高了超过 15% LogAUC。在谷氨酸受体离子型海人藻酸盐 1 (GRIK1) 和嘌呤核苷磷酸化酶 (PNPH) 中, 配体的分子量较低 (支持信息表 S3), 因此与通常分子量较大的 ChEMBL12 分子相比得分较低, 正如 Verdonk¹⁷ 所指出的那样。在尿激酶型纤溶酶原激活剂 (UROK) 中, 类药对接命中列表的顶部主要由带有脒基“弹头”的诱饵占据。由于这些很可能是结合物, 因此属性匹配富集度的提高是由于该集合中假诱饵数量减少所致。实际上, 切换到属性匹配的诱饵后出现的 2.4% 的 LogAUC 下降源于这两个相互竞争的因素: 诱饵的属性匹配降低了富集度, 而减少假诱饵又提高了富集度。

总体而言, 通过平均 LogAUC 来衡量, DUD-E 的富集度比原始的 DUD 高出 1.5 倍。为了解释这一现象, 我们首先将变化归因于修订后的诱饵生成程序。使用原始 DUD 的配体和靶点准备, 但将诱饵从原始的换成修订后的, 使得 37 个直接可比靶点的平均富集度从 14.8% 的 LogAUC 提升至 19.7% (表 3, 支持信息)

表 3. DUD 与 DUD-E 之间富集变化的分解

渐进式变化	全部原创	新式诱饵	切换到新的配体	切换目标准备
诱饵	哑弹	嘟嘟-E	嘟嘟-E	嘟嘟-E
配体	哑弹	哑弹	嘟嘟-E	嘟嘟-E
受体剂	哑弹	哑弹	哑弹	嘟嘟-E
平均 LogAUC ^a	14.8	19.7	16.4	22.8

^aOver 37 个常见目标 (每个目标的数据见支持信息表 S5)。

表 S5)。采用新的结合净电荷的自适应属性匹配程序后, 原本预期经过修正的诱饵分子会降低富集度, 但实际情况却是总体富集度有所提高。通过检查对接命中列表, 我们发现与配体相似度极高以至于可能实际结合的高分值诱饵分子数量大幅减少。实际上, 我们用于调整差异性程序的三个具有可识别药效团的目标, 其富集度均有显著提升: FA10 从 13% 提升至 28% Lo

gAUC, PUR2 从 40% 提升至 62% LogAUC, KITH 从 1% 提升至 32% LogAUC。如果我们将目标从原始配体和修正后的诱饵分子切换为 DUD-E 中的配体和诱饵分子, 平均富集度则从 19.7% 降至 16.4% LogAUC。我们认为这种下降是由于 DUD-E 中的配体列表更大且更具多样性。最后, 将目标准备过程以及用于代表目标的特定 PDB 结构的选择进行切换, DUD 和 DUD-E 之间的富集度从 16.4% 提升至 22.8% LogAUC (支持信息表 S5)。在 DOCK 3.6 中, 通过去除 SEV 配体的溶剂化作用, 总体效果是使平均富集率从针对 DUD 的 14.8% LogAUC 提升至针对 DUD-E 基准的 22.8% LogAUC。

任何基准测试集的一个核心动机都是至少从回顾的角度来检验新方法。我们想探究一下我们最近提出的基于环境的配体脱溶剂化方法³¹在 DUD-E 基准测试中的表现。因此, 我们用它重新审视了溶剂排除体积 (SEV) 配体脱溶剂化方法与不使用脱溶剂化项 (None) 或使用从水到十六烷的完整转移自由能 (Full) 相比的效用。在我们对 40 个原始 DUD 目标进行的初步研究中, SEV 相对于 None 仅提高了 0.7% 的平均 LogAUC。然而, 在 102 个 DUD-E 目标中, SEV 相对于 None 平均提高了 3.8% 的 LogAUC, None、Full 和 SEV 脱溶剂化方法的平均 LogAUC 值分别为 20.6、14.3 和 24.4%

(图 4, 支持信息表 S4)。尽管存在这些平均趋势, 但针对各个目标的 ROC 曲线在不同方法之间可能会有显著差异 (图 5)。与最初的脱溶剂化分析一样, 某些目标更适合完全脱溶剂化, 例如儿茶酚 O-甲基转移酶 (COMT) 和嘌呤核苷磷酸化酶 (PNPH), 而其他目标则更适合不进行脱溶剂化。例如因子 X (FA10) 和甘氨酸胺核糖核苷酸甲酰基转移酶 (PUR2)。在 DUD-E 基准测试中, SEV 脱溶不仅优于其他方法, 而且在两种类型的靶点上都表现出色。这表明在更全面的靶点集合中, 以及我们所认为的更好的配体和诱饵集合中, SEV 配体脱溶处理在物理上更准确的优势会更加明显。

蛋白质与配体之间的静电相互作用是一个很大的项, 它会阻碍配体的脱溶, 二者之间的相对平衡对于结合至关重要。由于在对接之前我们并不知道潜在配体的结合构象, 所以我们需要近似配体可能占据的低介电常数区域, 以便预先计算静电网格。此前, 我们使用受体的负像 (由 SPHGEN 计算得出) 来构建这一低介电常数区域, 但通常需要手动调整。在 CXCR4 较大的开放结合口袋中, 我们发现仅在蛋白质边缘周围使用一层薄薄的低介电常数层, 就能让配体与之相互作用, 同时减少其大结合口袋中心的介电常数扰动。³ 在此, 我们探索了在整个 DUD-E 数据集中使用自动化的薄介电层策略。从视觉上看, 这些新的自动化薄介电层更符合物理现实, 即使在极少数情况下, 它们实际上比之前的层更厚 (因为水探针能够穿透该层)。采用这些薄的低介电层 (薄层) 后, 102 个目标的平均 LogAUC 从 24.4% 提升至 24.9% (图 4, 支持信息表 S4)。其中 6 个目标使用了人工制备的




图 4. 对比配体脱溶和静电方法的回顾性富集分析。以 DUD-E 数据集为对象，通过 LogAUC 测量对接结果。“None”未采用配体脱溶项，“SEV”采用溶剂排除体积配体脱溶，“Thin”在静电计算中采用薄低介电层。

这些差异并非直接反映自动化介电层之间的差异 (AA2A2、ADRB1、AMPC、CDK2、CXCR4 和 DRD3 层)，排除这六层后，平均差异从 0.5% 提高到了 1.0% 的 LogAUC。诚然，这些差异不算大，但它们表明 DUD-E 可用于测试新的对接方法，并暗示随着对接模型的改进，富集效果将会提升。

在此，我们更详细地介绍三个具有代表性的靶点，以展示 DUD-E 的放大视图。

盐皮质激素受体 (MCR)。在 DUD-E 中，MCR 的富集程度最低。在所有 11 个自动对接结构中，DUD-E 配体相对于其诱饵的富集程度几乎可以忽略不计。因此，我们选择了与原始 DUD 相同的 PDB 结构，即分辨率为 1.95 Å 的 2AA2。尽管使用新的 DUD-E 数据集的富集效果比随机值更差，LogAUC 为 -4%，AUC 为 36% (表 2)，但使用原始 DUD 配体和诱饵时，LogAUC

为 45%，AUC 为 76%。尽管在 DUD-E 中富集效果不佳，但从头构建并对接晶体配体 (忽略晶体学信息) 仍能获得良好的构象一致性 (图 6A)。综合来看，我们可以解释富集差异的原因，因为 15 个原始配体中有 13 个与对接良好的晶体配体共享多环骨架，而 94 个新配体的骨架多样性更大。因此，DUD-E 中富集程度的降低反映了由于纳入更多配体并根据 Bemis-Murcko 原子框架对其进行聚类而导致的化学类型多样性增加。在 DUD-E 中富集程度最低四个靶点中，有三个是核激素受体，即盐皮质激素受体 (MCR)、糖皮质激素受体 (GCR) 和雄激素受体 (ANDR)。这些受体都有疏水性口袋，其结合位点的残基 (如甲硫氨酸和亮氨酸) 具有一定的灵活性，因此单个刚性受体可能无法与所有配体对接。因此，这些靶点可能是检验受体柔性对接方法的良好测试对象。

甲状腺激素受体 $\beta 1$ (THB)。当具有开放亚口袋的结构出现时，THB 能够实现良好的富集。




图 5. 具有代表性的 ROC 曲线。使用无脱溶 (None)、溶剂排除体积配体脱溶 (SEV)、薄低介电层 (Thin) 或由所有 ChEMBL12 数据库中亲和力优于 $10\ \mu\text{M}$ 的配体构成的药物样背景 (Drug-like) 绘制的 ROC 曲线。黑色虚线代表随机对接配体所预期的结果。图例文本中报告了 LogAUC 百分比。

所选的 16 个自动对接结构的富集度差异显著, 从 13% (1NQ0) 到 37% LogAUC (1Q4X) 不等。富集度较低的结构在精氨酸 320 附近 (图 6B 右侧) 有较大的空腔, 与溶剂相通; 富集度较高的结构在结合位点的另一端 (左侧) 靠近甲硫氨酸 420 处有较大的空腔, 与溶剂相通。尽管 1Q4X 的分辨率仅为 2.80 埃, 但其晶体配体将苏氨酸 273 推离, 使左侧的亚口袋更大, 因此我们选择了其自动准备。使用 SEV 脱溶处理后, 富集度统计值为 3

6% LogAUC、79% AUC, 以及基于受试者工作特征曲线的 1% (EF_1) 富集因子为 38 (表 2)。重新对接的晶体配体具有极佳的构象一致性 (图 6B)。

丝氨酸/苏氨酸蛋白激酶 AKT (AKT1)。AKT1 是新添加的一种激酶, 在选择 PDB 结构时存在一些考量。虽然自动对接了 10 个 PDB 结构, 但有 4 个的富集效果比随机情况还差。这 4 个结构均对应的是 Pleckstrin 同源结构域 (PH 结构域), 而非激酶结构域。这




图 6. 具有代表性的对接构象。从头重建并对接了晶体配体。(A - F) 将晶体构象(洋红色)与对接所得构象(绿色)进行比较。在(C)中, 生成了更多的配体构象, 并且还展示了重新对接的构象(棕褐色)。关键氢键以黑色虚线表示, 部分透明的蛋白质表面按原子类型着色。

具有最佳正常 AUC 值 (3096) 的结构对应于 PH 结构域和激酶结构域交界处的别构位点, 而非传统的 ATP 结合口袋。而通过 LogAUC 值 (2.00 A) 表现最佳的富集结构 3CQW 对应的是典型位点, 但其非标准的磷酸苏氨酸氨基酸使自动化协议失效。手动准备该残基后, 可获得 27% 的 LogAUC 值、72% 的 AUC 值和 29 EF₁ (表 2)。然而, 重新对接的配体(绿色)未能生成晶体配体构象(品红色)(图 6C)。不过, 该配体体积较小, 仅有一个中心可旋转键, 需要围绕该键进行特定旋转才能适配结合位点。降低配体构象生成的均方根偏差阈值, 可使该旋转得以采样, 从而恢复正确的配体结合构象(棕褐色)(图 6C)。

讨论

对接研究目前仍通过前瞻性研究中的命中率以及回顾性研究中的富集度来评判, 因为现在它无法计算亲和力, 甚至无法确定单调排序。因此, 就像蛋白质结构预测一样, 对接研究仍是一个经验性的领域, 尽管我们认为它也是一个实用的领域。对接研究对富集度的依赖推动了基准测试集的发展, 这一领域最早由 Rognan 和 Jain 探索,¹²最近由 Boeckler 和 Cavasotto 进行了研究;³⁴其中使用最广泛且被引用最多的是“有用诱饵目录”

(DUD)。¹⁵尽管 DUD 被广泛采用, 但它仍存在严重缺陷, 包括配体多样性不足、与净电荷的性质匹配度低以及存在大量假诱饵。本文所描述的增强版 DUD (DUD-E) 旨在解决这些问题, 并扩大目标列表, 使其更能代表药理学相关的空间。

平衡配体和诱饵以实现富集。DUD 存在一个重要问题, 源于最初选择的配体和诱饵。前者有时在少数化学类型中过度代表, 而后者有时并非诱饵, 而是实际的配体。此外, 在发布的数据集中, 特定配体与其匹配诱饵的对应关系已丢失。在构成 DUD-E 的 102 个配体和诱饵集中, 任何给定集合中的

配体多样性显著增加, 从而减少了因单一化学类型排名过高而产生的偏差。每个靶点至少有 40 个配体, 并且倾向于最大化化学类型多样性, DUD-E 使得对接筛选的代表性测试更具代表性。相应地, 为每个配体单独匹配性质匹配的诱饵, 同时更严格地去除假诱饵(即配体), 使研究人员能够直接将特定配体与其诱饵分子匹配, 并减少了 DUD 中某些靶点人为造成的低富集度。在 DUD 中, 将净电荷作为属性来匹配配体和诱饵分子, 解决了两者之间存在的差异, 即配体的平均净电荷往往高于诱饵分子, 这导致了我们对诸如脱溶作用等物理力的评估出现偏差。

这些变化对接性能的影响是显著且明确的。在排除其他影响因素的情况下, 为实现多样性而对配体进行聚类会降低富集度, 这在预料之中, 因为表现优异且过度代表的配体集已被大量移除。相反, 新的诱饵分子与 DUD 相比提高了富集度。起初这似乎有悖常理, 因为人们会认为更平衡、更严格的诱饵分子集会对对接程序构成更大挑战。然而, 这被移除那些原本是虚假诱饵分子(配体)所带来的好处所抵消, 这些虚假诱饵分子作为配体时往往排名较高, 但作为诱饵分子时却稀释了已标注的配体, 从而在 DUD 中人为地降低了富集度。最后, 从针对 3500 多种结构的对接活动中精心挑选出的新靶点准备也提高了富集度。总体而言, DUD-E 中富集度的提高应能为对接算法的基准测试提供更高的灵敏度, 使其对降低富集度的改进以及提高富集度的改进都更具响应性。

用于自动生成更多配体和诱饵集的在线工具。DUD-E 被设计成一个更出色的平台, 用于配体和诱饵集的优化和扩展。各靶点的配体和诱饵彼此独立, 允许添加、删除或替换靶点。用于生成 DUD-E 诱饵的协议已在线提供, 仅需提供靶点列表即可生成任何靶点的诱饵。

配体结构,这使得研究人员能够将 DUD-E 扩展到新的感兴趣靶点。诱饵服务器直接从可购买的 ZINC 数据库子集获取数据,从而继承其改进和购买更新。⁴⁶从适用的诱饵池中最终选择诱饵时,在可能的情况下是随机的,这允许生成多个诱饵集以测试对标准 DUD-E 诱饵的过拟合情况。每个诱饵仅属于一个配体,因此如果要过滤某个配体,则可以轻松删除相应的诱饵。例如,我们提供了在通过 Bemis-Murcko 原子框架进行聚类之前未经处理的配体和诱饵集。如果需要使用不同的聚类方法,从而选择原始配体的不同子集,那么相应的诱饵可以保留(此外,我们还提供了用于从原始集生成聚类子集的 python 脚本)。我们还提供了额外的数据,以便对某些设计决策进行更改,例如,我们包含了活性高于我们 1 μM 截止值的边缘配体。

对接优化与测试的应用。ddu-e 应该为探索新的对接方法提供更健壮的基础测试集,因此我们非常希望将它与我们一直在研究的新方法进行测试。当对旧的 DUD 组进行测试时,我们发现一种新的溶剂排除体积(SEV)配体脱溶方法对富集的影响小得令人失望,尽管它显然是一个更好的物理模型。然而,当对 ddu-e 基准进行测量时,新旧方法之间的差异性能大大增加,有利于后者。同样,对于 DUD-e 基准,用于从静态泊松-玻尔兹曼映射中计算静电相互作用项的物理上更真实的介电层也导致了 DUD 集中由于上述问题而在很大程度上被掩盖的改进的富集。

需要提出几点注意事项。最重要的是,DUD-E 是从多个源数据库合成的一个大型数据集,每个源数据库都在不断演进和改进。因此,出现个别错误在所难免,不过通常都能追溯到构建 DUD-E 时的源数据库。尽管我们仅展示了使用 DOCK 3.6 并采用溶剂排除体积配体脱溶处理的对接结果,但 DUD-E 的设计初衷是作为一个通用的基准测试集。因此,在努力提供一个可用于比较对接算法的规范数据集的过程中,我们做出了一些任意的选择和简化假设。例如,我们假定一个 PDB 编码就能代表目标,但有些目标具有高度的灵活性,或者同时包含正构和变构结合口袋。从根本上说,DUD 和 DUD-E 的设计目的是衡量三维方法相对于简单的一维分子属性的筛选性能提升。通过二维配体相似性去除可能结合的诱饵分子,因此 DUD-E 不适合用于测试二维方法。在构建过程中,使用这些二维相似性方法,配体相对于 DUD-E 诱饵分子呈现出明显的富集优势,从而造成了人为的有利偏差。最后需要提醒的是,为了在 DUD-E 中过滤掉更多的假诱饵分子,我们仅保留了四分之一的差异最大的假诱饵分子。然而,虽然我们表明这种差异性的增加能够去除假诱饵分子,但它也可能导致对接富集度的人为提升。

尽管存在这些限制,DUD-E 相较于最初的 DUD 已有了显著改进。它是一个规模更大、多样性更强的数据集,其中的诱饵分子与配体的相似度更低,从而纠正了其前身存

在的诸多缺陷。尽管我们预计它在此处所描述的这种形式下会被最广泛地使用,但开发时就考虑到了其能够灵活扩展和演进;甚至还在网上提供了相关工具(<http://dude.docking.org>)。我们希望它及其后续版本能够为社区内的对接评估提供有用的工具,直到能够对对接性能进行更根本的衡量为止。

■ 方法

ChEMBL 和 RCSB PDB 数据提取。这个增强版的 DUD 数据库是通过整合来自 ChEMBL³⁸ 的配体数据和来自 RCSB PDB³⁹ 的结构数据构建而成的(支持信息图 S1A)。从 ChEMBL09 数据库中提取了与蛋白质靶点(ChEMBL 置信度得分 ≥ 4)的亲合力(IC₅₀, EC₅₀, EC₅₀, EC₅₀及其对数形式)为 1 μM 或更好的配体。³⁸同样,我们将亲合力在 30 μM 或更高(仅大于关系)且无法测量的分子指定为实验性诱饵。亲合力高于 1 μM 的其余配体以及亲合力低于 30 μM 且无法测量的诱饵分子也包含在内,以保证完整性,并被统称为“边缘”分子。通过 ChEMBL,配体通过 UniProt⁴⁰ 访问代码与特定的靶点序列相关联,然后使用 2011 年 2 月 23 日获取的 <http://www.uniprot.org/docs/pdbtosp.txt> 文件将 UniProt 访问代码映射⁴¹到蛋白质数据银行(PDB)结构(仅限 X 射线)。

目标选择对接。对每个映射到 ChEMBL 配体且包含单一明确共晶配体的 PDB 结构,使用 DOCK Blaster 进行了初步对接计算。⁴²通过以下自动化诱饵生成程序,利用 Daylight 指纹并设置 Tanimoto 系数(T_i)阈值低于 0.5,生成了与属性匹配的计算诱饵。这些诱饵通过 DOCK 3.6 进行对接,并与它们对应的配体进行比较,采用溶剂排除体积(SEV)配体脱溶处理。³¹为了平衡多样性、药物相关性、大量配体和结构以及至少适度的自动化对接富集等并行目标,我们为新的 DUD 选定了 119 个暂定目标。通过诸如配体和 PDB 在不同目标间重复(例如,FNTB 重复 FNTA)、低分辨率结构(RAF1)、空间受限的结合位点(NR1H2、THA)或过度代表(MK08、MTOR)等因素,将此列表缩减至最终的 102 个目标。

目标准备。对于每个目标,我们收集了所有具有任何原始 ChEMBL 化合物(配体、诱饵、边缘配体或边缘诱饵)的 UniProt 登录号(物种)。仅针对这些登录号,通过 ChEMBL 到 PDB 的映射提取结构,但手动将 P07700 添加到 ADRB1 中,以包含该 GPCR 的另外六个罕见结构。此过程忽略了属于没有从 ChEMBL 提取任何原始化合物的登录号的 PDB 结构。例如,1KIM 是原始 DUD 中胸苷激酶(KITH)的 PDB 结构。该 KITH 结构来自疱疹病毒(UniProt P03176),其登录号没有从 ChEMBL 提取任何原始化合物,因此未包含在用于构建新 DUD 的 ChEMBL/PDB 交集中。不过,仍有 5025 个 PDB 编码被发送到更新的 DOCK Blaster 管道进行自动对接准备(支持信息图 S1D)。在某些情况下,无法找到明确的配体来指示结合位点,但我们通过手动检查超过 1300 个结构,成功分配了另外 565 个配体。最终,3692 个结构完成了输入网格准备,除两个之外,其余均完成了对接和富集分析。使用 ECFP4 指纹将聚类后的配体集对接到属性匹配的诱饵分子(如下所述),并移除查询诱饵分子中相似度最高的 75%。使用 DOCK 3.6 进行对接,采用 SEV 配体脱溶剂(如下所述)。对于每个靶点,收集富集度、分辨率和生物体信息,并按富集度在 `pdb_analyze.txt` 中排序,该文件可在线获取,网址为 <http://dude.docking.org>。选择过程的粗略记录在 `pdb_selection.txt` 中,所选结构列于 `pdb_blessed.txt` 中。AA2AR 和 DRD3 的对接准备由 Jens Carlson 提供,^{44,45} CXCR4 部分由 Dahlia Weiss 提供,³ ADRB1 由 Peter Kolb 提供(个人交流),AMPC 由 Sarah Barelier、Oliv Eidam 和 Inbar Fish 提供(未发表结果)。

配体准备。为每个靶点准备配体集时，首先将 ChEMBL 亲和力和 log 变体归一化为 nM 单位（支持信息图 S1B）。去除盐类，标准化电荷，并使用 Molinspiration 的 mib 软件包计算属性（www.molinspiration.com）。去除分子量大于或等于 600 Da 或具有 20 个或更多可旋转键的配体。使用 OpenEye 的 OEChem 软件将 Smiles 转换为规范形式。⁴⁸将每个物种的配体集合并，按归一化亲和力升序排列，然后根据规范 Smiles 去除重复项。对于实验性诱饵、边缘配体和边缘诱饵，也采用相同的程序进行整理。对于 AmpC β -内酰胺酶（AMPC），这是一个原始的 DUD 靶点，ChEMBL09 配体本质上是共价的。为了识别非共价配体，我们手动从文献中收集了亲和力低于 5 mM 的配体^{6,43,49}和实验性诱饵^{43,51}。

配体聚类。为了将 ChEMBL 配体的数量减少到可管理的规模，同时增加支架多样性，正如 Good 和 Oprea 所建议的那样，²⁷我们根据 Molinspiration 的 mib 生成的 Bemis-Murcko 原子框架对配体进行了聚类。如果存在 100 个或更多的框架，我们仅从每个框架中选择亲和力最高的配体。如果 Murcko 框架少于 100 个，则从每个框架中增加亲和力最高的配体数量，直到达到至少 100 个配体（或直到所有配体都被包含）。相反，如果存在超过 600 个 Murcko 框架，则按照 [1 μ M、300 nM、100 nM、30 nM、10 nM、3 nM] 的顺序依次降低配体亲和力阈值，直到框架数量少于 600 个，然后从每个框架中选择亲和力最高的配体。虽然聚类配体集是默认设置，但完整的未聚类配体集和相应的诱饵也是可用的。用于根据配体 ID 选择聚类子集脚本（subset_decoys.py）与完整的配体集一起提供，以便可以替换其他聚类算法或过滤方法。

自动化诱饵生成。与原始的 DUD 一样，我们使用分子量、估计的水-辛醇分配系数（miLogP）、可旋转键、氢键受体和氢键供体等属性将诱饵与配体进行匹配，此外还增加了净电荷。我们使用 Schrödinger 的 Epik 软件在 pH 值 6 - 8 范围内生成所有配体的质子化状态，使用参数为“-ph 7.0 -pht 1.0 -tp 0.20”（支持信息图 S1C）。然后使用 Molinspiration 的 mib 计算分子属性。对于给定配体的所有质子化形式，我们仅保留具有独特六种物理化学属性集的那些。对于每个独特的属性集，我们旨在生成 50 个匹配的诱饵。例如，一个输入配体预测具有两种不同的电荷，将为每种电荷生成 50 个属性匹配的诱饵。为了实现这一目标，从 ZINC 数据库中选择诱饵池，采用动态协议，通过围绕六个属性在七个步骤中缩小或扩大窗口来适应局部化学空间。目标是返回 3000 - 9000 个与诱饵参考质子化状态（预测在 pH 7.05 时最常见的形式）匹配的潜在诱饵。在最终的诱饵筛选过程中，Scitegic 的 Pipeline Pilot 软件为配体和潜在诱饵生成了 ECFP4 指纹。根据诱饵与任何配体的最大 T_c 值对其进行排序，并通过这种差异性筛选保留了差异最大的 25%。然后，我们通过将诱饵从重复次数最少到最多进行排序，从配体集中去除重复的诱饵，并将每个诱饵分配给已分配诱饵数量最少的质子化配体。这样可以确保独特的诱饵尽可能均匀地分布在配体中。最后，如果可用，从这个去重后的列表中随机选取 50 个诱饵。

原始 DUD 对比。对于原始 DUD 对比，我们从 dud.docking.org 下载了配体和诱饵，并使用我们现代的 ZINC 工具链准备了对接柔性基底。⁴⁶原始 DUD 目标准备是原始版本的复制品，经过修改以执行先前所述的 SEV 脱溶计算。³¹我们还为原始 DUD 配体生成了 DUD-E 风格的自动化诱饵和柔性基底。分析是在 37 个直接可比的目标上进行的，不包括原始目标 PDGFr β 、ER α agonist 和 ER antagonist。

对接计算。除非另有说明，对接计算均使用 DOCK 3.6 进行，并采用先前所述的溶剂排除体积（SEV）配体脱溶剂化方法。³¹配体构象由 OpenEye 的 Omega 生成。³¹采样时，将图匹配节点的最小数量更改为 3，配体重叠更改为 0.1。配体被限制在 5 至 100 个重原子之间。单个配体层次结构的超时时间为 180 秒。我们进行了 200 步单纯形最小化，初始平移为 0.2 埃，初始旋转为 5°。通过沿每个 DMS（http://www.cgl.ucsf.edu/Overview/ftp/dms.zip）表面法线向外移动 1.8 埃并放置一个球体来创建薄介电层 Delphi 球体。然后将此薄球体层用作 makespheres1.pl 的输入，以替代通常的 SPHGEN 球体。随机背景计算使用 SEV 脱溶剂化进行，将 DUD-E 配体播种到整个 ChEMBL12_10 的 ZINC 子集，其中包括 273375 个注释亲和力低于 10 μ M 的配体。

对接指标。受试者工作特征曲线（ROC）下的面积（AUC）是衡量对接性能的一种常见指标。然而，ROC 曲线图通常会对 x 轴进行半对数变换，以便放大早期的变化。如前所述，³¹对数 AUC 在这种变换空间中与 AUC 完全类似，用于测量曲线下的单位面积百分比。正式地，我们在此使用调整后的 LogAUC_{0.001}，它跨越三个数量级的对数空间，并减去随机曲线的对数 AUC（14.462%），从而使随机富集率为 0%。我们通常将调整后的 LogAUC_{0.001} 称为调整后的对数 AUC 或简称为对数 AUC。基于 ROC 的 1% (EF₁) 富集因子是指在找到 1% 的诱饵时找到的配体百分比，它优于传统的富集因子。⁵³

■ 相关内容

* 支持性信息

图示展示了 DUD-E 工作流程，而表格则提供了详细的目标数据，制表符分隔的文本文件则提供了原始数据。这些材料可通过互联网免费获取，网址为 http://pubs.acs.org。

■ 作者信息

通讯作者

致 J.J.I.: 电话: (415) 514-4127; 电子邮箱: jji@cgl.ucsf.edu. 致 B.K.S.: 电话: (415) 514-4126; 电子邮箱: shoichet@cgl.ucsf.edu. 地址: 约翰·J·欧文或布莱恩·K·肖伊切特, 加利福尼亚大学旧金山分校药物化学系, 旧金山市第四街 1700 号 2550 号信箱, 邮编: 94158-2330。

笔记

作者声明不存在任何利益冲突。

■ 致谢

本研究由美国国立卫生研究院（NIH）资助项目 GM71896（资助对象：J.J.I. 和 B.K.S.）。我们感谢安德鲁·古德（Andrew Good）的讨论，这促成了 DUD-E 的诞生。我们感谢蒂格·斯特林（Teague Sterling）的网站开发工作以及苏尼尔·库瓦卡特（Sunil Koovakkat）对 DOCK 的错误修复。我们对支持 ZINC 和诱饵生成工具链的商业软件供应商表示感谢：斯洛伐克布拉迪斯拉发的 Molinspiration 公司提供的 mib 软件，新墨西哥州圣达菲的 OpenEye 科学软件公司提供的 OEChem、Omega 和 QuacPac 软件，德国埃尔兰根的 Molecular Networks 公司提供的 Corina 软件，加利福尼亚州圣地亚哥的 Accelrys 公司提供的 Pipeline Pilot 软件，以及匈牙利布达佩斯的 ChemAxon 公司提供的 cxcalc 软件。我们感谢奥利弗·艾达姆（Oliv Eidam）、马修·梅尔斯基（Matthew Merski）和尼尔·伦敦（Nir London）审阅了本手稿。

■ 所用缩略语

DUD, 有用诱饵目录; DUD-E, 增强型有用诱饵目录; EF₁, ROC 曲线 1% 处的富集因子

曲线; PH, 普列克斯特林同源结构域; ROC, 受试者工作特征曲线; SEV, 溶剂可排除体积; T_c, 塔尼莫托系数

■ 参考文献

- (1) Kitchen, D. B.; Decornez, H.; Furr, J. R.; Bajorath, J. Docking and scoring in virtual screening for drug discovery: methods and applications. *Nature Rev. Drug Discovery* 2004, 3, 935–949.
- (2) Kolb, P.; Rosenbaum, D. M.; Irwin, J. J.; Fung, J. J.; Kobilka, B. K.; Shoichet, B. K. Structure-based discovery of beta(2)-adrenergic receptor ligands. *Proc. Natl. Acad. Sci. U.S.A.* 2009, 106, 6843–6848.
- (3) Mysinger, M. M.; Weiss, D. R.; Ziarek, J. J.; Gravel, S.; Doak, A. K.; Karpiak, J.; Heveker, N.; Shoichet, B. K.; Volkman, B. F. Structure-based ligand discovery for the protein–protein interface of chemokine receptor CXCR4. *Proc. Natl. Acad. Sci. U.S.A.* 2012, 109, 5517–5522.
- (4) Gruneberg, S.; Stubbs, M. T.; Klebe, G. Successful virtual screening for novel inhibitors of human carbonic anhydrase: strategy and experimental confirmation. *J. Med. Chem.* 2002, 45, 3588–3602.
- (5) Jain, A. N.; Nicholls, A. Recommendations for evaluation of computational methods. *J. Comput.-Aided Mol. Des.* 2008, 22, 133–139.
- (6) Babaoglu, K.; Simeonov, A.; Irwin, J. J.; Nelson, M. E.; Feng, B.; Thomas, C. J.; Cancian, L.; Costi, M. P.; Maltby, D. A.; Jadhav, A.; Ingles, J.; Austin, C. P.; Shoichet, B. K. Comprehensive mechanistic analysis of hits from high-throughput and docking screens against beta-lactamase. *J. Med. Chem.* 2008, 51, 2502–2511.
- (7) Ferreira, R. S.; Simeonov, A.; Jadhav, A.; Eidam, O.; Mott, B. T.; Keiser, M. J.; McKerrow, J. H.; Maloney, D. J.; Irwin, J. J.; Shoichet, B. K. Complementarity between a docking and a high-throughput screen in discovering new cruzain inhibitors. *J. Med. Chem.* 2010, 53, 4891–4905.
- (8) Gohlke, H.; Klebe, G. Approaches to the description and prediction of the binding affinity of small-molecule ligands to macromolecular receptors. *Angew. Chem., Int. Ed. Engl.* 2002, 41, 2644–2676.
- (9) Enyedy, I. J.; Egan, W. J. Can we use docking and scoring for hit-to-lead optimization? *J. Comput.-Aided Mol. Des.* 2008, 22, 161–168.
- (10) Stahl, M.; Rarey, M. Detailed analysis of scoring functions for virtual screening. *J. Med. Chem.* 2001, 44, 1035–1042.
- (11) Bissantz, C.; Folkers, G.; Rognan, D. Protein-based virtual screening of chemical databases. 1. Evaluation of different docking/ scoring combinations. *J. Med. Chem.* 2000, 43, 4759–4767.
- (12) Pham, T. A.; Jain, A. N. Parameter estimation for scoring protein–ligand interactions using negative training data. *J. Med. Chem.* 2006, 49, 5856–5868.
- (13) Kellenberger, E.; Rodrigo, J.; Muller, P.; Rognan, D. Comparative evaluation of eight docking tools for docking and virtual screening accuracy. *Proteins* 2004, 57, 225–242.
- (14) Ferrara, P.; Gohlke, H.; Price, D. J.; Klebe, G.; Brooks, C. L., III. Assessing scoring functions for protein–ligand interactions. *J. Med. Chem.* 2004, 47, 3032–3047.
- (15) Huang, N.; Shoichet, B. K.; Irwin, J. J. Benchmarking sets for molecular docking. *J. Med. Chem.* 2006, 49, 6789–6801.
- (16) Christofferson, A. J.; Huang, N. How to benchmark methods for structure-based virtual screening of large compound libraries. In *Computational Drug Discovery and Design (Methods in Molecular Biology)*; 2011/12/21 ed.; Baron, R., Ed.; Springer Protocols: New York, 2012; Vol. 819, Chapter 13, pp 187–195.
- (17) Verdonk, M. L.; Berdini, V.; Hartshorn, M. J.; Mooij, W. T.; Murray, C. W.; Taylor, R. D.; Watson, P. Virtual screening using protein–ligand docking: avoiding artificial enrichment. *J. Chem. Inf. Comput. Sci.* 2004, 44, 793–806.
- (18) Kuntz, I. D.; Chen, K.; Sharp, K. A.; Kollman, P. A. The maximal affinity of ligands. *Proc. Natl. Acad. Sci. U.S.A.* 1999, 96, 9997–10002.
- (19) Fan, H.; Irwin, J. J.; Webb, B. M.; Klebe, G.; Shoichet, B. K.; Sali, A. Molecular Docking Screens Using Comparative Models of Proteins. *J. Chem. Inf. Model.* 2009, 49, 2512–2527.
- (20) Repasky, M. P.; Murphy, R. B.; Banks, J. L.; Greenwood, J. R.; Tubert-Brohman, I.; Bhat, S.; Friesner, R. A. Docking performance of the glide program as evaluated on the Astex and DUD datasets: a complete set of glide SP results and selected results for a new scoring function integrating WaterMap and glide. *J. Comput.-Aided Mol. Des.* 2012, DOI: 10.1007/s10822-012-9575-9.
- (21) Brozell, S. R.; Mukherjee, S.; Balias, T. E.; Roe, D. R.; Case, D. A.; Rizzo, R. C. Evaluation of DOCK 6 as a pose generation and database enrichment tool. *J. Comput.-Aided Mol. Des.* 2012, DOI: 10.1007/s10822-012-9565-y.
- (22) Neves, M. A.; Totrov, M.; Abagyan, R. Docking and scoring with ICM: the benchmarking results and strategies for improvement. *J. Comput.-Aided Mol. Des.* 2012, DOI: 10.1007/s10822-012-9547-0.
- (23) Spitzer, R.; Jain, A. N. Surflex-Dock: docking benchmarks and real-world application. *J. Comput.-Aided Mol. Des.* 2012, DOI: 10.1007/s10822-011-9533-y.
- (24) Schneider, N.; Hindle, S.; Lange, G.; Klein, R.; Albrecht, J.; Briem, H.; Beyer, K.; Claussen, H.; Gastreich, M.; Lemmen, C.; Rarey, M. Substantial improvements in large-scale redocking and screening using the novel HYDE scoring function. *J. Comput.-Aided Mol. Des.* 2011, DOI: 10.1007/s10822-011-9531-0.
- (25) Liebeschuetz, J. W.; Cole, J. C.; Korb, O. Pose prediction and virtual screening performance of GOLD scoring functions in a standardized test. *J. Comput.-Aided Mol. Des.* 2012, DOI: 10.1007/s10822-012-9551-4.
- (26) Novikov, F. N.; Stroylov, V. S.; Zeifman, A. A.; Stroganov, O. V.; Kulkov, V.; Chilov, G. G. Lead Finder docking and virtual screening evaluation with Astex and DUD test sets. *J. Comput.-Aided Mol. Des.* 2012, DOI: 10.1007/s10822-012-9549-y.
- (27) Good, A. C.; Oprea, T. I. Optimization of CAMD techniques 3. Virtual screening enrichment studies: a help or hindrance in tool selection? *J. Comput.-Aided Mol. Des.* 2008, 22, 169–178.
- (28) Mackey, M. D.; Melville, J. L. Better than random? The chemotype enrichment problem. *J. Chem. Inf. Model.* 2009, 49, 1154–1162.
- (29) Hawkins, P. C.; Warren, G. L.; Skillman, A. G.; Nicholls, A. How to do an evaluation: pitfalls and traps. *J. Comput.-Aided Mol. Des.* 2008, 22, 179–190.
- (30) Irwin, J. J. Community benchmarks for virtual screening. *J. Comput.-Aided Mol. Des.* 2008, 22, 193–199.
- (31) Mysinger, M. M.; Shoichet, B. K. Rapid context-dependent ligand desolvation in molecular docking. *J. Chem. Inf. Model.* 2010, 50, 1561–1573.
- (32) Vogel, S. M.; Bauer, M. R.; Boeckler, F. M. DEKOIS: demanding evaluation kits for objective in silico screening—a versatile tool for benchmarking docking programs and scoring functions. *J. Chem. Inf. Model.* 2011, 51, 2650–2665.
- (33) Wallach, I.; Lilien, R. Virtual decoy sets for molecular docking benchmarks. *J. Chem. Inf. Model.* 2011, 51, 196–202.
- (34) Gatica, E. A.; Cavasotto, C. N. Ligand and decoy sets for docking to G protein-coupled receptors. *J. Chem. Inf. Model.* 2012, 52, 1–6.
- (35) Cereto-Massague, A.; Guasch, L.; Valls, C.; Mulero, M.; Pujadas, G.; Garcia-Vallve, S. DecoyFinder: an easy-to-use python GUI application for building target-specific decoy sets. *Bioinformatics* 2012, 28, 1661–1662.
- (36) Rohrer, S. G.; Baumann, K. Maximum unbiased validation (MUV) data sets for virtual screening based on PubChem bioactivity data. *J. Chem. Inf. Model.* 2009, 49, 169–184.
- (37) Ripphausen, P.; Wassermann, A. M.; Bajorath, J. REPROVIS-DB: a benchmark system for ligand-based virtual screening derived from reproducible prospective applications. *J. Chem. Inf. Model.* 2011, 51, 2467–2473.
- (38) Gaulton, A.; Bellis, L. J.; Bento, A. P.; Chambers, J.; Davies, M.; Hersey, A.; Light, Y.; McGlinchey, S.; Michalovich, D.; Al-Lazikani, B.; Overington, J. P. ChEMBL: a large-scale bioactivity database for drug discovery. *Nucleic Acids Res.* 2012, 40, D1100–1107.
- (39) Bemis, G. W.; Murcko, M. A. The properties of known drugs. 1. Molecular frameworks. *J. Med. Chem.* 1996, 39, 2887–2893.

- (40) Berman, H. M.; Westbrook, J.; Feng, Z.; Gilliland, G.; Bhat, T. N.; Weissig, H.; Shindyalov, I. N.; Bourne, P. E. The Protein Data Bank. *Nucleic Acids Res.* 2000, 28, 235–242.
- (41) Apweiler, R.; Bairoch, A.; Wu, C. H.; Barker, W. C.; Boeckmann, B.; Ferro, S.; Gasteiger, E.; Huang, H.; Lopez, R.; Magrane, M.; Martin, M. J.; Natale, D. A.; O'Donovan, C.; Redaschi, N.; Yeh, L. S. UniProt: The Universal Protein Knowledgebase. *Nucleic Acids Res.* 2004, 32, D115–D119.
- (42) Irwin, J. J.; Shoichet, B. K.; Mysinger, M. M.; Huang, N.; Colizzi, F.; Wassam, P.; Cao, Y. Automated docking screens: a feasibility study. *J. Med. Chem.* 2009, 52, 5712–5720.
- (43) Powers, R. A.; Morandi, F.; Shoichet, B. K. Structure-based discovery of a novel, noncovalent inhibitor of AmpC beta-lactamase. *Structure* 2002, 10, 1013–1023.
- (44) Carlsson, J.; Yoo, L.; Gao, Z. G.; Irwin, J. J.; Shoichet, B. K.; Jacobson, K. A. Structure-based discovery of A2A adenosine receptor ligands. *J. Med. Chem.* 2010, 53, 3748–3755.
- (45) Carlsson, J.; Coleman, R. G.; Setola, V.; Irwin, J. J.; Fan, H.; Schlessinger, A.; Sali, A.; Roth, B. L.; Shoichet, B. K. Ligand discovery from a dopamine D3 receptor homology model and crystal structure. *Nature Chem. Biol.* 2011, 7, 769–778.
- (46) Irwin, J. J.; Shoichet, B. K. ZINC—a free database of commercially available compounds for virtual screening. *J. Chem. Inf. Model.* 2005, 45, 177–182.
- (47) Velankar, S.; McNeil, P.; Mittard-Runte, V.; Suarez, A.; Barrell, D.; Apweiler, R.; Henrick, K. E-MSD: an integrated data resource for bioinformatics. *Nucleic Acids Res.* 2005, 33, D262–265.
- (48) Hawkins, P. C.; Skillman, A. G.; Nicholls, A. Comparison of shape-matching and docking as virtual screening tools. *J. Med. Chem.* 2007, 50, 74–82.
- (49) Teotico, D. G.; Babaoglu, K.; Rocklin, G. J.; Ferreira, R. S.; Giannetti, A. M.; Shoichet, B. K. Docking for fragment inhibitors of AmpC beta-lactamase. *Proc. Natl. Acad. Sci. U.S.A.* 2009, 106, 7455–7460.
- (50) Tondi, D.; Morandi, F.; Bonnet, R.; Costi, M. P.; Shoichet, B. K. Structure-based optimization of a non-beta-lactam lead results in inhibitors that do not up-regulate beta-lactamase expression in cell culture. *J. Am. Chem. Soc.* 2005, 127, 4632–4639.
- (51) Graves, A. P.; Brenk, R.; Shoichet, B. K. Decoys for docking. *J. Med. Chem.* 2005, 48, 3714–3728.
- (52) Hawkins, P. C.; Skillman, A. G.; Warren, G. L.; Ellingson, B. A.; Stahl, M. T. Conformer generation with OMEGA: algorithm and validation using high quality structures from the Protein Data Bank and Cambridge Structural Database. *J. Chem. Inf. Model.* 2010, 50, 572–584.
- (53) Jain, A. N. Bias, reporting, and sharing: computational evaluations of docking methods. *J. Comput.-Aided Mol. Des.* 2008, 22, 201–212.