

GEFA: 药物-靶点亲和力预测中的早期融合方法

Tri Minh Nguyen^{ID}, Thin Nguyen^{ID}, Thao Minh Le^{ID}, and Truyen Tran^{ID}

摘要 - 预测化合物与靶点之间的相互作用对于快速药物再利用至关重要。深度学习已成功应用于药物 - 靶点亲和力 (DTA) 问题。然而, 先前基于深度学习的方法忽略了对药物与蛋白质残基之间直接相互作用的建模。这会导致对靶点表示的学习不准确, 因为靶点表示可能会因药物结合效应而发生变化。此外, 先前的 DTA 方法仅基于 DTA 数据集中少量的蛋白质序列来学习蛋白质表示, 而忽略了 DTA 数据集之外蛋白质的使用。我们提出了 GEFA (图早期融合亲和力), 这是一种具有注意力机制的新型图神经网络, 用于解决因结合效应而导致的靶点表示变化问题。具体而言, 将药物建模为原子图, 然后将其作为残基 - 药物复合物的更大图中的一个节点。所得到的模型是一个具有表现力的深度嵌套图神经网络。我们还利用了最近在学习上下文蛋白质表示方面的努力所提供的预训练蛋白质表示。这些实验在不同的设置下进行, 以评估诸如新型药物或靶点等场景。结果表明, 预训练的蛋白质嵌入的有效性以及我们的 GEFA 在建模药物 - 靶点相互作用的嵌套图方面的优势。

索引词 - 药物 - 靶点结合亲和力、图神经网络、早期融合、表示变化

C

简介

预测药物与靶点的结合亲和力 (药物靶点亲和力预测) 在新药开发以及药物再利用方面至关重要[1]、[2]。确定结合亲和力的金标准是通过实验测定, 但作为快速筛选工具, 这种方法成本过高, 因为有超过 1 亿种类药化合物[3]和超过 5000 种潜在的蛋白质靶点[4]。因此, 有必要采用基于模拟或机器学习的替代计算方法来预测新药物与靶点配对的结合亲和力。机器学习方法特别有吸引力, 因为借助于庞大的药物靶点亲和力数据库[4], 它们提供了廉价且快速的替代方案, 并且性能合理。

随着机器学习的发展, 许多计算预测方法[5]、[6]、[7]、[8]已被提出用于解决药物-靶点相互作用 (DTA) 问题。在近期的研究中, 蛋白质通常被表示为由字母表示的氨基酸序列[7]、[8]、[9]。但使用蛋白质序列的缺点在于, 它无法表示蛋白质的三维结构, 而三维结构对于实际确定蛋白质与药物之间的结合亲和力至关重要[10]。然而, 获取高分辨率的三维结构是一项具有挑战性的任务。一个更实用的解决方案是使用二维成对距离或接触图来表示蛋白质的三级结构[11]。如今, 借助深度学习算法, 这些图可以以合理的精度确定[12]、[13]。

接触图可以利用深度学习领域的最新进展——图神经网络 (GNN) 进行自然建模。在此模型中, 每个残基都被表示为图中的一个节点, 而两个残基之间的接触则表示为一条边。首先, 每个节点都嵌入一个特征向量。GNN 通过在节点之间迭代传递消息来运行, 通过从其邻近节点和远距离节点收集信息, 有效地细化节点表示。然后, 可以从其残基中汇集蛋白质的表示。

先前基于深度学习的药物 - 靶点相互作用 (DTA) 预测方法[7]、[8]、[9]、[11]通常采用后期融合的方法。后期融合方法分别提取药物和靶点的表示, 然后在过程的最后一步从组合表示中预测结合亲和力。然而, 这种做法忽略了结合发生在口袋而非整个蛋白质这一事实。口袋是蛋白质三维结构中的一个小凸洞, 有助于药物与蛋白质的稳定结合。一旦药物结合, 它会改变蛋白质的功能从而产生药理作用, 因此也会改变蛋白质的结构[14], 从而改变其表示。由于后期融合方法仅将从输入中提取的药物和靶点表示进行组合, 因此无法处理由于结合过程导致的蛋白质表示的变化。此外, 该模型假设非位点特异性结合, 这使得难以将功劳归于相互作用的位点。这还可能导致学习速度变慢, 预测结果难以解释。

为解决目标蛋白质表示变化的问题, 我们提出了一种基于早期融合的方法。首先, 从给定药物分子的药物图结构中提取表示特征。然后, 在蛋白质表示学习阶段之前, 将药物表示整合到蛋白质图结构中。这本质上是一个图结构嵌套在另一个图结构中。此图结构 -

The authors are with Applied Artificial Intelligence Institute, Deakin University, Geelong, VIC 3217, Australia. E-mail: {minhtri, thin.nguyen, lethao, truyen.tran}@deakin.edu.au.

Manuscript received 1 Sept. 2020; revised 3 June 2021; accepted 29 June 2021. Date of publication 1 July 2021; date of current version 1 Apr. 2022. (Corresponding author: Tri Minh Nguyen.)

Digital Object Identifier no. 10.1109/TCBB.2021.3094217

1545-5963 © 2021 电气与电子工程师协会 (IEEE)。个人使用允许, 但如需重新发布/再分发, 须获得 IEEE 许可。

欲了解更多信息, 请访问 <https://www.ieee.org/publications/rights/index.html>。

授权许可使用范围限于: 多伦多大学。于 2025 年 3 月 23 日 07:04:52 UTC 从 IEEE Xplore 下载。使用受限。

图内神经网络的设计使模型能够学习到蛋白质与药物分子结合过程中蛋白质表示的变化。

先前的研究[7]、[8]、[9]、[15]通常使用独热编码将氨基酸残基向量化。这种传统方法无法嵌入氨基酸残基之间的上下文依赖关系，也无法利用未标记的蛋白质序列。自然语言处理领域的最新进展使得能够从大量未标记的数据中学习上下文嵌入，这在许多任务中都是当前的最先进水平[16]。因此，我们利用基于大量蛋白质序列（包括 DTA 数据集中不存在的蛋白质）的蛋白质语言模型所学习到的蛋白质嵌入特征来表示给定目标蛋白质中的氨基酸残基。在本研究中，我们将 DTA 数据集中具有结合亲和力信息的目标蛋白质称为有标签蛋白质，而将 DTA 数据集中不存在的蛋白质称为无标签蛋白质。

总之，我们的工作贡献在于两个方面。首先，我们将蛋白质序列嵌入特征与蛋白质接触图相结合，构建目标蛋白质的图表示。其次，为了反映结合过程中目标表示的变化，我们提出了一种所谓的用于结合亲和力预测的图早期融合（GEFA）方法，以实现更准确的生物学建模。我们在 Davis 数据集 [17] 上展示了 GEFA 的效果，它在不同设置下均表现出优于以往研究的性能。我们的 Python 实现和数据可在 <https://github.com/ngminhtri0394/GEFA> 公开获取。

2 相关作品

2.1 药物再利用作为新型疾病的替代疗法

药物再利用[18]是指为新目标疾病确定已获广泛应用的药物的过程。与开发全新药物相比，药物再利用的优势在于风险更低且开发周期更短[19]。药物再利用的过程包含三个关键步骤：根据目标疾病确定候选分子、在临床前试验中评估药物效果以及在临床试验中评估有效性[20]。第一步，即假设生成，至关重要，因为它决定了整个过程的成败。在假设生成过程中会用到先进的计算方法。药物再利用中的计算方法可分为六类[20]：基因关联[21]、[22]，通路分析[23]、[24]、[25]，回顾性临床分析[26]、[27]、[28]，新型数据源，特征匹配[29]、[30]、[31]，分子对接[32]、[33]、[34]。

2.2 药物-靶点结合亲和力预测问题

药物与靶点的结合亲和力表明了靶蛋白与其配体（药物或抑制剂）之间的结合力强度[35]。药物-靶点结合亲和力预测问题是一个回归任务，用于预测结合力的值。结合强度通过平衡解离常数 (K_D) 来衡量。较小的 K_D 值表明蛋白质与配体之间的结合亲和力更强[35]。主要存在两种

方法：结构方法和非结构方法[1]。结构方法利用蛋白质和配体的三维结构来运行蛋白质与配体之间的相互作用模拟。另一方面，非结构方法依赖于配体和蛋白质的特征，如序列、疏水性、相似性或其他替代结构信息。

2.2.1 结构化方法

基于结构的方法涉及分子对接，即预测目标-配体复合物的三维结构。在分子对接中，存在大量的目标-配体复合物构象。这些构象通过评分函数进行评估。根据评分函数的类型，结构方法可分为三类[1]：经典评分函数法[36]、[37]、[38]、[39]，机器学习评分函数法[40]和深度学习评分函数法[41]、[42]。在经典评分方法中，Elanie 等人[36]使用 DelPhi 计算的每个配体原子的电位作为接触评分函数。在机器学习方法中，Kundu 等人[40]从 3D 结构数据中提取配体特征（例如原子数、物理化学性质）和蛋白质特征（例如可接触表面、链数），然后应用机器学习来学习评分函数。在深度学习方法中，Marta 等人[41]使用蛋白质-配体 3D 结构的 3D 卷积来预测结合亲和力。

2.2.2 非结构化方法

非结构化方法在无需目标的精确三维结构的情况下解决了结合亲和力回归任务。它不依赖于目标和药物原子的三维坐标，而是依靠药物与药物、目标与目标的相似性、目标和药物原子序列以及其他替代结构信息，如接触图或二级结构。

非结构化方法中的蛋白质表示：表示蛋白质链最简单的方式是用一串字母。使用 20 个字母来编码 20 种氨基酸。蛋白质序列中每个氨基酸的扭转角用一对 ϕ 角和 ψ 角来表示。蛋白质序列中的氨基酸具有三种主要的二级结构类型： α 螺旋、 β 折叠片和卷曲。因此，使用三个字母来编码二级结构。两个非相邻残基之间的相互作用表示为接触图或距离图。两个非相邻残基

如果两个残基之间的距离小于 8 Å，则它们处于接触状态。接触图是二进制图，用于显示蛋白质链中的两个残基是否处于接触状态。

基于核函数的方法（KronRLS）：KronRLS [5]、[6] 采用基于核函数的方法来构建药物之间或靶蛋白之间的相似性。在 KronRLS 中，核函数是用于衡量两个分子描述符之间相似性的函数，随后在正则化最小二乘回归（RLS）框架下作为学习模型来预测结合亲和力。

相似性匹配方法（SimBoost）：SimBoost [43] 从伴随结合的相似性出发，为每种药物、靶点以及药物 - 靶点构建特征。

药物与靶点之间的亲和力。然后，基于相似性的特征被用作梯度提升机的输入，以预测药物 - 靶点组合的结合亲和力的连续值。

基于深度学习的方法：DeepDTA [7] 利用一维卷积从蛋白质和药物的一维表示中预测结合亲和力。该方法的缺点在于使用序列来表示药物和靶点。然而，药物和靶点的结构信息在药物 - 靶点相互作用中起着重要作用。

GraphDTA [8] 不再使用一维表示来表示药物，而是使用图来表达分子中原子间的相互作用，并使用传统的图神经网络学习药物表示。这使得能够对药物分子内任意两个原子之间的相互作用进行建模。然而，蛋白质仍然以序列形式表示，这限制了模型的性能。DrugVQA [11] 使用距离图来表示蛋白质。通过顺序自注意力机制来学习蛋白质的哪些部分与配体相互作用。DrugVQA 使用动态卷积神经网络和双向长短期记忆网络来学习药物和蛋白质的表示。多头自注意力机制用于学习药物中哪些原子对药物 - 靶点相互作用的贡献较大。然而，DrugVQA 是一种监督学习方法，没有对靶点或药物进行任何预训练。因此，它可能无法很好地应对新型药物或蛋白质。Graph-CNN [44] 通过最小化表示差异来预训练蛋白质口袋图自动编码器。结合剂相互作用模型将蛋白质口袋图和二维分子图作为输入。然后使用两个图神经网络来学习药物和蛋白质口袋的固定大小表示。无监督学习有助于模型克服口袋图训练数据有限的问题。然而，Graph-CNN 需要蛋白质口袋作为目标表示，这可能限制了其通用性。DGraphDTA [15] 使用接触图构建蛋白质图结构，并将 PSSM、独热编码和残基属性作为节点特征。这使得模型能够利用图神经网络获得准确的蛋白质表示。然而，DGraphDTA 忽略了由于构象变化导致的目标表示变化。因此，模型学习到的目标表示可能不准确。

3 拟议方法

药物-靶点结合亲和力（DTA）问题的任务是预测靶蛋白 P 与药物化合物 D 之间的结合亲和力 A。从数学角度来讲，该问题被表述为一个回归任务。

$$A = \mathcal{F}_\theta(P, D), \quad (1)$$

其中 θ 是预测函数 $\mathcal{F}$ 的模型参数。

在本节中，我们将详细介绍解决药物 - 靶点相互作用（DTA）问题的方法。第 3.1 节阐述了目标蛋白 P 的特征表示，第 3.2 节介绍了药物化合物 D 的特征表示。我们的主要贡献在于第 3.3 节，旨在反映由于构象变化而导致的目标蛋白表示的变化。

3.1 蛋白质的图表示

先前将深度学习应用于药物靶点相互作用（DTA）的方法 [7]、[8]、[9] 使用目标蛋白质序列，其残基通常采用独热编码嵌入向量空间。随后，使用多个一维卷积层的编码器来获得蛋白质序列的最终表示。这种方法仅利用了目标蛋白质序列的一级结构信息。然而，三级结构信息对于药物靶点相互作用至关重要 [10]。尽管三维表示能够精确描述三级结构，但获取蛋白质的三维几何结构信息既耗时又具有挑战性。对于某些蛋白质类型，使用核磁共振（NMR）或 X 射线晶体学方法甚至无法获得 [45]。为了在复杂性和效率之间取得平衡，我们利用二维接触图信息作为三级结构的表示来表示蛋白质的图结构。

鉴于我们拥有二维三级结构信息，每个目标蛋白质都被视为一种图结构，其中节点是蛋白质序列中的残基。先前的研究 [7]、[8] 使用独热编码将蛋白质序列中的每个残基向量化。虽然使用独热编码很方便，但它无法体现元素之间的相似性，而是认为它们彼此等距。此外，这种表示方式的选择限制了学习能力，因为它无法利用残基之间的上下文依赖关系，而这种依赖关系可以通过无监督学习来估计。实际上，学习信号仅来自特定数据集中有限数量的目标蛋白质。事实上，用于药物-靶点结合亲和力（DTA）预测的任务中，仅有 7605 个目标蛋白质 [4] 被使用，而大多数蛋白质未被利用。据估计，存在超过 1.88 亿个未标记的目标蛋白质序列 [46]。

利用这一丰富的未标记蛋白质集，我们采用最先进的语言建模方法来学习上下文残基嵌入表示。我们使用从 TAPE [47] 提供的大量未标记蛋白质序列中学习到的嵌入表示，而非独热编码，来表示蛋白质图中的每个节点。更具体地说，它依赖于自然语言处理中广泛研究的自监督学习的最新进展。自监督学习是无监督学习的一个子集，其中监督信息来自数据本身 [48]。通常，会保留一部分数据，然后训练模型来预测这部分数据。在自然语言处理中，语言建模是自监督学习的一个常见案例，它通过诸如预测缺失的标记或序列中的下一个标记等预设任务来学习序列的表示 [16]。TAPE 是一种专门用于蛋白质表示的语言模型变体。随后，对于一个由 L 个残基组成的蛋白质序列，节点

蛋白质图的特征 $\mathbf{u}$ 是一个集合 $\mathbf{V}_p = \{ \mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_L \}$ ，其中 h 是由 TAPE 提供的嵌入向量的长度。每个 $\mathbf{v}_i$ 都是上下文相关的，也就是说，残基出现在周围残基的环境中。因此，结构信息被隐式地编码到嵌入中。

我们使用二级结构，因为它决定了目标蛋白质的主链形状，这也有助于结合位点的形状以及整体结构。对于每一个




图 1. GEFA 框架的早期融合步骤。GEFA 以药物分子和蛋白质靶点的图表示作为输入。首先，我们使用图卷积网络（GCN）对药物图特征进行细化，然后应用最大池化操作以获得整个药物图的估计表示。接着，将药物估计向量作为额外节点添加到蛋白质图中，从而在不同领域间建立图嵌套图表示。

残基的二级结构特征以三种二级结构类型（ α 螺旋、 β 折叠片和卷曲）的概率形式表示。

溶剂可及性表明了残基与药物分子之间的相互作用程度。溶剂可及性分为三类：埋藏（pACC 为 0 至 10）、中等（pACC 为 11 至 40）和暴露（pACC 为 41 至 100）。位于蛋白质核心内部的埋藏残基与药物分子相互作用的可能性较小，而暴露的残基与药物分子相互作用的可能性较大。最终，通过 TAPE 提取的嵌入向量、二级结构特征向量和溶剂可及性特征向量的组合被用于表示目标蛋白质图中残基节点的特征。

接触图信息提供了蛋白质图中任意两个残基节点之间的接触情况。序列信息也以边的形式保留在图结构中，这些边连接着蛋白质序列中相邻残基的任意两个节点。在实际应用中，接触图和序列信息以邻接矩阵的形式存储 A_p 。在本文的其余部分，我们将蛋白质图表示为 $G_p \propto \tilde{D} V_p$ ； $A_p \tilde{D}$ ，其中 V_p 是蛋白质链中的残基节点。

3.2 药物化合物的图表示

输入的药物化合物采用 SMILES 格式。在分子的图表示中，原子是节点，原子之间的键是边。节点特征由五个属性组成：原子符号、原子度（即与原子相连的原子邻居总数）、氢原子数、原子的隐式值以及原子是否为芳香族原子。这些特征被连接起来形成一个多维特征。边通过邻接列表表示，该列表表明化合物中任意两个原子之间是否存在键。由于键是对称的，药物化合物图是一个双向图。在后面




图 2. 药物 - 靶点图的优化步骤。利用图卷积网络（GCN）对药物 - 靶点图进行优化。然后将药物节点从药物 - 靶点图中分离出来。

对于药物化合物的图表示法，我们将其表示为 $G_d \propto \tilde{D} V_d$ ； $A_d \tilde{D}$ ，其中 V_d 表示原子特征，而 A_d 表示原子间的键。

3.3 用于结合亲和力预测的图早期融合 (GEFA)

我们所提出方法的整体架构在图 1、2 和 3 中给出。我们的 GEFA 以药物 G_d 的图结构和靶点 G_p 的图结构作为输入，并输出结合亲和力的预测结果。我们使用图卷积网络（GCN）[49] 来进行图表示。整个过程包含三个关键步骤：药物和靶点的早期融合以形成药物 - 靶点图（图 1）、药物 - 靶点图的优化（图 2）以及亲和力预测（图 3）。此外，我们还利用了广为人知的残差跳跃连接技巧，以充分利用非常深的 GCN。

3.3.1 图卷积网络

GCN 是一种专门针对图结构信号设计的卷积网络。其目标是从给定的输入图 $G \propto (X; A)$ 中学习节点级别的表示，其中 X 是 N 个节点的节点特征矩阵， $A \in \mathbb{R}^{N \times N}$ 是描述图结构的邻接矩阵。设 W_l 为第 l 层的权重矩阵，图卷积操作定义为

$$H^1 = X, \quad (2)$$

$$H^l = \sigma\left(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^{l-1} W^{l-1}\right), \quad (3)$$




图 3. 结合亲和力预测步骤。从药物-蛋白质图中检索到的信息以及药物表示最终被用作输入，以预测给定药物分子与蛋白质靶点之间的结合亲和力。

其中 $A \sim = \frac{1}{4}A + I$ 是邻接矩阵，

P 自环进入

每个节点。I 是单位矩阵，D

$\sim \frac{1}{4} A_{ij}$ 和 s 是 $\sim$

在我们后续的实验中，它是一个非线性函数，即 ReLU 函数 [50]。

3.3.2 带残差块的更深GCN

一般来说，深度模型比浅层网络具有更好的泛化能力和更紧凑的结构[51]。然而，堆叠普通的图卷积网络（GCN）通常会因式（3）中的矩阵乘法而导致梯度消失和数值不稳定的问题。为了缓解这一问题，我们采用了[52]中提出的带有残差跳过连接的 GCN。与著名的卷积神经网络（CNN）中的残差块类似，GCN 中的跳过连接有助于形成更直接的梯度流，从而能够使用更多的卷积层实现更深的网络。从数学角度来说，图卷积操作由以下公式给出

$$H^l = \mathcal{X}, \quad (4)$$

$$F^l(H^{l-1}) = W_2^{l-1} \sigma(AH^{l-1}W_1^{l-1} + b^{l-1}), \quad (5)$$

$$H^l = \sigma(H^{l-1} + F^l(H^{l-1})), \quad (6)$$

其中 W_1 和 W_2 是可学习的权重矩阵， l 是逐层索引， σ 是一个非线性函数，即 ReLU 激活函数。

3.3.3 图-图集成与早期融合

为了反映药物分子与蛋白质相互作用所导致的目标蛋白质表达的变化，我们提出了结合亲和力的图早期融合（GEFA）方法，该方法通过自注意力机制将药物分子图 G_d 与蛋白质图 G_p 相融合。

我们首先使用如式（3）所示的两层 GCN 和残差块对药物图中的节点表示进行细化。

在式（4）、（5）和（6）中。令 V_0 作为节点

GCN 后药物图的特征，其中 S 为药物图中的节点数， h_1 为节点特征向量的维度。请注意， v_0 包含了来自其邻域的信息聚合，因此我们只需将细化后的药物图的最大估计表示作为整个图的表示。这很容易通过最大池化操作，然后通过两个线性层进行特征投影来获得：

$$v'_{\max} = \text{MaxPool}(V'_d), \quad (7)$$

$$x_d = (W_0 v'_{\max} + b_0) W_1 + b_1. \quad (8)$$

我们将所得向量 $x_d \in \mathbb{R}^{h_1}$ 称为药物分子节点，其中 h_1 是 x_d 的维度。

我们接下来解释如何将药物分子节点 x_d 集成到蛋白质图 G_p 中，这是本研究的主要贡献。关键思想是将药物节点 x_d 作为附加节点与目标图 G_p 相结合。蛋白质图中连接药物节点和残基节点的边表示残基与药物分子之间的相互作用以及结合位点。由于并非每个残基对结合亲和力的贡献都相同，边的权重表示每个残基与药物分子相互作用的程度。为了学习贡献程度，我们利用由残基特征驱动的自注意力机制 V_p 。这里 L 是蛋白质序列的长度， h_2 是特征向量的维度。自注意力机制的灵感来源于蛋白质的结合位点取决于其结构这一事实。换句话说，注意力权重表明哪些残基更有可能参与结合过程。从数学上讲，注意力权重由以下公式给出

P_L

$$\alpha_i = \text{softmax}(W_2 \tanh(W_1 v_i)), \quad (9)$$

其中 v_i 是第 i 个残基特征， W_1 和 W_2 是可学习的参数。

给定药物节点 x_d 及其与目标蛋白质图 G_p 中残基的连接关系 f_{ag} ，我们现在构建一个跨域图 G_{pd} ，其中 V_{pd} 和 A_{pd} 与之前处理药物图的方式类似，我们采用两层 GCN 并在其后添加残差块来优化药物-蛋白质图 G_{pd} 的节点表示。

在执行图特征提取之前，从 GCN 精炼节点 V_{0pd} 中取出融合后的药物节点 v_{0dp} ，将其从蛋白质图中移除，以确保图特征仅包含残基节点。最终，我们通过全局最大池化操作符，再接一个两层线性网络来提取蛋白质图的潜在表示：

$$v'_{\max} = \text{MaxPool}(V'_p), \quad (10)$$

$$v_{pd} = (W_0 v'_{\max} + b_0) W_1 + b_1, \quad (11)$$

其中 V_{0p} 是去除药物节点后蛋白质图的节点表示。

同时，药物潜在向量 x_d 通过线性变换被转换到与 v_{0dp} 相同的维度空间。

我们通过简单的拼接操作将这两种特征结合起来，从而获得药物的最终表示形式。

$$v_{db} = [x_d; v'_{dp}], \quad (12)$$

其中， $\frac{1}{2};$ 表示两个向量的拼接操作。然后沿通道维度执行最大池化操作，以获得组合药物的表示。

$$v_{dc} = \text{MaxPool}(v_{db}). \quad (13)$$

因此，药物向量 v_{dc} 和蛋白质潜在向量 v_{pd} 被连接起来，最终输入到由三个全连接层组成的预测器中，以预测结合亲和力。

我们希望假设，我们的早期融合方法结合自注意力机制具有两个优势。首先，早期融合方法明确地对药物图和目标蛋白质图之间的相互作用进行建模。其次，自注意力机制使得学习模型更具可解释性，能够展示哪些残基与药物分子相互作用以及它们对结合过程的贡献程度。我们将在后续实验中验证这些假设。

3.4 图后期融合基线方法

为了将我们的早期融合方法与传统的后期融合方法进行比较，我们提供了一个后期融合的基准模型。我们的后期融合基准模型（GLFA - 用于结合亲和力的图后期融合）遵循传统模型，其中药物和蛋白质的表示分别学习。GLFA 以药物和靶点的图结构作为输入。两个图结构分别通过两层 GCN 和残差块并行处理以学习隐藏特征。然后，通过全局最大池化和两个线性层获得潜在特征。来自蛋白质和药物的潜在特征被连接起来，然后经过三个全连接层。最终全连接层的输出是输入药物和靶点蛋白质的结合亲和力值。后期融合模型是早期融合的一个特例，其中所有药物-残基边权重均设置为 0。后期融合方法用作基准，与我们提出的早期融合方法进行比较。

4 实验

我们在 Davis 数据集 [17] 和 PDBBind 数据集 [54]、[55] 上对所提出的 GEFA 模型进行了评估，并将其与后期融合基线以及包括 GCNConvNet [8]、GINConvNet [8]、DGraphDTA [15] 在内的最新方法进行了比较。在这些方法中，GCNConvNet 和 GINConvNet 以蛋白质序列和药物分子图作为输入，而 DGraphDTA 则以基于接触的蛋白质图和药物分子作为输入。我们在第 4.1 节展示了定性结果，并在第 4.2 节通过广泛的消融研究进一步分析了我们所提出的模型。

4.1 定量实验

4.1.1 数据集

戴维斯数据集包含了 72 种药物与 442 个靶点之间的结合亲和力信息。药物与靶点之间的结合亲和力通过 K_D （激酶）来衡量。

对于 Davis 数据集，我们在实验中使用了来自 DeepDTA [7] 训练/测试集的 68 种药物的 SMILES 序列以及 442 个靶点的蛋白质序列。

针对四种场景设置了四个实验环境。第一个实验环境是“暖环境”，在这种环境中，模型已知蛋白质和药物的信息。在这种情况下，每种蛋白质和药物都会出现在训练集、验证集和测试集中。

第二个实验是冷靶点实验，其中蛋白质对于模型来说是未知的，而药物对于模型来说是已知的。这种设置模拟了针对新靶点进行药物再利用的场景。在这种情况下，每个独特的蛋白质序列仅出现在训练集、验证集或测试集中。由于冷靶点设置要求训练集、验证集和测试集中的靶点序列必须是唯一的，因此具有相同序列的靶点被过滤掉，最终剩下 361 个靶点。这 361 个靶点按照 0.8/0.2 的比例分为训练验证集和测试集。然后，训练验证集再按照 0.8/0.2 的比例分为训练集和验证集。

第三个实验设置是“冷药物”，在这种情况下，模型已知蛋白质，但药物未知。也就是说，每种药物仅出现在训练集、验证集或测试集中的一种。我们采用与“冷靶点”相同的划分流程，但针对药物进行操作。

最后，最后一个实验设置是冷药物 - 冷靶点，即模型既不知道药物也不知道蛋白质。这种情况相当于为新靶点研发新药物。蛋白质靶点的筛选与冷靶点实验相同，最终得到 361 个靶点。在此设置中，我们对药物和靶点都进行拆分处理，以确保训练集、验证集和测试集之间不存在任何相同的药物或靶点。

PDBBind 数据集 (v2019) [54]、[55] 是一个包含蛋白质数据银行 (PDB) 中药物靶点三维结构结合亲和力的综合数据库。PDBBind 数据集提供了靶蛋白和配体结构的三维坐标。我们将通用集作为训练集，将 PDBBind 数据集的精炼集作为测试集。精炼集是从通用集中选取的样本，其结合数据、晶体结构和复合物性质的质量更高[54]、[55]。首先，我们提取具有完整配体结构的样本。然后，我们去除通用集和精炼集之间的重叠部分。为了使训练过程稳定，我们仅选择通用集中蛋白质序列长度小于 1000 的样本。然而，我们在精炼集中测试所有长度的蛋白质序列样本。通用集按照 8:2 的比例分为训练集和验证集。最终，我们有 8391 个训练样本、1680 个验证样本和 3940 个测试样本。

4.1.2 实施细节

我们的方法是使用 Pytorch 实现的。蛋白质序列嵌入特征是通过 TAPE-Protein [56] 提取的。接触图是通过 RaptorX [57] 预测的。TAPE-Protein 使用 BERT 语言模型 [16]。TAPE-Protein 提取的嵌入特征输出是一个嵌入向量大小为 768。图卷积网络

使用了 Pytorch 几何库 [58]。模型在 128 个小型批次上进行训练。在预热设置中，学习率为 0.0005。在冷目标、冷药物以及冷药物 -

表 1

戴维斯数据集实验在“暖启动”设置下的结果
冷靶点设定、冷药物设定、冷药物靶点

设置	均方根误差#	皮尔逊相关系数#	斯皮尔曼相关系数#	企业形象识别系数#
建筑学				
暖启动设置				
GCN 卷积网络 [8]	0.5331	0.8043	0.6609	0.8649
GIN卷积网络 [8]	0.50723	0.8245	0.6818	0.8785
DGraphDTA [15]	0.4917	0.8378	0.7001	0.8869
GLFA	0.4850	0.8412	0.7073	0.8950
GEFA	0.4775	0.8467	0.7023	0.8927
冷目标设定				
GCN 卷积网络 [8]	0.7071	0.5145	0.4316	0.7293
GIN卷积网络 [8]	0.7144	0.5166	0.3904	0.7065
DGraphDTA [15]	0.6855	0.5597	0.4941	0.7656
GLFA	0.6732	0.5828	0.5228	0.7802
GEFA	0.6584	0.6030	0.5506	0.7951
感冒药设置				
GCN 卷积网络 [8]	0.9723	0.3385	0.3764	0.6784
GIN卷积网络 [8]	0.9592	0.3779	0.3693	0.6758
DGraphDTA [15]	0.9583	0.3610	0.3150	0.5337
GLFA	0.9280	0.4023	0.3549	0.6703
GEFA	0.9202	0.4515	0.4320	0.7091
冷药物靶点设定				
GCN 卷积网络 [8]	1.0632	0.1904	0.1698	0.5782
GIN卷积网络 [8]	1.0651	0.1974	0.2763	0.6275
DGraphDTA [15]	1.0749	0.0228	0.1795	0.6081
GLFA	1.0698	0.3473	0.2901	0.6362
GEFA	0.9949	0.3148	0.2932	0.6390

在目标设定中，学习率为 0.001，较高的学习率有助于模型具有更好的泛化能力，且不太可能过拟合。采用了学习率衰减策略，即如果验证集中的均方误差（MSE）指标在 40 个周期内没有改善，学习率就会降低 20%。使用了 Adam 优化器。模型训练了 1000 个周期。

4.1.3 评估指标

模型的性能通过一致性指数（CI）[59]、均方根误差（RMSE）、皮尔逊相关系数[60]和斯皮尔曼相关系数[61]进行评估。一致性指数用于衡量排序的质量。其公式如下：

$$CI = \frac{1}{Z} \sum_{d_i > d_j} h(b_i - b_j), \quad (14)$$

$$h(x) = \begin{cases} 1, & \text{if } x > 0 \\ 0.5, & \text{if } x = 0, \\ 0, & \text{if } x < 0 \end{cases} \quad (15)$$

其中 b_i 是较大亲和值 d_i 的预测值， b_j 是较小亲和值 d_j 的预测值， Z 是归一化常数， $h(x)$ 是阶跃函数。

皮尔逊相关系数衡量的是预测值 p 与真实值 y 之间的线性相关程度。

$$Pearson = \frac{\phi(p, y)}{\phi(p)\phi(y)}, \quad (16)$$

表 2

PDBBind 数据集实验在通用 - 精细设置下的结果

建筑学	均方根误差 (RMSE) #	斯皮尔曼	CI (企业形象识别系数)
GCN 卷积网络 [8]	1.7108	0.5972	0.7108
GIN卷积网络 [8]	1.7514	0.5505	0.6995
DGraphDTA [15]	1.5150	0.6796	0.7404
GLFA	1.4945	0.6831	0.7560
GEFA	1.4647	0.6979	0.7589

其中， $f(p; y)$ 是预测值与真实值之间的协方差， $f(p)$ 是 p 的标准差， $f(y)$ 是 y 的标准差。

斯皮尔曼等级相关系数衡量等级相关性

$$Spearman = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}, \quad (17)$$

其中 d_i 表示预测值与真实值之间两个等级的差值。

4.1.4 结果

我们在表 1 中的 Davis 基准测试的四种设置以及表 2 中的 PDBBind 数据集上报告了我们的后期融合方法 GLFA 和早期融合方法 GEFA 与先前工作的对比情况。我们提出的 GEFA 方法在 Davis 数据集的四种设置和 PDBBind 数据集的一般 - 精细设置中始终优于先前的工作。我们的方法在所有四种设置中均达到了最先进的性能。在两种基于后期融合的方法 DGraphDTA [15] 和 GLFA 之间，我们提出的 GLFA 方法也优于 DGraphDTA。这符合我们的预期，因为嵌入特征包含的信息比独热编码和 PSSM 更丰富。这也证明了使用残差块的优势。

DGraphDTA [15]、GLFA 和 GEFA 在所有四种设置中均优于 GIN-ConvNet。GIN-ConvNet 和 GCNConv-Net [8] 仅使用序列和 CNN 来学习目标表示。另一方面，DGraphDTA [15]、GLFA 和 GEFA 利用从蛋白质接触图构建的图，并使用 GCN 学习目标表示。这表明使用接触图的图表示具有优势。

总体而言，早期融合方法 GEFA 比晚期融合方法 GLFA 更具优势。这符合我们的预期，因为早期融合允许在图表示学习阶段药物图和蛋白质图之间进行交互，从而获得更准确的潜在表示。具体来看，在暖设置中，GEFA 和 GLFA 方法的结果相当。在这种情况下，任务只是插值，大部分信息都是可用的。在冷药物设置中，我们推测潜在的靶点特异性结合位点使模型能够学习到更准确的结合机制，即使药物缺失也是如此。然而，当引入新的靶点和药物时（冷药物 - 靶点设置），模型学习到的结合区域效果较差。

我们可以观察到一个共同的趋势，即所有模型在感冒药物设置中的表现都低于其其他环境中的表现。

表 3
不同成分实验暖态启动的结果
戴维斯数据集在暖环境下的表现

建筑学	均方根误差#	皮尔逊相关系数#	斯皮尔曼相关系数#	（余弦相似性）
GEFA	0.4775	0.8467	0.7023	0.8954
独热编码	0.5050	0.8274	0.6919	0.8828
未受关注	0.4887	0.8392	0.7014	0.8909
无两层 GCN	0.4844	0.8425	0.6933	0.887
残差块使用				
无残差块	0.4933	0.8351	0.686	0.8819
药物图谱分辨率块 0.494		0.8351	0.6874	0.8828
蛋白质图分辨率块	0.4873	0.8407	0.7045	0.8941
药品代理选择				
融合前代表。	0.4806	0.8448	0.7058	0.8954
融合后代表。	0.5171	0.8174	0.6437	0.8558

第一行展示了包含所有组件的拟议通用能源框架协议（GEFA）。

冷靶点设置。原因在于戴维斯数据集中的独特靶点序列数量高于独特 SMILES 序列的数量。因此，模型有更多的靶蛋白样本用于学习蛋白质的特征空间。

4.2 消融研究

为了解早期融合 GEFA 模型中每个组件对整体性能的贡献,我们将每个组件从 GEFA 模型中移除。我们在 Davis 数据集基准的热启动设置下进行了消融实验。

首先，我们通过将其与独热编码进行比较来评估嵌入特征的使用情况。

其次，我们评估了注意力掩码作为图边的使用情况。与将注意力用作药物 - 残基边权重不同，在目标图中，药物 - 残基边的权重与残基 - 残基边的权重相同。

第三，我们评估了两层 GCN 的使用情况以及残差块在优化图结构方面的使用情况。由于所有残差块都共享权重，这减少了参数数量，可能有助于防止过拟合。

第四，我们评估残差块。我们测试了三种情况：蛋白质图和药物图中均无残差块、蛋白质图中无残差块以及药物图中无残差块。

最后，我们将从药物 - 蛋白质融合图中提取的药物表示与从药物图中提取的药物表示进行比较。我们不是先融合两种类型的药物特征然后再进行池化，而是仅使用一种类型的药物特征与基于图的蛋白质表示进行组合。

如表 3 所示，使用蛋白质嵌入特征的模型在均方误差（MSE）方面提高了 11.85%，在一致性指数（CI）方面提高了 1.00%。这突显了将蛋白质嵌入特征用作图节点特征的优势。

在蛋白质图中使用注意力掩码作为药物残留边，均方误差（MSE）提高了 4.74%，结合指数（CI）提高了 0.20%。若不使用注意力掩码，则假设药物分子与目标蛋白质中的所有残基相互作用程度相同。然而，每个残

基对结合过程的贡献程度各不相同。因此，使用自注意力机制来学习每个残基的贡献水平，并将其作为药物节点与残基节点之间的边权重是合理的。

使用两层 GCN（表 3 中的 GEFA）相较于不使用两层 GCN（表 3 中的“不使用两层 GCN”）有所改进。与仅使用残差块作为图细化的模型（表 3 中的“无两层 GCN”）相比，使用残差块的模型优于仅使用两层 GCN 的模型（表 3 中的“无图残差块”）。因此，可以认为残差块具有与两层 GCN 相同甚至更好的学习能力。有趣的是，将两层 GCN 和残差块结合使用可带来最佳结果，如全组件模型 GEFA 所示。

在药物图和蛋白质图中均使用残差块的模型比不使用任何残差块的模型更具优势。同时在药物图和蛋白质图中使用残差块的模型在均方误差（MSE）方面比不使用残差块的模型提高了 6.73%。有趣的是，仅在药物图中应用残差块会使模型性能略有下降（均方误差降低 0.2%，CI 降低 0.1%）。重新在蛋白质图中添加残差块有助于模型在均方误差方面提高 2.43%。在早期融合方法中，在蛋白质图中堆叠残差块更为关键，因为它不仅影响蛋白质图的表示，还影响药物节点的表示。

最后，我们比较了药物表示在融合药物 - 靶点图之前和之后的情况。仅使用融合前药物表示的模型表现相当，而使用融合后药物表示的模型在均方误差（MSE）方面性能下降了 17.24%。这表明融合前的药物表示比融合后的更有用。原因可能在于图神经网络中的消息传递。药物节点的信息是从其相邻的残基节点更新的。因此，这表明结合过程并未给配体潜在表示带来任何显著变化。

4.3 错误分析

我们分析了蛋白质序列是如何聚类的，以及它们对模型性能的影响。结果表明，良好的性能并非源于训练集中特定目标的过度表示，而是源于聚类的某些特定特征，例如序列长度、基序等（见补充材料第 1 节），该补充材料可在计算机学会数字图书馆获取，网址为 <http://doi.ieeecomputersociety.org/10.1109/TCBB.2021.3094217>。

我们对 GEFA 模型在成功案例和失败案例中预测的结合位点进行了分析。我们选取了两个具有 3D 结构且绝对误差最低和最高的药物 - 靶点结合对。对于成功案例，我们分析了由我们提出的模型预测的靶点 MST1 与化合物 Bosutinib（PubChem CID 5328940）之间的结合情况，并将其与盲法对接模拟 [62] 进行了比较。Bosutinib - MST1 对的预测值为 K_D 6.72132，绝对误差为 0.0000738。

MST1 目标自注意力层的注意力值表明，残基 ASP 167. A 具有




图 4. MST1 目标预测结合位点的注意力值。在残基 ASP 149.A 处的注意力值为 0.2 (20%)，在残基 ASP 167.A 处为 0.72 (72%)，在残基 ASP 206.A 处为 0.07 (7%)。




图 5.通过盲法对接预测的 MST1 与博舒替尼之间的残基 - 配体相互作用。




图 6. 预测的结合口袋以红色突出显示以及博舒替尼配体的对接情况。

具有最高的结合位点概率 (0.72) (图 4)。这与盲法对接结果一致。在博舒替尼 - MST1 对的盲法对接模拟 (图 6) 中，结合能最低 (-7.30 kcal/mol) 的构象显示了 ASP 167.A 与配体之间的氢键 (图 5)。

对于失败的案例，我们分析了靶点 EGFR (T790M) 与拉帕替尼 (PubChem CID 208908) 之间的结合情况。预测的结合能值为 8.7785，而真实值为 6.0655。从自注意力层获得的注意力值在 ASP 896.A 处达到峰值，置信度为 0.48 (48%) (见图 7)。然而，在 EGFR 的结晶结构中




图 7. EGFR (T790M) 靶点预测结合位点的注意力值。




图 8. EGFR (T790M) 靶点的溶剂可及表面值。




图 9. 通过盲法对接预测的 EGFR (T790M) 与拉帕替尼之间的残基 - 配体相互作用。

对于 (T790M) 而言，896.A 残基处于埋藏状态 (见图 8)，不太可能是结合位点。此外，盲法对接预测的构象显示 896.A 残基与配体之间没有相互作用 (见图 9)。因此，在早期融合模型中，药物节点与结合位点残基之间的边是不正确的。结果，拉帕替尼 - EGFR (T790M) 的预测 K_D 值在 Davis 测试集中误差最高。从成功案例和失败案例这两个例子来看，获得正确的结合位点以形成正确的药物节点 - 残基边是早期融合方法的重要方面之一。

5 结论

我们提出了一种新颖的深度学习方法，称为 GEFA (用于结合亲和力预测的图早期融合)，用于靶点 - 药物亲和力预测，这是快速实现这一关键任务的重要手段。

虚拟药物筛选和药物再利用。为了增强蛋白质表示的能力，我们采用自监督学习方法，以利用大量未标记的目标序列。为了解决由于结合过程中构象变化而导致的潜在表示变化问题，提出了药物与靶点的早期融合方法。与分别提取表示的晚期融合方法不同，早期融合方法将药物表示信息整合到蛋白质表示学习阶段。目标序列的自注意力值被用作连接药物节点和目标蛋白质图中残基节点的边权重。自注意力机制使模型更具可解释性，因为它能够展示哪些残基参与了结合过程以及每个残基的贡献程度。定量实验表明，早期融合方法优于晚期融合方法。使用嵌入特征作为目标节点特征优于使用独热编码。残差块设计允许堆叠多个 GCN 层，从而提高表示学习能力。

这项工作为未来的研究开辟了空间。尽管通过在表示学习阶段向目标图添加药物节点解决了目标表示的变化问题，但构象变化（即残基 - 残基边连接的变化）并未得到解决。如果我们能够学习边的变化，就能表达出药物 - 目标结合所引起的构象变化。此外，如果目标蛋白在不同区域有多个结合口袋，药物分子可能一次仅与其中一个口袋结合。然而，在我们的模型中，药物节点通过自注意力掩码与所有可能的结合位点相连。如果能将药物信息结合到寻找药物 - 残基边的过程中，结合过程的建模将会更加准确。

微小 RNA 已被作为难以成药蛋白质的新靶点进行的研究[63]、[64]，并且已有一些计算模型被提出用于预测药物与微小 RNA 的关联[65]、[66]。我们的框架可用于具有能够结合类药物分子的结合位点的 RNA。然而，如果药物结合的是 RNA 的二级结构，其结合机制可能会有所不同，目标图可能需要修改以表示二级结构的相互作用。

参考文献

- [1] M. Thafar, A. B. Raies, S. Albaradei, M. Essack, and V. B. Bajic, "Comparison study of computational prediction tools for drug-target binding affinities," *Front. Chem.*, vol. 7, 2019, Art. no. 782.
- [2] X. Chen et al., "Drug-target interaction prediction: Databases, web servers and computational models," *Brief. Bioinf.*, vol. 17, no. 4, pp. 696–712, 2016.
- [3] S. Kim et al., "PubChem 2019 update: Improved access to chemical data," *Nucleic Acids Res.*, vol. 47, no. D1, pp. D1102–D1109, 2019.
- [4] M. K. Gilson, T. Liu, M. Baitaluk, G. Nicola, L. Hwang, and J. Chong, "BindingDB in 2015: A public database for medicinal chemistry, computational chemistry and systems pharmacology," *Nucleic Acids Res.*, vol. 44, no. D1, pp. D1045–D1053, 2016.
- [5] A. Cichonska et al., "Computational-experimental approach to drug-target interaction mapping: A case study on kinase inhibitors," *PLoS Comput. Biol.*, vol. 13, no. 8, 2017, Art. no. e1005678.
- [6] A. Cichonska et al., "Learning with multiple pairwise kernels for drug bioactivity prediction," *Bioinformatics*, vol. 34, no. 13, pp. i509–i518, 2018.
- [7] H. Ozt€urk, A. Ozt€urk, and E. Ozkirimli, "DeepDTA: Deep drug-target binding affinity prediction," *Bioinformatics*, vol. 34, no. 17, pp. i821–i829, 2018.
- [8] T. Nguyen, H. Le, T. P. Quinn, T. Nguyen, T. D. Le, and S. Venka-tesh, "GraphDTA: Prediction of drug-target binding affinity using graph convolutional networks," *Bioinformatics*, vol. 37, no. 8, pp. 1140–1147, 2020.
- [9] H. Ozt€urk, E. Ozkirimli, and A. Ozt€urk, "WideDTA: Prediction of drug-target binding affinity," 2019, arXiv:1902.04166.
- [10] Z.-C. Li et al., "Identification of drug-target interaction from inter-actome network with 'guilt-by-association' principle and topology features," *Bioinformatics*, vol. 32, no. 7, pp. 1057–1064, 2016.
- [11] S. Zheng, Y. Li, S. Chen, J. Xu, and Y. Yang, "Predicting drug-protein interaction using quasi-visual question answering system," *Nat. Mach. Intell.*, vol. 2, no. 2, pp. 134–140, 2020.
- [12] S. Wang, S. Sun, and J. Xu, "Analysis of deep learning methods for blind protein contact prediction in CASP12," *Proteins: Struct., Funct., Bioinf.*, vol. 86, pp. 67–77, 2018.
- [13] A. W. Senior et al., "Improved protein structure prediction using potentials from deep learning," *Nature*, vol. 577, no. 7792, pp. 706–710, 2020.
- [14] S. J. Teague, "Implications of protein flexibility for drug discovery," *Nat. Rev. Drug Discov.*, vol. 2, no. 7, pp. 527–541, 2003.
- [15] M. Jiang et al., "Drug-target affinity prediction using graph neural network and contact maps," *RSC Advances*, vol. 10, no. 35, pp. 20 701–20 712, 2020.
- [16] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proc. Conf. North Amer. Chapter Assoc. Comput. Linguistics: Hum. Lang. Technol.*, 2019, pp. 4171–4186.
- [17] M. I. Davis et al., "Comprehensive analysis of kinase inhibitor selectivity," *Nat. Biotechnol.*, vol. 29, no. 11, pp. 1046–1051, 2011.
- [18] J. Langedijk, A. K. Mantel-Teeuwisse, D. S. Slikkerman, and M.-H. D. Schutjens, "Drug repositioning and repurposing: Terminology and definitions in literature," *Drug Discov. Today*, vol. 20, no. 8, pp. 1027–1034, 2015.
- [19] H. Xue, J. Li, H. Xie, and Y. Wang, "Review of drug repositioning approaches and resources," *Int. J. Biol. Sci.*, vol. 14, no. 10, pp. 1232–1244, 2018.
- [20] S. Pushpakom et al., "Drug repurposing: Progress, challenges and recommendations," *Nat. Rev. Drug Discov.*, vol. 18, no. 1, pp. 41–58, 2019.
- [21] M. P. Grover et al., "Novel therapeutics for coronary artery disease from genome-wide association study data," *BMC Med. Genomic.*, vol. 8, no. S2, 2015, Art. no. S1.
- [22] P. Sanseau et al., "Use of genome-wide association studies for drug repositioning," *Nat. Biotechnol.*, vol. 30, no. 4, 2012, Art. no. 317.
- [23] F. Iorio, A. Isacchi, D. di Bernardo, and N. Brunetti-Pierri, "Identification of small molecules enhancing autophagic function from drug network analysis," *Autophagy*, vol. 6, no. 8, pp. 1204–1205, 2010.
- [24] F. Iorio, J. Saez-Rodriguez, and D. Di Bernardo, "Network based elucidation of drug response: From modulators to targets," *BMC Syst. Biol.*, vol. 7, no. 1, pp. 1–9, 2013.
- [25] S. B. Smith, W. Dampier, A. Tozeren, J. R. Brown, and M. Magid-Slav, "Identification of common biological pathways and drug targets across multiple respiratory viruses based on human host gene expression analysis," *PLoS One*, vol. 7, no. 3, 2012, Art. no. e33174.
- [26] M. Hurler, L. Yang, Q. Xie, D. Rajpal, P. Sanseau, and P. Agarwal, "Computational drug repositioning: From data to therapeutics," *Therapeutics*, vol. 93, no. 4, pp. 335–341, 2013.
- [27] P. B. Jensen, L. J. Jensen, and S. Brunak, "Mining electronic health records: towards better research applications and clinical care," *Nat. Rev. Genetic*, vol. 13, no. 6, pp. 395–405, 2012.
- [28] H. Paik et al., "Repurpose terbutaline sulfate for amyotrophic lateral sclerosis using electronic medical records," *Sci. Rep.*, vol. 5, 2015, Art. no. 8580.
- [29] J. T. Dudley, T. Deshpande, and A. J. Butte, "Exploiting drug-disease relationships for computational drug repositioning," *Brief. Bioinf.*, vol. 12, no. 4, pp. 303–311, 2011.
- [30] F. Iorio, T. Rittman, H. Ge, M. Menden, and J. Saez-Rodriguez, "Transcriptional data: A new gateway to drug repositioning?" *Drug Discov. Today*, vol. 18, no. 7–8, pp. 350–357, 2013.
- [31] M. Sirota et al., "Discovery and preclinical validation of drug indications using compendia of public gene expression data," *Sci. Transl. Med.*, vol. 3, no. 96, pp. 96ra77–96ra77, 2011.

- [32] D. B. Kitchen, H. Decornez, J. R. Furr, and J. Bajorath, "Docking and scoring in virtual screening for drug discovery: Methods and applications," *Nat. Rev. Drug Discov.*, vol. 3, no. 11, pp. 935–949, 2004.
- [33] S. Dakshanamurthy et al., "Predicting new indications for approved drugs using a proteochemometric method," *J. Med. Chem.*, vol. 55, no. 15, pp. 6832–6848, 2012.
- [34] R. M. Cooke, A. J. Brown, F. H. Marshall, and J. S. Mason, "Structures of G protein-coupled receptors reveal new opportunities for drug discovery," *Drug Discov. Today*, vol. 20, no. 11, pp. 1355–1364, 2015.
- [35] W. Ma, L. Yang, and L. He, "Overview of the detection methods for equilibrium dissociation constant KD of drug-receptor interaction," *J. Pharmaceut. Anal.*, vol. 8, no. 3, pp. 147–152, 2018.
- [36] E. C. Meng, B. K. Shoichet, and I. D. Kuntz, "Automated docking with grid-based energy evaluation," *J. Comput. Chem.*, vol. 13, no. 4, pp. 505–524, 1992.
- [37] W. L. Jorgensen, J. Chandrasekhar, J. D. Madura, R. W. Impey, and M. L. Klein, "Comparison of simple potential functions for simulating liquid water," *J. Chem. Phys.*, vol. 79, no. 2, pp. 926–935, 1983.
- [38] A. Pullman, *Intermolecular Forces*. Berlin, Germany: Springer, 2013.
- [39] K. Raha et al., "The role of quantum mechanics in structure-based drug design," *Drug Discov. Today*, vol. 12, no. 17–18, pp. 725–731, 2007.
- [40] I. Kundu, G. Paul, and R. Banerjee, "A machine learning approach towards the prediction of protein–ligand binding affinity based on fundamental molecular properties," *RSC Advances*, vol. 8, no. 22, pp. 12127–12137, 2018.
- [41] M. M. Stepniewska-Dziubinska, P. Zielenkiewicz, and P. Siedlecki, "Development and evaluation of a deep learning model for protein–ligand binding affinity prediction," *Bioinformatics*, vol. 34, no. 21, pp. 3666–3674, 2018.
- [42] J. Gomes, B. Ramsundar, E. N. Feinberg, and V. S. Pande, "Atomic convolutional networks for predicting protein–ligand binding affinity," 2017, arXiv:1703.10603.
- [43] T. He, M. Heidemeyer, F. Ban, A. Cherkasov, and M. Ester, "SimBoost: A read-across approach for predicting drug–target binding affinities using gradient boosting machines," *J. Cheminform.*, vol. 9, no. 1, pp. 1–14, 2017.
- [44] W. Torng and R. B. Altman, "Graph convolutional neural networks for predicting drug–target interactions," *J. Chem. Inf. Model.*, vol. 59, no. 10, pp. 4131–4149, 2019.
- [45] J.-J. Lacapere, E. Pebay-Peyroula, J.-M. Neumann, and C. Etchebest, "Determining membrane protein structures: Still a challenge!" *Trends Biochem. Sci.*, vol. 32, no. 6, pp. 259–270, 2007.
- [46] UniProt Consortium, "UniProt: A worldwide hub of protein knowledge," *Nucleic Acids Res.*, vol. 47, no. D1, pp. D506–D515, 2019.
- [47] R. Rao et al., "Evaluating protein transfer learning with TAPE," in *Proc. Adv. Neural Inf. Process. Syst.*, 2019, pp. 9689–9701.
- [48] L. Jing and Y. Tian, "Self-supervised visual feature learning with deep neural networks: A survey," *IEEE Trans. Pattern Anal. Mach. Intell.*, early access, May 4, 2020, doi: [10.1109/TPAMI.2020.2992393](https://doi.org/10.1109/TPAMI.2020.2992393).
- [49] T. N. Kipf and M. Welling, "Semi-supervised classification with graph convolutional networks," in *Proc. Int. Conf. Learn. Representations*, 2017, pp. 24–38.
- [50] A. F. Agarap, "Deep learning using rectified linear units (ReLU)," 2018, arXiv:1803.08375.
- [51] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.
- [52] T. Minh Le, V. Le, S. Venkatesh, and T. Tran, "Dynamic language binding in relational visual reasoning," in *Proc. Int. Joint Conf. Artif. Intell.*, 2020, pp. 818–824.
- [53] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE Conf. Comput. Vis. Pattern Recog-nit*, 2016, pp. 770–778.
- [54] R. Wang, X. Fang, Y. Lu, and S. Wang, "The PDBbind database: Collection of binding affinities for protein–ligand complexes with known three-dimensional structures," *J. Med. Chem.*, vol. 47, no. 12, pp. 2977–2980, 2004.
- [55] R. Wang, X. Fang, Y. Lu, C.-Y. Yang, and S. Wang, "The PDBbind database: Methodologies and updates," *J. Med. Chem.*, vol. 48, no. 12, pp. 4111–4119, 2005.
- [56] R. Rao et al., "Evaluating protein transfer learning with TAPE," in *Proc. Adv. Neural Inf. Process. Syst.*, 2019, pp. 9689–9701.
- [57] S. Wang, S. Sun, Z. Li, R. Zhang, and J. Xu, "Accurate de novo prediction of protein contact map by ultra-deep learning model," *PLoS Comput. Biol.*, vol. 13, no. 1, 2017, Art. no. e1005324.
- [58] M. Fey and J. E. Lenssen, "Fast graph representation learning with PyTorch geometric," in *Proc. ICLR Workshop Representation Learn. Graphs Manifolds*, 2019, pp. 1–9.
- [59] M. G€onen and G. Heller, "Concordance probability and discriminatory power in proportional hazards regression," *Biometrika*, vol. 92, no. 4, pp. 965–970, 2005.
- [60] J. Benesty, J. Chen, Y. Huang, and I. Cohen, *Noise Reduction in Speech Processing*. Berlin, Germany: Springer, 2009.
- [61] D. Zwillinger and S. Kokoska, *CRC Standard Probability and Statistics Tables and Formulae*. Boca Raton, FL, USA: CRC Press, 1999.
- [62] I. Sanchez-Linares, H. Perez-Sanchez, J. M. Cecilia, and J. M. Garcia, "High-throughput parallel blind virtual screening using BIND-SURF," *BMC Bioinform.*, vol. 13, no. S14, 2012, Art. no. S13.
- [63] X. Chen, N.-N. Guan, Y.-Z. Sun, J.-Q. Li, and J. Qu, "MicroRNA-small molecule association identification: From experimental results to computational models," *Brief. Bioinf.*, vol. 21, no. 1, pp. 47–61, 2020.
- [64] K. D. Warner, C. E. Hajdin, and K. M. Weeks, "Principles for targeting rna with drug-like small molecules," *Nat. Rev. Drug Discov.*, vol. 17, no. 8, pp. 547–558, 2018.
- [65] C.-C. Wang and X. Chen, "A unified framework for the prediction of small molecule–MicroRNA association based on cross-layer dependency inference on multilayered networks," *J. Chem. Inf. Model.*, vol. 59, no. 12, pp. 5281–5293, 2019.
- [66] Y. Zhao, X. Chen, J. Yin, and J. Qu, "SNMFSSMA: Using symmetric nonnegative matrix factorization and Kronecker regularized least squares to predict potential small molecule–microRNA association," *RNA Biol.*, vol. 17, no. 2, pp. 281–291, 2020.



Tri Minh Nguyen 目前正在迪肯大学攻读博士学位。他的研究兴趣包括将机器学习应用于蛋白质结构和功能的研究。他正在探索基于能量模型在蛋白质结构和功能方面的应用。



阮廷 (Thin Nguyen) 在澳大利亚科廷大学获得计算机科学博士学位。他目前是澳大利亚迪肯大学应用人工智能研究所的高级研究员。他的研究兴趣包括跨学科领域，将大规模数据分析、模式识别、遗传学和医学相结合。他的研究方向是开发机器学习方法，以发现药物、基因和疾病之间的功能联系。



Thao Minh Le 目前在迪肯大学应用人工智能研究所攻读博士学位。他的研究兴趣包括计算机视觉及其应用以及机器推理。他目前正在探索跨不同模态的学习和推理的新领域。



Truyen Tran 目前是迪肯大学的副教授。他是应用人工智能研究所的成员，在该所负责深度学习及其在健康、基因组学、软件和材料科学领域应用的相关工作。他的研究兴趣包括概率图模型、推荐系统、排序学习、异常检测、多关系数据库、模型稳定性以及混合型分析。

如需了解有关此主题或任何其他计算机相关主题的更多信息，请访问我们的数字图书馆：www.computer.org/csdl。