



KNU-DTI: 知识联合药物-靶点相互作用预测

Ryong Heo ^{a,c}, Dahyeon Lee ^b, Byung Ju Kim ^c, Sangmin Seo ^d, Sanghyun Park ^d, Chihyun Park ^{a,b,c,e,*}



韩国江原道春川市江原国立大学医学大数据融合跨学科研究生项目, 邮编: 24341

韩国江原国立大学数据科学系, 韩国京畿道水原市交通路 237 号 c UBLBio 公司, 邮编 16679

韩国首尔西大门区延世路 50 号延世大学计算机科学系, 邮编 0372

韩国江原国立大学计算机科学与工程系

文章信息

关键词:

药物发现

基于序列的药物-靶标蛋白质相互作用

多模态表示学习 特征融合

摘要

动机: 准确预测药物与靶标蛋白的相互作用 (DTI) 是药物发现的关键所在, 有助于识别潜在的治疗化合物。尽管基于序列的预测模型较为简单, 但它们在直接从原始序列中提取关键信息方面展现出巨大潜力。然而, 近期的 DTI 研究越来越倾向于提升算法的复杂性, 这往往导致未能充分利用强大的序列表示学习方法。这种趋势导致了对有效捕捉序列中判别特征的方法的低估和逐渐忽视。我们的工作旨在纠正这一偏差, 强调精心构建的序列表示算法的价值, 证明即使采用简单的相互作用映射算法技术, 也能构建出准确的 DTI 模型。通过优先考虑有意义的信息提取而非过度追求模型复杂性, 我们致力于推进实用且通用的 DTI 预测框架的发展。结果: 我们开发了知识联合 DTI 模型 (KNU-DTI), 该模型能够检索结构信息并将其整合。蛋白质的结构特性是通过结构特性序列 (SPS) 获得的。扩展连接指纹 (ECFP) 用于评估分子中的构效关系。包含这两个特征, 通过各种神经网络从蛋白质和分子中总共推导出五个潜在向量, 并通过元素级相加进行整合, 以预测结合相互作用或亲和力。使用四个测试概念来评估模型, 我们表明该模型优于近期发表的竞争对手。最后, 一个案例研究表明, 在某些情况下, 我们的模型比现有的对接模拟更具优势。

1. 简介

药物发现或再利用是系统生物学领域的一个活跃研究方向。在此, 药物-靶点相互作用 (DTI) 预测对于预测 DTI 关系至关重要。尽管投入了大量资金和时间, 但基于传统湿实验室的药物发现研究在临床试验阶段的成功率仅为 10%。对于尚未进入临床试验的药物, 成功率往往低于 10% [1]。此外, 过去几十年产生了大量的高通量生物和化学数据, 其数量之大, 无法通过常规手段进行评估。

传统的基于湿实验室的研究。

这些局限性促使了计算机机器学习 (ML) 的发展,

这极大地降低了药物发现早期阶段的成本和时间[2]。从计算机科学的角度来看, 药物靶点相互作用 (DTI) 预测可以分为两类: i) 仅识别药物与靶点之间是否存在相互作用; ii) 回归, 即预测具有实际数值的结合亲和力, 这是一个复杂的问题。此前已基于二分类开发了许多基于机器学习的 DTI 预测模型[2]。诸如 KronRLS[3] 或 Simboost[4] 等模型则是基于机器学习的回归模型。利用精细的 3D 结构数据进行虚拟筛选、基于序列相似性的模型以及基于矩阵分解的模型在基于机器学习的 DTI 预测研究中取得了高分。尽管虚拟筛选在 DTI 预测中取得了很高的成功率, 但它存在计算成本高和时间复杂度大的问题。

* Corresponding author. Interdisciplinary Graduate Program in Medical Bigdata Convergence, Kangwon National University, Chuncheon-si, 24341, Gangwon-do, Republic of Korea

E-mail address: chihyun@kangwon.ac.kr (C. Park).

<https://doi.org/10.1016/j.combiomed.2025.109927>

Received 1 October 2024; Received in revised form 17 January 2025; Accepted 24 February 2025

Available online 1 March 2025

0010-4825/© 2025 The Authors. Published by Elsevier Ltd. This is an open access article under the CC BY-NC license (<http://creativecommons.org/licenses/by-nc/4.0/>).

基于深度学习 (DL) 的模型在各个领域都取得了比基于机器学习 (ML) 的模型更好的性能, 因此, 研究方向迅速转向使用基于深度学习的模型。

DeepAffinity [5] 使用了一种结构属性序列 (SPS), 旨在解决循环神经网络 (RNN) 存在的局限性。由于循环权重矩阵的反复乘法, 该模型存在与输入序列长度相关的梯度消失和梯度爆炸问题[6]。SPS 是一个由四个字母组成的代码序列, 其中针对原始蛋白质序列算法性地确定了不同的片段。尽管 SPS 尽可能多地保留了蛋白质结构信息, 但其长度却比原始蛋白质序列短 10 倍以上。这使得 RNN 能够避免与序列长度相关的梯度消失问题。

GraphDTA [7] 是首个将图神经网络 (GNN) [8] 应用于结合亲和力和预测的模型。此前的 GraphDTA 模型使用一维 (1D) 化合物序列, 例如简化分子线性输入规范 (SMILES) [9]。然而, Nguyen 等人认为 1D 化合物序列会丢失其拓扑信息。因此, 他们使用图结构的化合物数据来保留拓扑特征。使用了四种 GNN 变体, 即图卷积网络 (GCN)、图注意力网络 (GAT)、图同构网络 (GIN) 以及 GAT-GCN 组合模型来学习表示向量。

MolTrans [10] 使用变压器编码器 [11] 来获取蛋白质和化合物的表示向量。这些表示向量进行矩阵乘法运算以生成相互作用图。随后, 二维卷积神经网络 (2D CNN) 模块从相互作用图中学习局部模式。MolTrans 使用 FCS 矿算法为蛋白质和化合物序列生成子词标记 [12]。这种方法很有用, 因为某些蛋白质结构域、活性位点残基高度保守 [13], 化合物官能团也反复出现。

TransformerCPI [14] 保留了 Transformer 的编码器 - 解码器结构, 但改变了内部表示向量学习模块。对于蛋白质输入, 使用预训练的 Word2Vec [15] 模型执行 3-g 词嵌入。门控卷积神经网络 (GCNN) [16] 学习蛋白质表示向量。然后将化合物转换为二维图结构数据, 并使用图卷积网络 (GCN) 和自注意力模块进行处理。最后, 交叉注意力模块学习蛋白质和化合物表示向量之间的相互作用图。

与仅使用两个序列之间注意力得分的一般注意力机制不同, HyperAttentionDTI [17] 提出了一种超注意力机制, 该机制从深度特征空间向量计算注意力得分。卷积神经网络 (CNN) 模块学习蛋白质和化合物的表示向量。然后对每个表示向量执行超注意力模块操作。来自 CNN 模块的表示向量和超注意力向量被连接成决策向量。接着使用全连接 (FC) 层进行相互作用预测。超注意力机制将现有的低分辨率序列空间注意力机制扩展为高分辨率特征空间注意力机制。

感知器CPI [18] 使用有向消息传递神经网络 (D-MPNN) [19] 和摩根环指纹 (即 ECFP) [20] 从化学化合物中学习拓扑特征。D-MPNN 和 GCNN 块分别学习化合物和蛋白质的表示向量。第二个全连接层学习 ECFP 表示向量。两个化合物衍生的向量通过交叉注意力块转换为一个向量。另一个交叉注意力块从化合物和蛋白质的表示向量中创建相互作用图。由于大型语言模型最近在其他表示学习方法中脱颖而出, 构建高级相互作用图是药物靶点相互作用预测中的一个有前景的步骤。该模型展示了构建相互作用图的先进交叉注意力方法。此外, 药物靶点相互作用预测的最新进展, 例如 MT-DTA [21] 和 TDGraphDTA [22] 模型, 突显了设计复杂和复杂的神经网络的趋势。

网络架构。MT-DTA 模型通过自注意力机制和变分自编码器出色地捕捉了分子的局部和全局特征, 提高了相互作用预测的可解释性和准确性。同样, TDGraphDTA 模型利用多尺度信息交互和图优化来改进分子图表示, 并提取精细的上下文特征。这些方法突显了先进神经网络不仅能够提升药物与靶点之间相互作用图谱的学习效果, 还能提供更强的可扩展性、可解释性和预测性能。

尽管这些研究提供了相关的见解, 但现有方法的缺陷可总结如下。

- Although SPS 仍能提供结构信息, 仅使用 SPS 而不使用原始蛋白质序列会导致非结构信息的丢失。
- In 在 Moltrans 中, 二维卷积神经网络 (2D CNN) 是学习局部模式的理想模块, 但不适用于全局模式。对于药物 - 靶点对而言, 重要的相互作用序列通常相距较远, 这意味着全局模式在药物 - 靶点相互作用 (DTI) 预测中至关重要。
- The 在转换型 CPI 中使用的编码器 - 解码器模块的主要思想是机器翻译。换句话说, 对于不适合分类或回归的任务, 生成任务并非最佳选择。相反, 使用一个转换器编码器来学习表示向量并创建一个高级交互图, 对于 DTI 预测任务来说是合适的。
- HyperAttentionDTI 使用 1D CNN 块来学习表示向量。在 Moltrans 中, CNN 专门用于学习局部模式。在药物 - 靶点相互作用 (DTIs) 预测中, 蛋白质序列通常具有超过 1000 个残基的平均长度, 这给使用小尺寸的 CNN 核来有效捕捉全局模式带来了挑战。

受 Sun 等人[23]的启发, 他们证明了结合正交特征能够通过捕获其他子空间中剩余的有用信息来提高预测性能, 仅提取一个特征是不够的, 因为这可能会遗漏互补信息。我们认识到原始序列中存在多种内在信息, 例如二级或三级结构特征、手性、化学信息和分子结构信息。使用旨在捕获不同特征的学习模块来尽可能多地提取信息, 是药物-靶点相互作用 (DTI) 预测的重要因素。然而, 仅从序列数据中获取所有类型的信息是不可能的。因此, 我们专注于两个预期对预测 DTI 影响最大的主要属性。第一个是结构特征, 它捕捉蛋白质和化合物的几何和拓扑特性。第二个是基于注意力得分的上下文特征, 它检索整个序列中的上下文关系。我们提出了一种知识融合模型, 该模型通过三种表示学习模块来获取这些特征。我们使用图卷积神经网络 (GCNN) 通过卷积和门控函数来学习蛋白质的结构表示。对于具有图结构的化合物, 我们使用图神经网络 (GNN) 从化合物序列中学习分子拓扑特征, 并利用多层感知机 (MLP) 来学习化合物序列的分子结构特征。蛋白质和化合物都使用基于注意力机制的转换器模型来检索整个序列中的上下文关系。鉴于上述缺陷, 我们的贡献如下:

利用合适模块增强表示学习: 我们通过采用更合适的表示学习模块来解决现有 DTA 预测模型的局限性。与依赖局部模式或次优的翻译启发式架构的先前工作不同, 我们的模型能够有效地捕捉局部和全局模式。具体而言, 我们利用 GCNN 来表示蛋白质结构, 利用 GNN 来表示化合物的拓扑特征, 并利用注意力机制来学习序列内的全局上下文关系。

这种设计确保了与 DTI 相关的信息能够更全面、更有效地整合。

多种特征空间的整合：该模型通过逐元素相加的方式统一了蛋白质和化合物的独立表示，从正交的潜在空间中捕获互补信息。这种知识整合的方法能够将多种属性（例如结构、拓扑和上下文属性）整合到一个丰富且单一的潜在表示中，从而最大程度地减少信息损失并提高预测性能。

平衡模型的可访问性和预测性能：我们的方法通过将简单的神经网络模块与算法提取的特征相结合，实现了可访问性和性能之间的最佳平衡。这种设计为研究人员提供了直观的理解，同时保持了强大的预测准确性，使该模型对于实际的药物-靶点相互作用预测任务而言既易于访问又具有可扩展性。

2. 系统和方法

在本节中，我们将从所用数据和所提出的表示学习方法（图 1）两方面对 KNU-DTI 进行概述。本节中描述的所有表示向量均直接从在数据上进行端到端训练的模块中获得，未使用预训练模型。

2.1. 蛋白质表示

SPS 表示法 (OSPS)：我们使用 SSpro 和 ACCpro 生成 SPS [24]。这两个工具从原始蛋白质序列中提取二级结构序列和溶剂可及性序列。利用提取的序列和原始蛋白质序列，为每个片段获得相应的四字母 SPS 代码。第一个代码表示二级结构： α (A)、 β (B) 和卷曲 (C)。第二个代码表示溶剂暴露特征，即不暴露 (N) 或暴露 (E)。第三个类别表

示性质特征：非极性 (G)、极性 (T)、酸性 (D) 或碱性 (K)。最后一个字母表示片段长度：短 (S)、中 (M) 或长 (L)。SPS 的生成方法在补充信息中有详细描述。SPS 被嵌入并通过 GCNN 层以学习详细的结构特征。该模型具有一个 CNN 层以及一个输出门（即门控线性单元，GLU），这使得网络能够控制哪些信息应传递到下一层。直观地说，在语言建模中，门机制允许选择对预测下一个单词重要的单词或特征。卷积神经网络 (CNN) 层的流程如下：

$$h_1(X) = X * W + s \quad (1)$$

其中 $X \in \mathbb{R}^{n \times m_1}$ 是第 h_1 层的输入特征， $W \in \mathbb{R}^{k \times m_1 \times m_2}$ ， $s \in \mathbb{R}^{m_2}$ 。n 是 SPS 的最大长度。 m_2 的大小是 m_1 的两倍，这里，* 符号表示 1D 卷积操作，而非矩阵乘法。使用零填充以保持通过 GLU 的特征图的大小。卷积操作后， $h_1(X)$ 被分为两半。

$$A = h_1[: \text{half}] \quad (2)$$

$$B = h_1[\text{half}:] \quad (3)$$

其中 $A, B \in \mathbb{R}^{n \times m}$ ，随后进行门控操作。

$$h_1 = A \otimes \delta(B) \quad (4)$$

其中 $h_1 \in \mathbb{R}^{n \times m}$ ， δ 是一个非线性激活函数，默认使用 S 型函数。最后，添加跳跃连接层，然后乘以缩放因子，返回隐藏状态输出。

$$h_{l+1} = (h_l \oplus X) \times \text{scale} \quad (5)$$

蛋白质表示 (O_{Tp}): 黄等人提出了可解释子结构分区指纹 (ESPF) [12]，这是一种受自然语言中的字节对编码 (BPE) [25] 启发的算法




图 1.所提模型的工作流程：(a) 从蛋白质序列中提取的结构属性序列 (SPS) 被嵌入。通过 GCNN 层，获得包含所学结构信息的 SPS 表示向量 (O_{SPS})。 (b) 原始蛋白质序列被嵌入，多头自注意力编码器块学习蛋白质表示向量 (O_{Tp})。 (c) 使用 RDKit 将原始化合物序列转换为二维矩阵分子图结构。通过 t 步消息传递和最后的读出阶段，获得具有拓扑信息的图表示向量 (O_{Gc})。 (d) 与步骤 (b) 类似，将原始化合物序列转换为化合物表示向量 (O_{Tc})。 (e) 使用 RDKit 将原始化合物序列转换为 2048 维的二进制向量，也称为 Morgan 圆形指纹。MLP 层返回所学的 ECFP 表示向量 (O_{Mc})。 (f) 所有五个表示向量具有相同的形状。应用元素级相加，得到最终的知识联合表示向量 (F_p 和 F_c)。值得注意的是，联合后的向量 F_p 和 F_c 的颜色比联合前的每个表示向量包含更多信息。 (g) 向量连接成决策向量，最终的多层感知机 (MLP) 层返回最终的预测得分。（有关此图例中颜色的解释，请参阅本文的网络版。）

处理过程中, ESPF 能够识别序列 (如 SMILES 或氨基酸链) 中频繁出现的子结构, 并为药物和蛋白质生成可解释的指纹词汇表。该算法通过迭代合并最频繁出现的标记对来创建子结构词汇表, 从而将序列分解为有意义的子结构, 这些子结构以位向量的形式表示。此外, 其灵活性还使其能够应用于其他生物医学序列数据, 例如 DNA。利用 ESPF, 原始蛋白质序列被处理成子词标记, 然后转换为嵌入向量, 并通过一个变压器编码器生成 O_{Tp} 。变压器架构 [11] 最初是为机器翻译任务设计的, 已在包括自然语言处理 (NLP) 和生物信息学 [26] 在内的多个领域展现出卓越的性能。蛋白质和化合物序列 (如氨基酸、SMILES 和 SELFIES [27]) 已成功使用变压器进行建模以预测药物-靶点相互作用 (DTI), 生成的表示向量能够同时涵盖上下文特征和一般特征 [28]。变压器编码器采用多头自注意力模块, 其中查询 (Q)、键 (K) 和值 (V) 均来自同一来源。注意力机制的数学表示如下:

$$\text{attention}(Q, K, V) = \text{softmax}\left(QK^T / \sqrt{d_k}\right)V \tag{6}$$

2.2. 复合表示法

图表示 (O_{Gc}): 将化合物转换为图 $G(V, E)$, 其中 V 是原子 (顶点) 特征矩阵, 每个原子特征表示为 x_v 。同样, E 表示键 (边) 特征矩阵, 每个键特征表示为 evw 。我们采用了与标准 D-MPNN 相同的图初始化方法。组成原子和键的特征总结在表 1 中。尽管 D-MPNN 与现有的 MPNN [29] 结构相似, 但它考虑了键的方向性, 从而导致键的隐藏状态 (h_{vw} 和 h_{wv}) 根据其方向具有不同的值。D-MPNN 分为两个不同的阶段: 消息传递阶段和读出阶段。在消息传递阶段, 使用以下方程:

$$m_{vw}^{t+1} = \sum_{k \in N(v)} M_t(x_v, x_k, h_{kv}^t) \tag{7}$$

$$h_{vw}^{t+1} = U_t(h_{vw}^t, m_{vw}^{t+1}) \tag{8}$$

其中 $N(v)$ 表示每个顶点 v 的邻接顶点。 Σ is 是一个聚合函数, 用于聚合从邻接顶点流来的消息值 (m_{vw})。 M_t 和 U_t 分别是消息函数和更新函数, 您可以使用任何函数。在消息传递步骤 T 结束时, 每个原子的最终隐藏状态计算如下:

表 1
原子和键的初始特征化

原子特性	描述	尺寸
原子类型	原子类型 (例如: C、N、O), 按原子序数排列	100
# 债券	该原子参与的化学键数量	6
形式电荷	分配给原子的整数电子电荷	5
手性	未指定、四面体顺时针/逆时针或其他	4
# 赫斯	成键氢原子数	5
杂交	sp、sp ² 、sp ³ 、sp ³ d 或 sp ³ d ²	5
芳香性	这个原子是否属于芳香体系的一部分	1
原子质量	原子质量除以 10	1
债券特征	描述	尺寸
债券类型	单键、双键、三键或芳香键	4
共轭的	该化学键是否为共轭键	1
在环中	该键是否属于一个环的一部分	1
立体声	无、任何、顺反异构 (E/Z) 或顺反 (顺式/反式)	6

$$m_v = \sum_{k \in N(v)} h_{kv}^T \tag{9}$$

$$h_v = \tau(W_a \bullet \text{cat}(x_v, m_v)) \tag{10}$$

其中, $\text{cat}(x_v, m_v)$ 是初始化原子特征向量与每个顶点 v 的消息值的拼接向量, W_a 是可学习矩阵, τ 是激活函数。后续的读出阶段很简单: 将图中所有原子的隐藏状态相加, 以生成分子图特征向量:

$$h = \sum_{v \in G} h_v \tag{11}$$

复合表示 (O_{Tc}): 类似于蛋白质表示 (O_{Tp}), ESPF 算法被应用于 SMILES 嵌入。来自 ChEMBL [30] 数据集的约 200 万个分子序列被处理成 ESPF 子词词汇表。使用这些 ChEMBL 词汇表将 SMILES 转换为 ESPF 子词标记, 并通过一个 Transformer 编码器块生成丰富的复合表示向量。

摩根表示法 (O_{Mc}): 扩展连接指纹 (ECFP) [20] 是一种基于哈希的算法, 用于将分子结构表示为固定长度的位向量。ECFP 通过迭代探索分子中每个原子周围的圆形邻域来生成指纹, 从而捕获原子和键的特征。在每次迭代中, 相邻原子的特征会被组合并哈希处理, 以创建子结构的唯一标识符。ECFP 的早期版本被称为摩根指纹 [31], 最初旨在解决同构问题。然而, 在 21 世纪初, 该算法得到了改进, 以更好地捕捉与分子活性相关的特征, 并重新命名为扩展连接指纹 (ECFP)。ECFP 算法以其强大的化学结构特征捕捉能力而著称。此迭代过程会持续进行预先设定的迭代次数 (半径), 以纳入越来越大的分子子结构。在我们的研究中, 使用 RDKit [32] 将 SMILES 字符串转换为 ECFP, 参数设置为半径 2 和 2048 位。随后, 将得到的 2048 维二进制向量通过一个多层感知机 (MLP) 层进行处理, 以生成最终的 Morgan 表示向量 (O_{Mc})。

2.3. 知识融合

为了构建最终的知识统一表示向量, 我们基于这样一个观点: 嵌入空间反映了实体之间有意义的关系。正如 Mikolov 等人 [33] 所展示的那样, 具有相似属性的实体通常会被映射到方向相似的向量中, 而具有独立或不相关特征的实体则可能由于其独立性而被映射到正交方向。在此基础上, 我们提出, 专注于相似特征 (如结构和拓扑属性) 的学习模块, 其输出应映射到方向一致的表示向量中。相反, 旨在捕捉不同且独立特征 (如结构和序列属性) 的学习模块, 应生成正交的表示向量。基于这一基础, 我们参考了 Sun 等人 [23] 的研究, 该研究证明了在序数回归任务中通过正交投影向量提取多个独立特征的实用性。该研究表明, 组合正交向量能够创建更具信息量的决策边界, 从而提高预测性能。这些发现突显了利用独立特征不仅能够提高序数回归任务的准确性, 还能提升更广泛机器学习场景 (如回归和分类) 的性能。然而, 要有效地利用正交表示向量, 需要有方法能将它们进行最优组合, 同时保留其独立特征。在这方面, Word2vec [15] 表明, 在训练良好的嵌入空间内进行简单的元素级操作能够有效地捕捉到

词与词之间的关系，能够对相似和相对的概念进行简洁的表述。受此范例启发，我们假设正交表示向量的逐元素相加能够保留所有原始信息，同时合成一个更全面、更富信息量的表示。基于这些考虑，我们提出了以下假设。

· Since 每个学习模块针对不同的属性，因此这些模块所学习到的表示向量将呈现正交性。

· If 表示向量相互正交，执行逐元素加法运算能够有效地将独立信息整合到统一的潜在空间中。

· If 这种知识联合表示向量提升了 DTI 预测模型的性能，这验证了知识联合操作的有效性和合理性。

这些假设意味着，每个表示向量的逐元素相加会产生一个知识融合 的表示向量，该向量从多个独立的方向捕获互补的属性。直观地说，包含更多信息的蛋白质和化合物表示向量使得在相互作用图中区分正样本和负样本变得更容易。然后，我们将两个最终的知识融合向量连接起来以提取相互作用模式，随后通过一个多层感知机（MLP）层来预测相互作用。

$$F_p = O_{SPS} + O_{Tp}, F_c = O_{Gc} + O_{Tc} + O_{Mc} \quad (12)$$

$$\hat{y} = \text{MLP}(\text{concat}(F_p, F_c)) \quad (13)$$

我们将最后一层多层感知机（MLP）的输出大小设置为既能用于分类任务又能用于回归任务，并分别使用二元交叉熵（BCE）和均方误差（MSE）损失函数。对于回归任务，PerceiverCPI 采用加权更新方法来处理诸如 Davis 和 KIBA 这类数据分布不均衡的集合并且我们也采用了这种加权更新方法来聚焦于模型预期学习的标签范围。有关详细的加权方法，请参阅补充材料第 3 节。

2.4. 基准数据集

BindingDB [35] 是实验测定的蛋白质 - 配体结合亲和力最全面的公共数据库之一 [2]。ELECTRA-DTA [36] 确认 DeepAffinity 中使用的 BindingDB 数据包含重叠的配对。在去除重叠配对的过程中，数据集被精简至 129,109 个样本，并与 DeepAffinity 提供的人类蛋白质 - SPS 对表合并。对于未匹配的蛋白质，我们使用 SCRATCH-1D 构建 SPS。在生成 SPS 的过程中，有两条蛋白质序列被舍弃，最终我们获得了包含 129,107 个样本的 BindingDB 数据集。对于分类任务，我们以 pKi 值 6.5 作为阈值将正负配对分开。

BindingDB 蛋白质类别数据集包含来自 DeepAffinity 的数据，该数据集提供了蛋白质化合物对序列，并使用基因本体论（GO）术语获得了四类蛋白质标签。从原始数据集中排除重复项后，获得了 G 蛋白偶联受体（GPCR）（n = 73,042）、雌激素受体（ER, n = 495）、激酶（n = 3211）和离子通道（n = 7548）。由于该数据集并非随机整理，因此其分布与 BindingDB 不同。

戴维斯[37]研究了 442 种蛋白质和 68 种化合物，形成了 30,056 对药物-靶点（DT）组合。同样，我们使用了戴维斯数据集，但去除了 ELECTRA-DTA 提供的重复项。总共使用了 24,548 个样本，包括蛋白质-SPS 对。戴维斯数据集的 pKi 值分布严重偏斜，约为 5.0。使用与 BindingDB 相同的阈值会产生类别不平衡。因此，我们采用了 6.0 的阈值。

戴维斯模型以缓解类别不平衡问题。

PDBbind [38] 被用于评估所提出模型的通用性。

由于我们的目标是仅使用一维序列来预测药物靶点相互作用（DTIs），因此我们未使用任何三维结构信息。我们采用了来自 DeepDTAF [39] 的经过整理的 PDBbind 2016v 数据。DeepDTAF 原始数据集分为三部分，分别是通用集、精炼集和核心集，分别包含 9、221、3685 和 290 个复合物。我们选择了满足以下三个条件的蛋白质 - 配体复合物。

蛋白质序列长度超过 500 个氨基酸。

2) 与用作训练数据的全部 1614 种独特的 BindingDB 蛋白质相比，史密斯 - 沃特曼相似性比率低于 40%。

数据。

3) 智人起源

我们获得了 218 对无重复的蛋白质 - 配体组合。数据集的结合亲和力分布和 SPS 长度分别在图 S1 和 S2 中展示。表 2 描述了本研究所用数据集的详细信息。

3. 实施与讨论

3.1. 实验装置

我们进行了四项实验，以评估所提出的模型是否适用于分类和回归任务，以及该模型是否具有通用性。由于我们设计了两项测试来考察模型的通用性，因此未进行仅使用未见过的测试对集来评估模型性能的新对测试。在引言中提到的所有基于深度学习的模型均作为竞争模型使用。由于其中一些模型仅用于分类或回归任务，因此我们修改了最后一层输出的形状，并预测了评分函数，以执行分类和回归任务。

评估指标：我们对结合亲和力预测和相互作用预测得分均进行了评估。对于回归任务，我们使用了均方根误差（RMSE）、均方误差（MSE）、一致性指数（CI），该指数可确定预测标签顺序正确的随机成对样本数量占总样本对数的比例、R² 分数以及皮尔逊相关系数（PCC）。对于分类任务，我们使用了 AUROC、AUPRC、准确率、召回率和精确率等指标。

实验环境与超参数：我们遵循了基线模型相关论文中所描述的相关超参数设置。我们通过网格搜索对所提出的模型超参数进行了经验性搜索（表 S1）。

3.2. 模型性能测试

我们使用 BindingDB 和 Davis 数据集评估了模型在分类和回归方面的性能。然而，这些结果只能反映简单且浅层的药物靶点相互作用（DTI）预测性能，并不能确保模型的泛化能力。此外，由于 Davis 数据集的标签严重倾斜且样本数量较少，与特征空间相比样本稀疏，因此应谨慎解读结果。我们使用相同的随机状态值和分割函数将数据随机按 7:1:2 的比例（训练/验证/测试）分割了五次，以确保分割后的数据集相同，从而进行公平比较。表 3 和图 S5 展示了 BindingDB 的回归结果。

所提出的模型（KNU-DTI）在均方根误差（RMSE）和置信区间（CI）方面表现最佳。我们在表中列出了集成模型的结果以展示其最佳性能。然而，为了公平比较，我们以未采用集成的模型作为标准。我们还测试了 DeepAffinity，因为它是一个使用 SPS 的对比模型（表 S2）。表 4 和图 S6 展示了相同数据集的分类结果。所提出的模型在 AUROC、AUPRC、准确率和精确率方面均表现最佳。尽管 HyperAttentionDTI 在召回率方面得分最高，但在药物发现任务中，精确率比召回率更重要，因为低精确率意味着高误报率。

表 2 数据集详情。

数据集	化合物	蛋白质	正对	负样本对	总计	阈值 (pKi)
BindingDB	83,756	1614	75,606	53,501	129,107	6.5
戴维斯	68	361	4026	20,522	24,548	6
PDBbind	194	186	106	112	218	6.5
ER	287	6	338	157	495	6.5
GPCR	51,182	323	49,115	23,927	73,042	6.5
激酶	2367	48	2570	641	3211	6.5
离子通道	6838	78	4402	3149	7548	6.5

表 3
所提模型与基准模型在 BindingDB 回归任务上的对比结果。

模型	均方根误差 (越小越好)	CI (上升)
超注意力DTI	0.8220 (0.005)	0.8309 (0.001)
图 DTA (图卷积网络)	0.8279 (0.004)	0.8273 (0.001)
Moltrans	1.008 (0.025)	0.7895 (0.010)
ELECTRA 数据集	0.8062	0.8370 (0.002)
PerceiverCPI	0.8702 (0.011)	0.8193 (0.003)
KNU-DTI (基础版)	0.9594 (0.004)	0.7956 (0.001)
KNU-DTI (完整版)	0.7804 (0.002)	0.8410 (0.000)
KNU-DTI (完整版, 集成模型3)	0.7443 (0.004)	0.8505 (0.000)

阳性率，这会导致无意义的成本和时间消耗。GINConvNet 紧随我们的模型之后。这表明将化合物表示为图是一种很有前景的方法。尽管我们提出的模型在 Davis 数据集上的表现并非最佳。但这并不意味着我们的模型预测性能低于其他模型，因为 Davis 数据集存在数据不稳定性 (表 S3)。有关 Davis 数据集不稳定性的详细信息，请参阅补充材料的第 5 节。

3.3. 消融测试

为了验证第 2.3 节中定义的第一个假设，我们计算了从每个学习模块获得的表示向量之间的余弦相似度。余弦相似度值总结在表 5 中。除了使用 ECFP 和 D-MPNN 学习到的表示向量外，所有其他向量都表现出近乎零的相似度，这证实了它们的正交性。这一结果证实了第一个假设的有效性。此外，正如第二个假设所述，我们假设如果每个学习模块都能有效地捕获其目标特征，那么通过逐元素相加操作，所学的表示向量可以整合为一个知识统一向量。这个统一向量有望封装更丰富的特征信息用于药物-靶点相互作用 (DTI) 预测。如果新构建的知识统一向量能更有效地捕获用于 DTI 预测的更全面信息，其贡献可以通过消融测试来分析。这些测试旨在验证第 2.3 节中的第二个和第三个假设。蛋白质和化合物转换器编码器模块均被用作基础模块，而其他模块则作为消融条件的附加特征。消融测

表 4
所提模型与基准模型在 BindingDB 分类上的比较结果。

模型	AUROC	AUPRC	ACC	召回	精度
变压器CPI	0.8816 (0.003)	0.9054 (0.002)	0.8036 (0.001)	0.8187 (0.013)	0.8458 (0.007)
超注意力DTI	0.9050 (0.001)	0.9249 (0.003)	0.8350 (0.002)	0.9011 (0.005)	0.8319 (0.005)
图 DTA (图卷积网络)	0.9065 (0.003)	0.9232 (0.003)	0.8341 (0.004)	0.8455 (0.006)	0.8672 (0.002)
Moltrans	0.8525 (0.011)	0.8815 (0.012)	0.7807 (0.012)	0.8606 (0.008)	0.7866 (0.014)
CPI	0.8801 (0.001)	0.9053 (0.003)	0.8142 (0.020)	0.8331 (0.020)	0.8337 (0.008)
KNU-DTI (完整版)	0.9121 (0.001)	0.9319 (0.001)	0.8383 (0.005)	0.8490 (0.016)	0.8724 (0.004)
KNU-DTI (完整版, 集成模型3)	0.9230 (0.001)	0.9413 (0.001)	0.8496 (0.003)	0.8583 (0.014)	0.8827 (0.006)
KNU-DTI (基线)	0.8730 (0.002)	0.8965 (0.003)	0.7989 (0.003)	0.8165 (0.011)	0.8363 (0.004)

试结果表明，ECFP 表征向量对模型性能有显著影响 (表 6)。此外，正如预期的那样，通过分别使用每个附加特征，我们能够进一步提高模型性能。这表明所有学习模块所学习到的表征向量成功地捕获了提高预测性能所需的信息。然而，消融测试揭示了一个值得注意的例外情况。当 ECFP 表征向量与 D-MPNN 表征向量结合使用时，与单独使用 ECFP 表征向量相比，并未观察到性能提升。有趣的是，这与基于余弦相似度的观察结果一致，即 ECFP 和 D-MPNN 表征向量是唯一一对未能表现出正交性的。这表明通过 ECFP 和 D-MPNN 学习模块所学习到的信息并非完全独立，包含了一些冗余特征。鉴于 D-MPNN 关注二维化合物图的拓扑特征，而 ECFP 则通过算法描述符强调分子结构特征，因此这两个模块有可能捕获到重叠的信息。

3.4. 蛋白质类别依赖性测试

我们使用基于蛋白质类别的测试来评估模型的泛化能力。用于模型性能测试的相同 BindingDB 数据集 (n = 129,107) 被随机分为训练集和验证集，比例为 0.95:0.05。为了最大限度地增加可用于训练的数据量，仅将 5% 的数据分配给验证集。超参数是通过 3.2 节的模型性能测试确定的，测试集作为外部数据集准备，而非从训练数据中划分。这使我们能够在不损害评估过程的情况下为训练分配更多数据。基于 GO 术语选择的蛋白质类别标记数据集被用作测试集。尽管训练集和测试集均来自同一数据库，但由于其不同的选择方法，它们之间的依赖性显著降低：训练集是通过

表 5
表示向量之间的余弦相似度。

表示向量对		余弦相似度
蛋白质	奥克斯斯/奥特普	0.07
化合物	场外 [	0.04
	OTC/OTC	0.04
	/ / OMc	0.23

表 6
使用 Binding DB 进行消融测试。

消融设置			均方误差 (↓)	均方根误差 (越小越好)	CI (上升)	R2 (↑)
SPS	D-MPNN	ECFP				
X	X	X	0.9282 (0.007)	0.9634 (0.003) (-19.3%)	0.7954 (0.000)	0.6178 (0.003)
O	X	X	0.8780 (0.015)	0.9370 (0.008) (-17.0%)	0.8004 (0.002)	0.6385 (0.006)
X	O	X	0.8531 (0.010)	0.9236 (0.006) (-15.8%)	0.8030 (0.001)	0.6487 (0.004)
X	X	O	0.6393 (0.006)	0.7995 (0.004) (-2.7%)	0.8357 (0.001)	0.7368 (0.002)
O	O	X	0.8218 (0.005)	0.9065 (0.003) (-14.2%)	0.8080 (0.001)	0.6616 (0.002)
O	X	O	0.6113 (0.006)	0.7819 (0.004) (-0.5%)	0.8419 (0.000)	0.7483 (0.002)
X	O	O	0.6391 (0.005)	0.7994 (0.003) (-2.7%)	0.8365 (0.001)	0.7368 (0.002)
O	O	O	0.6053 (0.003)	0.7780 (0.002) (0.0%)	0.8413 (0.000)	0.7508 (0.001)

*注：均方根误差（RMSE）列中的第三个值表明其与最高得分的比率呈下降趋势。

对无效数据进行了算法过滤，而测试集则是基于 GO 术语分类构建的。此外，训练集和测试集之间的 Smith-Waterman 比对得分显示平均序列相似度低于 30%，进一步表明它们之间的重叠度较低。这些观察结果表明，基于蛋白质类别的测试对模型的泛化能力进行了部分评估。基于蛋白质类别的测试结果见表 7 和图 S7。所提出的模型在激酶、GPCR 和离子通道类别中表现最佳。然而，对于 ER 类别，基于简单 Transformer 编码器的模型表现最佳。值得注意的是，ER 类别仅有 6 个蛋白质样本，显著低于其他类别。这可能会导致结果的方差较大，从而造成不准确性。

3.5. 额外领域测试

如上所述，仅使用基于蛋白质类别的测试无法确保模型的泛化能力。因此，我们进行了额外的领域测试。我们使用了与蛋白质类别相关测试中相同的训练/验证集，但将 PDBbind 数据用作测试集。由于所用测试集与训练集的序列相似度较低（第 2.6 节），现在可以确保我们模型的泛化能力（表 8 和图 S8）。我们的模型总体上表现最佳。这表明我们的模型比其他基准模型具有更好的泛化能力。尽管我们的模型总体上

在取得最佳性能的情况下，跨域测试的均方根误差显著高于模型性能测试中的均方根误差（第 3.2 节）。这表明所提出的模型的泛化能力优于基线模型；不过，我们谨慎地认为，我们模型的绝对泛化能力足以应用于实际研究。

3.6. 案例研究

我们证明了所提出的模型能够有效地预测药物-靶点相互作用（DTIs）。然而，从药物发现的角度来看，DTI 预测模型可以与分子生成模型相结合，基于靶蛋白生成新的化合物序列。基于序列的 DTI 预测模型具有易于理解且能应用于新药物-靶蛋白对的优势。此外，由于它们能迅速返回预测结果，因此不会造成瓶颈。换句话说，它们可以作为生成分子模型的结合亲和力评估模块。然而，如前所述，序列信息检索仍是一个挑战。基于三维（3D）结构的对接模拟器利用从实际实验中获得的复杂 3D 相互作用信息，因此比基于序列的 DTI 预测方法更精确。然而，对接模拟器计算成本高，时间复杂度大。因此，尽管对接模拟器可用于高通量分析，但其计算成本高，时间复杂度大，这限制了其应用。

表 7
蛋白质类别依赖性测试。

蛋白质类别	模型	均方误差 (↓)	均方根误差 (越小越好)	CI (上升)	R2 (↑)	PCC (↑)
激酶 (n = 3211)	Moltrans	4.5670	2.1371	0.4941	−1.3538	−0.0142
	图数据处理架构 (图卷积神经网络)	3.8158	1.9534	0.6012	−0.9676	0.3189
	超注意力DTI	3.4217	1.8498	0.5437	−0.7644	0.1370
	感知者消费者价格指数	4.9380	2.2222	0.5973	−1.5463	0.3239
	KNU-DTI (完整版)	3.2089	1.7913	0.6270	0.6547	0.3791
	KNU-DTI (基线)	3.9074	1.9767	0.4975	−1.0138	−0.0205
GPCR (n = 73,042)	Moltrans	2.0176	1.4204	0.5376	−0.2486	0.1213
	图数据处理架构 (图卷积神经网络)	2.2113	1.4870	0.5557	−0.3684	0.1846
	超注意力DTI	1.9587	1.3995	0.5384	−0.2121	0.1278
	感知者消费者价格指数	2.0906	1.4459	0.5833	−0.2937	0.2805
	KNU-DTI (完整版)	1.8318	1.3534	0.5822	0.1336	0.2766
	KNU-DTI (基线)	2.3590	1.5359	0.5211	−0.4599	0.0710
急诊室 (n = 495)	Moltrans	2.2962	1.5153	0.5483	0.2570	0.1655
	图数据处理架构 (图卷积神经网络)	3.6589	1.9128	0.5578	−1.0122	0.1903
	超注意力DTI	2.7541	1.6596	0.4382	−0.5147	−0.1777
	感知者消费者价格指数	3.1235	1.7673	0.5618	−0.7178	0.1900
	KNU-DTI (完整版)	2.6881	1.6395	0.5375	−0.4783	0.1148
	KNU-DTI (基线)	2.2943	1.5147	0.5145	−0.2995	0.0662
频道 (n = 7548)	Moltrans	2.2828	1.5109	0.5393	−0.2437	0.1269
	图数据处理架构 (图卷积神经网络)	2.3999	1.5492	0.5435	−0.3063	0.1196
	超注意力DTI	2.2810	1.5103	0.5456	−0.2415	0.1336
	感知者消费者价格指数	2.8678	1.6935	0.5820	−0.5609	0.2628
	KNU-DTI (完整版)	2.1519	1.4669	0.5883	0.1713	0.2709
	KNU-DTI (基线)	2.7516	1.6588	0.5038	−0.5002	0.0384

表 8 PDB 额外域测试。

蛋白质类别	模型	均方误差 (↓)	均方根误差 (越小越好)	CI (上升)	R2 (上升)	PCC (↑)
PDB (n = 218)	Moltrans	6.7882	2.6054	0.5913	-1.1249	0.1381
	图深度学习药物相互作用预测模型	3.6071	1.8992	0.5343	-0.1085	0.0709
	超注意力	3.2008	1.7891	0.5967	0.0164	0.3327
	感知者消费者价格指数	3.2657	1.8071	0.6134	-0.0035	0.3290
	KNU-DTI (完整版)	2.7839	1.6685	0.6604	0.1445	0.4383
	KNU-DTI (基线)	5.2026	2.2809	0.4898	-0.5987	-0.0310

在端到端生成模型中，虽然不需要即时响应，但它可能是工作流程中的一个限速步骤。在本节中，我们将展示一个案例研究，内容是关于 3D 分子对接方法与所提出的基于序列的模型在药物靶点相互作用 (DTIs) 预测得分上的相关性。我们使用以下三个得分展示了相关性热图。

- 1) 来自真实实验的 PDB pK_i/pK_a 标签。
- 2) 使用吉布斯自由能评分的 Vina 分子对接模拟器。
- 3) 使用所提出模型中的 pKi 值预测的 DTA。

Vina 分子对接分数代表药物与靶蛋白之间的吉布斯自由能。负值表示自发反应占主导，正值表示非自发反应占主导，零值表示处于平衡状态。我们使用了 UCSF Chimera [40] 和 AutoDock Vina 分子对接模拟器 [41] 以及与额外域测试 (第 3.5 节) 相同的 PDBbind 数据集。然而，在对接过程中，有一个样本被排除在外，因为我们无法获得其明确的对接分数。本研究共使用了 217 个样本。

案例研究的结果以散点图的形式呈现 (图 2)。样本被分为三组，即单体、均聚物和杂聚物。在杂聚物组中，Vina 分子对接得分与标签之间的最佳 PCC 值为 -0.38。相比之下，在均聚物组中，预测的 pK_i 值与标签之间的最佳 PCC 值为 0.49。这可以解释为所提出的模型预测的值具有正向被标记的趋势。此外，基于序列预测的 pK_i 值的相关性高于对接得分的相关性。与普遍观念不同，这些结果表明，在某些情况下，基于序列的预测模型比对接模拟器更具优势。

4. 结论

在本研究中，我们提出了一种基于序列的知识融合模型 KNU-DTI，该模型利用算法提取的特征 (如 SPS 和 ECFPs) 来学习结构信息。我们表明，与基准模型相比，我们的模型具有最佳的药物靶点相互作用 (DTIs) 预测能力和泛化能力。

此外，通过消融测试，我们证明了这些提取的特征会影响预测性能，并且知识融合可以是一种有效的方法。另外，一个案例研究表明，在某些情况下，基于序列的 DTI 预测模型比对接模拟器更具优势。

然而，我们的模型存在一些局限性。本研究的一个关键局限在于无法定量地建立正交性与信息真正独立性之间的关系，也无法精确评估表示向量之间的冗余程度。其次，虽然我们证明了在多样化的表示向量上进行训练能够通过将它们整合为知识向量来提升性能，但这种方法也会导致模型复杂度增加以及过拟合风险上升。解决这些局限性将是未来工作的重点，旨在更严格地理解各个表示向量对预测性能的相互作用和贡献，同时提高信息捕获能力并降低模型复杂度。

CRedit 作者贡献声明

Ryong Heo: 撰写 - 初稿, 验证, 软件, 方法论, 数据整理, 概念化。**Dahyeon Lee**: 可视化, 验证, 软件, 数据整理。**Byung Ju Kim**: 撰写 - 初稿, 调查, 资金获取, 概念化。**Sangmin Seo**: 正式分析, 数据整理, 概念化。**Sanghyun Park**: 项目管理, 调查, 资金获取, 概念化。**Chihyun Park**: 撰写 _review 及编辑, 撰写 _初稿, 可视化, 监督, 资源, 项目管理, 调查, 资金获取, 概念化。

数据可用性

本研究中所用模型的运行数据集和代码可在我们的 GitHub 页面获取: https://github.com/DBpackage/KNU_DTA。

固态离子学伦理声明

- 1) 本材料为作者原创作品，此前未曾在他处发表。




图 2.案例研究散点图。(a) pK_i(label) 与对接分数呈轻微负相关。(b) pK_i 与预测的 pK_i 值 (DTA) 呈正相关。(c) 对接分数与预测的 pK_i 值呈负相关。

- 2) 该论文目前未在其他任何地方投稿或考虑发表。
- 3) 该论文真实、完整地反映了作者自身的研究和分析。
- 4) 该论文恰当地肯定了合著者和合作研究者所做出的重要贡献。
- 5) 研究结果恰当地置于先前和现有的研究背景之中。
- 6) 所有使用的资料都应正确披露（正确引用）。逐字照搬的文本必须加引号并给出恰当的出处。
- 7) 所有作者均亲自并积极参与了形成该论文的大量工作，并将对论文内容承担公开责任。

违反《道德准则》的规定可能会导致严重的后果。

为验证原创性，您的文章可能会通过原创性检测软件 iThenti cate 进行检查。详情请见 <http://www.elsevier.com/editors/plagdetect>。

关于写作过程中使用生成式人工智能及人工智能辅助技术的声明

在撰写本作品期间，作者使用了 ChatGPT v4.0 来修订语法并提高某些段落的可读性。使用该工具/服务后，作者根据需要对内容进行了审查和编辑，并对发表的文章内容承担全部责任。

利益冲突声明

作者声明，他们不存在任何已知的可能影响本论文所述研究工作的财务利益冲突或个人关系。

致谢

本研究得到了韩国国家研究基金会（NRF）资助，该基金由韩国政府（科学技术信息通信部）提供（项目编号：RS-2023-00229822、NRF-2022R1F1A1075186、RS-2023-00242528）。

附录 A. 补充数据

本文的补充数据可在 <https://doi.org/10.1016/j.compbimed.2025.109927> 上获取。

参考文献

- [1] D. Sun, W. Gao, H. Hu, S. Zhou, Why 90% of clinical drug development fails and how to improve it? *Acta Pharm. Sin. B* 12 (7) (2022) 3049–3062.
- [2] X. Chen, C.C. Yan, X. Zhang, X. Zhang, F. Dai, J. Yin, et al., Drug–target interaction prediction: databases, web servers and computational models, *Briefings Bioinf.* 17 (4) (2016) 696–712.
- [3] A.C. Nascimento, R.B. Prudêncio, I.G. Costa, A multiple kernel learning algorithm for drug–target interaction prediction, *BMC Bioinf.* 17 (2016) 1–16.
- [4] T. He, M. Heidemeyer, F. Ban, A. Cherkasov, M. Ester, SimBoost: a read-across approach for predicting drug–target binding affinities using gradient boosting machines, *J. Cheminf.* 9 (1) (2017) 1–14.
- [5] M. Karimi, D. Wu, Z. Wang, Y. Shen, DeepAffinity: interpretable deep learning of compound–protein affinity through unified recurrent and convolutional neural networks, *Bioinformatics* 35 (18) (2019) 3329–3338.
- [6] Independently recurrent neural network (indrmn): building a longer and deeper rnn, in: S. Li, W. Li, C. Cook, C. Zhu, Y. Gao (Eds.), *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2018.
- [7] T. Nguyen, H. Le, T.P. Quinn, T.D. Le, S. Venkatesh, GraphDTA: predicting drug–target binding affinity with graph neural networks, *Bioinformatics* 37 (8) (2021) 1140–1147.
- [8] F. Scarselli, M. Gori, A.C. Tsoi, M. Hagenbuchner, G. Monfardini, The graph neural network model, *IEEE Trans. Neural Network.* 20 (1) (2008) 61–80.
- [9] D. Weininger, SMILES, a chemical language and information system. 1. Introduction to methodology and encoding rules, *J. Chem. Inf. Comput. Sci.* 28 (1) (1988) 31–36.
- [10] K. Huang, C. Xiao, L.M. Glass, J. Sun, MolTrans: molecular interaction transformer for drug–target interaction prediction, *Bioinformatics* 37 (6) (2021) 830–836.
- [11] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A.N. Gomez, et al., Attention is all you need, *Adv. Neural Inf. Process. Syst.* 30 (2017).
- [12] K. Huang, C. Xiao, L. Glass, J. Sun (Eds.), *Explainable Substructure Partition Fingerprint for Protein, Drug, and More*, *NeurIPS Learning Meaningful Representation of Life Workshop*, 2019.
- [13] J. Mistry, A. Bateman, R.D. Finn, Predicting active site residue annotations in the Pfam database, *BMC Bioinf.* 8 (1) (2007) 1–14.
- [14] L. Chen, X. Tan, D. Wang, F. Zhong, X. Liu, T. Yang, et al., TransformerCPI: improving compound–protein interaction prediction by sequence-based deep learning with self-attention mechanism and label reversal experiments, *Bioinformatics* 36 (16) (2020) 4406–4414.
- [15] T. Mikolov, K. Chen, G. Corrado, J. Dean, Efficient Estimation of Word Representations in Vector Space, 2013 arXiv preprint arXiv:1301.3781.
- [16] Language modeling with gated convolutional networks, in: Y.N. Dauphin, A. Fan, M. Auli, D. Grangier (Eds.), *International Conference on Machine Learning*, PMLR, 2017.
- [17] Q. Zhao, H. Zhao, K. Zheng, J. Wang, HyperAttentionDTI: improving drug–protein interaction prediction by sequence-based deep learning with attention mechanism, *Bioinformatics* 38 (3) (2022) 655–662.
- [18] N.-Q. Nguyen, G. Jang, H. Kim, J. Kang, Perceiver CPI: a nested cross-attention network for compound–protein interaction prediction, *Bioinformatics* 39 (1) (2023) btac731.
- [19] K. Yang, K. Swanson, W. Jin, C. Coley, P. Eiden, H. Gao, et al., Analyzing learned molecular representations for property prediction, *J. Chem. Inf. Model.* 59 (8) (2019) 3370–3388.
- [20] D. Rogers, M. Hahn, Extended-connectivity fingerprints, *J. Chem. Inf. Model.* 50 (5) (2010) 742–754.
- [21] Z. Zhu, Z. Yao, G. Qi, N. Mazur, P. Yang, B. Cong, Associative learning mechanism for drug–target interaction prediction, *CAAI. Trans. Intell. Technol.* 8 (4) (2023) 1558–1577.
- [22] Z. Zhu, Z. Yao, X. Zheng, G. Qi, Y. Li, N. Mazur, et al., Drug–target affinity prediction method based on multi-scale information interaction and graph optimization, *Comput. Biol. Med.* 167 (2023) 107621.
- [23] B.-Y. Sun, H.-L. Wang, W.-B. Li, H.-J. Wang, J. Li, Z.-Q. Du, Constructing and combining orthogonal projection vectors for ordinal regression, *Neural Process. Lett.* 41 (2015) 139–155.
- [24] J. Cheng, A.Z. Randall, M.J. Sweredoski, P. Baldi, SCRATCH: a protein structure and structural feature prediction server, *Nucleic. acids. Res.* 33 (suppl_2) (2005) W72–W76.
- [25] P. Gage, A new algorithm for data compression, *C Users J.* 12 (2) (1994) 23–38.
- [26] T. Lin, Y. Wang, X. Liu, X. Qiu, A Survey of Transformers, *AI Open*, 2022.
- [27] M. Krenn, F. Hase, A. Nigam, P. Friederich, A. Aspuru-Guzik, Self-referencing embedded strings (SELFIES): a 100% robust molecular string representation, *Mach. Learn.: Sci. Technol.* 1 (4) (2020) 045024.
- [28] A.M. Bran, P. Schwaller, Transformers and large language models for chemistry and drug discovery. *Drug Development Supported by Informatics*, Springer, 2024, pp. 143–163.
- [29] J. Gilmer, S.S. Schoenholz, P.F. Riley, O. Vinyals, G.E. Dahl (Eds.), *Neural Message Passing for Quantum Chemistry*. *International Conference on Machine Learning*, PMLR, 2017.
- [30] A. Gaulton, L.J. Bellis, A.P. Bento, J. Chambers, M. Davies, A. Hersey, et al., ChEMBL: a large-scale bioactivity database for drug discovery, *Nucleic. acids. Res.* 40 (D1) (2012) D1100–D1107.
- [31] H.L. Morgan, The generation of a unique machine description for chemical structures—a technique developed at chemical abstracts service, *J. Chem. Doc.* 5 (2) (1965) 107–113.
- [32] G. Landrum, RDKit: Open-Source Cheminformatics, 2006.
- [33] Linguistic regularities in continuous space word representations, in: T. Mikolov, W.-Y. H. G. Zweig (Eds.), *Proceedings of the 2013 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 2013.
- [34] J. Tang, A. Szawajda, S. Shakyawar, T. Xu, P. Hintsanen, K. Wennerberg, et al., Making sense of large-scale kinase inhibitor bioactivity data sets: a comparative and integrative analysis, *J. Chem. Inf. Model.* 54 (3) (2014) 735–743.
- [35] T. Liu, Y. Lin, X. Wen, R.N. Jorissen, M.K. Gilson, BindingDB: a web-accessible database of experimentally determined protein–ligand binding affinities, *Nucleic. acids. Res.* 35 (suppl_1) (2007) D198–D201.
- [36] J. Wang, N. Wen, C. Wang, L. Zhao, L. Cheng, ELECTRA-DTA: a new compound–protein binding affinity prediction model based on the contextualized sequence encoding, *J. Cheminf.* 14 (1) (2022) 1–14.
- [37] M.I. Davis, J.P. Hunt, S. Herrgard, P. Ciceri, L.M. Wodicka, G. Pallares, et al., Comprehensive analysis of kinase inhibitor selectivity, *Nat. Biotechnol.* 29 (11) (2011) 1046–1051.
- [38] R. Wang, X. Fang, Y. Lu, S. Wang, The PDBbind database: collection of binding affinities for protein–ligand complexes with known three-dimensional structures, *J. Med. Chem.* 47 (12) (2004) 2977–2980.

- [39] K. Wang, R. Zhou, Y. Li, M. Li, DeepDTAF: a deep learning method to predict protein–ligand binding affinity, *Briefings Bioinf.* 22 (5) (2021) bbab072.
- [40] E.F. Pettersen, T.D. Goddard, C.C. Huang, G.S. Couch, D.M. Greenblatt, E.C. Meng, et al., UCSF Chimera—a visualization system for exploratory research and analysis, *J. Comput. Chem.* 25 (13) (2004) 1605–1612.
- [41] O. Trott, A.J. Olson, AutoDock Vina: improving the speed and accuracy of docking with a new scoring function, efficient optimization, and multithreading, *J. Comput. Chem.* 31 (2) (2010) 455–461.