



MMDG-DTI: 基于多模态特征融合和领域泛化的药物-靶点相互作用预测

Yang Hua^a, Zhenhua Feng^{b,c}, Xiaoning Song^{a,*}, Xiao-Jun Wu^a, Josef Kittler^{b,c}

^a 中国江苏省无锡市江南大学人工智能与计算机科学学院, 邮编: 21412

^b 英国萨里大学计算机科学与电子工程学院, 吉尔福德, GU2 7XH, 英国

^c 英国萨里大学视觉、语音与信号处理中心, 吉尔福德, GU2 7XH, 英国

文章信息

数据集链接: <https://github.com/JU-HuaY/MMDG-DTI>, https://drive.google.com/file/d/1TLcGfcpmgFlPqm1aBw-EW23TdOy0z7rL/view?usp=share_link, https://drive.google.com/file/d/1hSsu2D8XcRama_gnmp5FpxSEXi_wtbOV/view?usp=drive_link, <https://drive.google.com/file/d/1dSpGwBbFp6yOPtCIY4a-LbjvWJrowhdY/view?usp=sharing>

关键词:

药物-靶点相互作用 多模态特征融合 域泛化

摘要

近来, 深度学习已成为药物靶点相互作用 (DTI) 预测的关键方法。然而, 现有的基于学习的表示方法会嵌入训练数据所包含的先验知识, 从而获取与 DTI 预测无关的冗余领域信息, 这会降低深度网络对陌生实例的泛化能力。为解决这一局限性, 我们提出了一种基于多模态特征融合和领域泛化的新型 DTI 预测方法 (MMDG-DTI)。具体而言, 我们首先利用预训练的大规模语言模型 (LLMs) 获取涵盖几乎整个生物文本词汇的通用文本特征, 具备处理未见过样本的能力, 并能提取出稳健且具有区分性的特征。同时, 我们提出了一种基于混合图神经网络 (GNN) 的统一结构特征提取器。该提取器通过从另一种模态中提取特征并舍弃领域特定先验子结构的表示, 从而提升了 MMDG-DTI 的性能。然后, 我们利用一种创新的分类器整合了 LLM 和 GNN 特征的互补信息, 并借助领域对抗训练 (DAT) 和对比学习来增强泛化能力。最后, 我们提出了一种新颖的跨领域评估协议, 以提高实际应用中的预测准确性。在多个基准数据集上获得的定量和可视化结果表明, MMDG-DTI 在单领域和跨领域设置下均达到了最先进的性能, 证实了所提出方法的优越性。数据集和代码将在项目主页上提供: <https://github.com/JU-HuaY/MMDG-DTI>。

1. 简介

药物靶点相互作用 (DTI) 预测对于虚拟药物筛选以及提高传统药物发现流程的效率至关重要[1]。现有的 DTI 预测模型大致可分为两类: 基于分类的方法[2]和基于回归的方法[3]。分类模型用于识别药物与靶点蛋白之间的相互作用, 而回归模型则用于量化结合亲和力。由于这两类模型的架构相似, 我们在文献中对现有的 DTI 和药物靶点结合亲和力 (DTA) 预测模型进行了交叉引用[4,5]。与模式识别领域的其他任务类似, 大多数现有的 DTI 方法都是基于深度学习的[6,7]。这些方法通过探究药物化合物和靶点蛋白的内在特性, 并整合多种深度神经网络组件, 探索了各种框架。Ozturk 等人首次提出了 DeepDTA[7], 该模型应用卷积神经网络 (CNN) 和多层感知机 (MLP) 来提取药物和蛋白质的特征, 以进行 DT

A 估计。沿着这些思路, 众多研究 [8-10] 都致力于通过优化三个关键部分来改进药物-靶点相互作用 (DTI) 模型: 药物特征提取、蛋白质特征提取以及分类器设计。

在药物特征提取方面, Lee 等人[8]提出使用分子指纹[11]和多层感知机 (MLP), 其预测性能优于 DeepDTA 中使用的序列药物特征。Nguyen 等人[9]提出采用图结构来表示药物特征, 并研究了多种图网络, 包括 GCN[12]、GAT[13] 和 GIN[14], 进一步丰富了药物特征提取的过程。在蛋白质特征提取方面, Tsubaki 等人提出了 CPI-GNN[10], 通过包含比 DeepDTA 中使用的氨基酸嵌入更复杂文本信息的词嵌入来表示蛋白质, 在一定程度上提高了预测性能。为了增强蛋白质的文本属性, Chen 等人[15]提出

*Corresponding author.

E-mail address: x.song@jiangnan.edu.cn (X. Song).

<https://doi.org/10.1016/j.patcog.2024.110887>

Received 5 November 2023; Received in revised form 3 March 2024; Accepted 12 August 2024

Available online 20 August 2024

0031-3203/© 2024 Elsevier Ltd. All rights are reserved, including those for text and data mining, AI training, and similar technologies.

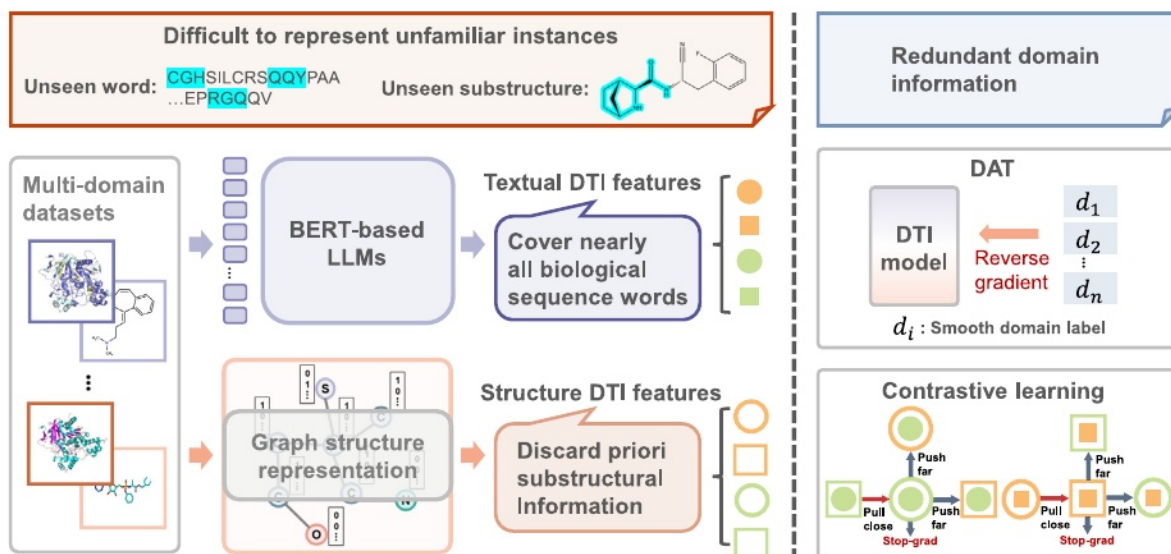


图 1. 左侧展示了针对当前学习表示局限性的解决方案，右侧则展示了如何减轻领域冗余信息的负面影响。在对比学习中，形状代表数据领域，颜色代表 DTI 标签。

TransformerCPI 使用 Word2Vec [16] 对蛋白质特征进行表示，并采用 Transformer [17] 进行最终特征提取。这项工作提高了单域数据集上的药物-靶点相互作用 (DTI) 预测性能。此外，许多研究通过设计分类器来改进 DTI 预测。HADTI [18] 和 MATT-DTI [19] 均应用注意力层来强化药物和蛋白质特征之间的交互信息。MCANet [20] 开发了多头交叉注意力机制以进一步增强注意力模块。DeepCDA [21] 在注意力层之前使用 LSTM [22] 模块来捕获样本的时间信息，从而进一步为分类层补充有益信息。

上述方法尽管采用了轻量级模型架构，但仍取得了令人鼓舞的成果。后来，硬件和 GPU 资源的持续发展进一步推动了药物靶点相互作用 (DTI) 研究领域的发展。近期的方法通常使用多尺度或多模态特征来进行高性能的 DTI 预测。MGraphDTA [23] 在 GraphDTA 的基础上，通过结合多尺度的蛋白质和药物特征来增强特征提取能力。MolTrans [24] 利用知识启发式的子结构模式挖掘算法，在更精细的尺度上分解结构特征，从而实现更准确和可解释的 DTI 预测。CPIInformer [1] 采用分子指纹和图结构这两种模态来表示药物特征，并通过 Informer [25] 提取 DTI 信息，从而提升了 DTI 预测的性能。DeepGS [26] 是另一个采用两种模态来表示药物特征的例子。该方法通过使用 Smi2Vec 和图结构来表示药物分子，展示了有效的预测性能。此外，基于 CPIInformer，MFR-DTA [27] 还引入了氨基酸嵌入来提取蛋白质特征。上述所有方法均证实了多模态特征的使用对弥散张量成像 (DTI) 预测是有益的。

尽管上述 DTI 预测方法在单领域数据集上取得了令人满意的结果，但在处理未见过的样本时，它们的泛化能力可能有限。如图 1 所示，这种不足主要归因于训练数据的领域属性以及训练模型的表示能力。具体而言，现有的词嵌入和结构表示，如 Word2Vec [15]、Smi2Vec [26] 和基于 GNN 的模型 [9, 28]，都融入了仅限于源领域训练数据集的先验知识。虽然这些方法在单领域数据集上表现出显著的预测能力，但表示过程降低了对包含未见过的词或子结构的

陌生实例的泛化能力，从而导致性能下降。另一方面，现有的基准数据集具有独特的领域属性，例如序列记录、样本特征分布和统计情况。具体而言，由于数据完整性标准存在差异、收集标准不一以及处理软件的不一致，样本在不同数据库中的记录并不完全相同。这些特性可能会误导模型在训练过程中获取与药物靶点相互作用预测无关的冗余知识，从而降低其泛化能力。

为了解决这些问题，我们提出了一种由多模态特征融合和领域泛化驱动的新型药物-靶点相互作用 (DTI) 预测模型 (MMDG-DTI)。首先，我们分别使用两个基于 BERT 的大型语言模型 (LLMs)，即 Prot-Bert (Prot_Bert_bfd) [29] 和 Smiles-Bert (Pub-Chem10M_SMILES_BPE_450K) [30]，来提取蛋白质和药物的特征。这两个模型分别在近四千亿个氨基酸序列和一千万个化学分子上进行了训练。由于使用了庞大的训练数据，从这两个 LLM 中提取的文本特征几乎涵盖了整个生物文本词汇，并且与之前的方法相比，具有更好的泛化能力。我们还应用了 DenseNet [31] 和 Informer [25] 来进一步优化所学的文本特征，以提升性能。其次，我们提出了一种混合图神经网络 (GNN)，通过从另一种模态中提取结构特征来提高 DTI 预测性能。所提取的特征反映了药物中原子与蛋白质中氨基酸之间的结构关系，并且在小样本数据集上表现出色。此外，结构特征提取器使用统一的氨基酸嵌入和分子图结构，无需特定领域的子结构先验知识。因此，该提取器能够处理具有未见过的子结构的样本。第三，我们设计了一种创新的分类器，用于融合基于 LLM 和基于 GNN 的特征的语义特征，以实现更全面的药物-靶点相互作用 (DTI) 预测。该分类器通过整合两种领域泛化方法——领域对抗训练 (DAT) [32] 和对比学习 [33]，减轻了冗余领域信息对模型的负面影响。此外，我们还提出了新颖的跨领域实验协议，以便更好地评估药物-靶点相互作用预测方法的泛化能力。

我们在单域和跨域两种设置下对所提出的方法进行了评估。实验结果表明，所提出的方法在药物-靶点相互作用 (DTI) 预测的准确性方面优于现有的最先进方法，尤其是在跨域设置下。我们还检验了所提出的每个创新组件的有效性。

通过在我们的 MMDG-DTI 中进行各种消融实验，我们验证了这一点。最后，我们通过可视化蛋白质-药物对的高响应区域，展示了所提出方法的强大泛化能力。大量的实验结果表明，我们提出的方法是有效的，能够为药物发现研究人员提供更好的选择，但在跨领域实验方面仍有改进的空间。同时，设计的跨领域实验为评估药物-靶点相互作用模型提供了更真实的环境。

总之，MMDG-DTI 的主要贡献包括：

- 一种基于大语言模型的蛋白质和药物特征表示的文本特征提取器，具有增强的泛化能力。
 - 一种基于混合图神经网络的结构特征提取器，用于补充拓扑特征。
 - 一种创新的分类器，它融合了文本和结构特征，同时通过领域泛化来缓解过拟合问题。
 - 一种用于评估的新型跨领域实验设计
- 关于 DTI 预测方法的泛化能力。

本文其余部分的结构安排如下。首先，在第 2 节中介绍相关工作。然后，在第 3.2 节中介绍所提出的 MMDG-DTI 方法。最后，在第 4 节中报告并分析实验结果，在第 5 节中得出结论。

2. 相关工作

在本节中，我们将介绍与所提出方法相关的先前工作，重点在于药物-靶点相互作用预测和领域泛化。

2.1. DTI 预测

从序列数据预测药物靶点相互作用经历了三个主要阶段：传统机器学习[34]、基于单一特征的深度学习[20]以及基于多模态特征的深度学习[27]。起初，研究人员采用手工制作的方法来表示药物和靶点的特征，并使用诸如 KNN[35] 和 SVM[36] 等浅层机器学习方法来预测药物靶点相互作用（DTIs）。然而，这些方法在准确性和泛化能力方面表现相对有限。随着深度学习的发展，诸如 DeepDTA[7]、DeepConvDTI[8]、HADTI[18]、MATT-DTI[37] 和 MCANet[20] 等先进的 DTI 预测方法相继被提出。

尽管上述研究使用单一表示来提取药物和靶点特征，但近期研究发现多模态特征融合更有效[27,38,39]。具体而言，蛋白质和药物的原始数据格式均为具有生物学意义的序列，本质上包含两个显著特性：生物学特性和文本特性。对于蛋白质而言，不仅单个氨基酸具有不同的生物学特性，而且不同的氨基酸组合还形成了具有特定意义的结构域。基于这一生物学特性，MFR-DTA [27] 提出了一个 BioCNN 块，用于提取全局和个体特征以优化蛋白质特征。蛋白质的文本特性是由实验驱动的。例如，CPI-GNN [10] 采用三个氨基酸作为一个词，而 TransformerCPI [15] 则通过 Word2Vec [16] 捕获这一特征。尽管文本特性缺乏自然语言的可解释性，但它对深度模型的预测性能有积极影响。同样，药物属性包含多种模式，例如以分子指纹形式存在的生物特性、以简化分子线性输入规范（SMILES）形式存在的文本含义以及描述分子内原子直接位置关系的图结构。众多现有方法[27,38]通过整合来自多种模式的药物特征来改进药物-靶点相互作用（DTI）预测。然而，不同模式的特征质量参差不齐，特征优化方法往往会影响训练模型的泛化能力，这值得进一步研究和探索。

2.2. 领域泛化方法

领域泛化[40]最早由 Blanchard 等人提出，作为一种机器学习问题，它旨在解决目标数据在模型训练期间不可用的分布外（OOD）场景[41]。领域泛化的主要方法包括：领域对齐[42]、元学习[43]、数据增强[44]、自监督学习[45]以及正则化策略[46]。这些领域泛化方法通常在两种设置下进行研究：多源领域泛化，即存在多个不同但相关的领域；单源领域泛化，即训练数据来自单个领域且同质[41]。现有的大多数研究都集中在多源设置上，该设置假定存在多个不同但相关的领域。正如[40]中所述，研究领域泛化的最初动机是利用多源数据学习对不同边缘分布具有不变性的表示。多个领域有助于发现更稳定的跨领域模式，从而实现更好的迁移。相比之下，单源领域泛化与 OOD（域外数据）鲁棒性相关[47]，研究模型在扰动情况下的鲁棒性。单源方法不需要领域标签，并且可以应用于多源场景。实际上，大多数基于深度学习的模型都是通用的 OOD 解决方案，既适用于单源实验也适用于多源实验[48]。

我们采用两种领域泛化方法，即领域对抗训练（DAT）[32]和对比学习[33]，来提升所提方法的泛化能力。DAT 是一种多源领域泛化方法，需要领域标签，而对比学习是一种单源领域泛化方法，无需领域标签。鉴于当前基准数据集的特性，我们针对多源和单源领域泛化场景设计了两种不同的跨领域实验协议。因此，在单源协议中我们仅使用对比学习策略，在多源协议中则同时使用这两种领域泛化方法。

3. 材料与方法

3.1. 基准数据集

我们在六个公开数据集上评估所提出的方法，包括四个经典的药物-靶点相互作用（DTI）基准数据集：人类（H）[1]、秀丽隐杆线虫（C）[1]、BindingDB（B）[1]、DrugBank（D）[18]，以及两个基于药物-靶点亲和力（DTA）的数据集：Davis（Da）[18]和KIBA（K）[18]。对于四个经典的 DTI 基准数据集，预测参数为相互作用标签，这些标签表明一对样本之间的相互作用关系，它们是从相应的数据库中获取的。在两个基于 DTA 的数据集中，预测参数是根据阈值基于药物靶点亲和力构建的。具体而言，Zhao 等人[18]通过为 Davis 和 KIBA 数据集分别设置 5.0 和 12.1 的阈值构建了这两个二分类数据集。对于单域任务，我们的评估方法和数据集划分遵循先前的研究工作[1,18]。人类和秀丽隐杆线虫数据集通过 5 折交叉验证协议进行评估，BindingDB 被划分为训练集、验证集和测试集。与[18]一致，我们还对 DrugBank、Davis 和 KIBA 进行了 10 次重复的 5 折交叉验证以评估模型的性能。为确保结果具有统计学意义，我们使用 5 个随机种子来训练模型，并在所有实验表格中报告得分结果的均值和方差。六个基准数据集的统计信息总结在表 1 中。

对于跨领域任务，我们基于上述六个数据集设计了两种类型的实验，即多源跨领域实验和单源跨领域实验。我们基于四个经典的药物靶点相互作用（DTI）基准数据集设计了多源跨领域实验，其中三个作为源领域，另一个作为目标领域。按照这种设计，多源跨领域实验包含四种协议。




图 2. 六个数据集中蛋白质的长度、药物的原子数量以及分子属性（包括分子量和油水分配系数（LogP））的分布情况。

表 1

基准数据集的统计信息。

数据集	蛋白质	药物	互动	积极的	否定的
人类	852	1052	6212	3369	2843
秀丽隐杆线虫	2504	1434	7511	4000	3511
BindingDB	811	四万九千五百六十七	六万零七百八十	三十三万七千七百七十七	七千零三
DrugBank	4254	6645	三万五千零二十二	一万七千五百一十一	一万七
戴维斯	379	68	二万五千七百七十二	7320	三千九百四十五
KIBA	225	2068	一百一十六万三千五百四十二	一万一千五百四十九	九千一百九

即 B&D&H 到 C,B&D&C 到 H,B&H&C 到 D 以及 D&H&C 到 B。由于 Davis 和 KIBA 数据集具有相似的标签属性，我们使用这两个数据集来设计单源跨域实验，包括两个协议，即 Da 到 K 和 K 到 Da。此外，我们在图 2 中展示了基准测试的基本信息，包括蛋白质序列和药物 SMILES 的长度、药物的重量以及药物的油水分配系数：LogP。表 1 和图 2 均表明，不仅在蛋白质和药物的数量上存在差异，而且在这些数据集中的药物属性分布上也存在差异，尤其是在四个经典的药物 - 蛋白质相互作用（DTI）基准测试中。尽管 Davis 和 KIBA 数据集之间的数据分布相对相似，但药物数量的巨大差异仍使跨域实验具有挑战性。

3.2. MMDG-DTI 方法的流程

我们的 MMDG-DTI 方法的流程如图 3 所示。它包含五个主要组件：文本特征提取器、结构特征提取器、分类器以及两个领域泛化模块。在本节的剩余部分，我们将对这三个组件进行更详细的介绍。

3.2.1. 基于 LLM 的文本特征提取器

如图 3 所示，我们基于两个基于 BERT 的语言模型、一个 DenseNet 编码器和 Informer 块设计了文本特征提取器。首先，我们使用 Prot-Bert [29] 和 Smiles-Bert [30] 分别将蛋白质序列和药物 SMILES 表示为嵌入特征 $\mathbf{F}_p \in \mathbb{R}^{L_p \times C_p}$ 和 $\mathbf{F}_d \in \mathbb{R}^{L_d \times C_d}$ 。Prot-Bert 和 Smiles-Bert 均

Bert 是基于 BERT 的大型语言模型（LLMs），通过在大量序列数据上使用自监督学习进行训练，其优势在于其嵌入具有很强的泛化能力。然后，我们通过基于 DenseNet 的编码器提取蛋白质和药物嵌入的文本特征。该编码器与我们在先前工作 CPInformer [1] 中提出的编码器类似，能够很好地捕捉序列的全局和局部特征。编码器的公式化表示为：

$$\mathbf{F}^{i+1} = \mathbf{F}^i + g * \text{Relu}(\text{Bn}(\text{Conv}_{1D}(\mathbf{F}^i))), \quad (1)$$

其中 $\mathbf{F}^i \in \mathbb{R}^{L \times C_i}$ 表示第 i 层获得的特征图， L 和 C 分别是嵌入特征的长度和表示通道。 G 是保留率， $\text{ReLU}()$ 是 ReLU 激活函数， $\text{BN}()$ 是批量归一化层， $\text{CONV}_{1D}()$ 是卷积核大小为 15 的一维卷积层。最后，我们通过 Informer 块提取文本 DTI 特征 $\mathbf{F}_t \in \mathbb{R}^{L_t \times C_{dti}}$ ：

$$\mathbf{F}_t = I(\mathbf{F}_p, \text{Concate}(\mathbf{F}_d, \mathbf{F}_p)) + I(\mathbf{F}_d, \text{Concate}(\mathbf{F}_p, \mathbf{F}_p)), \quad (2)$$

$$I(\mathbf{Q}, \mathbf{F}_C) = \text{Softmax}\left(\frac{\mathbf{Q}\mathbf{F}_C^T}{\sqrt{d}}\right)\mathbf{F}_C, \quad (3)$$

其中， $\mathbf{F}_p \in \mathbb{R}^{L_p \times C_p}$ 和 $\mathbf{F}_d \in \mathbb{R}^{L_d \times C_d}$ 分别是蛋白质和药物的文本特征。不同特征的所有维度信息列于表 2 中。 $\text{Concate}()$ 和 $I()$ 分别表示拼接操作和 Informer 函数。 $\mathbf{F}_C \in \mathbb{R}^{L_t \times C_{dti}}$ 是拼接后的药物 - 蛋白质相互作用（DTI）特征。关于 Informer 模块，我们遵循 CPInformer 中所采用的方法。具体而言，Informer 将 Transformer 模块 [17] 中的查询矩阵 $\mathbf{Q}$ 替换为稀疏矩阵 $\mathbf{Q}$ 。

更多信息

有关 Informer 的详细信息，读者可参考 [1,25]。

3.2.2. 基于混合图神经网络的结构特征提取器

为了用药物与靶蛋白的结构关系来补充 DTI 模型，我们基于混合图神经网络（GNN）设计了结构特征提取器。该提取器通过氨基酸嵌入 [27] 来表示蛋白质，然后提取

蛋白质特征通过基于密集网络的编码器表示为 $\mathbf{F}_p \in \mathbb{R}^{L_p \times C_s}$ 。同样地，提取器通过原子特征 $\mathbf{F}_d \in \mathbb{R}^{L_d \times C_s}$ 和基于图的邻接矩阵 $\mathbf{A}_d \in \mathbb{R}^{L_d \times L_d}$ 来表示药物。

通过 RDKit [49] 分析药物的结构。

然后，我们基于上述三个特征矩阵提取结构化的药物-靶点相互作用（DTI）特征。需要注意的是，我们可以通过图表示将药物分子构建成为以原子为节点的拓扑图。然而，目标蛋白质序列无法直接形成氨基酸之间的图结构关系。尽管我们可以使用基于深度学习的蛋白质结构预测方法来完成这项工作，但这会消耗大量的计算资源。更重要的是，即使是很小的预测误差也可能对 DTI 模型的性能产生很大的负面影响。因此，我们以氨基酸为节点构建蛋白质特征矩阵，节点之间的关系设计是基于序列顺序记录相邻氨基酸作为相邻节点。通过这种设计，我们可以使用卷积核为 3 的一维深度智慧卷积（DWC）[50] 来提取蛋白质的结构关系。我们通过将相关蛋白质和原子特征相乘来构建样本对之间的关联矩阵 $\mathbf{C} \in \mathbb{R}^{L_p \times L_d}$ 。




图 3. MMDG-DTI 的整体流程。它包含五个主要组件：文本特征提取器、结构特征提取器、分类器以及两个领域泛化模块，即领域对抗训练（DAT）和对比学习。




图 4. 所提出的混合 GNN 模块的架构（左）以及我们混合 GNN 的公式（右）。

然后，此矩阵及其转置矩阵 $C^T \in \mathbb{R}^{L^p \times L^p}$ 分别用作原子和蛋白质特征的权重。

如图 4 所示，我们可以通过混合 GNN 提取结构 DTI 特征 $F_s \in \mathbb{R}^{L^s \times C^s}$ ，其公式如下：

$$F_s = \begin{bmatrix} A_p & C \\ C^T & A_d \end{bmatrix} \begin{bmatrix} F_p \\ F_d \end{bmatrix}, \quad (4)$$

$$A_p F_p = DW C(F_p), C = \text{Softmax}(F_p F_d^T), \quad (5)$$

其中 A_p 表示假设的氨基酸邻接矩阵。具体而言，结构 DTI 特征是经过 N 次混合 GNN 聚合后的结果。在每次聚合过程中， F_p 和 F_d 按照如下方式进行更新：

$$\delta(F_p) = DW C(\omega(F_p)) + C \omega(F_d) + F_p, \quad (6)$$

$$\delta(F_d) = C^T \omega(F_p) + A_d \omega(F_d) + F_d, \quad (7)$$

$$F_s = \text{Concat}(\delta(F_p), \delta(F_d)), \quad (8)$$

其中， $\delta()$ 是更新操作， $\omega()$ 是线性层与 GELU 函数的组合。为了更平滑地提取特征，我们在更新 F_p 和 F_d 时添加了残差操作。

实际上，这种混合 GNN 通过整合几种不同组件的优势来捕捉药物与靶蛋白之间的关系。这些组件包括使用经典 GNN 提取药物的结构关系、使用 DWConv 提取蛋白质的结构关系以及使用关联矩阵提取相互作用。如上所述，这三种结构关系的融合无限逼近基于更大邻接矩阵的蛋白质-药物相互作用的图结构特征。然而，所提出的混合 GNN 更高效且更精细。

3.2.3. 创新分类器

在本部分，我们将文本和结构的药物-靶点相互作用（DTI）特征进行整合以预测 DTI。如图 3 所示，分类器由五个基本模块组成：Res-CNN、线性、融合、DAT 和对比学习。首先，我们使用 Res-CNN 模块进一步优化文本和结构的 DTI 特征。Res-CNN 模块包含一维卷积、ReLU、残差连接和全局平均池化层。然后，利用这两个优化后的特征通过线性模块分别预测文本特征 DTI 和结构特征 DTI。接下来，我们将从线性模块最后一层获得的两个语义特征，即 $F_T \in \mathbb{R}^{C \times 1}$ 和 $F_S \in \mathbb{R}^{C \times 1}$ 进行融合。进一步，基于融合后的特征，利用一个新的线性模块来预测融合后的 DTI， $F \in \mathbb{R}^{C}$ 。融合过程的公式表述为：

$$f = \omega(\text{Concat}(f_t, f_s, \sigma(f_s) * f_t, \sigma(f_t) * f_s)), \quad (9)$$

其中， $\omega()$ 和 $\text{Concat}()$ 分别表示线性层和拼接操作。 $\sigma()$ 是 Sigmoid 函数。最后，我们将这三个预测的药物-靶点相互作用（DTI）进行聚合，作为最终的预测结果。

对于跨领域实验，我们采用了两个领域泛化模块：领域对抗训练（DAT）[32] 融合和对比学习[33]，以进一步提高模型的泛化能力。如图 3 所示，DAT 融合作用于由 Res-CNN 生成的细化特征 $F_{RC} \in \mathbb{R}^{C^s}$ ，并由数据域的平滑标签进行训练。在前向传播中，DAT 作为恒等变换。在反向传播中，DAT 取下一层的梯度，乘以一个负超参数，并将其传递给前一层。通过这种设计，任何数据域差异的负面影响都可以在细化特征中得到缓解。

基于文本特征 $F_{\text{TRC}} \in \mathbb{R}^{C_{\text{TRC}}}$ 和结构特征 $F_{\text{SRC}} \in \mathbb{R}^{C_{\text{SRC}}}$ 的推理可以表述为:

$$\mathbf{y}_p = \omega(\sigma(\omega_1(d(f_{\text{TRC}}))) * \omega_2(d(f_{\text{SRC}}))), \quad (10)$$

其中 $\mathbf{Y}_p \in \mathbb{R}^3$ 是推断结果, $\omega()$ 和 $D()$ 分别是线性层和 DAT 操作, $\sigma()$ 是 Sigmoid 函数。关于 DAT 的更多细节, 读者可参考 [32]。

值得注意的是, 从大型语言模型中提取的文本 DTI 特征在不同数据集分布相似且具有更强的泛化能力[29]。相比之下, 由分子结构、权重和化学性质决定的结构 DTI 特征在不同数据集领域中的差异要大得多[51]。因此, 结构 DTI 特征可能会导致融合特征受到冗余的领域特定信息的负面影响。我们使用对比学习[33]来抑制这些负面影响。该过程如图 3 所示。首先, 我们在一批数据中随机打乱结构 DTI 特征的顺序, 并将其与相关的文本 DTI 特征融合, 形成打乱融合特征, 即 $F^* = \text{FUSE}(F_{\text{ITS}}, \text{FISS}^*) \in \mathbb{R}^{C_{\text{F}}}$, 如公式 (9) 所示。接下来, 我们计算打乱融合特征和融合特征 $F^l = \text{FUSE}(F_{\text{ITS}}, \text{FISS}) \in \mathbb{R}^{C_{\text{F}}}$ 的相似度, 并将相似度与对比损失内容相乘作为对比损失 L_{CONTRA} , 具体如下:

$$L_{\text{contra}} = \sum_B \text{Eq}(\mathbf{x}^i, \mathbf{x}^{i*}) \cdot \text{Sim}(\text{stopgrad}(f^i), f^{i*}) \quad (11)$$

$$\text{Eq}(\mathbf{x}^i, \mathbf{x}^{i*}) = \begin{cases} +1, \text{label}(\mathbf{x}^i) == \text{label}(\mathbf{x}^{i*}), \\ -1, \text{otherwise}, \end{cases} \quad (12)$$

其中, $\text{EQ}(\mathbf{X}^i, \mathbf{X}^{i*})$ 是对比标签, $\text{FITS} \in \mathbb{R}^B \times \mathbb{C}_{\text{F}}$ 、 $\text{FISS} \in \mathbb{R}^B \times \mathbb{C}_{\text{F}}$ 和 $\text{FISS}^* \in \mathbb{R}^B \times \mathbb{C}_{\text{F}}$ 分别是一批文本语义特征、结构语义特征和打乱后的结构语义特征。 $\mathbf{X}^i$ and $\mathbf{X}^{i*}$ 分别是正常批次和打乱后的批次的第 i 个索引。B 是批次大小, $\text{SIM}(\mathbf{A}, \mathbf{B}) = -\|\mathbf{A} - \mathbf{B}\|_2$

其中 $\cos$ 是余弦相似度, $\text{stopgrad}()$ 是停止梯度传播操作符。然后, 我们在单领域和跨领域任务上将所提出的方法与最先进的方法进行比较。最后, 我们展示不同提取的语义特征的散点图, 并可视化蛋白质-药物对的高响应区域, 以对我们的方法进行可解释性验证。

3.3. 损失函数及实现细节

所提出的 MMDG-DTI 方法是一种多任务学习模型, 它使用不同的损失函数来训练由专用分支执行的不同任务。我们使用二元交叉熵损失函数来计算三种 DTI 损失, 包括文本特征和结构特征 DTI 损失 LTB 和 LSB 以及融合 DTI 损失 LFB, 具体计算方式如下:

$$L_B = \frac{1}{N} \sum_i -[y_i \cdot \log(p_i) + (1 - y_i) \cdot \log(1 - p_i)], \quad (13)$$

其中 y_i denotes 表示样本 i 的标签, 正类为 1, 负类为 0。 p_i denotes 表示样本 i 被预测为正类的概率。对于 DAT 融合块的训练, 我们使用交叉熵损失函数:

$$L_C = -\frac{1}{N} \sum_i \sum_{c=1}^M y_{ic} \log(p_{ic}), \quad (14)$$

其中 p_{ic} is 表示样本 i 属于类别 C 的预测概率, y_{ic} indicates 表示样本 i 是否属于类别 C , 而 M 和 N 分别表示类别总数和样本总数。对于对比学习, 损失 L_{CONTRA} 通过公式 (11) 计算得出。最后, 我们得到最终的损失为:

$$L_{\text{total}} = \lambda_1 * L_B^t + \lambda_2 * L_B^s + \lambda_3 * L_B^f + \lambda_4 * L_C^{\text{domain}} + \lambda_5 * L_{\text{contra}}, \quad (15)$$

其中每个 λ 都是一个平衡参数。

表 2

MMDG-DTI 的超参数设置。

超参数	价值
表示渠道 $C_{\text{TRC}}^t, C_{\text{TRC}}^s, C_{\text{TRC}}^f, C_{\text{SRC}}^t, C_{\text{SRC}}^s, C_{\text{SRC}}^f$	1024, 768, 75, 75
隐藏层特征通道 $C_{\text{H}}^t, C_{\text{H}}^s, C_{\text{H}}^f$	75
影片时长 $L_{\text{TRC}}, L_{\text{SRC}}, L_{\text{F}}$	1200, 100, 1300, 130
留存率 $G_{\text{TRC}}, G_{\text{SRC}}, G_{\text{F}}$	128, 128, 15
编码器的卷积核大小 $K_{\text{TRC}}, K_{\text{SRC}}, K_{\text{F}}$	十五, 十五, 三十一
Res-CNN 的卷积核大小 K	7
残差卷积神经网络 (Res-CNN) 模块中的卷积层数量	3
残差线性块中的线性层数量	3
单域任务: $\lambda_1, \lambda_2, \lambda_3, \lambda_4, \lambda_5$	1, 1, 1, 0, 0
单域任务 (未见过的样本): $\lambda_1, \lambda_2, \lambda_3, \lambda_4, \lambda_5$	1, 1, 1, 0, 1
单源跨域任务: $\lambda_1, \lambda_2, \lambda_3, \lambda_4, \lambda_5$	1, 1, 1, 0, 1
多源跨域任务: $\lambda_1, \lambda_2, \lambda_3, \lambda_4, \lambda_5$	1, 1, 1, 1, 1

我们采用受试者工作特征曲线下的面积 (AUC-ROC) 和精确率-召回率曲线下的面积 (AUC-PR) 作为主要评估指标, 这与之前的工作[1]保持一致。具体来说, ROC 曲线在 Y 轴上绘制真阳性率, 在 X 轴上绘制假阳性率。PR 曲线则分别在 Y 轴和 X 轴上绘制精确率和召回率的值。此外, 对于单领域实验, 我们遵循标准评估协议使用精确率和召回率指标。我们的方法是在 Python 3.8 中使用 PyTorch 1.8.0 实现的。实验在一台运行 Ubuntu 20.04 操作系统的机器上进行, 该机器配备有 Intel Core i7-11700K CPU 和一块 NVIDIA GeForce RTX 3090 显卡。我们使用 AdamW 优化器[52]进行网络训练。在训练过程中, 我们将学习率设为 5×10^{-4} , 权重衰减设为 7×10^{-2} , 批处理大小设为 16, 丢弃率设为 0.1。更多超参数设置见表 2。

4. 实验结果与讨论

在本节中, 我们首先通过消融实验的结果展示每个创新组件的有效性。然后, 我们在单领域和跨领域任务上将所提出的方法与最先进的方法进行比较。最后, 我们展示不同提取的语义特征的散点图, 并可视化蛋白质-药物对的高响应区域, 以对我们的方法进行可解释性验证。

4.1. 消融研究

在消融研究中, 我们评估了每个创新组件在单领域和跨领域任务中的有效性。具体而言, 对于单领域任务, 我们评估了主要组件的有效性, 包括文本特征提取器 (TFE)、结构特征提取器 (SFE) 以及分类器中的融合模块。对于跨领域任务, 我们还评估了所提出的两个领域泛化模块的有效性, 即领域对抗训练 (DAT) 和对比学习 (CL)。需要注意的是, 跨领域任务分为两类: 多源和单源。

4.1.1. 单领域任务的消融研究

MMDG-DTI 模型是一个新设计的框架, 没有对应的基线方法。因此, 我们使用文本特征 DTI 和结构特征 DTI 在四个经典的 DTI 基准上的性能来评估相应的提取器。请注意, 在评估单个提取器时, 不涉及无关模块的训练和推理。此外, 我们还比较了不同的语义特征融合方法, 以证明所提出的融合模块的有效性。所比较的语义特征融合方法主要包括拼接、成对内积[53]、叉积[54]、逐元素乘积[55]以及基于 Informer 的方法。

表 3
在四个基准数据集（即 Human、C.elegans、BindingDB 和 DrugBank）上获得的消融研究结果（AUC-ROC）。

模型	TFE	SFE	融合方法	人类	秀丽隐杆线虫	BindingDB	DrugBank
型号-1	✓		–	0.979 ± 0.003	0.983 ± 0.002	0.956 ± 0.003	0.879 ± 0.004
型号 2		✓	–	0.980 ± 0.003	0.985 ± 0.004	0.951 ± 0.005	0.876 ± 0.005
Model 3	✓	✓	连接	0.983 ± 0.002	0.988 ± 0.003	0.963 ± 0.003	0.886 ± 0.004
型号 4	✓	✓	成对内积	0.976 ± 0.005	0.983 ± 0.005	0.953 ± 0.004	0.878 ± 0.006
型号 5	✓	✓	叉积	0.973 ± 0.007	0.979 ± 0.007	0.943 ± 0.006	0.880 ± 0.005
型号 6	✓	✓	逐元素乘积	0.984 ± 0.002	0.989 ± 0.002	0.959 ± 0.002	0.889 ± 0.003
型号 7	✓	✓	基于告密者的融合模块	0.988 ± 0.003	0.991 ± 0.003	0.966 ± 0.001	0.894 ± 0.002
型号 8			提议的融合模块	0.991 ± 0.002	0.996 ± 0.002	0.971 ± 0.001	0.901 ± 0.001

表 4
使用多源跨域协议（B&D&H 到 C、B&D&C 到 H、D&H&C 到 B 以及 B&H&C 到 D）所获得的消融研究结果（AUC-ROC）。

模型	TFE	SFE	数据 (Data)	CL	B&D&H 至 C	B&D&C 至 H	D&H&C 对企业 (D&H&C 企业对商	企业H&C 至 D
型号 - mc1	✓		✓	–	0.893 ± 0.003	0.763 ± 0.002	0.583 ± 0.003	0.539 ± 0.002
型号 - mc2		✓	–	–	0.907 ± 0.002	0.781 ± 0.003	0.617 ± 0.001	0.551 ± 0.003
型号 - mc3			✓	–	0.877 ± 0.005	0.741 ± 0.004	0.525 ± 0.006	0.479 ± 0.005
型号 - mc4			–	–	0.895 ± 0.004	0.735 ± 0.003	0.527 ± 0.002	0.493 ± 0.003
型号 - mc5	✓	✓			0.917 ± 0.003	0.790 ± 0.002	0.652 ± 0.002	0.575 ± 0.004
型号 - mc6	✓	✓	✓	✓	0.919 ± 0.002 ↑	↑ 0.789 ± 0.001 译文：上升 0.789 ± 0.001	0.649 ± 0.003	↑ 0.580 ± 0.002
型号 - mc7				✓	0.921 ± 0.002 ↑	0.794 ± 0.003 ↑	0.657 ± 0.001	0.579 ± 0.002
型号 - mc8	✓	✓	✓	✓	↑ 0.927 ± 0.002	↑ 0.799 ± 0.001	0.658 ± 0.002 ↑	0.583 ± 0.003

融合模块 [1]。其中，前四种方法是两个向量之间的基本操作，而基于 Informer 的融合模块是基于 Informer [1] 的语义特征融合方法。实验结果如表 3 所示。

模型 1 和模型 2 分别代表仅使用文本特征和结构特征的药物 - 靶点相互作用（DTI）模型。很明显，模型 1 在样本量较大的数据集（BindingDB 和 DrugBank）上表现更优，而模型 2 在样本量较小的数据集上则更胜一筹。由于文本特征提取器的表示是在大量数据上进行预训练的，因此提取的特征似乎吸收了更多的信息，并表现出更强的泛化能力。因此，当数据集中包含更多不同的蛋白质和药物分子时，该提取器更加强大。尽管结构特征包含的信息较少，但它们能够突出分子的结构样式，这可能在小数据集上带来稍好的性能。

我们使用剩余的模型（从 Model-3 到 Model-8）来展示不同融合方法的性能。拼接是一种简单而有效的结合文本和结构特征的方法。Model-3 的准确率高于仅使用单一特征的模型（Model-1 和 Model-2）。Model-4 和 Model-5 的性能相对较差，这表明成对内积和叉积都不太适合语义特征融合。Model-6 的性能与 Model-3 相似，这证实了逐元素乘积能很好地保留融合的两个语义特征的内容。Model-7 的性能表明，基于 Informer 的融合模块[1,25]通过引入注意力信息显著提升了 DTI 模型。最重要的是，所提出的融合模块在融合语义特征时参数更少，并在四个基准测试中达到了最先进的水平。

4.1.2. 跨领域任务的消融研究

对于跨领域任务，我们首先在表 4 中展示了多源跨领域协议的结果。表 4 中的前四个模型是单一的药物 - 靶点相互作用（DTI）特征模型。可以看出，基于文本特征的 DTI 的泛化能力远优于基于结构特征的 DTI，这从 Model-mc1 和 Model-mc3 的结果中可以明显看出。这一结果符合预期，因为文本特征提取器在预训练时接收到了更多的样本。此外，从 Model-mc2 和 Model-mc4 的表现中可以看出，数据增强技术（DAT）在跨领域实验中对模型的优化效果显著。由于对比学习是基于文本和结构特征的融合而设计的，因此仅应用于双流模型。Model-mc5 的性能表明，

表 5
使用单源跨域协议（包括 Da 到 K 和 K 到 Da）所获得的消融研究结果（AUC-ROC）。

模型	TFE	SFE	CL	达托克	K 到达
模型-sc1	✓	✓		0.625 ± 0.006	0.685 ± 0.007
模型-sc2	✓	✓		0.587 ± 0.010	0.607 ± 0.012
模型-sc3	✓	✓	✓	0.638 ± 0.008	0.708 ± 0.010
模型-sc4				↑ 0.644 ± 0.007 译文：上升 0.644 ± 0.007	↑ 0.716 ± 0.008

使用双特征融合提高了模型的泛化能力。在大多数情况下，引入数据增强技术（DAT）或对比学习能够提升模型的泛化能力，但模型 Model-mc6 在协议 D&H&C TOB 中除外。为了解其原因，我们分析了图 2，发现 BindingDB 数据集的样本分布与其他三个数据集差异较大。此外，其他三个数据集的领域属性相似，这使得 DAT 难以发挥作用。然而，当我们将 DAT 和对比学习结合使用时，对比学习带来的梯度变换在一定程度上缓解了这一问题，使得 MMDG-DTI 在多源跨域任务中表现最优。

接下来，我们在表 5 中展示了单源跨域协议的结果。KIBA 和 Davis 这两个数据集的主要区别在于所包含的独特药物分子的数量。表 1 清晰地表明，KIBA 中的独特药物分子数量远多于 Davis，因此在 K 到 Da 协议中，药物靶点相互作用（DTI）模型的表现优于 Da 到 K 协议。此外，表 5 再次表明，基于文本的 DTI 特征比基于结构的 DTI 特征具有更好的泛化能力。当两者结合时，整体性能还能进一步提升。这意味着信息内容是互补的。此外，对比学习能够提升单源跨域任务中的模型性能，正如 Model-mc5 的表现所展示的那样。

4.2. 与最先进的方法进行比较

在本部分，我们将所提出的 MMDG-DTI 方法与包括 DeepConvDTI [8]、TransformerCPI [15]、MolTrans [24]、HADTI [18]、CPIformer [1]、MCANet [20]、TriMulDTI [56] 和 MFR-DTA [27] 在内的最先进的药物靶点相互作用（DTI）预测模型在四个经典的 DTI 基准数据集以及两个基于药物靶点相互作用（DTA）的阈值分割数据集上进行了比较。对比实验涵盖了单领域和跨领域任务。

表 6

在 Human、C.elegans、BindingDB 和 DrugBank 数据集上，就 AUC-ROC、AUC-PR、准确率和召回率而言，与最先进的方法进行比较。

方法	人类				秀丽隐杆线虫			
	AUC-ROC	AUC-PR (精确率-召回率曲线下面积)	精度	召回	AUC-ROC	AUC-PR (精确率-召回率曲线下面积)	精度	召回
DCDTI [8]	0.970±0.003	0.978±0.003	0.942±0.002	0.953 ± 0.003	0.979±0.003	0.981±0.002	0.947±0.002	0.950±0.001
TransCPI [15]	0.973±0.002	0.979±0.002	0.916±0.006	0.925 ± 0.006	0.988±0.002	0.987±0.001	0.957±0.006	0.953±0.005
MolTrans [24]	0.975±0.004	0.977±0.003	0.952±0.003	0.935 ± 0.003	0.987±0.003	0.989±0.002	0.961±0.005	0.967±0.003
HADTI [18]	0.978±0.002	0.980±0.003	0.932±0.002	0.938 ± 0.003	0.985±0.003	0.987±0.003	0.961±0.004	0.967±0.003
CPInformer [1]	0.985±0.003	0.989±0.002	0.961±0.002	0.951 ± 0.002	0.991±0.002	0.992±0.001	0.956±0.002	0.976±0.001
MCANet [20]	0.983±0.003	0.989±0.002	0.961±0.002	0.937 ± 0.002	0.989±0.002	0.990±0.002	0.967±0.002	0.963±0.001
TriMulDTI [56]	0.985±0.003	0.986±0.002	0.953±0.001	0.949 ± 0.001	0.986±0.003	0.988±0.002	0.957±0.002	0.961±0.001
MFR-DTA [27]	0.986±0.003	0.983±0.002	0.938±0.001	0.959 ± 0.001	0.988±0.002	0.985±0.001	0.968±0.002	0.969±0.002
MMDG-DTI	0.991 ± 0.002	0.993 ± 0.002	0.978 ± 0.002	0.945 ± 0.002	0.996 ± 0.001	0.996 ± 0.001	0.979 ± 0.001	0.981 ± 0.001

方法	BindingDB				DrugBank			
	AUC-ROC	AUC-PR (精确率-召回率曲线下面积)	精度	召回	AUC-ROC	AUC-PR (精确率-召回率曲线下面积)	精度	召回
DCDTI [8]	0.944±0.002	0.947±0.003	0.933 ± 0.003	0.941 ± 0.002	0.867±0.001	0.777 ± 0.002	0.750 ± 0.001	0.698±0.001
TransCPI [15]	0.951±0.003	0.949±0.004	0.959 ± 0.003	0.937 ± 0.003	0.837±0.003	0.836 ± 0.002	0.750±0.003	0.792±0.003
MolTrans [24]	0.956±0.002	0.949±0.003	0.921 ± 0.002	0.918 ± 0.003	0.861±0.002	0.836 ± 0.002	0.786 ± 0.002	0.796±0.002
HADTI [18]	0.956±0.003	0.951±0.004	0.919 ± 0.003	0.931 ± 0.003	0.889±0.001	0.897 ± 0.001	0.829 ± 0.001	0.799±0.001
CPInformer [1]	0.965 ± 0.002 0.965, 误差为±0.005	0.966±0.003	0.957 ± 0.002	0.970 ± 0.005	0.887±0.002	0.891±0.002	0.816 ± 0.002	0.823±0.001
MCANet [20]	0.961±0.003	0.963±0.002	0.963 ± 0.003	0.919 ± 0.003	0.897±0.002	0.902 ±0.005	0.824 ± 0.002	0.827±0.003
TriMulDTI [56]	0.963±0.003	0.967±0.002	0.958 ± 0.004	0.951 ± 0.005	0.895±0.002	0.897 ± 0.003	0.827 ± 0.002	0.819±0.002
MFR-DTA [27]	0.962±0.002	0.959±0.003	0.947 ± 0.003	0.936 ± 0.003	0.893±0.002	0.891 ± 0.003	0.831 ± 0.002	0.806±0.002
MMDG-DTI	0.971 ± 0.001	0.972 ± 0.002	0.960 ± 0.003	0.955±0.002	0.901 ± 0.001	0.897 ± 0.001	0.798 ± 0.002	0.840 ± 0.001

表 7

与 BindingDB 数据集中未见过的药物、靶点和配对设置的最新方法进行比较。标有 “*” 的结果是由使用具有领域泛化模块的 MMDG-DTI 方法获得的。

方法	未见药物		未见目标		未见的搭档	
	AUC-ROC	AUC-PR (精确率-召回率曲线下面积)	AUC-ROC	AUC-PR (精确率-召回率曲线下面积)	AUC-ROC	AUC-PR (精确率-召回率曲线下面积)
DCDTI [8]	0.875 ± 0.003	0.843 ± 0.003	0.871 ± 0.004	0.847 ± 0.005	0.851 ± 0.010	0.818±0.013
TransCPI [15]	0.870±0.005	0.824 ± 0.006	0.868 ± 0.005	0.845±0.005	0.831 ± 0.015	0.818±0.017
MolTrans [24]	0.869±0.008	0.845 ± 0.010	0.877 ± 0.01	0.853 ± 0.008	0.831 ± 0.019	通常翻译为数值表达时，需额外翻译。
HADTI [18]	0.870 ± 0.007	0.843 ± 0.006	0.875±0.009	0.850±0.012	0.842 ± 0.013	0.823±0.012
CPInformer [1]	0.881 ± 0.005	0.874 ± 0.004	0.883 ± 0.010	0.862±0.008	0.845 ± 0.015	0.827 ± 0.016
MCANet [20]	0.905±0.003	0.901±0.004	0.892±0.008	0.869 ± 0.009	0.867±0.012	0.838 ± 0.013
TriMulDTI [56]	0.895 ± 0.007	0.898 ± 0.008	0.897 ± 0.009	0.879 ± 0.01	0.862 ± 0.015	0.825 ± 0.017
MFR-DTA [27]	0.898 ± 0.005	0.899±0.003	0.897 ± 0.006	0.873 ± 0.008	0.863 ± 0.010	0.832 ± 0.01
MMDG-DTI	0.914 ± 0.004	0.910 ± 0.003	0.921 ± 0.006	0.904±0.007	0.872 ± 0.009	0.837 ± 0.012
MMDG-DTI*	0.928 ± 0.003	0.925 ± 0.002	0.926 ± 0.005	0.910 ± 0.006	0.883 ± 0.008	0.847 ± 0.010

4.2.1. 单领域任务的比较

对于单域任务，我们采用 AUC-ROC、AUC-PR、准确率和召回率作为评估指标。在四个经典的药物靶点相互作用（DTI）基准数据集上的实验结果如表 6 所示。根据该表，所提出的 MMDG-DTI 方法在大多数指标上均优于其他所有方法。对于相对较小的人类和秀丽隐杆线虫数据集，MMDG-DTI 在 AUC-ROC、AUC-PR 和准确率方面均优于其他所有方法，这证实了其在小数据集上的优越性。尽管在人类数据集上的召回率指标并非最优，但在实际应用中可通过优化阈值来加以改善。对于 BindingDB 数据集，该数据集被划分为训练集、验证集和测试集，我们按照文献[1]中的方式对 MMDG-DTI 进行评估，因此该数据集的指标在表 6 中未给出方差。所提出的方法在 AUC-ROC 和 AUC-PR 指标上取得了最佳结果，与第二好的方法 CPInformer 相比，性能提升了 0.6%。MCANet 和 CPInformer 这两种方法分别在准确率和召回率这两个指标上表现更优。然而，我们的方法在这两项指标上相对更均衡。此外，我们在表 7 中报告了该数据集中每个模型在未见过的药物、靶点和配对设置下的性能。总体而言，未见过的样本配对设置比单独未见过的药物或靶点设置更难处理。然而，结果也表明，所提出的方法在开放场景中具有优势，因为多种模态表示的结合使模型更具鲁棒性，尤其是在同时使用领域泛化模块时。此外，我们的模型在 DrugB

ank 数据集上的表现不如在其他数据集上，但在 AUC-ROC 和召回率指标上取得了最佳性能，这表明其具有竞争力。

接下来，我们在基于 DTA 的 Davis 和 KIBA 数据集上，从 AUC-ROC 和 AUC-PR 两个方面对所提出的方法进行评估。结果如图 5 所示。在该图中，DC-DTI 和 TransDTI 分别代表 Deep-ConvDTI [8] 和 TransformerCPI [15]。图 5 以箱线图的形式更直观地展示了这些方法的性能，包括准确性和稳定性。我们可以发现，除了所提出的 MMDG-DTI 方法外，其他方法往往难以同时具备这两种优势。此外，根据表 1 和图 5 可以看出，Davis 和 KIBA 数据集中正类样本数量远少于负类样本数量，这导致所有模型在 AUC-PR 指标上的表现都比在 AUC-ROC 指标上差。然而，在这两个基于 DTA 的阈值分割数据集上进行的若干实验表明，MMDG-DTI 在所有指标上都优于现有方法，进一步证实了所提出方法的优越性。

4.2.2. 跨领域任务的对比实验

对于跨域任务，我们在表 8 中展示了多源跨域和单源跨域任务的实验结果。我们在跨域任务中从 AUC-ROC 和 AUC-PR 两个方面对所提出的方法进行了评估，并提供了两种版本的 MMDG-DTI 的实验结果以作公平比较。表 8 清晰地表明了我们的方法的优越性，在六种跨域协议中，无论是多源还是单源，均取得了最佳性能。值得注意的是，具有更通用表示能力的模型




图 5. 在 Davis 和 KIBA 数据集上，与最先进的方法在 AUC-ROC 和 AUC-PR 方面的比较。

表 8
在跨域实验中，就 AUC-ROC 和 AUC-PR 而言，与最先进的方法进行比较。标有 “*” 的结果是由使用带有领域泛化模块的 MMDG-DTI 的方法获得的。

方法	B&D&H 至 C		B&D&C 至 H		D&H&C 对企业 (D&H&C 企业对商业)	
	AUC-ROC	AUC-PR (精确率-召回率曲线下的面积)	AUC-ROC	AUC-PR (精确率-召回率曲线下的面积)	AUC-ROC	AUC-PR (精确率-召回率曲线下的面积)
DCDTI [8]	0.891±0.002	0.895±0.003	0.762±0.003	0.764±0.002	0.593±0.003	0.595±0.005
TransCPI [15]	0.843±0.004	0.859±0.006	0.715±0.004	0.721±0.006	0.507±0.005	0.529±0.006
MolTrans [24]	0.865±0.005	0.877±0.006	0.722±0.007	0.739±0.005	0.527±0.007	0.549±0.008
HADTI [18]	0.878±0.004	0.879±0.003	0.741±0.004	0.748±0.003	0.535±0.006	0.557±0.005
CPIInformer [1]	0.875±0.005	0.881±0.007	0.742±0.003	0.753±0.003	0.539±0.004	0.542±0.003
MCANet [20]	0.883±0.004	0.899±0.002	0.761±0.002	0.757±0.003	0.609±0.003	0.623±0.002
TriMulDTI [56]	0.881±0.004	0.893±0.006	0.753±0.003	0.767±0.003	0.602±0.003	0.635±0.005
MFR-DTA [27]	0.887±0.003	0.893±0.002	0.751±0.002	0.769±0.001	0.581±0.002	0.605±0.003
MMDG-DTI	0.917 ± 0.003	0.926±0.003	0.790 ± 0.001	0.811 ± 0.002	0.652 ± 0.003	0.693 ± 0.003
MMDG-DTI*	0.927 ± 0.002	0.943 ± 0.003	0.799 ± 0.001	0.827 ± 0.002	0.658 ± 0.002	0.701 ± 0.003

方法	B&H&C 至 D		达托克		K 到达	
	AUC-ROC	AUC-PR (精确率-召回率曲线下的面积)	AUC-ROC	AUC-PR (精确率-召回率曲线下的面积)	AUC-ROC	AUC-PR (精确率-召回率曲线下的面积)
DCDTI [8]	0.543±0.003	0.547±0.004	0.607±0.010	0.408±0.012	0.607±0.012	0.516±0.016
TransCPI [15]	0.497±0.005	0.479±0.003	0.525±0.014	0.321±0.017	0.577±0.013	0.516±0.015
MolTrans [24]	0.509±0.006	0.514±0.007	0.516±0.019	0.303±0.016	0.581±0.021	0.496±0.023
HADTI [18]	0.536±0.004	0.541±0.006	0.565±0.015	0.373±0.013	0.659±0.018	0.531±0.020
CPIInformer [1]	0.525±0.003	0.516±0.005	0.583±0.012	0.305±0.014	0.601±0.016	0.510±0.015
MCANet [20]	0.541±0.004	0.543±0.002	0.603±0.010	0.393±0.008	0.672±0.013	0.535±0.012
TriMulDTI [56]	0.537±0.003	0.537±0.004	0.601±0.011	0.405±0.012	0.659±0.013	0.529±0.015
MFR-DTA [27]	0.532±0.002	0.525±0.003	0.597±0.010	0.418±0.007	0.613±0.012	0.527±0.015
MMDG-DTI	0.575 ± 0.003	0.561 ± 0.003	0.638 ± 0.008	0.425 ± 0.009	0.708±0.012	0.543 ± 0.013 此为数值表达时，通常直接呈现，无需额外翻译。
MMDG-DTI *	0.583 ± 0.003	0.567 ± 0.002	0.644 ± 0.006	0.311±0.008	0.716 ± 0.010	

在跨领域实验中，某些方法表现更佳。例如，DeepConvDTI 仅使用氨基酸序列来表示蛋白质，并使用 Morgan 指纹[11,57]来表示药物分子，就能取得非常出色的效果。相比之下，在单一数据集中预训练的词表示虽然能提升 Transformer 和 CPIInformer 等模型在单一领域实验中的性能，但在跨领域环境中表现欠佳。在 MMDG-DTI 中，文本特征提取器采用了一种通用的词表示模型，该模型在大量生物分子样本上进行了预训练，几乎涵盖了所有生物序列词表示。需要注意的是，结构特征提取器中的氨基酸嵌入和图结构表示舍弃了样本的子结构表示，这适用于所有未见过的蛋白质和药物分子。因此，上述两种提取器的结合使 MMDG-DTI 能够处理任何未见过的实例，并在跨领域实验中取得最先进的性能。此外，这两种领域泛化方法还能进一步提升所提出模型在跨领域环境中的性能。

4.3. 关于 MMDG-DTI 可解释性的讨论

4.3.1. 不同特征的可视化展示

在本部分，我们旨在通过可视化为我们的方法提供可解释的验证。首先，我们展示图 6，该图展示了源域和目标域测试集上不同语义特征的散点图。这些语义特征通过主成分分析（PCA）进行降维，以在平面空间中形成位置坐标，从而

能够可视化不同模型提取的样本特征的空间分布。因此，图 6 可以直接展示不同创新的贡献。请注意，我们使用了多源和单源跨域任务中的第一个协议，即 B&D&H 到 C 和 Da 到 K 协议，来生成这些散点图。图 6 的上部和下部分别展示了这两个协议的结果。

在多源跨域任务中，文本 DTI 特征在预测测试样本的药物靶点相互作用（DTI）方面通常比结构 DTI 特征更有效。虽然在源域中，文本 DTI 特征的表现略逊于结构 DTI 特征，但在目标域中，其泛化能力更强。实际上，结构 DTI 特征能够有效地表示蛋白质和药物分子的浅层生物结构信息。尽管在单域条件下样本对能够被有效表示，但对生物结构信息的过度敏感性也降低了其在跨域实验中的性能。相比之下，文本 DTI 特征是样本对深层语义信息的体现，它更抽象地表示了样本对之间的深层语义关联，从而提高了泛化能力。不出所料，通过融合这两种特征，预测 DTI 的模型得到了改进，交互样本点也聚集得更紧密。此外，对比学习模块显著提高了特征表示能力，如可视化所示。在提取特征的两个主成分维度中，正样本点和负样本点具有更明显的类别区域。这种改进主要是通过使用对比学习实现的，对比学习有助于从标签中提取语义信息，从而导致不同类别特征之间的差异更加显著。此外，




图 6.不同创新对跨领域任务的贡献。图中每个点的 X 和 Y 坐标代表通过主成分分析（PCA）降维至二维空间后的每个 DTI 特征的值。

DAT 减少了域信息的污染，并有助于平衡正负样本散射之间的分布空间。

对于单源跨域任务，每项创新对模型的影响与它在多源跨域任务中的效果类似。然而，Davis 数据集和 KIBA 数据集之间药物数量的巨大差异，使得模型难以区分目标域中的正样本和负样本。尽管对比学习在一定程度上缓解了这一问题的，但设计出在这种跨域协议中表现良好的模型仍然是一项挑战。

4.3.2. 高响应区域的可视化

为了分析所提出模型对样本结构的感知能力，我们对测试集中的蛋白质 - 药物对的高响应区域进行了可视化。如图 7 所示，可视化包括源域样本可视化（SDSV）和目标域样本可视化（TDSV）。SDSV 表示模型对来自与训练数据相同数据集的源域测试样本的响应可视化。相比之下，TDSV 则描绘了跨域任务中目标域测试样本的响应。请注意，蛋白质和药物的响应向量是通过计算注意力权重矩阵 QF 的平均值得出的。

$\text{Softmax}(\sqrt{c})$ ，来自文本特征提取器和关联

从结构特征提取器中获取矩阵 C，因此这些响应向量既包含样本的文本语义，也包含其结构信息。每个响应向量中响应值排名前 30% 的区域被记录为高响应区域。此外，我们在相同的实验条件下为 CPInformer [1] 生成可视化结果，以便与所提出的模型进行比较。如先前所展示的 [27]，这些高响应区域可能无法准确反映真实世界的药物 - 靶点结合区域，但对于深度学习模型确定一对样本之间是否存在相互作用至关重要。因此，这些区域可用于评估在不同数据集上训练的深度模型的鲁棒性和泛化能力。根据图 7 可以清楚地看出，在处理相同的蛋白质或药物时，基于不同数据集训练的 MMDG-DTI 模型在高响应区域的相似度高于 CPInformer。这表明 MMDG-DTI 能够从本质上捕获

表 9
源域和目标域样本的高响应区域的平均相似度。

数据集	CPInformer		MMDG-DTI	
	蛋白质	药物	蛋白质	药物
人类	0.391±0.231	0.573±0.275	0.575±0.263	0.655±0.308
秀丽隐杆线虫	0.463±0.257	0.612±0.318	0.625±0.279	0.713±0.257
BindingDB	0.372±0.214	0.317±0.236	0.553±0.187	0.624±0.271
DrugBank	0.307±0.198	0.373±0.213	0.465±0.190	0.538±0.239
戴维斯	0.160±0.103	0.232±0.117	0.391±0.213	0.420±0.220
KIBA	0.242±0.125	0.115±0.087	0.453±0.317	0.318±0.253

这些不变特征增强了其在先前未见过的数据上的稳健性和性能。

为了验证上述发现的统计显著性，我们在所有基准测试中计算了 SDSV 和 TDSV 之间的响应相似度，并将结果报告在表 9 中。我们使用杰卡德相似系数来计算响应向量的相似度，并根据各个基准测试中的所有相似度结果确定平均值和标准差。结果表明，在六个基准数据集上，使用不同训练数据学习的 MMDG-DTI 模型对蛋白质和药物的响应相似度高于 CPInformer，从而证实了上述发现。

5. 结论

我们提出了一种新颖的 MMDG-DTI 模型，用于药物-靶点相互作用（DTI）预测，该模型在跨领域中的泛化能力更强。首先，我们构建了一个基于大规模语言模型（LLMs）的文本特征提取器，能够处理几乎所有样本实例，以提高模型的泛化能力。然后，提出了基于混合图神经网络（GNN）的结构特征提取器，通过捕获样本成分的结构关系来增强模型。最后，我们设计了一种创新的分类器，结合了文本和结构 DTI 特征的优势，并借助创新的领域泛化模块进一步提高泛化能力。为了优化评估，我们基于现有的公共数据集提出了新的跨领域实验，包括单源和多源跨领域协议。为了直观地展示所提出的方法，我们还提供了若干可视化结果。




图 7. 源域样本可视化 (SDSV) 和目标域样本可视化 (TDSV)，展示了测试集中样本在 CPInformer 和 MMDG-DTI 中的高响应区域。CPInformer 以绿色和蓝色突出显示蛋白质和药物的高响应区域。MMDG-DTI 则以黄色和橙色突出显示相应区域。（关于本图例中颜色的解释，请参阅本文的网络版。）

实验结果证实了我们的方法在单领域和跨领域任务中均优于当前最先进的方 法。虽然所提出的 MMDG-DTI 框架展现出了更强的泛化能力，但在跨领域 实验中的预测准确性方面仍有提升空间。未来，我们将基于诸如更大规模的 语言模型和更先进的领域泛化方法等前沿技术进一步优化所提出的模型，为 该领域提供更可靠、更通用的药物靶点相互作用（DTI）预测模型，助力人工 智能在药物发现中的应用。

CRediT 作者贡献声明

杨华：写作 - 审阅与编辑、写作 - 原稿、可视化、验证、软件、资源、方 法论、调查、正式分析、数据管理、概念化。冯振华：写作 - 审阅与编辑、监 督、方法论、调查、正式分析。宋晓宁：写作 - 审阅与编辑、监督、资源、项 目管理、资金获取、正式分析、概念化。吴小军：监督、项目管理、资金获取、 写作 - 审阅与编辑。约瑟夫·基特勒：写作 - 审阅与编辑、监督、项目管理、方 法论、正式分析。

利益冲突声明

作者声明，他们不存在任何已知的可能影响本论文所述研究工作的财务利 益冲突或个人关系。

数据可用性

数据集和代码将在项目主页上提供：<https://github.com/JU-HuaY/MMDG-DTI>。

有关数据可用性的更多详情如下。依赖性

该代码已在以下环境中进行了测试：Python-3.8,

PyTorch-1.8.0

CUDA 11.1

数据集链接：https://drive.google.com/file/d/1TLcGFcpmgFIPqm1aBw-EW23TdOy0z7rL/view?usp=share_link

BindingDB_Cold 数据集：https://drive.google.com/file/d/1hSsu2D8XcRama_gnmp5FpxSEXi_wtbOV/view?usp=drive_link.

训练好的模型链接：<https://drive.google.com/file/d/1dSpGwBbFp6yOPtCIY4a-LbjvWJrowhdY/view?usp=sharing>。

将训练好的模型存储在路径 “PATH_MODEL” 中，该模型可通过以 下代码在 main.py 中加载。

model_data = torch.load (PATH_MODEL) 模型数据 = torch.load(模型路径 数据处理：

原始数据首先由代码文件“Predata.py”进行处理；然后我们可以使用“data_split_name.py”来拆分数据集；之后，我们可以运行main.py。此文件还会导入“merge.py”和“model.py”；我们唯一要做的就是编写数据协议和保存路径；具体的数据协议在文件“data_merge.py”中有描述。

致谢

本研究部分得到了中国国家重点研发计划（2023YFF1105102, 2023YFF1105105）、国家社会科学基金重大项目（编号：21&ZD166）、国家自然科学基金（61876072）、江苏省自然科学基金（编号：BK20221535）以及江苏省研究生科研与实践创新计划（编号：KYCX23_2438）的支持。

参考文献

- [1] Y. Hua, X. Song, Z. Feng, X.-J. Wu, J. Kittler, D.-J. Yu, CPInformer for efficient and robust compound-protein interaction prediction, *IEEE/ACM Trans. Comput. Biol. Bioinform.* 20 (1) (2023) 285–296.
- [2] L. Jacob, J.-P. Vert, Protein-ligand interaction prediction: an improved chemogenomics approach, *Bioinformatics* 24 (19) (2008) 2149–2156.
- [3] J. Tang, A. Szawajda, S. Shakyawar, T. Xu, P. Hintsanen, K. Wennerberg, T. Aittokallio, Making sense of large-scale kinase inhibitor bioactivity data sets: a comparative and integrative analysis, *J. Chem. Inf. Model.* 54 (3) (2014) 735–743.
- [4] F. Wang, D. Liu, H. Wang, C. Luo, M. Zheng, H. Liu, W. Zhu, X. Luo, J. Zhang, H. Jiang, Computational screening for active compounds targeting protein sequences: methodology and experimental validation, *J. Chem. Inf. Model.* 51 (11) (2011) 2821–2828.
- [5] Y. Wang, J. Zeng, Predicting drug-target interactions using restricted Boltzmann machines, *Bioinformatics* 29 (13) (2013) i126–i134.
- [6] K. Tian, M. Shao, Y. Wang, J. Guan, S. Zhou, Boosting compound-protein interaction prediction by deep learning, *Methods* 110 (2016) 64–72.
- [7] H. Öztürk, A. Özgür, E. Ozkirimli, DeepDTA: deep drug–target binding affinity prediction, *Bioinformatics* 34 (17) (2018) i821–i829.
- [8] I. Lee, J. Keum, H. Nam, DeepConv-DTI: Prediction of drug-target interactions via deep learning with convolution on protein sequences, *PLoS Comput. Biol.* 15 (6) (2019) 1–21.
- [9] T. Nguyen, H. Le, T.P. Quinn, T. Nguyen, T.D. Le, S. Venkatesh, GraphDTA: Predicting drug–target binding affinity with graph neural networks, *Bioinformatics* 37 (8) (2021) 1140–1147.
- [10] M. Tsubaki, K. Tomii, J. Sese, Compound–protein interaction prediction with end-to-end learning of neural networks for graphs and sequences, *Bioinformatics* 35 (2) (2019) 309–318.
- [11] D. Rogers, M. Hahn, Extended-connectivity fingerprints, *J. Chem. Inf. Model.* 50 (2010) 742–754.
- [12] T.N. Kipf, M. Welling, Semi-supervised classification with graph convolutional networks, in: *International Conference on Learning Representations, ICLR*, 2017.
- [13] P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò, Y. Bengio, Graph attention networks, in: *International Conference on Learning Representations*, 2018.
- [14] K. Xu, W. Hu, J. Leskovec, S. Jegelka, How powerful are graph neural networks? in: *International Conference on Learning Representations*, 2019.
- [15] L. Chen, X. Tan, D. Wang, F. Zhong, X. Liu, T. Yang, X. Luo, K. Chen, H. Jiang, M. Zheng, TransformerCPI: improving compound–protein interaction prediction by sequence-based deep learning with self-attention mechanism and label reversal experiments, *Bioinformatics* 36 (16) (2020) 4406–4414.
- [16] T. Mikolov, I. Sutskever, K. Chen, G.S. Corrado, J. Dean, Distributed representations of words and phrases and their compositionality, in: *Advances in Neural Information Processing Systems*, vol. 26, Curran Associates, Inc., 2013, pp. 1–9.
- [17] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A.N. Gomez, L. Kaiser, I. Polosukhin, Attention is all you need, in: I. Guyon, U.V. Luxburg, S. Bengio, H. Wallach, R. Fergus, S. Vishwanathan, R. Garnett (Eds.), in: *Advances in Neural Information Processing Systems*, vol. 30, Curran Associates, Inc., 2017, pp. 1–11.
- [18] Q. Zhao, H. Zhao, K. Zheng, J. Wang, HyperAttentionDTI: improving drug–protein interaction prediction by sequence-based deep learning with attention mechanism, *Bioinformatics* 38 (3) (2022) 655–662.
- [19] Y. Zeng, X. Chen, Y. Luo, X. Li, D. Peng, Deep drug-target binding affinity prediction with multiple attention blocks, *Brief. Bioinform.* 22 (5) (2021) bbab117.
- [20] J. Bian, X. Zhang, X. Zhang, D. Xu, G. Wang, MCANet: shared-weight-based MultiheadCrossAttention network for drug–target interaction prediction, *Brief. Bioinform.* 24 (2) (2023) bbad082.
- [21] K. Abbasi, P. Razzaghi, A. Poso, M. Amanlou, J.B. Ghasemi, A. Masoudi-Nejad, DeepCDA: deep cross-domain compound–protein affinity prediction through LSTM and convolutional neural networks, *Bioinformatics* 36 (17) (2020) 4633–4642.
- [22] S. Hochreiter, J. Schmidhuber, Long short-term memory, *Neural Comput.* 9 (8) (1997) 1735–1780.
- [23] Z. Yang, W. Zhong, L. Zhao, C.Y.-C. Chen, MGraphDTA: deep multiscale graph neural network for explainable drug–target binding affinity prediction, *Chem. Sci.* 13 (3) (2022) 816–833.
- [24] K. Huang, C. Xiao, L.M. Glass, J. Sun, MolTrans: molecular interaction transformer for drug–target interaction prediction, *Bioinformatics* 37 (6) (2021) 830–836.
- [25] H. Zhou, S. Zhang, J. Peng, S. Zhang, J. Li, H. Xiong, W. Zhang, Informer: Beyond efficient transformer for long sequence time-series forecasting, in: *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 35, (no. 12) 2021, pp. 11106–11115.
- [26] X. Lin, K. Zhao, T. Xiao, Z. Quan, Z.-J. Wang, P.S. Yu, DeepGS: Deep representation learning of graphs and sequences for drug–target binding affinity prediction, in: *ECAI 2020*, IOS Press, 2020, pp. 1301–1308.
- [27] Y. Hua, X. Song, Z. Feng, X. Wu, MFR-DTA: a multi-functional and robust model for predicting drug–target binding affinity and region, *Bioinformatics* 39 (2) (2023) btad056.
- [28] X.-b. Ye, Q. Guan, W. Luo, L. Fang, Z.-R. Lai, J. Wang, Molecular substructure graph attention network for molecular property identification in drug discovery, *Pattern Recognit.* 128 (2022) 108659.
- [29] A. Elnaggar, M. Heinzinger, C. Dallago, G. Rehawi, Y. Wang, L. Jones, T. Gibbs, T. Feher, C. Angerer, M. Steinegger, et al., ProtTrans: Toward understanding the language of life through self-supervised learning, *IEEE Trans. Pattern Anal. Mach. Intell.* 44 (10) (2021) 7112–7127.
- [30] S. Wang, Y. Guo, Y. Wang, H. Sun, J. Huang, Smiles-bert: large scale unsupervised pre-training for molecular property prediction, in: *Proceedings of the 10th ACM International Conference on Bioinformatics, Computational Biology and Health Informatics*, 2019, pp. 429–436.
- [31] G. Huang, Z. Liu, L. Van Der Maaten, K.Q. Weinberger, Densely connected convolutional networks, in: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 2017, pp. 4700–4708.
- [32] Y. Zhang, J. Liang, Z. Zhang, L. Wang, R. Jin, T. Tan, et al., Free lunch for domain adversarial training: Environment label smoothing, in: *International Conference on Learning Representations*, 2023, pp. 1–15.
- [33] Z. Wang, Z. Wang, Z. Yu, W. Deng, J. Li, T. Gao, Z. Wang, Domain generalization via shuffled style assembly for face anti-spoofing, in: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022, pp. 4123–4133.
- [34] K. Bleakley, Y. Yamanishi, Supervised prediction of drug–target interactions using bipartite local models, *Bioinformatics* 25 (18) (2009) 2397–2403.
- [35] H.E. Manoochchery, M. Nourani, Predicting drug-target interaction using deep matrix factorization, in: *2018 IEEE Biomedical Circuits and Systems Conference, BioCAS, IEEE*, 2018, pp. 1–4.
- [36] D.-S. Cao, S. Liu, Q.-S. Xu, H.-M. Lu, J.-H. Huang, Q.-N. Hu, Y.-Z. Liang, Large-scale prediction of drug–target interactions using protein sequences and drug topological structures, *Anal. Chim. Acta* 752 (2012) 1–10.
- [37] B. Shin, S. Park, K. Kang, J.C. Ho, Self-attention based molecule representation for predicting drug-target interaction, in: *Machine Learning for Healthcare Conference, PMLR*, 2019, pp. 230–248.
- [38] Y. Zhu, L. Zhao, N. Wen, J. Wang, C. Wang, DataDTA: a multi-feature and dual-interaction aggregation framework for drug–target binding affinity prediction, *Bioinformatics* (2023) btad560.
- [39] Y. Wang, X. Wang, C. Chen, H. Gao, A. Salhi, X. Gao, B. Yu, RPI-CapsuleGAN: Predicting RNA-protein interactions through an interpretable generative adversarial capsule network, *Pattern Recognit.* 141 (2023) 109626.
- [40] G. Blanchard, G. Lee, C. Scott, Generalizing from several related classification tasks to a new unlabeled sample, in: *Advances in Neural Information Processing Systems*, vol. 24, Curran Associates, Inc., 2011, pp. 2178–2186.
- [41] K. Zhou, Z. Liu, Y. Qiao, T. Xiang, C.C. Loy, Domain generalization: A survey, *IEEE Trans. Pattern Anal. Mach. Intell.* 45 (4) (2023) 4396–4415.
- [42] H. Li, S.J. Pan, S. Wang, A.C. Kot, Domain generalization with adversarial feature learning, in: *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2018, pp. 5400–5409.
- [43] S. Sankaranarayanan, Y. Balaji, Meta learning for domain generalization, in: *Meta-Learning with Medical Imaging and Health Informatics Applications*, Elsevier, 2023, pp. 75–86.
- [44] K. Zhou, Y. Yang, T. Hospedales, T. Xiang, Deep domain-adversarial image generation for domain generalization, in: *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 34, (no. 07) 2020, pp. 13025–13032.
- [45] F.M. Carlucci, A. D’Innocente, S. Bucci, B. Caputo, T. Tommasi, Domain generalization by solving jigsaw puzzles, in: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2019, pp. 2229–2238.
- [46] Z. Huang, H. Wang, E.P. Xing, D. Huang, Self-challenging improves cross-domain generalization, in: *Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part II 16*, Springer, 2020, pp. 124–140.

- [47] D. Hendrycks, T. Dietterich, Benchmarking neural network robustness to common corruptions and perturbations, in: *International Conference on Learning Representations*, 2019, pp. 1–16.
- [48] Z. Huang, H. Wang, E.P. Xing, D. Huang, Self-challenging improves cross-domain generalization, in: *Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part II 16*, Springer, 2020, pp. 124–140.
- [49] G. Landrum, et al., Rdkit: Open-source cheminformatics software. 2016, 149 (150), 2016, p. 650, doi <http://www.rdkit.org/>, <https://github.com/rdkit/rdkit>.
- [50] F. Chollet, Xception: Deep learning with depthwise separable convolutions, in: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, CVPR*, 2017, pp. 1251–1258.
- [51] H. Ma, Y. Bian, Y. Rong, W. Huang, T. Xu, W. Xie, G. Ye, J. Huang, Cross-dependent graph neural networks for molecular property prediction, *Bioinformatics* 38 (7) (2022) 2003–2009.
- [52] I. Loshchilov, F. Hutter, Decoupled weight decay regularization, in: *International Conference on Learning Representations*, 2018, pp. 1–18.
- [53] S. Li, F. Wan, H. Shu, T. Jiang, D. Zhao, J. Zeng, MONN: a multi-objective neural network for predicting compound-protein interactions and affinities, *Cell Syst.* 10 (4) (2020) 308–322.
- [54] S. Dere, S. Ayvaz, Prediction of drug–drug interactions by using profile fingerprint vectors and protein similarities, *Healthc. Inform. Res.* 26 (1) (2020) 42–49.
- [55] Y. Chen, T. Ma, X. Yang, J. Wang, B. Song, X. Zeng, MUFFIN: multi-scale feature fusion for drug–drug interaction prediction, *Bioinformatics* (2021).
- [56] A. Dehghan, P. Razzaghi, K. Abbasi, S. Gharaghani, TripletMultiDTI: Multimodal representation learning in drug-target interaction prediction with triplet loss function, *Expert Syst. Appl.* (2023) 120754.
- [57] S. Riniker, G.A. Landrum, Similarity maps—a visualization strategy for molecular fingerprints and machine-learning methods, *J. Cheminformatics* 5 (1) (2013) 1–7.



杨华是中国无锡江南大学人工智能与计算机学院的
一名博士生。他的研究兴趣包括模式识别和生物信息学。
他在《生物信息学》和《IEEE/ACM TCB》等期刊上发
表了相关主题的学术论文。



冯振华于 2016 年在英国萨里大学视觉、语音与信号处理
中心 (CVSSP) 获得博士学位。目前，他是萨里大学计
算机科学系计算机视觉与机器学习讲师。在此之前，他
是 CVSSP 的高级研究员。他的研究兴趣包括模式识别、
机器学习和计算机视觉。他在 TPAMI、IJCV、CVPR、
ICCV、IJCAI、ACL、TCYB、TIP、TIFS、TCSVT、
TBIOM、ACM TOMM、《信息科学》、《模式识别》
等顶级会议和期刊上发表了 60 多篇研究论文。他曾担任
2021 年英国计算机视觉会议 (BMVC) 的领域主席以及
2021 年国际人工智能联合会议 (IJCAI) 的高级程序委
员会成员。他目前是《复杂与智能系统》杂志的编委。
他获得了 2017 年欧洲生物医学工程学会奖。



荣获欧洲生物识别协会 (EAB) 颁发的“行业奖”以及
AMDO2018 会议颁发的“最佳商业应用论文奖”。

宋晓宁于 1997 年在南京东南大学获得计算机科学学士学位，
2005 年在江苏科技大学（位于中国镇江）获得计算
机科学硕士学位，2010 年在南京理工大学（位于中国南
京）获得模式识别与智能系统博士学位。2014 年至 2015
年期间，他曾在英国萨里大学视觉、语音与信号处理中
心担任访问学者。目前，他是中国无锡江南大学人工智
能与计算机学院的教授。他的研究兴趣包括模式识
别、机器学习和计算机视觉。



吴小俊于 1991 年在南京师范大学获得数学学士学位，
1996 年和 2002 年分别在南京理工大学获得模式识别与
智能系统专业硕士学位和博士学位。1996 年至 2006 年，
他在江苏科技大学电子信息学院任教，并晋升为教授。
自 2006 年起，他任职于江南大学信息工程学院，担任模
式识别与计算智能教授。2003 年至 2004 年，他曾作为
访问学者在英国萨里大学视觉、语音与信号处理中心
(CVSSP) 工作。他在其研究领域发表了 300 多篇论文。
目前，他是中国无锡江南大学的人工智能与模式识别教
授。他的研究兴趣包括模式识别、计算机视觉、模糊系
统、神经网络和智能系统。



约瑟夫·基特勒于 1971 年、1974 年和 1991 年分别在剑桥
大学获得文学学士学位、哲学博士学位和科学博士学位。
他是英国吉尔福德萨里大学视觉、语音和信号处理中心
的杰出机器学习教授。他的研究领域包括生物识别、视
频和图像数据库检索、医学图像分析以及认知视觉。他
出版了《模式识别：统计方法》一书，并发表了约 1000
篇科学论文。他的出版物被引用了约 70000 次。

他是施普林格《计算机科学讲义》系列的编辑。目
前，他是《模式识别快报》《模式识别与人工智能》
《模式分析与应用》等期刊的编委。1982 年至 1985 年
期间，他曾担任《IEEE 模式分析与机器智能汇刊》的编
委。1982 年至 2005 年期间，他是国际模式识别协会
(IAPR) 理事会的两名英国代表之一，并于 1994 年至
1996 年担任该协会主席。