

MuRL-DTI: 一种用于药物-靶点相互作用冷启动问题的多模态特征融合强化学习方法

Yao Liu
北京航空航天大学数字媒体北京市重点实验室
中国北京
ly0708@buaa.edu.cn (此邮件地址无需翻译)

Ye Liu*
北京航空航天大学仪器科学与光电工程学院
中国北京
lylyzyq1314@buaa.edu.cn (此邮件地址无需翻译)

Xin Wang
牛津大学工程科学系
英国牛津
王欣欣邮箱: xin.wang@eng.ox.ac.uk

Dandan Dou
北京航空航天大学生物科学与医学工程学院
中国北京
yidan@buaa.edu.cn
(此邮件地址无需翻译, 保持原样即可。)

摘要 - 药物靶点相互作用 (DTI) 旨在探究特定药物分子与其生物靶点之间的相互作用, 以评估药物的有效性和安全性。与传统方法相比, 基于计算技术的 DTI 研究取得了显著进展, 包括基于机器学习的 DTI 模型、基于深度学习的 DTI 模型以及基于知识图谱的 DTI 模型。然而, 这些模型往往依赖丰富的上下文和结构信息, 在处理稀疏数据时会导致预测准确性降低, 并在冷启动场景中面临挑战。为解决这一局限性, 我们提出了一种名为 MuRL-DTI 的新型 DTI 预测方法。具体而言, 我们采用基于 DQN 的强化学习应用于 DTI 任务, 通过利用已学习的知识转移到未知的药物 - 靶点相互作用来解决冷启动问题。此外, 我们还利用来自多个来源的生物信息, 包括序列特征和化合物特征, 以强化所学的环境信息并提高预测准确性。在三个基准数据集上的实验结果表明, 我们的模型优于基线模型, 这验证了所提出方法的有效性。

索引词: 多模态、强化学习、冷启动、药物靶点相互作用。

I. 简介

药物 - 靶点相互作用 (DTI) 预测[1]、[2]涉及利用计算生物学和生物信息学的方法来预测药物分子与生物靶点 (如蛋白质) 之间的相互作用。这项研究旨在加快药物开发[3], 提高成功率, 发现新的靶点[4]并优化药物设计[5]。最终, 这些努力有助于新药发现和个性化医疗, 同时降低研发成本和风险。

传统的药物-靶点相互作用 (DTI) 预测方法主要通过生化实验来进行, 这种方法耗时且存在风险。通过将计算技术引入 DTI 预测, 能够高效处理和分析大量生物数据, 从而提高预测的准确性, 这一领域已取得显著进展。现有的方法大致可分为三类: 基于机器学习的方法[1]、基于深度学习的方法[2]以及基于知识图谱的模型[6]。

用于药物 - 靶点相互作用 (DTI) 预测的机器学习方法主要包括基于相似性的、基于特征提取的以及半监督的方法。基于相似性的机器学习方法的核心原理是相似的药物倾向于与相似的靶点相互作用, 反之亦然。此类方法中的著名模型包括[7]-[13]。这

些向量随后使用分类算法进行分类。此类别中的典型模型包括[14]-[16]。半监督方法主要用于减轻负样本选择对药物靶点相互作用预测的影响, 其中著名的模型包括[17]-[21]。

基于深度学习的药物-靶点相互作用 (DTI) 预测任务的核心原理是通过构建深度神经网络模型来自动提取和学习药物及靶点的高维特征表示。这种方法旨在捕捉复杂的相互作用模式, 并最终实现对药物与靶点潜在相互作用的准确预测。典型的模型包括 GraphDTA [22]、BridgeDPI [23]、MGraphDTA [24]、Deep-GLSTM [25]、CSatDTA [26]、DTITR [27]、CoaDTI [28]。

知识图谱 (KGs) 通过捕捉药物及其相关属性之间的关系, 为药物相互作用提供了一种结构化的表示形式。例如, TriModel [29] 结合了药物和靶点的先验信息, 从而提高了预测的准确性。DTiGEMS+ [30] 结合了药物-药物和靶点-靶点的相似性图谱, 以改进药物-靶点相互作用图谱。NeoDTI 模型引入了一种新颖的非线性端到端学习方法, 该方法整合了异构图数据中的多种信息。EEG-DTI 模型 [31] 利用图卷积网络 (GCN) 基于药物和靶点在异构图中的低维特征表示来预测药物-靶点相互作用。GraphDTA [22] 利用图神经网络来预测药物-靶点亲和力。

然而, 现有的模型依赖于丰富且具有上下文信息的数据来进行有效建模, 在面对数据稀疏和冷启动问题时预测准确性较低。冷启动问题[32]指的是由于缺乏足够的历史数据, 无法可靠地预测新药物或新靶点的相互作用。例如, 新药物或新靶点的引入会因上下文数据不足而降低模型的准确性。为了解决这一挑战, 我们提出了一种用于药物-靶点相互作用 (DTI) 预测的多模态强化学习 (RL) 模型, 称为 MuRL-DTI, 该模型利用已学习到的相互作用知识来预测新的药物-靶点组合。具体而言, 我们首先通过整理生物数据库中的药物和靶点信息构建相互作用网络, 通过边将相互作用的药物和靶点连接起来。然后, 我们采用基于 DQN 的 RL 模型来学习网络中当前的相互作用信息。

我们提出了有效利用历史知识的机制，使其能够在未知或稀疏数据上发挥作用。此外，我们还提议将多源生物特征，包括序列特征和化合物特征，整合到强化学习框架中，以丰富环境信息并提升模型性能。我们的贡献在于：

我们提出了一种多模态融合强化学习模型，称为 MuRL-DTI，该模型采用基于 DQN 的强化学习模型，将获取的知识迁移到未知药物与靶点的相互作用中。此外，它还融合了多源生物特征信息，以丰富强化学习环境并提高预测准确性。

我们通过实验来评估我们的模型在三个公开可用的药物 - 靶点相互作用 (DTI) 数据集上的性能。结果表明，MuRL-DTI 模型优于现有的模型，这验证了其有效性。

II. 方法论

A. 预备知识

a) 强化学习中的环境 - 状态、动作、转移和奖励: S 表示状态空间，包含环境的所有可能状态。状态 $S \in S$ 用 $(e_t, e_{tq}, r_t, e_{tq})$ 表示，其中状态空间包括所有有效组合。 O 表示观测空间。由于环境被定义为部分可观测的，这意味着决策者无法获取环境的所有状态信息，而只能通过观测获取部分信息。观测空间定义了决策者可能接收到的所有观测结果。 A 表示动作空间，包含决策者可选择的所有可能动作。通过选择不同的动作，决策者旨在改变环境的状态以实现特定目标。 δ 表示状态转移函数，描述了在给定动作后环境状态的变化方式。状态转移函数是确定性的，这意味着对于给定的状态和动作，环境将转移到特定的新状态。 R 表示奖励函数，它为每个状态转移分配一个数值奖励。

B. 多模态特征融合

我们融合了两种信息来增强环境背景：药物的蛋白质序列特征和化合物的结构特征。图 1 展示了提取的多模态特征。蛋白质序列可以表示为“MVSY-WDTGGVLLSSS...”，与传统的描述性文本相比，它能更准确地反映蛋白质的结构和特性。为了有效地从蛋白质序列中提取特征，我们使用了一个成熟的蛋白质特征提取工具 FECS [33]。该工具基于蛋白质的结构和统计特征进行序列提取，其准确性已在各种研究任务中得到验证。

对于化合物的结构特征，我们首先采用 SMILES 表示法 [34]，将化合物的分子组成转换为字符串格式。然后，我们使用 RDKit 工具将这些字符串表示转换为结构图。最后，利用 GraphDTA 算法 [22] 生成化合物的结构特征。

C. 基于深度 Q 网络的多模态强化学习




图 1: 多模态特征提取。

在交互网络中确定目标，并让模型在该网络环境中学习。然后，我们提出了一种基于深度 Q 网络 (DQN) 的强化学习模型，该模型考虑了生物特征的高维特性。具体而言，该模型使用两个架构相同的多层神经网络，分别称为 $Q_{\text{预测}}$ 网络和 $Q_{\text{目标}}$ 网络，图 3 展示了网络的结构。 $Q_{\text{预测}}$ 网络的主要功能是根据当前环境状态选择最优动作，而目标网络则为这些动作生成目标 Q 值，该值代表预期的未来奖励。为了增强学习过程的稳定性，DQN 方法引入了周期性更新机制，即定期将 $Q_{\text{预测}}$ 网络的参数转移到目标网络。这一过程减少了训练过程中目标 Q 值与预测 Q 值之间的差异，从而防止了学习过程中的振荡和发散。

模型的训练过程如下：输入状态 s_t 表示药物或靶点的特征表示。模型针对给定状态 s_t 输出所有可能动作的 Q 值。采用贪婪策略选择一个动作 a_t ，然后将其输入到环境中。这种交互会产生一个新的状态 s_{t+1} 和一个奖励 r_t 。奖励 r_t 的定义基于药物与靶点之间交互的结果，如果药物有效地实现了目标，则赋值为 +1，否则为 -1。随后，计算 Q 预测网络的值：

$$y_t = r_t + \gamma \cdot \max_a Q_{\text{Target}}(s_{t+1}, a; w) \quad (1)$$

其中， γ 表示折扣因子，用于衡量未来的奖励。它控制着赋予未来奖励的权重，通常取值在 0 到 1 之间。然后计算损失函数：

$$L = 1/2 [y_t - Q_{\text{Prediction}}(s_t, a; w)]^2 \quad (2)$$

根据损失值，使用梯度下降法更新 Q 预测网络的参数，以最小化 $Q_{\text{Prediction}}(s_t, a)$ 和 y_t 之间的差异。然后按如下方式更新 Q 预测网络：

$$Q_{\text{Prediction}}(s_t, a_t, w) \leftarrow Q_{\text{Prediction}}(s_t, a_t, w) + \alpha [r_{t+1} + \gamma \max_a \hat{q}(s_{t+1}, a_t, w) - Q_{\text{Prediction}}(s_t, a_t, w)] \quad (3)$$

完成上述步骤后，即可得到四元数过渡： (s_t, a_t, r_t, s_{t+1}) 。重复上述过程，直至达到预定的训练重复次数。




图 2: 基于 DQN 的多模态强化学习概述。




图 3: Q 预测网络和 Q 目标网络的结构。

网络 $Q_{T \text{ 目标}}$ 保持不变。在经过一定次数的更新后，更新后的 $Q_P \text{ 预测}$ 权重会被复制到 $Q_{T \text{ 目标}}$ ，以用于下一批更新。

III. 实验

A. 实验设置

a) 数据集: 我们采用三个公开数据集进行实验验证，分别是 Luo 的 [35]、Yamanishi 的 [36] 和 Zheng 的 [37] 数据集。Luo 的数据集构建了一个复杂的生物信息网络，其中包括药物-靶点、药物-药物以及蛋白质-药物相互作用，该网络包含 12,015 个节点和 1,895,445 条边。Zheng 的数据集涵盖了广泛的药物和靶点数据，记录了 11,819 种药物-靶点相互作用，涉及 1,094 种不同的药物和 1,556 个靶点。Yamanishi 的数据集包含了已知的药物-靶点相互作用，其数量分别为 635、2926、1476 和 90。

在每个数据集中，所有已知的药物-靶点相互作用 (DTI) 都被归类为正样本，而未记录的药物-靶点配对则被归类为负样本。此外，还使用了两种不同的比例来选择正样本：1:1 和 1:10。这意味着对于每个正样本，分别选择数量相等和十倍数量的负样本，以创建两个不同的实验数据集。这种设置旨在考虑样本比例对结果可能产生的影响。

b) 评估指标: 我们采用两种广泛使用的评估指标：AUC（受试者工作特征曲线下面积）和 AUPR（精确率-召回率曲线下面积）来评估模型的性能。AUC 用于衡量模型的区分能力，即模型区分正负样本的能力。

区分正样本和负样本，而 AUPR 则侧重于精确率和召回率之间的平衡。这两个指标的值都更接近于 0 到 1，表明模型更优。

c) 基线模型: 我们基于不同的算法选择了一系列模型进行对比分析，包括：

- 随机森林 (RF) [38] 是一种用于分类的集成学习方法。
- 支持向量机 (SVM) [39] 是一种经典的有监督学习技术，它直接提供有关药物及其靶点的嵌入信息。
- XGBoost [40] 将决策树模型与梯度提升机制相结合，从而提高了预测精度和计算效率。
- GCN [41] 是一种典型的半监督学习方法。它以药物-靶点关联网络作为输入，预测其他潜在的药物-靶点配对。
- 图注意力网络 (GAT) [42] 被用于不仅捕捉药物与靶点之间的复杂关系，还用于获取深层次的特征表示。
- DTICNN [43] 通过异构网络捕获药物及其靶点的嵌入表示，并使用去噪自编码器模型根据学习到的特征推断它们之间的相互作用。
- GCNMDA [44] 通过构建药物与微生物之间的网络，探究了药物与微生物之间的相关性。
- MVGCN [45] 利用多视图 GCN 的设计，充分考虑生物医学数据的复杂性和多样性，从而提高预测的准确性。

d) 超参数设置: 我们采用网格搜索来确定每个数据集的最佳超参数设置。这些设置包括 Q 目标网络和预测网络中的深度神经网络层数、输入层中的节点数（输入节点）、每个隐藏层中的节点数（隐藏层节点数）、学习率 (lr) 以及强化学习中的 γ 值。

卢的数据集: 深度神经网络层数 - 4，输入节点 - 1500，隐藏层节点数 - 512、256、128、64。学习率 - 0.001， γ - 0.9。

山下数据集: 深度神经网络层数 - 3，输入节点 - 1500，隐藏层节点数 - 512、256、128。学习率 - 0.001， γ - 0.85。

郑的实验数据集: 深度神经网络层数 - 4，输入节点 - 1500，隐藏层节点数 - 512、256、128、64。学习率 - 0.001， γ - 0.9。

B. 性能分析

表 I、表 II 和表 III 展示了不同尺度下的预测精度结果。可以得出结论: 02,2025 年 00:29:25 (世界协调时) 来自 IEEE Xplore。存在限制条件。

表 I: 在罗氏数据集上不同尺度的 DTI 预测结果。

模型	1:1		1:10	
	AUC	AUPR	AUC	AUPR
射频 [38]	0.9016	0.9129	0.9176	0.7156
支持向量机 [39]	0.8586	0.8111	0.8871	0.6078
XGBoost [40]	0.9238	0.9323	0.9311	0.7864
GCN [41]	0.8938	0.8758	0.8617	0.5817
GAT [42]	0.8759	0.8668	0.8525	0.5340
DTICNN [43]	0.9262	0.9340	0.9319	0.7957
gcnda [44] 0.9424		0.9347	0.9423	0.6573
MVGCN [45]	0.9042	0.9017	0.9163	0.6959
MuRL-DTI	0.9541	0.9477	0.9513	0.8145

表 II: 在 Yamanishi 数据集上不同尺度下 DTI 预测的结果。

模型	1:1		1:10	
	AUC	AUPR	AUC	AUPR
射频 [38]	0.8485	0.8867	0.8475	0.8432
支持向量机 [39]	0.8411	0.8271	0.8071	0.7834
XGBoost [40]	0.9258	0.9213	0.9311	0.7864
GCN [41]	0.8818	0.8271	0.8313	0.6897
GAT [42]	0.8913	0.8578	0.8561	0.7382
DTICNN [43]	0.9012	0.8640	0.8612	0.8057
gcnda [44] 0.9214		0.8517	0.8221	0.8461
MVGCN [45]	0.9412	0.8819	0.8983	0.9159
MuRL-DTI	0.9542	0.9317	0.9413	0.9209

在 Lou 的数据集上，结果表明 MuRL-DTI 模型优于基准模型。具体而言，与 DTICNN 模型相比，AUC 和 AUPR 评估指标分别平均提高了约 2.4% 和 5.2%。与 GCNMDA 模型相比，AUC 和 AUPR 指标分别提高了 1.2% 和 12.3%。与 MVGCN 模型相比，性能分别提高了 3.6% 和 10.1%。这些结果证明了所提出模型的有效性。Yamanishi 和 Zheng 数据集的结果也表明，与基准模型相比，MuRL-DTI 表现最佳。

我们比较了 MuRL-DTI 与基准模型在不同样本比例下的性能。来自 Lou 数据集的结果表明，在 1:1 的样本比例下，MuRL-DTI 的 AUC 和 AUPR 指标优于基准模型，分别达到了 0.9541 和 0.9477 的高值。GCNMDA 模型的 AUC 和 AUPR 分别为 0.9424 和 0.9347，比 MuRL-DTI 低 1.2% 和 1.3%。此外，当样本比例变化时，该模型仍能保持其优越的性能。

表 III: 在郑的数据集上不同尺度的 DTI 预测结果。

模型	1:1		1:10	
	AUC	AUPR	AUC	AUPR
射频 [38]	0.9489	0.9481	0.8935	0.8001
支持向量机 [39]	0.9181	0.8824	0.9033	0.8249
XGBoost [40]	0.9440	0.9319	0.8909	0.8303
GCN [41]	0.9273	0.9100	0.8898	0.6926
GAT [42]	0.9186	0.8933	0.8729	0.7527
DTICNN [43]	0.9187	0.9132	0.8818	0.8817
gcnda [44] 0.5405		0.3727	0.4963	0.3422
MVGCN [45]	0.9024	0.8994	0.8495	0.8627
MuRL-DTI 授权	0.9591	0.9612	0.9323	0.9019

比例提高到 1:10，进一步证实了其稳健性和高效性。

C. 消融研究

我们评估了所提出的多模态融合（MF）模块和 DQN-RL 模块对模型性能的贡献。消融实验的结果分别在表 IV、V 和 VI 中给出。结果表明，这两个模块均显著提升了模型的整体性能，证明了它们的有效性。

表 IV: 在 Lou 数据集上的消融研究

模型	1:1		1:10	
	AUC	AUPR	AUC	AUPR
深度 Q 网络强化学习 (DQN-RL)	0.9321	0.9294	0.9295	0.7824
深度 Q 网络强化学习 + 矩阵分解	0.9477	0.9477	0.9513	0.8145

表 V: 在山下数据集上的消融研究

模型	1:1		1:10	
	AUC	AUPR	AUC	AUPR
深度 Q 网络强化学习 (DQN-RL)	0.9234	0.9091	0.9291	0.9027
深度 Q 网络强化学习 + 矩阵分解	0.9442	0.9317	0.9413	0.9209

表六: 在郑的数据集上的消融研究

模型	1:1		1:10	
	AUC	AUPR	AUC	AUPR
深度 Q 网络强化学习 (DQN-RL)	0.9134	0.9294	0.9192	0.8747
深度 Q 网络强化学习 + 矩阵分解	0.9401	0.9612	0.9323	0.9019

D. 参数敏感性分析

我们评估了深度神经网络层数对模型性能的影响。图 4 显示，随着层数的增加，存在一个阈值，超过该阈值后对性能的积极影响变得微不足道，从而导致模型复杂度增加。




图 4: 深度神经网络层数的影响。

IV. 结论

在本文中，我们提出了一种用于药物-靶点相互作用（DTI）预测的多模态融合强化学习模型，称为 MuRL-DTI。该模型采用基于 DQN 的强化学习框架来解决数据稀疏性和冷启动问题。通过利用现有知识来促进对未知药物与靶点相互作用预测的学习。我们纳入了两种生物学特征：化合物的序列特征和结构特征，以丰富强化学习中的环境信息并提高预测准确性。我们在三个标准的药物-靶点相互作用数据集上分别设计了正负样本分布比例为 1:1 和 1:10 进行测试。实验结果表明，我们的模型优于基准模型，突显了所提出方法的有效性。

参考文献

- [1] Chen, Hao, et al. "Drug target prediction through deep learning functional representation of gene signatures." *Nature communications* 15.1 (2024): 1853.
- [2] Suruliandi, A., T. Idhaya, and S. P. Raja. "Drug target interaction prediction using machine learning techniques—a review." (2024).
- [3] Bhargavi, V. Sessa, et al. "Accelerating Pharmaceutical Research and Development through AI-Driven Drug Discovery." 2024 Ninth International Conference on Science Technology Engineering and Mathematics (ICONSTEM). IEEE, 2024.
- [4] Tan, Dandan, et al. "Caution when using network partners for target identification in drug discovery." *bioRxiv* (2024): 2024-08.
- [5] Tu, Gao, et al. "Computational chemistry in structure-based solute carrier transporter drug design: Recent advances and future perspectives." *Journal of chemical information and modeling* 64.5 (2024): 1433-1455.
- [6] Li, Nan, et al. "Drug–target interaction prediction using knowledge graph embedding." *iScience* (2024).
- [7] Perlman L, Gottlieb A, Atias N, Rupp E, Sharan R. Combining drug and gene similarity measures for drug-target elucidation. *J Comput Biol*. 2011;18(2):133–45.
- [8] Perlman L, Gottlieb A, Atias N, Rupp E, Sharan R. Combining drug and gene similarity measures for drug-target elucidation. *J Comput Biol*. 2011;18(2):133–45.
- [9] Shi JY, Yiu SM In: 2015 IEEE International Conference on Bioinformatics and Biomedicine (BIBM) (IEEE, 2015): 1636–1641.
- [10] Shi JY, Li JX, Lu HM, Zhang Y. In: Intelligence Science and Big Data Engineering. Big Data and Machine Learning Techniques: 5th International Conference, IScIDE 2015, Suzhou, June 14–16, 2015, Revised Selected Papers, Part II 5 (Springer, 2015): 477–486.
- [11] Shi JY, Yiu SM, Li Y, Leung HC, Chin FY. Predicting drug-target interaction for new drugs using enhanced similarity measures and super-target clustering. *Methods*. 2015;83:98–104.
- [12] Pahikkala T, Airola A, Pietilä S, Shakyawar S, Szwarda A, Tang J, Aittokallio T. Toward more realistic drug-target interaction predictions. *Brief Bioinform*. 2015;16(2):325–37.
- [13] He T, Heidemeyer M, Ban F, Cherkasov A, Ester M. Simboost: a read-across approach for predicting drug-target binding affinities using gradient boosting machines. *J Cheminform*. 2017;9(1):1–14.
- [14] Yu H, Chen J, Xu X, Li Y, Zhao H, Fang Y, Li X, Zhou W, Wang W, Wang Y. A systematic prediction of multiple drug-target interactions from chemical, genomic, and pharmacological data. *PLoS ONE*. 2012;7(5): e37608.
- [15] Fu G, Ding Y, Seal A, Chen B, Sun Y, Bolton E. Predicting drug target interactions using meta-path-based semantic network analysis. *BMC Bioinform*. 2016;17(1):1–10.
- [16] Wang MY, Li P, Qiao P, et al. The virtual screening of the drug protein with a few crystal structures based on the adaboost-svm. *Comput Math Methods Med*. 2016: 2016.
- [17] Xia Z, Wu LY, Zhou X, Wong ST. In: *BMC systems biology*, vol. 4 (BioMed Central, 2010): 1–16.
- [18] Van Laarhoven T, Nabuurs SB, Marchiori E. Gaussian interaction profile kernels for predicting drug-target interaction. *Bioinformatics*. 2011;27(21):3036–43.
- [19] Wang Y, Zeng J. Predicting drug-target interactions using restricted Boltzmann machines. *Bioinformatics*. 2013;29(13):i126–34.
- [20] Aghakhani S, Qabaja A, Alhaji R. Integration of k-means clustering algorithm with network analysis for drug-target interactions network prediction. *Int J Data Min Bioinform*. 2018;20(3):185–212.
- [21] Ma T, Xiao C, Zhou J, Wang F. Drug similarity integration through attentive multi-view graph auto-encoders. *arXiv preprint arXiv:1804.10850*. 2018.
- [22] Nguyen T, Le H, Quinn TP, Nguyen T, Le TD, Venkatesh S. Graphdta: predicting drug-target binding affinity with graph neural networks. *Bioinformatics*. 2021;37(8):1140–7.
- [23] Wu Y, Gao M, Zeng M, Zhang J, Li M. Bridgedpi: a novel graph neural network for predicting drug-protein interactions. *Bioinformatics*. 2022;38(9):2571–8.
- [24] Yang Z, Zhong W, Zhao L, Chen CYC. Mgraphdta: deep multiscale graph neural network for explainable drug-target binding affinity prediction. *Chem Sci*. 2022;13(3):816–33.
- [25] Mukherjee S, Ghosh M, Basuchowdhuri P. In: *Proceedings of the 2022 SIAM international conference on data mining (SDM)* (SIAM, 2022): 729–737. Authorized licensed use limited to: IEEE Xplore. Downloaded on April 02, 2025 at 00:29:25 UTC from IEEE Xplore. Restrictions apply.
- [26] Ghimire A, Tayara H, Xuan Z, Chong KT. Csadta: prediction of drug-target binding affinity using convolution model with self-attention. *Int J Mol Sci*. 2022;23(15):8453.
- [27] Monteiro NR, Oliveira JL, Arrais JP. Dtitr: end-to-end drug-target binding affinity prediction with transformers. *Comput Biol Med*. 2022;147: 105772.
- [28] Huang L, Lin J, Liu R, Zheng Z, Meng L, Chen X, Li X, Wong KC. Coadti: multi-modal co-attention based framework for drug–target interaction annotation. *Brief Bioinform*. 2022;23(6):bbac446.
- [29] Mohamed S K, Novák V, Nounu A. Discovering protein drug targets using knowledge graph embeddings[J]. *Bioinformatics*, 2020, 36(2): 603-610.
- [30] Thafar M A, Olayan R S, Ashoor H, et al. DTiGEMS+: drug–target interaction prediction using graph embedding, graph mining, and similarity-based techniques[J]. *Journal of Cheminformatics*, 2020, 12: 1-17.
- [31] Peng J, Wang Y, Guan J, et al. An end-to-end heterogeneous graph representation learning-based framework for drug–target interaction prediction[J]. *Briefings in bioinformatics*, 2021, 22(5): bbaa430.
- [32] Tang, Wuguo, Qichang Zhao, and Jianxin Wang. "LLMDTA: Improving Cold-Start Prediction in Drug-Target Affinity with Biological LLM." *International Symposium on Bioinformatics Research and Applications*. Singapore: Springer Nature Singapore, 2024.
- [33] Mu, Zengchao, et al. "FECS: a novel feature extraction model for protein sequences and its applications." *BMC bioinformatics* 22 (2021): 1-15.
- [34] Islam, Md Ataul, and Tahir S. Pillay. "Simplified molecular input line entry system-based descriptors in QSAR modeling for HIV-protease inhibitors." *Chemometrics and Intelligent Laboratory Systems* 153 (2016): 67-74.
- [35] Luo, Yunan, et al. "A network integration approach for drug-target interaction prediction and computational drug repositioning from heterogeneous information." *Nature communications* 8.1 (2017): 573.
- [36] Yamanishi, Yoshihiro, et al. "Prediction of drug–target interaction networks from the integration of chemical and genomic spaces." *Bioinformatics* 24.13 (2008): i232-i240.
- [37] Zheng, Yi, et al. "Predicting drug targets from heterogeneous spaces using anchor graph hashing and ensemble learning." 2018 International Joint Conference on Neural Networks (IJCNN). IEEE, 2018.
- [38] Pedregosa, Fabian, et al. "Scikit-learn: Machine learning in Python." *the Journal of machine Learning research* 12 (2011): 2825-2830.
- [39] Chang, Chih-Chung, and Chih-Jen Lin. "LIBSVM: a library for support vector machines." *ACM transactions on intelligent systems and technology (TIST)* 2.3 (2011): 1-27.
- [40] Chen, Tianqi, and Carlos Guestrin. "Xgboost: A scalable tree boosting system." *Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining*. 2016.
- [41] Kipf, Thomas N., and Max Welling. "Semi-supervised classification with graph convolutional networks." *arxiv preprint arxiv:1609.02907* (2016).
- [42] Velićković, Petar, et al. "Graph attention networks." *arxiv preprint arxiv:1710.10903* (2017).
- [43] Peng, Jiajie, **gyi Li, and Xuequn Shang. "A learning-based method for drug-target interaction prediction based on feature representation learning and deep neural network." *BMC bioinformatics* 21.Suppl 13 (2020): 394.
- [44] Long, Yahui, et al. "Predicting human microbe–drug associations via graph convolutional network with conditional random field." *Bioinformatics* 36.19 (2020): 4918-4927.
- [45] Fu, Haitao, et al. "MVGCN: data integration through multi-view graph convolutional network for predicting links in biomedical bipartite networks." *Bioinformatics* 38.2 (2022): 426-434.