

MVCL-DTI: 基于异质图的多视图对比学习模型预测药物-靶点相互作用

Bei Zhang, Lijun Quan,* Zhijun Zhang, Lexin Cao, Qiufeng Chen, Liangchen Peng, Junkai Wang, Yelu Jiang, Liangpeng Nie, Geng Li, Tingfang Wu, and Qiang Lyu



引用格式:《化学信息与建模杂志》2025年,第65卷,第1009



Read Online

访问权限



指标与更多内容




文章推荐

* 支持信息

摘要: 准确预测药物-靶点相互作用 (DTIs) 对于加快药物发现和药物再利用进程至关重要。MVCL-DTI 是一种利用异质图预测 DTIs 的新型模型,旨在解决从不同生物子网络中综合信息的难题。该模型整合了邻居视图、元路径视图和扩散视图以捕获语义特征,并采用基于注意力机制的对比学习方法以及多视图注意力加权融合模块,从而有效地整合信息并自适应地调整。

权重来自不同视角的信息。在……下进行测试

在基准数据集的各种条件下,包括不同的正负样本比例、进行难负样本采样实验、以不同比例屏蔽已知的药物靶点相互作用 (DTIs) 以及具有不同相似性度量的冗余 DTIs, MVCL-DTI 均表现出强大的稳健泛化能力。然后,该模型被用于预测新的 DTIs,特别关注与 COVID-19 相关的药物,突出了其实际应用价值。最终,通过特征可视化和计算属性分析,我们确定了关键要素,包括基因本体论和取代基节点,以及适当的初始化策略,强调了它们在 DTI 预测任务中的重要作用。



1. 简介

在大多数药物设计项目中,药物发现流程的第一步是识别能与特定蛋白质靶点高亲和力结合的配体分子。这些分子可进一步开发成药物类化合物,因为药物通过与蛋白质相互作用发挥治疗作用。¹用于识别药物分子的实验方法,如高通量筛选,既耗时又昂贵。相比之下,用于药物-蛋白质相互作用预测的计算方法可以显著减少所需资源、时间和成本,并且最大程度地减少对生物湿实验室研究来筛选新的治疗候选药物的需求。

计算型药物-靶点相互作用 (DTI) 预测方法大致可分为基于对接的方法、基于配体的方法以及基于机器学习的方法。²基于对接的方法计算量大,需要精确的蛋白质三维结构测量。^{3,4}基于配体的方法通常遵循相似性原则,⁵即结构相似的化合物往往具有相似的生物活性。尽管这些方法不需要蛋白质的详细结构信息,但其准确性在很大程度上取决于已知 DTI 数据的可用性和质量。基于机器学习的方法由于能够处理大规模和复杂的生物数据,在 DTI 预测中越来越受欢迎。这些方法利用各种算法来学习模式和关系。

根据已知的相互作用,并利用这些知识来预测新的相互作用。

现有的药物-靶点相互作用 (DTI) 预测模型主要依赖机器学习方法,其中图神经网络 (GNN) 被广泛应用。通过将药物分子和蛋白质表示为图,节点代表原子或氨基酸,边代表化学键,GNN 能够捕捉药物和蛋白质的功能结构及化学特性。所学得的表示有助于 DTI 的预测。^{NetLapRLS6} 基于化学结构、基因组数据及其他特征构建药物和靶点相似性矩阵。^{EADTN7} 引入了一种创新的特征适应技术,能够自动提取药物和靶点的局部权重。它还采用聚类增强的参数微调来解决假阴性问题,从而提高其在药物发现中的可靠性。GCN-DTI⁸ 构建药物-蛋白质对 (DPP) 网络,并将边预测问题转化为 DPP 分类问题。然而,构建同质图虽然能对相互作用进行详细的微观层面分析,但

Received: November 9, 2024

Revised: January 1, 2025

Accepted: January 8, 2025

Published: January 15, 2025






图 1. MVCL-DTI 的架构。MVCL-DTI 主要由四个部分组成：(a) 异构图的构建。该图包含六种类型的节点：药物、蛋白质、疾病、副作用、取代基和 GO 术语。它们之间的相互作用、关联或相似性以不同类型的边来表示。(b) 从三个不同视角进行表示学习。邻居视图编码器捕获 2 跳邻居信息，元路径视图编码器从基于元路径的邻居中推导特征，扩散视图编码器通过随机游走捕获高阶邻居信息。(c) 通过对比学习整合多视图信息。采用注意力加权融合机制有效地整合来自三个视图的表示。(d) 异构网络的重构。利用邻居视图的节点表示来重构原始网络，所得的药物 - 蛋白质相互作用 (DTI) 网络作为最终的预测结果。

限制了对复杂生物背景（如疾病关联和药物副作用）的整合，而这些对于全面理解至关重要。

此外，引入包含多种类型节点和边的异质图，相较于同质图，丰富了语义背景。异质图将蛋白质、药物、疾病等作为节点，将相互作用和关联作为边，使模型能够学习生物网络中的全面拓扑信息和复杂交互。对于涉及药物和蛋白质的异质图，DPI 模型⁹提出了一种新颖的框架，通过整合药物 - 蛋白质二部图中节点的全局和局部特征，实现高效的药物 - 蛋白质相互作用推断。IGRLDTI¹⁰ 利用异质生物交互网络 (HBIN)，将药物和靶点的生物知识与其相互作用相结合，并采用依赖节点的局部平滑策略，自适应地确定每个生物分子的传播深度，从而缓解过度平滑问题，提升药物和靶点的表示效果。与此同时，大多数图神经网络 (GNNs) 针对的是同质图，其中每一层仅从单跳邻居处聚合信息。将这些方法应用于异质图时，通过堆叠多个网络层会引入大量噪声，并且很容易导致过度平滑。因此，异质图神经网络 (HGNNs) 应运而生。DTInet¹¹ 集成多种数据源构建异质网络以进行药物 - 靶点相互作用 (DTI) 预测。NeoDTI¹² 也构建了一个包含药物和蛋白质信息的异质网络，并采用网络嵌入技术学习药物和蛋白质的低维表示，基于它们的接近程度来预测相互作用。EEG-DTI¹³ 利用异质图卷积网络在异质网络中学习药物和靶点的表示，并采用端到端框架进行 DTI 预测。SGCL¹⁴ 使用基于元路径

的图编码器结合注意力机制从异质网络中学习药物和蛋白质节点表示，构建拓扑和语义网络以进行 DTI 预测。FuHLDR¹⁵ 利用图卷积网络进行低阶表示学习，并采用基于元路径的策略来学习药物、蛋白质和疾病之间的高阶关系。SHGCL-DTI¹⁶ 引入了邻域视图和元路径视图编码器用于节点聚合，并采用图对比学习来获取节点表示，从而提升了药物 - 靶点相互作用 (DTI) 预测性能以及框架的泛化能力。LG-DTI¹⁷ 采用双视图方法进行 DTI 预测，结合了从分子结构和蛋白质序列等生物信息中提取属性特征的局部视图，以及从异质信息网络 (HIN) 的拓扑结构中捕获药物和蛋白质行为特征的全局视图。MHGNN-DTI¹⁸ 利用元路径聚合的异质图神经网络，在生物异质图中捕捉药物 - 靶点对之间的高阶关联，以进行 DTI 预测。MHTAN-DTI¹⁹ 应用了基于元路径的分层变换器和注意力网络，在异质生物信息网络上利用元路径实例级变换器、单语义注意力和多语义注意力，生成药物和蛋白质的低维向量表示，以实现准确的 DTI 预测。

然而，目前用于药物 - 靶点相互作用预测的异质图通常仅包含药物、蛋白质、疾病和副作用节点。尽管这些异质图提供了详细的信息和丰富的语义，但通过整合更多的数据源来提升预测性能仍有很大的潜力。例如，纳入多组学数据，如分子属性、蛋白质相互作用和基因本体注释，能够提供更全面的生物网络视图，从而丰富特征空间。

并且提高模型的预测能力。此外, 现有的大多数多视图方法主要只利用两个视图, 这限制了信息的交互和整合。多视图交互的潜力巨大,²¹ 因为不同的视图可以从不同的角度对相同的生物现象进行补充。然而, 挑战在于如何有效地整合和融合来自多个视图的信息。因此, 开发能够平衡每个视图的贡献、保留它们所提供的独特信息并增强其集体预测能力的有效多视图融合方法至关重要。

为应对上述挑战, 我们提出了一种新颖的异质图多视图对比学习模型 MVCL-DTI 用于预测药物-靶点相互作用 (DTIs)。首先, 我们引入了两种有效的特征用于 DTI 预测任务: 基因本体论 (GO) 和取代基, 它们补充了异质图中节点和边的生物学信息。与其他方法将 GO 和取代基作为目标和药物特征编码的一部分不同, 我们的方法将 GO 和取代基视为异质图结构中的独立节点。然后, 该模型从异质图的三个不同视图 (即邻居视图、元路径视图和扩散视图) 中学习表示, 捕获多维信息以实现全面的特征表示。通过自注意力机制, 每个视图保持相对独立, 而对比学习则最大化了同一蛋白质和药物节点在三个视图中的表示相似度。此外, 还采用了多视图注意力加权融合机制, 以自适应地整合来自这些不同视图的信息, 确保每个视图中最相关的特征得到突出。最后, 我们重建原始异质图以获得药物-靶点相互作用 (DTI) 预测结果。实验结果表明, 我们的模型在经典数据集上优于基线方法, 并在具有挑战性的场景中保持了稳健的性能。具体而言, MVCL-DTI 在不同正负样本比例下的基准测试中, 在 AUROC 和 AUPR 指标上均表现出色。此外, 在涉及选择难负样本、掩码已知和冗余 DTI 以及评估独特 DTI 的实验中, 它也展示了稳健的性能, 这表明其在各种场景中的适应性和有效性。通过文献验证的新 DTI 支持了该模型发现新治疗靶点的潜力, 其在诸如 COVID-19 药物研究等实际应用中的竞争力也得到了强调。特征可视化揭示了该模型捕捉丰富高维特征的能力, 而计算属性分析则确定了 MVCL-DTI 优越性能的关键因素, 包括有效的特征表示、GO 和取代基节点特征表示的整合以及特征初始化策略的重要性。在训练期间对超参数进行调整对于模型的成功至关重要。全面的实验表明, MVCL-DTI 的稳健性能是精心设计和仔细训练的结果。

2. 材料与方法

MVCL-DTI 的架构如图 1 所示。我们的方法包含四个主要组件: 首先, 我们构建包含药物、蛋白质、疾病、副作用、取代基和 GO 节点的异构图。它们之间的相互作用、关联或相似性以各种类型的边来表示。其次, 我们从三个不同的视角学习异构图的表示, 即邻

居视角编码器、元路径视角编码器和扩散视角编码器, 使模型能够捕获多维信息。邻居视角编码器捕获异构图中每个节点的 2 跳邻居信息。元路径视角编码器从基于元路径的邻居节点中推导节点特征。扩散视角编码器通过在异构图上进行随机游走进一步捕获高阶邻居信息。第三, 我们采用带有注意力机制的对比学习, 通过有效整合不同视角的信息来推导节点表示。此外, 还利用了多视图注意力加权融合模块来进一步增强整合过程, 使模型能够自适应地为每个视图分配重要性, 从而获得更稳健和全面的特征表示。最后, 我们使用来自邻居视图的节点表示来重建原始的异质网络, 重建的药物-靶点相互作用网络即为预测结果。

2.1. 数据集。我们选择罗 (Luo) 的数据集¹¹ 作为构建我们自己的药物-靶点相互作用 (DTI) 任务数据集的基础。罗的数据集是一个经典的用于构建异质网络以预测药物-靶点相互作用的数据集。它包含了从公共数据库收集的四种类型的节点: 来自 DrugBank 数据库²³ 的药物节点、来自 HPRD 数据库²⁴ 的蛋白质节点、来自 Comparative Toxicogenomics Database²⁵ 的疾病节点以及来自 SIDER 数据库²⁶ 的副作用节点。这些节点之间的相互作用形成了八种关系网络: “药物-副作用关联网络”来自 SIDER 数据库, “蛋白质-疾病关联网络”和 “药物-疾病关联网络”来自 Comparative Toxicogenomics Database, “药物-蛋白质相互作用网络”和 “药物-药物相互作用网络”来自 DrugBank 数据库, “蛋白质-蛋白质相互作用网络”来自 HPRD 数据库。此外, 还有 “药物化学结构相似性网络”, 其中药物间的相似性是基于药物的化学结构, 利用 Tanimoto 系数计算得出;²⁷ 以及 “蛋白质序列相似性网络”, 其中蛋白质间的相似性是基于基因组序列, 利用 Smith-Waterman 算法计算得出。²⁸ 总体而言, 罗的数据集包含 12,015 个节点和 1,894,854 条边。

此外, 我们还添加了两类节点类型: 从 Uniprot 收集的 GO 以及从 DrugBank 数据库收集的药物取代基:

- 基因本体论 (GO) 从三个方面描述生物学知识: 分子功能、生物过程和细胞成分, 这些通常与基因和蛋白质的功能相关联。
- 取代基: 药物取代基是指药物分子中某些原子或基团取代一个或多个氢原子而形成的官能团。取代基能够显著影响药物分子的物理、化学和生物特性, 改变其活性、选择性和药代动力学性质。

同时, 引入了两个新的边: 来自 Uniprot 的 “蛋白质 - GO 关联网络” 和来自 DrugBank 数据库的 “药物 - 基团关联网络”。这些新增内容增强了数据集的全面性, 并提供了更详细的药物相关相互作用的表示。我们新构建的数据集现在包含 22,225 个节点和 1,953,082 条边。详细统计数据见表 1。我们在该异构图中识别出 1,923 个药物 - 目标相互作用, 并将此数据集命名为 D1923。积极的

表 1.D1923 详细统计数据

节点	计数	边缘	计数
药物	708	药物-蛋白质	1,923
蛋白质	1,512	药物-药物	10,036
疾病	5,603	药物-疾病	199,214
副作用	4,192	药物副作用	80,164
GO	9,279	药物取代基	14,896
取代基	931	蛋白质-蛋白质	7,363
总计	22,225	蛋白质-疾病	1,596,745
		蛋白质-基因本体论	42,741
		总计	1,953,082

用于药物靶点相互作用 (DTI) 预测的样本是从已知的 DTI 中选取的, 而负样本则从未知的 DTI 中选取。因此, 在这个异构图中, 正样本和负样本的数量分别为 1923 和 1068573。需要注意的是, 用于训练的负样本数量可以根据不同的实验设置随机选取。

为了捕捉多样化的交互关系, 我们定义了以下元路径: 药物-药物、药物-蛋白质-药物、药物-疾病-药物、药物-副作用-药物、药物-取代基-药物、蛋白质-蛋白质、蛋白质-药物-蛋白质、蛋白质-疾病-蛋白质以及蛋白质-GO-蛋白质。元路径不仅考虑节点之间的直接关系, 还考虑通过多个节点和边连接的间接关系。例如, 药物-蛋白质-药物表示药物通过相同的蛋白质相互关联, 与相同蛋白质相互作用的药物可能具有相似的特性。药物-疾病-药物表示药物通过治疗相同的疾病相互关联, 治疗相同疾病的药物可能具有相似的特性。药物-副作用-药物表示药物通过引起相同的副作用相互关联, 引起相同副作用的药物可能具有相似的特性。因此, 元路径能够捕捉更复杂的图结构和语义信息, 对于从异质网络中提取有意义的关系至关重要。

2.2. 异构网络构建。异构图可以表示为 $G = (V, E)$, 其中 V 和 E 分别表示图中的节点集和边集, 而 A 和 R 分别表示节点类型集和边类型集。在异构图中, 存在多种节点和边类型, 即 $|A + R| > 2$ 。

我们扩展了罗的数据集¹¹来构建我们的异质图, 引入了两个新节点: GO 和取代基, 以及两条相应的新边: 药物-取代基和蛋白质-GO 关联。因此, 在这项工作中, $A = \{\text{药物、蛋白质、疾病、副作用、GO、取代基}\}$, $R = \{\text{药物-药物相互作用、药物-蛋白质相互作用、药物-疾病关联、药物-副作用关联、药物-取代基关联、蛋白质-蛋白质相互作用、蛋白质-疾病关联、蛋白质-GO 关联、药物-药物相似性、蛋白质-蛋白质相似性}\}$ 。对于八个相互作用或关联网络, 每条边的权重 q 均设为 1。对于两个相似的网路, 边的权重 q 则基于药物之间的相似性得分或蛋白质之间的相似性得分。然后, 我们将这些相似性得分归一化到 0-1 的范围内, 将其作为边的权重。

元路由交替出现的节点类型及其关系构成, 是用于描述异构网络中节点与边之间关系的抽象路径。元路径不仅考虑节点之间的直接连接, 还考

虑通过不同类型的节点和关系形成的间接连接, 从而捕获异构网络中的高阶结构和语义信息。我们使用

一条元路径, 其中 $a_i \rightarrow a_j$ 表示

在本文中, 对于节点 v_i , 基于元路径的邻居节点被定义为通过元路径 P_n 与 v_i 相连的节点。

2.3. 节点特征初始化。对于药物节点特征的初始化, 使用分子表示法以人类可读的格式描述分子, 其中简化分子线性输入规范 (SMILES) 是一种常见的格式。^{29,30} SMILES 采用严格的语法简化化学结构。此外, 为了更全面地理解药物分子结构, 还建立了化学指纹。^{31,32} 经过对多种方法的试验, 我们选择基于 SMILES 表达式的 MACCS 指纹作为药物节点的输入。该表达式定义了 166 个分子描述符。为了提取最重要的分子描述符, 我们采用主成分分析 (PCA) 将其维度³³至 128。

对于蛋白质节点, 自然语言处理 (NLP) 领域中预训练模型的进步已成功应用于从蛋白质序列中学习隐藏的生物学信息。我们利用 ESM2 蛋白质语言模型³⁴从其序列中提取蛋白质特征。与药物处理类似, 我们使用主成分分析 (PCA) 将蛋白质节点描述符的维度降至 128。

对于其余节点: 疾病、副作用、GO 和取代基, 我们遵循了 Yao 等人的方法,¹⁶ 并采用 node2vec 方法来初始化这些节点特征。Node2vec 提供了一种在广度优先搜索 (BFS) 和深度优先搜索 (DFS) 之间取得平衡的机制, 通过随机游走学习节点嵌入, 从而能够更好地捕捉图的局部和全局结构。Node2vec 将上下文关系转化为药物-药物相互作用、药物-疾病关联、药物-副作用关联、药物-取代基关联、蛋白质-蛋白质相互作用、蛋白质-疾病关联以及蛋白质-GO 关联的特征。输出维度设置为 128, 与药物和蛋白质特征的维度保持一致。

2.4. 邻居视图编码器。我们利用异构图卷积网络 (HGNC) 从构建的异构图中提取节点特征。对于每个节点, 我们首先根据边的类型对其一阶邻居进行分组, 以便不同类型的边能够分别聚合。当 HGNC 只有一层时, 节点只能从一阶邻居处聚合信息。堆叠 N 层图卷积使得节点能够从 N 阶邻居处聚合信息。 N 越大, 聚合范围越广, 但 N 过大可能导致梯度消失。通过实验, 我们将 N 设为 2。每个 HGNC 层的聚合过程定义如下:

其中 l 表示层数, N_{ir} 表示在边类型 r 下节点 v_i 的邻居集合, $|R|$ 是边类型的数量

类型, $Q_{ir} = \sum_{j \in N_{ir}} q_{ij,r}$, $q_{ij,r}$ 表示边的权重,

$$h_i^{(l+1)} = \frac{1}{1 + |R|} \left(\sum_{r \in R} \sum_{j \in N_{ir}} \frac{q_{ij,r}}{Q_{ir}} \sigma(W_r^{(l)} h_j^{(l)} + b_r^{(l)}) + h_i^{(l)} \right) + h_i^{(l)} \quad (1)$$

$\sum_{\epsilon}$

其中 Q_{ir} 和 $W_r^{(l)}$ 是归一化常数, $b_r^{(l)}$ 和 $h_i^{(l)}$ 是边类型 r 的全连接层的权重和偏差, σ 是激活函数 (ReLU)。 $h_j^{(l)}$ 和 $h_i^{(l)}$ 分别表示第 l 层的节点特征和邻居特征。为了应对堆叠多层时可能出现的过度平滑问题,我们在 HGCN 架构中引入了残差连接。具体来说,第 $l+1$ 层中每个节点的特征表示是通过将其邻居的转换特征与第 l 层的原始特征相加而获得的。这种残差设计确保了模型在有效学习高阶交互的同时保留了低级信息。当 $l=0$ 时,使用初始化的节点特征作为输入。最终,我们获得了邻居视图的节点特征 h^{ne} 。

2.5. 元路径视图编码器。利用预定义的元路径,我们采用基于特征线性调制的图神经网络 (GNN-FiLM) 来获取元路径视图中的节点表示。GNN-FiLM 为不同类型的节点生成不同的偏移 (β) 和缩放 (γ) 参数,根据每个节点的类型动态调整节点特征表示:

$$\beta_{p_n,i}^{(l)}, \gamma_{p_n,i}^{(l)} = g(h_i^{(l)}; \theta_{g,p_n}) \quad (2)$$

其中 g 是用于计算仿射变换参数的可学习函数, θ_{g,p_n} 是元路径 p_n 的可学习函数的参数。

在 GNN-FiLM 中,目标节点的表示通过变换应用于所有传入的信息,实现了基于特征调制的信息传输。目标节点的表示根据其类型利用 FiLM 参数 $\beta_{p^{(l)},i}$ 和 $\gamma_{p^{(l)},i}$ 进行调制。

$$h_{i,p_n}^{(l+1)} = \sigma \left(\sum_{j \in N_{i,p_n}^{(l)}} \gamma_{p_n,i}^{(l)} \odot (W_{p_n,i}^{(l)} h_j^{(l)}) + \beta_{p_n,i}^{(l)} \right) + h_{i,p_n}^{(l)} \quad (3)$$

其中, $N_{i,p_n}^{(l)}$ 是基于元路径 p_n 的节点 v_i 的邻域集合, $W_{p_n,i}^{(l)}$ 是第 l 层的权重矩阵。与标准的 GCN 相比, GNN-FiLM 在处理包含多种节点和边类型的异构图时特别有效,因为标准 GCN 不区分节点类型,对所有节点一视同仁。

GNN-FiLM 使我们能够捕获异构图中的深层语义信息,从而增强模型对复杂图结构的理解。由于不同类型的元路径封装了不同的语义信息,我们使用语义级注意力机制来聚合来自不同元路径的结果。首先,我们按如下方式计算每条元路径的重要性:

$$W_{p_n} = \frac{1}{|V|} \sum_{i \in V} \alpha^T \cdot \sigma(W h_{i,p_n}^{(l)} + b) \quad (4)$$

其中 W 是权重矩阵, b 是偏差向量, α 是语义级注意力向量。在获得每条元路径的重要性之后,我们使用 softmax 对其进行归一化处理,以得到元路径的权重 p_n :

$$\beta_{p_n} = \text{softmax}(W_{p_n}) = \frac{\exp(W_{p_n})}{\sum_{p_i \in P} \exp(W_{p_i})} \quad (5)$$

最后,我们得到最终的节点表示:

$$h_i^{(l)} = \sum_{n=1}^m \beta_{p_n} \cdot h_{i,p_n}^{(l)} + h_i^{(l-1)} \quad (6)$$

其中 m 表示元路径的数量。与邻域视图类似,通过使用带有残差连接和 L2 正则化的两层元路径视图编码器,我们获得了元路径视图 h^{mp} 的节点表示。

2.6. 扩散视图编码器。为缓解多层图卷积操作所导致的过度平滑效应,我们首先应用一跳图卷积操作,如公式 1 所示。

在图卷积之后,我们采用随机游走重启 (RWR) 策略进行进一步的信息传播。在异构图上应用 RWR 可以使模型关注更高阶的邻居,同时避免过度平滑。在随机游走图中,节点通过一系列随机步骤在图中移动,通常由概率分布决定。该模型有助于研究节点间的信息扩散过程,捕捉更大范围内的连接。如果异构网络的转移矩阵为 A ,重启概率为 ∂ ,则 RWR 定义为

$$A_{ppr} = \partial(I - (1 - \partial)A)^{-1} \quad (7)$$

其中 I 是单位矩阵,而 $A_{ppr}(u, v)$ 表示节点 u 对节点 v 的影响。

根据公式 7,我们可以将节点信息传播到较远的距离,从而得到最终的节点嵌入向量:

$$h^{(l)} = \partial(I - (1 - \partial)A)^{-1} h^* + h^{(l-1)} \quad (8)$$

其中 h^* 是通过卷积操作获得的节点嵌入矩阵。与前两个视图类似,通过使用带有残差连接和 L2 正则化的两层扩散视图编码器,我们获得了扩散视图 h^{df} 的节点表示。

2.7. 对比学习。首先,我们分别将来自三个视角的节点嵌入矩阵通过自注意力机制层进行传递。在相同视角内进行计算时,自注意力机制³⁹使得模型的不同部分能够相互“关注”,从而增强模型的表示能力。自注意力机制有助于模型更好地捕捉重要特征和关系,提高表示的质量和准确性。以邻居视角的嵌入计算为例:

$$h_{att}^{ne} = \text{Attention}(h^{ne}) \quad (9)$$

我们采用了一个具有隐藏层神经元的多层感知器 (MLP)。

将 h_{att}^{ne} 、 h_{att}^{mp} 和 h_{att}^{df} 映射到适合计算对比损失的空间中,从而得到 z^{ne} 、 z^{mp} 和 z^{df} 。接下来,我们将不同视图中相同的药物或蛋白质节点定义为正样本对,其他节点对定义为负样本对。对于节点 v_i , Pos_i 表示正样本集,其余节点构成负样本集 Neg_i 。利用信息噪声对比估计损失 (InfoNCE)⁴⁰,我们计算两个视图 (例如邻居视图和元路径视图) 之间的对比损失:

$$L_k^{NEtoMP} = \frac{1}{|V|} \sum_{i \in V_k} -\log \left(\sum_{j \in Pos_i} \text{softmax} \left(\frac{\text{sim}(z_i^{ne}, z_j^{mp})}{\tau} \right) \right) \quad (10)$$

$$L_k^{MPtoNE} = \frac{1}{|V|} \sum_{i \in V_k} -\log \left(\sum_{j \in Pos_i} \text{softmax} \left(\frac{\text{sim}(z_i^{mp}, z_j^{ne})}{\tau} \right) \right) \quad (11)$$

$$L^{ne-mp} = \sum_{k \in K} L_k^{NEtoMP} + L_k^{MPtoNE} \quad (12)$$

其中 τ 是温度系数, V_k 表示类型为 k 的节点集合, k 属于 $K = \{\text{药物}, \text{蛋白质}\}$, sim 表示余弦相似度。我们最大化正样本对表示之间的相似度, 使节点能够从三个视角学习表示。

对比损失 L^{ne-mp} 、 L^{ne-df} 和 L^{mp-df} 的计算方式类似, 所得到的表示用于后续的 DTI 预测:

$$Loss_{contrastive} = L^{ne-mp} + L^{ne-df} + L^{mp-df} \quad (13)$$

2.8. 多视角注意力加权融合。为了进一步整合从不同视角提取的特征, 我们引入了一个受 RGLDR 启发的多视角注意力融合模块。⁴¹ 对比学习中学习到的表示 h^{ne} 、 h^{mp} 和 h^{df} 被输入到注意力融合模块中, 该模块动态地为每个视角分配重要性权重, 并有效地聚合它们的信息。该过程可总结如下:

对于每个视图 $i \in \{ne, mp, df\}$, 注意力得分 e^i 计算方式如下

$$e^i = W_{att}^T \cdot \tanh \left(W \cdot \frac{1}{|V|} \sum_{k \in I} h_k^i + b \right) \quad (14)$$

其中, $\mathbb{V}(h_{ki})$ 表示节点 k 在视图 i 中的特征向量, $\mathbb{V}(W)$ 和 W_{att} 是可学习的权重矩阵, $\mathbb{V}(b)$ 是偏置项。此步骤捕捉了不同视图之间的高级交互。

注意力系数 β_i (表示每个视角的相对重要性) 随后通过 softmax 函数进行归一化处理:

$$\beta_i = \frac{\exp(e^i)}{\sum_{j \in \{ne, mp, df\}} \exp(e^j)} \quad (15)$$

最后, 我们为每种节点类型 k 计算融合表示 H_k , 将其作为特定视图表示的加权和:

$$H_k = \sum_{i \in \{ne, mp, df\}} \beta_i \cdot h_k^i \quad (16)$$

2.9. 用于药物-靶点相互作用预测的异质网络重构。在特征聚合和信息传播之后, 我们利用所获得的六种类型节点的表示来重构异质网络, 并采用 DistMult⁴² 方法作为评分机制。具体而言, 对于原始异质图中的十种类型的边, 我们使用 DistMult 进行重构。重构后的药物-靶点相互作用网络即为预测结果, 定义为

$$N_{reconstruction}^{dti} = H_{drug}^T M_{dti} H_{protein} \quad (17)$$

其中 H_{drug} 和 $H_{protein}$ 分别是前面步骤中获得的药物和蛋白质节点特征矩阵, 而 M_{dti} 是一个可学习的针对特定边类型的对角矩阵。其他类型边的重建过程与 DTI 网络的类似。

损失函数的计算方法如下:

$$Loss_{reconstruction} = \sum_{r \in R} (Q^r)^2, \quad Q^r = N_{original}^r - N_{reconstruction}^r \quad (18)$$

并且是原始的和重建的边类型为 r 的异构网络。 Q 是一个矩阵, 用于存储预测值与真实值之间的差值。

最后, 加上 L2 正则化项, 我们得到最终的目标函数:

$$\begin{aligned} Loss &= Loss_{reconstruction} + \lambda_1 Loss_{contrastive} + \lambda_2 Loss_{L_2} \\ &= Loss_{reconstruction} + \lambda_1 Loss_{contrastive} + \lambda_2 \sum_w w^2 \end{aligned} \quad (19)$$

其中, λ_1 和 λ_2 是超参数, w 表示模型中的权重。本文训练过程的目标是使该目标函数最小化。

3. 实验评估与讨论

3.1. 参数设置。对于我们的模型, 我们将每个视图编码器的网络层数设置为 2 层, 隐藏层维度为 2048。学习率设置为 1e-3, 温度参数 τ 设置为 0.5, 丢弃率设置为 0.2。我们使用带有提前停止机制的 Adam 优化器, 运行 5000 次迭代。

3.2. 评估指标。药物靶点相互作用 (DTI) 预测可视为二分类任务, 因此我们使用 AUROC (受试者工作特征曲线下面积) 和 AUPR (精确率召回率曲线下面积) 作为评估指标。AUROC 是一种用于评估分类器性能的全局指标。它通过绘制真阳性率 (TPR, 也称为召回率) 与假阳性率 (FPR) 之间的关系来衡量分类器在不同决策阈值下的性能。AUROC 值介于 0.5 至 1 之间, 值越高表明模型性能越好。在极度不平衡的数据集中, 假阳性率可能非常低, 这可能会使 AUROC 值具有误导性。即使假阳性率很低, AUROC 仍可能表现良好, 但在实际应用中模型可能无法有效区分少数类。而 AUPR 则评估不同阈值下精确率与召回率之间的关系, 其值介于 0 至 1 之间。AUPR 特别适合用于评估不平衡数据集上的模型性能, 因为它更侧重于少数类别的预测。为确保实验结果的均衡性, 我们在整个数据集上采用了 10 折交叉验证的设置。其他方法的结果取自其各自的论文。

3.3. 基准方法。在选择对比方法时, 我们优先考虑具有代表性和处于前沿水平的方法, 包括 SHGCL-DTI¹⁶, 以验证我们模型的竞争力。此外, 我们还纳入了两种经典的机器学习方法, 即 NetLapRLS⁶ 和 DTInet¹¹, 这两种方法在该领域广受认可, 并常被用作基准。其余的方法均为先进的基于图神经网络 (GNN) 的方法: NeoDTI¹² 和 EEG-DTI¹³。最终, 为了评估我们模型的性能, 我们使用罗 (Luo) 的数据集与五种基准方法进行了比较:

· NetLapRLS: NetLapRLS 采用了一种半监督学习算法, 该算法运用拉普拉斯正则化最小二乘法, 将相似性和交互信息都纳入预测框架之中。

表 2.不同正负样本比例的结果

比率	1:1		1:10		1: 所有; 全部	
	AUROC	AUPR	AUROC	AUPR	AUROC	AUPR
NetLapRLS	0.9412	0.9485	0.9073	0.7406	0.8891	0.4081
DTInet	0.9302	0.9538	0.9150	0.8184	0.9072	0.4402
新DTI	0.9455	0.9555	0.9452	0.8495	0.9153	0.5808
脑电图-弥散张量成像 (EEG-DTI)	0.9551	0.9643	0.9554	0.8747	0.9532	0.1697
SHGCL-DTI	0.9510	0.9621	0.9582	0.8851	0.9234	0.6098
MVCL-DTI	0.9604	0.9674	0.9677	0.9024	0.9449	0.6728

表中加粗的数值表示最高性能。

· DTInet: DTInet 利用无监督学习从异质网络数据中推导出药物和靶点的低维特征表示。它根据候选靶点的特征向量与药物向量的几何距离对靶点进行排序, 从而预测新的药物-靶点相互作用。

· NeoDTI: NeoDTI 将图卷积网络 (GCNs) 应用于异构图。利用网络来学习药物和靶点的表示形式。它进行优化以端到端的方式进行特征提取和弥散张量成像 (DTI) 预测通过重建原始网络来预测相互作用。

· 脑电图-弥散张量成像 (EEG-DTI): EEG-DTI 是一种端到端的异构图表示学习方法。它使用图卷积网络 (GCNs) 来生成异构图中节点的特征表示网络。最后一步涉及应用内积。预测药物靶点相互作用 (DTIs) 的方法。

· SHGCL-DTI: SHGCL-DTI 构建了一个邻域视图编码器和用于节点聚合的元路径视图编码器。这种方法利用图对比学习来获取稳健的节点表示。通过对比不同的视角, SHGCL-DTI 提升了模型的性能和泛化能力。

DTI 预测框架。

3.4. MVCL-DTI 在基准测试中的预测准确性。3.4.1 正负样本比例对模型性能的影响。在实际场景中, 已确认的药物-靶点相互作用较为稀少, 导致负样本数量远多于正样本。我们通过不同比例的正负样本进行了实验, 以探究样本比例变化对实验结果的影响, 并验证模型的泛化能力。实验结果见表 2。

首先, 我们构建了一个正负样本比例为 1:1 的平衡数据集, 其中所有已知的药物-靶点相互作用 (DTI) 作为正样本, 从未知的 DTI 中随机选取了相同数量的负样本。我们的模型优于所有基线方法, 在平衡数据集设置下, AUROC 指标高出第二名模型 1.38%, AUPR 指标高出 0.93%。这种在平衡数据集设置下的优越性能, 不仅归功于新增的两个节点丰富了药物和蛋白质的生物学信息, 还归功于我们的三视图对比学习框架, 该框架能够捕获更有效的嵌入以提高预测准确性。

为了进一步扩大不平衡程度, 我们建立了一个正负样本比例为 1:10 的数据集, 将所有已知的药物-靶点相互作用 (DTIs) 作为正样本, 并随机选取十倍数量的未知 DTIs 作为负样本。同样, 我们的模型再次展现出优越性, 在 AUROC 和 AUPR 评分上分别比第二好的方法高出 0.95% 和 1.73%。此外, 我们还使用包括准确率、精确率、召回率、F1 值和 MCC 在内的其他指标, 在正负样本比例为 1:1 和 1:10 的情

况下评估了我们模型的性能。结果见表 S1 和 S2, 表明我们的模型在不同的评估标准下都具有很强的稳健性。

为了进一步加剧这种不平衡, 我们建立了一个数据集, 其中所有已知的药物-靶点相互作用 (DTIs) 作为正样本, 所有未知的 DTIs 作为负样本。我们的模型在 AUPR 方面取得了最佳性能, 比排名第二的方法高出显著的 6.3%。在 AUROC 方面, 我们的模型取得了第二好的结果, 比 EEG-DTI 低 0.83%。然而, 对于高度不平衡的数据, AUROC 可能对假阳性率过于宽容, 从而高估了模型的实际性能。在实际应用中, 我们通常更关心模型能否正确识别少数类, 因此 AUPR 更能反映这一需求。

如图 S1 所示, 随着负样本比例的增加, 主要指标 AUPR 逐渐降低。然而, 我们的方法中 AUPR 的下降幅度相对较小, 分别减少了 0.069 和 0.2296, 如表 S3 所示。因此, AUPR 的显著提升表明了我们的模型在预测能力上的优越性, 尤其是在真实世界中 DTI 标注稀疏的情况下。

为了进一步增强 MVCL-DTI 优势的可靠性, 我们进行了全面的统计分析, 以评估六种对比方法在性能上的差异是否显著。我们使用了正负样本比例为 1:1 和 1:10 时 10 折交叉验证的结果来计算 AUROC 和 AUPR, 并应用了弗里德曼检验、弗里德曼检验、Nemenyi 检验以及包括均值和标准差在内的常见统计指标。弗里德曼检验是一种用于比较多个相关样本的非参数方法。该分析表明, 六种方法之间存在显著的整体差异, AUROC 的平均 p 值为 0.0029248, AUPR 的平均 p 值为 0.0014899。为了确定具体的成对差异, 我们进行了事后 Nemenyi 检验。这些检验证实了我们的模型在性能上显著优于几种基准方法。详细的成对 p 值和校正后的 p 值分别列于表 S4 和 S5 中。此外, 我们还报告了每种方法在 10 折交叉验证中 AUROC 和 AUPR 的均值、标准差 (Std) 以及 95% 置信区间 (CI), 详情见表 S6 和 S7。这些指标综合起来表明了 MVCL-DTI 的卓越稳定性和有效性, 突显了其在处理不同样本比例方面的优势, 并且在统计显著性和实际性能方面均优于其他方法。

3.4.2. 不同比例随机掩码已知药物-靶点相互作用的效果。为了进一步分析我们的模型预测未知药物-靶点相互作用的能力, 我们随机对不同比例的已知药物-靶点相互作用进行了掩码处理。我们将掩码后的药物-靶点相互作用作为测试集中的正样本, 未掩码的药物-靶点相互作用作为训练集中的正样本。




图 2. 对 MVCL-DTI 模型和基准模型在具有不同已知药物-靶点相互作用 (DTI) 掩码比例的测试集上进行比较分析。掩码的 DTI 用作测试集中的正样本, 而未掩码的 DTI 则作为训练集中的正样本。测试集和训练集中的负样本均从未知的 DTI 中随机选取, 保持正负样本比例为 1:10。




图 3. MVCL-DTI 模型与基准模型在非冗余药物-靶点相互作用 (DTI) 上的对比分析: (a) 屏蔽涉及相似药物或蛋白质的 DTI, (b) 屏蔽具有相似药物相互作用的药物的 DTI, (c) 屏蔽与具有相似副作用的药物相关的 DTI。在这三个实验中, 正负样本的比例始终保持在 1:10。

训练集。测试集和训练集中的负样本均从未知的药物-靶点相互作用 (DTI) 中随机选取, 正负样本比例为 1:10。掩码比例分别为 10%、30%、50%、70% 和 90%。如图 2 所示, 在所有掩码比例下, 我们的模型均优于第二好的方法。在 90% 的掩码比例下, 我们模型的 AUROC 和 AUPR 分别比第二好的方法高出 1.67% 和

分别为 1.71%。对于其他 10%、30%、50% 和 70% 的掩码比例, 我们的模型显著优于第二好的方法, AUROC 分别提高了 1.28%、2.18%、

分别提高了 2.47%、1.97%, 以及 AUPR 分别提高了 2.7%、4.15%、2.92% 和 3.62%。此外, 很明显, 预测准确率随着掩码比例的增加而逐渐降低。这表明随着训练集中先验知识的减少, 模型的泛化能力下降。然而, 我们的方法始终保持着最佳性能。这些结果表明, 我们的模型在预测未知药物-靶点相互作用方面具有很强的泛化能力。

3.5. MVCL-DTI 泛化能力分析
3.5.1. 未知药物靶点相互作用 (DTI) 上的模型性能。 初始数据集可能包含冗余的药物靶点相互作用, 例如同源蛋白质或相似药物, 这引发了对模型强大的预测性能可能源于易于预测的相互作用的担忧。为了增强对 MVCL-DTI 整体稳健性的验证, 我们执行了两项额外的实验, 专门设计为难预测目标测试。这些包括对非冗余 DTI 和独特 DTI 的验证。

通过屏蔽这些冗余的药物-靶点相互作用 (DTIs), 我们能够获得更贴近实际的结果。我们使用与罗 (Luo) 相同的数据集处理方法进行了以下额外实验: (a) 屏蔽具有相似药物 (即药物化学结构相似度 > 0.6) 或相似蛋白质 (即蛋白质序列相似度 > 40%) 的 DTIs; (b) 屏蔽具有相似药物相互作用 (即杰卡德相似度 > 0.6) 的药物的 DTIs; (c) 移除具有相似副作用的药物的 DTIs (即




图 4. 在非唯一药物 - 靶点相互作用 (DTI) 上训练的 MVCL-DTI 模型与基线模型在唯一 DTI 上的测试比较分析。唯一 DTI 的特征在于药物或靶点仅与一个对应的靶点或药物存在相互作用。对于训练集和测试集, 正负样本的比例均保持在 1:10。





图 5. MVCL-DTI 和 SHGCL 在三种负样本选择策略下的对比分析。基于药物相似性、基于蛋白质相似性以及基于组合相似性的采样场景下 MVCL-DTI 和 SHGCL 的 AUROC (左) 和 AUPR (右) 分布。对于训练集和测试集, 正负样本的比例均保持在 1:10。

杰卡德相似度大于 0.6)。这三次实验中正负样本的比例为 1:10。从图 3 的实验结果来看, 在这些实验中我们的模型仍然优于所有基线方法, 在三个数据集上, 我们的方法的准确率平均比第二好的方法提高了 1.94% 和 3.22%, 这证实了我们模型的稳定性和泛化能力。

3.5.2. 针对独特药物-靶点相互作用(DTI)的模型性能。为了进一步增加预测难度, 我们考虑了药物(靶点)仅与一个靶点(药物)相互作用的 DTI, 将其称为独特 DTI。在二分类任务中, 如果数据集包含多个独特 DTI, 传统的交叉验证可能不是评估预测性能的恰当方法, 因为它可能会利用对这些独特药物和靶点的偏向来提高性能。因此, 我们在非独特 DTI 上训练所有方法, 并在独特 DTI

上进行测试, 确保训练集和测试集之间相互隔离。训练集和测试集中正负样本的比例均为 1:10。如图 4 所示, 我们的模型优于所有基线方法, 在 AUROC 上提高了 1.34%, 在 AUPR 上提高了 2.66%, 超过了第二好的方法。这表明我们的模型具有更强的泛化能力和鲁棒性, 能够在对已知 DTI 知之甚少的情况下预测新的 DTI。

3.5.3. 模型在难负样本药物靶点相互作用上的表现。在我们实验的初始设计中, 我们采用了一种简单的随机抽样策略来生成负样本, 以确保与现有方法的一致性和可比性。然而, 这种方法可能会导致低质量负样本的纳入, 从而限制模型学习有效特征表示的能力。为了解决这个问题, 我们进行了额外的实验, 采用了更复杂的负样本生成策略。



(1) 基于药物相似性的采样: 从数据集中选取负样本, 要求负样本中的药物与正样本中的药物的化学结构相似度超过 0.6。这些样本在结构上与正样本相似, 从而得到 864,453 个负样本药物-靶点相互作用 (DTI)。(2) 基于蛋白质相似性的采样: 从数据集中选取负样本, 要求负样本中的蛋白质与正样本中的蛋白质的序列相似度超过 40%。这产生了 347,121 个负样本 DTI, 代表的是序列相似但不与给定药物相互作用的蛋白质对。(3) 基于药物和蛋白质相似性的联合采样: 选取药物化学结构相似度超过 0.6 且蛋白质序列相似度超过 40% 的负样本, 从而得到 280,566 个负样本 DTI。这些样本代表了高置信度的阴性配对, 其中药物和蛋白质在结构或序列上与阳性样本中的对应物相似, 但在生物学上却无关联。

3.6. MVCL-DTI 确定的新药物靶点相互作用。图 6 展示了 MVCL-DTI 预测的概率值最高的前 150 种药物靶点相互作用的网络图可视化。靶点和药物分别用蓝色圆圈和绿色圆圈表示。已知的药物-靶点相互作用用灰色边标记，而新预测的相互作用用橙色边显示。我们根据药物相似性将这 150 种药物靶点相互作用分为四个簇。很明显，一些簇表现出复杂的相互作用，表明它们之间存在直接或间接的关系。这进一步证实了相似药物可能具有相似相互作用模式的观点。此外，以 DR 开头的蛋白质聚集在一起，这些是与多巴胺（DR）受体相关的基因或蛋白质。这表明具有相似治疗功能的药物可能是相互关联的，反映了我们方法在揭示这些间接关系方面的泛化能力。

表 3. 在新预测的 22 种药物 - 靶点相互作用 (DTIs) 中, 有 19 种得到了文献支持。

<https://doi.org/10.1021/acs.jcim.4c02073> *J. Chem. Inf. Model.* 2025, 65, 1009–1026




图 7.对 3 种新预测的药物靶点相互作用 (DTIs) 进行计算对接验证: (a) 环苯扎林 - CHRM5, (b) 环苯扎林 - CHRM1 和 (c) 环苯扎林 - CHRM2。所有对接结果均获得低对接分数, 表明具有很强的结合亲和力。




图 8. 4 种药物与靶点相互作用的网络图。(a) 由现有数据集 D1923 得出的网络图和 (b) 由 MVCL-DTI 预测的网络图。

我们模型所预测的相互作用与已确立的科学知识相符, 从而增强了该模型的可靠性。

对于 3 种新预测但缺乏文献支持的药物靶点相互作用 (DTIs) —— 环苯扎林 - CHRM5、环苯扎林 - CHRM1 和环苯扎林 - CHRM2, 我们使用在线分子对接预测网站 [SwissDock43](#) 进行了分子对接预测, 并选择了 [AutoDock Vina](#) 进行对接预测。AutoDock Vina 是一个开源且免费的工具, 它通过使用更简单的评分函数提高了结合模式预测的准确性并加快了搜索速度。我们预测了每对 DTI 的结合模式和对接分数。结合模式如图 7 所示, 对接分数分别为 -4.933、-5.826 和 -5.454。AutoDock Vina 的对接分数代表计算出的亲和力 (千卡/摩尔), 数值越低表示结合亲和力越强。通常的经验法则是: 计算出的亲和力 > -4 千卡/摩尔表示结合力非常弱或无结合; -7 千卡/摩尔 < 计算出的亲和力 ≤ -4 千卡/摩尔表示中等结合; 计算出的亲和力 ≤ -7 千卡/摩尔表示强结合。因此, 我们预测的这 3 个没有文献支持的 DTIs 根据对接分数都属于中等结合类别。总体而言, 我们模型新预测的药物靶点相互作用 (DTIs) 的对接结果可能为理解这些预测的结构基础提供重要线索, 从而有助于阐明药物作用的潜在分子机制。

3.7. 对用于治疗新冠肺炎的药物靶点进行 MVCL-DTI 预测验证。 为了进一步验证我们模型在识别潜在药物 - 靶点相互作用 (DTI) 方面的有效性, 我们对以下四种药物进行了案例研究: 地塞米松、甲泼尼龙、利托那韦和达芦那韦。这些药物在新冠肺炎的治疗中得到了广泛应用。由 SARS-CoV-2 病毒引发的新冠肺炎疫情, 迫切需要有效的治疗手段。确定有效的药物及其与病毒和宿主蛋白质的相互作用对于开发治疗方法至关重要。地塞米松和甲泼尼龙是用于减轻炎症和免疫反应的皮质类固醇, 而利托那韦和达芦那韦是常用的蛋白酶抑制剂, 在抗病毒治疗中发挥着作用, 包括用于治疗艾滋病病毒 (HIV), 也可能用于治疗 SARS-CoV-2。我们从 DrugBank 和 PubChem 数据库中检索了与这些药物相互作用的目标蛋白。⁴⁴ 然后, 我们过滤掉了存在于我们数据集中的目标, 总共涉及 32 种药物 - 目标相互作用 (DTIs)。这些目标蛋白与四种与 COVID-19 相关的药物相互作用, 其中一些相互作用已存在于从 D1923 衍生的异质图中, 而另一些则是新发现的。此外, 还有一些相互作用是我们没有预测到的。详细信息见表 S8。训练我们的模型后, 我们发现它能够预测 6 种潜在的药物 - 目标相互作用, 变化情况如图 8 所示。图中的黄色线条代表新预测的药物 - 目标相互作用。对于地塞米松, 14 种药物 - 目标相互作用中, 我们的模型预测了 6 种, 而 SHGCL 模型预测了 4 种。对于甲泼尼龙, 我们的方法多预测了 1 种相互作用。




图 9. 对比学习前后蛋白质特征演化的可视化分析。蓝色代表蛋白质 1, 包括 CHRM1、CHRM2、CHRM3、CHRM4 和 CHRM5; 青色代表蛋白质 2, 包括 OPRD1、OPRK1、OPRM1 和 OPRL1。空心圆和实心圆分别表示对比学习前后的邻域视图; 空心三角形和实心三角形分别表示对比学习前后的元路径视图; 空心方块和实心方块分别对应对比学习前后的扩散视图。黑色虚线和紫色实线分别连接对比学习前后同一蛋白质在三个视图中的位置。

这表明我们的模型能够有效地预测与新冠病毒相关的潜在药物-靶点相互作用, 并突显了我们模型的实际应用价值。

此外, 我们还观察到, 对于未预测到药物靶点相互作用 (DTIs) 的两种药物节点 (利托那韦和达芦那韦), 其在原始异构图中的度数相对较小。例如, 预测到 DTIs 的两种药物节点 (地塞米松和甲泼尼龙) 的平均度数为 1280, 而未预测到 DTIs 的这两种药物的平均度数为 598, 这表明关于它们的先验知识较少, 从而影响了 MVCL-DTI 的学习性能。如果能添加更多相关的关系信息, 预计能够识别出更多的 DTIs。成功识别出更多的潜在 DTIs 可以加快这些药物在新冠肺炎治疗中的再利用, 从而可能更快地实现治疗干预。

3.8. 基于 MVCL-DTI 的语义特征可视化
3.8.1. 对比学习对蛋白质和药物特征表示的影响。为了展示对比学习模块的影响, 我们选取了两类蛋白质: 蛋白质 1 包括 CHRM1、CHRM2、CHRM3、CHRM4、CHRM5, 蛋白质 2 包括 OPRD1、OPRK1、OPRM1、OPRL1。我们使用 $t\text{-SNE}^{45}$ 来可视化对比学习前后这些节点的表示, 分别用空

心点和实心点表示。不同的形状代表不同的视图 (空心 and 实心圆分别代表对比学习前后的邻域视图; 空心 and 实心三角形分别代表对比学习前后的元路径视图; 空心 and 实心正方形分别代表对比学习前后的扩散视图), 不同的颜色表示不同的类别 (蓝色代表蛋白质 1; 青色代表蛋白质 2)。三种视图中相同的蛋白质由线条连接, 黑色虚线连接空心点, 紫色实线连接实心点。如图 9 所示, 在对比学习之前, 同一视角下的蛋白质表示彼此接近, 例如空心三角形、空心圆圈和空心正方形聚集在一起。经过对比学习后, 三个视角的蛋白质表示之间的接近程度表明了三个视角信息的有效整合, 这从实心点的聚集可以看出。此外, 紫色实线明显短于黑色虚线, 这表明不同视角下相同蛋白质的表示更接近, 这与对比学习的目标一致。

两类药物 (药物 1 包括甲泼尼龙、氟羟甲睾酮、螺内酯; 药物 2 包括三唑仑、咪达唑仑、阿普唑仑) 在对比学习前后的特征图见图 S2, 从中可以看出药物的特征不如蛋白质的特征明显。这是因为蛋白质和药物的特征表示均基于异质图结构中的信息。在异质图中, 每个蛋白质节点的平均度为 1090, 而每个药物节点的平均度为 432。

这表明蛋白质节点包含更多信息。鉴于与蛋白质相关的异质网络更为复杂，该模型能够更好地学习具有代表性的特征表示。因此，如果纳入更多与药物相关的相互作用信息，模型的预测准确性可能会进一步提高。

3.8.2. 特征融合中的注意力权重。为了进一步了解模型如何整合来自不同节点类型和视图的信息，我们可视化了在扩散视图中特征融合过程中学习到的注意力权重。这些权重揭示了各种关系和视图对最终特征表示的贡献。如图 S3 所示，药物 - 蛋白质矩阵和蛋白质 - 疾病矩阵分别对药物节点和蛋白质节点的预测性能贡献最大。这可归因于生物学原因：药物 - 蛋白质相互作用构成了药物 - 目标相互作用（DTI）任务的核心，因为它们代表了药物与其靶蛋白之间的直接生化关系；蛋白质 - 疾病关联对于捕捉蛋白质在生物网络中的功能相关性至关重要。蛋白质通常作为特定疾病的生物标志物或治疗靶点，它们与疾病节点的连接提供了关于其在病理过程中的作用的背景信息。

此外，我们还可可视化了多视图注意力加权融合过程中三个视图（邻接视图、元路径视图和扩散视图）的注意力权重，如图 S4 所示。观察发现，邻接视图的贡献最大。从模型角度来看，这一结果可以这样解释：邻接视图直接捕捉了图中的第一阶邻近性，代表了节点之间的直接连接。在异质图中，这些局部连接通常编码了最可靠和最易解释的信息，例如药物与蛋白质之间或蛋白质与疾病之间的直接相互作用。模型自然会优先考虑这些关系，因为与高阶或推断出的关系相比，它们受噪声影响较小。元路径视图和扩散视图虽然对于捕捉高阶和全局模式很有价值，但可能会稀释对药物-靶点相互作用任务至关重要的直接信号，这解释了它们相对较低的权重。

3.9. 关于 MVCL-DTI 计算特性的讨论。在本节中，我们将介绍对我们的模型的计算特性的研究。我们希望证明在前几节中所展示的结果并非偶然，而是由 MVCL-DTI 计算组件的有意设计和训练所促成的。

3.9.1. 确定药物-靶点相互作用（DTI）的关键特征。人们很容易认同，蛋白质和药物的表征特征对于 DTI 任务来说是必不可少的。我们发现 ESM2 和 MACCS 是 MVCL-DTI 的最佳表征。我们还发现，纳入 GO 和取代基节点特征能够极大地提升 MVCL-DTI 的性能。此外，我们还展示了由我们的 MVCL-DIT 模型训练的特征的恰当初始化策略。

起初，我们探究了多种用于初始化蛋白质和药物节点特征的方法，如表 4 所示。对于蛋白质，我们尝试使用诸如 ProtBERT46 和 ESM234 等蛋白质语言模型来提取蛋白质序列特征。结果表明，使用 ESM2 蛋白质语言模型提取的特征在药物 - 蛋白质相互作用（DTI）任务中的表现优于基线方法。对于药物，我们尝试将 SMILES 字符串表示为药效团指纹47、ECFP48、Mordred 描述符49 以及提取的特征。

表 4. 在 D1923 数据集上利用蛋白质和药物节点的不同特征对 MVCL-DTI 性能进行比较分析，正负样本比例为 1:10

特征类型		AUROC	AUPR
蛋白质	蛋白质 - 420 描述符	0.9558	0.8814
	蛋白质-ProtBERT	0.9624	0.8897
	蛋白质 - ESM2	0.9625	0.8900
药物	药物-MACCS	0.9558	0.8814
	药物-制药	0.9514	0.8751
	药物 - ECFP	0.9534	0.8716
	“毒药-莫德雷德”	0.9548	0.8739
	药物-LLM	0.9516	0.8793

表中加粗的数值表示最高性能。

我们从药物概要中使用大型语言模型提取信息。结果表明，基准方法仍然是最佳的。因此，我们使用 ESM2 提取蛋白质特征，并将药物的 SMILES 序列表示为 MACCS 指纹来表示药物特征。

然后，通过屏蔽与药物或蛋白质信息相关的不同子网络进行了子网络消融实验，以评估它们对整体预测性能的贡献。如图 10 所示，当屏蔽所有异质网络，仅保留药物 - 蛋白质相互作用网络时，模型性能最差。接下来，屏蔽新提出的 GO 和取代基网络导致性能下降幅度次之，AUROC 和 AUPR 分别下降了 0.52% 和 0.55%。这表明与疾病、副作用、药物 - 药物相互作用和蛋白质 - 蛋白质相互作用等传统子网络相比，新提出的 GO 和取代基节点及其相应的新边为药物 - 蛋白质相互作用任务提供了更有效的信息，从而证实了我们新提出的节点的优势。

此外，在特征工程的基础上，多视图协同学习药物靶点相互作用（MVCL-DTI）节点特征的初始化策略值得探究。因此，在我们的模型中，我们尝试了不同的节点特征初始化策略，以评估它们在药物靶点相互作用预测中的效果：

- 随机策略：四种类型节点的特征被随机初始化，维度为 128。
- 罗氏策略：¹¹ DTINet 应用了扩散成分分析（DCA）来学习药物和靶点特征的低维向量表示，这些表示能够捕捉异质网络的内在拓扑属性。我们直接使用了罗氏公开提供的节点初始化特征。对于其余两个节点特征，我们采用了随机初始化策略来获取。
- 姚氏策略（基准）：¹⁶ 采用 166 位的 MACCS 分子指纹作为药物的初始特征，并从蛋白质序列中提取氨基酸和二肽的相对比例构建了 420 个描述符。然后利用主成分分析（PCA）将这些特征降维至 128 维。
- 我们的策略：与基准类似，我们使用维度为 128 的 MACCS 指纹作为药物的初始特征。对于蛋白质，我们使用 ESM2 语言模型提取 1280 维的序列特征，然后通过主成分分析（PCA）将其降维至 128 维。此外，我们将 GO 和取代基视为新的特征，并使用 node2vec 对其特征进行初始化。




图 10. 在 D1923 数据集上, 正负样本比例为 1:10 时, 对不同的子网络进行掩码处理的 AUROC 和 AUPR。通过掩码处理与药物或蛋白质信息相关的各种子网络, 以评估它们对模型预测性能的贡献。进行了消融研究。

维度为 128, 与疾病和副作用节点的初始化策略类似。

如表 5 所示, 结果表明我们的初始化策略在该任务中取得了最佳性能。

表 5. 不同初始化策略下 MVCL-DTI 在 D1923 (比例 1:10) 上的结果

不同的策略	AUROC	AUPR
随机策略	0.9479	0.8428
罗的策略	0.9522	0.8610
姚的策略	0.9558	0.8814
我们的策略	0.9677	0.9024

表中加粗的数值表示最高性能。

DTI 任务。与次优的基线方法相比, 我们的模型将 AUROC 和 AUPR 分别提高了 1.19% 和 2.1%。主要原因在于新增的 GO 节点和取代基节点为蛋白质和药物提供了更多的功能信息, 使得我们的策略比基线方法信息更丰富。

3.9.2. MVCL-DTI 模型参数调优。除了蛋白质和药物特征外, MVCL-DTI 还从基因本体论 (GO)、取代基、副作用和疾病中学习特征。显而易见, 这些特征与蛋白质和药物的特征一起, 能够定性帮助确定药物-靶点相互作用 (DTI)。然而, 如何定量地融合这些特征是一项艰巨的任务。MVCL-DTI 的深度学习架构恰好有助于定量解决这一融合任务。

在训练阶段, 可以通过模型超参数对 MVCL-DTI 所有可能涉及的特征进行定量融合。MVCL-DTI 的最终模型超参数可在表 S9 中找到。在确定模型结构时, 我们对模型的超参数进行了敏感性分析以找到最优结构。首先, 我们专注于确定每个视图编码器的最佳层数。

如图 11 和 S5 所示, 我们发现当层数增加到一定程度时, 会出现梯度消失的问题, 这反过来又导致模型性能下降。这种现象的发生是因为更深的网络在训练过程中会使梯度难以通过各层进行反向传播, 从而导致权重更新不足和学习效果不佳。相反, 层数适中的网络能够从数据中聚合更多有用的信息特征, 从而提高性能。经过仔细的实验, 我们确定两层网络达到了最佳平衡, 既能够捕捉到复杂的关系, 又不会出现梯度问题。

此外, 我们还对网络隐藏层的维度进行了不同的实验。隐藏层的维度在决定模型学习和表示数据中复杂模式的能力方面起着重要作用。较大的维度能让模型捕获更详细和细微的信息, 但它们也需要更多的计算资源, 如果管理不当还可能导致过拟合。由于资源限制以及需要在模型复杂度和性能之间保持平衡, 我们将隐藏层的维度设置为 2048。这一选择为模型提供了足够的容量, 使其能够有效地从数据中学习, 同时将计算需求控制在可行的范围内。

4. 结论

在本研究中, 我们引入了 MVCL-DTI, 这是一种创新的基于图的学习模型, 旨在预测药物-靶点相互作用 (DTIs)。MVCL-DTI 首先通过添加两个关键节点——基因本体论 (GO) 术语和取代基, 以及代表“蛋白质-基因本体论关联”和“药物-取代基关联”的新边, 来扩展异质图。这种扩展丰富了异质数据, 使我们的模型能够更全面地表示生物网络。随后, 该模型




图 11. 不同层数和不同维度的 MVCL-DTI 的 PR 曲线。对模型的超参数进行了敏感性分析，以确定最优结构，重点在于 (a) 确定每个视图编码器的理想层数，以及 (b) 在网络中试验不同的隐藏层维度。

在增强型异构图中构建了三种不同的视图：邻居视图、元路径视图和扩散视图。通过利用对比学习，它有效地整合了来自这些不同视角的网络信息，以捕获具有丰富语义内容的多维节点表示。最后，该模型重建原始异构网络以生成准确的药物-靶点相互作用预测。

为了全面分析我们模型的性能，我们进行了大量的实验。首先，利用一个经典的公共数据集，我们采用了多种实验配置，包括不同的正负样本比例、以不同比例屏蔽已知的药物-靶点相互作用 (DTIs)、以各种相似性度量屏蔽冗余的 DTIs 以及评估独特的 DTIs。正负样本比例的实验突显了模型处理不平衡数据的有效性。屏蔽已知 DTIs 的实验证实了其稳定性和泛化能力，即使排除了冗余信息也是如此。评估独特的 DTIs 展示了其在没有大量先验知识的情况下预测新相互作用的能力。尽管难度增加，MVCL-DTI 在 AUROC 和 AUPR 指标上均表现出色，显示出高精度和稳健性。此外，MVCL-DTI 所识别的新型 DTIs 得到了文献的支持，这表明 MVCL-DTI 在发现新的治疗靶点和推进药物研发方面具有巨大潜力。此外，有关新冠相关药物的案例研究突显了 MVCL-DTI 在实际应用中的竞争优势，强调了 MVCL-DTI 的实际效用。

为了揭示 MVCL-DTI 优越性能背后的原因，我们对其特征可视化 and 计算特性进行了全面的考察。通过直观分析对比学习前后蛋白质特征的演变，可以明显看出我们的模型能够捕捉到语义丰富的高维特征。对 MVCL-DTI 计算特性的探索为我们带来了几个关键的见解：1) ESM2 和 MACCS 是 MVCL-DTI 最有效的表示形式；2) 整合 GO 和取代基节点特征表示极大地增强了模型的效能；3) 为

MVCL-DTI 模型训练的特征采用恰当的初始化策略对于提升其预测能力至关重要。最终，我们阐明了在训练阶段对模型的超参数进行微调，以解决 MVCL-DTI 中所有可能涉及特征的定量融合问题。因此，我们可以得出结论，MVCL-DTI 如前文所述的稳健性能并非偶然，而是精心设计和细致训练模型计算组件的结果。

MVCL-DTI 的成功可归因于几个关键因素：首先，引入 GO 术语和取代基丰富了蛋白质和药物的功能信息，显著增强了异质网络中的特征表示。GO 术语提供了有关蛋白质的详细注释，例如其生物过程、分子功能和细胞成分，通过引入功能背景丰富了蛋白质的表示。同样，取代基节点提供了有关药物化学基团和结构修饰的重要信息，这些对于确定其物理化学性质和结合亲和力至关重要。其次，使用三种不同的视图捕获了多维节点表示，从而能够全面理解异质图。第三，对比学习模块和多视图注意力加权融合机制有效地整合了多视图表示。对比学习模块对齐并增强了多视图表示的一致性，减少了冗余并提高了特征表示的鲁棒性。与此同时，注意力加权融合模块会自适应地为每个视角分配权重，使模型能够动态地优先考虑最具信息量的视角。这种对比学习与注意力加权融合之间的协同作用确保了模型能够从异质数据中学习到的稳健且有意义的特征。总体而言，尽管 MVCL-DTI 模型主要是为药物-靶点相互作用预测而设计的，但其方法论在未来也有望在类似场景中得到更广泛的应用，例如药物-药物相互作用和药物-疾病关系。

在药物靶点相互作用 (DTI) 预测等其他相关领域中, 异质图的一个关键优势在于其固有的可扩展性, 这使得它能够与生物和生物医学数据无缝集成, 从而促进跨不同领域的多任务预测。此外, 越来越多的证据表明, 微小核糖核酸 (miRNA) 在疾病进展中发挥着关键作用, 并且具有作为药物靶点的潜力, 这为扩展我们的框架提供了令人感兴趣的机遇。⁵⁰ 用于预测小分子与 miRNA 关联 (MMAs) 的计算模型, 如 JMSS-MMAS⁵¹ 和 GAM-MDRS⁵², 已经展示了基于图的方法如何有效地探索小分子与 miRNA 之间的关系。受这些方法的启发, 我们设想可以将我们的模型进行调整, 以在异质图框架内整合与 miRNA 相关的数据, 从而实现 miRNA 与小分子相互作用的预测。

然而, 我们方法的一个局限性在于其转导性质: 所有关于待预测药物和靶点的信息最初都必须存在于异质图中, 这意味着它无法预测新的药物-靶点相互作用。未来, 我们计划通过将异质图作为背景知识加以利用, 例如在知识图谱中, 来支持对新型药物-靶点相互作用的预测。通过将动态且全面的异质图信息整合到知识图谱框架中, 可以推断出原始图中未明确存在的相互作用, 从而将模型的应用范围扩展到新的预测。

■ 相关内容

数据可用性声明

源代码可在 [https://github.com/ljquanlab/MVCL-DTI] 获取。

* 支持信息

支持信息可在 <https://pubs.acs.org/doi/10.1021/acs.jcim.4c02073> 免费获取。

不同正负样本比例下的 AUPR (图 S1); 药物特征、节点特定注意力权重和视图特定注意力权重的可视化 (图 S2 - S4); MVCL-DTI 不同层数和维度下的 ROC 曲线 (图 S5); 正负样本比例为 1:1/1:10 时基准测试的 AUC、AUPR、准确率、召回率、F1 值和 MCC (表 S1 和 S2); MVCL-DTI 的 AUPR 下降情况 (表 S3); AUROC 和 AUPR 得分的成对统计比较 (表 S4 和 S5); 正负样本比例为 1:1/1:10 时 AUROC 和 AUPR 得分的均值、标准差和 95% 置信区间 (表 S6 和 S7); 我们从 DrugBank 和 pubchem 收集的目标 (表 S8); MVCL-DTI 的超参数设置 (表 S9) (PDF)

■ 作者信息

通讯作者

全立军 - 苏州大学计算机科学与技术学院, 江苏 215006, 中国; 江苏省软件新技术与产业化协同创新中心, 江苏 210000, 中国; ORCID: 0000-0003-4551-4198; 电子邮箱: ljquan@suda.edu.cn

作者

张贝 - 计算机科学与技术学院
中国江苏苏州大学, 邮编 215006; 中国移动
苏州软件技术有限公司, 苏州
中国 215163

张志军 - 计算机科学与技术学院
中国江苏苏州大学, 邮编 215006

曹乐欣 - 计算机科学与技术学院
中国江苏苏州大学, 邮编 215006

陈秋凤 - 计算机科学与技术学院
中国江苏苏州大学, 邮编 215006

彭良晨 - 计算机科学与技术学院
中国江苏苏州大学, 邮编 215006

王俊凯 - 计算机科学与技术学院
中国江苏苏州大学, 邮编 215006

耶鲁江 - 计算机科学与技术学院
中国江苏苏州大学, 邮编 215006

聂良鹏 - 计算机科学与技术学院
中国江苏苏州大学, 邮编 215006

耿丽 - 计算机科学与技术学院
中国江苏苏州大学, 邮编 215006

吴廷芳 - 计算机科学与技术学院
中国江苏苏州大学, 邮编 215006; 合作方
新型软件技术创新中心

工业化, 江苏 210000, 中国; orcid.org/0000-0001-8137-2436

吕强 - 计算机科学与技术学院
中国江苏苏州大学, 邮编 215006; 合作单位
新型软件技术创新中心
中国江苏 210000 工业化

完整的联系信息可在以下网址获取: <https://pubs.acs.org/doi/10.1021/acs.jcim.4c02073>

笔记

作者声明不存在任何利益冲突。

■ 致谢

本研究部分得到了国家自然科学基金 (62272335, 62002251) 的支持, 部分得到了江苏省高校青蓝工程的支持, 部分得到了校企合作教育计划的支持, 部分得到了江苏省自然科学基金青年基金 (BK20200856) 的支持, 部分得到了江苏高校优势学科建设工程的支持, 部分得到了新型软件技术与产业化协同创新中心的支持。

■ 参考文献

- (1) Jiang, L.; Sun, J.; Wang, Y.; Ning, Q.; Luo, N.; Yin, M. Identifying drug-target interactions via heterogeneous graph attention networks combined with cross-modal similarities. *Briefings Bioinf.* 2022, 23 (2), bbac016.
- (2) Xuan, P.; Hu, K.; Cui, H.; Zhang, T.; Nakaguchi, T. Learning multi-scale heterogeneous representations and global topology for drug-target interaction prediction. *IEEE J. Biomed Health Inform.* 2022, 26 (4), 1891-1902.
- (3) Donald, B. R. *Algorithms in Structural Molecular Biology*; MIT Press, 2011.
- (4) Morris, G. M.; et al. Autodock4 and autodocktools4: automated docking with selective receptor flexibility. *J. Comput. Chem.* 2009, 30, 2785-2791.
- (5) Keiser, M. J.; et al. Relating protein pharmacology by ligand chemistry. *Nat. Biotechnol.* 2007, 25, 197-206.

- (6) Xia, Z.; Ling-Yun, W.; Zhou, X.; Wong, S. T. C. Semi-supervised drug–protein interaction prediction from heterogeneous biological spaces. *BMC Syst. Biol.* 2010, 4, S6.
- (7) Wei, J.; Zhu, Y.; Zhuo, L.; Liu, Y.; Fu, X.; Li, F. Efficient deep model ensemble framework for drug–target interaction prediction. *J. Phys. Chem. Lett.* 2024, 15, 7681–7693.
- (8) Zhao, T.; Yang, H.; Valsdottir, L. R.; Zang, T.; Peng, J. Identifying drug–target interactions based on graph convolutional network and deep neural network. *Brief. Bioinform.* 2021, 22 (2), 2141–2150.
- (9) Zhou, Z.; Liao, Q.; Wei, J.; Zhuo, L.; Wu, X.; Fu, X.; et al. Revisiting drug–protein interaction prediction: a novel global–local perspective. *Bioinformatics* 2024, 40, btac271.
- (10) Zhao, B. W.; Su, X. R.; Hu, P. W.; Huang, Y. A.; You, Z. H.; Hu, L. iGRLDTI: an improved graph representation learning method for predicting drug–target interactions over heterogeneous biological information network. *Bioinformatics* 2023, 39 (8), btad451.
- (11) Luo, Y.; Zhao, X.; Zhou, J.; Yang, J.; Zhang, Y.; Kuang, W.; Peng, J.; Chen, L.; Zeng, J. A network integration approach for drug–target interaction prediction and computational drug repositioning from heterogeneous information. *Nat. Commun.* 2017, 8 (1), 573.
- (12) Wan, F.; Hong, L.; Xiao, A.; Jiang, T.; Zeng, J.; Wren, J. NeoDTI: neural integration of neighbor information from a heterogeneous network for discovering new drug–target interactions. *Bioinformatics* 2019, 35 (1), 104–111.
- (13) Peng, J.; Wang, Y.; Guan, J.; Jingyi, L.; Han, R.; Hao, J.; Wei, Z.; Shang, X. An end-to-end heterogeneous graph representation learning-based framework for drug–target interaction prediction. *Brief. Bioinform.* 2021, 22 (5), bbaa430.
- (14) Li, Y.; et al. Supervised graph co-contrastive learning for drug–target interaction prediction. *Bioinformatics* 2022, 38 (10), 2847–2854.
- (15) Zhao, B. W.; Wang, L.; Hu, P. W.; Wong, L.; Su, X. R.; Wang, B. Q.; You, Z. H.; Hu, L. Fusing higher and lower-order biological information for drug repositioning via graph representation learning. *IEEE Trans Emerg Top Comput* 2024, 12, 163.
- (16) Yao, K.; Wang, X.; Li, W.; Zhu, H.; Jiang, Y.; Li, Y.; Tian, T.; Yang, Z.; Liu, Q.; Liu, Q. Semi-supervised heterogeneous graph contrastive learning for drug–target interaction prediction. *Comput. Biol. Medicine* 2023, 163, 107199.
- (17) Su, X.; Hu, P.; Yi, H.; You, Z.; Hu, L. Predicting Drug-Target Interactions Over Heterogeneous Information Network. *IEEE J. Biomed. Health Inf.* 2023, 27, 562–572.
- (18) Zhang, M.; Hong, Y.; Shen, L.; Xu, S.; Xu, Y.; Zhang, X.; Liu, J.; Liu, X. A heterogeneous graph neural network with automatic discovery of effective metapaths for drug–target interaction prediction. *Future Generation Computer Systems* Elsevier 2024.
- (19) Zhang, R.; Wang, Z.; Wang, X.; Meng, Z.; Cui, W. MHTAN-DTI: Metapath-based hierarchical transformer and attention network for drug–target interaction prediction. *Briefings Bioinf.* 2023, 24 (2), bbad079.
- (20) Zheng, Y.; et al. Predicting Drug Targets from Heterogeneous Spaces using Anchor Graph Hashing and Ensemble Learning. In *2018 International Joint Conference On Neural Networks (IJCNN)*; IEEE, 2018. DOI: .
- (21) Wang, J.; Xiao, Y.; Shang, X.; Peng, J.; et al. Predicting drug–target binding affinity with cross-scale graph contrastive learning. *Brief. Bioinform* 2023, 25, bbad516.
- (22) Zheng, Y.; Peng, H.; Zhang, X.; et al. Predicting drug targets from heterogeneous spaces using anchor graph hashing and ensemble learning. In *2018 International Joint Conference on Neural Networks (IJCNN)*; IEEE: Piscataway, NJ, USA, 2018; pp. 1–7.
- (23) Knox, C.; Law, V.; Jewison, T.; Liu, P.; Ly, S.; Frolkis, A.; Pon, A.; Banco, K.; Mak, C.; Neveu, V.; Djoumbou, Y.; et al. DrugBank 3.0: a comprehensive resource for ‘omics’ research on drugs. *Nucleic Acids Res* 2011, 39 (suppl_1), D1035.
- (24) Keshava Prasad, T. S.; Goel, R.; Kandasamy, K.; Keerthikumar, S.; Kumar, S.; Mathivanan, S.; Telikicherla, D.; Raju, R.; Shafreen, B.; Venugopal, A.; et al. Human protein reference database 2009 update. *Nucleic Acids Res* 2009, 37 (suppl_1), D767–D772.
- (25) Peter Davis, A.; Grondin Murphy, C.; Johnson, R.; Lay, J. M.; Lennon-Hopkins, K.; Saraceni-Richards, C.; Sciaky, D.; King, B. L.; Rosenstein, M. C.; Wiegiers, T. C.; et al. The comparative toxicogenomics database: update 2013. *Nucleic Acids Res* 2013, 41 (D1), D1104–D1114.
- (26) Kuhn, M.; Campillos, M.; Letunic, I.; Juhl Jensen, L.; Bork, P. A side effect resource to capture phenotypic effects of drugs. *Mol. Syst. Biol.* 2010, 6 (1), 343.
- (27) Hattori, M.; Okuno, Y.; Goto, S.; Kanehisa, M. Development of a chemical structure comparison method for integrated analysis of chemical and genomic information in the metabolic pathways. *J. Am. Chem. Soc.* 2003, 125 (39), 11853–11865.
- (28) Smith, T. F.; Waterman, M. S. Identification of common molecular subsequences. *J. Mol. Biol* 1981, 147 (1), 195–197.
- (29) Veselinovic, A. M.; Veselinovic, J.; Zivkovic, J. V.; Nikolic, G. M. Application of SMILES notation based optimal descriptors in drug discovery and design. *Curr. Top. Med. Chem* 2015, 15 (18), 1768–1779.
- (30) Oztu rk, H.; Ozkirimli, E.; Oztu rk, A. A comparative study of SMILES-based compound similarity functions for drug–target inter-action prediction. *BMC Bioinf* 2016, 17 (1), 128.
- (31) Ding, Y.; Tang, J.; Guo, F. Identification of drug–target interactions via multiple information integration. *Inform. Sci.* 2017, 418, 546–560.
- (32) Yamanishi, Y.; Pauwels, E.; Saigo, H.; Stoven, V. Extracting sets of chemical substructures and protein domains governing drug–target interactions. *J. Chem. Inf. Model.* 2011, 51 (5), 1183–1194.
- (33) Durant, J. L.; Leland, B. A.; Henry, D. R.; Nourse, J. G. Reoptimization of MDL keys for use in drug discovery. *J. Chem. Inf. Comput. Sci.* 2002, 42 (6), 1273–1280.
- (34) Lin, Z.; Akin, H.; Rao, R.; Hie, B.; Zhu, Z.; Lu, W.; Smetanin, N.; Verkuil, R.; Kabeli, O.; Shmueli, Y.; dos Santos Costa, A.; et al. Evolutionary-scale prediction of atomic-level protein structure with a language model. *Science* 2023, 379 (6637), 1123–1130.
- (35) Grover, A.; Leskovec, J. node2vec: Scalable feature learning for networks. *Proceedings of The 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* ACM 2016, 855–864.
- (36) Schlichtkrull, M.; Kipf, T. N.; Bloem, P.; van den Berg, R.; Titov, I.; Welling, M. Modeling relational data with graph convolutional networks. In *European Semantic Web Conference*; Springer, 2018; pp. 593–607.
- (37) Brockschmidt, M. GNN-FiLM: Graph Neural Networks with Feature-wise Linear Modulation. *arXiv* 2020.
- (38) Tong, H.; Faloutsos, C.; Pan, J. Y. Random walk with restart: fast solutions and applications. *Knowl. Inform. Syst.* 2008, 14, 327–346.
- (39) Vaswani, A.; Shazeer, N.; Parmar, N.; et al. Attention is all you need. *Advances in Neural Information Processing Systems* 30 (NIPS 2017) NIPS 2017 30.
- (40) He, K.; Fan, H.; Wu, Y.; Xie, S.; Girshick, R. Momentum Contrast for Unsupervised Visual Representation Learning. *Proceedings of The IEEE Computer Society Conference on Computer Vision and Pattern Recognition* IEEE 2020, 9726–9735.
- (41) Zhao, B.-W.; Su, X.-R.; Yang, Y.; Li, D. X.; Li, G. D.; Hu, P. W.; You, Z. H.; Lu, X.; Hu, L. Regulation-aware graph learning for drug repositioning over heterogeneous biological network. *Inf. Sci.* 2025, 686, 121360.
- (42) Yang, B.; Yih, W.-T.; Xiaodong, H.; Gao, J.; Deng, L. Embedding entities and relations for learning and inference in knowledge bases. *arXiv* 2014.
- (43) Grosdidier, A.; Zoete, V.; Michielin, O. SwissDock, a protein–small molecule docking web service based on EADock DSS. *Nucleic Acids Res* 2011, 39, W270–7.
- (44) Chen, B.; Wild, D.; Guha, R. PubChem as a source of polypharmacology. *J. Chem. Inf. Model.* 2009, 49 (9), 2044–2055.
- (45) Van Der Maaten, L.; Hinton, G. E. Visualizing data using t-SNE. *J. Mach. Learn. Res.* 2008, 9, 2579–2605.
- (46) Brandes, N.; Ofer, D.; Peleg, Y.; Rappoport, N.; Linial, M. ProteinBERT: a universal deep-learning model of protein sequence and function. *Bioinformatics* 2022, 38, 2102–2110.

- (47) Wolber, G.; Langer, T. LigandScout: 3-D pharmacophores derived from protein-bound ligands and their use as virtual screening filters. *J. Chem. Inf. Model.* 2005, 45 (1), 160–169.
- (48) Rogers, D.; Hahn, M. Extended-connectivity fingerprints. *J. Chem. Inf. Model.* 2010, 50, 742–754.
- (49) Moriwaki, H.; Tian, Y.-S.; Kawashita, N.; Takagi, T. Mordred: a molecular descriptor calculator. *J. Cheminf.* 2018, 10, 4.
- (50) Chen, X.; Guan, N. N.; Sun, Y. Z.; Li, J. Q.; Qu, J. MicroRNA-small molecule association identification: from experimental results to computational models. *Briefings Bioinf.* 2020, 21 (1), 47–61.
- (51) Zhou, Z.; Zhuo, L.; Fu, X.; Lv, J.; Zou, Q.; Qi, R. Joint Masking and Self-Supervised Strategies for Inferring Small Molecule-miRNA Associations. *Molecular Therapy - Nucleic Acids* 2024, 35, 102103.
- (52) Zhou, Z.; Du, Z.; Jiang, X.; Zhuo, L.; Xu, Y.; Fu, X.; Liu, M.; Zou, Q. GAM-MDR: probing miRNA–drug resistance using a graph autoencoder based on random path masking. *Briefings Funct. Genomics* 2024, 23, 475–483.