

基于关系相似性的图对比学习在药物-靶点相互作用预测中的应用

Jilong Bian, Hao Lu, Limin Wei, Yang Li*, Guohua Wang*



中国黑龙江省哈尔滨市东北林业大学计算机与控制工程学院, 邮编 150040

*通讯作者。王国庆, 东北林业大学计算机与控制工程学院, 黑龙江哈尔滨 150040, 中国。电子邮箱: ghwang@nefu.edu.cn; 李阳, 东北林业大学计算机与控制工程学院, 黑龙江哈尔滨 150040, 中国。电子邮箱: yli@nefu.edu.cn

摘要

作为药物再利用过程的一部分, 准确且高效地预测药物与靶蛋白之间的相互作用至关重要。将对比学习引入药物靶点预测中, 将进一步提高药物再利用的准确性。然而, 基于深度学习的大部分药物靶点相互作用 (DTI) 预测方法要么仅关注使用图神经网络 (GNN) 或卷积神经网络 (CNN) 提取的蛋白质和药物的结构特征, 要么仅关注使用异质图神经网络在 DTI 异质图上提取的它们的关系特征。由于蛋白质和药物的结构特征和关系特征从不同角度描述了它们的属性信息, 因此将两者结合可以提高 DTI 预测性能。我们提出了一种基于关系相似性的图对比学习用于 DTI 预测 (RSGCL-DTI), 该方法结合了药物和蛋白质的结构特征与关系特征, 以提高 DTI 预测的准确性。在我们提出的方法中, 通过图对比学习从异质性药物-蛋白质相互作用网络中分别提取了蛋白质间关系特征和药物间关系特征。结果表明, 将通过图对比学习获得的关系特征与通过 D-MPNN 和 CNN 提取的结构特征相结合, 增强了特征表示能力, 从而提高了药物-蛋白质相互作用预测性能。我们提出的 RSGCL-DTI 在四个基准数据集上优于八个最先进的基线模型, 在不平衡数据集上表现良好, 并且在未见过的药物-蛋白质对上也表现出出色的泛化能力。

关键词: DTI 预测; 图对比学习; 关系相似性网络; 结构特征

介绍

与新药研发相比, 药物再利用通常具有更低的研究成本和更短的研究周期[1]。因此, 将现有药物用于治疗其他疾病 (即药物再利用) 正变得越来越有吸引力[2]。预测药物与新靶蛋白之间的相互作用 (药物-靶点相互作用, DTI) 对于发现现有药物的新治疗应用至关重要。准确预测 DTI 有助于更好地理解药物的多样性和潜在用途, 加快药物研发和创新, 并为疾病治疗提供更多选择和可能性[3-5]。DTI 预测旨在确定蛋白质与药物之间的相互作用, 这有助于我们更好地理解药物在体内的作用机制, 并加速药物的研发[6]。计算化学和生物信息学的迅速发展使得利用大量实验数据训练机器学习模型成为可能。过去十年中, 提出了许多用于高效预测 DTI 的机器学习方法, 并取得了重大突破[7-9]。然而, 随着实验数据的急剧增加以及数据分布的日益复杂, 传统机器学习方法所采用的手动设计特征已无法满足复杂的数据分布, 从而限制了其药物靶点相互作用 (DTI) 预测能力。基于深度学习的方

法无需手动特征工程和选择, 而是从原始数据中自动学习特征表示。它们能够充分利用大规模数据的优势, 挖掘数据中的潜在模式和特征, 从而提高模型性能和泛化能力。因此, 学术界提出了许多基于深度学习的 DTI 预测方法[10-13], 这些方法通常利用卷积神经网络 (CNN)、图神经网络 (GNN) 和循环神经网络 (RNN) 等网络模型, 从大量已知的药物靶点相互作用数据中学习特征表示, 以预测 DTI。同时, 这些特征表示可用于推断药物的其他可能治疗用途, 从而有助于药物再利用。

一般来说, 基于深度学习的药物-靶点相互作用 (DTI) 预测方法大致可分为结构表示学习方法和图神经网络方法。结构表示学习方法通常利用卷积神经网络 (CNN)、循环神经网络 (RNN) 和图神经网络 (GNN) 从药物表示 (如 SMILES 或分子图) 中提取药物特征, 以及从蛋白质表示 (如氨基酸序列) 中提取蛋白质特征。然后, 通过特征融合技术 (如拼接或注意力机制) 提取它们的相互作用特征, 以预测药物-靶点相互作用。DeepConv-DTI [14] 分别使用多尺度一维卷积和全连接层提取蛋白质和药物的结构特征。随后, 这些特征被

收稿日期: 2024 年 10 月 21 日。修改日期: 2025 年 2 月 11 日。接受日期: 2025 年 3 月 5 日。

©作者 2025 年。由牛津大学出版社出版。

This is an Open Access article distributed under the terms of the Creative Commons Attribution License (<https://creativecommons.org/licenses/by/4.0/>), which permits unrestricted reuse, distribution, and reproduction in any medium, provided the original work is properly cited.

通过全连接层融合以预测药物-靶点相互作用 (DTI)。DTI-RCNN [15] 考虑了基因与药物之间的关系, 并结合卷积神经网络 (CNN) 和长短期记忆网络 (LSTM) 来预测 DTI。由于 CNN 无法捕捉长距离依赖关系, Shin 等人 [16] 提出了多层双向 Transformer 编码器, 该编码器基于早期的 Transformer [17] 构建, 用于建模药物中长距离原子之间的依赖关系。Wang 等人 [18] 利用蛋白质序列比对生成蛋白质的位置特异性得分矩阵 (PSSM)。然后使用堆叠式自动编码器重建 PSSM 矩阵, 从而获得蛋白质的低维特征。这些特征与药物分子指纹相结合用于 DTI 预测。鉴于药物与蛋白质的结合实际上涉及药物与其蛋白质结合位点的相互作用, Yazdani-Jahromi 等人 [19] 提出了 AttentionSiteDTI, 其中提取蛋白质结合位点的信息并将其建模为图, 药物也建模为图。然后应用拓扑自适应图卷积网络 [20] 提取药物和蛋白质的特征。另一类方法是遵循“关联有罪”假设的图神经网络方法 [11, 21]。它们利用疾病、蛋白质、药物、药物副作用等构建异质网络, 将其作为异质图神经网络的输入, 以提取节点嵌入和边嵌入, 从而预测药物-靶点相互作用。罗等人 [21] 提出的 DTINet 模型将蛋白质、药物和药物副作用整合到一个异质图中。然后, 通过紧凑的特征学习算法获得蛋白质和药物的低维特征表示, 以预测药物-靶点相互作用。周等人 [22] 依照 DTINet 构建了一个异质图, 然后将药物的 SMILES、蛋白质序列以及它们形成的异质网络作为输入, 通过序列区域嵌入、深度采样残差模块来学习它们的化学结构特征。随后, 为了充分利用多模态数据以获得全面的嵌入表示, 他们提出了一种基于异质图的联合表示方法, 将异质图中相连的节点视为关联节点, 并通过最小化关联节点之间的距离来捕捉节点的相关性。Peng 等人 [23] 利用药物、药物副作用、蛋白质、疾病及其关联创建了一个异质图, 然后利用异质图卷积网络提取蛋白质和药物的特征以进行药物-靶点相互作用预测。Li 等人 [24] 利用已知的药物-靶点相互作用数据构建了一个药物-靶点二分网络, 并分别计算蛋白质的序列相似性和药物的化学结构相似性作为相应的节点特征。随后, 他们提出了一种个性化传播图自编码器模型和一个带有双线性解码器的特征嵌入模型, 从二分图中学习特征以进行药物-靶点相互作用预测。

结构表示学习方法通常将蛋白质的氨基酸序列和药物的简化分子线性输入规范 (SMILES) 作为输入, 以学习药物和蛋白质的化学结构特征。然而, 这类方法并未考虑药物与药物之间以及蛋白质与蛋白质之间的潜在关系相似性。图神经网络方法的预测准确性依赖于相似性得分的可靠性, 它们通常使用 Smith-Waterman 算法计算蛋白质序列之间的相似性, 并使用 Tanimoto 相似系数 (TCC) 计算药物之间的相似性。然而, 通过这些相似性计算方法识别出的相似药物和蛋白质并不总是能保证它们之间存在真实的相互作用。

因此, 仅仅依赖这些相似性计算方法可能会降低药物-靶点相互作用预测的性能。

为了充分利用蛋白质和药物的化学结构信息及其相互关系, 我们提出了一种基于关系相似性的图对比学习方法用于药物-靶点相互作用 (DTI) 预测 (RSGCL-DTI)。该方法利用已知的 DTI 数据构建药物-药物关系图和蛋白质-蛋白质关系图, 并采用图对比学习来提取药物的关系相似性特征和蛋白质的关系相似性特征, 然后分别使用 D-MPNN [26] 和 CNN 提取药物和蛋白质的化学结构特征, 最后融合药物和蛋白质的关系特征与结构特征来预测 DTI。

方法

本研究提出了一种新颖的 RSGCL-DTI 方法。RSGCL-DTI 的整体架构如图 1 所示, 由三个模块组成: (i) 基于关系相似性的图对比学习模块; (ii) 结构特征提取模块; (iii) 分类模块。

在基于关系相似性的图对比学习模块中, 我们首先利用已知的药物-靶点相互作用 (DTI) 数据构建药物-靶点相互作用的异质图。在构建过程中, 如果某种药物与某种蛋白质存在相互作用, 就在它们之间添加一条边。异质图构建完成后, 根据药物间关系相似性和蛋白质间关系相似性将其转换为药物-药物关系网络和蛋白质-蛋白质关系网络。随后, 采用图对比学习来提取药物关系特征和蛋白质关系特征。在结构特征提取模块中, 用于提取蛋白质特征的网络分支以蛋白质序列为输入, 通过卷积神经网络 (CNN) 提取蛋白质结构特征, 而用于提取药物分子特征的网络分支以药物分子图为输入, 通过药物分子图神经网络 (D-MPNN) 提取药物结构特征。在分类模块中, 将药物和蛋白质的关系特征与其结构特征融合, 然后将这些融合特征连接起来作为分类器的输入, 以预测药物-靶点相互作用 (DTI)。

基于关系相似性的图对比学习模块

作为一种自监督深度学习范式, 对比学习在图像处理领域取得了令人瞩目的成功 [27-29]。它通过最小化对同一数据点进行增强处理后得到的不同视图之间的差异, 利用大量未标记的数据来提取信息丰富且鲁棒的特征。鉴于这一优势, 许多研究人员将对对比学习应用于图结构数据, 并取得了成功的结果 [30-32]。在本文中, 提出了一种基于关系相似性的图对比学习方法, 用于学习蛋白质和药物的关系特征, 进而提升药物-靶点相互作用 (DTI) 预测性能。

关系相似性网络的构建

根据“关联归罪”假说 [11, 21], 结构相似的药物更有可能与结构相似的蛋白质发生相互作用。因此, 我们希望利用药物和蛋白质之间的关系数据来提取




图 1. RSGCL-DTI 的整体架构。(A) 通过图对比学习提取蛋白质和药物的关系特征。(B) 分别通过 D-MPNN 和 CNN 提取药物和蛋白质的结构特征。(C) 这是用于预测药物-蛋白质相互作用的分类模块。

我们将结合它们的关系特征和结构特征来增强其特征表示。为此，我们首先从药物-靶点相互作用的异构图中推导出药物之间的关系相似性网络和蛋白质之间的关系相似性网络。然后，在同构图上利用图对比学习来提取药物和蛋白质的关系特征。具体来说，我们首先使用已知的药物-靶点相互作用数据构建一个异构图 $G_{dp} = (V_d, V_p, E)$ ，其中 V_d 和 V_p 分别表示药物集和蛋白质集， $E \in \{0, 1\}$ 是药物-蛋白质关系矩阵， $|V_p|$ 和 $|V_d|$ 分别表示蛋白质和药物的数量。 E 中的每一列代表一个蛋白质与所有药物的相互作用，每一行代表一个药物与所有蛋白质的相互作用。这些相互作用被用作蛋白质和药物的特征表示，然后计算药物之间和蛋白质之间的余弦相似度，以构建两个关系相似性网络：一个用于药物，另一个用于蛋白质。具体来说，在构建药物的关系相似性网络时，药物 i 和 j 的特征编码分别由 E 的第 i 行和第 j 行表示。药物 i 和 j 的特征分别表示为 $g_i \in \mathbb{R}^{|V_p|}$ 和 $g_j \in \mathbb{R}^{|V_p|}$ 。它们的余弦相似度计算如下：

$$\text{Sim}_{ij} = \frac{g_i \cdot g_j}{\sqrt{(g_i)^2} \cdot \sqrt{(g_j)^2}} \quad (1)$$

如果药物 i 和 j 之间的余弦相似度 Sim_{ij} 超过了我们设定的药物相似度阈值 τ_d ，则认为它们是相似的，从而在药物-药物关系相似网络中从药物 i 到药物 j 添加一条边。对于 τ_d 的相似度阈值选择与网络的稀疏性有关。为防止关系相似网络过于稀疏而无法有效表示相似关系，在我们的实验中选择 0.3 作为相似度阈值。通过计算药物之间的成对相似度，我们得到邻接矩阵 $A_d \in \{0, 1\}$

$|V_d| \times |V_d|$ 。接下来，生成一个随机矩阵 $X_d \in \mathbb{R}^{|V_d| \times 167}$ 作为初始节点特征矩阵，从而得到药物-药物关系相似网络 $G_d = (A_d, X_d)$ 。同样地，我们得到蛋白质-蛋白质关系相似网络 $G_p = (A_p, X_p)$ ，其中 $A_p \in \mathbb{R}^{|V_p| \times |V_p|}$ 和 $X_p \in \mathbb{R}^{|V_p| \times 256}$ 。注意：药物节点的初始特征维度为 167，这是根据 RDKit 生成的 167 位大小的 MACCS 指纹确定的，而蛋白质节点的初始特征维度为 256，这是通过实验确定的。

基于对比学习的关系特征提取

受图对比学习[31, 33]的启发，我们通过图对比学习从药物和蛋白质的关系相似性网络中挖掘隐含的关系特征，以提高药物-靶点相互作用 (DTI) 预测的准确性。对比学习的模块架构如图 1A 所示，它由两个图对比学习模块组成：一个用于药物，另一个用于蛋白质。两个增强函数， f_{drug}^1

并且 f_{drug}^2 ，通过随机方式应用于增强图结构 G_d 。在药物-药物关系相似性网络 G_d 中移除边，并随机将节点特征设置为零向量，从而得到两个对比视图 $G_d^1 = (A_d^1, X_d^1)$ 和 $G_d^2 = (A_d^2, X_d^2)$ 。然后，使用两个图编码器 f_{drug}^{oe} 和 f_{drug}^{te} 分别使用 G_d^1 和 G_d^2 对其进行编码，以获得两个视图表示 H_{drug}^{oe} 和 H_{drug}^{te} 。药物和 H_{drug} 具有相同的结构

$$H_{drug}^{oe} = f_{drug}^{oe}(f_{drug}^1(G_d)) \quad (2)$$

$$H_{drug}^{te} = f_{drug}^{te}(f_{drug}^2(G_d)) \quad (3)$$

接下来， H_{drug}^{oe} 和 H_{drug}^{te} 被输入到线性变换的预测器 f_{drug}^p 中：

$$Z_{drug}^{oe} = f_{drug}^p(H_{drug}^{oe}) \quad (4)$$

最后，在视图表示 H_{te} 中对应的节点和佐伊

每一对 $药物$ 都被视为正样本对，通过最小化它们之间的差异来更新对比模型中的参数。

$$L = -\frac{2}{N} \sum_{i=0}^{N-1} \frac{Z_{drug_i}^{oe} \cdot H_{drug_i}^{teT}}{\|Z_{drug_i}^{oe}\| \cdot \|H_{drug_i}^{te}\|} \quad (5)$$

为了防止对比模型收敛到平凡解，图编码器 f_{drug_e} 利用了 Adam 优化器优化参数更新的算法，而图编码器 f_{drug} 采用指数移动平均法对于参数更新：

$$\xi \leftarrow \tau \xi + (1 - \tau) \theta \quad (6)$$

其中 ξ 是 f_{drug} 的参数 te ， θ 是 f_{drug} 的参数 oe ，还有 $\tau \in (0, 1)$ 表示衰减率。

对比学习模型训练完成后，图编码器 f_{drug_e}

将其应用于原始的 $药物-药物$ 关系相似性网络 G_d ，以获得 $药物$ 关系特征矩阵 $Zr_{drug} \in \mathbb{R}_{|V| \times 300}$ ，其中每一行代表一种药物的关系特征 $Xr_{drug} \in \mathbb{R}^{300}$ 。同样地，从 $蛋白质-蛋白质$ 关系相似性网络计算出 $蛋白质$ 关系特征矩阵 $Zr_{protein} \in \mathbb{R}_{|V| \times 300}$ 。

结构特征提取模块

氨基酸是构成蛋白质的基本结构单元。蛋白质的氨基酸序列决定了其结构，而这种结构又进一步决定了其功能和活性，这表明氨基酸序列是蛋白质中至关重要的描述性信息。基于此，我们将氨基酸序列作为模型的输入，并利用卷积神经网络（CNN）来提取蛋白质的结构特征。通常，药物的活性和性质与其分子结构和拓扑结构有关。此外，分子图可以作为有效表示药物结构和拓扑结构的手段。因此，我们选择分子图来表示药物，并利用 D-MPNN 来提取其结构特征。

药物结构特征提取模块

在本模块中，首先使用 RDKit 工具包将药物转换为分子图。分子图中节点的初始特征包括八个原子属性：原子序数、键数、形式电荷、手性、氢原子数、杂化态、芳香性以及原子质量。此外，边的初始特征包含四个键属性：键类型、共轭性、环成员资格以及立体化学。最后，在读出阶段使用 D-MPNN 计算所有节点的隐藏特征，并通过汇集所有节点的隐藏特征得到图级特征 $Xs_{drug} \in \mathbb{R}^{300}$ 。

蛋白质结构特征提取模块

在本模块中，采用 Tasks Assessing Protein Embeddings 分词器 [34] 将蛋白质的氨基酸序列编码为其数字表示，然后用零填充以获得固定长度的标记序列 $x_{token} \in \mathbb{R}^L$ 。伪代码如算法 1 所示。然后，将标记序列 x_{token} 输入嵌入层以获得嵌入矩阵。最后，应用 CNN 和 MaxPool 来提取蛋白质序列特征 $Xs_{protein} \in \mathbb{R}^{300}$ 。

Algorithm 1 The pseudo code for encoding amino acid sequences into digital representations

Require: Amino acid sequences S , vocabulary V , batch size B
Ensure: Digital representations res

```

1: for  $S_b \in S_1, \dots, S_B$  do
2:    $tokens \leftarrow$  Cut  $S_b$  into individual tokens by character.
3:    $tokens \leftarrow$  Add  $\langle cls \rangle$  and  $\langle sep \rangle$  before and after tokens.
4:    $tids \leftarrow$  Convert tokens to IDs using vocabulary  $V$ 
5:    $x \leftarrow$  Convert  $tids$  to a NumPy array
6:   if length of  $x \geq L_s$  then
7:      $x \leftarrow x[:L_e]$ 
8:   else  $X_{protein}^s = MP(CNN(Emb(x_{token})))$  (7)
9:      $zeros \leftarrow$  Array of zeros with length  $L_s - \text{length of } x$ 
10:     $x \leftarrow \text{concatenate}(x, zeros)$ 
11:   end if
12:   Append  $x$  to  $res$ 
13: end for
```

其中， $MP(\cdot)$ 表示最大池化层， $CNN(\cdot)$ 表示卷积神经网络块， $Emb(\cdot)$ 表示嵌入层。

分类模块

我们所提出的模型首先通过图对比学习模块和结构特征提取模块分别获取蛋白质和药物的关系特征及结构特征。随后，通过拼接的方式分别将这些关系特征和结构特征进行组合：

$$\begin{aligned} X_{drug} &= \text{concat}(X_{drug}^r, X_{drug}^s) \\ X_{protein} &= \text{concat}(X_{protein}^r, X_{protein}^s) \end{aligned} \quad (8)$$

其中， $X_{drug} \in \mathbb{R}^{600}$ 和 $X_{protein} \in \mathbb{R}^{600}$ 分别为组合药物特征和组合蛋白质特征。最后，将组合特征 X_{drug} 和 $X_{protein}$ 作为输入传递给分类模块以进行药物-靶点相互作用预测。遵循先前的研究 [14, 19, 35]，我们采用多层感知机（MLP）作为分类网络，并使用二元交叉熵损失作为损失函数。在多层感知机中，我们使用了三个全连接层，每个全连接层后面都跟着一个 Dropout 层和一个 LeakyReLU 激活函数。接下来，多层感知机的输出通过一个额外的全连接层以生成预测结果。

结果

数据集和评估指标

为了将 RSGCL-DTI 与现有的 DTI 预测方法进行比较，我们使用了 DrugBank [35]、BioSNAP [36]、Human [37] 和 C.elegans [37] 数据集来评估所有模型的性能。这些数据集的详细信息列于表 1 中。所有实验均已完成。

表 1. 基准数据集的详细描述

数据集	蛋白质	药物	否定的	积极的
人类	2001	2726	3364	3364
秀丽隐杆线虫	1876	2726	3894	3893
DrugBank	2888	6459	14442	11885
BioSNAP	2181	4509	13834	13834

表 2.RSGCL-DTI 与基准模型在 DrugBank 上的对比结果

模型	AUC (标准差)	标准型自动气候控制系统 (ACC) 召回率 (标准差)	精度 (标准差)	标准 AUPR
RSGCL-DTI	0.9315 (0.0065)	0.8658 (0.0142)	0.8912 (0.0334)	0.9528 (0.0047)
GIFDTI	0.9115 (0.0049)	0.8265 (0.0085)	0.8982 (0.0085)	0.9201 (0.0057)
超注意力DTI	0.9105 (0.0033)	0.8272 (0.0053)	0.8802 (0.0059)	0.9289 (0.0032)
MHSADTI	0.8695 (0.0089)	0.7912 (0.0115)	0.8381 (0.0254)	0.8622 (0.1000)
MCANet	0.9172 (0.0046)	0.8445 (0.0059)	0.8751 (0.0147)	0.9326 (0.0048)
BINDTI	0.8852 (0.0056)	0.8148 (0.0026)	0.7921 (0.0060)	0.9088 (0.0079)
MCL-DTI	0.8514 (0.0036)	0.7834 (0.0023)	0.8169 (0.0057)	0.7743 (0.0090)
CoaDTI	0.7849 (0.1290)	0.7126 (0.0106)	0.5943 (0.0824)	0.6793 (0.0077)

使用 10 折交叉验证。测试集通过从数据集中随机抽取 10% 的数据获得。剩余的 90% 数据被分为 10 个子集。在每一轮中，一个子集用作验证集，其余九个子集用作训练集。从数据集中已知的药物 - 蛋白质相互作用对构建正例。负例的选择过程包括随机选择一种药物，然后从不与所选药物相互作用的蛋白质集中随机选择一种蛋白质以形成负对。然后将生成的对与现有的负例进行唯一性验证。只有非冗余的对才被纳入最终的负例集。在平衡数据集上，使用 ACC、AUC、召回率、精确率和 AUPR 来评估 RSGCL-DTI 和基线模型，而在不平衡数据集上，则使用 AUPR 和 AUC 来评估 RSGCL-DTI 和基线模型。

对比实验

为了全面评估我们提出的 RSGCL-DTI 模型的预测能力，我们选取了 MHSADTI [38]、HyperAttentionDTI [35]、GIFDTI [39]、MCANet [40]、BINDTI [41]、MCL-DTI [42]、CoaDTI [43] 和 DRGCL [44] 作为基准模型。为了确保评估既科学又有效，我们在相同的实验环境中对上述基准模型与 RSGCL-DTI 进行了比较，并报告了在 DrugBank、C.elegans、Human 和 BioSNAP 数据集下 10 折交叉验证的平均指标值。在展示比较结果时，最佳指标值以粗体显示，次优指标值则以下划线标注。

表 2 中提供了在 DrugBank 上的比较结果。根据表中所示的结果，我们可以观察到 RSGCL-DTI 在 AUC、ACC、精度和 AUPR 这些预测性能指标上均表现最佳。RSGCL-DTI 在 AUC、ACC 和 AUPR 这些指标上分别比排名第二的 MCANet 高出 1.43%、2.13% 和 2.02%，并且在精度上比精度最高的基准模型 BINDTI 提高了 0.87%。然而，在召回率方面，它排名第二，比排名第一的 GIFDTI 低 0.7%。为了更直观地比较所有模型，我们使用 DrugBank 数据集为每个模型绘制了 ROC 和 PR 曲线，如图 2 所示。

表 3 展示了 RSGCL-DTI 与基准模型在秀丽隐杆线虫上的性能表现，从中我们可以观察到，RSGCL-DTI 在准确率（ACC）、召回率、精确率和 AUPR 上均取得了最佳成绩，分别比排名第一的基准模型高出 1.91%、1.49%、1.54% 和 0.18%。然而，其 AUC 值比 AUC 值最高的基准模型 DRGCL 低 0.05%。ROC 曲线和 PR 曲线见图 3。

在 Human 数据集上，RSGCL-DTI 在 AUC、ACC、召回率和 AUPR 这四个指标上分别比具有最高指标的基线模型提高了 0.26%、1.31%、1.00% 和 0.23%，但在准确率上比准确率最高的基线模型 DRGCL 低 0.05%。实验结果如表 4 所示。ROC 曲线和 PR 曲线见图 4。

表 5 展示了 BioSNAP 数据集的实验结果。RSGCL-DTI 在 AUC、召回率和 AUPR 上分别比表现最佳的基线 DRGCL 高出 0.04、0.62 和 0.15%，但在准确率和精确率上分别比 DRGCL 低 0.18 和 0.8%。图 5 展示了 RSGCL-DTI 和基线在 BioSNAP 上的 PR 和 ROC 曲线。为了进一步评估 RSGCL-DTI 的预测性能，我们使用 EMBOSS 套件中的 water 工具对 BioSNAP 数据集中的蛋白质序列进行局部序列比对，从而获得序列一致性。随后，我们采用凝聚聚类方法得出 10 个簇，作为 10 折，以确保各折之间数据的更大独立性。结果见表 6。实验结果表明，所有模型的 AUC 和 AUPR 的标准差都有所增加。此外，基于结构的 DTI 预测方法（如 GIFDTI、HyperAttentionDTI、MHSADTI 和 MCANet）的性能显著下降，而基于网络的方法（如 DRGCL 和 RSGCL-DTI）的性能仅略有下降。我们认为，这是因为测试集中的蛋白质与训练集中的蛋白质序列相似度较低时，它们的三维结构可能存在显著差异。因此，基于结构的模型难以从训练集中学习到有效的模式，从而准确预测测试集中的药物 - 蛋白质相互作用，导致性能大幅下降。相比之下，基于网络的方法并非完全依赖蛋白质和药物的结构信息，而是利用网络的拓扑结构以及节点之间的关系来识别潜在的相互作用。因此，它们的性能下降相对较小。

为了评估 RSGCL-DTI 模型在不平衡数据集上的预测能力，我们基于 DrugBank、BioSNAP、Human 和 C.elegans 数据集通过重复抽样构建了四个不平衡数据集，正负样本比例为 1:5。然后，我们使用 AUPR 和 AUC 指标在这些不平衡数据集上评估了 RSGCL-DTI 和基线模型的性能。从图 6 中可以看出，RSGCL-DTI 的表现优于所有基线模型，这表明 RSGCL-DTI 在不平衡数据集上也取得了出色的性能。

为了探究当数据集中的正负样本比例逐渐增加时 RSGCL-DTI 模型性能的变化情况，我们使用 Drug-Bank 数据集进行了实验，该数据集的正负样本比例分别为 1:1、1:5 以及

本文于 2025 年 4 月 2 日由访客从 <https://academic.oup.com/bib/article/26/2/bbaf122/8092301> 下载。




图 2.RSHCL-DTI 与基准模型在 DrugBank 上的 PR 和 ROC 曲线。

表 3.秀丽隐杆线虫的 RSGCL-DTI 与基线模型的比较结果

模型	AUC (标准差)	标准型自动气候控制系统 (ACC)	召回率 (标准差)	精度 (标准差)	标准 AUPR
RSGCL-DTI	0.9946 (0.0008)	0.9871 (0.0026)	0.9826 (0.0056)	0.9924 (0.0063)	0.9969 (0.0004)
GIFDTI	0.9880 (0.0056)	0.9422 (0.0135)	0.9529 (0.0175)	0.9366 (0.0163)	0.9902 (0.0049)
超注意力DTI	0.9934 (0.0011)	0.9551 (0.0088)	0.9677 (0.0095)	0.9466 (0.0133)	0.9939 (0.0011)
MHSADTI	0.9776 (0.0062)	0.9242 (0.0046)	0.9652 (0.0072)	0.9002 (0.0063)	0.9808 (0.0057)
MCANet	0.9920 (0.0018)	0.9661 (0.0048)	0.9666 (0.0090)	0.9666 (0.0054)	0.9925 (0.0014)
BINDTI	0.9907 (0.0034)	0.9602 (0.0018)	0.9628 (0.0218)	0.9604 (0.0165)	0.9932 (0.0019)
MCL-DTI	0.9706 (0.0030)	0.9072 (0.0063)	0.8486 (0.0161)	0.9744 (0.0112)	0.9769 (0.0031)
CoaDTI	0.9527 (0.0016)	0.8921 (0.0070)	0.8537 (0.0114)	0.9434 (0.0063)	0.9629 (0.0033)
DRGCL	0.9951 (0.0016)	0.9680 (0.0271)	0.9586 (0.0021)	0.9770 (0.0421)	0.9951 (0.0016)




图 3. RSHCL-DTI 与基准方法在秀丽隐杆线虫上的 PR 曲线和 ROC 曲线。

表 4.RSGCL-DTI 与基线模型在人类数据上的对比结果

模型	AUC (标准差)	标准型自动气候控制系统 (ACC)	召回率 (标准差)	精度 (标准差)	标准 AUPR
RSGCL-DTI	0.9963 (0.0007)	0.9703 (0.0026)	0.9715 (0.0043)	0.9677 (0.0033)	0.9925 (0.0006)
GIFDTI	0.9715 (0.0051)	0.9140 (0.0134)	0.9197 (0.0161)	0.9022 (0.0342)	0.9807 (0.0069)
超注意力DTI	0.9805 (0.0026)	0.9348 (0.0053)	0.9586 (0.0052)	0.9226 (0.0065)	0.9516 (0.0038)
MHSADTI	0.9693 (0.0012)	0.9117 (0.0056)	0.9311 (0.0142)	0.8992 (0.0155)	0.9225 (0.0054)
MCANet	0.9937 (0.0020)	0.9572 (0.0031)	0.9615 (0.0098)	0.9519 (0.0095)	0.9902 (0.0023)
BINDTI	0.9863 (0.0028)	0.9535 (0.0039)	0.9615 (0.0013)	0.9404 (0.0059)	0.9719 (0.0024)
MCL-DTI	0.9850 (0.0027)	0.9459 (0.0053)	0.9482 (0.0052)	0.9452 (0.0065)	0.9516 (0.0038)
CoaDTI	0.9700 (0.0077)	0.9154 (0.0070)	0.9395 (0.0255)	0.9061 (0.0154)	0.9131 (0.0067)
DRGCL	0.9876 (0.0031)	0.9476 (0.0101)	0.9232 (0.0198)	0.9682 (0.0226)	0.9899 (0.0024)




图 4. RSHCL-DTI 与基准方法在 Human 数据集上的 PR 曲线和 ROC 曲线。

表 5.RSGCL-DTI 与基线模型在 BioSNAP 上的对比结果

模型	AUC (标准差)	标准型自动气候控制系统 (ACC)	召回率 (标准差)	精度 (标准差)	标准 AUPR
RSGCL-DTI	0.9605 (0.0025)	0.8899 (0.0041)	0.8889 (0.0097)	0.8947 (0.0111)	0.9572 (0.0046)
GIFDTI	0.9179 (0.0060)	0.8412 (0.0106)	0.8671 (0.0126)	0.8265 (0.0142)	0.8412 (0.0051)
超注意力DTI	0.9228 (0.0051)	0.8475 (0.0080)	0.8679 (0.0116)	0.8357 (0.0093)	0.9277 (0.0054)
MHSADTI	0.9078 (0.0071)	0.8344 (0.0099)	0.8410 (0.0205)	0.8331 (0.0139)	0.8674 (0.0067)
MCANet	0.9354 (0.0026)	0.8630 (0.0068)	0.8467 (0.0101)	0.8851 (0.0070)	0.9387 (0.0041)
BINDTI	0.9118 (0.0024)	0.8413 (0.0021)	0.8241 (0.0060)	0.8652 (0.0044)	0.9117 (0.0049)
MCL-DTI	0.8809 (0.0056)	0.8095 (0.0066)	0.8224 (0.0370)	0.8043 (0.0249)	0.7780 (0.0057)
CoaDTI	0.7185 (0.0085)	0.6847 (0.0118)	0.5814 (0.0608)	0.7357 (0.0330)	0.7391 (0.0066)
DRGCL	<u>0.9601 (0.0186)</u>	0.8917 (0.0228)	<u>0.8827 (0.0601)</u>	0.9027 (0.0447)	<u>0.9557 (0.0199)</u>




图 5. RSHCL-DTI 与基准模型在 BioSNAP 上的 PR 曲线和 ROC 曲线。

实验结果如图 7 所示。实验结果表明，随着数据集不平衡程度的增加，模型的 AUPR 值下降。当数据集的正负样本比例从 1:5 增加到 1:10 时，模型的 AUPR 值仅下降了 0.87%，这表明我们的模型对数据不平衡具有良好的抗性。

消融实验

大量研究表明，药物与蛋白质之间的相互作用受其化学结构影响，而药物间和蛋白质间的潜在关系也会影响药物 - 蛋白质相互作用。鉴于此，我们提出将蛋白质和药物的关系特征与其结构特征相结合，以提高预测性能。为了探究关系特征和结构特征对预测性能

的影响，我们设计了两个变体模型 RSGCL-DTI-RF 和 RSGCL-DTI-SF，其中 RSGCL-DTI-RF 仅考虑关系特征对药物 - 蛋白质相互作用预测准确率的影响，而 RSGCL-DTI-SF 仅考虑结构特征对药物 - 蛋白质相互作用预测准确率的影响。具体而言，RSGCL-DTI-RF 仅采用图对比学习来学习用于药物 - 蛋白质相互作用预测的关系特征，而 RSGCL-DTI-SF 仅使用 CNN 和 D-MPNN 提取用于药物 - 蛋白质相互作用预测的蛋白质和药物的结构特征。此外，为了确保实验对比公平合理，我们确定了 RSGCL-DTI、RSGCL-DTI-RF 和




图 6.在不平衡数据集上的实验结果：(a) 不平衡的 DrugBank 数据集上的结果。(b) 不平衡的 BioSNAP 数据集上的结果。(c) 不平衡的人类数据集上的结果。(d) 不平衡的秀丽隐杆线虫 (C.elegans) 数据集上的结果。

表 6.在 BioSNAP 数据集上进行的凝聚聚类实验结果

模型	AUC (标准差)	标准 AUPR
RSGCL-DTI	0.9128 (0.0064)	0.8903 (0.0106)
GIFDTI	0.8366 (0.0124)	0.8184 (0.0151)
超注意力DTI	0.8202 (0.0125)	0.8153 (0.0172)
MHSADTI	0.8100 (0.0499)	0.8001 (0.0221)
MCANet	0.8350 (0.0111)	0.8306 (0.0077)
BINDTI	0.6771 (0.0410)	0.6988 (0.0554)
MCL-DTI	0.7168 (0.0239)	0.7483 (0.0524)
CoaDTI	0.7071 (0.0631)	0.7258 (0.0767)
DRGCL	0.9096 (0.0192)	0.8821 (0.0213)

我们通过多次实验对 RSGCL-DTI-SF 模型进行调整，以确保其性能能达到最佳。我们在 DrugBank 数据集上对 RSGCL-DTI-RF 和 RSGCL-DTI-SF 模型的超参数进行了确定，部分实验结果如表 7 所示。我们还在 DrugBank 数据集上对 RSGCL-DTI-RF 和 GCL-DTI-SF 模型进行了 10 折交叉验证测试。这




图 7.在 DrugBank 中不同比例的正负例实验结果。

表 7.关于确定变体模型超参数的实验结果

模型	超参数	AUC (标准差)	标准 AUPR
RSGCL-DTI-SF	卷积神经网络的一层	0.8937 (0.0118)	0.9188 (0.0085)
	两层卷积神经网络	0.9197 (0.0026)	0.9192 (0.0033)
	三层卷积神经网络	0.9071 (0.0051)	0.9270 (0.0050)
	一层 D-MPNN	0.8985 (0.0090)	0.9175 (0.0099)
	两层 D-MPNN	0.9197 (0.0026)	0.9192 (0.0033)
	三层 D-MPNN	0.8902 (0.0189)	0.9165 (0.0126)
RSGCL-DTI-RF	一层图卷积网络 (GCN)	0.9164 (0.0031)	0.9210 (0.0038)
	两层图卷积网络	0.9249 (0.0025)	0.9255 (0.0045)
	三层GCN	0.9153 (0.0061)	0.9234 (0.0038)

表 8. 剪枝实验的结果

数据集	模型	AUC (标准差)	标准型自动气候控制系统 (标准差)	召回率 (标准差)	精度 (标准差)	标准 AUPR
DrugBank	RSGCL-DTI	0.9315 (0.0065)	0.8658 (0.0142)	0.8912 (0.0334)	0.8683 (0.0122)	0.9528 (0.0047)
	RSGCL-DTI-RF	0.9213 (0.0033)	0.8624 (0.0015)	0.8741 (0.0083)	0.8752 (0.0072)	0.9323 (0.0052)
	RSGCL-DTI-SF	0.9234 (0.0042)	0.8526 (0.0023)	0.8797 (0.0014)	0.8679 (0.0032)	0.9215 (0.0046)
秀丽隐杆线虫	RSGCL-DTI	0.9946 (0.0008)	0.9871 (0.0026)	0.9826 (0.0056)	0.9924 (0.0063)	0.9969 (0.0004)
	RSGCL-DTI-RF	0.9763 (0.0011)	0.9127 (0.0011)	0.9029 (0.0546)	0.9319 (0.0405)	0.9857 (0.0065)
	RSGCL-DTI-SF	0.9912 (0.0034)	0.9607 (0.0048)	0.9634 (0.0086)	0.9595 (0.0024)	0.9925 (0.0016)
人类	RSGCL-DTI	0.9963 (0.0007)	0.9703 (0.0026)	0.9715 (0.0043)	0.9677 (0.0033)	0.9925 (0.0006)
	RSGCL-DTI-RF	0.9939 (0.0003)	0.9788 (0.0032)	0.9827 (0.0008)	0.9738 (0.0068)	0.9951 (0.0006)
	RSGCL-DTI-SF	0.9905 (0.0013)	0.9548 (0.0050)	0.9606 (0.0097)	0.9650 (0.0094)	0.9908 (0.0009)
BioSNAP	RSGCL-DTI	0.9605 (0.0025)	0.8899 (0.0041)	0.8889 (0.0097)	0.8947 (0.0111)	0.9572 (0.0046)
	RSGCL-DTI-RF	0.8861 (0.0040)	0.7885 (0.0108)	0.6591 (0.0293)	0.8933 (0.0095)	0.8976 (0.0042)
	RSGCL-DTI-SF	0.9186 (0.0015)	0.8503 (0.0042)	0.8588 (0.0112)	0.8465 (0.0056)	0.9223 (0.0412)

表 9.训练轮数对弥散张量成像预测的影响

纪元	AUC	ACC	召回	精度
1000	0.9277	0.8590	0.8861	0.8641
2000	0.9316	0.8648	0.8838	0.8721
3000	0.9315	0.8658	0.8912	0.8683

RSGCL-DTI 的消融实验结果如表 8 所示。

参数分析

在本次实验中，我们使用 DrugBank 数据集进行了参数分析，以评估图对比学习中训练轮数以及不同节点特征初始化策略对模型性能的影响。

对训练轮数的分析

在图对比学习中，会尽量减小不同视图对应节点之间的差异，以使它们的表示更加相似。这种相似程度会影响下游药物-靶点相互作用 (DTI) 预测任务的准确性。此外，在图对比学习中，这种相似性与训练轮数密切相关。因此，我们测试了在不同训练轮数（1000、2000 和 3000）下预测性能的变化。如表 9 所示的结果表明，随着训练轮数的增加，模型性能会提升，但当轮数超过 2000 时则趋于稳定。因此，在实验中，图对比学习模块的训练轮数被设定为 2000。

节点特征初始化策略分析

在本节中，我们将分析节点特征初始化策略对预测性能的影响。在图对比学习中，初始节点特征的选择是影响预测性能的关键因素。需要注意的是，不同的初始节点特征矩阵包含不同的先验信息，因此不同的节点特征初始化策略可能会对节点特征表示的学习产生影响。因此，我们设计了两种节点特征初始化策略：均匀初始化策略和随机初始化策略，以研究节点特征初始化策略对预测性能的影响。均匀初始化策略是为对比视图中的所有节点设置相同的随机初始特征。该策略认为关系特征受关系相似性网络拓扑结构的影响。从相同的初始节点特征中得出的节点关系特征之间的差异仅取决于网络拓扑信息。这种策略更准确地反映了节点之间的拓扑关系。随机初始化策略利用随机函数为对比视图中的每个节点生成长度不同的不同向量作为其初始特征。具体而言，药物节点由 167 维的随机向量初始化，而蛋白质节点则由 256 维的随机向量初始化。与均匀初始化策略相比，随机初始化策略考虑了节点之间的差异，这使得在学习网络拓扑结构时更注重单个节点的特征。实验在 DrugBank 数据集上进行，其中使用了 2000 个周期进行图对比学习。表 10 中的实验结果表明，使用均匀初始化策略的预测性能

表 10. 节点特征初始化策略对药物 - 靶点相互作用预测的影响

初始化策略	AUC	ACC	召回	精度
统一初始化策略	0.8217	0.7245	0.6458	0.8342
随机初始化策略	0.9316	0.8648	0.8838	0.8721

表 11. RSGCL-DTI 的前 20 项预测结果

等级	药物编号	蛋白质 ID	标签
1	DB02659	P00326	1
2	DB13345	P07550	1
3	DB13345	P08588	1
4	DB02613	P06276	0
5	DB12267	P00533	1
6	DB04216	P17812	0
7	DB00338	P35354	0
8	DB12140	P06239	0
9	DB12695	P06753	1
10	DB12695	Q92598	1
11	DB12141	O95263	0
12	DB08231	Q16769	0
13	DB00142	O43424	1
14	DB00142	O00222	1
15	DB00142	O00341	1
16	DB00142	O14841	1
17	DB00142	O15067	1
18	DB12267	P00519	1
19	DB04794	P12931	0
20	DB02379	P02144	1

显著低于随机初始化策略。我们认为，通过为每个节点分配不同的初始特征，模型能够更灵活地捕捉节点之间的差异和多样性，从而增强其对节点间关系的建模能力。

案例研究

为了评估 RSGCL-DTI 对未知药物-靶点相互作用（DTI）的预测能力，我们依照 AMGDTI [45] 的做法，将 DrugBank 数据集用作训练集。我们从在线的 DrugBank 数据库中收集了 80 个药物-靶点对作为阳性样本。为了构建阴性样本，我们将这些药物与它们的非相互作用靶点随机配对，确保训练集中既没有阳性样本也没有阴性样本，从而得到了总共 4000 个阴性样本。最后，将这些阳性样本和阴性样本混合，得到了阳性与阴性样本比例为 1:50 的测试集。在本次实验中，RSGCL-DTI、MCANet、HyperAttentionDTI、MCL-DTI、GIFDTI、MHSADTI、CoaDTI 和 BINDTI 这些模型的 AUPR 分别为 0.5130、0.5002、0.4797、0.2018、0.5056、0.4591、0.1502 和 0.3855。我们还对 AUPR 指标最高的四个模型（RSGCL-DTI、MCANet、GIFDTI 和 HyperAttentionDTI）预测得分最高的 80 个药物-靶点对进行了分析。在排名前 80 的药物 - 靶点对中，RSGCL-DTI 凭借准确识别出 46 个阳性案例，展现出了卓越的预测性能，优于 MCANet 和 GIFDTI（两者均正确预测了 41 个）以及 HyperAttentionDTI（正确预测了 42 个）。我们还在表 11 中列出了排名前 20 的药物 - 靶点对。

结论与未来工作

药物-靶点相互作用（DTI）的预测是药物再利用和新药开发的重要组成部分。在本研究中，我们提出了一种新颖的 RSGCL-DTI 方法，该方法利用药物和蛋白质的潜在相似性关系及其化学结构来计算它们的特征表示。RSGCL-DTI 首先利用已知的药物-蛋白质相互作用数据构建药物-蛋白质异质图，并将其转换为药物和蛋白质的关系相似性网络，然后采用图对比学习获取药物和靶点蛋白质的关系特征，并分别与通过图神经网络（GNN）和卷积神经网络（CNN）提取的化学结构特征相结合，以增强 DTI 的预测性能。为了从多个角度全面评估 RSGCL-DTI 的性能，我们选取了八个最先进的 DTI 预测模型作为基准，并进行了实验对比、消融实验和参数分析。实验结果表明，RSGCL-DTI 相较于基准模型具有显著优势，证明了结构特征和关系特征的结合能够有效提升 DTI 预测性能。

我们提出的模型包含两个关键模块。其中一个模块是图对比学习模块，旨在提取关系特征。未来，我们计划利用大型语言模型计算药物和蛋白质的特征表示，然后基于这些预训练特征构建特征相似性网络。接下来，我们将对这些网络应用对比学习，以优化和增强其特征表示，从而提高药物-靶点相互作用（DTI）预测的性能。

要点

在本文中，我们提出了 RSGCL-DTI。为了对蛋白质之间以及药物之间的相似性关系进行建模，我们基于已知的药物 - 蛋白质相互作用网络构建了两个关系相似性网络，并利用对比学习来捕捉蛋白质和药物的关系特征。同时，我们分别使用卷积神经网络（CNN）和图消息传递神经网络（D-MPNN）提取蛋白质和药物的关系特征。在多个平衡和不平衡的数据集上进行的实验表明，RSGCL-DTI 在预测性能方面优于现有的多个最先进模型，并且具有出色的泛化能力。

资金

本研究得到了国家自然科学基金（62225109，62450112）和国家重点研发计划（2021YFC2100101）的支持。

利益冲突：作者声明不存在利益冲突。

数据可用性

RSGCL-DTI 的代码和数据集可在 <https://github.com/tangjlh/RSGCL-DTI> 获取。

参考文献

1. Aragh AH, Givehchian P, Amirani RM. *et al.* MiRAGE: mining relationships for advanced generative evaluation in drug repositioning. *Brief Bioinform* 2024;25:bbae337.

2. Ashburn TT, Thor KB. Drug repositioning: identifying and developing new uses for existing drugs. *Nat Rev Drug Discov* 2004;**3**: 673–83. <https://doi.org/10.1038/nrd1468>
3. Jung Y-S, Kim Y, Cho Y-R. Comparative analysis of network-based approaches and machine learning algorithms for predicting drug-target interactions. *Methods* 2022;**198**:19–31. <https://doi.org/10.1016/j.ymeth.2021.10.007>
4. Masumshah R, Eslahchi C. DPSP: a multimodal deep learning framework for polypharmacy side effects prediction. *Bioinform Adv* 2023;**3**:vbad110.
5. Masumshah R, Aghdam R, Eslahchi C. A neural network-based method for polypharmacy side effects prediction. *BMC Bioinformatics* 2021;**22**:1–17. <https://doi.org/10.1186/s12859-021-04298-y>
6. Manoochehri HE, Nourani M. Drug-target interaction prediction using semi-bipartite graph model and deep learning. *BMC Bioinformatics* 2020;**21**:1–16. <https://doi.org/10.1186/s12859-020-3518-6>
7. Bleakley K, Yamanishi Y. Supervised prediction of drug-target interactions using bipartite local models. *Bioinformatics* 2009;**25**: 2397–403. <https://doi.org/10.1093/bioinformatics/btp433>
8. Tapio P, Antti A, Sami P. *et al.* Toward more realistic drug-target interaction predictions. *Brief Bioinform* 2015;**16**:325–37. <https://doi.org/10.1093/bib/bbu010>
9. Yamanishi Y, Araki M, Gutteridge A. *et al.* Prediction of drug-target interaction networks from the integration of chemical and genomic spaces. *Bioinformatics* 2008;**24**:i232–40. <https://doi.org/10.1093/bioinformatics/btn162>
10. Li F, Zhang Z, Guan J. *et al.* Effective drug-target interaction prediction with mutual interaction neural network. *Bioinformatics* 2022;**38**:3582–9. <https://doi.org/10.1093/bioinformatics/btac377>
11. Yifan W, Gao M, Zeng M. *et al.* BridgeDPI: a novel graph neural network for predicting drug-protein interactions. *Bioinformatics* 2022;**38**:2571–8.
12. Li Y, Qiao G, Wang K. *et al.* Drug-target interaction prediction via multi-channel graph neural networks. *Brief Bioinform* 2021;**23**: bbab346. <https://doi.org/10.1093/bib/bbab346>
13. Bian J, Hao L, Dong G. *et al.* Hierarchical multimodal self-attention-based graph neural network for DTI prediction. *Brief Bioinform* 2024;**25**:bbae293. <https://doi.org/10.1093/bib/bbae293>
14. Lee I, Keum J, Nam H. DeepConv-DTI: prediction of drug-target interactions via deep learning with convolution on protein sequences. *PLoS Comput Biol* 2019;**15**:e1007129. <https://doi.org/10.1371/journal.pcbi.1007129>
15. Zheng X, He S, Song X. *et al.* DTI-RCNN: new efficient hybrid neural network model to predict drug-target interactions. In: Kurkov V, Manolopoulos Y, Hammer B, Iliadis L, Maglogiannis I (eds.), *Artificial Neural Networks and Machine Learning –ICANN*, vol. **11139**, pp. 104–14. Cham, Switzerland: Springer, 2018. https://doi.org/10.1007/978-3-030-01418-6_11
16. Shin B, Park S, Kang K. *et al.* Self-attention based molecule representation for predicting drug-target interaction. In: *Machine Learning for Healthcare Conference*, pp. 230–48. Ann Arbor, MI, USA: PMLR, 2019.
17. Vaswani A, Shazeer N, Parmar N. *et al.* Attention is all you need. *Advances in Neural Information Processing Systems*, vol. **30**, pp. 5998–6008. 57 More house Lane, Red Hook, NY 12571, USA: Curran Associates, Inc, 2017.
18. Wang L, You Z-H, Chen X. *et al.* A computational-based method for predicting drug-target interactions by using stacked autoencoder deep neural network. *J Comput Biol* 2018;**25**:361–73. <https://doi.org/10.1089/cmb.2017.0135>
19. Yazdani-Jahromi M, Yousefi N, Tayebi A. *et al.* AttentionSiteDTI: an interpretable graph-based model for drug-target interaction prediction using NLP sentence-level relation classification. *Brief Bioinform* 2022;**23**:bbac272.
20. Jian D, Zhang S, Guanhang W. *et al.* Topology adaptive graph convolutional networks *ArXiv*, abs/1710.10370. 2018.
21. Luo Y, Zhao X, Zhou J. *et al.* A network integration approach for drug-target interaction prediction and computational drug repositioning from heterogeneous information. *Nat Commun* 2017;**8**:573. <https://doi.org/10.1038/s41467-017-00680-8>
22. Zhou D, Zhijian X, Li WT. *et al.* MultiDTI: drug-target interaction prediction based on multi-modal representation learning to bridge the gap between new chemical entities and known heterogeneous network. *Bioinformatics* 2021;**37**:4485–92. <https://doi.org/10.1093/bioinformatics/btab473>
23. Peng J, Wang Y, Guan J. *et al.* An end-to-end heterogeneous graph representation learning-based framework for drug-target interaction prediction. *Brief Bioinform* 2021;**22**:bbaa430. <https://doi.org/10.1093/bib/bbaa430>
24. Li Y-C, You Z-H, Chang-Qing Y. *et al.* PPAEDTI: personalized propagation auto-encoder model for predicting drug-target interactions. *IEEE J Biomed Health Inform* 2023;**27**:573–82. <https://doi.org/10.1109/JBHI.2022.3217433>
25. Maggiora G, Vogt M, Stumpfe D. *et al.* Molecular similarity in medicinal chemistry: miniperspective. *J Med Chem* 2014;**57**: 3186–204. <https://doi.org/10.1021/jm401411z>
26. Yang K, Swanson K, Jin W. *et al.* Analyzing learned molecular representations for property prediction. *J Chem Inf Model* 2019;**59**: 3370–88. <https://doi.org/10.1021/acs.jcim.9b00237>
27. He K, Fan H, Wu Y. *et al.* Momentum contrast for unsupervised visual representation learning. In: *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 9726–35. Seattle, WA, USA: IEEE, 2020.
28. Grill J-B, Strub F, Altché F. *et al.* Bootstrap your own latent: a new approach to self-supervised learning. *Advances in Neural Information Processing Systems*, vol. **33**, pp. 21271–84. 57 More house Lane, Red Hook, NY 12571, USA: Curran Associates, Inc., 2020.
29. Chen T, Kornblith S, Norouzi M. *et al.* A simple framework for contrastive learning of visual representations. In: *International Conference on Machine Learning*, pp. 1597–607. Vienna, Austria: PMLR, 2020.
30. Wei C, Liang J, Liu D. *et al.* Contrastive graph structure learning via information bottleneck for recommendation. *Adv Neural Inf Process Syst* 2022;**35**:1909–22.
31. Ma Y, He Y, Zhang A. *et al.* CrossCBR: cross-view contrastive learning for bundle recommendation. In: *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, pp. 1233–41. New York, NY, USA: Association for Computing Machinery, 2022.
32. Thakoor S, Tallec C, Azar MG. *et al.* Bootstrapped representation learning on graphs. In: *ICLR 2021 Workshop on Geometrical and Topological Representation Learning*. Virtual: PMLR, 2021.
33. Li Y, Qiao G, Gao X. *et al.* Supervised graph co-contrastive learning for drug-target interaction prediction. *Bioinformatics* 2022;**38**: 2847–54. <https://doi.org/10.1093/bioinformatics/btac164>
34. Rao R, Bhattacharya N, Thomas N. *et al.* Evaluating protein transfer learning with TAPE. In: Wallach HM, Larochelle H, Beygelzimer A, d'Alché-Buc F, Fox EB, Garnett R (eds.), *Advances in Neural Information Processing Systems*, vol. **32**, pp. 9689–701. Vancouver, Canada: Curran Associates, Inc., 2019.
35. Zhao Q, Zhao H, Zheng K. *et al.* HyperAttentionDTI: improving drug-protein interaction prediction by sequence-based deep learning with attention mechanism. *Bioinformatics* 2022;**38**: 655–62. <https://doi.org/10.1093/bioinformatics/btab715>

36. Zitnik M, Rok S, Leskovec J. BioSNAP datasets: Stanford biomedical network dataset collection. 2018. <http://snap.stanford.edu/biodata>
37. Hui L, Jianjiang S, Jihong G. et al. Improving compound-protein interaction prediction by building up highly credible negative samples. *Bioinformatics* 2015;**31**:i221–9. <https://doi.org/10.1093/bioinformatics/btv256>
38. Cheng Z, Yan C, Fang-Xiang W. et al. Drug-target interaction prediction using multi-head self-attention and graph attention network. *IEEE/ACM Trans Comput Biol Bioinform* 2022;**19**:2208–18. <https://doi.org/10.1109/TCBB.2021.3077905>
39. Zhao Q, Duan G, Zhao H. et al. GIFDTI: prediction of drug-target interactions based on global molecular and inter-molecular interaction representation learning. *IEEE/ACM Trans Comput Biol Bioinform* 2023;**20**:1943–52. <https://doi.org/10.1109/TCBB.2022.3225423>
40. Bian J, Zhang X, Zhang X. et al. MCANet: shared-weight-based multiheadcrossattention network for drug-target interaction prediction. *Brief Bioinform* 2023;**24**:bbad082. <https://doi.org/10.1093/bib/bbad082>
41. Peng L, Liu X, Yang L. et al. BINDTI: a bi-directional intention network for drug-target interaction identification based on attention mechanisms. *IEEE J Biomed Health Inform* 2025;**29**: 1602–12. <https://doi.org/10.1109/JBHI.2024.3492806>
42. Qian Y, Li X, Jian W. et al. MCL-DTI: using drug multi-modal information and bi-directional cross-attention learning method for predicting drug-target interaction. *BMC Bioinformatics* 2023;**24**: 323. <https://doi.org/10.1186/s12859-023-05447-1>
43. Huang L, Lin J, Liu R. et al. CoaDTI: multi-modal co-attention based framework for drug-target interaction annotation. *Brief Bioinform* 2022;**23**:bbac446. <https://doi.org/10.1093/bib/bbac446>
44. Jia X, Sun X, Wang K. et al. DRGCL: drug repositioning via semantic-enriched graph contrastive learning. *IEEE J Biomed Health Inform* 2024;**29**:1656–67. <https://doi.org/10.1109/JBHI.2024.3372527>
45. Yansen S, Zhiyang H, Wang F. et al. AMGDTI: drug-target interaction prediction based on adaptive meta-graph learning in heterogeneous network. *Brief Bioinform* 2024;**25**: bbad474.