

SCOPE-DTI: 基于深度学习的药物靶点相互作用预测中用于提升实际可用性的半归纳数据集构建与框架优化

Yigang Chen^{1, 2, 5, †}, Xiang Ji^{1, 2, †}, Ziyue Zhang^{1, 2, †}, Yuming Zhou¹, Yang-Chi-Dung Lin^{1, 2, 3, 5}, Hsi-Yuan Huang^{1, 2, 3}, Tao Zhang⁵, Yi Lai^{1, 2}, Ke Chen^{1, 2}, Chang Su¹, Xingqiao Lin¹, Zihao Zhu^{1, 2}, Yanggyi Zhang¹, Kangping Wei¹, Jiehui Fu¹, Yixian Huang^{1, 2}, Shidong Cui^{1, 2}, Shih-Chung Yen^{1, 2}, Ariel Warshel⁶, and Hsien-Da Huang^{1, 2, 3, 4, 5, *}

¹中国广东省深圳市龙岗区香港中文大学（深圳）医学院，邮编：518172，中国

²香港中文大学（深圳）医学院沃氏计算生物学研究所，广东省深圳市龙岗区深圳 518172，中国

³广东省数字生物学与药物开发重点实验室，香港中文大学（深圳），广东省深圳市龙岗区，深圳 518172，中国

⁴中国医学科学院北京协和医学院北京协和医院内分泌科，国家卫生健康委员会内分泌重点实验室，北京 100730，中华人民共和国

⁵更好之道集团 - 香港中文大学（深圳）沃什尔联合实验室（皮肤健康与活性分子创新），中国广东省深圳市龙岗区，邮编 518172

⁶美国加利福尼亚州洛杉矶市南加州大学化学系，邮编 90089-1062 † 这些作者对本工作贡献相同。

*corresponding 作者：黄先达 (huanghsienda@cuhk.edu.cn)

摘要

基于深度学习的药物靶点相互作用（DTI）预测方法已展现出强大的性能；然而，由于数据多样性有限以及建模复杂性，其在实际应用中的适用性仍受到限制。为解决这些挑战，我们提出了 SCOPE-DTI，这是一个将大规模、平衡的半归纳式人类 DTI 数据集与先进的深度学习建模相结合的统一框架。SCOPE 数据集由 13 个公共库构建而成，其数据量相较于人类数据集等常见基准数据集扩大了多达 100 倍。SCOPE 模型整合了三维蛋白质和化合物表示、图神经网络以及双线性注意力机制，能够有效捕捉跨领域相互作用模式，在各种 DTI 预测任务中显著优于现有最先进的方法。此外，SCOPE-DTI 还提供了一个用户友好的界面和数据库。我们通过实验鉴定人参皂苷 Rh1 的抗癌靶点进一步验证了其有效性。通过提供全面的数据、先进的建模和易用的工具，SCOPE-DTI 加速了药物发现研究。

介绍

识别药物与靶点的相互作用（DTIs）对于药物研发、药物再利用、毒性预测以及提高临床试验的成功率至关重要¹⁻⁴。数十年来，实验方法一直是 DTI 识别的主导手段，因其具有高准确性和可靠性^{5,6}。然而，其高昂的成本和漫长的时间需求限制了其可扩展性，尤其是在考虑到巨大的化学和生物搜索空间的情况下⁷。

大量实验数据集的积累推动了数据驱动计算方法的发展。基于机器学习的方法利用这些大规模数据集来学习和概括相互作用模式，从而能够快速且经济高效地预测新的药物-靶点相互作用（DTIs）。这些计算模型能够提供高效的预测，引导实验验证朝着最有前景的候选相互作用方向进行，从而加速药物研发并显著降低相关成本。

深度学习的最新进展极大地推动了药物-靶点相互作用（DTI）预测的计算能力。蛋白质化学计量学（PCM）是一种广泛使用的计算框架，它将药物和靶点表示为特征向量，通过监督分类来预测药物-靶点相互作用¹¹。分子和蛋白质的嵌入方法迅速发展，从最初基于一维卷积神经网络的方法^{12,13}，转向基于转换器的模型，如 BERT^{7,14}，随后又转向图模型。

神经网络 (GNNs)^{15,16} 以及三维空间嵌入^{17,18}。与此同时, 模型架构也从简单的多层感知机 (MLPs) 发展到诸如交互图¹⁹ 和双线性注意力网络 (BANs)¹⁵ 这样的交互机制。这些创新使得最先进的模型在包括 BindingDB^{20,21}、人类²² 以及 KIBA 数据集²³ 在内的标准基准测试中取得了显著的性能提升。

然而, 在实际应用中使用这些模型仍存在重大挑战。在实际的药物研发应用中, 准确预测新型化合物与可成药靶点之间的相互作用至关重要。因此, 模型必须展现出即使在超出其训练数据范围的情况下也能实现可靠预测性能的能力。Chatterjee 等人将药物-靶点相互作用 (DTI) 预测分为三种不同的场景: 转导、半归纳和归纳。在归纳场景中, 训练集中既没有药物也没有蛋白质, 这对于新型 DTI 的发现至关重要, 但仍然极具挑战性。目前最先进的模型在归纳条件下仅能达到中等预测准确率, AUROC 通常低于 0.7, 相关系数低于 0.515¹⁷, 这限制了它们的实际应用价值。相反, 转导场景中, 训练集中既有药物也有蛋白质, 但它们之间的相互作用未知, 这种情况下模型性能较高, 但往往因过拟合和数据集偏差而受到影响^{21,25}, 从而限制了其在实际任务中的泛化能力。

相比之下, 半归纳场景——尤其是预测针对已知蛋白质的新药相互作用——与纯归纳或转导方法相比具有显著潜力^{17,24}。尽管当前模型在这种场景中表现良好, 但其成功仍受限于可用数据的规模和多样性。扩大并整合现有数据集以涵盖更多可成药靶点, 能够大幅提高预测的准确性以及在实际中的适用性, 从而彰显半归纳方法的实际价值。

为了克服这些局限性, 我们提出了 SCOPE-DTI (用于增强基于深度学习的药物靶点相互作用预测实用性的半归纳数据集构建和框架优化), 这是一个旨在提升药物靶点相互作用预测模型实用性的统一框架。据我们所知, 我们构建了目前最大的半归纳、平衡良好且以人类为中心的蛋白质靶点相互作用数据集, 整合了来自 13 个公共存储库的数据, 与标准基准相比, 将可用的训练数据量扩大了 20 到 100 倍。利用该数据集, SCOPE 模型结合了三维结构嵌入、图神经网络和双线性注意力机制, 在各种预测任务中均取得了优于现有最先进方法的预测性能。此外, 我们还开发了一个用户友好的网络界面和可搜索的数据库, 以方便访问和使用。通过实验验证人参皂苷 Rh1 的新型抗癌靶点, 进一步证明了 SCOPE-DTI 的实际有效性, 突显了该模型在现实世界中的适用性。

总之, 我们的贡献在于: (1) 构建了用于半归纳式药物-靶点相互作用预测的最大且平衡良好的数据集; (2) 优化了预测框架以提升性能; (3) 开发了用户友好的网络界面, 方便访问数据集和使用模型; (4) 识别并验证了人参皂苷 Rh1 的抗癌靶点, 展示了其在药物发现中的实际应用价值。

结果

SCOPE 数据集开发

我们的研究旨在半归纳框架内预测新型化合物的药物靶点相互作用 (DTIs), 解决的关键问题是: 对于任何一种新型活性化合物, 如何准确识别其在全面的可成药蛋白质集合中的结合靶点? 为应对这一挑战, 我们构建了一个大规模、高质量的人类聚焦的药物靶点相互作用数据集。

如图 1A 所示, 我们汇总并整理了来自 13 个主要药物靶点相互作用 (DTI) 数据库的数据, 整合了来自超过 20 个来源的信息, 包括引用的数据集 (补充表 1)。每个数据集条目包含一种蛋白质、一种化合物和一个相互作用标签。蛋白质使用 UniProt 标识符进行注释, 仅保留人类蛋白质, 并根据 IUPHAR 数据库将其分类为药理学家族 (例如, G 蛋白偶联受体、激酶)。为了能够进行结构建模, 我们使用 AlphaFold2 生成了蛋白质的 3D 结构。化合物使用 PubChem 和 ChEMBL 的标识符进行注释, 并使用 RDKit 构建其 3D 结构, 然后用默克分子力场 (MMFF) 进行优化。相互作用标签是根据从 PubChem 生物活性数据中得出的标准化测量特定的截止值系统地分配的, 将相互作用分类为正 (1) 或负 (0) (补充图 1; 补充表 2)。有关标签方法的更多详细信息, 请参阅补充说明。

我们意识到目标水平的类别不平衡 (即某些蛋白质主要表现出某一类的相互作用) 可能会使半归纳预测产生偏差, 因此我们实施了一种过滤方法 (图 1B)。对于相互作用中某一类占比超过 75% 的蛋白质, 我们采用分层抽样随机移除相互作用, 使各类别比例保持在 50% 至 75% 之间。对于相互作用数量不足或类别分布极度不平衡的蛋白质则完全排除, 以保持数据集的完整性。图 1C 显示, 这种过滤方法显著减轻了不平衡现象, 确保了目标间相互作用标签的分布更加均衡 (补充图 2 提供了更多细节)。




图 1. SCOPE 数据集构建流程及数据特征概述。(A) 用于构建 SCOPE 数据集的数据整合与预处理步骤示意图。(B) 缓解目标层面不平衡的策略：对于某一类占主导地位的蛋白质，我们随机移除相互作用以实现平衡；在极端情况下，我们舍弃该蛋白质的所有相互作用。(C) 数据过滤的效果。红色和绿色分布分别代表过滤前后的数据集。(D) SCOPE 与先前数据集在化合物、靶点和相互作用数量方面的数据量比较。

最后，我们对所得的 SCOPE 数据集与广泛使用的基准数据集进行了定量比较（图 1D），结果显示其规模大幅增加——相互作用的数量增加了 20 至 100 倍，同时包含的蛋白质和化合物也显著增多。详细的数据集统计信息总结在补充表 3 中。总体而言，据我们所知，SCOPE 是目前可用的最大、最平衡的半归纳式人类药物 - 靶点相互作用数据集，为开发和验证新型药物 - 靶点相互作用的预测模型提供了坚实的基础。

SCOPE 框架

图 2 提供了所提出的用于预测药物 - 靶点相互作用的 SCOPE 框架的示意图。该框架首先将来自 SCOPE 数据集的药物分子和靶点蛋白转换为各自的三维（3D）构象，药物分子的构象通过 RDKit 生成，而蛋白质的构象则通过 AlphaFold2 生成。为了有效地捕捉蛋白质和化合物的复杂结构特征，分别使用异构图神经网络（HGNNs）^{33,34} 和几何向量感知器（GVPs）^{17,35} 对它们的 3D 结构进行编码。蛋白质编码模块同时编码了残基之间的序列关系以及通过基于残基坐标的半径图捕获的空间邻域信息。化合物编码则结合了 DGL-LifeSci 编码方案³⁶ 定义的原子特定特征（原子类型、电荷、杂化状态）以及代表其 3D 结构信息的空间坐标。这些编码方法的更多细节见补充表 4。

为了弥补小分子与大蛋白质之间的规模差异，通过全局池化聚合原子级特征，生成固定大小的分子表示，以供后续处理。这些池化的分子向量随后与编码的蛋白质表示相结合，并输入到双向注意力网络（BAN）中。该网络包含一个双线性注意力层，后面跟着一个双线性池化层，使模型能够捕捉药物与目标蛋白质残基之间的跨域相互作用。最终，组合后的表示通过多层感知机（MLP）分类器，计算出最终的预测分数，该分数代表药物与靶点相互作用的概率。




图 2.用于药物-靶点相互作用预测的 SCOPE 模型示意图。SCOPE 模型整合了蛋白质和化合物的三维结构信息来预测药物与靶点的相互作用。为了捕捉复杂的结构特征，蛋白质的三维结构和分子图通过异构图神经网络（HGNNs）和几何向量感知器（GVPs）结合全局池化进行编码。这些编码后的表示随后通过双线性注意力网络进行处理，该网络由双线性注意力层和双线性池化层组成，以生成一个联合表示，该表示模拟了药物与靶点蛋白之间的局部相互作用。最终的预测分数由一个全连接分类层计算得出，表示相互作用的可能性。

评估策略和指标

我们使用三个公开可用的数据集——BindingDB^{20, 21}、human22 和 KIBA23 以及我们专有的 SCOPE 数据集来评估我们模型的性能。为了在半归纳框架内模拟对新化合物的药物靶点相互作用（DTI）预测，我们将每个数据集随机划分，按照 7:1:2 的比例将化合物分配到训练集、验证集和测试集，同时确保与这些化合物相关的所有相互作用都包含在相应的集合中。重要的是，我们确保验证集和测试集中的所有蛋白质也在训练集中有所体现，从而保持半归纳学习设置的完整性，即模型在已知蛋白质上进行训练，但在新化合物上进行评估。有关数据集划分的详细信息，请参阅补充说明。

为了评估我们的过滤技术对模型性能的影响，我们使用所有数据集的原始版本和过滤版本进行了实验。这种对比使我们能够评估缓解目标层级交互不平衡对预测准确率的影响。

我们采用受试者工作特征曲线下面积（AUROC）和精确率召回率曲线下面积（AUPRC）作为评估分类性能的主要指标。此外，我们还报告了在对应于最佳 F1 分数的阈值下的准确率、灵敏度和特异度。为确保稳健性，对于每个数据集划分，我们至少进行了五次独立运行，每次运行使用不同的随机种子。在验证集上获得最高 AUROC 的模型被选中用于在测试集上的最终评估，然后记录性能指标。

性能比较

我们使用半归纳的新化合物拆分策略（图 3A），在应用偏差过滤技术前后，将 SCOPE 模型与五个基线模型在八个数据集上进行了评估。基线模型包括经典机器学习模型支持向量机（SVM）³⁷、传统深度学习模型多层感知机（MLP）³⁸ 以及三个用于药物靶点相互作用（DTI）预测的最新深度学习模型：MolTrans19、TransformerCPI25 和 DrugBAN15。在所有数据集和条件下，SCOPE 始终表现出最高的性能，比排名第二的 DrugBAN 模型高出 1% 至 3%，并且相较于其余模型有显著的性能提升（图 3C）。值得注意的是，




图 3. 在半归纳数据划分策略下，SCOPE 模型表现优于基准模型。（A）半归纳划分策略示意图：药物在验证集和测试集中保持未见状态，而靶点在训练数据集中保持可见状态。（B）八个数据集上四种模型的 AUPRC 性能，数据集过滤前后对比。（C）八个过滤后的数据集上 SCOPE 与五个基准模型的平均 AUROC 性能。每个实验至少进行了五次，图中展示的是平均值。SCOPE 在每个数据集上均持续优于所有基准模型。

如补充表 5 所示，SCOPE 在准确率、灵敏度和特异性方面始终优于所有基准模型。重要的是，在经过筛选的数据集上，SCOPE 仍明显优于大多数模型，进一步证明了该方法的稳健性和可靠性。

图 3B 表明，原始数据集存在显著偏差，这使得某些模型能够实现人为夸大的性能。这种偏差在较小的数据集（如 Human 和 BindingDB）中尤为明显，其原因在于具有有限相互作用的蛋白质主要属于单一相互作用类别，从而使模型能够主要基于蛋白质的身份来预测结果——这在实际药物发现中是不切实际的。我们的过滤方法有效地减轻了这种偏差，生成了更准确反映现实情况的数据集（见图 1B）。

在对过滤后的数据集进行评估时，包括支持向量机（SVM）、MolTrans、TransformerCPI 和深度多层感知机（MLP）在内的多个基准模型的性能出现了大幅下降（AUROC 和 AUPRC 下降了 20% 至 30%），这凸显了过滤策略的有效性。特别是 TransformerCPI，它对原始 BindingDB、Human 以及整体 SCOPE 数据集中存在的偏差特征表现出明显的依赖性。相比之下，DrugBAN 和 SCOPE 在过滤后仅出现轻微的性能下降，这表明它们具有更强的稳健性和适应现实平衡数据集的优越能力。这些性能趋势的一致性进一步证实了 DrugBAN 和 SCOPE 架构在各种实际数据条件下的强大适应能力。

图 3C 突出展示了 DrugBAN 和 SCOPE 在大规模数据集上的稳健且稳定的性能。具体而言，SCOPE 总数据集——无论是过滤前还是过滤后——包含的相互作用数量几乎是 Human 和 BindingDB 数据集总和的 100 倍。此外，SCOPE 数据集中针对激酶的特定子集大约是针对特定家族的 KIBA 数据集的 20 倍。这种数据集规模上的显著差异为评估每个模型适应大规模数据的能力提供了清晰的依据。

在基准模型中，它们处理大规模数据的能力存在明显差异。支持向量机（SVM）和 MolTrans 在扩展性方面表现不佳；在处理大规模数据时，它们的计算设计常常超出标准硬件的限制。虽然深度多层感知机（MLP）能够适应较大的数据集，但其性能并未得到显著提升，有时甚至出现准确率下降的情况。相比之下，TransformerCPI、DrugBAN 和 SCOPE 展现出了良好的扩展性，并在处理大规模数据时保持了稳定的性能。值得注意的是，SCOPE 始终表现最佳，其 AUROC 指标比 DrugBAN 高出 0.02 至 0.03，这表明其在大规模数据集上的适应性和预测能力更胜一筹。

总之，SCOPE 模型所展现的卓越性能突显了数据驱动表示学习的显著优势，尤其是将蛋白质和化合物的 3D 结构特征进行整合。通过其半归纳框架有效捕捉复杂的成对相互作用模式，SCOPE 在药物靶点相互作用预测任务中实现了更高的准确性和更强的稳健性。利用 BAN 集成高维、上下文敏感的分子特征表示，该模型能够揭示传统低维描述符或预定义特征集无法检测到的复杂分子相互作用。此外，SCOPE 的新型相互作用模块尤其增强了其在半归纳预测场景中的预测能力，巩固了其作为计算药物发现中强大且广泛应用工具的潜力。

消融实验

表 1. 在过滤后的 SCOPE 数据集上进行的消融研究（基于五次随机运行的平均值）。前三个模型评估化合物嵌入设计，接下来的两个模型评估蛋白质嵌入设计。后续模型展示了双线性注意力网络（BAN）层的影响。最后一个模型整合了 SCOPE 设计的所有组件。（最佳，次佳）

蛋白质编码	复合编码	脊梁骨	AUROC	AUPRC	F1
三维图 HGNN	1D 指纹	封禁+多层感知机	0.829±0.012	0.841±0.015	0.771±0.019
三维图 HGNN	二维图形	封禁+多层感知机	0.859±0.015	0.873±0.015	0.785±0.016
三维图 HGNN	3D 图 GVP 无池化操作	封禁+多层感知机	0.860±0.014	0.874±0.014	0.786±0.015
1D 独热编码	3D 图形 GVP	封禁+多层感知机	0.827±0.016	0.846±0.017	0.758±0.012
一维卷积神经网络	3D 图形 GVP	封禁+多层感知机	0.873±0.008	0.871±0.007	0.806±0.010
三维图 HGNN	3D 图形 GVP	多层感知机	0.859±0.024	0.857±0.025	0.789±0.026
三维图 HGNN	3D 图形 GVP	封禁+多层感知机	0.875±0.014	0.888±0.013	0.803±0.016

我们进行了消融研究，以评估蛋白质编码、化合物编码和骨架设计对 SCOPE 模型整体性能的各自贡献。表 1 总结了关键发现，突出了每个模块在模型有效性中所起的关键作用，详细的实验结果见补充表 7。

为了评估使用 3D 图形 GVP 进行化合物编码的影响，我们构建了 SCOPE 模型的三个变体，每个变体采用不同的化合物编码方法：1D 指纹³¹、2D 图形¹⁵以及不带全局池化的 3D 图形 GVP，其中最大原子数设定为 300。结果表明，增加化合物的表示维度显著提升了模型性能。值得注意的是，引入池化分子编码使性能提高了超过 1%，这突显了池化技术在增强分子表示中的关键作用。

对于蛋白质编码，我们将 SCOPE 模型中的蛋白质编码块替换成两种替代方法：1D 独热编码和 1D CNN¹⁵。结果表明，基于 1D CNN 的编码在 F1 分数方面表现与 3D 设计相当，甚至更优。然而，在 AUROC 和 AUPRC 方面，3D 图形 HGNN 架构仍优于 1D CNN 方法，这表明 3D 设计捕获了对模型性能至关重要的额外结构信息。

最后，我们研究了骨干网络中 BAN 层的影响。令人惊讶的是，移除 BAN 层导致性能大幅下降，使其与 DrugBAN 的表现相当，DrugBAN 采用 1D CNN 和 2D 图形对蛋白质和化合物进行编码。这突显了编码策略和骨干网络设计对于实现最佳模型性能的重要性。

总之，消融实验证实了 SCOPE 模型中每个模块的关键作用，验证了其整体设计的重要性以及在提升性能方面所发挥的作用。

网络服务器和数据库

为了提高可访问性和易用性，我们为 SCOPE 框架开发了一个网络服务器和数据库，可通过 <https://awi.cuhk.edu.cn/SCOPE/> 访问。该平台允许用户输入化合物的 SMILES 字符串来执行搜索或预测任务。在搜索模式下，服务器会识别并返回 SCOPE 数据集中与输入分子结构相似度大于 0.9 的所有化合物，相似度计算使用 RDKit 完成。在预测模式下，输入分子将与 SCOPE 库中的所有蛋白质进行配对，提供具有半归纳准确性的相互作用预测。此外，完整的 SCOPE 数据集可直接从网站下载。有关网络开发过程和用户指南的详细信息，请参阅补充说明和补充图 3。




图 4. 模型的可解释性分析。(A) 预测性能与每种蛋白质已知相互作用数量之间的关系。随着已知相互作用数量的增加，准确率稳定在 0.8 - 0.9 左右，而已知相互作用较少时，准确性变化较大。(B) 四种代表性蛋白质（两种预测性能稳健的蛋白质 P46095 和 P28482 以及两种准确率较低的蛋白质 O43826 和 P42224）的 BAN 注意力向量的 UMAP-OPTICS 聚类。富含相互作用数据的蛋白质（P46095 和 P28482）表现出明显的聚类，表明模型捕捉到了共同的结合特征。相比之下，数据有限的蛋白质（O43826 和 P42224）则没有明显的聚类。(C) 与 P46095 结合的配体的对接分析，突出了不同配体簇之间共享和独特的相互作用残基。独特的关键残基用蓝色和黄色标记，普遍重要的残基用紫色显示，表明存在全局和簇特异性的结合决定因素。(D) 预测准确率相对较低的蛋白质的分析。尽管 O43826 的准确率约为 0.7，但其已知的五个配体尽管作用于相同的口袋，却呈现出高度不同的构象，这阻碍了形成明确的共识。而对于 P42224（准确率低于 0.6）来说，已知的少量配体不仅结合取向各异，而且占据不同的口袋，这对模型的预测能力构成了挑战。

模型可解释性

如图 4A 所示，随着记录的蛋白质相互作用数量的增加，预测准确性逐步提高，这突显了充足药物 - 靶点相互作用 (DTI) 数据对于稳健模型训练的关键重要性。已知相互作用有限的蛋白质在预测性能方面表现出相当大的差异，而随着相互作用数据的增加，准确性稳定在约 0.8 - 0.9 之间。

为了进一步探究这种关系，我们对四种具有代表性的蛋白质进行了研究（图 4B）。蛋白质 O43826 和 P42224 由于已知相互作用较少，预测准确性较低。相比之下，蛋白质 P46095 和 P28482 由于数据集更丰富，预测准确性始终较高。我们使用 UMAP³⁹ 进行降维，并使用 OPTICS⁴⁰ 进行聚类，对来自 BAN 注意力模块的相互作用嵌入进行了分析。具有大量相互作用数据的蛋白质（P46095 和 P28482）显示出清晰、明显的聚类，表明该模型能够有效地捕捉到有意义的结合特征。相反，相互作用数据较少的 O43826 和 P42224 蛋白质则没有明显的聚类或聚类不清晰，这反映出识别一致结合模式存在困难。

对 GPCR 蛋白 P46095 的对接结果进行更深入的分析（图 4C）表明，模型识别出的簇群对应于典型结合口袋内化学性质不同的结合模式。具体而言，簇群 1、2 和 4 中的相互作用通常涉及 79、128、132、145、219、220、312 和 315 号残基，而簇群 1 的独特残基为 295 和 304，簇群 2 的独特残基为 141。这些发现证实了我们的模型能够捕捉到细微且与化学性质相关的特征，从而决定配体的特异性。

对预测准确率相对较低的蛋白质（图 4D）进行进一步研究发现，其情况更为复杂。蛋白质 O43826 尽管准确率约为 0.7，但其已知的五种配体在同一个口袋内却采用了显著不同的结合构象，这使得识别一致的模式变得困难。同样，蛋白质 P42224（准确率低于 0.6）的配体结合方式多样，且结合在不同的口袋内，这给建模带来了很大的挑战。

总的来说，这些分析强调了充足且多样化的相互作用数据对于准确预测药物 - 靶点相互作用的必要性。它们还展示了我们模型的解释能力，突出了其能够识别对于理解分子相互作用至关重要的全局和配体特异性结合特征。有关更多方法学细节和附加分析，请参阅补充说明。

利用 SCOPE-DTI 技术高效发现人参皂苷 Rh1 抗癌活性的作用靶点

为了展示 SCOPE 框架的实际适用性，我们选取了一种具有未知作用靶点的活性化合物，旨在利用 SCOPE 计算预测其分子靶点，并通过实验验证这些预测结果。人参皂苷是一类在人参属植物中大量存在的生物活性化合物，因其多样的药理作用而在传统和现代医学中得到广泛应用，惠及全球数百万人⁴¹。其中，人参皂苷 Rh1 被认为是人体内的主要终末代谢产物^{42,43}。尽管 Rh1 在多种情况下已显示出抗癌活性，但其对肝癌的潜在作用尚未得到探索，其具体分子靶点也尚未明确，这限制了其进一步开发和治疗应用^{44,45}。在本研究中，我们首先使用 CCK-8 检测法评估了 Rh1 对 HepG2 细胞的细胞毒性作用。如图 5A 和补充表 8 所示，Rh1 的 IC₁₀、IC₃₀ 和 IC₅₀ 值分别为 16.55 μM、24.86 μM 和 32.04 μM，这表明 Rh1 显著抑制 HepG2 细胞的增殖。

在确定了其抑制作用后，我们接下来利用 SCOPE 框架预测了 Rh1 在 HepG2 细胞中的潜在抗癌靶点。如图 5B 所示，Rh1 计算上与 SCOPE 数据库中的所有候选靶点进行了配对，并使用了多个采用不同随机参数训练的模型对这些靶点进行排序。在对所有模型的预测分数取平均值后，我们提取了排名前十的蛋白质。为了优化结果，我们应用了两个筛选标准：（1）排除根据先前研究⁴⁶ 没有抗癌相关性的靶点；（2）去除根据人类蛋白质图谱（HPA）⁴⁷ 不在 HepG2 细胞中表达的靶点。这一优化过程确定了三个高置信度靶点：AMPK、NF-κB p65 和 AKR1B10，这些靶点被选中进行进一步的实验验证。

为了实验性地验证这些计算预测，我们采用了细胞热位移分析（CETSA）结合蛋白质印迹法（CETSA-WB）分析。将 HepG2 细胞用 Rh1 或 DMSO 处理，并暴露于从 40 °C 到 67 °C 的温度梯度中。如图 5C 所示，与对照条件相比，Rh1 处理显著增强了 AKR1B10 的热稳定性，同时也对 AMPK 和 NF-κB p65 产生了适度的稳定作用。为了更深入地了解这些相互作用的分子基础，我们进行了分子对接模拟（图 5D）。对接结果表明，Rh1 占据了 AKR1B10 的理想结合口袋，可能阻碍其辅因子（如 NADPH）的结合，从而损害其酶活性。此外，Rh1 与 AMPK 的 AMP 结合位点的相互作用可能会破坏 AMP 介导的调节，从而影响 AMPK 的激活和下游信号传导。另外，Rh1 与 NF-κB p65 的 DNA 结合界面的结合可能会阻碍 DNA 关联，从而降低这一关键调节因子的转录活性。

在这些目标中，AKR1B10 在 CETSA-WB 检测中表现出最显著的稳定作用，这促使我们进一步利用表面等离子共振（SPR）技术研究 Rh1 与 AKR1B10 之间的直接结合情况。如图 5E 所示，SPR 分析证实了 Rh1 与 AKR1B10 之间存在直接的高亲和力结合，其解离平衡常数（K_D）为 1.158 × 10⁻⁸ M。综上所述，这些结果表明 AKR1B10 是 Rh1 的关键分子靶点，阐明了其在 HepG2 细胞中观察到的抗癌作用中的机制，并进一步证实了 SCOPE 框架在靶点识别方面的实用性和可及性。




图 5. 人参皂苷 Rh1 在 HepG2 细胞中抗肿瘤靶点的实验验证 (SCOPE-DTI 预测)。(A) 人参皂苷 Rh1 对 HepG2 细胞的剂量依赖性细胞毒性。使用 CCK-8 检测法评估 24 小时处理后的细胞活力。数据以未处理对照组为基准进行标准化, 并以平均值 $\pm$ 标准差表示。(B) HepG2 细胞中人参皂苷 Rh1 的靶点鉴定, 基于表达水平和功能相关性, 突出 AMPK、NF- κ B p65 和 AKR1B10 作为实验验证的候选蛋白。(C) 利用细胞热位移分析 (CETSA) 结合 Western blot 分析验证 Rh1 与 AMPK、NF- κ B p65 和 AKR1B10 的结合。将 Rh1 或 DMSO 处理的 HepG2 细胞的裂解物置于不同温度梯度下, 分析每个靶蛋白的热稳定性。红色星号表示观察到药物处理组与对照组之间差异的初始温度。(D) 基于分子对接模拟预测的 Rh1 在靶蛋白内的结合构象。放大图展示了支持 Rh1 与预测靶点亲和力的结合口袋和关键相互作用。(E) Rh1 与 AKR1B10 结合的分子对接模拟。通过测定解离平衡常数 (KD) 来量化 Rh1 与 AKR1B10 之间的结合亲和力。

结论

在本研究中, 我们推出了 SCOPE-DTI 这一全新框架, 旨在提升基于深度学习的药物 - 靶点相互作用 (DTI) 预测的实际应用价值。通过构建迄今为止规模最大的半归纳式人类 DTI 数据集, 我们为该领域的进一步研究奠定了坚实的基础。我们的方法采用了靶点层面的数据平衡策略, 确保在实际应用条件下对模型性能进行更可靠的评估。借助蛋白质和化合物的三维结构表示, 并结合基于注意力机制的模型架构, SCOPE-DTI 在多个基准数据集上展现出了卓越的预测性能。此外, 我们还验证了其结构可解释性, 突显了其在提供药物 - 靶点相互作用机制见解方面的潜力。除了这些技术进步, SCOPE-DTI 的实际应用性还通过实验鉴定人参皂苷 Rh1 的抗癌靶点得到了体现。为了促进更广泛的采用, 我们还开发了一个用户友好的网络界面, 为药物发现研究提供了对数据库和模型的便捷访问。

尽管取得了这些成就, 但仍有一些领域有待未来改进。我们的消融研究表明, 纳入 3D 化合物结构比整合 3D 蛋白质结构能带来更显著的性能提升。这种差异可能反映了 AlphaFold2 在生成高精度蛋白质表示方面目前存在的局限性。未来的迭代版本, 比如 AlphaFold3 或更精细的编码技术, 可能会提供更准确的蛋白质结构预测, 从而实现更精确的药物靶点相互作用预测。此外, 虽然双线性注意力机制能够有效地捕捉残基层面的相互作用模式, 但我们的案例分析表明, 其可解释性目前主要在聚类层面有意义, 而非在单个残基的特定层面, 因为注意力向量并不总是保持一致。

直接根据具体案例中观察到的相互作用进行处理。纳入更精细的数据，例如详细的口袋级结合信息，并结合有针对性的模型改进，能够进一步提高该框架的可解释性和准确性。

方法

SCOPE 数据集开发

我们开发了 SCOPE 数据集，这是一个全面、多源且标注详尽的资源，专为药物靶点相互作用（DTI）预测而设计。该数据集整合了来自众多公共来源的 DTI 数据，包括 ChEMBL activity30、PubChem activity29、DrugBank48、BindingDB20、DrugCentral49、TTD50、Pharos51、PROMISCUOUS52、GtoPdb27、Human22、BioSNAP53、KIBA23 和 DAVIS54。此外，这些来源还涵盖了 20 多个参考数据源。然而，原始数据存在一些挑战：（1）缺乏统一的标注，（2）尺度和药理学评估指标不一，（3）数据质量参差不齐，可能存在错误条目。为解决这些问题，我们进行了全面的数据清理和标准化处理。

蛋白质和化合物注释。我们通过 Uniprot 数据库统一了蛋白质注释，并筛选了所有人类蛋白质，重点关注可与小分子相互作用的药物靶点。使用 IUPHAR 数据库将蛋白质分类为药理学靶点家族（例如，G 蛋白偶联受体（GPCRs）、激酶）。为提供结构见解，我们使用 AlphaFold2 为所有蛋白质生成了三维（3D）结构。使用 PubChem 和 ChEMBL 数据库中的标识符对化合物进行注释。我们使用 RDKit 生成化合物的 3D 结构，并使用默克分子力场（MMFF）优化其构象。

相互作用标签统一。为了协调不同数据源中不同的尺度和药理学评估指标，我们根据 PubChem 活性分布为相互作用分配标签，将其分为正向（1）或负向（0）。具体的分类标准详见补充说明。这种方法使我们能够将来自不同来源的实验信息统一为一致的二元分类。

多源数据整合。为了进一步提高数据质量，我们整合了多个数据源，仅保留所有数据源中均被一致标记为正向的交互数据。如果任一数据源将某交互标记为负向，那么在我们的数据集中就将其视为负向交互。这种保守的方法最大限度地提高了正向样本的可靠性。

缓解目标层面的相互作用不平衡。为解决目标层面的相互作用不平衡问题——即某个蛋白质 p_i 与一类化合物的相互作用数量不成比例——我们实施了一种数据集过滤策略。对于每个蛋白质 p_i ，我们考虑其相互作用集 $I(p_i) = \{(p_i, c_j, l_{ij})\}$, where c_j 表示一种化合物， $l_{ij} \in \{0,1\}$ 表示相互作用标签。通过两个计数器来量化不平衡程度： N_0 (negative (负相互作用)) 和 N_1 (正相互作用) 在 $I(p_i)$ 中的数量。

如果 p_i 中超过 75% 的交互属于同一类别，我们则采用分层随机抽样来获取一个子集 $I'(p_i)$ ，使其满足：

$$\frac{\min(N'_0, N'_1)}{N'_0 + N'_1} \geq 0.25, \quad (1)$$

其中 N'_0 and N'_1 分别表示在 $I'(p_i)$ 中负向和正向相互作用的数量。这确保了少数类别的相互作用至少占 p_i 中相互作用的 25%，从而实现类别比例在 25% 到 75% 之间。过滤后相互作用数量不足的蛋白质被排除，以保持数据质量。

数据清理效果的可视化。为了展示我们的数据清理和平衡流程所产生的影响，我们分析了每种蛋白质在过滤前后的相互作用比率分布情况。对于每种蛋白质 p_i ，我们计算了正向相互作用的比率：

$$R(p_i) = \frac{N_1}{N_0 + N_1}, \quad (2)$$

其中， N_0 和 N_1 分别是蛋白质 p_i 的负向和正向相互作用的数量。我们根据 $R(p_i)$ 将蛋白质分组，组距为指定长度（例如 0.02），并绘制了每个区间内的蛋白质数量。这种可视化方式突出了经过筛选后相互作用严重失衡的蛋白质数量的减少。

数据集统计与比较分析。我们通过计算独特化合物、靶点以及总相互作用的数量对 SCOPE 数据集进行了量化。与现有的数据集相比，无论是在过滤程序之前还是之后，我们的数据集所涵盖的化合物和相互作用的数量都显著更多。为了说明 SCOPE 的规模和全面性，我们生成了图表，将数据量与之前的各数据集进行了比较，突出了我们数据集在规模和多样性方面的优势。详细的统计信息和比较分析见补充说明。

SCOPE 框架架构

HGNN 对蛋白质结构的应用。蛋白质 $P_i \in \mathcal{P}$ 由 M 个氨基酸残基组成，可由其一级序列 $S_i = (v_1, v_2, \dots, v_M)$ 表示，其中每个残基 v_m 属于 20 种标准氨基酸类型之一。在物理化学环境中，这些序列会折叠成稳定的三维（3D）结构⁵⁵。为了同时捕捉序列和

(i) (i) (i) (i)

对于蛋白质 P_i 的结构信息，我们构建了一个残基级别的异质蛋白质图 $G_P = (V_P, E_P, R)$ ，其中 V_P 表示残基作为节点， $E_P^{(i)}$ 表示连接它们的边，而 R 指定边的类型。

在这项工作中，我们使用两种类型的边来表示残基之间的关系。顺序边连接在一级序列中相邻的残基，保留了氨基酸的自然顺序。半径边连接那些基于所有原子的几何中心计算出的空间欧几里得距离低于预定义阈值的残基 d_r 。这种方法确保了折叠蛋白质中的局部序列背景和空间邻近性都被编码。

为了对异质蛋白质图 $G_P = (V_P, E_P, R)$ 进行编码，我们采用了一种异质图神经网络（HGNN）³³。在第 l 层，每种边类型 $r \in R$ 都关联着一个权重矩阵 $W_r^{(l)}$ ，同时还存在一个共享权重矩阵 $W_h^{(l)}$ 。

用于组合的

来自不同边缘类型的聚合消息。

节点嵌入在 L 层中迭代更新。在第 l 层（其中 $1 \leq l \leq L$ ），每个残基 v_m 的嵌入计算方式如下：

$$h_m^{(l)} = \text{BN} \left(\text{ReLU} \left(W_h^{(l)} \cdot \sum_{r \in R} \sum_{v_n \in \mathcal{N}_r(m)} W_r^{(l)} h_n^{(l-1)} \right) \right), \quad (3)$$

(0)

其中 $h_m = x_m$ 表示残基 v_m 的初始输入特征，而 h_m 则是第 l 层的嵌入。邻居 $\mathcal{N}_r(m)$ 被定义为通过边类型 r 与 v_m 相连的残基。批量归一化函数 $\text{BN}(\cdot)$ 和修正线性单元

(l)

激活函数 $\text{ReLU}(\cdot)$ 用于稳定训练，而 $W_r \in \mathbb{R}^{d \times d}$ 和 $W_h \in \mathbb{R}^{d \times d}$ 是可学习的权重矩阵。这种公式化设计确保了图的异质性能够得到有效捕捉，将序列信息和结构信息整合到统一的表示中。

这种公式化表述确保了来自不同边类型的消息能够得到恰当的转换和聚合。

药物编码的 GVP。给定分子中原子的三维（3D）坐标，我们将分子结构表示为一个图 $G_d = (V_d, E_d)$ ，其中节点 V_d 对应于分子中的原子，边 E_d 定义在欧几里得距离小于 4.5 Å 的原子对之间。这种表示方法既捕捉了分子内的化学关系，也捕捉了其空间关系。

(0) (0), v (0), s

节点特征:对于每个原子 i ，我们构建一个节点特征 $h_i = (h_i, h_i)$ ，它由一个向量分量 (0), v 组成。

(0),
s

v (0),

h_i 和一个标量分量 h_i 。向量特征 $h_i = c_i \in \mathbb{R}^3$ 表示原子在空间中的三维坐标。标量特征 $h_i^{(0)}$, $s \in \mathbb{R}^{74}$ 是一个 74 维的整数向量，它用八种类型的信息描述原子：原子类型、原子度、隐式氢原子数、形式电荷、自由基电子数、原子杂化、总氢原子数以及该原子是否为芳香族原子³⁶。

边特征:对于每条边 $(i, j) \in E_d$ ，我们定义一个边特征 $e_{ji} = (ev_{ji}, es_{ji})$ 。向量特征 $ev_{ji} = \frac{c_j - c_i}{\|c_j - c_i\|} \in \mathbb{R}^3$ 是

c - c

从原子 i 指向原子 j 的单位向量。标量特征 $es_{ji} = \text{RBF}(\|c_j - c_i\|) \in \mathbb{R}^{16}$ 使用 16 个高斯径向基函数（RBF）对成对距离进行编码，这些函数的中心在 0 到 4.5 Å 之间均匀分布。

分子图神经网络:为了学习输入分子的表示形式，我们采用基于几何向量感知器（GVPs）的图神经网络³⁵。每个节点嵌入 h_i

由 (1), v, (l, s) 由向量和标量组成

组件。

在每一层 l ，节点嵌入通过以下方程进行更新：

$$h_i^{(l)} = h_i^{(l-1)} + \text{GVP} \left(h_i^{(l-1)}, \sum_{j \in \mathcal{N}(i)} \text{GVP}(h_j^{(l-1)}, e_{ji}) \right), \quad (4)$$

其中 $\mathcal{N}(i)$ 表示节点 i 的相邻节点集， $\text{GVP}(\cdot, \cdot)$ 表示一个 GVP 层，用于处理节点和边 (0)

该更新规则结合了相邻原子的特征以及来自边特征的几何信息，其中 $h_i = v_i$ 是节点 i 的初始特征。

(L)

经过 L 层消息传递后，我们为图中的所有节点获取最终的节点嵌入 h_i 。为了推导出整个分子的固定大小表示，我们对所有节点嵌入应用全局加和池化操作：

$$h_d = \sum_{i \in V_d} h_i^{(L)}, \quad (5)$$

其中 $h_d \in \mathbb{R}^d$ 是输入分子的学习表示。

成对交互学习。为了捕捉药物与蛋白质之间的成对局部交互作用，我们采用了一个双线性注意力网络模块，该模块包含两个关键层：一个用于计算成对注意力权重的双线性交互图，以及一个在交互图上进行双线性池化的层，以提取药物 - 蛋白质的联合表示。

给定药物的编码器隐藏表示 $H_d \in \mathbb{R}^{N \times D_d}$ 和蛋白质的编码器隐藏表示 $H_p \in \mathbb{R}^{M \times D_p}$ ，我们计算成对相互作用矩阵 $I \in \mathbb{R}^{N \times M}$ 如下：

$$I = (\sigma(H_d U) q^\top) \odot \sigma(H_p V)^\top, \quad (6)$$

其中， $U \in \mathbb{R}^{D_d \times K}$ 和 $V \in \mathbb{R}^{D_p \times K}$ 是可学习的权重矩阵， $q \in \mathbb{R}^K$ 是可学习的权重向量， $\sigma(\cdot)$ 是激活函数（例如，S 型函数）， $\odot$ 表示逐元素乘法（哈达玛积），上标 $(\cdot)^\top$ 表示矩阵转置。每个元素 I_{ij} 表示药物的第 (i) 个原子与蛋白质的第 (j) 个残基之间的相互作用得分。

为了便于直观理解，元素 I_{ij} 可以表示为：

$$I_{i,j} = q^\top \left(\sigma(U^\top h_d^i) \odot \sigma(V^\top h_p^j) \right), \quad (7)$$

其中， h_d 和 h_p 分别是第 i 个原子和第 j 个残基的嵌入向量。

然后通过双线性池化来计算联合表示 $f' \in \mathbb{R}^K$ ：

$$f' = \left(\sigma(H_d U)^\top I \sigma(H_p V) \right) \mathbf{1},$$

其中 $\mathbf{1} \in \mathbb{R}^M$ 是一个全 1 向量，用于对蛋白质残基进行求和。为了降低维度，我们应用求和池化：

$$f = \text{SumPool}(f', s), \quad (9)$$

从而得到最终的特征向量 $f \in \mathbb{R}^{K/s_0}$ 。

为了计算交互概率，我们将联合表示 f 输入到一个解码器中，该解码器由一个全连接层和一个后置的 S 型激活函数组成：

$$p = \sigma(W_o f + b_o), \quad (10)$$

其中 W_o 和 b_o 是可学习的权重参数。

最后，我们使用反向传播共同优化所有可学习的参数。训练目标是通过 L2 正则化来最小化交叉熵损失：

$$\mathcal{L} = - \sum_i \left[y_i \log p_i + (1 - y_i) \log(1 - p_i) \right] + \frac{\lambda}{2} \|\theta\|_2^2, \quad (11)$$

其中， θ 表示所有可学习参数的集合， y_i 是第 i 个药物 - 蛋白质对的真实标签， p_i 是预测概率， λ 是正则化超参数。总体而言，这种成对交互学习方法深受 DrugBAN15 的启发并对其进行了改编。

实验设置

数据集。我们在四个公开的药物靶点相互作用（DTI）数据集上评估了 SCOPE 模型和五个最先进的基线模型：BindingDB、KIBA、Human 以及我们新构建的 SCOPE 数据集。SCOPE 数据集包含了由 IUPHAR 注释的各种蛋白质家族，例如 G 蛋白偶联受体（GPCRs）、激酶、离子通道和核激素受体，以及我们的全部数据集。所有数据集均以原始版本和去偏版本进行了测试。BindingDB 数据集 20 是一个可在线访问的数据库，其中包含小分子药物与蛋白质之间经实验验证的结合亲和力；我们使用了该数据集的低偏倚版本 21。KIBA 数据集 23 整合了各种生物活性测量结果，提供了全面的药物靶点相互作用集，尤其侧重于激酶抑制剂。Human 数据集由 Liu 等人 22 构建，包含通过计算机筛选方法生成的高度可信的负样本；遵循先前的研究 18,25，我们使用了正负样本数量相等的平衡版本。

实现。SCOPE 模型使用 Python 3.9 和 PyTorch^{2.2.057} 实现，同时使用了 PyG 2.5.258、DGL^{2.2.559}、DGLLifeSci^{0.3.236}、Scikit-learn^{1.0.260}、Numpy^{1.20.261}、Pandas^{1.5.262} 和 RDKit^{2021.03.231} 中的函数。批量大小^{大小}设置为 64，使用学习率为 5e-5 的 Adam 优化器。对于所有数据集，模型最多运行 100 个周期。在验证集上获得最佳 AUROC 分数的周期所对应的模型被选为最佳模型，然后用于评估测试集上的最终性能。蛋白质编码器 HGNN 使用 320 维的嵌入维度，并处理最长为 2000 个氨基酸的蛋白质序列。为构建蛋白质 3D 图，我们设置边缘截止距离为 10 埃。HGNN 包含 4 层，并包含一个带偏置的全连接层以增强模型容量。对于药物特征编码器，原子输入维度设置为 [74, 1]，以捕获标量和向量特征。原子隐藏维度为 [320, 64]，使模型能够学习复杂的表示。同样，边缘输入维度为 [16, 1]，边缘隐藏维度为 [32, 1]。GVP 模型由 3 层构成，并采用了 0.1 的丢弃率以防止过拟合。我们使用 4.5 埃的边截断距离，并计算 16 个径向分布函数来捕捉原子间的空间关系。值得注意的是，我们的模型对化合物的长度没有最大限制。在双线性注意力模块中，我们采用两个注意力头来增强可解释性，同时捕捉药物与蛋白质之间复杂的相互作用。潜在嵌入大小设置为 768，我们使用大小为 3 的求和池化窗口来有效地聚合特征。解码器是一个具有 512 个隐藏神经元的全连接网络，使模型能够基于学习到的表示进行准确预测。

基准方法。我们将 SCOPE 模型与以下五种用于药物 - 靶点相互作用 (DTI) 预测的方法进行比较：(1) 支持向量机 (SVM)，一种浅层机器学习算法；(2) 多层感知机 (MLP)，一个简单的深度神经网络，隐藏层维度为 [2048, 512, 128, 32]，应用于 ECFP4 和 PSC 指纹特征的拼接；(3) MolTrans，一种使用 Transformer 架构对药物和蛋白质特征进行编码的深度学习模型，并带有基于卷积神经网络 (CNN) 的模块来捕获子结构相互作用；(4) TransformerCPI，一种基于 Transformer 的模型，具有用于蛋白质序列的编码器和用于分子图的解码器，利用多头注意力机制提取相互作用特征；(5) DrugBAN，一种使用图卷积网络和一维卷积神经网络对药物分子和蛋白质序列进行编码的模型，随后通过双线性注意力网络捕获成对相互作用，并使用全连接解码器进行 DTI 预测。对于上述深度 DTI 模型，我们遵循其原始论文中推荐的模型超参数设置。

人参皂苷 Rh1 抗癌靶点的实验验证

实验方法的简要版本在此提供，详细描述见补充说明。

细胞培养。将 HepG2 肝癌细胞在含 10% 胎牛血清 (Gibco, 货号 26170043)、1× 非必需氨基酸 (Gibco, 货号 11140050)、1× 谷氨酰胺 (Gibco, 货号 35050061) 和 1% 青霉素/链霉素 (Gibco, 货号 15140122) 的最低必需培养基 (Gibco, 货号 310950251) 中培养。细胞在 37°C、5% 二氧化碳的加湿培养箱中培养，并用胰蛋白酶-乙二胺四乙酸 (Gibco, 货号 2585625) 进行传代。

细胞活力测定。将 HepG2 细胞以每孔 1×10^4 个细胞的密度接种于 96 孔板中，使其贴壁过夜。用人参皂苷 Rh1 (10 - 100 微摩尔) 处理细胞 24 小时，未处理的细胞作为对照。采用增强型细胞计数试剂盒 8 (碧云天生物技术, 货号 C0042) 通过 CCK-8 法测定细胞活力，于 450 纳米处测量光密度值。

CETSA-WB 实验。将 HepG2 细胞裂解物在室温下与 100 μ M 的白花丹素 (Rh1) 或 1% 的二甲基亚砜 (v/v) 孵育 10 分钟，然后在设定的温度 (40 - 67°C) 下加热 3 分钟。冷却并离心后，取上清液进行 SDS-PAGE 电泳，随后转移至 PVDF 膜上。用抗 AKR1B10 (Abcam, 货号 Ab96417)、抗 AMPK α 2 (Abcam, 货号 EP20772) 和抗 NF- κ B p65 (Abcam, 货号 E379) 抗体对膜进行孵育，最后进行化学发光检测和成像。

分子对接。从蛋白质数据库中获取了 AKR1B10 (PDB: 4JII)、AMPK (PDB: 4ZHX) 和 NF- κ B p65 (PDB: 1NFI) 的晶体结构。使用 CBDOCK2 将人参皂苷 Rh1 对接至这些蛋白质中。在 PyMOL 3.1.3 中对得分最高的对接构象进行了可视化和分析。

表面等离子体共振 (SPR)。将 AKR1B10 固定在 SPR 芯片上进行 SPR 分析。注入不同浓度的 Rh1 溶液 (200 - 1.5625 微摩尔/升)，并记录传感器图谱以确定结合 (k_a)、解离 (k_d) 和平衡解离 (K_D) 常数。

统计分析。数据使用 GraphPad Prism (版本 10.2.3) 进行分析，并以平均值 $\pm$ 标准差的形式呈现。统计学显著性定义为 $p < 0.05$ 。

数据可用性

每种分割策略的实验数据可在 <https://awi.cuhk.edu.cn/SCOPE/> 获取。本研究中使用的所有数据均来自公开资源。人类数据源位于 <https://github.com/lifanchen-simm/transformerCPI>；BindingDB 数据源位于 <https://github.com/peizhenbai/DrugBAN/tree/main/datasets>，KIBA 数据源位于 <https://github.com/luoyunan/KDBNet>。

代码可用性

SCOPE 的源代码和实现细节可在 GitHub 代码库 (<https://github.com/Yigang-Chen/SCOPE-DTI>) 免费获取。

附加信息

利益冲突：作者声明不存在利益冲突。

参考文献

1. Luo, Y. *et al.* A network integration approach for drug-target interaction prediction and computational drug repositioning from heterogeneous information. *Nat. Commun.* 8, 573, DOI: [10.1038/s41467-017-00680-8](https://doi.org/10.1038/s41467-017-00680-8) (2017).
2. Pushpakom, S. *et al.* Drug repurposing: Progress, challenges and recommendations. *Nat. Rev. Drug Discov.* 18, 41–58, DOI: [10.1038/nrd.2018.168](https://doi.org/10.1038/nrd.2018.168) (2019).
3. Mizutani, S., Pauwels, E., Stoven, V., Goto, S. & Yamanishi, Y. Relating drug-protein interaction network with drug side effects. *Bioinforma. (Oxford, England)* 28, i522–i528, DOI: [10.1093/bioinformatics/bts383](https://doi.org/10.1093/bioinformatics/bts383) (2012).
4. Smit, I. A. *et al.* Systematic Analysis of Protein Targets Associated with Adverse Events of Drugs from Clinical Trials and Postmarketing Reports. *Chem. Res. Toxicol.* 34, 365–384, DOI: [10.1021/acs.chemrestox.0c00294](https://doi.org/10.1021/acs.chemrestox.0c00294) (2021).
5. Hajare, A. A. *et al.* Review on: High-throughput screening is an approach to drug discovery. *Am. J. Pharm. Tech. Res* 4, 112–129 (2013).
6. Friman, T. Mass spectrometry-based Cellular Thermal Shift Assay (CETSA®) for target deconvolution in phenotypic drug discovery. *Bioorganic & Medicinal Chem.* 28, 115174, DOI: [10.1016/j.bmc.2019.115174](https://doi.org/10.1016/j.bmc.2019.115174) (2020).
7. Huang, Y. *et al.* A Robust Drug-Target Interaction Prediction Framework with Capsule Network and Transfer Learning. *Int. J. Mol. Sci.* 24, 14061, DOI: [10.3390/ijms241814061](https://doi.org/10.3390/ijms241814061) (2023).
8. Koutsoukas, A. *et al.* From in silico target prediction to multi-target drug design: Current databases, methods and applications. *J. Proteomics* 74, 2554–2574, DOI: [10.1016/j.jprot.2011.05.011](https://doi.org/10.1016/j.jprot.2011.05.011) (2011).
9. Chen, W., Liu, X., Zhang, S. & Chen, S. Artificial intelligence for drug discovery: Resources, methods, and applications. *Mol. Ther. Nucleic Acids* 31, 691–702, DOI: [10.1016/j.omtn.2023.02.019](https://doi.org/10.1016/j.omtn.2023.02.019) (2023).
10. Bagherian, M. *et al.* Machine learning approaches and databases for prediction of drug-target interaction: A survey paper. *Briefings Bioinforma.* 22, 247–269, DOI: [10.1093/bib/bbz157](https://doi.org/10.1093/bib/bbz157) (2021).
11. Van Westen, G. J., Wegner, J. K., IJzerman, A. P., Van Vlijmen, H. W. & Bender, A. Proteochemometric modeling as a tool to design selective compounds and for extrapolating to novel targets. *MedChemComm* 2, 16–30 (2011).
12. Öztürk, H., Özgür, A. & Ozkirimli, E. DeepDTA: Deep drug-target binding affinity prediction. *Bioinforma. (Oxford, England)* 34, i821–i829, DOI: [10.1093/bioinformatics/bty593](https://doi.org/10.1093/bioinformatics/bty593) (2018).
13. Lee, I., Keum, J. & Nam, H. DeepConv-DTI: Prediction of drug-target interactions via deep learning with convolution on protein sequences. *PLoS computational biology* 15, e1007129, DOI: [10.1371/journal.pcbi.1007129](https://doi.org/10.1371/journal.pcbi.1007129) (2019).
14. Karimi, M., Wu, D., Wang, Z. & Shen, Y. DeepAffinity: Interpretable deep learning of compound-protein affinity through unified recurrent and convolutional neural networks. *Bioinforma. (Oxford, England)* 35, 3329–3338, DOI: [10.1093/bioinformatics/btz111](https://doi.org/10.1093/bioinformatics/btz111) (2019).
15. Bai, P., Miljković, F., John, B. & Lu, H. Interpretable bilinear attention network with domain adaptation improves drug-target prediction. *Nat. Mach. Intell.* 5, 126–136 (2023).
16. Tsubaki, M., Tomii, K. & Sese, J. Compound-protein interaction prediction with end-to-end learning of neural networks for graphs and sequences. *Bioinforma. (Oxford, England)* 35, 309–318, DOI: [10.1093/bioinformatics/bty535](https://doi.org/10.1093/bioinformatics/bty535) (2019).
17. Luo, Y., Liu, Y. & Peng, J. Calibrated geometric deep learning improves kinase–drug binding predictions. *Nat. Mach. Intell.* 5, 1390–1401 (2023).
18. Zheng, S., Li, Y., Chen, S., Xu, J. & Yang, Y. Predicting drug–protein interaction using quasi-visual question answering system. *Nat. Mach. Intell.* 2, 134–140 (2020).
19. Huang, K., Xiao, C., Glass, L. M. & Sun, J. MolTrans: Molecular Interaction Transformer for drug-target interaction prediction. *Bioinforma. (Oxford, England)* 37, 830–836, DOI: [10.1093/bioinformatics/btaa880](https://doi.org/10.1093/bioinformatics/btaa880) (2021).

20. Gilson, M. K. *et al.* BindingDB in 2015: A public database for medicinal chemistry, computational chemistry and systems pharmacology. *Nucleic Acids Res.* 44, D1045–1053, DOI: [10.1093/nar/gkv1072](https://doi.org/10.1093/nar/gkv1072) (2016).
21. Bai, P. *et al.* Hierarchical clustering split for low-bias evaluation of drug-target interaction prediction. In *2021 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)*, 641–644 (IEEE, 2021).
22. Liu, H., Sun, J., Guan, J., Zheng, J. & Zhou, S. Improving compound-protein interaction prediction by building up highly credible negative samples. *Bioinforma. (Oxford, England)* 31, i221–229, DOI: [10.1093/bioinformatics/btv256](https://doi.org/10.1093/bioinformatics/btv256) (2015).
23. Tang, J. *et al.* Making sense of large-scale kinase inhibitor bioactivity data sets: A comparative and integrative analysis. *J. Chem. Inf. Model.* 54, 735–743, DOI: [10.1021/ci400709d](https://doi.org/10.1021/ci400709d) (2014).
24. Chatterjee, A. *et al.* Improving the generalizability of protein-ligand binding predictions with AI-Bind. *Nat. Commun.* 14, 1989, DOI: [10.1038/s41467-023-37572-z](https://doi.org/10.1038/s41467-023-37572-z) (2023).
25. Chen, L. *et al.* TransformerCPI: Improving compound-protein interaction prediction by sequence-based deep learning with self-attention mechanism and label reversal experiments. *Bioinforma. (Oxford, England)* 36, 4406–4414, DOI: [10.1093/bioinformatics/btaa524](https://doi.org/10.1093/bioinformatics/btaa524) (2020).
26. UniProt Consortium. UniProt: The Universal Protein Knowledgebase in 2023. *Nucleic Acids Res.* 51, D523–D531, DOI: [10.1093/nar/gkac1052](https://doi.org/10.1093/nar/gkac1052) (2023).
27. Harding, S. D. *et al.* The IUPHAR/BPS Guide to PHARMACOLOGY in 2024. *Nucleic Acids Res.* 52, D1438–D1449, DOI: [10.1093/nar/gkad944](https://doi.org/10.1093/nar/gkad944) (2024).
28. Jumper, J. *et al.* Highly accurate protein structure prediction with AlphaFold. *Nature* 596, 583–589, DOI: [10.1038/s41586-021-03819-2](https://doi.org/10.1038/s41586-021-03819-2) (2021).
29. Kim, S. *et al.* PubChem 2023 update. *Nucleic Acids Res.* 51, D1373–D1380, DOI: [10.1093/nar/gkac956](https://doi.org/10.1093/nar/gkac956) (2023).
30. Zdrzil, B. *et al.* The ChEMBL Database in 2023: A drug discovery platform spanning multiple bioactivity data types and time periods. *Nucleic Acids Res.* 52, D1180–D1192, DOI: [10.1093/nar/gkad1004](https://doi.org/10.1093/nar/gkad1004) (2024).
31. RDKit: Open-source cheminformatics.
32. Tosco, P., Stiefl, N. & Landrum, G. Bringing the MMFF force field to the RDKit: Implementation and validation. *J. Cheminformatics* 6, 37, DOI: [10.1186/s13321-014-0037-3](https://doi.org/10.1186/s13321-014-0037-3) (2014).
33. Zhang, C., Song, D., Huang, C., Swami, A. & Chawla, N. V. Heterogeneous Graph Neural Network. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 793–803, DOI: [10.1145/3292500.3330961](https://doi.org/10.1145/3292500.3330961) (ACM, Anchorage AK USA, 2019).
34. Wu, L. *et al.* MAPE-PPI: Towards Effective and Efficient Protein-Protein Interaction Prediction via Microenvironment-Aware Protein Embedding (2024). [2402.14391](https://arxiv.org/abs/2402.14391).
35. Jing, B., Eismann, S., Suriana, P., Townshend, R. J. L. & Dror, R. Learning from Protein Structure with Geometric Vector Perceptrons, DOI: [10.48550/arXiv.2009.01411](https://doi.org/10.48550/arXiv.2009.01411) (2021). [2009.01411](https://arxiv.org/abs/2009.01411).
36. Li, M. *et al.* DGL-LifeSci: An Open-Source Toolkit for Deep Learning on Graphs in Life Science, DOI: [10.48550/arXiv.2106.14232](https://doi.org/10.48550/arXiv.2106.14232) (2021). [2106.14232](https://arxiv.org/abs/2106.14232).
37. Cortes, C. & Vapnik, V. Support-vector networks. *Mach. Learn.* 20, 273–297, DOI: [10.1007/BF00994018](https://doi.org/10.1007/BF00994018) (1995).
38. Rumelhart, D. E., Hinton, G. E. & Williams, R. J. Learning representations by back-propagating errors. *Nature* 323, 533–536, DOI: [10.1038/323533a0](https://doi.org/10.1038/323533a0) (1986).
39. McInnes, L., Healy, J. & Melville, J. Umap: Uniform manifold approximation and projection for dimension reduction. *arXiv preprint arXiv:1802.03426* (2018).
40. Ankerst, M., Breunig, M. M., Kriegel, H.-P. & Sander, J. Optics: Ordering points to identify the clustering structure. *ACM Sigmod record* 28, 49–60 (1999).
41. Tang, Y. *et al.* Panax notoginseng alleviates oxidative stress through miRNA regulations based on systems biology approach. *Chin. Medicine* 18, 74, DOI: [10.1186/s13020-023-00768-y](https://doi.org/10.1186/s13020-023-00768-y) (2023).
42. Qi, L.-W. *et al.* Metabolism of Ginseng and its Interactions with Drugs. *Curr. Drug Metab.* 12, 818–822 (2011).
43. Tam, D. N. H. *et al.* Ginsenoside Rh1: A Systematic Review of Its Pharmacological Properties. *Planta Medica* 84, 139–152, DOI: [10.1055/s-0043-124087](https://doi.org/10.1055/s-0043-124087) (2018).
44. Lyu, X. *et al.* Ginsenoside Rh1 inhibits colorectal cancer cell migration and invasion in vitro and tumor growth in vivo. *Oncol. Lett.* 18, 4160–4166, DOI: [10.3892/ol.2019.10742](https://doi.org/10.3892/ol.2019.10742) (2019).

45. Jung, J.-S., Ahn, J.-H., Le, T. K., Kim, D.-H. & Kim, H.-S. Protopanaxatriol ginsenoside Rh1 inhibits the expression of matrix metalloproteinases and the in vitro invasion/migration of human astrogloma cells. *Neurochem. Int.* 63, 80–86, DOI: [10.1016/j.neuint.2013.05.002](https://doi.org/10.1016/j.neuint.2013.05.002) (2013).
46. Savage, S. R. *et al.* Pan-cancer proteogenomics expands the landscape of therapeutic targets. *Cell* 187, 4389–4407.e15, DOI: [10.1016/j.cell.2024.05.039](https://doi.org/10.1016/j.cell.2024.05.039) (2024).
47. Uhlén, M. *et al.* Proteomics. Tissue-based map of the human proteome. *Sci. (New York, N.Y.)* 347, 1260419, DOI: [10.1126/science.1260419](https://doi.org/10.1126/science.1260419) (2015).
48. Knox, C. *et al.* DrugBank 6.0: The DrugBank Knowledgebase for 2024. *Nucleic Acids Res.* 52, D1265–D1275, DOI: [10.1093/nar/gkad976](https://doi.org/10.1093/nar/gkad976) (2024).
49. Avram, S. *et al.* DrugCentral 2023 extends human clinical data and integrates veterinary drugs. *Nucleic Acids Res.* 51, D1276–D1287, DOI: [10.1093/nar/gkac1085](https://doi.org/10.1093/nar/gkac1085) (2023).
50. Zhou, Y. *et al.* TTD: Therapeutic Target Database describing target druggability information. *Nucleic Acids Res.* 52, D1465–D1477, DOI: [10.1093/nar/gkad751](https://doi.org/10.1093/nar/gkad751) (2024).
51. Kelleher, K. J. *et al.* Pharos 2023: An integrated resource for the understudied human proteome. *Nucleic Acids Res.* 51, D1405–D1416, DOI: [10.1093/nar/gkac1033](https://doi.org/10.1093/nar/gkac1033) (2023).
52. Gallo, K. *et al.* PROMISCUOUS 2.0: A resource for drug-repositioning. *Nucleic Acids Res.* 49, D1373–D1380, DOI: [10.1093/nar/gkaa1061](https://doi.org/10.1093/nar/gkaa1061) (2021).
53. Leskovec, J. & Sosić, R. SNAP: A General-Purpose Network Analysis and Graph-Mining Library. *ACM Trans. Intell. Syst. Technol.* 8, 1:1–1:20, DOI: [10.1145/2898361](https://doi.org/10.1145/2898361) (2016).
54. Davis, M. I. *et al.* Comprehensive analysis of kinase inhibitor selectivity. *Nat. Biotechnol.* 29, 1046–1051, DOI: [10.1038/nbt.1990](https://doi.org/10.1038/nbt.1990) (2011).
55. Zhang, Z. *et al.* Protein Representation Learning by Geometric Structure Pretraining (2023). [2203.06125](https://arxiv.org/abs/2203.06125).
56. Townshend, R. J. L. *et al.* ATOM3D: Tasks On Molecules in Three Dimensions (2022). [2012.04035](https://arxiv.org/abs/2012.04035).
57. Paszke, A. *et al.* PyTorch: An Imperative Style, High-Performance Deep Learning Library, DOI: [10.48550/arXiv.1912.01703](https://doi.org/10.48550/arXiv.1912.01703) (2019). [1912.01703](https://arxiv.org/abs/1912.01703).
58. Fey, M. & Lenssen, J. E. Fast Graph Representation Learning with PyTorch Geometric, DOI: [10.48550/arXiv.1903.02428](https://doi.org/10.48550/arXiv.1903.02428) (2019). [1903.02428](https://arxiv.org/abs/1903.02428).
59. Wang, M. *et al.* Deep Graph Library: A Graph-Centric, Highly-Performant Package for Graph Neural Networks, DOI: [10.48550/arXiv.1909.01315](https://doi.org/10.48550/arXiv.1909.01315) (2020). [1909.01315](https://arxiv.org/abs/1909.01315).
60. Pedregosa, F. *et al.* Scikit-learn: Machine Learning in Python, DOI: [10.48550/arXiv.1201.0490](https://doi.org/10.48550/arXiv.1201.0490) (2018). [1201.0490](https://arxiv.org/abs/1201.0490).
61. Harris, C. R. *et al.* Array Programming with NumPy, DOI: [10.48550/arXiv.2006.10256](https://doi.org/10.48550/arXiv.2006.10256) (2020). [2006.10256](https://arxiv.org/abs/2006.10256).
62. McKinney, W. Data Structures for Statistical Computing in Python. *scipy* DOI: [10.25080/Majora-92bf1922-00a](https://doi.org/10.25080/Majora-92bf1922-00a) (2010).

致谢

我们衷心感谢文森特与莉莉·吴基金会对“纪念黄博士的文森特与莉莉·吴奖学金”的慷慨资助。该奖学金由文森特与莉莉·吴基金会捐赠，并通过 MCMIA 基金会有限公司提供，我们对其对我们的研究工作的支持深表感激。

作者贡献声明

Y.C.、X.J.、Z.Z.（张子悦）、H.-Y.H. 和 H.-D.H. 设计了这项研究。数据收集工作由 Y.C. 和 Z.Z.（张子悦）完成。张（X.L.）、J.F.、Y.H.、Y.C.、Z.Z.（子悦 张）、K.C. 和 A.W. 设计了研究方法。计算分析由 Y.C.、Z.Z.（张子悦）、Y.Z.（周宇明）、K.C.、C.S.、X.L. 和 Y.H. 完成，并进行了可解释性验证由 Y.C. 和 Z.Z.（张子悦）提供。湿实验室实验由 X.J.、Y.L.、Z.Z.（朱子豪）、Y.Z.（杨怡）执行。张（K.W. Zhang）、李（Y.-C.-D. Li）。原稿由 Y.C.、X.J.、张子悦（Ziyue Zhang）、C.S.、H.-Y.H.、S.-C.Y. 起草。Y.-C.-D.L. 和 H.-D.H. 所有作者均审阅并批准了最终的稿件。