

TriCvT-DTI: 利用三模态表示和卷积视觉变换器预测药物-靶点相互作用

Azouz Maroua¹, Gang Tian², Rui Wang³, and Jiehan Zhou⁴ Member, IEEE

摘要 - 预测药物与其靶点之间的相互作用对于药物发现和再定位至关重要。传统技术速度慢且耗时，而深度学习算法提供了高效的解决方案。然而，深度学习通常侧重于单一药物表示或简单的组合，导致特征表示不理想。此外，在药物图像表示中广泛使用的卷积神经网络（CNN）忽略了药物-靶点相互作用（DTI）任务中局部和全局药物信息的必要性。为了解决这些挑战，我们提出了 TriCvT-DTI，这是一种新颖的方法，它结合了药物的分子图像、化学序列特征和图表示，以全面捕捉结构、空间和功能方面。TriCvT-DTI 引入了双向多头注意力机制，用于药物和靶点之间的交互特征学习，通过建模复杂关系来提高性能。通过使用卷积视觉变换器（CvTs），TriCvT-DTI 能够有效地从药物图像中提取结构和空间特征。我们在三个数据集（Human、C. elegans 和 Davis）上评估了我们的模型，并将其与最先进的方法进行了比较。然后，我们使用单模态和双模态对 TriCvT-DTI 进行训练，以比较并提取每种模态对 TriCvT-DTI 的影响。实验结果表明，TriCvT-DTI 在平衡和不平衡数据集上均优于现有方法。此外，它在药物-靶点相互作用（DTI）任务中表现出令人印象深刻的泛化能力。

关键词 - 生物信息学、计算药物发现、药物-靶点相互作用、药物、卷积视觉变换器、深度学习。

I. 简介

Manuscript received February 12, 2025. The work is supported by National Natural Science Foundation of China Youth Science Foundation Project (52404174), Humanities and Social Sciences Youth Foundation, Ministry of Education (23YJCZH221), Natural Science Foundation of Shandong Province (ZR2023QE030) and Qingdao Postdoctoral Fund-ing Project (QDBSH20220202063).

Azouz Maroua is a Ph.D. student in Bioinformatics at Shandong University of Science and Technology, Qingdao 266510, China (e-mail: 202285140005@sdu.edu.cn).

Gang Tian is an Assistant Professor with the School of Computer Science and Engineering, Shandong University of Science and Technology, Qingdao 266510, China (e-mail: gtian@sdu.edu.cn).

Rui Wang is a Lecturer with the College of Energy and Mining Engineering, Shandong University of Science and Technology, Qingdao 266510, China (e-mail: wangrui@sdu.edu.cn). Rui Wang is the corresponding author.

Dr. Jiehan Zhou, Prof. at Shandong University of Science and Technology, Qingdao, China and Docent at University of Oulu, Oulu, Finland. jiehan.zhou@ieee.org.

药物研发是一个复杂、耗资巨大且耗时的过程，从最初的研究到获得市场批准，平均成本约为 26 亿美元，耗时超过 10 年[1]。像新冠肺炎这样的传染病凸显了计算药物研发的重要性，人工智能模型能够加快候选药物的识别，优化治疗策略，并增进对疾病机制的理解。这些进展解决了疾病机制知识有限以及药物试验中的伦理问题等挑战[2]。

药物与靶点的相互作用（DTIs）在药物研发中至关重要，因为药物需要与疾病靶点相互作用才能发挥治疗效果。预测药物与靶点相互作用的传统技术[3]包括亲和层析和放射配体结合试验等生化检测方法，以及高通量筛选（HTS）。这些技术有助于发现潜在的相互作用，但可能需要大量资源，且无法全面涵盖所有可能的药物与靶点组合。计算药物研发领域的进步正在帮助克服这些局限性，通过提供更高效、更全面的药物与靶点相互作用预测方法，最终提高药物研发的效率和效果。

机器学习（ML）在药物靶点相互作用（DTI）预测中获得了广泛应用，它利用已知的相互作用来开发预测新 DTI 的模型[4]。机器学习算法从分子结构和相互作用网络等多样化的数据源中提取模式，使药物筛选更快、更经济。支持向量机（SVM）[5]、随机森林[6]和深度学习方法等技术已展现出良好的前景。包括卷积神经网络（CNN）[7]、图神经网络（GNN）[8]和基于注意力机制的方法[9]在内的深度学习模型已证明能提高预测的准确性。然而，传统的机器学习方法在特征表示方面往往存在困难，因此需要在分子和蛋白质数据的编码方面取得进展以获得更好的性能。

虽然大多数深度学习模型使用单模态（如 SMILES 序列、分子图或分子图像）或双模态（两种药物表示形式），但这些方法可能无法充分捕捉药物的特征和相互作用。三模态表示则能提供更全面的理解，有可能提升在不同数据集上的性能和稳健性。

现有的方法通常侧重于分别从药物和靶点中提取特征，导致相互作用信息的整合效果欠佳。通过引入卷积操作，

针对分子图像表示, 我们采用卷积神经网络 (CNNs) 和视觉变换器 (ViTs) 来提取局部特征、长程依赖关系以及三维交互模式。卷积视觉变换器 (CvT) 通过捕获关键的高级、非局部和三维特征来满足这些需求, 从而推动药物发现研究的发展。

在本文中, 我们提出了 TriCvT-DTI, 这是一种新颖的药物-靶点相互作用 (DTI) 预测模型, 它有效地整合了三模态表示: 分子图像、化学序列和图药物表示。与依赖单模态或双模态表示的现有方法不同, 我们的三模态框架能够更全面、更细致地理解药物特征, 从而在各种数据集上提高了鲁棒性和性能。为了从分子图像中提取特征, 我们利用了卷积视觉变换器 (CvT), 它不仅能够捕捉局部和全局特征, 还能捕捉对准确 DTI 建模至关重要的高级、非局部和 3D 相互作用模式。这使得我们的模型超越了传统的卷积神经网络 (CNN), 提供了更强大的特征表示能力。

TriCvT-DTI 的主要贡献在于: (1) 创新性地采用三模态表示 (分子图像、化学序列和图) 来全面捕捉对药物-靶点相互作用 (DTI) 至关重要的结构、空间和功能信息。这种整体集成显著增强了特征表示, 并在不同规模和复杂度的数据集上展现出强大的泛化能力。(2) 引入卷积视觉变换器 (CvT), 它不仅捕捉局部特征, 还能出色地提取对准确 DTI 建模至关重要的高级、非局部和 3D 交互模式。这解决了该领域长期存在的挑战, 提高了预测性能, 并能捕捉复杂的分子关系。(3) 突出了不同模态信息的影响。通过比较每种模态权重下的 AUC 值 (曲线下面积), 我们可以识别出每种模态的互补优势, 证明了三模态的重要贡献。

此外, 这种方法在各种数据集和任务中展现出卓越的适应性和稳健性, 彰显了其在加速药物筛选流程以及提高药物研发成功率方面的巨大潜力。

本文其余部分的结构安排如下: 第二部分介绍了药物-靶点相互作用预测的单模态和双模态方法的研究进展以及每项研究的局限性。第三部分描述了 TriCvT-DTI 方法以及使用每一部分的原因。然而, 在第四部分中, 概述了实验设置, 包括数据集、指标、实验设置以及我们进行的实验和获得的结果。接下来, 在第五部分中, 重点分析和讨论了 TriCvT-DTI 的性能以及不同模态信息的影响。最后, 在第六部分中总结了本文。

II. 文献综述

在过去的几十年里, 药物-靶点相互作用 (DTI) 预测的计算方法不断发展, 包括基于

对接、基于配体和基于化学基因组学的技术[10]-[14]。对接方法需要蛋白质的三维结构, 这在结构不可用时会限制其适用性。基于配体的方法依赖于已知的配体, 但这些配体可能数量稀少。化学基因组学方法利用数据库中的药物和靶点数据, 具有更广泛的适用性。

A. 卷积视觉变换器(CvT)

卷积视觉变换器 (CvT) 于 2021 年提出[15], 它结合了卷积神经网络 (CNN) 和视觉变换器, 用于处理视觉任务中的多分辨率特征。其能够捕捉局部和全局特征的能力使其在分子图像分析中表现出色, 有助于准确预测药物-靶点相互作用 (DTI)。CvT 的框架在第 III-A 节中有详细介绍。

B. 相关方法

机器学习和深度学习已成为药物-靶点相互作用 (DTI) 预测的核心方法[13]、[16]-[20]。Lan 等人[21]引入了 PUDT, 采用正样本-未标记样本学习方法, 结合随机游走和 SVM 等方法进行分类。其他方法还包括基于网络的[22]-[24]、基于聚类的[25]、基于核函数的[26]以及矩阵分解[27]-[29]等。深度学习技术通常侧重于对药物和靶点进行编码, 以完成二分类任务, 利用序列、图和图像等方法。

C. 单模态方法

1) 基于序列的方法: 许多 DTI 预测模型主要关注序列。Oztürk 等人[30]提出了 Deep-

DTA 使用卷积神经网络 (CNNs) 从 SMILES 表示和蛋白质序列中提取特征。其他模型, 如 MATT-DTI [31] 和 ELECTRA-DTA [32] 则通过自注意力机制来增强特征提取。尽管这些模型取得了成功, 但基于序列的模型往往忽略了分子结构和原子间的相互作用。为解决这一问题, Ingoo Lee 等人 [33] 提出了 DeepConv-DTI, 该模型利用卷积神经网络和药物指纹来捕捉局部特征。

2) 基于图的方法: 图神经网络 (GNNs) 越来越多地用于对分子图进行建模以预测药物-靶点相互作用 (DTI)。Graph-CPI [34] 将药物表示为图, 并使用 GNN 学习特征。其他模型, 如 GraphDTA [8] 和 DGraphDTA [35], 通过建模原子间的相互作用来改进 DTI 预测。GNN-CPI [36] 融合图特征以预测化合物-蛋白质相互作用。然而, 图模型通常缺乏诸如双键和三键之类的细节, 这表明需要采用多模态方法。

3) 基于图像的方法: 基于图像的方法在药物相互作用预测中不太常见, 但在增强特征提取方面显示出潜力。PWO-CPI [7] 和 DTI-CNN [37] 使用卷积神经网络 (CNN) 处理分子图像, 从而改进了相互作用预测。CAT-CPI [38] 和 DEEPScreen [39] 分别将卷积神经网络与变换器以及卷积神经网络相结合来处理药物图像。然而, 图像方法在可解释性方面存在困难, 并且可能缺乏关键的化学细节。

D. 双峰法

许多方法专注于单一模态，例如 SMILES 或分子图。结合多种模态可提高表示的准确性，如 MCL-DTI [40] 结合了化学文本和二维图像。TriCvT-DTI 集成了三种模态（图像、图和化学序列），提供了全面的分子表示，并改进了药物-靶点相互作用（DTI）预测。该模型使用 CvT 从分子图像中提取增强特征，优于传统的基于 CNN 的方法。

III. TriCvT-DTI

在药物-靶点相互作用（DTI）预测中，TriCvT-DTI 将任务设定为二分类问题，预测药物与靶点是否会相互作用（1 表示会，0 表示不会）。TriCvT-DTI 采用三模态（图像、化学序列和图表示）作为药物的输入，以及靶点的 FASTA 序列。其架构由四个模块组成：特征编码器、特征解码器、特征融合和分类器。输入数据通过 RDKit [41] 进行处理，以从 SMILES 中提取药物图像、化学序列特征和图表示。TriCvT-DTI 将药物表示为分子图，捕捉原子键和空间排列，同时对化学序列进行编码以捕捉序列模式。这些模态的整合增强了 DTI 预测的效果。

A. 卷积视觉变换器(CvT):数学解释

卷积视觉变换器（CvT）将卷积操作与 Transformer 机制相结合。CvT 集成了卷积标记嵌入（CTE）、卷积投影、多头自注意力（MSA）、层归一化（LN）、多层感知机（MLP）块和残差连接。

CTE 通过卷积操作（公式 1）对输入图像进行变换：

$$CTE(x_{i-1}) = \text{Conv2D}(x_{i-1}; k, s) \quad (1)$$

其中 x_{i-1} 是来自上一层的输入，Conv2D 是卷积操作， k 是卷积核大小， s 是步幅。

卷积投影进一步优化了表示（公式 2）：

$$x^v = \text{Flatten}(\text{Conv2D}(\text{Reshape2D}(x_i), s)) \quad (2)$$

其中 x^v 是查询、键和值矩阵的标记输入，而 Reshape2D 则将输入重塑为二维映射。

MSA 增强特征关系，随后是残差连接和 LN（公式 3）：

$$\text{LN}(x) = \frac{(\text{MSA}(x^v) + x_i - \mu)}{\sigma} \cdot \gamma + \beta \quad (3)$$

其中， μ 和 σ 分别是输入的均值和标准差， γ 和 β 是可学习的参数。

最终输出结合了 MSA 和 MLP 块（公式 4）：

$$\text{Output} = \text{MLP}(\text{LN}(x)) + \text{MSA}(x) \quad (4)$$

这些步骤使 CvT 能够提取局部和全局特征，从而提高药物发现的预测能力。

(A) 特征编码器模块：TriCvT-DTI 通过整合药物的图像、化学序列、图特征以及靶点的 FASTA 序列来提取药物特征。

1) 图像模态:为了捕获药物图像的局部和全局特征，并增强药物 - 靶点相互作用预测，TriCvT-DTI 采用了卷积视觉变换器（CvT）骨干网络，详情见第 III-A 节，该网络结合了卷积操作和第 II-A 节介绍的 Transformer 机制。这种集成增强了药物发现中的预测性能。药物结构式图像通过 RDKit 软件 [41] 从 SMILES 序列生成，提供了分子的可视化表示。这些图像编码了诸如键连接性、芳香性和立体化学等结构信息，这些信息从文本中难以获取。可视化这些特征提供了更直观的分子理解。

输入图像表示为 $I \in \mathbb{R}^{n \times n}$ ，其中 n 表示图像大小。通过 CvT 主干网络处理后，生成药物的图像特征图，如公式 5 所示：

$$x_{\text{img}} = \text{CvT}(I) \quad (5)$$

2) 化学序列模式:化学序列特征为药物分子提供了额外的信息，由两个部分组成：特征类型和特征族[41]。这些特征对氢键供体和芳香性等特性进行分类，有助于药效团匹配。通过使用 SMILES 序列，我们利用 RDKit [41] 提取化学文本特征，选择相关的特征族/类型数据以及关联的原子，如图 2 所示。

为了处理药物文本，我们采用 k-gram 方法，将序列分割成长度为 k 的短语。这会形成一个短语字典，根据字典中的位置将单词替换为数值。这些数值被嵌入到模型中，生成 x_{text} 化学序列特征输出。图 3 展示了 $k = 3$ 时的 k-gram 方法，包括分割和嵌入过程。这种方法能够高效地对药物文本信息进行编码，从而提升表示和分析的效果。

3) 图模态:为了在药物-靶点相互作用（DTI）中充分利用图表示的优势，我们使用 RDKit [41] 将药物的 SMILES 表示转换为图结构进行预处理。每个药物都表示为一个图 $G = (V, E)$ ，其中节点 V 表示原子，边 E 表示化学键。节点特征包括原子序数、手性、杂化态、度数、形式电荷、芳香性和环成员身份，而边特征包括类型、立体化学和共轭性。这些特征使图卷积网络（GCN）能够区分原子类型及其在图中的作用。

我们采用 Kipf 和 Welling 提出的 GCN 模型[42]，该模型在图结构上运行，使用节点




图 1.所提出的 TriCvT-DTI 方法的架构。(A) TriCvT-DTI 特征编码器的架构。(B) TriCvT-DTI 特征解码器的架构。(C) MSA 块的架构。




图 2.用于癌症治疗的 5-氟尿嘧啶 (5-FU) 的三模态表示。(a) 药物图像。(b) 化学文本。(c) 药物图。

Protein:
AVQDLEIDNMAHSPVAVQVPGMNNIADPEELFKLERIGKGSFGEVFKGIDNRTQVVAIKIIDLEEAEIKIEDIDPE

Dictionary	Word Embedding	Protein
MAH 1	0.813 0.017 0.122 -0.23 0.001 ... 0.016 0.002 0.214 0.060	4 AVQ
EDI 2	0.620 0.851 0.304 0.741 0.103 ... 0.014 -0.04 0.239 0.119	107 DLE
MQN 3	0.622 0.734 0.703 0.814 0.622 ... 0.334 0.623 0.421 0.194	1566 IDN
AVQ 4	-0.70 0.234 0.631 -0.23 0.881 ... 0.001 -0.10 0.671 0.334	1 MAH
I 1	I I I I I I I I I I	1 I
DPE 2998	0.245 -0.13 -0.73 0.642 0.340 ... 0.067 0.823 -0.48 0.654	23 IKI
SPV 2999	0.556 0.224 0.763 0.008 0.003 ... 0.114 0.096 -0.73 0.564	2 EDI
DEI 3000	0.273 -0.33 0.431 0.564 -0.28 ... 0.392 0.832 0.334 0.557	2998 DPE

图 3.使用 3-gram 方法 (分段和嵌入) 对蛋白质序列进行编码。

GCN 包含特征矩阵和邻接矩阵。GCN 有三个图卷积层, 后面跟着一个全局最大池化层。在每次图卷积过程中, 节点特征通过应用共享权重矩阵并借助邻接矩阵从相邻节点聚合信息来进行更新。这种消息传递机制能够捕捉局部连接性和原子属性, 在每一层生成丰富的节点嵌入。

为了获得图级表示, 全局最大池化层将学习到的节点级特征聚合为一个单一的代表向量, 从而总结出分子内远距离但关键的关系。通过结合特征编码、消息传递和全局池化, GCN 能够有效地处理药物图中多样节点类型和相互作用的复杂性。最终输出 x_{graph} 表示药物图的特征:

$$x_{\text{graph}} = \text{GCN}(G) \quad (6)$$

我们将药物的多种模态特征进行整合, 以构建化合物的综合表示, 记为 x_{drug} 。这些模态包括图像特征 x_{img} (公式 5)、化学序列特征 x_{text} 和基于图的特征 x_{graph} (公式 6)。为了突出每种模态的贡献, 我们使用可学习的权重 (λ_1 , λ_2 和 λ_3) 来组合这些特征。药物特征向量 x_{drug} 计算为这些模态的加权和:

$$x_{\text{drug}} = \lambda_1 \times x_{\text{text}} + \lambda_2 \times x_{\text{image}} + \lambda_3 \times x_{\text{graph}} \quad (7)$$

B. 目标编码器

对于目标序列, 其架构如图 1.A 所示, 我们首先直接使用其 FASTA 序列。我们使用 k-gram 技术处理该序列以生成其嵌入表示。接下来, 采用 MSA 模块从序列中提取高级特征, 捕捉序列内部复杂的依赖关系和相互作用 (MSA 模块架构如图 1.C 所示)。尽管数据主要基于序列, 但自注意力机制有助于推断结构和功能关系, 通过整合序列和间接结构信息来增强药物 - 靶点相互作用的预测。

目标序列的特征向量，记作 x_{target} ，是通过这种方法计算得出的。具体来说，通过 k-gram 方法获取嵌入表示，并使用 MSA 模块提取抽象特征。这种方法能够全面理解目标序列，将基于序列的信息和推断出的结构信息相结合，从而提高预测的准确性。

C. 特征解码模块

特征解码器通过两个解码器提取药物-靶点相互作用信息，每个解码器都包含一个多头自注意力（MSA）模块和一个多头交叉注意力（MCA）模块。这两个模块都融合了层归一化（LN）、多层感知机（MLP）模块和残差连接，区别在于注意力计算方式。MSA 模块捕捉内部特征依赖关系，而 MCA 模块则对药物和靶点特征之间的相互作用进行建模。在药物解码器的 MCA 模块中，输入药物和靶点特征，并对靶点特征进行线性变换以计算注意力输出。这种双向学习过程生成了两个特征图：Zdrug-target（来自靶点解码器中的药物特征）和 Ztarget-drug（来自药物解码器中的靶点特征），如图 1.B 所示。

D. 特征融合模块

融合块通过沿通道维度连接 Z 药物-靶点和 Z 靶点-药物特征图，然后依次进行二维和一维卷积、MLP 块以及全连接（FC）层操作，从而将它们整合在一起。最终的预测结果由以下公式给出：

$$\begin{aligned} CONV &= \text{Conv1D}(\text{Conv2D}([Z_{\text{drug-target}}, Z_{\text{target-drug}}])) \\ Z &= \text{FC}(\text{MLP}(CONV)) \end{aligned}$$

E. 分类器

该分类器使用交叉熵损失函数：

$$\mathcal{L} = -\frac{1}{N} \sum_{n=1}^N (y_n \log(P_n) + (1 - y_n) \log(1 - P_n))$$

其中 N 表示样本总数， y_n 表示真实标签。采用 Adam 优化器 [43] 来高效地更新模型参数。

IV. 实验

A. 数据集

我们使用了三个公开可用的药物-靶点相互作用（DTI）数据集：Human [44]、C. elegans [44] 和 Davis [45]。每个数据集都包含三个主要部分：（1）以文本形式表示的药物序列；（2）同样以文本形式表示的靶点蛋白序列；（3）一个二元相互作用标签，用于表明药物与靶点之间是否存在相互作用。表 I 提供了每个数据集所包含的药物和靶点的详细统计信息。Human 和 C. elegans 数据集的正负样本数量均衡，这些数据均来自 DrugBank [46] 和 Matador [47] 等高可信度的生化数据库。对于 Davis 数据集，共考虑了 64 种不同的药物和 379 个靶点，其中

药物-靶点相互作用对由 kd 值小于 30 单位来定义。Human 和 C. elegans 数据集按照 8:1:1 的比例划分训练集、验证集和测试集，而 Davis 数据集的划分则遵循 MolTrans [9] 中所描述的方法。此外，我们还使用了 Biosnap 数据集 [48] 来进行药物-药物相互作用（DDI）预测，该数据集包含 9648 种药物和 81194 个样本，其中约 50.5% 的样本为正例。

表一
弥散张量成像（DTI）数据集的出现情况

数据集	毒品	目标	样本	阳性样本	平衡的
秀丽隐杆线虫	1716	1856	7509	3892	真正的
戴维斯	64	379	10439	1428	错误的
人类	2496	1919	6184	3364	真的

B. 指标

我们使用 ROC-AUC（受试者工作特征曲线下面积）和 PR-AUC（精确率召回率曲线下面积）来评估我们的模型。ROC-AUC 是主要的评估指标，用于衡量模型在正负样本上的整体表现。PR-AUC 则侧重于正样本，尤其适用于不平衡数据集，突出了模型识别正样本的稳健性。召回率衡量的是正确识别的正样本所占的百分比，表明模型学习正样本的能力。所有结果均以平均值和标准差的形式呈现，从而全面展示模型的性能和波动情况。

C. 实验设置

实验使用 PyTorch [49] 进行，训练周期为 100 个。硬件配置包括英特尔 i9 10700f 处理器、32GB 内存和 RTX 4090 显卡。初始学习率为 $1e-3$ ，在 $[1e-3, 1e-4, 1e-5]$ 范围内进行探索，衰减率为 0.8，在 $[0.5 - 0.9]$ 范围内进行测试。批处理大小为 32，在 $[16, 32, 64]$ 范围内进行探索，丢弃率为 0.1，在 $[0.1 - 0.5]$ 范围内进行评估。超参数优化采用了网格搜索技术。

D. 三模态实验

在三模态实验中，我们对 TriCvT-DTI 模型进行了全面评估，将其与多种现有方法进行了基准测试。我们选择了在该领域广受认可且应用频繁的前沿方法，包括 MCL-DTI [40]、CAT-CPI [38]、MolTrans [9]、Mutual-DTI [50] 和 HiGraphDTI [51]。为了评估基于图的方法，我们纳入了 GNN-CPI [36] 和 HiGraphDTI [51]。相比之下，TransformerCPI [52]、DeepDTA [30] 和 DeepConv-DTI [33] 则用于评估基于序列的技术的有效性。此外，还加入了 PWO-CPI [7] 来评估我们的模型利用图像数据的能力。另外，MCL-DTI [40] 也被用于将 TriCvT-DTI 与双模态方法进行比较。这种多样化的选择使得能够

对 TriCvT-DTI 在多种模态下的全面评估, 提供了与现有模型的宝贵比较, 并对其在药物 - 靶点相互作用预测中的有效性进行了深入分析。最先进的技术和我们的实验结果总结在表 II 中。

V. 分析与讨论

A. TriCvT-DTI 在各数据集上的性能表现

表 II 展示了 TriCvT-DTI 与最新方法的对比结果。结果表明, TriCvT-DTI 的表现优于当前最先进的方法。

1) 人类数据集: TriCvT-DTI 的 ROC-AUC 值为 0.989, 优于 MCL-DTI (0.987) 和 Mutual-DTI (0.984) 等模型。尽管 HiGraphDTI 的 ROC-AUC 值略高, 为 0.993, 但 TriCvT-DTI 仍具有竞争力。其 PR-AUC 值为 0.990, 超过了 GNN-CPI (0.973)、Mutual-DTI (0.962) 和 MCL-DTI (0.989), 与 HiGraphDTI (0.993) 持平, 显示出高精度。TriCvT-DTI 的召回率为 0.962, 与 DeepConv-DTI 和 PWO-CPI 的最佳值相当, 表明其在识别真阳性方面具有稳健性。其在所有指标上的均衡表现使其成为一个强有力的竞争者。

2) 秀丽隐杆线虫数据集: TriCvT-DTI 在该数据集上的表现优于所有其他方法, 其 ROC-AUC 值达到 0.993, 超过了 MCL-DTI (0.992) 和 HiGraphDTI (0.985)。其 PR-AUC 值为 0.995, 召回率为 0.968, 这表明其在提取多模态数据特征和识别真阳性方面非常有效。

3) 戴维斯数据集: TriCvT-DTI 表现出色, 其 ROC-AUC 和召回率指标均很高, 超越了所有最新方法。尽管受数据集不平衡 (1 正样本对 19 负样本) 的影响, 其 PR-AUC 仍具有竞争力, 这突显了该模型的精度。TriCvT-DTI 的高召回率进一步证明了其在识别真正阳性样本方面的有效性。这些结果表明, TriCvT-DTI 具有很强的泛化性能, 能够很好地适应所有数据集, 无论平衡与否、大小如何, 因为它能够利用三种模态提取足够的特征来进行分类。

B. TriCvT-DTI 中不同模态的互补作用

文本模态编码了化学和生物特性, 包含了图或图像中所没有的信息。图模态捕捉分子和生物实体内部的结构关系。图像模态编码空间信息, 例如分子亚结构和三维构象, 揭示了文本和图数据所遗漏的见解。通过整合这三种模态, TriCvT-DTI 可以弥补彼此的不足, 从而提高预测性能。

C. 不同模态信息的影响

在 TriCvT-DTI 模型中, 参数 λ_1 、 λ_2 和 λ_3 分别代表图像、文本和图谱模态的相对贡献。这些参数在训练过程中动态学习, 使模型能够根

据每个模态与数据集以及预测药物 - 靶点相互作用任务的相关性, 自适应地调整其贡献。

图 4.A、4.B 和 4.C 分别展示了在 *C. elegans*、Human 和 Davis 数据集上随机时刻的 AUC 值与参数 λ_1 、 λ_2 和 λ_3 之间的关系, 其中 AUC 值大于或等于 0.90。此分析有助于了解最优且稳定的参数值, 从而加深我们对其对模型性能影响的理解。对于 Human 数据集 (图 4.B), 最优值为 $\lambda_1 = 0.61$ 、 $\lambda_2 = 0.66$ 和 $\lambda_3 = 0.37$, 其中文本模态 (λ_2) 贡献最大, 其次是图像 (λ_1), 而图模态 (λ_3) 贡献最小但仍具有显著意义。

对于秀丽隐杆线虫数据集 (图 4.A), 最优值为 $\lambda_1 = 0.57$ 、 $\lambda_2 = 0.70$ 和 $\lambda_3 = 0.21$ 。在此, 文本模态 (λ_2) 占主导地位, 图模态贡献较小, 图像模态则处于中等水平。

对于戴维斯数据集 (图 4.C), 最优参数为 $\lambda_1 = 0.75$ 、 $\lambda_2 = 0.68$ 和 $\lambda_3 = 0.67$, 其中图像模态 (λ_1) 贡献最大, 其次是文本 (λ_2) 和图 (λ_3), 这表明所有模态的贡献更为均衡。

这些结果表明, 尽管文本模态始终具有最高的权重, 但图像和图模态的相对重要性因数据集而异。在“人类”数据集中, 文本和图像特征处于平衡状态, 图模态作为补充; 而在“秀丽隐杆线虫”数据集中, 主要依赖文本, 图像使用适度, 图模态贡献极小。在“戴维斯”数据集中, 图像特征占主导地位, 但文本和图模态也发挥了重要作用。这种适应性凸显了 TriCvT-DTI 能够根据数据集的特点调整模态权重以优化性能的能力。

总之, TriCvT-DTI 通过动态学习模态贡献来调整图像、文本和图特征之间的平衡, 从而在不同数据集上优化性能。

VI. 结论

TriCvT-DTI 在预测药物与靶点相互作用方面取得了重大进展。通过结合分子图像、化学序列特征以及基于图的药物表示, 它能够更全面地理解这些相互作用, 涵盖结构、空间和功能等多个方面。该模型在多个数据集上均表现出色, 显示出其在药物发现和开发领域具有巨大的潜力。

有几个方面有待改进和探索。通过优化、采用替代注意力机制或增加其他数据类型来改进模型, 能够提高其准确性和通用性。TriCvT-DTI 还可以针对药物研发中的特定挑战进行调整, 例如药物再利用或个性化医疗, 为不同的治疗领域提供新的见解。确保模型的预测结果具有可解释性对于在临床环境中获得信任至关重要。此外, 研究诸如自监督学习和多任务学习等先进技术也十分重要。

表 II 不同方法在各种数据集上的性能指标。

数据集	方法	ROC-AUC 值	PR-AUC 值	召回值
人类	DeepDTA [30]	0.953±0.002	0.981±0.003	0.946±0.024
	GNN-CPI [36]	0.974±0.004	0.973±0.005	0.953±0.019
	DeepConv-DTI [33]	0.985±0.001	0.982±0.001	0.962±0.002
	TransformerCPI [52]	0.971±0.002	0.973±0.002	0.942±0.004
	PWO-CPI [7]	0.982±0.003	0.980±0.002	0.962 ± 0.001
	MolTrans [9]	0.978±0.002	0.978±0.001	0.933 ± 0.003
	MCL-DTI [40]	0.987±0.001	0.989±0.001	0.961 ± 0.002
	HiGraphDTI [51]	0.993±0.001	0.993±0.001	-
	相互 DTI [50]	0.984±0.001	0.962±0.019	0.943 ± 0.016
	TriCvT-DTI (我们的方法)	0.989±0.002	0.990±0.001	0.962 ± 0.002
秀丽隐杆线虫	DeepDTA [30]	0.987±0.001	0.990±0.002	0.964±0.011
	GNN-CPI [36]	0.978±0.002	0.975±0.005	0.949±0.003
	DeepConv-DTI [33]	0.980±0.002	0.981±0.001	0.937±0.003
	TransformerCPI [52]	0.985±0.001	0.985±0.002	0.952±0.002
	PWO-CPI [7]	0.979±0.002	0.978±0.003	0.933 ± 0.003
	MolTrans [9]	0.985±0.001	0.984±0.002	0.962 ± 0.001
	MCL-DTI [40]	0.992±0.001	0.994±0.001	0.959 ± 0.002
	HiGraphDTI [51]	0.985±0.001	0.988±0.001	-
	相互 DTI [50]	0.987±0.004	0.948±0.018	0.949±0.013
	TriCvT-DTI (我们的方法)	0.993±0.001	0.995±0.001	0.968 ± 0.002
戴维斯	DeepDTA [30]	0.860±0.002	0.238±0.002	0.818±0.003
	GNN-CPI [36]	0.840±0.003	0.269±0.003	0.696±0.002
	DeepConv-DTI [33]	0.822±0.002	0.192±0.001	0.905±0.003
	TransformerCPI [52]	0.841±0.002	0.227±0.001	0.842±0.001
	PWO-CPI [7]	0.835±0.002	0.188±0.002	0.798±0.002
	MolTrans [9]	0.907±0.002	0.404±0.002	0.800±0.001
	MCL-DTI [40]	0.922±0.001	0.492±0.002	0.895±0.002
	HiGraphDTI [51]	0.871±0.003	0.547±0.002	0.794±0.003
	相互 DTI [50]	0.900±0.002	0.767±0.002	0.680±0.001
	TriCvT-DTI (我们的方法)	0.935±0.001	0.614±0.001	0.911±0.001



图 4. λ_1 , λ_2 和 λ_3 的值对 AUC 度量性能的影响。A: 在秀丽隐杆线虫数据集上。B: 在人类数据集上。C: 在戴维斯数据集上。

这可能有助于更好地利用大型生物数据集，并进一步提高 TriCvT-DTI 的有效性。

参考文献

- [1] Joseph A DiMasi, Henry G Grabowski, and Ronald W Hansen. In-novation in the pharmaceutical industry: New estimates of r&d costs. *Journal of health economics*, 47:20–33, 2016.
- [2] Ben Mepham. Ethical dilemmas in the use of animals in research: The perspectives of three groups of people. *Alternatives to Laboratory Animals*, 36(3):277–282, 2008.
- [3] Tingting Cheng, Qianqian Li, Yanli Wang, and Stephen H Bryant. Predicting drug–target interactions by random walk on the heterogeneous network. *Molecular BioSystems*, 8(7):1970–1978, 2012.
- [4] Xi Chen, Chengfei Yan, Xue Zhang, Fang Dai, Jincai Yin, and Yang Zhang. Drug–target interaction prediction by random walk on the heterogeneous network. *Molecular BioSystems*, 12(7):2225–2232, 2016.
- [5] Baraa Taha Yaseen. Drug target interaction prediction using support vector machine (svm). In *2023 5th International Congress on Human-Computer Interaction, Optimization and Robotic Applications (HORA)*, pages 1–4, 2023.
- [6] Sangjin Ahn, Si Eun Lee, and Mi-hyun Kim. Random-forest model for drug–target interaction prediction via kullback–leibler divergence. *Journal of Cheminformatics*, 14(1):67, 2022.
- [7] Yuhong Qian, Xiang Li, Jun Wu, Aiqin Zhou, Zhiwei Xu, and Qiang Zhang. Picture-word order compound protein interaction: predicting compound–protein interaction using structural images of compounds. *J Comput Chem*, 43(4):255–264, 2022.
- [8] Thin Nguyen, Hang Le, Thomas P Quinn, Tri Nguyen, Thuc Duy Le, and Svetha Venkatesh. GraphDTA: predicting drug–target binding affinity

with graph neural networks. *Bioinformatics*, 37(8):1140–1147, 10 2020.

[9] Kexin Huang, Cao Xiao, Lucas M Glass, and Jimeng Sun. MolTrans: Molecular Interaction Transformer for drug–target interaction prediction. *Bioinformatics*, 37(6): 830–836, 10 2020.

[10] Ali Ezzat, Min Wu, Xiao-Li Li, and Chee-Keong Kwoh. Computational prediction of drug–target interactions using chemogenomic approaches: an empirical survey. *Briefings in bioinformatics*, 20(4):1337–1357, 2019.

[11] Kriti Sachdev and Manoj Kumar Gupta. A comprehensive review of feature based methods for drug target interaction prediction. *Journal of Biomedical Informatics*, 93:103159, 2019.

[12] Zengyou Wu, Wei Li, Gang Liu, and Yun Tang. Network-based methods for prediction of drug–target interactions. *Frontiers in Pharmacology*, 11:1134, 2018.

[13] Wei Zhang, Wen Lin, Dong Zhang, Shuang Wang, Jiye Shi, and Yan Niu. Recent advances in the machine learning-based drug–target interaction prediction. *Current Drug Metabolism*, 20(3):194–202, 2019.

[14] Ashish Nath, Pratibha Kumari, and Rajesh Chaube. Prediction of human drug targets and their interactions using machine learning methods: current and future perspectives. *Computational Drug Discovery and Design*, 2018. doi: 10.1007/978-1-4939-7756-7_2.

[15] Haiping Wu, Bin Xiao, Noel Codella, Mengchen Liu, Xiyang Dai, Lu Yuan, and Lei Zhang. Cvt: Introducing convolutions to vision transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 22–31, October 2021.

[16] Xiang Chen, Chengfei Yan, Xudong Zhang, Fuhai Dai, Jian Yin, and Yang Zhang. Drug–target interaction prediction: databases, web servers and computational models. *Briefings in bioinformatics*, 17(4):696–712, 2016.

[17] Rui Chen, Xingcheng Liu, Shaoliang Jin, Jiao Lin, and Jiajia Liu. Machine learning for drug–target interaction prediction. *Molecules*, 23(9):2208, 2018.

[18] S Anusuya, Manoj Kesharwani, K Vijay Priya, A Vimala, G Shan-mugam, D Velmurugan, and MM Gromiha. Drug–target interactions: prediction methods and applications. *Current Protocols in Peptide Science*, 19(6):537–561, 2018.

[19] Qingyao Zhao, Hao Yu, Meng Ji, Yang Zhao, and Xia Chen. Com-putational model development of drug–target interaction prediction: a review. *Current Protocols in Peptide Science*, 20(6):492–494, 2019.

[20] Mehdi Bagherian, Ehsan Sabeti, Kai Wang, Maureen A Sartor, Zaneta Nikolovska-Coleska, and Kayvan Najarian. Machine learning ap-proaches and databases for prediction of drug–target interaction: a survey paper. *Briefings in bioinformatics*, 22(1):247–269, 2021.

[21] Wei Lan, Jianxin Wang, Min Li, Jin Liu, Yaohang Li, Fang-Xiang Wu, and Yi Pan. Predicting drug–target interaction using positive-unlabeled learning. *Neurocomputing*, 206:50–57, 2016.

[22] Yuan Luo, Xiang Zhao, Jiaqi Zhou, Jian Yang, Yijia Zhang, Wenbo Kuang, Jian Peng, Li Chen, and Jianyang Zeng. A network integration approach for drug–target interaction prediction and computational drug repositioning from heterogeneous information. *Nature communications*, 8(1):1–13, 2017.

[23] Xin Chen, Meng-Xin Liu, and Gui-Ying Yan. Drug–target interaction prediction by random walk on the heterogeneous network. *Molecular BioSystems*, 8(7):1970–1978, 2012.

[24] Feixiong Cheng, Cheng Liu, Jing Jiang, Wencong Lu, Weihua Li, Gang Liu, Wapeng Zhou, Jing Huang, and Yang Tang. Prediction of drug– target interactions and drug repositioning via network-based inference. *PLoS computational biology*, 8(5):e1002503, 2012.

[25] Xiang Zhang, Lin Li, Michael K Ng, and Shu Zhang. Drug–target inter-action prediction by integrating multiview network data. *Computational biology and chemistry*, 69:185–193, 2017.

[26] Fei Shang, Lei Jiao, and Yi Liu. Integrating spectral kernel learning and constraints in semi-supervised classification. *Neural Processing Letters*, 36(2):101–115, 2012.

[27] Yong Liu, Min Wu, Chunyu Miao, Peng Zhao, and Xiao-Li Li. Neighborhood regularized logistic matrix factorization for drug–target interaction prediction. *PLoS computational biology*, 12(2):e1004760, 2016.

[28] B´alint Bolg´ar and P´eter Antal. Vb-mk-lmf: fusion of drugs, targets and interactions using variational bayesian multiple kernel logistic matrix factorization. *BMC bioinformatics*, 18(1):1–18, 2017.

[29] Mengmeng Hao, Stephen H Bryant, and Yan Wang. Predicting drug– target interactions by dual-network integrated logistic matrix factoriza-tion. *Scientific reports*, 7(1):1–11, 2017.

[30] Hakime Ozi

..

urk, Arzucan Ozg

..

ur, and Elif Ozkirimli. DeepDTA: deep

drug–target binding affinity prediction. *Bioinformatics*, 34(17):i821– i829, 09 2018.

[31] Y. Zeng, X. Chen, Y. Luo, X. Li, and D. Peng. Deep drug-target binding affinity prediction with multiple attention blocks. *Briefings in bioinformatics*, 22(5): bbab117, 2021.

[32] J. Wang, N. Wen, C. Wang, L. Zhao, and L. Cheng. Electra-dta: a new compound-protein binding affinity prediction model based on the contextualized sequence encoding. *J. Cheminformatics*, 14(1):14, 2022.

[33] Inuk Lee, Jaeheon Keum, and Hyun-Ju Nam. Deepconv-dti: Prediction of drug–target interactions via deep learning with convolution on protein sequences. *PLoS Comput Biol*, 15(6):e1007129, 2019.

[34] Zhe Quan, Yan Guo, Xuan Lin, Zhi-Jie Wang, and Xiangxiang Zeng. Graphcpi: Graph neural representation learning for compound-protein interaction. In *2019 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)*, pages 717–722, 2019.

[35] M. Jiang, Z. Li, S. Zhang, S. Wang, X. Wang, Q. Yuan, and Z. Wei. Drug–target affinity prediction using graph neural network and contact maps. *RSC Adv.*, 10:20701–20712, 2020.

[36] Makoto Tsubaki, Kentaro Tomii, and Jun Sese. Compound–protein interaction prediction with end-to-end learning of neural networks for graphs and sequences. *Bioinformatics*, 35(2):309–318, 2019.

[37] Zhiqiang Zhang, Shuang Wang, Shuang Zhang, and Zhiqiang Zhang. A learning-based method for drug–target interaction prediction using convolutional neural networks. *BMC Bioinformatics*, 21(1):1–10, 2020.

[38] Qian Zhang* Ying Qian, Jian Wu. Cat-cpi: Combining cnn and transformer to learn compound image features for predicting compound-protein interactions. *PubMed-not-MEDLINE*, 2024.

[39] Zhiqiang Zhang, Shuang Wang, Shuang Zhang, and Zhiqiang Zhang. Deepscreen: High performance drug–target interaction prediction with convolutional neural networks using 2-d structural compound represen-tations. *Chemical Science*, 11(1):88–98, 2020.

[40] Yuhong Qian, Xiang Li, Jun Wu, and Qiang Zhang. MCL-DTI: using drug multimodal information and bi-directional cross-attention learning method for predicting drug–target interaction. *BMC Bioinform*, 24(1):323, 2023.

[41] Greg Landrum. Rdkit documentation. *Release*, 1(1-79):4, 2013.

[42] Thomas N. Kipf and Max Welling. Semi-supervised classification with graph convolutional networks. *CoRR*, abs/1609.02907, 2016.

[43] Diederik P Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.

[44] Hui Liu, Jianjiang Sun, Jihong Guan, Jie Zheng, and Shuigeng Zhou. Im-proving compound-protein interaction prediction by building up highly credible negative samples. *Bioinformatics*, 31(12):i221–i229, jun 2015.

[45] MI Davis, JP Hunt, S Herrgard, P Ciceri, LM Wodicka, G Pallares, M Hocker, DK Treiber, and PP Zarrinkar. Comprehensive analysis of kinase inhibitor selectivity. *Nature Biotechnology*, 29(11):1046–1051, oct 2011.

[46] David S. Wishart, Craig Knox, An Chi Guo, Dean Cheng, Savita Shri-vastava, Dan Tzur, Bijaya Gautam, and Michael Hassanali. Drugbank: a knowledgebase for drugs, drug actions and drug targets. *Nucleic Acids Research*, 36(suppl-1): 901–906, 2008.

[47] Stefan G`unther, Michael Kuhn, Martin Dunkel, Michaela Campillos, Christian Senger, Evangelia Petsalaki, J`org Ahmed, Eugenio G. Urdiales, Andreas Gewiess, and Lars Juhl Jensen. Supertarget and matador: re-sources for exploring drug–target relationships. *Nucleic Acids Research*, 36(suppl-1):919–922, 2007.

[48] Kun Huang, Changhua Xiao, Tram Hoang, Lewis Glass, and Jianjiang Sun. Caster: Predicting drug interactions with chemical substructure representation. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 34, pages 702–709, 2020.

[49] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Brad-bury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimselshein, Luca Antiga, Alban Desmaison, Andreas Kopf, Edward Yang, Zachary DeVito, Martin Raison, Alykhan Tejani, Sasank Chilamkurthy, Benoit Steiner, Lu Fang, Junjie Bai, and Soumith Chintala. Pytorch: An imperative style, high-performance deep learning library. In *Advances in Neural Information Processing Systems*, volume 32, 2019.

[50] J. Wen, H. Gan, Z. Yang, R. Zhou, J. Zhao, and Z. Ye. Mutual-dti: A mutual interaction feature-based neural network for drug-target protein interaction prediction. *Math Biosci Eng*, 20(6):10610–10625, 2023.

[51] Bin Liu, Siqi Wu, Jin Wang, Xin Deng, and Ao Zhou. Higraphdti: Hierarchical graph representation learning for drug-target interaction prediction, 2024.

[52] Lifan Chen, Xiaoqin Tan, Dingyan Wang, Feisheng Zhong, Xiaohong Liu, Tianbiao Yang, Xiaomin Luo, Kaixian Chen, Hualiang Jiang, and Mingyue Zheng. TransformerCPI: improving compound–protein interaction prediction by sequence-based deep learning with self-attention mechanism and label reversal experiments. *Bioinformatics*,

36(16):4406–4414, 05 2020.