



WAE-DTI: 一种基于集成的药物-靶点相互作用预测架构, 使用描述符和嵌入技术

Tariq Sha'ban^a, Ahmad M. Mustafa^a

^a 约旦科技大学计算机信息系统系, 约旦, 伊尔比德, 22110

^a*, Mostafa Z. Ali^b

文章信息

关键词: 药物靶点相互作用
深度学习 集成学习
结合亲和力 药物发现

摘要

药物靶点相互作用 (DTI) 预测是制药和药物发现领域的主要挑战之一, 原因在于其成本高昂、耗时且需要大量人工实验来评估大量药物与靶点之间的相互作用。此外, 一种药物可以与多个靶点结合, 而一个靶点也可以与多种药物结合, 这使得 DTI 任务更加复杂。现有的计算机模型在应对这些挑战时往往力不从心, 尤其是在处理多样化的数据集方面。为了解决这些问题, 我们引入了加权平均集成药物靶点相互作用 (WAE-DTI) 模型。我们的方法整合了多种描述符和指纹表示来提高预测的准确性和泛化能力, 包括用于药物表示的原子对指纹、Avalon、MACCS、MH、Morgan、RDKit、SEC、拓扑扭结和 LDP, 以及用于靶点表示的 ESM-2。WAE-DTI 采用加权平均集成技术来有效处理多样化的数据集。该模型在最先方法基础上取得了显著改进, 在 Davis 数据集上的平均均方误差为 0.190 ± 0.001 , 在 Kiba 数据集上为 0.127 ± 0.001 , 在 DTC 数据集上为 0.143 ± 0.001 , 在 Metz 数据集上为 0.284 ± 0.004 , 在 ToxCast 数据集上为 0.308 ± 0.001 , 在 STITCH 数据集上为 0.934 ± 0.004 。至于分类任务, WAE-DTI 在 BioSNAP 数据集上的 AUPRC 为 0.943 ± 0.001 , 在 Davis 数据集上为 0.474 ± 0.011 , 在 BindingDB 数据集上为 0.707 ± 0.005 , 其表现优于现有模型。我们的代码可在 [1](#) 处公开获取。

1. 简介

药物靶点相互作用 (DTI) 任务在药物发现和药物再定位领域中至关重要。药物再定位可定义为将过去未能取得预期效果的药物化合物用于新的用途, 从而实现治疗上的新发现^[1]。例如, 米诺地尔过去主要用于治疗溃疡, 但现在则用于治疗脱发^[2]。

药物靶点相互作用 (DTI) 任务主要试图评估药物对特定靶点的影响; 这种影响通常被称为结合亲和力 (BA)。BA 通常使用平衡解离常数 (K_d)^[3] 来测量。值越低, 配体与其靶点之间的结合就越强。在机器学习中, 这被视为一个回归问题。然而, 很少有论文像上述方法^[4]那样处理 DTI 任务。相反, 它们使用一个阈值, 如果 K_d 值或其他任何指标超过该阈值, 则得出是否存在相互作用的结论; 这种方法被视为一个二分类任务。图 1 展示了药物 (通常以简化分子线性输入规范 (SM

ILES) 表示) 与蛋白质 (主要由相互缠绕的氨基酸组成) 之间的相互作用, 这种相互作用通常用前面提到的 K_d 表示。

不幸的是, 药物 - 靶点相互作用 (DTI) 研究因需要大量的湿实验才能得出可靠结论而成本高昂且耗时^[5]。此外, 药物与靶点的组合种类繁多, 使得湿实验难以实施。而且, 分析其复杂的生化过程也颇具难度。不过, 利用计算机模拟来推断药物 - 靶点相互作用预测可以缓解这一问题。这可以通过运用机器学习算法来解决; 显然, 机器学习能够取得令人满意的结果, 并直接大幅降低研究成本^[6]。

深度学习还能够检测脱靶效应, 这在药物研发中可能会产生重大影响。当药物分子与未预料到的靶点相互作用时, 就会引发不良的副作用。深度学习模型能够帮助研究人员预测脱靶效应, 从而开发出更安全、更有效的药物。

为了在现有研究的基础上提供更准确的结果, 构建了多个深度学习模型, 这

*通讯作者。

电子邮件地址: thshaban21@cit.just.edu.jo (T. Sha'ban), ammustafa@just.edu.jo (A.M. Mustafa), mzali@just.edu.jo (M.Z. Ali)。

¹ <https://github.com/tariqshaban/wae-dti>

<https://doi.org/10.1016/j.imu.2024.101604>

Received 9 August 2024; Received in revised form 28 November 2024; Accepted 28 November 2024

Available online 12 December 2024

2352-9148/© 2024 The Authors. Published by Elsevier Ltd. This is an open access article under the CC BY-NC-ND license (<http://creativecommons.org/licenses/by-nc-nd/4.0/>).




图 1.DTI 直觉。




图 2.所提出模型概述。在导入数据集之后，提取药物和蛋白质的表示形式。然后，针对每个数据集训练多个模型，基于集成模型进行加权；所得模型用作最终评估模型。

主要基于均方误差。由于蛋白质和靶点的特征都以文本数据的形式表示，因此需要建立两个空间：一个用于药物，一个用于靶点（蛋白质）；这通常通过特征提取来实现，更具体地说，是通过使用嵌入来实现。在训练模型之后，使用集成学习模型来预测结合强度；图 2 概述了用于展示深度学习模型方案的基本步骤。

在本研究的其余部分，将对药物 - 靶点相互作用（DTI）预测领域的相关工作进行详细讨论，并介绍用于克服 DTI 预测任务挑战的材料和方法。随后将重点展示研究结果，并与近期的研究进行比较。最后，将对研究发现进行讨论，并概述研究过程中发现的局限性。其目的是有效地衡量药物与蛋白质之间的结合强度。

1.1. 动机

手动实验和实验室测试被认为成本高昂，因为其需要高昂的设备费用、化合物合成成本、资金投入、时间以及人力。此外，测试药物与靶点的组合会产生数量庞大的实验。这些问题可以通过使用计算机预测来解决，以高效、及时地估算相互作用的强度。

1.2. 研究问题

本研究旨在回答以下研究问题：

- **模型性能：**能否构建一个深度学习模型要取得比现有的最先进模型更好的结果吗？

具体而言,该模型在均方误差 (MSE)、一致性指数 (CI) 和 R2M 方面的表现与现有研究相比如何?

- **特征表示:** 使用多种特征表示方式会怎样?
药物的不同剂量是否能提升模型的表现?
- **回归与分类:** 将问题定义设定为分类而非回归是否足够? 结合相互作用能否有效地被视为二元状态?
- **计算效率:** 训练一个模型需要多长时间?
在每个数据集上都建立模型吗?
- **新颖示例:** 模型在进行预测时表现如何
未被发现的药物或蛋白质?

1.3. 贡献

以往关于药物靶点相互作用预测的研究的主要缺陷在于用于训练的数据集数量有限。充足的示例数量能够增强模型的泛化能力。每个数据集都代表了药物和蛋白质的不同分布情况,有些专注于人类基因组,有些则侧重于具有小分子结构的药物。这种多样化的表示需要一个能够处理药物和蛋白质各种结构的模型。我们的贡献在于构建了一个深度学习集成模型,该模型能够基于大量多样化的数据集自动预测药物与靶点之间的相互作用。我们提出的模型在多个数据源上的表现都优于当前最先进的模型。

2. 相关工作

本节对药物-靶点相互作用 (DTI) 领域的相关研究进行了全面综述,涵盖了从经典机器学习方法和矩阵分解到深度学习算法实现的各个方面。大多数研究论文都将 DTI 预测任务视为分类问题,而很少有论文将其视为回归问题。根据用于解决 DTI 预测问题的方法对文章进行了分组。每节中的论文按时间顺序进行回顾,先讨论早期的论文,然后介绍近期的研究成果。本节包含多个子部分,包括经典机器学习模型、矩阵分解和图模型、聚类和半监督模型以及深度学习模型。表 1、2、3 和 4 对相关工作进行了总结。

2.1. 经典机器学习技术

在将经典机器学习技术应用于药物-靶点相互作用 (DTI) 预测的领域中,已有若干研究探索了多种模型和数据集。特别是支持向量机 (SVM) 一直是研究人员的热门选择。例如, Faulon 等人[7]利用带有核函数的 SVM 分类器,借助京都基因与基因组百科全书 (KEGG) 数据库,并与预测毒理学挑战 (PTC) 进行基准测试。同样, Tabei 等人[8]结合了逻辑回归和 SVM 模型,使用黄金数据集以及 PubChem 数据库中的化学指纹和 UniProt 数据库中的基因组信息。Ding 等人[19]也采用了 SVM,重点在于利用黄金数据集进行特征选择。Yu 等人[9]通过整合随机森林 (RF) 和 SVM 来提高数据质量,将药物-靶点对表示为来自 DrugBank 数据集的张量积。此外, Cao 等人[10]将分子访问系统 (MACCS) 子结构指纹纳入 SVM 模型,同样使用了黄金数据集。

除了支持向量机 (SVM) 之外,其他机器学习技术也被应用。例如, Laarhoven 等人[11]结合所提出的一种名为 GIP 的方法,使用了加权最近邻

(WNN) 算法,并采用了黄金数据集。Wang 等人[12]利用受限玻尔兹曼机模型,结合了手动注释的靶点和药物在线资源 (MATADOR) 数据库以及化学物质相互作用搜索工具 (STITCH) 数据集。Yuan 等人[13]开发了 DrugE-Rank 方法,该方法结合了基于特征和基于相似性的方法以及排序学习 (LTR),使用了来自 DrugBank 数据集的数据,并重点关注了经美国食品药品监督管理局 (FDA) 批准的药物或实验性药物以及人类蛋白质靶点。Ezzat 等人[14]使用主要由决策树组成的集成方法解决了类别不平衡问题,采用了 BindingDB 数据集。此外, Wang 等人[15]通过结合药物的结构特性和蛋白质的进化信息来表示药物-靶点相互作用对,使用了随机森林分类器和黄金数据集。

此外,其他研究引入了多种方法。姚等人[16]使用分子子结构指纹进行分子表示,并使用朴素贝叶斯对 BindingDB 数据集进行分类,还在网络服务器上部署了他们的模型。何等人[17]提出了 SimBoost 模型,这是一个经过训练的梯度提升回归模型,使用特征向量化作为输入。拉扬等人[18]提出了 iDTI-ESBoost 模型,该模型结合了进化特征,并使用了黄金数据集。李等人[20]利用黄金数据集开发了判别向量机 (DVM) 分类器。最后,石等人[21]提出了 LRF-DTIs 方法,该方法将伪位置特异性评分矩阵 (PsePSSM) 与 FP2 分子指纹相结合,用于药物和靶点提取。该方法还使用最小绝对收缩和选择算子 (LASSO) 进行降维,并使用合成少数类过采样技术 (SMOTE) 解决数据不平衡问题。该方法使用随机森林分类器,利用 DrugBank 批准的数据集和黄金标准数据集来预测药物靶点相互作用。

2.2. 矩阵分解与图技术

众多研究在利用矩阵分解和图模型预测药物-靶点相互作用 (DTI) 方面取得了重大进展。Yamanishi 等人[22]引入了将药物和靶点投影到“药理空间”的概念,采用二部图学习方法,使用来自 KEGG BRITE、布伦瑞克酶数据库 (BRENDA)、SuperTarget 和 DrugBank 的数据集,这些数据集统称为“黄金标准数据集”。Bleakley 等人[23]在此基础上进一步探索了通过局部模型进行二部图推断的方法。Yamanishi 等人[24]在此基础上更进一步,利用来自 KEGG DRUG、KEGG LIGAND、JAPIC、KEGG GENES 和 KEGG BRITE 的数据,通过有监督的二部图推断预测药理作用并推断未知的药物-靶点相互作用。

多项研究致力于构建模型以提升黄金数据集的结果。Laarhoven 等人[25]将高斯交互作用轮廓核与正则化最小二乘分类器相结合,而 Gonen 等人[26]则采用了核化贝叶斯矩阵分解。Chen 等人[27]在异构网络上使用了基于网络的随机游走重启 (NRWRH) 方法,Mei 等人[28]将基于邻居的交互轮廓推断 (NII) 整合到了二分局部模型 (BLM-NII) 中。Alaimo 等人[29]提出了一种基于网络的推断 (NBI) 模型,以解决纯“局部”模型的局限性。

科巴诺格鲁等人[30]利用概率矩阵分解方法处理了 DrugBank 数据集,郑等人[6]提出了多相似性协同矩阵分解 (MSCMF) 方法。山本等人[31]开发了一种基于二分图推理和成对核回归的模型,该模型后来被部署为一个网络服务器。帕希卡拉等人[32]提出了克罗内克正则化最小二乘 (KronRLS) 方法,这是一种基于相似性的模型,被认为是正则化最小二乘 (RLS) 模型的广义模型。刘等人[33]引入了邻域正则化逻辑矩阵分解 (NRLMF),纳西门托等人[34]将 KronRLS 模型扩展为 KronRLS-MKL。郝等人[35]和埃扎特等人[36]开发了

表 1
经典机器学习技术的相关工作比较。

纸	数据集	任务	方法论	结果
[7]	预测毒理学挑战数据集、KEGG 数据库、DRUGBANK (测试数据集)	分类	支持向量机	主要在 80% 以上
[8]	DrugBank	分类	逻辑回归 支持向量机	成对交叉验证: SCCA: AUC: 0.7975。 分块交叉验证: SCCA: AUC: 0.7496。
[9]	DrugBank STITCH (测试数据集) SuperTarget (测试数据集) KEGG (测试数据集)	分类	森林 (RF) 支持向量机 (SVM)	一致性: 82.83% 灵敏度: 81.33% 特异度: 93.62% AUC: 90.5
[10]	KEGG 数据库 金标准数据集	分类	支持向量机	酶: 准确率: 90.31 离子通道: 准确率: 88.91 G 蛋白偶联受体: 准确率: 84.68 核受体: 准确率: 83.74
[11]	黄金标准数据集	分类	加权最近邻轮廓	酶: 曲线下面积 (AUC) : 0.983 离子通道: 曲线下面积 (AUC) : 0.986 G 蛋白偶联受体: 曲线下面积 (AUC) : 0.972 核受体: 曲线下面积 (AUC) : 0.958
[12]	斗牛士缝法	分类	受限玻尔兹曼机	AUPR: 89.6
[13]	DrugBank 数据集	分类	学习排序集成学习	数据 -2: AUPR: 0.2031 数据 -3: AUPR: 0.2831 数据 -5: AUPR: 0.0997
[14]	DrugBank	分类	集成学习 决策树	AUC: 0.90
[15]	黄金标准数据集	分类	旋转森林	酶: 准确率: 91.3G 蛋白偶联受体: 准确率: 84.1 离子通道: 准确率: 89.1 核受体: 准确率: 71.1
[16]	BindingDB	分类	朴素贝叶斯 随机森林	CPDBAS: 0.746 ± 0.003 EPAFHM: 0.713 ± 0.004 FDAMDD: 0.807 ± 0.002
[17]	戴维斯·基巴·梅茨	回归	梯度提升	戴维斯: 均方根误差: 0.247 基巴: 均方根误差: 0.204 梅茨: 均方根误差: 0.16
[18]	黄金标准数据集	分类	AdaBoost	酶: AUPR: 0.680 G 蛋白偶联受体: AUPR: 0.480 离子通道: AUPR: 0.500 核受体: AUPR: 0.790
[19]	黄金标准数据集	分类	支持向量机 (SVM) 特征选择 (FS)	酶: AUPR: 0.899 G 蛋白偶联受体: AUPR: 0.821 离子通道: AUPR: 0.929 核受体: AUPR: 0.65
[20]	黄金标准数据集	分类	判别向量机	酶: 准确率: 93.16G 蛋白偶联受体: 准确率: 89.37 离子通道: 准确率: 91.73 核受体: 准确率: 92.2
[21]	黄金标准数据集	分类	套索回归 随机森林	酶: AUC: 0.9982 G 蛋白偶联受体: AUC: 0.9918 离子通道: AUC: 0.9965 核受体: AUC: 0.9559

分别整合了正则化最小二乘法和矩阵分解的模型。

进一步的创新包括: Lu 等人[37]利用 MATADOR 数据库提出的仅拓扑结构算法, Hao 等人[38]提出的双网络集成逻辑矩阵分解 (DNILMF), 以及 Wu 等人[39]利用 ChEMBL 和 DrugBank 数据库提出的基于子结构-药物-靶点网络的推理 (SDTNBI)。Luo 等人[40]引入了 DTINet 用于从异质网络中识别新的药物适应症。Olayan 等人[41]在异质图上应用了非线性相似性融合方法和随机森林分类器。最近, Ding 等人[42,43]通过诸如基于希尔伯特-施密特独立性准则的多核学习 (HSIC

-MKL) 的双拉普拉斯正则化最小二乘法 (DLapRLS) 和使用多核学习的模糊二部局部模型 (FBLM) 等模型推动了该领域的发展。

2.3. 聚类和半监督技术

关于将药物和蛋白质投影并聚类到统一平面的问题, Shi 等人[45]设计了一个模型, 该模型解决了大多数数据中缺失相互作用的问题, 包括非结构化和非序列信息。他们基于相似药物与相似靶点相互作用的直觉引入了“超级靶点”的概念, 并使用黄金数据集计算相似性度量。

表 2
矩阵分解和图技术的相关工作比较。

纸	数据集	任务	方法论	结果
[22]	黄金标准数据集（包含 KEGG、BRITE、BRENDA、SuperTarget 和 DrugBank）	分类	最近邻特征加权特征 二部图学习	（最近邻特征/加权特征/二部图学习）酶：AUC：0.767/0.812/0.904 离子通道：AUC：0.751/0.811/0.851 G 蛋白偶联受体：AUC：0.729/0.739/0.899 核受体：AUC：0.710/0.626/0.843
[23]	黄金标准数据集	分类	二部局部模型	酶：AUC：97.6 离子通道：AUC：97.3 G 蛋白偶联受体：AUC：95.5 核受体：AUC：88.1
[24]	黄金标准数据集	分类	监督二部图推断	酶：AUC：0.892 离子通道：AUC：0.812 G 蛋白偶联受体：AUC：0.827 核受体：AUC：0.835
[25]	黄金标准数据集	分类	正则化最小二乘法与克罗内克积核相结合（RLS-Kron）	AUPR：92.7
[26]	黄金标准数据集	分类	具有孪生核的核化贝叶斯矩阵分解	酶：AUC：0.832 离子通道：AUC：0.799 G 蛋白偶联受体：AUC：0.857 核受体：AUC：0.824
[27]	黄金标准数据集	分类	基于网络的异构网络随机游走重启算法（NRWRH）	酶：曲线下面积（AUC）：0.955 离子通道：曲线下面积（AUC）：0.948 G 蛋白偶联受体：曲线下面积（AUC）：0.976 核受体：曲线下面积（AUC）：0.876
[28]	黄金标准数据集	分类	基于邻居的交互模式推断（NII）与二部图局部模型	酶：AUC：98.8 离子通道：AUC：99.0 G 蛋白偶联受体：AUC：98.4 核受体：AUC：98.1
[29]	黄金标准数据集	分类	基于网络的推理与基于领域的知识	酶：AUC：0.9995 离子通道：AUC：0.9973 G 蛋白偶联受体：AUC：0.9995 核受体：AUC：1.000
[30]	黄金标准数据集 DrugBank	分类	概率矩阵分解	酶：AUC：0.861 离子通道：AUC：0.904 G 蛋白偶联受体：AUC：0.771 核受体：AUC：0.650 DrugBank：AUC：0.794
[6]	黄金标准数据集	分类	多重相似性协同矩阵分解（MSCMF）	酶：AUPR：0.673 离子通道：AUPR：0.773 G 蛋白偶联受体：AUPR：0.937 核受体：AUPR：0.894
[31]	KEGG	分类	二部图推断 二部局部模型 两两核函数	成对交叉验证：AUC：0.936 ± 0.010 分块交叉验证：AUC：0.870 ± 0.004
[32]	戴维斯·基巴	回归	克罗内克正则化最小二乘法（KronRLS）	戴维斯：均方误差：0.379 吉巴：均方误差：0.41
[33]	黄金标准数据集	分类	逻辑矩阵分解 邻域正则化	酶：AUC：0.987 离子通道：AUC：0.989 G 蛋白偶联受体：AUC：0.969 核受体：AUC：0.950
[34]	黄金标准数据集	分类	二部图网络多核学习算法	酶：AUPR：0.8818 离子通道：AUPR：0.8769 G 蛋白偶联受体：AUPR：0.6440 核受体：AUPR：0.5368
[35]	黄金标准数据集	分类	正则化最小二乘结合非线性核融合（RLS-KF）重新计算核矩阵	酶：AUPR：0.915 离子通道：AUPR：0.925 G 蛋白偶联受体：AUPR：0.853 核受体：AUPR：0.909
[36]	黄金标准数据集	分类	加权 K 近邻已知点图正则化矩阵分解	酶：AUPR：0.807 离子通道：AUPR：0.815 G 蛋白偶联受体：AUPR：0.615 核受体：AUPR：0.50
[37]	MATADOR 数据库	分类	基于相似性的算法（共同邻居、杰卡德指数、优先连接、卡茨指数）	共同邻居：AUPR：0.3715 杰卡德指数：AUPR：0.3697 优先连接：AUPR：0.0022 卡茨指数（μ = 0.005）：AUPR：0.3652 卡茨指数（μ = 0.01）：AUPR：0.3486 卡茨指数（μ = 0.02）：AUPR：0.3030

(续下页)

表 2 (续)

纸	数据集	任务	方法论	结果
[38]	黄金标准数据集	分类	核矩阵配置 相似性扩散 双网络逻辑矩阵分解	酶: AUPR: 0.922 G 蛋白偶联受体: AUPR: 0.812 离子通道: AUPR: 0.938 核受体: AUPR: 0.751
[39]	ChEMBL 数据库 DrugBank 数据库 BindingDB 数据库	分类	基于药物-靶点网络的子结构推断	GPCR: 曲线下面积 (AUC): 0.966 激酶: 曲线下面积 (AUC): 0.958 离子通道: 曲线下面积 (AUC): 0.971 核受体: 曲线下面积 (AUC): 0.932
[40]	药物节点: DrugBank 蛋白质节点: HPRD 疾病节点: 比较毒理基因组学数据库 副作用节点: SIDER 药物-靶点/药物-药物相互作用: DrugBank	分类	带重启的随机游走扩散分量分析	AUROC: 0.91 AUPR: 0.93
[41]	金标准数据集 DrugBank_FDA (测试数据集)	分类	异构图非线性相似性融合	酶: AUPR: 52% G 蛋白偶联受体: AUPR: 56% 离子通道: AUPR: 50% 核受体: AUPR: 71% DrugBank (美国食品药品监督管理局): 35%
[42]	黄金标准数据集	分类	模糊二部局部模型 (FBLM) 最小二乘支持向量机 (LS-SVM) 多核学习 (MKL)	酶: AUPR: 0.898 ± 0.010 G 蛋白偶联受体: AUPR: 0.917 ± 0.011 离子通道: AUPR: 0.743 ± 0.023 核受体: AUPR: 0.547 ± 0.101
[43]	黄金标准数据集	分类	双重拉普拉斯正则化最小二乘多核融合	CV1: (酶: AUPR: 0.90, 离子通道: AUPR: 0.93, G 蛋白偶联受体: AUPR: 0.767, 核受体: AUPR: 0.561) CV2: (酶: AUPR: 0.423, 离子通道: AUPR: 0.417, G 蛋白偶联受体: AUPR: 0.418, 核受体: AUPR: 0.444) CV3: (酶: AUPR: 0.822, 离子通道: AUPR: 0.812, G 蛋白偶联受体: AUPR: 0.631, 核受体: AUPR: 0.357)

表 3

聚类和半监督技术的相关工作比较。

纸	数据集	任务	方法论	结果
[44]	黄金标准数据集 DBSI (测试数据集)	分类	名为 NetCBP 的半监督方法	酶: 曲线下面积 (AUC): 0.8075 离子通道: 曲线下面积 (AUC): 0.8029 GPCR: 曲线下面积 (AUC): 0.802 核受体: 曲线下面积 (AUC): 0.7578
[45]	黄金标准数据集	分类	成对相似度 聚类	酶: 曲线下面积 (AUC): 0.832 离子通道: 曲线下面积 (AUC): 0.724 GPCR: 曲线下面积 (AUC): 0.93 核受体: 曲线下面积 (AUC): 0.878

陈等人[44]尝试通过创建一种名为 NetCBP 的架构来根据相关性对药物和靶点进行排序，该架构采用了一种半监督学习方法，他们也使用了黄金数据集。

2.4. 深度学习技术

深度学习模型也被用于药物靶点相互作用 (DTI) 任务。例如，Hu 等人[46]采用了一种名为多尺度特征深度表示 (MFDR) 的深度学习模型，该模型结合了自动编码器和支持向量机 (SVM)，并使用黄金数据集对其方法进行了验证。同样，Wen 等人[47]利用扩展连接指纹 (ECFP) 和蛋白质序列组成 (PSC) 描述符输入深度信念网络 (DBN) 模型，并从 Drugbank 数据库中获取见解。Wang 等人[48]引入了一种堆叠式自动编码器与旋转森林相结合的方法，并使用黄金数据集对其进行了评估。另一方面，Ozturk 等人[49]假设每个药物和蛋白质的输入为原始的一维数组，输入先经过标签编码器和嵌入层，然后输入卷积神经网络 (CNN) 模型，作者将每个 CNN 的输出展平合并到全连接神经网络中，他们将这种架构称为 DeepDTA。Ozturk 等人[50]后来扩展了他们的模型，并提出了 WideDTA 架构，该架构利用基于单词的序列表示而非基于字符的序列表示。

赵等人[51]旨在通过修改和微调架构来改进 Ozturk 等人[49]的 DeepDTA 结果，从而得到了 AttentionDTA 模型。

林等人[52]采用另一种方法，探索了结合距离感知注意力算法的图神经网络的应用，使用了诸如 Directory of Useful Decoys-Enhanced (DUD-E) 和 PDBbind 等多种数据集。万等人[53]提出了 NeoDTI 模型，该模型专注于药物和靶点的拓扑结构保持表示，其训练数据集由罗等人[40]构建。与此同时，李等人[54]实施了 DeepConv-DTI 以捕捉局部残基模式，使用了来自 DrugBank、KEGG 和国际基础与临床药理学联盟 (IUPHAR) 的数据集。唐等人[55]在多个数据集上实现了无监督图自编码器和 Graph-CNN 用于相互作用预测，这些数据集包括成药口袋、DUD-E 和 ChEMBL。申等人[56]指出，传统的卷积神经网络无法捕捉长距离关系，因此他们提出了一种基于变压器的方法，称为 MT-DTI，使用嵌入字符的变压器层处理药物，使用嵌入字符的卷积神经网络层处理蛋白质。

此外，贝克等人[57]致力于寻找针对新冠病毒 (SARS-CoV-2) 蛋白质的高亲和力药物，他们在 DTC 和 BindingDB 的数据集上对 AutoDock Vina 和 MT-DTI 等方法进行了比较，病毒序列则来自美国国家生物技术信息中心 (NCBI)。进一步丰富了这一领域，

表 4
深度学习中的相关工作比较。

纸	数据集	任务	方法论	结果
[46]	黄金标准数据集	分类	堆叠式自动编码器支持向量机	酶: AUROC: 0.969 G 蛋白偶联受体: AUROC: 0.904 离子通道: AUROC: 0.933 核受体: AUROC: 0.886 酶: AUROC: 0.969
[47]	DrugBank	分类	深度信念网络 (DBN)	真阳性率 (TPR) : 0.8227 真阴性率 (TNR) : 0.8953 准确率: 0.8588 面积下曲线 (AUC) : 0.9158
[48]	黄金标准数据集	分类	旋转森林堆叠自编码器	酶: 准确率: 94.41G 蛋白偶联受体: 准确率: 86.69离子通道: 准确率: 91.16核受体: 准确率: 80.56
[49]	戴维斯·基巴	回归	嵌入式卷积神经网络	戴维斯: 均方误差: 0.261 基巴: 均方误差: 0.194
[50]	戴维斯·基巴	回归	基于词的卷积神经网络嵌入序列表示	戴维斯: 均方误差: 0.262 吉巴: 均方误差: 0.179
[51]	戴维斯·基巴	回归	嵌入式卷积神经网络增强微调	戴维斯: 均方误差: 0.245 吉巴: 均方误差: 0.162
[52]	DUD-E PD Bbind 数据库	分类	蛋白质结构信息嵌入图神经网络	DUD-E: AUROC: 0.968 PDBbind: AUROC: 0.935
[53]	Drugbank 数据集 HPRD 数据集 比较毒理基因组学数据库 SIDER 数据库	分类	异构网络中的节点级嵌入	AUPR: 0.82 (正负样本比例为 0.1)
[54]	DrugBank	分类	美国有线电视新闻网	准确度: 0.79
[55]	DUD-E 数据集 最大无偏验证数据集	分类	图卷积神经网络	DUD-E: AUC: 0.886。 MUV: AUC: 0.619。
[56]	戴维斯·基巴	回归	嵌入字符的 Transformer 层 嵌入字符的 CNN 层	戴维斯: 均方误差: 0.245 吉巴: 均方误差: 0.193
[57]	药物靶点通用 (DTC) 结合数据库	回归	基于一致性得分的平均算法	N/A
[58]	DrugBank 数据库	分类	半二部图形式化深度神经网络	AUROC: 93%
[59]	戴维斯·基巴	回归	半监督生成对抗网络 (GAN) 卷积神经网络	戴维斯: 均方误差: 0.276 吉巴: 均方误差: 0.224
[60]	戴维斯·基巴	回归	图注意力网络 (GAT) 双向门控循环单元 (BiGRU) 卷积神经网络 (CNN)	戴维斯: 均方误差: 0.252 基巴: 均方误差: 0.193
[4]	基巴·戴维斯 绑定数据库 (测试数据集)	回归	双向长短期记忆网络 卷积神经网络 差分进化	(均方误差/平均精度均值) Kiba: 0.179/0.785 Davis: 0.235/0.722 BindDB: 0.483/0.761
[61]	HIPPIE 数据库、DrugBank 数据库 金标准数据集	分类	图卷积网络 深度神经网络	AUC: 0.93-0.98 AUPR: 0.85 - 0.98
[62]	戴维斯·基巴	回归	CNN 卷积神经网络 (GCN) 图注意力网络 (GAT) 图同构网络 (GIN)	戴维斯: 均方误差: 0.229 KIBA: 均方误差: 0.139
[63]	黄金标准数据集	分类	瀑布深林	酶: 曲线下面积 (AUC) : 0.975 G 蛋白偶联受体: 曲线下面积 (AUC) : 0.98 离子通道: 曲线下面积 (AUC) : 0.995 核受体: 曲线下面积 (AUC) : 0.98

(续下页)

表 4 (续)

纸	数据集	任务	方法论	结果
[64]	戴维斯	回归	图卷积网络 长短期记忆网络	(均方误差/置信区间/每平方米)
	KIBA			戴维斯: 0.232/0.895/0.680
	DTC			KIBA: 0.133/0.897/0.792
	梅斯			DTC: 0.149/0.895/0.841
	ToxCast			梅斯: 0.294/0.810/0.640
	缝合			ToxCast: 0.313/0.919/0.565 STITCH: 0.992 / - / 0.430
[65]	人类	分类回归	多尺度图神经网络 (MGNN) 多尺度卷积神经网络 (MCNN)	(均方误差/查准率/曲线下面积) 戴维斯:
	秀丽隐杆线虫			0.207/0.900/0.710 基巴: 0.128/0.902/0.801
	戴维斯			梅茨: 0.265/0.822/0.701 托克卡斯特: 0.176/0.902/0.430 (准确率/召回率/AUC)
	KIBADTC			人类: 0.955/0.956/0.983 酿酒酵母: 0.980/0.967/0.991
	梅斯			
	ToxCast			
[66]	戴维斯	回归	ESM-2 变形图卷积神经网络	(均方误差/置信区间/每平方米)
	KIBA			戴维斯: 0.222/0.896/0.723
	DTC			KIBA: 0.135/0.895/0.780
	梅斯			DTC: 0.171/0.881/0.830
	ToxCast			梅斯: 0.292/0.810/0.682
	缝合			ToxCast: 0.316/0.918/0.572 STITCH: 0.986/0.745/0.461

Manoochehri 等人[58]将药物-靶点相互作用 (DTI) 建模为半二分图, 并在 Luo 等人[40]整理的数据集上应用了深度神经网络。Zhao 等人[59]采用了一种名为 GANsDTA 的半监督生成对抗网络 (GAN) 来解决 DTI 预测任务, 该架构包含两个 GAN, 一个用于训练药物, 另一个用于训练靶点, 然后将两者结合到卷积神经网络 (CNN) 模型中。Lin 等人[60]提出了 DeepGS, 该模型利用图注意力网络 (GAT) 来表示药物, 双向门控循环单元 (BiGRU) 来处理局部化学环境, 卷积神经网络 (CNN) 来处理蛋白质, 具体来说, 使用了 Smi2Vec 和 Prot2Vec 进行向量化处理。Mahdaddi 等人[4]将 DTI 的识别视为回归问题, 在包括 Kiba、Davis 以及来自 BindingDB 的样本等数据集上部署了卷积神经网络 (CNN) 和基于注意力机制的双向长短期记忆网络 (BiLSTM)。

此外, 赵等人[61]构建了一个药物-蛋白质对 (DPP) 网络, 该网络整合了图卷积网络 (GCN) 和深度神经网络模型, 使用了来自人类蛋白质相互作用集成参考数据库 (HIPPIE)、DrugBank 以及黄金数据集的数据。为解决假阳性相关问题, 楚等人[63]基于级联深度森林 (CDF) 模型引入了 DTI-CDF, 并利用了黄金数据集。同时, 阮等人[62]提出了 GraphDTA, 该模型使用卷积神经网络 (CNN) 进行蛋白质表示训练, 并采用多种基于图的表示方法进行药物训练, 即 GCN、图注意力网络 (GAT)、图同构网络 (GIN) 以及 GAT-GCN 的组合。为了利用多种表示方法的特征提取优势, 杨等人[65]构建了一个模型, 该模型包含用于药物的多尺度图神经网络 (MGNN) 和用于蛋白质的多尺度卷积神经网络 (MCNN), 他们还采用了可解释的人工智能 (XAI) 来突出显示重要原子和键。最近, 穆吉吉等人[64]旨在通过开发基于深度长短期记忆网络 (DeepGLSTM) 回归架构来识别与 SARS-CoV-2 病毒蛋白结合的已获美国食品药品监督管理局 (FDA) 批准的药物, 该架构主要由用于药物的图卷积网络 (GCN) 和用于靶点的长短期记忆网络 (LSTM) 组成。同样, 达加等人[66]提出了 LEP-AD 回归架构, 该架构利用基于变压器的图卷积网络 (GCN) 和 ESM-2 跨越多个数据集, 包括 Davis、Kiba、DTC、Metz、ToxCast 和 STITCH。上述多种方法揭示了药物靶点相互作用 (DTI) 预测的复杂性, 并说明了如何通过不同数据集上整合各种机器学习和深度学习技术来增强对药物靶点相互作用的理解。

尽管现有的研究在药物靶点相互作用 (DTI) 预测方面已取得了一些令人鼓舞的成果, 但它们主要集中在分类任务上, 即预测相互作用是否发生。本研究将 DTI 预测视为回归问题, 旨在

估计相互作用强度, 同时保留关键信息。此外, 以往的研究通常仅使用有限数量的数据集, 有些甚至仅限于单一数据源。与此不同的是, 本研究利用了更广泛的数据集, 包括六个数据源用于回归任务, 以及三个额外的数据源用于分类任务, 以增强模型的泛化能力和鲁棒性。本文旨在多个数据集上超越当前技术, 在 DTI 的回归和分类任务中取得更好的预测效果。

3. 方法论

本节概述了所使用的数据集, 并讨论了用于执行结合亲和力预测回归任务的方法。此外, 该节还指明了用于训练和评估模型的硬件规格。

3.1. 数据源

我们使用了六个数据集来训练和评估模型, 分别是 Davis [67]、KIBA [68]、药物靶点公共数据库 (DTC) [69]、Metz [70]、毒性预测 (ToxCast) [71] 以及化学物质相互作用搜索工具 (STITCH) [72]。

戴维斯[67]数据集包含了激酶抑制剂与激酶之间的相互作用, 涵盖了超过80%的人类催化蛋白激酶组, 其中解离常数 (K_d) 为因变量。而基巴[68]包含了来自各种生物活性类型的补充信息, 包括 K_d 、抑制常数 (K_i) 和半数最大抑制浓度 (IC_{50}), 这些信息被定义为“基巴得分”。药物靶点连接[69]是一个网络平台, 为知识提取提供了多个抽象层次, 它主要包含药物-靶点生物活性数据, pK_i 从该数据集中提取, 它是 K_d 的负对数 (以10为底), 使用 pK_i 而非 K_d 使解释更直观。梅茨[70]同样关注激酶活性数据, 其中 pK_i 表示结合亲和力。毒理学预测[71]是一个针对数千种化学物质的体外高通量筛选 (HTS) 数据集, 包含数十万种相互作用。半数最大有效浓度 (AC_{50}) 是该数据集的因变量。STITCH[72]是一个多源数据集, 包含大量相互作用, 并使用其自身的评分系统。

表 5 展示了每个数据集中的药物和蛋白质的唯一数量。此外, 它还包含了它们之间的实验 (相互作用) 数量以及数据分割比例。我们已收集




图 3.数据集分布。

表 5 数据集比较。

数据集	毒品	目标	互动	验证 split	测试拆分
戴维斯 (K_d)	68	379	三万零五十六	20%	16.66%
奇巴	2068	229	一百一十八万两千五百四十四	20%	16.66%
DTC (pK_i)	5983	118	六万七千八百九十四	20%	20%
梅斯 (pK_i)	1471	170	三万五千三百零七	20%	30%
毒理学预测 (半数毒性浓度)	36	328	三十四万二千六百九十二	20%	20%
缝合; 缝合线; 缝合术	165 36		一万四千六百三十三万五千九百三十八	35%	

验证集是从训练集中划分出来的，而不是从整个数据集中划分。

为了确保比较的公平性，我们使用了来自[66]的数据集，该数据集已将数据集划分为训练集和测试集；我们还添加了一个验证集，以平衡对训练数据的拟合和对未见数据的泛化能力。图3使用核密度估计 (KDE) 表示了每个数据集中因变量的分布情况。如图所示，Davis 数据集使用 K_d 作为结合指标，而 DTC 和 Metz 则使用 pK_i ，ToxCast 使用 AC_{50} ，而 Kiba 和 STITCH 则定义了它们自己的定制评分。

K_d 是一种平衡常数，用于量化较大物体分解为较小成分的程度，它是结合常数的倒数。而 K_i 则衡量抑制剂与酶之间的结合亲和力。在某些情况下， K_d 和 K_i 可以近似相等；主要区别在于， K_d 是一个比 K_i 更为通用的术语。一些文献对这两个常数进行负对数变换，形成 pK_d 和 pK_i 。 IC_{50} 是指达到 50% 抑制所需的浓度；计算 K_i 需要找到 IC_{50} ，而 AC_{50} 则确定产生药物最大效应或活性 50% 所需的药物浓度。

公式 (1) 指明了 pK_d ，其中 $[L]$ 表示游离药物（未结合配体）的浓度， $[P]$ 表示游离靶点（未结合蛋白质）的浓度，而 $[LP]$ 则是结合复合物的浓度。

$$pK_d = -\log_{10} K_d = -\log_{10} \left(\frac{[L][P]}{[LP]} \right) \quad (1)$$

虽然式 (2) 计算的是以底物浓度 $[S]$ 表示的 pK_i ，而 K_m 是米氏常数，即观察到最大反应速率一半时的底物浓度，但 K_i 的计算源自 [73]。

$$pK_i = -\log_{10} K_i = -\log_{10} \left(\frac{IC_{50}}{1 + \frac{[S]}{K_m}} \right) \quad (2)$$

3.2. 方法

药物-靶点相互作用 (DTI) 预测任务首先将药物和蛋白质向量化为指纹和嵌入。然后，在获取提取特征的代表形式后，将结果输入到深度神经网络中，以预测结合亲和力和值。图 4 详细展示了模型架构。

在训练之前，我们使用多种向量化技术和转换器提取药物的特征，以捕捉药物的不同方面并提高泛化能力。特征提取技术包括原子对指纹、Avalon 指纹、分子访问系统 (MACCS) 键指纹、MinHash (MH) 指纹、Morgan 指纹、RDKit 指纹、SMILES 扩展连接 (SEC) 指纹、拓扑扭转指纹和局部度分布 (LDP) 指纹。我们所使用的所有描述符均来自 scikit-mol [74] Python 包，而 LDP 模型的实现则来自 Karate Club [75] 库。

至于蛋白质嵌入，我们使用了进化尺度建模 (ESM-2) [76,77] 进行特征提取，具体来说，是具有 30 亿参数、36 层和 2560 嵌入维度的模型。

我们对模型进行了多达 3000 轮的训练，设置了 200 轮的早停耐心值；也就是说，如果连续 200 轮损失值没有改善，训练过程就会停止。充足的计算资源和足够的样本数量使得批量大小可以达到 1024，学习率为 0.0005。为了减轻过拟合，我们使用了带有权重衰减的 Adam 优化器。




图 4.WAE-DTI 架构。首先，我们遍历每个数据集并提取独特的药物和蛋白质。对于每种药物，我们使用多种描述符计算其特征表示，包括原子对指纹、Avalon 指纹、MACCS 密钥指纹、MH 指纹、Morgan 指纹、RDKit 指纹、SEC 指纹、拓扑扭曲指纹和 LDP。对于每种蛋白质，我们使用 ESM-2 计算其嵌入。所有特征都通过存储在磁盘上来持久化。在训练过程中，我们使用计算出的特征来替换原始的 SMILES 表示和氨基酸序列。然后，我们对每个描述符进行排列，并训练其独立模型。根据模型在验证集上的表现，我们采用带有惩罚因子的加权平均集成，表现良好的模型会得到奖励；相反，表现不佳的模型会受到惩罚。集成模型的输出被视为最终预测结果。

损失函数我们采用了均方误差（MSE），其值为 0.00001。作为正则化的一种手段，我们在每个隐藏层之间插入了概率为 20% 的丢弃层，以随机停用神经元。

我们分别对每个药物转换器进行了训练。然后，我们将得到的训练模型作为加权平均集成模型的输入，该模型根据验证集的均方误差（MSE）为各个模型分配权重。模型权重的计算公式如式 (3) 所示，其中 w_i 表示模型 i 的权重， mse 表示验证集上的损失函数， p 是一个标量，表示惩罚因子， M 表示加权平均集成模型的输入模型数量。惩罚因子设置为 6，以显著降低表现不佳的模型的权重。

$$w_i = \frac{1}{mse^p} \quad \text{for } i = 1, 2, \dots, M \quad (3)$$

3.3. 计算资源

训练过程是在一台 HPE ProLiant DL380 Gen10 服务器上进行的，该服务器配备了两颗英特尔至强金牌 6130 处理器（主频 2.10 GHz）、256GB 内存以及两块英伟达 Tesla P40 显卡（每块显卡配备 24GB 虚拟内存）。模型是使用 PyTorch 2.2.1 版本和 Python 3.11.8 版本构建的。环境配置了 CUDA 工具包 12.4 版本和 cuDNN 库 8.9 版本，以支持 GPU 训练。所使用的操作系统为 Ubuntu 24.04.6 版本。

3.4. 模型评估

为了评估模型的性能，我们使用均方误差（MSE）、一致性指数（CI）以及 R^2_{Mas} 评估指标，将预测结果与测试集的真实值进行了比较。

均方误差（MSE）表示为每个示例的预测值与实际值之间平均平方差。公式 (4) 表示了这一指标的数学符号；MSE 值越低，表明预测值与实际值之间的平均距离越小。

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (4)$$

CI 是 ROC 曲线下面积（AUC）的扩展版本，它考虑了删失数据。CI 能够全面评估模型的判别能力。CI 可以通过公式计算得出。

$$CI = \frac{\sum_{i < j} w_{ij} I(Y_i < Y_j, T_i < T_j)}{\sum_{i < j} w_{ij}} \quad (5)$$

R^2_M [78] 是著名的决定系数 (R_M) 的一个变体，通过公式 (6) 进行测量，并用于基于回归的定量构效关系 (QSAR) 的验证。

$$r_m^2 = r^2 \cdot (1 - \sqrt{r^2 - r_0^2}) \quad (6)$$

4. 结果

对于每个数据集，我们提取药物和蛋白质的表示形式，药物通过九种不同的指纹描述符来表示，蛋白质则使用 ESM-2 来表示。这些表示形式在训练前就被提取并保存下来，因此无需在每个训练周期重新计算嵌入，而是直接从本地磁盘反序列化。接下来，对于每个数据集和药物描述符，我们通过输入所选的药物描述符与 ESM-2 蛋白质嵌入的组合来开始训练模型，每个模型在未应用的情况下结果如下

表 6
针对 Davis 和 Kiba 数据集，将模型在五项实验中的表现与相关工作进行比较。

模型	戴维斯 (K ₀)			奇巴		
	均方误差	CI	r^2m	均方误差	CI	r^2m
KronRLS ^a	0.379	0.871	0.407	0.411	0.782	0.342
SimBoost ^a	0.282	0.872	0.644	0.222	0.836	0.629
深度药物靶点相互作用预测模型	0.261	0.878	0.630	0.194	0.863	0.673
MT-DTI (无微调)	0.268	0.875	0.633	0.220	0.844	0.584
MT-DTI	0.245	0.887	0.665	0.152	0.882	0.738
WideDTA	0.262	0.886	0.633 ^b	0.179	0.875	0.675 ^b
GANsDTA	0.276	0.881	0.653	0.224	0.866	0.675
注意力时间序列分解分析 (Attention-DTA)	0.216	0.893	0.677	0.155	0.882	0.755
DeepGS	0.252	0.882	0.686	0.193	0.860	0.684
图数据处理架构 (图卷积网络)	0.254	0.880	–	0.139	0.889	–
图DTA (GAT-GCN)	0.245	0.881	–	0.139	0.891	–
图DTA (图注意力网络)	0.232	0.892	0.662 ^b	0.179	0.866	0.671 英镑
图DTA (图卷积神经网络)	0.229	0.893	0.649 ^b	0.147	0.882	0.684 英镑
CNN-AbiLSTM	0.235	0.897	0.668	0.179	0.876	0.733
深度长短期记忆网络	0.232	0.895	0.680	0.133	0.897	0.792
LEP-AD (AlphaFold)	0.228	0.894	0.692	0.133	0.893	0.752
LEP-AD	0.222	0.896	0.723	0.135	0.895	0.780
WAE-DTI	0.190	0.915	0.745	0.127	0.899	0.778

^a 引自[60]。 ^b 引自[66]。

表 7
在五个实验中，模型在 DTC 和 Metz 数据集上的性能与相关工作进行了比较。

模型	DTC (pK _i)			梅斯 (pK _i)		
	均方误差	CI	r^2m	均方误差	CI	r^2m
图DTA (GCN)	0.317	0.878	0.812	0.317	0.801	0.620
图DTA (GAT-GCN)	0.200	0.857	0.790	0.333	0.795	0.602
图DTA (GAT)	0.195	0.859	0.788	0.393	0.775	0.549
图DTA (图卷积神经网络) ^a	0.176	0.876	0.798	0.317	0.800	0.645
深度长短期记忆网络	0.149	0.895	0.841	0.294	0.810	0.640
LEP-AD	0.171	0.881	0.830	0.292	0.810	0.682
WAE-DTI	0.143	0.898	0.839	0.284	0.813	0.676

参考文献[66]。

集成学习可见附录 A。完成训练过程后，我们在同一数据集上对所有模型实施了加权平均集成模型，以提高预测的泛化能力。

表 6、7 和 8 展示了 WAE-DTI 在各数据集上的平均性能，基于五次重复实验，并与相关研究进行了比较。可以注意到，该模型在所有数据集上的表现均显著优于同类研究。具体而言，在 Davis 数据集上，我们取得了均方误差 (MSE) 为 0.190 ± 0.001 、一致性指数 (CI) 为 0.915 ± 0.001 以及 R^2 值为 0.745 ± 0.003 的成绩，而表现最佳的模型 (LEP-AD) 的相应数值分别为 0.222、0.896 和 R^2_{M} of 0.723。在 Kiba 数据集上，我们的模型取得了均方误差为 0.127 ± 0.001 、一致性指数为 0.899 ± 0.000 以及 R^2 值为 R^2_{M} of 0.778 ± 0.003 的成绩，而 LEP-AD 模型的相应数值分别为 0.135、0.895 和 R^2_{M} of 0.780。此外，在 DTC 数据集上，我们的模型取得了均方误差为 0.143 ± 0.001 、一致性指数为 0.898 ± 0.001 以及 R^2 值为 R^2_{M} of 0.839 ± 0.008 的成绩，而 LEP-AD 模型的相应数值分别为 0.149、0.895 和 R^2_{M} 0.841。再者，在 Metz 数据集上，我们的模型表现优于基准模型，取得了均方误差为 0.284 ± 0.004 、一致性指数为 0.813 ± 0.001 以及 R^2 值为 R^2_{M} of 0.676 ± 0.006 的成绩，而表现最佳的基准模型的相应数值分别为 0.289、0.810 和 R^2_{M} of 0.682。最后，我们的模型在 ToxCast 和 STITCH 数据集上的表现也优于基准模型。具体而言，在 ToxCast 数据集上，我们获得了均方误差 (MSE) 为 0.308 ± 0.001 、一致性指数 (CI) 为 0.922 ± 0.000 以及 R^2_{M} of 0.581 ± 0.003 的结果；而在 STITCH 数据集上，我们取得了均方误差 (MSE) 为 0.934 ± 0.004 、一致性指数 (CI) 为 0.772 ± 0.001 以及 R^2_{M} 为 0.488 ± 0.003 的成绩。相比之下，目标论文报告的 ToxCast 数据集的结果为均方误差 (MSE) 0.316、一致性指数 (CI) 0.918 以及 R^2_{M} for 0.572，而 STITCH 数据集的结果为均方误差 (MSE) 0.986、一致性指数 (CI) 0.745 以及 R^2_{M} 0.461。

在所有测试的数据集上，我们的方法始终实现了比 LEP-AD 更低的均方误差 (MSE)、更高的一致性指数 (CI) 和 R^2_{M} compared。这表明我们的方法在这些数据集上提供了更高的准确性、一致性和预测能力。然而，在 Kiba、DTC 和 Metz 数据集的 R^2_{M} metric 上，LEP-AD 和 DeepGLSTM 报告的结果略高。为了进一步可视化结果，我们为每个数据集构建了残差图，如图 5 所示；趋势线与水平线对齐表明模型拟合良好。在大多数数据集中，趋势线的斜率接近于零。但在 STITCH 数据集中，趋势线与水平线对齐不佳，这意味着 STITCH 上的预测任务比其他数据集更具挑战性，这从其 MSE、CI 和 R^2_{M} 中可以看出。此外，点的颜色表示使用高斯核的核密度估计 (KDE)。

总的来说，这些结果突显了我们所提出的方法 WAE-DTI 的有效性，在所有评估的数据集上，其表现都明显优于目标论文中的方法。

4.1. 模型在分类任务中的性能

尽管将药物与靶点之间的结合视为二元状态可能不如量化结合强度那样稳健，但在这种任务中对所提出模型的结果进行比较，证明了该模型在处理这两种情况时的灵活性，同时也验证了模型在分类任务中的性能。当然，这需要使用不同类型的数据库。此外，模型架构可能需要稍作修改，特别是损失函数的使用方面。

4.1.1. 材料

为确保该研究工作能够得到公正的评估，并与相关论文进行合理比较，我们采用了目标文献 [79] 中的材料。

表 8
针对 ToxCast 和 STITCH 数据集，在五项实验中模型性能与相关工作的对比。

模型	毒理学预测（半数毒性浓度）			缝合		
	均方误差	CI	r^2m	均方误差	CI	r^2m
图DTA（GCN）	0.316	0.917	0.561	1.022	–	0.424
图DTA（GAT-GCN）	0.317	0.917	0.566	–	–	–
图DTA（GAT）	0.346	0.911	0.535	–	–	–
图DTA（图卷积网络）	0.324	0.915	0.555	–	–	–
深度长短期记忆网络	0.313	0.919	0.565	0.992	–	0.430
LEP-AD	0.316	0.918	0.572	0.986	0.745	0.461
WAE-DTI	0.308	0.922	0.581	0.934	0.772	0.488

参考文献[66]。

表 9
分类数据集比较。

数据集	毒品	蛋白质	训练交互		验证交互		测试交互作用	
			积极的	否定的	积极的	否定的	积极的	否定的
BioSNAP	4510	2181	9619	9619	1374	1374	2748	2748
戴维斯	68	379	一千零四十三	一千零四十三	160	二千八百四十六	303	五千七百零八
BindingDB	一万零六百六十五	1413	6334	6334	927	5717	1905	一万一千三百四十八

表 10
分类模型的超参数。

超参数	价值
时期	3000
提前终止患者	200
提前停止得分决定因素	AUPRC
学习率	5×10^{-4}
优化器	亚当
权重衰减	10 的负 6 次方
丢弃概率	20%
损失函数	二元交叉熵

该数据集包含三个数据集，分别是来自 BioSNAP 的 MINER DTI [80]、Davis [67] 和 BindingDB [81]。尽管最新的 BioSNAP 更新包含 5017 种药物、2324 个靶点和 15138 个总相互作用，但为了与 [79] 中的数据集相匹配，使用了较旧的版本。该旧版本包含 4510 种药物、2181 个靶点和 13741 个总相互作用。由于 BioSNAP 仅包含正例，因此添加了负例未见样本以创建平衡数据集。Davis 包含 68 种药物和 379 个靶点，有 11103 个相互作用，涵盖了超过 80% 的人类激酶组。至于 BindingDB，它包含 10665 种药物和 1413 个靶点，有 32601 个相互作用。Davis 和 BindingDB 均使用解离常数 K_d 来测量结合亲和力。为了将预测值从连续值转换为二进制值，任何 K_d 小于 30 的值都表示结合成功。

表 9 列出了每个数据集中的独特药物、独特蛋白质以及相互作用的数量。数据集被划分为训练集、验证集和测试集的情况由 [79] 给出，因此结果的比较是合理且可靠的。该表还展示了每个数据集划分中二元标签的分布情况。

4.1.2. 方法

该模型试图预测药物与靶点的组合是否会结合。其架构与所提出的回归模型高度相似。然而，两者之间存在细微差别。两个模型都使用类似的嵌入和描述符来表示药物和蛋白质。表 10 列出了训练过程中使用的超参数。主要的区别在于早停判定指标，回归模型使用均方误差（MSE），而分类模型使用精确率 - 召回率曲线下的面积（AUPRC）。此外，回归模型使用均方误差作为其损失函数，而分类模型使用二元交叉熵（BCE）损失。

另一个显著的区别在于分配给各模型的集成权重；具体来说，分类模型使用 AUPRC。这些权重的计算使用公式 (7)，其中 W_i denotes 模型 i 的权重，auprc 表示模型在验证

集上的损失， p 是一个惩罚因子，用于惩罚表现较差的模型， M 是集成中包含的模型总数。惩罚因子 p 设为 6，以显著降低表现不佳的模型的影响。

$$w_i = \text{auprc}^p \text{ for } i = 1, 2, \dots, M \tag{7}$$

4.1.3. 模型评估

为了将我们的结果与现有文献进行比较，我们使用多种评估指标（如灵敏度、特异性、受试者工作特征曲线下的面积（AUC）以及精确率 - 召回率曲线下的面积（AUPRC））将预测结果与测试集的真实值进行对比。

灵敏度衡量的是检测结果呈阳性的概率。灵敏度高表明检测能有效识别出存在该状况的情况，从而将假阴性结果降至最低。它也被称为真阳性率。灵敏度的计算公式可由 (8) 式表示。

$$\text{Sensitivity} = \frac{TP}{TP + FN} \tag{8}$$

特异性衡量的是阴性（无病）检测结果的概率。特异性高表明该检测能有效识别出真正无病的情况，从而将假阳性结果降至最低。它也被称为真阴性率。特异性的评估可使用公式 (9)。

$$\text{Specificity} = \frac{TN}{TN + FP} \tag{9}$$

AUC 通过评估真阳性率（TPR）和假阳性率（FPR）之间的权衡来衡量模型区分正类和负类的能力。它使用梯形法进行近似计算，如公式 (10) 所示。然而，直接计算 AUC 可能会导致过于乐观的估计 [82,83]。

$$\text{AUC} \approx \sum_{i=1}^{n-1} \frac{(\text{Sensitivity}_{y_i} + \text{Sensitivity}_{y_{i+1}}) \cdot (\text{Specificity}_{y_i} - \text{Specificity}_{y_{i+1}})}{2} \tag{10}$$




图 5. WAE-DTI 在每个数据集上的预测残差图。

表 1

在五个实验中，模型在 BioSNAP 分类数据集上的性能与相关工作进行了比较。

纸	敏感性	特异性	AUC	AUPRC	阈值
LR	0.755 ± 0.039	0.800 ± 0.018	0.846 ± 0.004	0.850 ± 0.011	0.434
深度神经网络	0.776 ± 0.040	0.838 ± 0.024	0.849 ± 0.003	0.855 ± 0.010	0.499
GNN-CPI	0.780 ± 0.014	0.819 ± 0.012	0.879 ± 0.007	0.890 ± 0.004	0.349
深度药物靶点相互作用	0.789 ± 0.027	0.845 ± 0.017	0.876 ± 0.005	0.876 ± 0.006	0.347
深度药物靶点相互作用预测模型781 ± 0.015		0.824 ± 0.012	0.876 ± 0.005	0.883 ± 0.006	0.466
DeepConv-DTI	0.770 ± 0.023	0.832 ± 0.016	0.883 ± 0.002	0.889 ± 0.005	0.441
分子转运	0.775 ± 0.032	0.851 ± 0.014	0.895 ± 0.002	0.901 ± 0.004	0.431
WAE-DTI	0.862 ± 0.003	0.871 ± 0.006	0.935 ± 0.001	0.943 ± 0.001	0.478

AUPRC 与 AUC 类似。不过，AUPRC 评估的是精度和召回率之间的权衡，而非真阳性率和假阳性率之间的权衡。它也可以大致通过梯形法计算，如公式 (11) 所示。

$$AUPRC \approx \sum_{i=1}^{n-1} \frac{(Precision_i + Precision_{i+1}) \cdot (Recall_{i+1} - Recall_i)}{2} \quad (11)$$

4.1.4. 结果

在完成训练过程并基于测试集评估模型之后，附录 B 列出了应用集成学习之前每个模型的结果。此外，图 6 展示了模型在 AUC 和 AUPRC 方面的性能。同时，我们还基于灵敏度、特异性、AUC 和 AUPRC 将预测结果与相关论文进行了比较。所提出的模型在药物-靶点相互作用 (DTI) 分类任务中取得了显著的改进。如表 11、12 和 13 所示，这些表展示了在五次随机运行中应用集成投票后的模型评估指标的均值和标准差，以确保性能并非纯属偶然。这些结果还与相关且最先进的模型进行了比较，即 LR [79]、DNN [79]、GNN-CPI [84]、DeepDTI [47]、DeepDTA [49]、DeepConv-DTI [54] 和 MolTrans [79]。

用于确定灵敏度和特异性之间权衡的选定阈值定义为两者之间的最小差值，如公式 (12)

所示。该阈值也可以指定为能产生精度和召回率的最高调和平均值 (F1 分数) 的那个阈值；然而，这可能会导致灵敏度和特异性之间存在较大差异。

$$Threshold = \min_t |sensitivity(t) - specificity(t)| \quad (12)$$

5. 讨论

使用上述数据集训练模型，并将结果与相关论文进行比较后发现，所提出的模型利用了诸如嵌入等向量化技术来表示药物和蛋白质，在均方误差 (MSE)、CI 和 R^2_M 方面表现更优。这些结果表明，由于向量表示的表达能力优于原始字符串值，该模型能够有效地捕捉数据中的潜在关系，而原始字符串值往往无法捕捉这些分子的复杂性。因此，在开始训练过程之前，药物和蛋白质不是直接输入原始拼接值，而是表示在潜在空间中并保存下来；这样做提高了模型的性能和效率。

至于 [64,66] 在 Kiba、DTC 和 Metz 数据集上针对 R^2_M evaluation 指标的报告结果，其数值略高于我们结果的平均值。然而，当考虑到




图 6. 针对每个分类数据集的随机实验，展示模型性能的图表，包括 (a) 受试者工作特征 (ROC) 曲线和 (b) 精确率 - 召回率 (PR) 曲线。

表 12

在 Davis 分类数据集上，模型在五次实验中的性能与相关工作进行的比较。

纸	敏感性	特异性	AUC	AUPRC	阈值
LR	0.699 ± 0.051	0.842 ± 0.03	0.835 ± 0.010	0.232 ± 0.023	0.399
深度神经网络	0.764 ± 0.045	0.860 ± 0.038	0.864 ± 0.009	0.258 ± 0.024	0.489
GNN-CPI	0.696 ± 0.047	0.842 ± 0.039	0.840 ± 0.012	0.269 ± 0.020	0.487
深度药物靶点相互作用	0.751 ± 0.015	0.853 ± 0.012	0.861 ± 0.002	0.231 ± 0.006	0.387
深度药物靶点相互作用预测模型	0.764 ± 0.045	0.865 ± 0.020	0.880 ± 0.007	0.302 ± 0.04	0.482
深度卷积药物靶点相互作用预测模型 (DeepConv-DTI)	0.800 ± 0.02	0.876 ± 0.013	0.884 ± 0.008	0.299 ± 0.039	0.438
分子转运	0.800 ± 0.02	0.876 ± 0.013	0.907 ± 0.002	0.404 ± 0.016	0.447
WAE-DTI	0.900 ± 0.013	0.867 ± 0.010	0.936 ± 0.002	0.474 ± 0.01	0.528

表 13

针对 BindingDB 分类数据集，将模型在五项实验中的表现与相关工作进行了比较。

纸	敏感性	特异性	AUC	AUPRC	阈值
LR	0.741 ± 0.013	0.896 ± 0.011	0.887 ± 0.002	0.557 ± 0.015	0.394
深度神经网络	0.769 ± 0.028	0.914 ± 0.021	0.908 ± 0.003	0.613 ± 0.015	0.371
GNN-CPI	0.754 ± 0.015	0.903 ± 0.011	0.900 ± 0.004	0.578 ± 0.015	0.406
深度药物靶点相互作用	0.651 ± 0.024	0.895 ± 0.023	0.844 ± 0.002	0.429 ± 0.005	0.06
深度药物靶点相互作用预测模型	0.780 ± 0.035	0.915 ± 0.016	0.913 ± 0.003	0.622 ± 0.012	0.305
深度卷积药物靶点相互作用预测模型 (DeepConv-DTI)	0.797 ± 0.005	0.905 ± 0.013	0.908 ± 0.004	0.611 ± 0.015	0.318
分子转运	0.797 ± 0.005	0.896 ± 0.007	0.914 ± 0.001	0.622 ± 0.007	0.355
WAE-DTI	0.885 ± 0.006	0.853 ± 0.007	0.931 ± 0.001	0.707 ± 0.005	0.517

标准差表明，他们所报告的较高结果在我们的模型可实现的范围内。根据经验法则，他们的结果落在均值的一个标准差范围内，这涵盖了约 68% 的数据点，表明这种差异在统计学上并不显著。

此外，该模型似乎并非旨在处理新型药物或蛋白质。如果在测试集中引入未曾见过的药物或蛋白质，模型很可能会给出糟糕的预测。这种任务通常被称为零样本学习，即不仅在测试期间药物和蛋白质的相互作用对是未曾见过的，而且在测试阶段还可能引入前所未有的药物或蛋白质，或者两者皆有。要克服这一挑战，模型必须有效地捕捉药物和蛋白质的化学特性。然而，发现新型药物正变得越来越罕见。不过，蛋白质的形式数量几乎可以是无限的。

值得一提的是，有些研究（如[65]）并不适用于与我们提出的方法进行比较。尽管它们使用了相似的数据集，但训练集和测试集的使用存在不匹配的情况。具体来说，这些研究中的作者使用的样本数量较少。因此，直接进行比

较是无效且可能不公平的，因为使用不同的数据集进行结果比较无法得出确切的结论。为了解决这个问题，必须对数据集中的样本数量和划分策略进行标准化，以确保比较具有统计学意义。

作为未来的工作，为了增强我们模型的稳健性，必须对 Kiba、DTC 和 Metz 数据集的特性进行分析，并与其它数据集在 R^2_M evaluation 指标方面进行比较。该分析应包括对药物和蛋白质的元数据进行比较，例如原子和键的数量、药物重量、重原子数量、氢原子数量、蛋白质的芳香性以及分子量。为了解决零样本学习问题，增加更多的示例有助于减轻性能损失。此外，将药物和蛋白质的元数据作为特征添加进来，可以使模型更好地处理新的示例。

6. 结论

我们制定了一种加权平均集成方法来预测药物-靶点相互作用，将其命名为 WAE-DTI，该方法基于使用九种指纹描述符（即原子对）将药物向量化。

表 A.1

在对戴维斯回归数据集进行集成学习之前，五个实验中模型的表现。

药物	蛋白质	均方误差	CI	r^2m	分钟
原子对指纹	ESM-2	0.229 ± 0.006	0.892 ± 0.002	0.706 ± 0.007	7.150 ± 1.506
阿瓦隆指纹	ESM-2	0.213 ±0.005	0.897 ± 0.004	0.718 ± 0.01	10.303 ± 0.661
MACCS 密钥指纹	ESM-2	0.217 ± 0.002	0.895 ± 0.004	0.706±0.007	9.363 ± 1.365
MH 指纹	ESM-2	0.217±0.007	0.894 ± 0.002	0.709 ± 0.014	14.253 ± 1.849
摩根指纹	ESM-2	0.220±0.005	0.895±0.003	0.700 ± 0.01	12.947 ± 1.476
RDKit指纹	ESM-2	0.222 ± 0.008	0.895 ± 0.002	0.711±0.011	10.047 ± 2.675
SEC 指纹	ESM-2	0.219 ± 0.004	0.893 ± 0.004	0.711 ± 0.004	11.993 ± 1.107
拓扑扭指纹	ESM-2	0.218±0.007	0.896 ± 0.002	0.704±0.012	12.587 ± 2.957
自民党	ESM-2	0.310 ± 0.003	0.853 ± 0.003	0.597±0.014	18.023 ± 3.471

表 A.2

在进行 Kiba 回归数据集的集成学习之前，五个实验中模型的表现情况。

药物	蛋白质	均方误差	CI	r^2m	分钟
原子对指纹	ESM-2	0.155±0.002	0.885 ± 0.001	0.751 ± 0.006	55.157 ± 6.165
阿瓦隆指纹	ESM-2	0.150 ±0.002	0.883 ± 0.001	0.772 ± 0.006	49.700 ±5.369
MACCS 密钥指纹	ESM-2	0.171 ± 0.002	0.868 ± 0.003	0.732 ± 0.013	58.030 ± 3.450
MH 指纹	ESM-2	0.158 ± 0.002	0.883 ± 0.001	0.757 ± 0.014	57.120 ± 5.583
摩根指纹	ESM-2	0.157 ± 0.003	0.883 ± 0.001	0.753±0.014	56.350 ± 4.836
RDKit指纹	ESM-2	0.154 ± 0.001	0.885 ±0.002	0.751 ± 0.010	63.560 ± 14.731
SEC 指纹	ESM-2	0.158 ± 0.002	0.883 ± 0.002	0.756 ± 0.009	60.590 ± 16.958
拓扑扭指纹	ESM-2	0.158 ± 0.004	0.883 ± 0.003	0.747 ± 0.015	51.160 ± 12.123
自民党	ESM-2	0.389 ± 0.003	0.756 ± 0.001	0.422±0.007	92.910 ± 0.624

表 A.3

在进行 DTC 回归数据集的集成学习之前，五个实验中模型的表现。

药物	蛋白质	均方误差	CI	r^2m	分钟
原子对指纹	ESM-2	0.188 ± 0.004	0.883 ± 0.001	0.787 ± 0.009	28.917 ± 4.275
阿瓦隆指纹	ESM-2	0.177 ± 0.003	0.883 ± 0.003	0.812 ±0.013	22.953 ± 5.145
MACCS 密钥指纹	ESM-2	0.201±0.003	0.867 ± 0.003	0.800 ± 0.004	22.570 ± 5.897
MH 指纹	ESM-2	0.193 ± 0.006	0.877 ± 0.004	0.781 ± 0.010	33.233 ± 4.758
摩根指纹	ESM-2	0.191 ± 0.004	0.880±0.002	0.789±0.015	24.147 ± 3.512
RDKit指纹	ESM-2	0.179 ± 0.005	0.885 ±0.002	0.806 ± 0.017	29.973 ± 4.307
SEC 指纹	ESM-2	0.191 ± 0.001	0.881 ± 0.001	0.789±0.007	24.033 ± 3.985
拓扑扭指纹	ESM-2	0.189±0.003	0.880 ± 0.001	0.786±0.007	28.167 ± 2.972
自民党	ESM-2	0.434±0.005	0.768 ± 0.001	0.565±0.007	46.150 ± 2.969

除了使用 ESM-2 作为蛋白质嵌入器之外，我们还采用了 Avalon、MACCS keys、MH、Morgan、RDKit、SEC、拓扑扭转和 LDP 等九种模型。我们事先保存了所有描述符的向量，以避免在每个周期中重新计算。此外，我们根据每个模型在评估集上的表现为其分配了权重，然后使用加权平均集成方法进行预测。我们还引入了一个惩罚因子来抑制表现不佳的模型。这些模型分别在六个数据集（Davis、KIBA、DTC、Metz、ToxCast 和 STITCH）上独立训练。为了进一步评估模型的泛化能力，我们还对 BioSNAP、Davis 和 BindingDB 数据集进行了分类任务的适应性调整。结果表明，我们提出的模型在所有数据集上都有显著的改进。为了进一步提高结果，我们建议进行误差分析，以识别和研究模型预测误差较高的区域。

CRediT 作者贡献声明

塔里克·沙班：写作 - 审查与编辑、写作 - 原稿、软件、方法论、形式分析、概念化。**艾哈迈德·M·穆斯塔法：**写作 - 审查与编辑、监督、概念化。**穆斯塔法·Z·阿里：**监督、概念化。

道德声明

本研究未涉及从人类或动物受试者处收集任何新的数据。本研究中呈现的所有分析和发现均基于公开可用的数据集。因此，无需审查委员会的伦理批准。我们确认本研究不存在任何伦理问题。

资金

本研究未获外部资金支持。

利益冲突声明

作者声明，他们不存在任何已知的可能影响本论文所述研究工作的财务利益冲突或个人关系。

附录 A. 使用集成学习之前回归结果

表 A.1、A.2、A.3、A.4、A.5 和 A.6 展示了每个训练模型在用于集成模型之前五次重复实验的平均性能和标准偏差。除了纳入均方误差（MSE）、置信区间（CI）和 R^2_{Mof} 测试集之外，该表还显示了模型完成训练过程所需的时间（以分钟为单位），在处理较大数据集和具有大型向量输出的方法时，该时间可能会显著增加。此外，表现不佳的模型可能需要更长时间才能次优收敛。

附录 B. 使用集成学习之前的结果分类

与附录 A 中的表格类似，表 B.1、B.2 和 B.3 展示了每个训练模型在用于集成模型进行分类任务之前，五次重复实验的平均性能和标准差。不过，由于 MH 指纹描述符的性能较差，其结果未被纳入。

表 A.4

在进行集成学习之前，模型在 Metz 回归数据集上的五个实验中的表现。

药物	蛋白质	均方误差	CI	r^2m	分钟
原子对指纹	ESM-2	0.357±0.004	0.787 ± 0.002	0.570±0.005	7.623 ± 1.74
阿瓦隆指纹	ESM-2	0.325 ± 0.009	0.798 ± 0.005	0.616 ±0.005	11.030 ± 5.194
MACCS 密钥指纹	ESM-2	0.337±0.008	0.793 ± 0.003	0.610 ± 0.005	8.653 ± 1.907
MH 指纹	ESM-2	0.358±0.008	0.787 ± 0.002	0.575±0.016	11.217 ± 3.598
摩根指纹	ESM-2	0.365 ± 0.003	0.785 ± 0.001	0.561 ± 0.004	6.803 ± 0.760
RDKit指纹	ESM-2	0.330±0.003	0.796 ± 0.001	0.610±0.008	9.240 ± 1.83
SEC 指纹	ESM-2	0.364 ± 0.005	0.785 ± 0.002	0.563 ± 0.009	6.617 ± 2.395
拓扑扭指纹	ESM-2	0.363 ± 0.002	0.787 ± 0.001	0.563 ± 0.006	10.443 ± 3.239
自民党	ESM-2	0.532 ± 0.009	0.723 ± 0.003	0.418 ± 0.01	14.147 ± 3.052

表 A.5

在进行 ToxCast 回归数据集的集成学习之前，五个实验中模型的表现情况。

药物	蛋白质	均方误差	CI	r^2m	分钟
原子对指纹	ESM-2	0.326 ± 0.002	0.914 ± 0.002	0.553±0.008	37.240 ± 1.505
阿瓦隆指纹	ESM-2	0.321 ± 0.003	0.916 ± 0.001	0.559 ± 0.009	29.150 ± 0.219
MACCS 密钥指纹	ESM-2	0.324 ± 0.00	0.914 ± 0.001	0.561 ± 0.006	31.267 ± 0.694
MH 指纹	ESM-2	高价值	0.467 ± 0.030	0.004±0.005	31.363 ± 1.173
摩根指纹	ESM-2	0.333 ± 0.002	0.911±0.002	0.540±0.012	34.947 ± 1.226
RDKit指纹	ESM-2	0.323 ± 0.002	0.915 ± 0.001	0.553 ± 0.005	36.857 ± 1.719
SEC 指纹	ESM-2	0.333±0.003	0.911±0.002	0.540 ± 0.009	35.323 ± 0.961
拓扑扭指纹	ESM-2	0.331 ± 0.002	0.913 ± 0.001	0.541 ± 0.006	36.687 ± 2.912
自民党	ESM-2	0.369 ± 0.001	0.898 ± 0.00	0.506 ± 0.002	69.043 ± 10.728

表 A.6

在对 STITCH 回归数据集进行集成学习之前，五个实验中模型的表现情况。

药物	蛋白质	均方误差	CI	r^2m	分钟
原子对指纹	ESM-2	1.140 ± 0.003	0.751 ± 0.004	0.389 ± 0.004	199.053 ± 8.135
阿瓦隆指纹	ESM-2	1.078 ± 0.006	0.740 ± 0.006	0.417 ± 0.003	303.273 ± 86.829
MACCS 密钥指纹	ESM-2	1.120 ± 0.006	0.708 ± 0.004	0.407 ± 0.002	250.583 ± 58.438
MH 指纹	ESM-2	高价值	0.504±0.022	0.001 ± 0.001	164.047 ± 1.148
摩根指纹	ESM-2	1.122 ± 0.006	0.763 ± 0.004	0.398 ± 0.005	183.923 ± 4.397
RDKit指纹	ESM-2	1.143 ± 0.008	0.743±0.005	0.389 ± 0.006	262.890 ± 35.46
SEC 指纹	ESM-2	1.167 ± 0.006	0.759 ± 0.005	0.374±0.007	186.147 ± 6.879
拓扑扭指纹	ESM-2	1.163±0.003	0.754 ± 0.004	0.378 ± 0.004	196.000 ± 8.108
自民党	ESM-2	1.542 ± 0.003	0.627±0.002	0.201 ± 0.001	300.370 ± 62.823

表 B.1

在对 BioSNAP 分类数据集进行集成学习之前的五个实验中模型的表现。

药物	蛋白质	敏感性	特异性	AUC
原子对指纹	ESM-2	0.824 ± 0.008	0.830±0.019	0.899 ± 0.005
阿瓦隆指纹	ESM-2	0.859 ± 0.008	0.872 ± 0.005	0.932 ± 0.002
MACCS 密钥指纹	ESM-2	0.873 ± 0.006	0.884 ± 0.006	0.942 ± 0.002
摩根指纹	ESM-2	0.789 ± 0.008	0.830 ± 0.004	0.880 ± 0.003
RDKit指纹	ESM-2	0.841 ± 0.002	0.857 ± 0.009	0.915 ± 0.003
SEC 指纹	ESM-2	0.795 ± 0.006	0.826 ± 0.01	0.879 ± 0.001
拓扑扭指纹	ESM-2	0.807 ± 0.014	0.834 ± 0.010	0.888 ± 0.004
自民党	ESM-2	0.767 ± 0.010	0.805±0.012	0.858 ± 0.003
药物	蛋白质	AUPRC	阈值	分钟
原子对指纹	ESM-2	0.905 ± 0.002	0.560±0.251	7.083±1.940
阿瓦隆指纹	ESM-2	0.933 ± 0.001	0.582±0.121	6.213±1.021
MACCS 密钥指纹	ESM-2	0.945 ± 0.002	0.557±0.126	5.757±1.746
摩根指纹	ESM-2	0.892 ± 0.004	0.701±0.082	3.987±0.970
RDKit指纹	ESM-2	0.917 ± 0.003	0.670±0.186	7.670±1.473
SEC 指纹	ESM-2	0.888 ± 0.002	0.682±0.053	4.057±1.638
拓扑扭指纹	ESM-2	0.896 ± 0.003	0.442±0.098	3.780±0.970
自民党	ESM-2	0.862 ± 0.001	0.537±0.047	1.820±0.190

表 B.2

在对 Davis 分类数据集进行集成学习之前，五个实验中模型的表现情况。

药物	蛋白质	敏感性	特异性	AUC
原子对指纹	ESM-2	0.892 ± 0.009	0.853 ± 0.015	0.925 ± 0.005
阿瓦隆指纹	ESM-2	0.882 ± 0.013	0.847 ± 0.005	0.925 ± 0.005
MACCS 密钥指纹	ESM-2	0.890 ± 0.006	0.862 ± 0.009	0.929 ± 0.003
摩根指纹	ESM-2	0.881 ± 0.019	0.855 ± 0.017	0.926 ± 0.003
RDKit指纹	ESM-2	0.876 ± 0.020	0.844 ± 0.01	0.924 ± 0.004
SEC 指纹	ESM-2	0.879 ± 0.018	0.852 ± 0.009	0.926 ± 0.004
拓补扭指纹	ESM-2	0.874 ± 0.02	0.851 ± 0.007	0.919 ± 0.005
自民党	ESM-2	0.797 ± 0.015	0.728 ± 0.014	0.827 ± 0.003
药物	蛋白质	AUPRC	阈值	分钟
原子对指纹	ESM-2	0.408 ± 0.014	0.559 ± 0.168	3.017 ± 0.508
阿瓦隆指纹	ESM-2	0.431 ± 0.014	0.457 ± 0.082	1.660 ± 0.343
MACCS 密钥指纹	ESM-2	0.415 ± 0.021	0.564 ± 0.119	1.083 ± 0.072
摩根指纹	ESM-2	0.390 ± 0.016	0.590 ± 0.289	2.580 ± 0.507
RDKit指纹	ESM-2	0.416 ± 0.002	0.485 ± 0.093	2.793 ± 0.230
SEC 指纹	ESM-2	0.398 ± 0.022	0.561 ± 0.125	2.553 ± 0.299
拓补扭指纹	ESM-2	0.383 ± 0.009	0.618 ± 0.048	2.480 ± 0.287
自民党	ESM-2	0.239 ± 0.003	0.537 ± 0.059	0.837 ± 0.113

表 B.3

在对 BindingDB 分类数据集进行集成学习之前的五个实验中模型的表现。

药物	蛋白质	敏感性	特异性	AUC
原子对指纹	ESM-2	0.869 ± 0.009	0.830 ± 0.015	0.909 ± 0.011
阿瓦隆指纹	ESM-2	0.883 ± 0.007	0.833 ± 0.011	0.925 ± 0.003
MACCS 密钥指纹	ESM-2	0.886 ± 0.009	0.841 ± 0.006	0.923 ± 0.001
摩根指纹	ESM-2	0.831 ± 0.005	0.794 ± 0.003	0.879 ± 0.002
RDKit指纹	ESM-2	0.885 ± 0.004	0.832 ± 0.007	0.914 ± 0.001
SEC 指纹	ESM-2	0.844 ± 0.012	0.795 ± 0.006	0.881 ± 0.004
拓补扭指纹	ESM-2	0.876 ± 0.015	0.822 ± 0.014	0.908 ± 0.013
自民党	ESM-2	0.818 ± 0.013	0.788 ± 0.019	0.873 ± 0.006
药物	蛋白质	AUPRC	阈值	分钟
原子对指纹	ESM-2	0.636 ± 0.014	0.481 ± 0.054	6.157 ± 1.244
阿瓦隆指纹	ESM-2	0.651 ± 0.005	0.457 ± 0.045	2.620 ± 0.413
MACCS 密钥指纹	ESM-2	0.671 ± 0.004	0.372 ± 0.082	3.777 ± 1.089
摩根指纹	ESM-2	0.597 ± 0.001	0.468 ± 0.052	3.543 ± 0.475
RDKit指纹	ESM-2	0.634 ± 0.007	0.490 ± 0.076	3.733 ± 0.308
SEC 指纹	ESM-2	0.598 ± 0.002	0.500 ± 0.049	3.360 ± 0.377
拓补扭指纹	ESM-2	0.615 ± 0.016	0.518 ± 0.056	4.443 ± 1.776
自民党	ESM-2	0.511 ± 0.008	0.489 ± 0.057	2.673 ± 0.704

参考文献

[1] Ezzat A, Wu M, Li X-L, Kwok C-K. Computational prediction of drug–target interactions using chemogenomic approaches: an empirical survey. *Brief Bioinform* 2019;20:1337–57. <http://dx.doi.org/10.1093/bib/bby002>.

[2] Bagherian M, Sabeti E, Wang K, Sartor MA, Nikolovska-Coleska Z, Najarian K. Machine learning approaches and databases for prediction of drug–target interaction: a survey paper. *Brief Bioinform* 2021;22:247–69. <http://dx.doi.org/10.1093/bib/bbz157>.

[3] Kastritis PL, Bonvin AMJJ. On the binding affinity of macromolecular interactions: daring to ask why proteins interact. *J R Soc Interface* 2013;10:20120835. <http://dx.doi.org/10.1098/rsif.2012.0835>.

[4] Mahdaddi A, Meshoul S, Belguidoum M. EA-based hyperparameter optimization of hybrid deep learning models for effective drug-target interactions prediction. *Expert Syst Appl* 2021;185. <http://dx.doi.org/10.1016/j.eswa.2021.115525>.

[5] Chen R, Liu X, Jin S, Lin J, Liu J. Machine learning for drug-target interaction prediction. *Molecules* 2018;23:2208. <http://dx.doi.org/10.3390/molecules23092208>.

[6] Zheng X, Ding H, Mamitsuka H, Zhu S. Collaborative matrix factorization with multiple similarities for predicting drug-target interactions. In: *Proceedings of the 19th ACM SIGKDD international conference on Knowledge discovery and data mining*. New York, NY, USA: ACM; 2013, p. 1025–33. <http://dx.doi.org/10.1145/2487575.2487670>.

[7] Faulon JL, Misra M, Martin S, Sale K, Sapra R. Genome scale enzyme - metabolite and drug - target interaction predictions using the signature molecular descrip-tor. *Bioinformatics* 2008;24:225–33. <http://dx.doi.org/10.1093/bioinformatics/btm580>.

[8] Tabei Y, Pauwels E, Stoven V, Takemoto K, Yamanishi Y. Identification of chemogenomic features from drug-target interaction networks using interpretable classifiers. *Bioinformatics* 2012;28. <http://dx.doi.org/10.1093/bioinformatics/bts412>.

[9] Yu H, Chen J, Xu X, Li Y, Zhao H, Fang Y, et al. A systematic prediction of multiple drug-target interactions from chemical, genomic, and pharmacological data. *PLoS ONE* 2012;7. <http://dx.doi.org/10.1371/journal.pone.0037608>.

[10] Cao DS, Liu S, Xu QS, Lu HM, Huang JH, Hu QN, et al. Large-scale prediction of drug-target interactions using protein sequences and drug topological structures. *Anal Chim Acta* 2012;752:1–10. <http://dx.doi.org/10.1016/j.aca.2012.09.021>.

[11] Van Laarhoven T, Marchiori E. Predicting drug-target interactions for new drug compounds using a weighted nearest neighbor profile. *PLoS ONE* 2013;8. <http://dx.doi.org/10.1371/journal.pone.0066952>.

[12] Wang Y, Zeng J. Predicting drug-target interactions using restricted Boltzmann machines. 29, 2013, <http://dx.doi.org/10.1093/bioinformatics/btt234>.

[13] Yuan Q, Gao J, Wu D, Zhang S, Mamitsuka H, Zhu S. DrugE-rank: Improving drug-target interaction prediction of new candidate drugs or targets by ensemble learning to rank. *Bioinformatics* 2016;32:118–27. <http://dx.doi.org/10.1093/bioinformatics/btw244>.

[14] Ezzat A, Wu M, Li XL, Kwok CK. Drug-target interaction prediction via class imbalance-aware ensemble learning. *BMC Bioinformatics* 2016;17. <http://dx.doi.org/10.1186/s12859-016-1377-y>.

[15] Wang L, You Z-H, Chen X, Yan X, Liu G, Zhang W. RFDT: A rotation forest-based predictor for predicting drug-target interactions using drug structure and protein sequence information. *Curr Protein Peptide Sci* 2016;19:445–54. <http://dx.doi.org/10.2174/13892037186661611411656>.

[16] Yao ZJ, Dong J, Che YJ, Zhu MF, Wen M, Wang NN, et al. TargetNet: a web service for predicting potential drug–target interaction profiling via multi-target SAR models. *J Comput Aided Mol Des* 2016;30:413–24. <http://dx.doi.org/10.1007/s10822-016-9915-2>.

[17] He T, Heidemeyer M, Ban F, Cherkasov A, Ester M. SimBoost: a read-across approach for predicting drug–target binding affinities using gradient boosting machines. *J Cheminform* 2017;9:24. <http://dx.doi.org/10.1186/s13321-017-0209-z>.

[18] Rayhan F, Ahmed S, Shatabda S, Farid DM, Mousavian Z, Dehzangi A, et al. IDTI-ESBoost: Identification of drug target interaction using evolutionary and structural features with boosting. *Sci Rep* 2017;7. <http://dx.doi.org/10.1038/s41598-017-18025-2>.

[19] Ding Y, Tang J, Guo F. Identification of drug-target interactions via multiple information integration. *Inform Sci* 2017;418–419:546–60. <http://dx.doi.org/10.1016/j.ins.2017.08.045>.

- [20] Li Z, Han P, You ZH, Li X, Zhang Y, Yu H, et al. In silico prediction of drug-target interaction networks based on drug chemical structure and protein sequences. *Sci Rep* 2017;7. <http://dx.doi.org/10.1038/s41598-017-10724-0>.
- [21] Shi H, Liu S, Chen J, Li X, Ma Q, Yu B. Predicting drug-target interactions using lasso with random forest based on evolutionary information and chemical structure. *Genomics* 2019;111:1839–52. <http://dx.doi.org/10.1016/j.ygeno.2018.12.007>.
- [22] Yamanishi Y, Araki M, Gutteridge A, Honda W, Kanehisa M. Prediction of drug-target interaction networks from the integration of chemical and genomic spaces. *Bioinformatics* 2008;24. <http://dx.doi.org/10.1093/bioinformatics/btm162>.
- [23] Bleakley K, Yamanishi Y. Supervised prediction of drug-target interactions using bipartite local models. *Bioinformatics* 2009;25:2397–403. <http://dx.doi.org/10.1093/bioinformatics/btp433>.
- [24] Yamanishi Y, Kotera M, Kanehisa M, Goto S. Drug-target interaction prediction from chemical, genomic and pharmacological data in an integrated framework. *Bioinformatics* 2010;26. <http://dx.doi.org/10.1093/bioinformatics/btq176>.
- [25] Van Laarhoven T, Nabuurs SB, Marchiori E. Gaussian interaction profile kernels for predicting drug-target interaction. *Bioinformatics* 2011;27:3036–43. <http://dx.doi.org/10.1093/bioinformatics/btr500>.
- [26] Gönen M. Predicting drug-target interactions from chemical and genomic kernels using Bayesian matrix factorization. *Bioinformatics* 2012;28:2304–10. <http://dx.doi.org/10.1093/bioinformatics/bts360>.
- [27] Chen X, Liu MX, Yan GY. Drug-target interaction prediction by random walk on the heterogeneous network. *Mol Biosyst* 2012;8:1970–8. <http://dx.doi.org/10.1039/c2mb00002d>.
- [28] Mei JP, Kwok CK, Yang P, Li XL, Zheng J. Drug-target interaction prediction by learning from local information and neighbors. *Bioinformatics* 2013;29:238–45. <http://dx.doi.org/10.1093/bioinformatics/bts670>.
- [29] Alaimo S, Pulvirenti A, Giugno R, Ferro A. Drug-target interaction prediction through domain-tuned network-based inference. *Bioinformatics* 2013;29:2004–8. <http://dx.doi.org/10.1093/bioinformatics/btt307>.
- [30] Cobanoglu MC, Liu C, Hu F, Oltvai ZN, Bahar I. Predicting drug-target interactions using probabilistic matrix factorization. *J Chem Informat Model* 2013;53:3399–409. <http://dx.doi.org/10.1021/ci400219z>.
- [31] Yamanishi Y, Kotera M, Moriya Y, Sawada R, Kanehisa M, Goto S. DINIES: Drug-target interaction network inference engine based on supervised analysis. *Nucleic Acids Res* 2014;42. <http://dx.doi.org/10.1093/nar/gku337>.
- [32] Pahikkala T, Airola A, Pietilä S, Shakyawar S, Szwarda A, Tang J, et al. Toward more realistic drug-target interaction predictions. *Brief Bioinform* 2015;16:325–37. <http://dx.doi.org/10.1093/bib/bbu010>.
- [33] Liu Y, Wu M, Miao C, Zhao P, Li XL. Neighborhood regularized logistic matrix factorization for drug-target interaction prediction. *PLoS Comput Biol* 2016;12. <http://dx.doi.org/10.1371/journal.pcbi.1004760>.
- [34] Nascimento AC, Prudêncio RB, Costa IG. A multiple kernel learning algorithm for drug-target interaction prediction. *BMC Bioinformatics* 2016;17. <http://dx.doi.org/10.1186/s12859-016-0890-3>.
- [35] Hao M, Wang Y, Bryant SH. Improved prediction of drug-target interactions using regularized least squares integrating with kernel fusion technique. *Anal Chim Acta* 2016;909:41–50. <http://dx.doi.org/10.1016/j.aca.2016.01.014>.
- [36] Ezzat A, Zhao P, Wu M, Li XL, Kwok CK. Drug-target interaction prediction with graph regularized matrix factorization. *IEEE/ACM Trans Comput Biol Bioinform* 2017;14:646–56. <http://dx.doi.org/10.1109/TCBB.2016.2530062>.
- [37] Lu Y, Guo Y, Korhonen A. Link prediction in drug-target interactions network using similarity indices. *BMC Bioinformatics* 2017;18. <http://dx.doi.org/10.1186/s12859-017-1460-z>.
- [38] Hao M, Bryant SH, Wang Y. Predicting drug-target interactions by dual-network integrated logistic matrix factorization. *Sci Rep* 2017;7. <http://dx.doi.org/10.1038/srep40376>.
- [39] Wu Z, Cheng F, Li J, Li W, Liu G, Tang Y. SDTNBI: An integrated network and chemoinformatics tool for systematic prediction of drug-target interactions and drug repositioning. *Brief Bioinform* 2017;18:333–47. <http://dx.doi.org/10.1093/bib/bbw012>.
- [40] Luo Y, Zhao X, Zhou J, Yang J, Zhang Y, Kuang W, et al. A network integration approach for drug-target interaction prediction and computational drug repositioning from heterogeneous information. *Nature Commun* 2017;8. <http://dx.doi.org/10.1038/s41467-017-00680-8>.
- [41] Olayan RS, Ashoor H, Bajic VB. DDR: Efficient computational method to predict drug-target interactions using graph mining and machine learning approaches. *Bioinformatics* 2018;34:1164–73. <http://dx.doi.org/10.1093/bioinformatics/btx731>.
- [42] Ding Y, Tang J, Guo F. Identification of drug-target interactions via dual Laplacian regularized least squares with multiple kernel fusion. *Knowl-Based Syst* 2020;204. <http://dx.doi.org/10.1016/j.knsys.2020.106254>.
- [43] Ding Y, Tang J, Guo F. Identification of drug-target interactions via fuzzy bipartite local model. *Neural Comput Appl* 2020;32:10303–19. <http://dx.doi.org/10.1007/s00521-019-04569-z>.
- [44] Chen H, Zhang Z. A semi-supervised method for drug-target interaction prediction with consistency in networks. *PLoS ONE* 2013;8. <http://dx.doi.org/10.1371/journal.pone.0062975>.
- [45] Shi JY, Yiu SM, Li Y, Leung HC, Chin FY. Predicting drug-target interaction for new drugs using enhanced similarity measures and super-target clustering. *Methods* 2015;83:98–104. <http://dx.doi.org/10.1016/j.ymeth.2015.04.036>.
- [46] Hu PW, Chan KC, You ZH. Large-scale prediction of drug-target interactions from deep representations. In: Proceedings of the international joint conference on neural networks, vol. 2016-October. Institute of Electrical and Electronics Engineers Inc.; 2016, p. 1236–43. <http://dx.doi.org/10.1109/IJCNN.2016.7727339>.
- [47] Wen M, Zhang Z, Niu S, Sha H, Yang R, Yun Y, et al. Deep-learning-based drug-target interaction prediction. *J Proteome Res* 2017;16:1401–9. <http://dx.doi.org/10.1021/acs.jproteome.6b00618>.
- [48] Wang L, You ZH, Chen X, Xia SX, Liu F, Yan X, et al. A computational-based method for predicting drug-target interactions by using stacked autoencoder deep neural network. 25, Mary Ann Liebert Inc.; 2018, p. 361–73. <http://dx.doi.org/10.1089/cmb.2017.0135>.
- [49] Öztürk H, Özgür A, Ozkirimli E. DeepDTA: deep drug-target binding affinity prediction. *Bioinformatics* 2018;34:i821–9. <http://dx.doi.org/10.1093/bioinformatics/bty593>.
- [50] Öztürk H, Ozkirimli E, Özgür A. WideDTA: prediction of drug-target binding affinity. 2019. <http://dx.doi.org/10.48550/arXiv.1902.04166>.
- [51] Zhao Q, Xiao F, Yang M, Li Y, Wang J. AttentionDTA: prediction of drug-target binding affinity using attention model. In: 2019 IEEE international conference on bioinformatics and biomedicine. IEEE; 2019, p. 64–9. <http://dx.doi.org/10.1109/BIBM47256.2019.8983125>.
- [52] Lim J, Ryu S, Park K, Choe YJ, Ham J, Kim WY. Predicting drug-target interaction using a novel graph neural network with 3D structure-embedded graph representation. *J Chem Inf Model* 2019;59:3981–8. <http://dx.doi.org/10.1021/acs.jcim.9b00387>.
- [53] Wan F, Hong L, Xiao A, Jiang T, Zeng J. NeoDTI: Neural integration of neighbor information from a heterogeneous network for discovering new drug-target interactions. *Bioinformatics* 2019;35:104–11. <http://dx.doi.org/10.1093/bioinformatics/bty543>.
- [54] Lee I, Keum J, Nam H. DeepConv-DTI: Prediction of drug-target interactions via deep learning with convolution on protein sequences. *PLoS Comput Biol* 2019;15. <http://dx.doi.org/10.1371/journal.pcbi.1007129>.
- [55] Torng W, Altman RB. Graph convolutional neural networks for predicting drug-target interactions. *J Chem Inf Model* 2019. <http://dx.doi.org/10.1021/acs.jcim.9b00628>.
- [56] Shin B, Park S, Kang K, Ho JC. Self-attention based molecule representation for predicting drug-target interaction. 2019. <http://dx.doi.org/10.48550/arXiv.1908.06760>.
- [57] Beck BR, Shin B, Choi Y, Park S, Kang K. Predicting commercially available antiviral drugs that may act on the novel coronavirus (SARS-CoV-2) through a drug-target interaction deep learning model. *Comput Struct Biotechnol J* 2020;18:784–90. <http://dx.doi.org/10.1016/j.csbj.2020.03.025>.
- [58] Manoochehri HE, Nourani M. Drug-target interaction prediction using semi-bipartite graph model and deep learning. *BMC Bioinformatics* 2020;21. <http://dx.doi.org/10.1186/s12859-020-3518-6>.
- [59] Zhao L, Wang J, Pang L, Liu Y, Zhang J. GANsDTA: Predicting drug-target binding affinity using GANs. *Front Genet* 2020;10. <http://dx.doi.org/10.3389/fgene.2019.01243>.
- [60] Lin X. DeepGS: Deep representation learning of graphs and sequences for drug-target binding affinity prediction. 2020.
- [61] Zhao T, Hu Y, Valsdottir LR, Zang T, Peng J. Identifying drug-target interactions based on graph convolutional network and deep neural network. *Brief Bioinform* 2021;22:2141–50. <http://dx.doi.org/10.1093/bib/bba044>.
- [62] Nguyen T, Le H, Quinn TP, Nguyen T, Le TD, Venkatesh S. GraphDTA: predicting drug-target binding affinity with graph neural networks. *Bioinformatics* 2021;37:1140–7. <http://dx.doi.org/10.1093/bioinformatics/btaa921>.
- [63] Chu Y, Kaushik AC, Wang X, Wang W, Zhang Y, Shan X, Salahub DR, Xiong Y, Wei DQ. DTI-CDF: A cascade deep forest model towards the prediction of drug-target interactions based on hybrid features. *Brief Bioinform* 2021;22:451–62. <http://dx.doi.org/10.1093/bib/bbz152>.
- [64] Mukherjee S, Ghosh M, Basuchowdhuri P. Deep graph convolutional network and LSTM based approach for predicting drug-target binding affinity. 2022. <http://dx.doi.org/10.48550/arXiv.2201.06872>.
- [65] Yang Z, Zhong W, Zhao L, Chen CY-C. MGraphDTA: deep multiscale graph neural network for explainable drug-target binding affinity prediction. *Chem Sci* 2022;13:816–33. <http://dx.doi.org/10.1039/D1SC05180F>.
- [66] Daga A, Khan SA, Cabrero DG, Hoehndorf R, Kiani NA, Tegnér J. LEP-AD: Language embedding of proteins and attention to drugs predicts drug target interactions. 2023. <http://dx.doi.org/10.1101/2023.03.14.532563>, bioRxiv, <https://www.biorxiv.org/content/early/2023/03/15/2023.03.14.532563.full.pdf>.
- [67] Davis MI, Hunt JP, Herrgard S, Ciceri P, Wodicka LM, Pallares G, et al. Comprehensive analysis of kinase inhibitor selectivity. *Nature Biotechnol* 2011;29:1046–51. <http://dx.doi.org/10.1038/nbt.1990>.
- [68] Tang J, Szwarda A, Shakyawar S, Xu T, Hintsanen P, Wennerberg K, et al. Making sense of large-scale kinase inhibitor bioactivity data sets: A comparative and integrative analysis. *J Chem Inf Model* 2014;54:735–43. <http://dx.doi.org/10.1021/ci400709d>.

- [69] Tang J, ur Rehman Tanoli Z, Ravikumar B, Alam Z, Rebane A, Vähä-Koskela M, et al. Drug target commons: A community effort to build a consensus knowledge base for drug-target interactions. *Cell Chem Biol* 2018;25:224–9.e2. <http://dx.doi.org/10.1016/j.chembiol.2017.11.009>.
- [70] Metz JT, Johnson EF, Soni NB, Merta PJ, Kifle L, Hajduk PJ. Navigating the kinome. *Nat Chem Biol* 2011;7:200–2. <http://dx.doi.org/10.1038/nchembio.530>.
- [71] USEnvironmental Protection Agency (EPA). EPA summary files from invit-rodb v2. 2018, URL <https://www.epa.gov/chemical-research/toxicity-forecaster-toxcasttm-data>.
- [72] Kuhn M, von Mering C, Campillos M, Jensen LJ, Bork P. STITCH: interaction networks of chemicals and proteins. *Nucleic Acids Res* 2007;36:D684–8. <http://dx.doi.org/10.1093/nar/gkm795>.
- [73] Yung-Chi C, Prusoff WH. Relationship between the inhibition constant (KI) and the concentration of inhibitor which causes 50 per cent inhibition (i50) of an enzymatic reaction. *Biochem Pharmacol* 1973;22:3099–108. [http://dx.doi.org/10.1016/0006-2952\(73\)90196-2](http://dx.doi.org/10.1016/0006-2952(73)90196-2).
- [74] Bjerrum EJ, Bachorz RA, Bitton A, Choung O-h, Chen Y, Esposito C, et al. Scikit-Mol brings cheminformatics to Scikit-Learn. 2023, <http://dx.doi.org/10.26434/chemrxiv-2023-fzqwd>, ChemRxiv, preprint.
- [75] Rozemberczki B, Kiss O, Sarkar R. Karate club: An API oriented open-source python framework for unsupervised learning on graphs. In: Proceedings of the 29th ACM international conference on information and knowledge management. ACM; 2020, p. 3125–32. <http://dx.doi.org/10.48550/arXiv.2003.04819>.
- [76] Lin Z, Akin H, Rao R, Hie B, Zhu Z, Lu W, et al. Language models of protein sequences at the scale of evolution enable accurate structure prediction. 2022, <http://dx.doi.org/10.1101/2022.07.20.500902>, bioRxiv, arXiv:https://www.biorxiv.org/content/early/2022/07/21/2022.07.20.500902.full.pdf.
- [77] Rives A, Meier J, Sercu T, Goyal S, Lin Z, Liu J, et al. Biological structure and function emerge from scaling unsupervised learning to 250 million protein sequences. *Proc Natl Acad Sci USA* 2019. <http://dx.doi.org/10.1101/622803>.
- [78] Roy K, Chakraborty P, Mitra I, Ojha PK, Kar S, Das RN. Some case studies on application of 'rm2' metrics for judging quality of quantitative structure–activity relationship predictions: Emphasis on scaling of response data. *J Comput Chem* 2013;34:1071–82. <http://dx.doi.org/10.1002/jcc.23231>.
- [79] Huang K, Xiao C, Glass LM, Sun J. MolTrans: Molecular interaction transformer for drug–target interaction prediction. *Bioinformatics* 2021;37:830–6. <http://dx.doi.org/10.1093/bioinformatics/btaa880>.
- [80] Zitnik M, Sosić R, Maheshwari S, Leskovec J. BioSNAP Datasets: Stanford biomedical network dataset collection. 2018, <http://snap.stanford.edu/biodata>.
- [81] Liu T, Lin Y, Wen X, Jorissen RN, Gilson MK. BindingDB: a web-accessible database of experimentally determined protein–ligand binding affinities. *Nucleic Acids Res* 2007;35:D198–201. <http://dx.doi.org/10.1093/nar/gkl999>.
- [82] Davis J, Goadrich M. The relationship between precision–recall and ROC curves. In: Proceedings of the 23rd international conference on machine learning -ICML '06. New York, New York, USA: ACM Press; 2006, p. 233–40. <http://dx.doi.org/10.1145/1143844.1143874>.
- [83] Flach P, Kull M. Precision–recall–gain curves: PR analysis done right. In: Cortes C, Lawrence N, Lee D, Sugiyama M, Garnett R, editors. Advances in neural information processing systems, vol. 28. Curran Associates, Inc.; 2015, URL <https://dl.acm.org/doi/10.5555/2969239.2969333>.
- [84] Tsubaki M, Tomii K, Sese J. Compound–protein interaction prediction with end-to-end learning of neural networks for graphs and sequences. *Bioinformatics* 2019;35: 309–18. <http://dx.doi.org/10.1093/bioinformatics/bty535>.