


<https://doi.org/10.1038/s44385-024-00003-9>

人工智能在药物靶点相互作用预测中的应用：综述

Qian Liao^{1,2,7}, Yu Zhang, Ying Chu, Yi Ding, Zhen Liu, Xianyi Zhao, Yizheng Wang, Jie Wan, ^{1,7,11,12,3,4}Yijie Ding², Prayag Tiwari⁵, Quan Zou^{2,3} & Ke Han^{1,6}

预测药物与靶点的相互作用 (DTI) 是一项复杂的任务。随着机器学习和深度学习等人工智能 (AI) 方法的引入, 基于人工智能的 DTI 预测能够显著提高速度、降低成本, 并在实际实验前筛选出潜在的药物设计选项。然而, 人工智能方法的应用也面临着一些需要解决的挑战。本文回顾了各种基于人工智能的方法, 并提出了可能的未来发展方向。

药物研发传统上在时间和资金方面投入巨大。此外, 预测实验结果一直是个难题。然而, 近年来人工智能 (AI) 方法的引入为缓解这些问题提供了机会。通过利用 AI 进行计算分析和预测, 湿实验方法能够得到显著改进, 从而加快药物研发进程, 并避免不必要的开支。

药物靶点相互作用 (DTI) 的识别与预测在药物研发及生物医学领域的实际应用中具有重要意义, 主要包括药物再定位, 即预测药物与蛋白质的相互作用有助于发现现有药物的新用途, 重新评估已上市药物, 寻找与其它疾病相关的新的靶点, 从而加快新适应症探索与开发; 以及新药研发。通过预测药物与特定蛋白质之间的相互作用, 可以为新药的设计与发现提供指导。这对于发现潜在的候选药物化合物、加快药物研发进程、降低成本和风险至关重要; 还有副作用预测, 药物与蛋白质之间的相互作用可能导致药物副作用和不良反应。通过预测药物靶点相互作用, 可以提前检测潜在的副作用, 从而加强药物的安全性评估和监测。通过这些预测结果, 可以帮助研究人员更好地探索和理解药物的作用机制, 揭示药物如何调节生物过程以产生治疗效果。反过来, 或许能够根据个体的遗传、表型和环境特征找到个性化的疗法, 从而提供精准的治疗方案。特别是 2020 年, 周等人³基于基因、疾病、遗传关系、药物和副作用共同构建了一个基于网络的药物靶点相互作用预测系统 (Ta

rgetPredict) 分析模型, 并迅速发现用于治疗 1 型糖尿病的利拉鲁肽处方与降低阿尔茨海默病 (AD) 诊断风险显著相关。2022 年, 张等人⁴验证了基于 Transformer 的模型在大规模感染的新冠肺炎以及阿尔茨海默病 (AD) 的药物再定位实验中表现良好。2023 年, 李等人⁵基于 MT-DTI 方法对潜在的 TRPV1 拮抗剂进行预测, 找到了三氯吡作为活性成分, 有助于改善临床实践中皮肤的敏感性。

因此, 这些实例表明了基于人工智能的方法在预测药物靶点成对相互作用方面的可行性和巨大潜力。无论人工智能方法是设法从预测的药物 - 靶点配对中排除尽可能多的真阴性, 还是尽可能准确地筛选出真阳性, 都能降低后续湿实验工作中的试错成本并提高效率。

药物-靶点相互作用 (DTI) 中的数据包含多种类型的信息, 例如药物和蛋白质的分子结构、相互作用细节、临床表现、药物副作用等等。其中, 已知的药物与靶点之间的相互作用与未知的相互作用相比, 数量显著稀少。因此, 该领域最常见的问题是正负样本的不平衡, 这使得实现最优模型性能颇具挑战性。这无疑是一个重大难题。与此同时, 文本信息的整合与特征提取, 以及 AlphaFold⁷ 的出现, 引发了人们对蛋白质折叠结构研究的浓厚兴趣。这些三维结构的纳入引发了它们能否……

¹School of Computer and Information Engineering, Harbin University of Commerce, Harbin, China. ²Yangtze Delta Region Institute (Quzhou), University of Electronic Science and Technology of China, Quzhou, China. ³Institute of Fundamental and Frontier Sciences, University of Electronic Science and Technology of China, Chengdu, China. ⁴the Laboratory for Space Environment and Physical Sciences, Harbin Institute of Technology, Harbin, China. ⁵School of Information Technology, Halmstad University, Halmstad, Sweden. ⁶Pharmaceutical Engineering Technology Research Center, Harbin University of Commerce, Harbin, China. ⁷These authors contributed equally: Qian Liao, Yu Zhang. e-mail: wuxi_dyj@csj.uestc.edu.cn; prayag.tiwari@hh.se; zouquan@nclab.net; thruster@163.com



积极影响模型预测，并探讨如何最大限度地发挥这些潜在优势。随着生成式人工智能（GAI）的出现，为从零开始设计药物分子提供了新的基础，这促使人们思考并尝试需要做哪些准备才能有效地利用 GAI 生成可行的药物分子。近年来，量子化学也因其粒子层面优化复杂结构和研究酶催化反应方面的可行性而备受关注。最后，大规模模型的出现使得快速对话和交流成为可能，让我们能够迅速获得大量解决方案。因此，探索如何利用大型语言模型（LLM）强大的推理能力来整合药物发现任务，成为了一个新的前沿领域。

我们使用谷歌学术广泛收集论文，通过搜索诸如“药物靶点相互作用（DTI）”、“人工智能”、“机器学习”和“深度学习”等关键词，然后按年份进行排列。我们根据诸如“数据集”、“三维结构”、“多模态”、“特征融合”、“图神经网络”、“Transformer”、“注意力机制”、“对比学习”、“生成式人工智能”、“知识图谱”和“元路径”等关键词对这些论文进行了重新分类和筛选。此外，我们还探讨了包括“AlphaFold3”、“量子化学”和“大型模型”在内的新兴研究方向的可行性。由于药物性能分析依赖于临床数据，我们还讨论了数据隐私和安全问题，以回应公众关切。最终，我们选出了 100 篇具有代表性的参考文献，以供深入讨论。这些检索到的文章来自以下不同的期刊和会议：《自然综述：生物工程》、《自然综述：药物发现》、《化学信息与建模杂志》、《生物信息学》、《生物信息学简报》、《方法》、《IEEE/ACM 计算生物学与生物信息学汇刊》、《BMC 生物信息学》、IEEE 生物信息学与生物医学国际会议（BIBM）、国际生物信息学与生物医学技术会议（ICBBT）、国际智能计算会议（ICIC）等等。

本文方法部分所引用的内容来自过去五年内药物靶点相关性预测领域期刊和会议中介绍的新方法和一些经典方法。这些任务主要涉及药物靶点相互作用和药物靶点亲和力（DTA）的预测。所引用的数据来自公开可用的数据集和在线资源。文中讨论的方法包括传统机器学习和深度学习方法，以及生成式人工智能（GAI）、量子化学和大语言模型（LLM）等计算虚拟预测技术的最新进展。我们希望这些前沿方法能够拓展药物发现的可能性，并将这些技术的最新发展应用于药物靶点相关性预测领域。通过基础方法的改进，我们旨在突破瓶颈，为药物发现的进步做出贡献。

DTI 预测的基本原理及相关背景

问题分析

传统的药物发现过程涉及通过湿实验逐步提出假设和推导，然后进行设计和实验。然而，这种实验过程并非一蹴而就；假设的验证、推导过程、设计中的偏差以及实际实验中的错误都可能导致每一步的失败。这一过程需要大量的时间和可观的实验资金，而且如果重复多次，所耗费的时间和资金可能难以估量。随着人工智能方法在各种预测领域的不断发展和应用，这些方法也被用于药物靶点相互作用（DTI）的预测。

用于弥散张量成像预测的人工智能方法

人工智能方法是一种计算机化的方法，用于在湿实验之前完成药物开发工作的假设推

导和设计过程，这成为湿实验的准备，并能为后续的临床副作用监测提供参考和反馈指导。因此，人工智能方法与湿实验方法可以结合用于整个药物开发过程。基于人工智能方法的药物靶点相互作用（DTI）预测过程如图 1 所示。

利用人工智能预测药物与靶点的相互作用长期以来一直受到各国研究人员的关注，被视为药物发现与开发的关键技术工具，并随着人工智能方法的发展而不断改进。按照技术进步的顺序，从传统的对接模拟方法、统计计量经济学分析方法、机器学习方法、深度学习方法，到如今大模型蓬勃发展的背景下人工智能在科学领域的应用，各行业与大模型之间存在着多种多样的联系。与传统的仅通过湿实验研究药物与靶点相互关系的方法相比，在进行最终湿实验之前采用前沿的人工智能方法预测药物靶点相互作用已成为一大趋势。

药物的疗效归因于其与相应靶点的相互作用。因此，人工智能方法的研究旨在解决如何建立药物与靶点之间的对应关系这一问题。目前的研究主要通过两种方法来解决这一问题。首先，研究探索药物与靶点之间是否存在关联，并将这种关系视为“0/1”问题。这种分类问题可以通过二分类或对候选对象进行排序来解决。其次，研究利用药物与靶点之间的亲和系数关系来评估并将其关联归一化为“0/1”问题。这种二分类问题可以通过考虑药物与靶点之间的关系来解决。此外，还可以将药物靶点之间的关系视为回归问题，通过将其关系归一化到 0 到 1 的值区间来处理。总之，药物 - 靶点相互作用关系的研究可分为两类任务：一类是通过定性分析对药物 - 靶点相互作用进行分类预测，另一类是在药物 - 靶点亲和力预测中进行定量分析。

在这两项研究任务中都遇到了复杂且棘手的输入数据。要研究药物与靶点的相互作用，需要关键信息，包括药物、靶点以及已知的药物与靶点相互关系的数据。药物通常采用化学编码和药物指纹图谱进行表征，而蛋白质则包含序列信息、三维结构信息、残基信息以及若干其他信息类别。此外，还可以利用药物间和靶点间的相关性数据集来探索类间和类内的关联。药物与靶点相互作用的预测可以基于上述一种或多种模式的数据集。


研究数据

数据来源和数据类型。诸如用于弥散张量成像（DTI）的样本数据类型、其结构、维度以及正负样本成分的比例等各类信息，可能会影响模型的预测性能。因此，选择合适的样本数据作为模型预测的输入至关重要。

在药物靶点相互作用预测中，常用的数据类型包括药物、蛋白质、疾病、副作用、基因、药物靶点相互作用信息以及蛋白质相互作用信息，其中包括特定疾病遗传属性的数据（某些方法会涉及）或对特定样本的观察结果。这些数据的来源包括在线平台、生物医学文献、专家意见、实验室数据、生物医学公司的内部信息以及临床信息。通过从这些不同的多模态数据源中选择模型输入所处理的数据类型，可以开展进一步的研究。

常用的数据库包括金标准数据库核受体（NR）、G 蛋白偶联受体（GPCR）、离子通道（IC）、酶（Es）⁹ 以及其他公共数据库，如 Davis¹⁰ 和 KIBA¹¹，还有一些研究整合了来自数据平台的数据，包括 BindingDB¹² 等。

图 1 | 基于人工智能方法的基本组件。通过机器学习和深度学习方法预测药物 - 靶点相互作用以及药物 - 靶点的亲和关系, 能够实现一种不受单一信息源限制的多方面方法。这种方法同时利用多种因素, 包括药物、疾病、基因、蛋白质和患者特征, 从而能够整合序列数据、图像和三维模型进行预测。因此, 该方法旨在尽可能提高预测准确性的同时优化预测速度。



Basic components of Artificial Intelligence approach

Uniport (Uniport: <https://www.uniprot.org>) 和 PubChem (PubChem: <https://pubchem.ncbi.nlm.nih.gov>)。药物分子的表示形式包括简化分子线性输入规范 (SMILES) 和药物分子图谱, 蛋白质的表示形式包括序列、FASTA、PDB 和蛋白质接触图谱。这些数据可以直接从数据资源提供平台获取, 也可以使用诸如 rdkit (rdkit: <https://rdkit.org>) 之类的工具进行转换和处理。这些复杂的数据格式和多种数据源共同构成了用于药物-靶点相互作用预测的大型知识网络。这些数据之间的基本关系在图 2 中有所展示。

这些数据可以根据其维度分为一维 (1D)、二维 (2D) 和三维 (3D) 数据, 包括描述性文本、二值图像和三维模型。具体描述见表 1。

近年来, 用于预测的两类数据发展引起了关注: 量子化学数据和 AlphaFold 预测的蛋白质结构。

- (1) 量子化学数据 (量子化学数据: <https://caddtutorial.readthedocs.io/zh-cn/latest/QM.html>): 这包括可计算分子的各种参数, 例如分子结构、成键特征、总系统能量、每个轨道的分子信息、分子间相互作用、各种光谱、振动光谱、电磁光谱特性以及反应过渡态。量子化学描述符作为定量构效关系的描述符, 从粒子层面描述分子内部特性, 包括总能量、电离能、

分子生成热、辛醇-水分配系数、偶极矩、分子极化率、分子量、范德华体积以及一些电学参数等。在此基础上, 可以预测卤化反应、亲核取代反应的位点以及亲和作用发生的位点。如果能够处理对齐的量子化学数据以用于粒子层面的预测任务, 我们就可以从可解释性的角度优化预测模型, 从而提高模型的泛化性能。

- (2) AlphaFold14: 自 2020 年初第一代 AlphaFold 在蛋白质结构预测关键评估竞赛中首次亮相, 展示了其强大的蛋白质结构预测能力并引起关注以来, AlphaFold 已经经历了两次重大升级。2024 年, AlphaFold3 发布, 成功预测了几乎所有生物分子 (蛋白质、DNA、RNA、配体等) 的结构和相互作用。这些化学结构的成功预测无疑丰富了结构样本的数量, 并且如果应用于基于结构的药物靶点相互作用 (DTI) 和药物靶点亲和力 (DTA) 预测任务, 将增强模型的稳健性。

从单一模式向多模式转变。目前, 随着对药物 - 靶点相互作用的深入研究, 传统的“一种药物对应一个靶点”模型已不再适用。一种蛋白质可能对应多个靶点¹⁵, 药物之间也可能存在协同作用¹⁶。整合大数据和复杂的异质网络有助于拓展对药物 - 靶点相互作用的理解。为了更好地挖掘




图 2 | 数据资源介绍。药物与靶点之间关系的预测需要使用与药物和靶点相关的多个数据库，这些数据库包含两大类数据：（1）药物和靶点数据本身的特征；（2）药物与靶点之间的关联信息。目标，包括已知的药物相互作用、药物靶点相互作用、药物副作用关系以及表型数据。这些数据的常见来源包括众多在线网站和公共数据集。

表 1 | 数据维度分类

数据维度	数据描述
1D	包含药物和靶点的分子序列信息，以及疾病、副作用、临床表现等附加信息，还有诸如遗传信息等其他以文本形式输入的信息。
二维	包含药物分子图谱、蛋白质接触图谱、药物 - 靶点相互作用网络以及其他相关相互作用网络，还有以图像形式呈现的其他输入信息。
三维	包含有关药物和靶点的结构信息的 3D 模型，以及其他形式的 3D 输入信息。

单模态和多模态的相关信息流程图分别如图 3 所示。

大多数以往的药物靶点相互作用（DTI）预测方法仅考虑了药物化合物之间的结构关系，而对靶点侧的信息考虑不足。相反，如今的研究人员更注重同时挖掘药物和靶点的信息，以从药物和靶点的双方尽可能多地获取潜在的相关信息。研究内容从类内扩展到了类间。与此同时，随着对于预测 DTI 的人工智能方法研究的不断深入，研究人员开始通过将更多的信息源纳入模型来丰富模型输入的内容；除了已知的药物靶点关系信息

外，还引入了副作用、疾病、基因等相关信息，并且将信息从序列信息扩展到药物和靶点双方的分子结构图和三维模型，以构建具有多视角信息的模型。在药物和靶点方面，信息也从序列信息扩展到分子结构图、三维模型¹⁷以及其他多视角信息，以构建更大、更稳健的多模态异构预测网络。对于这些复杂节点的处理方法也逐渐从简单的直接节点关系处理扩展到通过引入更多具有“上下文”关系的间接节点来形成网络图结构，并寻找节点间路径的元路径。例如，在 2020 年，Wang 等人¹⁸构建了




图 3 | 用于药物 - 靶点相互作用预测的多模态网络演变。a 仅关注药物 - 作用信息的方法；b 仅关注已知药物 - 靶点相互作用关系的方法；c 关注药物的方法

以及目标和其他附加信息。模型使用的数据模式逐渐从单一模式转变为多模式。

为药物、靶点、疾病和副作用构建相互作用边，并随后消除孤立节点以创建一个广泛的相互作用网络。节点之间的相似性同时考虑了一阶和二阶连接。每个节点都被视为一个顶点和另一个节点的

“上下文”，通过邻域间接性增强了对相互关系的检测。2021 年，廖等人¹⁹认为，就预测目的而言，原子级序列（如分子图）的利用优于字符级序列（如 SMILES 字符串）的使用。

表 2 | 数据处理方法

问题类型	方法论特征	作者
负样本的定义不统一	通过筛选过程选择高质量的负样本以重建样本数据集，同时采用球形搜索方法来识别药物靶点相互作用（DTIs），以避免陷入局部最优解，并优化极值学习机的识别能力。	胡等人 ⁶⁹
正负样本数量之间的数字鸿沟	一种用于负样本堆叠的集成学习框架，通过采样和拆分负本来缩小正负样本之间的差距，然后进行集成训练。	杨等人 ⁷⁰
	数据扩充方法“合成少数类过采样技术”（SMOTE）被引入，用于从少量现有样本中生成新的样本。	卡拉吉安等人 ⁷¹
具体的样本量不够丰富，而且存在噪声，维度也多。	一种轻量级的学习框架——轻型深度卷积神经网络（LDCNN-DTI），使用较少的蛋白质描述符，并且能够对不同长度的氨基酸序列进行卷积。	王等人 ⁶⁸
冷启动问题	重新划分数据集。将正样本分为 5 组，随机选取负样本作为反例，组合成 4 个训练集和 1 个测试集。	李等人 ⁷²
	采用无监督方法，通过迁移学习将药物和靶点的类内及类间交互信息引入预测网络。这种预训练方法在药物 - 靶点相互作用（DTA）预测任务中也表现出色。	阮等人 ⁷³

样本数据处理。尽管这些数据集类型丰富、来源广泛且模态多样，但在实际模型训练过程中也存在一些问题。

- (1) 负样本的定义并不统一。当前一些方法将未知的药物 - 靶点相互作用直接训练为负样本，然而实际上，湿实验未排除的药物 - 靶点关系很可能仅仅由于存在隐藏的相互作用而未被检测到。
- (2) 正负样本数量之间的数字鸿沟。已知药物 - 靶点相互作用的数量相对于未知的药物 - 靶点关系而言少之又少，这导致数据集极度不平衡，从而影响模型训练的效果。
- (3) 具体样本量不够丰富、存在噪声且维度不够多。尽管整体数据集规模已经很大，但针对特定的数据需求而言，样本量仍显不足，尤其是在使用深度学习模型时，样本量不足以使模型达到最优性能点。此外，这些样本通常是高维度的，并且包含有噪声的数据。
- (4) 示例冷启动问题²¹。对于模型来说，处理训练集中不存在但在测试集中出现的药物或靶点是很困难的。

- 因此，已经提出了几种样本数据调整方法用于 DTI 预测。
- 仅使用已识别的负样本缩小数据集范围，以构建正样本集和负样本集。
- (2) 重新拆分并合并数据集中的正负样本对，从而缩小样本量的差距。
- (3) 扩充数据集并进行数据增强。
- (4) 采用了新的策略将训练集划分为测试集。

具体的解决方案列于表 2 中。

人工智能方法预测过程 传统机器学习方法

机器学习方法长期以来一直是药物发现的重要工具。药物靶点相互作用（DTI）关系通常以二元分类关系来表示，因此非常适合一些传统的分类算法。传统的机器学习方法，包括支持向量机、随机森林、朴素贝叶斯和人工神经网络等，被广泛用于通过定量构效关系、蛋白质化学计量学和分子对接方法来建模药物靶点相互作用。支持向量机是一种广泛用于分类问题的算法，它试图找到一个超平面，以最大化正样本和负样本之间的间隔，从而实现分类任务。随机森林和梯度提升树是一种集成方法，能够处理复杂的非线性关

系和高维特征空间，并能高效地进行分类预测。

应用于药物-靶点相互作用（DTI）问题的方法，根据解决问题的方向可分为矩阵分解法²⁸、基于相似性的方法²⁹、基于网络的方法³以及基于特征的方法^{30,31}，包括混合使用这些方法的程序。这四种基础方法在图 4 中有所展示。矩阵分解法是将问题空间表示为矩阵，然后对矩阵进行降维并解释以提取关键特征，常见的矩阵分解方法包括主成分分析（PCA）、奇异值分解（SVD）等。基于相似性的方法有两种思路：一种是将 DTI 问题中的药物和靶点视为两种不同的属性，寻找属性之间的相似关联，然后对接并整合这种相似性信息来处理；另一种是将药物和靶点作为一个整体来处理，寻找这两种不同数据类型之间的相似性信息。随着相似性信息研究的发展，基于相似性信息的方法不再局限于药物与靶点之间的关系，而是扩展到药物、靶点、疾病、基因、表型、副作用等不同模态之间的关系，并通过日益庞大的信息生态构建出更稳健的相似性关系。基于相似性的方法寻找对象之间的相似性关系，而基于网络的方法则将多种数据整合到一个数据网络路径中，共同解决预测问题。基于特征的方法包括特征选择、特征融合和基于特征的方法，这些方法通常都需要先验知识。特征选择涉及在数据处理后筛选出重要的数据特征并保留它们。特征融合通过将来自不同来源或不同类型的多个特征组合起来，以获得更具信息量和区分度的特征表示。特征融合可以通过多种方式实现，包括简单的加权平均、特征堆叠或级联。常见的特征融合方法包括加权融合、堆叠融合和级联融合，包括旋转随机森林³²和级联森林深度（CDF）模型³³。多核融合方法也是一种特殊的特征融合方法，是解决 DTI 问题的常用方法；它将问题分解为多个子空间，并结合不同的核函数来处理这些子空间，以整合不同的特征信息。多核融合可以以线性或非线性的方式融合不同的核函数，从而获得更具表现力的特征表示。

表 3 展示了各种机器学习方法的优缺点对比。

随着传统机器学习方法的不断发展，越来越多的研究方法将上述研究方向结合起来以解决药物-靶点相互作用（DTI）预测问题。例如，Liu 等人³⁴认为，一些基于相似性的过往方法




图 4 | 四种传统机器学习方法。a 矩阵分解方法；b 基于特征的方法（特征融合）；c 基于相似性的方法；d 基于网络的方法。

表 3 | 不同机器学习方法的比较

靠近	优点	可能的问题
矩阵分解	降维以减少计算和存储开销；降噪以提取数据的潜在特征；简洁表示	维度灾难；数据稀疏且存在过多默认值时性能会受到影响；容易过拟合；数据处理依赖大量先验知识；
基于相似性的方法	高度可解释；稳健；可用于无监督学习；侧重于局部信息；	维度灾难；全局信息构建不足，泛化能力差；计算和存储开销大；对特征选择和距离度量的选择敏感
基于网络的方法	强大的交互捕捉能力和上下文关系理解能力；高可解释性；高泛化能力；	图结构的计算复杂度高；对噪声数据的鲁棒性差；对模型参数敏感；
基于特征的方法	高抗噪性；高信息综合与提取能力；高跨领域和跨模态迁移学习能力；策略调整的高灵活性；	计算复杂度高；参数敏感度高；数据分布敏感度高；先验知识要求高

现有的整合方法要么完全不考虑全局交互信息，要么只考虑全局交互信息，而忽略了结构和关联拓扑的重要性。因此，他们提出了一种基于局部交互一致性（LIC）的相似性整合方法，用于预处理数据以构建相似性矩阵，并使用了三种矩阵分解方法来优化 AUPR 和 AUC 指标。

具体的机器学习方法在表 4 中有描述。

深度学习方法

随着深度学习方法日益成熟，现有研究已逐渐从机器学习转向深度学习方法。Khan 等人³⁵通过比较多种机器学习和深度学习方法发现，随机欠采样方法会影响模型性能，并且在应用数据集重

采样技术的情况下，深度学习方法与多种机器学习方法相比，其性能更为出色。

在预测药物与靶点相互作用关系的领域，深度学习方法被广泛使用，包括基于序列模型的方法、基于图神经网络的方法、基于深度生成学习的方法，以及将注意力机制融入这些方法，这使得模型能够更专注于在某些数据中寻找特定的成分和模式。例如，自从“Attention is All You Need”（《注意力就是你所需要的》）这篇论文提出“transformer”这一概念以来，研究人员对其兴趣浓厚。注意力机制在过去两年中非常流行，基于transformer方法的应用研究也十分热门。研究人员对从不同数据处理阶段（包括在不同模块和对象之间构建某种联系）改进的可能性进行了广泛的讨论和实验。药物和

表 4 机器学习特定方法介绍			特征
作者	年	靠近	方法描述
贾马尔等人 ⁴¹	2021	矩阵分解	一种能够将各基连接起来的非负矩阵三因子分解方法 通过一个特殊的矩阵 X 来构建药物-靶点空间，而无需通过稀疏采样来强制对齐丢失。
叶等人 ⁴²	2021	矩阵分解	一种引入非负约束和非平凡约束的正则化方法 为优化低值，对矩阵值中的负值施加约束以进行限制 包含潜在相关因子的多维矩阵，用于预测药物与靶点的相互作用。 重点在于获取药物靶点数据的内部结构信息以表示学习。
安等人 ⁴³	2022	基于相似性的方法	基于相似性，将 Kullback-Leibler 散度应用于药物-靶点相互作用 (DTIs) 的预测中，从而通过使用药物的三维分子指纹图，开发了随机森林模型。 药物分子的表示以对靶点和配体进行相似性评估。
周等人 ⁴⁴	2020	基于网络的方法	基于网络的排名算法通过整合大规模多模态数据来预测药物-靶点相互作用 药物、靶点、疾病、基因以及遗传关系的网络。
奥泽尔特等人 ⁴⁵	2023	基于特征的方法	特征选择是通过使用自动编码器作为对称学习方法来完成的。 用于捕捉受体与配体之间基于相似性的结合的化学分子线性输入规范 (SMILES)。
刘等人 ⁴⁶	2021	基于相似性的方法，矩阵分解	一种基于相似性方法和矩阵分解的方法利用相似性 基于局部交互一致性 (LIC) 的集成方法对数据进行预处理以 构建一个相似性矩阵，然后使用三种矩阵分解方法进行优化。 AUPR 和 AUC 指标。
刘等人 ⁴⁷	2022	矩阵分解，相似性，基于的方法	一种结合矩阵分解和随机游走策略 (MDMF) 的方法模型 具有高阶相似性的多重相似性集成结构。

目标是两个需要相互连接的不同对象，或许在深度学习的黑箱模型中可以找到令人印象深刻的连接方式。

基于序列模型的方法。对于蛋白质序列和药物分子结构的预测，可以使用基于序列模型的方法，包括循环神经网络或长短期记忆网络来捕捉序列中的时间依赖性。Jin 等人³⁶提出了 EmbedDTI 方法，通过序列嵌入和图卷积网络增强分子表达来预测药物靶点相互作用。对于蛋白质序列，氨基酸的特征嵌入通过语言模型进行预训练，并输入卷积神经网络模型进行表示学习。典型的基于序列的语言模型架构如图 5 所示。Liu 等人³⁷ (2022 年) 将 Transformer 方法应用于药物靶点相互作用 (DTI) 识别。他们的研究表明，即使仅使用序列信息，Transformer 也能有效地提取深层特征。Huang 等人³⁸ (2022 年) 引入了 CoaDTI 框架，该框架应用预训练编码器对蛋白质进行编码，以解决标注数据稀疏的问题。这是一个基于 Transformer 的模型，具有协同注意力机制，能够从原始蛋白质序列和药物分子 SMILES 中提取所需特征。在迁移学习和预训练的指导下，CoaDTI 显著提高了性能，并在识别新的药物 - 靶点相互作用方面表现出良好的泛化能力。

基于序列模型的方法不仅能提取数据的内在特征，还能考虑数据上下文之间的关联。特别是像药物和蛋白质这样的化学结构可能包含复杂的长距离上下文信息，例如化学键连接、环状结构和极性关系。因此，学习这种上下文信息的能力对于处理序列数据至关重要。Zheng 等人 (2023 年) 在图神经网络的基础上，采用多头注意力机制的双重参与来识别序列中的关键结合特征，从而在一定程度上解决了长距离依赖问题。Zhao 等人 (2022 年) 提出了 GIFTDTI 模型用于长距离编码，将药物、靶点和相互作用信息分为三个模块来提取关键特征。在局部特征提取模块中整合卷积神经网络 (CNN) 和 Transformer，能够捕获并编码长距离特征，结合全局信息、局部特征和类间相关性。该模型能更好地学习序列中的局部模式信息。

与 word2vec 等不依赖上下文的方法不同，BERT⁴¹ (2019 年) 是一种基于上下文的语言模型。它的出现推动了基于语言模型预训练的微调模型的研究，利用其强大的推理能力来完成诸如药物发现之类的任务。Kang 等人⁴² (2022 年) 使用了针对氨基酸的 BERT 基预训练模型 ProtBert 以及用于编码药物 SMILES 格式的 RoBERTa 预训练模型，显著提高了亲和力预测任务的性能。

基于图神经网络的方法。这类深度学习模型专门用于处理图结构数据。在预测药物与靶点的相互作用时，药物和蛋白质可以表示为图结构，然后利用图神经网络 (GNN) 学习图的节点和边的特征，以预测它们之间的相互作用。在传统的网络分析中，仅考虑直接相互作用，忽略了节点的局部效应 (如邻居节点和边的方向) 以及全局位置信息 (如全局拓扑或结构)。图神经网络 (GNN) 从局部邻居中采样和聚合特征，既保留了节点在图中的局部作用，也保留了全局位置信息。

2020 年，尹等人⁴³提出了 DeepDrugw 方法，这是一种基于图的通用深度学习框架，用于预测药物 - 药物相互作用 (DDIs) 和药物 - 靶点相互作用。它利用残差图卷积网络 (RGCNs) 和卷积网络 (CNNs) 来学习药物和蛋白质的结构和序列，从而提高预测效果。




图 5 | 基于序列的语言模型常见架构：以 Bert 为例。Bert 模型从上至下依次将输入序列编码为文本信息和位置信息，以获取绝对和相对位置。

然后进行掩码语言模型训练，以预测下一个句子，从而处理句子级别的分类任务。

药物相互作用 (DDIs) 和药物靶点相互作用 (DTIs) 的准确性。2021 年, Penget 等人⁴⁴提出了一种端到端的异构图学习架构 EEG-DTI, 该架构将多种生物信息模态作为输入, 并在模型训练过程中端到端地学习数据的低维特征表示。2022 年, Li 等人⁴⁵发现, 先前的方法往往忽视了全面整合节点属性和关系, 通常在处理过程中只关注某一方面。因此, Li 等人提出了 GCN-DTI 方法, 利用图神经网络整合节点属性和拓扑信息, 从而获得更具代表性的低维特征。Qu 等人⁴⁶提出了 Graph-DTI 方法, 这是一种基于异构网络图嵌入的药物靶点相互作用预测新模型, 通过使用受 GCN 启发的图自编码器提取高阶结构信息, 学习节点 (药物、蛋白质) 及其拓扑邻域表示, 以形成异构网络。于等人⁴⁷提出了一种基于双向长短期记忆网络 (Bi-LSTM) 和注意力机制的异构图神经网络模型, 以增强节点特征获取和异构数据聚合能力, 同时采用负采样技术进一步优化模型的预测能力。图 6 展示了一种典型的图神经网络方法。

基于深度生成模型的方法。基于生成对抗网络 (GAN) 的深度生成模型是一种通过从现有数据中学习来生成新表示的人工智能类型。这些新表示可以类似于现有数据, 也可以是改进的版本, 涵盖文本、语音、视频等多种类型。它们的出现进一步推动了从零开始设计药物分子的概念。与依赖于从大量数据集中学习分子表示以进行模式识别和预测的其他方法不同, 这种方法不仅能识别具有相似效果的药物, 还有可能从模仿和优化局部小分子开始设计药物分子构型, 逐渐适应更大分子的构建。它从学习-生成-判别角度补充数据, 以增强模型的鲁棒性。

这些模型能够学习数据分布并生成新的样本。在预测药物-靶点相互作用时, 包括变分自编码器、生成对抗网络或扩散模型在内的深度生成模型⁴⁹

可以通过学习药物和蛋白质的潜在表示来生成新的相互作用。Zhao 等人⁵⁰提出了基于半监督生成对抗网络 (GANs) 的 GANsDTA 方法来预测结合亲和力, 该方法由两部分组成: 用于特征提取的两个 GAN 和用于预测的回归网络。这是首个基于半监督 GAN 的结合亲和力预测方法。图 7 展示了用于 DTI 预测的添加了噪声数据的 GAN。

2022 年, 人们关注的重点在于注意力感知和迁移学习对药物发现中图注意力网络 (GAI) 的强化作用。李等人⁵¹提出了 HGAN 方法, 该方法构建了一个带有附加图注意力扩散层的异质图注意力网络。此方法从层内和层间视角捕获了更多的间接节点信息, 扩大了感受野并增强了注意力感知。研究还发现, 层内和层间感受野扩展程度的不同会导致不同的效果。具体而言, 在感受野扩展程度相同的情况下, 层间扩展比层内扩展能取得更好的模型预测性能。王等人⁵²提出了 GCHN-DTI 方法, 这是一种基于异质网络的图卷积方法, 用于预测药物-靶点相互作用。GCHN-DTI 集成了包括药物-靶点相互作用、药物-药物相互作用、药物相似性、靶点-靶点相互作用和靶点相似性在内的网络信息。在异质网络内执行图卷积操作, 以获得药物和靶点的嵌入表示。此外, 在图卷积层之间引入了注意力机制, 以联合处理来自每一层的节点嵌入。最后, 基于药物和靶点的嵌入来预测药物-靶点相互作用得分。该模型使用较少的网络类型, 并展现出更高的预测性能。Nguyen 等人⁵³面对冠状病毒数据集不够丰富的问题, 从原子层面增强数据, 并提出了一种图神经网络方法。他们引入了多跳门控机制, 通过从非相邻信息中获取更好的原子表示来改进模型训练。作者建议, 将大型数据集用于迁移学习可以进一步提高模型性能。

2023 年, 人们重新关注自编码器质量对底层模型性能的影响, 并且着重于其能力方面。




图 6 | 基本的变差函数自动编码器 (VGAE)。输入图的邻接矩阵 A 和节点的单位矩阵 X 用于通过编码器 (图卷积网络) 学习节点低维向量表示的均值 μ 和方差 σ , 然后通过解码器 (链路预测) 生成图。

为了从语义上捕获和去噪生成模型, 优化模型底层路径的生成学习模型, Zhang 等人⁵⁴ 使用两种不同的图自编码器推断未知药物 - 靶点空间的特征, 并为已知的药物 - 靶点相互作用传播标签, 从而形成一个增强的深度自编码器。这种方法旨在提取此类异构拓扑结构中的潜在信息。Li 等人⁵⁵ 提出了 MHTAN-DTI 方法, 与基于 GNN 的其他方法相比, 该方法通过元路径扩展增强了对生物异构图中高阶结构和语义信息的捕获。该方法利用分层变换器结构来建模上下文信息, 为不同的元路径分配权重, 引入注意力网络进行加权融合, 区分不同元路径的重要性, 减少噪声数据对模型的影响, 并提高模型的鲁棒性。Chen 等人⁵⁶ 引入了 SDGAE 方法, 这是一种图卷积自编码器方法。通过预处理步骤, SDGAE 在保留图结构的同时嵌入了节点之间的最近邻关系, 从而在基于图的学习过程中保持拓扑关系。这种方法有效地解决了传统图卷积自编码器模型中存在大量孤立节点的问题。

混合方法和多模态建模。随着跨模态和多模态模型的逐渐发展, 越来越多基

于序列的语言模型和基于图神经网络的图表示学习模型被结合起来, 在蛋白质和靶点的预测中完全融合了这两种表示形式的特征, 从而更全面地实现连接直觉的建模以提高可解释性。基于 Transformer 和 CNN 双塔结构的典型 DTI 预测网络如图 8 所示。同时, 深度生成学习网络的发展从从头构建的角度丰富了 DTI 预测的视野。研究人员还从不同角度探索了注意力机制, 包括单头、多头、联合和交叉注意力机制, 以找到模型构建的关键点和数据解释的关键环节。使用注意力机制的常见场景如图 9 所示。

我们的表 5 按时间顺序记录了若干深度学习方法, 包括作者、发表年份、所用数据集、方法描述以及方法特点。

跨领域学习药物-靶点相互作用 (DTI) 方法

随着 DTI 问题的深入解决, 几个方向不可避免地遇到了瓶颈。这些问题包括数据集完整性不足、数据维度高、噪声大以及数据可靠性差。运行速度方面




图 7 | 使用生成对抗网络进行药物 - 靶点相互作用预测。药物和靶点的两侧均将原始数据和噪声数据输入，通过生成器将噪声数据处理为虚假数据，然后将真实数据和虚假数据都输入判别器以判断对错。




图 8 | 在基于 Transformer 和 CNN 双塔结构的药物 - 靶点相互作用 (DTI) 预测网络中引入联合注意力机制。在预测过程中，卷积神经网络用于处理药物侧的分子图，而 Transformer 模型则用于处理靶点侧的词。

嵌入向量和位置嵌入向量。随后，通过双塔模型处理的数据被整合到联合注意力机制中，以进一步提炼和组织关键特征。

速度慢，而且提升计算能力所需的硬件设备价格昂贵；该模型本身也存在一些局限性，比如算法的并行能力差、可解释性差、参数优化时间长等，模型的泛化能力也较差。要达到模型的最佳效果，需要大量的数据。

因此，从其他领域学习成熟的解决方案思路能够为建模能力的提升提供积极的反馈。以药物 - 靶点对的相互作用预测问题为例，常见的解决方法是将药物和靶点的分子序列数据进行比较，从这种序列数据中提取信息很容易与自然语言处理 (NLP) 领域联

系起来，因此有很多研究人员从 NLP 的角度对药物 - 靶点分子的描述语言数据进行划分处理。

一些常见的推荐系统方法也被引入到药物 - 靶点相互作用 (DTIs) 的预测中：协同过滤方法可以根据相似性推荐靶点，奇异值分解 (SVD) 可以对数据进行降维和降噪处理。郑等人⁵⁷在来自不同信息源的异构数据上构建了多个核函数，然后提出了一种结合协同过滤和 SVD 的联合方法，该方法在多核空间中对数据进行降维和降噪处理后，再进行关联搜索。




图 9 | 注意力机制的常见应用场景。单头注意力机制、交叉注意力机制、混合注意力机制以及多头注意力机制被应用于不同的场景中。

图中模型的位置，指的是注意力机制可以添加到模型的各个模块和阶段，以增强模型的特征捕获能力这一事实。

建议根据相似度排名对潜在的直接交易对手（DTI）进行分类和排序。

药物靶点相互作用（DTI）问题也可以根据所使用数据的类型扩展到计算机视觉（CV）领域。例如，通过使用药物靶点的 3D 结构视觉表示，或者将其简化为 2D 层次来执行包括 3D 模型或图像的相似性判断、目标检测和分割等任务，DTI 预测中可能遇到的诸如结构构型和结合姿态等优化问题，可以通过计算机视觉领域的方法来解决。

挑战与机遇

用于预测的大多数数据集都是不平衡的，正负样本的比例严重失衡，且对负样本的判断标准不够准确。随着数据使用方式变得愈发复杂，对于多模态数据的表示描述、对齐和统一，包括针对不同数据类别的专门化和联合处理方法，需要有更深入的理解。传统机器学习方法逐渐进入瓶颈期，而深度学习能够适应更复杂多样的数据变化，并捕捉到深层潜在知识。药物靶点相互作用（DTI）数据集中的数据量对于深度学习网络来说不够大，参数训练也不充分，难以实现最佳模型性能。随着开放数据源数量的增加，获取数据资源的渠道越来越广，数据信息也愈发丰富。传统方法仅使用单一数据类别进行模型预测，而深度学习网络已逐渐能够处理更深层次的信息。因此，为了挖掘深度网络的预测潜力，可以将更多相关的信息纳入模型，以丰富数据的类别、类型、维度和时间跨度，从而提高对异质数据中隐含相关性信息的挖掘。然而，一些专业数据仍然存在样本量不足的问题。例如，已知三维结构的蛋白质总数与已知序列

的蛋白质总数之间仍存在较大差距。不过，从使用三维结构的模型的预测结果来看，引入三维结构的模型的预测准确率仍能显著高于仅基于序列的预测。由于冷冻电镜技术能够实现更高的精度，蛋白质结构的捕获速度可能会逐渐加快，结构数据的总量也将持续增加。因此，如果能充分利用已知的结构数据，在数据量扩大时，我们就能迅速从模型中获得高质量的预测结果。然而，深度学习也面临一些问题，包括模型训练时间长、参数调整的随机性过大以及可解释性差。从底层探索深度学习预测模型的优化是另一个可能的发展趋势。

同时，包括对最新领域知识的相应运用，拓宽对深度学习方法及其他知识（如计算机视觉、自然语言处理以及最新的大型语言模型）的理解和应用也至关重要。将其他领域成熟的预测方法迁移至药物靶点相互作用（DTI）预测中，也能加速我们对 DTI 的理解和应用。目前，大型模型的发展势头强劲。多个领域已开始积极利用大型模型来调整其相应的训练参数。来自不同领域的研究人员已开始关注大型模型。在生物学领域，已有几位研究人员对大规模问答模型进行了研究。例如，在医疗领域，香港中文大学（深圳）推出了“华佗”等，这一系列研究将大家的目光聚焦于大型语言模型的发展。如果能将 DTI 预测问题与大型语言模型出色的推理和预测能力相结合，DTI 预测模型的能力可能会得到显著提升。

因此，未来的研究可以从数据本身入手，整合和对齐所收集的数据，规范数据表示形式，并改进数据集的样本筛选和构建划分。还可以从多模态模型的联合构建角度提升模型的数据融合处理能力。同时，大模型之间的碰撞也可能带来突破性的创新。

表 5 | 深度学习方法简介

作者	年	数据集	方法描述	特征
赵等人 ^a	2020	DrugBank	利用多源数据改进图表示学习。	与药物、靶点以及药物-靶点对相关的信息被整合到异构图。这种方法丰富了节点信息的含义并且优化了传统图神经网络中过度平滑的现象。
蒙泰罗等人 ^a	2020	私有数据集	基于卷积神经网络 (CNN)，以蛋白质序列作为输入，结构化化合物的简化分子线性输入规范 (SMILES)	这种方法便于从传统描述符中获取数据表。
赵等人 ^a	2020	戴维斯, 基巴	一种基于生成对抗网络 (GANs) 的半监督方法用于预测结合亲和力和。	该方法由两部分组成, 即两个用于特征提取的生成对抗网络 (GAN) 和一个回归模型。用于预测的网络, 这是首个基于半监督生成对抗网络的方法, 以预测结合亲和力和。
金等人 ^a	2021	KIBA	通过序列增强药物靶点相互作用的分子表达预测嵌入和图卷积网络。	对于蛋白质序列, 氨基酸的特征嵌入是通过预训练获得的。语言建模输入卷积神经网络模型以进行表示。
王等人 ^a	2021	DUD-E、人类、BindingDB	由图神经网络和注意力模块组成的多任务神经网络以及一个多层感知器。	出色的多任务处理性能, 在结合亲和力和预测方面表现出色。交互分类
黄等人 ^a	2021	BioSnap、戴维斯、BindingDB	该方法专门选择了一种知识启发式模式挖掘算法用于在此基础上构建子结构和模型, 以模拟数据之间的相互作用。增强型在未标记的数据中也采用了变压器编码器来获取有关其的信息。子结构。	充分利用子结构的解析以及未标记数据的潜在知识。
程等人 ^a	2021	人类、秀丽隐杆线虫、DUD-E DrugBank	基于图神经网络, 对序列的关键结合特征进行探索通过多次注意力机制的两次交互作用。	卷积神经网络会受到卷积窗口大小的影响, 并且能够仅提取窗口区域内的局部相关信息, 而非长距离的相关信息。上下文关系。这种方法能够解决长距离依赖的问题。在某种程度上是有序的。
彭等人 ^a	2021	罗和山下	一种端到端图神经网络学习架构。	此异构网络的输入包含多种生物信息。各种模式、并且学习到数据的低维特征表示形式。在模型训练结束时。
王等人 ^a	2022	私有数据集	药物-靶点对知识图谱的构建。	知识图谱获取推荐信息。
李等人 ^a	2022	罗	图神经网络被用于综合节点属性和拓扑结构。	提取出的低维特征更具代表性, 同时考虑到了节点自身的属性以及节点之间的关系。
于等人 ^a	2022	罗	一种基于信息融合预测药物-靶点相互作用的框架关于结合注意力机制的异构图神经网络机制。	该方法首先获取药物的分子指纹信息以及蛋白质的氨基酸组成信息, 然后提取初始的通过双向长短期记忆网络 (Bi-LSTM) 提取节点特征, 并使用其融合异构邻居的信息注意力机制。
王等人 ^a	2022	罗	一种基于卷积运算预测药物-靶点相互作用的方法整合药物靶点网络信息的异质图神经网络相互作用、药物间相互作用、药物相似性、靶点间相互作用以及目标与目标之间的相似度。	在异构网络中执行图卷积操作以获得药物和靶点的节点嵌入。还引入了一种注意力机制在图卷积层之间, 共同处理来自每个图卷积层的节点嵌入。该模型使用较少的网络类型, 具有较高的预测性能。
阮等人 ^a	2022	PDBbind、Fragalysis	一种基于图神经网络的方法, 引入了多跳门控机制, 以及在面对数据时的原子增强设计新冠病毒数据集不够丰富。	从非邻近信息中可以获得更优的原子表示形式。为了提高模型的训练效果, 作者提到如果数据量很大引入数据集进行迁移学习可以提高模型性能。变得更好。
赵等人 ^a	2022	戴维斯、戴维斯、梅茨、KIBA	基于注意力机制的深度学习在药物靶点结合亲和力和预测中的应用机制。	利用注意力机制聚焦于药物和 (此处原文不完整, 可能应为“药物和疾病相关序列中的重要关键子序列”) 中的重要关键子序列。蛋白质序列以预测亲和力和。
张等人 ^a	2022	Tang、DrugBank、KEGG 以及 PubChem	基于卷积神经网络和图神经网络的 Transformer 深度学习模型网络能够有效提取序列中的局部残差信息, 并且分子结构的相互作用数据。	
王等人 ^a	2022	BindingDB	采用带有损失器的多视图策略来实现降维。矩阵维度, 同时采用端到端模型来降低复杂性。具有特征提取步骤的模型。	简化了获取局部重要特征的学习任务的特征描述工作残留物。
黄等人 ^a	2022	人类、秀丽隐杆线虫、BindingDB 数据库	一种基于 Transformer 的共享注意力机制模型, 用于提取所需内容分别从原始蛋白质序列和药物分子的简化分子线性输入规范 (SMILES) 中获取特征。	将预训练编码器应用于蛋白质编码, 以解决标注稀疏的问题并且引入迁移学习作为预训练的指导。
赵等人 ^a	2022	DrugBank、Davis、KIBA BindingDB	在用于序列局部特征提取的模块中, 卷积神经网络 (CNN) 和变换器 (Transformer) 被使用。结合起来能够在长距离范围内捕获并编码特征信息,	

表 5 (续) 深度学习方法简介			
作者	年	数据集	方法描述
			特征
			通过将药物、靶点和相互作用信息划分为三个模块并进行提取分别提取关键特征，序列中的局部模式信息就能更好地被获取。
王等人 ^a	2022	人类、秀丽隐杆线虫、戴维斯	能够学习构象稳定的原子信息，这表明其原子层面的可解释性。
李等人 ^a	2022	人、DUD-E、BindingDB	关注药物和靶点两方面的可解释性。
兰等人 ^a	2022	摩西	这种综合方法有效地减少了生成的分子数量，并且保留了大部分理论上结合良好的分子。
刘等人 ^a	2022	DUD-E、LIT-PCBA	这种方法在预测结合位点方面表现出色，并已在药物方面得到验证。冠状病毒的筛查。
叶等人 ^a	2022	黄金标准数据集 DrugBank	通过自动编码图、子空间层来增强其学习能力，并且集成层能够从网络输入中提取更多特征，为了更好地训练深度神经网络。
Bae 等人 ^a	2022	戴维斯, BindingDB 数据库	人们已经关注到蛋白质与药物之间的相互关系。亚结构。人们认为是某些特定亚结构之间的相互作用对于这些药物与靶点结合至关重要的亚结构。
乔希等人 ^a	2022	KIBA	这种方法通过聚焦有效地实现了药物分子结构的嵌入。在药物数据处理过程中，对诸如药物分子结构的化学性质进行分析。
梅赫迪等人 ^{a2}	2022	DUD-E、人类、BindingDB	将药物与靶点的关联性关系解释为句子层面的关系。在应用自然语言处理方法的背景下，更强的可解释性。
吴等人 ^a	2022	DrugBank、KEGG	该方法巧妙地将药物-靶点相互作用 (DTIs) 的分类预测问题转化为一个知识图谱中的邻域节点关联预测问题。
李等人 ^a	2022	杂环 A、杂环 B	在层内和层间视角中捕获了更多间接节点信息。从而扩大感知范围，实现注意力感知增强。该方法还发现，扩大感知范围的效果与预期的不同。在层内和层间视角存在不同程度的差异，而当感知到如果场域以相同程度扩展，那么层间感知场域也可以扩展到实现比层内感知域更优的模型预测。
王等人 ^a	2022	戴维斯、Biosnap、DrugBank	局部特征和全局特征分别提取，并通过交叉注意力机制进行耦合。机制，而药物-靶点对的相互作用信息则与一个卷积核进行卷积运算动态生成的滤镜，以实现局部和全局更佳的呈现效果特点。
Qu 等人 ^a	2022	DrugBank (药物数据库)、HPRD (人类蛋白质参考数据库)、HPRD (人类蛋白质参考数据库)、HPRD (人类蛋白质参考数据库)	通过学习节点 (药物、蛋白质) 及其拓扑邻域表示来实现利用受图卷积和网络自发的图自编码器提取高阶结构信息以形成导向网络。
马等 ^a	2022	PubChem、DrugBank、UniProt	多种注意力机制有助于提升模型处理特定任务的能力。要求。
尹等人 ^a	2023	DrugBank 数据集、TwoSides 数据集 DDinner	利用残差图学习药物和蛋白质的结构与序列和网络 (RGCNs) 和卷积神经网络 (CNNs) 以提升药物-药物相互作用 (DDI) 和药物-靶点相互作用 (DTI) 的预测准确性。
张等人 ^a	2023	DrugBank (药物数据库)、UniProt (通用蛋白质数据库)	在包含已知药物靶点相互作用 (DTIs) 的空间中进行特征推断和标签传播未知的药物靶点。
Bian 等人 ^a	2023	戴维斯、KIBA、DrugBank	蛋白质和药物的二维特征图被生成一维特征图，这些特征图然后将其连接并输入全卷积网络 (FCN) 进行分类。它能够有效地解决类别问题。药物-靶点数据集不平衡问题和过拟合问题。

表 5 (续) | 深度学习方法简介

作者	年	数据集	方法描述	特征
文等人 ^a	2023	人类、秀丽隐杆线虫、G 蛋白偶联受体、戴维斯	利用多注意力机制提取序列的长程相互依赖特征 提取原子-氨基酸相互作用特征和机制。	关注内部原子与大分子之间复杂的相互作用 化合物。
卡维普里亚等人 ^a	2023	KEGG BRITE、BRENDA 超细靶点、药物库	一种基于递归神经网络半监督方法 基于 RNN 的双向长短期记忆 (BiLSTM) 模型的方法来处理药物和靶点间的关系 相互作用并作为权重进行初始化。	由于双向长短期记忆 (BiLSTM) 技术的性能受到以下因素的显著影响： 在超参数方面，采用 Adam 优化器在训练过程中对超参数进行调整。 模型训练过程以提高预测性能。
郑等人 ^a	2023	DrugBank (药物数据库)、BindingDB (结合数据库)	结合数据库和具有两个变体编码器-解码器结构的多任务学习机制是 为增强目标特征的提取而引入。	率先应用 MolVec、BERT、注意力机制和多任务机制 归结为一个模型。
朱等人 ^a	2023	戴维斯，基巴	通过提取整个分子的序列特征和亚结构特征来实现 通过自编码器来建立关系，而信息交互路径则是在 在分子和序列之间建立起来的联系，形成了联想学习。 机制。	子结构之间的相关性得到了更好的表达，从而提高了准确性。 DTA 任务预测值中的
索菲亚等人 ^a	2023	戴维斯，基巴	基于卷积神经网络 (CNN)，输入为简化分子线性输入规范 (SMILES) 和蛋白质残基信息。	无需构建相似性矩阵，从而提高了计算效率。 与某些机器学习模型相比。
陈等人 ^a	2023	DrugBank、HPRD、CTD、SIDER	一种嵌入最近邻关系的图表示学习方法 在节点之间，以保持节点间关系拓扑结构不变形 在保持图拓扑结构的同时进行图形学习的过程。	有效地解决了传统图中孤立节点数量众多的问题 卷积自编码器模型。

大型语言模型的应用前景

自 ChatGPT 出现以来，大型语言模型的发展进入了高潮期。人们开始思考大型语言模型在预测药物与靶点相互作用方面的作用。基于文本序列的预测任务一直在稳步发展，但大型模型融入日常工具不可避免地给基于序列的预测方法带来了颠覆性的变革。我们能想到的最根本的变化之一是上下文推理任务中预测的可靠性，此前这类任务一直备受质疑。如今大型模型所展现的智能推理和响应能力极大地增强了我们的信心。因此，许多人正试图为大型模型提供与生物信息学相关的语料库，包括药物和靶点的序列信息、量子化学层面的结构细节、AlphaFold 提供的蛋白质折叠信息等 3D 结构，以及药物副作用、临床特征数据、遗传信息和多维度、多方面的遗传数据等外部相互作用数据。尽管处理如此海量的信息对于单个预测任务而言是一项艰巨的挑战，但对于大型模型而言，更丰富的语料库能产生更准确的推理结果。此外，我们还可以开发智能集成问答系统，从有限的用户输入中推断出预测结果，涵盖简单的医学知识查询和复杂的结构推理查询。同时，基于大型模型的方法也面临着显著的挑战，例如语料库不足、数据对齐困难、单次训练时间长、由于参数调整的不确定性导致的试错成本高以及硬件要求苛刻。然而，很明显，现在是推进基于大型模型的药物靶点相互作用预测的恰当时机。

关于人工智能方法的其他一些担忧

- (1) 数据输入的分解：在数据本身这一维度上，研究人员关注了不同的序列分解方法以及不同类别输入信息对预测性能的影响^{59,60}。例如，Nandhini 等人⁶¹利用分子表示学习中的频繁子序列将药物靶点的原始数据集转换为明确的子结构，并形成上下文相关的相互作用。
- (2) 数据原材料的影响：宏观特征观测值还是微观粒子级数据输入的选择？对于模型构建的维度以及预测方法的性能评估⁶²，研究人员探讨了如何对预测方法进行分类以及优化性能评估，Hinnerichs 等人⁶³将药物-靶点相互作用 (DTI) 预测方法分为“自上而下”的方法，即间接从可观测特征作为原材料进行计算，以及“自下而上”的方法，即直接从分子结构或序列的信息进行计算。Moon 等人⁶⁴提出了两种关键的增强策略，通过引入物理学的信息方程来捕捉原子-原子对相互作用力的四个层次的能量成分，并通过数据增强来提高泛化能力，从而解决深度学习模型泛化能力不足的问题。
- (3) 回归单药分析：模型预测效果的评估最终取决于单药的预测准确性。将药物靶点相互作用 (DTIs) 的预测落实到单药应用层面也是 DTIs 研究的一个重点。Das 等人⁶⁵通过 GDL 方法评估药物进入体内后对 HIV 病毒的作用效果，从而研究了药物对病毒耐药性的预测。这项研究将有助于药物开发后的效果评估。
- (4) 数据隐私与安全问题：用于药物靶点相互作用 (DTI) 预测的数据来源分布广泛，但无论是实验数据、公开数据源，还是涉及 DTI 的数据，都存在数据隐私与安全问题。

诸如患者的临床数据之类的调查数据，要求我们全面考虑数据隐私问题。Gianluca 等人⁶⁶讨论了药物靶点相互作用预测领域中的数据隐私问题。与其他领域相比，在药物靶点相互作用领域，可以构建具有良好隐私和安全性的模型，同时不会影响模型性能。Daniel 等人⁶⁷关于异构数据任务异质性的研究也表明，在药物靶点相互作用预测领域应用统一和标准化的平台来管理私有数据，对预测性能的影响是可以接受的。因此，在追求更多数据的同时，可以采取有效措施来解决公众对数据隐私和安全的担忧。

结论与展望

基于人工智能的药物靶点相互作用 (DTI) 预测所面临的问题和瓶颈包括：

- (1) 数据问题：数据样本有限，正负样本不平衡；数据维度高且存在噪声；数据类型复杂，多模态数据对齐困难；处理 3D 结构存在挑战。
- (2) 机器学习的局限性：需要大量的领域知识，性能受特征质量限制，泛化能力差，对数据依赖性强，不适用于复杂的数据结构，难以处理日益丰富的多模态数据。
- (3) 深度学习的局限性：需要大量数据，可解释性差，需要强大的硬件来提供计算支持，模型调优和优化通常耗时较长。
- (4) 数据安全与隐私问题：数据来源日益丰富，引发了对个人数据合法、公平使用的担忧。建立合法可靠的个人数据交换中心、对个人数据进行匿名化处理以及规范数据资源管理，这些都是关键挑战。

然而，随着人工智能方法的不断进步以及全面的硬件支持，众多前沿方法应运而生。这些方法包括运用生成式人工智能、量子化学以及大型模型。

未来，量子化学方法能够利用粒子层面的信息来处理分子相互作用数据、优化分子结构设计以及预测分子反应。生成式人工智能可以从大量数据输入中学习，预测诸如蛋白质折叠之类的复杂结构，类似于 AlphaFold，从而颠覆性地生成新的化合物。最后，应用于生物信息学的大模型不再局限于简单的问答系统，而是利用其推理能力在端到端的多任务反馈系统中执行分子序列分析、结构预测和分子相互作用预测等任务。

通过将量子化学中的原子信息整合到具有足够多样样本数据和语料库的大型复杂计算系统中，粒子层面的突破可能会带来深远的发展，这或许能让我们更深入地探索微观世界，而不仅仅是药物发现领域。

数据可用性

我们的文章属于综述类。文中相关的统计数据均来自参考文献，我们已在文中予以引用。

收稿日期：2024 年 4 月 25 日；接受日期：2024 年 9 月 12 日；
Published online: 13 January 2025

参考文献

1. Scannell, J. W. et al. Predictive validity in drug discovery: what it is, why it matters and how to improve it. *Nature Reviews Drug Discovery* 21, 915–931 (2022).
2. Jayatunga, M. K., Xie, W., Ruder, L., Schulze, U. & Meier, C. AI in small-molecule drug discovery: a coming wave. *Nat. Rev. Drug Discov* 21, 175–176 (2022).

3. Zhou, M., Zheng, C. & Xu, R. Combining phenome-driven drug-target interaction prediction with patients' electronic health records-based clinical corroboration toward drug discovery. *Bioinformatics* 36, i436–i444 (2020).
4. Zhang, P., Wei, Z., Che, C. & Jin, B. Deepmgt-dti: Transformer network incorporating multilayer graph information for drug-target interaction prediction. *Computers in biology and medicine* 142, 105214 (2022).
5. Lee, J. et al. Drug-target interaction deep learning-based model identifies the flavonoid trolox as a candidate trpv1 antagonist. *Applied Sciences* 13, 5617 (2023).
6. Liu, Z. et al. Ai-based language models powering drug discovery and development. *Drug Discovery Today* 26, 2593–2607 (2021).
7. Ren, F. et al. Alphafold accelerates artificial intelligence powered drug discovery: efficient discovery of a novel cdk20 small molecule inhibitor. *Chemical science* 14, 1443–1452 (2023).
8. Loewa, A., Feng, J. J. & Hedtrich, S. Human disease models in drug development. *Nature reviews bioengineering* 1, 545–559 (2023).
9. Yamanishi, Y., Araki, M., Gutteridge, A., Honda, W. & Kanehisa, M. Prediction of drug-target interaction networks from the integration of chemical and genomic spaces. *Bioinformatics* 24, i232–i240 (2008).
10. Davis, M. I. et al. Comprehensive analysis of kinase inhibitor selectivity. *Nature biotechnology* 29, 1046–1051 (2011).
11. Tang, J. et al. Making sense of large-scale kinase inhibitor bioactivity data sets: a comparative and integrative analysis. *Journal of Chemical Information and Modeling* 54, 735–743 (2014).
12. Liu, T., Lin, Y., Wen, X., Jorissen, R. N. & Gilson, M. K. Bindingdb: a web-accessible database of experimentally determined protein-ligand binding affinities. *Nucleic acids research* 35, D198–D201 (2007).
13. Siebenmorgen, T. et al. Misato: machine learning dataset of protein-ligand complexes for structure-based drug discovery. *Nature Computational Science* 1–12 (2024).
14. Abramson, J. et al. Accurate structure prediction of biomolecular interactions with alphafold 3. *Nature* 1–3 (2024).
15. Hassin, O. & Oren, M. Drugging p53 in cancer: one protein, many targets. *Nature Reviews Drug Discovery* 22, 127–144 (2023).
16. Janizek, J. D. et al. Uncovering expression signatures of synergistic drug responses via ensembles of explainable machine-learning models. *Nature Biomedical Engineering* 7, 811–829 (2023).
17. Lim, J. et al. Predicting drug-target interaction using a novel graph neural network with 3d structure-embedded graph representation. *Journal of chemical information and modeling* 59, 3981–3988 (2019).
18. Wang, J., Shi, Y., Wang, X. & Chang, H. A drug target interaction prediction based on line-rf learning. *Current Bioinformatics* 15, 750–757 (2020).
19. Liao, Z., Huang, X., Mamitsuka, H. & Zhu, S. Drug3d-dti: improved drug-target interaction prediction by incorporating spatial information of small molecules. In (ed.) 2021 IEEE International Conference on Bioinformatics and Biomedicine (BIBM), 340–347 (IEEE, 2021).
20. El-Beheri, H., Attia, A.-F., El-Fishawy, N. & Torkey, H. An ensemble-based drug-target interaction prediction approach using multiple feature information with data balancing. *Journal of Biological Engineering* 16, 1–14 (2022).
21. Torrisi, M., de la Vega de León, A., Climent, G., Loos, R. & Panjkovich, A. Improving the assessment of deep learning models in the context of drug-target interaction prediction. *bioRxiv* 2022–04 (2022).
22. Bagherian, M. et al. Machine learning approaches and databases for prediction of drug-target interaction: a survey paper. *Briefings in bioinformatics* 22, 247–269 (2021).
23. Vamathevan, J. et al. Applications of machine learning in drug discovery and development. *Nature reviews Drug discovery* 18, 463–477 (2019).

24. Yaseen, B. T. & Kurnaz, S. Drug–target interaction prediction using artificial intelligence. *Applied Nanoscience* 13, 3335–3345 (2023).
25. Barkat, M. R., Moussa, S. M. & Badr, N. L. Drug-target interaction prediction using machine learning. In (ed.) 2021 Tenth International Conference on Intelligent Computing and Information Systems (ICICIS), 480–485 (IEEE, 2021).
26. Madhukar, N. S. et al. A bayesian machine learning approach for drug target identification using diverse data types. *Nature communications* 10, 5221 (2019).
27. Islam, S. M., Hossain, S. M. M. & Ray, S. Dti-snnfra: Drug-target interaction prediction by shared nearest neighbors and fuzzy-rough approximation. *PLoS One* 16, e0246920 (2021).
28. Hao, M., Bryant, S. H. & Wang, Y. Predicting drug-target interactions by dual-network integrated logistic matrix factorization. *Scientific reports* 7, 40376 (2017).
29. Song, T. et al. Deepfusion: A deep learning based multi-scale feature fusion method for predicting drug-target interactions. *Methods* 204, 269–277 (2022).
30. Yu, D., Liu, G., Zhao, N., Liu, X. & Guo, M. Fpsc-dti: drug–target interaction prediction based on feature projection fuzzy classification and super cluster fusion. *Molecular Omics* 16, 583–591 (2020).
31. Jamali, A. A., Kusalik, A. & Wu, F. Nmtf-dti: A nonnegative matrix tri-factorization approach with multiple kernel fusion for drug-target interaction prediction. *IEEE/ACM Transactions on Computational Biology and Bioinformatics* (2021).
32. Zhan, X. et al. Prediction of drug-target interactions by ensemble learning method from protein sequence and drug fingerprint. *IEEE Access* 8, 185465–185476 (2020).
33. Chu, Y. et al. Dti-cdf: a cascade deep forest model towards the prediction of drug-target interactions based on hybrid features. *Briefings in Bioinformatics* 22, 451–462 (2021).
34. Liu, B. & Tsoumakas, G. Optimizing area under the curve measures via matrix factorization for predicting drug-target interaction with multiple similarities. *arXiv preprint arXiv:2105.01545* (2021).
35. Azlim Khan, A. K. & Ahamed Hassain Malim, N. H. Comparative studies on resampling techniques in machine learning and deep learning models for drug-target interaction prediction. *Molecules* 28, 1663 (2023).
36. Jin, Y., Lu, J., Shi, R. & Yang, Y. Embeddti: Enhancing the molecular representations via sequence embedding and graph convolutional network for the prediction of drug-target interaction. *Biomolecules* 11, 1783 (2021).
37. Liu, S. et al. Improved drug–target interaction prediction with intermolecular graph transformer. *Briefings in Bioinformatics* 23, bbac162 (2022).
38. Huang, L. et al. Coadti: multi-modal co-attention based framework for drug-target interaction annotation. *Briefings in Bioinformatics* 23, bbac446 (2022).
39. Zheng, Y. et al. A novel deep learning framework for interpretable drug-target interaction prediction with attention and multi-task mechanism. In (ed.) *International Conference on Database Systems for Advanced Applications*, 336–352 (Springer, 2023).
40. Zhao, Q. et al. Gifdti: Prediction of drug-target interactions based on global molecular and intermolecular interaction representation learning. *IEEE/ACM Transactions on Computational Biology and Bioinformatics* (2022).
41. Kenton, J. D. M.-W. C. & Toutanova, L. K. Bert: Pre-training of deep bidirectional transformers for language understanding. In (ed.) *Proceedings of naacL-HLT*, vol. 1, 2 (2019).
42. Kang, H. et al. Fine-tuning of bert model to accurately predict drug–target interactions. *Pharmaceutics* 14, 1710 (2022).
43. Yin, Q. et al. Deepdrug: a general graph-based deep learning framework for drug-drug interactions and drug-target interactions prediction. *Quantitative Biology* 11, 260–274 (2023).
44. Peng, J. et al. An end-to-end heterogeneous graph representation learning-based framework for drug–target interaction prediction. *Briefings in bioinformatics* 22, bbac430 (2021).
45. Li, Y. & Jin, L. A graph convolutional network-based method for drug-target interaction prediction running title: Gcndti. In (ed.) *Journal of Physics: Conference Series*, vol. 2400, 012018 (IOP Publishing, 2022).
46. Qu, X., Du, G., Hu, J. & Cai, Y. Graph-dti: A new model for drug-target interaction prediction based on heterogeneous network graph embedding. *Current Computer-Aided Drug Design* (2023).
47. Yu, L. et al. Hgdti: predicting drug–target interaction by using information aggregation based on heterogeneous graph neural network. *BMC bioinformatics* 23, 126 (2022).
48. Gangwal, A. et al. Generative artificial intelligence in drug discovery: basic framework, recent advances, challenges, and opportunities. *Frontiers in Pharmacology* 15, 1331062 (2024).
49. Guo, Z. et al. Diffusion models in bioinformatics and computational biology. *Nature reviews bioengineering* 2, 136–154 (2024).
50. Zhao, L., Wang, J., Pang, L., Liu, Y. & Zhang, J. Gansdti: Predicting drug-target binding affinity using gans. *Frontiers in genetics* 10, 1243 (2020).
51. Li, M., Cai, X., Li, L., Xu, S. & Ji, H. Heterogeneous graph attention network for drug-target interaction prediction. In (ed.) *Proceedings of the 31st ACM International Conference on Information & Knowledge Management*, 1166–1176 (2022).
52. Wang, W. et al. Gchn-dti: Predicting drug-target interactions by graph convolution on heterogeneous networks. *Methods* 206, 101–107 (2022).
53. Nguyen, D. Q. et al. Towards de novo drug design for the coronavirus: A drug-target interaction prediction approach using atom-enhanced graph neural network with multi-hop gating mechanism. In (ed.) *2022 9th NAFOSTED Conference on Information and Computer Science (NICS)*, 275–280 (IEEE, 2022).
54. Zhang, Y., Feng, Y., Wu, M., Deng, Z. & Wang, S. Vgaedti: Drug-target interaction prediction based on variational inference and graph autoencoder. *BMC bioinformatics* 24, 278 (2023).
55. Zhang, R., Wang, Z., Wang, X., Meng, Z. & Cui, W. Mhtan-dti: Metapath-based hierarchical transformer and attention network for drug–target interaction prediction. *Briefings in Bioinformatics* 24, bbac079 (2023).
56. Chen, P. & Zheng, H. Drug-target interaction prediction based on spatial consistency constraint and graph convolutional autoencoder. *BMC bioinformatics* 24, 1–21 (2023).
57. Zheng, Y. & Zhang, R. A novel drug-target interaction prediction model via singular value decomposition and collaborative filtering. In (ed.) *2022 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)*, 1417–1422 (IEEE, 2022).
58. Chakraborty, C., Bhattacharya, M. & Lee, S.-S. Artificial intelligence enabled chatgpt and large language models in drug target discovery, drug discovery, and development. *Molecular Therapy-Nucleic Acids* 33, 866–868 (2023).
59. Hassanzadeh, R. & Shabani-Mashcool, S. Does adding the drug–drug similarity to drug–target interaction prediction methods make a noticeable improvement in their efficiency? *BMC bioinformatics* 23, 1–14 (2022).
60. Gao, B. et al. Drugclip: Contrastive protein-molecule representation learning for virtual screening. *Advances in Neural Information Processing Systems*, 36 (2024).
61. Nandhini, K. & Mayilvahanan, P. Molecular sub-structural pattern discovery using transformer-cnn-ombo algorithm for drug-target interaction (dti) prediction. In (ed.) *2022 6th International Conference on Trends in Electronics and Informatics (ICOEI)*, 241–247 (IEEE, 2022).
62. Gong, X., Liu, M., Sun, H., Li, M. & Liu, Q. Hs-dti: Drug-target interaction prediction based on hierarchical networks and multi-

- order sequence effect. In (ed.) 2022 IEEE International Conference on Bioinformatics and Biomedicine (BIBM), 322–327 (IEEE, 2022).
63. Hinnerichs, T. & Hoehndorf, R. Dti-voodoo: machine learning over interaction networks and ontology-based background knowledge predicts drug–target interactions. *Bioinformatics* 37, 4835–4843 (2021).
 64. Moon, S., Zhung, W., Yang, S., Lim, J. & Kim, W. Y. Pignet: a physics-informed deep learning model toward generalized drug–target interaction predictions. *Chemical Science* 13, 3661–3673 (2022).
 65. Das, B., Kutsal, M. & Das, R. Effective prediction of drug–target interaction on hiv using deep graph neural networks. *Chemometrics and Intelligent Laboratory Systems* 230, 104676 (2022).
 66. Mittone, G., Svoboda, F., Aldinucci, M., Lane, N. & Lió, P. A federated learning benchmark for drug–target interaction. In (ed.) Companion Proceedings of the ACM Web Conference 2023, 1177–1181 (2023).
 67. Sándor, D. & Antal, P. Transfer learning in heterogeneous drug–target interaction predictions using federated boosting. *bioRxiv* 2023–01 (2023).
 68. Devlin, J., Chang, M.-W., Lee, K. & Toutanova, K. BERT: Pre-training of deep bidirectional transformers for language understanding. In Burstein, J., Doran, C. & Solorio, T. (eds.) Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers), 4171–4186 (Association for Computational Linguistics, Minneapolis, Minnesota, 2019). <https://aclanthology.org/N19-1423>.
 69. Hu, L. et al. Sselm-neg: spherical search-based extreme learning machine for drug–target interaction prediction. *BMC bioinformatics* 24, 38 (2023).
 70. Yang, J., He, S., Zhang, Z. & Bo, X. Negstacking: Drug–target interaction prediction based on ensemble learning and logistic regression. *IEEE/ACM Transactions on Computational Biology and Bioinformatics* 18, 2624–2634 (2020).
 71. Calangian, M. T. F. & Magboo, V. P. C. Predicting drug–target interaction (dti) based on machine learning with lasso dimensionality reduction and smote from protein sequence and drug fingerprint. In (ed.) 2022 International Conference on Electrical, Computer and Energy Technologies (ICECET), 1–6 (IEEE, 2022).
 72. Li, Y., Qiao, G., Gao, X. & Wang, G. Supervised graph co-contrastive learning for drug–target interaction prediction. *Bioinformatics* 38, 2847–2854 (2022).
 73. Nguyen, T. M., Nguyen, T. & Tran, T. Mitigating cold-start problems in drug–target affinity prediction with interaction knowledge transferring. *Briefings in Bioinformatics* 23, bbac269 (2022).
 74. Ye, Y. et al. Drug–target interaction prediction based on nonnegative and self-representative matrix factorization. In (ed.) 2021 IEEE International Conference on Bioinformatics and Biomedicine (BIBM), 2352–2359 (IEEE, 2021).
 75. Ahn, S., Lee, S. E. & Kim, M.-h. Random-forest model for drug–target interaction prediction via kullback–leibler divergence. *Journal of Cheminformatics* 14, 1–13 (2022).
 76. Ozsert Yigit, G. & Baransel, C. A novel autoencoder-based feature selection method for drug–target interaction prediction with human-interpretable feature weights. *Symmetry* 15, 192 (2023).
 77. Liu, B., Papadopoulos, D., Malliaros, F. D., Tsoumakas, G. & Papadopoulos, A. N. Multiple similarity drug–target interaction prediction with random walks and matrix factorization. *Briefings in Bioinformatics* 23, bbac353 (2022).
 78. Zhao, Y. et al. Dldti: a learning-based framework for drug–target interaction identification using neural networks and network representation. *Journal of Translational Medicine* 18, 1–15 (2020).
 79. Monteiro, N. R., Ribeiro, B. & Arrais, J. P. Drug–target interaction prediction: end-to-end deep learning approach. *IEEE/ACM transactions on computational biology and bioinformatics* 18, 2364–2374 (2020).
 80. Wang, S., Shan, P., Zhao, Y. & Zuo, L. Gandti: a multi-task neural network for drug–target interaction prediction. *Computational Biology and Chemistry* 92, 107476 (2021).
 81. Huang, K., Xiao, C., Glass, L. M. & Sun, J. Moltrans: molecular interaction transformer for drug–target interaction prediction. *Bioinformatics* 37, 830–836 (2021).
 82. Cheng, Z., Yan, C., Wu, F.-X. & Wang, J. Drug–target interaction prediction using multi-head self-attention and graph attention network. *IEEE/ACM Transactions on Computational Biology and Bioinformatics* 19, 2208–2218 (2021).
 83. Wang, S., Du, Z., Ding, M., Rodriguez-Paton, A. & Song, T. Kg-dti: a knowledge graph based deep learning method for drug–target interaction predictions and alzheimer’s disease drug repositions. *Applied Intelligence* 52, 846–857 (2022).
 84. Zhao, Q. et al. Attentiondta: Drug–target binding affinity prediction by sequence-based deep learning with attention mechanism. *IEEE/ACM Transactions on Computational Biology and Bioinformatics* 20, 852–863 (2022).
 85. Wang, G. et al. Multi-transdti: transformer for drug–target interaction prediction based on simple universal dictionaries with multi-view strategy. *Biomolecules* 12, 644 (2022).
 86. Wang, T. & Liu, X. A graph convolution-transformer neural network for drug–target interaction prediction. In (ed.) Proceedings of the 14th International Conference on Bioinformatics and Biomedical Technology, 145–150 (2022).
 87. Li, F., Zhang, Z., Guan, J. & Zhou, S. Effective drug–target interaction prediction with mutual interaction neural network. *Bioinformatics* 38, 3582–3589 (2022).
 88. Ranjan, A., Shukla, S., Datta, D. & Misra, R. Generating novel molecule for target protein (sars-cov-2) using drug–target interaction based on graph neural network. *Network Modeling Analysis in Health Informatics and Bioinformatics* 11, 1–11 (2022).
 89. Ye, Q., Zhang, X. & Lin, X. Drug–target interaction prediction via graph auto-encoder and multi-subspace deep neural networks. *IEEE/ACM Transactions on Computational Biology and Bioinformatics* (2022).
 90. Bae, H. & Nam, H. Graphatt-dta: Attention-based novel representation of interaction to predict drug–target binding affinity. *Biomedicine* 11, 67 (2022).
 91. Joshy, A., Kasyap, G. C., Reddy, P. D., Anjusha, I. & Nazeer, K. A. Drug target interaction prediction using graph convolution based neural fingerprinting. In (ed.) 2022 IEEE 19th India Council International Conference (INDICON), 1–6 (IEEE, 2022).
 92. Yazdani-Jahromi, M. et al. Attentionsitedti: an interpretable graph-based model for drug–target interaction prediction using nlp sentence-level relation classification. *Briefings in Bioinformatics* 23, bbac272 (2022).
 93. Wu, Z., Zhang, X. & Lin, X. Kgat: Predicting drug–target interaction based on knowledge graph attention network. In (ed.) International Conference on Intelligent Computing, 438–450 (Springer, 2022).
 94. Wang, T., Yang, W., Chen, J., Tian, Y. & Wei, D.-Q. Conformerdti: Local features coupling global representations for drug–target interaction prediction. In (ed.) 2022 IEEE International Conference on Bioinformatics and Biomedicine (BIBM), 1227–1234 (IEEE, 2022).
 95. Ma, X. & Cheng, Y. Prediction of drug–target interaction based on multi-head self-attention. In (ed.) 2022 IEEE Conference on Telecommunications, Optics and Computer Science (TOCS), 937–940 (IEEE, 2022).
 96. Bian, J., Zhang, X., Zhang, X., Xu, D. & Wang, G. Mcanet: shared-weight-based multi-head cross attention network for drug–target interaction prediction. *Briefings in Bioinformatics* 24, bbad082 (2023).
 97. Wen, J. et al. Mutual-dti: A mutual interaction feature-based neural network for drug–target protein interaction prediction. *Mathematical Biosciences and Engineering: MBE* 20, 10610–10625 (2023).
 98. Kavipriya, G. & Manjula, D. Drug–target interaction prediction model using optimal recurrent neural network. *Intelligent Automation & Soft Computing* 35 (2023).

99. Zhu, Z. et al. Associative learning mechanism for drug-target interaction prediction. *CAAI Transactions on Intelligence Technology* (2023).
100. D' Souza, S., Prema, K., Balaji, S. & Shah, R. Deep learning-based modeling of drug-target interaction prediction incorporating binding site information of proteins. *Interdisciplinary Sciences: Computational Life Sciences* 15, 306–315 (2023).

致谢

本研究得到了哈尔滨商业大学青年科研创新人才培养计划 YR 2023 (2023-KYYWF-0979)；国家自然科学基金 (62172076, 62425107, U22A2038)；浙江省自然科学基金 (LY23F020003)；以及衢州市人民政府 (2023D038) 的支持。

作者贡献

钱廖构思并撰写了该手稿。于章、英楚、易丁、真柳、王亦正和赵先义进行了数据收集。丁一杰、普拉亚格·蒂瓦里、邹权和韩柯撰写了手稿并进行了修订。所有作者均已阅读并批准了最终手稿。

资金

本文由哈尔姆斯塔德大学提供开放获取资金支持。

利益冲突

作者声明不存在利益冲突。

附加信息

来信及索取资料请寄给丁一杰、普拉亚格·蒂瓦里、邹权或韩珂。

有关转载和使用许可的信息，请访问 <http://www.nature.com/reprints>。

出版者注：施普林格·自然对于所发表的地图中涉及的管辖权主张以及机构隶属关系保持中立。

开放获取 本文依据知识共享署名 4.0 国际许可协议 (Creative Commons Attribution 4.0 International License) 发布，该协议允许在任何媒介或格式下使用、分享、改编、分发和复制，但须注明原作者和来源，提供知识共享许可协议的链接，并说明是否对内容进行了修改。除非另有说明，本文中的图片或其他第三方材料均受文章的知识共享许可协议约束。如果材料未包含在文章的知识共享许可协议中，且您的使用意图不受法规限制或超出许可范围，您需要直接从版权所有者处获得许可。如需查看此许可的副本，请访问 <http://creativecommons.org/licenses/by/4.0/>。

© 作者（们） 2025 年