

人工智能加速了药物与靶点相互作用的科学发现进程

Yuxin Yang ^{1,2} | Feixiong Cheng ^{1,2,3,4}

¹美国俄亥俄州克利夫兰市克利夫兰诊所勒纳研究所克利夫兰诊所基因组中心

²美国俄亥俄州克利夫兰市克利夫兰诊所勒纳研究所基因组医学研究所

³美国俄亥俄州克利夫兰市克利夫兰诊所勒纳医学院分子医学系, 凯斯西储大学

⁴凯斯西储大学医学院凯斯综合癌症中心, 美国俄亥俄州克利夫兰市

通信; 信件; 对应关系

程飞雄, 美国克利夫兰诊所基因组中心, 勒纳研究所, 克利夫兰诊所, 俄亥俄州克利夫兰市。电子邮箱: chengf@ccf.org

资金信息

美国国家老龄化研究所, 资助/奖励编号: R01AG066707、R01AG076448、R01AG082118、R01AG084250、R21AG083003、RF1AG082211、U01AG073323; 美国国家神经疾病与中风研究所, 资助/奖励编号: RF1NS133812; 阿尔茨海默病协会, 资助/奖励编号: ALZDISCOVERY-1051936

摘要

药物发现是一个复杂的过程, 通过该过程可识别出用于预防和治疗特定疾病的新疗法。药物靶点相互作用 (DTIs) 的识别是药物发现与开发领域中的关键环节。传统的药物发现过程, 尤其是 DTIs 的识别, 实验检测成本高昂且成功率低。计算方法已成为不可或缺的工具, 尤其是那些采用人工智能 (AI) 方法的手段, 能够简化这一过程, 从而降低成本、减少时间消耗, 并有可能提高成功率。在本综述中, 我们重点关注 AI 技术在 DTI 预测中的应用。具体而言, 我们首先对药物发现与开发进行全面概述, 以及 DTIs 的系统预测与验证。接着, 我们着重介绍用于开发 DTI 预测 AI 方法的突出数据库和工具包, 以及评估其效果的方法。我们进一步探讨了用于药物靶点相互作用预测的三种主要的前沿人工智能方法, 包括经典机器学习、深度学习和基于网络的方法。最后, 我们总结了关键发现, 并概述了人工智能方法在科学药物发现和开发中面临的当前挑战和未来方向。

关键词

人工智能, 药物靶点相互作用

1 | 引言

药物研发在医学和医疗保健领域仍是一项艰巨的挑战, 而药物靶点相互作用 (DTIs) 的识别则是其中的关键所在 (Zeng 等人, 2019 年; Zeng, Zhu 等人,

(et al., 2020b)。药物靶点相互作用 (DTIs) 揭示药物化合物能否与靶蛋白结合, 并阐明这种结合相互作用是如何发生的。传统识别 DTIs 的方法严重依赖成本高昂且耗时的体外和体内实验 (Paul 等人, 2010)。然而, 计算技术的最新进展, 尤其是人工智能 (AI) 方法, 在这一领域取得了显著成就 (Zeng 等人, 2019; Zeng, Wang 等人, 2022a; Zeng, Zhu 等人, 2020b)。AI 方法具有诸多优势, 如预测精度高、成本低以及预测速度快 (Ye 等人, 2021)。

Abbreviations: AD, Alzheimer's disease; AI, artificial intelligence; AUROC, area under the receiver operating characteristic; BERT, bidirectional encoder representations from transformers; DTIs, drug-target interactions; GAT, graph attention network; GCN, graph convolutional network; MS, multiple sclerosis; R, Pearson correlation coefficient; UniProt, Universal Protein Resource.

This is an open access article under the terms of the [Creative Commons Attribution-NonCommercial-NoDerivs](https://creativecommons.org/licenses/by-nc-nd/4.0/) License, which permits use and distribution in any medium, provided the original work is properly cited, the use is non-commercial and no modifications or adaptations are made.

©2025 The Author(s). British Journal of Pharmacology published by John Wiley & Sons Ltd on behalf of British Pharmacological Society.

在药物靶点相互作用 (DTI) 预测的早期应用中, 人工智能方法主要利用了传统的机器学习方法, 这些方法依赖于人工整理的药物或靶点的描述符或特征 (Bagherian 等人, 2021 年; Vamathevan 等人, 2019 年)。然而, 这些方法的一个显著挑战在于其对固定大小输入的要求, 这限制了它们在不同数据集上的泛化能力。相比之下, 深度学习方法因其能够处理更大规模的数据集、表现更优以及能够学习输入数据与输出之间的复杂关系而受到青睐 (LeCun 等人, 2015 年)。深度学习在计算机视觉 (Voulodimos 等人, 2018 年)、自然语言处理 (Otter 等人, 2020 年) 和强化学习 (Arulkumaran 等人, 2017 年) 等不同领域的成功应用, 推动了其在 DTI 预测中的应用。

过去十年, 得益于化合物、物质和蛋白质数据的广泛可用性, 计算能力的提升以及日益复杂的 AI 算法, 基于人工智能的药物靶点相互作用 (DTI) 预测研究蓬勃发展。尽管已有若干综述文章聚焦于计算药物发现中的 AI 方法, 但它们往往侧重于特定的方法, 例如深度学习方法 (Abbasi 等人, 2021 年; Askr 等人, 2023 年)、基于特征的机器学习方法 (Sachdev 和 Gupta, 2019 年)、基于分子相似性的机器学习方法 (Ding 等人, 2014 年) 以及基于网络的方法 (Liu 等人, 2020 年; Zeng、Zhu 等人, 2020 年 b)。然而, 对于涵盖所有 AI 技术在 DTI 预测中的应用的全面综述, 仍存在迫切需求。为填补这一空白, 本综述旨在对 AI 技术在 DTI 预测中的应用提供一个综合概述。具体而言, 我们首先总结了用于 DTI 预测和交叉验证的常用数据库、工具和评估指标。随后, 我们概述了人工智能技术, 特别是经典机器学习方法、深度学习方法及其在药物靶点相互作用 (DTI) 预测中的应用。此外, 我们还强调了人工智能技术在药物再利用中的应用, 这是 DTI 预测的一个特殊案例。最后, 我们通过讨论可能阻碍人工智能技术在 DTI 预测中发展的挑战和未来方向来结束这篇综述。

2 | 数据库、工具和评估指标

2.1 | 适用于人工智能的开放数据

多个数据库为药物靶点相互作用 (DTI) 的预测提供了关键数据, 涵盖配体化合物信息、靶蛋白信息以及相互作用信息。这些数据库通常可以分为三类: 以药物为中心的数据库、以靶点为中心的数据库和结合数据库。以药物为中心的数据库的著名例子包括 DrugBank (Wishart 等人, 2018 年) 和 ChEMBL (Gaulton 等人, 2012 年)。DrugBank Online 的最新版本 (2024 年 3 月 14 日发布的 5.1.12 版) 包含 17085 种药物, 其中包括 2786 种获批的小分子药物、1629 种获批的生物制剂以及许多处于临床或实验研究阶段的其他分子。ChEMBL 存储了超过 240 万种具有生物活性的类药化合物的

2D 结构、多种性质和生物活性 (2024 年 3 月 28 日更新的 ChEMBL34 版)。以靶点为中心的数据库的示例包括通用蛋白质资源 (UniProt) (UniProt 联盟, 2019 年)、蛋白质数据库 (PDB) (Berman 等人, 2000 年) 和 AlphaFold 蛋白质结构数据库 (Varadi 等人, 2024 年)。UniProt 存储了超过 2.45 亿种蛋白质的序列、功能和性质 (2024 年 7 月访问)。然而, 仅有不到 60 万种蛋白质经过了专家的手工注释和审核。据估计, 人类蛋白质组包含超过 82000 种蛋白质 (UniProt 蛋白质组: UP000005640)。蛋白质数据库 (Protein Data Bank) 收录了超过 20 万种通过 X 射线晶体学和核磁共振 (NMR) 光谱等实验方法测定的蛋白质三维结构数据。这些实验方法能够提供高度精确的蛋白质结构数据, 但其特点是成本高昂且进展缓慢。近年来, 计算方法, 尤其是人工智能方法在蛋白质结构预测方面的进步彻底改变了蛋白质结构发现的格局。AlphaFold 蛋白质结构数据库收录了超过 2.14 亿种由 AlphaFold2 预测的蛋白质结构 (Jumper 等人, 2021 年)。BindingDB (Gilson 等人, 2016 年) 和 PDBbind (Wang 等人, 2005 年) 是记录药物与靶点结合亲和力和信息的数据库。BindingDB 包含超过 290 万次测量数据, 涉及超过 130 万种化合物和超过 9000 个靶点。表 1 对用于识别药物 - 靶点相互作用 (DTI) 的常用数据库进行了全面概述。

2.2 | 分子表示工具

有多种工具可用于计算药物和靶点的物理化学特征。在此, 我们将常用的工具包分为三类: 用于计算特征向量的工具、用于计算相似性的工具以及用于生成结构的工具。

2.2.1 | 计算特征向量的工具

1. PaDEL (Yap, 2011): PaDEL is a software that calculates descriptors and fingerprints for molecules. PaDEL can compute 1875 different 1D, 2D and 3D descriptors and 12 types of finger-prints. PaDEL can take both molecular structure file and SMILES string as input.
2. ProtDCal (Ruiz-Blanco et al., 2015): ProtDCal is a software to compute features for proteins based on 3D structures and amino acid sequences. ProtDCal can generate 1998 features where 999 features are from sequence and 999 features are from structure.
3. ProtParam (Gasteiger et al., 2005): ProtParam is a web server that can compute numerous features of proteins, including molecular weight, atomic composition and amino acid composition. Prot-Param only takes amino acid sequences as input.
4. PubChemPy (斯温, 2014 年): PubChemPy 是一个 Python 工具包, 它使用户能够计算化学指纹。所有的计算工作都是通过 PubChem 的数据库和工具包在 PubChem 的服务器上完成的。

表 1 药物 - 靶点相互作用预测中常用的数据库。

数据库名称	描述	链接
以药物为重点的数据库		
DrugBank (Wishart 等人, 2018 年)	一个包含药物及药物靶点的数据库, 其中包含化学、药理学、序列、结构及其他信息。	https://go.drugbank.com/
ChEMBL (高尔顿等人, 2012 年)	一个经过人工整理的药物类生物活性化合物数据库, 其中包含结合、功能及其他信息。	https://www.ebi.ac.uk/chembl/
锌 20 (伊尔温等人, 2020 年)	一个包含有商业可得且已注释化合物的数据库。	https://zinc20.docking.org/
PubChem (Kim 等人, 2023 年)	一个包含各种分子属性、特征、结构及其他信息的分子数据库。	https://pubchem.ncbi.nlm.nih.gov/
DrugCentral (Ursu 等人, 2016 年)	一个包含药物使用说明、剂量、吸收、分布、代谢、排泄和毒性 (ADMET) 特性以及其他信息的数据库。	https://drugcentral.org/
SIDER (库恩等人, 2010 年)	一个包含已上市药品的副作用和不良反应的数据库。	http://sideeffects.embl.de/
目标导向型数据库		
UniProt (UniProt 基金会, 2019 年)	一个包含蛋白质序列、结构和功能信息的数据库。	https://www.uniprot.org/
蛋白质数据库 (伯曼等人, 2000 年)	一个由实验测定的蛋白质三维结构数据库。	https://www.rcsb.org/
AlphaFold 蛋白质结构数据库 (Jumper 等人, 2021 年)	一个托管由 AlphaFold2 预测的蛋白质结构的数据库。	https://alphafold.ebi.ac.uk/
结合相互作用数据库		
BindingDB (吉尔森等人, 2016 年)	一个包含蛋白质与类药小分子结合亲和力的数据库。	http://www.bindingdb.org/
PDBbind (王等人, 2005 年)	一个通过实验测定的化合物与蛋白质相互作用的结合亲和力数据的数据库。	http://www.pdbbind.org.cn/

2.2.2 | 计算分子相似性的工具

1. 相似化合物 (SIMCOMP) (Hattori 等人, 2010 年) : SIMCOMP 是一种基于图的化学结构比较方法。每个图代表一种化学化合物, 节点代表原子, 边代表共价键。药物相似性是根据两种药物结构之间的最大公共子结构来计算的。
2. 基于 R 编程语言的复合物 - 蛋白质相互作用 (Rcpi) (Cao 等人, 2015 年) : Rcpi 是 R 编程语言中的一个软件包, 提供了多种功能, 包括相似性计算。蛋白质之间的相似性源自蛋白质序列比对和基因本体论 (GO) 语义相似性。化合物之间的相似性则基于分子指纹和最大公共子结构。

2.2.3 | 生成化学结构的工具

1. Open Babel (O'Boyle 等人, 2011 年) : Open Babel 是一款软件, 具备多项对药物研发至关重要的功能, 尤其是能够从简化分子线性输入规范 (SMILES) 字符串生成分子的二维和三维结构。
2. RDKit (兰德鲁姆, 2013 年) : RDKit 是一套化学信息学工具, 其重要特性之一是从 SMILES 字符串生成分子的二维和三维结构。RD

Kit 可用于多种编程语言, 包括 C++ 和 Python。

虽然一些化学信息学工具包和软件仅提供单一功能, 但另一些则提供全面的功能套件。例如, RDKit 不仅能生成二维和三维分子结构, 还能计算分子的特征向量并执行相似性计算。RDKit 的这种多功能性, 再加上其用户友好的 Python 接口 (构建 AI 模型最流行的编程语言), 使其成为药物发现领域研究人员的热门选择。研究人员可以利用 RDKit 的多种功能来简化基于 AI 的药物发现框架中的各种任务。

2.3 | 指标

评估指标为衡量人工智能驱动的药物靶点相互作用 (DTI) 预测方法的性能提供了定量手段, 这些方法分为分类和回归两类任务, 每类任务采用不同的评估指标。分类任务常用的评估指标包括以下几种:

1. 正例与负例: 真阳性 (TP)、真阴性 (TN)、假阳性 (FP) 和假阴性 (FN) 是根据正例和负例标签来描述正确和错误预测的术语。

2. 准确性：准确性衡量的是在整个数据集中正确预测的比例：

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

3. 精确度：精确度衡量的是在所有预测为正的结果中，正确预测为正的结果所占的比例：

$$Precision = \frac{TP}{TP + FP}$$

4. 召回率：召回率衡量的是正确预测为正样本的数量占所有实际正样本数量的比例：

$$Recall = \frac{TP}{TP + FN}$$

5. F1 值：F1 值是准确率和召回率的调和平均值：

$$F1 = \frac{2 \times TP}{2 \times TP + FP + FN}$$

6. 受试者工作特征（ROC）曲线：ROC 曲线展示了在不同判别阈值下真阳性（TP）率与假阳性（FP）率之间的关系。

当数据集在不同类别间分布均衡时，准确率和受试者工作特征曲线（ROC 曲线）下的面积（AUROC）是评估模型性能的良好选择。然而，当数据集不平衡时，准确率和 AUROC 曲线可能会产生误导。例如，如果数据集中负样本多于正样本，而模型仅擅长预测负样本而不擅长预测正样本，AUROC 曲线仍可能很高。在这种情况下，使用 F1 值是更好的选择，因为 F1 值能更公平地评估模型（Jeni 等人，2013 年）。

回归任务中常用的评估指标包括以下几种：

1. 平均绝对误差（MAE）：MAE 用于评估预测值与实际值之间的绝对误差：

$$MAE = \frac{\sum_{i=1}^n |x_i - y_i|}{n}$$

2. 均方根误差（RMSE）：均方根误差用于评估预测值与实际值之间的差异，考虑了它们差值的平方：

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (x_i - y_i)^2}{n}}$$

3. 均方对数误差（MSLE）：MSLE 评估预测值与实际值之间的平方对数误差：

$$MSLE = \frac{\sum_{i=1}^n (\log(x_i + 1) - \log(y_i + 1))^2}{n}$$

4. 平均绝对百分比误差（MAPE）：MAPE 用于评估回归模型的预测准确性，且不受目标变量缩放的影响：

$$MAPE = 100 \times \frac{\sum_{i=1}^n \frac{|x_i - y_i|}{x_i}}{n}$$

5. 皮尔逊相关系数（R）：皮尔逊 R 相关系数用于评估预测值与实际值之间的线性相关程度：

$$R = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}}$$

在上述评估指标中， x_i 表示实际（观测）值，而 y_i 表示数据集内每个数据点 i 的预测值， $\bar{x}$ 和 $\bar{y}$ 分别表示实际值和预测值的平均值。与均方根误差（RMSE）相比，平均绝对误差对异常值不那么敏感。这是因为均方根误差的计算过程中会将异常值平方，从而导致其对最终指标的影响过大。因此，当数据集包含大量异常值时，平均绝对误差是更好的选择。当误差尺度应与目标尺度相匹配时，均方根误差是更好的选择，因为均方根误差更依赖于尺度。平均绝对百分比误差将误差表示为实际差值的百分比，使其成为与尺度无关的指标。然而，对于实际目标变量中包含零值的数据集，平均绝对百分比误差可能会出现除零未定义的问题。此外，平均绝对误差（MAE）和平均绝对百分比误差（MAPE）的计算通常比其他评估指标的计算成本更低。最终，评估指标的最佳选择取决于特定的药物 - 靶点相互作用（DTI）预测任务和数据集的特点。

3 | 基于人工智能的药物-靶点相互作用（DTI）预测

在 DTI 预测领域，常用的 AI 技术包括六种主要模型类型：基于特征向量的模型、基于相似性的模型、基于序列的模型、基于网络的模型

模型包括基于模型的模型、基于图像的模型和基于结构的模型 (Zeng, Wang 等人, 2022a)。将人工智能模型应用于预测药物-靶点相互作用 (DTIs) 包含三个基本步骤: 数据集处理、模型训练和预测。数据集处理涉及从输入的药物和靶点数据中提取重要特征, 或者直接使用原始数据。随后, 将数据集分为三个子集: 训练集、验证集和测试集, 其中训练集用于

为了促进人工智能模型的学习过程, 验证集用于微调人工智能模型的超参数, 而测试集则用于评估人工智能模型在未见过的数据上的表现 (图 1)。在此之后, 训练好的人工智能模型将应用于 DTI 数据的测试集, 以及可能在训练过程中未观察到的其他数据。

人工智能模型的架构和训练方法必须根据特定的药物靶点相互作用 (DTI) 预测任务以及可用的数据集进行调整。对于分类任务, 例如确定某种药物是否与给定的靶点相互作用, 模型应输出二元预测结果。相比之下, 回归任务, 如估计药物与靶点之间的结合亲和力, 则需要模型生成连续的数值输出。这种预测目标的根本区别要求对模型的结构、损失函数和评估指标进行适当的调整, 以确保在预期的 DTI 预测场景中实现最佳性能。在接下来的部分中, 我们将深入探讨用于 DTI 预测的人工智能模型的复杂性, 并在表 2 中简要介绍这些人工智能方法的优势和劣势。

3.1 | 基于指纹的模型

基于指纹的模型首先计算药物和靶蛋白的物理化学指纹 (图 2a 左侧)。这些指纹捕捉了相关的化学特征, 通常使用圆形指纹 (Glen 等人, 2006 年)、分子访问系统 (MACCS) 指纹 (Cereto-Massague 等人, 2015 年; Durant 等人, 2002 年) 和 PubChem 指纹 (Fernandez-de Gortari 等人, 2017 年) 来表示。为了提高经典机器学习模型的计算效率, 并可能减少冗余特征, 可以采用降维技术。主成分分析 (PCA) (Wold 等人, 1987 年) 是常用的选择, 还有诸如 t 分布随机邻域嵌入 (t-SNE) (Hinton 和 Roweis, 2002 年)、非负矩阵分解 (NMF) (Sra 和 Dhillon, 2005 年)、奇异值分解 (SVD) (Golub 和 Reinsch, 1971 年) 和均匀流形近似与投影 (UMAP) (McInnes 等人, 2018 年) 等技术。主成分分析和 UMAP 倾向于捕捉整个数据集的全局特征, 而 t 分布随机邻域嵌入 (t-SNE) 则倾向于保持数据样本之间的局部关系。在特征计算和可能的降维之后, 会采用不同的经典机器学习模型来学习这些特征并预测药物-靶点相互作用 (DTIs)。这些模型可以分为分类模型, 如支持向量机 (SVM) (Hearst 等人, 1998 年) 和随机森林 (RF) (Breiman, 2001 年), 或者回归模型, 如贝叶斯回归 (Bishop 和 Tipping, 2003 年) 或逻辑回归 (Kleinbaum 等人, 2002 年)。早期使用基于特征的方法进行 DTI 预测的研究通常依赖于单一模型架构。例如, Wang 等人 (2010 年) 基于支持向量机的模型、Ahn 等人 (2022 年) 和 Shi 等人 (2019 年) 基于随机森林的模型, 以及 Zhan 等人 (2020 年) 的旋转森林模型。然而, 这些单一模型的方法在实现更优性能和泛化能力方面存在局限性。近年来的发展见证了这一趋势的转变。




图 1 人工智能 (AI) 技术在药物发现中的应用流程。整个流程包含几个关键步骤。数据采集与预处理涉及药物、靶点以及潜在疾病和疾病相关基因的数据集收集。然后对数据进行处理, 并将其分为三个子集: 用于训练 AI 模型的训练数据集; 用于帮助调整超参数的验证数据集; 以及用于评估 AI 模型性能的测试数据集。AI 模型的训练是基于训练数据集找到模型的最优参数。超参数调整是找到 AI 模型的最佳超参数集, 以便模型能利用现有训练数据发挥最佳性能。对于数据驱动的 AI 模型 (如经典机器学习或深度学习模型), 超参数调整主要包括选择最优的模型架构 (如隐藏层的数量和激活函数) 以及更优的优化策略, 包括学习率和训练迭代次数。然而, 基于知识的人工智能模型 (例如基于网络的模型) 需要选择与知识相关的最优超参数, 例如药物-靶点相互作用逻辑以及药物-靶点相互作用网络的拓扑特征。使用训练数据集中未包含的数据对人工智能模型进行测试, 可以确认该人工智能模型的泛化能力。

表 2 近期开发的用于预测药物 - 靶点相互作用的人工智能方法。

模型类型	模型	描述	年
经典机器学习模型	基于特征向量的模型		
	王等人 (王等人, 2010 年)	一种支持向量机 (SVM) 模型, 该模型利用从药物 - 蛋白质对中提取的特征来预测药物 - 目标相互作用 (DTIs)。	2010
	安等人 (安等人, 2022 年)	一种使用 KLD 计算药物特征以预测药物靶点相互作用 (DTIs) 的随机森林 (RF) 模型。	2022
	施等人 (施等人, 2019 年)	一种使用 LASSO 和 RF 来预测药物 - 靶点相互作用 (DTIs) 的集成模型。药物 - 靶点特征通过 PsePSSM 和 FP2 分子指纹提取。	2019
	詹等人 (詹等人, 2020 年)	一种使用 LOOP 和 PSSM 计算得出的药物特征的射频模型。该模型在酶、离子通道、G 蛋白偶联受体和核受体数据上也取得了超越基准数据的高精度。	2020
	NegStacking (杨等人, 2020 年)	一种集成决策树和逻辑回归的集成模型, 用于预测药物 - 靶点相互作用 (DTI)。NegStacking 创新性地利用了数据集中大量的负样本, 从而提升了模型性能。	2020
	埃扎特等人 (Ezzat 等人, 2017 年)	该集成模型结合了降维、决策树和核岭回归器来预测药物 - 靶点相互作用 (DTI)。本研究中使用的特征包括药物的组成、拓扑和几何描述符以及靶蛋白的氨基酸组成、伪氨基酸组成和 CTD 描述符。	2017
	基于相似性的模型		
	布莱克利和山下 (布莱克利和山下, 2009 年)	一种基于二分图局部模型的相似性模型。药物 - 靶点相互作用 (DTIs) 在二分图中表示。该模型既能根据给定的药物预测靶点蛋白, 也能根据给定的靶点蛋白预测潜在药物。	2009
	DrugE-Rank (Yuan 等人, 2016 年)	DrugE-Rank 是一种借鉴集成学习理念的基于相似性的模型。它由六个机器学习组件构成。DrugE-Rank 已通过美国食品药品监督管理局 (FDA) 批准的药物和 FDA 实验药物进行了全面验证。	2016
深度学习模型	雅各布和韦特 (雅各布和韦特, 2008 年)	一种基于相似性的模型, 能够预测没有已知三维结构且已知相互作用药物很少或没有的靶点的药物靶点相互作用 (DTI)。该模型能够发现针对酶、G 蛋白偶联受体 (GPCRs) 和离子通道的潜在药物。	2008
	夏等人 (夏等, 2010 年)	一种基于相似性的模型, 该模型采用半监督学习方式训练。此模型将药物 - 靶点相互作用 (DTI) 信息与化学结构及基因组序列数据进行了整合。	2010
	戈嫩 (戈嫩, 2012 年)	一种基于相似性的模型, 它结合了贝叶斯公式、降维、矩阵分解和二元分类。该模型利用药物之间的化学相似性和靶点之间的基因组相似性。	2012
	基于序列的模型 WideDTA (Ozturk 等人, 2019 年)	一种以 SMILES 字符串和氨基酸序列作为输入的 CNN 模型。除了使用序列之外, WideDTA 还将配体最大公共子结构以及蛋白质结构域和基序编码到模型中, 以提高性能。	2019
	SMILES2Vec (Goh, Hodas 等人, 2017a)	一种直接将 SMILES 字符串作为输入的 RNN 模型。作者还通过可视化模型对分子的关注度来提高模型的可解释性。	2017
	DeepSMILES (奥博伊尔和达尔克, 2018 年)	一种以 SMILES 为输入的转换器模型。DeepSMILES 通过消除不匹配的环合并采用后缀表示法解决了 SMILES 中潜在的语法问题。	2018
	注意 DTA (Zhao 等人, 2019 年)	一种基于序列的模型, 该模型使用卷积神经网络 (CNN) 从 SMILES 字符串和氨基酸序列中提取表示特征, 并使用变换器模型来组合这些表示特征并预测药物 - 靶点相互作用 (DTIs)。	2019
	MT-DTI (Shin 等人, 2019 年)	一种基于序列的模型, 它使用变压器从 SMILES 字符串中提取表示, 使用卷积神经网络从氨基酸序列中提取表示。	2019
	SMILES 变换器 (本田等人, 2019 年)	一种采用编码器 - 解码器结构的转换器模型。SMILES 转换器采用了预训练策略, 即模型对输入的 SMILES 字符串进行重构, 以提高模型的性能。	2019
	SMILES-BERT (王等人, 2019 年)	仅含编码器的转换器模型。SMILES-BERT 经过预训练, 能够预测输入 SMILES 字符串中被掩码的部分。	2019

表 2 (续)

模型类型	模型	描述	年
基于图像的模型	CHEM-BERT (Kim 等人, 2021 年)	一种基于转换器编码器的模型。CHEM-BERT 采用了与 SMILES-BERT 类似的预训练策略。CHEM-BERT 提供了一个网络服务器, 用户可以在其中提交任务以在线预测药物靶点相互作用 (DTIs) 和药物属性。	
	Chemception (Goh, Siegel 等人, 2017 年 b)	Chemception 是一种仅将分子的二维快照作为输入的卷积神经网络 (CNN) 模型。该模型在包含不到 4 万种化合物的数据集上进行训练, 以预测不同的性质和药物靶点相互作用 (DTIs)。	2017
	DEEPScreen (Rifaoglu 等人, 2020 年)	一种专注于化合物二维结构表示的卷积神经网络 (CNN) 模型。DEEPScreen 经过训练, 能够预测 704 种靶蛋白的药物 - 靶点相互作用 (DTIs)。	2020
	ImageMol (曾翔等, 2022 年 b)	一种采用预训练策略从分子中学习重要化学信息的卷积神经网络 (CNN) 模型。ImageMol 被用于发现针对新冠病毒 (COVID-19) 的潜在治疗方法。	2022
	MolCLR (王、王等人, 2022 年 b)	一种以分子结构为输入的图卷积网络 (GCN) 模型。MolCLR 在约 1000 万种分子上进行了预训练, 以提高模型的泛化能力。	2022
	N 元语法图 (Liu 等人, 2019 年)	一种基于共价键构建分子结构表示的无监督图神经网络模型。N-gram 图在 60 项不同的任务中得到了严格的评价。	2019
	MGCN (Lu 等人, 2019 年)	一种使用分子图研究构象和空间信息的图卷积网络 (GCN) 模型。MGCN 采用分层设计以最大限度地提高模型的有效性。	2019
基于网络的模型	DGraphDTA (江等人, 2020 年)	一种专注于蛋白质并基于蛋白质接触图构建蛋白质图的图神经网络 (GNN) 模型。DGraphDTA 在多个基准数据集上展现出了强大的泛化能力和鲁棒性。	2020
	GCN-DTI (Zhao 等人, 2021 年)	一种以药物 - 蛋白质对网络作为输入的图卷积网络 (GCN) 模型。GCN-DTI 中使用的药物 - 蛋白质对网络包含三种药物 - 蛋白质关联类型: 强关联、弱关联和无关联。	2021
	DTI-GAT (王等人, 2021 年)	一种端到端的图注意力网络 (GAT) 模型, 用于处理药物 - 蛋白质相互作用网络, 并采用注意力机制。DTI-GAT 利用药物和蛋白质序列中的相互作用模式和特征。	2021
	DTI-HETA (邵等人, 2022 年)	一种基于网络的端到端模型, 同时使用了图卷积网络 (GCN) 和图注意力网络 (GAT)。GCN 从源数据集中的异构图中研究模式, 而 GAT 则突出了相邻节点的贡献。	2022
	DTI-GTN (王、郭等人, 2022a)	该 GTN 模型创新性地将每种药物 - 蛋白质相互作用视为一个节点。在本研究中, 主成分分析 (PCA) 被用于降低药物和蛋白质特征向量的维度。	2022
	AI-Bind (查特吉等人, 2023 年)	一种基于网络的框架, 利用无监督预训练提高药物 - 靶点相互作用 (DTI) 预测的泛化能力。进行了实验验证以支持预测结果。	2023
	deepDTnet (曾、朱等人, 2020 年 b)	deepDTnet 是一种以图表示为输入的编码器 - 解码器模型。它嵌入了 15 种不同的相互作用网络, 包括化学、基因组、表型和细胞网络。	2020
	deepDR (曾等, 2019 年)	一种多模态深度自编码器模型, 能够从异质性相互作用网络中学习药物的高级特征。deepDR 集成了 10 种不同类型的相互作用网络, 包括药物 - 疾病、药物 - 副作用、药物 - 靶点以及药物 - 药物网络。	2019

缩写词: CNN, 卷积神经网络; COVID-19, 2019 冠状病毒病; CTD, 组成、转换和分布; DTI, 药物-靶点相互作用; FDA, 食品药品监督管理局; GAT, 图注意力网络; GCN, 图卷积网络; GNN, 图神经网络; GPCRs, G 蛋白偶联受体; GTN, 图变换网络; KLD, Kullback-Leibler 散度; LASSO, 最小绝对收缩和选择算子; LOOP, 局部最优导向模式; PCA, 主成分分析; PsePSSM, 伪位置特异性评分矩阵; PSSM, 位置特异性评分矩阵; RF, 随机森林; RNN, 循环神经网络; SMILES, 简化分子线性输入规范; SVM, 支持向量机。

朝着结合多个经典机器学习模型的集成模型发展。这种方法旨在提高预测性能和模型的稳健性,并降低过拟合和欠拟合的风险(Dong 等人, 2020 年)。用于药物靶点相互作用预测的集成模型示例包括 Yang 等人(2020 年)提出的 NegStacking 以及 Ezzat 等人(2017 年)提出的集成方法。这些基于特征向量的人工智能模型在数据集较小且结构良好时可能较为高效,尤其是对于化学指纹这种结构良好的数据类型。然而,关键挑战在于特征构建和选择的策略。例如,较大的特征集可能包含冗余特征,从而导致更高的计算成本和过拟合问题,而较小的特征集可能不包含足够的特征供模型学习,从而导致欠拟合问题。

3.2 | 基于相似性的模型

基于相似性的模型假定化学结构、副作用谱或基因表达反应高度相似的药物很可能与相似的靶点相互作用,反之亦然,对于序列、蛋白质-蛋白质相互作用网络邻近性或基因本体论高度相似的靶点也是如此(Mitchell, 2001)。这些方法首先计算两个相似性矩阵。一个矩阵捕捉药物之间的成对相似性,另一个矩阵捕捉靶点之间的相似性。一旦生成了相似性矩阵,就可以采用不同的经典机器学习算法来预测药物-靶点相互作用(图 2a, 右)。常用的经典机器学习算法包括作为基线预测或作为集成模型一部分的 k 近邻(kNN)(Bleakley 和 Yamanishi, 2009; Yuan 等人, 2016)。其他算法,如支持向量机,可用于识别相似性和相互作用之间的非线性关系(Jacob 和 Vert, 2008)。此外,二部图局部模型(BLM)已被用于利用相似性矩阵中的二部图特性(Bleakley 等人, 2007; Bleakley 和 Yamanishi, 2009; Mordelet 和 Vert, 2008)。正则化最小二乘法(RLS)(Xia 等人, 2010 年)和核化贝叶斯矩阵分解(Gonen, 2012 年)是基于相似性预测药物-靶点相互作用(DTIs)的其他经典机器学习方法的示例。与基于特征向量的模型相比,这些基于相似性的模型更高效,因为基于相似性的模型无需构建特征。

尽管基于相似性的模型在药物-靶点相互作用(DTI)预测中表现出色,但这些模型的一个主要局限性在于其假设相似的药物具有相似的靶点,反之亦然。当药物或靶点之间的相似度不够高时,这种假设会限制基于相似性的模型在某些 DTI 预测任务中的表现(Ding 等人, 2014 年)。

3.3 | 基于序列的模型

基于序列的模型受到自然语言处理(NLP)技术的启发。药物通常用简化分子线性输入规范(SMILES)(Weininger, 1988)字符串来表示,而蛋白质则用其氨基酸序列来表示(图 2b)。早期的研究

工作利用了循环神经网络(RNN)(Medsker 和 Jain, 1999)或长短期记忆(LSTM)(Hochreiter 和 Schmidhuber, 1997),例如 WideDTA(Ozturk 等人, 2019)、SMILES2Vec(Goh, Hodas 等人, 2017a)和 DeepS-MILES(O'Boyle 和 Dalke, 2018)。这些模型取得了令人鼓舞的结果,但它们受到其固有的顺序处理性质的限制。这种顺序处理特性限制了它们高效处理非常长的 SMILES 字符串或蛋白质序列的能力,从而阻碍了它们在处理复杂药物和靶点时的可扩展性。注意力机制和 Transformer 模型(Vaswani, 2017)已被提出以克服循环神经网络和长短期记忆的局限性。注意力机制使模型在处理过程中能够专注于序列的相关部分,显著提高了捕捉数据中远程依赖关系的能力。基于注意力机制的 Transformer 模型通过增强并行化能力解决了循环神经网络和长短期记忆网络的效率瓶颈。这些进展促使了诸如 AttentionDTA(Zhao 等人, 2019 年)、MT-DTI(Shin 等人, 2019 年)、SMILES Transformer(Honda 等人, 2019 年)、CHEM-BERT(Kim 等人, 2021 年)和 SMILES-BERT(Wang 等人, 2019 年)等利用注意力机制和 Transformer 技术的序列模型的发展。这些基于 Transformer 的模型相较于基于循环神经网络或长短期记忆(LSTM)的模型表现出了更优的性能。序列模型具有两个关键优势。首先,数据集的准备要容易得多。与基于特征向量的模型或基于相似性的模型不同,无需构建复杂的特征集或相似性矩阵。其次,序列数据(如 SMILES 字符串或氨基酸序列)本质上是一维的,与三维结构数据相比,所需的计算资源更少。然而,必须认识到序列模型也存在局限性。基于序列的模型难以捕捉到三维结构中所蕴含的重要信息,例如立体化学信息,而这些信息会对分子与其靶点的相互作用产生重大影响。

3.4 | 基于网络的方法

基于网络的模型利用药物、靶点甚至患者之间的联系来预测药物-靶点相互作用(图 2c)。网络中的每个节点代表一种药物、一个靶点、一个与疾病相关的基因或一种疾病。边则编码药物、靶点、基因和疾病之间的关系。值得注意的例子包括基于图卷积网络(GCN)的 GCN-DTI(Zhao 等人, 2021 年)(Kipf 和 Welling, 2016 年)、基于图注意力网络(GAT)的 DTI-GAT(Wang 等人, 2021 年)(Velickovic 等人, 2017 年)、结合了 GCN 和 GAT 的 DTI-HETA(Shao 等人, 2022 年)、基于图变换网络(GTN)的 DTI-GTN(Wang, Guo 等人, 2022a)(Yun 等人, 2019 年)、deepDTnet(Zeng, Zhu 等人, 2020b)以及 deepDR(Zeng 等人, 2019 年)。AI-Bind 是另一种新颖的基于网络的框架,可用于预测蛋白质-配体结合(Chatterjee 等人, 2023 年)。AI-Bind 的结果已通过对接模拟和实验验证得到证实。基于网络的模型在发现药物之间的隐藏关系方面表现出色。






图 2 图例见下页。

它们的潜在靶点。这种优势使得基于网络的模型特别适合药物再利用，即对现有药物的新靶点和新适应症进行研究。例如，研究人员已成功利用基于网络的模型来识别针对 2019 冠状病毒病 (COVID-19) (Zhou, Hou, Shen, Huang 等人, 2020a)、心房颤动 (Lal 等人, 2022 年)、癌症 (Cheng 等人, 2017 年) 和疼痛 (Qiu 等人, 2024 年) 的潜在再利用药物。然而，随着这些网络涵盖的药物和靶点数量增加到数百万，计算复杂度也会显著增加。

3.5 | 基于图像模型

除了基于序列的模型之外，基于图像的方法也成为了药物靶点相互作用 (DTI) 预测的又一有力工具。这些模型受到计算机视觉技术的启发，将药物分子的二维快照图像作为输入数据 (图 2b)。与 1D 序列数据 (如 SMILES 字符串) 相比，这些图像能够潜在地编码更多关于药物化学结构以及原子空间排列的信息，这对于理解药物如何与靶点相互作用至关重要。基于图像的模型的主要架构是卷积神经网络 (CNN) (Krizhevsky 等人, 2012 年)。卷积神经网络擅长从空间数据中提取特征，使其成为分析药物分子二维表示的理想选择。开创性的工作包括 DEEPScreen (Rifaoglu 等人, 2020 年)、Chemception (Goh, Siegel 等人, 2017 年 b) 和 DrugCNN (Hu 等人, 2019 年)，这些研究使用卷积神经网络以分子图像作为输入，对 DTI 预测取得了令人鼓舞的结果。与仅从输入药物中捕获有限信息的基于指纹的模型、基于相似性的模型、基于网络的模型和基于序列的模型相比，这些基于图像的模型能够从分子图像中捕获二维结构信息，从而提供原子之间的关系，例如共价键的类型和键角，因此性能更优。最近，研究人员正在探索预训练深度学习模型以提高其泛化能力。曾祥等人 (2022b) 引入了 ImageMol，这是一种使用数百万分子图像进行预训练的基于图像的深度学习模型。这一预训练步骤使 ImageMol 能够有效地学习如何从输入分子图像中捕获重要的化学信息，从而有可能更准确地预测药物-靶点相互作用。LISA-CPI (杨等人, 2024) 整合了预训练的 ImageMol 以及 AlphaFold2 中的预训练模块来预测药物-靶点相互作用。近期，AlphaFold 3 (Abramson 等人, 202

4 年) 在蛋白质结构和生物分子相互作用预测方面的进展，为实现更精确的蛋白质结构预测以及更出色的性能带来了令人期待的前景。

3.6 | 基于结构的模型

基于结构的模型利用药物和靶点的三维结构来进行药物-靶点相互作用 (DTI) 预测 (图 2c)。一种流行的策略是使用图来建模药物和靶点的三维结构，其中每个节点代表一个原子或氨基酸，每条边代表一个共价键或肽键。基于图卷积网络 (GCN) 和图同构网络 (GIN) (Xu 等人, 2018 年) 的 MolCLR (Wang 等人, 2022 年 b)、基于 GCN 的 N-gram 图 (Liu 等人, 2019 年) 和 MGCN (Lu 等人, 2019 年) 是仅使用药物结构数据的图模型示例。像 DGraphDTA (Jiang 等人, 2020 年) 和 WGNN-DTA (Jiang 等人, 2022 年) 这样的模型则同时纳入了药物结构图和靶点结构图。与使用指纹、一维序列或二维图像的方法相比，图模型能够捕获药物和靶点整体结构的更全面信息。图模型通过明确地建模药物内原子之间或靶点内氨基酸之间的关系来实现这一点，这使得图模型能够更好地理解药物和靶点可能的相互作用方式。图模型通常具有较低的计算复杂度，在计算能力有限的情况下是更优的选择。然而，图无法完整呈现药物和靶点的结构信息，比如键角和键长等结构信息在图数据中是缺失的。最近，VideoMol 方法利用视频数据来捕捉分子的动态构象 (Cheng 等人, 2024 年)。VideoMol 不仅考虑了分子在不同角度和条件下的构象，而且超越了静态图的局限。VideoMol 在众多药物发现任务中取得了最先进的性能，这凸显了利用视频数据捕捉动态结构信息以改进药物靶点相互作用预测的潜力。

4 | 案例研究：人工智能揭示人类复杂疾病的潜在疗法

由于传统药物研发进程缓慢，人工智能方法已崭露头角，成为加速发现包括传染病、罕见病以及神经退行性疾病等各类疾病潜在治疗方法的有力手段。

图 2 用于药物-靶点相互作用 (DTI) 预测的不同类型的人工智能 (AI) 模型构建示意图。(a) 基于特征向量和相似性方法：生成药物和靶点的特征向量或相似性矩阵，然后基于特征向量或相似性矩阵训练机器学习模型以预测 DTI。(b) 基于序列、图像和结构的方法：首先将药物和靶点描述为一维 (1D) 序列 (药物的 SMILES 字符串或蛋白质的氨基酸序列)、二维 (2D) 图像快照或三维 (3D) 结构。随后，基于这些序列、图像或结构数据训练深度学习模型并进行预测。(c) 基于网络的方法：构建不同的相互作用网络，例如药物-靶点、药物-疾病和靶点-基因网络。然后在这些相互作用网络上训练深度学习神经网络以发现新的治疗方法。CNN，卷积神经网络；RNN，循环神经网络。




FIGURE 3 Legend on next page.

阿尔茨海默病 (AD) 和多发性硬化症 (MS)。在这篇综述中, 我们以 AD、MS、心血管疾病 (CVD) 和新冠病毒病 (COVID-19) 这几种人类复杂疾病为例, 研究人工智能技术如何被用于发现预防和治疗人类复杂疾病的潜在疗法。

4.1 | 阿尔茨海默病 (AD)

阿尔茨海默病 (AD) 是痴呆症的主要病因, 其特征是进行性记忆丧失和认知能力下降 (Blennow 等人, 2006 年)。人工智能技术在阿尔茨海默病药物研发方面取得了显著进展。分类人工智能模型用于确定药物是否与阿尔茨海默病相关靶点相互作用, 而回归模型则通过预测药物与阿尔茨海默病相关基因或靶点之间的结合活性水平来量化这些相互作用的强度。这种双重方法使研究人员既能识别潜在的候选药物, 又能评估其可能的疗效, 从而简化阿尔茨海默病治疗药物的研发流程。一种流行且成熟的策略是利用基于网络的模型来发现治疗阿尔茨海默病的新药、新靶点和新基因。例如, 一项研究采用单细胞网络机器学习框架来研究可能与阿尔茨海默病相关的细胞特异性风险基因 (Gupta 等人, 2022 年)。作者利用基于已知阿尔茨海默病相关基因的人工智能模型发现了新的阿尔茨海默病相关基因。另一项研究则使用基于网络的机器学习框架和多组学人类蛋白质-蛋白质相互作用组数据来寻找潜在的阿尔茨海默病治疗方法 (Fang 等人, 2022 年)。作者不仅强调了可用于治疗阿尔茨海默病 (AD) 的再利用药物, 还通过体外实验在人类小胶质细胞中研究了这些再利用药物的作用机制。除此之外, 研究还表明, 源自肠道微生物群的代谢产物针对人类 G 蛋白偶联受体 (GPCRs) 在治疗 AD 方面具有潜力 (Qiu 等人, 2024 年)。作者开发了一种机器学习模型, 以探究肠道微生物代谢产物、GPCRs 以及它们对 AD 潜在影响之间的关系。该模型确定了孤儿 GPCRs 作为治疗 AD 的潜在药物靶点, 以及与这些 GPCRs 相互作用的相应肠道微生物代谢产物。值得注意的是, 实验验证证实了这种治疗策略的有效性。这些研究充分展示了在 AD 药物靶点发现过程中应用人工智能技术的价值和有效性。

4.2 | 多发性硬化症 (MS)

多发性硬化症 (MS) 是一种自身免疫性疾病, 患者的免疫系统会攻击中枢神经系统 (包括大脑和脊髓) 神经细胞的保护层 (Dobson & Giovannoni, 2019)。人工智能 (AI) 正逐渐成为辅助多发性硬化症患者诊断和治疗开发的强大工具。在诊断领域, AI 已被证明能够高效地分析医学影像。例如, 卷积神经网络已被训练用于在磁共振成像 (MRI) 扫描数据中高精度地识别强化病灶 (Narayana 等人, 2020)。除了诊断, AI 还在多发性硬化症的药物研发方面发挥作用。回归模型能够对药物的治疗潜力进行定量评估, 预测其对炎症水平和脑部病灶减少等关键指标的影响。相反, 分类模型则能对药物治疗多发性硬化症的能力进行二元预测, 将化合物分为可能有效或无效两类。基于网络的方法被用于开展药物再定位研究, 评估现有药物对多发性硬化症相关基因的潜在疗效 (deAndres-Galiana 等人, 2019)。这种方法已促使在患多发性硬化症 (MS) 的患者中识别出多个高鉴别基因, 并且可能与感染因子有关。此外, 分析临床和影像数据的人工智能模型能够为 MS 患者确定潜在的新疗法 (Falet 等人, 2022 年)。例如, 通过这种方法发现的抗 CD20 单克隆抗体在提高 MS 患者的长期生存率方面显示出希望 (Falet 等人, 2022 年)。这些研究展示了人工智能在推进 MS 研究方面的价值和有效性。

4.3 | 心血管疾病 (CVD)

心血管疾病 (CVD) 是涉及心脏或血管的任何疾病和紊乱的统称, 也是全球头号死因 (Gaziano 等人, 2006 年)。新型人工智能方法已被证明是这场斗争中的有用工具, 有助于研究人员发现有前景的药物并减少可能的不良反应。对于 CVD 药物再利用, 分类模型和回归模型都得到了应用。分类模型预测药物、靶点和 CVD 相关基因之间的相互作用, 从而有效地识别出再利用的潜在候选药物。在此背景下, 回归模型用于估算药物与靶点之间的结合亲和力, 从而为这些相互作用的强度提供见解。为了

图 3 利用人工智能 (AI) 增强药物发现的未来方向。(a) 增强的数据整合: 左: 通过整合不同数据库 (包括专注于药物、靶点、结合相互作用、疾病、副作用和患者的数据库) 来简化数据访问和处理流程。这一统一平台将有助于全面的数据探索和分析。右: 构建多模态数据集, 将结构、序列、图像和特征向量等不同数据模式结合起来。通过利用每种数据类型的优势, 这些数据集可以为 AI 模型提供更全面的学习视角。(b) 先进的 AI 技术: 构建能够利用不同数据模式和组学数据 (基因组学、转录组学等) 的基础 AI 模型, 以更全面的方式应对药物发现挑战; 探索量子 AI 算法的潜力, 通过解决经典计算机无法解决的问题来加速药物发现; 开发高效且低资源的小型 AI 模型, 专门针对特定的药物发现任务, 从而在更广泛的研究环境中实现应用。(c) 有效的验证技术: 采用更强大的验证策略来严格测试模型及其预测结果, 对于简化药物研发流程至关重要。

例如, 已开发出一种基于网络的方法来探究人类蛋白质-蛋白质相互作用组中疾病基因与药物靶点之间的关系 (Cheng 等人, 2018 年)。具体而言, 该研究确定了一种可能增加冠状动脉疾病 (CAD) 风险的药物以及另一种可能降低 CAD 风险的药物。另一种基于网络的方法侧重于将现有药物重新用于心血管疾病 (CVD) 治疗 (Paci 等人, 2022 年)。值得注意的是, 这种方法结合了药物不良反应的数据, 旨在减少重新利用药物可能带来的不良影响。除了药物发现之外, 基于心电图 (ECG) 数据训练的人工智能模型在揭示患者对 CVD 治疗的反应方面也显示出前景, 为更个性化和高效的治疗策略铺平了道路 (Tison 等人, 2022 年)。这些研究展示了人工智能技术在推进 CVD 研究方面的价值和潜力。

4.4 | 新冠肺炎

由冠状病毒 SARS-CoV-2 引发的传染病 COVID-19 迅速演变成一场全球大流行病 (Ciotti 等人, 2020 年)。人工智能是抗击 COVID-19 的关键工具, 尤其是在发现和开发治疗药物方面 (Zhou、Wang、Tang、Nussinov 和 Cheng, 2020 年 c)。分类模型用于预测单药或药物组合是否有可能有效治疗 COVID-19, 给出二元结果。与此方法相辅相成, 回归模型通过量化药物与 SARS-CoV-2 病毒刺突蛋白之间的抑制水平提供更深入的见解。在疫情初期, 基于网络的方法发挥了重要作用。其中一项研究成功地重新定位了 16 种药物和 3 种药物组合, 这些药物组合有可能治疗 COVID-19 (Zhou、Hou、Shen、Huang 等人, 2020 年 a)。基于这一成功, 研究人员探索了其他基于网络的方法, 利用从知识图谱 (KG) 中提取的 SARS-CoV-2 病毒-宿主蛋白质相互作用或药物-基因-疾病关联来突出潜在的治疗方法 (Zeng、Song 等人, 2020 年 a; Zhou、Hou、Shen、Mehra 等人, 2020 年 b)。值得注意的是, 褪黑素已被确认为一种可能降低新冠病毒检测呈阳性的几率的潜在治疗方法, 而托瑞米芬在抑制新冠病毒刺突蛋白方面显示出希望, 刺突蛋白是病毒感染的关键因素 (马丁和程, 2020 年)。这些研究说明了人工智能在应对像新冠病毒这样的全球突发卫生威胁方面的重要性, 它能够迅速识别出潜在的治疗选择。

5 | 结论与展望

在这篇综述中, 我们探讨了利用人工智能技术促进药物发现方面所做的努力, 特别是预测药物-靶点相互作用 (DTIs) 及其在药物开发和药物再利用中的应用。我们研究了用于 DTI 研究的重要数据库, 以及处理药物和靶点数据的工具包。此外, 我们还研究了评估人工智能模型性能的关键技术。随后, 我们的研究深入探讨了利用人工智

能模型预测 DTIs 的应用, 重点关注传统机器学习和深度学习模型。我们分析了各种模型类型, 包括基于特征的、基于相似性的、基于序列的、基于图像的和基于网络/图的模型。

尽管人工智能方法取得了显著进展, 但人工智能和生物医学研究领域仍面临巨大挑战。其中一个主要挑战是数据的可获取性和质量。人工智能模型在训练过程中需要大量高质量的训练数据; 然而, 生物医学数据库往往存在噪声和不完整的问题。此外, 生物医学数据需要专家进行人工标注, 这既昂贵又耗时, 从而加大了有标签数据 and 无标签数据之间的差距 (Sarker 等人, 2022 年)。为了缓解这一挑战, 半监督学习技术提供了一种有前景的解决方案, 即利用有标签数据为无标签数据推断标签 (Van Engelen 和 Hoos, 2020 年)。未来的解决方案可能包括构建一个整合了三种类型数据库信息的数据库: 以药物为重点的数据库、以靶点为重点的数据库和以结合为重点的数据库 (图 3a)。

另一个重大挑战在于如何有效利用现有数据。目前, 人工智能模型主要在单一模态下运行, 限制了其利用多种数据类型的能力。多模态人工智能模型正日益涌现, 展现出整合不同数据源的能力。整合不同数据模态通常采用三种策略: 早期融合、中期融合和晚期融合。晚期融合先分别处理数据源, 然后再合并输出, 但难以处理数据源之间的弱相关性。早期融合则从一开始就将数据合并, 能很好地捕捉相关性, 但需要谨慎处理数据规模问题。中期融合则介于两者之间, 平衡了两者的优点 (Gadzicki 等人, 2020 年)。这类模型能够为单一给定的药物和靶点学习到更多信息, 因此比使用单一模态的模型表现更佳, 为这一局限性提供了一个有说服力的解决方案 (Ngiam 等人, 2011 年)。例如, 一个有前景的解决方案是构建生物医学基础模型 (图 3b)。该模型整合了药物和靶点的各种数据模态, 包括图像数据、SMILES 数据和氨基酸序列数据、结构数据以及指纹数据。通过同时利用这些丰富的信息, 生物医学基础模型有可能通过增强药物与靶点的理解来彻底改变药物发现过程, 并加速药物研发。此外, 多组学数据的整合是提高输入数据可理解性的另一个趋势 (Subramanian 等人, 2020 年)。

此外, 有效验证人工智能模型仍然是一个关键障碍。在药物靶点相互作用 (DTI) 预测中, 人工智能模型通常在泛化方面存在困难, 尤其是在面对与训练集数据分布不同的数据时。当模型是在有偏差或不完整的数据集上训练时, 这一局限性会更加严重。为了评估人工智能模型的 DTI 预测性能, 通常采用两种测试场景——热启动测试和冷启动测试。热启动测试评估模型对已知药物和靶点相互作用的预测能力, 相对来说难度较小。相比之下, 冷启动测试评估模型对新药物和新靶点相互作用的预测能力, 这对人工智能模型来说是一个更严格的挑战。冷启动场景对于评估模型的泛化能力至关重要, 因为其性能往往

当遇到训练数据中未出现的药物或靶点时，其性能会显著下降。这种全面的评估方法有助于研究人员识别出在真实世界药物发现场景中足够稳健、能够做出可靠预测的模型，在这种场景中遇到新型化合物和靶点的情况很常见。常见的训练和测试数据集随机分割方法通常会导致过于乐观的人工智能模型，特别是对于化学问题而言，而基于支架的分割方法又可能对人工智能模型来说过于困难（Wu 等人，2018 年）。关键的解决办法在于开发一种更公平的分割技术，在平衡真实世界数据表示的同时，防止过拟合和欠拟合。此外，为了全面验证人工智能模型的有效性，对几个具有高置信度的预测候选药物进行体外和体内实验验证以及临床试验也至关重要（图 3c）。

近期在大型语言模型（LLMs）方面取得的进展，例如生成式预训练转换器（GPT）（Radford, 2018）和双向编码器表示转换器（BERT）（Devlin, 2018），为促进药物发现和药物靶点相互作用（DTI）预测提供了前景广阔的可能，这得益于它们能够促进异构数据源的整合（Chakraborty 等人，2023）。然而，大型语言模型容易出现幻觉（Zhang 等人，2023）和有偏见的回应，尤其是刻板和有偏见的回应（Yu 等人，2024），因此在应用时需要谨慎。与大型模型相比，基于小规模但高质量数据集训练的小型人工智能模型可能更准确且更具成本效益，这些小型人工智能模型在未来药物发现中可发挥关键作用。量子计算是加速药物发现和 DTI 预测的另一个有前景的前沿领域。量子计算机能够提供无可比拟的计算速度，并能解决经典计算机无法解决的问题（Chauhan 等人，2022），但它们极易受到环境噪声的影响，从而导致不必要的错误（Resch 和 Karpuzcu, 2021）。

5.1 | 目标和配体的命名法

本文中的关键蛋白质靶点和配体已超链接至 IUPHAR/BPS 药理学指南网站 <http://www.guidetopharmacology.org> 上的相应条目，并永久存档于《2023/24 年药理学简明指南》（Alexander 等人，2023 年）。

作者贡献

杨 Y：数据整理（同等贡献）；形式分析（同等贡献）；调查（同等贡献）；方法论（同等贡献）；撰写初稿（同等贡献）。程 F：概念化（同等贡献）；资金获取（同等贡献）；项目管理（同等贡献）；资源（同等贡献）；验证（同等贡献）；撰写初稿（同等贡献）。

致谢

本研究主要由美国国家老龄化研究所（NIA）通过 U01AG073323、R21AG083003、R01AG066707、R01AG076448、R01AG082118、R01AG084250 和 RF1A

G082211 号资助项目，以及美国国家神经疾病与中风研究所（NINDS）通过 RF1NS133812 号资助项目，以及阿尔茨海默病协会（ALZDISCOVERY-1051936）资助 F.C. 完成。

利益冲突声明

作者已声明不存在利益冲突。

数据可用性声明

未通过审核。

参考文献

- Abbasi, K., Razzaghi, P., Poso, A., Ghanbari-Ara, S., & Masoudi-Nejad, A. (2021). Deep learning in drug target interaction prediction: Current and future perspectives. *Current Medicinal Chemistry*, 28(11), 2100–2113. <https://doi.org/10.2174/0929867327666200907141016>
- Abramson, J., Adler, J., Dunger, J., Evans, R., Green, T., Pritzel, A., Ronneberger, O., Willmore, L., Ballard, A. J., Bambrick, J., Bodenstein, S. W., Evans, D. A., Hung, C.-C., O'Neill, M., Reiman, D., Tunyasuvunakool, K., Wu, Z., Ziemgulytė, A., Arvaniti, E., ... Jumper, J. M. (2024). Accurate structure prediction of biomolecular interactions with AlphaFold 3. *Nature*, 630(8016), 493–500. <https://doi.org/10.1038/s41586-024-07487-w>
- Ahn, S., Lee, S. E., & Kim, M.-h. (2022). Random-forest model for drug–target interaction prediction via Kullback–Leibler divergence. *Journal of Cheminformatics*, 14(1), 67. <https://doi.org/10.1186/s13321-022-00644-1>
- Alexander, S. P. H., Christopoulos, A., Davenport, A. P., Kelly, E., Mathie, A. A., Peters, J. A., Veale, E. L., Armstrong, J. F., Faccenda, E., Harding, S. D., Davies, J. A., Abbracchio, M. P., Abraham, G., Agoulis, A., Alexander, W., Al-Hosaini, K., Bäck, M., Baker, J. G., Barnes, N. M., ... Ye, R. D. (2023). The Concise Guide to PHARMA-COLOGY 2023/24: G protein-coupled receptors. *British Journal of Pharmacology*, 180, S23–S144. <https://doi.org/10.1111/bph.16177>
- Arulkumaran, K., Deisenroth, M. P., Brundage, M., & Bharath, A. A. (2017). Deep reinforcement learning: A brief survey. *IEEE Signal Processing Magazine*, 34(6), 26–38. <https://doi.org/10.1109/MSP.2017.2743240>
- Ask, H., Elgeldawi, E., Aboul Ella, H., Elshaier, Y. A. M. M., Gomaa, M. M., & Hassani, A. E. (2023). Deep learning in drug discovery: An integrative review and future challenges. *Artificial Intelligence Review*, 56(7), 5975–6037. <https://doi.org/10.1007/s10462-022-10306-1>
- Bagherian, M., Sabeti, E., Wang, K., Sartor, M. A., Nikolovska-Coleska, Z., & Najarian, K. (2021). Machine learning approaches and databases for prediction of drug–target interaction: A survey paper. *Briefings in Bioinformatics*, 22(1), 247–269. <https://doi.org/10.1093/bib/bbz157>
- Berman, H. M., Westbrook, J., Feng, Z., Gilliland, G., Bhat, T. N., Weissig, H., Shindyalov, I. N., & Bourne, P. E. (2000). The Protein Data Bank. *Nucleic Acids Research*, 28(1), 235–242. <https://doi.org/10.1093/nar/28.1.235>
- Bishop, C. M., & Tipping, M. E. (2003). Bayesian regression and classification. In *Advances in learning theory: Methods, models and applications* (pp. 267–285). IOS Press.
- Bleakley, K., Biau, G., & Vert, J.-P. (2007). Supervised reconstruction of biological networks with local models. *Bioinformatics*, 23(13), i57–i65. <https://doi.org/10.1093/bioinformatics/btm204>
- Bleakley, K., & Yamanishi, Y. (2009). Supervised prediction of drug–target interactions using bipartite local models. *Bioinformatics*, 25(18), 2397–2403. <https://doi.org/10.1093/bioinformatics/btp433>
- Blennow, K., de Leon, M. J., & Zetterberg, H. (2006). Alzheimer's disease. *The Lancet*, 368(9533), 387–403. [https://doi.org/10.1016/S0140-6736\(06\)69113-7](https://doi.org/10.1016/S0140-6736(06)69113-7)
- Breiman, L. (2001). Random forests. *Machine Learning*, 45, 5–32. <https://doi.org/10.1023/A:1010933404324>

- Cao, D.-S., Xiao, N., Xu, Q. S., & Chen, A. F. (2015). Rcp: R/Bioconductor package to generate various descriptors of proteins, compounds and their interactions. *Bioinformatics*, 31(2), 279–281. <https://doi.org/10.1093/bioinformatics/btu624>
- Cereto-Massagué, A., Ojeda, M. J., Valls, C., Mulero, M., Garcia Vallvé, S., & Pujadas, G. (2015). Molecular fingerprint similarity search in virtual screening. *Methods*, 71, 58–63. <https://doi.org/10.1016/j.ymeth.2014.08.005>
- Chakraborty, C., Bhattacharya, M., & Lee, S.-S. (2023). Artificial intelligence enabled ChatGPT and large language models in drug target discovery, drug discovery, and development. *Molecular Therapy-Nucleic Acids*, 33, 866–868. <https://doi.org/10.1016/j.omtn.2023.08.009>
- Chatterjee, A., Walters, R., Shafi, Z., Ahmed, O. S., Sebek, M., Gysi, D., Yu, R., Eliassi-Rad, T., Barabási, A. L., & Menichetti, G. (2023). Improving the generalizability of protein-ligand binding predictions with AI-Bind. *Nature Communications*, 14(1), 1989. <https://doi.org/10.1038/s41467-023-37572-z>
- Chauhan, V., Negi, S., Jain, D., Singh, P., Sagar, A. K., & Sharma, A. K. (2022). Quantum computers: A review on how quantum computing can boom AI. In 2022 2nd International Conference on Advance Computing and Innovative Technologies in Engineering (ICACITE). IEEE.
- Cheng, F., Desai, R. J., Handy, D. E., Wang, R., Schneeweiss, S., Barabási, A. L., & Loscalzo, J. (2018). Network-based approach to prediction and population-based validation of in silico drug repurposing. *Nature Communications*, 9(1), 2691. <https://doi.org/10.1038/s41467-018-05116-5>
- Cheng, F., Hong, H., Yang, S., & Wei, Y. (2017). Individualized network-based drug repositioning infrastructure for precision oncology in the panomics era. *Briefings in Bioinformatics*, 18(4), 682–697. <https://doi.org/10.1093/bib/bbw051>
- Cheng, F., Xiang, H., Zeng, L., Hou, L., Li, K., Fu, Z., Qiu, Y., Nussinov, R., Hu, J., Zeng, X. X., & Rosen-Zvi, M. (2024). A molecular video-derived foundation model streamlines scientific drug discovery.
- Ciotti, M., Ciccozzi, M., Terrinoni, A., Jiang, W. C., Wang, C. B., & Bernardini, S. (2020). The COVID-19 pandemic. *Critical Reviews in Clinical Laboratory Sciences*, 57(6), 365–388. <https://doi.org/10.1080/10408363.2020.1783198>
- deAndrés-Galiana, E. J., Bea, G., Fernández-Martínez, J. L., & Saligan, L. N. (2019). Analysis of defective pathways and drug repositioning in multiple sclerosis via machine learning approaches. *Computers in Biology and Medicine*, 115, 103492. <https://doi.org/10.1016/j.combiomed.2019.103492>
- Devlin, J. (2018). BERT: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*.
- Ding, H., Takigawa, I., Mamitsuka, H., & Zhu, S. (2014). Similarity-based machine learning methods for predicting drug–target interactions: A brief review. *Briefings in Bioinformatics*, 15(5), 734–747. <https://doi.org/10.1093/bib/bbt056>
- Dobson, R., & Giovannoni, G. (2019). Multiple sclerosis—A review. *European Journal of Neurology*, 26(1), 27–40. <https://doi.org/10.1111/ene.13819>
- Dong, X., Yu, Z., Cao, W., Shi, Y., & Ma, Q. (2020). A survey on ensemble learning. *Frontiers of Computer Science*, 14, 241–258. <https://doi.org/10.1007/s11704-019-8208-z>
- Durant, J. L., Leland, B. A., Henry, D. R., & Nourse, J. G. (2002). Reoptimization of MDL keys for use in drug discovery. *Journal of Chemical Information and Computer Sciences*, 42(6), 1273–1280. <https://doi.org/10.1021/ci010132r>
- Ezzat, A., Wu, M., Li, X. L., & Kwok, C. K. (2017). Drug-target interaction prediction using ensemble learning and dimensionality reduction. *Methods*, 129, 81–88. <https://doi.org/10.1016/j.ymeth.2017.05.016>
- Falet, J.-P. R., Durso-Finley, J., Nichyporuk, B., Schroeter, J., Bovis, F., Sormani, M. P., Precup, D., Arbel, T., & Arnold, D. L. (2022). Estimating individual treatment effect on disability progression in multiple sclerosis using deep learning. *Nature Communications*, 13(1), 5645. <https://doi.org/10.1038/s41467-022-33269-x>
- Fang, J., Zhang, P., Wang, Q., Chiang, C. W., Zhou, Y., Hou, Y., Xu, J., Chen, R., Zhang, B., Lewis, S. J., Leverenz, J. B., Pieper, A. A., Li, B., Li, L., Cummings, J., & Cheng, F. (2022). Artificial intelligence frame-work identifies candidate targets for drug repurposing in Alzheimer's disease. *Alzheimer's Research & Therapy*, 14, 1–23. <https://doi.org/10.1186/s13195-021-00951-z>
- Fernández-de Gortari, E., García-Jacas, C. R., Martínez-Mayorga, K., & Medina-Franco, J. L. (2017). Database fingerprint (DFP): An approach to represent molecular databases. *Journal of Cheminformatics*, 9, 1–9. <https://doi.org/10.1186/s13321-017-0195-1>
- Gadzicki, K., Khamsehashari, R., & Zetsche, C. (2020). Early vs late fusion in multimodal convolutional neural networks. In 2020 IEEE 23rd Inter-national Conference on Information Fusion (FUSION). IEEE.
- Gasteiger, E., Hoogland, C., Gattiker, A., Duvaud, S. E., Wilkins, M. R., Appel, R. D., & Bairoch, A. (2005). Protein identification and analysis tools on the ExPASy server. Springer.
- Gaulton, A., Bellis, L. J., Bento, A. P., Chambers, J., Davies, M., Hersey, A., Light, Y., McGlinchey, S., Michalovich, D., al-Lazikani, B., & Overington, J. P. (2012). ChEMBL: A large-scale bioactivity database for drug discovery. *Nucleic Acids Research*, 40 (D1), D1100–D1107. <https://doi.org/10.1093/nar/gkr777>
- Gaziano, T., Reddy, K. S., Paccaud, F., Horton, S., & Chaturvedi, V. (2006). Cardiovascular disease. In *Disease control priorities in developing countries* (2nd ed.). The International Bank for Reconstruction and Development/The World Bank.
- Gilson, M. K., Liu, T., Baitaluk, M., Nicola, G., Hwang, L., & Chong, J. (2016). BindingDB in 2015: A public database for medicinal chemistry, computational chemistry and systems pharmacology. *Nucleic Acids Research*, 44(D1), D1045–D1053. <https://doi.org/10.1093/nar/gkv1072>
- Glen, R. C., Bender, A., Arnby, C. H., Carlsson, L., Boyer, S., & Smith, J. (2006). Circular fingerprints: Flexible molecular descriptors with applications from physical chemistry to ADME. *IDrugs*, 9(3), 199.
- Goh, G. B., Hodas, N. O., Siegel, C., & Vishnu, A. (2017a). SMILES2Vec: An interpretable general-purpose deep neural network for predicting chemical properties. *arXiv preprint arXiv:1712.02034*.
- Goh, G. B., Siegel, C., Vishnu, A., Hodas, N. O., & Baker, N. (2017b). Chem-ception: A deep neural network with minimal chemistry knowledge matches the performance of expert-developed QSAR/QSPR models. *arXiv preprint arXiv:1706.06689*.
- Golub, G. H., & Reinsch, C. (1971). Singular value decomposition and least squares solutions. In *Handbook for automatic computation: Volume II: Linear algebra* (pp. 134–151). Springer. https://doi.org/10.1007/978-3-642-86940-2_10
- Gönen, M. (2012). Predicting drug–target interactions from chemical and genomic kernels using Bayesian matrix factorization. *Bioinformatics*, 28(18), 2304–2310. <https://doi.org/10.1093/bioinformatics/bts360>
- Gupta, C., Xu, J., Jin, T., Khullar, S., Liu, X., Alatar, S., Cheng, F., & Wang, D. (2022). Single-cell network biology characterizes cell type gene regulation for drug repurposing and phenotype prediction in Alzheimer's disease. *PLoS Computational Biology*, 18(7), e1010287. <https://doi.org/10.1371/journal.pcbi.1010287>
- Hattori, M., Tanaka, N., Kanehisa, M., & Goto, S. (2010). SIMCOMP/SUB-COMP: Chemical structure search servers for network analyses. *Nucleic Acids Research*, 38(suppl_2), W652–W656. <https://doi.org/10.1093/nar/gkq367>
- Hearst, M. A., Dumais, S. T., Osuna, E., Platt, J., & Scholkopf, B. (1998). Support vector machines. *IEEE Intelligent Systems and their Applications*, 13(4), 18–28. <https://doi.org/10.1109/5254.708428>
- Hinton, G. E., & Roweis, S. (2002). Stochastic neighbor embedding. *Advances in Neural Information Processing Systems*, 15, 857–864.

- Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- Honda, S., Shi, S., & Ueda, H. R. (2019). SMILES Transformer: Pre-trained molecular fingerprint for low data drug discovery. arXiv preprint arXiv: 1911.04738.
- Hu, S., Xia, D. N., Su, B., Chen, P., Wang, B., & Li, J. (2019). A convolutional neural network system to discriminate drug-target interactions. *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, 18(4), 1315–1324. <https://doi.org/10.1109/TCBB.2019.2940187>
- Irwin, J. J., Tang, K. G., Young, J., Dandarchuluun, C., Wong, B. R., Khurelbaatar, M., Moroz, Y. S., Mayfield, J., & Sayle, R. A. (2020). ZINC20—A free ultralarge-scale chemical database for ligand discovery. *Journal of Chemical Information and Modeling*, 60(12), 6065–6073. <https://doi.org/10.1021/acs.jcim.0c00675>
- Jacob, L., & Vert, J.-P. (2008). Protein-ligand interaction prediction: An improved chemogenomics approach. *Bioinformatics*, 24(19), 2149–2156. <https://doi.org/10.1093/bioinformatics/btn409>
- Jeni, L. A., Cohn, J. F., & De La Torre, F. (2013). Facing imbalanced data—Recommendations for the use of performance metrics. In 2013 Humaine Association Conference on Affective Computing and Intelligent Interaction. IEEE.
- Jiang, M., Li, Z., Zhang, S., Wang, S., Wang, X., Yuan, Q., & Wei, Z. (2020). Drug–target affinity prediction using graph neural network and contact maps. *RSC Advances*, 10(35), 20701–20712. <https://doi.org/10.1039/D0RA02297G>
- Jiang, M., Wang, S., Zhang, S., Zhou, W., Zhang, Y., & Li, Z. (2022). Sequence-based drug-target affinity prediction using weighted graph neural networks. *BMC Genomics*, 23(1), 449. <https://doi.org/10.1186/s12864-022-08648-9>
- Jumper, J., Evans, R., Pritzel, A., Green, T., Figurnov, M., Ronneberger, O., Tunyasuvunakool, K., Bates, R., Zidek, A., Potapenko, A., Bridgland, A., Meyer, C., Kohl, S. A. A., Ballard, A. J., Cowie, A., Romera-Paredes, B., Nikolov, S., Jain, R., Adler, J., Hassabis, D. (2021). Highly accurate protein structure prediction with AlphaFold. *Nature*, 596(7873), 583–589. <https://doi.org/10.1038/s41586-021-03819-2>
- Kim, H., Lee, J., Ahn, S., & Lee, J. R. (2021). A merged molecular representation learning for molecular properties prediction with a web-based service. *Scientific Reports*, 11(1), 11028. <https://doi.org/10.1038/s41598-021-90259-7>
- Kim, S., Chen, J., Cheng, T., Gindulyte, A., He, J., He, S., Li, Q., Shoemaker, B. A., Thiessen, P. A., Yu, B., Zaslavsky, L., Zhang, J., & Bolton, E. E. (2023). PubChem 2023 update. *Nucleic Acids Research*, 51(D1), D1373–D1380. <https://doi.org/10.1093/nar/gkac956>
- Kipf, T. N., & Welling, M. (2016). Semi-supervised classification with graph convolutional networks. arXiv preprint arXiv:1609.02907.
- Kleinbaum, D. G., Dietz, K., Gail, M., Klein, M., & Klein, M. (2002). Logistic regression. Springer.
- Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. *Advances in Neural Information Processing Systems*, 25, 1097–1105.
- Kuhn, M., Campillos, M., Letunic, I., Jensen, L. J., & Bork, P. (2010). A side effect resource to capture phenotypic effects of drugs. *Molecular Systems Biology*, 6(1), 343. <https://doi.org/10.1038/msb.2009.98>
- Lal, J. C., Mao, C., Zhou, Y., Gore-Panther, S. R., Rennison, J. H., Lovano, B. S., Castel, L., Shin, J., Gillinov, A. M., Smith, J. D., Barnard, J., van Wagoner, D. R., Luo, Y., Cheng, F., & Chung, M. K. (2022). Transcriptomics-based network medicine approach identifies metformin as a repurposable drug for atrial fibrillation. *Cell Reports Medicine*, 3(10), 100749. <https://doi.org/10.1016/j.xcrm.2022.100749>
- Landrum, G. (2013). RDKit: A software suite for cheminformatics, computational chemistry, and predictive modeling. *Greg Landrum*, 8(31.10), 5281.
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436–444. <https://doi.org/10.1038/nature14539>
- Liu, C., Ma, Y., Zhao, J., Nussinov, R., Zhang, Y. C., Cheng, F., & Zhang, Z. K. (2020). Computational network biology: Data, models, and applications. *Physics Reports*, 846, 1–66. <https://doi.org/10.1016/j.physrep.2019.12.004>
- Liu, S., Demirel, M. F., & Liang, Y. (2019). N-gram graph: Simple unsupervised representation for graphs, with applications to molecules. *Advances in Neural Information Processing Systems*, 32, 8466–8478.
- Lu, C., Liu, Q., Wang, C., Huang, Z., Lin, P., & He, L. (2019). Molecular property prediction: A multilevel quantum interactions modeling perspective. In *Proceedings of the AAAI Conference on Artificial Intelligence*. AAAI Press.
- Martin, W. R., & Cheng, F. (2020). Repurposing of FDA-approved toremifene to treat COVID-19 by blocking the spike glycoprotein and NSP14 of SARS-CoV-2. *Journal of Proteome Research*, 19(11), 4670–4677. <https://doi.org/10.1021/acs.jproteome.0c00397>
- McInnes, L., Healy, J., & Melville, J. (2018). UMAP: Uniform Manifold Approximation and Projection for dimension reduction. arXiv preprint arXiv:1802.03426.
- Medsker, L., & Jain, L. C. (1999). Recurrent neural networks: Design and applications. CRC Press. <https://doi.org/10.1201/9781420049176>
- Mitchell, J. B. (2001). The relationship between the sequence identities of alpha helical proteins in the PDB and the molecular similarities of their ligands. *Journal of Chemical Information and Computer Sciences*, 41(6), 1617–1622. <https://doi.org/10.1021/ci010364q>
- Mordelet, F., & Vert, J.-P. (2008). SIRENE: Supervised inference of regulatory networks. *Bioinformatics*, 24(16), i76–i82. <https://doi.org/10.1093/bioinformatics/btn273>
- Narayana, P. A., Coronado, I., Sujit, S. J., Wolinsky, J. S., Lublin, F. D., & Gabr, R. E. (2020). Deep learning for predicting enhancing lesions in multiple sclerosis from noncontrast MRI. *Radiology*, 294(2), 398–404. <https://doi.org/10.1148/radiol.2019191061>
- Ngiam, J., Khosla, A., Kim, M., Nam, J., Lee, H., & Ng, A. Y. (2011). Multi-modal deep learning. In *Proceedings of the 28th International Conference on Machine Learning (ICML-11)*. Omnipress.
- O'Boyle, N., & Dalke, A. (2018). DeepSMILES: An adaptation of SMILES for use in machine-learning of chemical structures.
- O'Boyle, N. M., Banck, M., James, C. A., Morley, C., Vandermeersch, T., & Hutchison, G. R. (2011). Open Babel: An open chemical toolbox. *Journal of Cheminformatics*, 3, 1–14. <https://doi.org/10.1186/1758-2946-3-33>
- Otter, D. W., Medina, J. R., & Kalita, J. K. (2020). A survey of the usages of deep learning for natural language processing. *IEEE Transactions on Neural Networks and Learning Systems*, 32(2), 604–624. <https://doi.org/10.1109/TNNLS.2020.2979670>
- Öztürk, H., Ozkirimli, E., & Özgür, A. (2019). WideDTA: Prediction of drug-target binding affinity. arXiv preprint arXiv:1902.04166.
- Paci, P., Fiscon, G., Conte, F., Wang, R. S., Handy, D. E., Farina, L., & Loscalzo, J. (2022). Comprehensive network medicine-based drug repositioning via integration of therapeutic efficacy and side effects. *Npj Systems Biology and Applications*, 8(1), 12. <https://doi.org/10.1038/s41540-022-00221-0>
- Paul, S. M., Mytelka, D. S., Dunwiddie, C. T., Persinger, C. C., Munos, B. H., Lindborg, S. R., & Schacht, A. L. (2010). How to improve R&D productivity: The pharmaceutical industry's grand challenge. *Nature Reviews Drug Discovery*, 9(3), 203–214. <https://doi.org/10.1038/nrd3078>
- Qiu, Y., Hou, Y., Gohel, D., Zhou, Y., Xu, J., Bykova, M., Yang, Y., Leverenz, J. B., Pieper, A. A., Nussinov, R., Caldwell, J. Z. K., Brown, J. M., & Cheng, F. (2024). Systematic characterization of multi-omics landscape between gut microbial metabolites and GPCR in Alzheimer's disease. *Cell Reports*, 43(5), 114128. <https://doi.org/10.1016/j.celrep.2024.114128>
- Radford, A. (2018). Improving language understanding by generative pre-training.

- Resch, S., & Karpuzcu, U. R. (2021). Benchmarking quantum computers and the impact of quantum noise. *ACM Computing Surveys CSUR*, 54(7), 1–35. <https://doi.org/10.1145/3464420>
- Rifaioğlu, A. S., Nalbat, E., Atalay, V., Martin, M. J., Cetin-Atalay, R., & Dogan, T. (2020). DEEPScreen: High performance drug–target interaction prediction with convolutional neural networks using 2-D structural compound representations. *Chemical Science*, 11(9), 2531–2557. <https://doi.org/10.1039/C9SC03414E>
- Ruiz-Blanco, Y. B., Paz, W., Green, J., & Marrero-Ponce, Y. (2015). ProtD-Cal: A program to compute general-purpose-numerical descriptors for sequences and 3D-structures of proteins. *BMC Bioinformatics*, 16, 1–15. <https://doi.org/10.1186/s12859-015-0586-0>
- Sachdev, K., & Gupta, M. K. (2019). A comprehensive review of feature based methods for drug target interaction prediction. *Journal of Bio-medical Informatics*, 93, 103159. <https://doi.org/10.1016/j.jbi.2019.103159>
- Sarker, B., Khare, N., Devignes, M. D., & Aridhi, S. (2022). Improving automatic GO annotation with semantic similarity. *BMC Bioinformatics*, 23(Suppl 2), 433. <https://doi.org/10.1186/s12859-022-04958-7>
- Shao, K., Zhang, Y., Wen, Y., Zhang, Z., He, S., & Bo, X. (2022). DTI-HETA: Prediction of drug–target interactions based on GCN and GAT on heterogeneous graph. *Briefings in Bioinformatics*, 23(3), bbac109. <https://doi.org/10.1093/bib/bbac109>
- Shi, H., Liu, S., Chen, J., Li, X., Ma, Q., & Yu, B. (2019). Predicting drug–target interactions using Lasso with random forest based on evolution-ary information and chemical structure. *Genomics*, 111(6), 1839–1852. <https://doi.org/10.1016/j.ygeno.2018.12.007>
- Shin, B., Park, S., Kang, K., & Ho, J. C. (2019). Self-attention based molecule representation for predicting drug–target interaction. In *Machine Learning for Healthcare Conference*. PMLR.
- Sra, S., & Dhillon, I. (2005). Generalized nonnegative matrix approximations with Bregman divergences. *Advances in Neural Information Processing Systems*, 18, 283–290.
- Subramanian, I., Verma, S., Kumar, S., Jere, A., & Anamika, K. (2020). Multi-omics data integration, interpretation, and its application. *Bioinformatics and Biology Insights*, 14, 1177932219899051.
- Swain, M. (2014). PubChemPy documentation. Release 1.0.4.
- Tison, G. H., Siontis, K. C., Abreau, S., Attia, Z., Agarwal, P., Balasubramanyam, A., Li, Y., Sehnert, A. J., Edelberg, J. M., Friedman, P. A., Olgin, J. E., Noseworthy, P. A., & PIONEER-OLE Investigators. (2022). Assessment of disease status and treatment response with artificial intelligence-enhanced electrocardiography in obstructive hypertrophic cardiomyopathy. *Journal of the American College of Cardiology*, 79(10), 1032–1034. <https://doi.org/10.1016/j.jacc.2022.01.005>
- UniProt Consortium. (2019). UniProt: A worldwide hub of protein knowledge. *Nucleic Acids Research*, 47(D1), D506–D515. <https://doi.org/10.1093/nar/gky1049>
- Ursu, O., Holmes, J., Knockel, J., Bologa, C. G., Yang, J. J., Mathias, S. L., Nelson, S. J., & Oprea, T. I. (2016). DrugCentral: Online drug compendium. *Nucleic Acids Research*, 45, gkw993. <https://doi.org/10.1093/nar/gkw993>
- Vamathevan, J., Clark, D., Czodrowski, P., Dunham, I., Ferran, E., Lee, G., Li, B., Madabhushi, A., Shah, P., Spitzer, M., & Zhao, S. (2019). Applications of machine learning in drug discovery and development. *Nature Reviews Drug Discovery*, 18(6), 463–477. <https://doi.org/10.1038/s41573-019-0024-5>
- Van Engelen, J. E., & Hoos, H. H. (2020). A survey on semi-supervised learning. *Machine Learning*, 109(2), 373–440. <https://doi.org/10.1007/s10994-019-05855-6>
- Varadi, M., Bertoni, D., Magana, P., Paramval, U., Piduchna, I., Radhakrishnan, M., Tsenkov, M., Nair, S., Mirdita, M., Yeo, J., Kovalevskiy, O., Tunyasuvunakool, K., Laydon, A., Židek, A., Tomlinson, H., Hariharan, D., Abrahamson, J., Green, T., Jumper, J., ... Velankar, S. (2024). AlphaFold Protein Structure Database in 2024: Providing structure coverage for over 214 million protein sequences. *Nucleic Acids Research*, 52(D1), D368–D375. <https://doi.org/10.1093/nar/gkad1011>
- Vaswani, A. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30, 5998–6008.
- Velickovic, P., Cucurull, G., Casanova, A., Romero, A., Lio, P., & Bengio, Y. (2017). Graph attention networks. *Stat*, 1050(20), 10–48550.
- Voulodimos, A., Doulamis, N., Doulamis, A., & Protopapadakis, E. (2018). Deep learning for computer vision: A brief review. *Computational Intelligence and Neuroscience*, 2018, 1–13. <https://doi.org/10.1155/2018/7068349>
- Wang, H., Guo, F., du, M., Wang, G., & Cao, C. (2022a). A novel method for drug–target interaction prediction based on graph transformers model. *BMC Bioinformatics*, 23(1), 459. <https://doi.org/10.1186/s12859-022-04812-w>
- Wang, H., Zhou, G., Liu, S., Jiang, J. Y., & Wang, W. (2021). Drug–target interaction prediction with graph attention networks. *arXiv preprint arXiv:2107.06099*.
- Wang, R., Fang, X., Lu, Y., Yang, C. Y., & Wang, S. (2005). The PDBbind database: Methodologies and updates. *Journal of Medicinal Chemistry*, 48(12), 4111–4119. <https://doi.org/10.1021/jm048957q>
- Wang, S., Guo, Y., Wang, Y., Sun, H., & Huang, J. (2019). SMILES-BERT: Large scale unsupervised pre-training for molecular property prediction. In *Proceedings of the 10th ACM International Conference on Bioinformatics, Computational Biology and Health Informatics*. Association for Computing Machinery.
- Wang, Y., Wang, J., Cao, Z., & Barati Farimani, A. (2022b). Molecular contrastive learning of representations via graph neural networks. *Nature Machine Intelligence*, 4(3), 279–287. <https://doi.org/10.1038/s42256-022-00447-x>
- Wang, Y.-C., Yang, Z. X., Wang, Y., & Deng, N. Y. (2010). Computationally probing drug–protein interactions via support vector machine. *Letters in Drug Design & Discovery*, 7(5), 370–378. <https://doi.org/10.1016/j.sci.2010.07.005>
- Weininger, D. (1988). SMILES, a chemical language and information system. 1. Introduction to methodology and encoding rules. *Journal of Chemical Information and Computer Sciences*, 28(1), 31–36. <https://doi.org/10.1021/ci00057a005>
- Wishart, D. S., Feunang, Y. D., Guo, A. C., Lo, E. J., Marcu, A., Grant, J. R., Sajed, T., Johnson, D., Li, C., Sayeeda, Z., Assempour, N., Iynkkaran, I., Liu, Y., Maciejewski, A., Gale, N., Wilson, A., Chin, L., Cummings, R., Li, D., ... Wilson, M. (2018). DrugBank 5.0: A major update to the DrugBank database for 2018. *Nucleic Acids Research*, 46(D1), D1074–D1082. <https://doi.org/10.1093/nar/gkx1037>
- Wold, S., Esbensen, K., & Geladi, P. (1987). Principal component analysis. *Chemometrics and Intelligent Laboratory Systems*, 2(1–3), 37–52. [https://doi.org/10.1016/0169-7439\(87\)80084-9](https://doi.org/10.1016/0169-7439(87)80084-9)
- Wu, Z., Ramsundar, B., Feinberg, E. N., Gomes, J., Geniesse, C., Pappu, A. S., Leswing, K., & Pande, V. (2018). MoleculeNet: A benchmark for molecular machine learning. *Chemical Science*, 9(2), 513–530. <https://doi.org/10.1039/C7SC02664A>
- Xia, Z., Wu, L. Y., Zhou, X., & Wong, S. T. C. (2010). Semi-supervised drug–protein interaction prediction from heterogeneous biological spaces. In *BMC systems biology*. Springer.
- Xu, K., Hu, W., Leskovec, J., & Jegelka, S. (2018). How powerful are graph neural networks? *arXiv preprint arXiv:1810.00826*.
- Yang, J., He, S., Zhang, Z., & Bo, X. (2020). NegStacking: Drugtarget interaction prediction based on ensemble learning and logistic regression. *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, 18(6), 2624–2634. <https://doi.org/10.1109/TCBB.2020.2968025>
- Yang, Y., Qiu, Y., Hu, J., Rosen-Zvi, M., Guan, Q., & Cheng, F. (2024). A deep learning framework combining molecular image and protein structural representations identifies candidate drugs for pain. *Cell Reports Methods*, 4(10), 100865. <https://doi.org/10.1016/j.crmeth.2024.100865>

- Yap, C. W. (2011). PaDEL-Descriptor: An open source software to calculate molecular descriptors and fingerprints. *Journal of Computational Chemistry*, 32(7), 1466–1474. <https://doi.org/10.1002/jcc.21707>
- Ye, Q., Hsieh, C. Y., Yang, Z., Kang, Y., Chen, J., Cao, D., He, S., & Hou, T. (2021). A unified drug–target interaction prediction framework based on knowledge graph and recommendation system. *Nature Communications*, 12(1), 6775. <https://doi.org/10.1038/s41467-021-27137-3>
- Yu, Y., Zhuang, Y., Zhang, J., Meng, Y., Ratner, A. J., Krishna, R., Shen, J., & Zhang, C. (2024). Large language model as attributed training data generator: A tale of diversity and bias. *Advances in Neural Information Processing Systems*, 36, 36.
- Yuan, Q., Gao, J., Wu, D., Zhang, S., Mamitsuka, H., & Zhu, S. (2016). DrugE-Rank: Improving drug–target interaction prediction of new candidate drugs or targets by ensemble learning to rank. *Bioinformatics*, 32(12), i18–i27. <https://doi.org/10.1093/bioinformatics/btw244>
- Yun, S., Jeong, M., Kim, R., Kang, J., & Kim, H. J. (2019). Graph transformer networks. *Advances in Neural Information Processing Systems*, 32, 11983–11993.
- Zeng, X., Song, X., Ma, T., Pan, X., Zhou, Y., Hou, Y., Zhang, Z., Li, K., Karypis, G., & Cheng, F. (2020a). Repurpose open data to discover therapeutics for COVID-19 using deep learning. *Journal of Proteome Research*, 19(11), 4624–4636. <https://doi.org/10.1021/acs.jproteome.0c00316>
- Zeng, X., Wang, F., Luo, Y., Kang, S. G., Tang, J., Lightstone, F. C., Fang, E. F., Cornell, W., Nussinov, R., & Cheng, F. (2022a). Deep generative molecular design reshapes drug discovery. *Cell Reports Medicine*, 3(12), 100794. <https://doi.org/10.1016/j.xcrm.2022.100794>
- Zeng, X., Xiang, H., Yu, L., Wang, J., Li, K., Nussinov, R., & Cheng, F. (2022b). Accurate prediction of molecular properties and drug targets using a self-supervised image representation learning framework. *Nature Machine Intelligence*, 4(11), 1004–1016. <https://doi.org/10.1038/s42256-022-00557-6>
- Zeng, X., Zhu, S., Liu, X., Zhou, Y., Nussinov, R., & Cheng, F. (2019). deepDR: A network-based deep learning approach to in silico drug repositioning. *Bioinformatics*, 35(24), 5191–5198. <https://doi.org/10.1093/bioinformatics/btz418>
- Zeng, X., Zhu, S., Lu, W., Liu, Z., Huang, J., Zhou, Y., Fang, J., Huang, Y., Guo, H., Li, L., Trapp, B. D., Nussinov, R., Eng, C., Loscalzo, J., & Cheng, F. (2020b). Target identification among known drugs by deep learning from heterogeneous networks. *Chemical Science*, 11(7), 1775–1797. <https://doi.org/10.1039/C9SC04336E>
- Zhan, X., You, Z. H., Cai, J., Li, L., Yu, C., Pan, J., & Kong, J. (2020). Prediction of drug–target interactions by ensemble learning method from protein sequence and drug fingerprint. *IEEE Access*, 8, 185465–185476. <https://doi.org/10.1109/ACCESS.2020.3026479>
- Zhang, Y., Li, Y., Cui, L., Cai, D., Liu, L., Fu, T., Huang, X., Zhao, E., Zhang, Y., Chen, Y., & Wang, L. (2023). Siren's song in the AI ocean: A survey on hallucination in large language models. *arXiv preprint arXiv: 2309.01219*.
- Zhao, Q., Xiao, F., Yang, M., Li, Y., & Wang, J. (2019). AttentionDTA: Prediction of drug–target binding affinity using attention model. In *2019 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)*. IEEE.
- Zhao, T., Hu, Y., Valsdottir, L. R., Zang, T., & Peng, J. (2021). Identifying drug–target interactions based on graph convolutional network and deep neural network. *Briefings in Bioinformatics*, 22(2), 2141–2150. <https://doi.org/10.1093/bib/bbaa044>
- Zhou, Y., Hou, Y., Shen, J., Huang, Y., Martin, W., & Cheng, F. (2020a). Network-based drug repurposing for novel coronavirus 2019-nCoV/SARS-CoV-2. *Cell Discovery*, 6(1), 14. <https://doi.org/10.1038/s41421-020-0153-3>
- Zhou, Y., Hou, Y., Shen, J., Mehra, R., Kallianpur, A., Culver, D. A., Gack, M. U., Farha, S., Zein, J., Comhair, S., Fiocchi, C., Stappenbeck, T., Chan, T., Eng, C., Jung, J. U., Jehi, L., Erzurum, S., & Cheng, F. (2020b). A network medicine approach to investigation and population-based validation of disease manifestations and drug repurposing for COVID-19. *PLoS Biology*, 18(11), e3000970. <https://doi.org/10.1371/journal.pbio.3000970>
- Zhou, Y., Wang, F., Tang, J., Nussinov, R., & Cheng, F. (2020c). Artificial intelligence in COVID-19 drug repurposing. *The Lancet Digital Health*, 2(12), e667–e676. [https://doi.org/10.1016/S2589-7500\(20\)30192-8](https://doi.org/10.1016/S2589-7500(20)30192-8)

如何引用本文：杨, Y., & 程, F. (2025). 人工智能助力药物靶点相互作用的科学发现。《英国药理学杂志》, 1 - 18。
<https://doi.org/10.1111/bph.17427>