

DEBERTaV3: 利用带有梯度解耦嵌入共享的 ELECTRA 风格预训练改进 DEBERTa

Pengcheng He¹, Jianfeng Gao², Weizhu Chen¹

¹ 微软 Azure 人工智能

² 微软研究院

{penhe,jfgao,wzchen}@microsoft.com (此邮件地址无需翻译, 保持原样即可。)

摘要

本文提出了一种新的预训练语言模型 DeBERTaV3, 它通过用更高效的样本替换标记检测 (RTD) 任务取代原始 DeBERTa 模型中的掩码语言模型 (MLM) 来改进该模型。我们的分析表明, ELECTRA 中的简单嵌入共享会降低训练效率和模型性能, 因为判别器和生成器的训练损失会将标记嵌入向不同方向拉扯, 从而产生“拔河”动态。因此, 我们提出了一种新的梯度解耦嵌入共享方法, 避免了这种拔河动态, 从而提高了训练效率和预训练模型的质量。我们使用与 DeBERTa 相同的设置对 DeBERTaV3 进行了预训练, 以展示其在广泛的下游自然语言理解 (NLU) 任务中的卓越性能。以包含八个任务的 GLUE 基准为例, DeBERTaV3 Large 模型的平均得分为 91.37%, 比 DeBERTa 高 1.37%, 比 ELECTRA 高 1.91%, 在具有类似结构的模型中达到了新的最先进水平 (SOTA)。此外, 我们还预训练了一个多语言模型 mDeBERTaV3, 并且观察到其相较于强大的基线模型取得了更大的提升, 这一提升幅度超过了英语模型。例如, mDeBERTaV3 Base 在 XNLI 上实现了 79.8% 的零样本跨语言准确率, 比 XLM-R Base 提升了 3.6%, 在该基准测试中创造了新的最先进水平。我们的模型和代码可在 <https://github.com/microsoft/DeBERTa> 公开获取。

1 简介

预训练语言模型 (PLM) 的最新进展在许多自然语言处理 (NLP) 任务中创造了新的最先进的成果。虽然通过增加数十亿甚至数万亿的参数来扩展预训练语言模型 (Raffel 等人, 2020 年; Radford 等人, 2019 年; Brown 等人, 2020 年; He 等人, 2020 年; Fedus 等人, 2021 年) 已被证明是提升模型容量的有效途径, 但更重要的是探索更节能的方法, 以构建参数更少、计算成本更低但模型容量仍高的预训练语言模型。

朝着这个方向, 有一些工作显著提高了预训练语言模型 (PLMs) 的效率。首先是 RoBERTa (Liu 等人, 2019 年), 它通过使用更大的批量大小和更多的训练数据来提升模型容量。基于 RoBERTa, DeBERTa (He 等人, 2020 年) 通过引入解耦注意力机制 (一种改进的相对位置编码机制) 进一步提高了预训练效率。通过将参数规模扩大到 15 亿, 约为 xxlarge T5 (Raffel 等人, 2020 年) 参数量的八分之一, DeBERTa 首次在 SuperGLUE (Wang 等人, 2019a) 排行榜上超越了人类表现。第二种提高效率的新预训练方法是替换标记检测 (RTD), 由 ELECTRA (Clark 等人, 2020 年) 提出。与 BERT (Devlin 等人, 2019 年) 不同, BERT 使用 Transformer 编码器通过掩码语言模型 (MLM) 预测被遮蔽的标记, 而 RTD 则使用生成器生成模糊的错误标记, 并使用判别器将这些模糊标记与原始输入区分开来, 这与生成对抗网络类似。

网络（生成对抗网络）。RTD 的有效性也得到了多项研究的验证，包括 CoCo-LM（Meng 等人，2021 年）、XLM-E（Chi 等人，2021 年）、CodeBERT（Feng 等人，2020 年）和 SmallBenchNLP（Kanakarajan 等人，2021 年）。

在本文中，我们探讨了两种提高 DeBERTa 预训练效率的方法。借鉴 ELECTRA 的训练方式，我们将 DeBERTa 中的掩码语言模型（MLM）替换为替换检测（RTD），即训练模型作为判别器，预测输入中被破坏的标记是原始标记还是由生成器替换的标记。我们发现，采用 RTD 训练的 DeBERTa 模型显著优于使用 MLM 训练的模型。第二种方法是一种新的嵌入共享方法。在 ELECTRA 中，判别器和生成器共享相同的标记嵌入。然而，我们的分析表明，嵌入共享会降低训练效率和模型性能，因为判别器和生成器的训练损失会将标记嵌入向相反方向拉扯。这是因为生成器和判别器的训练目标差异很大。用于训练生成器的掩码语言模型（MLM）试图将语义相似的标记拉近，而判别器的替换检测（RTD）则试图区分语义相似的标记，并尽可能地将它们的嵌入拉远以优化二分类准确率，这导致了它们训练目标之间的冲突。换句话说，这会产生“拔河”效应，降低训练效率和模型质量，正如 Hadsell 等人（2020 年）所阐述的那样。另一方面，我们发现，当在下游任务上对判别器进行微调时，为生成器和判别器使用分离的嵌入会导致性能显著下降，这表明了嵌入共享的优势，例如，生成器的嵌入有助于生成更优的判别器，正如 Clark 等人（2020 年）所论述的那样。为了平衡这些权衡，我们提出了一种新的梯度解耦嵌入共享（GDES）方法，其中生成器与判别器共享嵌入，但阻止判别器的梯度向生成器嵌入反向传播。这样，我们就能避免“拔河”效应，同时保留嵌入共享的好处。我们通过实验证明，GDES 能够提高预训练效率和预训练模型的质量。

我们对 DeBERTaV3 模型的四个变体进行了预训练，即 DeBERTaV3_{large}、DeBERTaV3_{base}、DeBERTaV3_{small} 和 DeBERTaV3_{xsmall}。我们在多个具有代表性的自然语言理解（NLU）基准测试上对其进行了评估，并在具有类似模型结构的模型中取得了新的最佳成绩。例如，DeBERTaV3_{large} 在 GLUE（Wang 等人，2019b）基准测试中的平均得分比之前具有类似模型结构的最佳模型高出 +1.37%，这一提升是显著的。DeBERTaV3_{base} 在 MNLI-matched（Williams 等人，2018）评估集上达到了 90.6% 的准确率，在 SQuAD v2.0（Rajpurkar 等人，2018）评估集上达到了 88.4% 的 F1 值。这分别比 DeBERTa_{base} 提高了 1.8% 和 2.2%。在没有知识蒸馏的情况下，DeBERTaV3_{small} 和 DeBERTaV3_{xsmall} 在 MNLI-matched 和 SQuAD v2.0 评估集上的准确率分别比之前具有类似模型结构的最佳模型高出 1.2% 以上，在 F1 值上高出 1.3%。我们还使用与 XLM-R（Conneau 等人，2020）类似的设置在 CC100（Conneau 等人，2020）多语言数据上训练了 DeBERTaV3_{base}，但训练轮数仅为 XLM-R 的三分之一。我们将该模型标记为 mDeBERTaV3_{base}。在跨语言迁移设置下，mDeBERTaV3 在 XNLI（Conneau 等人，2018）任务上取得了 79.8% 的平均准确率，分别比 XLM-R_{base} 和 mT5_{base}（Xue 等人，2021）高出 3.6% 和 4.4%。这使得 mDeBERTaV3 成为具有类似模型结构的多语言模型中的最佳模型。所有这些结果都强有力地证明了 DeBERTaV3 模型的高效性，并为未来探索更高效的预训练语言模型奠定了良好的基础。

2 背景

2.1 变压器

基于 Transformer 的语言模型由 L 个堆叠的 Transformer 块组成（Vaswani 等人，2017 年）。每个块包含一个多头自注意力层，后面跟着一个全连接的位置前馈网络。标准的自注意力机制缺乏一种自然的方式来编码单词的位置信息。因此，现有的方法会在每个输入词嵌入中添加位置偏差，这样每个输入词就由一个向量表示，其值取决于词的内容和位置。位置偏差可以通过绝对位置嵌入（Vaswani 等人，2017 年；Brown 等人，2020 年；Devlin 等人，2019 年）或相对位置嵌入（Huang 等人，2018 年；Yang 等人，2019 年）来实现。多项研究表明，相对位置表示更有效。

用于自然语言理解和生成任务（戴等人，2019 年；肖等人，2018 年；何等人，2020 年）。

2.2 DeBERTa

DeBERTa 通过两个新颖的组件改进了 BERT：DA（解耦注意力）机制和增强型掩码解码器。与现有方法使用单个向量同时表示每个输入词的内容和位置不同，DA 机制使用两个单独的向量：一个用于内容，另一个用于位置。同时，DA 机制通过内容和相对位置的解耦矩阵来计算词之间的注意力权重。与 BERT 类似，DeBERTa 也是通过掩码语言模型进行预训练的。DA 机制已经考虑了上下文词的内容和相对位置，但未考虑这些词的绝对位置，而在很多情况下，绝对位置对于预测至关重要。DeBERTa 使用增强型掩码解码器在掩码语言模型解码层添加上下文词的绝对位置信息，从而改进了掩码语言模型。

2.3 依勒克拉

2.3.1 掩码语言模型

大规模基于 Transformer 的预训练语言模型（PLMs）通常在大量文本上进行预训练，以使用一种称为掩码语言模型（MLM）的自监督目标来学习上下文中的词表示（Devlin 等人，2019）。具体来说，给定一个序列 $X = [x_1, \dots, x_n]$ ，我们将其破坏为 $\tilde{X}$ ，通过对其 15% 的标记进行掩码处理

随机地进行掩码处理，然后训练一个由参数 θ 定义的语言模型，通过在给定 $\tilde{X}$ 的条件下预测掩码标记 $x_{\square}$ 来重构 X 。

$$\max_{\theta} \log p_{\theta}(X|\tilde{X}) = \max_{\theta} \sum_{i \in C} \log p_{\theta}(\tilde{x}_i = x_i|\tilde{X}) \quad (1)$$

其中 C 是序列中被遮蔽标记的索引集。BERT 的作者提议保持 10% 的被遮蔽标记不变，另外 10% 用随机选取的标记替换，其余的则用 [MASK] 标记替换。

2.3.2 替换标记检测

与仅使用一个 Transformer 编码器并通过掩码语言模型（MLM）进行训练的 BERT 不同，ELECTRA 是以生成对抗网络（GAN）的方式训练的，使用了两个 Transformer 编码器。其中一个称为生成器，通过掩码语言模型进行训练；另一个称为判别器，通过一个标记级别的二分类器进行训练。生成器用于生成模糊标记来替换输入序列中的掩码标记。然后将修改后的输入序列输入到判别器中。判别器中的二分类器需要判断相应标记是原始标记还是由生成器替换的标记。我们分别用 θ_G 和 θ_D 来表示生成器和判别器的参数。判别器中的训练目标称为 RTD（替换标记检测）。生成器的损失函数可以写成：

$$L_{MLM} = \mathbb{E} \left(- \sum_{i \in C} \log p_{\theta_G}(\tilde{x}_{i,G} = x_i|\tilde{X}_G) \right) \quad (2)$$

其中 $\tilde{X}_G$ 是通过在 X 中随机遮蔽 15% 的标记而输入到生成器中的内容。

判别器的输入序列是通过将被遮蔽的标记替换为根据生成器输出概率采样的新标记来构建的：

$$\tilde{x}_{i,D} = \begin{cases} \tilde{x}_i \sim p_{\theta_G}(\tilde{x}_{i,G} = x_i|\tilde{X}_G), & i \in C \\ x_i, & i \notin C \end{cases} \quad (3)$$

判别器的损失函数可写为，

$$L_{RTD} = \mathbb{E} \left(- \sum_i \log p_{\theta_D}(\mathbb{1}(\tilde{x}_{i,D} = x_i)|\tilde{X}_D, i) \right) \quad (4)$$

其中 $1p^{\sim}q$ 是示性函数, x

$\boxplus_0$ 是通过以下方式构建的判别器的输入

公式 3. 在 ELECTRA 中, LMLM 和 LRTD 被联合优化, 即 $L = L_{MLM} + \lambda L_{RTD}$, 其中 λ 是判别器损失 L_{RTD} 的权重, 在 ELECTRA 中被设置为 50。

3 DEBERTAV3

本节介绍 DeBERTaV3, 它通过采用克拉克等人 (2020 年) 的 RTD 训练损失以及一种新的权重共享方法对 DeBERTa 进行了改进。

3.1 带 RTD 的 DEBERTA

由于 ELECTRA 中的替换标记检测 (RTD) 以及 DeBERTa 中的解耦注意力机制已被证明在预训练中具有样本高效性, 我们提出了一种新的 DeBERTa 版本, 称为 *DeBERTaV3*, 通过用 RTD 目标替换 DeBERTa 中使用的掩码语言模型 (MLM) 目标, 以结合后者的优点。

在该实现中, 训练数据使用的是维基百科和书语料库 (Zhu 等人, 2015 年), 遵循了 Devlin 等人 (2019 年) 的基础模型配置。生成器的宽度与判别器相同, 但深度只有其一半。批量大小设置为 2048, 模型以 $5e-4$ 的学习率训练 125,000 步, 预热步数为 10,000 步。依照 Clark 等人 (2020 年) 的方法, 我们使用 $\lambda=50$ 并采用相同的优化超参数。我们在两个具有代表性的自然语言理解任务, 即 MNLI 和 SQuAD v2.0 上验证了 DeBERTaV3 的有效性。表 2 中的 1 所示结果表明, DeBERTaV3 显著优于 DeBERTa, 即在 MNLI-m 准确率上提高了 2.5%, 在 SQuAD v2.0 的 F1 值上提高了 3.8%。

在接下来的两个小节中, 我们将展示通过用一种新的梯度解耦嵌入共享 (GDES) 方法取代 DeBERTaV3 中用于 RTD 的原始嵌入共享 (ES) 方法 (最初由 Clark 等人于 2020 年提出), 其性能能够得到进一步提升。我们从对 ES 的分析开始, 见第 3.2 节。

3.2 ELECTRA 中的 TOKEN 嵌入共享

为了对 ELECTRA 进行预训练, 我们使用了共享词嵌入的生成器和判别器, 如图 1 (a) 所示。这种方法称为嵌入共享 (ES), 它能让生成器为判别器提供信息丰富的输入, 并减少需要学习的参数数量。然而, 这也造成了多任务学习问题, 即生成器和判别器的目标相互干扰, 从而减缓了训练收敛速度。

设 E 和 g_E 分别为标记嵌入及其梯度。在 ELECTRA 的每个训练步骤中, 我们通过反向传播来自生成器的掩码语言模型 (MLM) 损失和判别器的替换标记检测 (RTD) 损失的误差来计算 g_E , 即 $g_E = \frac{\partial L_{MLM}}{\partial E} + \lambda \frac{\partial L_{RTD}}{\partial E}$ 。此方程意味着标记嵌入通过平衡来自这两个任务的梯度进行更新, 这可以被视为一种拔河过程 (Hadsell 等人, 2020)。如果仔细控制更新速度 (例如, 使用较小的学习率或梯度裁剪), 该过程最终可以收敛, 但如果两个任务对嵌入的最优方向不同, 则该过程可能非常低效。对于 MLM 和 RTD 来说, 情况确实如此, 因为它们对标记嵌入的影响是相反的。MLM 鼓励语义相似标记的嵌入彼此靠近, 而 RTD 则试图将它们分开, 以使分类更容易。

为了验证我们的假设, 我们实现了一种变体的 ELECTRA, 其中生成器和判别器之间不共享词元嵌入, 我们将其称为“无嵌入共享” (NES), 如图 1 (b) 所示。在 NES 中, 我们在每个训练步骤中交替更新生成器和判别器。首先, 我们运行生成器以生成判别器的输入, 然后通过反向传播 MLM 损失来更新生成器的参数, 包括其词元嵌入 E_G 。接下来, 我们使用生成器的输入运行判别器, 并通过反向传播 RTD 损失来更新判别器的参数, 包括其词元嵌入 E_D 。

我们在三个方面对 ES 和 NES 进行了比较: 收敛速度、标记嵌入的质量以及在下游自然语言理解 (NLU) 任务上的表现。图 2 显示, NES 的收敛速度比 ES 快, 这在预料之中, 因为它避免了两者的冲突梯度。




图 1: 不同嵌入共享方法的示例。(a) ES: E 、 θ_G 和 θ_D 将在单次反向传播中联合更新, 依据 $L_{MLM} + \lambda L_{RTD}$ 。(b) NES: 首先通过反向传播依据 L_{MLM} 更新 E_G 和 θ_G , 然后通过反向传播依据 λL_{RTD} 更新 E_D 和 θ_D 。(c) GDES: 首先通过反向传播依据 L_{MLM} 更新 E_G 和 θ_G , 然后通过反向传播依据 λL_{RTD} 和 E_G 更新 E_D 和 θ_D 。sg 是停止梯度操作符, 防止判别器更新 E_G 。

表 1: 采用不同嵌入共享方法时生成器和判别器的词嵌入平均余弦相似度。

词嵌入共享	例如	ED	能量差 (或: 能量变化)
1. 西班牙	0.02	0.02	-
2. 台湾 NES	0.45	0.02	-
3. GDES	0.45	0.29	0.02

表 2: 采用不同嵌入共享方法训练的基础模型在 MNLI 和 SQuAD v2.0 任务上的微调结果。

模型	MNLI-m/mm 准确率	SQuAD 2.0 的 F1 值/精确匹配率 (EM)
BERT _{base}	84.3/84.7	76.3/73.7
ELECTRA _{base}	85.8/-	-/-
DeBERTa _{base}	86.3/86.2	82.5/79.3
DeBERTa+RTD _{base}		
1. 西班牙	88.8/88.4	86.3/83.5
2. 台湾 NES	88.3/87.9	85.3/82.7
3. GDES	89.3/89.0	87.2/84.5

下游任务。然后, 我们测量了标记嵌入的平均余弦相似度得分¹。表 1 显示, NES 生成了两个不同的嵌入模型, 其中 E_G 比 E_D 更具语义一致性。这证实了我们的假设。然而, NES 学习到的嵌入在两个具有代表性的下游自然语言理解任务 (即 MNLI 和 SQuAD v2.0) 上并未带来任何显著的改进, 如表 2 所示。这一结果支持了 Clark 等人 (2020 年) 的观点, 即 ES 除了节省参数外, 还具有使判别器受益于生成器嵌入的优势。在下一小节中, 我们提出了一种新的嵌入共享方法, 该方法结合了 ES 和 NES 的优点, 同时避免了它们的缺点。

3.3 梯度解缠嵌入共享

我们提出了梯度解耦嵌入共享 (GDES) 方法, 以克服嵌入共享 (ES) 和非嵌入共享 (NES) 的缺陷, 同时保留它们的优点。如图 1 (c) 所示, GDES 在生成器和判别器之间共享标记嵌入, 这使得两个模型能够从相同的词汇表中学习, 并利用嵌入中编码的丰富语义信息。然而, 与 ES 不同的是, GDES 不让真实/假数据 (RTD) 损失影响生成器的梯度, 从而避免了由冲突目标导致的干扰和低效。相反, GDES 仅使用掩码语言模型 (MLM) 损失来更新生成器的嵌入, 这确保了生成器输出的一致性和连贯性。因此, GDES 可以达到与 NES 相同的收敛速度, 同时又不会牺牲嵌入的质量。

为实现 GDES, 我们将判别器嵌入重新参数化为 $E_D = \text{sg}(E_G) + E_\Delta$, 其中停止梯度操作符 sg 阻止梯度流经生成器嵌入 E_G , 仅更新残差嵌入 E_Δ 。我们初始化 E_Δ 为一个零矩阵, 并按照 NES 程序训练模型。在每次迭代中, 我们首先使用生成器生成判别器的输入, 并使用 MLM 损失更新 E_G 和 E_D 。然后, 我们在生成的输入上运行判别器, 并仅通过 E_Δ 使用 RTD 损失更新 E_D 。训练完成后, 我们将 E_Δ 到 E_G 相加, 并将所得矩阵保存为 E_D 作为判别器。

¹We sample 10% of the word pieces from the vocabulary and calculate the average cosine similarity of every pair of two word pieces.

我们进行了大量实验来评估 GDES 与 ES 和 NES 的有效性。我们测量了收敛速度、标记嵌入的质量以及在下游任务中的表现。图 2、表 1 和表 2 中的结果表明，GDES 在各个方面都优于 ES 和 NES。首先，图 2 显示 GDES 的收敛速度比 ES 快，并且与 NES 的效率相当。由于 GDES、ES 和 NES 仅在嵌入共享方式上有所不同，因此每一步的计算成本是相同的。其次，表 1

表明 GDES 生成了两个独特的标记嵌入矩阵，其中生成器

具有更高平均相似度的嵌入向量

得分低于判别器嵌入的得分。然而，这一差异小于 NES 中的差异，这表明通过部分权重共享，GDES 在判别器嵌入中保留了更多的语义信息。第三，表 2 显示，在微调之后，使用 GDES 预训练的模型在两个下游任务 MNLI 和 SQuAD v2.0 上取得了最佳性能。这些结果证实了 GDES 是一种适用于使用 MLM 和 RTD 进行预训练的语言模型的有效权重共享方法。




图 2：采用不同词嵌入共享方法的生成器的掩码语言模型训练损失。

4 实验

4.1 自然语言理解任务的主要成果

为了进一步验证这些技术的有效性，我们将 RTD、GDES 和 DA（解耦注意力）结合起来，使用标准的预训练设置训练不同规模（即大、基础和小）的模型。由于我们所有的实验都是基于 DeBERTa 代码库进行修改，并且遵循 DeBERTa 的大部分设置，我们将新模型分别记为 DeBERTaV3_{large}、DeBERTaV3_{base} 和 DeBERTaV3_{small}。DeBERTaV3_{large} 和 DeBERTaV3_{base} 的判别器部分分别与 DeBERTa_{large} 和 DeBERTa_{base} 相同。DeBERTaV3_{small} 的判别器宽度和注意力头与 DeBERTa_{base} 相同，深度为 DeBERTa_{base} 的一半，即 6 层，隐藏层大小为 768，注意力头为 12。DeBERTaV3 的生成器宽度与判别器相同，深度为判别器的一半。我们使用 160GB 的数据训练这些模型，这与 DeBERTaV2 和 RoBERTa 相同，并使用与 DeBERTaV2（He 等人，2020）相同的 SentencePiece（Kudo, 2018; Sennrich 等人，2016）词汇表，其中包含 128,000 个标记。所有模型均训练 500,000 步，批处理大小为 8192，预热步数为 10,000。基础和小模型的学习率为 5e-4，而大模型的学习率为 3e-4。遵循 DeBERTa 的设置，我们使用带有权重衰减的 AdamW 优化器（Loshchilov & Hutter, 2018），它是 Adam 优化器（Kingma & Ba, 2014）的一个固定版本，并将优化器的 β_1 设置为 0.9， β_2 设置为 0.98。预训练完成后，这些模型的判别器按照与 BERT、RoBERTa、ELECTRA 和 DeBERTa 等 Transformer 预训练语言模型相同的范式用于下游任务的微调。有关预训练和微调的更多超参数细节，请参见附录。

4.1.1 大型模型的性能

在对先前关于预训练语言模型（PLMs）的研究进行回顾之后，我们首先在 GLUE（Wang 等人，2019b）中的八个自然语言理解（NLU）任务上对我们的模型进行了评估，这些任务是最具代表性的句子分类任务。我们通过在最后一层的 [CLS] 标记的隐藏状态上添加一个分类头来对预训练模型进行微调。我们在表 3 中总结了结果，其中将 DeBERTaV3 与结构相似的先前基于 Transformer 的 PLMs（即 24 层，隐藏层大小为 1024）进行了比较，包括 BERT、RoBERTa、XLNet（Yang 等人，2019）、ALBERT（Lan 等人，2019）、ELECTRA 和 DeBERTa。与之前的最先进模型相比，DeBERTaV3 在所有任务中的表现均相当或大多更优。同时，在八项任务中有七项任务中，DeBERTaV3 的表现优于 XLNet。就平均 GLUE 分数而言，DeBERTaV3 以较大优势（超过 1.3%）领先于其他最先进 PLMs。特别是与之前的最佳成绩相比，DeBERTaV3 在多个任务上取得了显著的提升。

在低资源任务（即 RTE（4.4%）、CoLA（4.8%））的性能上有显著提升。这表明 DeBERTaV3 更具数据效率，泛化性能更优。我们还注意到，在 SST-2、STS-B 和 MRPC 上的提升相对较小（约 0.3%）。我们推测这是由于这些任务的性能已接近饱和，因此即使是很小但持续的改进也是有价值的。

表 3: 在 GLUE 开发集上的对比结果。

型号 # 列车	MRPC 准确率 3.7k	Acc	MNLI-m/mm 准确率 393k	SST-2 准确率 67k	STS-B 修正版 700	QNLI 准确率 108k	RTE 账户 250	MRPC 准确率 3.7k	平均值
	8500	36400							
BERTlarge	60.6	91.3	86.6/-	93.2	90.0	92.3	70.4	88.0	84.05
RoBERTalarge	68.0	92.2	90.2/90.2	96.4	92.4	93.9	86.6	90.9	88.82
XLNetlarge	69.0	92.3	90.8/90.8	97.0	92.5	94.9	85.9	90.8	89.15
ELECTRAlarge (无准确对应的中文词汇)	60.9	91.3	90.9/-	96.9	92.6	95.0	88.0	90.8	89.46
DeBERTAlarge	70.5	92.3	91.1/91.1	96.8	92.8	95.3	88.3	91.9	90.00
DeBERTaV3 大型模型	75.3	93.0	91.8/91.9	96.9	93.0	96.0	92.7	92.2	91.37

为了进一步评估模型性能，除了 GLUE 之外，DeBERTaV3_{large} 还在三类具有代表性的自然语言理解基准测试上进行了评估：（1）问答：SQuAD v2.0、RACE (Lai 等人, 2017)、ReCoRD (Zhang 等人, 2018) 和 SWAG (Zellers 等人, 2018)；（2）自然语言推理：MNLI；（3）命名实体识别：CoNLL-2003 (Sang 和 De Meulder, 2003)。在这些任务中，RACE、SWAG 和 MNLI 采用与句子分类任务相同的方式进行微调。SQuAD v2.0、ReCoRD 和 NER 则作为序列标注任务进行微调，在最后一层的每个标记的隐藏状态之上添加了一个标记分类头。为了进行比较，我们纳入了 ALBERT_{xxlarge} e 2、DeBERTAlarge、DeBERTa1.5B 和 Megatron (Shoeybi 等人, 2019)，其中 Megatron 有三种不同的模型大小，分别表示为 Megatron336M、Megatron1.3B 和 Megatron3.9B，它们使用与 RoBERTa 相同的数据集进行训练。需要注意的是，Megatron_{336M} 的模型大小与上述其他模型相近³。我们在表 4 中总结了结果。与之前相比

表 4: 在 MNLI 领域内/外、SQuAD v2.0、RACE、ReCoRD、SWAG 和 CoNLL 2003 命名实体识别开发集上的结果。请注意，文献中缺失的结果以“-”表示。

模型	MNLI-m/mm	SQuAD v2.0	RACE	ReCoRD	SWAG	命名实体识别	F1
BERTlarge	86.6/-	81.8/79.0	72.0	-	86.6	92.8	
ALBERTlarge	86.5/-	84.9/81.8	75.2	-	-	-	
RoBERTalarge	90.2/90.2	89.4/86.5	83.2	90.6/90.0	89.9	93.4	
XLNetlarge	90.8/90.8	90.6/87.9	85.4	-	-	-	
ELECTRAlarge (无准确对应的中文词汇)	-	88.1/84.8	-	-	-	-	
Megatron336M	89.7/90.0	88.1/84.8	83.0	-	-	-	
DeBERTAlarge	91.1/91.1	90.7/88.0	86.8	91.4/91.0	90.8	93.8	
DeBERTaV3 大型模型	91.8/91.9	91.5/89.0	89.2	92.3/91.8	93.4	93.9	
ALBERTxxlarge	90.8/-	90.2/87.4	86.5	-	-	-	
梅加托恩 13 亿	90.9/91.0	90.2/87.1	87.3	-	-	-	
“Megatron 3.9B”	91.4/91.4	91.2/88.5	89.5	-	-	-	
DeBERTa 15 亿参数版	91.7/91.9	92.2/89.7	90.8	94.5/94.0	92.3	-	

在模型规模相近的情况下（即 BERT、RoBERTa、XLNet、ALBERT_{large}、Megatron_{336M} 和 DeBERTAlarge），DeBERTaV3large 在所有六项任务中的表现都更胜一筹。在 RACE（+2.4%）和 SWAG（+2.6%）这两项任务上，我们看到了显著的性能提升，这两项任务要求模型具备一定的推理能力和常识知识 (Lai 等人, 2017; Zellers 等人, 2018)。我们推测这些改进表明 DeBERTaV3_{large} 具备更强的推理能力和常识知识。尽管增加参数数量已被证明能有效提升模型容量 (Raffel 等人, 2020; Fedus 等人, 2021)，但与规模更大的模型相比，

²The hidden dimension of ALBERT_{xxlarge} is 4 times of DeBERTa and the computation cost is about 4 times of DeBERTa.

³T5 (Raffel et al., 2020) has more parameters (11B). Raffel et al. (2020) only reported the test results of T5 which are not comparable with models mentioned above.

DeBERTaV3large 在所有三项任务中的表现都大幅优于 ALBERTxxlarge 和 Megatron1.3B, 同时在 MNLI 和 SQuAD v2.0 上的表现也优于 Megatron_{3.3B}。与 DeBERTa_{1.5B} 相比, 后者曾是 GLUE 和 SuperGLUE 领导板上的 SOTA NLU 模型, DeBERTaV3large 在 MNLI 上的表现与其持平, 但在 SWAG 上则更胜一筹。

4.1.2 基础款和小型号的性能表现

我们在两个具有代表性的任务 (即 MNLI 和 SQuAD v2.0) 上对 DeBERTaV3base、DeBERTaV3small 和 DeBERTaV3xsmall 进行了评估, 并将结果总结在表 5 中。DeBERTaV3base 一直以比大型模型更大的优势优于 DeBERTa_{base} 和 ELECTRA_{base}。例如, 在 MNLI-m 上, DeBERTaV3_{base} 相对于 DeBERTa_{base} 和 ELECTRA_{base} 的提升为 +1.8 (90.6% 对比 88.8%)。在 SQuAD v2.0 的 EM 得分方面, DeBERTaV3base 相对于 ELECTRA_{base} 提升了 +4.9% (85.4% 对比 80.5%), 相对于 DeBERTa_{base} 提升了 +2.3% (85.4% 对比 83.1%)。

表 5: MNLI 领域内/领域外 (m/mm) 和 SQuAD v2.0 开发集的结果。TinyBERTsmall (Jiao 等人, 2019 年)、MiniLMv2small 和 MiniLMv2xsmall 模型是通过知识蒸馏进行预训练的, 而 BERTsmall、DeBERTaV3small 和 DeBERTaV3xsmall 分别通过从头开始的 MLM 和 RTD 目标进行训练。

模型	词汇量 (千)	骨干网参数 (M)	MNLI-m/mm 准确率	SQuAD 2.0 的 F1 值/精确匹配率 (EM)
基础模型: 12 层, 768 隐藏单元, 12 头				
BERTbase	30	86	84.3/84.7	76.3/73.7
RoBERTabase	50	86	87.6/-	83.7/80.5
XLNetbase	32	92	86.8/-	负八十分之二
ELECTRAbase	30	86	88.8/-	负八十分之五
DeBERTabase	50	100	88.8/88.5	86.2/83.1
DeBERTaV3 _{base}	128	86	90.6/90.7	88.4/85.4
小型模型: 6 层, 隐藏层大小 768, 12 个头				
TinyBERTsmall	30	44	84.5/-	77.7/-
MiniLMv2 小型版	30	44	87.0/-	81.6/-
BERTsmall	30	44	81.8/-	73.2/-
DeBERTaV3small	128	44	88.2/87.9	82.9/80.4
超小型模型: 12 层, 隐藏层大小 384, 6 个头				
MiniLMv2 小型版	30	22	86.9/-	82.3/-
DeBERTaV3 小型版	128	22	88.1/88.3	84.8/82.0

与具有相似模型结构的较小规模模型相比, DeBERTaV3_{small} 在上述两项任务 (即 MNLI-m 任务上提高了 6.4%, SQuAD v2.0 任务上的 F1 分数提高了 9.7%) 上的表现大幅优于 BERT_{small} (Wang 等人, 2020b)。令人惊讶的是, 尽管 DeBERTaV3xsmall 的参数量仅为 DeBERTaV3small 的一半, 但在这些任务上的表现却与 DeBERTaV3small 相当甚至更优。我们推测这可能是因为 DeBERTaV3xsmall 的层数更深, 从而能够提取出更优质的语义特征。在没有知识蒸馏的情况下, DeBERTaV3small 在 MNLI-m 和 SQuAD v2.0 上分别比 MiniLMv2small (Wang 等人, 2020a) 高出 1.2% 和 1.3%。DeBERTaV3xsmall 在 MNLI-m 和 SQuAD v2.0 上分别比 MiniLMv2xsmall (Wang 等人, 2020a) 高出 1.2% 和 2.5%。值得注意的是, 尽管 DeBERTaV3xsmall 的骨干参数量仅为 RoBERTabase 和 XLNetbase 的 1/4, 但在这些具有代表性的任务上, 前者的表现明显优于这两个模型 (即 MNLI-m 任务上提高了 0.5%, SQuAD v2.0 任务上的 EM 分数提高了 1.5%)。这进一步证明了 DeBERTaV3 模型的高效性。

4.2 多语言模型

作为一个重要的扩展, 我们将 DeBERTaV3 扩展到多语言领域。我们使用与 XLM-R 相同的 2.5T CC100 多语言数据集来训练多语言模型, 并将其标记为 mDeBERTaV3_{base}。我们使用与 mT5 相同的 SentencePiece 词汇表, 包含 25 万个标记。模型结构与我们的基础模型相同, 即隐藏层大小为 768, 12 层, 12 个注意力头。值得注意的是, 与 XLM 或 XLM-E 不同, 我们没有使用任何平行数据来训练我们的模型。

4. 预训练设置与 XLM-R 类似，只是我们将模型的训练步数从 150 万步减少到了 50 万步。

表 6: 在跨语言迁移和全翻译训练设置下 XNLI 测试集的结果。

模型	en	真的吗	西班牙语	el	背景	ru	tr	ar	6	th	zh	嗨	sw	ur	平均值
跨语言迁移															
XLM	83.2	76.7	77.7	74.0	72.7	74.1	72.7	68.7	68.6	72.9	68.9	72.5	65.6	58.2	70.7
mT5base	84.7	79.1	80.3	77.4	77.1	78.6	77.1	72.8	73.3	74.2	73.2	74.1	70.8	69.4	75.4
XLM-Rbase	85.8	79.7	80.7	78.7	77.5	79.6	78.1	74.2	73.8	76.5	74.6	76.7	72.4	66.5	76.2
mDeBERTaV3 _{base}	88.2	82.6	84.4	82.7	82.3	82.4	80.8	79.5	78.5	78.1	76.4	79.5	75.9	73.9	79.8
全部训练															
XLM	84.5	80.1	81.3	79.3	78.6	79.4	77.5	75.2	75.6	78.3	75.7	78.3	72.1	69.2	76.9
mT5base	82.0	77.9	79.1	77.7	78.1	78.5	76.5	74.8	74.4	74.5	75.0	76.0	72.2	71.5	75.9
XLM-Rbase	85.4	81.4	82.2	80.3	80.4	81.3	79.7	78.6	77.3	79.7	77.9	80.2	76.1	73.1	79.1
mDeBERTaV3 _{base}	88.9	84.4	85.3	84.8	84.0	84.5	83.2	82.0	81.6	82.0	79.8	82.6	79.3	77.3	82.2

由于 XNLI 是衡量多语言模型泛化性能的主要基准之一，我们评估了 mDeBERTaV3 在 XNLI 中 15 种语言上的表现。与之前的多语言预训练模型一样，我们报告了零样本跨语言迁移性能和 translate-train-all 性能。零样本跨语言迁移是指仅使用英语数据对模型进行微调，并在多语言测试集上进行评估。translate-train-all 是指使用英语数据和从英语数据翻译而来的多语言数据对模型进行微调，这些数据与 XNLI 数据集（Conneau 等人，2018 年）一起提供，然后在多语言测试集上评估模型。如表 6 所示，在两种设置下，mDeBERTaV3_{base} 在所有语言上的表现均显著优于之前的 SOTA 模型 XLM-R_{base}。就平均得分而言，在跨语言迁移设置中，mDeBERTaV3_{base} 相比 XLM-R_{base} 提升了 +3.6%（79.8% 对比 76.2%），在 translate-train-all 设置中，相比 XLM-R_{base} 提升了 +3.1%（82.2% 对比 79.1%）。这些结果清楚地表明了 DeBERTaV3 的有效性，同时表明了这种解耦对于多语言预训练也是有价值的。

所有这些都清楚地表明了 DeBERTaV3 模型的高效性。在众多下游任务中持续取得的改进也彰显了改进预训练语言模型的巨大价值。

5 结论

在本文中，我们提出了一种基于 DeBERTa 和 ELECTRA 相结合的新型语言模型预训练范式，这两种模型分别采用了相对位置编码和替换标记检测（RTD）。我们发现，简单地将这两种模型结合会导致预训练不稳定和效率低下，这是由于 RTD 框架中生成器和判别器之间存在一个众所周知的“拉锯战”动态干扰问题。为了解决这个问题，我们引入了一种称为 GDES 的新型嵌入共享范式，这是本文的主要创新和贡献。GDES 允许判别器利用生成器嵌入层中编码的语义信息，同时不会干扰生成器的梯度，从而提高了预训练效率。GDES 定义了一种在 RTD 框架中生成器和判别器之间共享信息的新方式，可轻松应用于其他基于 RTD 的语言模型。我们进行了广泛的分析和实验，将 GDES 与其他替代方案进行比较，以验证其有效性。

此外，我们表明，采用 GDES 的 DeBERTaV3 在涵盖自然语言理解不同方面的各种 NLU 任务上，均显著优于先前的最先进（SOTA）模型。例如，DeBERTaV3_{Large} 在 GLUE 平均得分上比具有类似架构的其他模型高出 1.37% 以上，而在 XNLI 任务的跨语言迁移准确率方面，mDeBERTaV3_{base} 比 XLM-R_{base} 高出 3.6%。这些结果突显了所有 DeBERTaV3 模型的有效性，并确立了 DeBERTaV3 作为不同模型规模（即 Large、Base、Small 和 XSmall）下自然语言理解的新的 SOTA 预训练语言模型（PLMs）。同时，这项工作清楚地表明了进一步提高模型参数效率的巨大潜力，并为未来研究更高效的预训练语言模型提供了一些方向。

⁴we expect to have a better model by continually pre-training on parallel data and will release a new model when available

参考文献

- Roy Bar-Haim, Ido Dagan, Bill Dolan, Lisa Ferro, and Danilo Giampiccolo. The second PASCAL recognising textual entailment challenge. In *Proceedings of the Second PASCAL Challenges Workshop on Recognising Textual Entailment*, 01 2006.
- Luisa Bentivogli, Ido Dagan, Hoa Trang Dang, Danilo Giampiccolo, and Bernardo Magnini. The fifth pascal recognizing textual entailment challenge. In *In Proc Text Analysis Conference (TAC’09)*, 2009.
- Tom B Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. *arXiv preprint arXiv:2005.14165*, 2020.
- Daniel Cer, Mona Diab, Eneko Agirre, Inigo Lopez-Gazpio, and Lucia Specia. Semeval-2017 task 1: Semantic textual similarity-multilingual and cross-lingual focused evaluation. *arXiv preprint arXiv:1708.00055*, 2017.
- Zewen Chi, Shaohan Huang, Li Dong, Shuming Ma, Saksham Singhal, Payal Bajaj, Xia Song, and Furu Wei. Xlm-e: Cross-lingual language model pre-training via electra. *arXiv preprint arXiv:2106.16138*, 2021.
- Kevin Clark, Minh-Thang Luong, Quoc V. Le, and Christopher D. Manning. ELECTRA: Pre-training text encoders as discriminators rather than generators. In *ICLR*, 2020.
- Alexis Conneau, Ruty Rinott, Guillaume Lample, Adina Williams, Samuel Bowman, Holger Schwenk, and Veselin Stoyanov. Xnli: Evaluating cross-lingual sentence representations. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, pp. 2475–2485, 2018.
- Alexis Conneau, Kartikay Khandelwal, Naman Goyal, Vishrav Chaudhary, Guillaume Wenzek, Fran-cisco Guzmán, Édouard Grave, Myle Ott, Luke Zettlemoyer, and Veselin Stoyanov. Unsupervised cross-lingual representation learning at scale. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pp. 8440–8451, 2020.
- Ido Dagan, Oren Glickman, and Bernardo Magnini. The pascal recognising textual entailment challenge. In *Proceedings of the First International Conference on Machine Learning Challenges: Evaluating Predictive Uncertainty Visual Object Classification, and Recognizing Textual Entailment, MLCW’05*, Berlin, Heidelberg, 2006.
- Zihang Dai, Zhilin Yang, Yiming Yang, Jaime G Carbonell, Quoc Le, and Ruslan Salakhutdinov. Transformer-xl: Attentive language models beyond a fixed-length context. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, pp. 2978–2988, 2019.
- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pp. 4171–4186, 2019.
- William B Dolan and Chris Brockett. Automatically constructing a corpus of sentential paraphrases. In *Proceedings of the Third International Workshop on Paraphrasing (IWP2005)*, 2005.
- William Fedus, Barret Zoph, and Noam Shazeer. Switch transformers: Scaling to trillion parameter models with simple and efficient sparsity. *arXiv preprint arXiv:2101.03961*, 2021.
- Zhangyin Feng, Daya Guo, Duyu Tang, Nan Duan, Xiaocheng Feng, Ming Gong, Linjun Shou, Bing Qin, Ting Liu, Daxin Jiang, et al. Codebert: A pre-trained model for programming and natural languages. *arXiv preprint arXiv:2002.08155*, 2020.
- Danilo Giampiccolo, Bernardo Magnini, Ido Dagan, and Bill Dolan. The third PASCAL recognizing textual entailment challenge. In *Proceedings of the ACL-PASCAL Workshop on Textual Entailment and Paraphrasing*, pp. 1–9, Prague, June 2007. Association for Computational Linguistics. URL <https://www.aclweb.org/anthology/W07-1401>.

- Raia Hadsell, Dushyant Rao, Andrei A Rusu, and Razvan Pascanu. Embracing change: Continual learning in deep neural networks. *Trends in Cognitive Sciences*, 24(12):1028–1040, 2020.
- Pengcheng He, Xiaodong Liu, Jianfeng Gao, and Weizhu Chen. DeBERTa: Decoding-enhanced bert with disentangled attention. In *International Conference on Learning Representations*, 2020.
- Cheng-Zhi Anna Huang, Ashish Vaswani, Jakob Uszkoreit, Ian Simon, Curtis Hawthorne, Noam Shazeer, Andrew M Dai, Matthew D Hoffman, Monica Dinculescu, and Douglas Eck. Music transformer: Generating music with long-term structure. 2018.
- Xiaoqi Jiao, Yichun Yin, Lifeng Shang, Xin Jiang, Xiao Chen, Linlin Li, Fang Wang, and Qun Liu. Tinybert: Distilling bert for natural language understanding. *arXiv preprint arXiv:1909.10351*, 2019.
- Kamal Raj Kanakarajan, Bhuvana Kundumani, and Malaikannan Sankarasubbu. Small-bench nlp: Benchmark for small single gpu trained models in natural language processing. *ArXiv*, abs/2109.10847, 2021.
- Diederik Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- Taku Kudo. Subword regularization: Improving neural network translation models with multiple sub-word candidates. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 66–75, 2018.
- Guokun Lai, Qizhe Xie, Hanxiao Liu, Yiming Yang, and Eduard Hovy. Race: Large-scale reading comprehension dataset from examinations. In *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*, pp. 785–794, 2017.
- Zhenzhong Lan, Mingda Chen, Sebastian Goodman, Kevin Gimpel, Piyush Sharma, and Radu Soricut. Albert: A lite bert for self-supervised learning of language representations. In *International Conference on Learning Representations*, 2019.
- Hector Levesque, Ernest Davis, and Leora Morgenstern. The winograd schema challenge. In *Thirteenth International Conference on the Principles of Knowledge Representation and Reasoning*, 2012.
- Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. Roberta: A robustly optimized bert pretraining approach. *arXiv preprint arXiv:1907.11692*, 2019.
- Ilya Loshchilov and Frank Hutter. Fixing weight decay regularization in adam. 2018.
- Yu Meng, Chenyan Xiong, Payal Bajaj, Saurabh Tiwary, Paul Bennett, Jiawei Han, and Xia Song. Coco-lm: Correcting and contrasting text sequences for language model pretraining. *arXiv preprint arXiv:2102.08473*, 2021.
- Alec Radford, Jeffrey Wu, Rewon Child, David Luan, Dario Amodei, and Ilya Sutskever. Language models are unsupervised multitask learners. *OpenAI Blog*, 1(8), 2019.
- Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J. Liu. Exploring the limits of transfer learning with a unified text-to-text transformer. *Journal of Machine Learning Research*, 21(140):1–67, 2020. URL <http://jmlr.org/papers/v21/20-074.html>.
- Pranav Rajpurkar, Jian Zhang, Konstantin Lopyrev, and Percy Liang. SQuAD: 100,000+ questions for machine comprehension of text. In *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*, November 2016.
- Pranav Rajpurkar, Robin Jia, and Percy Liang. Know what you don’t know: Unanswerable questions for squad. In *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, pp. 784–789, 2018.

- Erik Tjong Kim Sang and Fien De Meulder. Introduction to the conll-2003 shared task: Language-independent named entity recognition. In *Proceedings of the Seventh Conference on Natural Language Learning at HLT-NAACL 2003*, pp. 142–147, 2003.
- Rico Sennrich, Barry Haddow, and Alexandra Birch. Neural machine translation of rare words with subword units. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 1715–1725, Berlin, Germany, August 2016. Association for Computational Linguistics. doi: 10.18653/v1/P16-1162. URL <https://aclanthology.org/P16-1162>.
- Peter Shaw, Jakob Uszkoreit, and Ashish Vaswani. Self-attention with relative position representations. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 2 (Short Papers)*, pp. 464–468, 2018.
- Mohammad Shoeybi, Mostofa Patwary, Raul Puri, Patrick LeGresley, Jared Casper, and Bryan Catanzaro. Megatron-lm: Training multi-billion parameter language models using gpu model parallelism. *arXiv preprint arXiv:1909.08053*, 2019.
- Richard Socher, Alex Perelygin, Jean Wu, Jason Chuang, Christopher D Manning, Andrew Ng, and Christopher Potts. Recursive deep models for semantic compositionality over a sentiment treebank. In *Proceedings of the 2013 conference on empirical methods in natural language processing*, pp. 1631–1642, 2013.
- Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in neural information processing systems*, pp. 5998–6008, 2017.
- Alex Wang, Yada Pruksachatkun, Nikita Nangia, Amanpreet Singh, Julian Michael, Felix Hill, Omer Levy, and Samuel Bowman. Superglue: A stickier benchmark for general-purpose language understanding systems. In *Advances in neural information processing systems*, pp. 3266–3280, 2019a.
- Alex Wang, Amanpreet Singh, Julian Michael, Felix Hill, Omer Levy, and Samuel Bowman. Glue: A multi-task benchmark and analysis platform for natural language understanding. In *7th International Conference on Learning Representations, ICLR 2019*, 2019b.
- Wenhui Wang, Hangbo Bao, Shaohan Huang, Li Dong, and Furu Wei. Minilmv2: Multi-head self-attention relation distillation for compressing pretrained transformers. *arXiv preprint arXiv:2012.15828*, 2020a.
- Wenhui Wang, Furu Wei, Li Dong, Hangbo Bao, Nan Yang, and Ming Zhou. Minilm: Deep self-attention distillation for task-agnostic compression of pre-trained transformers. *arXiv preprint arXiv:2002.10957*, 2020b.
- Alex Warstadt, Amanpreet Singh, and Samuel R Bowman. Neural network acceptability judgments. *arXiv preprint arXiv:1805.12471*, 2018.
- Adina Williams, Nikita Nangia, and Samuel Bowman. A broad-coverage challenge corpus for sentence understanding through inference. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*, pp. 1112–1122. Association for Computational Linguistics, 2018. URL <http://aclweb.org/anthology/N18-1101>.
- Linting Xue, Noah Constant, Adam Roberts, Mihir Kale, Rami Al-Rfou, Aditya Siddhant, Aditya Barua, and Colin Raffel. mt5: A massively multilingual pre-trained text-to-text transformer. In *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pp. 483–498, 2021.
- Zhilin Yang, Zihang Dai, Yiming Yang, Jaime Carbonell, Russ R Salakhutdinov, and Quoc V Le. Xlnet: Generalized autoregressive pretraining for language understanding. In *Advances in neural information processing systems*, pp. 5754–5764, 2019.

- Rowan Zellers, Yonatan Bisk, Roy Schwartz, and Yejin Choi. Swag: A large-scale adversarial dataset for grounded commonsense inference. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing*, pp. 93–104, 2018.
- Sheng Zhang, Xiaodong Liu, Jingjing Liu, Jianfeng Gao, Kevin Duh, and Benjamin Van Durme. ReCoRD: Bridging the gap between human and machine commonsense reading comprehension. *arXiv preprint 1810.12885*, 2018.
- Yukun Zhu, Ryan Kiros, Rich Zemel, Ruslan Salakhutdinov, Raquel Urtasun, Antonio Torralba, and Sanja Fidler. Aligning books and movies: Towards story-like visual explanations by watching movies and reading books. In *Proceedings of the IEEE international conference on computer vision*, pp. 19–27, 2015.

附录

A.1 数据集

表 7: 自然语言处理应用基准的汇总信息。

语料库	任务	#训练	#开发	#测试	#标签	指标
通用语言理解评估 (GLUE)						
CoLA	可接受性	850	一千	一千	2	马修斯系数
SST	情绪	6700	872	180	2	准确性
MNLI	自然语言推理	39.3 万	两万	两万	3	准确性
RTE	自然语言推理	250	276	三千	2	准确性
WNLI	自然语言推理	634	71	146	2	准确性
QQP	释义; 改述; 同义表述	364 千字节	四万	39.1 万	2	准确率/F1 值
MRPC	释义; 改述; 同义表述	三千七百	408	170	2	准确率/F1 值
QNLI	问答/自然语言推理	108 千字节	五千七百	五千七百	2	准确性
STS-B	相似性	700	150	140	1	皮尔逊/斯皮尔曼相关系数
问答系统						
SQuAD 1.1 版	MRC	8760	1050	950	-	精确匹配 (EM) /F1
SQuAD 2.0 版	MRC	13030	1190	890	-	精确匹配 (EM) /F1
ReCoRD	MRC	10.1 万	10 千米	10 千米	-	精确匹配 (EM) /F1
赛跑	MRC	87,866	4,887	4,934	4	准确性
SWAG	多项选择题	七万三千五百两万	两万	两万	4	准确性
标记分类						
CoNLL 2003	命名实体识别	14,987	3,466	3,684	8	F1
多语言自然语言推理 (XNLI)						
XNLI 跨语言	自然语言推理	39.3 万	三万七千	七万五千	3	准确性
XNLItranslate 训练	自然语言推理	5.9 兆 (字节)	三万七千	七万五千	3	准确性

GLUE (通用语言理解评估) 基准包含九项自然语言理解 (NLU) 任务。如表 7 所示, 这些任务包括问答 (Rajpurkar 等人, 2016 年)、语言可接受性 (Warstadt 等人, 2018 年)、情感分析 (Socher 等人, 2013 年)、文本相似度 (Cer 等人, 2017 年)、句对相似度检测 (Dolan 和 Brockett, 2005 年) 以及自然语言推理 (NLI) (Dagan 等人, 2006 年; Bar-Haim 等人, 2006 年; Giampiccolo 等人, 2007 年; Bentivogli 等人, 2009 年; Levesque 等人, 2012 年; Williams 等人, 2018 年)。这些任务的多样性使得 GLUE 非常适合用于评估 NLU 模型的泛化能力和鲁棒性。

RACE 是一个大规模的机器阅读理解数据集, 来自中国针对中学生和高中的英语考试中的题目组成 (Lai 等人, 2017)。

斯坦福问答数据集 (SQuAD) v1.1 和 v2.0 (Rajpurkar 等人, 2016 年; 2018 年) 是两个广受欢迎的机器阅读理解基准测试集, 它们取材自约 500 篇维基百科文章, 其中的问题和答案均通过众包方式获取。SQuAD v2.0 数据集包含了针对相同段落的无法回答的问题。

SWAG 是一个用于基于情境的常识推理任务的大规模对抗数据集, 它将自然语言推理和基于物理的情境推理统一起来 (Zellers 等人, 2018 年)。SWAG 包含了 11.3 万个关于具体情境的多项选择题。

CoNLL 2003 (桑和德·梅尔德, 2003 年) 是一个由多种来源文本组成的英语数据集。它包含 4 种类型的命名实体。

XNLI (Conneau 等人, 2018 年) 附带了 15 种语言的真实开发集和测试集, 以及一个与 MNLI 训练集相同的真实英语训练集。该训练集已被机器翻译成其余 14 种语言, 为这些语言提供了合成训练数据。

A.2 预训练数据集

对于 DeBERTaV3 的预训练, 我们使用与 RoBERTa 和 DeBERTa_{xxl} 相同的数据, 即维基百科、Bookcorpus、CCNews、Stories 以及 OpenWebText 的组合。多语言版本

DeBERTaV3 是使用 2.5TB 的 CC100 数据集进行训练的，这与 XLM-R 相同。在预训练过程中，我们还从训练数据中抽取 5% 作为验证集以监控训练过程。表 8 对不同预训练模型所使用的数据集进行了比较。

表 8: 预训练数据的比较。

模型	维基+图书 16GB	开放网络文本 38GB	故事 31GB	创意共享新闻 76GB	吉伽5 16GB	克鲁韦伯 19 gb	共同爬虫 110 gb	创意共享10 2.5 太字节
BERT	✓							
XLNet	✓				✓	✓	✓	
伊莱克特拉	✓				✓	✓	✓	
RoBERTa	✓	✓	✓	✓				
DeBERTa	✓	✓	✓	✓				
DeBERTa _{1.5b}	✓	✓	✓	✓				
DeBERTaV3	✓	✓	✓	✓				
mDeBERTaV3 _{base}								✓

A.3 GDES 的一般性

为了展示 GDES 作为 RTD 增强手段的通用性，我们将其应用于 ELECTRA 场景，其中我们使用了 12 层的判别器和 6 层的生成器的基模型，两者的隐藏层大小相同。我们使用维基百科和 BookCorpus 数据从头开始以 $5e-4$ 的学习率和 2k 的批处理大小预训练模型 125k 步。然后，我们在 MNLI 和 SQuAD v2.0 上评估了预训练模型，使用与表 2 相同的设置。表 9 中的结果表明，GDES 在此设置中也能提高 RTD 的训练效率，这与表 2 中的发现一致。

表 9: 采用不同嵌入共享方法训练的基础 ELECTRA 模型在 MNLI 和 SQuAD v2.0 任务上的微调结果。

模型	MNLI-m/mm 准确率	SQuAD 2.0 的 F1 值/精确匹配率 (EM)
ELECTRAbase	85.8/-	-/-
ELECTRAbase		
重新实现 (西班牙语)	87.9/87.4	85.0/82.3
2 台 NES 游戏机	86.3/85.6	81.7/78.9
3 GDES	88.3/87.8	85.9/83.1

A.4 实施细节

我们的预训练几乎遵循与 DeBERTa (He 等人, 2020 年) 相同的设置。生成器通过掩码语言模型 (MLM) 进行训练，其中我们随机将 15% 的输入标记替换为 [MASK] 标记。判别器通过替换检测 (RTD) 进行训练，这与 ELECTRA 相同。第 3 节中的实验使用维基百科英文数据和 Bookcorpus 数据进行训练，批处理大小为 2000，训练步数为 125000 步。第 4 节中的实验使用表 8 中列出的数据进行训练，批处理大小为 8000，训练步数为 500000 步。我们在表 10 中列出了预训练的详细超参数。对于预训练，我们使用带有权重衰减 (Loshchilov 和 Hutter, 2018 年) 的 Adam (Kingma 和 Ba, 2014 年) 作为优化器。对于微调，为了公平比较，我们使用 Adam (Kingma 和 Ba, 2014 年) 作为优化器。对于微调，我们通过超参数搜索过程训练每个任务，每次运行在 DGX-2 节点上大约需要 1 到 2 小时。所有超参数均在表 11 中列出。模型选择基于特定任务的开发集上的性能。

我们的代码是基于 DeBERTa (He 等人, 2020)⁵ 和 ELECTRA (Clark 等人, 2020)⁶ 实现的。

⁵<https://github.com/microsoft/DeBERTa>

⁶<https://github.com/google-research/electra>

表 10: DeBERTaV3 预训练的超参数。

超参数	DeBERTaV3 _{large}	DeBERTaV3 _{base}	DeBERTaV3 _{small}	mDeBERTaV3 _{base}	DeBERTaV3 _{base-analysis}
层数	24	12	6	12	12
隐藏层大小	1024	768	768	768	768
FNN 内部隐藏层大小	4096	3072	3072	3072	3072
注意力头	12	12	12	12	12
注意力头大小	64	64		64	64
辍学	0.1	0.1	0.1	0.1	0.1
热身步骤	10 千米	10 千米	10 千米	10 千米	10 千米
学习率	3e-4	6e-4	6e-4	6e-4	5e-4
批量大小	8K	8K	8K	8K	2048
权重衰减	0.01	0.01	0.01	0.01	0.01
最大步数	50 万	50 万	50 万	50 万	12.5 万
学习率衰减	线性的	线性的	线性的	线性的	线性的
亚当 β_1	1e-6	1e-6	1e-6	1e-6	1e-6
亚当 β_2	0.9	0.9	0.9	0.9	0.9
亚当 β_3	0.98	0.98	0.98	0.98	0.999
梯度裁剪	1.0	1.0	1.0	1.0	1.0

表 11: 在下游任务中对 DeBERTaV3 进行微调的超参数。

超参数	DeBERTaV3 大型模型	DeBERTaV3 _{base}	DeBERTaV3small	mDeBERTaV3 _{base}
任务层的丢弃	{0, 0.15, 0.3}	{0, 0.1, 0.15}	{0, 0.1, 0.15}	{0, 0.1, 0.15}
热身步骤	{50, 100, 500, 1000}	{50, 100, 500, 1000}	{50, 100, 500, 1000}	{50, 100, 500, 1000}
学习率	{ 5×10^{-5} , 8×10^{-5} , 9×10^{-5} , 1×10^{-4} , 1.5×10^{-4} , 2×10^{-4} , 2.5×10^{-4} , 3×10^{-4} }	{ 5×10^{-5} , 8×10^{-5} , 9×10^{-5} , 1×10^{-4} , 1.5×10^{-4} , 2×10^{-4} , 2.5×10^{-4} , 3×10^{-4} }	{ 5×10^{-5} , 8×10^{-5} , 9×10^{-5} , 1×10^{-4} , 1.5×10^{-4} , 2×10^{-4} , 2.5×10^{-4} , 3×10^{-4} }	{ 5×10^{-5} , 8×10^{-5} , 9×10^{-5} , 1×10^{-4} , 1.5×10^{-4} , 2×10^{-4} , 2.5×10^{-4} , 3×10^{-4} }
批量大小	{16, 32, 48, 64}	{16, 32, 48, 64}	{16, 32, 48, 64}	{16, 32, 48, 64}
权重衰减	0.01	0.01	0.01	0.01
最大训练轮数	10	10	10	10
学习率衰减	线性的	线性的	线性的	线性的
亚当 β_1	1e-6	1e-6	1e-6	1e-6
亚当 β_2	0.9	0.9	0.9	0.9
亚当 β_3	0.999	0.999	0.999	0.999
梯度裁剪	1.0	1.0	1.0	1.0