

MolE: 一种基于解耦注意力机制的分子图基础模型

收件日期: 2024 年 3 月 11 日

Oscar Méndez-Lucio¹, Christos A. Nicolaou^{1,2} & Berton Earnshaw¹

接受日期: 2024 年 10 月 18 日

Published online: 12 November 2024



能够基于化学结构准确预测物质性质的模型是化学科学领域中的重要工具。然而, 对于许多性质而言, 公开和私有的训练集通常规模较小, 这使得模型难以很好地泛化到训练数据之外。最近, 通过在大规模未标记数据集上进行自监督预训练, 然后在较小的标记数据集上进行微调, 这种泛化能力不足的问题得到了缓解。受这些进展的启发, 我们报告了 MolE, 这是一种针对分子图的 Transformer 架构, 以及一种两步预训练策略。预训练的第一步是专注于学习化学结构的自监督方法, 训练数据集包含约 8.42 亿个分子图; 第二步是采用大规模多任务方法来学习生物学信息。我们表明, 以这种方式进行预训练的模型在微调后, 在 Therapeutic Data Commons 领导板 (截至 2023 年 9 月) 所包含的 22 个 ADMET (吸收、分布、代谢、排泄和毒性) 任务中的 10 个任务上, 其表现优于已发表的最佳结果。

机器学习在化学科学领域的成功应用已有数十年之久¹。特别是分子性质预测在推进材料和药物发现项目方面发挥了关键作用²。然而, 该领域仍面临的一个重大挑战是如何以与机器学习算法兼容且信息损失最小的方式表示分子。最初, 分子是通过其物理化学性质 (例如分配系数) 或从分子式中可获取的信息 (如分子量或杂原子数量) 来表示的³。尽管这种方法在早期定量构效关系 (QSAR) 研究中取得了成功⁴, 但它仅使用了分子的整体性质, 而未涉及化学结构本身。随着时间的推移, 人们开始采用更复杂的方法来描述分子, 例如使用 MACCS 密钥⁵和扩展连接指纹 (ECFPs)⁶ 等分子指纹。这些分子指纹通过预设的化学基团或原子环境的形式对分子的结构进行编码。尽管分子指纹在众多定量构效关系 (QSAR) 应用中取得了成功, 但当使用较短的指纹长度时, 它们无法完整地保留分子图的拓扑结构。

随着自然语言建模的最新进展, 人们注意到分子可以直接以 SMILES (一种为快速简便地

存储和搜索分子结构而开发的基于字符串的表示形式) 的形式作为预测模型的输入。SMILES 已被用于诸如循环神经网络 (RNN) 和 Transformer 等深度学习架构中, 但由于分子的 SMILES 表示并非唯一, 这给其应用带来了一定的局限性。此外, 还提出了其他基于字符串的表示形式, 例如 Self-Referencing Embedded Strings (SELFIES), 它以适合深度学习应用的乔姆斯基类型 2 自由上下文文法的形式对分子图进行编码。另一种方法是使用分子的图表示, 其中节点代表原子, 边代表化学键。这种方法与图神经网络 (GNN) 兼容, 后者已被广泛用于分子性质预测。通常, 图神经网络 (GNN) 会将每个节点的局部信息与其相邻原子的信息进行聚合, 然后将这些信息聚合为一个用于预测特定性质的单一分子表示。尽管图神经网络能够为分子学习表示提供最自然的方式, 并且在性质预测任务中表现出色, 但它们也存在一些缺陷, 例如在图神经网络的每一层中, 一个原子只能从其最近邻原子那里聚合信息。

¹ Recursion, Salt Lake City, UT, USA. ²Present address: Novo Nordisk Research Center, Lexington, MA, USA. e-mail: oscar.mendez-lucio@recursion.com; berton.earnshaw@recursion.com

在语言领域，学习有意义的表示的一种常用策略是训练基础模型。这些模型通常通过在大量未标记的数据集上进行自监督训练来构建，之后可针对各种下游任务进行微调¹⁹⁻²¹。这一策略也被用于使用 SMILES 训练化学领域的基础模型^{11,14}。然而，针对分子图的训练策略并不那么直接，且仅在相对有限的数据上进行了少数尝试²²⁻²⁴。特别是，Hu 等人提出了上下文预测方法²²，其任务是使用图神经网络（GNN）对分子的一部分进行编码，并通过负采样将所得嵌入与分子其余部分（称为上下文图）的嵌入进行匹配，并在 200 万分子的数据集上进行了训练。在本文中，我们报告了一种基于分子图训练的化学基础模型，该模型使用了约 8.42 亿个分子的数据进行自监督预训练。我们将此模型称为 MoIE，即分子嵌入的简称。特别是，MoIE 能够直接从分子图中学习原子环境层面的分子嵌入，使用的是变形器（transformer）²⁵。具体而言，我们对 DeBERTa26 中的解耦注意力机制进行了修改，以考虑分子图中相对原子位置的影响。我们还描述了一种用于图的自监督预训练策略，其中每个原子预测其原子环境，即所有相邻原子的原子类型和连接性。通过使用 Therapeutic Data Commons（TDC）²⁷ 中定义的 ADMET 任务，我们表明 MoIE 能够在小数据集上进行微调，从而达到顶尖性能。这项工作对于化学科学领域具有重要意义，在该领域中，大量未标记的分子结构可用，但标记数据集的规模通常非常小。

结果

一种用于分子图的变压器模型

模型输入。与基于 SMILES 的模型不同，在基于 SMILES 的模型中，构成 SMILES 字符串的字符被用作标记，而 MoIE 直接处理图结构，将原子标识符作为输入标记，并将图的连接性作为相对位置信息。原子标识符是通过将不同的原子属性（即 Daylight 原子不变量）哈希为一个整数来计算得出的⁶。具体来说，此哈希包含以下信息：相邻重原子的数量、相邻氢原子的数量、价态减去所连接氢原子的数量、原子电荷、原子质量、所连接的键类型以及环成员身份。原子标识符（也称为半径为 0 的原子环境）是使用 RDKit 29 中实现的 Morgan 算法²⁸ 计算得出的。除了标记之外，MoIE 还将图的连接性信息作为输入，这是重要的归纳偏差，因为它编码了分子图中原子的相对位置。在这种情况下，图的连接性以拓扑距离矩阵 d 的形式给出，其中 d_{ij} 表示将原子 i 与原子 j 分隔开的键的最短路径的长度。

模型架构。MoIE 采用 Transformer²⁵ 作为其基础架构，该架构此前也已应用于图结构数据^{30,31}。Transformer 的性能在很大程度上得益于自注意力机制的广泛使用。在标准的 Transformer 中，输入标记被嵌入到查询、键和值 Q 、 K 、 V 中，维度为 $2RN \times d$ ，用于计算自注意力，其计算方式如下：

$$A = \frac{QK^T}{\sqrt{d}} \quad (1)$$

$$H_0 = \text{softmax}(A)V \quad (2)$$

其中 $H_0 \in \mathbb{R}^{2N \times d}$ 是经过自注意力机制处理后的输出隐藏向量， d 是隐藏空间的维度。为了在 Transformer 的每一层中明确传递位置信息，MoIE 使用了来

自 DeBERTa26 的解耦自注意力机制：

$$a_{ij} = Q_i^c K_j^{cT} + Q_i^c K_{j,i}^{pT} + K_j^c Q_{j,i}^{pT} \quad (3)$$

$$A = \frac{a}{\sqrt{3d}} \quad (4)$$

$$H_0 = \text{softmax}(A)V^c \quad (5)$$

其中， $\setminus (Q_c, K_c, V_c \in \mathbb{R}^{N \times d}) \times d$ 是包含标记信息的上下文查询、键和值（用于标准的自注意力机制），而 $\setminus (Q_{\{p_{ij}\}}, K_{\{p_{ij}\}} \in \mathbb{R}^{N \times d}) \times d$ 是位置查询和键，用于编码第 i 个原子相对于第 j 个原子的相对位置。使用解耦注意力使得 MoIE 对输入原子的顺序具有不变性。

预训练策略。如前所述，自监督预训练能够有效地将大量未标记数据集中的信息转移到较小的有标签数据集上。在此，我们提出一种两步预训练策略，如图 1 所示。第一步是采用自监督方法学习化学结构表示。为此，我们使用类似于 BERT 的方法³²，其中每个原子以 15% 的概率被随机掩码，所选标记中有 80% 被替换为掩码标记，10% 被替换为词汇表中的随机标记，10% 保持不变。与 BERT 不同的是，预测任务不是预测掩码标记的身份，而是预测半径为 r 的相应原子环境（或功能原子环境⁶），即与掩码原子相隔两个或更少键的所有原子。需要注意的是，我们对输入（半径 0）和标签（半径 2）采用了不同的标记化策略，并且输入标记不包含相邻原子的重叠数据，以避免信息泄露。这激励模型在学习局部分子特征的同时，从相邻原子中聚合信息。MoIE 通过一个分类任务进行学习，在该任务中，半径为 2 的每个原子环境都有一个预定义的标签，这与通过负采样将半径为 4 的原子环境的嵌入与半径 4 以外的环境原子（即周围原子）的嵌入进行匹配的上下文预测方法不同。第二步使用一个大型标注数据集进行图级别的有监督预训练。正如 Hu 等人所提出的，结合³³和图级别的预训练有助于学习局部和全局特征，从而提高最终的预测性能。有关预训练步骤的更多详细信息，请参阅方法部分。

在下游任务中实现高性能。MoIE 是通过使用来自 ZINC20 和 ExCAPE-DB 的约 8.42 亿个分子的超大型数据库进行预训练的，采用了自监督方案（带有辅助损失），随后使用约 45.6 万个分子进行了监督预训练（更多细节见方法部分）。我们通过在一系列下游任务上对 MoIE 进行微调来评估分子嵌入的质量。在此情况下，我们使用了 Therapeutic Data Commons（TDC）基准测试中的 22 个 ADMET 任务集。该基准测试由 9 个回归任务和 13 个二分类任务组成，所涉及的数据集从数百个化合物（例如，DILI 数据集包含 475 种化合物）到数千个化合物（例如，CYP 抑制任务包含约 13,000 种化合物）不等。使用此基准测试的一个优势在于，它提供了一种标准化的方式来比较模型性能（使用 5 次独立运行的平均值和标准差）。截至 2023 年 9 月，已有约 15 种不同的方法在该基准测试中得到官方评估，其中包括使用预计算指纹（例如 RDKit 或 Morgan 指纹）的模型、使用 SMILES 的卷积神经网络以及不同版本的图神经网络，如 ChemProp¹⁸。




图 1 | 本研究中使用的预训练和微调方法。a 一种自监督方法，其中输入的一个原子被掩码，任务是预测半径为 2 的相应原子环境，即被掩码的原子加上所有距离不超过两个键的相邻原子。请注意，在这种方法中

例如，两个被遮蔽的标记对应于相同的原子标识符（2041434490），但与每个标记相关联的原子环境是不同的。b 一种监督方法，其中将各个标记的嵌入聚合到一个聚合标记中，然后将其输入到预训练头中。

表 1 列出了 MoIE 在 TDC 基准测试中的结果，其在 22 项任务中的 10 项任务上达到了最先进的性能（截至 2023 年 9 月），并且在另外 4 项任务中排名第二。更具体地说，它在 6 项回归任务和 4 项分类任务（主要是 CYP 抑制）中表现最佳。值得注意的是，在纳入 MoIE 的结果后，排名第二的模型 ZairaChem 在 22 项任务中仅在 5 项任务中取得了最佳成绩。不出所料，MoIE 在数据集较大的任务中取得了最佳结果，例如预测 CYP 抑制。然而，它在一些仅有几百个训练样本的任务中也取得了最佳成绩，例如预测半衰期和 CYP 底物。

通过消融实验理解 MoIE 的性能

利用前文所述的 TDC ADMET 任务，我们进行了消融研究，以了解不同架构和预训练选择对模型性能的影响。表 2 总结了研究结果，而补充表 S1-S5 则提供了详细情况。为了尽量减少完成这些消融研究所需的大量训练，我们在 GuacaMol 数据集（约 120 万种化合物）上进行了自监督训练步骤，同时保持相同的监督策略。

解缠注意力的作用。MoIE 的一个重要结构选择是使用解缠注意力机制³⁶。该特性利用相对位置嵌入向模型告知分子中每个原子的位置，使其不受原子顺序的影响。移除解缠注意力会对性能产生显著影响，这与从标准双向转换器中移除位置嵌入的影响类似^{36,37}。补充图 S1 展示了两种自监督预训练场景下的训练损失和测试准确率。不出所料，在掩码建模任务中，使用解缠注意力的自监督预训练实现了高准确率（0.96），而不使用这种注意力机制的准确率仅为 0.12。我们还在 TDC 基准上评估了没有解缠注意力的 MoIE，结果在 22 项任务中有 19 项的表现不如使用解缠注意力的模型（补充表 S1）。

预训练的效果。补充表 S1 展示了 MoIE 在 TDC ADMET 任务上的表现，1) 未经任何预训练；2) 仅经过监督预训练。值得注意的是，在没有任何预训练的情况下，仅针对每个单独任务训练 MoIE，其在 22 个任务中的 4 个（PPBR、VDss、半衰期和 DILI）上的表现就已经优于 Huang 等人在 TDC 上进行基准测试的早期模型。这表明仅使用具有解耦注意力机制的转换器就已经能够取得这样的效果。

表 1 | 治疗数据共享平台（TDC）排行榜（截至 2023 年 9 月）中所报告的最佳模型与微调后的 MolE 模型之间的比较

TDC 领导板最佳表现 (2023 年 9 月)				TDC 领导板最佳表现 (2024 年 6 月)		摩尔	
数据集	度量标准	尺寸	当前最佳模型	结果	当前最佳模型	结果	结果
吸收	Caco2 (钙通道阻滞剂)	MAE	906	基础增强	MapLight	0.276 ± 0.005	0.329±0.008
	HIA	AUROC	578	RF堆叠器	MapLight + 图神经网络	0.989 ± 0.001	0.984 ± 0.005
	Pgp	AUROC	1212	ZairaChem	MapLight + 图神经网络	0.938 ± 0.002	0.93±0.005
	生物利用度	AUROC	640	SimGCN	SimGCN	0.748 ± 0.03	0.64±0.046
	亲脂性	MAE	4200	Chemprop-RDKit	Chemprop-RDKit	0.467 ± 0.006	0.406±0.009
	溶解度	MAE	9982	Chemprop-RDKit	Chemprop-RDKit	0.761 ± 0.025	0.776 ± 0.019
分配	BBB	AUROC	1975	灯笼 RADR	注册金融分析师	0.920±0.006	0.903±0.003
	PPBR	MAE	1797	Chemprop	MapLight + 图神经网络	7.526 ± 0.106	7.229 ± 0.168
	漏源极击穿电压	斯皮尔曼	1130	基础机器学习	MapLight + 图神经网络	0.713±0.007	0.644±0.013
新陈代谢	CYP2D6 抑制作用	AUPRC	13,130	Chemprop-RDKit	MapLight + 图神经网络	0.790 ± 0.001	0.679 ± 0.006
	CYP3A4 抑制作用	AUPRC	12,328	ZairaChem	MapLight + 图神经网络	0.916 ± 0.00	0.876 ± 0.002
	CYP2C9 抑制作用	AUPRC	12,092	ZairaChem	MapLight + 图神经网络	0.859 ± 0.001	0.782 ± 0.001
	CYP2D6 底物	AUPRC	664	ZairaChem	上下文预测	0.736 ± 0.024	0.692 ± 0.017
	CYP3A4 底物	AUROC	667	CNN (深度目的)	注册金融分析师	0.667±0.019	0.692 ± 0.019
	CYP2C9 底物	AUPRC	666	ZairaChem	ZairaChem	0.441 ± 0.03	0.409±0.014
排泄	半衰期	斯皮尔曼	667	欧克利亚 ML 模型	注册金融分析师	0.576 ± 0.025	0.578 ± 0.032
	清除微粒体	斯皮尔曼	1102	RF堆叠器	MapLight + 图神经网络	0.630±0.010	0.632±0.008
	清除型肝细胞	斯皮尔曼	1020	基础机器学习	注册金融分析师	0.536 ± 0.020	0.456 ± 0.027
毒性	hERG	AUROC	648	SimGCN	MapLight + 图神经网络	0.880 ± 0.002	0.835 ± 0.018
	艾姆斯	AUROC	7255	ZairaChem	ZairaChem	0.871 ± 0.002	0.834 ± 0.015
	药物性肝损伤	AUROC	475	ZairaChem	ZairaChem	0.925 ± 0.005	0.852 ± 0.02
	LD50	MAE	7385	基础增强 KyQVZ6b2	基础增强 KyQVZ6b2	0.552 ± 0.009	0.602 ± 0.016

在 TDC 的 22 项任务中，MolE 在其中 10 项任务中取得了最先进的结果（加粗并下划线的值）。此表展示了 5 次独立训练运行的平均值和标准差。MAE：平均绝对误差，AUROC：受试者工作特征曲线下面积，AUPRC：精确率-召回率曲线下面积。

表 2 | 各种 MolE 简化模型在 Therapeutic Data Commons（TDC）排行榜（截至 2023 年 9 月）上针对 22 项 ADMET（吸收、分布、代谢、排泄和毒性）任务取得最佳性能的任务数量

预训练	自监督标签	无辅助损失	logP 作为辅助损失	FP 作为辅助损失
无	–	0	–	–
仅监督的	–	2	–	–
仅自监督（约 120 万）	原子环境	2	2	2
	功能环境	4	2	3
自监督（约 120 万）+ 监督	原子环境	7	7	2
	功能环境	6	4	6
仅自监督（约 8.42 亿）	原子环境	1	–	3
自监督（8.42 亿）+ 监督	原子环境	6	–	10

详情请见补充信息。

尽管仅在小型、特定任务的数据集上进行训练，但这些模型对性能产生了积极影响。遗憾的是，这些模型的表现都不如 TDC 领导板（截至 2023 年 9 月）上的最佳模型。仅通过有监督的预训练就能提升 TDC 任务的性能，然而相较于基准模型，这种提升幅度很小，这表明仅靠有监督的预训练不足以学习到可迁移的表征。

在补充表 S2 中，我们展示了自监督预训练的结果。这里我们考虑了三种方法：普通的掩码标记建模（M

TM）、MolE 和 MolE-FE。尽管这三种方法都使用半径为 0 的原子环境作为输入，但它们的预测标签各不相同。普通的 MTM 任务预测用作输入的掩码标记的身份（即预测半径为 0 的原子环境），MolE 任务预测半径为 2 的原子环境，而 MolE-FE 则预测半径为 2 的功能原子环境。尽管采用任何一种策略都能在验证集上获得高准确率（>98%），但 MolE-FE 在基准任务上的表现略好，截至 2023 年 9 月，在 22 项任务中的 4 项上超过了之前的模型^{27,38}，而 MolE 只在 2 项任务上表现更优（见表 2）。然而，在自监督预训练之后添加监督预训练极大地提高了 MolE 的性能，在 22 项任务中的 7 项上取得了最佳结果。当添加监督预训练时，MolE-FE 的结果也有所改善（从 4 项最佳结果增加到 6 项）。有趣的是，普通的 MTM 是这三种策略中表现最差的。造成这种情况的两个可能原因是：1）与预测原子环境（约 140,000 个标记）相比，由于词汇量较小（207 个标记），这似乎是一个更容易的预训练任务；2）MolE 和 MolE-FE 间接包含了普通的掩码标记任务，因为它们需要预测被掩码原子的身份，以便选择正确的半径为 2 的原子环境。

辅助任务的效果。我们还研究了在自监督预训练期间添加以下辅助任务，以期学习到更有意义的化学表征：学习分配系数（logP）或学习分子的二进制指纹。对于 logP，我们在输入中添加了一个额外的标记（称为聚合标记），并在其编码输出中添加了一个预测头，同时最小化 logP 预测误差和掩码标记任务的误差（图 1a）。我们使用 RDKit29 计算 logP。

表 2 和补充表 S3 展示了 MoIE 和 MoIE-FE 在使用 logP 作为辅助损失进行训练后的结果。总体而言，仅观察到自监督版本的 MoIE-FE 的性能有轻微下降，在这种情况下，其仅在 2 项任务中表现最佳，而非 4 项。有趣的是，使用这种辅助损失并未改变 MoIE 在任何预训练策略下的性能。

对于指纹学习，我们将此设定为一个多任务二分类问题，任务在于判定分子中词汇表内半径为 2 的每个原子环境是否存在。通过这种方式，我们迫使模型将分子中所有原子环境的信息聚合到一个单一的向量中，该向量可用作下游任务的起点。如表 2 和补充表 S4 所示，这一辅助任务再次导致两种环境和两种预训练策略的性能持平或更低。我们的假设是，由于输出众多，指纹学习是一项非常复杂的任务，需要更多的训练样本才能带来任何益处。

数据规模的影响。在我们持续进行的研究中，我们还分析了将预训练扩展到更大规模数据集的影响：从 ZINC 数据集中随机抽取的分别包含 1000 万和 1 亿个分子的两个数据集，以及包含约 8.42 亿个分子的完整 ZINC 数据集。之所以这样做，是因为更大的训练集往往能提高模型的泛化能力。为清晰起见，我们将扩展预训练的结果包含在补充图 S3 以及补充表 S5 和 S6 中。值得注意的是，使用更大规模的训练集所带来的性能提升是显著的，在许多任务中都提高了模型的性能。当在完整的 ZINC 数据集上训练时，MoIE 的表现尤为出色，在 10 项任务中均有所提升，超过了截至 2023 年 9 月 TDC 领导板上之前表现最佳的模型。这些结果突显了在更大、更多样化的数据集上进行预训练所带来的益处，使模型对化学有了更全面的理解。事实上，在基于完整的 ZINC20 数据集进行训练时，该模型接触到了约 6000 万种不同的贝米斯 - 穆尔科骨架，其中出现频率最高的分别是吡啶环、环己烷环和噻吩环（分别在 230 万、160 万和 99 万种物质中出现）。不过，鉴于化学多样性这一概念难以衡量，多样性的影响不在本研究的讨论范围之内。在少数任务中，模型的表现并未显著提升，甚至略有下降。这种情况可能归因于任务的复杂性、所涉及的化学结构的性质或其他限制因素。要理解这些具体案例，还需要进行更深入的分析，但总体结果表明，增加预训练数据量能显著提升模型性能。

MoIE 嵌入是分子图的一种有意义的表示形式。

MoIE 的一个重要特点是能够生成有意义的分子嵌入。为了证明这一点，我们对分子嵌入进行了内在和外在测试。内在评估衡量的是嵌入的质量，不依赖于其预测功能。该测试主要集中在评估分子嵌入之间的拓扑或功能关系，类似于评估词嵌入中的句法或语义关系，可以被视为对嵌入捕捉分子结构属性能力的更广泛评估。相反，外在分析则检查嵌入在下游任务中的有效性，这种评估计算量更大，但对特定任务更有意义，尽管可解释性较差。由于没有单一的评估能够全面检查模型嵌入，因此建议采用多种指标。

在本研究中，我们采用了一种围绕相似性展开的内在测试，具体来说就是邻域变化⁴⁰。为此，我们计算了来自 GuacaMol 测试集的约 79,000 种化合物的分子嵌入。对于每种化合物的嵌入，我们使用余弦相似度找到了 k 个最近邻（其中 k 分别为 5、10、15、25、50、100）。然后，我们确定了这些 k 个最近邻与使用摩根指纹（半径 2）^{6,28} 或 RDKitFP²⁹ 结合 Tanimoto 相似度所确定的最近邻的重叠情况，Tanimoto 相似度是一种广泛认可的用于评估化学相似性的方法³。所有分子的邻域重叠分布情况以箱线图的形式展示在图 2 中。总体而言，观察结果表明，更近的邻域（即 $k = 5、10$ ）更保守，而当考虑更远的邻域时，重叠度会降低。此外，MoIE 嵌入与摩根指纹的重叠有限，在 $k = 5$ 或 10 时，最近邻的重叠中位数约为 20%，对于更远的邻域，这一数字会降低。与现有两个基准（摩根和 RDKitFP）之间的重叠相比，这个数字要低得多，在 $k = 5$ 时，摩根和 RDKitFP 的重叠中位数约为 40%。使用仅通过自监督方法进行预训练的模型的 MoIE 嵌入进行了类似的比较。值得注意的是，这些嵌入与 Morgan 指纹有显著的重叠，在 $k = 5$ 时，它们共享的邻居中位数约为 60%，超过了 Morgan 和 RDKitFP 之间的重叠。MoIE 自监督嵌入与 Morgan 指纹的类似行为可归因于两者都基于半径为 2 的原子环境，这也再次证实了自监督方法在学习化学信息方面的成功。总之，这些结果表明嵌入确实捕获了有关化学结构的信息，并且无论其在预测任务中的表现如何，这一点始终成立。

使用上述 TDC 任务对分子嵌入进行了外在评估。在此情况下，将 MoIE 嵌入用作训练 XGBoost 模型的输入特征。此过程不会更新嵌入，从而能够对特定预测任务中嵌入的质量进行恰当评估。评估结果详见补充表 S7，在 22 项任务中的 12 项中，使用 MoIE 嵌入训练的模型表现最佳，而使用仅自监督的 MoIE 嵌入、半径为 2 的 Morgan 指纹或 RDKitFP 训练的模型则表现不佳。值得注意的是，在肝细胞清除率回归任务中，使用 MoIE 嵌入训练的 XGBoost 模型也优于 TDC 领先板上的模型。这些结果表明，监督预训练使 MoIE 嵌入更具生物学意义，并可能部分解释了这些嵌入与 Morgan 或 RDKitFP 指纹在内在评估中的差异，因为后者仅包含有关分子结构的信息。

图 2b 展示了 MoIE 嵌入空间的 UMAP 表示。每个点代表 GuacaMol 测试集中约 79K 种化合物中存在的一种原子环境的嵌入。为简洁起见，我们仅展示了围绕杂原子的原子环境。所选示例展示了不同子图（预计具有相似生物效应，如生物等排体）在嵌入空间中位置相近的情况。总体而言，重要的是要注意，本节中发现的结果表明，仅通过自监督学习得到的 MoIE 嵌入捕获了与 Morgan 指纹相似的化学信息，并且 MoIE 嵌入包含一定程度的生物信息，这增强了其在 TDC 基准任务中的性能。然而，不应将这些发现解读为这些嵌入将在所有可能的任务（无论是相似性搜索还是预测能力）中提供更优的分子表示。

讨论

在本文中，我们介绍了 MoIE，它使用具有解耦注意力机制的 Transformer（即 DeBERTa）来预测化学和生物方面的内容。




图2 | 对 MoIE 嵌入结果的评估。a 对分子嵌入进行邻域变化测试的评估。这些箱线图展示了不同分子编码方法下所有分子 ($n = 79,568$) 的邻域重叠分布情况。重叠值越接近 1, 表明两种编码方法所共享的 k 近邻越多。半径为 2 的 Morgan 指纹与仅在自监督数据上预训练的 MoIE 嵌入的邻域重叠度较高。

a 盒形图的中心线代表中位数; 盒形图的上下边界分别代表第一和第三四分位数, 而须状线则代表 1.5 倍四分距 (IQR)。b 以杂原子为中心的 MoIE 原子嵌入的 U-map 表示。有趣的是, 具有相似生物效应的不同子图 (例如生物电子等排体) 在嵌入空间中距离较近。

直接从分子图中获取属性。本文的具体贡献在于:

我们证明了, 当分子图通过半径为 0 的原子环境和相对位置嵌入来表示时, 具有解缠注意力机制的转换器可以直接用于分子图。

我们提出了一种针对分子图的自监督方法, 其任务是从仅包含单个原子及其所有相连键的信息的半径为 0 的原子环境, 学习出半径大于 0 的原子环境。

通过采用两步预训练方法——先进行自监督学习, 再进行监督学习——我们得以训练出在截至 2023 年 9 月 Therapeutic Data Commons 领先排行榜所包含的 22 项任务中有 10 项任务表现优于此前报道的方法, 在截至 2024 年 6 月的 22 项任务中有 5 项任务表现更优 (表 1)。

我们假设, 学习原子环境会迫使模型聚合用于预测的局部化学基团。学习原子环境的嵌入以及如何将其聚合为分子嵌入有助于解决经典指纹的一些问题, 例如使用位向量时出现的稀疏性和冲突。有趣的是, 这种自监督方法不仅限于使用转换器, 因为它可以轻松用于预训练图神经网络。由于我们仅使用了类药物分子, 因此在自监督过程中数据多样性的影响仍有待确定。不过, 我们预计更大、更多样化的数据集只会提高模型当前的性能。总体而言, 我们认为这项工作是迈向化学性质预测基础模型的初步一步。

方法

数据集

我们使用来自 ZINC20 和 ExCAPE-DB 的约 8.42 亿个分子进行了自监督预训练, 并在约

4400 万个分子的集合上进行了验证。在消融研究中, 我们使用 GuacaMol 训练集 (包含约 120 万个化合物) 进行自监督预训练, 并使用 GuacaMol 测试集 (包含 7.9 万个分子) 进行验证。值得一提的是, 我们仅使用了重原子不超过 100 个的分子, 并从训练集中移除了所有包含在 TDC 测试集中的分子, 以避免信息泄露。所有剩余的 SMILES 都使用 RDKit 转换为分子图, 从中计算出距离矩阵和原子环境 (半径 0 用作输入, 半径 2 用作标签)。原子环境标识符被聚合为两个词汇表, 一个用于输入, 一个用于标签。输入词汇表包含 207 个标记, 对应于 GuacaMol 中 120 万个分子以及 ZINC2033 中约 8.8 亿个分子中所有半径为 0 的原子环境。同样, 用于标签的词汇表包含约 14.1 万个原子环境或约 11.4 万个功能原子环境 (表 3)。这些是从 GuacaMol 训练集中选取的 90K 个最常见的原子环境或功能环境, 再加上 ZINC20 中最常见的 90K 个环境, 然后移除了在少于 3 个分子中出现的环境。

监督预训练是使用约 456,000 种分子完成的, 这些分子具有来自 ChEMBL41 的 1310 项活性数据, ChEMBL41 是依照 Mayr 等人提出的方案进行整理的, 并且该数据集已被使用。

表 3 | 用于监督和自监督预训练方法的任务及输入/输出词汇表汇总

自监督预训练			监督预训练	
标签类型	输入（半径 0）	输出（半径 2）	分子	任务
原子环境	207	约 141 千字节	约 456 千字节	1310
功能环境	207	约 114 千字节	约 456 千字节	1310

表 4 | XGBoost 模型超参数优化过程中使用的值列表

超参数名称	价值观
伽马	0, 0.1, 0.2, 0.4, 0.8, 1.6, 3.2, 6.4, 12.8, 25.6, 51.2, 102.4, 20
学习率	0.01, 0.03, 0.06, 0.1, 0.15, 0.2, 0.25, 0.300000012, 0.4, 0.5, 0.6, 0.7
最大深度	5, 6, 7, 8, 9, 10, 11, 12, 13, 14
估计器数量	50, 65, 80, 100, 115, 130, 150
阿尔法	0, 0.1, 0.2, 0.4, 0.8, 1.6, 3.2, 6.4, 12.8, 25.6, 51.2, 102.4, 20
Lambda	0, 0.1, 0.2, 0.4, 0.8, 1.6, 3.2, 6.4, 12.8, 25.6, 51.2, 102.4, 20

这是胡等人用于预训练的数据集²²。与胡等人²²的方法的一个重要区别在于，我们没有使用完整的数据集进行有监督预训练，而是移除了约 9900 种存在于 TDC 基准测试集中的分子。这避免了信息泄露，因为在某些情况下，TDC 测试集与用于有监督预训练的数据集之间的重叠可能超过 80% 的分子（补充表 S8）。在预训练阶段移除这些化合物使得 MoLE 模型能够公平地在 TDC 中进行基准测试。

训练

MoLE 采用 ^{DeBERTa26} 基础配置（12 层转换器，每层 12 个注意力头），并在聚合标记的输出端连接一个预测头，该聚合标记由两层具有 ^{GELU43} 和 ^{dropout44} 层的多层感知机（MLP）组成（补充图 S4）。无监督预训练使用 8 个 GPU 分布处理 512 个分子的批次，共进行 420,000 步（有效批次大小为 4096 个化合物）。学习率在前 10,000 步线性增加至 2×10^{-4} ，随后采用线性衰减的学习率计划。监督方法使用单个 GPU 处理 512 个分子的批次，预训练 60,000 步。在这种情况下，我们使用 5×10^{-6} 的学习率，采用与无监督训练相同的学习率计划。梯度范数被限制在 1.0，且未使用权重衰减。

在微调过程中，仅随机初始化了预测头的权重。模型使用每批 32 个分子的批量大小训练了 100 个周期。每 5 个周期在验证集上评估一次模型，并且仅保留根据这些验证指标表现最佳的模型的权重，用于在测试集上进一步评估。我们通过使用 TDC 基准数据集提供的折进行 5 折交叉验证，对超参数进行优化，以找到最佳的学习率（ $1e-5$ 、 $8e-6$ 、 $5e-6$ 、 $3e-6$ 、 $1e-6$ 、 $5e-7$ ）和预测头的丢弃率（0、0.1、0.15）。在训练过程中，学习率在训练步骤的前 10% 线性增加，之后保持不变。

基准

MoLE 模型使用来自治疗数据共享库（TDC）的 ADMET 基准组进行了评估。该基准组提供了已预先标准化并按 80%/20% 的比例通过支架拆分法分为训练集和测试集的数据集，以便公平地评估分子属性预测模型。它包含 22 个不同的分类和回归任务，涉及与药物发现相关的属性。例如，细胞通透性（Caco-2）、人体肠道吸收（HIA）和 P-糖蛋白抑制（Pgp），以及其他物理化学性质，能够很好地估计药物在体内的吸收程度。分布容积（VDss）、血浆蛋白结合率（PPBR）和血脑屏障（BBB）等属性则能让我们了解药物在体内的分布情况。了解分子是否抑制或成为特定细胞色素（CYP）同工酶的底物，有助于预测可能影响药物在体内停留时间的生物转化过程，而药物在体内的停留时间可通过半衰期和清除率来衡量。最后，了解一种分子是否具有心脏毒性（hERG）、

遗传毒性（Ames）或肝毒性（DILI）对于将安全的药物推向临床至关重要。关于这些任务的更多信息列于表 1 中。

TDC 会维护一个不同模型在这些任务上表现的排行榜。这些模型为性能比较提供了标准，因为它们采用了不同的架构和编码策略，例如预先计算的描述符（如 Morgan 或 RDKit 2D 指纹²⁹）、使用 SMILES 训练的卷积神经网络（CNNs），以及不同变体的基于图的方法（如 ^{NeuralFP17}、^{GCNs45}、^{AttentiveFP46} 等）。它还包含了采用不同预训练策略（例如 AttrMasking 和 ^{ContextPred22}）的模型。

XGBoost 模型

使用 XGBoost 模型来评估分子嵌入在外部预测任务中的质量。对于每个模型，使用贝叶斯优化在表 4 中列出的值范围内进行超参数搜索。此过程会找到在交叉验证期间使误差最小的一组超参数。为此，使用高斯过程模型作为优化器，并更新 120 次。使用最佳超参数训练最终模型，然后在 TDC 提供的测试集上进行评估。

报告摘要

有关研究设计的更多信息，请参阅与本文相关联的《自然》系列期刊报告摘要。

数据可用性

本研究结果所依据的数据完全公开，可通过以下链接获取：· ZINC：<https://zinc.docking.org/> · GuacaMol：<https://figshare.com/projects/GuacaMol/56639> · 治疗数据共享平台（TDC）：<https://tdcommons.ai/> 本论文提供了原始数据。

代码可用性

本研究中所报告模型的使用代码可在 https://github.com/recursionpharma/mole_public 下载，该代码遵循知识共享署名 - 非商业性使用 4.0 国际许可协议（CC-BY-NC 4.0）^{47, 48}。

参考文献

1. Martin, Y. C. Hansch analysis 50 years on. *WIREs Comput. Mol. Sci.* 2, 435–442 (2012).
2. Butler, K. T., Davies, D. W., Cartwright, H., Isayev, O. & Walsh, A. Machine learning for molecular and materials science. *Nature* 559, 547–555 (2018).
3. Willett, P., Barnard, J. M. & Downs, G. M. Chemical Similarity Searching. *J. Chem. Inf. Comput. Sci.* 38, 983–996 (1998).
4. Hansch, C. & Fujita, T. ρ - σ - π Analysis. A Method for the Correlation of Biological Activity and Chemical Structure. *J. Am. Chem. Soc.* 86, 1616–1626 (1964).
5. Durant, J. L., Leland, B. A., Henry, D. R. & Nourse, J. G. Reoptimization of MDL keys for use in drug discovery. *J. Chem. Inf. Comput. Sci.* 42, 1273–1280 (2002).
6. Rogers, D. & Hahn, M. Extended-Connectivity Fingerprints. *J. Chem. Inf. Model.* 50, 742–754 (2010).

7. Weininger, D. SMILES, a chemical language and information system. 1. Introduction to methodology and encoding rules. *J. Chem. Inf. Comput. Sci.* 28, 31–36 (1988).
8. Weininger, D., Weininger, A. & Weininger, J. L. SMILES. 2. Algorithm for Generation of Unique SMILES Notation. *J. Chem. Inf. Comput. Sci.* 29, 97–101 (1989).
9. Winter, R., Montanari, F., Noé, F. & Clevert, D. A. Learning continuous and data-driven molecular descriptors by translating equivalent chemical representations. *Chem. Sci.* 10, 1692–1701 (2019).
10. Chithrananda, S. & Ramsundar, B. ChemBERTa: Utilizing Transformer-Based Attention for Understanding Chemistry. Pre-print at <https://arxiv.org/abs/2010.09885> (2020).
11. Ahmad, W., Simon, E., Chithrananda, S., Grand, G. & Ramsundar, B. ChemBERTa-2: Towards chemical foundation models. Preprint at <http://arxiv.org/abs/2209.01712> (2022).
12. Wang, S., Guo, Y., Wang, Y., Sun, H. & Huang, J. SMILES-BERT: Large Scale Unsupervised Pre-Training for Molecular Property Prediction. In Proceedings of the 10th ACM International Conference on Bioinformatics, Computational Biology and Health Informatics, 429–436 (Association for Computing Machinery, 2019).
13. Fabian, B. et al. Molecular representation learning with language models and domain-relevant auxiliary tasks. Preprint at <https://arxiv.org/abs/2011.13230> (2020).
14. Ross, J. et al. Large-scale chemical language representations capture molecular structure and properties. *Nat. Mach. Intell.* 4, 1256–1264 (2022).
15. O'Boyle, N. & Dalke, A. DeepSMILES: an adaptation of SMILES for use in machine-learning of chemical structures. Preprint at <https://chemrxiv.org/engage/chemrxiv/article-details/60c73ed6567dfe7e5fec388d> (2018).
16. Krenn, M., Häse, F., Nigam, A. K., Friederich, P. & Aspuru-Guzik, A. Self-referencing embedded strings (SELFIES): A 100% robust molecular string representation. *Mach. Learn. Sci. Technol.* 1, 045024 (2020).
17. Duvenaud, D. et al. Convolutional Networks on Graphs for Learning Molecular Fingerprints. In Advances in Neural Information Processing Systems (eds Cortes, C., Lawrence, N., Lee, D., Sugiyama, M., Garnett, R.) (NeurIPS, 2015).
18. Yang, K. et al. Analyzing Learned Molecular Representations for Property Prediction. *J. Chem. Inf. Model.* 59, 3370–3388 (2019).
19. Brown, T. B. et al. Language Models are Few-Shot Learners. Preprint at <http://arxiv.org/abs/2005.14165> (2020).
20. Zhang, S. et al. OPT: Open Pre-trained Transformer Language Models. Preprint at <http://arxiv.org/abs/2205.01068> (2022).
21. Chowdhery, A. et al. PaLM: Scaling Language Modeling with Pathways. Preprint at <http://arxiv.org/abs/2204.02311> (2022).
22. Hu, W. et al. Strategies for pre-training Graph Neural Networks. Preprint at <http://arxiv.org/abs/1905.12265> (2019).
23. Wang, Y., Wang, J., Cao, Z. & Barati Farimani, A. Molecular contrastive learning of representations via graph neural networks. *Nat. Mach. Intell.* 4, 279–287 (2022).
24. Beaini, D. et al. Towards Foundational Models for Molecular Learning on Large-Scale Multi-Task Datasets. Preprint at <http://arxiv.org/abs/2310.04292> (2023).
25. Vaswani, A. et al. Attention Is All You Need. Preprint at <http://arxiv.org/abs/1706.03762> (2017).
26. He, P., Liu, X., Gao, J. & Chen, W. DeBERTa: Decoding-enhanced BERT with Disentangled Attention. Preprint at <http://arxiv.org/abs/2006.03654> (2020).
27. Huang, K. et al. Artificial intelligence foundation for therapeutic science. *Nat. Chem. Biol.* 18, 1033–1036 (2022).
28. Morgan, H. L. The generation of a unique machine description for chemical structures—A technique developed at chemical abstracts service. *J. Chem. Doc.* 5, 107–113 (1965).
29. Landrum, G. A. RDKit: Open-source cheminformatics. <https://doi.org/10.5281/zenodo.7671152> (Zenodo, 2023).
30. Liu, X., Ye, K., van Vlijmen, H. W. T., Ilzerman, A. P. & van Westen, G. J. P. DrugEx v3: scaffold-constrained drug design with graph transformer-based reinforcement learning. *J. Cheminform.* 15, 24 (2023).
31. Ying, C. et al. Do transformers really perform badly for graph representation? *Adv. Neural Inf. Process. Syst.* 34, 28877–28888 (2021).
32. Devlin, J., Chang, M.-W., Lee, K. & Toutanova, K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. Preprint at <http://arxiv.org/abs/1810.04805> (2018).
33. Irwin, J. J. et al. ZINC20—A Free Ultralarge-Scale Chemical Database for Ligand Discovery. *J. Chem. Inf. Model.* 60, 6065–6073 (2020).
34. Sun, J. et al. ExCAPE-DB: An integrated large scale dataset facilitating Big Data analysis in chemogenomics. *J. Cheminform.* 9, 1–9 (2017).
35. Brown, N., Fiscato, M., Segler, M. H. S. & Vaucher, A. C. GuacaMol: Benchmarking Models for De Novo Molecular Design. *J. Chem. Inf. Model.* 59, 1096–1108 (2018).
36. Haviv, A., Ram, O., Press, Ofir, Izsak, P. & Levy, O. Transformer Language Models without Positional Encodings Still Learn Positional Information. Preprint at <http://arxiv.org/abs/2203.16634> (2022).
37. Lasri, K., Lenci, A. & Poibeau, T. Word Order Matters when you Increase Masking. Preprint at <http://arxiv.org/abs/2211.04427> (2022).
38. Tian, H., Ketkar, R. & Tao, P. ADMETboost: a web server for accurate ADMET prediction. *J. Mol. Model.* 28, 408 (2022).
39. Wang, B., Wang, A., Chen, F., Wang, Y. & Kuo, C.-C. J. Evaluating word embedding models: methods and experimental results. *APSIPA Trans. Signal Inf. Process.* 8, e19 (2019).
40. Pierrejean, B. & Tanguy, L. Towards qualitative word embeddings evaluation: Measuring neighbors variation. In Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Student Research Workshop (Association for Computational Linguistics, 2018).
41. Gaulton, A. et al. ChEMBL: a large-scale bioactivity database for drug discovery. *Nucleic Acids Res.* 40, D1100–7 (2012).
42. Mayr, A. et al. Large-scale comparison of machine learning methods for drug target prediction on ChEMBL. *Chem. Sci.* 9, 5441–5451 (2018).
43. Hendrycks, D. & Gimpel, K. Gaussian Error Linear Units (GELUs). Preprint at <http://arxiv.org/abs/1606.08415> (2016).
44. Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I. & Salakhutdinov, R. Dropout: A Simple Way to Prevent Neural Networks from Overfitting. *J. Mach. Learn. Res.* 15, 1929–1958 (2014).
45. Kipf, T. N. & Welling, M. Semi-Supervised Classification with Graph Convolutional Networks. Preprint at <http://arxiv.org/abs/1609.02907> (2016).
46. Xiong, Z. et al. Pushing the Boundaries of Molecular Representation for Drug Discovery with the Graph Attention Mechanism. *J. Med. Chem.* 63, 8749–8760 (2020).
47. Méndez-Lucio, O., Nicolaou, C. & Earnshaw, B. MolE: A Foundation Model for Molecular Graphs Using Disentangled Attention (Code). <https://doi.org/10.5281/ZENODO.13891642> (Zenodo, 2024).
48. Méndez-Lucio, O., Nicolaou, C. & Earnshaw, B. MolE: A Foundation Model for Molecular Graphs Using Disentangled Attention [Source Code]. <https://doi.org/10.24433/CO.2928188.v1> (CodeOcean, 2024).

致谢

作者感谢杰克·施密特、基安·肯扬·迪恩和埃斯特法尼亚·巴雷托-奥赫达提供的工程支持。感谢 Recursion 公司的所有高性能计算团队成员，尤其是亚历山大·蒂莫菲耶夫、布伦特·加夫里卢伊克和乔舒亚·弗莱尔，他们一直致力于将 BioHive 计算机集群保持在最佳状态，以运行所有相关程序。

在此项工作中，感谢蒂博·瓦兰、萨拉·卡尔巴莱伊哈尼和玛丽亚·埃琳娜·加西亚·奥查加维亚作为早期用户提供的反馈，以及所有帮助改进和测试此项目的人员。

作者贡献

O.M.L. 和 B.E. 提出了这个想法并规划了项目。O.M.L. 编写了代码并进行了实验。O.M.L.、C.N. 和 B.E. 共同撰写了论文，并进行了富有见地的讨论，这有助于完善最初的想法。

利益冲突

O.M.L.、C.N. 和 B.E. 在开发此项目时是 Recursion 公司的员工。

附加信息

补充信息：在线版本包含补充材料，获取链接为 <https://doi.org/10.1038/s41467-024-53751-y>。

来信及索取资料请寄给奥斯卡·门德斯 - 卢西奥或伯顿·厄恩肖。

《自然·通讯》感谢 Jinho Chang 以及另一位匿名审稿人对本稿件的评审工作。审稿文件可供查阅。

有关转载和使用许可的信息，请访问 <http://www.nature.com/reprints>。

出版者注：施普林格·自然对于所发表的地图中涉及的管辖权主张以及机构隶属关系不持立场。

开放获取 本文依据知识共享署名 - 非商业性使用 - 禁止演绎 4.0 国际许可协议发布，该协议允许任何非商业用途的使用、分享、分发和复制，只要您适当署名原作者和来源，提供知识共享许可协议的链接，并说明是否对许可材料进行了修改。未经本许可协议许可，您无权分享基于本文或其部分内容改编的材料。除非材料的版权信息中另有说明，本文中的图片或其他第三方材料均受本文知识共享许可协议的约束。如果材料未包含在本文的知识共享许可协议中，且您的使用意图不受法定法规的允许或超出许可范围，您需要直接从版权所有者处获得许可。如需查看此许可协议的副本，请访问 <http://creativecommons.org/licenses/by-nc-nd/4.0/>。

© 作者（们）2024 年